

# Резюмета по стъпки

---

Изследване на възможностите за приложение на изкуствения интелект в  
компютърни игри

Александър Андреев

Юли 2026

# Резюмета по стъпки

## Съдържание

|                                                                                                   |    |
|---------------------------------------------------------------------------------------------------|----|
| Стъпка 1 Резюме - Основи на обучението с подкрепление.....                                        | 3  |
| Стъпка 2 Резюме - Теория на игрите и основи на CFR.....                                           | 4  |
| Стъпка 3 Резюме - Варианти на CFR и методи на Монте Карло .....                                   | 5  |
| Стъпка 4 Резюме - Абстракция на игри и мащабиране .....                                           | 6  |
| Стъпка 5 Резюме - Невронни мрежи за игри с непълна информация .....                               | 7  |
| Стъпка 6 Резюме - Архитектури на игрови ИИ от край до край .....                                  | 8  |
| Стъпка 7 Резюме - Моделиране на противника .....                                                  | 9  |
| Стъпка 8 Резюме - Безопасна експлоатация .....                                                    | 10 |
| Стъпка 9 Резюме - Обучение с подкрепление за множество агенти .....                               | 11 |
| Стъпка 10 Резюме - Обучение, базирано на популации, и еволюционна теория на игрите.....           | 12 |
| Стъпка 11 Резюме - Динамично формиране на коалиции в състезателни игри всеки срещу всеки .....    | 13 |
| Стъпка 12 Резюме - Последователни модели и агенти с голям езиков модел в стратегически среди..... | 14 |

# Стъпка 1 Резюме - Основи на обучението с подкрепление

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

April 2026

**Проблем.** Всичко по-нататък в този план - намиране на **невронно** равновесие (Стъпка 5), изпълнителният механизъм с модел на противника (Стъпки 7–8), многоагентно обучение (Стъпка 9) - се основава на мрежи за стойност, градиенти на стратегията и повторение на натрупан опит. Стъпка 1 полага основите: как един агент подобрява стратегията си само въз основа на награда в напълно наблюдаема едноагентна среда, преди тази картина да бъде усложнена от втори, скрит, състезателен играч. Тя косвено подпомага Принос №1 (архитектурните модели се използват повторно от адаптивния модел на противника) и директно осигурява речниковия запас за изпълнение, който всяка следваща стъпка предполага.

**Подход.** По един алгоритъм от всяко семейство, написан от нулата в pyTorch: **DQN** (базиран на стойност, извънполитиков) върху `cartPole-v1` - q-мрежа [4->128->128->2], кръгов буфер за повторение на опит, замразена целева мрежа, синхронизирана на всеки 5 епизода - и **PPO** (градиент на политиката, политика на работа) върху `lunarLander-v3` - отделен актьор [8->128->128->4] и оценител, GAE ( $\lambda=0.95$ ) чрез обратно обхождане, изрязан заместител при  $\epsilon=0.2$ . Всеки от тях беше сравнен с неговия аналог от **stable-Baselines3** при съответстващи основни хиперпараметри и бюджети за стъпки (DQN 750K, PPO 500K), като резултатът се оценява по най-доброто плъзгащо средно от 100, така че ранното спиране да не може да повлияе на крайния резултат. **Всички числа по-долу са измерени.**

**Ключови резултати (измерени).**

- *И двете цели са постигнати.* DQN решава **cartPole** на **епизод 1011**, със средна стойност за 100 епизода **477.5** (цел 475); PPO решава **lunarLander** на **264,192 стъпки** при **202.2** (цел 200) - 236K стъпки в рамките на бюджета.
- *Версиите, написани от нулата, превъзхождат настройките по подразбиране на SB3 при тези задачи.* Най-добро плъзгащо средно от 100: DQN **477.5 срещу 293.9**, PPO **203.6 срещу 131.2**. Причината е алгоритмична, а не несправедливо настройване: намаляване на **епсилон** на база епизоди спрямо намаляване на база стъпки при SB3, адаптивна **синхронизация на целта** (5 епизода са приблизително 100 стъпки по-рано и около 2500 след решаването) спрямо фиксирани 1000 стъпки, както и **ранно спиране** вместо изпълнение на пълния бюджет.
- *$\epsilon_{\text{min}}$  беше решаващият параметър за DQN.* При стойност 0.01 изпълнението достигна връх от **479.1** (епизод 810) и спадна до **302.6**; 0.001 плюс **най-добър модел с контролна точка** превърна влошаващата се стратегия в стабилна.
- *Капацитетът, а не бюджетът, беше тясното място за PPO.* [64, 64] достигна връх от **179.9** и никога не премина 200; [128, 128] го преодоля. **Нормализиране на предимството** се оказа незаменимо при награди в диапазона -500 до +300, а без **бонус за ентропия** от 0.01 стратегията колабираше до задържане на място.
- *Честно тълкуване на сравнението.* Настройките по подразбиране на SB3 са настроени за **устойчивост** в различни среди, а не за класически контрол; неговият PPO все още се покачваше при 500K и вероятно би достигнал целта при 1–2M стъпки. Твърдението е за специфично предимство на задачата, а не за по-добър алгоритъм.

**Връзка с дисертацията.** Стекът от 300–500 реда (срещу около 10,000 при SB3) е съзнателно платената цена за висока степен на модифицируемост: вмъкването на наблюдения на състоянието на убежденията в актьор-оценител изисква дълбоко подклаждане в рамките на SB3, докато тук това се свежда до локална редакция - точно от какво има нужда работата по експлоатацията в стъпки 7–8. Същата двойка актьор-оценител се използва отново като MAPPO/MADDPG в стъпка 9, а механизмът на мрежата за стойност се появява повторно като мрежа за предимства на Deep CFR в стъпка 5.

**Отворени въпроси.** Предположението на MDP, което прави всичко това възможно - напълно наблюдаемо състояние - е именно това, което покерът нарушава: върху информационно множество  $\mathcal{m}$  на DQN и стратегията по състояния на PPO са и двете некоректно дефинирани, поради което стъпка 2 променя инструмента, а не мащаба. Остава отворен въпросът: доколко от набора инструменти за стабилност при един агент (целеви мрежи, доверителни региони, нормализиране на предимството) се запазва, когато средата сама по себе си е учаш се агент (отложено за нестационарността в стъпка 9), и дали измереното тук предимство по отношение на изискванията за проби е реално свойство или артефакт на две малки, добре обусловени задачи за контрол.

# Стъпка 2 Резюме - Теория на игрите и основи на CFR

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

April 2026

**Проблем.** Механизмите от Стъпка 1 предполагат напълно наблюдаемо състояние и стационарна среда; покерът няма нито едното, нито другото. Двуйгровите игри с нулева сума с непълна информация изискват различна концепция за решение - равновесие на Наш, дефинирано върху *информационни множества* - и различен показател за качество: експлоатируемост, а не награда. Стъпка 2 установява и двете, както и алгоритъма, който ги изчислява, тъй като всичко след това представлява или приближение на CFR (Стъпки 3–5), умишлено отклонение от равновесието, което произвежда CFR (Стъпки 7–8), или опит да се дефинира какво всъщност означава равновесие, когато  $N > 2$  (Стъпки 9, 11).

**Подход.** Обикновен вариант на CFR, написан от нулата за **Кун покер** - 3 карти, 2 играчи, 12 информационни множества: достатъчно малък, за да има равновесие *семејство* в затворена форма (параметризирано чрез  $\alpha$  в  $[0, 1/3]$ ), и достатъчно богат, за да включва блъфване, смесени стратегии и безразличие. Ръчно кодирани компоненти: игровият двигател, рекурсивно контрафактивно обхождане с напасване на съжалението и вероятностна извадка, както и оценка на точната експлоатируемост чрез изброяване на всички  $2^6 = 64$  чисти стратегии - тъй като „предсказвач“ най-добър отговор за всяко състояние *не е* най-добрият отговор; най-добрият отговарящ трябва да се ангажира с едно действие на информационно множество. Обучен за 100,000 итерации, с OpenSpiel скрипт за кръстосана проверка. **Всички числа по-долу са измерени** (implementation/step02/models/cfr\_results.json).

## Ключови резултати (измерени).

- *CFR попада вътре в аналитичното равновесно семејство, а не просто близо до него.* Възстановеният параметър за блъф е  $\alpha = 0.1941$ , а вътрешното ограничение на самото семејство  $P(\text{bet} \mid K) = 3 \cdot \alpha$  се запазва до **2.6e-4** (измерено **0.58247** спрямо **0.58221**, което собствената му алфа предполага).
- *Чистите решения сходяват бързо; смесените честоти носят  $O(1/\sqrt{T})$  опашката.* Поп залага и плаща на  $\geq 0.9999$ , Вале пасува при залог на **0.99998**, Дама предава в корена на **0.99993** - докато смесването е **0.002–0.011** извън затворената форма (блъф на Вале след пас **0.3403** срещу  $1/3$ ; плащане на Дама **0.5387** срещу  $1/3 + \alpha = 0.5274$ ). Честотите са бавната част, което е точното място, където се проявява остатъчното съжаление.
- *Стойност на играта -0.0602*, измерена спрямо точната  $-1/18 = -0.0556$  при 100k итерации, възпроизвежда структурното първоначално предимство на Играч 0.
- *Скорост на сходимост е теоретичната.* Лог-лог наклон на експлоатируемостта **-0.489** спрямо предвидените **-0.5**.
- *Само стойността на играта не е проверка за валидност.* Стратегия, която винаги блъфира с Вале, все още може да се усредни близо до  $-1/18$ , като същевременно е тривиално експлоатируема; само експлоатируемостта я улавя. Ето защо експлоатируемост - а не награда - е показателят, който се пренася в Стъпки 7–8 и 14.

**Връзка с дисертацията.** Равновесието на Наш е отправната точка, от която тази дисертация се стреми да надгради: Принос №1 анализира конкретен противник, за да обоснове отклонението от него, а Принос №2 определя границите на това отклонение. Конкретно, точният код за най-добър отговор и експлоатируемост, разработен тук, се използва като буквален предсказвач в Стъпки 7–10, а Кун покер остава най-малката тестова среда, в която всяко следващо твърдение може да бъде проверено чрез точен отговор.

**Отворени въпроси.** Защо *средната* стратегия сходи, когато текущата не го прави - интуицията (усредняването потиска превишаването, както усредняването на Поляк) не е доказателство. Всичко тук се основава на теоремата за минимум в игра за двама с нулева сума и нито гаранцията на CFR, нито смисълът на експлоатируемостта се запазват при  $n$ -игрени или игри с обща сума (Стъпки 9, 11). А пълното обхождане на дърво засяга всяко информационно множество при всяка итерация, така че този точен алгоритъм вече е извън възможностите само една игра по-нагоре - мотивацията за извадката по метода Монте Карло в Стъпка 3 и абстракцията в Стъпка 4.

# Стъпка 3 Резюме - Варианти на CFR и методи на Монте Карло

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

April 2026

**Проблем.** Обикновеният вариант на CFR от Стъпка 2 обхожда всяко информационно множество при всяка итерация, което става недостъпно дори само една игра над Кун. Двата подхода в областта са метод с по-добра константа за пълно обхождане (**CFR+**) и *извадка* от дървото на играта (**MCCFR**), като общоприетото мнение е, че именно извадката направи решаването на реален покер възможно. Стъпка 3 поставя въпроса кой от двата метода всъщност се представя по-добре, при какъв размер на играта и защо - отговорът на този въпрос определя решавача, върху който ще се надграждат всички следващи стъпки.

**Подход.** Всички четири алгоритъма са ръчно кодирани на Python + NumPy върху **Ледюк покер** (6 карти, два рунда за залагане, една разкрита обща карта, 936 информационни множества, 10,200 възела, 120 раздавания): обикновен вариант на CFR, CFR+ (подово ограничаване на съжалението, линейно осредняване, редуващи се актуализации), MCCFR **външно вземане на проби** (всички действия на `traverse`-а, едно случайно избрано действие на противника) и MCCFR **извадка по резултати** (една корен-краен траектория,  $\epsilon = 0.6$  политика на работа смес с корекция чрез важноствено вземане на проби). Оценявани са чрез точен най-добър отговор, ограничен до информационни множества, при общ **бюджет в реално време от 180 секунди**, като OpenSpiel се използва за референтен решавач. **Всички числа по-долу са измерени.**

**Ключови резултати (измерени).**

- **CFR+ е работният кон и не е близо до останалите.** При по същество същия брой итерации като обикновения вариант на CFR (3,706 срещу 3,713), CFR+ достига  **$2.6e-5$**  експлоатируемост спрямо  **$4.4e-3$**  на обикновения - приблизително **170 пъти** по-добър резултат, благодарение на три локализирани промени в кода.
- **MCCFR губи сериозно при този размер на играта.** Външното вземане на проби достига  **$5.5e-2$**  след **3.5 милиона** итерации, а извадката по резултати  **$1.0e-1$**  след **8.3 милиона** - три до четири порядъка по-лошо от пълното обхождане въпреки **~1,000 пъти** повече итерации.
- **Причината е дисперсията, а не скоростта, и тя е количествено определена.** Извадката е  **$945x / 2\,228x$**  по-евтина на итерация, но се нуждае от  **$\sim 99\,000x / \sim 520\,000x$**  повече от тях. Преобразувано в константа за реално време  $C_w = C/\sqrt{\text{speed}}$ : **0.075** (обикновен вариант) срещу **0.767** и **1,143** - извадката е  **$10.2x / 15.3x$**  по-бавна за постигане на дадена точност.
- **Пресечната точка може да бъде изведена и Ледюк е далеч под нея.** Извадката достига равновесие при приблизително **2.1 милиона възела** (външна) и **4.8 милиона** (по резултати); 10,200-те възела на Ледюк са  **$210x / 466x$**  твърде малко, докато лимит холдем ( $\sim 1e14$ ) е с порядъци откъд нея. Това съгласува „MCCFR беше от съществено значение за реалния покер“ с „MCCFR губи тук“ - един и същ алгоритъм, но от противоположната страна на линията.
- **Кръстосано валидиран спрямо OpenSpiel** при съпоставен бюджет от 500 итерации: обикновен вариант **0.020** срещу **0.022**, CFR+  **$8.6e-4$**  срещу  **$9.4e-4$** .
- **Една измерена аномалия остава необяснена.** Обикновеният вариант на CFR надминава собствения си най-лош случай: предполагаемата константа  $\epsilon \cdot \sqrt{T}$  пада от **0.90** ( $T=100$ ) до **0.27** ( $T=3,700$ ), вместо да остане постоянна, така че границата  $O(1/\sqrt{T})$  тук е по-слаба, отколкото самата граница предвижда.

**Връзка с дисертацията.** Тази стъпка установява инструментариума за всичко последващо: **Ледюк**, заедно с точния **най-добър отговор**, се превръщат в стандартната тестова среда за стъпки 7–12, а **CFR+** става **наш** референтният алгоритъм, спрямо който всяко по-късно моделиране на противника, **безопасна експлоатация** и число, свързано с **голям езиков модел**, ще бъдат съпоставяни. Компромисът между точност и **дисперсия**, измерен тук, се появява отново в стъпка 5, където извадените оценки захранват **мрежа** вместо таблица.

**Отворени въпроси.** Дали броят на възлите при пресечната точка е свойство на самите алгоритми или на константните фактори в тази конкретна имплементация - векторизиран или компилиран решавач за пълно обхождане променя `speed_v` и измества прага, така че стойността е валидна само за този код и все още не може да се приеме като твърдение за алгоритмите по принцип. Коя схема на извадка ще се окаже най-устойчива, когато стратегията се представя чрез невронна мрежа вместо таблица (стъпка 5). И защо обикновеният вариант на CFR достига сходимост по-бързо от предвиденото в неговия най-лош случай.

# Стъпка 4 Резюме - Абстракция на игри и мащабиране

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

May 2026

**Проблем.** Стъпка 3 установи, че обхватът на решавача е ограничен от размера на дървото, поради което класическият път към реалния покер не е по-добър решавач, а *по-малка игра*: свийте я, решете сведената версия, преведете стратегията обратно и платете данък експлоатируемост за разликите, които сте изхвърлили. Стъпка 4 измерва този данък. Въпросът не е „помага ли абстракцията“, а коя ос на компресия е безопасна и дали изчислителната мощност, спестена от намалението, някога ще компенсират загубената стратегическа информация.

**Подход.** Конвейер тип „Ледюк“, който компресира по три оси и оценява всяка получена стратегия **в собствената ѝ пълна игра: беззагубен изоморфизъм на боите** (изплащанията в Ледюк зависят единствено от ранга и дали тайната карта съвпада с борда, така че информационните множества с изоморфни бои се сливат без загуба), **загубено групиране на карти** (характеристика за силата на ръката, разстояния от ЕМД тип, k-средни, в режими на перфектно и неперфектно извикване) и **абстракция на действията плюс преобразуване** (най-близко действие, вероятно разпределение, псевдохармонично) върху Mini-NL Ледюк с променлив залог. Тестван с CFR+ при общ бюджет от **180 секунди**, 3 семена, върху Ледюк с фиксиран лимит, Mini-NL Ледюк и 4-рангов Extended Ледюк. **Всички числа по-долу са измерени.**

**Ключови резултати (измерени).**

- *Беззагубната компресия е най-ценният ход и печели, като осигурява повече итерации.* Изоморфизмът на боите намалява Ледюк с фиксиран лимит от **936 до 288** информационни набора и достига **3.13e-6** експлоатируемост спрямо **4.44e-5** на пълния CFR+ за същото време на часовника - защото завършва **14,185** итерации вместо **2,655**. Потвърдено в по-голям мащаб върху Extended Ледюк: **10,304 -> 2,968** информационни набора (-71%), **0.0272 -> 0.00126**, приблизително 6 пъти повече итерации.
- *Загубените клъстери за карти поставят таван, който изчислителната мощност не може да преодолее.* k2 **0.571**, k3 **0.382**, k5 **0.382** - всички при 11,000+ итерации, т.е. 4 пъти повече решаване от пълната игра и четири порядъка по-лошо. Грешката е в абстракцията, а не в бюджета.
- *Абстракция на действията е опасната ос.* Mini-NL: пълната игра с 4,704 информационни набора достига **0.00692**, докато абстракцията на действията с 936 информационни набора достига **0.673** въпреки 5 пъти повече итерации - приблизително **100 пъти по-лошо** за дърво, което е 5 пъти по-малко. Extended Ледюк е още по-драстичен: suit+action **4.696** и suit+action+buckets **4.734**, и двете далеч по-лоши от простото решаване на неабстрахираната игра. Грешката в превода доминира общата стойност.
- *Измерен артефакт, а не закон.* k5 съвпада точно с k3, защото пост-флоп разпределенията на силата на ръката в Ледюк се свиват до три ефективни форми; подреждането по брой клъстери за карти, наблюдавано тук, е свойство на тази малка игра.
- *Посочени ограничения.* CFR+ е детерминистичен, така че трите семена не са независими стохастични изпълнения; числата за абстракция на действията зависят от текущия преводач и семантиката на внедряване и трябва да се разглеждат като диагностичен режим на отказ; а сравнението с OpenSpiel подравнява всички 936 информационни набора като проверка за коректност, а не като доказателство за идентична динамика на решавача.

**Връзка с дисертацията.** Преносимата част е форматът на представяне на резултатите: качеството на стратегията е безсмислено без посочения размер на играта, а парето границата между тях представлява ранно начално число за методологията за оценяване в принос №3. Механизмът също се пренася - базираното на типове моделиране на противника от стъпка 7 е същата идея „групирай за постигане на управляемост“, но вече приложена от пространството на състоянията към пространството на стратегиите, а неговият уверен, но погрешен неуспех представлява неправилна спецификация на преобразуването на действие в друга форма.

**Отворени въпроси.** Статичният превод е крехък по конструкция, поради което под-играта и вложеното решаване (Стъпка 6) се явяват производствено решение за действия извън дървото. Дали наблюдаваната тук йерархия - абстракция на карти оцеляваща, абстракция на действията разрушителна - ще се запази и в игра с достатъчно разнообразие на силата на ръката, така че k5 действително да се различава от k3. И дали една абстракция може да бъде адаптирана към противника, вместо да бъде фиксирана предварително, което е мястото, където тази стъпка докосва директно адаптивната рамка.

# Стъпка 5 Резюме - Невронни мрежи за игри с непълна информация

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

May 2026

**Проблем.** В стъпки 2–4 стратегията се съхранява като таблица, индексирана по информационно множество, а в стъпка 4 беше показано, че и двата начина за избягване на тази таблица - чрез използване на по-добър решаващ или чрез ограничаване до по-малка игра - се оказват недостатъчни. Третият подход е да се спре изброяването: вместо таблицата със съжалението да се използва апроксиматор на функции, който *обобщава* подобни информационни състояния при фиксиран обем памет. Стъпка 5 разглежда тази подмяна - Deep CFR, неговите варианти с една мрежа, NFSP - и какви са цената и компромисите по отношение на гаранциите.

**Подход.** Обхватът, заявено честно: **тази стъпка приключи след изследване и четене - няма имплементация от нулата на Фаза 4 и няма отчет за имплементацията**, а заключителният синтез на проучването все още е заготовка. Измерената работа е двудневно изследване срещу референтните решаващи двигатели на OpenSpiel върху Ледюк и Кун - Deep CFR при три размера на мрежата, NFSP и в двете игри, табличен MCCFR и CFR+ като базови линии - оценявани по собствената експлоатируемост на OpenSpiel, така че директният сблъсък да е честен (MCCFR от стъпка 3 работи върху персонализиран двигател и не е сравним). **Всички числа по-долу са измерени** (implementation/step05/exploration/logs/day0{1.2}\_results.json).

**Ключови резултати (измерени).**

- *Най-същественният артефакт от стъпката е грешка в библиотеката.* DeepCFRSolver на pyTorch в OpenSpiel 1.6.12 **никога не обучава своите мрежи за предимства**: `if len(samples.info_state == 0)` взема `len` от елементно сравнение, което винаги е истина, така че връща преди стъпката на оптимизатора. Загубите за предимство се връщат мълчаливо като `None`, а експлоатируемостта остава на нивото на случайна стратегия (~1.69) независимо от броя итерации. Поправено е с една промяна на символ, локално закръпено.
- *Където таблицата се побира, таблицата печели - убедително.* Ледюк при сравнимо реално време: CFR+ **0.00123** (400 итерации, 92 s), табличен MCCFR **0.0967** (50,000 итерации, 68 s), Deep CFR **1.49–1.70** (120 итерации, ~95 s), NFSP **2.46** (50,000 епизода) - CFR+ е приблизително **1400 пъти** по-добър от Deep CFR.
- *Тези невронни числа са артефакти на бюджета, а не присъди.* Кривите на Deep CFR са плоски от итерация 30 до 120, където в статията се използват 400+, а собственият пример на OpenSpiel за NFSP Ледюк работи с **2e7** епизода - **400 пъти** нашия бюджет. Прието правило: недоверявайте се на крива на NFSP Ледюк под ~1e6 епизода.
- *По-малката мрежа спечели при този бюджет.* (32, 32) **1.1441** победи (64, 64) **1.7002** и (128, 128, 128) **1.4908** - съгласувано с недообучен резултат при малко различни извадки и се очаква да се обърне с повече итерации.
- *Как изглежда недообучението вътре в политиката.* Срещу 400-итерационен еталонен тест CFR+, Deep CFR при 40 итерации има **медианна обща вариация 0.35** за 8 взети извадкови информационни множества на Ледюк (диапазон 0.163–0.708): посоката на всяко решение обикновено е правилна, но вероятностите са дръпнати към равномерни (**0.73/0.27**, където CFR+ е **0.92/0.07**) - регресия по средноквадратична грешка върху шумни контрафактични извадки води до недоверено изглаждане на равновесието.
- *Структурата на разходите, която оправдава семейството въпреки всичко.* Една външна итерация на Deep CFR струва **~0.7 s** срещу **~1.4 ms** (~500 пъти) за една итерация на табличен MCCFR, но работата му за итерация е приблизително постоянна спрямо размера на играта, докато табличните разходи се мащабират с броя информационни множества. Ледюк е учебен еталонен тест, където невронните методи губят от базови линии, които никога не са били предназначени да победят.

**Връзка с дисертацията.** Мрежата за предимства на Deep CFR представлява мрежата за стойности от стъпка 1, но с контрафактична цел - връзката, която позволява на стъпки 6–8 да надхвърлят игрите с табличен размер. По-точно, недовереното изглаждане, наблюдавано тук, е режимът на отказ, който стъпка 7 впоследствие оценява: модел с правилна посока, но грешна честота, води до това най-добре реагиращият към несъвършено четене да загуби от наш равновесие.

**Отворени въпроси.** Собствената бариера на стъпката остава непреодоляна: ръчно кодиран **Deep CFR** с Vitter резервоарен **извадков модул** и **извадка по резултати** на **DREAM** с **изваждане на базова линия**, и двете все още не са реализирани, така че въпросът „мога ли да го изградя“ остава без отговор. Непроверено е дали табличното спрямо **невронното** подреждане се обръща точно при преминаването на броя възли в стъпка 3 и дали структурата на тензора на информационните състояния наистина има по-голямо значение от **дълбочината на мрежата**.

# Стъпка 6 Резюме - Архитектури на игрови ИИ от край до край

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

June 2026

**Проблем.** Стъпки 2–5 разглеждаха отделни компоненти - варианти на CFR, абстракция, неврално приближение на стойност - без да се изследва как те се комбинират в системата, способна да побеждава хора, или какви гаранции предоставя такава система. Стъпка 6 представя обзор на пет архитектури от състезателно равнище за периода 2017–2023 г., разглеждайки ги като еволюция на проектните компромиси, а не просто като класация: това е съвременното равнище, върху което настоящата дисертация се опира и от което се различава.

**Подход.** Умишлено *архитектурно* изследване - какво всяка система изчислява **извън линия**, какво изчислява в реално време, къде се намира обучението, какво може да докаже - на **deepStack** (2017), **Libratus** (2017/18), **Pluribus** (2019), **Recursive Belief-based Learning** (2020) и **Student of Games** (2023), като всяка е оценена по същите девет измерения и поставена върху три оси: от **абстракция** към **невронно представяне**, от предварително изчисление към търсене в реално време, от игра с непълна информация само до унифицирана игра. **Тази стъпка не произведе код; всяко число по-долу е резултатът, който всяка статия съобщава, а не наше измерване**, и самата глава е изготвена, но все още не е окончателно одобрена.

**Ключови резултати (според съобщенията в статиите).**

- *Ерата на абстракцията се оказа далеч по-експлоатируема, отколкото резултатите ѝ в състезанията подсказваха.* Сондаж за най-добър локален отговор показва, че водещите състезателни ботове губят **над 3000 mbb/g** - няколко пъти повече от темпа на печалба, който ги правеше да изглеждат силни. Затварянето на тази разлика беше целта на десетилетието.
- *Търсенето при извод, а не предварителната стратегия, носи предимството.* Суровият план на Libratus **загуби** от Baby Tartanian8 с **8 mbb/g**; с включено вложено безопасно решаване на под-игри същата система **спечели с 63**, и победи четирима професионалисти със **147 mbb/g за 120,000 ръце**. Решаването на залози извън менюто в реално време също победи най-близкия по размер превод на действие **119 срещу 1465 mbb/g** в най-лошия случай - провалът на превода от Стъпка 4 беше поправен чрез отказ от превод.
- *Цената не е оста, за която изглежда.* DeepStack похарчи **~175 процесорно-ядрени години** за етикетирание на стойности и Libratus **~25 милиона ядро-часа**, докато планът на Pluribus струваше **~12,400 ядро-часа** - около **\$150** на един сървър - и въпреки това победи петима елитни професионалисти с **+48 mbb/g**.
- *Всеки напредък беше платен другаде.* Pluribus достигна шест играчи, като се отказа от **всички** гаранции за безопасност в полза на несигурно търсене; ReBeL възстанови двуигровата гаранция и елиминира както абстракцията, така и плана (Dong Kim **+165 mbb/g**), но се върна към двама играчи; Student of Games обедини игра с пълна и непълна информация по надежден начин (като победи сондажа за най-добър локален отговор с **+434 mbb/g**), докато остана **над 1100 Elo** под специалистите по Го - „цената на общността“, според авторите му. Никоя система не доминира всяка ос.
- *Единственият пропуск, който всичките пет споделят.* Всяка е **независима от противника по дизайн**: тя изчислява най-лошосценарийна устойчива стратегия и я играе безусловно. Системите, тествани срещу хора, го казват изрично, а Pluribus дори не знае срещу кого играе.

**Връзка с дисертацията.** Този споделен пропуск е отправната точка, която настоящата дисертация заема, а главата предоставя необходимите механизми за неговото запълване. **Общодостъпното състояние на вярванията** на ReBeL представлява основата, върху която Принос №1 разширява обхвата от убеждения относно картите до убеждения относно *типа* на противника, наследявайки доказателствата за коректност, свързани с него, вместо да добавя адаптация като външен елемент. Pluribus е аргументът на Принос №2, реализиран в рамките на една система: ако равновесието не осигурява безопасност при  $N > 2$ , отказът от експлоатация означава отказ от гаранция, която никога не е била валидна. Експлоатируемостта, LBR сондажът (преназначен от сертификат в стрес тест) и намаляването на дисперсията чрез AIVAT са три готови инструмента за Принос №3.

**Отворени въпроси.** Четири, директно от синтеза: самата **невидимост за противника** (Стъпка 7); **безопасна експлоатация извън двуигрова игра с нулева сума**, която Pluribus спечели без и Student of Games не можа да разшири (Стъпка 8); пренасяне на **модел на противника отвъд границата на дълбочината** вместо да се изхвърля във възел; и **изчислителни бюджети** в реално време, чието шест-редово разпределение най-силно ограничава агент, който трябва да преизчислява и да преоценява противника едновременно. Следствие: изграждане на евтино, с отворен произход - водещият код е непубликуван или със **свръхкомпютърен мащаб**.



# Стъпка 7 Резюме - Моделиране на противника

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

**Проблем.** Равновесната стратегия на Наш е неексплоатируема, но сляпа - тя се играе еднакво срещу всички и никога не наказва слаб противник. Моделирането на противника действа като сензор, който преобразува наблюдаваните действия в оценка на стратегията на конкретен противник, така че агентът да може да се отклони от равновесието с цел експлоатация - това е първата част от рамката за поведенческа адаптация, представена в дисертацията (Принос №1). Трудната част се състои в това да се постигне експлоатация, без самият агент да стане експлоатируем.

**Подход.** Байесов цикъл на актуализиране на убежденията (априорно  $\times$  правдоподобие  $\rightarrow$  апостериорно  $\rightarrow$  най-добър отговор), изграден зад един общ интерфейс, така че един точен най-добър отговор да може да бъде приложен към три взаимозаменяеми модела: (1) **типово базиран** - убеждение върху фиксирано меню от типове опоненти; (2) **непрекъснат** - свободно формирани Дирихле преброявания за всяка ситуация; (3) **съгласуван** - оценка чрез изпъкнала оптимизация в последователна форма (Ganzfried 2025). **Адаптивен експлоатер** изпълнява цикъла наблюдавай  $\rightarrow$  моделирай  $\rightarrow$  оптимално отговарям  $\rightarrow$  действай, със смес за безопасност на Наш и по избор детектор за точка на промяна за нестационарни опоненти. Тестови среди: Кун покер и Ледюк Холдем, и двете точно решими, така че всеки резултат е ограничен от точни аналитични препратки.

## Ключови резултати (измерени).

- *Моделирането си заслужава.* Равновесната игра оставя **0.11–0.28 на ръка** на масата срещу експлоатируеми Kuhn противници; разликата спрямо Nash противник е  $\sim 0$  (не можете да експлоатирате равновесие).
- *Когато класът на модела съвпада, най-добрият отговор достига абсолютния таван* - типово базираният модел е статистически неразличим от тавана на най-добрия отговор срещу всеки противник и в двете игри.
- *Уверен, но недообучен модел ви прави уязвими.* В Ледюк непрекъснатият модел **губи от Nash (-0.175 спрямо таван от -0.083)** - най-добре реагиращ на грешна оценка на неексплоатируем противник отваря пропуск в собствената си игра. Това е напрежението между експлоатацията и безопасността в едно число.
- *Увереността, съчетана с грешка, крие реален риск.* Срещу противник извън менюто типово базираното апостериорно твърдо се ангажира с най-близкия представим тип; при над 300 семена грешен тип доведе след ръка 100 в  $\sim 13\%$  от изпълненията (той винаги се коригира в крайна сметка и никога не пада, след като е заключен).
- *Нестационарността зависи от сценария.* Забравянето на точка на промяна спасява вреден остарял модел (Kuhn:  $-0.116 \rightarrow +0.226$ ), но се представя по-зле от простата адаптация, когато новият противник е експлоатируем и детекторът даде фалшива аларма (Ледюк). Реакцията има значение толкова, колкото и откриването.
- *Съгласуваност.* Съгласуваният модел възстановява Kuhn стратегиите точно (TV  $\sim 0.004-0.021$ ), но неговото изпъкнало решаване при всяка актуализация е твърде скъпо за онлайн цикъла в изградения вид - емпиричен отговор на въпроса за осъществимостта в реално време на тази стъпка, насочващ към постепенно решаване / приближения от Стъпка 8.

**Връзка с дисертацията.** Стъпка 7 изгражда **сензора** (модела), а Стъпка 8 - **изпълнителния механизъм** (безопасна експлоатация, регулирана с КЛ-дивергенция). Саморазкриването на наш равновесие в непрекъснатия модел е емпиричното обосноваване за този предпазен механизъм; теорията на съгласуваността представлява принципния гръбнак, върху който рамката се надгражда.

**Отворени въпроси.** Съгласувано моделиране в реално време (постепенна изпъкнала оптимизация); принципна нестационарност (мащабирано от доверие забравяне, по-добри сигнали за промяна); противници извън менюто (откриване на типове в отворен свят); преминаване от един към много противници (съвместният най-добър отговор не е комбинация от отделни и изпъкналата гаранция се нарушава при  $N > 2$ ).

## Стъпка 8 Резюме - Безопасна експлоатация

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

**Проблем.** Стъпка 7 изгради *сензора* - модел на противника - и показва неговата опасност: най-добре реагиращият към несъвършен модел може да отвори пропуск в собствената си игра (непрекъснатият модел *загуби* от наш равновесие в Ледюк). Стъпка 8 изгражда *изпълнителния механизъм*: превръщане на модел в печалба, **без да става експлоатируем**. Това е втората половина на рамката за поведенческа адаптация на дисертацията (Принос №1) и отправната точка за многоагентна безопасна експлоатация (Принос №2).

**Подход.** Всеки метод за безопасна експлоатация представлява една и съща програма - *максимизиране на очакваната стойност спрямо модела на противника при условие за праг на безопасност върху най-лошия стойностен случай* - която е линейна по отношение на последователната форма за реализация на героя. Един LP двигател я решава чрез **генериране на ограничения** (решаване → прочитане на политиката → извикване на точен най-добър отговор като най-лошия случай предсказвач → добавяне на разрез, ако е небезопасен → повторно решаване), използвайки повторно двигателите от Стъпка 7, най-добрия отговор, наш равновесие и „зоологията“ на противниците. Пет семейства се различават единствено по прага: **RNR** (настройваем  $p$ ), **Ganzfried** ( $\geq$  стойността на наш равновесие  $v^*$ ), **prime-safe** ( $\geq v^* - \epsilon$  за базова линия на  $\epsilon$ -равновесие), **SES** (стойност на плана, наложена локално върху под-игра чрез джаджа), **adaptation** (не по-експлоатируем от плана). Тестови среди: Kuhn и Ледюк, и двете точно решими, така че всеки резултат е ограничен от точни аналитични препратки. **Всички числа по-долу са измерени.**

**Ключови резултати (измерени).**

- **Безопасното използване работи в Kuhn. Ganzfried е безопасен срещу всеки противник** (най-лошият случай  $\geq v^*$  в рамките на  $1e-3$ ) **и превъзхожда собствената очаквана стойност на Наш за всеки експлоатируем тип** - например **+0.222 срещу +0.146 на Наш** при AlwaysPass. Пълният най-добър отговор носи повече (+0.975), но неговият най-лош случай се срива до **-0.5** (катастрофално експлоатируем). Това е централният валидиран резултат.
- $\epsilon$  **се измерва, а не се конструира**. Prime-safe/adaptation понижават прага до  $v^* - \epsilon$ , като експлоатируемостта на базовата линия се измерва при  $\epsilon = 0.0074$ , и печелят малко повече от Ganzfried, като използват този бюджет (+0.266 срещу +0.222 при AlwaysPass).
- **Каноничният RNR е превключващ, а не с гладка граница** (противоречащо предсказание). В игра толкова малка, LP max-min скача от безопасния връх право към пълния най-добър отговор при  $p \approx 0.7$  - гладката крива е на **наивното смесване**, и тя се доминира в безопасния ъгъл.
- **Заглавие - глобалната безопасна експлоатация не се мащабира; локалната да.** В **Ледюк**, глобалните решаващи (Ganzfried/prime-safe/adaptation) **не успяват да се сближат в рамките на 40 итерации** (най-лош случай **-0.64 до -1.33**, грубо небезопасен), докато **методът на под-играта (SES) се сближава** (194–350 итерации) и остава почти безопасен (най-лош случай  $\approx -0.13$ ), като същевременно извлича **+0.25 до +0.68** срещу слабите типове. Това е разрыв между теория и практика на глобалното и локалното равнище на безопасността, измерен върху миниатюрна игра.
- **Гаранцията за безопасност действа срещу най-лошия възможен противник, а не срещу добронамерен.** При обучаващата атака (примамка → разкриване на Наш), честният разграничителен сигнал е броят нарушения на безопасността (**full\_br 40/40 пренастройвания, Ganzfried 0/40**), а не осъществената печалба - нежен разкривател на равновесие на Наш никога не си връща вятърничавата печалба от фазата на примамка. За наказателен тест е необходим адаптивен контраексплойтър.

**Връзка с дисертацията.** Стъпка 7 представлява сензор; Стъпка 8 - изпълнителен механизъм. Резултатите на Кун потвърждават коректността на изпълнителния механизъм; несъходимостта на Ледюк е конкретният аргумент в полза на методи за под-игри в реално време (SES / OX-Search) и/или точна двойствена линейнопрограмна задача, като същевременно представлява емпиричния мост към мащабируемата многоагентна безопасна експлоатация от Принос №2.

**Отворени въпроси.** Мащабируема безопасност (точна двойствена линейнопрограмна задача срещу подлокална игра - стената на Ледюк); остатъчната експлоатируемост на приспособлението SES ( $0.04 > \text{tol}$  - доказуемо или само приблизително безопасен?); наказателна обучаваща атака (адаптивно разкриване); и **безопасност при  $n$  играчи** - всяка гаранция тук се основава на факта за двуйгрови игри с нулева сума, че равновесието на Наш осигурява  $v^*$  срещу всеки противник, котва, която изчезва при  $N > 2$  (Принос №2).

# Стъпка 9 Резюме - Обучение с подкрепление за множество агенти

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

**Проблем.** Стъпки 2–8 се развиваха в рамките на двуйгрови игри с нулева сума, където една наша стратегия осигурява стойност  $v^*$  срещу всеки и CFR доказуемо се сближава към нея. Стъпка 9 е повратната точка към многоагентния свят, където определящата трудност е **нестационарност**: всеки агент се учи едновременно, така че от гледната точка на който и да е агент средата (която съдържа останалите) никога не остава непроменена. Това е отправната точка за многоагентните приноси на дисертацията - динамично **моделиране на противника** (#1), **безопасна експлоатация** без **минимакс котва** (#2) и оценка на ниво **популация** (#3).

**Подход.** Изграждане и сравняване на четирите структурни отговора на полето на нестационарност върху малки, *точно решими* тестови среди, така че всеки обучаващ се да бъде оценен спрямо обективната истина. **Самостоятелно обучение** (контролният вариант, който се проваля) върху четири канонични матрични игри; **CTDE** - централизиране на оценителя по време на обучение и децентрализиране на актьора при изпълнение - чрез MADDPG и MAPPO върху кооперативни задачи; **PSRO** - игра, изиграна върху *популация* от политики (мета-Наш + предсказвач за най-добър отговор), като се използва точният най-добър отговор от Стъпка 07 както като предсказвач, така и като метрика за експлоатируемост - върху Kuhn, Ледюк, матрична игра и родна Goofspiel; **научена комуникация** (CommNet); и **LOLA** (диференциране през стъпката на обучение на противника) върху Итерирания дилема на затворника. **Всички числа по-долу са измерени.**

**Ключови резултати (измерени).**

- *Самостоятелното обучение се проваля точно там, където теорията предсказва.* То се сближава към Нашово равновесие при Дилемата на затворника (дефекция), Ловът на елени (рисково доминиращият ъгъл) и Битката на половите, но **игра „хвърляне на монета“ никога не се сближава** - разстоянието ѝ до Нашово равновесие всъщност *нараства* ( $0.30 \rightarrow 0.48$ ), което е по-рязко от предвидената несходимост (противоречиво предсказание, §9 от доклада).
- *PSRO е мостът между теория на игрите и MARL и работи върху малките игри.* Експлоатируемостта  $\rightarrow$  машинна нула при Kuhn ( $0.917 \rightarrow 2 \times 10^{-16}$ , 6 рунда),  $\rightarrow 0$  при матричната игра и Камък–ножица–хартия. Самообучението потвърждава механизма: при Kuhn **средният** итеративен NashConv пада до  $0.24 \rightarrow 0.031$ , докато **последният** итерат продължава да осцилира - затова е необходима популация/усредняване.
- *Централизиран оценител е почти нулев дисперсионен учител.* При CoopSignal остатъкът на централизирания оценител е  $3.2e-11$  срещу  $0.077$  на независимия оценител - потвърждение на твърдението за намаляване на дисперсията в CTDE.
- *Комуникацията премахва прага на отгатваемост.* CommNet с ВКЛЮЧЕН канал постига резултат  $0.795$  срещу  $0.204$  при ИЗКЛЮЧЕН (праг  $1/K = 0.2$ ) - научен, а не проектиран протокол.
- *LOLA превръща дефекторите в кооператори.* Възвръщаемостта на IPD за стъпка се повишава от  $1.04$  (наивна дефекция) до  $2.82$  (кооперация с LOLA); нулирането на предвиждането възстановява точно наивния градиент (проверка на механизма).
- *Честни отрицателни (запазени предсказания, §9).* PSRO при Ледюк намалява, но достига скалираща стена ( $4.75 \rightarrow 2.16$  след 20 рунда, а не  $<0.5$ ); **Goofspiel K=4** осцилира вместо да се сближава (отбелязана аномалия в кода, документирана, но не поправена); и при **изкачващата се игра** нито един метод не достига оптимума 11 (IL/MAPPO 7, MADDPG 5) - централизиран оценител намалява дисперсията, но сам по себе си не решава координацията при риск от прекомерно изследване.

Връзка с дисертацията. PSRO представлява итерирания най-добър отговор от Стъпка 2, издигнат до популационно равнище и служещ като емпиричен гръбнак на настоящата работа; LOLA е *динамично* моделиране на противника - допълнение към статичното четене от Стъпка 7, насочено към движеща се цел (Принос №1); мета-играта на PSRO е методология за оценка на популационно равнище (Принос №3). Стената на мащабиране при Ледюк отразява откритието глобално срещу локално от Стъпка 8, а мястото, където всяка двуйгрова гаранция престава да важи - **липсващата минимакс котва за  $N>2$**  - е именно проблемната постановка на Принос №2.

**Отворени въпроси.** Може ли приблизителен (RL) предсказвач да доближи Ледюк PSRO до Нашовото равновесие и каква е цената на тази гаранция? Какво прекъсва колебанието при Goofspiel-K=4 (премахване на дубликати? смесена популация? различен мета-решател?) и защо централизираният оценител *вреди* в изкачващата се игра? И под всичко това: без минимаксна стойност за  $N>2$ , какво означава „безопасен“ за една популация и може ли мета-играта на PSRO да осигури заместител (Принос №2)?

# Стъпка 10 Резюме - Обучение, базирано на популации, и еволюционна теория на игрите

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

**Проблем.** Самообучението може да се върти в кръг: в циклична игра (камък-ножица-хартия) „да станеш по-добър“ няма смисъл, така че популация, която тренира единствено срещу себе си, започва да се върти вместо да се подобрява. Стъпка 10 представлява оценка на популационно равнище - как да *диагностицираме* дали една игра/популация е скала на уменията или колело от броячи и как да *тренираме и оценяваме* цяла популация от агенти. Тя е отправната точка за автоматизирано моделиране на противника (#1), безопасна експлоатация на популационно равнище без минимакс котва (#2) и оценка на популационно равнище (#3).

**Подход.** Две части, и двете оценявани спрямо точни референции. **Част I - еволюционна теория на игрите като диагностика:** репликаторна динамика върху четири решими матрични игри (проверени спрямо аналитичния ESS/Наш) и транзитивната/цикличната **пумпал** декомпозиция. **Част II - лига от тип AlphaStar PBT** от невронни PPO агенти на Ледюк Холдем (три типа агенти: основен / експлоатер на основната стратегия / експлоатер на лигата, плюс замразяване и PFSP), оценявана с **EGTA/мета-Наш**, Ело и метрики за разнообразие - всяка невронна стратегия е извлечена в *таблична* стратегия, така че точният най-добър отговор от Стъпка 07 да измери нейната експлоатируемост. **Всички числа по-долу са измерени.**

**Ключови резултати (измерени).**

- *Репликаторната динамика възпроизвежда всеки аналитичен резултат.* Дилемата на затворника → всички „Дефект“; Ястреб–Гълъб → вътрешният 0.5 ESS (орбитален радиус 0.0); **камък-ножица-хартия никога не се сближава** (орбита на центъра, радиус 0.095); Лов на елен → басейнозависим чист ESS.
- *Диагностиката „пумпал“ работи и структурата на Ледюк зависи от популацията.* Декомпозицията на Ходж дава RPS транзитивни 0.0 / циклични 1.0 и скала на уменията 1.0 / 0.0 (методът SVD с ранг 1 неправилно дава RPS 0.707). Мета-играта **най-добър отговор** на PSRO върху Ледюк е предимно **циклична** ( $\approx 0.45$  транзитивни, 27 трицикли); мета-играта на **моментната снимка на лигата** е предимно **транзитивна** ( $\approx 0.94-0.98$ ) - противоречаща прогноза (§4/§7 от доклада).
- *Лигата произвежда силни индивиди.* Най-добрата и замразена моментна снимка достига експлоатируемост 1.305 (скала), надминавайки точния PSRO (2.163) и самообучението (3.683); CFR-Наш долната граница е 0.0099.
- *Честни отрицателни (запазени прогнози).* Експлоатируемостта на лигата е **немонотонна в мащаб** (4.73 → мин.  $\approx 1.21 \rightarrow 2.05$  за 120 епохи) - активните агенти регресират късно; най-добрите агенти са замразени моментни снимки. И **мета-Наш сместа е повече експлоатируема от най-добрия си член** в мащаб (3.418 > 1.305) - мета-Наш минимизира мета-игровото съжаление, а не пълната експлоатируемост на играта, така че смесването на поведенчески стратегии може да навреди. Разнообразието е слабо (коефициент на участие 1.9, един поведенчески клъстер).

**Връзка с дисертацията.** Лигата представлява PSRO от Стъпка 9, реализирано асинхронно чрез невронни предсказвачи, като използва точния най-добър отговор от Стъпка 07 като еталон; основните експлоататори са автоматизирани моделиращи съперника (Принос №1); EGTA/мета-Наш е методологията за оценяване на популацията (Принос №3). Липсващата гаранция на лигата - възможността ѝ да регресира и фактът, че нейната смес може да бъде експлоатируема - представлява популационната форма на **липсващия  $N > 2$  предпазен ограничител** (Принос №2). Транзитивната/циклична диагностика предсказва, че коалиционните игри всеки срещу всеки от Стъпка 11 ще бъдат силно циклични.

**Отворени въпроси.** Премахва ли **задържането на моментна снимка / регуляризацията на популацията** късната регресия (поправка в обучението), или тя е присъща на тритипния дизайн (поправка в дизайна)? Трябва ли една популация да изпрати избран **най-добър устойчив отговор елемент**, или **мета-решавател с регуляризация за разнообразие** вместо **мета-Наш сместа**? И подлежащо и на двете: при липса на **минимаксна стойност** за популацията, какво означава „безопасно“ и може ли **експлоатационният механизъм** да получи гаранция, вместо да остане **евристика** (Принос №2)?

# Стъпка 11 Резюме - Динамично формиране на коалиции в състезателни игри всеки срещу всеки

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

**Проблем.** Стъпки 2–10 се опираха на една опора: двуигрови игра с точен най-добър отговор и предсказвач за експлоатируемост, така че въпросът „проработи ли?“ имаше еднозначен числов отговор. С добавянето на трети играч възникват възможности за съюзи - тяхното формиране, експлоатация и предателство - докато **наш равновесие** става едновременно неразрешим и стратегически празен, тъй като изцяло пренебрегва коалициите. Стъпка 11 умишлено премахва тази опора. Това представлява границата на тезата, а не стъпка за консолидация.

**Подход.** Създаден е нативен 4-игрови **двигател „Со Лонг Съкър“** - играта от 1950 г., разработена от Неш, Шейпли, Шубик и Хауснер за изследване на съюзите - въз основа на формализацията на De Carufel & Jerade, като единствената му точна опора е **минимакс крайна игра**. Върху него са надградени: **детектор на коалиции** (оценяващ помощта или вредата от поставянето на чип), **стойност на Шейпли**, предефинирана като приноса на даден играч към вероятността за победа, **Coalition-Aware MAPPO** трениор, който комбинира наградата за коалиция и „всичко или нищо“ чрез тегло  $\alpha$ , както и анализ **eGTA + пумпал**, преизползван от Стъпка 10. **Всички посочени по-долу резултати са измерени**, с уточнението, че `scale_results.json` представлява **предварително коригиран** прогон, цитиран единствено като доказателство за грешката по-долу - авторитетните данни се съдържат в `sweep_scale.json` (5 семена) и след корекцията в `smoke_results.json`.

**Ключови резултати (измерени).**

- *Сертифицирано там, където съществува точност.* 100/100 случайни игри завършват, всички награди са **игра с нулева сума**, `endgame_mismatches`: 0 спрямо точния минимакс. Детекторът възстановява „**засадена**“ **коалиция {0.1}** единствено от потока ходове (оценка на двойката **10.0**, записи между двойките 0 или -1), а стойността на Шейпли точно възпроизвежда играчките „ръкавица“ и „мнозинство“, включително празнотата на ядрото.
- *Най-голямото откритие в тази стъпка е грешка, а нейният урок надживя самата нея.* Две червени проверки имаха една причина: **~99.5% от случайните игри завършват с патова ситуация**, така че победителят се определя от `_most_chips`, чиято **развръзка** по най-нисък индекс даваше на място 0 два пъти повече, отколкото му се полага (случайни победители [94, 42, 33, 31]). С безпристрастна развръзка симетричното разпределение на Шейпли спадна от **0.525 до 0.013**, а победителите станаха равномерни; същата поправка намали впечатляващия процент победи на героя от **0.87 до честен ~0.41** спрямо минимум от 0.25. В игра, която почти винаги завършва с равен резултат, правилото за развръзка е носещо.
- *„Коалициите не възникват в голям мащаб“ беше опровергано чрез намирането на правилния регулатор.*  $\alpha$  доминира и **стойността по подразбиране 0.3 попада в мъртва зона**: при  $\alpha \sim 0$  разликата в заместващия кредит е **+0.0376 +/- 0.0103** (~4.4 пъти по-голяма от оскъдните **0.0109**), докато **всяка клетка с  $\alpha \geq 0.3$  е отрицателна**. Ефектът **нараства** с размера на играта (~10 пъти при `smoke`), а евтиният заместващ показател за критична стойност превъзхожда скъпия контрафактичен кредит (**+0.038 срещу +0.013**).
- *Коалиционното поведение се купува, не е безплатно.*  $\alpha = 0$  намалява процента победи на героя до **~0.29**, по същество случаен минимум, докато  $\alpha \geq 0.1$  го поддържа на **~0.52**.
- *Силно цикличен, честно казано недостатъчен.* Пулът от нива на умения е транзитивно-доминантен (цикличност **0.25-0.31**), но коалиционният пул повишава цикличността до **~0.57-0.69** - голяма, но все още недостатъчна за спазване на строгото правило „>50% доминация“, така че проверката остава червена. Резултат: **4/5 ПРЕЗ**.

**Връзка с дисертацията.** Принос №1 се обобщава по естествен начин: **моделирането на противника** се разширява от „какъв тип играч е това“ към „с кого е в съюз“, което може да бъде изведено директно от последователността на ходовете. Принос №2 получава по-прецизно формулиран проблем, вместо решен - при **празно ядро** и липса на котва в **наш равновесие**, понятието „безопасен“ не може да се разбира като ограничено **отклонение от равновесие**, а трябва да бъде дефинирано в поведенчески или популационен смисъл (pIKL). Принос №3 получава работещ заместител на **експлоатируемост** чрез EGTA и **декомпозиция „пумпал“**, като наследява уговорката от Стъпка 10, че съставът на разглежданата **популация** определя дали ще се наблюдава йерархия или цикъл.

**Отворени въпроси.** Съгласуването на модела за **ход и развръзка на двигателя** с този на De Carufel & Jerade представлява най-ценното последващо действие - както грешката в място 0, така и червената **циклична проверка** се проследяват до документирани опроставания, а теоремите остават непроверени за четене. Дали **EGTA Projection**, съобразена с 3 или 4 играчи, ще разкрие **цикличността**, която колапсът от 2 типа премахва. И какво изобщо може да означава „безопасен“, когато **ядрото** е празно.

# Стъпка 12 Резюме - Последователни модели и агенти с голям езиков модел в стратегически среди

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

**Проблем.** Два посткласически подхода към играта заобикалят всичко, изградено в стъпки 2–11.

**Моделирането на последователности** преформулира играта като условно предсказване - подават се на трансформър тройки (очаквана възвръщаемост до края, състояние, действие) и се изисква следващото действие при зададена желана възвръщаемост, без функция на стойността и без самообучение - а **абстрактният дървовиден модел на решенията** добавя минимакс преетикетиране за устойчивост в най-лошия случай.

**Агентите с големи езикови модели** изцяло пропускат фазата на обучение: на модела се предоставят правилата на английски език. Стъпка 12 оценява и двата подхода спрямо точен еталонен тест.

**Подход.** Кун покер, където стъпка 2 предоставя точна експлоатируемост на Наш и точна експлоатируемост, с тесен порт към Ледюк Холдем като проверка за сложност. Сравнени са: nash-CFR, поведенческо клониране, Decision Transformer, ARDT и четири опорни системи за големи езикови модели (извън линия заглушка, gpt-oss-20b, Qwen2.5-7B, openThinker3-7B), както и последващи въпроси *защо* се получава тази класация. **Всички числа по-долу са измерени** от ангажирани JSON файлове, с две уговорки: два резултата бяха **оттеглени** по средата на сесията (невъзможна разлика е намалена с +1.59 и Ледюк -0.83 от декодер, който изхвърля 70% от вероятностната маса), а референтният Наш е 0.0162 жетона при 5,000 итерации на CFR, но 0.0061 при 50,000 - и двете ~0.

**Ключови резултати (измерени).**

- *Двата номинални обекта на стъпката завършват последни.* **BC 0.055 « ARDT 0.469 < DT 0.799 < LLM 0.833**, спрямо Наш **0.0162**. Клонирането достига до 0.04 жетона от Наш чрез копиране на почти равновесие на Наш стратегия, докато DT прекарва същата стратегия през канал за условно връщане, носещ предимно късмет - условното връщане тук активно унищожава информация.
- *Условното връщане никога не насочва в нито една от игрите.*  $\text{high}(+2) = 0.6981$  срещу  $\text{low}(-2) = 0.6928$ : равни и подредени грешно. Обяснението за Кун (набор печалби с 4 стойности) беше **половинчатото опровергано** на Ледюк: 15 стойности на печалбата накараха предвидения артефакт да изчезне, но насочването все още не се появи ( $r = +0.062$ ).
- *Моделите играят по-добре, отколкото могат да обяснят.* Хипотезата преди това беше „знае правилната честота, не може да я извади“; данните казват обратното. Оценени като стратегии, *изказаните* честоти са много по-лоши от *играните* - Qwen **0.921 срещу 0.357** жетона, gpt-oss **1,576 срещу 0.392**. Проучете поведението; не питайте.
- *Експлоатативен по подразбиране, а не адаптивен.* Средната разлика е намалена с **+0.38**, но средното обучение е **-0.22**: срещу единствения добре овластен модел на противника моделът улавя **83%** от наличната експлоатация от първата половина нататък и никога не се подобрява. Той експлоатира **61% по-силно от Наш, като същевременно е 59 пъти по-експлоатируем**, и само срещу пасивни опоненти.
- *Мащабът е без значение, а предимството на големите езикови модели принадлежи на Кун.* **Qwen-7B побеждава gpt-oss-20B с +0.162 жетона/ръка** за 20 хил. ръце на двойка, строго транзитивно. На Ледюк големият езиков модел е неразличим от DT (-0.463 срещу -0.454) и изобщо не може да победи слаби опоненти (-0.071, където Наш получава +0.582), като **100%** от масата му с незаконни действия е едно-единствено погрешно схващане: пас, когато проверката е безплатна.
- *Една скаларна величина скрива диагнозата.* Един възел „Дама“ представлява **41.4%** от общата експлоатируемост, докато залагането за стойност на „Поп“ при 1.00, където Наш смесва при 0.68, струва **0.1%** - размерът и цената на отклонението са почти некорелирани. Резултат: **3 ПАС / 2 НЕУСПЕХ**, честно червено.

**Връзка с дисертацията.** Първият принос дава отрицателен резултат, който е ценен: поведенческата адаптация *липсва* в контекста, поради което трябва да се изгради експлицитен модел на противника, вместо да се приема за даденост. Вторият принос определя границата, измерена върху един график - 61% повече експлоатация при 59 пъти по-голяма експлоатируемост, но само срещу слаби опоненти. Третият принос осигурява разлагане по решения и протокол за измерване.

**Отворени въпроси.** Назованото поправяне е  $Q(s, a)$  на абстрактния дървовиден модел на решенията: оценител на връщането, зависим единствено от състоянието, не може да различи „това състояние е лошо“ от „това действие е лошо“, поради което т. обхождането противоречи на теорията и експлоатируемостта се оказва *най-ниска* на оптимистичната страна - стойността по подразбиране беше оставена на теоретично правилната, вместо да бъде променена с цел получаване на по-добър резултат. Дали погрешното схващане за Ледюк може да бъде отстранено само с един ред в подканата. И постоянната уговорка: всеки извод за голям езиков модел относно Ледюк се основава на един модел, един стил на подкана и 600 раздавания.