

Резюмета по глави

Изследване на възможностите за приложение на изкуствения интелект в
компютърни игри

Александър Андреев

Юли 2026

Резюмета по глави

Съдържание

Глава 1 Резюме – Основи на обучението с подкрепление	3
Глава 2 Резюме – Теория на игрите и основи на CFR	4
Глава 3 Резюме – Варианти на CFR и методи на Монте Карло	5
Глава 4 Резюме – Абстракция на игри и мащабиране	6
Глава 5 Резюме – Невронни мрежи за игри с непълна информация	7
Глава 6 Резюме – Архитектури на игрови ИИ от край до край	8
Глава 7 Резюме – Моделиране на противника	9
Глава 8 Резюме – Безопасна експлоатация	10
Глава 9 Резюме – Многоагентно обучение с подкрепление	11
Глава 10 Резюме – Обучение на базата на популации и еволюционна теория на игрите	12
Глава 11 Резюме – Формиране и засичане на коалиции	13
Глава 12 Резюме – Модели на последователности и агенти с голям езиков модел в стратегически среди	14

Глава 1 Резюме – Основи на обучението с подкрепление

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

April 2026

Проблем. Всичко по-нататък в този план – намиране на равновесие с невронни мрежи (Глава 5), изпълнителният механизъм с модел на противника (Глави 7–8), многоагентно обучение (Глава 9) – се основава на мрежи за стойност, градиенти на стратегията и повторение на натрупан опит. Глава 1 полага основите: как един агент подобрява стратегията си само въз основа на награда в напълно наблюдаема едноагентна среда, преди тази картина да бъде усложнена от втори, скрит, състезателен играч. Тя косвено подпомага Принос №1 (архитектурните модели се използват повторно от адаптивния модел на противника) и пряко осигурява понятийния апарат за реализацията, който всяка следваща глава предполага.

Подход. По един алгоритъм от всяко семейство, написан от нулата в PyTorch: **DQN** (базиран на стойността, с обучение извън текущата стратегия) върху CartPole-v1 – Q-мрежа [4->128->128->2], кръгов буфер за повторение на опит, замразена целева мрежа, синхронизирана на всеки 5 епизода – и **PPO** (градиент на стратегията, обучение по текущата стратегия) върху LunarLander-v3 – отделен актьор [8->128->128->4] и оценител, GAE ($\lambda=0.95$) чрез обратно обхождане, изрязана сурогатна цел при $\epsilon=0.2$. Всеки от тях беше сравнен с аналога си от **Stable-Baselines3** (PPO – при същите основни хиперпараметри и същия бюджет от 500 хил. стъпки; DQN – с настроените за CartPole стойности от RL Zoo при 100 хил. стъпки, изпълнение от 6 април 2026 г.), като резултатът се оценява по най-добрата плъзгаща се средна за 100 епизода, така че ранното спиране да не може да повлияе на крайния резултат. **Всички числа по-долу са измерени.**

Ключови резултати (измерени).

- *И двете цели са постигнати.* DQN решава **CartPole** на **епизод 1011**, със средна стойност за 100 епизода **477,5** (цел 475); PPO решава **LunarLander** на **264 192 стъпки** при **202,2** (цел 200) – 236 хил. стъпки преди изчерпването на бюджета.
- *Версиите, написани от нулата, постигат по-високи резултати от изпълненията на SB3 при тези задачи.* Най-добра плъзгаща се средна за 100 епизода: DQN **477,5 срещу 222,4**, PPO **203,6 срещу 131,2**. Причините не са проверени: всяка страна е изпълнена веднъж (нашата – без фиксирано начално число), а DQN на SB3 с настройките на Zoo не достига целта при бюджет, два пъти по-голям от техните 50 хил. стъпки, което трябва да се провери с второ начално число, преди да се тълкува като свойство на SB3.
- *ϵ_{ps_min} беше решаващият параметър за DQN.* При стойност 0,01 изпълнението достигна връх от **479,1** (епизод 810) и спадна до **302,6**; стойност 0,001 заедно със запазването на най-добрия модел превърна влошаващата се стратегия в стабилна.
- *Капацитетът, а не бюджетът, беше тясното място за PPO.* [64, 64] достигна връх от **179,9** и никога не премина 200; [128, 128] го преодоля. Нормализирането на предимството беше използвано навсякъде (наградите са в диапазона от -500 до +300), а без **бонус за ентропия** от 0,01 стратегията колабираше до задържане на място.
- *Честно тълкуване на сравнението.* PPO на SB3 все още се покачваше при 500 хил. стъпки и вероятно би достигнал целта при 1–2 млн. стъпки, а базовият DQN е едно-единствено изпълнение с настроени параметри. Твърдението е за предимство при тези конкретни задачи, а не за по-добър алгоритъм.

Връзка с дисертацията. Стекът от 300–500 реда (срещу около 10 000 при SB3) е съзнателно платената цена за висока степен на модифицируемост: вмъкването на наблюдения на състоянието на убежденията в актьор-оценител изисква дълбоко подклаждане в рамките на SB3, докато тук това се свежда до локална редакция – точно от което има нужда работата по експлоатацията в глави 7–8. Същата двойка актьор-оценител се използва отново като MAPPO/MADDPG в глава 9, а механизмът на мрежата за стойност се появява повторно като мрежа за предимства на Deer CFR в глава 5.

Отворени въпроси. Предположението на MDP, което прави всичко това възможно – напълно наблюдаемо състояние – е именно това, което покерът нарушава: върху информационно множество стойността на действието зависи от стратегията на противника, която се променя, докато той се учи, а алчният $\max$ на DQN не може да изрази смесените стратегии, които изисква равновесната игра; затова глава 2 сменя инструмента, а не мащаба. Остава отворен въпросът: доколко от набора инструменти за стабилност при един агент (целеви мрежи, доверителни области, нормализиране на предимството) се запазва, когато средата сама по себе си е учаш се агент (отложено за нестационарността в глава 9), и дали измереното тук предимство в ефективността по отношение на данните е реално свойство или артефакт на две малки, добре обусловени задачи за управление.

Глава 2 Резюме – Теория на игрите и основи на CFR

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

April 2026

Проблем. Механизмите от Глава 1 предполагат напълно наблюдаемо състояние и стационарна среда; покерът няма нито едното, нито другото. Игрите за двама играчи с нулева сума и непълна информация изискват различна концепция за решение – равновесие на Наш, дефинирано върху *информационни множества* – и различен показател за качество: експлоатируемост, а не награда. Глава 2 установява и двете, както и алгоритъма, който ги изчислява, тъй като всичко след това представлява или приближение на CFR (Глави 3–5), умишлено отклонение от равновесието, което произвежда CFR (Глави 7–8), или опит да се дефинира какво всъщност означава равновесие, когато $N > 2$ (Глави 9, 11).

Подход. CFR с извадка на случайните събития, написан от нулата за **Кун покер** – 3 карти, 2 играчи, 12 информационни множества: достатъчно малък, за да има *семејство* от равновесия в затворена форма (параметризирано с $\alpha \in [0, 1/3]$), и достатъчно богат, за да включва блъфиране, смесени стратегии и безразличие. Ръчно кодирани компоненти: игровият двигател, рекурсивно контрафактивно обхождане с нападение на съжалението и извадка на случайните събития, както и оценка на точната експлоатируемост чрез изброяване на всички $2^6 = 64$ чисти стратегии – тъй като „най-добрият отговор“, избран поотделно за всяко състояние със знание за картата на противника, не е истински най-добър отговор: играчът трябва да избере едно действие за цялото информационно множество. Обучен със 100 000 итерации (начално число 0); към него има и скрипт за кръстосана проверка с OpenSpiel. **Всички числа по-долу са измерени** (implementation/step02/models/cfr_results.json).

Ключови резултати (измерени).

- *CFR стига близо до аналитичното семејство от равновесия.* Възстановеният параметър за блъф е $\alpha = 0,1792$, а вътрешното ограничение на самото семејство $P(\text{залог} \mid K) = 3\alpha$ е изпълнено с точност до **0,038** (измерено **0,5758** спрямо **0,5377**, което предполага собствената му α); въпреки това експлоатируемостта на целия профил е само **0,006**.
- *Чистите решения се установяват бързо; бавната опашка $O(1/\sqrt{T})$ е в смесените честоти.* С Поп играчът залага и плаща с вероятност $\geq 0,9999$, с Вале се отказва при залог с вероятност **0,99996**, а с Дама пасува при първия ход с вероятност **0,9995** – докато смесените честоти се отклоняват с **0,005–0,038** от затворената форма (блъф на Вале след пас **0,3387** срещу $1/3$; плащане на Дама **0,5307** срещу $1/3 + \alpha = 0,5126$). Честотите са бавната част, което е точното място, където се проявява остатъчното съжаление.
- *Стойността на играта за средната стратегия е -0,0555 при точна стойност $-1/18 = -0,0556$* (текущата средна на изтеглените печалби за всичките 100k итерации е **-0,0613**) и възпроизвежда структурно неблагоприятното положение на Играч 0, който действа пръв.
- *Скоростта на сходимост съответства на теоретичната.* Наклонът на експлоатируемостта в двулогаритмичен мащаб е **-0,52 $\pm$ 0,02** (5 начални числа, 100–100k итерации) спрямо **-0,5** за границата $O(1/\sqrt{T})$.
- *Само стойността на играта не е проверка за валидност.* Стратегия, която винаги блъфира с Вале, може да дава средна стойност близо до $-1/18$, като същевременно е тривиално експлоатируема; само експлоатируемостта я улавя. Ето защо експлоатируемост – а не награда – е показателят, който се пренася в Глави 7–8 и в методологията за оценяване (Принос №3).

Връзка с дисертацията. Равновесието на Наш е отправната точка, от която дисертацията цели да се отдалечи: Принос №1 анализира конкретен противник, за да обоснове отклонението от него, а Принос №2 определя границите на това отклонение. Конкретно, точният код за най-добър отговор и експлоатируемост, разработен тук, се използва без промени като оракул за най-добър отговор в Глави 7–10, а Кун покер остава най-малката тестова среда, в която всяко следващо твърдение може да бъде проверено чрез точен отговор.

Отворени въпроси. Защо *средната* стратегия клони към равновесие, а текущата – не – интуицията (усредняването потиска превишаването, както усредняването на Поляк) не е доказателство. Всичко тук се основава на теоремата за минимум в игра за двама с нулева сума и нито гаранцията на CFR, нито смисълът на експлоатируемостта се запазват в игри с N играчи или с обща сума (Глави 9, 11). А дори с по едно изтеглено раздаване на итерация CFR обхожда всички последователности от действия, така че този точен алгоритъм става непосилен още за следващата по големина игра – мотивацията за извадката по метода Монте Карло в Глава 3 и абстракцията в Глава 4.

Глава 3 Резюме – Варианти на CFR и методи на Монте Карло

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

April 2026

Проблем. Обикновеният вариант на CFR от Глава 2 обхожда всяко информационно множество при всяка итерация, което престава да е изчислително поносимо още при следващата по големина игра след Кун. Двата подхода в областта са метод с по-добра константа за пълно обхождане (**CFR+**) и *извадка* от дървото на играта (**MCCFR**), като общоприетото мнение е, че именно извадката направи решаването на реален покер възможно. Глава 3 поставя въпроса кой от двата метода всъщност се представя по-добре, при какъв размер на играта и защо – отговорът на този въпрос определя решавача, върху който се надграждат всички следващи глави.

Подход. Всички четири алгоритъма са ръчно кодирани на Python + NumPy върху **Ледюк покер** (6 карти, два рунда за залагане, една разкрита обща карта, 936 информационни множества, 10 200 възела, 120 раздавания): обикновен вариант на CFR, CFR+ (нулиране на отрицателните съжаления, линейно претеглено усредняване, редуващи се актуализации), MCCFR **външно вземане на проби** (всички действия на обхождащия играч и едно случайно избрано действие на противника) и MCCFR **извадка по резултати** (една траектория до край, ϵ -микс с текущата стратегия при $\epsilon_{ps} = 0.6$ и корекция чрез извадка по важност). Оценявани са чрез точен най-добър отговор, ограничен до информационни множества, при общ **бюджет от 180 секунди време за изпълнение**, като OpenSpiel се използва за референтен решавач. **Всички числа по-долу са измерени.**

Ключови резултати (измерени).

- **CFR+ е основният инструмент, с категорично предимство.** При по същество същия брой итерации като обикновения вариант на CFR (3 706 срещу 3 713), CFR+ достига **2,6e-5** експлоатируемост спрямо **4,4e-3** на обикновения – приблизително **170 пъти** по-добър резултат, благодарение на две локализирани промени в кода (нулиране на отрицателните съжаления и линейно усредняване; базовият вариант вече редува актуализациите).
- **MCCFR губи сериозно при този размер на играта.** Външното вземане на проби достига **5,5e-2** след **3,5 милиона** итерации, а извадката по резултати **1,0e-1** след **8,3 милиона** – 12–23 пъти по-лошо от обикновения CFR и три до четири порядъка по-лошо от CFR+ въпреки ~1 000 пъти повече итерации.
- **Причината е дисперсията, а не скоростта, и тя е количествено определена.** Извадката е **945x / 2 228x** по-евтина на итерация, но се нуждае от **~99 000x / ~520 000x** повече от тях. Преобразувано в константа по време на изпълнение $C_w = C/\sqrt{\text{speed}}$: **0,075** (обикновен вариант) срещу **0,767** и **1 143** – при еднакво време извадката завършва с **10,2x / 15,3x** по-висока експлоатируемост, т.е. за дадена точност ѝ е нужно **~105x / ~233x** повече време.
- **Пресечната точка може да бъде изведена и Ледюк е далеч под нея.** Извадката се изравнява с пълното обхождане при приблизително **1,1 милиона възела** (външна) и **2,4 милиона** (по резултати); 10 200-те възела на Ледюк са **105x / 233x** под прага, докато лимитният тексаски холдем (~3e17 състояния) е далеч отвъд него по модела, но все пак е решен с CFR+ с пълно обхождане, така че прагът е ориентир по порядък. Това съгласува „MCCFR беше от съществено значение за реалния покер“ с „MCCFR губи тук“ – един и същ алгоритъм, но от противоположната страна на линията.
- **Кръстосано валидиран спрямо OpenSpiel** при съпоставен бюджет от 500 итерации: обикновен вариант **0,020** срещу **0,022**, CFR+ **8,6e-4** срещу **9,4e-4**.
- **Обикновеният вариант на CFR е по-бърз от собствения си най-лош случай.** Предполагаемата константа $\epsilon_{ps} \cdot \sqrt{T}$ пада от **0,90** ($T=100$) до **0,27** ($T=3,700$), вместо да остане постоянна, така че горната граница $O(1/\sqrt{T})$ тук далеч не се достига, което е обичайно за граница за най-лошия случай.

Връзка с дисертацията. Тази глава установява инструментариума за всичко последващо: **Ледюк**, заедно с точния **най-добър отговор**, се превръщат в стандартната тестова среда за глави 7–12, а CFR+ става еталонът за равновесие на Наш, спрямо който ще се съпоставят всички по-късни резултати за моделиране на противника, безопасна експлоатация и големи езикови модели. Компромисът между точност и **дисперсия**, измерен тук, се появява отново в глава 5, където извадените оценки захранват **мрежа** вместо таблица.

Отворени въпроси. Дали броят на възлите при пресечната точка е свойство на самите алгоритми или на константните фактори в тази конкретна имплементация – векторизиран или компилиран решавач за пълно обхождане променя `speed_v` и измества прага, така че стойността е валидна само за този код и все още не може да се приеме като твърдение за алгоритмите по принцип. Коя схема на извадка ще се окаже най-устойчива, когато стратегията се представя чрез невронна мрежа вместо таблица (глава 5). И защо обикновеният вариант на CFR достига сходимост по-бързо от предвиденото в неговия най-лош случай.

Глава 4 Резюме – Абстракция на игри и мащабиране

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

May 2026

Проблем. Глава 3 установи, че обхватът на решавача е ограничен от размера на дървото, поради което класическият път към реалния покер не е по-добър решавач, а *по-малка игра*: свийте я, решете сведената версия, преведете стратегията обратно и платете данък експлоатируемост за разликите, които сте изхвърлили. Глава 4 измерва този данък. Въпросът не е „помага ли абстракцията“, а коя ос на компресия е безопасна и дали изчислителното време, спестено от намалението, някога ще компенсира загубената стратегическа информация.

Подход. Конвейер тип „Ледюк“, който компресираща по три оси и оценява всяка получена стратегия **в собствената ѝ пълна игра: беззагубен изоморфизъм на боите** (печалбите в Ледюк зависят единствено от ранга и от това дали частната карта образува чифт с общата, така че информационните множества с изоморфни бои се сливат без загуба), **групиране на карти със загуби** (признаци за силата на ръката, разстояния от типа EMD, k-средни, с пълна и с непълна памет) и **абстракция на действията с транслация** (към най-близкото действие, вероятно разделяне, псевдохармонично преобразуване) върху Mini-NL Ледюк с променлив залог. Всичко е тествано с CFR+ при общ бюджет от **180 секунди**, с 3 начални числа, върху Ледюк с лимит, Mini-NL Ледюк и разширен Ледюк с 4 ранга. **Всички числа по-долу са измерени.**

Ключови резултати (измерени).

- *Беззагубната компресия е най-ценният ход и печели, като осигурява повече итерации.* Изоморфизмът на боите намалява Ледюк с лимит от **936 до 288** информационни множества и достига **3,13e-6** експлоатируемост спрямо **4,44e-5** на пълния CFR+ за същото време за изпълнение – защото завършва **14 185** итерации вместо **2 655**. Потвърдено в по-голям мащаб върху разширения Ледюк: **10 304 -> 2 968** информационни множества (-71%), **0,0272 -> 0,00126**, приблизително 6 пъти повече итерации.
- *Клъстерите на карти със загуби поставят долна граница на експлоатируемостта, която допълнителните изчисления не могат да понижат.* k2 **0,571**, k3 **0,382**, k5 **0,382** – всички при 11 000+ итерации, т.е. 4 пъти повече решаване от пълната игра и четири порядъка по-лошо. Грешката е в абстракцията, а не в бюджета.
- *Абстракцията на действията, както е внедрена тук, е опасната ос.* Mini-NL: пълната игра с 4 704 информационни множества достига **0,00692**, докато абстракцията на действията с 936 информационни множества достига **0,673** въпреки 5 пъти повече итерации – приблизително **100 пъти по-лошо** за дърво, което е 5 пъти по-малко. Разширеният Ледюк е още по-показателен: бои + действия **4,696** и бои + действия + клъстери **4,734**, и двете далеч по-лоши от простото решаване на неабстрахираната игра. При текущото правило за внедряване грешката от съпоставянето на действията доминира общата стойност (вж. ограниченията).
- *Измерен артефакт, а не закон.* k5 съвпада точно с k3, защото разпределенията на силата на ръката в Ледюк след откриването на общата карта се свиват до три ефективни форми; подреждането по брой клъстери за карти, наблюдавано тук, е свойство на тази малка игра.
- *Посочени ограничения.* CFR+ е детерминистичен, така че трите изпълнения не са независими; числата за абстракцията на действията измерват текущото правило за внедряване (абстрактните малки залози се изиграват като големия, а трите транслатора не се задействат и дават еднакви стойности), а не качеството на транслацията, и трябва да се разглеждат като диагностичен режим на отказ; а сравнението с OpenSpiel подравнява всички 936 информационни множества като проверка за коректност, а не като доказателство за идентична динамика на решавача.

Връзка с дисертацията. Преносимата част е форматът на представяне на резултатите: качеството на стратегията е безсмислено без посочения размер на играта, а Парето границата между тях е зародишът на методологията за оценяване от принос 3. Механизмът също се пренася – типова базираното моделиране на противника от глава 7 е същата идея „групирай за постигане на управляемост“, но вече приложена от пространството на състоянията към пространството на стратегиите, а неговият провал – уверено, но погрешно убеждение – е същата грешна спецификация като при транслацията на действия, само в друга форма.

Отворени въпроси. Статичната транслация е крехка по самото си устройство, затова решаването на под-игри и вложеното решаване (глава 6) са отговорът на действията извън дървото, използван в реалните системи. Дали измереният тук ред – абстракцията на картите е поносима, а абстракцията на действията е разрушителна – ще издържи след поправка на съпоставянето на действията и ще се запази в игра с достатъчно разнообразие на силата на ръката, така че k5 действително да се различава от k3. И дали една абстракция може да бъде адаптирана към противника, вместо да бъде фиксирана предварително, което е мястото, където тази глава докосва директно адаптивната рамка.

Глава 5 Резюме – Невронни мрежи за игри с непълна информация

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

May 2026

Проблем. В глави 2–4 стратегията се съхранява като таблица, индексирана по информационно множество, а в глава 4 беше показано, че и двата начина за избягване на тази таблица – чрез използване на по-добър решаващ или чрез ограничаване до по-малка игра – се оказват недостатъчни. Третият подход е да се спре изброяването: вместо таблицата със съжалението да се използва апроксиматор на функции, който *обобщава* подобни информационни състояния при фиксиран обем памет. Глава 5 разглежда тази подмяна – Deep CFR, неговите варианти с една мрежа, NFSP – и какви са цената и компромисите по отношение на гаранциите.

Подход. Казано откровено, обхватът е ограничен: **тази глава приключи след изследване и четене – няма имплементация от нулата на Фаза 4 и няма отчет за имплементацията**, а заключителният синтез на обзора все още не е написан. Измерената работа е двудневно изследване срещу референтните решаващи на OpenSpiel върху Ледюк и Кун – Deep CFR при три размера на мрежата, NFSP и в двете игри, табличен MCCFR и CFR+ като базови линии – оценявани по собствената експлоатируемост на OpenSpiel, така че прякото сравнение да е коректно (MCCFR от глава 3 работи върху собствена реализация на играта и не е сравним). **Всички числа по-долу са измерени** (implementation/step05/exploration/logs/day0{1,2}_results.json; за CFR+: findings.md).

Ключови резултати (измерени).

- *Най-същественният артефакт от главата е грешка в библиотеката.* DeepCFRSolver на PyTorch в OpenSpiel 1.6.12 **никога не обучава своите мрежи за предимства**: `if len(samples.info_state == 0)` взема `len` от елементно сравнение, което винаги е истина, така че връща преди стъпката на оптимизатора. Загубите за предимство се връщат мълчаливо като `None`, а експлоатируемостта остава около **~1,69** независимо от броя итерации (равномерно случайната стратегия има 2,37). Поправката е от един символ, приложена локално; в OpenSpiel 1.6.13 (март 2026 г.) е отстранена независимо. *Уговорка:* и поправеният опит (64, 64) остава на 1,70, затова числата му са изключени до повторно изпълнение.
- *Където таблицата се побира, таблицата печели – убедително.* Ледюк при сравнимо време за изпълнение: CFR+ **0,00123** (400 итерации, 92 s), табличен MCCFR **0,0967** (50 000 итерации, 68 s), Deep CFR **1,14–1,49** при (32, 32) и (128, 128, 128) (120 итерации, 87–101 s), NFSP **2,46** (50 000 епизода) – CFR+ е приблизително **900 пъти** по-добър от най-добрия опит с Deep CFR.
- *Тези невронни числа са артефакти на бюджета, а не присъди.* Кривите на Deep CFR са плоски от итерация 30 до 120 при само 40 обхождания на итерация (в настройката за Ледюк на Steinberger, 2019, те са 1500), а собственият пример на OpenSpiel за NFSP Ледюк работи с **2e7** епизода – **400 пъти** нашия бюджет. Прието правило: на крива на NFSP за Ледюк под $\sim 1e6$ епизода не може да се разчита.
- *По-малката мрежа спечели при този бюджет.* (32, 32) **1,1441** победи (128, 128, 128) **1,4908** (едно начално число), което съответства на недообучение при малко на брой различни извадки; при повече итерации подредбата вероятно ще се обърне.
- *Как изглежда недообучението вътре в стратегията.* В сравнение с еталонна стратегия от CFR+ след 400 итерации, Deep CFR (64, 64) при 40 итерации (експлоатируемост 1,70, т.е. предварителен резултат) има **медианно разстояние по обща вариация 0,35** за 8 случайно избрани информационни състояния на Ледюк (диапазон 0,163–0,708): посоката на всяко решение обикновено е правилна, но вероятностите са дръпнати към равномерни (**0,73/0,27**, където CFR+ е **0,92/0,07**) – регресия по средноквадратична грешка върху шумни контрафактични извадки води до изгладено приближение на равновесието с прекалено ниска увереност.
- *Структурата на разходите, която оправдава семейството въпреки всичко.* Една външна итерация на Deep CFR струва **~0,7 s** срещу **~1,4 ms** (~500 пъти) за една итерация на табличен MCCFR, но работата му за итерация е приблизително постоянна спрямо размера на играта, докато табличните разходи се мащабират с броя информационни множества. Ледюк е учебна игра, в която невронните методи губят от базови линии, които никога не са били предназначени да победят.

Връзка с дисертацията. Мрежата за предимства на Deep CFR представлява мрежата за стойности от глава 1, но с контрафактична цел – връзката, която позволява на глави 6–8 да надхвърлят игрите с табличен размер. По-точно, изглаждането с прекалено ниска увереност, наблюдавано тук, е видът отказ, чиято цена глава 7 измерва по-късно: модел с правилна посока, но грешни честоти, е причината най-добрият отговор на неточна преценка за противника да губи срещу „Наш“.

Отворени въпроси. Собствената бариера на главата остава непреодоляна: ръчно кодиран **Deep CFR** с резервоарна извадка по Vitter и **извадка по резултати на DREAM с изваждане на базова линия**, и двете все още не са реализирани, така че въпросът „мога ли да го изградя“ остава без отговор. Непроверено е дали предимството на табличния метод пред невронния се обръща точно в точката на пресичане по брой възли от глава 3 и дали структурата на тензора на информационните състояния наистина има по-голямо значение от дълбочината на мрежата.

Глава 6 Резюме – Архитектури на игрови ИИ от край до край

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

June 2026

Проблем. Глави 2–5 разглеждаха отделни компоненти – варианти на CFR, абстракция, невронно приближение на стойностите – без да се изследва как те се комбинират в системата, способна да побеждава хора, или какви гаранции предоставя такава система. Глава 6 представя обзор на пет архитектури от състезателно равнище за периода 2017–2023 г., разглеждайки ги като еволюция на проектните компромиси, а не просто като класация: това е съвременното равнище, върху което настоящата дисертация се опира и от което се различава.

Подход. Умишлено *архитектурно* изследване – какво всяка система изчислява **офлайн**, какво изчислява в реално време, къде се намира обучението, какво може да докаже – на **DeepStack** (2017), **Libratus** (2017/18), **Pluribus** (2019), **ReBeL** (2020) и **Student of Games** (2023), като всяка е оценена по същите девет измерения и поставена върху три оси: от **абстракция** към **невронно представяне**, от предварително изчисление към търсене в реално време, от игри само с непълна информация към единен алгоритъм за двата вида игри. **Тази глава не произведе код; всяко число по-долу е резултатът, който всяка статия съобщава, а не наше измерване.**

Ключови резултати (според съобщенията в статиите).

- *Ерата на абстракцията се оказа далеч по-експлоатируема, отколкото резултатите ѝ в състезанията подсказваха.* Проверка с локален най-добър отговор показва, че водещите състезателни ботове губят **над 3000 mbb/g** – четири пъти повече, отколкото би се загубило при отказ във всяко раздаване. Затварянето на тази разлика беше целта на десетилетието.
- *Предимството идва от търсенето по време на игра, а не от предварителната стратегия.* Суровият план на Libratus **не победи** Baby Tartanian8 (-8 ± 15 mbb/g); с включено вложено безопасно решаване на под-игри същата система **спечели с 63**, и победи четирима професионалисти със **147 mbb/g за 120 000 раздавания**. Решаването на заложи извън менюто в реално време също победи трансляцията на действия към най-близкия размер **119 срещу 1465 mbb/g** в най-лошия случай – провалът на трансляцията от Глава 4 беше поправен чрез отказ от трансляция.
- *Цената не е оста, за която изглежда.* DeepStack похарчи **~175 процесорни ядро-години** за генериране на целевите стойности и Libratus **~25 милиона ядро-часа**, докато планът на Pluribus струваше **~12 400 ядро-часа** – около **\$150** на един сървър – и въпреки това победи петима елитни професионалисти с **+48 mbb/g**.
- *Всеки напредък беше платен другаде.* Pluribus достигна шест играчи, като се отказа от **всички** гаранции за безопасност в полза на небезопасно търсене; ReBeL възстанови гаранцията за игри за двама и елиминира както абстракцията, така и плана (Dong Kim **+165 mbb/g**), но се върна към двама играчи; Student of Games обедини игра с пълна и непълна информация по коректен начин (като победи проверката с локален най-добър отговор с **+434 mbb/g**), докато в Го спечели само **2 от 400** партии срещу AlphaZero – „цената на универсалността“, по думите на авторите. Никоя система не доминира всяка ос.
- *Единственият пропуск, който всичките пет споделят.* Всяка е „**сляпа**“ за **противника по замисъл**: тя изчислява стратегия, устойчива в най-лошия случай, и я играе безусловно. Libratus и Pluribus го казват изрично, а Pluribus дори не знае срещу кого играе.

Връзка с дисертацията. Този споделен пропуск е отправната точка, която настоящата дисертация заема, а главата предоставя необходимите механизми за неговото запълване. **Публичното състояние на убежденията** (PBS) на ReBeL представлява основата, върху която Принос №1 разширява обхвата от убеждения относно картите до убеждения относно *типа* на противника, наследявайки доказателствата за коректност, свързани с него, вместо да добавя адаптация като външен елемент. Pluribus е аргументът на Принос №2, реализиран в рамките на една система: ако равновесието не осигурява безопасност при $N > 2$, отказът от експлоатация означава отказ от гаранция, която никога не е била валидна. Експлоатируемостта, проверката с LBR (преназначена от сертификат в стрес тест) и намаляването на дисперсията чрез AIVAT са три готови инструмента за Принос №3.

Отворени въпроси. Четири, директно от синтеза: самата „**слепота**“ за **противника** (Глава 7); **безопасна експлоатация** извън **игрите за двама с нулева сума** – Pluribus спечели без нея, а Student of Games не успя да я разшири (Глава 8); пренасяне на **модел на противника отвъд границата на дълбочината** вместо да се изхвърля в листото; и **изчислителни бюджети** в реално време, чийто разброс от шест порядъка най-силно ограничава агент, който трябва да пререшава и да преоценява противника едновременно. Следствие: надграждането трябва да е върху евтините системи с отворен код – кодът на водещите системи не е публикуван или изисква **свърхкомпютър**.

Глава 7 Резюме – Моделиране на противника

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Проблем. Равновесната стратегия на Наш е неексплоатируема, но сляпа – тя се играе еднакво срещу всички и никога не наказва слаб противник. Моделирането на противника действа като сензор, който преобразува наблюдаваните действия в оценка на стратегията на конкретен противник, така че агентът да може да се отклони от равновесието с цел експлоатация – това е първата част от рамката за поведенческа адаптация, представена в дисертацията (Принос №1). Трудната част се състои в това да се постигне експлоатация, без самият агент да стане експлоатируем.

Подход. Байесов цикъл на актуализиране на убежденията (априорно $\times$ правдоподобие $\rightarrow$ апостериорно $\rightarrow$ най-добър отговор), изграден зад един общ интерфейс, така че един точен най-добър отговор да може да бъде приложен към три взаимозаменяеми модела: (1) **типово базиран** – убеждение върху фиксирано меню от типове опоненти; (2) **непрекъснат** – свободно формирани Дирихле преброявания за всяка ситуация; (3) **състоятелен** – оценка чрез изпъкнала оптимизация в последователна форма (Ganzfried 2025). **Адаптивен експлоататор** изпълнява цикъла наблюдение $\rightarrow$ моделиране $\rightarrow$ най-добър отговор $\rightarrow$ действие, със смесване с равновесието на Наш за безопасност и по избор детектор за точка на промяна за нестационарни опоненти. Тестови среди: Кун покер и Ледюк Холдем, и двете точно решими, така че всеки резултат е поставен в точни аналитични граници.

Ключови резултати (измерени).

- *Моделирането си заслужава.* Равновесната игра оставя **0,11–0,28 на раздаване** на масата срещу експлоатируеми противници в Кун; срещу противника „Наш“ разликата е ~ 0 (не можете да експлоатирате равновесие).
- *Когато класът на модела пасва на противника, най-добрият отговор достига точния таван* – типово базираният модел остава в рамките на 3% от тавана на най-добрия отговор срещу всеки противник и в двете игри (и в рамките на две стандартни грешки за почти всички).
- *Уверен, но недообучен модел ви прави уязвими.* В Ледюк непрекъснатият модел губи срещу „Наш“ (**-0,175 при таван -0,083**) – най-добрият отговор на грешна оценка на неексплоатируем противник създава уязвимост в собствената му игра. Това е напрежението между експлоатацията и безопасността в едно число.
- *Увереността, съчетана с грешка, крие реален риск.* Срещу противник извън менюто типово базираното апостериорно разпределение твърдо се ангажира с най-близкия представим тип; в 300 изпълнения с различни начални числа грешен тип все още водеше след раздаване 100 в $\sim 13\%$ от тях (той винаги се коригира в крайна сметка и никога не пада, след като е заключен).
- *Нестационарността зависи от сценария.* Забравянето на точка на промяна спасява вреден остарял модел (Кун: $-0,106 \rightarrow +0,211$), но се представя по-зле от простата адаптация, когато новият противник е експлоатируем и детекторът даде фалшива аларма (Ледюк). Реакцията има значение толкова, колкото и откриването.
- *Състоятелност.* Състоятелният модел възстановява точно стратегиите в Кун (разстояние по обща вариация $\sim 0,004\text{--}0,021$), но неговото изпъкнало решаване при всяка актуализация е твърде скъпо за онлайн цикъла в изградения вид – емпиричен отговор на въпроса за осъществимостта в реално време на тази глава, насочващ към постепенно решаване / приближения от Глава 8.

Връзка с дисертацията. Глава 7 изгражда **сензора** (модела), а Глава 8 – **изпълнителния механизъм** (безопасна експлоатация с KL-регуларизация). Самонанесената уязвимост на непрекъснатия модел срещу противника „Наш“ е емпиричният аргумент за този предпазен механизъм; теорията на състоятелността представлява принципния гръбнак, върху който рамката се надгражда.

Отворени въпроси. Състоятелно моделиране в реално време (последователна изпъкнала оптимизация); принцип на нестационарност (забравяне, мащабирано според увереността; по-добри сигнали за промяна); противници извън менюто (откриване на типове в отворен свят); преминаване от един към много противници (съвместният най-добър отговор не е комбинация от отделни и изпъкналата гаранция се нарушава при $N > 2$).

Глава 8 Резюме – Безопасна експлоатация

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Проблем. Глава 7 изгради *сензора* – модел на противника – и показва неговата опасност: най-добрият отговор на несъвършен модел може да създаде уязвимост в собствената игра (непрекъснатият модел загуби срещу „Наш“ в Ледюк). Глава 8 изгражда *изпълнителния механизъм*: превръщане на модел в печалба, **без да става експлоатируем**. Това е втората половина на рамката за поведенческа адаптация на дисертацията (Принос №1) и отправната точка за многоагентна безопасна експлоатация (Принос №2).

Подход. Всеки метод за безопасна експлоатация е една и съща задача – *максимизиране на очакваната стойност спрямо модела на противника при ограничение стойността в най-лошия случай да не пада под прага на безопасност* – която е линейна по плана за реализация на агента в последователна форма. Един LP двигател я решава чрез **генериране на ограничения** (решаване → точният най-добър отговор като оракул за най-лошия случай → отсичащо ограничение, ако стратегията е небезопасна → ново решаване) върху двигателите, равновесието на Наш и „зоопарка“ от противници на Глава 7. Пет семейства се различават единствено по прага: **RNR** (настройваем p), **най-доброто равновесие** (базовият вариант на Ганцфрид и Сандхолм; $\geq$ стойността на играта v^*), **prime-safe** ($\geq v^* - \epsilon$ за базова линия, която е ϵ -равновесие), **SES** (стойността на плана, наложена локално в под-игра чрез приспособление), **адаптация** (не по-експлоатируема от плана). Тестови среди: Кун и Ледюк, и двете точно решими. **Всички числа по-долу са измерени.**

Ключови резултати (измерени).

- **Безопасната експлоатация работи в Кун, но печели малко. Най-доброто равновесие е безопасно срещу всеки противник** (стойност в най-лошия случай $\geq v^*$ в рамките на $1e-3$) **и печели повече от стратегията на Наш срещу всеки експлоатируем тип** – например **+0,222 срещу +0,146 за Наш** при AlwaysPass – но само с 0,002–0,076 на раздаване (1–9% от печалбата на пълния най-добър отговор): прагът v^* за всяко раздаване допуска само равновесни стратегии. Пълният най-добър отговор носи повече (+0,975), но стойността му в най-лошия случай се срива до **-0,5** (катастрофално експлоатируем).
- ϵ **се измерва, а не се приема наготово.** Prime-safe и адаптацията понижават прага до $v^* - \epsilon$, като експлоатируемостта на базовата линия е измерена: $\epsilon = 0,0074$; изразходвайки този бюджет, те печелят малко повече от най-доброто равновесие (+0,266 срещу +0,222 при AlwaysPass).
- **Каноничният RNR превключва скокообразно, а не по плавна граница** (предсказанието не се потвърди). В толкова малка игра максиминната LP-задача скача от безопасния връх направо към пълния най-добър отговор между $p = 0,6$ и $0,7$ (изпробвани през 0,1); смесването на двата върха дава отсечка, която тук подобрява наивното смесване само с около 0.002.
- **Основен резултат – при лимит от 40 итерации глобалните решавачи не достигат сходимост, а локалният метод (с лимит 400) достига.** В Ледюк глобалните решавачи (най-доброто равновесие/prime-safe/адаптация) **не достигат сходимост в рамките на 40 итерации** (най-лош случай **от -0,64 до -1,33**, силно небезопасни), **докато методът на под-играта (SES) достига сходимост** (194–350 итерации) и остава почти безопасен (най-лош случай $\approx -0,13$), като същевременно извлича **+0,25 до +0,68** срещу слабите типове. Бюджетите обаче са неравни: резултатът показва, че глобалният цикъл е бавен, а не че не може да достигне сходимост.
- **Гаранцията действа срещу най-неблагоприятния противник, а не срещу безобиден.** При обучаващата атака (приамка → „разкриване“ с равновесие на Наш) разграничителният сигнал е броят нарушения на безопасността (**full_br 40/40, най-доброто равновесие 0/40**), а не печалбата: „разкриващият“ „Наш“ е твърде мек, за да си върне неочакваната печалба на full_br. За наказващ тест е нужен адаптивен контраексплоататор.

Връзка с дисертацията. Глава 7 е сензорът; Глава 8 – изпълнителният механизъм. Резултатите в Кун показват, че той работи според теорията (при точни модели, в точно решима игра); липсата на сходимост в Ледюк е аргумент за методи за под-игри в реално време (SES / OX-Search) и/или точна двойствена LP-задача и мост към многоагентната безопасна експлоатация от Принос №2.

Отворени въпроси. RYWE – алгоритъмът на Ганцфрид и Сандхолм, който рискува натрупаните подаръци, като посилен базов метод за двама играчи (същата LP-задача с подвижен праг; бъдеща работа); мащабируема безопасност (точна двойствена LP-задача срещу под-игри – „стената“ на Ледюк, при равни бюджети); доказуемо безопасен ли е SES (остатъкът 0,04 е спрямо v^* ; прага на плана спазва до допустимото отклонение 0,01); наказваща обучаваща атака; и **безопасност при N играчи** – гаранциите тук стъпват на това, че в игра с нулева сума за двама играчи равновесието на Наш осигурява v^* ; при $N > 2$ тази опора изчезва, а известните понятия са много консервативни (максимин срещу коалиция) или неосигурими (равният дял) – отворена остава експлоатацията с ограничена загуба спрямо базова линия, и срещу противници в сговор (Принос №2).

Глава 9 Резюме – Многоагентно обучение с подкрепление

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Проблем. Глави 2–8 се развиваха почти изцяло в рамките на игри за двама с нулева сума, където равновесната стратегия на Наш осигурява стойност v^* срещу всеки и CFR доказуемо се сближава към нея. Глава 9 е повратната точка към многоагентния свят, където определящата трудност е **нестационарността**: всички агенти се учат едновременно, така че от гледната точка на който и да е агент средата (която съдържа останалите) никога не остава непроменена. Това е отправната точка за многоагентните приноси на дисертацията – динамично **моделиране на противника** (#1), **безопасна експлоатация без минимаксна опора** (#2) и оценка на ниво **популация** (#3).

Подход. Изграждане и сравняване на контролен вариант и на четирите структурни отговора, които областта дава на нестационарността, върху малки, *точно решими* тестови среди, така че всеки обучаващ се агент да бъде оценен спрямо обективната истина. **Независимо обучение** (контролният вариант, който се проваля) върху четири канонични матрични игри; **CTDE** – централизиране на оценителя по време на обучение и децентрализиране на актьора при изпълнение – чрез MADDPG и MAPPO върху кооперативни задачи; **PSRO** – игра, изиграна върху *популация* от стратегии (мета-Наш + оракул за най-добър отговор), като се използва точният най-добър отговор от Глава 7 както като оракул, така и като мярка за експлоатируемост – върху Кун, Ледюк, матрична игра и собствена реализация на Goofspiel; **научена комуникация** (CommNet); и **LOLA** (диференциране през стъпката на обучение на противника) върху повтарящата се дилема на затворника. **Всички числа по-долу са измерени.**

Ключови резултати (измерени).

- *Независимото обучение се проваля точно там, където го предвижда теорията.* То се сближава с равновесие на Наш при дилемата на затворника (предателство), лова на елен (рисково доминиращия ъгъл) и битката на полете, но **в „съвпадение на монети“ обучението никога не се сближава** – разстоянието на траекторията до равновесието на Наш всъщност *нараства* ($0,30 \rightarrow 0,48$), което е по-рязко от предвидената несходимост (опровергано предсказание, §9 от доклада).
- *PSRO е мостът между теорията на игрите и MARL и работи в малките игри.* Експлоатируемостта $\rightarrow$ машинна нула при Кун ($0,917 \rightarrow 2 \times 10^{-16}$, 6 кръга), $\rightarrow 0$ при матричната игра и камък–ножица–хартия. Самообучението потвърждава механизма: при Кун NashConv на **средната** стратегия спада $0,24 \rightarrow 0,031$, докато **последната** итерация продължава да осцилира – затова е необходима популация/усредняване.
- *Централизиращият оценител напасва целевата си стойност почти точно.* При CoopSignal остатъкът на централизиращия оценител е $3.2e-11$ срещу 0.077 на независимия – много по-точно напасване на целевата стойност (което не е същото като по-ниска дисперсия на градиента на стратегията).
- *Комуникацията надхвърля тавана при случайно отгатване.* CommNet с включен канал постига 0.795 срещу 0.204 при изключен (таван $1/K = 0,2$) – протокол, който агентите научават, а не който някой е проектирал.
- *LOLA превръща предателството в сътрудничество.* Възвръщаемостта на стъпка в IPD се повишава от 1.04 (наивните агенти стигат до предателство) до 2.82 (сътрудничество с LOLA); нулирането на предвиждането възстановява точно наивния градиент (проверка на механизма).
- *Отрицателни резултати, запазени честно (опровергани предсказания, §9 от доклада).* PSRO при Ледюк намалява, но достига стената на мащабиране ($4.75 \rightarrow 2.16$ след 20 кръга, а не < 0.5); **Goofspiel K=4** осцилира, вместо да се сближава (отбелязана аномалия в кода, документирана, но не поправена); и в играта „**изкачване**“ нито един метод не достига оптимума 11 (IL/MAPPO 7; MADDPG във вариант в стила на COMA – 5) – централизиращият оценител напасва по-добре целевата стойност, но сам по себе си не решава координатията, когато изследването е трудно.

Връзка с дисертацията. PSRO представлява итерирания най-добър отговор от Глава 2, издигнат до популационно равнище и служещ като емпиричен гръбнак на настоящата работа; LOLA е *динамично* моделиране на противника – насочено към движеща се цел допълнение към статичната преценка за противника от Глава 7 (Принос №1); мета-играта на PSRO е методология за оценка на популационно равнище (Принос №3). Стената на мащабиране при Ледюк отразява откритието глобално срещу локално от Глава 8, а мястото, където престава да важи всяка гаранция за игри с двама играчи – **липсващата минимаксна опора за $N \geq 2$** – е именно проблемната постановка на Принос №2.

Отворени въпроси. Може ли приблизителен (RL) оракул да доближи PSRO в Ледюк до равновесието на Наш и до колко това отслабва гаранцията? Какво прекъсва колебанието при Goofspiel-K=4 (премахване на дубликати? смесена популация? различен мета-решател?) и защо централизиращият оценител *вреди* в играта „изкачване“? И под всичко това: без минимаксна стойност за $N \geq 2$, какво означава „безопасен“ за една популация и може ли мета-играта на PSRO да осигури заместител (Принос №2)?

Глава 10 Резюме – Обучение на базата на популации и еволюционна теория на игрите

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Проблем. Самообучението може да се върти в кръг: в циклична игра (камък-ножица-хартия) „да станеш по-добър“ няма смисъл, така че популация, която тренира единствено срещу себе си, започва да се върти вместо да се подобрява. Глава 10 е популационното ниво на дисертацията – как да *диагностицираме* дали една игра/популация е стълбица на уменията или кръг от контрастратегии и как да *тренираме и оценяваме* цяла популация от агенти. Тя е отправната точка за автоматизирано моделиране на противника (#1), безопасна експлоатация на популационно равнище без опора в минимаксната стойност (#2) и оценка на популационно равнище (#3).

Подход. Две части, и двете оценявани спрямо точни еталонни стойности. **Част I – еволюционна теория на игрите като диагностика:** репликаторна динамика върху четири решими матрични игри (проверени спрямо аналитичните ESS и равновесия на Наш) и декомпозицията „пумпал“ на транзитивна и циклична част. **Част II – PBT лига в стила на AlphaStar** от невронни PSRO агенти на Ледюк Холдем (три типа агенти: основни агенти / основни експлоататори / експлоататори на лигата, плюс замразяване и PFSP), оценявана с EGTA/мета-Наш, Ело и метрики за разнообразие – всяка невронна стратегия е извлечена в *таблична* стратегия, така че точният най-добър отговор от Глава 7 да измери нейната експлоатируемост. **Всички числа по-долу са измерени.**

Ключови резултати (измерени).

- *Репликаторната динамика възпроизвежда всеки аналитичен резултат.* Дилемата на затворника → всички избират „предателство“; „Ястреб-гълъб“ → вътрешната ESS 0,5 (орбитален радиус 0,0); **камък-ножица-хартия никога не се сближава** (обикаля около центъра на разстояние 0,095); „Лов на елен“ → чиста ESS според бैसेйна на привличане.
- *Диагностиката „пумпал“ работи и структурата на Ледюк зависи от популацията.* Декомпозицията на Ходж дава за „камък-ножица-хартия“ транзитивна компонента 0,0 и циклична 1,0, а за стълбицата на уменията – 1,0 и 0,0 (методът SVD с ранг 1 неправилно дава 0,707 за „камък-ножица-хартия“). Мета-играта на **най-добрите отговори** в PSRO за Ледюк е предимно **циклична** (транзитивно съотношение ≈ 0.45 , 27 цикъла от три стратегии); мета-играта на **моментните снимки на лигата** е предимно **транзитивна** (≈ 0.94 –0,98) – прогноза, която измерванията опровергава (§3 и §8.2 от доклада).
- *Лигата произвежда силни отделни агенти.* Най-добрата ѝ замразена моментна снимка достига експлоатируемост (NashConv) 1,305 (пълнен мащаб) – по-добре от PSRO с точен оракул (2,163) и сравнимо с най-добрата итерация на самообучението (1,396; крайният агент е 3,683), при едно изпълнение; долната граница, CFR (равновесие на Наш), е 0,0099.
- *Отрицателни резултати (запазени прогнози).* Експлоатируемостта на лигата е **немонотонна при пълнен мащаб** (4,73 → мин. ≈ 1.21 → 2,05 за 120 епохи) – активните агенти регресират късно; най-добрите агенти са замразени моментни снимки. И **мета-Наш сместа е по-експлоатируема от най-добрия член на популацията** при пълнен мащаб (3,418 > 1,305) – мета-Наш минимизира съжалението в мета-играта, а не експлоатируемостта в пълната игра, а мета-Наш не даде никакво тегло на най-малко експлоатируемия агент. Разнообразието е слабо (коефициент на участие 1,9, един поведенчески клъстер).

Връзка с дисертацията. Лигата представлява PSRO от Глава 9, реализирано асинхронно чрез невронни оракули, като използва точния най-добър отговор от Глава 7 като еталон; основните експлоататори на практика са автоматизирани модели на противника (Принос №1); EGTA/мета-Наш е методологията за оценяване на популацията (Принос №3). Липсващата гаранция на лигата – възможността ѝ да регресира и фактът, че нейната смес може да бъде експлоатируема – представлява популационната форма на **липсващата опора за безопасност при $N > 2$ играчи** (Принос №2). Транзитивната/циклична диагностика предсказва, че коалиционните игри всеки срещу всеки от Глава 11 ще бъдат силно циклични.

Отворени въпроси. Премахва ли запазването на най-добрата моментна снимка или **регуляризацията на популацията** късната регресия (поправка в обучението), или тя е присъща на дизайна с три типа агенти (поправка в дизайна)? Трябва ли като резултат от популацията да се използва избран член, **устойчив срещу най-добър отговор**, или **мета-решавател с регуляризация за разнообразие** вместо **мета-Наш сместа**? И по-дълбокият въпрос зад двата: при липса на **минимаксна стойност** за популацията, какво означава „безопасно“ и може ли **механизмът с експлоататори** да получи гаранция, вместо да остане **евристика** (Принос №2)?

Глава 11 Резюме – Формиране и засичане на коалиции

Изследване на възможностите за приложение на изкуствения интелект в компютърни игри

Alexander Andreev

July 2026

Проблем. Глави 2–10 се опираха на една опора: игра с двама играчи с точен най-добър отговор и оракул за експлоатируемост, така че на въпроса „проработи ли?“ се отговаряше с едно число. С трети играч стават възможни съюзи – формиране, експлоатация, предателство – а равновесието на Наш става едновременно изчислително непосилно и лишено от гаранции, тъй като изобщо не отчита коалициите. Глава 11 умишлено премахва тази опора. Тук е отвореният край на дисертацията, а не етап на затвърждаване.

Подход. Създаден е собствен **двигател на So Long Sucker** за 4 играчи – играта на Хауснер, Наш, Шапли и Шубик, публикувана през 1964 г. – по публикуваните правила; единствената точна опорна точка е **минимаксът на крайната фаза**, а анализът ѝ от De Carufel & Jerade още не е сверен с двигателя. Върху него са надградени: **детектор на коалиции** (помощ и вреда според поставянето на жетоните), **стойност на Шапли**, предефинирана като принос на играча към вероятността за победа, обучение **MARPO с отчитане на коалициите**, което смесва коалиционния принос и наградата „победителят взема всичко“ с тегло α , и анализ **EGTA + разлагане „пумпал“**, преизползван от Глава 10. **Всички резултати по-долу са измерени**; `scale_results.json` е прогон **отпреди поправката** и служи само като доказателство за грешката – меродавни са `sweep_scale.json` (5 начални числа) и `smoke_results.json` след поправката.

Ключови резултати (измерени).

- *Сертифицирано там, където съществува точност.* 100/100 случайни игри завършват, сумата на наградите във всяка игра е нула, `endgame_mismatches`: 0 спрямо точния минимакс. Детекторът разпознава **предварително зададената коалиция {0, 1}** само от потока от ходове (резултат на двойката **10,0**, за останалите 0 или -1; проверено срещу една програмирана, открита двойка), а стойността на Шапли точно възпроизвежда опростените игри „ръкавици“ и „мнозинство“, включително празното ядро.
- *Най-голямото откритие е грешка, чийто урок я надживя.* Две неуспешни проверки имаха една причина: **~99,5% от случайните игри в този двигател завършват с пат**, така че победителят се определя от `_most_chips`, чието правило при равенство (най-малък индекс) даваше на място 0 двоен дял (случайни победители [94, 42, 33, 31]). При безпристрастно разрешаване на равенството размахът на симетричния принос по Шапли спадна от **0,54 до 0,013**, а победителите станаха равномерни; същата поправка свали впечатляващия дял победи на собствения агент от **0,87** до реалните **~0,41** при ниво на случайната игра 0.25. В игра, която почти винаги завършва с равен резултат, правилото при равенство е решаващо.
- *Нулевият резултат при пълния мащаб се опроверга с намирането на решаващия параметър – с уговорка.* α доминира и **стойността по подразбиране 0,3 е в мъртва зона**: при $\alpha \sim 0$ разликата при заместителя е **+0,0376 +/- 0,0103** (резултатът на агентите с принос е ~4,5 пъти **0,0109** при рядката награда), а **всяка клетка с $\alpha \geq 0.3$ при пълния мащаб е отрицателна**. Ефектът е 12 пъти по-голям при пълния мащаб (но там се менят и размерът, и дължината на обучението), а заместителят от оценките на оценителя дава по-силен ефект от приноса чрез симулации (**+0,038 срещу +0,013**). Но нито един от двата вида принос не показва кой на кого помага, а коалиционният резултат отчита и враждебните взаимодействия: плътната награда повишава резултата, което още не доказва научени коалиции.
- *Коалиционният резултат се купува, не е безплатен.* $\alpha = 0$ сваля дела на победите на собствения агент до **~0,29**, близо до нивото на случайната игра (0,25), а при $\alpha \geq 0.1$ той е **~0,52**.
- *Силна циклична компонента, но под прага.* Популацията „стълба на уменията“ е преобладаващо транзитивна (циклично съотношение **0,25-0,31**), а коалиционната повишава цикличното съотношение до **~0,57-0,69** – много, но недостатъчно за строгото правило „>50% доминиране“, така че проверката остава неуспешна. Проверки: **4 от 5 успешни**.

Връзка с дисертацията. Принос №1 се обобщава естествено: моделирането на противника се разширява от „какъв тип играч е това“ към „кой с кого е в съюз“, изведено направо от ходовете. Принос №2 получава по-точна постановка, а не решение – без минимаксна стойност и при **празно ядро** „безопасен“ не може да означава ограничено отклонение от равновесието; поведенческа опорна стратегия по подобие на `riKL` е кандидат, а не гаранция. Принос №3 получава работещ заместител на експлоатируемостта чрез EGTA и разлагането „пумпал“, с уговорката от Глава 10, че съставът на популацията определя дали се вижда стълба, или колело.

Отворени въпроси. Най-ценната следваща стъпка е да се сверят редът на ходовете и правилото при равенство с формализацията на De Carufel & Jerade – към тези опростявания водят и грешката с място 0, и неуспешната проверка за цикличност. Дали проекция за EGTA с 3 или 4 играчи ще разкрие цикличността, която свиването до 2 типа губи. Дали принос, изграден върху матрицата на помощта и вредата от детектора и сравнен с плътна награда без коалиционна информация, поражда истински коалиции. И какво може да означава „безопасен“ при празно ядро.

Глава 12 Резюме – Модели на последователности и агенти с голям езиков модел в стратегически среди

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Проблем. Два посткласически подхода заобикалят всичко от глави 2–11. **Моделирането на последователности** преформулира играта като условно предсказване – подават се на трансформър тройки (остатъчна възвръщаемост, състояние, действие) и се иска следващото действие при желана възвръщаемост, без функция на стойността и самообучение; **ARDT** добавя минимаксно преетикетиране за устойчивост в най-лошия случай. **Агентите с големи езикови модели** пропускат обучението и получават правилата на английски. Главата ги оценява спрямо точен еталон.

Подход. Кун покер, за който глава 2 дава точно равновесие на Наш и точна експлоатируемост, и ограничено пренасяне към Ледюк Холдем като проверка при по-сложна игра. Сравнени са: CFR (равновесие на Наш), поведенческо клониране, Decision Transformer, ARDT и четири агента с голям езиков модел (офлайн заглушка без модел; gpt-oss-20b, Qwen2.5-7B и OpenThinker3-7B, локално в LM Studio на RTX 5090, температура 0,7), и допълнителни експерименти за това *защо* класацията е такава. **Всички числа по-долу са собствени измервания** от записаните JSON файлове, с две уговорки: два резултата бяха **оттеглени** (невъзможна затворена част от разликата +1.59 и резултат -0.83 в Ледюк от декодер, който отхвърля 70% от вероятностната маса), а експлоатируемостта на референтното равновесие е 0.0162 жетона при 5 000 итерации на CFR и 0.0061 при 50 000 – и двете ~0.

Ключови резултати (измерени).

- Обикновеното клониране бие DT и ARDT. **BC 0,055 < ARDT 0,469 < DT 0,799** спрямо равновесие **0,0162**; реалните езикови модели са между **0,25 и 0,33** (заглушката без езиков модел: 0,833). Клониранието остава на 0,04 жетона от равновесието, като копира почти равновесна стратегия; DT прекарва същата стратегия през обуславяне по възвръщаемост, която носи предимно късмет, и така унищожава информация.
- Обуславянето по възвръщаемостта не насочва стратегията в нито една от двете игри. $\text{high}(+2) = 0.6981$ срещу $\text{low}(-2) = 0.6928$: равни и подредени грешно. Обяснението за Кун (само 4 възможни стойности на печалбата) беше **наполовина опровергано** в Ледюк: при 15 стойности предвиденият артефакт изчезна, но насочване пак не се появи ($r = +0.062$).
- Моделите играят по-добре, отколкото могат да обяснят. Изходната хипотеза беше „знае правилната честота, но не може да я изиграе“; данните показват обратното. Оценени като стратегии, *заявените* честоти са много по-лоши от *изиграните* – Qwen **0,921 срещу 0,357** жетона, gpt-oss **1 576 срещу 0,392**. Проучете поведението; не питайте.
- Експлоатиращ по подразбиране, но не адаптивен. Срещу единствения противник с достатъчна статистическа мощност („Винаги пас“) моделът (Qwen2.5-7B, 120 раздавания) улавя **83%** от наличната експлоатация още от първата половина и не се подобрява (при другите два грешката е $\pm 0,53-0,80$). Срещу ботовете печели **0,177 жетона на раздаване срещу 0,110 за равновесието** при експлоатируемост 0,357 срещу 0,006; близо 90% от предимството идва от пасивния и случайния противник.
- Размерът на модела не обяснява класацията, а предимството на езиковите модели важи само за Кун. **Qwen2.5-7B побеждава gpt-oss-20b (3,6 млрд. активни параметъра) с +0,162 жетона на раздаване** при 20 хил. раздавания на двойка, строго транзитивно. В Ледюк езиковият модел е неразличим от DT (-0.463 срещу -0.454) и губи средно от слабите противници (-0.071 срещу $+0.582$ за равновесието; печели само срещу двата пасивни типа); **100%** от масата му за недопустими действия е едно погрешно схващане: отказ, когато чекът е безплатен.
- Една скаларна величина скрива диагнозата. Един възел „Дама“ носи **41,4%** от общата експлоатируемост, а залагането за стойност с „Поп“ при 1,00 (изчисленото равновесие смесва с 0,68) струва **0,1%** – размерът и цената на отклонението почти не са свързани. Проверки: **3 успешни / 2 неуспешни**, оставени както са.

Връзка с дисертацията. Първият принос получава ценен отрицателен резултат: адаптация от историята в контекста не се появява (на съобщен тип противник моделите реагират), затова моделът на противника трябва да се изгради изрично. За втория принос компромисът е измерен: повече експлоатация (0,177 срещу 0,110) при много по-висока експлоатируемост (0,357 срещу 0,006), главно срещу слаби противници. Третият получава разлагането по решения и протокола за измерване.

Отворени въпроси. Най-вероятното решение е $Q(s, a)$ на ARDT (още непроверено; при случайни ходове като раздаването минимаксната цел на ARDT не е точна): оценител само на състоянието не различава „това състояние е лошо“ от „това действие е лошо“ – вероятно затова серията по τ противоречи на теорията и експлоатируемостта е *най-ниска* от оптимистичната страна; стойността по подразбиране е оставена теоретично правилната, а не нагласена за по-добър резултат. Дали грешката в Ледюк се отстранява с един ред в подканата. Уговорка: изводите за езиковия модел в Ледюк почиват на един модел, един стил на подкана и 600 раздавания.