

Доклади по глави

Изследване на възможностите за приложение на изкуствения интелект в
компютърни игри

Александър Андреев

Юли 2026

Съдържание

1	Глава 01 – Основи на обучението с подкрепление: Доклад за реализацията	4
1.1	Съдържание	4
1.2	Преглед	5
1.3	DQN – Дълбока Q-мрежа	5
1.4	PPO – оптимизация на стратегията с ограничение на близостта	7
1.5	Сравнение с базовите решения на SB3	9
1.6	Ключови изводи	13
1.7	Приложение – Възпроизвеждане	14
2	Глава 02 – Основи на теорията на игрите и CFR: Доклад за реализацията	15
2.1	1. Какво беше разработено	15
2.2	2. Ключови резултати и визуализации	15
3	Глава 03 – Варианти на CFR и методи на Монте Карло: Доклад за реализацията	19
3.1	1. Разработени елементи	19
3.2	2. Игрови двигател за Ледюк покер	20
3.3	3. Реализации на алгоритми	20
3.4	4. Фаза на изследване (референция OpenSpiel)	22
3.5	5. Сравнителен тест с бюджет от 180 секунди време за изпълнение	26
3.6	6. Кръстосана проверка спрямо OpenSpiel	28
3.7	7. Възпроизвеждане	29
4	Глава 04 – Абстракция на играта и мащабиране на игри с непълна информация: Доклад за внедряването	30
4.1	1. Какво беше разработено	30
4.2	2. Модули за абстракция	31
4.3	3. Еталонен тест на CFR+ с ограничено време	32
4.4	4. Парето граница	36
4.5	5. Кръстосана проверка	37
4.6	6. Ключови изводи	37
4.7	7. Възпроизвеждане	38
5	Глава 07 – Моделиране на противника в игри с непълна информация	39
6	ЧАСТ I – ИЗСЛЕДВАНЕ НА КУН ПОКЕР	39
6.1	1. Предмет на изследването в тази глава	39
6.2	2. Експеримент 1 – Поведенчески отпечатъци	40
6.3	3. Експеримент 2 – Възможност за експлоатация (защо си струва усилието)	42
6.4	4. Експеримент 3 – Детектор на тип по Байес (ядрото на цикъла)	43
6.5	5. Експеримент 4 – Възстановяване на сместа чрез модел на смес с ЕМ	46
6.6	6. Какво установява Част I	49
7	ЧАСТ II – ПЪЛНА СИСТЕМНА ОЦЕНКА НА „КУН“ И „ЛЕДЮК“	50
7.1	7. Какво тества и как	50
7.2	8. Откриване – кой е опонентът?	52
7.3	9. Експлоатация – каква печалба носи моделирането?	53
7.4	10. Нестационарност – адаптиране към смяна по време на игра	55

7.5	11. Достатъчни ли са размерите на извадките?	58
7.6	12. Ограничения	59
7.7	13. Заключение и насоки за бъдещи изследвания	60
7.8	14. Възпроизвеждане	61
8	Глава 08 – Безопасна експлоатация в игри с непълна информация	62
9	ЧАСТ I – КОМПРОМИСЪТ, ВИДИМ ВЪРХУ КУН	62
9.1	1. За какво става дума в тази глава	62
9.2	2. Експеримент 1 – наивната граница между равновесието на Наш и най-добрия отговор	64
9.3	3. Експеримент 2 – наивната серия по бюджета на RNR (и една уговорка) . . .	65
9.4	4. Какво установява Първа част	67
10	ЧАСТ II – ПЪЛНА ОЦЕНКА НА СИСТЕМАТА ВЪРХУ КУН И ЛЕДЮК	67
10.1	5. Какво тестваме и как	67
10.2	6. Подробната таблица метод × противник (Кун)	69
10.3	7. Ефективната граница – и скокообразното превключване	71
10.4	8. Prime-safe / адаптация и измереният ϵ -бюджет	74
10.5	9. Обучаващата атака – защо осъществената печалба е грешната гледна точка .	74
10.6	10. Ледюк – основният извод: при лимит 40 итерации глобалните решавачи не достигат сходимост, а SES (лимит 400) достига	76
10.7	11. Достоверни ли са резултатите?	79
10.8	12. Ограничения	80
10.9	13. Заключение и насоки за бъдещи изследвания	81
10.10	14. Възпроизвеждане	82
11	Глава 9 – Многоагентно обучение с подкрепление: Доклад за експериментите	84
12	ЧАСТ I – ЗАЩО МНОГОАГЕНТНОТО ОБУЧЕНИЕ Е ТРУДНО	85
12.1	1. Какво разглеждаме тук	85
12.2	2. Експеримент 1 – независими обучаващи се агенти в четирите матрични игри	85
12.3	3. Експеримент 2 – орбитата на нестационарността („съвпадение на монети“ спрямо дилемата на затворника)	86
12.4	4. Експеримент 3 – самообучение в Кун: средна срещу последна итерация . . .	87
13	ЧАСТ II – СТРУКТУРНИТЕ РЕШЕНИЯ	88
13.1	5. Експеримент 4 – PSRO при различни семейства игри	88
13.2	6. Експеримент 5 – CTDE: остатък на оценителя и играта „изкачване“	89
13.3	7. Експеримент 6 – научена комуникация (CommNet)	90
13.4	8. Експеримент 7 – LOLA в повтарящата се дилема на затворника	91
13.5	9. Съпоставка на прогнозите с реалността	92
13.6	10. Достоверност и достатъчност на извадката	93
13.7	11. Ограничения (подредени според влиянието им върху изводите)	94
13.8	12. Заключение и насоки за бъдещи изследвания	94
13.9	13. Възпроизвеждане на резултатите	95
14	Глава 10 – Обучение на базата на популации и еволюционна теория на игрите: експериментален доклад	96

15 ЧАСТ I – ЕВОЛЮЦИОННА ТЕОРИЯ НА ИГРИТЕ КАТО ДИАГНОСТИЧЕН ИНСТРУМЕНТ	97
15.1 1. Какво разглежда тази глава	97
15.2 2. Експеримент 1 – репликаторна динамика върху четири матрични игри . . .	97
15.3 3. Експеримент 2 – „пумпалът“: транзитивна и циклична структура	100
16 ЧАСТ II – ЛИГАТА С РВТ	102
16.1 4. Какво представлява лигата и как се оценява	102
16.2 5. Експеримент 3 – динамика на обучението в лигата	103
16.3 6. Експеримент 4 – EGTA, мета-Наш и разнообразие	104
16.4 7. Експеримент 5 – лигата срещу PSRO, самообучението и CFR (равновесие на Наш)	106
16.5 8. Съпоставка на прогнозите с резултатите	108
16.6 9. Достоверност и достатъчност на извадката	110
16.7 10. Ограничения (подредени според степента на влияние върху заключенията)	110
16.8 11. Заключения и насоки за бъдещи изследвания	111
16.9 12. Възпроизвеждане на резултатите	112
17 Глава 11 – Формиране и засичане на коалиции (So Long Sucker): експериментален доклад	113
17.1 Част I – МЕХАНИЗМЪТ И НЕГОВИТЕ ТОЧНИ ОПОРНИ ТОЧКИ	114
17.2 За какво е тази глава	114
17.3 Експеримент 1 – двигателят на SLS спрямо точната крайна фаза с двама играчи	115
17.4 Експеримент 2 – детекторът на коалиции спрямо предварително зададен съюз	116
17.5 Експеримент 3 – принос по Шапли: точни опростени игри, после позиции в SLS	118
17.6 Част II – ОБУЧЕНИЕ НА КОАЛИЦИИ И АНАЛИЗ НА ПОПУЛАЦИЯТА	120
17.7 Експеримент 4 – MAPPO с отчитане на коалициите и серията експерименти по alpha	120
17.8 Експеримент 5 – EGTA и разлагането „пумпал“: циклична ли е SLS?	123
17.9 Обобщение на проверките	124
17.10 Съпоставка прогноза ↔ резултат	125
17.11 Достоверност и достатъчност на извадката	128
17.12 Ограничения (подредени по влияние върху заключенията)	128
17.13 Заключения и насоки за бъдещи изследвания	129
17.14 Възпроизвеждане	130
18 Глава 12 – Модели на последователности и агенти с голям езиков модел в стратегически среди: Доклад от експеримента	132
18.1 За какво е предназначена тази глава	132
18.2 Основният резултат от сравнението	133
18.3 Петте цели за валидиране	135
18.4 МАТЕМАТИЧЕСКИ ФЛАГ Б – посоката на експектила в ARDT	137
18.5 Последващи експерименти: какво крие скаларната оценка	139
18.6 Ледюк Холдем – проверка на сложността	144
18.7 Съпоставка: прогноза и реалност	146
18.8 Достоверност и достатъчност на извадката	147
18.9 Ограничения (подредени според значимостта им за заключенията)	148
18.10 Заключения и насоки за бъдещи изследвания	148

1 Глава 01 – Основи на обучението с подкрепление: Доклад за реализацията

Среда: април 2026 г.

Алгоритми: DQN (CartPole-v1), PPO (LunarLander-v3)

Цели: DQN ≥ 475 , PPO ≥ 200 (средна стойност от 100 епизода)

Статус: И двете цели са постигнати ✓

1.1 Съдържание

- Преглед
 - DQN – Дълбока Q-мрежа
 - Архитектура
 - Ключови проектни решения
 - Итерации на хиперпараметри
 - Окончателни резултати
 - PPO – оптимизация на стратегията с ограничение на близостта
 - Архитектура
 - Ключови проектни решения
 - Итерации на хиперпараметри
 - Окончателни резултати
 - Сравнение с базовите решения на SB3
 - Ключови изводи
-

1.2 Преглед

Глава 01 реализира два фундаментални RL алгоритъма от нулата с **PyTorch**, като включва подробни коментари в кода, обясняващи *защо* зад всяко проектно решение. И двата алгоритъма са сравнени със Stable-Baselines3 (SB3): PPO – с нашите хиперпараметри, DQN – с настроените за CartPole стойности от RL Baselines3 Zoo (вж. Сравнение).

Структура на изходния код:

```
implementation/step01/
├─ dqn/
│   ├── replay_buffer.py    # Circular buffer, random batch sampling
│   ├── q_network.py       # MLP Q-function
│   ├── agent.py           # DQNAgent: select/store/train/sync/save
│   └─ train.py            # Training loop, best-model checkpointing, early stop
├─ ppo/
│   ├── networks.py        # PolicyNetwork (actor), ValueNetwork (critic)
│   ├── gae.py             # Generalized Advantage Estimation (reverse sweep)
│   ├── agent.py           # PPOAgent: rollout → GAE → clipped SGD
│   └─ train.py            # Training loop, rollout collection, logging
├─ compare_sb3.py          # Comparison script - reads TB logs, trains SB3
├─ config.py               # DQN_CONFIG, PPO_CONFIG
├─ utils/
│   └─ logger.py           # TensorBoard SummaryWriter wrapper
```

1.3 DQN – Дълбока Q-мрежа

1.3.1 Архитектура

Среда: CartPole-v1 – четиримерен непрекъснат вектор на наблюдение, два вида дискретни действия и максимум от 500 стъпки в един епизод.

Q-мрежа: Два скрити слоя с активации ReLU и без изходна активация (тъй като Q-стойностите могат да приемат всяка реална стойност). Размерът ѝ е [obs_dim=4 → 128 → 128 → 2].

Буфер за повторение на опита: Предварително заделени numpy масиви с кръгов курсор за запис, които съхраняват кортежи от вида (състояние, действие, награда, следващо състояние, приключено). Случайната извадка от минипакет прекъсва времевата корелация между последователните преходи.

Целева мрежа: Замразено копие на Q-мрежата, което се синхронизира на всеки `target_update_freq` епизода. Предотвратява нестабилния цикъл на обратна връзка, при който целта се изменя със същата скорост като прогнозите, които се обучават.

1.3.2 Ключови проектни решения

Решение	Избор	Обосновка
График на изследване	Епизодно базирано ϵ -затихване ($\epsilon \times 0.995$ на епизод)	По-предвидимо е от базираното на стъпка, когато дължината на епизода варира
Минимален епсилон	$\epsilon_{\min} = 0.001$	Избягва смъртоносни случайни действия след сходимост; по-нисък от стандартния 0,05 на SB3
Синхронизация на целта	На всеки 5 епизода	Балансира стабилност и скорост; твърде рядка (на всеки 10) водеше до по-бавни плата
Размер на мрежата	[128, 128]	С мрежа [64, 64] се достигаше плато около 300 средна награда; по-голяма мрежа се учеше по-бързо
Размер на буфера	50 000	По-малък (10K) водеше до преобучение към скорошен опит

1.3.3 Итерации на хиперпараметри

Окончателната **конфигурация** беше достигната след три кръга от настройки:

Изпълнение 1 – Базова линия (500 епизода)

- Конфигурация: `buffer=10K`, `hidden=[64,64]`, `episodes=500`, `target_freq=10`, `ε_min=0.01`
- Резултат: Крайна средна стойност 225; не се премина целта от 475
- Проблем: Малък буфер и мрежа; редки актуализации на целта

Изпълнение 2 – Първа настройка (1000 епизода)

- Конфигурация: `buffer=50K`, `hidden=[128,128]`, `episodes=1000`, `target_freq=5`, `ε_min=0.01`

- Резултат: Постигната пикова средна стойност **479,1** на епизод 810, но в края тя спадна до 302,6
- Проблем: $\epsilon_{\min}=0.01$ означава постоянно 1% случайни действия – достатъчно, за да се прекратят дългите епизоди
- Необходима корекция: Намаляване на стойността на $\epsilon_{\min}$ + добавяне на запазване на най-добрия модел

Изпълнение 3 – Финално (1500 епизода, добавено ранно спиране)

- Конфигурация: същата + $\epsilon_{\min}=0.001$, episodes=1500
- Добавено запазване на най-добър модел и ранно спиране (запазва при първо достигане на целта от 475 и прекратява обучението)
- Резултат: **Решена в епизод 1011**, Средна стойност(100) = **477,5** ✓

1.3.4 Крайни резултати

Метрика	Стойност
Решена в епизод	1011
Финална средна награда (100 еп.)	477,5
Цел	475,0
Общо обучени епизоди	1011 (ранно спиране)
Най-добър модел	models/dqn_cartpole_best.pt

1.4 PPO – оптимизация на стратегията с ограничение на близостта

1.4.1 Архитектура

Среда: LunarLander-v3 – 8-измерно непрекъснато наблюдение и 4 дискретни действия. Успешното кацане носи +200 точки, катастрофата води до -100, а разходът на гориво се санкционира.

Актьор-оценител (отделни мрежи): - **PolicyNetwork:** [obs=8 → 128 → 128 → 4] с логити, преобразувани в Categorical разпределение - **ValueNetwork:** [obs=8 → 128 → 128 → 1] с изход като неограничена скаларна величина

Отделните мрежи предотвратяват смущението в градиента между стратегията и стойностната цел. Един оптимизатор Adam обучава и двете чрез комбинираната загуба.

Обобщена оценка на предимството (generalized advantage estimation, GAE; $\lambda=0.95$):

Изчислява се чрез обратно обхождане на буфера за разгръщане. Маската (1 – done) нулира стойностите от буутстрапинга в границите между епизодите, като по този начин коректно обработва разгръщанията, които преминават през множество епизоди.

Изрязана сурогатна цел:

$$L^{CLIP} = \mathbb{E} \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]$$

където $r_t(\theta) = \pi_\theta(a|s) / \pi_{old}(a|s)$ и $\epsilon = 0.2$.

1.4.2 Ключови решения в проектирането

Решение	Избор	Обосновка
Нормализиране на предимството	Средна стойност нула, единично стандартно отклонение за всяко разгръщане	Стабилизира големината на градиента при различни мащаби на наградата
Бонус за ентропия	coef = 0.01	Предотвратява преждевременен колапс на стратегията; насърчава изследването
Изрязване на градиента	max_norm = 0.5	Избягва експлодиращ градиент по време на ранното обучение
Дължина на разгръщане	n_steps = 2048	Достатъчно дълго за многостъпково разпределяне на заслугата при кацания
SGD с минипартиди	10 епохи, партида=64	Стандартен PPO; всяко разгръщане се използва повторно 10 пъти преди изхвърляне

1.4.3 Итерации на хиперпараметрите

Изпълнение 1 – Базова линия (300K стъпки, hidden=[64,64])

- Резултат: Постигната пикова средна стойност **179,9**, без преминаване на целта от 200

- Проблем: недообучение – малката мрежа не успява да обхване 8-измерното наблюдение на LunarLander
- Също така: 300K стъпки се оказаха малко недостатъчни за пълна сходимост

Изпълнение 2 – Финално (500K стъпки, hidden=[128,128])

- Размерът на мрежата е удвоен; обучителният бюджет е увеличен с 67%
- Резултат: **Решено на 264K стъпки** (задействано е ранно спиране), средната стойност за 100 епизода = **202,2** ✓
- Забележително: проблемът е решен 236K стъпки *преди* изчерпването на обучителния бюджет


1.4.4 Финални резултати

Метрика	Стойност
Решено на стъпка	264 192
Финална средна награда (100 епизода)	202,2
Цел	200,0
Общо обучени стъпки	264 192 (ранно спиране)
Най-добър модел	models/ppo_lunarlander_best.pt

1.5 Сравнение с базовите решения на SB3

PPO на SB3 беше обучен с нашите основни хиперпараметри (скорост на обучение, γ , размер на мрежата, диапазон на изрязване и др.) и същия бюджет от 500K стъпки. DQN на SB3 беше обучен с настроените за CartPole-v1 хиперпараметри от RL Baselines3 Zoo за 100K стъпки (изпълнение от 6 април 2026 г., начално число 42). Източник: `implementation/step01/compare_sb3.py`; наградите по епизоди на SB3 са в `sb3_results_cache.json`.

1.5.1 4,1 DQN върху CartPole-v1



Фигура 1: DQN върху CartPole-v1: плъзгаща се средна на наградата за 100 епизода, собствена реализация срещу SB3 (първите 1 061 от 1 255 епизода на SB3).

Собственият DQN решава CartPole около епизод ~1011 и достига целта от 475 (средна награда за последните 100 епизода). **DQN на SB3** (настройки на RL Zoo: скорост на обучение 0,0023, [256, 256], синхронизация на целевата мрежа на всеки 10 стъпки, `train_freq=256` със 128 градиентни стъпки, $\epsilon \rightarrow 0,04$ през първите 16K стъпки) е обучен 100K стъпки (1 255 епизода). Най-добрата му плъзгаща се средна за 100 епизода е **222,4**, при епизод 695 (≈ 51 K стъпки), а крайната – 134.3. Фигурата показва първите му 1 061 епизода.

Заменено изпълнение. По-ранно изпълнение на DQN на SB3 (3 април 2026 г.: 750K стъпки, 17 176 епизода, нашите основни хиперпараметри с `exploration_fraction=0.36` и `target_update_interval=1000`) достига най-много 293.9. На 6 април то е заменено с горното; резултатите му остават в историята на `sb3_results_cache.json` в git (commit 4a173d2).

Защо тази разлика? Не е установено. Тъй като SB3 използва настроени хиперпараметри, а не същите като нашите, сравнението не е равностойно. Две различия не са проверени:


1. **Изследване в показаните епизоди:** наградите са от епизоди на обучение, в които SB3 все още избира случайно действие в 4% от случаите (крайно $\epsilon = 0,04$), докато нашият ϵ

($\times 0,995$ на епизод) е около 0,006 към момента на решаването на задачата.

2. **Обновявания на стъпка:** SB3 прави 128 градиентни стъпки на всеки 256 стъпки на средата – наполовина по-малко обновявания на стъпка от нашия агент, който обновява мрежата при всяка стъпка.

Всяка реализация е изпълнена веднъж (нашата – без фиксирано начално число), а Zoo обучава тези настройки 50K стъпки, така че неуспехът на SB3 при 100K трябва да се провери с второ начално число, преди да се тълкува като свойство на SB3.

1.5.2 4,2 PPO на LunarLander-v3



Фигура 2: PPO върху LunarLander-v3: плъзгаща се средна наградата за 50 епизода, собствена реализация (окончателното изпълнение) срещу SB3 (първите 577 от 1 224 епизода).


Собственият PPO достига целта от 200 около епизод ~543 (264K стъпки). **PPO на SB3**, със същия бюджет от 500K стъпки, постига най-добра плъзгаща се средна за 100 епизода **131,2** и продължава да се покачва в края на обучението. (Прозорецът на плъзгащата се средна във фигурата е 50 епизода; числата в текста са за 100.)

Разликата тук е по-малка, отколкото при DQN. И двата алгоритъма използват идентични хиперпараметри на PPO. Оставащата разлика може да се дължи на: - ортогоналната инициализация на теглата в SB3; - нормализирането на предимството в SB3 във всяка мини-партида,

а не в цялото разгръщане; - случайността: всяка реализация е изпълнена веднъж.

При предоставяне на по-голям обучителен бюджет (напр. 1–2 милиона стъпки) PPO на SB3 вероятно би достигнал целта. В това единствено изпълнение нашият собствен PPO използва данните по-ефективно от SB3 при тази задача.

1.5.3 4,3 Обобщение на постигнатата максимална производителност



Фигура 3: Най-добра плъзгаща се средна за 100 епизода: собствените реализации срещу SB3.

Алгоритъм	Среда	Наша най-добра плъзгаща се средна (100)	Най-добра плъзгаща се средна на SB3 (100)	Цел
DQN	CartPole-v1	477,5	222,4	475
PPO	LunarLander-v3	203,6	131,2	200

Методологична бележка: „Най-добра плъзгаща се средна (100)“ е максимумът на плъзгащата се средна за 100 епизода по цялата крива на обучение. Тази метрика е справедлива независимо от ранното спиране: тя измерва пиковата способност, а не къде обучението се е случило да приключи. Бюджети за стъпки: PPO – 500K и за двете реализации; DQN на SB3 – 100K (нашият DQN спира при епизод 1011). Нашите стойности са от записите на окончателните изпълнения, прочетени на 3 април 2026 г. (самите записи не са запазени); тези на SB3 се изчисляват от `sb3_results_cache.json`.

1.6 Ключови изводи

1.6.1 5,1 DQN

1. **Запазването на най-добрия модел е от съществено значение:** DQN е податлив на катастрофално забравяне, след като епсилон достигне своя минимум. Запазването на най-добрия модел предотвратява загубата на добро решение.
2. **$\epsilon_{\min}$ има по-голямо значение от очакваното:** Намалването от 0,01 до 0,001 беше разликата между деградираща стратегия и стабилна такава.
3. **Честота на синхронизация на целевата мрежа:** Синхронизирането на всеки 5 епизода последователно даваше по-добри резултати от това на всеки 10. Твърде рядко $\rightarrow$ бавно обучение; твърде често $\rightarrow$ нестабилност (еквивалентно на липса на целева мрежа).
4. **Изследване, базирано на епизод срещу стъпково изследване:** За среди с нарастваща дължина на епизода (като CartPole), намаляването, базирано на епизод, е поестествено – агентът наблюдава повече от динамиката на средата, преди да прекрати изследването.

1.6.2 5,2 PPO

1. **Стеснение в размера на мрежата:** [64, 64] създаде стеснение в обучението върху 8-измерното пространство на LunarLander. Удвояването до [128, 128] беше решаващата промяна.
2. **Нормализирането на предимството беше използвано навсякъде:** без него големината на градиента би зависела от абсолютните награди, които в LunarLander варират от -500 до +300. Изпълнение без него не е записано, така че ефектът му тук е очакван, а не измерен.
3. **GAE $\lambda = 0,95$ е устойчив:** Стандартната стойност работеше добре без настройка.
4. **Бонусът за ентропия предотвратява застой:** Без него стратегията клонеше към „висяне на място“ (локално безопасна, но неоптимална стратегия) в ранните етапи на обучението на LunarLander.

1.6.3 5,3 Реализация от нулата срещу SB3

- Чиста реализация от нулата е с обем 300–500 реда, докато SB3 има ~10 000 реда. Компромисът е по-малко функции, но пълна прозрачност и възможност за отстраняване на грешки.

- Базовият DQN на SB3 използва настроените за CartPole стойности от RL Zoo и в единствено изпълнение при 100K стъпки достига най-много 222,4; това трябва да се провери с второ начално число, преди да се тълкува като свойство на SB3. Нашите реализации, съобразени със задачата, достигат и двете цели.
 - За изследователски цели (дисертационната работа върху експлоатацията на противника, глави 7–8) собствените реализации позволяват целенасочени модификации (например инжектиране на наблюдения на състоянието на убежденията), които биха изисквали дълбоко подкласиране в SB3.
-

1.7 Приложение – Възпроизвеждане

From repo root, with .venv activated:

Train DQN (early stops ~episode 1000):

```
python implementation/step01/dqn/train.py
```

Train PPO (early stops ~step 264K):

```
python implementation/step01/ppo/train.py
```

Regenerate comparison figures (caches SB3 results after first run):

```
python implementation/step01/compare_sb3.py
```

View training curves in TensorBoard:

```
tensorboard --logdir implementation/step01/logs/
```

Записите в TensorBoard от собствените изпълнения не се пазят в хранилището, затова `compare_sb3.py` не може да начертае отново кривите на обучение, докато изпълненията не бъдат повторени. Фигурите тук са запазените изображения (DQN – от 6 април 2026 г., PPO – от 3 април 2026 г.); `deliverables/reports/step01/summary/make_comparison_panels.py` изрязва от тях панела с плъзгащата се средна и превежда надписите.

Генерираните фигури са в `deliverables/reports/step01/figures/`.

2 Глава 02 – Основи на теорията на игрите и CFR: Доклад за реализацията

Среда: април 2026 г.

Игра: Кун покер (3 карти, 2 играчи)

Алгоритъм: минимизиране на контрафактичното съжаление (CFR) с извадка на случайните събития

Цели: стратегии на Наш с точност до четири десетични знака, стойност на играта $\approx -1/18$, експлоатируемост $O(1/\sqrt{T})$

Статус: Целите за стойността на играта и скоростта на сходимост са постигнати; смесените честоти са на 0,005–0,038 от затворената форма (точност до четири знака е постигната само при чистите решения с Поп и с Вале)

2.1 1. Какво беше разработено

Глава 02 реализира модулна версия на минимизирането на контрафактичното съжаление (CFR) с извадка на случайните събития, приложена към Кун покер, написана изцяло на Python. Тя демонстрира, че рамката успешно открива стратегии в равновесие на Наш в многоагентна среда с непълна информация.

Ключови изградени компоненти: - **Игрови двигател:** `kuhn_poker.py` обработва крайни печалби, залагания и представяне на информационните множества. - **Ядро на алгоритъма CFR:** Рекурсивно обхождане на дърво с извадка на случайните събития и напасване на съжалението (`cfr_trainer.py`, `info_set_node.py`). - **Оценител на експлоатируемостта и най-добър отговор:** Брутфорс агрегиране на чисти стратегии за изчисляване на точна експлоатируемост (`evaluate/best_response.py`, `evaluate/exploitability.py`). - **Регистратор на сходимостта и визуализации:** Помощни средства за графично представяне на метрики за експлоатируемостта и сходимостта на стратегията в хода на итерациите (`utils/plotting.py`, `evaluate/convergence.py`). - **Кръстосана проверка с OpenSpiel:** Проверка спрямо стандартни библиотеки с отворен код (`compare_openspiel.py`).


2.2 2. Ключови резултати и визуализации

- **Сходимост към минимаксно оптимална стратегия:** Алгоритъмът се доближава на 0,038 до аналитичното семейство от равновесия на Наш (параметризирано с α); експлоатируемостта на средната стратегия след 100 000 итерации е 0.006.
- **Коефициент на затихване на експлоатируемостта:** Наклонът на експлоатируемостта спрямо итерациите в двулогаритмичен мащаб е $-0,52 \pm 0,02$ (5 начални числа, 100–

100 000 итерации), което съответства на теоретичната граница $O(1/\sqrt{T})$.


- **Точност на стойността на играта:** След 100 000 итерации точната стойност на средната стратегия ($-0,0555$) съвпада с теоретичната стойност $-1/18$ ($-0,0556$) с точност $8 \cdot 10^{-5}$; текущата средна на изтеглените печалби е -0.0613 .

2.2.1 Сходимость на стойността на играта




Фигура 4: Сходимость на стойността на играта

2.2.2 Сходимость на експлоатируемостта



Фигура 5: Сходимость на експлоатируемостта

2.2.3 Анализ на стратегиите



Фигура 6: Анализ на стратегиите

3 Глава 03 – Варианти на CFR и методи на Монте Карло: Доклад за реализацията

Среда: април 2026 г.

Игра: Ледюк покер (6 карти, 2 играчи, 2 рунда на залагане)

Алгоритми: обикновен вариант на CFR, CFR+, MCCFR с външно вземане на проби, MCCFR с извадка по резултати

Цели: експлоатируемост на CFR+ < 0,001 в рамките на ≤ 180 s · кръстосана проверка спрямо OpenSpiel · наклон в лог-лог мащаб $\approx -0,5$ за MCCFR

Статус: Всички цели са постигнати ✓

3.1 1. Разработени елементи

Две направления на работа: **фаза на изследване**, използваща референтните решаващи програми на OpenSpiel за изграждане на интуиция и установяване на опорни базови резултати, последвана от **реализация от нулата** на всичките четири алгоритъма, ръчно кодирани единствено в Python + NumPy.

Структура на кода:

```
implementation/step03/
├─ cfr/
│   ├── leduc_poker.py          # Full game engine (6 cards, 2 rounds, community card)
│   ├── info_set_node.py       # Regret & strategy storage per info set
│   ├── cfr_trainer.py         # Vanilla CFR (full-traversal, buffered regrets)
│   ├── cfrplus_trainer.py     # CFR+ (flooring + linear avg + alternating)
│   ├── mccfr_external_trainer.py # External Sampling MCCFR
│   ├── mccfr_outcome_trainer.py # Outcome Sampling MCCFR ( $\epsilon$ -on-policy + IS)
│   ├── train.py               # Single-algorithm training entry point
│   └─ train_all_timed.py      # 180 s wall-clock benchmark harness
├─ evaluate/
│   ├── best_response.py       # Info-set-constrained best response
│   ├── exploitability.py      #  $(BR_0 + BR_1)/2$  exact exploitability
│   └─ convergence.py         # Geometric-spaced snapshot logger
├─ exploration/
│   ├── implDayOne1.py         # OpenSpiel five-algorithm comparison on Kuhn
│   ├── leduc_comparison.py    # OpenSpiel four-algorithm comparison on Leduc
│   └─ leduc_race.py          # 5-minute wall-clock race
```

```
|— compare_openspiel.py          # Cross-validation against OpenSpiel solvers
|— utils/plotting.py            # Figure generation
```

3.2 2. Игрови двигател за Ледюк покер

Пълна реализация, съответстваща на семантиката на OpenSpiel: шест карти ($\{J, Q, K\} \times 2$ бои), два кръга на залагане с разкрита обща карта между тях, действия отказ/плащане/вдигане, фиксирани размери на залога (2 в първия кръг, 4 във втория кръг), максимум две вдигания в един кръг. Класиране на ръка по двойки: тайна карта, която съвпада с общата карта, побеждава всяка висока карта. Изброява всички 120 пермутации на раздаването за точно изчисляване на математическо очакване.

3.3 3. Реализации на алгоритми

3.3.1 3,1 Обикновен вариант на CFR

Пълно обхождане на дърво с вероятностна извадка върху всичките 120 раздавания при всяка итерация. Актуализациите на съжалението се буферират за всяко информационно множество и се прилагат атомарно в края на обхождането на всяко раздаване, с цел да се избегне отклонение от стратегията по средата на итерацията.

3.3.2 3,2 CFR+

Три модификации на обикновения вариант на CFR, всяка от които е локализирана. Основната промяна е стъпката за нулиране на отрицателните съжаления:

```
# cfrplus_trainer.py - regret flooring (ReLU-style clip)
for info_set, deltas in regret_buffer.items():
    node = node_map[info_set]
    for a in range(node.num_actions):
        node.regret_sum[a] = max(node.regret_sum[a] + deltas[a], 0.0)
```

Линейно претегленото усредняване на стратегиите дава на итерация t тегло t в текущата средна; при редуващите се актуализации двамата играчи се обновяват последователно в рамките на всяка итерация, така че обновяването на втория вече отчита новите съжаления на първия. Обикновеният вариант тук също редува актуализациите, така че двата се различават само по нулирането на отрицателните съжаления и линейното усредняване.

3.3.3 3,3 Външно вземане на проби в MCCFR

Взема извадка от едно раздаване на итерация. Във възлите на обхождащия играч се изследват всички действия, докато във възлите на противника се взема проба само от едно действие, избрано според текущата стратегия на противника.

```
def external_cfr(state, update_player):
    if state.is_terminal():
        return state.get_utility(update_player)

    player = state.current_player()
    strategy = get_strategy(state.info_set(player))

    if player == update_player:
        # explore ALL actions (same as vanilla CFR)
        values = [external_cfr(state.apply(a), update_player)
                   for a in legal_actions]
        node_value = sum(strategy[a] * values[a] for a in legal_actions)
        for a in legal_actions:
            regret[info_set][a] += values[a] - node_value
        return node_value
    else:
        # SAMPLE one opponent action from the current strategy
        sampled_action = sample(strategy)
        return external_cfr(state.apply(sampled_action), update_player)
```

Разходът на итерация е приблизително 42 възела (срещу 20 400 при пълно обхождане).

3.3.4 3,4 MCCFR с извадка по резултати

Тегли една-единствена траектория до край. Във възлите на обхождащия играч действията се избират от ϵ -микс с текущата стратегия ($\epsilon = 0,6$: равномерно с вероятност ϵ , в противен случай според текущата стратегия). Актуализациите на съжалението се коригират чрез извадка по важност – отношението между истинската вероятност за достигане и вероятността за извадка – като по този начин се запазва свойството на неизместена оценка. Разходът на итерация е приблизително 5,5 възела.

3.3.5 3,5 Оценител на експлоатируемостта

Итеративен най-добър отговор, ограничен до информационно множество: за всеки играч се изчислява оптималната контрастратегия при условие, че отговарящият трябва да изиграе


едно и също действие във всички състояния в рамките на дадено информационно множество. Връща $(BR_0(\sigma_1) + BR_1(\sigma_0)) / 2$ като точна експлоатируемост (конвенцията на OpenSpiel: $NashConv / 2$).

3.4 4. Фаза на изследване (референция OpenSpiel)


3.4.1 4.1 Кун покер – 5000 итерации

За проверка за коректност в малък мащаб бяха стартирани и четирите алгоритъма на OpenSpiel, както и собственият CFR от Глава 2, който тегли по едно случайно раздаване на итерация. Всички решавачи започват от начално число 42; експлоатируемостта е $NashConv / 2$, както навсякъде в главата; времето е само за обучение (без оценяването).

Алгоритъм	Експлоатируемост при	
	5000 итерации	Време за обучение
Собствен CFR (Глава 2, извадка от раздаването)	$6,0 \times 10^{-3}$	0,03 s
OpenSpiel CFR	$1,8 \times 10^{-4}$	2,1 s
OpenSpiel CFR+	$2,8 \times 10^{-5}$	2,2 s
MCCFR с външно вземане на проби	$1,3 \times 10^{-2}$	0,4 s
MCCFR с извадка по резултати	$4,1 \times 10^{-2}$	0,4 s



Фигура 7: Кун покер: експлоатируемост спрямо броя на итерациите




Фигура 8: Кун покер: експлоатируемост спрямо времето за обучение


Всички алгоритми се изпълняват за секунди, а подредбата им вече е същата като при Ледюк: CFR+, след него CFR и накрая двата варианта с извадка.

3.4.2 4,2 Ледюк покер – 5 000 итерации

Алгоритъм	Експлоатируемост при 5000 итерации	Време за обучение
CFR+	$1,8 \times 10^{-5}$	368 s
Обикновен вариант на CFR	$3,6 \times 10^{-3}$	327 s
MCCFR с външно вземане на проби	0,44	1,3 s
MCCFR с извадка по резултати	1,65	0,7 s



Фигура 9: Ледюк покер: експлоатируемост спрямо броя на итерациите




Фигура 10: Ледюк покер: експлоатируемост спрямо времето за обучение

На итерация методите с пълно обхождане водят с два до три порядъка (обикновеният CFR) и с четири до пет (CFR+). Петте хиляди итерации с извадка отнемат около секунда, така че оста на времето сравнява много различни бюджети; сравнението при еднакво време е тестът в раздел 5.


3.5 5. Сравнителен тест с бюджет от 180 секунди време за изпълнение

`train_all_timed.py` стартира всяка собствена реализация при общ бюджет от 180 секунди, като използва геометрично разположени моментни снимки. Това представлява справедливото сравнение за компромиса между дисперсия и скорост.

Алгоритъм	Итерации	Крайна експлоатируемост	Информационни множества
Обикновен вариант на CFR	3 713	$4,4 \times 10^{-3}$	936
CFR+	3 706	$2,6 \times 10^{-5}$	936
MCCFR, външно вземане на проби	3 504 665	$5,5 \times 10^{-2}$	936
MCCFR, извадка по резултати	8 262 137	$1,0 \times 10^{-1}$	936



Фигура 11: Експлоатируемост спрямо броя на итерациите (двойна логаритмична скала)



Фигура 12: Експлоатируемост спрямо времето за изпълнение (логаритмична ос у)

CFR+ достига почти точно равновесие на Наш ($2,6 \times 10^{-5}$) за 3 минути – над 150 пъти по-добър резултат от обикновения вариант на CFR, въпреки че извършва само малко по-малко **ите-рации**. И двата варианта на MCCFR, въпреки милионите **итерации**, остават с 3–4 порядъка по-лоши от CFR+ (и 12–23 пъти по-лоши от обикновения CFR) при този размер на играта, както е предвидено от анализа на **дисперсията** и скоростта в резюмето.

3.6 6. Кръстосана проверка спрямо OpenSpiel

И двете реализации с пълно **обхождане** се валидират спрямо референтните решаващи алгоритми на OpenSpiel при еднакъв **брой итерации** – 500.

Алгоритъм	Наша реализация (500 итерации)	OpenSpiel (500 итерации)	Съвпадение
Обикновен вариант на CFR	0,020	0,022	✓
CFR+	$8,6 \times 10^{-4}$	$9,4 \times 10^{-4}$	✓

Малки разлики се наблюдават поради подреждането на раздаванията и случайните начални числа; и двете клонят към едно и също равновесие на Наш в рамките на допустимия шум.

3.7 7. Възпроизвеждане

From repo root, with .venv activated:

Train a single algorithm (configurable in train.py):

```
python implementation/step03/cfr/train.py
```

Run the 180 s timed benchmark for all four algorithms (--plot-only redraws the saved res

```
python implementation/step03/cfr/train_all_timed.py
```

Exploration - OpenSpiel reference comparisons (seed 42; --plot-only re-plots the saved c

```
python implementation/step03/exploration/implDayOne1_test.py # Kuhn (section 4.1)
```

```
python implementation/step03/exploration/leduc_comparison.py # Leduc, iteration budget
```

```
python implementation/step03/exploration/leduc_race.py # Leduc, 5-min wall-clock
```

Cross-validate custom vs OpenSpiel:

```
python implementation/step03/compare_openspiel.py
```

Генерираните фигури са налични в deliverables/reports/step03/figures/.

4 Глава 04 – Абстракция на играта и мащабиране на игри с непълна информация: Доклад за внедряването

Среда: Май 2026 г.

Игри: Ледюк с лимит, Mini-NL Ледюк, разширен Ледюк

Алгоритми: обикновен вариант на CFR, CFR+, MCCFR, абстракция на информацията/действията

Цели: беззагубната абстракция съхранява качеството на равновесието на Наш; абстракцията със загуби разкрива праг на експлоатируемост; изградена е Парето граница между размера на абстракцията и експлоатируемостта

Статус: Основните цели са постигнати

4.1 1. Какво беше разработено

Глава 04 разширява набора от инструменти за CFR от Глава 03 с явна **абстракция на играта**. Реализацията изгражда **конвейер от типа „Ледюк“**, който може да свие играта по три оси, да реши **абстрахираната** игра, да транслира получената **стратегия** обратно в пълната игра и да измери **разхода за експлоатируемост**.

Структура на изходния код:

```
implementation/step04/
├─ exploration/
│   ├── leduc_suit_abstracted.py      # early suit-isomorphism probe
│   ├── leduc_lossy_abstracted.py    # early lossy rank-bucket probe
│   ├── day01_*                      # CFR/MCCFR comparison scripts
│   ├── day02/mini_nl_leduc.py       # early variable-bet game
│   └─ figures/                      # exploration figures
├─ phase4/
│   ├── leduc_full_engine.py         # full fixed-limit Leduc baseline
│   ├── leduc_rank_engine.py         # rank-canonical / suit-isomorphic Leduc
│   ├── mini_nl_leduc.py             # variable-bet Mini-NL Leduc
│   ├── extended_leduc.py            # 4-rank, 2-suit Leduc variant
│   ├── cfr_trainer.py               # generic vanilla CFR trainer
│   ├── exploitability.py            # full-game exploitability evaluator
│   ├── day01_*                      # lossless suit-isomorphism experiments
│   ├── day02_*                      # card bucketing, HSD, EMD, k-means
│   └─ day03_*                      # action abstraction and translators
```

```

|   └─ day04_*                # combined abstraction pipeline
|   └─ day05_*                # exploitability gap and Pareto frontier
|   └─ day06_openspiel_compare.py # OpenSpiel cross-validation
|   └─ day07_cfrplus_panels.py   # 180 s CFR+ benchmark panels
└─ EXPERIMENT_RESULTS.md        # final CFR+ result summary

```

4.2 2. Модули за абстракция

4.2.1 2,1 Беззагубен изоморфизъм на боите

Боите в Ледюк не носят стратегическа информация, тъй като печалбите зависят единствено от ранга и от това дали частната карта образува чифт с общата карта. Поради това глава 04 реализира двигатели с ранг-канонична форма, които обединяват информационните множества, изоморфни по боя.

Тази абстракция е беззагубна: тя запазва качеството на равновесието на Наш, като същевременно намалява броя на информационните множества и увеличава броя на възможните итерации на CFR/CFR+ при същия бюджет от време за изпълнение.

4.2.2 2,2 Групиране на карти със загуби

Пътят на абстракцията със загуби изчислява характеристики за силата на ръката, сравнява кандидатите за клъстери чрез разстояния от типа EMD и групира информационните множества с конфигурируем брой клъстери.

Представени са два режима на паметта:

Режим	Значение
Клъстери с пълна памет	Групиране на текущата сила на частната/общата карта, като се запазва предишната траектория на клъстерите
Клъстери с непълна памет	Замяна на част от по-ранната история с идентичността на клъстера , което води до по-агресивно свиване на дървото

Целта не е да се постигне точност в тази **абстракция**. Целта е да се измери **прагът на експлоатируемост**, породен от обединяването на стратегически различни състояния.

4.2.3 2,3 Абстракция на действията и трансляция

Mini-NL Ледюк въвежда променливи размери на залозите. Абстракцията на действията след това редуцира множеството действия и оценява как абстрактната стратегия се представя при прилагането ѝ в игра с пълно множество действия.

Реализирани транслатори:

Транслатор	Роля
Най-близко действие	Преобразуване на залог извън решетката в най-близкия абстрактен залог
Вероятностно разделяне	Разпределяне на маса между съседни абстрактни залози
Псевдохармонично преобразуване	Вероятностно преобразуване, изведено от равновесието на опростена покерна игра (Ganzfried & Sandholm 2013); реализирано с цел сравнение и бъдещо разширение

4.2.4 2,4 Разширена и комбинирана абстракция


Разширеният Ледюк увеличава еталонния тест до четири ранга и две бои. Комбинираният конвейер съставя изоморфизма на боите, абстракцията на действията и групирането на карти, след което оценява получената стратегия в подходящото пълно игрово семейство.

4.3 3. Еталонен тест на CFR+ с ограничено време

Окончателният еталонен тест използва CFR+ с нулиране на отрицателните съжаления и линейно претеглено усредняване.

Настройка	Стойност
Обучителен бюджет	180 секунди за всяка конфигурация
Повторения	3 изпълнения с начални числа 1, 2 и 3
Метрика	Крайна експлоатируемост след обучението
Сурови изходи	phase4/.day07_cfrplus_results.json, phase4/.day07_cfrplus_results.csv

4.3.1 3,1 Ледюк с лимит



Фигура 13: Ледюк с лимит: крайна експлоатируемост след 180 s CFR+ за всяка конфигурация на абстракцията (три изпълнения, логаритмична скала); числото над всяка група е броят информационни множества.


Конфигурация	Информационни множества	Средна експлоатируемост	Среден брой итерации
Пълна игра	936	4,44e-05	2 655
Изоморфизъм на боите	288	3,13e-06	14 185
k2, пълна памет	132	0,571	11 399
k3, пълна памет	228	0,382	11 043
По ранг, пълна памет	288	4,18e-06	10 806

Беззагубната абстракция с изоморфизъм на боите дава най-добрия резултат в Ледюк с лимит. Тя намалява изискванията към паметта и постига по-ниска експлоатируемост от пълния CFR+ в рамките на същия бюджет от време за изпълнение, тъй като успява да изпълни значително повече итерации. Вариантите с клъстери по ранг се държат сходно, защото след

разделянето на случаите по ранг и по обща карта оставащото компресиране на практика представлява изоморфизъм на боите.

Грубите клъстери със загуби остават силно експлоатируеми. Допълнителните итерации на CFR+ не успяват да преодолеят тази разлика, тъй като самата абстракция е премахнала стратегически релевантна информация.

4.3.2 3,2 Mini-NL Ледюк




Фигура 14: Mini-NL Ледюк: крайна експлоатируемост след 180 s CFR+ – пълната игра срещу абстракцията на действията; числото над всяка група е броят информационни множества. Незапълнените маркери отбелязват абстракцията на действията, чиято стойност отразява текущото правило за внедряване (вж. текста).

Конфигурация	Информационни множества	Средна експлоатируемост	Средни итерации
Пълна игра	4 704	0,00692	439
Абстракция на действията	936	0,673	2 338

Играта с **абстракция на действията** изпълнява значително повече **итерации**, тъй като дървото е по-малко, но крайната **експлоатируемост** остава висока. Тези стойности обаче измерват текущото правило за внедряване – всеки абстрактен малък залог се изиграва като голям, а големите залози на противника се четат като малки – а не трите транслятора, които в тази реализация не се задействат и дават еднакви резултати. Те показват колко може да струва наивното съпоставяне на абстрактното и реалното множество действия; не са измер-

ване на грешката от транслацията и не бива да се цитират като такова, докато реализацията не бъде поправена и изпълнена отново.

4.3.3 3,3 Разширен Ледюк




Фигура 15: Разширен Ледюк: крайна експлоатируемост след 180 s CFR+ за пълната игра, изоморфизма на боите и комбинираните абстракции; числото над всяка група е броят информационни множества. Незапълнените маркери отбелязват конфигурациите с абстракция на действията (вж. текста).

Конфигурация	Информационни множества	Средна експлоатируемост	Средна стойност на итерациите
Пълна игра	10 304	0,0272	111
Изоморфизъм на боите	2 968	0,00126	671
Бои + действия	504	4,696	4 145
Бои + действия + клъстери	108	4,734	3 694

Разширеният Ледюк потвърждава стойността на беззагубната абстракция в по-голям мащаб: изоморфизмът на боите намалява броя информационни множества с около 71% и постига значително по-ниска експлоатируемост при същия бюджет от време за изпълнение. Конфигурациите с абстракция на действията са полезни като пример за неуспех: агресивната компресия на действията води до компактни игри, но внедрените стратегии се оказват силно експлоатируеми в по-пълната игра с действия – при същото правило за внедряване като в §3.2, така че и тези стойности описват това съпоставяне, а не качеството на транслацията.

4.4 4. Парето граница



Фигура 16: Граница на Парето: брой информационни множества срещу експлоатируемост в пълната игра след 180 s CFR+ за всяка конфигурация на абстракцията (средно от три изпълнения). Линиите свързват недоминираните точки на всяка игра; незапълнените маркери са конфигурации с абстракция на действията, чиито стойности отразяват текущото правило за внедряване.

Парето границата обобщава основния компромис от Глава 04: по-малките абстрактни игри се обучават по-бързо, но не всяко съкращение е стратегически **безопасно**.

Семейство абстракции	Резултат
Изоморфизъм на боите	Най-добър компромис; по-малка игра без стратегическа загуба в Ледюк

Семейство абстракции	Резултат
Пълни рангови клъстери	Поведение, близко до изоморфизма на боите
Груби клъстери със загуби	По-малки дървета, с постоянен праг на експлоатируемост
Абстракция на действията	Най-голяма измерена загуба в Mini-NL и разширения Ледюк при текущото правило за внедряване (§3.2); не е измерване на грешката от транслацията

Практичният критерий следователно не е просто „по-малкото е по-добро“. Полезната абстракция трябва да спести достатъчно изчислителни разходи, за да компенсира въведената разлика в експлоатируемостта.

4.5 5. Кръстосана проверка

day06_openspiel_compare.py подравнява всички 936 информационни множества на Ледюк спрямо OpenSpiel и проверява дали собствената реализация е в същия стратегически режим. Оставащите разминавания се интерпретират като разминавания в конвенциите за обновяване, а не като точни несъответствия в траекториите, така че това представлява проверка за коректност, а не доказателство за идентична динамика на решавача.

4.6 6. Ключови изводи

1. **Беззагубната абстракция представлява компресията с най-висока стойност.** В игрите от типа на Ледюк изоморфизмът на боите съществено намалява играта и подобрява сходимостта при същото време за изпълнение, без да въвежда грешка на абстракцията.
2. **Информационната абстракция със загуби поражда праг на експлоатируемост.** Грубите клъстери за карти се решават по-бързо, но не могат да възстановят различията, които умишлено са премахнали.
3. **Абстракцията на действията е по-опасна от абстракцията на карти в тези експерименти.** Ограничени множества от действия при текущото правило за внедряване (§3.2) доведоха до висока експлоатируемост, дори когато абстрактното дърво беше значително по-малко.

4. **Парето границата е подходящият формат за докладване.** Качеството на стратегията трябва да бъде представено заедно с размера на играта и типа абстракция.
 5. **Решаването на под-игра е естественият следващ механизъм.** Статичната трансляция е крехка; методите за безопасно и вложено решаване от Глава 6 са отговорът на действията извън дървото, използван в реалните системи.
-

4.7 7. Възпроизвеждане

From repo root:

```
cd implementation/step04/phase4
```

Smoke-test budget used by the phase-4 integration notes:

```
python day01_train.py --iterations 200
```

```
python day02_train.py --iterations 200
```

```
python day03_train.py --iterations 100
```

```
python day04_train.py --iterations 20000
```

```
python day05_train.py
```

```
python day06_openspiel_compare.py --iterations 200
```

Final CFR+ benchmark panels (plots only when all runs are already saved):

```
python day07_cfrplus_panels.py
```

Pareto frontier from the CFR+ results:

```
python day05_plots.py
```

Генерираните JSON/CSV файлове се записват в директорията `implementation/step04/phase4/`, а фигурите – в `implementation/step04/phase4/figures/`.

5 Глава 07 – Моделиране на противника в игри с непълна информация

Игри: Кун покер (3 карти, 2 играчи) и Ледюк Холдем (6 карти, 2 рунда) – най-малките точно решими тестови среди с непълна информация, които използват повторно енджина за Кун от Глава 02 + CFR решавач и енджина за Ледюк от Глава 03.

Връзка с дисертацията: Принос №1 (Рамка за поведенческа адаптация) – моделът на противника е *сензорът*, който преобразува наблюдаваните действия в оценка на стратегията на противника; адаптивният експлоататор е първият *изпълнителен механизъм*, формализиран в Глава 08 като безопасна експлоатация с KL-регуларизация.

Обхват на резултатите: Част I представлява последователност от експерименти в Кун покер със зададени начални условия, които изграждат интуиция. Част II е пълна оценка и за двете игри (5 начални числа, мачове от 20 000 раздавания, базови линии на равновесие на Наш при 200 000 / 40 000 итерации на CFR). Всички фигури са измерени от тези изпълнения и, където е възможно, са поставени в *точни* аналитични граници, а не в симулирани.

Как да четете този доклад. И двете части следват една и съща структура: **какво тестваме → как го тестваме → резултати → заключения.** **Част I (§1–§6)** изследва типово базирания байесов модел самостоятелно в Кун – как изглежда „типът“ на противника, защо моделирането си струва и как се държи цикълът на актуализиране на убежденията (включително къде се проваля). **Част II (§7–§13)** оценява цялата система – три модела на противника и адаптивен експлоататор – в Кун и Ледюк. §14 съдържа команди за възпроизвеждане.

6 ЧАСТ I – ИЗСЛЕДВАНЕ НА КУН ПОКЕР

6.1 1. Предмет на изследването в тази глава

Стратегията на **равновесие** е изградена така, че в дългосрочен план да не носи загуба, *независимо срещу кого се прилага*. Тази сигурност обаче има своята цена: тя се играе еднакво както срещу световен шампион, така и срещу противник, който се отказва при всеки **залог**. **Моделирането на противника** представлява *наблюдение на начина, по който даден опонент действително играе*, и актуализиране на убеждение относно неговата стратегия, с цел да **можем да се отклоняваме от равновесие, за да използваме грешките му** – да блъфираме повече срещу противник, който се отказва твърде често, и да правим по-тънък стойностен залог срещу такъв, който плаща прекалено често.

Техниката, която се изследва първо, е **типово базиран (байесов) модел**: вместо да се науча-

ва стратегия от нулата, се поддържа убеждение – разпределение на вероятностите – върху малък набор от предварително дефинирани типове противници, което се актуализира след всяко наблюдавано действие чрез **правилото на Бейс**:

$$\text{апостериорно разпределение(тип)} \propto \text{априорно разпределение(тип)} \times P(\text{наблюдавано действие} \mid \text{този тип})$$

Действие, което даден тип смята за невъзможно, намалява вероятността му до нула; действие, което той предвижда добре, я увеличава. След много раздавания убеждението се концентрира върху най-подходящия тип и спрямо него се изчислява най-добрият отговор. Всички числа в Част I са измерени от възпроизводими изпълнения на Кун покер с фиксирани начални числа.

6.1.1 1,1 Типовият зоопарк на противниците

Четири истински типа изпълняват двойна роля – те са едновременно противниците, срещу които играем, и кандидат-хипотезите, върху които детекторът разсъждава:

Тип	Поведение
AlwaysCall	Пасивен играч – никога не залага, никога не се отказва (прави чек в отворен пот, плаща всеки залог).
TightPassive	Камък – ангажира жетони само с най-силната ръка (K); отказва се от всичко останало. Най-експлоатируемият тип.
LooseAggressive	Маниак – винаги залага или плаща, независимо от ръката.
Nash	Балансирана равновесна игра (от CFR решаваща на Глава 02); използва смесени стратегии; неексплоатируем.

6.2 2. Експеримент 1 – Поведенчески отпечатъци


Какво изследваме. Проявява ли всеки тип отличителен и възстановим отпечатък в действията си?

Как. Използваме 50/50 „сонда“ срещу всеки тип (за да се гарантира посещаването на всяко информационно множество) и записваме емпиричната стойност на $P(\text{bet})$ във всяко информационно множество до истинската стойност на $P(\text{bet})$ за съответния тип.

Резултати. Четирите поведенчески отпечатъка са ясно различни, като емпиричните честоти съответстват на истинските вероятности в добре посетените информационни множества: **разпуснат-агресивен** $\approx 1,0$ навсякъде; **стегнат-пасивен** ≈ 0 , освен когато държи К; **alwaysCall** ≈ 0 при чек в отворен пот, но $\approx 1,0$ при изправяне срещу залог; „Наш“ – дробни и смесени.



Фигура 17: Behavioral fingerprint – TightPassive (bets only with the King).



Фигура 18: Behavioral fingerprint – Nash (mixed frequencies; empirical tracks true).

Заклучение. Възстановяването на поведенческия отпечатък на даден тип от наблюдаваните действия представлява цялата задача по моделиране и е осъществимо – но информационните множества с малко посещения имат шумни емпирични честоти, което именно прави моделирането трудно при наличие на ограничени данни.

6.3 3. Експеримент 2 – Възможност за експлоатация (защо си струва усилието)

Какво изследваме. Каква допълнителна стойност носи моделирането в сравнение със сляпо равновесие на Наш?

Как. За всеки тип и място изчислете *точно* (i) очакваната стойност на собствения агент при **равновесие на Наш**, (ii) **стойността на най-добрия отговор (таванът на експлоатацията)**, при допускане, че типът е известен перфектно), и (iii) разликата между тях. Тази разлика показва колко пари **равновесието на Наш** оставя неизползвани.

Опонент	Място	Очаквана стойност при равновесие на Наш	Стойност на най-добрия отговор	Разлика
AlwaysCall	0	+0,119	+0,333	0,215
AlwaysCall	1	+0,220	+0,333	0,113
TightPassive	0	-0,060	+0,167	0,227
TightPassive	1	+0,055	+0,333	0,278
LooseAggressive	0	+0,121	+0,333	0,213
LooseAggressive	1	+0,116	+0,333	0,217
Nash	0	-0,055	-0,052	0,004
Nash	1	+0,055	+0,060	0,005

Резултати. При трите експлоатируеми типа разликата е значителна (0,11–0,28 на раздаване), докато срещу „Наш“ тя е ≈ 0 – както и следва, тъй като **равновесието на Наш** е неексплоатируемо и най-добрият отговор не може да надмине стойността на играта. По-конкретно, изчисленият най-добър отговор срещу **стегнат-пасивен тип блъфтира**, като залага с най-слабата си ръка (Вале) в отворен пот, понеже този тип се отказва от всичко освен Поп.

Заключение. Стойността на моделирането на противника е реална и измерима, а експлоатирането на камък означава *повече блъфтиране*. (Недостатъкът от $-1/18 \approx -0,056$ за първия играч в Кун на място 0 обяснява малките отрицателни стойности при **равновесие на Наш** – това е особеност на играта, а не грешка.)

6.4 4. Експеримент 3 – Детектор на тип по Байес (ядрото на цикъла)


Какво изследваме. Започвайки от равномерно априорно разпределение, може ли цикълът на актуализиране на убежденията да идентифицира противника единствено по поведението му – и какво се случва, когато поведението на противника не съответства на *нито един* тип?

Как. Поддържайте апостериорно разпределение върху четирите типа; след всяко наблюдавано действие на противника умножете по неговото правдоподобие при всеки тип и нормализирайте отново (в логаритмично пространство, като използвате малко изглаждане на вероятностите $\epsilon = 0,02$, за да не елиминира нито едно „невъзможно“ действие трайно някой кандидат). Стартирайте няколко скрити противника и наблюдавайте развитието на апостериорното разпределение стъпка по стъпка.

6.4.1 4,1 Противници от множеството – бързи, точни и стабилни

Когато скритият противник действително е един от четирите кандидати, апостериорното разпределение се концентрира коректно и се стабилизира:

- **Скрит = стегнат-пасивен:** апостериорното разпределение се концентрира върху „стегнат-пасивен“ и се стабилизира при $\approx 1,0$ до раздаване ~ 18 . („Наш“ е бавно умиращият съперник, тъй като „камък“ и равновесна игра съвпадат при много раздавания.)
- **Скрит = alwaysCall:** се заключава до раздаване ~ 4 (много отличителен тип).




Фигура 19: Hidden = TightPassive: clean convergence to the correct type.

6.4.2 4,2 Противник извън набора – „няма честно място“

Инструктивният случай е скрит противник, който представлява **50/50 смес по действие** между стегнат-пасивен и разпуснат-агресивен – умишлено *нищо един* от четирите типа. Човек би могъл да очаква апостериорното разпределение да се „раздели между двата най-близки типа“. **То не го прави.** Детекторът твърдо се ангажира с *един* тип в даден момент и прескача:

alwaysCall (раздаване 1–2) → разпуснат-агресивен (раздаване ~5–40) → „Наш“ (раздаване ~43+, $\approx 1,0$).



Фигура 20: Hidden = Mixture(TightPassive, LooseAggressive): the belief thrashes, then lands on Nash.

Това е *правилно* баесово поведение, а причината за него е основният извод от тази фаза:

- Смесеният играч играе истинско (0.5; 0.5) на средни раздавания (J/Q) и винаги залага с Поп. Всеки път, когато заложи J/Q, камъкът (който никога не го прави) получава наказание по правдоподобие; всеки път, когато направи чек с J/Q, маниакът (който винаги залага) получава такова.
- Двата детерминистични екстремума следователно биват опровергавани около половината от времето. „Наш“ е единственият кандидат, който присвоява реална вероятност както на залог, така и на чек със средна ръка, така че това е единствената стратегия, която никога не е фатално опровергана – а произведение на правдоподобия

апостериорно разпределение се концентрира върху единственото най-добро обяснение, а не върху смес.

Заклучение. Малкото меню от стереотипи няма *честен начин да каже „нито едно от горните“*. Изправено пред противник, който не може да представи, то се ангажира – уверено – с най-близкия *смесен* тип, вместо да докладва истинска несигурност. Две точки изострят това. Първо, апостериорното разпределение е **относителна, нормализирана** величина – четирите стълба са принудени да сумират до 1, така че $P(\text{nash})=1.0$ означава „най-добро приближение *сред тези четири*“, а не „добро приближение в абсолютни термини“. Измерването на абсолютното приближение на победителя (геометрична средна вероятност, която той присвоява на всяко наблюдавано действие) разкрива разликата: печелившият модел „Наш“ отбелязва **0,74 на действие срещу истински противник „Наш“**, но само **0,31 срещу сместа** – еднакво уверен на хартия, много по-лош в действителност. Второ, честното решение е да спрем да питаем „кой тип?“ и да попитаме „каква смес от типове?“ – Експеримент 4 (§5) и мотивацията за **непрекъснатите** и **състоятелните** модели в Част II.


6.4.3 4,3 Колко устойчива е тази сходимост? – стрес тест от 500 раздавания

Тъй като §4.2 завършва с типа „Наш“, естествен въпрос е дали в хода на дълъг мач убеждението все още може да „отпадне“ от него. Изпълнихме сценария със **смес за 500 раздавания при 300 начални числа** и разграничихме две явления, които **наивната метрика** обединява – *бавна сходимост* и *отпадане след сходимост*.

Измерване (300 начални числа × 500 раздавания)	Резултат
Крайният победител на раздаване 500 е „Наш“	300 / 300 (100%)
След като „Наш“ <i>постоянно</i> поеме преднината, той по-късно спада под 0,5	0 / 300 (никога)
Грешен тип все още водеше след раздаване 100	40 / 300 (~13%)
Грешен тип все още водеше след раздаване 200	14 / 300 (~5%)
Раздаване, на което „Наш“ се заключава окончателно	медиана 23 · 90-ти персентил 125 · най-лошо 461

Резултати. „Наш“ никога не *отпада*: след като окончателно поеме преднината, той остава фиксирано на ≈ 1.0 . Истинският риск е обратният – **бавна сходимост, при която за дълго време се поддържа уверено, но грешно убеждение**. В значителна част от изпълненията

маниакът (свободно-агресивният) държи убеждението на $\approx 1,0$ повече от сто раздавания, преди „Наш“ да го изпревари – единствено защото ранна серия от тежки залози изглежда като стратегия „винаги залага“. Графиката по-долу (най-волатилното начално число) показва как свободно-агресивният тип поддържа $\approx 1,0$ от раздаване ~ 35 до ~ 220 , след което рязко се преминава към „Наш“ за остатъка:



Фигура 21: Hidden = Mixture, 500 hands (most volatile seed): a wrong type can dominate for 200 hands before Nash overtakes; once locked, Nash never falls.

Заклучение. Сред четирите кандидата „Наш“ е този, който е *най-близо* (минимална дивергенция на Кулбак–Лайблер (KL)) до истинската смесена стратегия. Поради това всеки детерминиран тип в крайна сметка се сблъсква с противоречие, което не може да преодолее. „Наш“ е единственият дългосрочен победител – „дългосрочен“ понякога означава просто над 200 раздавания. Най-добре реагиращ на ранно, уверено, но грешно убеждение би означавало да се адаптираш към победа над илюзия.

6.5 5. Експеримент 4 – Възстановяване на сместа чрез модел на смес с ЕМ

Какво тестваме. §4 показва, че ако се зададе въпросът „кой единствен тип сте?“, смесеният опонент се свежда до най-близкия смесен тип („Наш“) и се прикрива лошото абсолютно съответствие. Можем ли вместо това да зададем въпроса „каква **смес** от типове сте?“ и да възстановим действителната смес?

Как. Напасваме **тегла за смесване** п върху същите четири фиксирани типа чрез **очаквателна стъпка–стъпка М**: всяко наблюдавано действие се *меко приписва* на типовете про-

порционално на това колко добре всеки от тях го обяснява (оцаквателна стъпка), а теглата са средното приписано количество (стъпка М), итерирано до **сходимост**.

- оцаквателна стъпка: $\text{отговорност}(\text{тип} \mid \text{действие}) \propto \pi(\text{тип}) \times P(\text{действие} \mid \text{тип})$
- стъпка М: $\pi(\text{тип}) = \text{средната стойност на отговорностите за всички наблюдения}$


Изкушаващ пряк път – **твърдо** преброяване по раздавания (избиране на единствения най-подходящ тип за всяко раздаване и след това броене) – **не** работи: той е объркан от *тип припокриване* (напр. alwaysCall и TightPassive и двата правят чек със слаба ръка, така че argmax не може да ги разграничи). Меката, итерирана версия на ЕМ ги **разграничава**.

Резултати. Пренапасването на теглата след всяко раздаване (започващо от предишната оценка) дава **траектория по раздавания** – аналогът на сместа към графиките „разпределение на апостериорни вероятности във времето“ от §4. Двата активни компонента нарастват до истинските си тегла, а другите два намаляват до нула, докато старото еднотипно апостериорно разпределение вместо това показва „**Наш**“ $\approx 1,0$ през цялото време:


Скрит противник	Метод	alwaysCall	стегнат-пасивен	разпуснат-агресивен	„Наш“
50 / 50 смес	глобално	0,00	0,00	0,00	1,00 x
	апостериорно разпределение (старо)				
	тегла на ЕМ @250 раздавания	0,00	0,51	0,49	0,00 ✓
	<i>истинска смес</i>	0,00	<i>0,50</i>	<i>0,50</i>	0,00
70 / 30 смес	глобално	0,00	0,00	0,00	1,00 x
	апостериорно разпределение (старо)				

Скрит противник	Метод	alwaysCall	стегнат- пасивен	разпуснат- агресивен	„Наш“
	тегла на	0,00	0,66	0,34	0,00 ✓
	ЕМ @250				
	раздава- ния				
	<i>истинска</i>	0,00	<i>0,70</i>	<i>0,30</i>	0,00
	<i>смес</i>				

(Малката остатъчна грешка при 250 раздавания се дължи на шум от извадката; по-продължително изпълнение я намалява – при 4 000 раздавания се получават стойности 0,50/0,50 и 0,69/0,31.)



Фигура 22: Recovering a 50/50 blend – EM mixing weights per hand. After early thrashing, TightPassive (orange) and LooseAggressive (green) converge together onto the true 0,50 line while AlwaysCall and Nash decay to zero.



Фигура 23: Recovering a 70/30 blend – the two active components settle onto their distinct true weights (dotted), recovering not just *which* two types but their proportions.

Заклучение. ЕМ възстановява не само *кои* типове са налични, но и *в какво съотношение* – интерпретируемо и честно описание („ $\approx 70\%$ камък + 30% маниак“), докато моделът с един тип даде уверено грешен отговор. Това отразява основополагащата работа в **моделирането на противника** (Bayes' Bluff, Southey и др. 2005), която поддържа *разпределение върху* стратегиите на противника, вместо да се ангажира с една. Част II обобщава това още повече – **непрекъснат** оценител в последователна форма за всяка информационна съвкупност (броене на Дирихле за всяка ситуация, което представя *всяка* стратегия, включително смес) и **състоятелен** оценител в последователна форма (Ganzfried 2025). Експеримент 4 е най-малкото, най-четимо стъпало на тази стълбица.

6.6 6. Какво установява Част I

Изследването в Част I показва с конкретни измерени стойности напрежението, което глави 07–08 са създадени да разрешат:

1. **Стойността е реална (Експеримент 2):** слепото **равновесие на Наш** оставя на масата между 0,1 и 0,3 на раздаване срещу **експлоатируеми опоненти** – следователно моделирането си заслужава.

2. **Моделът може да бъде уверен и грешен за дълго време (Експеримент 3):** в около 13% от сериите с по 500 раздавания детекторът уверено е вярвал в грешния тип след 100-ното раздаване, а стереотипното меню не може да представи **противник извън менюто** (Експерименти 3–4).
 3. **Следователно експлоатацията трябва да бъде регулирана.** Не бива да се играе най-добър отговор на това, в което моделът в момента вярва; стремежът към **експлоатация** трябва да бъде ограничен (например чрез **KL-регуларизация**) и мащабиран според това доколко е *обоснована* преценката за противника. Част I превръща този абстрактен принцип в демонстриран **режим на отказ**; Част II го измерва в пълен **мащаб**, а глава 08 изгражда **безопасния** изпълнителен механизъм.
-

7 ЧАСТ II – ПЪЛНА СИСТЕМНА ОЦЕНКА НА „КУН“ И „ЛЕДЮК“

7.1 7. Какво тестваме и как

Част II оценява цялостна система за моделиране на противника – **три взаимозаменяеми модела на противника**, които захранват **един адаптивен експлоататор** – и в двете игри, спрямо точни аналитични критерии.

Трите модела (всички използват един и същ интерфейс: приемат наблюдавани раздавания → извеждат прогнозирана **стратегия** на противника):

- **Типово базиран** – Дирихле–мултиномиално апостериорно разпределение върху фиксирано множество от типове противник (моделът от Част I, увеличен); докладва тип MAP и стратегия, усреднена по модел.
- **Непрекъснат** – оценка по Дирихле за всеки информационен набор (отчита какво е направил противникът във всяка ситуация, с изглаждане). Той може да представи *всяка* стратегия; скритите карти (при отказ) се обработват чрез разпределяне на меки/ЕМ преброявания върху съгласуваните раздавания.
- **Състоятелен** – максимално апостериорна оценка в последователна форма на Ганцфрид (2025), решена като малка задача на изпъкналата оптимизация. Оценяването на една глобално съгласувана стратегия (вместо всеки информационен набор поотделно) е замислено така, че да използва наблюденията при частична наблюдаемост по-ефективно.

Експлоататорът. На всеки k раздавания той преизгражда собствената си стратегия като точен най-добър отговор спрямо текущата оценка на модела, по избор смесена с равновесието на Наш с тегло за безопасност и по избор забравящ модела при откриване на точка на промяна (байесово онлайн откриване на точка на промяна върху сигнал за агресия). Тъй като

всичките три модела захранват *един и същ* точен най-добър отговор, експлоатацията се сравнява при равни условия.

Точни мерки. И двете игри са достатъчно малки, за да бъдат решавани напълно, така че всяка симулирана крива е ограничена от две аналитични препратки, изчислени с ръчно проверена математика, а не със симулация: `nash_ev` (какво печели безопасната равновесна игра срещу този противник – дори при безполезна преценка за противника резултатът не може да е по-лош) и `ceiling` (точната стойност на най-добрия отговор – максималното, което може да бъде извлечено). Добрият експлоататор се намира между тях и се изкачва към тавана. Самият апарат е надежден по две независими причини. *Вътрешно*: нашият решаващ възпроизвежда точната стойност на Наш за Кун от $-1/18$ ($\text{NashConv} \approx 0,002$, т.е. по същество неексплоатируем), а точният най-добър отговор побеждава равномерната игра с предвидените разлики (Кун +0,500, Ледюк +2,087). *Външно*: кръстосано валидиран спрямо **OpenSpiel**, NashConv на нашия двигател за най-добър отговор върху равномерната стратегия съвпада с този на OpenSpiel до пълна точност – Кун 0,916667 срещу 0,916667 и Ледюк 4,747222 срещу 4,747222 ($|\Delta| = 0,000000$ и в двата случая, толеранси 0,001 / 0,01). Тъй като $\text{NashConv} = br_0 + br_1$ в игра с нулева сума, това сравнява двата двигателя без никакво съпоставяне на нивове със състояния на информация.

Трите проучвания.

1. **Откриване** – може ли всеки модел да възстанови *кой* играе срещу него? За типово базирания модел представяме апостериорното разпределение върху истинския тип и дали MAP е правилен; за всички модели представяме средното разстояние по обща вариация (TV) между оценената и действителната стратегия на противника (по-ниска стойност означава по-добро възстановяване).
2. **Експлоатация** – колко печели най-добре реагиращият към всеки модел, измерено спрямо точните `nash_ev` и `ceiling`?
3. **Нестационарност** – когато противникът промени стила си по средата на мача, възстановяването чрез забравяне на точка на промяна протича ли по-бързо в сравнение с модел, който никога не забравя?

Размери на извадките. Откриване: 5 начални числа $\times$ 4 000 раздавания за всеки тип. Експлоатация: 5 начални числа $\times$ мачове от по 20 000 раздавания, с повторно напасване на всеки 200 раздавания. Нестационарност: 5 начални числа $\times$ мачове от по 20 000 раздавания със смяна на стила на 10 000-тото раздаване. Базовите линии за **равновесна игра** използват 200 000 (Кун) / 40 000 (Ледюк) **итерации на CFR**.

Бележка относно имената на типовете. В Част II се използва по-голям, специфичен за всяка игра типов зоопарк в сравнение с четирите ръчно изградени типа от Част I: зоопаркът за Кун включва {AlwaysPass, AlwaysBet, TightPassive, LooseAggressive, Thresholdish, Nash,

Random, Level1–3}, а тази за *Ледюк* съдържа {CallingStation, Maniac, Rock, LoosePassive, Nash, Random, Level1–3}. Поради това имената се различават от Част I – по-конкретно, *AlwaysCall* в Част I (пасивен играч, който никога не се отказва) е различен тип от *AlwaysPass* при Кун в Част II (който само прави чек/се отказва); пасивният играч от Част II съществува в зоопарка на *Ледюк* като *CallingStation*.

Едно умишлено уточнение – състоятелният модел не се изпълнява в цикъла на експлоатация. Той решава наново своята задача на изпъкналата оптимизация от нулата всеки път, когато експлоататорът се актуализира, а тази цена нараства с броя на вече наблюдаваните **раздавания** (от част от секундата в началото до около 12 s за всяко повторно решаване при близо 20 000 **раздавания**), което прави пълния онлайн мач непрактичен. Затова оценяваме състоятелния модел по отношение на **възстановяване на стратегия (откриване)**, където неговата последователна форма MAP е проектирана да се представи най-добре, и оставяме типово базирания и непрекъснатия модел да носят сравнението за експлоатация. (В *Ледюк* задачата в последователна форма е голяма, така че откриването със състоятелния модел се докладва само за Кун.)

7.2 8. Откриване – кой е опонентът?

Откриването, базирано на типове, е по същество перфектно: апостериорното разпределение се концентрира изцяло върху истинския тип и MAP е коректен (TV разстояние 0,000) – с **едно показателно изключение**. На Кун по-високите Level-k противници се припокриват: Level-2 и Level-3 клонят към *една и съща* поведенческа стратегия, така че апостериорното разпределение се разделя 0,50/0,50 между тях и MAP за истинския Level-3 попада върху Level-2. Това не е грешка – два типа, които играят идентично, са наистина неразличими *по своите действия*, което е всичко, което един детектор на типове може да наблюдава. **Непрекъснатите и състоятелните** модели, които оценяват действителната стратегия, а не етикет, възстановяват и двата коректно ($TV \approx 0,005$).

Непрекъснати модел има малка средна стойност на TV спрямо истината при Кун (0,006–0,030), но по-голяма при *Ледюк* (0,11–0,36): *Ледюк* разполага с далеч повече информационни множества и по-силна частична наблюдаемост, така че свободен оценител за всяко информационно множество се нуждае от значително повече раздавания, за да **достигне сходимост**, а рядко посещаваните информационни множества доминират остатъчната грешка. **Състоятелният** модел (Кун) съвпада или превъзхожда възстановяването на непрекъснати модел ($TV \approx 0,004$ – $0,021$), както е проектиран неговият MAP в последователна форма.

Заклучение. Възстановяването е успешно и класовите модели се поддредват в съответствие с теоретичните предвиждания: добре специфицираното меню от типове е ненадминато ко-

гато противникът принадлежи към него; необходимо е използването на модели, оценяващи стратегията, във всички останали случаи, като те заплащат **разход на данни**, който нараства с мащаба на играта.

7.3 9. Експлоатация – каква печалба носи моделирането?


Реализираната средна печалба на раздаване в мачове от 20 000 раздавания ($\times 5$ начални числа), спрямо точния **таван** на най-добрия отговор. Всяка таблица показва пет представителни типа от „зоопарка“ на съответната игра (10 Кун / 9 Ледюк; пълният набор е в резултатите JSON). Типово базираният модел почти точно проследява тавана и в двете игри; непрекъснатият модел го съвпада при Кун и го следва отблизо при Ледюк, като остава под него за най-трудните за нападение типове (недостига на наблюдения от §8).

Кун (таван / типово базиран / непрекъснат):

Опонент	таван	типово базиран	непрекъснат
AlwaysPass	0,975	0,966	0,966
AlwaysBet	0,333	0,335	0,335
разпуснат-агресивен	0,333	0,337	0,330
стегнат-пасивен	0,167	0,168	0,168
„Наш“	-0,055	-0,055	-0,053

Ледюк (таван / типово базиран / непрекъснат):

Опонент	таван	типово базиран	непрекъснат
Level1	3,056	3,061	2,672
Маниак	2,177	2,199	2,038
CallingStation	1,464	1,451	1,434
Камък	0,937	0,912	0,848
„Наш“	-0,083	-0,085	-0,175



Фигура 24: Exploitation vs opponent type (Ледюк): type-based (blue) hugs the exact BR ceiling for every type; continuous (orange) tracks close but sits below for the hardest-to-fit types; both drop below zero against Nash.

Резултати – два основни извода:

1. **Не можете да експлоатирате равновесие.** Срещу противника „Наш“ всеки модел печели приблизително (отрицателната) очаквана стойност при равновесие на Наш, никога повече – абсолютният таван е по същество стойността на играта. Това потвърждава, че експлоатацията е реална, а не артефакт. (Където реализираното число е с косъм *над* своя таван – например непрекъснат $-0,053$ срещу тавана от $-0,055$ срещу „Наш“ в Кун – излишъкът е шум от краен брой проби в рамките на ± 1 SE, а не реално нарушение: абсолютният таван всъщност не може да бъде надминат.)
2. **Уверен, но недообучен модел ви прави експлоатируем.** На Ледюк непрекъснатият модел губи срещу „Наш“ ($-0,175$ срещу тавана от $-0,083$): с несвършени данни той най-добре реагира на *грешна* оценка на неексплоатируем противник, създавайки уязвимост в собствената си игра.

Заклучение. Когато класът на модела е подходящ, най-добрият отговор достига точния таван на извличимата стойност – моделирането осигурява пълната теоретична стойност. Когато това не е така (непрекъснат при многото информационни множества на Ледюк), се появяват два разхода: пари, оставени на масата срещу експлоатируеми опоненти, и – по-опасно – *отрицателен* резултат срещу опонент, който изобщо не може да бъде експлоатиран. Този


втори разход е напрежението между експлоатацията и безопасността в числа и пряката мотивация за безопасната експлоатация с KL-регуларизация и ограничен риск от Глава 08.

7.4 10. Нестационарност – адаптиране към смяна по време на игра


Какво тестваме. Опонентът сменя стила си на раздаване 10 000 от общо 20 000. Сравняваме **статичен** непрекъснат модел с модел, който прилага **забравяне на точка на промяна** (откриване на промяна в стила → нулиране на модела → преминаване към безопасна игра → повторно обучение).

Резултатът е **сценарийно-зависим**, което само по себе си представлява откритието. Средната печалба на раздаване *след смяната*, усреднена за 5 начални числа ($\pm$ стандартна грешка; всяко отделно начално число съвпада по знак):

Игра	Смяна (на раздаване 10k от 20k)	точка на промяна (след смяната)	
		статичен (след смяната)	
Кун	Стегнат-пасивен	-0,106 $\pm$ 0,007	+0,211 $\pm$ 0,008
	→ Свободно-агресивен		
Ледюк	Стратегия „камък“ →	+1,834 $\pm$ 0,054	+0,552 $\pm$ 0,017
	Маниак		



Фигура 25: Non-stationarity (Kuhn): after the switch the static model bleeds (exploiting a phantom), while change-point detection resets and recovers.



Фигура 26: Non-stationarity (Ледюк): here the static model wins – the Maniac is so exploitable that continuous adaptation captures it, and the detector’s false-positive resets cost more than they save.

- **Кун – точката на промяна печели.** Остарялата анти-стратегия „камък“ (блъф-ориентирана) *активно губи* срещу новия маниак (който плаща всеки залог), така че статичният модел става отрицателен при всяко начално число ($-0,077$ до $-0,122$); откриването на смяната и повторното обучение възстановява до $+0,21$ (всички начални числа от $+0,18$ до $+0,24$). Двете ленти не се припокриват.
- **Ледюк – точката на промяна губи.** Маниакът губи $2+/\text{раздаване}$, така че непрекъснато адаптиращият се статичен модел го експлоатира добре без никакво нулиране ($+1,83$); междувременно детекторът отчита много **фалшиво положителни резултати** по време на стабилната фаза (54–63 нулирания на начално число срещу една единствена истинска смяна), всяко от които преминава към безопасна игра и изхвърля данни, и завършва три пъти и половина по-ниско ($+0,55$). Отново лентите за начални числа са ясно разделени.

Заключение. Забравянето на точка на промяна е от полза именно когато остарелият модел е *вреден*, но в наивната си форма – детектор с нисък сигнал, който често дава фалшиви сигнали, плюс пълно връщане в безопасен режим при всяко засичане – може да се представи по-слабо от простата непрекъсната адаптация, когато новият противник е толкова експлоа-

тируем, че остарелият модел губи малко. *Реакцията* на засечена промяна е толкова важна, колкото и самото ѝ засичане: по-икономични решения (частично забравяне вместо твърдо нулиране; детектор с по-ниска склонност към фалшиви задействания) са ясна следваща стъпка.

7.5 11. Достатъчни ли са размерите на извадките?

Тъй като всеки експеримент записва стойностите за всяко начално число, адекватността може да бъде количествено определена, вместо да се приема за даденост. Краткият отговор е: **адекватни във всичките три изследвания** – напълно достатъчни за експлоатация и нес-тационарност, както и достатъчни за качествените твърдения за откриване.

Експлоатация – достатъчни и с голям резерв. Стандартната грешка (СГ) на средната печалба на раздаване за 5-те начални числа е пренебрежимо малка спрямо заявените ефекти:

Игра	типична стандартна грешка (на раздаване)	разлика на типово базирания модел спрямо точния таван	недостиг на непрекъснатия модел спрямо типово базирания
Кун	0,000–0,005	в рамките на ≈ 1 стандартна грешка за 9 от 10 типа; AlwaysPass 0,966 спрямо 0,975 (≈ -17 стандартни грешки, но под 1%)	≤ 1 стандартна грешка (те съвпадат)
Ледюк	0,007–0,040	в рамките на 2 стандартни грешки за 7 от 9 типа; Камък (≈ -3) и Level2 (≈ -2 стандартни грешки), и двата под 3%	5–20 стандартни грешки (напр. Ниво1 3,061 спрямо 2,672, $\Delta = 0,389$ при стандартна грешка $\approx 0,02-0,04$)

И така (1) типово базираният модел остава **в рамките на 3% от точния таван** за всеки тип и в двете игри (и в рамките на две стандартни грешки за почти всички – 16 от 19) – „моделирането достига тавана“ не се дължи на начална случайност; и (2) недостигът на непрекъснатия модел при Ледюк (§9) е **реален ~5–20 σ ефект**, както и неговата самонанесена уязвимост

срещу „Наш“ ($-0,175$ спрямо $-0,083$, разлика от $0,092$ при $СГ \approx 0,015 \approx 6 \sigma$). Извадката потвърждава всяка разлика, на която се основава докладът.

Откриване – достатъчно за направените твърдения. Апостериорните разпределения на типово базирания модел са наситени, а разстоянията по обща вариация (TV) за непрекъснатия и състоятелния модел са стабилни и подредени според предсказанията. Представяме точкови стойности на TV, вместо грешкови ленти; по-пълна версия би повторила откриването за различните начални числа и би публикувала доверителни ленти за TV.

Нестационарност – стабилна (5 начални числа). Всяка вариация вече се изпълнява върху едни и същи 5 начални числа. Стандартните грешки след превключването са малки и, в двете игри, статичните и базираните на **точка на промяна** ленти са ясно разграничени: **Кун** $-0,106 \pm 0,007$ срещу $+0,211 \pm 0,008$ (**точката на промяна** печели с ~ 40 комбинирани СГ); **Ледюк** $+1,834 \pm 0,054$ срещу $+0,552 \pm 0,017$ (статичният модел печели с ~ 24 комбинирани СГ). Всяко отделно начално число е в съответствие със знака на ефекта, така че двустранната констатация от §10 представлява измерен резултат, а не единична реализация.

7.6 12. Ограничения

Класирани по степента, в която **квалифицират** заключенията:

1. **Детекторът за точка на промяна е прекалено чувствителен (§10).** Наблюдава се около едно фалшиво нулиране на всеки 330 раздаване в стационарен режим – съществен недостатък, произтичащ от наивния детектор и дизайна с твърдо нулиране, който е причината детекторът за точка на промяна да губи в Ледюк. Това представлява най-ясно изразената разлика в качеството и е пряк стимул за бъдещи изследвания, но не и непреодолима пречка.
2. **Експлоатацията на състоятелния модел не се измерва по дизайн (§7).** Изключването ѝ прави онлайн мачовете управляеми, но сравнението на експлоатацията е ограничено само до типово базирания срещу непрекъснатия модел; характеристиките на състоятелния модел се определят чрез възстановяване.
3. **Откриването със състоятелния модел в Ледюк е отложено** – програмата в последователна форма там е твърде голяма, поради което възстановяването между игри за състоятелния модел разчита на резултатите от Кун.
4. **Добре специфицираното откриване представлява лесен случай.** Всеки истински тип също е кандидат, така че апостериорна вероятност 1,000 е *очаквана*; това валидира механизма, но не и устойчивостта срещу опонент *извън* зададения набор – именно там непрекъснатите и състоятелните модели трябва да покажат предимствата си (и където непрекъснатият модел видимо се затруднява в Ледюк).

5. **Две малки игри, данни от самообучение.** Кун/Ледюк са точно решили *защо* са изключително малки; ефектите на частичното наблюдение и недостига на наблюдения, които доминират в Ледюк, ще се засилят значително в по-големи игри. Това е контролирано доказателство за концепция, а не твърдение за мащабируемост.
-

7.7 13. Заключение и насоки за бъдещи изследвания

Заключения. Добрият модел на противника е *необходим, но не и достатъчен* за печеливша и безопасна адаптация. Когато класът на модела съответства на противника, най-добре реагиращият към него достига точния извличаем таван (типично базиран и в двете игри; непрекъснат в Кун) – реализира се пълната теоретична стойност на моделирането. Но при частична наблюдаемост и ограничени данни (непрекъснат в Ледюк), недообученият модел както остава пари на масата, така и срещу неексплоатируем противник най-добре реагира на призрак и губи. Нестационарността добавя втори ръб: забравянето на остарял модел е полезно само когато остарялостта е активно вредна, а фалшивите нулирания на небрежен детектор могат да струват повече, отколкото спестяват. Във всичките три изследвания се повтаря един и същ принцип: степента на експлоатация трябва да съответства на това доколко е обоснована преценката за противника.

Насоки за бъдещи изследвания (всяка от които вече е обоснована с измерено въздействие по-горе):

- **Безопасна експлоатация с KL-регуляризация.** Самонанесената уязвимост на непрекъснатия модел срещу „Наш“ (§9) е емпиричното проявление на напрежението между експлоатацията и безопасността – конкретното предаване към **Глава 08** и **Принос №2** на дисертацията: ограничаване на отклонението на най-добрия отговор от равновесието на Наш според увереността на самия модел, така че недообученият модел да не може да създаде пробив.
- **Забравяне, мащабирано според увереността, вместо твърдо нулиране (§10).** Фактор за забравяне или нулиране, чиято дълбочина се мащабира с доверието на откриването, трябва да доминира над настоящото връщане в безопасен режим.
- **По-добър сигнал за точка на промяна (§10, §12).** Наблюдение на съотношението на правдоподобията за всяка информационна група или многомерен детектор върху няколко поведенчески характеристики биха намалили степента на лъжливи положителни резултати, която в момента проваля забравянето при точка на промяна в Ледюк.
- **Неправилно специфицирани / извън менюто противници (§12).** Тъй като добре специфицираното откриване е наситено, интересният режим са противниците *не* в менюто (смеси, дрейф, състезателни). Тук непараметричните модели и моделите в последователна форма трябва да се отделят от типично базирания, а детекторът „никой от

моите типове не пасва“ (откриване на типове в отворен свят) се превръща в самостоятелен въпрос – най-малката версия на който Част I (§4.2, §5) вече демонстрира в Кун.

- **Онлайн/инкрементален състоятелен модел (§7).** Започването на всяко решаване на изпъкналата задача от предишното решение и инкременталното кеширане на членовете за отделните раздавания биха могли да въведат модела в последователна форма в онлайн цикъл на експлоатация, превръщайки метод само за откриване в използваем експлоататор в реално време.
- **Възстановяване при недостиг на наблюдения (§8).** Недостигът при непрекъснатия Ледюк се дължи основно на рядко посещавани информационни групи; априорните знания, които споделят статистика между свързани информационни групи (йерархично / абстрактно-базиран), са естественото решение и свързват моделирането на противника с литературата за абстракции.

7.8 14. Възпроизвеждане

Част I – експерименти с изследване (от основната директория на хранилището, при активирана `.venv`; всеки отпечатва таблици в стандартния изход и записва фигури в `implementation/step07/exploration/figures/`):

```
python implementation/step07/exploration/behavioral_fingerprints.py # Exp 1
python implementation/step07/exploration/exploitation_opportunity.py # Exp 2 (Nash EV vs B
python implementation/step07/exploration/bayesian_type_detector.py # Exp 3 (5 hidden opp
python implementation/step07/exploration/mixture_recovery.py # Exp 4 (EM, 50/50 &
python implementation/step07/exploration/robustness_sweep.py # §4.3 sweep (500 han
```

Част II – цялостна оценка (от `implementation/step07/implementation/`, при активирана `.venv`; изисква `numpy`, `scipy`, `matplotlib`):

```
python tournament.py --config smoke # quick Kuhn pass (~3 s)
python tournament.py --config scale # full run: Kuhn ~2 min, Leduc ~14 min
python compare_openspiel.py # OpenSpiel NashConv cross-validation (needs open
```

Резултатите се записват във файлове с разширение `results/*.json`, а графиките – във файлове с разширение `plots/*.png`. Фигурите, възпроизведени в настоящия доклад, са налични в директорията `deliverables/reports/step07/figures/` (фигурите от изследването са запазени под оригиналните си имена, а фигурите от оценката носят префикс `impl_`).

8 Глава 08 – Безопасна експлоатация в игри с непълна информация

Игри: Кун покер (3 карти, 2 играчи) и Ледюк Холдем (6 карти, 2 рунда на залагане) – най-малките точно решими тестови среди с непълна информация, които използват изцяло повторно стека от Глава 07 (двигателя за Кун покер от Глава 02 + CFR решаващ, двигателя за Ледюк от Глава 03, както и кода за точен най-добър отговор/експлоатируемост и зоопарка от типове противници от Глава 07).

Връзка с дисертацията: това е втората половина на **Принос №1 (Рамка за поведенческа адаптация)** и отправната точка за **Принос №2 (Многоагентна безопасна експлоатация)**. Глава 07 изгради *сензора* – модел на противника, който превръща наблюдаваните действия в оценка на стратегията; Глава 08 изгражда *изпълнителния механизъм*, който превръща тази оценка в печалба **без да става експлоатируем**, и определя точно къде предположението за игра с нулева сума се включва в гаранциите за безопасност (точката, от която тръгва дисертацията).

Обхват на резултатите: всяко число в този доклад е **измерено от реално изпълнение** и прочетено от артефактите от изпълнението под `implementation/step08/implementation/results/`, `.../plots/` и `.../exploration/figures/`. Когато това е възможно, симулираната стойност е оградена от *точно* аналитично сравнение (стойността на играта, точната стойност на най-добрия отговор), а не от друга симулация. Две прогнози от фаза 4 бяха **опровергани** от изпълненията; съгласно работния процес на проекта, те са запазени в първоначалния си вид и съпоставени с действително настъпилото (§7, §10).

Как да се чете този доклад. И двете части следват една и съща дъга: **какво тестваме → как го тестваме → резултати → заключения**. **Част I (§1–§4)** прави компромиса между експлоатация и безопасност видим върху Кун с две малки серии експерименти с фиксирани начални числа. **Част II (§5–§13)** оценява цялата система – един двигател за линейно програмиране в последователна форма и пет семейства решаващи за безопасна експлоатация – върху Кун и Ледюк спрямо точни еталони. §14 изброява команди за възпроизвеждане.

9 ЧАСТ I – КОМПРОМИСЪТ, ВИДИМ ВЪРХУ КУН

9.1 1. За какво става дума в тази глава

Стратегия в **равновесие на Наш** никога не губи в дългосрочен план срещу *никого*, но и никога не *наказва* слаб противник – тя играе еднакво както срещу световен шампион, така и

срещу някой, който се отказва всеки път при **залог**. Глава 07 показва, че добрият **модел на противника** отключва печалба от 0,1–0,3 на раздаване срещу експлоатируеми противници, но също така и че най-добрият отговор на несъвършен модел може да създаде уязвимост в собствената игра (непрекъснатият модел *загуби* срещу „Наш“ в Ледюк). **Безопасна експлоатация** е дисциплината, която разрешава това напрежение: насочете се към **експлоатацията** на модела, но ограничете доколко **най-лошият възможен противник** може да ви накаже.

Формално, всеки метод в тази глава представлява една и съща **оптимизационна задача с ограничения**:

максимизиране на очакваната стойност на собствения агент спрямо модела на противника **при ограничение**: стойността му в най-лошия случай да не пада под прага на безопасност.

Очакваната стойност е *линейна* спрямо плана за реализация на агента в последователна форма, така че това е задача на линейното програмиране (LP); петте семейства методи се различават единствено по **какъв е прагът на безопасност**:

Метод	Праг на безопасност	Произход
ограничен отговор по Наш (RNR)	настройваем чрез параметър p (Наш при $p=0 \rightarrow$ най-добър отговор при $p=1$)	Johanson 2007
Най-добро равновесие (ganzfried)	$\geq$ стойността на играта v^* , наложена на стратегията за всяко раздаване	Ganzfried & Sandholm 2015 (техният базов вариант „най-добро равновесие“)
Prime-safe	$\geq v^* - \epsilon$, където $\epsilon =$ експлоатируемостта на базовата линия	Jeary & Turrini 2023
SES (под-игра)	$\geq$ стойността на плана, наложена <i>локално</i> върху една под-игра чрез приспособление (тук реализирано като безопасност на адаптацията по Ge и др.)	Liu и др. 2022
безопасност на адаптацията	най-лошият случай $\geq$ най-лошият случай на плана (т.е. не по-експлоатируем от плана)	Ge и др. 2024

Бележка за „най-доброто равновесие“. Ганцфрид и Сандхолм определят безопасността за повтарящата се игра (средно поне v^* на раздаване). Наложен на стратегията за всяко отделно раздаване, както тук, прагът допуска само равновесни стратегии, така че LP-задачата връща равновесието, което печели най-много срещу модела: техния базов вариант „най-добро равновесие“, а не алгоритмите им за безопасна експлоатация. Те (RWYWE, BEFFE) се отклоняват извън равновесието, като рискуват само вече натрупаните „подаръци“: RWYWE е същата LP-задача с праг $v^* - k_t$ за всяко раздаване, който се мени според натрупаните подаръци. Тези алгоритми са доказуемо безопасни и могат да експлоатират повече; реализацията и изпитването им остават за бъдеща работа (§13).


Част I изследва *наивния* край на това меню – поведенческо смесване на равновесието на Наш и най-добрия отговор – именно за да покаже защо са необходими строго обоснованите LP-методи от Част II. Всички числа в Част I са измерени при изпълнения в Кун с фиксирани начални числа; собственият агент е играч 0, чиято стойност на играта в Кун е $-1/18 \approx -0,056$ (така че „експлоатация“ означава надминаване на тази стойност срещу даден противник, а абсолютните числа могат да останат отрицателни срещу стегнат противник).

9.2 2. Експеримент 1 – наивната граница между равновесието на Наш и най-добрия отговор

Какво тестваме. Ако просто смесите равновесието на Наш и пълния най-добър отговор спрямо слаб противник – $(1-\lambda) \cdot \text{nash} + \lambda \cdot \text{full_br}$ – каква крива на компромис ще се получи между печалбата и собствената ви експлоатируемост?

Как. Изменете λ от 0 (чисто равновесие на Наш) до 1 (чист най-добър отговор) срещу силно експлоатируемия тип `TightPassive` и изчислете, **точно**, печалбата на агента (EV спрямо стегнат-пасивен) и загубата в най-лошия случай (разликата между стойността на играта и стойността на агента в най-лошия случай). Данни: `exploration/figures/pareto_curve_kuhn.json`.

λ (тегло върху пълен най-добър отговор)	печалба (EV спрямо стегнат-пасивен)	загуба в най-лошия случай (експлоатируемост)
0,0 (равновесие на Наш)	-0,047	0,001
0,3	+0,017	0,133
0,5	+0,060	0,222
0,7	+0,103	0,311
1,0 (пълен най-добър отговор)	+0,167	0,444



Фигура 27: Наивното смесване на равновесието на Наш с най-добрия отговор очертава плавна граница между експлоатация и безопасност в Кун: всяка стъпка към по-голяма печалба струва почти пропорционално нарастване на собствената загуба в най-лошия случай.

Резултати. Смесената стратегия проследява гладка, монотонна линия: всяко увеличение на печалбата е съпроводено с почти пропорционално нарастване на експлоатируемостта. Пълният най-добър отговор носи най-голяма печалба (+0,167), но е максимално експлоатируем (най-лошата загуба е 0,444 – тоест противник може да свали агента до -0,5); равновесието на Наш е неексплоатируемо, но не носи допълнителна печалба.


Заклучение. Компромисът е реален и непрекъснат, но равномерното смесване е *груб* инструмент – то мащабира отклонението навсякъде наведнъж. Стойността на LP методите от Част II се състои в това, че те избират *къде* да се отклоняват, постигайки същата печалба при по-ниска експлоатируемост (§7). Тази крива е базовата линия, която те трябва да надминат.

9.3 3. Експеримент 2 – наивната серия по бюджета на RNR (и една уговорка)

Какво тестваме. Същото смесване, преформулирано като неформалния „ограничен отговор по Наш“ от първоначалните бележки: мащабирайте отклонението с p и наблюдавайте

как печалбата и експлоатируемостта нарастват. Съществува ли *бюджет* за евтина ранна експлоатация?

Как. Изменение на $p \in \{0, \dots, 1\}$ срещу стегнат-пасивен; записване на печалбата и експлоатируемостта. Данни: `exploration/figures/rnr_playground_kuhn.json`.



Фигура 28: Наивната серия по RNR в Кун: печалбата (лява ос) и експлоатируемостта (дясна ос) растат с p . Това е неформалното смесване от първоначалните бележки – НЕ каноничният RNR на Йохансон, който в Част II се държи съвсем различно.

Резултати. Печалбата се покачва плавно от $-0,047$ (при $p=0$) до $+0,167$ (при $p=1$), а експлоатируемостта нараства синхронно от приблизително 0 до 0.444. Наблюдава се скромнен ранен „бюджет“: първите увеличения на p носят печалба при все още ниска стойност на експлоатируемостта.

Уговорка (наивен $\neq$ каноничен RNR). Това p -смесване е описанието от ден 2 на първоначалните бележки и е добър инструмент за интуиция, но то **не е** ограниченият отговор по Наш на Йохансон. Каноничният RNR търси *равновесието срещу p -ограничен противник* – максиминна LP-задача, реализирана в Част II. Част II (§7) показва, че двете се държат **напълно различно** в Кун: каноничната версия

превключва скокообразно, а не плавно. Ние ги запазваме и двете и ги обозначаваме, вместо да ги смесваме.

Заклучение. Интуицията за „бюджет“ се потвърждава при наивното смесване, но Част II показва, че принципният алгоритъм в малка игра се държи по различен начин – конкретен пример защо интуитивната серия не бива да се приема за самия алгоритъм, който то илюстрира.

9.4 4. Какво установява Първа част

1. **Компромисът между експлоатация и безопасност представлява реална, измерима зависимост** (Експеримент 1): по-голяма печалба води до по-висока собствена експлоатируемост, почти пропорционално, при наивното смесване.
 2. **Пълният най-добър отговор е рисков** – той е максимално изгоден спрямо модела, но същевременно максимално експлоатируем (най-лошият случай $-0,5$ в Кун), което е основната причина да бъде въведен праг на безопасност.
 3. **Интуитивната серия не е самият алгоритъм** (Експеримент 2): наивното смесване изглежда гладко, но каноничният RNR, който то илюстрира, не е (§7). Част II заменя грубото смесване с LP методи, които разпределят бюджета за експлоатируемост *там, където осигуряват най-голяма печалба*.
-

10 ЧАСТ II – ПЪЛНА ОЦЕНКА НА СИСТЕМАТА ВЪРХУ КУН И ЛЕДЮК

10.1 5. Какво тестваме и как

Част II оценява пълната система за безопасна експлоатация – **един двигател за линейно програмиране в последователна форма и пет семейства решавачи**, изградени върху него – и на двете игри, спрямо точни аналитични критерии.

Един двигател. HeroTreeplex изброява плана за реализация на агента в последователна форма (като използва повторно дървовидния политоп, treeplex, от Глава 07), превръща „очаквана стойност срещу постоянен противник“ в линейна цел $s \cdot x$ и налага прага на безопасност чрез **генериране на ограничения (метод на двойния оракул / метод на отсичащите равнини)**: решава LP-задачата $\rightarrow$ прочита стратегията на агента $\rightarrow$ извиква **точния най-добър отговор** от Глава 07 като противник в най-лошият случай $\rightarrow$ ако най-лошият случай е под прага, добавя линейното отсичащо ограничение и решава отново.

Петте семейства се различават единствено по прага (§1). Това означава, че една проверена елементарна операция (точният най-добър отговор от Глава 07) захранва както целта, така и всяка проверка за безопасност.

Точни критерии. И двете игри са достатъчно малки, за да бъдат решавани напълно, така че докладваната печалба и най-лошият случай на всеки решаващ се изчисляват върху пълното дърво – без извадка. Двата опорни пункта са **стойността на играта** (v^* – безопасната базова линия) и **точният пълен най-добър отговор** (таванът на експлоатацията). Безопасният метод се намира между тях; небезопасният има стойност в най-лошия случай под v^* .

Методите (идентификатори като низове, както се появяват в таблиците с резултати): `nash` (базова линия, без адаптация), `full_br` (максимизиране на EV спрямо модела, без безопасност), `rng_0.5` (каноничен RNR при $p=0.5$), `ganzfried` (най-добро равновесие: праг = v^*), `prime_safe` (праг = $v^*-\epsilon$), `adaptation` (праг = най-лошият случай на плана), `ses_subgame` (под-игра с приспособление; при Кун под-играта е цялата игра, така че съвпада с решаване чрез адаптация).

Трите изследвания.

1. **Таблица „Точен метод $\times$ тип противник“** – за всеки тип противник се решава всеки метод срещу *перфектен* модел на този тип и се отчита експлоатационната EV (печалба), стойността в най-лошия случай (безопасност) и дали тя е над прага на Наш.
2. **Ефективна граница** – каноничният RNR при различни p , наивното смесване и работните точки на най-доброто равновесие / `prime-safe` / адаптацията, всички върху един график „експлоатация срещу експлоатируемост“.
3. **Обучаваща атака (онлайн)** – измамлив противник примамва със слаб стил, след което разкрива силен; модел от Глава 7 подава на всеки решаващ по k раздавания; проследяваме осъществената печалба и броя на нарушенията на безопасността.

Конфигурации и времена за изпълнение (измерени). Кун `smoke` (30 000 итерации на CFR): **1,4 s**. Кун `scale` (200 000 итерации на CFR, добавя `AlwaysBet/AlwaysPass/ses_subgame`, обучаваща атака с 5 начални числа $\times$ 20 000 раздавания): **10,3 s**. Ледюк `bounded_scale` (човешки добавена конфигурация: лимит от 40 итерации за генериране на ограничения, `leduc_tol` = 0.01, SES върху под-играта „поп на масата“): **минути** (индивидуални клетки на SES 10–79 s). Всичко е ограничено от CPU / LP – CFR, най-добър отговор за цялото дърво и малки LP-задачи със SciPy HiGHS – така че GPU е без значение, както беше предвидено. Измерени стойности на игрите: Кун $v^* = -0.0556$ ($\approx -1/18$ ✓), Ледюк $v^* = -0.0862$.


Не е уловено. Не са запазени журнал за преминати и непреминати тестове от `validate.py` и артефакт за кръстосана проверка на `OpenSpiel` от тези изпълнения, така че тези конкретни изходни данни на рамката не се докладват; точните таблици по-долу потвърждават повечето цели за валидиране директно (§11).

10.2 6. Подробната таблица метод × противник (Кун)

Основният резултат е представен чрез решаване на всеки метод срещу перфектен модел на всеки противник, като се оценяват печалбата (EV) и безопасността (най-лошият случай), при праг на Наш $v^* = -0.056$. Данните са извлечени от файла `results/kuhn_scale.json`.

Противник	метрика	nash	full_br	rn timer 0.5	най-добро равн.	prime_safe	adaptation	ses_subgame
Стегнат пасивен	EV	-0,047	+0,167	-0,044	-0,044	-0,040	-0,040	-0,040
	най-лош случай	-0,056	-0,500	-0,056	-0,056	-0,063	-0,063	-0,063
Разпуснат агресивен	EV	+0,118	+0,333	+0,278	+0,131	+0,151	+0,151	+0,151
	най-лош случай	-0,056	-0,167	-0,111	-0,056	-0,063	-0,063	-0,063
Always Bet	EV	+0,113	+0,333	+0,333	+0,115	+0,131	+0,131	+0,131
	най-лош случай	-0,056	-0,167	-0,167	-0,056	-0,063	-0,063	-0,063
Always Pass (най-експлоатируем)	EV	+0,146	+0,975	+0,975	+0,222	+0,266	+0,266	+0,266
	най-лош случай	-0,056	-0,500	-0,333	-0,056	-0,063	-0,063	-0,063
„Наш“ (контролен)	EV	-0,056	-0,055	-0,056	-0,056	-0,055	-0,055	-0,055

Противник	метрика	най-добро					
		nash	full_br	rn timer_0.5	равн.	prime_safe	adaptation ses_subgame
най-лош	случай	-0,056	-0,333	-0,056	-0,056	-0,063	-0,063



Фигура 29: Методите срещу стегнат-пасивен (Кун): в зелено е EV срещу противника, в червено – стойността в най-лошия случай, пунктирът е прагът на Наш. Само при full_br стойността в най-лошия случай (червено) пада далеч под прага; всички останали методи остават близо до него.

Резултатите – три ключови извода.

1. **full_br е поучителната история.** Той винаги печели най-много срещу фиксиран модел (до +0,975 срещу AlwaysPass), но стойността му в най-лошия случай се срива до -0,5 – противник може да го накаже катастрофално. Това е единственият метод, който е небезопасен срещу *всеки* противник (rn timer_0.5 е небезопасен срещу три). Именно тази опасност главата трябва да предотврати.

2. **Най-доброто равновесие (ganzfried) е безопасно и все пак печели – но съвсем малко.** Срещу всеки противник стойността му в най-лошия случай остава на прага на Наш (безопасно в рамките на $1e-3$) и печели повече от стратегията на Наш срещу всеки експлоатируем тип – най-ярко **+0,222 срещу +0,146 за Наш** срещу AlwaysPass и +0,131 срещу +0,118 срещу LooseAggressive. Може да се експлоатира, като доказуемо никога не се пада под равновесната стойност, но съвсем малко: срещу четирите експлоатируеми типа в таблицата печалбата спрямо Наш е 0,002–0,076 на раздаване, т.е. 1–9% от онова, което печели пълният най-добър отговор, защото прагът v^* за всяко отделно раздаване допуска само равновесни стратегии (§1).
3. **rng_0.5 е безопасен само при малки уязвимости на противника.** Срещу TightPassive той е безопасен, но срещу силно експлоатируемите AlwaysPass/AlwaysBet той вече е *преминал* към пълен най-добър отговор (EV, идентична с тази на full_br, стойност в най-лошия случай $-0,33 / -0,17$ – небезопасен). RNR преходът е **зависим от противника** – един глобален p не е настройка за безопасност (§7).

prime_safe / adaptation / ses_subgame съвпадат при Кун (всички са насочени към един и същ праг – коригирания с ε , който е и прагът на плана, – а под-играта на SES в Кун е цялата игра). Стойността им в най-лошия случай е $-0,063 = v^* - 0.008$ и са маркирани като „небезопасни“ *единствено* защото флагът ги сравнява с v^* , докато по замисъл те легитимно се насочват към по-нисък праг (§8).


Бележка за точността на измерването. При бързата проверка smoke (30 000 итерации на CFR) дори стратегията на Наш е маркирана като „небезопасна“ (стойност в най-лошия случай $-0,0568$, т.е. 0,0013 под точната v^* , малко над допустимото отклонение $1e-3$) – чист артефакт на приближението чрез CFR. При scale (200 000 итерации) недостигът на Наш спада до $3e-4$ и той правилно е маркиран като безопасен. Урок за тестовата среда: допустимото отклонение на флага за безопасност трябва да надвишава собствената грешка на приближението на базовата линия, в противен случай базовата линия няма да издържи собствената си проверка.

10.3 7. Ефективната граница – и скокообразното превключване

Серията по параметъра p на каноничния RNR срещу стегнат-пасивен, заедно с наивното смесване и трите работни точки на LP-методите (от results/pareto_kuhn.json):

p	каноничен		наивно	
	каноничен RNR – EV	RNR – експлоа- тируемост	наивно смесване – EV	смесване – экс- плоатируемост
0,0	-0,044	~0,000	-0,047	0,000
0,3	-0,044	~0,000	+0,017	0,133
0,6	-0,044	~0,000	+0,081	0,266
0,7	+0,167	0,444	+0,103	0,311
1,0	+0,167	0,444	+0,167	0,444

Работни точки: най-доброто равновесие ganzfried (EV -0.044, експлоатируемост 0,0005); prime_safe / адаптация (EV -0.040, експлоатируемост 0,0079); измерена стойност на $\varepsilon = 0.0074$.



Фигура 30: Граница между експлоатация и безопасност (Кун). Каноничният RNR дава само две групи точки (безопасния ъгъл и ъгъла на пълния най-добър отговор); сивата линия е наивното смесване; звездите (най-доброто равновесие и съвпадащите prime-safe и адаптация) са в ефективния безопасен ъгъл, увеличен във вложената графика.

10.3.1 Предсказване ↔ реалност: каноничният RNR превключва скокообразно, а не по гладка граница

- **Предсказване (Фаза 4):** „сериата по RNR е монотонна и каноничният RNR доминира наивното смесване навсякъде.“
- **Какво всъщност се случи:** Каноничният RNR е **стъпаловидна функция**. За $p \in [0, 0.6]$ тя връща *същата* безопасна стратегия (EV -0.044, експлоатируемост ≈ 0); при $p \approx 0.7$ тя преминава направо към *пълния* най-добър отговор (EV +0.167, експлоатируемост 0.444). Между изпробваните стойности (през 0,1) **няма междинни точки**.
- **Защо (проверено разсъждение).** Целевата функция на каноничния RNR $\max_x [p \cdot \text{EV}(\text{model}) + (1-p) \cdot \min_{\sigma'} \{ \text{EV}(x, \sigma') \}]$ е *линейна* спрямо плана за реализация на агента върху *политоп*, така че нейният оптимум е **връх**, който се сменя само когато p премине критично съотношение. Политопът на стратегиите на Кун е малък (малко върхове), така че преходът е единичен скок. Гладката граница на RNR при Йохансон е явление от големи игри или от варианта със смещение към данните (много върхове или отделно p за всяко информационно множество); тя не се появява в толкова малка игра. **Наивното смесване** *проследява* гладка линия – именно защото интерполира две фиксирани стратегии – но е доминирана в безопасния ъгъл (при експлоатируемост ≈ 0 LP методите достигат EV -0.044 срещу -0.047 на смесването) и купува печалбата си във вътрешността с голям разход за експлоатируемост.
- **Скокообразно е съответствието между p и стратегията, а не границата.** Смесването на двете RNR стратегии (Йохансон и др. дефинират такова смесване) достига всяка точка от отсечката между двата ъгъла, защото EV е линейна по смесването, а стойността в най-лошия случай е вдлъбната. При двата намерени върха превключването става при $p \approx 0.68$; евентуален междинен връх би бил оптимален само за p между 0.6 и 0.7, където сериата не е проверявала. Срещу стегнат-пасивен отсечката подобрява наивното смесване само с около 0.002, така че в тази игра изборът *къде* да се отклониш почти не носи предимство пред равномерното смесване (Йохансон и др. отчитат силно вдлъбнати граници в голяма абстрахирана игра на холдем). Кун показва друго: p не е плавна скала – прагът на превключване се измества според това колко експлоатируем е противникът (§6: `rnr_0.5` вече е при *пълния* BR срещу `AlwaysPass`). Затова най-доброто равновесие – което ограничава *стойността*, а не p – е по-добрата основа.

10.4 8. Prime-safe / адаптация и измереният ϵ -бюджет

Prime-safe и адаптацията понижават прага на безопасност от v^* до $v^* - \epsilon$, където ϵ е **собствената експлоатируемост на базовата линия, измерена при CFR, спрян преждевременно** (никога измислена). Изпълнението измерва $\epsilon = 0.0074$, а стойността в най-лошия случай при prime-safe/адаптацията е $-0,063 = v^* - 0.0079$ срещу всеки противник – в съответствие с коригирания с ϵ праг до закръгляне. Изразходвайки този бюджет, те печелят малко повече от най-доброто равновесие: **+0,266 срещу +0,222** срещу AlwaysPass, +0,151 срещу +0,131 срещу LooseAggressive (§6). Те са маркирани като „небезопасни“ в таблицата само защото флагът ги сравнява с v^* ; спрямо собствения им ϵ -праг те са безопасни по конструкция. Prime-safe и адаптацията съвпадат по конструкция: ϵ се определя като v^* минус стойността на базовата линия в най-лошия случай, така че $v^* - \epsilon$ е точно тази стойност, а изпълнението използва една и съща стратегия (CFR, спрян преждевременно) като базова линия за prime-safe и като план за адаптацията. Праговете на Jeary и Turrini и на Ge и др. съвпадат винаги, когато двете са една и съща стратегия; разликата е в приложението (експлоатация в цялата игра срещу повторно решаване на под-игри), а не в прага.


Заклучение. Механизмът prime-safe функционира точно според замисъла си: несъвършена (ϵ -експлоатируема) базова линия се *измерва* коректно и прагът на безопасност се понижава именно с тази стойност – превръщайки гаранцията на Ганцфрид и Сандхолм, която „изисква точно равновесие на Наш“, в такава, приложима към приблизителните базови линии, каквито всяка реална система неизбежно притежава.

10.5 9. Обучаващата атака – защо осъществената печалба е грешната гледна точка

Какво тестваме. Измамлив противник играе слабата примамка TightPassive в първите 10 000 раздавания, след което „разкрива“ силна игра (Nash) за още 10 000; на всеки 500 раздавания непрекъснатият модел от Глава 7 подава обновената си оценка на всеки решавач (5 начални числа). Осигурява ли прагът на безопасност защита на безопасните методи, когато противникът промени поведението си? Данните са от results/kuhn_scale.json.

метод	средно на раздаване (общо)	средно на раздаване (след смяната)	нарушения на безопасността / начално число
full_br	+0,051	-0,061	40, 40, 40, 40, 40
най-добро равн. (ganzfried)	-0,048	-0,055	0, 0, 0, 0, 0
adaptation	-0,046	-0,055	40, 40, 40, 40, 40

метод	средно на раздаване (общо)	средно на раздаване (след смяната)	нарушения на безопасността / начално число
nash	-0,051	-0,061	0, 0, 0, 0, 0



Фигура 31: Обучаваща атака (Кун), натрупана печалба (изпълнение с начално число 0). `full_br` (синьо) се изкачва до $\approx +1700$ по време на примамката и след смяната само бавно слиза – завършва далеч напред, защото „разкриващият“ противник, който играе равновесие на Наш, си връща само $\approx$ стойността на играта на раздаване. Безопасните методи не се хващат на примамката и през цялото време плащат „данъка“ на първия играч.

10.5.1 Прогноза $\leftrightarrow$ реалност: „разкриващ“ противник, който играе равновесие на Наш, е твърде мек, за да накаже `full_br`

- **Прогноза (Фаза 4):** „средната стойност на безопасните методи след превключването остава близо до базовата; тази на `full_br` е ясно по-лоша; брой нарушения на безопасността = 0 за безопасните методи, > 0 за `full_br`.“
- **Какво всъщност се случи.** Половината с брой нарушения на безопасността се потвърди **напълно**: `full_br` наруши прага на Наш при **40/40** повторни настройки, най-доброто равновесие (`ganzfried`) при **0/40**. Но средната печалба на `full_br` след

смяната (-0,061) е само *незначително* по-лоша от стойността на играта (-0,056), и той завършва с **огромна нетна печалба** общо (+0,051 на раздаване) – защото „разкриващият“ противник е „Наш“, който си връща само $\approx$ стойността на играта на раздаване, така че неочакваната печалба от фазата с примамката не бива върната в рамките на 10 000 раздавания.

- **Защо (проверено разсъждение).** Най-лошият случай за една стратегия се реализира от противник, който *играе най-добър отговор срещу нея* (това е причината full_br да стигне до -0,5 в §6). Стационарният противник, който играе равновесие на Наш, **не** е такъв противник, така че експериментът с онлайн осъществена печалба никога не задейства риска, който излага точната колона на най-лошия случай. Следователно измерването на обучаващата атака чрез печалбата срещу „Наш“ *подценява* опасността.
- **Коригиран извод.** Честният разграничителен сигнал тук е **точният най-лош случай / брой нарушения на безопасността** (full_br 40, най-доброто равновесие 0), а не осъществената печалба. За да накаже full_br в печалбата, разкриването трябва да бъде **адаптивен контраексплоататор** (най-добър отговор на остарелия модел на експлоататора), а не фиксиран „Наш“. Това е конкретното усъвършенстване за следващото изпълнение (§13).
- **Нюанс в дизайна, а не грешка.** adaptation показва 40 нарушения, докато nash показва 0 (в мащаб): адаптацията умишлено се насочва към праг *под* v^* (§8), така че използваната стратегия задейства брояча, отчитан спрямо v^* , при всяка повторна настройка – по замисъл. Нулата на Наш (в пълен мащаб) потвърждава, че 10-те „нарушения“ при бързата проверка бяха артефактът от точността на CFR от §6.

10.6 10. Ледюк – основният извод: при лимит 40 итерации глобалните решавачи не достигат сходимост, а SES (лимит 400) достига

Изпълнението в **Ледюк** е конфигурацията с човешко разширение **bounded_scale**: **лимит на итерациите от 40** за цикъла на генериране на ограничения, leduc_tol = 0.01 и подиграта на SES, зададена като „поп на масата“ (leduc_flop_rank(King) – експлоатация само след като на масата се появи поп). За всяка клетка е записано дали решаването е **достигнало сходимост**, или лимита (**capped**). От results/leduc_bounded_scale.json; праг на Наш $v^* = -0.086$.

Противник		метрика		най-добро			
		nash	full_br	ses_subgame	павн.	prime_safe	adaptation
Камък	EV	+0,201	+0,937	+0,247	+0,624	+0,635	+0,635

Противник		метрика			най-добро равн.	prime_safe	adaptation
	най-лош случай	-0,089	-1,633	-0,130	-0,838	-0,744	-0,744
	сходим?	✓	✓	✓ (194 итера-ции)	✗ лимит	✗ лимит	✗ лимит
Маниак	EV	+0,438	+2,177	+0,682	+1,806	+1,842	+1,842
	най-лош случай	-0,089	-1,100	-0,130	-0,638	-0,657	-0,657
	сходим?	✓	✓	✓ (211 итера-ции)	✗ лимит	✗ лимит	✗ лимит
Разпусна	EV	+0,449	+1,405	+0,559	+1,306	+1,309	+1,309
	пассивен (LoosePassive)						
	най-лош случай	-0,089	-4,200	-0,133	-1,239	-1,334	-1,334
	сходим?	✓	✓	✗ (400 итера-ции)	✗ лимит	✗ лимит	✗ лимит
Пассивен игрок	EV	+0,559	+1,464	+0,663	+1,342	+1,363	+1,363
	(CallingStation)						
	най-лош случай	-0,089	-1,000	-0,130	-0,915	-0,686	-0,686
	сходим?	✓	✓	✓ (350 итера-ции)	✗ лимит	✗ лимит	✗ лимит
„Наш“ (контролен)	EV	-0,086	-0,083	-0,091	-0,083	-0,083	-0,083

Противник	метрика	nash	full_br	ses_subgame	най-добро равн.	prime_safe	adaptation
най-лош случай		-0,089	-0,842	-0,129	-0,376	-0,325	-0,325

10.6.1 Предсказване ↔ реалност: при лимит от 40 итерации глобалната безопасност не се пренася в Ледюк

- **Предсказване (Фаза 4):** „Ganzfried: най-лош случай $\geq v$ в рамките на допустимото отклонение (безопасно).“* И точка №1 в списъка на README за реализацията с най-вероятните слаби места: „сходимост на генерирането на ограничения + обусловеност на LP-задачата.“
- **Какво всъщност се случи.** В Ледюк глобалните решавачи (най-доброто равновесие ganzfried, prime_safe, adaptation, rnr_0.5) **всички достигнаха лимита от 40 итерации, без да достигнат сходимост**, оставяйки стойности за най-лошия случай от **-0,64 до -1,33** (нарушения на безопасността от 0,55–1,25) – грубо небезопасни. Потвърденият в Кун резултат „най-доброто равновесие е безопасно“ **не се пренесе** в Ледюк при лимит от 40 итерации.
- **Защо (проверено разсъждение).** Методът на отсичащите равнини добавя по едно отсичащо ограничение (от най-добрия отговор на противника) на итерация; при по-голямото дърво на Ледюк множеството от релевантни чисти най-добри отговори е голямо, така че 40 ограничения са далеч недостатъчни, за да фиксират истинския най-лош случай, и главната LP-задача продължава да връща оптимистични, но небезопасни стратегии. Това е точно режимът на отказ, сигнализиран преди изпълнението – сега потвърден с числа.
- **Положителният резултат. Методът на под-играта (SES) достигна сходимост** при 3 от 4 експлоатируеми противници (194 / 211 / 350 итерации), защото решава наново само под-играта „поп на масата“, като останалата част от дървото е фиксирана към плана – много по-малка LP-задача с много по-малко множество от отговори на противника. Той извлича реална стойност **(+0,25 до +0,68)** срещу слабите типове – повече от стратегията на Наш) при най-лош случай $\approx -0,13$, което е **с порядък по-близо до безопасно**, отколкото глобалните методи (-0,13 срещу -0,64...-1,33). Сравнението обаче не е при равни условия: глобалните решавачи са спрени след 40 итерации (около 2,5 s на клетка), а SES е имал лимит 400 и е използвал 194–400 итерации (30–79 s на клетка). Резултатът показва, че глобалният цикъл е бавен и небезопасен *в рамките на този бюджет*, а не че не може да достигне безопасност при по-голям.

- **Честна уговорка относно SES.** Неговата остатъчна експлоатируемост ($\approx 0,043$) все още надвишава допустимото отклонение за Ледюк от 0,01, така че и той е *маркиран като небезопасен*, а при LoosePassive изпълни 400 итерации, без да достигне сходимост. Това нарушение обаче се мери спрямо v^* . Собственият праг на SES е стойността в най-лошия случай на плана – тук спряното преждевременно CFR ($-0,120$ според бележките от изпълнението), а не равновесието на Наш ($-0,089$) – и трите клетки със сходимост са с 0,010 под него, т.е. точно на границата на допустимото отклонение 0.01. Следователно SES е спазил своя праг в рамките на допустимото отклонение, а остатъкът се дължи главно на експлоатируемостта на самия план; дали методът е *доказуемо* безопасен, ще покаже повторно изпълнение с по-малко допустимо отклонение.
- **Какво означава това.** Това е разграничението между **глобална спрямо локална безопасност** – въведено във фазите на интуиция и четене като теория – което се появява *емпирично* в игра, толкова малка, колкото Ледюк. Това е конкретната, измерена мотивация за методи на под-игри в реално време (SES / OX-Search) и за замяна на метода на отсичащите равнини с точна двойствена LP-задача, решавана еднократно. Тестова среда толкова малка се оказа достатъчно голяма, за да разкрие стената при мащабирането.

10.6.2 Укрепване на решавача по време на изпълненията

Резултатите от Ледюк съдържаха полета, които кодът от Фаза 4 не излъчваше, така че решавачът беше укрепен по време на изпълнението – съответстващо на очакваното отстраняване на грешки: малък резерв за допустимост върху отсичанията (`_FEAS_SLACK = 5e-4`, така че приблизителен праг на Наш, който леко надвишава истинския максимум, не прави главната LP-задача недопустима), изрично обработване на недопустимост (запазване на последната допустима стратегия), проследяване на `converged / capped / iterations` за всяка клетка и драйверът `bounded_scale` за Ледюк Холдем с предикат за SES „поп на масата“. Това са точно смекчаващите мерки, към които сочи списъкът „вероятно ще се случат“ в README файла на имплементацията.

10.7 11. Достоверни ли са резултатите?

Три независими проверки подкрепят числата, с две уговорки.

- **Точните опорни точки възпроизвеждат известната теория.** Измерената стойност на играта Кун е $-0,0556$ ($\approx -1/18$, известният недостатък на първия играч ✓); стойността на Ледюк е -0.0862 . Срещу противника „Наш“ всеки метод печели $\approx$ стойността на играта и не повече (§6, §10) – както трябва да бъде, тъй като равновесие не може да

бъде експлоатирано; когато едно число е съвсем малко над своя таван, това е шум от краен брой проби, а не реално нарушение.

- **Вътрешна съгласуваност на LP двигателя.** Всеки решаващ, който трябва да достигне пълната стойност на най-добрия отговор, го прави: `full_br` и постпреходният `rng` достигат точно +0,167 (Кун, стегнат-пасивен) и големите стойности на най-добрия отговор за Ледюк, което е възможно само ако векторът на печалбата в последователна форма $s \cdot x$ съвпада с точния най-добър отговор – централното условие за коректност на двигателя.
- **Сходимостта вече е наблюдаема.** Флаговете `converged` / `capped` (Ледюк) правят единственото място, където методът може да се провали безшумно – липса на сходимост при генерирането на ограничения – изрично в изхода, вместо скрито.

Уговорки. (1) Не е запазен журнал за преминати и непреминати тестове от `validate.py` и не е създаден артефакт за кръстосана проверка на OpenSpiel, поради което тези два изхода от системата за тестване остават непотвърдени чрез артефакти тук (може да се повтори изпълнението за потвърждение). (2) Ледюк беше стартиран единствено в конфигурацията `bounded_scale` с ограничен мащаб и брой итерации, така че числата на глобалните решаващи за Ледюк отразяват *бюджет*, а не решение със сходимост – те показват, че методът е бавен/небезопасен **в рамките на 40 итерации**, но не и че никога не би могъл да достигне безопасност при значително по-голям брой итерации.

10.8 12. Ограничения

Подредени според това доколко ограничават изводите:

1. **Глобалната безопасна експлоатация не достига сходимост в Ледюк (§10).** При лимит от 40 итерации методът на отсичащите равнини оставя най-доброто равновесие/`prime-safe`/адаптацията силно небезопасни. Това е най-ясната празнина и основната изследователска отправна точка – да се реши с точна двойнствена LP-задача или със значително по-голям бюджет и да се провери дали методът е „бавен“, или „структурно блокиран“.
2. **Остатъчна експлоатируемост на SES (§10).** SES достига сходимост; нарушението му от $\approx 0,04$ се мери спрямо v^* , а спрямо собствения си праг (стойността на плана в най-лошия случай) клетките със сходимост са точно на границата на допустимото отклонение 0.01. Дали методът е *доказуемо* безопасен, ще покаже повторно изпълнение с по-малко допустимо отклонение.
3. **Обучаващата атака наказва твърде слабо (§9).** Стационарният „разкриващ“ противник, който играе равновесие на Наш, не задейства най-лошия случай, така че осъществената печалба не успява да отдели безопасните от небезопасните – само броят нару-

шения го прави. Необходим е адаптивен наказващ противник, за да се покаже, че един безопасен метод *надминава* full_br при измама.

4. **Две малки игри; перфектни модели в точната таблица.** Таблиците от §6/§10 решават срещу *перфектен* модел на всеки тип (офлайн случай); онлайн случаят с обучаван модел е само обучаващата атака. Кун/Ледюк са точно решими *защото* са малки; стената на сходимостта, която се появява в Ледюк, ще се влоши още повече при увеличаване на мащаба – това е контролирано доказателство за концепция, а не твърдение за мащабиране.
5. **Непотвърдени кръстосани проверки (§11).** validate.py и сравнението с OpenSpiel не бяха уловени като артефакти.

10.9 13. Заключение и насоки за бъдещи изследвания

Заключения. Безопасната експлоатация е една идея – *максимизиране на стойността спрямо модела при спазване на праг на безопасност* – и в напълно решима игра тя работи точно както казва теорията: **най-доброто равновесие (базовият вариант на Ганцфрид и Сандхолм) е безопасно срещу всеки противник и печели повече от Наш срещу всеки експлоатируем** (+0,222 спрямо +0,146 срещу AlwaysPass), макар и само с 0,002–0,076 на раздаване, докато наивният най-добър отговор носи повече печалба, но е катастрофално експлоатируем (стойност в най-лошия случай –0,5). Prime-safe и адаптацията разширяват това към несвършени базови линии, като изразходват *измерен ϵ -бюджет* под v^* . Но най-ценният резултат от главата е отрицателен и емпиричен: в игра толкова малка като **Ледюк** *глобалното* решаване за безопасна експлоатация не достигна сходимост при лимит от 40 итерации, докато *локалният* метод на под-играта (SES, лимит 400) достигна – разликата между глобалната и локалната безопасност, измерена при неравни бюджети. Две прогнози от фаза 4 (гладка граница на RNR; най-доброто равновесие е безопасно в Ледюк) бяха опровергавани и съпоставени с резултата; съпоставките са по-поучителни, отколкото биха били самите прогнози.

Насоки за бъдещи изследвания (мотивирани от установените ефекти по-горе):

- **По-силният базов метод за двама играчи (§1).** Реализирайте алгоритъма RWYWE на Ганцфрид и Сандхолм, който рискува натрупаните подаръци – съществуващата LP-задача с праг $v^* - k_t$ за всяко раздаване, който се мени според натрупаните подаръци, – като базов метод за Принос №2 и повторете сравнението в Кун/Ледюк, като в Ледюк глобалните решавачи и решаването на под-игри получат равни бюджети.
- **Масшабируема безопасност – централната следваща задача (§10).** Заменете метода на отсичащите равнини с **точна двойнствена LP-задача, решавана еднократно**,

за ограничението за най-лошия случай, или изберете **локална безопасност на ниво под-игра** (SES / OX-Search) като мащабируем път. Липсата на сходимост в Ледюк (при неравни бюджети) е довод в полза на второто.

- **Остатъчната експлоатируемост на SES (§10).** Разликата от 0,04 се мери спрямо v^* ; спрямо собствения си праг (на плана) SES е на границата на допустимото отклонение 0.01. Повторно изпълнение с по-малко допустимо отклонение ще покаже дали методът на под-играта е доказуемо или само приблизително безопасен.
- **Наказваща обучаваща атака (§9).** Заменете „разкриващия“ противник „Наш“ с адаптивен контраексплоататор, така че осъществената печалба да потвърждава най-лошия случай и да се покаже, че безопасният метод *надминава* full_br при измама.
- **Безопасност при N играчи – принос №2 на дисертацията.** Всяка гаранция тук се основава на факта, валиден за игри с нулева сума за двама играчи, че равновесната стратегия на Наш осигурява v^* срещу всеки противник; при $N > 2$ такава опора v^* няма. Понятия за безопасност при N играчи съществуват, но са или много консервативни (максимин срещу координирана коалиция, Celli и Gatti 2018), или по принцип неосигурими (равният дял – справедлива цел, която не може да бъде гарантирана срещу противници с различни фиксирани стратегии, Ge и др. 2025). Отвореният проблем, който тази глава прави прецизен, е експлоатацията с ограничена загуба спрямо базова линия, изпитана и срещу противници в сговор.
- **Затворете цикъла на валидиране (§11).** Стартирайте и архивирайте validate.py и кръстосаната проверка на OpenSpiel; повторете глобалните решавачи за Ледюк с голям бюджет / точна двойствена задача, за да различите „бавен“ от „структурно небезопасен“.

10.10 14. Възпроизвеждане

Част I – изследване (от implementation/step08/exploration/, .venv активна; всяка отпечатва таблици в стандартния изход и записва фигури под exploration/figures/):

```
python pareto_curve.py           # Exp 1 - naive Nash/BR frontier
python rnr_playground.py         # Exp 2 - naive RNR p-sweep
python exploitation_safety_playground.py # Nash vs BR vs blend, all metrics
python naive_exploit_danger.py   # why full BR is dangerous
python subgame_peek.py           # blueprint vs local exploit (Leduc)
```

Част II – цялостна оценка (от implementation/step08/implementation/, .venv активна; изисква numpy, scipy, matplotlib):

```
python tournament.py --config smoke      # quick Kuhn pass (~1.4 s)
python tournament.py --config scale      # Kuhn full run (~10 s): table + teaching attack
python pareto.py --config scale           # the exploitation-safety frontier
python validate.py                       # PASS/FAIL vs the raw-step targets
python compare_openspiel.py              # OpenSpiel NashConv cross-validation (needs open_sp
# Leduc used a human-added bounded_scale driver (40-iter cap, King-flop SES); see results/
```

Резултатите се записват във файлове с разширение `results/*.json`, а графиките – в `plots/*.png`. Фигурите, възпроизведени в този доклад, се намират в `deliverables/reports/step08/figures` (фигурите за изследване са под оригиналните си имена; фигурите за оценка имат префикс `impl_`). Пълната проверена консолидация с регистър на прогноза↔реалност е достъпна в `implementation/step08/consolidation/report.md`.

11 Глава 9 – Многоагентно обучение с подкрепление: Доклад за експериментите

Тестови среди: четири канонични матрични игри 2×2 (дилемата на затворника, „съвпадение на монети“ (Matching Pennies), лов на елен, битка на половете); Кун покер и Ледюк холдем (чрез точните инструменти от Глава 7); собствена реализация на Goofspiel ($K = 3, 4$); две малки кооперативни среди (едностъпковата референциална игра CoopSignal и играта „изкачване“ на Claus и Boutilier); както и повтарящата се дилема на затворника с памет 1. Покер игрите използват изцяло модула за Кун от Глава 2, модула за Ледюк от Глава 3 и кода за точен най-добър отговор / NashConv от Глава 7.

Връзка с дисертацията: преминаването от игри за двама с нулева сума (глави 2–8) към многоагентно обучение с подкрепление. Три връзки: LOLA като *динамично моделиране на противника* (Принос №1); PSRO като *методология за оценяване на популационно равнище* (Принос №3); и *липсващата минимаксна опора при $N > 2$* , където гаранциите за безопасност от игрите за двама се губят (Принос №2).

Обхват на резултатите: всяко число в този доклад е **измерено при реално изпълнение** и прочетено от файловете с резултати `implementation/step09/implementation/results/{smoke,scale}_` и `implementation/step09/exploration/figures/*.json`. Когато е възможно, симулираните числа са оградени с *точен* аналитичен ориентир (аналитично равновесие на Наш за матричните игри; точен най-добър отговор / NashConv от Глава 7 за Кун, Ледюк и Goofspiel). Четири прогнози от фаза 4 бяха **опровергани** от изпълненията; съгласно работния процес на проекта (§0.1) те са запазени в първоначалния си вид и съпоставени с това, което действително се случи (§9).

Как да четете този доклад. И двете части следват една и съща дъга: **какво тестваме → как → резултати → заключение**. **Част I (§1–§4)** показва *защо* многоагентното обучение е трудно, върху матрични игри и самообучение в Кун. **Част II (§5–§8)** оценява структурните решения – PSRO, CTDE, комуникация, LOLA – спрямо точни мерки. §9 съпоставя четирите опровергани прогнози с резултатите; §10–§12 обхващат доверието, ограниченията и насоките; §13 изброява командите за възпроизвеждане.

12 ЧАСТ I – ЗАЩО МНОГОАГЕНТНОТО ОБУЧЕНИЕ Е ТРУДНО

12.1 1. Какво разглеждаме тук

Едноагентното обучение с подкрепление предполага **стационарна** среда; многоагентното обучение с подкрепление – не, тъй като другите агенти *също се учат*, което превръща ефективната среда на всеки агент в подвижна цел (**нестационарност**). Част I показва този проблем чрез най-простите възможни контролни експерименти – независими градиентни агенти в игри с точно известни равновесия на Наш – преди Част II да представи механизмите за неговото преодоляване. Всички данни от Част I идват от изследователските скриптове с фиксирани начални числа (`exploration/figures/*.json`); агентите използват **точни градиенти**, така че динамиката не съдържа шум от извадката и въпросът „сближава ли се?“ има еднозначен отговор.

12.2 2. Експеримент 1 – независими обучаващи се агенти в четирите матрични игри

Какво изследваме. Достигат ли два независими градиентни агента аналитичното равновесие на Наш във всяка канонична игра 2×2 и ако не, по какъв начин се провалят?

Как. Два агента с точен градиент, 4000 стъпки, скорост на обучение 0,1, симетрично начало (0,5, 0.5) и начално число 0. „Сближил се“ означава, че последните 100 стъпки са останали почти непроменени. Данни: `exploration/figures/matrix_games_playground.json`.

Игра	p_{final} (ред)	q_{final} (колона)	печалба на реда	сближил ли се?	аналитично равновесие на Наш
дилемата на затворника	0,0025	0,0025	1,008	да	(предателство, предателство), стойност 1
„съвпадение на монети“	0,508	0,496	−0,0001	не	смесено $(\frac{1}{2}, \frac{1}{2})$, стойност 0

Игра	p_{final} (ред)	q_{final} (колона)	печалба на реда	сближил ли се?	аналитично равновесие на Наш
лов на елен	0,0009	0,0009	2,997	да	(заек, заек), рисково доминиращо, стойност 3
битка на половете	0,0029	0,0014	0,996	да	(футбол, футбол), ред 1 / колона 2

(Тук действието с индекс 0 е сътрудничество/елен/опера; $p \rightarrow 0$ означава, че агентът на реда играе *второто* действие – предателство/заек/футбол.)

Резултати. В три от четирите игри агентите се сближават с истинско равновесие на Наш. В дилемата на затворника те стигат до взаимно предателство (доминираща стратегия). В лова на елен се установяват в **рисково доминиращото** равновесие (заек, заек) вместо в доминиращото по печалба (елен, елен) – безопасният ъгъл надделява при градиентна динамика. В битката на половете се координират в едно чисто равновесие. В „съвпадение на монети“ агентите **не се сближават**: на стъпка 4000 те са близо до $(0,51, 0.50)$, но изпълнението отчита *липса на сходимост*, а §3 показва, че траекторията продължава да се движи.

Заключение. Независимото обучение е контролният експеримент, който се проваля *умишлено*: то работи там, където играта има доминираща стратегия или достижимо чисто равновесие, и се проваля там, където единственото равновесие е смесено. Именно този провал обосновава всичко в Част II.

12.3 3. Експеримент 2 – орбитата на нестационарността („съвпадение на монети“ спрямо дилемата на затворника)

Какво тестваме. В „съвпадение на монети“ намалява ли с времето разстоянието до смесеното равновесие на Наш (сходимост), или не намалява (нестационарност)?

Как. Проследяваме разстоянието до равновесието на Наш в последователни времеви про-

зорци и го сравняваме с разстоянието до (предателство, предателство) в дилемата на затворника. Стъпки 6000, скорост на обучение 0,1, начало извън центъра (0,7, 0.3), начално число 0. Данни: exploration/figures/nonstationarity_demo.json.

Времеви прозорец	Радиус при „съвпадение на монети“	Радиус при дилемата на затворника
1	0,301	0,079
2	0,349	0,010
3	0,391	0,0058
4	0,425	0,0041
5	0,453	0,0032
6	0,476	0,0026

Резултати. Радиусът при дилемата на затворника клони към нула (сходимост). Радиусът при „съвпадение на монети“ **нараства** от 0,30 до 0,48 - траекторията се отдалечава по спирала *навън* към границата, вместо да се установи или да поддържа постоянна орбита.

Заключение. Последната итерация не се сближава. При непрекъснато време (безкрайно малка стъпка) траекторията би обикаляла около равновесието по затворена крива (Singh и др., 2000); при фиксирана стъпка 0,1 всяко обновяване излиза леко навън от кривата, затова траекторията бавно се отдалечава по спирала и при тази стъпка повече изчисления водят до по-голямо отдалечаване, а не до сходимост. (Това опровергава прогнозата от фаза 4 за „орбита с постоянен радиус“; вж. §9.)

12.4 4. Експеримент 3 – самообучение в Кун: средна срещу последна итерация

Какво изследваме. При самообучение чрез фиктивна игра в реална игра с непълна информация сближава ли се *средната* стратегия с равновесието на Наш, дори когато *последната* итерация не се сближава?

Как. Фиктивна игра в Кун (всеки играч дава най-добър отговор на текущата средна стратегия на противника чрез точния най-добър отговор от Глава 7), 200 итерации, с измерване на всеки 5. Проследяваме NashConv на средната стратегия и NashConv на последната итерация. Данни: exploration/figures/selfplay_vs_nash.json.

Итерация	NashConv на средната стратегия	NashConv на последната итерация
5	0,240	0,500
50	0,063	0,500
100	0,046	0,500
150	0,038	0,500
200	0,031	0,500

(Стойността на последната итерация се колебае в $\{0,33, 0,50, 0,67, 0,83\}$ през цялото време – тя никога не показва тенденция към намаляване.)

Резултати. Експлоатируемостта на средната стратегия намалява монотонно от 0,24 до 0,031, а стойността на последната итерация продължава да осцилира в $[0,33, 0,83]$.

Заключение. Самообучението се сближава **в средното, а не в последната итерация** – това е конкретната причина за осредняването (CFR, фиктивна игра) и за мета-Наш *сместа* върху популация в PSRO, вместо да се разчита на най-новата стратегия (§5).

13 ЧАСТ II – СТРУКТУРНИТЕ РЕШЕНИЯ

13.1 5. Експеримент 4 – PSRO при различни семейства игри

Какво изследваме. Свежда ли PSRO (популация + мета-Наш + оракул за най-добър отговор) експлоатируемостта на мета-Наш сместа до нула и запазва ли се това при игри с различен размер?

Как. PSRO с **точния** оракул за най-добър отговор от Глава 7. Мета-Наш сместа на противника върху поведенчески стратегии се свежда до една реализационно еквивалентна поведенческа стратегия (теоремата на Кун, пълна памет), за да може да се приложи модулът за точен BR. Експлоатируемостта е NashConv на мета-сместа в цялата игра. Данни: results/scale_results.json (блок psro); RPS от exploration/figures/psro_peek.json; Goofspiel $K = 3$ от results/smoke_results.json (конфигурацията в пълен мащаб изпълни само $K = 4$).

Игра	кръг 0	крайна стойност (кръг)	извод
Кун покер	0,917	$\sim 2 \times 10^{-16}$ (6)	сближава се до машинна нула

Игра	кръг 0	крайна стойност (кръг)	извод
матрична игра („съвпадение на монети“)	2,0	0,0 (2)	сближава се
камък-ножица-хартия	2,0	0,017 (4)	сближава се; смес → (0,335, 0.336, 0.329)
Ледюк Холдем	4,75	2,16 (19)	намалява, далеч над целта 0,5
Goofspiel ($K = 3$, бърза проверка)	1,33	0,0 (1)	сближава се
Goofspiel ($K = 4$)	1,50	1,71 (7); колебае се 1,24–2,0	не се установява

Резултати. В малките игри (Кун, матрична игра, RPS, Goofspiel $K = 3$) експлоатируемостта спада до практически нула за няколко кръга – типично поведение на метода на двойния оракул. Ледюк се колебае през първите осем кръга (между 3,73 и 6,83; максимумът е в кръг 1), след което намалява до 2,16, но след 20 кръга остава далеч над целта 0,5. Goofspiel $K = 4$ се колебае между $\sim 1,2$ и 2,0 през своите 8 кръга, без да се установи.

Заключение. PSRO е потвърден като мост между теорията на игрите и MARL в малките игри, със същия точен показател за експлоатируемост както в глави 2–8. Два резултата – бавната сходимост при Ледюк и колебанието при Goofspiel $K = 4$ - не съответстваха на прогнозите и са разгледани в §9.

13.2 6. Експеримент 5 – CTDE: остатък на оценителя и играта „изкачване“

Какво тестваме. (а) Има ли *централизираният* оценител по-ниска дисперсия на целевата стойност от *независимите* оценители? (б) Позволява ли централизираният оценител на кооперативните агенти да избегнат капана на некоординираността и да надминат независимите обучаващи се агенти?

Как. (а) MADDPG в едностъпковата задача CoopSignal: централизиран $Q(s, a_1, \dots, a_N)$ и отделни $Q_i(o_i)$ за всеки агент се обучават върху едни и същи данни; сравнява се крайният остатък. (б) Независими обучаващи се агенти, MADDPG и MAPPO в играта „изкачване“ на Claus и Boutilier (оптимум 11, заобиколен от наказания -30 ; безопасен атрактор 5); сравнява се отборната награда при алчна стратегия. Данни: results/scale_results.json (блок coop).

(a) Остатък на оценителя (CoopSignal):

Оценител	краен остатък (грешка на функцията на стойността)
централизиран $Q(s, a_1, \dots, a_N)$	$3,17 \times 10^{-11}$
независим $Q_i(o_i)$	0,0766

(b) Награда при алчна стратегия в играта „изкачване“:

Обучаващ се агент	награда	(оптимум 11, безопасна стойност 5)
независими обучаващи се агенти	7,0	–
MADDPG	5,0	–
MAPPO	7,0	–

Резултати. (a) Остатъкът на централизирания оценител е практически нула (той отчита целта и съвместното действие, така че наградата е детерминистична функция на входовете му) – с порядъци под остатъка 0,077 на независимия оценител: централизираният оценител напасва целевата си стойност много по-точно. Това само по себе си не означава по-ниска дисперсия на градиента на стратегията; при сходили оценители централизираният оценител може дори да я увеличи (Луи и др., 2021). (b) **Нито един метод не достига оптимума**; независимите обучаващи се агенти и MAPPO достигат 7, а **MADDPG изостава с 5** (безопасният атрактор). Тук MADDPG е вариант за дискретни действия, чийто актьор се обновява с контрафактична базова линия в стила на COMA (Foerster и др., 2018) вместо с детерминистичния градиент на стратегията, затова резултатът се отнася до този вариант, а не до MADDPG в оригиналния му вид.

Заклучение. Централизираният оценител напасва целевата си стойност много по-добре (потвърдено), но само това **не** решава координацията, когато изследването е трудно – наказанията —30 възпират агентите да опитат съвместното действие, което води до 11. Това, че MADDPG остава под независимите агенти, насочва вниманието към неговия дискретен актьор с контрафактична базова линия (§9, §11).

13.3 7. Експеримент 6 – научена комуникация (CommNet)

Какво тестваме. Позволява ли канал за съобщения, който агентите научават сами, слушател, който не вижда целта, да надхвърли тавана при случайно отгатване $1/K$?

Как. CommNet в CoopSignal ($K = 5$, таван при случайно отгатване 0,2), обучен с включен и с изключен канал; сравнява се отборната награда при алчна стратегия. Данни: results/scale_results.json (coop.communication).

Канал	награда при алчна стратегия
с комуникация	0,795
без комуникация	0,204

Резултати. С канала наградата е 0,795, далеч над тавана 0,2; без него е 0,204, точно на тавана.

Заключение. Комуникацията се научава от край до край и върши реална работа – говорителят се научава да кодира целта, а слушателят – да я декодира. (При конфигурацията за бърза проверка и двете стойности бяха 0,24; ефектът изисква обучение до сходимост – §9.)

13.4 8. Експеримент 7 – LOLA в повтарящата се дилема на затворника

Какво тестваме. Сътрудничат ли агентите, които диференцират през *следващата* стъпка на обучение на противника, там, където наивните агенти стигат до предателство?

Как. Повтаряща се дилема на затворника с памет 1 и точна затворена форма на възвръщаемостта; наивни градиентни агенти срещу агенти с LOLA (предвиждане чрез вложени крайни разлики). Сравнява се дисконтираната възвръщаемост на стъпка (пълно сътрудничество ≈ 3 , взаимно предателство ≈ 1). Данни: results/scale_results.json (lola); изследователска крива в exploration/figures/lola_ipd_playground.json.

Обучаващи се агенти	възвръщаемост на стъпка
наивни срещу наивни	1,04
LOLA срещу LOLA	2,82

(Изследователското изпълнение с по-голяма скорост на обучение при предвиждане достигна възвръщаемост с LOLA 2,67 и 2,93 за двамата агенти (средно 2,80) срещу $\sim 1,06$ при наивните.)

Резултати. Наивното обучение стига до взаимно предателство (1,04); LOLA достига почти пълно сътрудничество (2,82). Вградена проверка потвърждава механизма: при нулева скорост на обучение при предвиждане градиентът на LOLA съвпада точно с наивния градиент, така че сътрудничеството се дължи на члена от втори ред.

Заклучение. LOLA променя динамиката на обучението – *динамично* моделиране на противника – и превръща предателството в повтарящата се дилема на затворника в сътрудничество. Това е допълнението за движеща се цел към статичната преценка за противника от Глава 7 (Принос №1).

13.5 9. Съпоставка на прогнозите с реалността

Съгласно работния процес (§0.1) опроверганите прогнози от фаза 4 се запазват и се съпоставят с резултатите, а не се редактират мълчаливо. Четири разминавания:

1. **Орбитата в „съвпадение на монети“ (§3).** *Прогнозирано:* чиста орбита с приблизително постоянен радиус около $(\frac{1}{2}, \frac{1}{2})$. *Измерено:* радиусът нарасна $0,30 \rightarrow 0,48$ (спирала навън); агентът със softmax параметризация в имплементацията вместо това се отклони към ъглите ($\text{NashConv} \sim 1,8$). *Съпоставка:* урокът за липсата на сходимост остава в сила. Моделът на „енергозапазващата орбита“ е верен за непрекъснатата динамика (безкрайно малка стъпка): тогава траекторията обикаля около равновесието по затворена крива (Singh и др., 2000); при фиксирана стъпка 0,1 всяко обновяване излиза леко навън от кривата и траекторията бавно се отдалечава по спирала към границата. И в двата случая последната итерация не се сближава, а това е аргумент в полза на методите с осредняване и популация. Това не е грешка – наблюдавани са две различни, но валидни градиентни динамики.
2. **PSRO в Ледюк (§5).** *Прогнозирано:* експлоатируемост $< 0,5$ в рамките на 20 итерации. *Измерено:* $4,75 \rightarrow 2,16$ за 20 кръга – колебания през първите осем кръга (до 6,83), след това намаление, но далеч над 0,5. *Съпоставка:* истинска бавна сходимост, а не програмна грешка – Кун достигна машинна нула за 6 кръга, но дървото на Ледюк е много по-голямо и популация от 20 *чисти* стратегии не може да приближи добре неговото смесено равновесие на Наш. Целта беше прекалено оптимистична; низходящата тенденция е правилното поведение. Това се потвърждава от чистата сходимост при Кун, матричната игра и RPS по същия път в кода.
3. **Goofspiel $K = 4$ (§5).** *Прогнозирано:* ненарастваща експлоатируемост. *Измерено:* $K = 3$ (бърза проверка) се сближи до 0; $K = 4$ се колебае в интервала 1,24–2,0. *Съпоставка:* единствената необяснена аномалия. Документирана, но не поправена (съгласно избрания път). Основните заподозрени за последваща проверка: драйверът на PSRO за Goofspiel никога не премахва дублиращите се стратегии за най-добър отговор, а популация от чисти стратегии вероятно е твърде слаба, за да представи смесеното мета-Наш равновесие на по-голямата игра. Отбелязана като отворен въпрос в кода – **не** е представена като валидиран резултат на PSRO.

4. **Играта „изкачване“ (§6).** *Прогнозирано:* централизираният оценител достига оптимума 11 и надминава независимите обучаващи се агенти. *Измерено:* никой не достигна 11; независимите агенти и MAPPO достигнаха 7, а MADDPG изостана с 5. *Съпоставка:* отделният резултат за напаването на оценителя се потвърди (остатък на централизирания оценител $\sim 3 \times 10^{-11}$ срещу 0,077), така че честното разграничение е „CTDE дава по-точен оценител $\neq$ CTDE решава координацията, когато изследването е трудно“. Това, че MADDPG остава под независимите агенти, освен това насочва вниманието към неговия актьор с контрафактивна базова линия в стила на СОМА. Изводът остава в сила, но в по-сдържан вид.

Методологична бележка, която засяга всички раздели: двата **невронни** ефекта (остатък на оценителя, §6а; комуникация, §7) бяха **невидими при бързата проверка** – с комуникация = без комуникация = 0,24, загубите на оценителите почти еднакви (0,0897 срещу 0,0927) – и се проявиха едва в конфигурацията в пълен мащаб. Твърденията за невронните мрежи почиват на числата от пълния мащаб.

13.6 10. Достоверност и достатъчност на извадката

- **Игровитеоретичните резултати са ограничени от точни референтни стойности.** Матричните резултати се проверяват спрямо аналитичното равновесие на Наш; експлоатируемостта при Кун/Ледюк/Goofspiel е *точно* NashConv от Глава 7 (не симулация). Резултатът на PSRO за Кун, $\sim 2 \times 10^{-16}$, е нула с машинна точност – най-силното възможно потвърждение.
- **Матричните агенти и агентите в PSRO са детерминистични** (точни градиенти / точен BR + фиксирани начални числа), така че тези числа са напълно възпроизводими.
- **Невронните резултати са ограничени от броя начални числа.** Резултатите за кооперация, комуникация и LOLA са докладвани при едно основно начално число (конфигурацията в пълен мащаб позволява 3); те са *качествени неравенства* (централизиран < независим; с комуникация > без комуникация; LOLA > наивни), устойчиви по посока, но по големина чувствителни към началното число и версията на библиотеката. Не трябва да се тълкуват като точни точкови оценки.
- **Не е записан при това изпълнение:** журналът с преминатите и непреминатите проверки от `validate.py` (запазени са само JSON файловете с резултати). Графиките са построени от тези JSON резултати (вж. `../figures/README.md`).

13.7 11. Ограничения (подредени според влиянието им върху изводите)

1. **Колебание при Goofspiel $K = 4$ (§5, §9.3)** – необяснена аномалия на PSRO; заподозрени са липсата на премахване на дублиращите се BR в драйвера на PSRO за Goofspiel и популацията му от чисти стратегии. Докато не бъде изяснена, може да се разчита само на резултата за Goofspiel с $K = 3$.
2. **MADDPG се представя по-слабо от IL в играта „изкачване“ (§6, §9.4)** – сочи към дискретното обновяване на актьора с контрафактична базова линия (в стила на COMA); резултатите на MADDPG за *наградата* следователно не са надеждни, но резултатът му за *напасването на оценителя* (отделно, чисто измерване) е надежден.
3. **PSRO в Ледюк не достига целта (§5, §9.2)** – резултатът е истински, но означава, че твърдението „PSRO се мащабира“ е показано само качествено (низходяща тенденция), а не до ниска експлоатируемост в по-голямата игра.
4. **Невронни резултати с едно начално число (§10)** – устойчиви по посока, несигурни по големина.
5. **Мащаб на опростен модел навсякъде** – матрични игри, едностъпкови кооперативни задачи, миниатюрен покер; нищо от тук не бива да се екстраполира към дълбокото многоагентно обучение с подкрепление в голям мащаб. (Политиката за изчислителните разходи правилно ги запази малки; GPU не беше нужен.)
6. **Липсващ артефакт от изпълнението** – журналът от `validate.py` не е записан; графиките се генерират впоследствие от JSON резултатите.

13.8 12. Заключение и насоки за бъдещи изследвания

Заключения. Главата изпълнява своята дъга от край до край: независимото обучение се проваля точно там, където теорията предсказва („съвпадение на монети“), а структурните решения поправят конкретни проблеми – PSRO свежда експлоатируемостта до (почти) нула в малките игри със същия точен показател като в главите по теория на игрите; самообучението работи в средното, а не в последната итерация; централизираният оценител напасва целевата си стойност почти точно; научената комуникация надхвърля тавана при случайно отгатване; и LOLA превръща предателството в IPD в сътрудничество. Отрицателните резултати са не по-малко ценни: PSRO достига стената на мащабиране в Ледюк, централизираният оценител сам по себе си не решава координацията, когато изследването е трудно, а един вариант на PSRO (Goofspiel $K = 4$) се държи неправилно.

Насоки за бъдещи изследвания (всяка е свързана с измерен ефект):

- *Приблизителни оракули за мащабиране на PSRO* - 2,16 след 20 кръга в Ледюк (§5) мотивира RL/приблизителен оракул за най-добър отговор и измерване на това доколко той

отслабва гаранцията.

- *Поправка и повторна проверка на двете отбелязани части* – премахване на дубликати в Goofspiel $K = 4$ + популация от смесени стратегии (§9.3); контрафактичната базова линия на MADDPG (§9.4).
 - *Динамично + статично моделиране на противника* – съчетаване на предвиждането на LOLA (§8) със статичната преценка за противника от Глава 7 (Принос №1).
 - *Безопасност без минимаксна опора* – празнината при $N > 2$, посочена в обобщението (раздел 9.2 там): може ли мета-играта на PSRO да осигури използваем заместител на безопасността там, където не съществува единствена стойност на играта (Принос №2)?
-

13.9 13. Възпроизвеждане на резултатите

От `implementation/step09/implementation/` с активирана проектна `.venv`:

```
# validation harness (PASS/FAIL/SKIP against the raw-step targets)
python validate.py
```

```
# full comparison runs -> results/{smoke,scale}_results.json
python tournament.py --config smoke
python tournament.py --config scale
```

```
# plots from a results JSON -> plots/*.png (needs matplotlib; reads only, default --config scale)
python plotting.py --config scale
```

От `implementation/step09/exploration/` (фигури от Част I и съответните JSON файлове):

```
python matrix_games_playground.py
python nonstationarity_demo.py
python selfplay_vs_nash.py
python psro_peek.py
python lola_ipd_playground.py
```

```
# redraw all Part I figures from the saved JSON, without rerunning anything
python plot_results.py
```

Началните числа са фиксирани в `config.py` (реализация) и в `CONFIG` на всеки изследователски скрипт. Резултатите от матричните игри и PSRO са точно възпроизводими; невронните резултати са устойчиви по посока при различни начални числа. Всички резултати в настоящия доклад са прочетени от `results/{smoke,scale}_results.json` и `exploration/figures/*.json`.

14 Глава 10 – Обучение на базата на популации и еволюционна теория на игрите: експериментален доклад

Тестови среди: четири симетрични матрични игри за еволюционната част (дилемата на затворника, „ястреб-гълъб“, „камък-ножица-хартия“, „лов на елен“); синтетична стълбица на уменията; мета-играта на най-добрите отговори в PSRO за Ледюк Холдем; и малка **PBT лига** в стила на AlphaStar от невронни PPO агенти, които играят Ледюк Холдем. Средата за Ледюк, точният оракул за най-добър отговор и NashConv/експлоатируемостта са взети от Глава 7 (използвани без промени); PSRO и решавателят за мета-Наш са от Глава 9. Невронните агенти се обучават с PyTorch и след това се извличат в *таблични* стратегии, за да може **точният** най-добър отговор от Глава 7 да ги оцени.

Връзка с дисертацията: популационното ниво на дисертацията. Три връзки: **основните експлоататори като автоматизирани модели на противника** (Принос №1 – байесовата преценка за противника от Глава 7, пренесена на ниво популация); **лигата на AlphaStar като механизъм за безопасна експлоатация на ниво популация, чиято гаранция липсва** (Принос №2); и EGTA / **мета-Наш като методология за оценяване на популацията** (Принос №3).

Обхват на резултатите: всяко число в този доклад е **измерено при реално изпълнение** и е взето от файловете `implementation/step10/implementation/results/{smoke,scale}_results.json` и `implementation/step10/exploration/figures/*.json`. Еволюционните резултати са съпоставени с *аналитични* еталони (ESS / равновесие на Наш за всяка матрична игра), а резултатите от лигата – с *точната* експлоатируемост от Глава 7. Три прогнози от фаза 4 бяха **опровергани** от изпълнението при пълен мащаб; съгласно WORKFLOW §0.1 те се запазват така, както са формулирани, и се съпоставят с действителния резултат (§8).

Как да се чете този доклад. И двете части следват една и съща последователност: **какво проверяваме → как → резултати → заключение**. **Част I (§1-§3)** използва еволюционната теория на игрите като *диагностичен инструмент*: репликаторна динамика върху решими матрични игри и след това транзитивно-цикличното разлагане „пумпал“. **Част II (§4-§7)** изгражда и оценява **PBT лигата**: динамика на обучението, EGTA/мета-Наш, разнообразие и рейтинг по Ело и пряко сравнение с PSRO, самообучението и CFR (равновесие на Наш). §8 съпоставя трите опровергани прогнози с резултатите; §9-§11 разглеждат достоверността, ограниченията и насоките; §12 изброява командите за възпроизвеждане.

15 ЧАСТ I – ЕВОЛЮЦИОННА ТЕОРИЯ НА ИГРИТЕ КАТО ДИАГНОСТИЧЕН ИНСТРУМЕНТ

15.1 1. Какво разглежда тази глава

Глави 2–9 разглеждаха равновесията на *фиксирана* игра. Глава 10 преминава на по-високо ниво – към **популации от стратегии, които се променят във времето**, – и поставя два въпроса, на които гледната точка на един агент не може да отговори: *кои стратегии нарастват?* (репликаторна динамика) и *има ли тази игра изобщо „най-добра“ стратегия, или само кръг от контрастратегии?* (транзитивно-цикличното разлагане). Тези два инструмента са диагностиката, от която се нуждае обучението на базата на популации в Част II, защото дали една самообучаваща се популация ще се сближи, или ще зацikli, зависи от структурата на играта, а не от скоростта на обучение. Всички еволюционни числа в Част I са детерминистични (фиксирани начални числа, точна динамика), така че въпросът „сближи ли се?“ има еднозначен отговор.

15.2 2. Експеримент 1 – репликаторна динамика върху четири матрични игри

Какво проверяваме. Възпроизвежда ли репликаторната динамика *аналитичния* еволюционен резултат за всяка игра – сближаване с доминираща стратегия, с вътрешна ESS, с чиста ESS според басейна на привличане, или несходяща орбита? (Проверка по първоначалния план, L530–533.)


Как. Репликаторната динамика се интегрира с дискретния метод на Ойлер от зададена вътрешна начална точка; „сходим“ означава, че последната итерация е спряла да се променя; „орбитален радиус“ е разстоянието, на което траекторията се държи от равномерната точка. Еталон са аналитичните ESS и равновесия на Наш. Данни: `results/smoke_results.json` (блок replicator), траекториите – в `exploration/figures/replicator_playground.json`.

Игра	Аналитичен			Орбитален радиус
	еталон	Начало x_0	Краен x	
Дилемата на затворника	предателството доминира; единствената ESS (0, 1)	[0,666, 0.334]	[0,0, 1,0]	да 0,707

Игра	Аналитичен еталон	Начало x_0	Краен x	Сходим?	Орбитален радиус
Ястреб- гълъб	вътрешна ESS $p(\text{ястреб}) =$ $V/C =$ 0,5	[0,548, 0.452]	[0,5, 0,5]	да	0,0
Камък- ножица- хартия	равновесие на Наш = равномер- на стратегия; няма ESS (център)	[0,347, 0.385, 0.268]	[0,299, 0.288, 0.413]	не	0,095
Лов на елен ($x_0 =$ [0,8, 0.2])	две чисти ESS (според басейна на привлича- не)	[0,8, 0.2]	[1,0, 0,0]	да	0,707
Лов на елен ($x_0 =$ [0,2, 0.8])	две чисти ESS (според басейна на привлича- не)	[0,2, 0.8]	[0,0, 1,0]	да	0,707

Резултати. И четирите съвпадат напълно с теорията. Дилемата на затворника стига до всеобщо предателство (доминиращата стратегия). „Ястреб-гълъб“ се сближава с вътрешната смесена ESS точно при 0,5 (орбитален радиус 0,0 - траекторията *достига* точката на покой). „Камък-ножица-хартия“ **не се сближава**: траекторията обикаля около равномерния център (радиус ≈ 0.095), тъй като вътрешната неподвижна точка е център, а не атрактор. В непрекъснато време орбитите са затворени; използваният явен метод на Ойлер ги превръща в бавно разширяваща се спирали, така че радиусът леко нараства по време на изпълнението. „Лов на елен“ стига до *различни* чисти ESS в зависимост от началото - [0,8, 0.2] $\rightarrow$ всички ловуват елен, [0,2, 0.8] $\rightarrow$ всички ловуват заек – двата басейна на привличане се виждат ясно.

Заклучение. Репликаторната динамика е непрекъснатата идеализация на подбора в популация: всяко равновесие на Наш е нейна точка на покой, а всяка ESS – асимптотично устойчива точка на покой (Hofbauer & Sigmund, 2003; обратното в общия случай не е вярно – например всяка чиста стратегия е точка на покой). Играта, която *не се сближава* – „камък-ножица-хартия“, – е основната причина за Част II: цикличната игра няма устойчива популация, затова самообучаваща се популация в нея ще се върти, вместо да се установи.



Фигура 32: Траектории на репликаторната динамика (дял на първата стратегия във времето) в четирите матрични игри: в дилемата на затворника популацията стига до всеобщо предателство, в „ястреб-гълъб“ – до вътрешната ESS с дял 0,5, в „камък-ножица-хартия“ обикаля около центъра, без да се сближава, а в „лов на елен“ се разделя на два басейна (всички ловуват елен или всички ловуват заек) в зависимост от началото. Несходящата орбита при „камък-ножица-хартия“ е най-нагледният аргумент за механизмите за разнообразие в Част II.

15.3 3. Експеримент 2 – „пумпалът“: транзитивна и циклична структура

Какво проверяваме. Можем ли да разложим матрицата на печалбите на една игра на **транзитивна** компонента (стълбица на уменията) и **циклична** компонента („камък-ножица-хартя“) и разпознава ли това разлагане правилно чистите случаи и реалните популации? (Проверка по първоначалния план, L532, L534.)


Как. Комбинаторното разлагане на Ходж (по разлики в рейтингите) на антисиметричната част на матрицата на печалбите дава транзитивно и циклично съотношение (компонентите са ортогонални, затова квадратите им се събират до 1). За „камък-ножица-хартя“ даваме и транзитивното съотношение по метода SVD с ранг 1 от първоначалния план, за да документираме известния му недостатък. Данни: results/{smoke,scale}_results.json (блок spinning_top), exploration/figures/game_landscape.json.

Популация	Транзитивно съотношение (Ходж)	Циклично съотношение (Ходж)	Цикли от три стратегии	Бележка
Камък- ножица- хартя	0,0	1,0	1	SVD с ранг 1 неправилно дава 0,707
Чиста стълбица на уменията	1,0	0,0	0	монотонна сила
Мета-игра на PSRO за Ледюк (бърза проверка, 8 кръга)	0,457	0,890	–	предимно циклична
Мета-игра на PSRO за Ледюк (пълен мащаб, 20 кръга)	0,411	0,912	27	предимно циклична

Популация	Транзитивно съотношение (Ходж)	Циклично съотношение (Ходж)	Цикли от три стратегии	Бележка
Мета-игра на моментните снимки на лигата (бърза проверка / пълен мащаб)	0,981 / 0,937	–	–	предимно транзитивна

Резултати. Разлагането на Ходж разпознава точно чистите случаи: „камък-ножица-хартия“ има транзитивно съотношение 0,0 и циклично 1,0 (един цикъл от три стратегии), а стълбицата на уменията - 1,0 и 0,0. Методът **SVD с ранг 1**, предложен в първоначалния план, дава за „камък-ножица-хартия“ транзитивно съотношение ≈ 0.707 - грешно, защото сингулярните стойности на антисиметрична матрица винаги са по двойки, затова приближението с ранг 1 обхваща най-много половината от квадрата на нормата ѝ при всяка игра (чистата стълбица на уменията също получава 0,707); затова за диагностиката се използва методът на Ходж. Двете *реални* популации се различават рязко: **мета-играта на най-добрите отговори в PSRO за Ледюк е предимно циклична** (транзитивно съотношение ≈ 0.41 –0,46, 27 цикъла от три стратегии), докато **мета-играта на моментните снимки на лигата е предимно транзитивна** (≈ 0.94 –0,98).

Заклучение. Транзитивното/цикличното съотношение е *диагностика преди обучението*. Две популации от една и съща игра (Ледюк) имат противоположна структура в зависимост от начина, по който са изградени (най-добри отговори или моментни снимки от обучението – вж. §8.2). Точно този инструмент предсказва дали наивното самообучение/PBT ще се сближи, или ще зацikli, и дисертацията го пренася в следващите глави.



Фигура 33: Транзитивно съотношение на четири популации: „камък-ножица-хартя“ (0,0, чисто циклична), чиста стълбичка на уменията (1,0, чисто транзитивна), мета-играта на най-добрите отговори в PSRO за Ледюк (~0,41-0,46, предимно циклична, 27 цикъла от три стратегии) и мета-играта на моментните снимки на лигата (~0,94-0,98, предимно транзитивна). От това коя популация се разлага зависи дали Ледюк изглежда като кръг, или като стълбичка.

16 ЧАСТ II – ЛИГАТА С РВТ

16.1 4. Какво представлява лигата и как се оценява

Втората част изгражда малка **лига в стила на AlphaStar** върху Ледюк Холдем с три типа агенти – **основни** агенти (крайният продукт), **основни експлоататори** (търсят слабости в текущите основни агенти) и **експлоататори на лигата** (търсят слабости навсякъде в замразената история) – плюс периодично **замразяване** на моментни снимки в „музей“ и сдвояване по **PFSP** (по-трудните противници се избират по-често). Агентите са **невронни РРО мрежи** върху кодиране на информационното състояние в Ледюк; РВТ копира най-добрите агенти (експлоатация) и променя тяхната **скорост на обучение и ентропия** (изследване). От решаващо значение е, че всяка мрежа се извлича в **таблична стратегия**, така че **точният** най-добър отговор от Глава 7 измерва нейната **експлоатируемост** – същият показател NashConv, използван още от Глава 2. NashConv е сумата от печалбите на двата най-добри

отговора (по един за всеки играч); в конвенцията на OpenSpiel експлоатируемостта е половината от нея, затова всички стойности на експлоатируемостта в този доклад са стойности на NashConv и трябва да се разделят на две, преди да се сравняват с числа в конвенцията на OpenSpiel. Две конфигурации: **бърза проверка** (7 активни агента, 15 епохи) и **пълен мащаб** (8 активни агента, 120 епохи, 48 замразени моментни снимки).

16.2 5. Експеримент 3 – динамика на обучението в лигата


Какво проверяваме. Намалява ли експлоатируемостта на лигата по време на обучението и следва ли мета-Наш сместа на популацията това подобрение? (Проверка по първоначалния план, L535, L537.)

Как. На всяка епоха се записват минималната експлоатируемост сред основните агенти и експлоатируемостта на текущата мета-Наш смес; записват се също транзитивното съотношение на мета-играта на моментните снимки на лигата и крайният рейтинг по Ело. Данни: `results/{smoke,scale}_results.json` (блок `league`).

Показател	Бърза проверка (15 епохи)	Пълен мащаб (120 епохи)
минимална експлоатируемост сред основните агенти	4,67 → 3,04 (монотонно, най-ниската стойност е в края)	4,73 → мин ≈ 1.21 (еп 66) → 2,05 (еп 119)
експлоатируемост на мета-Наш сместа	4,73 → 3,04	5,01 → мин ≈ 1.32 (плато 1,60) → 2,96 (еп 119)
транзитивно съотношение на мета-играта на лигата	0,981	0,937
краен рейтинг по Ело (активни агенти)	1176–1211	1198–1210

Резултати. Бързата проверка показва ясно монотонно намаляване и завършва с най-ниската си стойност (3,04) – но 15 епохи са твърде малко, за да се види какво следва. Пълният мащаб го показва: експлоатируемостта спада рязко през първите около 15 епохи и е най-ниска около епохи 20–40 (мета-Наш сместа достига ≈ 1.32 в епоха 21, а най-добрата моментна снимка е от епоха 29; единичният минимум сред основните агенти, ≈ 1.21 в епоха 66, е изолиран спад), след това се задържа на плато ≈ 1.60 за мета-Наш сместа и накрая **нараства отново** до ≈ 2.05 (минимумът сред основните агенти) и ≈ 2.96 (мета-Наш) в епоха 119. Рейтингите по Ело са близки (всички активни агенти са в рамките на ≈ 15 точки), което съответства на популация с близко поведение.

Заклучение. Лигата наистина води до силно ранно подобрене, но **при пълен мащаб подобрието не е монотонно**: в края на обучението активните основни агенти губят позиции по абсолютна експлоатируемост. Натискът на експлоататорите може да допринася за това, но базовото самообучение, което няма експлоататори, също се влошава след епоха 100, така че той не е единствената причина. Най-добрите агенти са запазени като *замразени моментни снимки* от първата половина на обучението. Тази немонотонност е честният основен извод от изпълнението при пълен мащаб и е разгледана в §8.3.



Фигура 34: Експлоатируемост (NashConv) на лигата по време на обучението (пълен мащаб, 120 епохи): минимумът сред основните агенти и експлоатируемостта на мета-Наш сместа спадат рязко през първите около 15 епохи, най-ниски са около епохи 20-40 (мета-Наш ~1,32 в епоха 21) и след това отново нарастват (~2,05 / ~2,96) до епоха 119. Пунктирната сива линия е базовото самообучение, което също се влошава след епоха 100. Лигата не се подобрява монотонно; най-добрите агенти са замразени моментни снимки от първата половина на обучението.

16.3 6. Експеримент 4 – EGTA, мета-Наш и разнообразие

Какво проверяваме. (а) По-малко експлоатируема ли е мета-Наш сместа на крайната популация от всеки отделен агент (очакването от първоначалния план, L536)? (б) Колко разнообразна е популацията (ефективен размер, поведенческа клъстеризация, покритие на експло-

атацията – L538)?

Как. Строи се емпиричната симетрична матрица на печалбите за всички агенти (активни и замразени), намира се мета-Наш сместа, тя се свежда до една поведенческа стратегия и точната ѝ експлоатируемост се сравнява с тази на най-добрия отделен агент. Разнообразие: ефективен размер на популацията (коефициент на участие на мета-Наш теглата), поведенческа клъстеризация чрез единично свързване и покритие на експлоатацията. Данни: `results/{smoke,scale}_results.json` (`league.egta`, `league.diversity`). Интуиция от опростен модел: `exploration/figures/mini_pbt.json`.

(а) *Мета-Наш сместа спрямо най-добрия отделен агент:*

Конфигурация	експлоатируемост на мета-Наш сместа	най-добър отделен агент	мета-Наш $\leq$ най-добрия?
Бърза проверка	2,665	2,665	да (цялото тегло е върху най-добрия агент)
Пълен мащаб	3,418	1,305	не (теглото е разпределено: 0.645 и два по-малки дяла)


(б) *Разнообразието:*

Показател	Бърза проверка	Пълен мащаб
агенти / активни (участие)	16 / 1 (1,00)	56 / 3 (1,92)
поведенчески клъстери (праг 0,30)	1 (максимално разстояние между двойки 0,255)	1 (максимално разстояние между двойки 0,484)
покритие на експлоатацията	0,625	0,571

Резултати. (а) При бързата проверка мета-Наш дава цялото тегло на единствения най-добър агент, така че мета-Наш = най-добрия = 2,665 (прогнозата се потвърждава тривиално). При пълен мащаб мета-Наш разпределя теглото и сместа, сведена до една поведенческа стратегия, е *по-експлоатируема* (3,418) от най-добрия отделен член на популацията (1,305), който получава тегло нула – прогнозата **не се потвърждава** (§8.1). (б) Популацията е само слабо разнообразна: коефициентът на участие нараства от 1 до 1,9, но поведенческата клъстеризация свежда всичко до **един клъстер** и при двете конфигурации (въпреки че при пълен мащаб максималното разстояние между двойки, 0,484, надвишава прага 0,30 - единичното свързване обединява агентите във верига). Опростеният модел мини-PBT показва механиз-

ма нагледно: в транзитивната дилема на затворника разнообразието спада до 0, а в цикличната игра „камък-ножица-хартя“ стратегиите непрекъснато се сменят (0,07–0,29).

Заключение. EGTA дава експлоатируемост на ниво популация, но се открояват два извода: мета-Наш сместа **не** е непременно по-малко експлоатируема от най-добрия член на популацията (§8.1), а разнообразието в PBT тук е *на ниво тегла*, а не *на ниво поведение* – агентите са почти еднакви, така че „популацията“ е по-бедна, отколкото подсказва размерът ѝ.



Фигура 35: Разнообразие при мини-PBT през поколенията: в транзитивната дилема на затворника разнообразието на стратегиите в популацията спада до нула (всички преминават към предателство), а в цикличната игра „камък-ножица-хартя“ стратегиите непрекъснато се сменят (0,07–0,29), докато популацията следва кръга от контрастратегии. Дали разнообразието ще се запази, зависи от структурата на играта (изпълнен е само един размер на популацията).

16.4 7. Експеримент 5 – лигата срещу PSRO, самообучението и CFR (равновесие на Наш)

Какво проверяваме. Как се сравнява лигата с алтернативите – точния PSRO, обикновеното самообучение и CFR (равновесие на Наш) – по експлоатируемост в Ледюк? (Проверка по първоначалния план, L539.)

Как. Всеки метод се изпълнява до бюджета на своята конфигурация и се отчита експлоа-


тируемостта. За лигата се взема **най-добрият отделен агент** (най-силната замразена моментна снимка, т.е. най-добрата стойност за цялото обучение); самообучението е дадено както с крайния агент, така и с най-добрата си итерация по епохи, за да се сравнява най-доброто с най-доброто; PSRO използва точния оракул за най-добър отговор (крайната му стойност е и най-добрата); CFR дава долната граница, близка до равновесие на Наш. Данни: `results/{smoke,scale}_results.json (league, baselines)`.

Метод	Бърза проверка	Пълен мащаб	Бележка
CFR, равновесие на Наш (долна граница)	0,033 (2 хил. итерации)	0,0099 (20 хил. итерации)	приблизително равновесие на Наш, целевата долна граница
Лига – най-добър отделен агент	2,665	1,305	най-силната замразена моментна снимка (най-добрата за цялото обучение)
Самообучение – най-добра итерация	3,111	1,396 (еп 100)	най-добрата за цялото обучение, пряко сравнима с лигата
PSRO (точен оракул за най-добър отговор)	3,037 (12 кръга)	2,163 (20 кръга)	бавната „стена“ на Ледюк от Глава 9
Лига – мета-Наш смес	2,665	3,418	вж. §8.1
Самообучение – краен агент	3,140	3,683	най-добър отговор само на последната версия

Резултати. При пълен мащаб **най-добрият отделен агент** на лигата (1,305) има най-ниската стойност сред методите, основани на обучение – по-добър от точния PSRO (2,163) и от крайния агент на самообучението (3,683), но сравним с най-добрата итерация на самото самообучение (1,396 в епоха 100; и двете са от едно изпълнение, така че разликата не е значима), – и всички остават далеч над долната граница на CFR (0,0099). **Мета-Наш сместа** на лигата (3,418) е по-лоша от PSRO и от най-добрия отделен агент, но по-добра от

крайния агент на самообучението (§8.1). Крайният агент на самообучението всъщност се влошава от бързата проверка към пълния мащаб, което съответства на липсата на сходимост на последната итерация: при пълен мащаб самообучението достига 1,396 и след това се влошава през последните 20 епохи.

Заклучение. Лигата създава силни *отделни агенти* – най-добрата ѝ моментна снимка е по-добра от PSRO и от крайния агент на самообучението и е сравнима с най-добрата итерация на самообучението, – но сместа не е силна, а нито един от методите, основани на обучение, не се доближава до долната граница на точния CFR за Ледюк. Като резултат от лигата трябва да се използва избран отделен агент, а не мета-Наш сместа (§8.1).



Фигура 36: Експлоатируемост (NashConv) в Ледюк по методи (пълен мащаб): долна граница CFR (равновесие на Наш) ~0,01; най-добрият отделен агент на лигата (1,31, най-добрият за цялото обучение) е сравним с най-добрата итерация на самообучението (1,40) и е под PSRO (2,16), под мета-Наш сместа на лигата (3,42) и под крайния агент от самообучението (3,68). Като резултат трябва да се използва избран отделен агент, а не сместа.

16.5 8. Съпоставка на прогнозите с резултатите

Съгласно WORKFLOW §0.1 опроверганите прогнози от фаза 4 се запазват и се съпоставят с резултатите, а не се редактират мълчаливо. Три разминавания.

1. **Мета-Наш сместа на лигата $\leq$ най-добрият отделен агент (§6a).** Прогноза (контролният списък от първоначалния план, L536): мета-Наш сместа е по-малко експлоатиру-

ема от всеки отделен агент. *Измерено*: вярно при бързата проверка ($2,665 = 2,665$, цялото тегло е върху най-добрия агент), **невярно при пълен мащаб** ($3,418 > 1,305$). *Съпоставка*: не е грешка в смесването – същият код (`mixture_behavioral_policy`) дава мета = най-добрия при бързата проверка. Мета-Наш минимизира **съжалението в мета-играта** (резултата срещу популацията), а това е *различна цел* от минимизирането на **експлоатируемостта в пълната игра**. Сместа всъщност е *по-малко* експлоатируема от всеки от трите си компонента (3,558, 3,932, 4,262 при тегла 0,322, 0,645, 0,032); най-малко експлоатируемият агент (1,305, `main_2#e29`) и другите ранни моментни снимки просто получават тегло нула в мета-Наш. Изводът се обръща и изостря: оценката на популацията трябва да измерва пряко експлоатируемостта на сместа, а на практика като резултат да се използва избран отделен агент, а не самата смес.

2. **Мета-играта на Ледюк е транзитивна (§3).** *Прогноза*: документът с интуицията представяше покера като стълбица на уменията. *Измерено*: мета-играта на **най-добрите отговори** в PSRO е предимно циклична (транзитивно съотношение ≈ 0.41 - 0.46 , 27 цикъла от три стратегии), докато мета-играта на **моментните снимки** на лигата е предимно транзитивна (≈ 0.94 - 0.98). *Съпоставка*: не е грешка – популацията от най-добри отговори за цикля (А побеждава сместа, Б побеждава А, по-късен най-добър отговор побеждава Б; „пумпалът“ на Czarnecki и др.), докато популацията от моментни снимки от траекторията на обучение образува стълбица, защото по-късните моментни снимки обикновено са по-силни. Структурата е свойство на *популацията*, а не само на играта; и двете измервания са верни и поучителни.
3. **Експлоатируемостта на лигата намалява монотонно (§5).** *Прогноза*: монотонно намаляване. *Измерено*: при бързата проверка (15 епохи) спадът е плавен и най-ниската стойност е в края (3,04); при пълен мащаб (120 епохи) експлоатируемостта спада рязко през първите около 15 епохи, най-ниска е около епохи 20–40 (мета-Наш ≈ 1.32 в епоха 21, най-добрата моментна снимка е от епоха 29; единичен минимум сред основните агенти ≈ 1.21 в епоха 66; плато на мета-Наш 1,60) и след това **нараства отново** до $\approx 2.05 / \approx 2.96$ в епоха 119. *Съпоставка*: честна и вероятно реална нестабилност на обучението, която се вижда само при достатъчно дълго обучение – в края активните основни агенти губят позиции по абсолютна експлоатируемост (стратегии им непрекъснато се сменят и част от наученото се забравя); натискът на експлоататорите може да допринесе, но самообучението без експлоататори също се влошава след епоха 100, така че той не е единствената причина. Най-добрите агенти са замразените моментни снимки от първата половина на обучението – точно затова показателят за най-добрия отделен агент (§7) е силен, а късните активни агенти не са. Проблемът е документиран, но не е отстранен; естественото решение е запазване на най-добрата моментна снимка или регуляризация на популацията (§11). Това повтаря методологичното правило

от Глава 9: **пълният мащаб разкрива това, което бързата проверка скрива.**

16.6 9. Достоверност и достатъчност на извадката

- **Еволюционните резултати са съпоставени с аналитични еталони.** Всеки резултат на репликаторната динамика се проверява спрямо аналитичните ESS и равновесия на Наш на играта; съотношенията „пумпал“ се проверяват спрямо чистите случаи („камък-ножица-хартия“ = 0,0, стълбица на уменията = 1,0). Те са детерминистични и напълно възпроизводими.
 - **Експлоатируемостта на лигата е точният NashConv от Глава 7,** а не симулация: всяка невронна стратегия се извлича в таблична стратегия и се оценява с точен най-добър отговор, така че въпросът „колко експлоатируем е този агент/смес?“ е проверен спрямо точни стойности, а не оценен приблизително.
 - **Обучението на невронните мрежи е чувствително към началното число и към използваната библиотека.** Лигата е едно изпълнение на PBT за всяка конфигурация; надеждни са *качествените* изводи (ранно подобрене; най-добрата моментна снимка < PSRO < крайния агент на самообучението; късна регресия при пълен мащаб; мета-Наш сместа > най-добрия член на популацията при пълен мащаб), а не стойностите до третия знак след десетичната запетая.
 - **Показателите за разнообразие зависят от прага.** Резултатът с един клъстер зависи от прага 0,30 при единичното свързване; той трябва да се чете като „поведенчески сходни“, а не като „доказано една стратегия“.
-

16.7 10. Ограничения (подредени според степента на влияние върху заключенията)

1. **Регресия в късната фаза на обучението при пълен мащаб (§5, §8.3)** – лигата не се подобрява монотонно; докато не се добави запазване на най-добрата моментна снимка или регуляризация и изпълнението не се повтори, твърдението „лигата се подобрява“ важи само за *първата половина* от обучението и за *най-добрата замразена* моментна снимка, а не за активните агенти.
2. **Мета-Наш сместа е по-експлоатируема от най-добрия член на популацията, на когото дава тегло нула (§6а, §8.1)** – затова при оценката на популацията сместа не трябва да се представя като силата на лигата; правилният резултат е избраният отделен агент.
3. **Слабо поведенческо разнообразие (§6б)** – коефициентът на участие 1,9 и единст-

веният поведенчески клъстер показват, че „популацията“ е почти изродена; ползите от разнообразието, описани за AlphaStar, където по време на обучението са създадени близо 900 различни агента, не се проявяват в този мащаб.

4. **Невронните резултати са от едно изпълнение (§9)** – посоката е надеждна, но стойностите са несигурни.
5. **Мащаб на опростен модел навсякъде** – Ледюк и малки матрични игри; нищо оттук не бива да се екстраполира към лиги с дълбоко обучение с подкрепление в мащаба на AlphaStar.

16.8 11. Заключение и насоки за бъдещи изследвания

Заключения. Част I дава диагностиката: репликаторната динамика възпроизвежда всеки аналитичен резултат (ESS или равновесие на Наш), включително несходящата орбита при „камък-ножица-хартия“, а разлагането „пумпал“ на Ходж ясно отделя умениято от цикличността – и показва, че *една и съща* игра (Ледюк) е циклична като популация от най-добри отговори, но транзитивна като популация от моментни снимки. Част II изгражда лигата и я оценява с точна експлоатируемост: тя създава силни *отделни агенти* (най-добрата моментна снимка е 1,305 - по-добра от PSRO, 2,163, и сравнима с най-добрата итерация на самообучението, 1,396; крайният агент на самообучението е 3,683; всички от едно изпълнение), но три прогнози честно се оказаха неверни – при пълен мащаб мета-Наш сместа е *по-експлоатируема* от най-добрия член на популацията, мета-играта на най-добрите отговори в Ледюк е *циклична*, а не транзитивна, а експлоатируемостта на лигата *нараства отново* в края на дългото обучение. Популационният механизъм работи, но не дава гаранция за монотонност или безопасност – а точно това е празнината, към която е насочена дисертацията.

Насоки за бъдещи изследвания (всяка е свързана с измерен ефект):

- *Запазване на най-добрата моментна снимка / регуляризация на популацията* – насочено е пряко към късната регресия (§8.3); повторно изпълнение ще покаже дали липсата на гаранция е проблем на обучението, или на дизайна.
- *Отчитане на избрания отделен агент или мета-решавател с регуляризация за разнообразие* – слабостта на мета-Наш сместа (§8.1) мотивира или използването на избран агент, устойчив срещу най-добър отговор, или смяна на целта на мета-решавателя.
- *Прилагане на транзитивно-цикличната диагностика към игрите всеки срещу всеки от Глава 11* – пряка проверка на прогнозата за „голяма циклична компонента“, при която се очаква наивното РВТ да зацикли.
- *Формализиране на безопасността на популацията без опора в минимаксна стойност (Принос №2)* – механизмът с експлоататори е евристичен; §8.1 и §8.3 показват, че той не гарантира неексплоатируема популация.

16.9 12. Възпроизвеждане на резултатите

От `implementation/step10/implementation/`, с активирана проектна виртуална среда `.venv`:

```
# validation harness (PASS/FAIL/SKIP against the raw-step targets)
python validate.py
```

```
# full comparison runs -> results/{smoke,scale}_results.json
python tournament.py --config smoke
python tournament.py --config scale
```

```
# plots from a results JSON -> plots/*.png (needs matplotlib)
python plotting.py --config scale
```

От `implementation/step10/exploration/` (фигурите от Част I и съответните JSON файлове):

```
python replicator_playground.py      # replicator phase portraits + JSON
python game_landscape.py              # transitive/cyclic ratios (RPS / skill / PSRO-Leduc)
python mini_pbt.py                   # diversity collapse vs churn
python psro_population_peek.py        # PSRO population dynamics on Leduc
```

Началните числа са фиксирани в `config.py` (реализацията) и в конфигурацията на всеки скрипт за изследване. Еволюционните резултати и тези за „пумпала“ са точно възпроизводими; при невронната лига посоката на резултатите е устойчива при различни начални числа. Всички числа в този доклад са взети от `results/{smoke,scale}_results.json` и `exploration/figures/*.json`.

17 Глава 11 – Формиране и засичане на коалиции (So Long Sucker): експериментален доклад

Тестова среда: собствен детерминиран двигател на **So Long Sucker (SLS)** за 4 играчи – играта за договаряне на Хауснер, Наш, Шапли и Шубик, публикувана през 1964 г. – реализиран по публикуваните правила (не е копиран от външно хранилище), като анализът на крайната фаза на De Carufel & Jerade е еталонът, с който двигателят още не е сверен. Върху него главата изгражда **детектор на коалиции** (помощ и вреда според поставянето на жетоните), **принос по Шапли**, адаптиран към изцяло състезателна игра, обучение **MAPPO с отчитане на коалициите** чрез самообучение и анализ на популацията с **EGTA + разлагане „пумпал“**. Разлагането „пумпал“ (на Ходж) е преизползвано изцяло от Глава 10, а мета-равновесието на Наш на проектираната мета-игра – от Глава 9; детекторът на коалиции пресъздава от нулата принципа за моделиране на противника от Глава 7. Единствената **точна** опорна точка е минимаксният решаващ на **крайната фаза с двама играчи**, с който се проверява двигателят.

Връзка с дисертацията: това е *отвореният край* на дисертацията. Три връзки: **детекторът на коалиции** пренася моделирането на противника от въпроса „какъв тип играч е това?“ към въпроса „кой с кого е в съюз?“ (Принос №1); **безопасната базова линия при N играчи** губи опората си в равновесието на Наш – без минимаксна стойност и при празно ядро няма стабилно разпределение, на което да се опре безопасността; поведенческа опорна стратегия по подобие на riKL е кандидат, а не гаранция (Принос №2 – празнината, която главата *очертава*, но не *запълва*); мета-играта на **EGTA** и **приносът по Шапли** заместват експлоатируемостта, която при повече от двама играчи вече не показва какво е гарантирано на агента, още по-малко срещу коалиция (Принос №3).

Обхват на резултатите: всяко число в този доклад е **измерено в реално изпълнение** и е взето от файловете в `implementation/results/` – `smoke_results.json`, `sweep_smoke.json`, `sweep_scale.json` – и от дневника с измерени и прогнозирани стойности `EXECUTION_NOTES.md` (пътищата са относно `implementation/step11/`). Опростените кооперативни игри са проверени спрямо *точните* си учебникови стойности (игра с ръкавиците, мнозинство от трима играчи); средата SLS – спрямо *точното* минимаксно решение на крайната фаза с двама играчи. Съгласно WORKFLOW §0.1 опровергаваните прогнози са **запазени в първоначалния си вид и съпоставени** с действителния резултат (*съпоставка прогноза ↔ резултат*) – включително истинска грешка в двигателя, открита и поправена по време на работата.

Уговорка за файловете (прочетете веднъж). `results/scale_results.json` е турнир **отпреди поправката** (размах на симетричния принос 0.525, дял победи на собствения агент ~0.83, `shapley_higher_coalition:false`, `alpha=0.3`). По-

долу той се цитира **само** като доказателство за грешката с място 0 (съпоставката за *грешката в правилото при равенство*). Версия след поправката не е генерирана, затова меродавните числа за пълния мащаб идват от `sweep_scale.json` (5 начални числа), а меродавните числа за единичната конфигурация – от `smoke_results.json` след поправката.

Как да се чете докладът. Двете части следват една и съща линия: **какво проверяваме → как → резултати → заключение**. **Част I** изгражда и *проверява механизма*: двигателя на SLS спрямо точната крайна фаза, детектора на коалиции спрямо предварително зададен съюз и приноса по Шапли спрямо точни кооперативни игри и ръчно зададени позиции в SLS. **Част II** *обучава и анализира коалиции*: MAPPO с отчитане на коалициите и серията експерименти по α с 5 начални числа, след това структурата на популацията с EGTA и разлагането „пумпал“. Разделът *Съпоставка прогноза ↔ резултат* разглежда опровергаваните прогнози (грешката в правилото при равенство, мъртвата зона на α , цикличната, но не доминираща структура, компромиса между коалиции и победи); *Достоверност, Ограничения и Закljučения* обхващат надеждността, ограниченията и насоките; *Възпроизвеждане* изброява командите.

17.1 Част I – МЕХАНИЗМЪТ И НЕГОВИТЕ ТОЧНИ ОПОРНИ ТОЧКИ

17.2 За какво е тази глава

Глави 2–10 се опираха на едно: игра с **двама играчи** с **точен** оракул за най-добър отговор и експлоатируемост, така че на въпроса „проработи ли?“ се отговаряше с едно число. Глава 11 се отказва от това. Щом се включи трети играч, стават възможни **съюзи** – формирането им, използването им и предателството – а равновесието на Наш става едновременно *изчислително непосилно* ($N=4$, всеки срещу всеки) и *лишено от гаранции* (защитава само от едностранни отклонения, а не от коалиции). Затова главата заменя точната оценка с **емпирична** (дял на победите, коалиционен резултат, циклично съотношение от EGTA) и запазва една-единствена точна опорна точка: аналитично решимата **крайна фаза с двама играчи**. Всичко в Част I служи да направи по-късните твърдения за обучението надеждни – проверка на средата, на детектора и на разпределянето на приноса – преди една популация да се обучава в тази среда.

17.3 Експеримент 1 – двигателят на SLS спрямо точната крайна фаза с двама играчи

Какво проверяваме. Дали собственият двигател на SLS (а) винаги завършва, (б) запазва нулевата сума и (в) съвпада с **точен минимаксен** решавач в крайната фаза с двама играчи – единствената подигра с известен победител? (Проверка от плана на главата, коректност на средата.)

Как. Изиграват се 100 случайни игри с четирима играчи и се проверява дали завършват и дали сумата на наградите е нула. Отделно се изброяват малки позиции от крайната фаза с двама играчи и победителят при оптимална игра в двигателя се сравнява с пълно минимаксно търсене. Данни: `results/smoke_results.json` (блок `env`).

Проверка	Измерено	Резултат
Случайните игри завършват	100/100 завършени	успешна
Нулева сума на наградите	във всички игри	успешна
Двигател спрямо минимакс в крайната фаза	<code>endgame_mismatches: 0</code>	успешна

Резултати. Няма нито едно несъответствие в крайната фаза, всички игри завършват и сумата на наградите винаги е нула. Двигателят е вярна и вътрешно последователна реализация на SLS *според собствените си правила*. Една уговорка остава в сила: минимаксната проверка сертифицира двигателя спрямо **собствените му** документирани правила (`capturer-plays-next`, `empty-hand skip`, правило при равенство по `most-chips` при пат), а не спрямо формализацията на De Carufel & Jerade, чиито теореми още не са проверени (*Достоверност и достатъчност на извадката*). Тази разлика се оказва съществена (съпоставката за *грешката в правилото при равенство*).

Заключение. Средата е проверена там, където има точен отговор. Тъй като при $N=4$ точен оракул няма, тази опорна точка с двама играчи е единствената обективна проверка, на която се опира останалата част от главата – и затова при асиметрично поведение на симетрична постановка първо се подозират *опростяванията* на двигателя, а не решавачът.

17.4 Експеримент 2 – детекторът на коалиции спрямо предварително зададен съюз


Какво проверяваме. Може ли детекторът да *разпознае коалиция, за която не е получил никаква информация*, само по ходовете? (Проверка от плана на главата; Принос №1.)

Как. Двама играчи са програмирани систематично да си помагат (поставят жетони в купчините един на друг) и да вредят на останалите (вземат купчините им). Детекторът изгражда матриците `help` и `harm` от дневника `MoveEvent`, пресмята `net_support` и посочва най-силната двойка. Данни: `results/smoke_results.json` (блок `detector`).


Величина	Измерено	Оценка
Предварително зададени съюзници	$\{0, 1\}$	–
Най-силна засечена двойка	$\{0, 1\}$	вярна
Коалиционен резултат на двойката	10.0	ясно отделена
Коалиционна матрица	$[0, 1] = 10.0$; всички останали двойки 0 или -1	чиста

Резултати. Детекторът разпознава точно предварително зададената коалиция $\{0, 1\}$ с висок положителен резултат (10.0) за съюзната двойка и нулева или отрицателна нетна подкрепа навсякъде другаде. Съюзът се разчита изцяло от потока на поставяне на жетоните – в този двигател съюзът е *кодиран изцяло в ходовете* (поставянето на жетон е ръкостискане, вземането на купчина – нож): свободните и необвързващи преговори от истинската игра не се моделират. Това е проверка срещу една програмирана, открито действаща двойка; честотата на фалшивите тревоги при игра без съюзи и разпознаването на прикрити съучастници не са проверявани.

Заклучение. Моделирането на противника се обобщава естествено от „извеждане на типа или ръката на противника“ (Глава 7) към „извеждане на социалната структура“ (кой с кого е в съюз). Това е Принос №1, конкретизиран върху реална игра, и е входният сигнал, който обучението с отчитане на коалициите (*Експеримент 4*) възнаграждава.



Фигура 37: Матрица на коалиционния резултат от проверката с предварително зададен съюз (smoke_results.json), изведена само от поставянето на жетоните: съюзът между играчи 0 и 1 се вижда като силна взаимна подкрепа (10), а за останалите двойки стойностите са неутрални (0) или враждебни (-1). Детекторът разчита съюза направо от потока от ходове; в този двигател преговорите не се моделират.



Фигура 38: Коалиционен резултат по двойки през една примерна игра на базовата популация от евристични агенти (по-стара графика, чието заглавие все още е „PREDICTION“): появяват се само враждебни (отрицателни) стойности, които до края на играта се връщат към 0 – в тази популация съюз не възниква. Такъв времеви изглед е това, от което един обучаем агент би се нуждаел, за да избере момента за експлоатация и разваляне на съюза.

17.5 Експеримент 3 – принос по Шапли: точни опростени игри, после позиции в SLS

Какво проверяваме. (а) Възпроизвежда ли реализацията на стойността на Шапли *точните* учебникови стойности за опростени кооперативни игри (игра с ръкавиците, мнозинство от трима играчи), включително проверката на **ядрото** (стабилност)? (б) Адаптирана към SLS – където „стойността на коалицията“ е предефинирана като *вероятността неин член да спечели* – дава ли **симетрична** позиция **равни** приноси и съсредоточава ли **асиметрична** позиция със силна двойка приноса върху силната двойка? (Проверка от плана на главата; Принос №3.)

Как. Точна стойност на Шапли чрез изброяване за опростените игри; празнота на ядрото чрез проверка за допустимост с линейно програмиране. В SLS приносът е стойността на Шапли на характеристичната функция „вероятност за победа“, оценена чрез симулации по метода Монте Карло (shapley_rollouts=300). Данни: results/smoke_results.json (блок


shapley).

Случай	Прогноза	Измерено	Оценка
Игра с ръкавиците, стойност на Шапли	$(2/3, 1/6, 1/6)$	$[0,6667, 0.1667, 0.1667]$	точна
Игра с ръкавиците, ядро	непразно, разпределение $(1, 0, 0)$	непразно, разпределение $[1, 0, 0]$	точна
Мнозинство от трима, стойност на Шапли	$(1/3, 1/3, 1/3)$	$[0,3333, 0.3333, 0.3333]$	точна
Мнозинство от трима, ядро	празно	ядро непразно = False	точна
SLS, симетрична позиция	размах $< 0,15$	$[0,247, 0.257, 0.253, 0.243]$, успешна (след размах 0,013	поправката от съпоставката за <i>грешката в правилото при равенство</i>)
SLS, асиметрична $[8, 8, 1, 1]$	силната двойка доминира	принос на силната двойка 1,0 срещу 0,0 за слабата; $v(\{0, 1\}) = 1,0$	успешна

Резултати. Опростените кооперативни игри са възпроизведени до четвъртия знак след десетичната запетая, *включително* двата структурни факта, които имат значение за дисертацията: ядрото на играта с ръкавиците е **непразно** (съществува стабилно разпределение), а ядрото на играта на мнозинството е **празно** (няма стабилно разпределение – всяка двойка може изгодно да се отдели). В SLS наистина симетрична позиция дава почти равни приноси (размах 0.013), а асиметрична позиция със силна двойка приписва *целия* принос на силната двойка – стойността на коалицията $\{0, 1\}$ е 1.0. Симетричният резултат е получен **след** поправка на истинска грешка (съпоставката за *грешката в правилото при равенство*): при първото изпълнение размахът беше 0.54 – неуспешна проверка, която се оказа артефакт на правилото при равенство в двигателя, а не грешка в изчисляването на стойността на Шапли.

Заклучение. Кодът за стойността на Шапли е надежден сам по себе си – той издържа точните проверки и за справедливост, и за стабилност – и, адаптиран към състезателна игра чрез вероятността за победа, се държи правилно в симетрични и асиметрични позиции в SLS. **Празното ядро** на играта на мнозинството е ситуацията в SLS в миниатюра: SLS е съществена игра с постоянна сума, затова и нейното ядро е празно – *не съществува стабилно*

разпределение, така че коалициите ще се разпадат – и заедно с липсата на минимаксна стойност при повече от двама играчи това обяснява защо „безопасната“ игра при N играчи не може да се оприе на стабилно равновесие (Принос №2).



Фигура 39: Принос по Шапли в две позиции на SLS (smoke_results.json): стойност на Шапли на всяко място за характеристичната функция „вероятност за победа“. В симетричната позиция приносът е почти равен за четирите места (размах 0,013 след поправката); в асиметричната позиция [8, 8, 1, 1] силната двойка получава целия принос (0,503 + 0,497), а слабата – 0.0. Приносът следва реалното предимство едва след като правилото при равенство в двигателя стане безпристрастно.

17.6 Част II – ОБУЧЕНИЕ НА КОАЛИЦИИ И АНАЛИЗ НА ПОПУЛАЦИЯТА

17.7 Експеримент 4 – MAPPO с отчитане на коалициите и серията експерименти по α

Какво проверяваме. Дали смесването на рядката награда за победа с **коалиционен принос, разложен по Шапли**, води до агенти, които *формират повече коалиции* от агентите с рядка награда – и, което е решаващо, *при какво тегло на смесване?* (Проверка от плана на главата, L560: формирането на коалиции е основната цел, победата – второстепенна.)

Как. Агент PPO с маскиране на недопустимите ходове, обучаван по цели епизоди, заема всяко място и се обучава чрез самообучение с награда $r = \alpha \cdot r_{\text{sparse}} + (1 - \alpha) \cdot \text{credit}$ ($\alpha = 1$: само наградата за победа; $\alpha = 0$: само приносът), където credit е или евти-

ният заместител проху, изчислен от оценките на оценителя, или по-скъпият принос по Шапли чрез симулации (в кода counterfactual). **Коалиционният резултат** е средният резултат на детектора за обучената популация. Изпълненията с единична конфигурация използват стойността по подразбиране $\alpha=0.3$; след това **сдвоени сравнения с 5 начални числа** (sweep.py) обхващат всички комбинации $\alpha \times \text{credit_mode} \times \text{synergy}$ на две нива – бърза проверка (5 жетона, 400 игри за обучение) и пълен мащаб (7 жетона, 1500 игри) – и отчитат сдвоената разлика $\text{gap} = \text{coalition_score}(\text{shapley}) - \text{coalition_score}(\text{sparse})$ с интервали на грешката. Данни: results/smoke_results.json (training), results/sweep_{smoke,scale}.json.

Единична конфигурация (по подразбиране $\alpha=0.3$):

Метод	Коалиционен резултат (бърза проверка)	Дял победи срещу случайна игра (бърза проверка)
Случайна базова линия	0,000	0,250
MAPPO (рядка награда)	0,00125	0,44
MAPPO + принос по Шапли (тази глава)	0,00417	0,41


*Сдвоени сравнения с 5 начални числа (** = средна разлика $> 2 \cdot SE$, което при 5 начални числа отговаря приблизително на $p < 0,12$; коалиционен резултат на базовата линия с рядка награда: бърза проверка 0,0073, пълен мащаб 0,0109):*

Ниво	Принос	α	Синергия	Разлика (Шапли – рядка)	Знач.
пълен мащаб (7/1500)	заместител	0,0	0,3	$+0,0376 \pm 0,0103$	** (резултат ~4,5 пъти по-висок)
пълен мащаб	заместител	0,0	0,1	$+0,0305 \pm 0,0130$	**
пълен мащаб	чрез симулации	0,0	–	$+0,0128 \pm 0,0026$	**
пълен мащаб	всеки	$\geq 0,3$	*	$-0,0003 \dots -0,0035$	– (навсякъде отрицателна)
бърза проверка (5/400)	заместител	0,0	0,1	$+0,0024 \pm 0,0008$	** (много малка)

Ниво	Принос	α	Синергия	Разлика (Шапли – рядка)	Знач.
бърза проверка	<i>всеки</i>	$\geq 0,3$	*	$-0,0031 \dots +$ $0,0012$	– (без значими)

Резултати. При стойността по подразбиране $\alpha=0.3$ агентът с принос по Шапли надминава агента с рядка награда при бързата проверка ($0.00417 > 0.00125$), но само с малко, а в единичното изпълнение при пълен мащаб отпреди поправката посоката се обърна (съпоставката за *мъртвата зона на α*). Серията експерименти премахва неяснотата: **α е определящият параметър, а 0.3 попада в мъртва зона.** Коалиционният резултат нараства *значимо* само при ниско α : при $\alpha \approx 0$ заместителят с $\text{synergy}=0.3$ дава вдвояна разлика $+0.0376 \pm 0.0103$ (резултатът на агентите с принос, 0.0484 , е $\sim 4,5$ пъти този на базовата линия 0.0109), докато **всяка клетка с $\alpha \geq 0.3$ при пълния мащаб е отрицателна.** Ефектът е *по-голям* при пълния мащаб (12 пъти разликата при бързата проверка при $\text{synergy}=0.1$; размерът на играта и продължителността на обучението се променят заедно, така че двата фактора не са разделени), а **евтиният заместител дава по-силен ефект от скъпия принос чрез симулации** ($+0.038$ срещу $+0.013$ при пълния мащаб).

Заклучение. Ефектът при ниско α е **реален и устойчив в серията експерименти, но още не доказва научени коалиции.** Както е реализиран, приносът не носи информация за коалициите: стойността от симулациите $v(S) = \sum_{i \in S} P(i \text{ печели})$ е адитивна, така че приносът по Шапли на всеки играч е просто собствената му вероятност за победа (изчислявана веднъж за партида, от началното състояние), а центрираният заместител е собствената оценка на оценителя за агента минус средната за масата; коалиционният резултат (средното $|C_{ij}|$) расте и при взаимна враждебност. Преди ефектът да се тълкува като формиране на коалиции, е нужен контролен експеримент с плътна награда без коалиционна информация. Решението е „да се даде голяма тежест на коалиционния принос“ ($\alpha \approx 0.05 - 0.1$), а не „да се изчисли по-точен принос“. И това има цена: изцяло коалиционният принос ($\alpha=0$) сваля дела на победите до ~ 0.29 (близо до нивото на случайната игра 0.25), докато при $\alpha \geq 0.1$ той остава ~ 0.52 (съпоставката *коалиции срещу победи*) – коалиционният резултат се купува със състезателно представяне, точно както беше заложено в плана на главата.



Фигура 40: Сдвоена разлика в коалиционния резултат (Шапли минус рядка награда) за всички комбинации $\alpha \times$ вид на приноса $\times$ синергия, 5 начални числа, $\pm$ една стандартна грешка. Разликата е голяма и значима само при ниско α (максимум +0,038 при заместителя и $\alpha = 0$; резултатът на агентите с принос е $\sim 4,5$ пъти този на базовата линия), а при пълен мащаб е отрицателна при всяко $\alpha \geq 0.3$. Първоначалният нулев резултат идва от измерване при $\alpha = 0,3$ – мъртвата зона.

17.8 Експеримент 5 – EGTA и разлагането „пумпал“: циклична ли е SLS?

Какво проверяваме. Ако целите стратегии в SLS се разглеждат като атоми на мета-игра, циклична ли е получената популация (кръг от контрастратегии между коалициите, както Глава 10 предвиди за игрите всеки срещу всеки), или **транзитивна** (стълба на уменията)? (Проверка от плана на главата, L561.)

Как. Всяка група стратегии се изиграва, за да се попълни емпиричната матрица на печалбите; тензорът на печалбите за четирима играчи се **проецира** в матрица на сблъсъците по двойки (така `solve_meta_nash` от Глава 9 и `spinning_top` на Ходж от Глава 10 остават приложими) и се отчита транзитивното и цикличното съотношение. Разлагат се две популации: базовата популация „**стълба на уменията**“ и **коалиционна популация** (`fixed_ally_1/2/3 + betrayer_1 + random`). Данни: `results/smoke_results.json` (egta), `EXECUTION_NOTES.md` (проверка 5; за коалиционната популация няма файл с резултати).

Популация	Транзитивна	Циклична	Структура
„Стълба на уменията“ (бърза проверка)	0,9675	0,2529	преобладаващо транзитивна
„Стълба на уменията“ (пълнен мащаб)	0,951	0,308	преобладаващо транзитивна
Коалиционна популация (60 игри/клетка)	–	$\approx 0,57$	силна циклична компонента
Коалиционна популация (200 игри/клетка)	–	$\approx 0,69$	силна циклична компонента

Резултати. Както в Глава 10, *коя популация се разлага определя какво се вижда*. Базовата популация „стълба на уменията“ е преобладаващо транзитивна (циклично съотношение 0.25-0.31), но коалиционната популация повишава цикличното съотношение до **~0.57-0.69** – голяма нетранзитивна компонента, която силно потвърждава *посоката* на прогнозата (L561). Проверката **остава неуспешна** по строгия праг „>50% доминиране“ (квадратът на цикличното съотношение е все още малко под 0.5; транзитивната компонента е малко по-голяма, а популацията не е нагласяна да премине границата).

Заклучение. Коалиционните стратегии правят SLS *съществено нетранзитивна и почти балансирана*, но не строго доминирана от цикличната компонента в този мащаб. Вероятната причина за остатъка е, че **проекцията върху двойки типове губи коалиционните ефекти между трима и четирима играчи** – разлагане директно на тензора или проекция за 3 типа е отвореният въпрос на моделирането (съпоставката *циклична, но не доминираща, Заклучения и насоки*). Уговорката от Глава 10 се повтаря дословно: начинът, по който се съставя популацията, определя дали ще се види колело, или стълба.

17.9 Обобщение на проверките

Скриптът `validate.py` съдържа критериите за успех и неуспех от плана на главата. След поправката на двигателя от съпоставката за *грешката в правилото при равенство*:

№	Проверка	Резултат	Оценка
1	Среда SLS (крайна фаза спрямо минимакс / завършване / нулева сума)	0 несъответствия, завършва, нулева сума	успешна
2	Засичане на коалиции (предварително зададена $\{0, 1\}$)	най-силна двойка $\{0, 1\}$, резултат 10.0	успешна
3	Шапли (опростени игри + размах при симетрия + асиметрия)	ръкавици/мнозинство точно; размах 0.013; силната двойка доминира	успешна
4	Обучение с отчитане на коалициите (бърза проверка)	Шапли 0.004 > рядка 0.001	успешна
5	Пумпал (строго циклично доминиране > 50%)	коалиционна популация: циклично ~0.57-0.69, под строгия праг	неуспешна (честно)

Общо: validate.py --config smoke = 4 от 5 успешни. Проверка 5 честно остава неуспешна по правилото за строго доминиране (и Глава 10 завърши с честно неуспешна проверка). Механизмът (среда, детектор, Шапли) е напълно проверен; единственият неуспех е находка за структурата на играта, а не грешка в кода.

17.10 Съпоставка прогноза ↔ резултат

Съгласно WORKFLOW §0.1 опровергаваните прогнози се запазват и съпоставят с резултата, а не се поправят мълчаливо. Четири разминавания – едно от тях истинска грешка, открита, защото първо беше заподозрян двигателят, а не прогнозата.

17.10.1 Двете неуспешни проверки имаха една причина: грешка в правилото при равенство при пат, а не редът на ходовете

Прогноза: симетрична позиция дава симетрични резултати (проверка 3 – размах < 0.15 ; проверка 5 вижда цикличната коалиционна структура). *Измерено (първо изпълнение):* проверка 3 – размах 0.54, проверка 5 – транзитивно 0.998 – и двете неуспешни – с монотонно **предимство за място 0** в три независими скрипта (победи при изцяло случайна игра [94, 42, 33, 31]; симетричен принос по Шапли [0.593, 0.24, 0.113, 0.053]; една и съща стратегия с фиксиран съюзник постига 0.493 на място 0 срещу 0.243 на място 1). *Съпоставка:* тъй като първо беше заподозрян двигателят (§0.1), диагностиката откри механизма: **~99,5% от случайните игри в този двигател завършват с пат** (всички играчи, останали в играта, са без жетони в ръка след ~28 хода – следствие от опростените правила, които пропускат играч с празна ръка), затова победителят се определя от `_most_chips`, чието **правило при равенство (най-малък индекс)** даваше на място 0 около два пъти повече от справедливия дял (завъртането на началното място не промени нищо; пристрастието беше в правилото при равенство, а не в реда на ходовете). Поправка: **безпристрастно случайно разрешаване на равенството при пат**, подадено през `sls_game.apply(..., rng=...)` в игрите, оценката и обучението, като точният минимакс на крайната фаза остава детерминиран (а `verify_endgame_consistency` премина към детерминирана игра „оптимален срещу оптимален“, за да съвпада с минимаксното дърво). Резултат: размах при симетрия **0.54 → 0.013** (проверка 3 от неуспешна стана успешна), победите при изцяло случайна игра вече са равномерни ([0.251, 0.238, 0.251, 0.260]). Страничен ефект разкри втори артефакт: впечатляващият дял победи ~0.87 на собствения агент е бил *същото* предимство на място 0 (агентът винаги е заемал място 0); реалната стойност е **~0.41** при ниво на случайната игра 0.25. Урокът: в игра, която почти винаги завършва с почти равен резултат, **правилото при равенство е решаващо**, а симетричната *позиция* дава симетричен *изход* едва когато това правило е безпристрастно.

17.10.2 „Коалициите не възникват при пълния мащаб“ се опроверга – теглото на смесване беше неподходящо

Прогноза: приносът по Шапли води до по-високо коалиционно поведение от рядката награда. *Измерено (единична конфигурация):* вярно при бързата проверка ($0.0042 > 0.0013$), но **сриване и обръщане на посоката при пълния мащаб** в изпълнението отпреди поправката – тогава тълкувано като „приносът от заместителя е твърде слаб при по-дълго обучение“. *Съпоставка:* сдвоените сравнения с 5 начални числа опровергават това. α е определящият параметър и **0.3 попада в мъртвата зона**; коалиционният резултат нараства значимо **само при ниско α** (при $\alpha \approx 0$ заместителят с `synergy=0.3` дава $+0.0376 \pm 0.0103$; резултатът е ~4,5 пъти по-висок от този при рядката награда), докато **всяка клет-**

ка с $\alpha \geq 0.3$ при пълния мащаб е отрицателна (членът с рядка награда „победителят взема всичко“ потиска коалиционния сигнал). Две допълнителни изненади: ефектът е **по-голям при пълния мащаб** (размерът на играта и продължителността на обучението не са разделени; обратно на наивното тълкуване „положителен при бързата проверка, нулев при пълния мащаб“, което се дължеше на използването на $\alpha = 0.3$ и на двете нива) и **евтини-ят заместител дава по-силен ефект от скъпия принос чрез симулации** ($+0.038$ срещу $+0.013$). Ефектът е **реален и устойчив в подходящия режим** – макар че, както е реализиран, приносът не носи информация за коалициите (Експеримент 4, заключение) – а решението е „да се даде голяма тежест на коалиционния принос“, а не „да се изчисли по-точен принос“. Методологически това повтаря урока от глави 9-10: **една-единствена конфигурация скрива онова, което разкрива серия експерименти с няколко начални числа.**

17.10.3 Мета-играта на SLS има силна циклична компонента, но (още) не е строго доминирана от нея

Прогноза (от Глава 10): коалиционните игри всеки срещу всеки имат голяма циклична компонента. *Измерено:* това зависи изцяло от **коя популация** се разлага. Базовата популация „**стълба на уменията**“ е преобладаващо транзитивна (циклично съотношение $0.25/0.31$), но **коалиционната популация** повишава цикличното съотношение до $\sim 0.57-0.69$ – голяма нетранзитивна компонента, която силно потвърждава *посоката* на прогнозата (L561), като проверката **остава неуспешна** по строгия праг „ $>50\%$ доминиране“ (квадратът на цикличното съотношение е малко под 0.5). *Съпоставка:* това не е грешка – същият урок от Глава 10, че структурата е свойство на *популацията*. Вероятната причина за остатъка е, че **проекцията върху двойки типове губи коалиционните ефекти между трима и четирима играчи** (L600) – въпрос на моделирането за етапа на затвърждаване, а не грешка в решаване.

17.10.4 Коалиционният резултат се купува със състезателно представяне (истински компромис)

Прогноза (L560): формирането на коалиции е основната цел, а победата – второстепенна. *Измерено:* изцяло коалиционният принос ($\alpha = 0$) сваля дела на победите на собствения агент до ~ 0.29 (близо до нивото на случайната игра 0.25), докато при $\alpha \geq 0.1$ той остава ~ 0.52 . *Съпоставка:* прогнозата се потвърждава и вече е количествена – коалиционният резултат не се получава безплатно; параметърът α е точно този, който разменя състезателно представяне срещу социално поведение.

17.11 Достоверност и достатъчност на извадката

- **Точните опорни точки са надеждни.** Опростените кооперативни игри (ръкавици, мнозинство) възпроизвеждат учебниковите си стойности на Шапли и резултатите за ядрото (стабилност) до четвъртия знак; двигателят на SLS няма **нито едно** несъответствие спрямо точния минимакс на крайната фаза с двама играчи. Тези резултати са детерминирани и напълно възпроизводими.
 - **Резултатът на детектора е точно разпознаване**, а не оценка: предварително зададената коалиция $\{0, 1\}$ се разпознава точно, с ясно отделен резултат (10.0 срещу 0/-1).
 - **Твърденията за обучението се основават на сдвоени сравнения с 5 начални числа**, а не на едно изпълнение. Значимите клетки (**) имат средни разлики над две стандартни грешки; *посоките* (ниско α – положителна, $\alpha \geq 0.3$ при пълния мащаб – отрицателна, заместител $\geq$ симулации, по-голям ефект при пълния мащаб) са надеждните твърдения, а не величините до третия знак. При 5 начални числа средна стойност над 2 SE отговаря приблизително на $p < 0.12$; основните клетки надхвърлят 3 SE.
 - **Верността на двигателя е основната уговорка.** Двигателят е сертифициран спрямо *собствените си* правила, а не спрямо формализацията на De Carufel & Jerade; грешката с място 0 (съпоставката за *грешката в правилото при равенство*) показва, че правилото при равенство наистина променя резултатите, така че тази сверка не е козметична.
 - **Остарелият `scale_results.json`** е резултат отпреди поправката, използван само за да покаже *грешката в правилото при равенство*; той не е източник за нито едно твърдение за пълния мащаб.
-

17.12 Ограничения (подредени по влияние върху заключенията)

1. **Приносът не носи информация за коалициите (Експеримент 4)** – приносът чрез симулации е собствената вероятност за победа на всеки играч (адитивна игра), заместителят – собствената оценка на оценителя за агента минус средната за масата, а коалиционният резултат отчита както подкрепата, така и враждебните взаимодействия. Ефектът при ниско α показва, че плътната награда променя взаимодействията, а не че се научават коалиции; нужни са принос, изграден върху матрицата на помощта и вредата от детектора, и контролен експеримент с плътна награда без коалиционна информация.
2. **Верността на двигателя спрямо правилата от статията (съпоставката за *грешката в правилото при равенство*, *Достоверност и достатъчност на извадката*)** – грешката с място 0 и все още неуспешната проверка за цикличност произтичат от документираните опростявания на двигателя (правило при равенство в `_most_chips`, `capturer-plays-next`, `empty-hand skip`). Сверяването на реда на ходовете и на

правилото при равенство с De Carufel & Jerade е най-ценната следваща стъпка; там се подобряват и коректността, и цикличният сигнал.

3. **Проекцията върху двойки типове (съпоставката циклична, но не доминираща)** – свиването на тензора на печалбите за 4 играчи до сблъсъци по двойки вероятно губи цикличността на коалициите между трима и четирима играчи – основната вероятна причина цикличното съотношение да остава малко под прага на строго доминиране.
4. **α е проектно решение, а не настроено в стойността по подразбиране (съпоставката за мъртвата зона на α)** – кодът запазва $\alpha=0.3$ (мъртвата зона) с честния си пределен резултат; основаната на данните препоръка $\alpha \approx 0.05-0.1$ е оставена за решение от човек (§0.1: докладвай, не нагласявай).
5. **Обобщимост на заместителя (съпоставката за мъртвата зона на α)** – евтиният заместител дава по-силен ефект от приноса чрез симулации в SLS при ниско α ; дали това важи за други игри, не е проверено.
6. **Мащаб на опростен модел навсякъде** – 4-7 жетона, малки мрежи; нищо тук не бива да се екстраполира към големи игри с N играчи.

17.13 Заключение и насоки за бъдещи изследвания

Заключения. Част I проверява механизма: двигателят на SLS съвпада с точния минимум на крайната фаза с двама играчи (0 несъответствия), детекторът на коалиции разпознава точно предварително зададен съюз ($\{0, 1\}$, резултат 10.0), а стойността на Шапли възпроизвежда точно опростените кооперативни игри – *включително празното ядро* на играта на мнозинството, структурният белег на нестабилните коалиции. Част II обучава и анализира коалиции: MAPPO с отчитане на коалициите повишава коалиционния резултат спрямо рядката награда – устойчиво (+0.038, 5 начални числа), но само при **ниско α** и с измерена състезателна цена; както е реализиран обаче, приносът не носи информация за коалициите, така че това още не доказва научени коалиции. Мета-играта на SLS има **силна циклична компонента** за коалиционната популация ($\sim 0.57-0.69$), макар транзитивната да остава малко по-голяма. Две прогнози честно се провалиха и една грешка беше открита: „симетричната“ игра криеше артефакт на правилото при равенство, а „коалициите не възникват при пълния мащаб“ се дължеше на неподходящо тегло на смесване.

Насоки за бъдещи изследвания (всяка е свързана с измерен ефект):

- *Да се сверят редът на ходовете и правилото при равенство в двигателя с De Carufel & Jerade*, след което да се провери отново доминирането при разлагането „пумпал“ – съпоставките за *грешката в правилото при равенство и циклична, но не доминираща* вероятно имат общ корен.

- Да се приеме $\alpha \approx 0.05 - 0.1$ като стойност по подразбиране за обучението на коалиции – данните от серията експерименти (съпоставката за мъртвата зона на α); решението е оставено на човек.
- Да се опита проекция за EGTA, съобразена с 3 или 4 играчи (вместо свиването до 2 типа), за да се види дали цикличността на коалициите преминава строгия праг от >50% (съпоставката циклична, но не доминираща).
- Да се формализира безопасността при N играчи без опора в равновесие на Наш или в ядрото (Принос №2) – празното ядро (Експеримент 3) премахва стабилността, основана на ядрото, а riKL дава поведенческа опорна стратегия без граница на експлоатируемостта; това е отвореният край на дисертацията, който главата очертава, но не запълва.
- Да се изгради принос с коалиционна информация от матрицата на помощта и вредата на детектора и да се сравни с контролна плътна награда без коалиционна информация – истинската поправка на уговорката от Експеримент 4 и изследователска задача за Принос №2.
- Да се генерира отново остарелият `results/scale_results.json`, така че записаният турнир при пълен мащаб да съответства на серията експерименти.

17.14 Възпроизвеждане

От `implementation/step11/implementation/` при активирана `.venv` на проекта:

```
# validation harness (PASS/FAIL against the raw-step targets)
```

```
python validate.py --config smoke
```

```
# single-config tournament -> results/{smoke,scale}_results.json
```

```
python tournament.py --config smoke
```

```
python tournament.py --config scale
```

```
# the 5-seed paired alpha sweep -> results/sweep_{smoke,scale}.json + plots/sweep_coalition
```

```
python sweep.py --tier smoke
```

```
python sweep.py --tier scale
```

```
# chapter figures from the saved results only (no games, no training)
```

```
python plotting.py
```

Началните числа са фиксирани в `config.py` и в `sweep.py`. Резултатите за средата, детектора и опростените кооперативни игри са напълно възпроизводими; посоките на резултатите от обучението са устойчиви при петте начални числа. Всички числа в доклада са взети от `results/{smoke_results.json, sweep_smoke.json, sweep_scale.json}` и от дневника с

измерени и прогнозираны стойности EXECUTION_NOTES.md; файлът scale_results.json отпреди поправката се цитира само като доказателство за грешката с място 0 в правилото при равенство.

18 Глава 12 – Модели на последователности и агенти с голям езиков модел в стратегически среди: Доклад от експеримента

Тестова среда: Кун покер (точно равновесие на Наш и точна експлоатируемост от глава 2), с ограничено пренасяне към Ледюк Холдем като проверка при по-сложна игра.

Сравнявани методи: Nash-CFR · поведенческо клониране · Decision Transformer (DT) · Adversarially Robust Decision Transformer (ARDT) · четири варианта на агент с голям езиков модел (офлайн заглушка без езиков модел, gpt-oss-20b, Qwen2.5-7B-Instruct, OpenThinker3-7B).

Връзка с дисертацията: Принос №1 (поведенческа адаптация), Принос №2 (безопасна експлоатация), Принос №3 (методология за оценяване).

Обхват на резултатите: всички числа са собствени измервания при реални изпълнения (RTX 5090, локални модели с отворени тегла чрез LM Studio 0.4.20, температура 0,7; квантизацията на теглата не е записана). Всяка фигура е генерирана от записан JSON файл с резултати.

Забележка относно артефакта (прочетете веднъж). Два резултата бяха **оттеглени по време на сесията** и се появяват тук само като оттегляния: резултат от обучение в контекста със затворена част от разликата +1.59 (невъзможно – вж. „Съпоставка: прогноза и реалност“, R5) и резултат за Ледюк Холдем от голям езиков модел от -0.83 жетона на раздаване, получен чрез дефектен декодер (R6). Експлоатируемостта на референтното равновесие зависи от бюджета на CFR – 0.0162 жетона при 5 000 итерации (сравнителна таблица), 0.0061 при 50 000 (последващи експерименти); и двете стойности са ≈ 0 . Редът с plain-подкана на OpenThinker3 не е сравним с реда му с CoT (34% от вероятностната му маса отива към токени, които не са действия при обикновена подкана).

Как да четете този доклад. Основният набор от резултати отговаря на петте цели за валидиране от първоначалния план на главата. Последващите експерименти бяха добавени, защото тези пет цели класират методите, без да ги обясняват. Всяко твърдение е свързано с именуван артефакт в `implementation/step12/implementation/`.

18.1 За какво е предназначена тази глава

Два посткласически начина за игра на игра. **Моделирането на последователности** преформулира RL като условно предсказване на последователност: подават се тройки (остатъчна


възвръщаемост, състояние, действие) на модел от типа GPT и се предсказва следващото **действие**, обусловено от желаната бъдеща възвръщаемост – без функция на стойността, без оператор на Белман, без самообучение. **ARDT** добавя минимаксно обуславяне по възвръщаемостта, така че стратегията да бъде устойчива спрямо най-лошия възможен противник, вместо да бъде настроена към този, който случайно се е оказал в данните. **Агентите с голям езиков модел** изцяло пропускат обучението: на езиковия модел се дават правилата на английски и той играе.

Кун покер е споделяната тестова среда, тъй като нейното равновесие на Наш и експлоатируемост могат да бъдат изчислени *точно*, така че всеки метод получава резултат, проверен спрямо точна стойност, а не просто анекдот. Всички методи са приведени към формата на стратегия с 12 информационни множества от глава 2 и се оценяват с една и съща точна метрика.

18.2 Основният резултат от сравнението

Експлоатируемост в жетони (по-ниска стойност означава по-голяма близост до равновесието на Наш); профил SMOKE (бърза проверка), офлайн заглушка за редовете с голям езиков модел.

Метод	Експлоатируемост			стойностен залог(K)
	(жетони)	mbb/h	блъф(J)	
Nash-CFR (референтен)	0,0162	16,2	0,23	0,68
поведенческо клониране	0,0550	55,0	0,20	0,68
ARDT	0,4691	469,1	0,33	0,35
Decision Transformer	0,7992	799,2	1,00	0,64
Голям езиков модел (заглушка) × 3 стила на подкана	0,8333	833,3	1,00	1,00



Фигура 41: Експлоатируемост по методи според точната метрика за Кун: обикновеното поведенческо клониране, включено само като базова линия за сравнение, превъзхожда и двата метода, на които е посветена главата. Редът на големия езиков модел е офлайн заглушката, а не езиков модел.

Обикновеното клониране превъзхожда и двата метода, на които е посветена главата (както и реалните езикови модели по-долу, с 0,25–0,33; редът 0,833 е офлайн заглушката, а не езиков модел). Обикновеното поведенческо клониране – най-простата възможна базова линия – се оказва на 0,04 жетона от равновесието на Наш и превъзхожда DT, обусловен по възвръщаемостта, приблизително 14 пъти. При почти равновесни данни от самообучение поведенческото клониране просто копира почти равновесна стратегия, докато DT трябва да прекара същата стратегия през обуславяне по възвръщаемостта, което (както е показано по-долу) носи предимно късмет. **Обуславянето по възвръщаемостта тук активно унищожава информация.**

18.2.1 Реални модели

Измерено при температура 0,7 с 24 проби на информационно множество – протоколна точка, която има значение; вижте *протокол за измерване* по-долу.

Модел	стил	експл. (жетони)	блъф(J)	стойностен залог(K)	недопустим ход	адапт.
gpt-oss-20b	обикновен	0,2760	0,00	1,00	0%	+0,67
gpt-oss-20b	CoT	0,2500	0,08	1,00	1%	+0,79
gpt-oss-20b	теория на игрите	0,3316	0,46	1,00	1%	+0,25
Qwen2.5-7B	обикновен	0,3125	0,00	1,00	0%	+0,00
Qwen2.5-7B	CoT	0,3183	0,58	1,00	0%	+0,42
Qwen2.5-7B	теория на игрите	0,3032	0,50	1,00	0%	+0,21
OpenThinker3-7B	CoT (n=12)	0,2882	0,33	1,00	16%	+0,92

Модел със 7 млрд. параметъра се представя наравно с gpt-oss-20b – модел със смес от експерти с 21 млрд. параметъра общо, но само 3,6 млрд. активни при всеки токен; при три модела и една опростена игра това не позволява извод за ролята на мащаба. Две грешки са общи – всеки от тестваните реални модели залага за стойност с поп с вероятност 1,00, докато изчисленото с CFR равновесие смесва с 0,68, и при обикновена подкана нито един не блъфира с вале (24 опита на информационно множество). В Кун равновесията на първия играч образуват еднопараметрично семейство (блъф с вале с вероятност $\alpha \in [0, 1/3]$ и залог с поп с вероятност 3α ; Kuhn, 1950), така че поотделно и двете поведения са равновесни; неравновесна е само комбинацията им. Езиковите модели определят правилно *ранга* на ръката, но грешат в *честотите*.


Настройка на разсъжденията в изолирани условия. OpenThinker3-7B е дообучаване за разсъждения (SFT) на *същия* базов модел Qwen2.5-7B, така че редовете с CoT изолират ефекта му: експлоатируемост $0.318 \rightarrow 0.288$, блъф(J) $0.58 \rightarrow 0.33$ (при 0,23 за равновесието на Наш), адаптация $+0.42 \rightarrow +0.92$ – постигнато с **16% недопустими ходове** и **65 пъти повече токени** (~6 500 спрямо ~99 на решение).

18.3 Петте цели за валидиране

validate.py, профил SMOKE: **3 УСПЕХА / 2 НЕУСПЕХА / 0 ПРОПУСНАТИ** (PyTorch и CUDA бяха активни, така че нищо не беше пропуснато).

#	Цел	Измерено	Присъда
1	DT: по-висока остатъчна възвръщаемост → по-ниска експлоатируемост, отколкото при по-ниска	high(+2) = 0.6981 срещу low(-2) = 0.6928 жетона	НЕУСПЕХ
2	Действието на DT варира според картата (научава късмета)	P(bet) в корена за J/Q/K = 1.00/0.03/0.70, разлика 0,97	УСПЕХ
3	ARDT < стандартен DT върху същите смесени данни	ARDT 0.5034 срещу DT 0.7212 жетона	УСПЕХ
4	ARDT в рамките на ~50 mbb/h от равновесието на Наш	0.5034 жетона срещу допустима стойност 0.05	НЕУСПЕХ
5	Големият езиков модел е действително по-експлоатируем от равновесието на Наш	0.8333 > 0.0162; реални модели 0.25–0.33	УСПЕХ

И двата неуспеха са действителни констатации, а не проблеми с настройката, като и двата са разгледани по-долу.




Фигура 42: Експлоатируемост на DT в зависимост от целевата възвръщаемост, по която е обусловен, включително недостижимата стойност +3. Кривата е почти равна в целия реален диапазон с изключение на рязък скок при $R = -1$ – най-честата печалба, която е и печалбата при пас.

Цел №1 не е изпълнена, защото реакцията на DT към целевата възвръщаемост **не е подредена според това колко добра е тази възвръщаемост**. Реакция има – при фина серия от целеви стойности $P(\text{bet})$ в корена с поп е $0.747 \rightarrow 0.020 \rightarrow 0.781$ – но експлоатируемостта рязко скача точно при $R = -1$, където играта на DT се срива: той играе пас в **11 от 12** информационни множества и експлоатируемостта му е 1,98 жетона. $R = -1$ е най-честата възвръщаемост в данните (41,7% от стъпките) и печалбата при пас.

18.4 МАТЕМАТИЧЕСКИ ФЛАГ Б – посоката на експектила в ARDT

Първоначалният план на главата задава $\tau = 0.9$ и го определя като „песимистичен“. Реализацията отбелязва това като **обърнат** и по подразбиране използва 0.1 . **Статията потвърждава отбелязването**: Уравнение (6) в ARDT дефинира експектилната загуба, а Уравнение (7) гласи $\lim_{\alpha \rightarrow 0} g_{\alpha} = \min$, $\lim_{\alpha \rightarrow 1} g_{\alpha} = \max$ и ред 1 в Алгоритъм 1 използва $\alpha = 0.01$. Това беше независимо потвърдено от собствената самопроверка на модула, която възстановява *аналитичните* експектили на изкривена извадка ($\tau=0,1 \rightarrow -1,951$, $\tau=0,9 \rightarrow 0,000$).



Фигура 43: Експлоатируемост на ARDT в зависимост от параметъра τ на експектилната регресия; по дясната ос – средната целева стойност при преетикетирането. Целевата стойност се изменя монотонно, както изисква теорията, но експлоатируемостта е най-ниска от оптимистичната страна.

Емпиричната серия експерименти противоречи на теорията, а най-вероятната причина е показателна. Целевата стойност при преетикетирането се изменя монотонно с τ ($-0.626 \rightarrow +0.854$), което потвърждава, че механизмът е изграден коректно – но експлоатируемостта е **най-ниска при $\tau = 0,9$** , оптимистичната страна. Вероятното обяснение е в Алгоритъм 1: ARDT преетикетира с $\tilde{R}_t = \tilde{Q}_v(s_t, a_t)$, стойност на двойката състояние-действие от две свързани мрежи (уравнения 8–11), докато тази реализация преетикетира със стойност само на състоянието $V(s)$. Цел само по състояние не може да различи „това състояние е лошо“ от „това действие е лошо“ – точно разграничението, на което разчита ARDT – така че преместването на $\tau \rightarrow 0$ подава на DT еднакво отрицателна стойност, което води до избор на линията с *пас* вместо на *устойчивата*. Вариант с $\tilde{Q}(s, a)$ още не е изпълнен, така че това е хипотеза, а не резултат. EXPECTILE_TAU умишлено е оставено на 0,1, теоретично правилната страна; промяната му на 0,9 за получаване на по-добър резултат би представлявала манипулация на изследването.


18.5 Последващи експерименти: какво крие скаларната оценка

Петте цели класират методите, но не дават обяснение за тях. Проведени бяха още шест допълнителни експеримента.

18.5.1 Извличане на точна стратегия, 24 пъти по-евтино

Четенето на разпределението на действията от **логаритмичните вероятности на токени-те** (logprobs; предварително попълване с "Action:", сумиране на вероятностната маса върху повърхностните форми) замества 288 извадкови извиквания с **12**, като дисперсията на извадката е нула. Валидирано чрез извадка при идентични подкани: средната стойност на разликата $|P(\text{bet})|$ е **0,027** спрямо стандартна грешка на биомно разпределение от 0,102 (резултатът е съгласуван). Не е валидно при използване на подкана тип „верига от мисли“ – предварителното попълване противоречи на принципа „разсъждавай първо“, което води до извънразпределителна стратегия – граница, документирана в кода.

18.5.2 Къде всъщност се проявява загубата




Фигура 44: Дял на всяко информационно множество в общата експлоатируемост (Qwen2.5-7B-Instruct, 0,357 жетона) и отклонението му от равновесието на Наш. Двете подредби почти не си съответстват.

Информационно множество	P(залог)	Равновесие на Наш	отклонение	дял от загубата
2p (Дама, опонентът е пасувал)	1,000	0,000	1,000	41,4%
2b (Дама, при залог от опонента)	0,253	0,347	0,094	13,1%
3 (Поп, начална позиция)	1,000	0,561	0,439	0,1%

Това **коригира извод, заявен по-рано в тази глава**. „Всеки голям езиков модел залага за стойност с поп с вероятност 1,00, където равновесието смесва с 0,68“ беше представено като характерен провал – а струва **0,1%** от загубата. Прекомерното залагане на ръка, която никога не е по-слаба, е почти безплатно. Щетата идва от един възел Дама: винаги залагане на Дамата след като опонентът пасува е **41,4%** от общата експлоатируемост, а поправянето само на това едно решение премества модела от 0,357 на 0,209 жетона. **Величината на отклонението и цената са почти некорелирани**, което е точно това, което се скрива зад едно число.

18.5.3 Моделите играят по-добре, отколкото могат да обяснят



Фигура 45: Заявени (при запитване) и реално изиграни честоти на залагане на двата модела по информационни множества, с равновесието на Наш за сравнение, и експлоатируемост на изиграната стратегия на всеки модел и на стратегия, построена от собствените му заявени честоти.

Попитани, на същите информационни множества и с идентичен описателен текст за ситуацията, какъв процент от времето трябва да направят **залог**:

	MAE спрямо равновесието (заявени)	MAE спрямо равновесието (изиграни)	експлоатируемост, ако играе това, което заявява	експлоатируемост при изиграната стратегия
Qwen2.5-7B	0,353	0,246	0,921 жетона	0,357

	MAE спрямо равновесието (заявени)	MAE спрямо равновесието (изиграни)	експлоатируемост, ако играе това, което заявява	експлоатируемост при изиграната стратегия
gpt-oss-20b	0,434	0,328	1,576 жетона	0,392


И двата модела имат **заявени** стратегии, които са значително по-слаби от **изиграните** – съответно 2,6× и 4,0× по-експлоатируеми. Начините на провал се различават (Qwen отговаря „50%“ в 11 от 12 информационни множества; gpt-oss отговаря ~0% в 8 от 12, включително всичките три възела с Поп, където равновесието на Наш залага 100%), което подсилва общото заключение: **извличането на стратегия от голям езиков модел чрез задаване на въпроси води до резултат, по-лош от проучването на неговото поведение.**

18.5.4 Експлоатиращ по подразбиране, но не адаптивен

Сесии от 120 **раздавания** срещу фиксиран архетип, с наблюдаемата история на предишни **раздавания** в контекста. Базовите линии се изчисляват **точно** върху реализираните **раздавания** на самия **агент**, така че нито късметът при раздаването, нито случайността на опонента участват в сравнението.

Опонент	Равновесие на Наш	таван на най-добрия отговор	агент $\pm$ SE	затворена част от разликата	обучение (2-ра – 1-ва половина)
„Винаги пас“	+0,229	+0,981	+0,850 $\pm$ 0,056	+0,83 $\pm$ 0,07	+0,00
„Винаги залог“	+0,319	+0,530	+0,383 $\pm$ 0,169	+0,31 $\pm$ 0,80	-0,52
„Стегнат- пасивен“	+0,088	+0,316	+0,092 $\pm$ 0,122	+0,02 $\pm$ 0,53	-0,15

Средното обучение е **-0,22**, но тази средна стойност се определя от двете клетки с недостатъчна статистическа мощност. В единствената клетка с достатъчна мощност агентът (Qwen2.5-7B-Instruct, последните 20 раздавания в контекста) улавя 83% от наличната експлоатация още от първата половина и не се подобрява (0,824 срещу 0,827) – фиксирано априорно убеждение, благоприятстващо разпуснато-агресивна игра, а не моделиране на противника от историята. Когато обаче типът на противника е описан в подканата, моделите променят честотата на блъфиране с до 0,92 (колоната *адапт.* по-горе): липсва изводът от историята, а не способността да се реагира на описание.



Фигура 46: Печалба срещу всеки противник от набора: Qwen2.5-7B-Instruct печели средно 0,177 жетона на раздаване (равновесието – 0,110) при експлоатируемост 0,357 жетона (равновесието – 0,006); по-голямата част от предимството идва от пасивния и случайния противник.

Съотношението между експлоатация и експлоатируемост го потвърждава: големият езиков модел (Qwen2.5-7B-Instruct) **печели 0,177 жетона на раздаване срещу 0,110 за равновесието на Наш (с 61% повече), но експлоатируемостта му е 0,357 жетона срещу 0,006**, като близо 90% от предимството идва от *пасивния и случайния* противник („Винаги пас“ 0,374 срещу 0,168, „Случаен“ 0,267 срещу 0,119). Срещу двата най-компетентни архетипа той се представя **по-зле** от равновесието. Това е измереният компромис между безопасност и експлоатация, с който се занимава Принос №2.

18.5.5 Директен сблъсък

20 000 раздавания на двойка, с редуване на позициите. Равновесната стратегия срещу себе си дава точно 0,0000 и не губи от никого, което валидира турнира.


Играч по ред	срещу равновесието	срещу gpt-oss	срещу OpenThinker3	срещу Qwen	средна стойност	експлоатируемост
Nash-CFR	0,0000	+0,1061	+0,1245	+0,0806	+0,104	0,0061
Qwen2.5-7B	-0,0806	+0,1618	+0,1817	0,0000	+0,088	0,3571

Играч по ред	срещу равновесието	срещу gpt-oss	срещу OpenThinker3Qwen	срещу средна стойност	експлоатируемост	
gpt-oss-20b	-0,1061	0,0000	+0,1535	-0,1618	-0,038	0,3917
OpenThinker3-0,1245 7B		-0,1535	0,0000	-0,1817	-0,153	0,8940

Qwen2.5-7B побеждава gpt-oss-20b (3,6 млрд. активни параметъра), а подреждането е строго транзитивно и напълно съответства на подреждането по експлоатируемост – в тази популация експлоатируемостта предсказва резултатите от директен сблъсък.

18.6 Ледюк Холдем – проверка на сложността

Ограничено пренасяне (кодировчик, набор от данни, обучение на DT и серия експерименти с обуславяне по възвръщаемостта, оценявани в жетони на раздаване срещу почти равновесен противник) плюс предварителна проверка на голям езиков модел. Ледюк разполага с **936** информационни множества спрямо 12 при Кун, **15** различни стойности на печалба спрямо 4, два рунда на залагане и една обща карта.




Фигура 47: Резултат на DT в Ледюк в зависимост от целевата възвръщаемост, по която е обусловен, със стандартни грешки. При най-честата възвръщаемост няма спад и няма монотонна тенденция, но остават два необяснени спада – при 0 и при -5.

Вдлъбнатината от Кун не се възпроизвежда – при най-честата възвръщаемост DT е на 0,2

SE от средната стойност при останалите цели. **Обулавянето обаче пак не насочва:** Pearson $r = +0.062$, Spearman $\rho = -0.054$. То не е без ефект (разликата между целите е 0,60 жетона на раздаване, многократно по-голяма от стандартната грешка на точка), а просто не е подредено според качеството на целта. Недостижимата цел се насища – единственото предсказание от Кун, което се възпроизвежда чисто. Два спада остават необяснени: при 0 (-0.80 ± 0.07 ; втората по честота възвръщаемост, 17,4% от стъпките) и при -5 (-0.88 ± 0.06), и двата по-дълбоки от точката при най-честата възвръщаемост (-0.45 ± 0.02).

Компетентността на големия езиков модел рязко намалява. В Ледюк големият езиков модел постига -0.463 ± 0.132 **жетона на раздаване** срещу почти равновесен противник – статистически неразлично от -0.454 на DT; срещу експлоатируемия зоопарк той постига -0.071 , докато равновесието печели $+0.582$, като побеждава само двата пасивни типа противници и губи дори от „Случаен“. Само **31–54%** от 936-те информационни множества някога са били достигнати, поради което вероятността за достигане прави пълното изброяване ненужно.



Фигура 48: Склонност към недопустими действия по категории и по ситуации. Единствена категория обяснява цялата маса и тя е съсредоточена в една ситуация.

Склонността му към недопустими действия (23,4% от вероятностната маса) е **едно систематично погрешно схващане**, а не обща обърканост: FOLD_WHEN_FREE (отказ при безплатен чек) формира **100%** от масата на недопустимите действия, докато RAISE_AT_CAP е 0.0000 , а отговорите, които не са действие (грешка във формата) – 0.0001 . Тя е съсредоточена във 2. рунд, когато няма залог за плащане (0.5138 , до $0,99$), при слаби ръце без чифт и висока

обща карта – моделът бърка „ръката ми е слаба“ с „трябва да се откажа“, забравяйки, че чекът е безплатен. Почти нулевият дял в 1. рунд показва, че това се **задейства от състава на общите карти, а не от пропуск в правилата**, което го прави откритие за подканата, а не таван на възможностите.

18.7 Съпоставка: прогноза и реалност

Предварителните прогнози се съхраняват; към тях се добавя и това, което действително е настъпило (работен процес §0.1).

R1 – Обуславянето по възвръщаемостта никога не насочва, а предложеното обяснение беше наполовина вярно. Обяснението за Кун (големината кодира залога, знакът е късмет с картите, така че модалната печалба при пас избира „линията на пас“) предсказва, че ефектът трябва да отслабне при по-богат **набор печалби**. Ледюк премахна вдлъбнатината точно както беше предсказано, **но насочването не се появи вместо това**. Механизмът обяснява *вдлъбнатината*, а не *провала*, който оцелява при 15 стойности на печалбата, два рунда и **обща карта**.

R2 – Математическият флаг В беше правилен относно τ и подцени структурната разлика. Потвърдено е спрямо ур. 6–7; най-вероятно реалната разлика е между $V(s)$ и $Q(s, a)$ от статията (Алгоритъм 1) – още непроверено. Цел №4 остава червена.

R3 – Поведенческото клониране печели, а „провалът“ с поп беше почти безплатен. Вижте *Основният резултат от сравнението* и *Къде всъщност се проявява загубата*.

R4 – Първоначалната хипотеза беше опровергана. „Знае честотата, но не може да я възпроизведе при избора на действие“ предсказваше заявени $\approx$ равновесието и изиграни $\neq$ равновесието. Измерено: заявените са *по-лоши* от изиграните и при двата модела.

R5 – Резултатът от обучение в контекста +1.59 беше оттеглен. Затворена част от разликата над 1,0 означава да се победи точният най-добър отговор, което е невъзможно; таванът беше проверен ръчно ($K \rightarrow +2$, $Q \rightarrow 0$, $J \rightarrow -1 \Rightarrow +0.333$, съответстващо на изчисленото +0.3387), като така се установи, че стойността на агента е артефакт. Причина: сесия от 60 раздавания беше сравнена с базови линии, взети от *различни* раздавания, при което стандартното отклонение в Кун от ~1,2 на раздаване дава стандартна грешка, съпоставима с целия диапазон равновесие $\rightarrow$ най-добър отговор. При използване на точни двойки базови линии заключението **се обръща** към липса на обучение.

R6 – Резултатът от голям езиков модел за Ледюк от -0.83 беше оттеглен. Токенизаторът разделя RAISE на " RA" и FOLD на " F", докато CALL/CHECK остават цели, поради което съвпадението по цяла дума елиминира 70% от вероятностната маса и *обърна* стратегията – модел, който повишава с $p=0,953$, беше оценен като плащач ~97% от времето. Коригирано

със съвпадение, чувствително към представката, до -0.463 ± 0.132 .

R7 – Смесването на голям езиков модел не може да бъде измерено при температура 0. При тази стойност реалният модел играе *чиста* стратегия, така че всяка измерена честота дегенерира до 0 или 1: блъф(J) отчете 0,75, 0,25 и 1,00 в три изпълнения на една и съща конфигурация, а увеличаването на броя проби от 4 на 24 не помогна. При температура 0,7 честотите стават междинни, а делът на недопустимите ходове става ненулев.

18.8 Достоверност и достатъчност на извадката

Четири резултата в тази глава изглеждаха като открития и се оказаха измервателни артефакти (R5, R6, възвръщаемост от позиция 0, която беше на 1,7 стандартни грешки от шума от извадката, както и тенденция в Ледюк, която изчезна при 20 пъти повече раздавания). Всеки от тях беше засечен чрез евтина проверка за съгласуваност спрямо нещо, което може да се изчисли точно – точна стойност на играта, точен таван на най-добрия отговор, стандартна грешка или диагностика за запазване на вероятностната маса.

Поотделно, `plotting.py` първоначално съдържаше **само** самопроверка, която изчертаваше твърдо кодирани числа в директорията с резултати и представляваше единствения път за създаване на фигури в тази глава; буквалното следване на наръчника за изпълнение би довело до записване на фалшифицирана фигура. Той беше заменен с рендър, който чете **изключително** от записан JSON, което е начинът, по който всяка фигура в този доклад беше създадена.

Достатъчност на извадката: клетките за директен сблъсък използват 20 000 раздавания; мацовете срещу зоопарка – 4 000; серията в Ледюк – 4 000 на цел. Клетките за моделиране на противника „Винаги залог“ и „Стегнат-пасивен“ са с **недостатъчна статистическа мощност** ($SE \pm 0,80$ и $\pm 0,53$, тъй като диапазонът им от равновесието до най-добрия отговор е тесен), а убедителна е само клетката за „Винаги пас“.

Вариация на обучението при невронните модели. Наборът от данни, CFR и офлайн заглушката използват фиксирани начални числа и се възпроизвеждат точно, но всяко извикване на сравнителната таблица **преобучава** невронните модели, поради което DT/BC/ARDT показват дисперсия от изпълнение до изпълнение. Измерено при две изпълнения на една и съща конфигурация, експлоатируемостта на DT се измести от **0,671** → **0,799** (колебание от ~19%), докато двата детерминистични реда (Nash-CFR 0,0162, заглушката на езиковия модел 0,8333) се възпроизведоха с точност до четири знака след десетичната запетая. Числата, цитирани тук, са тези от записания артефакт `results/comparison_SMOKE_stub.json`; качествената подредба остава непроменена, но **тези редове не бива да се сравняват с точност до три знака след десетичната запетая между различни изпълнения.**

18.9 Ограничения (подредени според значимостта им за заключенията)

1. **Всички заключения за голям езиков модел в Ледюк се основават на един модел, един стил на подкана и 600 раздавания** ($SE \pm 0,13$). Достатъчно е да се каже, че предимството на Кун не се пренася; недостатъчно е за класиране на модели в Ледюк.
2. **ARDT е документирано опростяване на публикувания метод** – едностранен, със стойност само на състоянието $V(s)$ вместо свързаната стойност на двойката състояние-действие $\tilde{Q}(s, a)$. Целите #3–4 тестват заместителя, а не ARDT.
3. **Няма точна експлоатируемост за Ледюк**. Метриката за Ледюк е в глава 3, чийто пакет също се нарича cfr и влиза в конфликт с пакета от глава 2; вместо нея са използвани жетони на раздаване срещу почти равновесен противник.
4. **Резултатите на Кун са SMOKE-профил** (5 000 траектории, 5 000 итерации на CFR, малки мрежи). Качествената подредба е стабилна, но абсолютните стойности биха се изместили при по-голям мащаб.
5. **Извличането на логаритмична вероятност е валидирано само за обикновени подкани**; цифрите за CoT са получени чрез извадка.
6. **OpenThinker3 беше измерен само в реда на CoT** ($n=12$); пълното изпълнение е ~9 часа при ~38 s на решение.
7. **Двете недостатъчно мощни клетки на B5** (по-горе) – затягането им изисква приблизително 30 пъти повече раздавания.

18.10 Заключения и насоки за бъдещи изследвания

Заключения. Обуславянето по възвръщаемостта не насочва Decision Transformer в покер в нито една от двете игри, и причината не е размерът на набора печалби: в игра с нулева сума с непълна информация реализираната възвръщаемост се доминира от фактори, които агентът не контролира. Обикновеното поведенческо клониране превъзхожда и двата метода, на които тази глава е кръстена. Езиковите модели определят правилно класирането на ръка, но грешно честотите на смесване; не могат да вербализират стратегията, която всъщност прилагат, не извеждат противника от историята в контекста (макар да реагират, когато типът му е съобщен) и губят привидната си компетентност при добавяне на един рунд на залагане към играта.

Насоки за бъдещи изследвания (всяка от тях е свързана с измерен ефект):

- *Заменете преетикетирането само на състояние в ARDT с оценителите на състояние-действие, предложени в статията (уравнения 8–11 плюс загривката в Алгоритъм 1). Това е най-вероятната причина за слабото представяне на заместителя (още непроверена). При случайни ходове като раздаването минимаксната цел на ARDT е точна само при детерминирани преходи (Tang, Cheng & Kumar, 2025, arXiv:2510.11877, предлагат CART), така че при записани покер партии и това трябва да се отчете.*
- *Разглеждат DT, обусловен по възвръщаемостта, като неподходящ инструмент за офлайн покер – стойността на преетикетирането в ARDT е, че заменя целева стойност, която агентът не контролира, с такава, която зависи главно от собствените му действия.*
- *Представяйте разложения по решения, вместо скаларна величина, когато се оценяват агенти; големината на отклонението не е заместител на цената.*
- *Проучвайте поведението, вместо да задавате въпроси във всеки компонент за моделиране на противник чрез езиков модел.*
- *Тествайте едноредовото поправяне на подканата в Ледюк („можете да направите чек безплатно“), преди да правите каквито и да било заключения относно възможностите на големите езикови модели при покер с няколко рунда на залагане.*

18.11 Възпроизвеждане

from the repository root, with the venv active

`cd implementation/step12/implementation`

```
python validate.py                                # 5 validation targets -> 3 PASS / 2 FAIL / 0 SKI
python comparison_table.py                        # headline table -> results/comparison_SMOKE_<bac
python tau_sweep.py --seeds 3                     # MATH FLAG B, empirical half
python exploitability_decomposition.py --style plain --method logprob
python frequency_elicitation.py --repeats 3 --temp 0.7 --exec-style plain
python opponent_modeling.py --hands 120 --style cot
python exploitation_vs_zoo.py --style plain --hands 4000
python llm_head_to_head.py --tournament --hands 20000
python leduc_stage0.py                            # Leduc DT return-conditioning sweep
python leduc_llm.py --hands 600                   # Leduc LLM scouting
python leduc_illegal_taxonomy.py                  # illegal-action breakdown
python plotting.py                                # all 12 figures, from committed JSON only
```

Реалните изпълнения на модела изискват локален сървър, съвместим с OpenAI. Протоколът, който е от значение: **заредете точно един модел** (`lms unload --all`, след това `lms load <model>`), рестартирайте сървъра след всяко прекратено изпълнение (осиротелите връзки

заемат всички паралелни слотове и по-късните изпълнения блокират безкрайно) и задайте STEP12_LLM_TEMP=0.7 – при температура 0 измерените честоти са безсмислени (R7).

Детерминираност: наборите от данни, CFR и инициализацията на мрежите използват фиксирани начални числа; офлайн заглушката на езиковия модел е детерминистична, така че таблицата SMOKE и валидационната среда се възпроизвеждат точно без GPU или мрежа. Реалните резултати от модела **не** са битово възпроизводими (маршрутизацията в MoE при пакетно обслужване), поради което оценките на честотите използват 24 проби, а температурният протокол е посочен изрично.