

Доклади по стъпки

Изследване на възможностите за приложение на изкуствения интелект в
компютърни игри

Александър Андреев

Юли 2026

Доклади по стъпки

Съдържание

1	Стъпка 01 - Основи на обучението с подкрепление: Доклад за реализацията	8
1.1	Съдържание	8
1.2	Преглед	9
1.3	DQN - Дълбока Q-мрежа	9
	Архитектура	9
	Ключови проектни решения	10
	Итерации на хиперпараметри	10
	Крайни резултати	11
1.4	PPO - Оптимизация на проксималната стратегия	11
	Архитектура	11
	Ключови решения в проектирането	12
	Итерации на хиперпараметрите	12
	Финални резултати	13
1.5	Сравнение с базовите решения на SB3	13
	4.1 DQN върху cartPole-v1	13
	4.2 PPO на lunarLander-v3	14
	4.3 Обобщение на постигнатата максимална производителност	15
1.6	Ключови изводи	16
	5.1 DQN	16
	5.2 PPO	16
	5.3 Реализация от нулата срещу SB3	17
1.7	Приложение - Възпроизвеждане	17
	Стъпка 02 - Основи на теорията на игрите и CFR: Доклад за реализацията	19
1.1	1. Какво беше разработено	19
1.2	2. Ключови резултати и визуализации	19
	Сходимост на стойността на играта	20

Сходимост на експлоатируемостта	20
Анализ на стратегиите	20
1 Стъпка 03 - Варианти на CFR и методи на Монте Карло: Доклад за реализацията ..	23
1.1 1. Разработени елементи	23
1.2 2. Игрови двигател за Ледюк покер	24
1.3 3. Реализации на алгоритми	24
3.1 Обикновен вариант на CFR	24
3.2 CFR+	24
3.3 Външно вземане на проби в MCCFR	25
3.4 MCCFR Outcome Sampling	25
3.5 Оценител на експлоатируемостта	25
1.4 4. Фаза на изследване (референция OpenSpiel)	26
4.1 Кун покер - 5000 итерации	26
4.2 Ледюк покер - 5,000 итерации	26
1.5 5. Еталонен тест с ограничение във времето - 180 секунди реално време	28
1.6 6. Кръстосана проверка спрямо OpenSpiel	29
1.7 7. Възпроизвеждане	29
1 Стъпка 04 - Абстракция на играта и мащабиране на игри с непълна информация: Доклад за внедряването	31
1.1 1. Какво беше разработено	31
1.2 1. Какво беше разработено	31
1.3 2. Модули за абстракция	32
2.1 Беззагубен изоморфизъм на боите	32
2.2 Загубено групиране на карти	32
2.3 Абстракция на действията и превод	33
2.4 Разширена и комбинирана абстракция	33
1.4 3. Еталонен тест на CFR+ с ограничено време	33
3.1 Ледюк с фиксиран лимит	33
3.2 Mini-NL Ледюк	34
3.3 Extended Ледюк	34
1.5 4. Парето граница	36
1.6 5. Кръстосана проверка	37
1.7 6. Ключови изводи	37
1.8 7. Възпроизвеждане	38

1	Стъпка 07 - Моделиране на противника в игри с непълна информация	39
2	ЧАСТ I - ИЗСЛЕДВАНЕ НА КУН ПОКЕР	39
2.1	1. Предмет на изследването в тази стъпка	39
1.1	Типовият зоопарк на противниците	40
2.2	2. Експеримент 1 - Поведенчески отпечатъци	40
2.3	3. Експеримент 2 - Възможност за експлоатация (защо си струва усилието)	42
2.4	4. Експеримент 3 - Детектор на тип по Байес (ядрото на цикъла)	42
4.1	Противници от множеството - бързи, точни и стабилни	43
4.2	Противник извън набора - „няма честно място“	43
4.3	Колко устойчива е тази сходимост? - стрес тест от 500 раздавания	45
2.5	5. Експеримент 4 - Възстановяване на сместа чрез модел на смес с ЕМ	46
2.6	6. Какво установява Част I	49
3	ЧАСТ II - ПЪЛНА СИСТЕМНА ОЦЕНКА НА „КУН“ И „ЛЕДЮК“	49
3.1	7. Какво тестваме и как	49
3.2	8. Откриване - кой е опонентът?	51
3.3	9. Експлоатация - каква печалба носи моделирането?	52
3.4	10. Нестационарност - адаптиране към смяна по време на игра	54
3.5	11. Достатъчни ли са размерите на извадките?	56
3.6	12. Ограничения	57
3.7	13. Закljučения и насоки за бъдещи изследвания	58
3.8	14. Възпроизвеждане	59
1	Стъпка 08 - Безопасна експлоатация в игри с непълна информация	61
2	ЧАСТ I - КОМПРОМИСЪТ, ВИДИМ ВЪРХУ КУН	61
2.1	1. За какво става дума в тази стъпка	61
2.2	2. Експеримент 1 - наивната граница на най-добрия отговор на Наш	63
2.3	3. Експеримент 2 - наивното обхождане на бюджета на RNR (и един флаг)	64
2.4	4. Какво установява Първа част	65
3	ЧАСТ II - ПЪЛНА ОЦЕНКА НА СИСТЕМАТА ВЪРХУ КУН И ЛЕДЮК	66
3.1	5. Какво тестваме и как	66
3.2	6. Подробната таблица метод × опонент (Кун)	67
3.3	7. Ефективната граница - и изненадващият обрат	70
	Предсказване ↔ реалност: Canonical RNR е изненадващ обрат, а не гладка граница	70
3.4	8. Безопасен спрямо прайм / адаптация и измереният ϵ -бюджет	72

3.5	9. Обучаващата атака - защо осъществената печалба е грешната гледна точка	72
	Прогноза $\leftrightarrow$ реалност: разкриващ противник в наш равновесие се оказва недостатъчно наказателен спрямо full_br	73
3.6	10. Ледюк - основният извод: глобалната безопасна експлоатация не сходява, но SES сходява	74
	Предсказване $\leftrightarrow$ реалност: глобалната безопасност не се мащабира до Ледюк, както е предвидено	76
	Втвърдяване на решавача по време на изпълненията	77
3.7	11. Достоверни ли са резултатите?	77
3.8	12. Ограничения	78
3.9	13. Заключение и насоки за бъдещи изследвания	78
3.10	14. Възпроизвеждане	79
1	Стъпка 9 - Многоагентно обучение с подкрепление: Доклад за експериментите	81
2	ЧАСТ I - ЗАЩО МНОГОАГЕНТНОТО ОБУЧЕНИЕ Е ТРУДНО	81
2.1	1. Какво разглеждаме тук	81
	2. Експеримент 1 - независими обучаващи агенти в четирите матрични игри	82
2.3	3. Експеримент 2 - орбитата на нестационарност (игра „хвърляне на монета“ спрямо Дилемата на затворника)	83
2.4	4. Експеримент 3 - самообучение на Кун: средна спрямо последна итерация	84
3	ЧАСТ II - СТРУКТУРНИТЕ РЕШЕНИЯ	85
3.1	5. Експеримент 4 - PSRO при различни семейства игри	85
3.2	6. Експеримент 5 - CTDE: дисперсия на оценителя и изкачваща се игра	86
3.3	7. Експеримент 6 - научена комуникация (commNet)	87
	8. Експеримент 7 - LOLA в дилемата на затворника (Iterated Prisoner's Dilemma)	87
3.5	9. Съгласуване на прогноза и реалност	88
3.6	10. Достоверност и достатъчност на извадката	89
3.7	11. Ограничения (подредени според влиянието им върху изводите)	90
3.8	12. Заключение и насоки за бъдещи изследвания	90
3.9	13. Възпроизвеждане на резултатите	91
1	Стъпка 10 - Обучение, базирано на популации и еволюционна теория на игрите: Експериментален доклад	92
2	ЧАСТ I - ЕВОЛЮЦИОННА ТЕОРИЯ НА ИГРИТЕ КАТО ДИАГНОСТИЧЕН ОБЕКТИВ	93
2.1	1. Какво разглежда тази стъпка	93
2.2	2. Експеримент 1 - репликаторна динамика върху четири матрични игри	93
2.3	3. Експеримент 2 - пумпалът: транзитивна спрямо циклична структура	95

3	ЧАСТ II - ЛИГАТА С РВТ	97
3.1	4. Какво представлява лигата и как се оценява	97
3.2	5. Експеримент 3 - динамика на обучението в лига	98
3.3	6. Експеримент 4 - EGTA, мета-Наш и разнообразие	99
3.4	7. Експеримент 5 - сравнение между лига, PSRO, самообучение и cFR-Nash	101
3.5	8. Съгласуване на прогноза <-> реалност	103
3.6	9. Достоверност и достатъчност на извадката	104
3.7	10. Ограничения (подредени според степента на влияние върху заключенията)	105
3.8	11. Заключения и насоки за бъдещи изследвания	105
3.9	12. Възпроизвеждане на резултатите	106
1	Стъпка 11 - Експериментален доклад за динамичното формиране на коалиции в състезателни игри всеки срещу всеки (Со Лонг Съкър)	108
1.1	Част I - МЕХАНИЗМЪТ И НЕГОВИТЕ ТОЧНИ АНКЕРИ	109
1.2	За какво става дума в тази стъпка	109
	Експеримент 1 - sLS двигател срещу точната крайна игра между двама играчи	109
1.4	Експеримент 2 - детекторът на коалиции срещу засаден съюз	110
1.5	Експеримент 3 - Стойност на Шейпли: точни кооперативни игри, след това позиции в SLS	114
1.6	Част II - ИЗУЧАВАНЕ НА КОАЛИЦИИТЕ И АНАЛИЗ НА ПОПУЛАЦИЯТА	116
1.7	Експеримент 4 - Coalition-Aware MAPPO и обхождане на алфа	116
1.8	Експеримент 5 - EGTA и пумпалът: цикличен ли е SLS?	119
1.9	Обобщение на валидирането	121
1.10	Съгласуване на прогнозата с реалността	122
	Двата червени ПРОВАЛЪ имаха една и съща първопричина: грешка при развръзка на равни резултати при задънена улица, а не редът на първия играч	122
	„Коалициите не възникват в голям мащаб“ беше опровергано - неправилно зададено тегло на смесване	122
	Мета-играта на SLS е силно циклична, но не (още) стриктно циклично доминираща	123
	Социалното поведение се купува с цената на състезателното представяне (истински компромис)	123
1.11	Достоверност и достатъчност на извадката	124
1.12	Ограничения (подредени според въздействието им върху заключенията)	124
1.13	Заключения и насоки за бъдещи изследвания	125
1.14	Възпроизвеждане	126
	Стъпка 12 - Последователни модели и агенти с голям езиков модел в стратегически ситуации: Доклад от експеримента	127
1.1	За какво е предназначена тази стъпка	127
1.2	Основният резултат от сравнението	128

Реални модели.....	129
1.3 Петте цели за валидиране	130
1.4 МАТЕМАТИЧЕСКИ ФЛАГ Б - посоката на експектиля в абстрактния дървовиден модел на решенията	132
1.5 Последващи експерименти: какво крие скаларната оценка.....	133
Извличане на точна стратегия, 24 пъти по-евтино	133
Къде всъщност се проявява загубата	133
Моделите играят по-добре, отколкото могат да обяснят	134
Експлоатативен по подразбиране, а не адаптивен	135
Директен сблъсък	136
1.6 Ледюк Холдем - проверка на сложността	137
1.7 Съгласуване между прогноза и реалност	139
1.8 Достоверност и достатъчност на извадката	140
1.9 Ограничения (подредени според значимостта им за заключенията)	141
1.10 Заключения и насоки за бъдещи изследвания.....	141
1.11 Възпроизвеждане	142

1 Стъпка 01 - Основи на обучението с подкрепление: Доклад за реализацията

Среда: април 2026 г.

Алгоритми: DQN (cartPole-v1), PPO (lunarLander-v3)

Цели: DQN ≥ 475 , PPO ≥ 200 (средна стойност от 100 епизода)

Статус: И двете цели са постигнати ✓

1.1 Съдържание

- Преглед
 - DQN - Дълбока Q-мрежа
 - Архитектура
 - Ключови проектни решения
 - Итерации на хиперпараметри
 - Окончателни резултати
 - PPO - оптимизация на проксималната стратегия
 - Архитектура
 - Ключови проектни решения
 - Итерации на хиперпараметри
 - Окончателни резултати
 - Сравнение с базовите линии на SB3
 - Ключови изводи
-

1.2 Преглед

Стъпка 01 реализира два фундаментални RL алгоритъма от нулата с **pyTorch**, като включва подробни коментари в кода, обясняващи *защо* зад всяко проектно решение. И двата алгоритъма използват еднакви набори от **хиперпараметри** при сравнение с еквивалентите от **stable-Baselines3** (SB3).

Структура на изходния код:

```
implementation/step01/
├─ dqn/
│   ├── replay_buffer.py    # Circular buffer, random batch sampling
│   ├── q_network.py        # MLP Q-function
│   ├── agent.py            # DQNAgent: select/store/train/sync/save
│   └─ train.py             # Training loop, best-model checkpointing, early stop
├─ ppo/
│   ├── networks.py         # PolicyNetwork (actor), ValueNetwork (critic)
│   ├── gae.py              # Generalized Advantage Estimation (reverse sweep)
│   ├── agent.py            # PPOAgent: rollout → GAE → clipped SGD
│   └─ train.py             # Training loop, rollout collection, logging
├─ compare_sb3.py           # Comparison script - reads TB logs, trains SB3
├─ config.py                # DQN_CONFIG, PPO_CONFIG
├─ utils/
│   └─ logger.py            # TensorBoard SummaryWriter wrapper
```

1.3 DQN - Дълбока Q-мрежа

1.3.1 Архитектура

Среда: CartPole-v1 - четиримерен непрекъснат вектор на наблюдение, два вида дискретни действия и максимум от 500 стъпки в един епизод.

q-мрежа: Два скрити слоя с ReLU активации и без изходна активация (тъй като q-стойностите могат да приемат всяка реална стойност). Размерът ѝ е [obs_dim=4 → 128 → 128 → 2].

Буфер за възпроизвеждане: Предварително заделени numpy масиви с кръгов курсор за запис, които съхраняват кортежи от вида (състояние, действие, награда, следващо състояние, приключено). Случайната извадка от минипакет прекъсва времевата корелация между последователните преходи.

Целева мрежа: Замразено копие на q-мрежата, което се синхронизира на всеки `target_update_freq` епизода. Предотвратява нестабилния цикъл на обратна връзка, при който целта се изменя със същата скорост като прогнозите, които се обучават.

1.3.2 Ключови проектни решения

Решение	Избор	Обосновка
График на изследване	Епизодно базирано ϵ -затихване ($\epsilon \times 0.995$ на епизод)	По-предвидимо е от базираното на стъпка, когато дължината на епизода варира
Минимален епсилон	$\epsilon_{\min} = 0.001$	Избягва смъртоносни случайни действия след сходимост; по-нисък от стандартния 0.05 на SB3
Синхронизация на целта	На всеки 5 епизода	Балансира стабилност и скорост; твърде рядка (на всеки 10) водеше до по-бавни плата
Размер на мрежата	[128, 128]	С мрежа [64, 64] се достигаше плато около 300 средна награда; по-голяма мрежа се учеше по-бързо
Размер на буфера	50,000	По-малък (10K) водеше до преобучение към скорошен опит

1.3.3 Итерации на хиперпараметри

Окончателната **конфигурация** беше достигната след три кръга от настройки:

Run 1 - Базова линия (500 епизода)

- Конфигурация: `buffer=10K`, `hidden=[64,64]`, `episodes=500`, `target_freq=10`, `ε_min=0.01`
- Резултат: Крайна средна стойност 225; не се премина целта от 475
- Проблем: Малък буфер и мрежа; редки актуализации на целта

Run 2 - Първа настройка (1000 епизода)

- Конфигурация: `buffer=50K`, `hidden=[128,128]`, `episodes=1000`, `target_freq=5`, `ε_min=0.01`

- Резултат: Постигната пикова средна стойност **479.1** на епизод 810, но в края тя спадна до 302.6
- Проблем: $\epsilon_{\min}=0.01$ означава постоянно 1% случайни действия - достатъчно, за да се прекратят дългите епизоди
- Необходима корекция: Намаляване на стойността на $\epsilon_{\min}$ + добавяне на най-добър модел с контролна точка

Run 3 - Финална (1500 епизода, добавено ранно спиране)

- Конфигурация: същата + $\epsilon_{\min}=0.001$, episodes=1500
- Добавено запазване на най-добър модел и ранно спиране (запазва при първо достигане на целта от 475 и прекратява обучението)
- Резултат: **Решена в епизод 1011**, Средна стойност(100) = **477.5** ✓

1.3.4 Крайни резултати

Метрика	Стойност
Решена в епизод	1011
Финална средна награда (100 еп.)	477.5
Цел	475.0
Общо обучени епизоди	1011 (ранно спиране)
Най-добър модел	models/dqn_cartpole_best.pt

1.4 PPO - Оптимизация на проксималната стратегия

1.4.1 Архитектура

Среда: LunarLander-v3 - 8-измерно непрекъснато наблюдение и 4 дискретни действия. Успешното кацане носи +200 точки, катастрофата води до -100, а разходът на гориво се санкционира.

Актьор-оценител (отделни мрежи): - **PolicyNetwork:** [obs=8 → 128 → 128 → 4] с логити, преобразувани в Categorical разпределение - **ValueNetwork:** [obs=8 → 128 → 128 → 1] с изход като неограничена скаларна величина

Отделните мрежи предотвратяват смущението в градиента между стратегията и стойностната цел. Един Adam optimizer обучава и двете чрез комбинираната загуба.

Generalized Advantage Estimation ($\lambda=0.95$): Изчислява се чрез обратно обхождане на буфера за разгръщане. Маската (1 – done) нулира стойностите от буутстрапинга в границите между епизодите, като по този начин коректно обработва разгръщанията, които преминават през множество епизоди.

Изрязана сурогатна цел:

$$L^{CLIP} = \mathbb{E} \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]$$

където $r_t(\theta) = \pi_\theta(a|s) / \pi_{old}(a|s)$ и $\epsilon = 0.2$.

1.4.2 Ключови решения в проектирането

Решение	Избор	Обосновка
Нормализиране на предимството	Средна стойност нула, единично стандартно отклонение за всяко разгръщане	Стабилизира големината на градиента при различни мащаби на наградата
Бонус за ентропия	coef = 0.01	Предотвратява преждевременен колапс на стратегията; насърчава изследването
Отсичане на градиента	max_norm = 0.5	Избягва експлодиращ градиент по време на ранното обучение
Дължина на разгръщане	n_steps = 2048	Достатъчно дълго за многостъпково разпределяне на заслугата при кацания
Mini-batch SGD	10 епохи, партида=64	Стандартен PPO; всяко разгръщане се използва повторно 10 пъти преди изхвърляне

1.4.3 Итерации на хиперпараметрите

Изпълнение 1 - Базова линия (300K стъпки, hidden=[64,64])

- Резултат: Постигната пикова средна стойност **179.9**, без преминаване на целта от 200
- Проблем: Малката мрежа е недообучена за 8-измерното наблюдение на lunarLander

- Също така: 300K стъпки са едва достатъчни за пълна сходимост

Изпълнение 2 - Финално (500K стъпки, hidden=[128,128])

- Размерът на мрежата е удвоен; обучителният бюджет е увеличен с 67%
- Резултат: **Решено на 264K стъпки** (задействано е ранно спиране), средната стойност за 100 епизода = **202.2** ✓
- Забележително: проблемът е решен 236K стъпки *преди* изчерпването на обучителния бюджет

1.4.4 Финални резултати

Метрика	Стойност
Решено на стъпка	264,192
Финална средна награда (100 епизода)	202.2
Цел	200.0
Общо обучени стъпки	264,192 (ранно спиране)
Най-добър модел	models/ppo_lunarlander_best.pt

1.5 Сравнение с базовите решения на SB3


SB3 беше обучен с еднакви основни хиперпараметри (скорост на обучение, γ , размер на мрежата, диапазон на изрязване и др.) и **съответстващи бюджети за стъпки**. Източник: `implementation/step01/compare_sb3.py`.

1.5.1 4.1 DQN върху cartPole-v1

Персонализираният DQN решава cartPole около **епизод** ~1011 и достига **целта** от 475 (**средна стойност за епизод**, изчислена върху 100 **епизода**). **SB3 DQN**, обучен със 750K стъпки ($\approx 17K$ **епизода**), достига максимум с най-добра пълзяща средна стойност за 100 **епизода** от **293.9** - започва да се подобрява около **епизод** 12K и показва пикове, достигащи 500, но никога не поддържа средна стойност за 100 **епизода** над 300.

Защо тази разлика? Три различия в реализацията я обясняват:

1. **График на изследване:** Нашият ϵ намалява с всеки **епизод** ($\times 0.995$), което позволява графикът на изследване да насочи обучителния бюджет към по-информативни **епизоди**, докато тяхната продължителност нараства. При SB3 ϵ намалява линейно спрямо броя *стъпки* (`exploration_fraction=0.36` $\rightarrow$ 270K стъпки). В среди с кратки **епизоди**



Фигура 1: DQN Learning Curves

като cartPole, намаляването на базата на стъпки води до пропиляване на множество **епизоди** в почти случайна **мода**, преди да започне експлоатацията.


2. **Честота на синхронизация на целевата мрежа:** Нашият код синхронизира на всеки 5 епизода - *адаптивен план*: около 100 стъпки в началото и около 2500 стъпки, когато задачата е решена. SB3 използва фиксиран интервал от 1000 стъпки. Адаптивният план осигурява по-бърза обратна връзка в началните етапи на обучението.
3. **Ранно спиране:** Нашият агент прекратява обучението при достигане на пикова производителност, като така се избягва катастрофално забравяне. SB3 изпълнява целия предвиден бюджет и в тази среда неговата стратегия колебае се - решава задачата от време на време, но не успява да задържи решението.

Това са реални алгоритмични различия, а не несправедливост при настройката на хиперпараметрите. За рамка с общо предназначение като SB3 графици, базирани на стъпки, са подходящи за разнообразни среди; нашият избор, специфичен за задачата, просто дава по-добри резултати на cartPole.

1.5.2 4.2 PPO на lunarLander-v3

Персонализираният PPO достига целта от 200 около **епизод** ~543 (264K стъпки). **SB3 PPO**, със същия бюджет от стъпки (500K стъпки), постига най-добър пълзящ среден за последните 100 **епизода** от **131.2** и продължава да се покачва в края на обучението.

Разликата тук е по-малка, отколкото при DQN. И двата алгоритъма използват идентични хиперпараметри на PPO. Оставащата разлика вероятно се дължи на: - ортогоналната инициализация на теглата и вграденото нормализиране на наблюденията на SB3, които подпомагат




Фигура 2: PPO Learning Curves

по-дългите изпълнения, но могат да забавят ранната сходимост; - по-консервативното вътрешно конструиране на минипакети и графика за промяна на скоростта на обучение на SB3.

При предоставяне на по-голям обучителен бюджет (напр. 1–2 милиона стъпки), SB3 PPO вероятно би сходил към целта. Нашият персонализиран PPO е просто по-ефективен по отношение на пробите за тази конкретна задача.

1.5.3 4.3 Обобщение на постигнатата максимална производителност



Фигура 3: Peak Performance

Алгоритъм	Среда	Най-добра средна стойност (подвижна 100)	Най-добра средна стойност на SB3 (подвижна 100)	Цел
DQN	cartPole-v1	477.5	293.9	475
PPO	lunarLander-v3	203.6	131.2	200

Методологична бележка: „Най-добра средна стойност (подвижна 100)“ е максимумът на 100-епизодния подвижен среден по цялата крива на обучение. Тази метрика е справедлива независимо от ранно спиране: тя измерва пиковата способност, а не къде обучението се е случило да приключи. Бюджетите за стъпки са съпоставени (DQN: 750K, PPO: 500K).

1.6 Ключови изводи

1.6.1 5.1 DQN

1. **Най-добър модел с контролна точка е от съществено значение:** DQN е податлив на катастрофално забравяне, след като епсилон достигне своя минимум. Запазването на най-добрия модел предотвратява загубата на добро решение.
2. **$\epsilon_{\min}$ има по-голямо значение от очакваното:** Намаляването от 0.01 до 0.001 беше разликата между деградираща стратегия и стабилна такава.
3. **Честота на синхронизация на целевата мрежа:** Синхронизирането на всеки 5 епизода последователно даваше по-добри резултати от това на всеки 10. Твърде рядко → бавно обучение; твърде често → нестабилност (еквивалентно на липса на целева мрежа).
4. **Изследване, базирано на епизод срещу стъпково изследване:** За среди с нарастваща дължина на епизода (като cartPole), намаляването, базирано на епизод, е поестествено - агентът наблюдава повече от динамиката на средата, преди да прекрати изследването.

1.6.2 5.2 PPO

1. **Тясно място в размера на мрежата:** [64, 64] създаде тясно място в обучението върху 8-измерното пространство на lunarLander. Удвояването до [128, 128] беше решаващата промяна.
2. **Нормализирането на предимството е задължително:** Без него величините на градиента се мащабират спрямо абсолютните награди. Наградите в lunarLander варират от

–500 до +300, което води до катастрофално големи актуализации без нормализиране.

3. **GAE $\lambda = 0.95$ е устойчив:** Стандартната стойност работеше добре без настройка.

4. **Бонусът за ентропия предотвратява застой:** Без него стратегията сходи към „висяне на място“ (локално безопасна, но неоптимална стратегия) в ранните етапи на обучението на lunarLander.

1.6.3 5.3 Реализация от нулата срещу SB3

- Чиста реализация от нулата е с обем 300–500 реда, докато SB3 има ~10,000 реда. Компромисът е по-малко функции, но пълна прозрачност и възможност за отстраняване на грешки.
- Настройките по подразбиране в SB3 са оптимизирани за устойчивост в широк кръг среди (като Atari Games с милиони стъпки и дискретни входни данни от изображения), а не за класически задачи за управление като cartPole. Това кара алгоритъма по подразбиране на SB3 да се затруднява или да се проваля без обширна настройка в сравнение с нашите специфични за средата хиперпараметри. Специфичните за задачата реализации могат да превъзхождат настройките по подразбиране на SB3 при подходящи хиперпараметри.
- За изследователски цели (дипломна работа върху експлоатация на противника, стъпки 7–8), персонализираните реализации позволяват целенасочени модификации (например инжектиране на наблюдения на състоянието на убежденията), които биха изисквали дълбоко подклаждане в SB3.

1.7 Приложение - Възпроизвеждане

```
# From repo root, with .venv activated:
```

```
# Train DQN (early stops ~episode 1000):
```

```
python implementation/step01/dqn/train.py
```

```
# Train PPO (early stops ~step 264K):
```

```
python implementation/step01/ppo/train.py
```

```
# Regenerate comparison figures (caches SB3 results after first run):
```

```
python implementation/step01/compare_sb3.py
```

```
# View training curves in TensorBoard:
```

```
tensorboard --logdir implementation/step01/logs/
```

Генерираните фигури са в deliverables/reports/step01/figures/.

1 Стъпка 02 - Основи на теорията на игрите и CFR: Доклад за реализацията

Среда: април 2026 г.

Игра: Кун покер (3 карти, 2 играчи)

Алгоритъм: Vanilla Counterfactual Regret Minimization (CFR)

Цели: стратегии на Наш с точност до четири десетични знака, стойност на играта $\approx -1/18$, експлоатируемост $O(1/\sqrt{T})$

Статус: Всички цели са постигнати ✓


1.1 1. Какво беше разработено

Стъпка 02 реализира модулна версия на Vanilla Counterfactual Regret Minimization (CFR), приложена към Кун покер, написана изцяло на Python. Тя демонстрира, че рамката успешно открива стратегии в равновесие на Наш в многоагентна среда с непълна информация.

Ключови изградени компоненти: - **Игрови двигател:** `kuhn_poker.py` обработва крайни печалби, залагания и представяне на информационни набори. - **Ядро на алгоритъма CFR:** Рекурсивно обхождане на дърво с вероятностна извадка и напасване на съжалението (`cfr_trainer.py`, `info_set_node.py`). - **Оценител на експлоатируемостта и най-добър отговор:** Брутфорс агрегиране на чисти стратегии за изчисляване на точна експлоатируемост (`evaluate/best_response.py`, `evaluate/exploitability.py`). - **Регистратор на сходимостта и визуализации:** Помощни средства за графично представяне на метрики за експлоатируемостта и сходимостта на стратегията в хода на итерациите (`utils/plotting.py`, `evaluate/convergence.py`). - **Кръстосана проверка с OpenSpiel:** Проверка спрямо стандартни библиотеки с отворен код (`compare_openspiel.py`).

1.2 2. Ключови резултати и визуализации

- **Сходимость към минимакс-оптимално:** Алгоритъмът сходи точно към аналитичното семейство на равновесие на Наш (параметризирано от α).
- **Коефициент на затихване на експлоатируемостта:** Наклонът в лог-лог мащаб на експлоатируемостта спрямо итерациите е ≈ -0.489 , което потвърждава теоретичната гаранция $O(1/\sqrt{T})$.
- **Точност на стойността на играта:** След 100,000 итерации научената средна стойност на играта (-0.0602) почти съвпада с теоретичната точна стойност от $-1/18$ (-0.0556).




Фигура 1: Сходимость на стойността на играта

1.2.1 Сходимость на стойността на играта


1.2.2 Сходимость на експлоатируемостта

1.2.3 Анализ на стратегиите



Фигура 2: Сходимость на експлоатируемостта

Kuhn Poker — CFR Strategy Analysis



Фигура 3: Анализ на стратегиите

1 Стъпка 03 - Варианти на CFR и методи на Монте Карло: Доклад за реализацията

Среда: април 2026 г.

Игра: Ледюк покер (6 карти, 2 играчи, 2 рунда на залагане)

Алгоритми: обикновен вариант на CFR, CFR+, MCCFR External Sampling, MCCFR Outcome Sampling

Цели: експлоатируемост на CFR+ < 0.001 в рамките на ≤ 180 s · кръстосана проверка спрямо OpenSpiel · наклон в лог-лог мащаб ≈ -0.5 за MCCFR

Статус: Всички цели са постигнати ✓

1.1 1. Разработени елементи

Две направления на работа: **фаза на изследване**, използваща референтните решаващи програми на OpenSpiel за изграждане на интуиция и установяване на опорни базови резултати, последвана от **реализация от нулата** на всичките четири алгоритъма, ръчно кодирани единствено в Python + NumPy.

Структура на кода:

implementation/step03/

```
|— cfr/
|   |— leduc_poker.py          # Full game engine (6 cards, 2 rounds, community card)
|   |— info_set_node.py       # Regret & strategy storage per info set
|   |— cfr_trainer.py         # Vanilla CFR (full-traversal, buffered regrets)
|   |— cfrplus_trainer.py     # CFR+ (flooring + linear avg + alternating)
|   |— mccfr_external_trainer.py # External Sampling MCCFR
|   |— mccfr_outcome_trainer.py # Outcome Sampling MCCFR ( $\epsilon$ -on-policy + IS)
|   |— train.py               # Single-algorithm training entry point
|   |— train_all_timed.py     # 180 s wall-clock benchmark harness
|— evaluate/
|   |— best_response.py       # Info-set-constrained best response
|   |— exploitability.py      #  $BR_0$  +  $BR_1$  exact exploitability
|   |— convergence.py        # Geometric-spaced snapshot logger
|— exploration/
|   |— implDayOne1.py         # OpenSpiel five-algorithm comparison on Kuhn
|   |— leduc_comparison.py    # OpenSpiel four-algorithm comparison on Leduc
|   |— leduc_race.py          # 5-minute wall-clock race
```

```
|— compare_openspiel.py          # Cross-validation against OpenSpiel solvers
|— utils/plotting.py            # Figure generation
```

1.2 2. Игрови двигател за Ледюк покер

Пълна реализация, съответстваща на семантиката на OpenSpiel: шест карти ($\{J, Q, K\} \times 2$ бои), два кръга на залагане с разкрита обща карта между тях, действия пас/зalog/повишаване, фиксирани размери на залога (2 в първия кръг, 4 във втория кръг), максимум две повишавания в един кръг. Класиране на ръка по двойки: тайна карта, която съвпада с общата карта, побеждава всяка висока карта. Изброява всички 120 пермутации на раздаването за точно изчисляване на математическо очакване.

1.3 3. Реализации на алгоритми

1.3.1 3.1 Обикновен вариант на CFR

Пълно обхождане на дърво с вероятностна извадка върху всичките 120 раздавания при всяка итерация. Актуализациите на съжалението се буферират за всяко информационно множество и се прилагат атомарно в края на обхождането на всяко раздаване, с цел да се избегне отклонение от стратегията по средата на итерацията.

1.3.2 3.2 CFR+

Три модификации на обикновения вариант на CFR, всяка от които е локализирана. Основната промяна е стъпката за подово ограничаване на съжалението:

```
# cfrplus_trainer.py - regret flooring (ReLU-style clip)
for info_set, deltas in regret_buffer.items():
    node = node_map[info_set]
    for a in range(node.num_actions):
        node.regret_sum[a] = max(node.regret_sum[a] + deltas[a], 0.0)
```

Усредняването на линейни стратегии претегля итерация t със стойността на самата t в плъзгащата средна; редуващите се актуализации напредват само със съжаленията на един играч при всяко преминаване (играч 0 при нечетните итерации, играч 1 при четните).

1.3.3 3.3 Външно вземане на проби в MCCFR

Във възловите състояния на traverser-а се изследват всички действия, докато във възловите състояния на противника се взема проба само от едно действие, избрано според текущата стратегия на противника.

```
def external_cfr(state, update_player):
    if state.is_terminal():
        return state.get_utility(update_player)

    player = state.current_player()
    strategy = get_strategy(state.info_set(player))

    if player == update_player:
        # explore ALL actions (same as vanilla CFR)
        values = [external_cfr(state.apply(a), update_player)
                   for a in legal_actions]
        node_value = sum(strategy[a] * values[a] for a in legal_actions)
        for a in legal_actions:
            regret[info_set][a] += values[a] - node_value
        return node_value
    else:
        # SAMPLE one opponent action from the current strategy
        sampled_action = sample(strategy)
        return external_cfr(state.apply(sampled_action), update_player)
```

Разходът на итерация е приблизително 42 възела (срещу 20,400 при пълно обхождане).

1.3.4 3.4 MCCFR Outcome Sampling

Изважда една единствена корен-краен траектория. Във възлите на **traverser** действията се изтеглят от ϵ -on-policy mixture ($\epsilon = 0.6$: равномерно с вероятност ϵ , в противен случай текущата стратегия). Актуализациите на съжалението се коригират чрез извадка по важност - отношението между истинската вероятност за достигане и вероятността за извадка - като по този начин се запазва свойството на безпристрастен оценител. Разходът на итерация е приблизително 5.5 възела.

1.3.5 3.5 Оценител на експлоатируемостта

Итеративен най-добър отговор, ограничен до информационно множество: за всеки играч се изчислява оптималната контрастратегия при условие, че отговарящият трябва да изиграе


едно и също действие във всички състояния в рамките на дадено информационно множество. Връща $BR_0(\sigma_1) + BR_1(\sigma_0)$ като точна експлоатируемост.

1.4 4. Фаза на изследване (референция OpenSpiel)

1.4.1 4.1 Кун покер - 5000 итерации

За проверка за коректност в малък **мащаб** бяха стартирани и четирите алгоритъма на OpenSpiel, както и персонализираният CFR от Стъпка 02.


Алгоритъм	Експлоатируемост	Време
Персонализиран CFR (Стъпка 02)	$\sim 3.5 \times 10^{-4}$	< 1 s
OpenSpiel CFR	$\sim 1.5 \times 10^{-3}$	~ 2 s
CFR+	$\sim 3.0 \times 10^{-4}$	~ 2 s
MCCFR с външно вземане на проби	$\sim 4 \times 10^{-3}$	~ 1 s
MCCFR с извадка по резултати	$\sim 2.5 \times 10^{-2}$	~ 1 s



Фигура 1: Kuhn - Exploitability vs Iterations


Всички алгоритми достигат почти равновесие на Наш за секунди; разликата е само от академично значение при този мащаб.

1.4.2 4.2 Ледюк покер - 5,000 итерации




Фигура 2: Kuhn - Exploitability vs Wall-Clock Time

Алгоритъм	Експлоатируемост при 5k итерации	Време
CFR+	$\sim 5.4 \times 10^{-5}$	~ 859 s
Обикновен вариант на CFR	$\sim 7.6 \times 10^{-3}$	~ 747 s
MCCFR с външно вземане на проби	~ 1.17	~ 7 s
MCCFR с извадка по резултати	~ 3.08	~ 5 s



Фигура 3: Ледюк - Exploitability vs Iterations

Методите с пълно обхождане доминират с 4-5 порядъка на итерация; измерени в реално време, разликата намалява, но остава при дървета с размер, съпоставим с този на Ледюк.





Фигура 4: Ледюк - Exploitability vs Wall-Clock Time

1.5 5. Еталонен тест с ограничение във времето - 180 секунди реално време

`train_all_timed.py` стартира всяка персонализирана имплементация при общ бюджет от 180 секунди, като използва геометрично разположени моментни снимки. Това представлява справедливото сравнение за компромиса между дисперсия и скорост.

Алгоритъм	Итерации	Крайна експлоатируемост	Информационни множества
Обикновен вариант на CFR	3,713	4.4×10^{-3}	936
CFR+	3,706	2.6×10^{-5}	936
MCCFR External	3,504,665	5.5×10^{-2}	936
MCCFR Outcome	8,262,137	1.0×10^{-1}	936





Фигура 6: Exploitability vs Wall-Clock Time (log-y)

1.6 6. Кръстосана проверка спрямо OpenSpiel

И двете реализации с пълно **обхождане** се валидират спрямо референтните решаващи алгоритми на OpenSpiel при еднакъв **брой итерации** - 500.

Алгоритъм	Наша реализация (500 итерации)	OpenSpiel (500 итерации)	Съвпадение
Обикновен вариант на CFR	0.020	0.022	✓
CFR+	8.6×10^{-4}	9.4×10^{-4}	✓

Малки разлики се наблюдават поради подреждането на сделките и случайните начални стойности; и двете сходяват към едно и също **равновесие на Наш** в рамките на допустимия шум.

1.7 7. Възпроизвеждане

From repo root, with .venv activated:

Train a single algorithm (configurable in train.py):

python implementation/step03/cfr/train.py

Run the 180 s timed benchmark for all four algorithms:

`python implementation/step03/cfr/train_all_timed.py`

Exploration - OpenSpiel reference comparisons:

`python implementation/step03/exploration/implDayOne1.py` *# Kuhn*

`python implementation/step03/exploration/leduc_comparison.py` *# Leduc, iteration budget*

`python implementation/step03/exploration/leduc_race.py` *# Leduc, 5-min wall-clock*

Cross-validate custom vs OpenSpiel:

`python implementation/step03/compare_openspiel.py`

Генерираните фигури са налични в deliverables/reports/step03/figures/.

1 Стъпка 04 - Абстракция на играта и мащабиране на игри с непълна информация: Доклад за внедряването

Среда: Май 2026 г.

Игри: Ледюк с фиксиран лимит, Mini-NL Ледюк, Extended Ледюк

Алгоритми: обикновен вариант на CFR, CFR+, MCCFR, абстракция на информацията/действията

Цели: беззагубната абстракция съхранява качеството на Нашово равновесие; абстракцията със загуби разкрива праг на експлоатируемост; изградена е парето граница между размера на абстракцията и експлоатируемостта

Статус: Основните цели са постигнати

1.1 1. Какво беше разработено

Стъпка 04 разширява cFR toolkit от Стъпка 03 с изрична **абстракция на играта**. Реализацията изгражда **конвейер от типа „Ледюк“**, който може да свие играта по три оси, да реши **абстрахираната** игра, да преведе получената **стратегия** обратно в пълната игра и да измери **разхода за експлоатируемост**.

1.2 1. Какво беше разработено

implementation/step04/

```
├─ exploration/
|   ├─ leduc_suit_abstracted.py      # early suit-isomorphism probe
|   ├─ leduc_lossy_abstracted.py    # early lossy rank-bucket probe
|   ├─ day01_*                      # CFR/MCCFR comparison scripts
|   ├─ day02/mini_nl_leduc.py       # early variable-bet game
|   └─ figures/                     # exploration figures
├─ phase4/
|   ├─ leduc_full_engine.py         # full fixed-limit Leduc baseline
|   ├─ leduc_rank_engine.py         # rank-canonical / suit-isomorphic Leduc
|   ├─ mini_nl_leduc.py             # variable-bet Mini-NL Leduc
|   ├─ extended_leduc.py           # 4-rank, 2-suit Leduc variant
|   ├─ cfr_trainer.py               # generic vanilla CFR trainer
|   ├─ exploitability.py            # full-game exploitability evaluator
|   ├─ day01_*                      # lossless suit-isomorphism experiments
|   ├─ day02_*                      # card bucketing, HSD, EMD, k-means
|   └─ day03_*                      # action abstraction and translators
```

```

|   |— day04_*                # combined abstraction pipeline
|   |— day05_*                # exploitability gap and Pareto frontier
|   |— day06_openspiel_compare.py  # OpenSpiel cross-validation
|   |— day07_cfrplus_panels.py    # 180 s CFR+ benchmark panels
└── EXPERIMENT_RESULTS.md        # final CFR+ result summary

```

1.3 2. Модули за абстракция

1.3.1 2.1 Беззагубен изоморфизъм на боите

Боите в Ледюк не носят стратегическа информация, тъй като изплащанията зависят единствено от ранга и дали тайната карта съвпада с общата карта. Поради това стъпка 04 реализира двигатели с ранг-канонична форма, които обединяват информационните множества, изоморфни по боя.

Тази абстракция е беззагубна: тя запазва качеството на Нашовото равновесие, като същевременно намалява броя на информационните множества и увеличава броя на възможните итерации на CFR/CFR+ при същия бюджет в реално време.

1.3.2 2.2 Загубено групиране на карти

Пътят на абстракцията със загуби изчислява характеристики за силата на ръката, сравнява кандидатите за клъстери чрез разстояния от ЕМД тип и групира информационните множества с конфигурируем брой клъстери.

Два режима на извикване са представени:

Режим	Значение
Кошчета с пълно припомняне	Групиране на текущата сила на частната/общата карта, като се запазва предишната траектория на клъстерите
Кошчета с непълна памет	Замяна на част от по-ранната история с идентичността на клъстера , което води до по-агресивно свиване на дървото

Целта не е да се постигне точност в тази **абстракция**. Целта е да се измери **прагът на експлоатируемост**, породен от обединяването на стратегически различни състояния.

1.3.3 2.3 Абстракция на действията и превод

Mini-NL Ледюк въвежда променливи размери на залозите. Абстракцията на действията след това редуцира множеството действия и оценява как абстрактната стратегия се представя при прилагането ѝ в игра с пълно множество действия.

Имплементирани преводачи:

Преводач	Роля
Най-близко действие	Преобразуване на залог извън мрежата в най-близкия абстрактен залог
Вероятностно разпределение	Разпределяне на маса между съседни абстрактни залози
Псевдохармоничен	Интерполация в пространството на коефициентите, специфична за покера; имплементирана с цел сравнение и бъдещо разширение

1.3.4 2.4 Разширена и комбинирана абстракция


Extended Ледюк увеличава еталонния тест до четири ранга и две бои. Комбинираният конвейер съставя изоморфизма на боите, абстракцията на действията и групирането на карти, след което оценява получената стратегия в подходящото пълно игрово семейство.

1.4 3. Еталонен тест на CFR+ с ограничено време

Окончателният еталонен тест използва CFR+ с подово ограничаване на съжалението и усредняване на линейни стратегии.

Настройка	Стойност
Обучителен бюджет	180 секунди за всяка конфигурация
Повторения	3 изпълнения със семена 1, 2 и 3
Метрика	Крайна експлоатируемост след обучението
Сурови изходи	phase4/.day07_cfrplus_results.json, phase4/.day07_cfrplus_results.csv

1.4.1 3.1 Ледюк с фиксиран лимит



Фигура 1: Fixed-limit Ледюк CFR+ abstraction results


Конфигурация	Информационни множества	Средна експлоатируемост	Среден брой итерации
Пълен CFR+	936	4.44e-05	2,655
Suit iso	288	3.13e-06	14,185
k2 perfect	132	0.571	11,399
k3 perfect	228	0.382	11,043
full bucket perfect	288	4.18e-06	10,806

Беззагубната абстракция с изоморфизъм на боите дава най-добрия резултат при фиксиран лимит. Тя намалява изискванията към паметта и постига по-ниска експлоатируемост от пълния CFR+ в рамките на същия бюджет в реално време, тъй като успява да изпълни значително повече итерации. Вариантите с пълен клъстер се държат сходно, защото след разделянето на случаите според ранга/флопа оставащото компресиране на практика представлява изоморфизъм на боите.


Загубените груби интервали остават силно експлоатируеми. Допълнителните итерации на CFR+ не успяват да преодолеят тази разлика, тъй като самата абстракция е премахнала стратегически релевантна информация.

1.4.2 3.2 Mini-NL Ледюк

Конфигурация	Информационни множества	Средна експлоатируемост	Средни итерации
Пълно mini-NL	4,704	0.00692	439
Абстракция на действията	936 4	0.673	2,338



Фигура 2: Mini-NL Ледюк CFR+ abstraction results



Фигура 3: Extended Ледюк CFR+ abstraction results

Конфигурация	Информационни множества	Средна експлоатируемост	Средна стойност на итерациите
Пълно разширено	10,304	0.0272	111
Изоморфизъм на боя	2,968	0.00126	671
Боя и действие	504	4.696	4,145
Боя, действие и клъстери	108	4.734	3,694


Extended Ледюк потвърждава стойността на беззагубната абстракция в по-голям мащаб: изоморфизмът на боите намалява броя информационни множества с около 71% и постига значително по-ниска експлоатируемост при същия бюджет в реално време. Конфигурациите с абстракция на действията са полезни като пример за неуспех: агресивната компресия на действията води до компактни игри, но преведените стратегии се оказват силно експлоатируеми в по-пълната игра с действия.

1.5 4. Парето граница

Парето границата обобщава основния компромис от Стъпка 04: по-малките абстрактни игри се обучават по-бързо, но не всяко съкращение е стратегически **безопасно**.

Семейство абстракции	Резултат
Изоморфизъм на боите	Най-добър компромис; по-малка игра без стратегическа загуба в Ледюк
Пълни рангови клъстери	Поведение, близко до изоморфизма на боите
Груби загубени клъстери	По-малки дървета, с постоянен праг на експлоатируемост
Абстракция на действията	Най-голям риск; грешка при превода доминира в mini-NL и Extended Ледюк

Практичният критерий следователно не е просто „по-малкото е по-добро“. Полезната абстракция трябва да осигури достатъчно подобрене на изчислителната мощност, за да компенсира въведената експлоатируема разлика.



Фигура 4: Abstraction Pareto frontier

1.6 5. Кръстосана проверка

day06_openspiel_compare.py подравнява всички 936 информационни множества на Ледюк спрямо OpenSpiel и проверява дали персонализираната имплементация е в същия стратегически режим. Оставащите разминавания се интерпретират като разминавания в конвенциите за обновяване, а не като точни несъответствия в траекториите, така че това представлява проверка за коректност, а не доказателство за идентична динамика на решавача.

1.7 6. Ключови изводи

1. **Беззагубната абстракция представлява компресията с най-висока стойност.** В игрите от типа на Ледюк изоморфизмът на боите съществено намалява играта и подобрява сходимостта в реално време, без да въвежда грешка на абстракцията.
2. **Загубената информационна абстракция поражда праг на експлоатируемост.** Грубите клъстери за карти се решават по-бързо, но не могат да възстановят различията, които умишлено са премахнали.
3. **Абстракцията на действията е по-опасна от абстракцията на карти в тези ек-**

сперименти. Ограничени множества от действия плюс статичен превод доведоха до висока експлоатируемост, дори когато абстрактното дърво беше значително по-малко.

4. **Парето границата е подходящият формат за докладване.** Качеството на стратегията трябва да бъде представено заедно с размера на играта и типа абстракция.
 5. **Решаването на под-игра е естественият следващ механизъм.** Статичният превод е крехък; методите за безопасно решаване от Стъпка 6 представляват производствения стандартен отговор на действия извън дървото.
-

1.8 7. Възпроизвеждане

From repo root:

```
cd implementation/step04/phase4
```

Smoke-test budget used by the phase-4 integration notes:

```
python day01_train.py --iterations 200
```

```
python day02_train.py --iterations 200
```

```
python day03_train.py --iterations 100
```

```
python day04_train.py --iterations 20000
```

```
python day05_train.py
```

```
python day06_openspiel_compare.py --iterations 200
```

Final CFR+ benchmark panels:

```
python day07_cfrplus_panels.py
```

Генерираните JSON/CSV файлове се записват в директорията `implementation/step04/phase4/`, а фигурите - в `implementation/step04/phase4/figures/`.

1 Стъпка 07 - Моделиране на противника в игри с непълна информация

Игри: Кун покер (3 карти, 2 играчи) и Ледюк Холдем (6 карти, 2 рунда) - най-малките точно решими тестови среди с непълна информация, които използват повторно енджина за Кун от Стъпка 02 + cFR решаващ и енджина за Ледюк от Стъпка 03.

Връзка с дисертацията: Принос №1 (Рамка за поведенческа адаптация) - моделът на противника е *сензорът*, който преобразува наблюдаваните действия в оценка на стратегията на противника; адаптивният експлоатер е първият *изпълнителен механизъм*, формализиран в Стъпка 08 като безопасна (регулирана с КЛ-дивергенция) експлоатация.

Обхват на резултатите: Част I представлява последователност от експерименти в Кун покер със зададени начални условия, които изграждат интуиция. Част II е пълна оценка и за двете игри (5 начални условия, мачове с 20,000 ръце, базови линии на Неш при 200,000 / 40,000 итерации на CFR). Всички фигури са измерени от тези изпълнения и, където е възможно, са ограничени от *точни* аналитични препратки, а не от симулирани такива.

Как да четете този доклад. И двете части следват една и съща структура: **какво тестваме → как го тестваме → резултати → заключения.** **Част I (§1–§6)** изследва базирания на типове байесов модел самостоятелно в Кун - как изглежда „типът“ на противника, защо моделирането си струва и как се държи цикълът на актуализиране на убежденията (включително къде се проваля). **Част II (§7–§13)** оценява цялата система - три модела на противника и адаптивен експлоатер - в Кун и Ледюк. §14 съдържа команди за възпроизвеждане.

2 ЧАСТ I - ИЗСЛЕДВАНЕ НА КУН ПОКЕР

2.1 1. Предмет на изследването в тази стъпка

Стратегията на **равновесие** е изградена така, че в дългосрочен план да не носи загуба, *независимо срещу кого се прилага*. Тази сигурност обаче има своята цена: тя се играе еднакво както срещу световен шампион, така и срещу противник, който се отказва при всеки **залог**. **Моделирането на противника** представлява *наблюдение на начина, по който даден опонент действително играе*, и актуализиране на убеждение относно неговата стратегия, с цел да **можем да се отклоняваме от равновесие, за да използваме грешките му** - да блъфираме повече срещу противник, който се отказва твърде често, и да правим по-тънък стойностен залог срещу такъв, който плаща прекалено често.

Техниката, която се изследва първо, е **базиран на типове (Байесов) модел**: вместо да се

научава стратегия от нулата, се поддържа убеждение - разпределение на вероятностите - върху малък набор от предварително дефинирани типове противници, което се актуализира след всяко наблюдавано действие чрез **правилото на Бейс**:

$$\text{апостериорно разпределение(тип)} \propto \text{предварително убеждение(тип)} \times P(\text{наблюдавано действие} \mid \text{този тип})$$

Действие, което даден тип смята за невъзможно, намалява вероятността му до нула; действие, което той предвижда добре, я увеличава. След много раздавания убеждението се концентрира върху най-подходящия тип и ние оптимално отговаряме на него. Всички числа в Част I са измерени от инициализирани, възпроизводими Kuhn игри.

2.1.1 1.1 Типовият зоопарк на противниците

Четири истински типа изпълняват двойна роля - те са едновременно противниците, срещу които играем, и кандидат-хипотезите, върху които детекторът разсъждава:

Тип	Поведение
AlwaysCall	Пасивен играч - никога не залага, никога не се отказва (проверява в отворен пот, плаща всеки залог).
TightPassive	Камък - ангажира жетони само с най-силната ръка (K); отказва се от всичко останало. Най-експлоатируемият тип.
LooseAggressive	Маниак - винаги залага или плаща, независимо от ръката.
Nash	Балансирана равновесна игра (от cFR решаваща на Стъпка 02); използва смесени стратегии; неексплоатируем.


2.2 2. Експеримент 1 - Поведенчески отпечатъци

Какво изследваме. Проявява ли всеки тип отличителен и възстановим отпечатък в действията си?


Как. Използваме 50/50 „сонда“ срещу всеки тип (за да се гарантира посещаването на всяко информационно множество) и записваме емпиричната стойност на $P(\text{bet})$ във всяко информационно множество до истинската стойност на $P(\text{bet})$ за съответния тип.

Резултати. Четирите поведенчески отпечатъка са ясно различни, като емпиричните честоти съответстват на истинските вероятности в добре посетените информационни множес-

тва: **разпуснат-агресивен** ≈ 1.0 навсякъде; **стегнат-пасивен** ≈ 0 , освен когато държи К; **alwaysCall** ≈ 0 при проверка в отворен пот, но ≈ 1.0 при изправяне срещу залог; **наш равновесие** - дробни и смесени.



Фигура 1: Behavioral fingerprint - TightPassive (bets only with the King).



Фигура 2: Behavioral fingerprint - Nash (mixed frequencies; empirical tracks true).

Заклучение. Възстановяването на поведенческия отпечатък на даден тип от наблюдаваните действия представлява цялата задача по моделиране и е осъществимо - но информационните множества с малко посещения имат шумни емпирични честоти, което именно прави моделирането трудно при наличие на ограничени данни.

2.3 3. Експеримент 2 - Възможност за експлоатация (защо си струва усилието)

Какво изследваме. Каква допълнителна стойност носи моделирането в сравнение със сляпо равновесие по Наш?

Как. За всеки тип и място изчислете *точно* (i) очакваната стойност на героя при **наш равновесие**, (ii) **стойността на най-добрия отговор** (таванът на експлоатацията, при допускане, че типът е известен перфектно), и (iii) разликата между тях. Тази разлика показва колко пари **наш равновесието** оставя неизползвани.

Опонент	Място	Нашева	Стойност на най-добрия	
		очаквана стойност	отговор	Разлика
AlwaysCall	0	+0.119	+0.333	0.215
AlwaysCall	1	+0.220	+0.333	0.113
TightPassive	0	-0.060	+0.167	0.227
TightPassive	1	+0.055	+0.333	0.278
LooseAggressive	0	+0.121	+0.333	0.213
LooseAggressive	1	+0.116	+0.333	0.217
Nash	0	-0.055	-0.052	0.004
Nash	1	+0.055	+0.060	0.005

Резултати. При трите експлоатируеми типа разликата е значителна (0.11–0.28 на ръка), докато срещу **наш равновесие** тя е ≈ 0 - както и следва, тъй като **наш равновесието** е неексплоатируемо и най-добрият отговор не може да надмине стойността на играта. По-конкретно, изчисленият най-добър отговор срещу **стегнат-пасивен тип блъфтира**, като залага с най-слабата си ръка (Вале) в отворен пот, понеже този тип фолдва всичко освен Поп.

Заклучение. Стойността на моделирането на противника е реална и измерима, а експлоатирането на камък означава *повече блъфиране*. (Недостатъкът от $-1/18 \approx -0.056$ за първия играч в Кун на място 0 обяснява малките отрицателни стойности при **наш равновесие** - това е особеност на играта, а не грешка.)

2.4 4. Експеримент 3 - Детектор на тип по Байес (ядрото на цикъла)

Какво изследваме. Започвайки от равномерно предварително убеждение, може ли цикълът на актуализиране на убежденията да идентифицира противника единствено по поведението


му - и какво се случва, когато поведението на противника не съответства на *ниито един* тип?

Как. Поддържайте апостериорно разпределение върху четирите типа; след всяко наблюдавано действие на противника умножете неговата вероятност при всеки тип и нормализирайте отново (в логаритмично пространство, като използвате малко изглаждане на вероятностите $\varepsilon = 0.02$, за да не елиминира нито едно „невъзможно“ действие трайно някой кандидат). Стартирайте няколко скрити противника и наблюдавайте развитието на апостериорното разпределение стъпка по стъпка.

2.4.1 4.1 Противници от множеството - бързи, точни и стабилни

Когато скритият противник действително е един от четирите кандидати, апостериорното разпределение се концентрира коректно и се стабилизира:

- **Скрит = стегнат-пасивен:** апостериорното разпределение се концентрира върху „стегнат-пасивен“ и се стабилизира при ≈ 1.0 до раздаване ~ 18 . (Наш е бавно умиращият съперник, тъй като „камък“ и равновесна игра съвпадат при много раздавания.)
- **Скрит = alwaysCall:** се заключава до раздаване ~ 4 (много отличителен тип).




Фигура 3: Hidden = TightPassive: clean convergence to the correct type.

2.4.2 4.2 Противник извън набора - „няма честно място“

Инструктивният случай е скрит противник, който представлява **50/50 смес по действие** между стегнат-пасивен и разпуснат-агресивен - умишлено *ниито един* от четирите типа.

Човек би могъл да очаква апостериорното разпределение да се „раздели между двата най-близки типа“. **То не го прави.** Детекторът твърдо се ангажира с *един* тип в даден момент и прескача:

alwaysCall (раздаване 1–2) → разпуснат-агресивен (раздаване ~5–40) → **наш равновесие** (раздаване ~43+, ≈ 1.0).



Фигура 4: Hidden = Mixture(TightPassive, LooseAggressive): the belief thrashes, then lands on Nash.

Това е *правилно* баесово поведение, а причината за него е основният извод от тази фаза:

- Смесеният играч играе истинско (0.5 ; 0.5) на средни раздавания (J/Q) и винаги залага с Поп. Всеки път, когато заложи J/Q, камъкът (който никога не го прави) получава наказание по вероятност; всеки път, когато провери J/Q, маниакът (който винаги залага) получава такова.
- Двата детерминистични екстремума следователно биват опровергавани около половината от времето. **Наш равновесие е единственият кандидат, който присвоява реална вероятност както на залагане, така и на проверка при средно раздаване**, така че това е единствената стратегия, която никога не е фатално опровергана - а произведение на правдоподобия апостериорно разпределение се концентрира върху единственото най-добро обяснение, а не върху смес.

Заклучение. Малкото меню от стереотипи няма *честен начин да каже „нито едно от горните“*. Изправено пред противник, който не може да представи, то се ангажира - уверено


- с най-близкия *смесен* тип, вместо да докладва истинска несигурност. Две точки изострят това. Първо, апостериорното разпределение е **относителна, нормализирана** величина - четирите стълба са принудени да сумират до 1, така че $P(\text{nash})=1.0$ означава „най-добро приближение *сред тези четири*“, а не „добро приближение в абсолютни термини“. Измерването на абсолютното приближение на победителя (геометрична средна вероятност, която той присвоява на всяко наблюдавано действие) разкрива разликата: печелившият наш модел отбелязва **0.74 на действие срещу истински наш противник, но само 0.31 срещу сместа** - еднакво уверен на хартия, много по-лош в действителност. Второ, честното решение е да спрем да питаем „кой тип?“ и да попитаме „каква *смес* от типове?“ - Експеримент 4 (§5) и мотивацията за **непрекъснатите и съгласувани** модели в Част II.

2.4.3 4.3 Колко устойчива е тази сходимост? - стрес тест от 500 раздавания

Тъй като §4.2 завършва с **наш равновесие**, естествен въпрос е дали в хода на дълъг мач убеждението все още може да „отпадне“ от него. Изпълнихме сценария със **смес** за **500 раздавания при 300 случайни семена** и разграничихме две явления, които **наивната метрика** обединява - *бавна сходимост* и *отпадане след сходимост*.

Измерване (300 семена × 500 раздавания)	Резултат
Крайният победител на раздаване 500 е наш равновесие	300 / 300 (100%)
След като наш равновесие <i>постоянно</i> поеме преднината, то по-късно спада под 0.5	0 / 300 (никога)
Грешен тип все още водеше след раздаване 100	40 / 300 (~13%)
Грешен тип все още водеше след раздаване 200	14 / 300 (~5%)
Раздаване, на което наш равновесие се заключава окончателно	медиана 23 · 90-ти перцентил 125 · най-лошо 461

Резултати. Наш равновесие никога не *отпада*: след като окончателно поеме преднината, то остава фиксирано на ≈ 1.0 . Истинският риск е обратният - **бавна сходимост, при която за дълго време се поддържа уверено, но грешно убеждение**. В значителна част от изпълненията маниакът (свободно-агресивният) държи убеждението на ≈ 1.0 повече от сто раздавания, преди наш равновесие да го изпревари - единствено защото ранна серия от тежки залози изглежда като стратегия „винаги залага“. Графиката по-долу (най-волатилното начално число) показва как свободно-агресивният тип поддържа ≈ 1.0 от раздаване ~35 до ~220, след което рязко се преминава към наш равновесие за остатъка:



Фигура 5: Hidden = Mixture, 500 hands (most volatile seed): a wrong type can dominate for 200 hands before Nash overtakes; once locked, Nash never falls.

Заклучение. Сред четирите кандидата наш равновесие е този, който е *най-близо* (минимално разминаване на Кълбек–Лайблер) до истинската смесена стратегия. Поради това всеки детерминиран тип в крайна сметка се сблъсква с противоречие, което не може да преодолее. Наш равновесие е единственият дългосрочен победител - „дългосрочен“ понякога означава просто над 200 раздавания. Най-добре реагиращ на ранно, уверено, но грешно убеждение би означавало да се адаптираш към победа над илюзия.

2.5 5. Експеримент 4 - Възстановяване на сместа чрез модел на смес с ЕМ

Какво тестваме. §4 показва, че ако се зададе въпросът „кой единствен тип сте?“, смесеният опонент се свежда до най-близкия смесен тип (наш равновесие) и се прикрива лошото абсолютно съответствие. Можем ли вместо това да зададем въпроса „каква **смес** от типове сте?“ и да възстановим действителната смес?

Как. Напасваме **тегла за смесване** п върху същите четири фиксирани типа чрез **очаквателна стъпка–стъпка М**: всяко наблюдавано действие се *меко приписва* на типовете пропорционално на това колко добре всеки от тях го обяснява (очаквателна стъпка), а теглата са средното приписано количество (стъпка М), итерирано до **сходимост**.

- очаквателна стъпка: $\text{отговорност}(\text{тип} \mid \text{действие}) \propto \pi(\text{тип}) \times P(\text{действие} \mid \text{тип})$
- стъпка М: $\pi(\text{тип}) = \text{средната стойност на отговорностите за всички наблюдения}$

Изкушаващ пряк път - **твърдо** преброяване по ръце (избиране на единствения най-


подходящ тип за всяка ръка и след това броене) - **не** работи: той е объркан от *тип припокриване* (напр. alwaysCall и TightPassive и двата проверяват слаба ръка, така че argmax не може да ги разграничи). Меката, итерирана версия на ЕМ ги **разграничава**.

Резултати. Пренапасването на теглата след всяка ръка (топло стартирана от предишната оценка) дава **траектория за всяка ръка** - аналогът на сместа към графиките „разпределение на апостериорни вероятности във времето“ от §4. Двата активни компонента нарастват до истинските си тегла, а другите два намаляват до нула, докато старото еднотипно апостериорно разпределение вместо това показва **наш равновесие** ≈ 1.0 през цялото време:


Скрит противник	Метод	alwaysCall	стегнат-пасивен	разпуснат-агресивен	наш равновесие
50 / 50 смес	глобален постериор (стар)	0.00	0.00	0.00	1.00 x
	тегла на ЕМ @250	0.00	0.51	0.49	0.00 ✓
	раздавания истинска смес	0.00	0.50	0.50	0.00
70 / 30 смес	глобален постериор (стар)	0.00	0.00	0.00	1.00 x
	тегла на ЕМ @250	0.00	0.66	0.34	0.00 ✓
	раздавания истинска смес	0.00	0.70	0.30	0.00

(Малката остатъчна грешка при 250 раздавания се дължи на шум от извадката; по-продължително изпълнение я намалява - при 4,000 раздавания се получават стойности 0.50/0.50 и 0.69/0.31.)

Заклучение. ЕМ възстановява не само кои типове са налични, но и в какво съотношение - интерпретируемо и честно описание („ ≈ 70 % камък + 30 % манияк“), докато моделът с един тип даде уверено грешен отговор. Това отразява основополагащата работа в **моделирането на противника** (Bayes' Bluff, Southey и др. 2005), която поддържа *разпределение върху страте-*



Фигура 6: Recovering a 50/50 blend - EM mixing weights per hand. After early thrashing, TightPassive (orange) and LooseAggressive (green) converge together onto the true 0.50 line while AlwaysCall and Nash decay to zero.



Фигура 7: Recovering a 70/30 blend - the two active components settle onto their distinct true weights (dotted), recovering not just *which* two types but their proportions.

гите на противника, вместо да се ангажира с една. Част II обобщава това още повече - **непрекъснат** оценител в последователна форма за всяка информационна съвкупност (броене на Дирихле за всяка ситуация, което представя всяка стратегия, включително смес) и **съгласуван** оценител в последователна форма (Ganzfried 2025). Експеримент 4 е най-малкото, най-четимо стъпало на тази стълбица.

2.6 6. Какво установява Част I

Повърхностите за **изследване**, с конкретно измерено лице, открояват напрежението, което стъпки 07–08 са създадени да разрешат:

1. **Стойността е реална (Експеримент 2):** слепото **наш равновесие** оставя на масата между 0.1 и 0.3 на ръка срещу **експлоатируеми опоненти** - следователно моделирането си заслужава.
 2. **Моделът може да бъде уверен и грешен за дълго време (Експеримент 3):** в около 13% от сериите с по 500 ръце детекторът уверено е вярвал в грешния тип след 100-ата ръка, а стереотипното меню не може да представи **противник извън менюто** (Експерименти 3–4).
 3. **Следователно експлоатацията трябва да бъде регулирана.** Не бива да се **оптимално отговаря** на това, в което моделът в момента вярва; стремежът към **експлоатация** трябва да бъде ограничен (например чрез **регулиран с КЛ-дивергенция**) и мащабиран според степента, в която прочетеното е *заслужено*. Част I превръща този абстрактен принцип в демонстриран **режим на отказ**; Част II го измерва в пълен **мащаб**, а стъпка 08 изгражда **безопасния** изпълнителен механизъм.
-

3 ЧАСТ II - ПЪЛНА СИСТЕМНА ОЦЕНКА НА „КУН“ И „ЛЕДЮК“

3.1 7. Какво тестваме и как

Част II оценява цялостна система за моделиране на противника - **три взаимозаменяеми модела на противника**, които захранват **един адаптивен експлоатер** - и в двете игри, спрямо точни аналитични критерии.

Трите модела (всички използват един и същ интерфейс: приемат наблюдавани раздавания → извеждат прогнозирана **стратегия** на противника):

- **Типово базиран** - дирихле–мултиномиално апостериорно разпределение върху фиксирано множество от типове противник (моделът от Част I, увеличен); докладва тип

MAP и стратегия, усреднена по модел.

- **Непрекъснат** - оценка по Дирихле за всеки информационен набор (отчита какво е направил противникът във всяка ситуация, с изглаждане). Той може да представи всяка стратегия; скритите карти (фолдове) се обработват чрез разпределяне на меки/ЕМ преброявания върху съгласуваните раздавания.
- **Съгласуван** - последователна форма максимално апостериорна оценка на Ганцфрид (2025), решена като малка изпъкнала програмираща задача. Оценяването на една глобално съгласувана стратегия (вместо всеки информационен набор поотделно) е проектирано да използва доказателствата за частична наблюдаемост по-ефективно.

Експлоатерът. На всеки k раздавания той преизгражда стратегията на героя като точен най-добър отговор спрямо текущата оценка на модела, по избор смесена към наш равновесие с тегло за безопасност и по избор забравящ модела при откриване на точка на промяна (байесово онлайн откриване на точка на промяна върху сигнал за агресия). Тъй като всичките три модела запазват *един и същ* точен най-добър отговор, експлоатацията се сравнява „ябълки с ябълки“.

Точни мерки. И двете игри са достатъчно малки, за да бъдат решавани напълно, така че всяка симулирана крива е ограничена от две аналитични препратки, изчислени с ръчно проверена математика, а не със симулация: `nash_ev` (какво печели безопасната равновесна игра срещу този противник - не можете да се представите по-зле, ако прочитът е безполезен) и `ceiling` (точната стойност на най-добрия отговор - максималното, което може да бъде извлечено). Добрият експлоатер се намира между тях и се изкачва към тавана. Самият апарат е надежден по две независими причини. *Вътрешно*: нашият решаващ възпроизвежда точната стойност на Наш за Кун от $-1/18$ ($\text{NashConv} \approx 0.002$, т.е. по същество неексплоатируем), а точният най-добър отговор побеждава равномерната игра с предвидените разлики (Кун $+0.500$, Ледюк $+2.087$). *Външно*: кръстосано валидиран спрямо **OpenSpiel**, NashConv на нашия двигател за най-добър отговор върху равномерната стратегия съвпада с този на OpenSpiel до пълна точност - Кун 0.916667 срещу 0.916667 и Ледюк 4.747222 срещу 4.747222 ($|\Delta| = 0.000000$ и в двата случая, толеранси $0.001 / 0.01$). Тъй като $\text{NashConv} = br_0 + br_1$ в игра с нулева сума, това сравнява двата двигателя без никакво съпоставяне на низове със състояния на информация.

Трите проучвания.

1. **Откриване** - може ли всеки модел да възстанови *кой* играе срещу него? За типово базирания модел представяме апостериорното разпределение върху истинския тип и дали MAP е правилен; за всички модели представяме средната обща вариация (TV) дистанция между оценената и действителната стратегия на противника (по-ниска стойност означава по-добро възстановяване).
2. **Експлоатация** - колко печели най-добре реагиращият към всеки модел, измерено

спрямо точните *nash_ev* и *ceiling*?

3. **Нестационарност** - когато противникът промени стила си по средата на мача, възстановяването чрез забравяне на точка на промяна протича ли по-бързо в сравнение с модел, който никога не забравя?

Размери на извадките. Откриване: 5 семена $\times$ 4,000 раздавания за всеки тип. Експлоатация: 5 семена $\times$ мачове от по 20,000 раздавания, с пренастройване на всеки 200 раздавания. Нестационарност: 5 семена $\times$ мачове от по 20,000 раздавания със смяна на стила на 10,000-тото раздаване. Базовите линии за **равновесна игра** използват 200,000 (Кун) / 40,000 (Ледюк) итерации на CFR.

Бележка относно имената на типовете. В Част II се използва по-голям, специфичен за всяка игра типов зоопарк в сравнение с четирите ръчно изградени типа от Част I: зоологическата градина за *Кун* включва {AlwaysPass, AlwaysBet, TightPassive, LooseAggressive, Thresholdish, Nash, Random, Level1-3}, а тази за *Ледюк* съдържа {CallingStation, Maniac, Rock, LoosePassive, Nash, Random, Level1-3}. Поради това имената се различават от Част I - по-конкретно, *AlwaysCall* в Част I (пасивен играч, който никога не се отказва) е различен тип от *AlwaysPass* при *Кун* в Част II (който само проверява/се отказва); пасивният играч от Част II съществува в зоологическата градина на *Ледюк* като *CallingStation*.

Едно умишлено уточнение - съгласуваният модел не се изпълнява в цикъла на експлоатация. Той преобучава своята изпъкнала програмираща задача от нулата всеки път, когато експлоататорът се актуализира, а тази цена нараства с броя на вече наблюдаваните **раздавания** (от част от секундата в началото до около 12 s за преобучаване при близо 20,000 **раздавания**), което прави пълния онлайн мач непрактичен. Затова оценяваме съгласувания модел по отношение на **възстановяване на стратегия (откриване)**, където неговата последователна форма MAP е проектирана да се представи най-добре, и оставяме базираните на типове и непрекъснати модели да носят сравнението за експлоатация. (На *Ледюк* последователната програмираща задача е голяма, така че съгласуваното откриване се докладва само за *Кун*.)

3.2 8. Откриване - кой е опонентът?

Откриването, базирано на типове, е по същество перфектно: апостериорното разпределение се концентрира изцяло върху истинския тип и MAP е коректен (TV разстояние 0.000) - с **едно показателно изключение**. На *Кун* по-високите Level-k противници се припокриват: Level-2 и Level-3 сходяват към *една и съща* поведенческа стратегия, така че апостериорното разпределение се разделя 0.50/0.50 между тях и MAP за истинския Level-3 попада върху Level-2. Това не е грешка - два типа, които играят идентично, са наистина неразличими по

своите действия, което е всичко, което един детектор на типове може да наблюдава. **Непрекъснатите** и **съгласуваните** модели, които оценяват действителната стратегия, а не етикет, възстановяват и двата коректно ($TV \approx 0.005$).

Непрекъснати модел има малка средна стойност на TV спрямо истината при Кун (0.006–0.030), но по-голяма при Ледюк (0.11–0.36): Ледюк разполага с далеч повече информационни множества и по-силна частична наблюдаемост, така че свободен оценител за всяко информационно множество се нуждае от значително повече раздавания, за да **сходява**, а рядко посещаваните информационни множества доминират остатъчната грешка. **Съгласуваният** модел (Кун) съвпада или превъзхожда възстановяването на непрекъснатия модел ($TV \approx 0.004$ – 0.021), както е проектиран неговият MAP в последователна форма.

Заклучение. Възстановяването е успешно и класовете модели се подреждат в съответствие с теоретичните предвиждания: добре специфицираното меню от типове е ненадминато *когато противникът принадлежи към него*; необходимо е използването на модели, оценяващи стратегията, във всички останали случаи, като те заплащат **разход на данни**, който нараства с мащаба на играта.

3.3 9. Експлоатация - каква печалба носи моделирането?


Реализираната средна печалба на ръка в 20,000-ръчни мача ($\times 5$ семена), спрямо точния най-добър отговор **ceiling**. Всяка таблица показва пет представителни типа от „зоологическата градина“ на съответната игра (10 Кун / 9 Ледюк; пълният набор е в резултатите JSON). Типово базираният модел почти точно проследява тавана и в двете игри; непрекъснати модел го съвпада при Кун и го следва отблизо при Ледюк, като остава под него за най-трудните за нападение типове (подбирането на ограничена извадка от §8).

Кун (ceiling / базиран на типове / непрекъснат):

Opponent	ceiling	базиран на типове	непрекъснат
AlwaysPass	0.975	0.966	0.966
AlwaysBet	0.333	0.335	0.335
разпуснат-агресивен	0.333	0.337	0.330
стегнат-пасивен	0.167	0.168	0.168
наш равновесие	-0.055	-0.055	-0.053

Ледюк (таван / базиран на типове / непрекъснат):

Opponent	ceiling	базиран на типове	непрекъснат
Level1	3.056	3.061	2.672
Маниак	2.177	2.199	2.038
CallingStation	1.464	1.451	1.434
Камък	0.937	0.912	0.848
Наш равновесие	-0.083	-0.085	-0.175



Фигура 8: Exploitation vs opponent type (Ледюк): type-based (blue) hugs the exact BR ceiling for every type; continuous (orange) tracks close but sits below for the hardest-to-fit types; both drop below zero against Nash.

Резултати - два основни извода:

1. **Не можете да експлоатирате равновесие.** Срещу нашия противник всеки модел печели приблизително (отрицателната) наша очаквана стойност, никога повече - абсолютният таван е по същество стойността на играта. Това потвърждава, че експлоатацията е реална, а не артефакт. (Където реализираното число е с косъм *над* своя таван - например непрекъснат -0.053 срещу тавана от -0.055 на Кун нашево равновесие - излишъкът е шум от краен брой проби в рамките на ± 1 SE, а не реално нарушение: абсолютният таван всъщност не може да бъде надминат.)
2. **Уверен, но недообучен модел ви прави експлоатируем.** На Ледюк непрекъснатият модел губи от наш равновесие (-0.175 срещу тавана от -0.083): с несвършени данни той най-добре реагира на *грешна* оценка на неексплоатируем противник, отваряйки изтичане в собствената си игра.

Заклучение. Когато класът на модела е подходящ, най-добрият отговор достига точния из-
вличащ се таван - моделирането осигурява пълната теоретична стойност. Когато това не
е така (непрекъснат при многото информационни множества на Ледюк), се появяват два
разхода: пари, оставени на масата срещу експлоатируеми опоненти, и - по-опасно - *отри-*
цателен резултат срещу опонент, който изобщо не може да бъде експлоатиран. Този втори
разход е напрежението между експлоатацията и безопасността в числа и пряката мотивация
за безопасната експлоатация с регуляризация на КЛ и ограничена опасност от Стъпка 08.


3.4 10. Нестационарност - адаптиране към смяна по време на игра

Какво тестваме. Опонентът сменя стила си на ръка 10,000 от общо 20,000. Сравняваме **ста-**
тичен непрекъснат модел с модел, който прилага **забравяне на точка на промяна** (откри-
ване на промяна в стила → нулиране на модела → преминаване към безопасна игра → повтор-
но обучение).

Резултатът е **сценарийно-зависим**, което само по себе си представлява откритието. Средна-
та печалба на ръка *след смяната*, усреднена за 5 начални числа ($\pm$ стандартна грешка; всяко
отделно начално число съвпада по знак):

Игра	Смяна (на ръка 10k от 20k)	статичен (след смяната)	точка на промяна (след смяната)
Кун	Стегнат-пасивен → Свободно- агресивен	-0.106 $\pm$ 0.007	+0.211 $\pm$ 0.008
Ледюк	Стратегия „камък“ → Маниак	+1.834 $\pm$ 0.054	+0.552 $\pm$ 0.017


- **Кун - точката на промяна печели.** Остарялата анти-стратегия „камък“ (блъф-ориентирана) *активно губи* срещу новия маниак (който приема всичко), така че статичният модел става отрицателен при всяко начално число (-0.077 до -0.122); откриването на смяната и повторното обучение възстановява до $+0.21$ (всички начални числа от $+0.18$ до $+0.24$). Двете ленти не се припокриват.
- **Ледюк - точката на промяна губи.** Маниакът губи $2+/\text{ръка}$, така че непрекъснато адаптиращият се статичен модел го експлоатира добре без никакво нулиране ($+1.83$); междувременно детекторът отчита много **фалшиво положителни резултати** по време на стабилната фаза (58–59 нулирания на начално число срещу една единствена истинска смяна), всяко от които преминава към безопасна игра и изхвърля данни, и за-



Фигура 9: Non-stationarity (Kuhn): after the switch the static model bleeds (exploiting a phantom), while change-point detection resets and recovers.

вършва три пъти и половина по-ниско (+0.55). Отново лентите за начални числа са ясно разделени.

Заключение. Забравянето на точка на промяна е от полза именно когато остарелият модел е *вреден*, но в наивната си форма - детектор с нисък сигнал, който често дава фалшиви сигнали, плюс пълно връщане в безопасен режим при всяко засичане - може да се представи по-слабо от простата непрекъсната адаптация, когато новият противник е достатъчно експлоатируем, така че остарялостта не носи значителни загуби. *Реакцията* на засечена промяна е толкова важна, колкото и самото ѝ засичане: по-икономични решения (частично забравяне вместо твърдо нулиране; детектор с по-ниска склонност към фалшиви задействания) са ясна следваща стъпка.



Фигура 10: Non-stationarity (Ледюк): here the static model wins - the Maniac is so exploitable that continuous adaptation captures it, and the detector's false-positive resets cost more than they save.

3.5 11. Достатъчни ли са размерите на извадките?

Тъй като всеки експеримент записва стойностите за всяко начално число, адекватността може да бъде количествено определена, вместо да се приема за даденост. Краткият отговор е: **адекватни във всичките три изследвания** - напълно достатъчни за експлоатация и нестационарност, както и достатъчни за качествените твърдения за откриване.

Експлоатация - достатъчни и с голям резерв. Стандартната грешка (СГ) на средната печалба на ръка за 5-те начални числа е пренебрежимо малка спрямо заявените ефекти:

Игра	типична стандартна грешка (на ръка)	разлика на базиран на типове модел спрямо абсолютния таван	недостиг на непрекъснат модел спрямо базиран на типове
Кун	0.000–0.005	в рамките на ≈ 1 стандартна грешка навсякъде	≤ 1 стандартна грешка (те съвпадат)

Игра	типична стандартна грешка (на ръка)	разлика на базиран на типове модел спрямо абсолютния таван	недостиг на непрекъснат модел спрямо базиран на типове
Ледюк	0.007–0.040	в рамките на ≈ 1 стандартна грешка навсякъде	5–20 стандартни грешки (напр. Ниво1 3.061 спрямо 2.672, $\Delta = 0.389$ при стандартна грешка ≈ 0.02 –0.04)

И така (1) базираният на типове модел е **статистически неразличим от абсолютния таван** за всеки тип и в двете игри - „моделирането достига тавана“ не се дължи на начална случайност; и (2) недостигът на непрекъснатия модел при Ледюк (§9) е **реален ~5–20 σ ефект**, както и неговото саморазкриване на Наш равновесие (-0.175 спрямо -0.083 , разлика от 0.092 при $СГ \approx 0.015 \approx 6 \sigma$). Извадката потвърждава всяка разлика, на която се основава докладът.

Откриване - достатъчно за направените твърдения. Задните разпределения, базирани на типове, са наситени, а непрекъснатите/съгласуваните ТВ разстояния са стабилни и подредени според предсказанията. Представяме точкови стойности на ТВ, вместо грешкови ленти; по-пълна версия би повторила откриването за различните начални числа и би публикувала доверителни ленти за ТВ.

Нестационарност - стабилна (5 начални числа). Всяка вариация вече се изпълнява върху едни и същи 5 начални числа. Стандартните грешки след превключването са малки и, в двете игри, статичните и базираните на **точка на промяна** ленти са ясно разграничени: **Кун** -0.106 ± 0.007 срещу $+0.211 \pm 0.008$ (**точката на промяна** печели с ~ 40 комбинирани СГ); **Ледюк** $+1.834 \pm 0.054$ срещу $+0.552 \pm 0.017$ (статичният модел печели с ~ 24 комбинирани СГ). Всяко отделно начално число е в съответствие със знака на ефекта, така че двустранната констатация от §10 представлява измерен резултат, а не единична реализация.

3.6 12. Ограничения

Класирани по степента, в която **квалифицират** заключенията:

1. **Детекторът за точка на промяна е прекалено чувствителен (§10).** Наблюдава се около едно фалшиво нулиране на всеки 330 раздаване в стационарен режим - съществен недостатък, произтичащ от наивния детектор и дизайна с твърдо нулиране, който

е причината детекторът за точка на промяна да губи в Ледюк. Това представлява най-ясно изразената разлика в качеството и е пряк стимул за бъдещи изследвания, но не и непреодолима пречка.

2. **Експлоатацията на съгласуван модел не се измерва по дизайн (§7).** Изключването ѝ прави онлайн мачовете управляеми, но сравнението на експлоатацията е ограничено само до базиран на типове подход срещу непрекъснат; характеристиките на съгласувания модел се определят чрез възстановяване.
3. **Съгласуваното откриване в Ледюк е отложено** - програмата в последователна форма там е твърде голяма, поради което възстановяването между игри за съгласувания модел разчита на резултатите от Кун.
4. **Добре специфицираното откриване представлява лесен случай.** Всеки истински тип също е кандидат, така че апостериорна вероятност 1.000 е *очаквана*; това валидира механизма, но не и устойчивостта срещу опонент *извън* зададения набор - именно там непрекъснатите и съгласуваните модели трябва да покажат предимствата си (и където непрекъснатият модел видимо се затруднява в Ледюк).
5. **Две малки игри, данни от самообучение.** Кун/Ледюк са точно решими *защото* са изключително малки; ефектите на частичното наблюдение и подбирането на ограничена извадка, които доминират в Ледюк, ще се засилят значително в по-големи игри. Това е контролирано доказателство за концепция, а не твърдение за мащабируемост.

3.7 13. Заключение и насоки за бъдещи изследвания

Заключения. Добрият модел на противника е *необходим, но не и достатъчен* за печеливша и безопасна адаптация. Когато класът на модела съответства на противника, най-добре реагиращият към него достига точния извличаем таван (базиран на типове и в двете игри; непрекъснат в Кун) - реализира се пълната теоретична стойност на моделирането. Но при частична наблюдаемост и ограничени данни (непрекъснат в Ледюк), недообученият модел както оставя пари на масата, така и срещу неексплоатируем противник най-добре реагира на призрак и *губи*. Нестационарността добавя втори ръб: забравянето на остарял модел е полезно само когато остарялостта е активно вредна, а фалшивите нулирания на небрежен детектор могат да струват повече, отколкото спестяват. Във всичките три изследвания се повтаря един и същ принцип: експлоатацията трябва да бъде мащабирана според това колко добре е заслужено прочитането.

Насоки за бъдещи изследвания (всяка от които вече е обоснована с измерено въздействие по-горе):

- **Безопасна (регулирана с КЛ-дивергенция) експлоатация.** Саморазкриването на Наш при непрекъснатия модел (§9) е емпиричното проявление на напрежението

между експлоатацията и безопасността - конкретното предаване към **Стъпка 08** и теза **Принос №2**: ограничаване на отклонението на най-добрия отговор от Наш чрез собственото доверие на модела, така че недообученият модел да не може да създаде пробив.

- **Мащабирано от доверие забравяне вместо твърдо нулиране (§10).** Фактор за забравяне или нулиране, чиято дълбочина се мащабира с доверието на откриването, трябва да доминира над настоящото връщане в безопасен режим.
- **По-добър сигнал за промяна на точката (§10, §12).** Наблюдение на съотношението на правдоподобията за всяка информационна група или многомерен детектор върху няколко поведенчески характеристики биха намалили степента на лъжливи положителни резултати, която в момента потапя промяната на точката в Ледюк.
- **Неправилно специфицирани / извън менюто противници (§12).** Тъй като добре специфицираното откриване е наситено, интересният режим са противниците *не* в менюто (смеси, дрейф, състезателни). Тук последователните модели трябва да се отделят от базираните на типове, а детекторът „никой от моите типове не пасва“ (откриване на типове в отворен свят) се превръща в самостоятелен въпрос - най-малката версия на който Част I (§4.2, §5) вече демонстрира в Кун.
- **Онлайн/инкрементален съгласуван модел (§7).** Топло стартиране на конвексното решаване от предишното прилягане и инкрементално кеширане на ръчните термини биха могли да въведат последователния модел в онлайн цикъл на експлоатация, превръщайки метод само за откриване в използваем експлоататор в реално време.
- **Възстановяване с оглед на подбирането на ограничена извадка (§8).** Недостигът при непрекъснатия Ледюк се дължи основно на рядко посещавани информационни групи; априорните знания, които споделят статистика между свързани информационни групи (йерархично / абстрактно-базиран), са естественото решение и свързват моделирането на противника с литературата за абстракции.

3.8 14. Възпроизвеждане

Част I - експерименти с изследване (от основната директория на хранилището, при активирана `.venv`; всеки отпечатва таблици в стандартния изход и записва фигури в `implementation/step07/exploration/figures/`):

```
python implementation/step07/exploration/behavioral_fingerprints.py # Exp 1
python implementation/step07/exploration/exploitation_opportunity.py # Exp 2 (Nash EV vs B
python implementation/step07/exploration/bayesian_type_detector.py # Exp 3 (5 hidden opp
python implementation/step07/exploration/mixture_recovery.py # Exp 4 (EM, 50/50 &
python implementation/step07/exploration/robustness_sweep.py # §4.3 sweep (500 han
```

Част II - цялостна оценка (от `implementation/step07/implementation/`, при активирана `.venv`; изисква `numpy`, `scipy`, `matplotlib`):

```
python tournament.py --config smoke           # quick Kuhn pass (~3 s)
python tournament.py --config scale           # full run: Kuhn ~2 min, Leduc ~14 min
python compare_openspiel.py                   # OpenSpiel NashConv cross-validation (needs open
```

Резултатите се записват във файлове с разширение `results/*.json`, а графиките - във файлове с разширение `plots/*.png`. Фигурите, възпроизведени в настоящия доклад, са налични в директорията `deliverables/reports/step07/figures/` (фигурите от изследването са запазени под оригиналните си имена, а фигурите от оценката носят префикс `impl_`).

1 Стъпка 08 - Безопасна експлоатация в игри с непълна информация

Игри: Кун покер (3 карти, 2 играчи) и Ледюк Холдем (6 карти, 2 кръга) - най-малките точно решими тестови среди с непълна информация, които използват изцяло повторно стека от Стъпка 07 (двигателя за Кун покер от Стъпка 02 + CFR решаващ, двигателя за Ледюк от Стъпка 03, както и кода за точен най-добър отговор/експлоатируемост и типовия зоопарк на опонентите от Стъпка 07).

Връзка с дисертацията: това е втората половина на **Принос №1 (Рамка за поведенческа адаптация)** и отправната точка за **Принос №2 (Многоагентна безопасна експлоатация)**. Стъпка 07 изгради *сензора* - модел на противника, който превръща наблюдаваните действия в оценка на стратегията; Стъпка 08 изгражда *изпълнителния механизъм*, който превръща тази оценка в печалба **без да става експлоатируем**, и определя точно къде предположенията за игра с нулева сума се включва в гаранциите за безопасност (точният обект на атака в дисертацията).

Обхват на резултатите: всяко число в този доклад е **измерено от реално изпълнение** и прочетено от артефактите от изпълнението под `implementation/step08/implementation/results/`, `.../plots/` и `.../exploration/figures/`. Когато това е възможно, симулираната стойност е оградена от *точно* аналитично сравнение (стойността на играта по Наш равновесие, точната стойност на най-добрия отговор), а не от друга симулация. Две прогнози от фаза 4 бяха **опровергнати** от изпълненията; съгласно работния процес на проекта, те са запазени в първоначалния си вид и приведени в съответствие с действително настъпилото (§7, §10).

Как да се чете този доклад. И двете части следват една и съща дъга: **какво тестваме → как го тестваме → резултати → заключения**. **Част I (§1–§4)** прави компромиса между експлоатация и безопасност видим върху Кун с два малки инициализирани обхвата. **Част II (§5–§13)** оценява цялата система - един двигател за линейно програмиране в последователна форма и пет семейства решаващи за безопасна експлоатация - върху Кун и Ледюк спрямо точни еталони. §14 изброява команди за възпроизвеждане.

2 ЧАСТ I - КОМПРОМИСЪТ, ВИДИМ ВЪРХУ КУН

2.1 1. За какво става дума в тази стъпка

Стратегия в **равновесие на Наш** никога не губи в дългосрочен план срещу *никого*, но и никога не *наказва* слаб опонент - тя играе еднакво както срещу световен шампион, така и срещу

някой, който се отказва всеки път при **залог**. Стъпка 07 показва, че добрият **модел на противника** отключва печалба от 0.1–0.3 на ръка срещу **експлоатируеми опоненти**, но също така и че най-добре реагиращият на несъвършен модел може да създаде **изтичане** в собствена си игра (**непрекъснатият модел загуби** от равновесие на Наш** в Ледюк). **Безопасна експлоатация** е дисциплината, която разрешава това напрежение: насочете се към **експлоатацията** на модела, но ограничете доколко **най-лошият възможен противник** може да ви накаже.

Формално, всеки метод в тази стъпка представлява една и съща **ограничена оптимизация**:

максимизиране на очакваната стойност на героя спрямо модела на противника,
при условие че прагът на безопасност върху най-лошия случай за героя е спазен.

Очакваната стойност е *линейна* спрямо плана за реализация на героя в последователна форма, така че това представлява линейна програма; петте семейства методи се различават единствено по **какъв е прагът на безопасност**:

Метод	Праг на безопасност	Произход
ограничен отговор по Наш (RNR)	настройваем чрез параметър p (Наш при $p=0 \rightarrow$ най-добър отговор при $p=1$)	Johanson 2007
ganzfried	$\geq$ стойността на играта по Наш v^*	Ganzfried & Sandholm 2015
безопасен спрямо прайм	$\geq v^* - \varepsilon$, където $\varepsilon =$ експлоатируемостта на базовата линия	Jeary & Turrini 2023
SES (под-игра)	$\geq$ стойността на плана, наложена <i>локално</i> върху една под-игра чрез приспособление	Liu и др. 2022
безопасност на адаптацията	най-лошият случай $\geq$ най-лошият случай на плана (т.е. не по-експлоатируем от плана)	Ge и др. 2024

Част I изследва *наивното* крайно на това меню - поведенчески синтез на **равновесие на Наш** и **най-добър отговор** - именно за да покаже защо са необходими принципираните LP методи в Част II. Всички числа в Част I са измерени от **инициализирани Кун** игри; **героят** е играч 0, чиято **стойност на играта** в Кун е $-1/18 \approx -0.056$ (така че „експлоатация“ означава надминаване на тази **стойност** срещу даден противник, а абсолютните числа могат да

останат отрицателни срещу стегнат противник).

2.2 2. Експеримент 1 - наивната граница на най-добрия отговор на Наш


Какво тестваме. Ако просто смесите **наш равновесие** и **пълнен най-добър отговор** спрямо слаб противник - $(1-\lambda) \cdot \text{nash} + \lambda \cdot \text{full_br}$ - каква крива на компромис ще се получи между печалбата и собствената ви експлоатируемост?

Как. Обходете λ от 0 (чисто равновесие на Наш) до 1 (чист най-добър отговор) срещу силно експлоатируемия тип `TightPassive` и изчислете, **точно**, печалбата на героя (EV спрямо стегнат-пасивен) и най-лошата загуба (разлика между стойността на играта и най-лошия стойностен случай на героя). Данни: `exploration/figures/pareto_curve_kuhn.json`.

λ (тегло върху пълен най-добър отговор)	печалба (EV спрямо стегнат-пасивен)	най-лошата загуба (експлоатируемост)
0.0 (наш равновесие)	-0.047	0.001
0.3	+0.017	0.133
0.5	+0.060	0.222
0.7	+0.103	0.311
1.0 (пълнен най-добър отговор)	+0.167	0.444

Резултати. Смесената стратегия проследява гладка, монотонна линия: всяко увеличение на печалбата е съпроводено с почти пропорционално нарастване на експлоатируемостта. Пълният най-добър отговор носи най-голяма печалба (+0.167), но е максимално експлоатируем (най-лошата загуба е 0.444 - тоест противник може да свали героя до -0.5); наш равновесието е неексплоатируемо, но не носи допълнителна печалба.

Заклучение. Компромисът е реален и непрекъснат, но равномерното смесване е *груб* инструмент - то мащабира отклонението навсякъде наведнъж. Стойността на LP методите от Част II се състои в това, че те избират *къде* да се отклоняват, постигайки същата печалба при по-ниска експлоатируемост (§7). Тази крива е базовата линия, която те трябва да надминат.



Фигура 1: The naive Nash/best-response blend traces a smooth exploitation-safety frontier on Kuhn: every step toward more profit buys a near-proportional increase in your own worst-case loss.


2.3 3. Експеримент 2 - наивното обхождане на бюджета на RNR (и един флаг)

Какво тестваме. Същото смесване, преформулирано като неформален „ограничен отговор по Наш“ на стъпката: мащабирайте отклонението с p и наблюдавайте как печалбата и експлоатируемостта нарастват. Съществува ли *бюджет* за евтина ранна експлоатация?

Как. Обхождане на $p \in \{0, \dots, 1\}$ срещу стегнат-пасивен; записване на печалбата и експлоатируемостта. Данни: `exploration/figures/rnr_playground_kuhn.json`.

Резултати. Печалбата се покачва плавно от -0.047 (при $p=0$) до $+0.167$ (при $p=1$), а експлоатируемостта нараства синхронно от приблизително 0 до 0.444. Наблюдава се скромнен ранен „бюджет“: първите увеличения на p носят печалба при все още ниска стойност на експлоатируемостта.

Флаг (наивен $\neq$ Canonical RNR). Тази p -смес е описанието от Ден 2 на суровата стъпка и е добър инструмент за интуиция, но тя **не е** Ограниченият отговор по Наш на Йохансон. Canonical RNR решава за *равновесието срещу p -ограничен про-*



Фигура 2: Naive RNR sweep on Kuhn: profit (left axis) and exploitability (right axis) both rise with p . This is the raw step's informal blend - NOT Johanson's canonical RNR, which Part II shows behaves very differently.

тивник - максимин линеен програмен модел, реализиран в Част II. Част II (§7) показва, че двете се държат **напълно различно** на Кун: каноничната версия е изненадващ обрат, а не плавна. Ние ги запазваме и двете и ги обозначаваме, вместо да ги смесваме.

Заклучение. Интуицията за „бюджет“ се потвърждава при наивната смеска, но Част II показва, че принципният алгоритъм в малка игра се държи по различен начин - конкретен пример защо интуитивното обхождане не бива да се приема за самия алгоритъм, който то илюстрира.

2.4 4. Какво установява Първа част

1. **Компромисът между експлоатация и безопасност представлява реална, измерима зависимост** (Експеримент 1): по-голяма печалба води до по-висока собствена експлоатируемост, почти пропорционално, при наивната смеска.

2. **Пълният най-добър отговор е рисков** - той е максимално изгоден спрямо модела, но същевременно максимално експлоатируем (най-лошият случай -0.5 в Кун), което е основната причина да бъде въведен праг на безопасност.
3. **Интуитивното обхождане не е самият алгоритъм** (Експеримент 2): наивната смеска изглежда гладка, но Canonical RNR, който тя илюстрира, не е (§7). Част II заменя грубата смеска с LP методи, които разпределят бюджета за експлоатируемост *там, където осигуряват най-голяма печалба*.

3 ЧАСТ II - ПЪЛНА ОЦЕНКА НА СИСТЕМАТА ВЪРХУ КУН И ЛЕ-ДЮК

3.1 5. Какво тестваме и как

Част II оценява пълната система за безопасна експлоатация - **един двигател за линейно програмиране в последователна форма и пет семейства решавачи**, изградени върху него - и на двете игри, спрямо точни аналитични критерии.

Един двигател. HeroTreeplex изброява последователната форма за реализация на героя (повторно използвайки treeplex от Стъпка 07), превръща „очаквана стойност срещу постоянен противник“ в линейна цел с $\cdot x$ и налага прага на безопасност чрез **генериране на ограничения (цикъл с двоен предсказвач / равнини на отсичане)**: решава ЛП $\rightarrow$ прочита стратегията на героя $\rightarrow$ извиква **точния най-добър отговор** от Стъпка 07 като противник в най-лошия случай $\rightarrow$ ако най-лошият случай е под прага, добавя линейното сечение и преизчислява. Петте семейства се различават единствено по прага (§1). Това означава, че една валидирана примитивна операция (точният най-добър отговор от Стъпка 07) захранва както целта, така и всяка проверка за безопасност.

Точни критерии. И двете игри са достатъчно малки, за да бъдат решавани напълно, така че докладваната печалба и най-лошият случай на всеки решавач се изчисляват върху пълното дърво - без извадка. Двата опорни пункта са **стойността на играта по Наш** (v^* - безопасната базова линия) и **точният пълен най-добър отговор** (таванът на експлоатацията). Безопасният метод се намира между тях; несигурният има най-лошия случай под v^* .

Методите (идентификатори като низове, както се появяват в таблиците с резултати): `nash` (базова линия, без адаптация), `full_br` (максимизиране на EV спрямо модела, без безопасност), `rnr_0.5` (Canonical RNR при $p=0.5$), `ganzfried` (праг = v^*), `prime_safe` (праг = $v^* - \epsilon$), `adaptation` (праг = най-лошият случай на плана), `ses_subgame` (подпомагащ под-игра; при Кун под-играта е цялата игра, така че съвпада с решаване чрез адаптация).

Трите изследвания.

1. **Таблица „Точен метод × тип противник“** - за всеки тип противник се решава всеки метод срещу *перфектен* модел на този тип и се отчита експлоатационната EV (печалба), най-лошият стойностен случай (безопасност) и дали най-лошият случай покрива долната граница на Наш.
2. **Ефективна граница** - Canonical RNR, обхващащ p , наивната смеска и работните точки на Ganzfried / безопасен спрямо прайм / адаптация, всички върху един график „експлоатация срещу експлоатируемост“.
3. **Обучаваща атака (онлайн)** - измамен противник примама със слаб стил, след което разкрива силен; модел от Стъпка 7 подава на всеки решаващ по k раздавания; проследяваме осъществената печалба и броя на нарушенията на безопасността.

Конфигурации и времена за изпълнение (измерени). Кун smoke (30,000 CFR итерации): **1.4 s**. Кун scale (200,000 CFR итерации, добавя AlwaysBet/AlwaysPass/ses_subgame, обучаваща атака върху 5 семена × 20,000 раздавания): **10.3 s**. Ледюк bounded_scale (човешки добавена конфигурация: лимит от 40 итерации за генериране на ограничения, leduc_tol = 0.01, SES върху под-играта „поп на флопа“): **минути** (индивидуални клетки на SES 10–79 s). Всичко е ограничено от CPU / LP - CFR, най-добър отговор за цялото дърво и малки линейни програми SciPy HiGHS - така че GPU е без значение, както беше предвидено. Измерени стойности на игрите: Кун $v^* = -0.0556$ ($\approx -1/18$ ✓), Ледюк $v^* = -0.0862$.

Не е уловено. Не са запазени журнал за преминати и непреминати тестове от validate.py и артефакт за кръстосана проверка на OpenSpiel от тези изпълнения, така че тези конкретни изходни данни на рамката не се докладват; точните таблици по-долу потвърждават повечето цели за валидиране директно (§11).

3.2 6. Подробната таблица метод × опонент (Кун)


Основният резултат е представен чрез решаване на всеки метод срещу перфектен модел на всеки опонент, като се оценяват печалбата (EV) и безопасността (най-лошият случай), при долна граница на Наш $v^* = -0.056$. Данните са извлечени от файла results/kuhn_scale.json.

Опонентметрика	nash	full_br	rnr_0.5	ganzfried	prime_safe	adaptation	ses_subgame
Стегнат-EV	-0.047	+0.167	-0.044	-0.044	-0.040	-0.040	-0.040
пасивен							

Опонент	метрика	nash	full_br	rnrr_0.5	ganzfried	prime_safe	adaptation	ses_subgame
	най-лошият случай	-0.056	-0.500	-0.056	-0.056	-0.063	-0.063	-0.063
Свободен	EV	+0.118	+0.333	+0.278	+0.131	+0.151	+0.151	+0.151
агресивен								
	най-лошият случай	-0.056	-0.167	-0.111	-0.056	-0.063	-0.063	-0.063
AlwaysBe	EV	+0.113	+0.333	+0.333	+0.115	+0.131	+0.131	+0.131
	най-лошият случай	-0.056	-0.167	-0.167	-0.056	-0.063	-0.063	-0.063
AlwaysPass	EV	+0.146	+0.975	+0.975	+0.222	+0.266	+0.266	+0.266
(най-експлоатируем)								
	най-лошият случай	-0.056	-0.500	-0.333	-0.056	-0.063	-0.063	-0.063
Наш	EV	-0.056	-0.055	-0.056	-0.056	-0.055	-0.055	-0.055
(контрол)								
	най-лошият случай	-0.056	-0.333	-0.056	-0.056	-0.063	-0.063	-0.063

Резултатите - три ключови извода.

1. **full_br** е поучителната история. Той винаги печели най-много срещу фиксиран модел (до **+0.975** срещу AlwaysPass), но неговият най-лош случай се срива до **-0.5** - противник може да го накаже катастрофално. Това е опасността, която цялата стъпка съществува, за да предотврати.
2. **ganzfried** е безопасната и печелившата златна среда. Срещу всеки противник него-



Фигура 3: Methods vs TightPassive (Kuhn): green = EV vs the opponent, red = worst-case value, dashed = the Nash floor. Only full_br's worst-case (red) plunges far below the floor; every other method hugs it.

вият най-лош случай остава на долната граница на Наш (безопасен в рамките на $1e-3$) и той надминава собствената равновесна стойност на Наш при всеки експлоатируем тип - най-впечатляващо **+0.222 срещу +0.146 на Наш** срещу AlwaysPass и +0.131 срещу +0.118 срещу LooseAggressive. Това е централният валидиран резултат от стъпката: можете да експлоатирате смислено, като същевременно доказуемо никога не падате под равновесната стойност.

3. **rnr_0.5 е безопасен само при леки течения.** Срещу TightPassive той е безопасен, но срещу силно експлоатируемите AlwaysPass/AlwaysBet той вече е *преминал* към пълен най-добър отговор (равновесна стойност идентична с тази на full_br, най-лош случай -0.33 / -0.17, небезопасен). RNR преходът е **зависим от противника** - един глобален p не е настройка за безопасност (§7).

prime_safe / adaptation / ses_subgame съвпадат при Кун (всички са насочени към една и съща ϵ -коригирана / план за долна граница, а SES под-играта на Кун е цялата игра). Те имат най-лошият случай $-0.063 = v^* - 0.008$ и са маркирани като “небезопасни” *единствено* защото флагът се сравнява с v^* , докато по замисъл те легитимно се насочват към по-ниска долна граница (§8).

Бележка относно резолюцията на измерването. При изпълнението smoke (30,000 CFR итерации) дори политиката на Наш е маркирана като “небезопасна” (най-лошият случай -0.0568 , т.е. 0.0013 под точната v^* , малко над допустимата стойност от $1e-3$) - чисто артефакт на приближението чрез CFR. При scale (200,000 итерации) недостигът на Наш спада до $3e-4$ и той правилно е маркиран като безопасен. Урок за системата: допустимата стойност за безопасния флаг трябва да надвишава собствената грешка на приближението на базовата линия, в противен случай базовата линия ще задейства собствения си тест.

3.3 7. Ефективната граница - и изненадващият обрат


Обхождането на параметъра p на Canonical RNR спрямо стегнат-пасивен, както и наивната смеска и трите работни точки на LP (от results/pareto_kuhn.json):

p	Canonical RNR - EV	Canonical - експлоатируемост	наивна смеска - EV	наивна - експлоатируемост
0.0	-0.044	~ 0.000	-0.047	0.000
0.3	-0.044	~ 0.000	+0.017	0.133
0.6	-0.044	~ 0.000	+0.081	0.266
0.7	+0.167	0.444	+0.103	0.311
1.0	+0.167	0.444	+0.167	0.444

Работни точки: ganzfried (EV -0.044 , експлоатируемост 0.0005); prime_safe / адаптация (EV -0.040 , експлоатируемост 0.0079); измерена стойност на $\varepsilon = 0.0074$.

3.3.1 Предсказване $\leftrightarrow$ реалност: Canonical RNR е изненадващ обрат, а не гладка граница

- **Предсказване (Фаза 4):** “обхватът на RNR е монотонен и Canonical RNR доминира наивната смеска навсякъде.”
- **Какво всъщност се случи:** Canonical RNR представлява **стъпаловидна функция**. За $p \in [0, 0.6]$ тя връща *същата* безопасна стратегия (EV -0.044 , експлоатируемост ≈ 0); при $p \approx 0.7$ тя преминава направо към *пълния* най-добър отговор (EV $+0.167$, експлоатируемост 0.444). **Няма междинни точки.**
- **Защо (проверено разсъждение).** Целевата функция на Canonical RNR $\max_x [p \cdot \text{EV}(\text{model}) + (1-p) \cdot \min_{\sigma'} \text{EV}(x, \sigma')]$ е *линейна* спрямо плана за реализация



Фигура 4: Exploitation-safety frontier (Kuhn). The canonical RNR “curve” is an interpolation between just two achieved clusters (safe corner and full-BR corner); the naive blend traces the smooth line; the LP operating points (stars) sit at the efficient safe corner.

на героя върху *политоп*, така че нейният оптимум е **връх**, който се сменя само когато p премине критично съотношение. Политопът на стратегиите на Кун е малък (малко върхове), така че преходът е единичен скок. Гладката граница на RNR на Йохансон е явление в големи игри / пристрастено от данни (много върхове или p за всеки информационен набор); тя не се появява в толкова малка игра. **Наивната смеска** проследява гладка линия - именно защото интерполира две фиксирани стратегии - но е доминирана в безопасния ъгъл (при експлоатируемост ≈ 0 LP методите достигат EV -0.044 срещу -0.047 на смеската) и купува печалбата си във вътрешността с голям разход за експлоатируемост.

- **Изводът остава, усъвършенствен.** “Изберете *къде* да се отклоните, а не *колко* равномерно” все още е валидно - Ганцфрид се намира в ефективния безопасен ъгъл и наивната смеска е доминирана там. Но *механизмът* (“гладка настройка на RNR”) е артефакт на

големите игри; в Кун честната картина е дискретен преход от безопасен връх $\rightarrow$ BR-връх, чийто праг се движи според това колко експлоатируем е противникът (§6: rng_0.5 вече е при пълен BR срещу AlwaysPass). Именно затова Ганцфрид - който ограничава стойността, а не p - е по-добрият примитив.

3.4 8. Безопасен спрямо прайм / адаптация и измереният ϵ -бюджет


Безопасен спрямо прайм и адаптация понижават прага на безопасност от v^* до $v^* - \epsilon$, където ϵ е собствената експлоатируемост на базовата линия, измерена чрез **преждевременно прекратен CFR-прогон** (никога измислена). Прогонът измерва $\epsilon = 0.0074$, а най-лошият случай при безопасен спрямо прайм/адаптация е $-0.063 = v^* - 0.0079$ срещу всеки противник - съответствайки на ϵ -коригирания праг до закръгляне. Изразходвайки този бюджет, те печелят малко повече от ганцфрид: **+0.266 срещу +0.222** срещу AlwaysPass, +0.151 срещу +0.131 срещу LooseAggressive (§6). Те са маркирани като „небезопасни“ в таблицата само защото флагът се отнася до v^* ; спрямо собствения им ϵ -праг те са безопасни по конструкция. Безопасен спрямо прайм и адаптация съвпадат тук, защото за тази базова линия $v^* - \epsilon = \text{worst_case_value}(\text{blueprint})$ - двата прага са равни (факт, който фазата на четене маркира, сега потвърден от прогона, а не предположен).

Заклучение. Механизмът „безопасен спрямо прайм“ функционира точно според замисъла си: несъвършена (експлоатируема) базова линия се *измерва* коректно и прагът на безопасност се понижава именно с тази стойност - превръщайки гаранцията на ганцфрид „изисква се перфектно наш равновесие“ в такава, приложима към приблизителните базови линии, каквито всяка реална система неизбежно притежава.

3.5 9. Обучаващата атака - защо осъществената печалба е грешната гледна точка

Какво тестваме. Измамен противник използва слабата примамка TightPassive в първите 10,000 раздавания, след което преминава към силното „разкриване“ Nash за още 10,000; непрекъснат модел от стъпка-7 подава на всеки решавач по 500 раздавания (5 семена). Осигурява ли прагът на безопасност защита на безопасните методи, когато противникът промени поведението си? Данните са от `results/kuhn_scale.json`.

метод	средна стойност/ръка (всички)	средна стойност/ръка (след превключването)	брой нарушения на безопасността / начално число
full_br	+0.051	-0.061	40, 40, 40, 40, 40
ganzfried	-0.048	-0.055	0, 0, 0, 0, 0
адаптация	-0.046	-0.055	40, 40, 40, 40, 40
наш равновесие	-0.051	-0.061	0, 0, 0, 0, 0



Фигура 5: Teaching attack (Kuhn), cumulative profit. full_br (blue) climbs on the bait to $\approx +1700$, then only drifts down after the switch - it ends far ahead because a Nash “revealer” claws back only $\approx$ the game value per hand. The safe methods refuse the bait and pay the P0 tax throughout.

3.5.1 Прогноза $\leftrightarrow$ реалност: разкриващ противник в наш равновесие се оказва недостатъчно наказателен спрямо full_br

- **Прогноза (Фаза 4):** „средната стойност на безопасните методи след превключването остава близо до базовата; тази на full_br е ясно по-лоша; брой нарушения на безопасността = 0 за безопасните методи, > 0 за full_br.“
- **Какво всъщност се случи.** Половината с брой нарушения на безопасността се потвърди **напълно**: full_br наруши долната граница на Наш при 40/40 пренастройки, ganzfried при 0/40. Но скоростта на full_br след превключването (-0.061) е само

незначително по-лоша от стойността на играта (-0.056), и той завършва с **огромна нетна печалба** общо ($+0.051$ /ръка) - защото противникът „разкриване“ е *Наш*, който печели обратно само $\approx$ стойността на играта на ръка, така че вятърната печалба от фазата с примамката никога не се възстановява в рамките на 10,000 ръце.

- **Защо (проверено разсъждение).** Най-лошият случай за една стратегия се реализира от противник, който *реагира най-добре на нея* (това е причината `full_br` да стигне до -0.5 в §6). Стационарното разкриване на Нашово равновесие **не е** този противник, така че експериментът с онлайн осъществена печалба никога не задейства риска, който излага точната колона на най-лошия случай. Следователно измерването на обучаващата атака чрез печалба спрямо Нэш *подценява* опасността.
- **Коригиран извод.** Честният разграничителен сигнал тук е **точният най-лош случай / брой нарушения на безопасността** (`full_br 40, ganzfried 0`), а не осъществената печалба. За да накаже `full_br` в печалбата, разкриването трябва да бъде **адаптивен контраексплойтър** (най-добър отговор на остарелия модел на експлоатация), а не фиксиран Наш. Това е конкретното усъвършенстване за следващото изпълнение (§13).
- **Нюанс в дизайна, а не грешка.** `adaptation` показва 40 нарушения, докато `nash` показва 0 (в мащаб): адаптацията умишлено се насочва към долна граница *под* v^* (§8), така че използваната стратегия задейства брояча, рефериран към v^* , при всяка пренастройка - по дизайн. Нулата на Наш (в мащаб) потвърждава, че 10-те „нарушения“ от тестовото изпълнение бяха артефактът на `cFR-resolution` от §6.

3.6 10. Ледюк - основният извод: глобалната безопасна експлоатация не сходява, но SES сходява

Изпълнението в **Ледюк** е конфигурацията с човешко разширение **bounded_scale**: **лимит на итерациите от 40** за цикъла на генериране на ограничения, `leduc_tol = 0.01` и подиграта на SES, зададена на крал-флоп (`leduc_flop_rank(King)` - експлоатация само след като се появи крал на борда). Всяка клетка записва дали решаването е **сходимо** или е достигнало лимита (**capped**). От `results/leduc_bounded_scale.json`; долна граница на Наш $v^* = -0.086$.

Опонент	метрика	nash	<code>full_br</code>	ses_subgame	<code>ganzfried</code>	<code>prime_safe</code>	<code>adaptation</code>
Камък	EV	+0.201	+0.937	+0.247	+0.624	+0.635	+0.635
	най-	-0.089	-1.633	-0.130	-0.838	-0.744	-0.744
	лошият случай						

Опонент	метрика	nash	full_br	ses_subgame	ganzfried	prime_safe	adaptation
	сходим?	✓	✓	✓ (194 итера- ции)	✗ capped	✗ capped	✗ capped
Маниак	EV	+0.438	+2.177	+0.682	+1.806	+1.842	+1.842
	най- лошият случай	-0.089	-1.100	-0.130	-0.638	-0.657	-0.657
	сходим?	✓	✓	✓ (211 итера- ции)	✗ capped	✗ capped	✗ capped
LoosePassive	EV	+0.449	+1.405	+0.559	+1.306	+1.309	+1.309
	най- лошият случай	-0.089	-4.200	-0.133	-1.239	-1.334	-1.334
	сходим?	✓	✓	✗ (400 итера- ции)	✗ capped	✗ capped	✗ capped
CallingStation	EV	+0.559	+1.464	+0.663	+1.342	+1.363	+1.363
	най- лошият случай	-0.089	-1.000	-0.130	-0.915	-0.686	-0.686
	сходим?	✓	✓	✓ (350 итера- ции)	✗ capped	✗ capped	✗ capped
Наш равно- весие (конт- роль)	EV	-0.086	-0.083	-0.091	-0.083	-0.083	-0.083
	най- лошият случай	-0.089	-0.842	-0.129	-0.376	-0.325	-0.325

3.6.1 Предсказване ↔ реалност: глобалната безопасност не се мащабира до Ледюк, както е предвидено

- **Предсказване (Фаза 4):** *„Ganzfried: най-лошият случай $\geq v^*$ в рамките на толеранс (безопасно).”* И точка №1 от README файла за имплементацията, която вероятно ще се счупи: *„сходимост на генерирането на ограничения + кондициониране на линейното програмиране.”*
- **Какво всъщност се случи.** На Ледюк **глобалните** решаващи методи (ganzfried, prime_safe, adaptation, rnr_0.5) **всички достигнаха лимита от 40 итерации, без да сходяват**, оставяйки стойности за най-лошия случай от **-0.64 до -1.33** (нарушения на безопасността от 0.55–1.25) - грубо небезопасни. Резултатът, валидиран в Кун „Ganzfried е безопасен“, **не се пренесе** към Ледюк при практически брой итерации.
- **Защо (проверено разсъждение).** Цикълът с равнини на отсичане добавя по едно ограничение за най-добър отговор на съперника на всяка итерация; при по-голямото дърво на Ледюк множеството от релевантни чисти най-добри отговори е голямо, така че 40 ограничения са далеч недостатъчни, за да фиксират истинския най-лош случай, и главният проблем продължава да връща оптимистични, но небезопасни стратегии. Това е точно режимът на отказ, сигнализиран преди изпълнението - сега потвърден с числа.
- **Положителният резултат. Методът на под-играта (SES) сходи** при 3 от 4 експлоатируеми опоненти (194 / 211 / 350 итерации), защото пререшава само под-играта „поп на флопа“, като останалата част от дървото е фиксирана към шаблона - много по-малко линейно програмиране с много по-малък съперников набор. Той извлича реална стойност (**+0.25 до +0.68** спрямо слабите типове, побеждавайки Наш) при най-лош случай ≈ -0.13 , което е **с порядък по-близо до безопасно**, отколкото глобалните методи (-0.13 срещу $-0.64 \dots -1.33$).
- **Честна уговорка относно SES.** Неговата остатъчна експлоатируемост (≈ 0.043) все още надвишава толеранса на Ледюк от 0.01, така че и той е *маркиран като небезопасен*, а при LoosePassive той работи 400 итерации без да сходи. Дали тази остатъчна стойност 0.04 е (а) джаджата, която легитимно се ограничава до вече под- v^* шаблон (най-лошият случай на самия Наш е -0.089 , което е с 0.003 под v^*), (б) артефакт на толеранс за сходимост, или (в) малък пропуск във външното поддървено фиксиране, е основният въпрос за изследване преди цитирането на SES като доказано „безопасен“.
- **Какво означава това.** Това е разграничението между **глобална спрямо локална безопасност** - въведено във фазите на интуиция и четене като теория - което се появява *емпирично* в мащаб, толкова малък, колкото Ледюк. Това е конкретната, измерена мотивация за методи на под-игри в реално време (SES / OX-Search) и за замяна на цикъла с равнини на отсичане с точно еднократно двойствено линейно програмиране. Тестова среда толкова малка се оказа достатъчно голяма, за да разкрие стената при мащабирането.

3.6.2 Втвърдяване на решавача по време на изпълненията

Резултатите от Ледюк съдържаха полета, които кодът от Фаза 4 не излъчваше, така че решавачът беше втвърден по време на изпълнение - съответстващо на очакваното отстраняване на грешки: малък резерв за допустимост върху отсичанията (`_FEAS_SLACK = 5e-4`, така че приблизителна долна граница на Наш, която леко надвишава истинския максимум, не прави главния проблем недопустим), изрично обработване на недопустимост (запазване на последната допустима стратегия), проследяване на `converged / capped / iterations` за всяка клетка и Ледюк Холдем драйвер с `bounded_scale` с крал-флоп SES предикат. Това са точно смекчаващите мерки, към които сочи списъкът „вероятно ще се счупи“ в README файла на имплементацията.

3.7 11. Достоверни ли са резултатите?

Три независими проверки подкрепят числата, с две уговорки.

- **Точните опорни точки възпроизвеждат известната теория.** Измерената стойност на играта Кун е -0.0556 ($\approx -1/18$, известният недостатък на първия играч ✓); стойността на Ледюк е -0.0862 . Срещу нашов противник всеки метод печели $\approx$ стойността на играта и не повече (§6, §10) - както трябва да бъде, тъй като равновесие не може да бъде експлоатирано; когато едно число е съвсем малко над своя таван, това е шум от краен брой проби, а не реално нарушение.
- **Вътрешна съгласуваност на LP двигателя.** Всеки решавач, който трябва да достигне пълната стойност на най-добрия отговор, го прави: `full_br` и постпреходният `rng` достигат точно $+0.167$ (Kuhn TightPassive) и големите стойности на най-добрия отговор за Ледюк, което е възможно само ако векторът на печалбата в последователна форма $s \cdot x$ съвпада с точния най-добър отговор - централното условие за коректност на двигателя.
- **Сходимостта вече е наблюдаема.** Флаговете `converged / capped` (Ледюк) правят единственото място, където методът може да се провали безшумно - несходимост при генериране на ограничения - изрично в изхода, вместо скрито.

Оговорки. (1) Не е запазен журнал за преминати и непреминати тестове от `validate.py` и не е създаден артефакт за кръстосана проверка на OpenSpiel, поради което тези два изхода от системата за тестване остават непотвърдени чрез артефакти тук (може да се повтори изпълнението за потвърждение). (2) Ледюк беше стартиран единствено в конфигурацията `bounded_scale` с ограничен мащаб и брой итерации, така че числата на глобалните решавачи алгоритми за Ледюк отразяват *бюджет*, а не сходно решение - те показват, че методът е бавен/несигурен **в рамките на 40 итерации**, но не и че никога не би могъл да достигне

сигурност при значително по-голям брой итерации.

3.8 12. Ограничения

Класирани по степента, в която **подлагат на съмнение** изводите:

1. **Глобалната безопасна експлоатация не се сближава при Лъодюк (§10).** При ограничение от 40 итерации цикълът с равнини на отсичане оставя Ganzfried/prime-safe/адаптация грубо небезопасни. Това е най-ясната празнина и основният изследователски кукичка - разрешаване чрез точна двойствена линейнопрограмна задача или значително по-голям бюджет, и потвърждаване дали е „бавна“ или „структурно заседнала“.
 2. **sES остатъчна експлоатируемост (§10).** sES се сближава, но стои ≈ 0.04 над толеранса на Лъодюк от 0.01; дали джаджата-както е реализирана е *доказуемо* безопасна или само *приблизително* такава остава неразрешено.
 3. **Обучаващата атака поднаказва (§9).** Стационарното разкриване на равновесието на Наш не задейства най-лошия случай, така че осъществената печалба не успява да отдели безопасните от небезопасните - само броят нарушения го прави. Необходим е адаптивен наказващ, за да се покаже, че един безопасен метод *надминава* full_br при измама.
 4. **Две малки игри; перфектни модели в точната таблица.** Таблиците от §6/§10 решават срещу *перфектен* модел на всеки тип (офлайн случай); онлайн случай с научен модел е само обучаващата атака. Кун/Лъодюк са точно решими *защото* са малки; стената на сходимостта, която се появява при Лъодюк, ще се влоши още повече при увеличаване на мащаба - това е контролирано доказателство за концепция, а не твърдение за скалиране.
 5. **Непотвърдени кръстосани проверки (§11).** validate.py и сравнението с OpenSpiel не бяха уловени като артефакти.
-

3.9 13. Заключение и насоки за бъдещи изследвания

Заключения. Безопасното използване е една идея - *максимизиране на стойността спрямо модела при условие за праг на безопасност* - и върху напълно решима игра то работи точно както теорията казва: **Ганцфрид е безопасен срещу всеки противник, като същевременно надминава равновесната стойност на всеки експлоатируем такъв** (+0.222 спрямо +0.146 срещу AlwaysPass), докато наивният най-добър отговор носи повече печалба, но е катастрофално експлоатируем (най-лошият случай -0.5). Безопасен спрямо прайм/адаптация разши-

рват това към неперфектни базови нива, като изразходват *измерен* ϵ -брой итерации под v^* . Но най-ценният резултат от стъпката е отрицателен и емпиричен: върху игра толкова малка като **Льодюк**, *глобалната* безопасна експлоатация не се сближава в рамките на практически брой итерации, докато *локалният* метод на под-играта (SES) го прави - измерената глобална спрямо локална безопасност. Две прогнози от фаза 4 (гладка граница на RNR; Ганцфрид безопасен при Льодюк) бяха опровергани и примирени; примиренията са по-показателни от това, което биха били самите прогнози.

Насоки за бъдещи изследвания (мотивирани от установените ефекти по-горе):

- **Мащабируема безопасност - централната следваща стъпка (§10).** Заменете цикъла с равнини на сечение с **точния еднократен дуален LP** за най-лошия случай, *или* приемерете **локална / метод на под-играта** безопасност (SES / OX-Search) като мащабируем път. Несходимостта на Ледюк е пряко доказателство в полза на последното.
- **Разрешаване на остатъчната експлоатируемост на джаджата SES (§10).** Определете дали разликата от 0.04 се дължи на ограничаване по план, е артефакт на толерантност или представлява теч на фиксиране - това ще покаже дали методът на под-играта е доказуемо или само приблизително безопасен.
- **Наказваща обучаваща атака (§9).** Заменете разкриването на Наш с адаптивен контраексплойтър, така че осъществената печалба да потвърждава най-лошия случай и да се покаже, че безопасният метод *надминава* `full_br` при измама.
- **Безопасност при n играчи - принос на дисертацията №2.** Всяка гаранция тук се основава на факта за игра за двама с нулева сума, че нашава стратегия осигурява v^* срещу всеки противник; за $N > 2$ няма такъв v^* котва. Разширяването на понятието за безопасност, закотвено в стойност, към многоагентния случай (или намирането на структурна алтернатива, например коалиционна структура) е отвореният проблем на дисертацията, който тази стъпка прави прецизен.
- **Затворете цикъла на валидиране (§11).** Стартирайте и архивирайте `validate.py` и кръстосаната проверка на OpenSpiel; повторете глобалните решаващи програми за Ледюк с голям бюджет / точен дуал, за да различите „бавен“ от „структурно небезопасен“.

3.10 14. Възпроизвеждане

Част I - изследване (от `implementation/step08/exploration/`, `.venv` активна; всяка отпечатва таблици в стандартния изход и записва фигури под `exploration/figures/`):

```
python pareto_curve.py           # Exp 1 - naive Nash/BR frontier
python rnr_playground.py         # Exp 2 - naive RNR p-sweep
python exploitation_safety_playground.py # Nash vs BR vs blend, all metrics
```

```
python naive_exploit_danger.py      # why full BR is dangerous
python subgame_peek.py              # blueprint vs local exploit (Leduc)
```

Част II - цялостна оценка (от `implementation/step08/implementation/`, `.venv` активна; изисква `numpy`, `scipy`, `matplotlib`):

```
python tournament.py --config smoke  # quick Kuhn pass (~1.4 s)
python tournament.py --config scale  # Kuhn full run (~10 s): table + teaching attack
python pareto.py --config scale      # the exploitation-safety frontier
python validate.py                  # PASS/FAIL vs the raw-step targets
python compare_openspiel.py         # OpenSpiel NashConv cross-validation (needs open_sp
# Leduc used a human-added bounded_scale driver (40-iter cap, King-flop SES); see results/
```

Резултатите се записват във файлове с разширение `results/*.JSON`, а графиките - във `plots/*.PNG`. Фигурите, възпроизведени в този доклад, се намират в `deliverables/reports/step08/figures` (фигурите за изследване са под оригиналните си имена; фигурите за оценка имат префикс `impl_`). Пълната проверена консолидация с регистър на прогноза↔реалност е достъпна в `implementation/step08/consolidation/report.md`.

1 Стъпка 9 - Многоагентно обучение с подкрепление: Доклад за експериментите

Тестови среди: четири канонични матрични игри 2×2 (дилемата на затворника, игра „хвърляне на монета“, лов на елен, битка на половете); Кун покер и Ледюк холдем (чрез точния стек от Стъпка 07); собствен двигател за Goofspiel ($K = 3, 4$); две малки кооперативни среди (едностъпковата референтна игра „coopsignal“ и изкачващата се игра claus-Boutilier climbing game); както и Iterated Prisoner’s Dilemma с памет 1. Покер игрите използват повторно двигателя за Кун от Стъпка 02, двигателя за Ледюк от Стъпка 03 и кода за точен най-добър отговор / NashConv от Стъпка 07 изцяло.

Връзка с дисертацията: преминаването от **двуигрови игри с нулева сума** (Стъпки 2–8) към **многоагентно обучение с подкрепление**. Три ключови момента: **LOLA** като *динамично моделиране на противника* (Принос №1); **PSRO** като *методология за оценяване на популационно равнище* (Принос №3); и *липсващата $N > 2$ минимакс котва*, при която гаранциите за безопасност, характерни за двуигровите ситуации, се губят (Принос №2).

Обхват на резултатите: всяко число в този доклад е **измерено от реално изпълнение** и прочетено от артефактите от изпълнението под `implementation/step09/implementation/results/{smok` и `implementation/step09/exploration/figures/*.json`. Когато е възможно, симулираните числа са оградени с *точен* аналитичен ориентир (аналитично равновесие на Наш за матричните игри; точен най-добър отговор / NashConv от Стъпка 07 за Кун, Ледюк и Goofspiel). Четири прогнози от фаза 4 бяха **опровергани** от изпълненията; съгласно работния процес на проекта (§0.1) те са запазени в първоначалния си вид и съгласувани с това, което действително се случи (§9).

Как да четете този доклад. И двете части следват една и съща дъга: **какво тестваме → как → резултати → заключение**. **Част I (§1–§4)** показва *защо* многоагентното обучение е трудно, върху матрични игри и самообучение в Кун. **Част II (§5–§8)** оценява структурните корекции - PSRO, CTDE, комуникация, LOLA - спрямо точни мерки. §9 съгласува четирите опровергани прогнози; §10–§12 обхващат доверие, ограничения и насоки; §13 изброява команди за възпроизвеждане.

2 ЧАСТ I - ЗАЩО МНОГОАГЕНТНОТО ОБУЧЕНИЕ Е ТРУДНО

2.1 1. Какво разглеждаме тук

Single-agent RL предполага **стационарна** среда; многоагентното обучение с подкрепление не, тъй като другите агенти *също се учат*, което прави ефективната среда на всеки агент под-

вижна цел (**нестационарност**). Част I показва този проблем чрез най-простите възможни контроли - независими градиентни обучаеми в игри с точно известни равновесия на Наш - преди Част II да представи механизма за неговото преодоляване. Всички данни от Част I произлизат от инициализираните скриптове за изследване (`exploration/figures/*.json`); обучаемите използват **точни градиенти**, така че динамиката не съдържа шум от извадката и въпросът „сходя ли се?“ има еднозначен отговор.

2.2 2. Експеримент 1 - независими обучаващи агенти в четирите матрични игри

Какво изследваме. Достигат ли два независими градиентни обучаеми до аналитичното равновесие на Наш за всяка канонична 2×2 игра и ако не, по какъв начин се провалят?

Как. Двама обучаващи с точен градиент, 4000 стъпки, скорост на обучение 0.1, симетричен старт (0.5, 0.5) и начално число 0. „Сходим“ означава, че последните 100 стъпки са останали почти непроменени. Данни: `exploration/figures/matrix_games_playground.json`.

Игра	p_{final} (ред)	q_{final} (колона)	печалба на реда	сходим?	аналитично равновесие на Наш
дилемата на затворника	0.0025	0.0025	1.008	да	(дефект, дефект), стойност 1
игра „хвърляне на монета“	0.508	0.496	-0.0001	не	смесено $(\frac{1}{2}, \frac{1}{2})$, стойност 0
лов на елен	0.0009	0.0009	2.997	да	(заек, заек), рисково доминиращ, стойност 3
битка на половете	0.0029	0.0014	0.996	да	(футбол, футбол), ред 1 / колона 2

(Тук индекс на действие 0 е Сътрудничество/Елен/Опера; $p \rightarrow 0$ означава, че обучаемият от реда играе *второто* действие - дефект/заек/футбол.)

Резултати. Три от четири сходяват към истинско равновесие на Наш. Дилемата на затворника завършва във взаимно предателство (доминираща стратегия). Ловът на елен се установява върху **рисково доминиращия** вариант (заек, заек), вместо върху доминиращия по печалба (елен, елен) - безопасният ъгъл надделява при градиентна динамика. Битката на половете се координира в едно чисто равновесие. Играта „хвърляне на монета“ **не сходява**: обучаемите остават близо до (0.51, 0.50) на стъпка 4000, но изпълнението отчита *несходим*, а §3 показва, че траекторията продължава да се движи.

Заклучение. Самостоятелното обучение е контролът, който се проваля *умишлено*: то работи там, където играта има доминираща стратегия или достижимо чисто равновесие, и се проваля там, където единственото равновесие е смесено. Този провал е случаят за всичко в Част II.

2.3 3. Експеримент 2 - орбитата на нестационарност (игра „хвърляне на монета“ спрямо Дилемата на затворника)

Какво тестваме. При играта „хвърляне на монета“ намалява ли разстоянието до смесеното равновесие на Наш с времето (сходимост), или остава непроменено (нестационарност)?

Как. Проследяваме разстоянието до нашово равновесие в последователни времеви прозорци и го сравняваме с разстоянието до (дефект, дефект) при дилемата на затворника. Стъпки 6000, $\text{lr } 0.1$, начално число 0, изследване от нецентрична позиция (0.7, 0.3). Данни: `exploration/figures/nonstationarity_demo.json`.

Времеви прозорец	Радиус на игра „хвърляне на монета“	Радиус на дилемата на затворника
1	0.301	0.079
2	0.349	0.010
3	0.391	0.0058
4	0.425	0.0041
5	0.453	0.0032
6	0.476	0.0026

Резултати. Радиусът на дилемата на затворника клони към нула (сходимост). Радиусът на игра „хвърляне на монета“ **нараства**, от 0.30 до 0.48 - траекторията спираловидно се отдалява *навън* към границата, вместо да се установява или да поддържа постоянна орбита.

Заклучение. Нестационарността е структурна: по-голяма изчислителна мощност води до по-силно разминаване, а не до сходимост. (Това противоречи на прогнозата за „постоянна радиус орбита“ във Фаза 4; виж §9.)

2.4 4. Експеримент 3 - самообучение на Кун: средна спрямо последна итерация

Какво изследваме. При самообучение чрез фиктивна игра в реална игра с непълна информация, сходява ли се *средната* стратегия към наш равновесие, дори когато *последната* итерация не го прави?

Как. Фиктивна игра на Кун (всеки играч дава точен най-добър отговор на плъзгащата средна на опонента чрез точния най-добър отговор от Стъпка 07), 200 итерации, измервани през всеки 5. Проследяваме NashConv на средната итерация и NashConv на последната итерация. Данни: `exploration/figures/selfplay_vs_nash.json`.

Итерация	NashConv на средната итерация	NashConv на последната итерация
5	0.240	0.500
50	0.063	0.500
100	0.046	0.500
150	0.038	0.500
200	0.031	0.500

(Стойността на последната итерация се колебае в $\{0.33, 0.50, 0.67, 0.83\}$ през цялото време - тя никога не показва тенденция към намаляване.)

Резултати. Експлоатируемостта на средната итерация намалява монотонно от 0.24 до 0.031, а стойността на последната итерация продължава да осцилира в $[0.33, 0.83]$.

Заклучение. Самообучението се сближава **в средното, а не при последната итерация** - това е конкретната причина за осредняването (CFR, фиктивна игра) и за използването на смес от мета-Наш *популации* в PSRO вместо да се разчита единствено на най-новата стратегия (§5).

3 ЧАСТ II - СТРУКТУРНИТЕ РЕШЕНИЯ

3.1 5. Експеримент 4 - PSRO при различни семейства игри

Какво изследваме. Дали PSRO (популация + мета-Наш + предсказвач за най-добър отговор) свежда експлоатируемостта на мета-Наш сместа до нула и дали това се запазва при игри с различни мащаби?

Как. PSRO с **точния** двигател за най-добър отговор от Стъпка 07. Мета-Наш сместа на опонента върху поведенчески стратегии се свежда до една единствена стратегия на поведение, реализационно еквивалентна (Kuhn's Theorem, пълна памет), така че да може да се приложи двигателят за точен BR. Експлоатируемостта се изчислява като NashConv на мета-сместа в пълната игра. Данни: results/scale_results.json (psro блок); RPS от exploration/figures/psro_peek.json.

Игра	кръг 0	финален (кръг)	присъда
Кун покер	0.917	$\sim 2 \times 10^{-16}$ (6)	конвергира към Machine Zero
матрица (игра „хвърляне на монета“)	2.0	0.0 (2)	конвергира
камък-ножица-хартия	2.0	0.017 (4)	конвергира; смес $\rightarrow$ (0.335, 0.336, 0.329)
Ледюк Холдем	4.75	2.16 (19)	намалява, над целта от 0.5
Goofspiel ($K = 3$)	1.33	0.0 (1)	конвергира
Goofspiel ($K = 4$)	1.50	1.71; колебае се 1.4–2.0	не достига установяване

Резултати. При малките игри (Кун, матрица, RPS, Goofspiel $K = 3$) експлоатируемостта спада до практически нула в рамките на няколко рунда - типично поведение при двоен предсказвач. Ледюк намалява постепенно (4.75 $\rightarrow$ 2.16), но остава значително над 0.5 целта след 20 рунда. Goofspiel $K = 4$ продължава да се колебае между ~ 1.4 и ~ 2.0 , без да достига установяване.

Заклучение. PSRO е потвърден като MARL при малките игри, използвайки същия показател за точна експлоатируемост както в стъпки 2–8. Два резултата - бавната сходимост на **Ледюк** и колебанието на Goofspiel $K = 4$ - не съответстваха на прогнозите и са разгледани в §9.

3.2 6. Експеримент 5 - CTDE: дисперсия на оценителя и изкачваща се игра

Какво тестваме. (а) Притежава ли *централизираният* оценител по-ниска дисперсия на целевата стойност в сравнение с *независимите* оценители? (б) Дава ли централизираният оценител възможност на сътрудническите се обучаеми да избегнат капан на нескоординираност и да превъзхождат независимите обучаващи агенти?

Как. (а) MADDPG върху задачата CoopSignal с една стъпка, обучавайки централизиран $Q(s, \text{joint } a)$ и на агент $Q_i(o_i)$ върху едни и същи данни; сравняване на остатъчната загуба в края. (б) Независими обучаващи агенти, MADDPG и MAPPO върху claus-Boutilier climbing game (оптимум 11, фланкиран от наказания -30 ; безопасен атрактор 5); сравняване на наградата за отборна алчност. Данни: results/scale_results.json (coop блок).

(а) Дисперсия на оценителя (CoopSignal):

Оценител	остатъчна загуба (загуба на стойност)
централизираният $Q(s, \text{joint } a)$	3.17×10^{-11}
независимият $Q_i(o_i)$	0.0766

(б) Награда за алчност в изкачващата се игра:

Обучаващ агент	награда	(оптимум 11, безопасен 5)
независими обучаващи агенти	7.0	-
MADDPG	5.0	-
MAPPO	7.0	-

Резултати. (а) Остатъкът на централизирания оценител е практически нула (той се обуславя от целта и съвместното действие, така че наградата е детерминистична спрямо неговите входове), с порядъци по-нисък от остатъка на независимия оценител 0.077 - твърдението за намаляване на дисперсията на CTDE е потвърдено. (б) **Нито един метод не достига оптимума**; независимите обучаващи агенти и MAPPO достигат 7, а **MADDPG изостава при 5** (безопасният атрактор).

Заклучение. Централизираният оценител е учител с по-ниска дисперсия (потвърдено), но това само по себе си **не** решава координацията при сложно проучване - наказанията -30 възпират агентите да опитат съвместното действие, което достига 11. Недостатъчното представяне на MADDPG спрямо независимите обучаващи агенти конкретно насочва вниманието към неговия дискретен актьор с контрафактична базова линия за преглед (§9, §11).

3.3 7. Експеримент 6 - научена комуникация (commNet)

Какво тестваме. Дали научен съобщителен канал позволява на слушател, който не вижда целта, да надхвърли прага на отгатваемост $1/K$?

Как. CommNet върху CoopSignal ($K = 5$, праг на отгатваемост 0.2), обучен при включена и изключена комуникация; сравняване на награда за отборна алчност. Данни: results/scale_results.json (coop.communication).

Канал	награда за алчност
комуникация върху	0.795
изключена комуникация	0.204

Резултати. При използване на канала наградата е 0.795, значително над прага от 0.2; без него тя е 0.204, точно на прага.

Заклучение. Комуникацията се усвоява от край до край и има реален ефект - говорещият се научава да кодира целта, а слушателят да я декодира. (При конфигурация на дима и двамата бяха 0.24; ефектът изисква обучение до сходимост - §9.)

3.4 8. Експеримент 7 - LOLA в дилемата на затворника (Iterated Prisoner's Dilemma)

Какво тестваме. Дали учащите, които диференцират спрямо следващата стъпка на обучение на опонента, ще сътрудничат там, където наивните учащи дефектират?

Как. IPD с памет 1 и точна затворена форма на възвръщаемостта; наивни градиентни обучаеми срещу LOLA learners (предвиждане чрез вложени крайни разлики). Сравнение на дисконтираната възвръщаемост на стъпка при пълно сътрудничество ≈ 3 и взаимно предателство ≈ 1 . Данни: results/scale_results.json (lola); крива на изследване в exploration/figures/lola_ipd_playground.json.

Обучаеми	възвръщаемост на стъпка
наивни срещу наивни	1.04
LOLA срещу LOLA	2.82

(Изследователският прогон с по-висока степен на предвиждане достига LOLA възвръщаемост от ~ 2.67 – 2.93 в сравнение с наивни ~ 1.06 .)

Резултати. Наивното обучение се сближава до взаимно предателство (1.04); LOLA достига почти пълно сътрудничество (2.82). Вградена проверка потвърждава механизма: при нулева степен на предвиждане градиентът на LOLA съвпада точно с наивния градиент, поради което сътрудничеството се дължи на втория ред.

Заклучение. LOLA преоформя динамиката на учене - *динамично* моделиране на противника - превръщайки дефектьорите в IPD в сътрудници. Това е допълнението с подвижна цел към статичния противник прочит от Стъпка 7 (Принос №1).

3.5 9. Съгласуване на прогноза и реалност

Съгласно работния процес §0.1, противоречащите прогнози от фаза 4 се запазват и съгласуват, а не се редактират мълчаливо. Четири разминавания:

1. **Игра „хвърляне на монета“ орбита (§3).** *Прогнозирано:* чиста орбита с приблизително постоянен радиус около $(\frac{1}{2}, \frac{1}{2})$. *Измерено:* радиусът нарасна $0.30 \rightarrow 0.48$ (външна спирала); софтвакс обучаващият в имплементацията се отклони към ъглите (NashConv ~ 1.8). *Съгласуване:* урокът за несходимост остава валиден и е по-ясен; мисловният модел „енергозапазваща орбита“ беше погрешен, а действителното отклонение на границата представлява по-силен аргумент в полза на методи на осредняване. Това не е грешка - наблюдавани са две различни, но валидни градиентни динамики.
2. **PSRO върху Ледюк (§5).** *Прогнозирано:* експлоатируемост < 0.5 в рамките на 20 итерации. *Измерено:* $4.75 \rightarrow 2.16$ за над 20 рунда - намаляваща, но далеч над 0.5. *Съгласуване:* действително наблюдаваме бавна сходимост, а не бъг - Кун достигна Machine Zero за 6 рунда, но дървото на Ледюк е значително по-голямо и популация от 20 члена с чисти стратегии не може да апроксимира достатъчно добре неговото смесено равновесие на Наш. Поставената цел беше прекалено оптимистична; наблюдаемата низходяща тенденция е правилното поведение. Това се потвърждава от чистата сходимост на Кун/матрица/RPS по същия път в кода.
3. **Goofspiel $K = 4$ (§5).** *Прогнозирано:* неувеличаваща се експлоатируемост. *Измерено:* $K = 3$ сходи към 0; $K = 4$ колебае се в интервала 1.4–2.0. *Съгласуване:* единствената неразрешена аномалия. Документирана, но не поправена (съгласно избрания път). Основните заподозрени за последващо проучване: драйверът на Goofspiel PSRO никога не премахва дублираните най-добри отговорни политики и една популация от чисти стратегии вероятно е твърде слаба, за да апроксимира достатъчно добре смесеното мета-Наш равновесие на по-голямата игра. Отбелязана като открит елемент в кода - **не** представена като валидиран резултат от PSRO.

4. **Изкачваща се игра (§6).** *Прогнозирано:* централизираният оценител достига оптимума 11 и превъзхожда независимите обучаващи агенти. *Измерено:* никой не достигна 11; независимите обучаващи агенти и MAPPO достигнаха 7, а MADDPG изостана на 5. *Съгласуване:* отделното твърдение за дисперсията на оценителя се потвърди (централен остатък $\sim 3 \times 10^{-11}$ срещу 0.077), така че коректното разделение е „CTDE намалява дисперсията на оценителя $\neq$ CTDE решава координацията при риск от прекомерно изследване“. MADDPG, представяйки резултати под тези на независимите обучаващи агенти, допълнително подчертава неговия контрафактичен базов актьор. Изводът остава валиден, но в по-умерен вид.

Забележка по методологията, която се отнася до всички раздели: двата **невронни** ефекта (дисперсия на оценителя §6а; комуникация §7) бяха **невидими при бързата smoke конфигурация** - включена комуникация = изключена комуникация = 0.24, загубите на оценителя почти еднакви (0.0897 срещу 0.0927) - и се проявиха единствено при **scale** конфигурацията. Числата от **scale** конфигурацията са тези, върху които почиват твърденията за **невронните** мрежи.

3.6 10. Достоверност и достатъчност на извадката

- **Игровитеоретичните резултати са ограничени от точни референтни стойности.** Матричните резултати се проверяват спрямо аналитично равновесие на Наш; експлоатируемостта на Kuhn/Ледюк/Goofspiel е *точното* NashConv от Стъпка 07 (не симулация). Резултатът на PSRO за Kuhn, достигащ $\sim 2 \times 10^{-16}$, е нула с машинна точност - най-силното възможно потвърждение.
- **Матричните и PSRO обучаемите са детерминистични** (използват точни градиенти / точен BR двигател + фиксирани начални стойности), така че тези числа са напълно възпроизводими.
- **Невронните резултати са ограничени от началните стойности.** Резултатите за кооперация/комуникация/LOLA са докладвани при една основна начална стойност (мащабът позволява 3); те представляват *качествени неравенства* (централната $<$ е независима; комуникация ВКЛ. $>$ ИЗКЛ.; LOLA $>$ наивна), устойчиви по посока, но чувствителни към началната стойност и версията на библиотеката по големина. Те не трябва да се тълкуват като точни точкови оценки.
- **Не са заснети при това изпълнение:** журналът за преминати и непреминати тестове от `validate.py` и експерименталните PNG файлове (само JSON artifacts са запазени). Посочени като „за затваряне“ в `../figures/README.md`.

3.7 11. Ограничения (подредени според влиянието им върху изводите)

1. **Колебание на Goofspiel $K = 4$ (§5, §9.3)** - необяснима аномалия на PSRO; липсата на премахване на дубликати в BR и популацията от чисти стратегии на драйвера за Goofspiel PSRO са заподозрени. Докато не бъде разрешено, трябва да се разчита само на резултата $K = 3$ за Goofspiel.
2. **MADDPG се представя по-слабо от IL в изкачващата се игра (§6, §9.4)** - сочи към дискретното актьорско обновяване с контрафактична базова линия; резултатите на MADDPG за *награда* следователно не са надеждни, въпреки че резултатът му за *дисперсия на оценител* (отделно, чисто измерване) е.
3. **PSRO за Ледюк не достига целта (§5, §9.2)** - истинско, но означава, че твърдението „PSRO се мащабира“ е демонстрирано само качествено (намаляваща тенденция), а не до ниска експлоатируемост, в по-голямата игра.
4. **Еднократни невронни резултати (§10)** - устойчиви по посока, но несигурни по големина.
5. **Игрови мащаб навсякъде** - матрични игри, едностъпкови кооперативни задачи, миниатюрен покер; нищо оттук не трябва да се екстраполира към дълбоко обучение с подкрепление MARL в голям мащаб. (Политиката за изчислителна мощност правилно ги запази малки; GPU беше без значение.)
6. **Липсващи артефакти от изпълнението** - не е записан журналът от `validate.py` или PNG файловете; фигурите се генерират пост-фактум от JSON.

3.8 12. Заключение и насоки за бъдещи изследвания

Заключения. Стъпката изпълнява своята дъга от край до край: самостоятелното обучение се проваля точно там, където теорията предсказва (игра „хвърляне на монета“), а структурните корекции поправят конкретни проблеми - PSRO намалява експлоатируемостта до (почти) нула в малки игри със същия точен показател като стъпките от теорията на игрите; самостоятелното обучение работи средно, а не при последна итерация; централизираният оценител е учител с почти нулева дисперсия; научената комуникация преодолява прага на отгатваемост; и LOLA превръща дефекторите в IPD сътрудници. Честните отрицателни също са ценни: PSRO достига стена на мащабиране при Ледюк, централизираният оценител сам по себе си не решава координацията при риск от прекомерно изследване и един вариант на PSRO (Goofspiel $K = 4$) се държи неправилно.

Насоки за бъдещи изследвания (всяка от тях е свързана с установен ефект):

- *Приблизителни предсказвачи за мащабиране на PSRO* - 2.16 след 20 рунда в Ледюк (§5) мотивира RL/приблизителен **предсказвач** за най-добър отговор и измерване на гаран-

цията, която той струва.

- *Поправка и повторна валидация на двете маркирани части* - премахване на дубликати в Goofspiel $K = 4$ + популация от смесени стратегии (§9.3); контрафактична базова линия на MADDPG (§9.4).
 - *Динамично + статично моделиране на противника* - комбиниране на предвиждането на LOLA (§8) със статичното четене от Стъпка 7 (Принос №1).
 - *Безопасност без минимакс котва* - пролуката $N > 2$, посочена в резюмето (§2 там): може ли мета-играта на PSRO да осигури използвана безопасна алтернатива там, където не съществува единична стойност на играта (Принос №2)?
-

3.9 13. Възпроизвеждане на резултатите

От `implementation/step09/implementation/` с активирана проектна `.venv`:

```
# validation harness (PASS/FAIL/SKIP against the raw-step targets)
python validate.py
```

```
# full comparison runs -> results/{smoke,scale}_results.json
python tournament.py --config smoke
python tournament.py --config scale
```

```
# plots from a results JSON -> plots/*.png (needs matplotlib)
python plotting.py --config scale
```

От `implementation/step09/exploration/` (фигури от Част I и съответните JSON файлове):

```
python matrix_games_playground.py
python nonstationarity_demo.py
python selfplay_vs_nash.py
python psro_peek.py
python lola_ipd_playground.py
```

Семената са фиксирани в `config.py` (реализация) и в `CONFIG` на всеки сценарий за изследване. Резултатите от матричните игри и PSRO са точно възпроизводими; невронните резултати са посокоустойчиви при различни семена. Всички резултати в настоящия доклад са прочетени от `results/{smoke,scale}_results.json` и `exploration/figures/*.json`.

1 Стъпка 10 - Обучение, базирано на популации и еволюционна теория на игрите: Експериментален доклад

Тестови среди: четири симетрични матрични игри за еволюционно-динамичната половина (Дилемата на затворника, Ястреб–Гълъб, Камък–Ножица–Хартия, Лов на елен); синтетична стълбица на чистото умение; мета-играта на най-добър отговор PSRO върху Ледюк Холдем; и малка **PBT лига** в стил alphaStar от невронни PPO агенти, играещи Ледюк Холдем. Двигателят за Ледюк, точният предсказвач за най-добър отговор и NashConv/експлоатируемост са взети от стъпка 07 (използвани изцяло); PSRO и решавачът на мета-Наш са от стъпка 09. Невронните агенти се обучават с pyTorch, след което се извличат към *таблични* политики, така че **точният** най-добър отговор от стъпка 07 да може да ги оценява.

Връзка с дисертацията: популационното ниво на тезата. Три връзки: **основните експлоатори като автоматизирани моделиращи съперника** (Принос №1, популационният лифт на байесовото четене от стъпка 07); **AlphaStar League като механизъм за безопасна експлоатация на популацията, чиято гаранция липсва** (Принос №2); и **EGTA / мета-Наш като методология за оценяване на популацията** (Принос №3).

Обхват на резултатите: всяко число в този доклад е **измерено от реален прогон** и извлечено от артефактите в `implementation/step10/implementation/results/{smoke,scale}_results.json` и `implementation/step10/exploration/figures/*.json`. Еволюционните резултати са съпоставени с *аналитични* препратки (ESS / наш равновесие за всяка матрична игра), а резултатите от лигата - с **точния** експлоатируемост от стъпка 07. Три прогнози от фаза 4 бяха **опровергани** от прогона в мащаб; съгласно РАБОТЕН ПРОЦЕС §0.1 те се запазват така, както са формулирани и се съгласуват с действително настъпилото (§8).

Как да се чете този доклад. И двете части следват една и съща дъга: **какво тестваме -> как -> резултати -> заключение**. **Част I (§1-§3)** използва еволюционна теория на игрите като *диагностичен обектив*: репликаторна динамика върху решими матрични игри, след това транзитивното/цикличното разлагане „пумпал“. **Част II (§4-§7)** изгражда и оценява **PBT лигата**: динамика на обучението, EGTA/мета-Наш, разнообразие + Elo и директен сблъсък срещу PSRO / самообучение / CFR-Nash. §8 съгласува трите опровергани прогнози; §9-§11 обхващат доверие, ограничения и насоки; §12 изброява командите за възпроизвеждане.

2 ЧАСТ I - ЕВОЛЮЦИОННА ТЕОРИЯ НА ИГРИТЕ КАТО ДИАГНОСТИЧЕН ОБЕКТИВ

2.1 1. Какво разглежда тази стъпка

Стъпки 2–9 разглеждаха равновесията на *фиксирана* игра. Стъпка 10 преминава към по-високо ниво - **популации от стратегии, които се променят във времето**, и поставя два въпроса, на които един агент не може да отговори: *кои стратегии нарастват?* (репликаторна динамика) и *тази игра изобщо ли има „най-добра“ стратегия или само колело от броячи?* (транзитивно/циклично разлагане). Тези два инструмента представляват диагностиката, необходима за обучението, базирано на популации в Част II - защото дали една самообучаваща се популация ще сходява или ще циклира зависи от структурата на играта, а не от скоростта на обучение. Всички еволюционни числа в Част I са детерминистични (фиксирани начални стойности, точна динамика), така че въпросът „сходи ли?“ има еднозначен отговор.

2.2 2. Експеримент 1 - репликаторна динамика върху четири матрични игри

Какво тестваме. Възпроизвеждат ли репликаторната динамика еволюционния *аналитичен* резултат за всяка игра - сходимост към доминираща стратегия, към вътрешно ESS, към басейнозависим чисто ESS или неконвергентна орбита? (Проверка на суровите стъпки, L530–533.)


Как. Дискретна интеграция на репликатора на Ойлер от инициализирано начало от вътрешността; „сходим“ означава, че последната итерация е спряла да се променя; „орбитален радиус“ е разстоянието, което траекторията поддържа от равномерната точка. Аналитично равновесие на Еволюционно стабилни стратегии/Наш служи като референтна стойност. Данни: results/smoke_results.json (блок „replicator“), фазови портрети в exploration/figures/replicator_playground.json.

Игра	Аналитична референция	Начало x_0	Краен x	Сходим?	Орбитален радиус
Дилемата на затворника	Дефектът доминира; уникално ESS (0, 1)	[0.666, 0.334]	[0.0, 1.0]	да	0.707

Игра	Аналитична референ- ция	Начало x_0	Краен x	Сходим?	Орбитален радиус
Ястреб- гълъб	вътрешно ESS $p(\text{Hawk}) =$ $V/C =$ 0.5	[0.548, 0.452]	[0.5, 0.5]	да	0.0
Камък- ножица- хартия	Наш рав- новесие = равномер- но; няма ESS (център)	[0.347, 0.385, 0.268]	[0.299, 0.288, 0.413]	не	0.095
Лов на елен ($x_0 =$ [0.8, 0.2])	две чисто ESS (басейно- зависим)	[0.8, 0.2]	[1.0, 0.0]	да	0.707
Лов на елен ($x_0 =$ [0.2, 0.8])	две чисто ESS (басейно- зависим)	[0.2, 0.8]	[0.0, 1.0]	да	0.707

Резултати. И четирите съвпадат напълно с теорията. Дилемата на затворника се свежда до all-Defect (доминиращата стратегия). Ястреб–гълъб сходява към вътрешната смесена ESS точно при 0.5 (орбитален радиус 0.0 - тя *достига* равновесната точка). Камък–ножица–хартия **не сходява**: тя обикаля около равновесната точка с постоянен радиус (0.095), тъй като вътрешната неподвижна точка е център, а не атрактор. Лов на елен попада върху *различни* чисто ESS в зависимост от началото - $[0.8, 0.2] \rightarrow \text{all-Stag}$, $[0.2, 0.8] \rightarrow \text{all-Hare}$ - двата басейна се проявяват ясно.

Заклучение. Репликаторната динамика представлява непрекъсната идеализация на подбора на популация, а нейните равновесни точки съответстват точно на nash/ESS. Тази, която *не сходява* - RPS - е основната причина за съществуването на Част II: циклична игра няма стабилна популация, поради което самообучаваща се популация в нея ще се върти, вместо да достигне равновесие.



Фигура 1: Replicator phase portraits on the four matrix games: Prisoner's Dilemma collapses to all-Defect, Hawk-Dove converges to the interior 0.5 ESS, Rock-Paper-Scissors orbits the centre without converging, and Stag Hunt splits into two basins (all-Stag or all-Hare) depending on the start. The non-converging RPS orbit is the visceral case for the diversity machinery in Part II.

2.3 3. Експеримент 2 - пумпалът: транзитивна спрямо циклична структура

Какво тестваме. Можем ли да разложим матрицата на печалбата на една игра на **транзитивен** (скала на уменията) компонент и **цикличен** (камък-ножица-хартия) компонент, и дали това разлагане правилно идентифицира чистите случаи и диагностицира реални популации? (проверка на суровите стъпки, L532, L534.)


Как. Комбинаторно-**Hodge** разлагане (на база разлика в рейтингите) на антисиметризираната матрица на печалбата, което отчита транзитивно и циклично съотношение (ортогонални величини, които се събират квадратурно до 1). Допълнително представяме **sVD rank-1** транзитивното съотношение, изчислено чрез суровите стъпки за RPS, с цел да документираме неговия известен провал. Данни: `results/{smoke,scale}_results.json` (блок `spinning_top`), `exploration/figures/game_landscape.json`.

Популация	Транзитивно съотношение (Hodge)	Циклично съотношение (Hodge)	Трицикли	Бележка
Камък- ножица- хартия	0.0	1.0	1	sVD rank-1 неправилно дава 0.707
Чиста скала на уменията	1.0	0.0	0	монотонна сила
Мета-игра PSRO-Ледюк (smoke, 8 рунда)	0.457	0.890	-	предимно циклична

Популация	Транзитивно съотношение (Hodge)	Циклично съотношение (Hodge)	Трицикли	Бележка
Мета-игра PSRO-Ледюк (мащаб, 20 рунда)	0.411	0.912	27	предимно циклична
Моментна снимка на лигата мета-игра (smoke / мащаб)	0.981 / 0.937	-	-	предимно транзитивна

Резултати. Разлагането на Ходж точно определя чистите случаи: RPS е 0.0 транзитивен / 1.0 цикличен (един трицикл), а скалата на уменията е 1.0/0.0. Методът **sVD rank-1**, предложен вместо това от суровите стъпки, неправилно отчита RPS като ≈ 0.707 транзитивен - грешно, тъй като антисиметрично приближение с ранг 1 не може да представи чист цикъл; за диагнозата се използва именно методът на Ходж. Двете *реални* популации се различават рязко: **мета-играта на най-добър отговор PSRO върху Ледюк е предимно циклична** (≈ 0.41 – 0.46 транзитивен, 27 трицикли), докато **моментната снимка на лигата мета-игра е предимно транзитивна** (≈ 0.94 – 0.98).

Заключение. Транзитивното/цикличното съотношение представлява *предварителна диагностика на обучението*. Две популации, извлечени от една и съща игра (Ледюк), имат противоположна структура в зависимост от начина им на формиране (най-добри отговори спрямо моментни снимки на обучението - виж §8.2). Това е именно инструментът, който предсказва дали наивното самообучение/PBT ще сходи или ще циклира, и това е диагностиката, която дисертацията прилага в следващите стъпки.



Фигура 2: Transitive-ratio bar chart: Rock-Paper-Scissors (0.0, purely cyclic), a pure skill ladder (1.0, purely transitive), the PSRO-Ледюк best-response meta-game (~0.41-0.46, mostly cyclic with 27 three-cycles), and the league snapshot meta-game (~0.94-0.98, mostly transitive). Which population you decompose decides whether Ледюк looks like a wheel or a ladder.

3 ЧАСТ II - ЛИГАТА С РВТ

3.1 4. Какво представлява лигата и как се оценява

Втората половина изгражда малка **AlphaStar-style League** върху Ледюк Холдем с три типа агенти - **основни** агенти (продуктът), **основни експлоатъори** (търсят слабости в настоящите основни) и **експлоатъори в лигата** (търсят слабости навсякъде във замразената история) - плюс периодично **замразяване** на снимки в музей и **PFSP** сдвояване (по-често срещане с по-трудни опоненти). Агентите са **невронни РРО мрежи** върху **кодиране на информационно състояние** за Ледюк; РВТ копира най-добрите агенти (експлоатация) и променя тяхната **скорост на обучение / ентропия** (изследване). От решаващо значение е, че всяка мрежа се извлича в **таблична стратегия**, така че **точният** най-добър отговор от Стъпка 07 измерва нейната **експлоатируемост** - същият NashConv показател, използван още от Стъпка 2. Две конфигурации: **smoke** (7 активни агенти, 15 епохи) и **scale** (8 активни агенти, 120 епохи, 48 замразени снимки).

3.2 5. Експеримент 3 - динамика на обучението в лига


Какво тестваме. Намалява ли експлоатируемостта на лигата по време на обучението и отразява ли мета-Наш равновесието на популацията това подобрение? (Проверка на суровите стъпки, L535, L537.)

Как. На всяка епоха се записва минималната експлоатируемост сред основните агенти и експлоатируемостта на текущата мета-Наш смес; също така се записват транзитивното съотношение на мета-играта в моментната снимка на лигата и крайното ЕЛО. Данни: `results/{smoke,scale}_results.json` (блок `league`).

Метрика	Smoke (15 епохи)	Scale (120 епохи)
минимална експлоатируемост при основен отговор	4.67 → 3.04 (монотонно, завършва на мин)	4.73 → мин ≈ 1.21 (еп ~64) → 2.05 (еп 119)
експлоатируемост на мета-Наш равновесие	4.73 → 3.04	5.01 → мин ≈ 1.32 (плато 1.60) → 2.96 (еп 119)
транзитивно съотношение на мета-играта в лигата	0.981	0.937
крайно ело на активните агенти	1176–1211	1198–1210

Резултати. Smoke показва ясно монотонно намаляване и достига своя минимум (3.04) - но 15 епохи са твърде кратки, за да се разкрие какво следва. Мащабът обаче показва друго: експлоатируемостта спада рязко до минимум около епоха 60–65 (**мин-основен** ≈ 1.21 , мета-Наш достига дъно ≈ 1.32 и след това се задържа на ≈ 1.60 плато), а впоследствие **регресира** обратно до ≈ 2.05 (мин-основен) и ≈ 2.96 (мета-Наш) към епоха 119. Разпределението на ЕЛО е стеснено (всички активни агенти са в рамките на ≈ 15 точки), което съответства на популация с близко поведение.

Заклучение. Лигата действително води до силно ранно подобрение - но подобрението **не е монотонно при мащаб**: под постоянен натиск на експлоататорите, активните основни агенти ги преследват и губят позиции спрямо абсолютната експлоатируемост в късния етап на обучението. Най-добрите агенти се улавят като *замразени моментни снимки* по средата на изпълнението. Тази немонотонност е честното заключение от мащабния експеримент и е разгледана в §8.3.



Фигура 3: League exploitability over training (scale, 120 epochs): min-main and meta-Nash exploitability both fall steeply to a minimum near epoch 60 (min-main ~ 1.21 , meta-Nash ~ 1.32) and then regress upward (~ 2.05 / ~ 2.96) by epoch 119. A running league is not a monotonically improving one; the best agents are frozen snapshots from mid-run.

3.3 6. Експеримент 4 - EGTA, мета-Наш и разнообразие

Какво изследваме. (а) Дали мета-Наш равновесието на финалната популация е по-малко експлоатируемо от всеки отделен агент (очакваната стойност за стъпка, L536)? (b) Колко разнообразна е популацията (ефективен размер, поведенческо групиране, покритие на експлоатация - L538)?

Как. Изграждане на емпирична симетрична матрица на печалбата върху всички агенти (живи и замразени), определяне на мета-Наш сместа, свеждането ѝ до една поведенческа стратегия и измерване на нейната точна експлоатируемост спрямо най-добрия индивид. Разнообразие: ефективен размер на популацията (коефициент на участие на мета-Наш тегла), клъстеризация на поведенчески стратегии чрез единична връзка и покритие на експлоатация. Данни: results/{smoke,scale}_results.json (league.egta, league.diversity). Игрова интуиция: exploration/figures/mini_pbt.json.

(а) Мета-Наш спрямо най-добрия индивид:


Конфигурация	експлоатируемост на мета-Наш равновесие	най-добър индивид	мета-Наш $\leq$ най-добър?
Smoke	2.665	2.665	да (всички тегла върху най-добрия агент)
Scale	3.418	1.305	не (разпределение на тегла 0.645+опашка)

(б) Разнообразието:

Метрика	Smoke	Мащаб
агенти / активни (участие)	16 / 1 (1.00)	56 / 3 (1.92)
поведенчески клъстери (праг 0.30)	1 (максимално разстояние между двойки 0.255)	1 (максимално разстояние между двойки 0.484)
покриване на експлоатация	0.625	0.571

Резултати. (а) В smoke мета-Наш равновесието поставя всички тегла върху единствения най-добър агент, така че мета-Наш = най-добър = 2.665 (прогнозата се потвърждава тривиално). При мащаб мета-Наш равновесието разпределя тегла и неговата колапсирала смес е *повече* експлоатируема (3.418), отколкото най-добрият единичен член (1.305) - прогнозата **не се потвърждава** (§8.1). (б) Популацията е само слабо разнообразна: коефициентът на участие нараства от 1 до 1.9, но поведенческото групиране колапсира всичко в един **единствен клъстер** и при двата мащаба (въпреки че максималното разстояние между двойки в популацията при мащаб 0.484 надвишава прага от 0.30 - единичната връзка обединява веригата). Играчката mini-PBT прави механизма ясен: при транзитивен дилемата на затворника разнообразието колапсира до 0; при цикличен RPS то се върти безкрайно (0.07–0.29).

Заклучение. EGTA предоставя експлоатируемост на ниво популация, но се открояват два извода: смесването на поведенчески стратегии чрез мета-Наш равновесието **не** гарантира по-малко експлоатируем резултат (§8.1), а разнообразието в PBT тук е *на ниво тегло*, а не *на ниво поведение* - агентите са почти идентични, така че „популацията“ е по-оскъдна, отколкото размерът ѝ предполага.



Фигура 4: Mini-PBT diversity over generations: on the transitive Prisoner’s Dilemma the population’s strategy diversity collapses to zero (everyone converges to Defect), while on cyclic Rock-Paper-Scissors it churns indefinitely (0.07-0.29) as the population chases the wheel of counters. Game structure, not population size, sets whether diversity survives.

3.4 7. Експеримент 5 - сравнение между лига, PSRO, самообучение и cFR-Nash

Какво тестваме. Как се сравнява лигата с алтернативните методи - точен PSRO, обикновено самообучение и cFR-Nash - по отношение на експлоатируемостта в Ледюк? (проверка на суровите стъпки, ред L539.)


Как. Изпълнете всеки метод до бюджета в неговата конфигурация и отчетете крайната експлоатируемост. Записът за лигата е нейният **най-добър индивид** (най-силната замразена моментна снимка); PSRO използва точния BR предсказвач; cFR-Nash представлява долната граница на Наш. Данни: `results/{smoke,scale}_results.json` (league, baselines).

Метод	Smoke	Scale	Бележка
CFR-Nash (долна граница)	0.033 (2k итерации)	0.0099 (20k итерации)	приблизително равновесие на Наш, целевата долна граница

Метод	Smoke	Scale	Бележка
Лига - най-добър индивид	2.665	1.305	най-силната замразена моментна снимка
PSRO (точен BR двигател)	3.037 (12 рунда)	2.163 (20 рунда)	Стъпка 09's стената на Ледюк
Самообучение	3.140	3.683	обикновен най-добър отговор към последната итерация
Лига - мета-Наш смес	2.665	3.418	виж §8.1

Резултати. В мащаб **най-добрият индивид** на лигата (1.305) е най-силният сред научените методи - по-добър от точния PSRO (2.163) и самообучението (3.683) - въпреки че всички остават далеч над долната граница на CFR-Nash (0.0099). **Мета-Наш сместа** на лигата (3.418), напротив, е *най-слабата*, дори по-лоша от самообучението (§8.1). Самообучението всъщност се *влошава* при преминаване от smoke към scale, което е съгласувано с несходимост при последна итерация.

Заклучение. Лигата се оказва добър производител на силни индивиди - най-добрата ѝ моментна снимка превъзхожда PSRO и самообучението - но сместа не е такава, като нито един от научените методи не достига долната граница на exact-CFR за Ледюк. От една лига следва да се изпрати избран член, а не мета-Наш сместа (§8.1).



Фигура 5: Final Ледюк exploitability by method (scale): CFR-Nash floor ~0.01; the league's best individual (1.31) beats PSRO (2.16) and self-play (3.68); the league's meta-Nash mixture (3.42) is the weakest learned result. Ship a selected member, not the mixture.

3.5 8. Съгласуване на прогноза <-> реалност

Съгласно РАБОТЕН ПРОЦЕС §0.1, опроверганите прогнози от фаза 4 се запазват и се съгласуват, а не се редактират мълчаливо. Три пропуски.

1. **Мета-Наш на лигата $\leq$ най-добър индивид (§6a).** *Предвидено* (суров стъпков изходен контролен списък, L536): мета-Наш е по-малко експлоатируем от всеки отделен агент. *Измерено*: вярно при smoke ($2.665 = 2.665$, всички тегла върху най-добрия агент), **невярно при мащаб** ($3.418 > 1.305$). *Съгласуване*: не е грешка в смесването - идентичният път на кода `mixture_behavioral_policy` даде мета = най-добър при smoke. Мета-Наш минимизира **мета-игрово съжаление** (победа срещу популацията), което е *различна цел* от минимизиране на ****пълната експлоатируемост на играта; и реализационно претеглена смес от поведенчески стратегии може да бъде повече*** експлоатируема от своите компоненти, защото сместа въвежда „разкриващи“ знаци в информационен набор, които най-добрият отговорчик наказва. Урокът се обръща и изостря: оценката на популацията трябва да измерва експлоатируемостта на колапсирала смес директно и, на практика, да изпраща избран член, а не самата смес.
2. **Мета-играта на Ледюк е транзитивна (§3).** *Предвидено*: интуитивният документ

представи покера като скала на уменията. *Измерено*: мета-играта с **най-добри отговори** на PSRO е предимно циклична (≈ 0.41 - 0.46 транзитивна, 27 трицикли), докато мета-играта с **моментни снимки** на лигата е предимно транзитивна (≈ 0.94 - 0.98). *Съгласуване*: не е грешка - популация от най-добри отговори циклира (А побеждава сместа, Б побеждава А, по-късен най-добър отговор побеждава Б; пумпалът на Балдуци), докато популация от моментни снимки на траекториите на обучение формира стълба, защото по-късните моментни снимки са предимно по-силни. Структурата е свойство на *популацията*, а не само на играта; и двете измервания са верни и поучителни.

3. **Експлоатируемостта на лигата намалява монотонно (§5).** *Предвидено*: монотонно намаляване. *Измерено*: при smoke (15 епохи) намалява чисто и завършва в своя минимум (3.04); при мащаб (120 епохи) спада до минимум около епоха 60 (мин-основни ≈ 1.21 , мета-Наш ≈ 1.32 /плато 1.60) и след това **регресира** до ≈ 2.05 / ≈ 2.96 към епоха 119. *Съгласуване*: честна, вероятно реална нестабилност при обучението, видима едва когато обучението е достатъчно дълго - под постоянен натиск на експлоаторите активните основни агенти преследват своите експлоатори и губят позиции в абсолютната експлоатируемост (разместване / частично забравяне). Най-добрите агенти са замразените моментни снимки от средата на изпълнението, което е точно причината най-добрият индивидуален показател (§7) да е силен, докато късните активни агенти не са. Документирано, но не поправено; естественото средство за защита е съхраняване на най-добрия модел / регуляризация на популацията (§11). Това отразява методологичното правило от Стъпка 09: **мащабът разкрива онова, което smoke скрива.**
-

3.6 9. Достоверност и достатъчност на извадката

- **Еволюционните резултати са ограничени от аналитични референции.** Всеки изход на репликатора се проверява спрямо аналитичното равновесие на Еволюционно стабилни стратегии/Наш на играта; съотношенията на пумпала се проверяват спрямо чистите случаи ($RPS = 0.0$, скала на уменията = 1.0). Те са детерминистични и абсолютно възпроизводими.
- **Експлоатируемостта на лигата е *точният* NashConv от Стъпка 07**, а не симулация: всяка невронна стратегия се извлича в таблична стратегия и се оценява чрез точен най-добър отговор, така че въпросът „колко експлоатируем е този агент/смес?“ е проверен на място, а не оценен.
- **Обучението на невронна мрежа е чувствително към seed и използваната библиотека.** Лигата представлява едно PBT изпълнение за всяка конфигурация; *качествените* констатации (ранно подобрене; най-добрият индивид < PSRO < самообучение; късна

регресия при мащаб; мета-Наш > най-добър член при мащаб) са надеждните твърдения, а не величините с трети знак след десетичната запетая.

- **Метриките за разнообразие са чувствителни към прагове.** Резултатът от единствената група зависи от прага на 0.30 единична връзка; той трябва да се чете като „поведенчески сходни“, а не „доказуемо една стратегия“.
-

3.7 10. Ограничения (подредени според степента на влияние върху заключенията)

1. **Регресия при късно обучение при мащаб (§5, §8.3)** - лигата не показва монотонно подобрене; докато съхраняване на най-добрия модел/регуляризация не бъдат добавени и изпълнението не бъде повторено, твърдението „лигата се подобрява“ е валидно единствено за *първата половина* от обучението и за *замразения най-добър*, а не за активните агенти.
 2. **Мета-Наш смес по-експлоатируема от най-добрия член (§6a, §8.1)** - това означава, че оценката на популацията не трябва да представя сместа като силата на лигата; правилният артефакт е избраният член.
 3. **Ниско поведенческо разнообразие (§6b)** - коефициентът на участие 1.9 и единственият поведенчески клъстер показват, че „популацията“ е почти дегенерирала; ползите от разнообразието, които AlphaStar докладва при ~600 агента, не се проявяват в този мащаб.
 4. **Еднократно изпълнение на невронните резултати (§9)** - посоката е надеждна, но величината е несигурна.
 5. **Игрови мащаб през цялото време** - Ледюк и малки матрични игри; нищо оттук не трябва да се екстраполира към дълбоко обучение с подкрепление в лиги с мащаба на AlphaStar.
-

3.8 11. Заключение и насоки за бъдещи изследвания

Заключения. Част I представя диагнозата: репликаторната динамика възпроизвежда всяко аналитично равновесие на Еволюционно стабилни стратегии/Наш (включително неконвергиращата орбита на RPS), а декомпозицията тип пумпал на Ходж ясно разграничава уменията от циклите - показвайки, че *същата* игра (Ледюк) е цикличена като популация на най-добри отговори, но транзитивна като моментна популация. Част II изгражда лигата и я оценява чрез точна експлоатируемост: тя създава силни *индивиди* (най-добър моментен модел 1.305, побеждаващ PSRO 2.163 и самообучение 3.683), но три прогнози се оказаха невер-

ни - мета-Наш сместа е *по-* експлоатируема от най-добрия си член в мащаб, мета-играта на най-добър отговор за Ледюк е *циклична*, а не транзитивна, и експлоатируемостта на лигата *регресира* късно при дълго обучение. Популационният механизъм функционира, но не предоставя гаранция за монотонност или безопасност - което представлява самата празнина в тезата.

Насоки за бъдещи изследвания (всяка е свързана с измерен ефект):

- *Съхраняване на най-добрия модел / регуляризация на популацията* - насочено е директно към късната регресия (§8.3); повторно изпълнение, за да се установи дали празнината в гаранциите е проблем на обучението или на дизайна.
- *Докладване на избрания елемент или метарешавател с регуляризация за разнообразие* - провалът на мета-Наш-смесването (§8.1) мотивира или изпращане на най-добър устойчив на отговор елемент, или промяна на метацелта.
- *Прилагане на транзитивната/циклична диагностика към игрите всеки срещу всеки в стъпка 11* - директно тестване на прогнозата за „голям цикличен компонент“, където се очаква наивният РВТ да проявява цикъл.
- *Формализиране на безопасността на популацията без минимакс котва (Принос №2)* - експлоатационният механизъм е евристичен; §8.1/§8.3 показват, че той не гарантира неексплоатируема популация.

3.9 12. Възпроизвеждане на резултатите

От `implementation/step10/implementation/`, с активирана проектна виртуална среда `.venv`:

```
# validation harness (PASS/FAIL/SKIP against the raw-step targets)
python validate.py
```

```
# full comparison runs -> results/{smoke,scale}_results.json
python tournament.py --config smoke
python tournament.py --config scale
```

```
# plots from a results JSON -> plots/*.png (needs matplotlib)
python plotting.py --config scale
```

От `implementation/step10/exploration/` (фигурите от Част I и съответните JSON файлове):

```
python replicator_playground.py      # replicator phase portraits + JSON
python game_landscape.py              # transitive/cyclic ratios (RPS / skill / PSRO-Leduc)
```

```
python mini_pbt.py           # diversity collapse vs churn  
python psro_population_peek.py # PSRO population dynamics on Leduc
```

Семената са фиксирани в `config.py` (реализация) и в конфигурацията на всеки сценарий за изследване. Еволюционните резултати и тези от пумпал са точно възпроизводими; резултатите от невронната лига са посокоустойчиви при различни семена. Всички числа в този доклад са прочетени от `results/{smoke,scale}_results.json` и `exploration/figures/*.json`.

1 Стъпка 11 - Експериментален доклад за динамичното формиране на коалиции в състезателни игри всеки срещу всеки (Со Лонг Съкър)

Тестова среда: собствен, детерминистичен 4-играчев енджин на **So Long Sucker (SLS)** - играта от 1950 г., проектирана от Наш, Шейпли, Шубик и Хауснер за изучаване на съюзи - имплементиран по формализацията на De Carufel & Jerade (не е клониран от външно хранилище). Върху него стъпката изгражда **детектор на коалиции** (извод за помощ/вредата от поставянето на чипове), **стойност на Шейпли**, адаптирана към чисто състезателна игра, **Coalition-Aware MAPPO** треньор за самообучение и анализ на популация с **eGTA + пумпал**. Декомпозицията с пумпал (Hodge) е преизползвана изцяло от Стъпка 10, а прогнозираното мета-Наш равновесие на метаиграта - от Стъпка 09; детекторът на коалиции преоткрива принципа за моделиране на противника от Стъпка 07 от нулата. Единственият **точен** ориентир е решаващ за енджина **минимакс игра в крайна фаза** за двама играчи, използван за сертифициране.

Връзка с дисертацията: това представлява *границата* на дисертацията. Три ключови момента: **детекторът на коалиции** разширява обхвата на моделирането на противника от „какъв играч е този?“ до „с кого е в съюз?“ (Принос №1); **n-играчната безопасна базова линия** губи своята наша опорна точка - при празно ядро не съществува стабилно разпределение, поради което „безопасна“ трябва да се дефинира чрез поведенчески/популационен подход, основан на π KL, а не като ограничено отклонение от Наш (Принос №2, пропускът, който тази стъпка *оформя*, но не затваря); и **EGTA Meta-Game + стойност на Шейпли** заменя експлоатируемостта, която губи смисъл при наличие на коалиции (Принос №3).

Обхват на резултатите: всяко число в този доклад е **измерено от реално изпълнение** и извлечено от артефактите в `implementation/results/` - `smoke_results.json`, `sweep_smoke.json`, `sweep_scale.json` - както и от дневника за разминаванията между измереното и предсказаното `EXECUTION_NOTES.md` (и двата относително към `implementation/step11/`). Теоретичните игри от теорията на кооперативните игри са оградени с техните *точни* стойности от учебниците (ръкавица, тричленно мнозинство); SLS средата е оградена с *точния* минимакс игра в крайна фаза за двама играчи. Съгласно РАБОТЕН ПРОЦЕС §0.1, противоречащите предсказания са **запазени в първоначалния си вид и съгласувани** с това, което действително се е случило (*съгласуване на предсказание <-> реалност*) - включително реален бъг в двигателя, открит и отстранен по време на изпълнението.

Забележка относно артефакта (прочетете веднъж). `results/scale_results.json` е турнир с **предварителна поправка** (симетрично разпределение 0.525, победа на героя ~0.83, `shapley_higher_coalition:false`, `alpha=0.3`). Той се цитира по-долу **само** като доказателство за грешката в позиция 0 (съгласуването на *грешка*

при разпределение на равни резултати). Неговият наследник с последваща поправка не е бил регенериран, така че авторитетните числа за мащаб-ниво идват от 5-начално число `sweep_scale.json`, а авторитетните единична конфигурация - от `smoke_results.json` с последваща поправка.

Как да четете този доклад. И двете части следват една и съща арка: **какво тестваме -> как -> резултати -> заключение**. **Част I** изгражда и *сертифицира машината*: sLS двигателя спрямо точния краен етап, детектора на коалиции спрямо засаден съюз и стойността на Шейпли спрямо точни кооперативни игри и ръчно зададени позиции в sLS. **Част II** *изучава и анализира коалиции*: Coalition-Aware MAPPO и 5-началното α сканиране, след това EGTA / популационна структура на пумпал. *Съгласуване на предсказание <-> реалност* съгласува противоречивите предсказания (грешката при развързка, мъртвата зона на α , цикличната, но не доминираща структура, компромиса между коалиция и победа); *Достоверност, Ограничения и Закljučения* обхващат доверие, ограничения и насоки; *Възпроизвеждане* изброява командите за възпроизвеждане.

1.1 Част I - МЕХАНИЗМЪТ И НЕГОВИТЕ ТОЧНИ АНКЕРИ

1.2 За какво става дума в тази стъпка

Стъпки 2–10 се опираха на едно нещо: **двуигрална** игра с **точен** предсказвач за най-добър отговор / експлоатируемост, така че „проработи ли?“ се свеждаше до едно число. Стъпка 11 премахва това. С присъединяването на трети играч стават възможни **коалиции** - формирането им, използването им и предателството - а равновесието на Наш става едновременно *не-разрешимо* ($N=4$, всеки срещу всеки) и *стратегически празно* (тъй като игнорира коалиции). Затова стъпката заменя точната оценка с **емпирична** оценка (процент победи, коалиционен резултат, EGTA Cyclic Ratio) и запазва един-единствен точен анкер: аналитично решимата **крайна игра между двама играчи**. Всичко в Част I има за цел да направи по-късните твърдения относно обучението надеждни - сертифициране на средата, сертифициране на детектора и сертифициране на разпределянето на заслугата - преди да бъде поискано от популация да се учи в нея.

1.3 Експеримент 1 - sLS двигател срещу точната крайна игра между двама играчи

Какво тестваме. Дали родният SLS двигател (а) винаги завършва, (б) остава игра с нулева сума и (в) съвпада с **точен минимакс** решавач в крайната игра между двама играчи -

единствената под-игра с установен победител? (Проверка на суровите стъпки, коректност на коалиционна среда.)

Как. Изиграйте 100 произволни игри с четирима играчи и проверете дали завършват, както и дали наградите са с нулева сума. Отделно избройте малки крайни игри между двама играчи и сравнете победителя при оптимална игра на двигателя с резултата от пълно минимакс търсене. Данни: `results/smoke_results.json` (блок `env`).

Проверка	Измерено	Резултат
Произволни игри завършват	100/100 завършени	pass
Наградите са игра с нулева сума	всички са с нулева сума	pass
Двигател срещу минимакс крайна игра	<code>endgame_mismatches: 0</code>	pass

Резултати. В крайната игра няма несъответствия, всички игри завършват, а сумата от всички награди е нула. Двигателят представлява вярна и самосъгласувана реализация на SLS за *собствения си правилник*. Едно уточнение относно достоверността се пренася напред: проверката с минимакс сертифицира двигателя спрямо **неговите собствени** документирани правила (`capturer-plays-next`, `empty-hand skip`, задънена улица с развързка по `most-chips`), а не спрямо буквален препис на De Carufel & Jerade - чиито твърдения остават за проверка при четене (*Достоверност и достатъчност на извадката*). Тази разлика се оказва от значение (съгласуването на *грешката при разпределение на равни резултати*).

Заклучение. Средата е сертифицирана там, където съществува точен отговор. Понеже за $N=4$ няма точен предсказвач, тази двуигрова основа е единствената обективна истина, на която може да се опира останалата част от стъпката - и именно затова *опростяванията* на двигателя, а не решаващът му, са основните заподозрени, когато симетрична постановка по-късно проявява асиметрия.

1.4 Експеримент 2 - детекторът на коалиции срещу засаден съюз


Какво тестваме. Може ли детекторът да *възстанови коалиция*, за която не е бил информиран, единствено въз основа на ходовете? (проверка на суровите стъпки; принос №1.)

Как. Двама играчи са програмирани систематично да си помагат взаимно (като поставят жетони в купчините на другия) и да вредят на останалите (като пленяват). Детекторът изгражда матрици `help` и `harm` от лог `MoveEvent`, формира `net_support` и докладва най-силната двойка. Данни: `results/smoke_results.json` (детектор блок).


Количество	Измерено	Присъда
Засадени съюзници	$\{0.1\}$	-
Най-силна засечена двойка	$\{0.1\}$	вярна
Коалиционен резултат на двойката	10.0	ясно разграничение
Коалиционна матрица	$[0,1]=10.0$; всички междудвойкови записи са 0 или -1	чисто

Резултати. Детекторът възстановява точно засадената коалиция $\{0.1\}$ с отчетливо висок положителен резултат (10.0) за съюзената двойка и нулева или отрицателна нетна подкрепа навсякъде другаде. Съюзът се разчита изцяло от потока с поставяне на жетони - *SLS кодира цялата коалиция в самите ходове* (поставянето на жетон е ръкостискане, а пленяването на купчина - нож), така че няма отделен канал за преговори, който да се моделира.

Заклучение. Моделирането на противника се обобщава естествено от „извеждане на типа/ръката на опонента“ (Стъпка 07) до „извеждане на социалната структура“ (кой е съюзен с кого). Това представлява конкретизация на Принос №1 върху реална игра и е входният сигнал, който обучителят с отчитане на коалиции (*Експеримент 4*) възнаграждава.



Фигура 1: Coalition graph inferred from chip placement: nodes are the four SLS players and directed edges are net support (help minus harm). The planted $\{0.1\}$ alliance shows up as a strong reciprocal help edge, while cross-pair edges are neutral or hostile. The detector reads the alliance straight off the move stream, with no negotiation channel.



Фигура 2: Coalition timeline over a single SLS game: per-turn net support between players as the game unfolds, showing the alliance strengthening as allied chips are placed and the betrayal turn where net support flips. The temporal view is what a learning agent would condition on to time an exploit-then-break.

1.5 Експеримент 3 - Стойност на Шейпли: точни кооперативни игри, след това позиции в SLS

Какво тестваме. (а) Възпроизвежда ли имплементацията на Shapley *точните* стойности от учебниците за кооперативни игри (ръкавица, тричленно мнозинство), включително теста за **ядрото** (стабилност)? (б) Адаптирано към SLS - където „стойност на коалиция“ е предефинирана като *вероятността член на коалицията да спечели* - дава ли **симетрична** позиция **равен принос**, и концентрира ли **асиметрична** позиция със силна двойка приноса върху силната двойка? (Проверка на суровите стъпки; Принос №3.)


Как. Точна стойност на Шейпли чрез изброяване за кооперативни игри; празнота на ядрото чрез осъществимост чрез линейно програмиране. За SLS приносът е стойността на Шейпли на характеристичната функция на вероятността за победа, оценена чрез Монте Карло симулации (shapley_rollouts=300). Данни: results/smoke_results.json (блок shapley).

Случай	Предвиждане	Измерено	Присъда
Стойност на Шейпли за Glove Game	$(2/3, 1/6, 1/6)$	$[0.6667, 0.1667, 0.1667]$	точна
Ядро на Glove Game	непразно, разпределение $(1, 0, 0)$	непразно, разпределение $[1, 0, 0]$	точна
Стойност на Шейпли за тричленно мнозинство	$(1/3, 1/3, 1/3)$	$[0.3333, 0.3333, 0.3333]$	точна
Ядро на тричленно мнозинство	празно	ядро непразно = False	точна
Принос при симетрична позиция в SLS	разпределение < 0.15	$[0.247, 0.257, 0.253, 0.243]$ разпределение 0.013	преминато (след съгласуването на артефакт на развързката)
Асиметрична $[8, 8, 1, 1]$ в SLS	силната двойка доминира	принос на силната двойка 1.0 срещу слабата 0.0; $v(\{0, 1\}) = 1.0$	преминато

Резултати. Кооперативните игри-играчки са възпроизведени до четвъртия знак след десетичната запетая, *включително* двата структурни факта, които имат значение за тезата: яд-

рото на **Glove Game** е **непразно** (съществува стабилно разпределение), докато ядрото на **играта на мнозинството** е **празно** (няма стабилно разпределение - всяка двойка може изгодно да дефектира). За SLS една наистина симетрична позиция дава почти равен принос (**разпределение** 0.013), а една асиметрична позиция със силна двойка предава *целия* принос на силната двойка - стойността на коалиция $\{0.1\}$ е 1.0 . Симетричният резултат е докладван **след** реална поправка на грешка (съгласуването на *артефакт на развързката*): при първото изпълнение разпределението беше 0.54 , което е червен FAIL, оказал се артефакт на развързката в двигателя, а не грешка на **shapley**.

Заключение. Shapley механизмът е надежден сам по себе си - той преминава точните тестове за справедливост и стабилност - и, адаптиран към състезателна игра чрез вероятността за победа, се държи правилно както при симетрични, така и при асиметрични позиции в SLS. **Празното ядро** на играта на мнозинството е ситуацията в SLS в миниатюра: *не съществува стабилно разпределение, поради което коалициите ще се разпаднат*, което е именно причината n -играчен „безопасен“ стил на игра да не може да бъде основан на стабилно равновесие (Принос №2).



Фигура 3: Разпределение на заслуги по Шейпли за позиции в SLS: стойност на Шейпли за всеки играч от характеристичната функция на вероятността за победа. В симетричната позиция заслугата е почти равномерно разпределена между четирите места (разпределение 0.013, след поправката); в асиметричната позиция [8,8,1,1] силната двойка получава цялата заслуга (1.0), а слабата двойка - 0.0. Разпределянето на заслугата отразява реалния принос, след като развръзката в двигателя е безпристрастна.

1.6 Част II - ИЗУЧАВАНЕ НА КОАЛИЦИИТЕ И АНАЛИЗ НА ПОПУЛАЦИЯТА

1.7 Експеримент 4 - Coalition-Aware MAPPO и обхождане на алфа

Какво изследваме. Дали смесването на оскъдната награда за победител с **разложена по Шейпли коалиционна стойност** води до създаването на агенти, които *формират повече коалиции* в сравнение с агентите с оскъдна награда - и, което е от решаващо значение, *при какво тегло на смесване?* (Проверка на суровите стъпки L560: **коалиционното формиране** е основната цел, побеждаването е второстепенна.)

Как. Маскирана, епизодна PPO позиция се обучава чрез самообучение с награда $r = (1 - \alpha) \cdot r_{\text{sparse}} + \alpha \cdot \text{credit}$, където **credit** е или евтиният заместващ показател за критична стойност ргоху, или скъпото разгръщане **контрафактивен Shapley**. **Коалиционният резултат** е средната оценка на детектора за обучената популация. Единичните конфигурационни изпълнения използват стойността по подразбиране $\alpha=0.3$; след това **сдвоено петкратно кръстосано сравнение** (sweep.py) обхожда $\alpha \times \text{credit_mode} \times$

synergy на две нива, като отчита сдвоената разлика $gap = coalition_score(shapley) - coalition_score(sparse)$ с грешкови ленти. Данни: results/smoke_results.json (training), results/sweep_{smoke,scale}.json.

Единична конфигурация (по подразбиране $\alpha=0.3$):

Метод	Коалиционен резултат (smoke)	Процент победи спрямо случайна базова линия (smoke)
Случайна базова линия	0.000	0.250
MAPPO (sparse)	0.00125	0.44
MAPPO + Shapley (тази стъпка)	0.00417	0.41


Петкратно кръстосано сравнение по двойки (** = средна разлика $> 2 \cdot SE$; коалиционен резултат на оскъдната базова линия: smoke 0.0073, мащаб 0.0109):

Ниво	Кредит	α	Синергия	Разлика (shapley - оскъден)	Знач.
мащаб (7/1500)	заместващ показател за критична стойност	0.0	0.3	$+0.0376 \pm 0.0103$	** (~4.4 пъти оскъден)
мащаб	заместващ показател за критична стойност	0.0	0.1	$+0.0305 \pm 0.0130$	**
мащаб	контрафактичен	0.0	-	$+0.0128 \pm 0.0026$	**
мащаб	всякакъв	≥ 0.3	*	$-0.001 \dots -0.004$	- (отрицателна)
smoke (5/400)	заместващ показател за критична стойност	0.0	0.1	$+0.0024 \pm 0.0008$	** (незначителна)

Ниво	Кредит	alpha	Синергия	Разлика (shapley - оскъден)	Знач.
smoke	всякакъв	≥ 0.3	*	$\sim 0 \dots -0.003$	-

Резултати. При стойността по подразбиране $\alpha=0.3$, агентът Shapley превъзхожда оскъдната базова линия при smoke ($0.00417 > 0.00125$), но само с малка разлика, а в предварителното единично обхождане на мащаб посоката се обърна (съгласуването в *алфа мъртва зона*). Обхождането премахва неяснотата: **α е доминиращият параметър, а 0.3 попада в мъртва зона.** Коалициите се формират *значимо* само при ниски стойности на α : при $\alpha \approx 0$, заместващ кредитен сигнал с synergy=0.3 дава вдвояна разлика от **$+0.0376 \pm 0.0103$** (~4.4 пъти оскъдната базова линия 0.0109), докато **всички клетки при $\alpha \geq 0.3$ са с отрицателна стойност.** Ефектът *нараства* с размера на играта (разликите при ниска стойност на α за мащаб са около 10 пъти тези за smoke), а **евтини-ят заместващ показател за критична стойност превъзхожда скъпия контрафактичен** ($+0.038$ срещу $+0.013$ при мащаб).

Заклучение. Основният сигнал за дисертацията (суров L560) е **реален и устойчив - в правилния режим.** Решението е „да се придаде голямо тегло на коалиционния кредит“ ($\alpha \approx 0.05-0.1$), а не „да се изчисли по-точен кредит“. И това има цена: чистият коалиционен кредит ($\alpha=0$) намалява процента победи до ~ 0.29 (близо до случайния минимум 0.25), докато $\alpha \geq 0.1$ го поддържа на ~ 0.52 (съгласуването *коалиционно формиране срещу печелене*) - коалиционното формиране се постига за сметка на състезателното представяне, точно както беше формулирано в суровата стъпка.



Фигура 4: Paired coalition-score gap (Shapley minus sparse) across the alpha x credit x synergy sweep, 5 seeds with error bars. The gap is large and significant only in the low-alpha regime (peaking at +0.038 with the proxy credit at alpha=0, ~4.4x the sparse baseline) and goes negative for every alpha>=0.3. The earlier null result came from measuring at alpha=0.3 - the dead zone.

1.8 Експеримент 5 - EGTA и пумпалът: цикличен ли е SLS?


Какво тестваме. Разглеждайки цялостните SLS стратегии като атоми на една мета-игра, дали получената популация е **циклична** (колело от коалиционни жетони, както предсказва Стъпка 10 за игрите всеки срещу всеки) или **транзитивна** (скала на уменията)? (Проверка на суровите стъпки L561.)

Как. Изиграйте всяка двойка стратегии, за да попълните емпирична матрица на печалбата, проектирайте 4-игровия тензор на печалбата към матрица на двустранните противопоставяния (за да могат solve_meta_nash от Стъпка 09 и spinning_top на Ходж от Стъпка 10 все още да се прилагат) и докладвайте транзитивно/циклично отношение. Разложени са два пула: **базовата линия** пул на скалата на уменията и **коалиционен пул** (fixed_ally_1/2/3 + betrayer_1 + random). Данни: results/smoke_results.json (egta), EXECUTION_NOTES.md (проверка 5).

Популация	Транзитивен	Цикличен	Структура
Пул от нива на умения (smoke)	0.9675	0.2529	транзитивно-доминантен
Пул от нива на умения (машаб)	0.951	0.308	транзитивно-доминантен
Коалиционен пул (60 игри/клетка)	-	≈ 0.57	силно цикличен
Коалиционен пул (200 игри/клетка)	-	≈ 0.69	силно цикличен

Резултати. Както и в Стъпка 10, от коя популация се прави разлагането зависи какво ще се наблюдава. Базовият пул от нива на уменията е транзитивно-доминантен (циклично 0.25-0.31), но коалиционният пул повишава цикличното съотношение до **~0.57-0.69** - значителна нетранзитивна компонента, която силно потвърждава *посоката* на суровия L561. Той остава **честно червен** под строгия праг „>50% доминация“ (циклично² все още малко под 0.5; транзитивният компонент е маргинално по-голям, а пулът не беше настроен да премине границата).

Заклучение. Коалиционните стратегии правят SLS *съществено нетранзитивен и почти балансиран*, но не строго циклично-доминантен в този мащаб. Вероятният остатък е, че **двойната проекция на 2-тип игнорира 3-/4-игрови ефекти от коалиция** - въпросът за отвореното моделиране е тензорно-нативна или 3-типна декомпозиция (*съгласуването циклично, но не доминантно, заключения и насоки за бъдещи изследвания*). Резервата от Стъпка 10 се повтаря буквално: начинът, по който изградите популацията, определя дали ще видите колело или стълба.



Фигура 5: Spinning-top transitive/cyclic ratios across SLS populations: the skill-ladder baseline pool is transitive-dominant (cyclic ~0.25-0.31), while the coalition pool (fixed-ally + betrayer strategies) is strongly cyclic (~0.57-0.69). Coalition play injects large non-transitivity, confirming the direction of the Step-10 prediction, though it stays just under strict cyclic dominance.

1.9 Обобщение на валидирането

Средата `validate.py` кодира целите за преминаване/непреминаване на всяка стъпка. След поправката на двигателя за съгласуване, отстраняваща грешката при развързка на равни резултати:

#	Проверка	Резултат	Присъда
1	SLS среда (крайна игра спрямо минимакс / прекратяване / игра с нулева сума)	0 несъответствия, прекратена, игра с нулева сума	PASS
2	Откриване на коалиции (засадена {0.1})	най-силната двойка {0.1}, резултат 10.0	PASS
3	Shapley (играчи + симетрично разпределение + асиметрично)	ръкавица/мнозинство точно; разпределение 0.013; силната двойка доминира	PASS
4	Обучение с отчитане на коалициите (smoke)	shapley 0.004 > sparse 0.001	PASS
5	Пумпал (строго циклична > 50% доминация)	коалиционният пул е циклична ~0.57-0.69, под строг праг	FAIL (честно)

Мрежа: `validate.py --config smoke` = 4/5 PASS. Проверка 5 остава честно отбелязана като неуспешна съгласно правилото за строго доминиране (Стъпка 10 също е изпратена с честно червен FAIL). Машината (среда, детектор, Shapley) е напълно сертифицирана; единственият неуспешен резултат представлява откритие, свързано със структурата на играта, а не грешка в кода.

1.10 Съгласуване на прогнозата с реалността

Съгласно работния процес §0.1, противоречащите на прогнозите резултати се съхраняват и съгласуват, а не се редактират мълчаливо. Четири пропуски - един от които беше истинска грешка, установена чрез съмнение в двигателя преди прогнозата.

1.10.1 Двата червени ПРОВАЛА имаха една и съща първопричина: грешка при развързка на равни резултати при задънена улица, а не редът на първия играч

Прогноза: симетрична позиция дава симетрични резултати (проверка 3 разпределение <0.15 ; проверка 5 вижда циклична коалиционна структура). *Измерено (първо изпълнение):* проверка 3 разпределение 0.54 и проверка 5 транзитивно 0.998 - и двете червени - с монотонно **предимство за играч 0** в три независими скрипта (случайни победители [94,42,33,31]; симетрична стойност на Шейпли [0.593.0.24.0.113.0.053]; същата стратегия с фиксиран съюзник отбелязва 0.493 на място 0 срещу 0.243 на място 1). *Съгласуване:* подозирайки двигателя преди прогнозата (§0.1), диагностиката откри механизма: **~99.5% от случайните игри завършват със задънена улица** (всички живи ръце празни на ~28 хода), така че победителят се решава от `_most_chips` - чиято **развързка по най-нисък индекс** даваше на играч 0 ~2 пъти повече от справедливия му дял (ротацията на началния играч не променяше нищо; пристрастието беше в развързката, а не в реда на ходовете). Решение: **непристрастна случайна развързка при задънена улица** през `sls_game.apply(..., rng=...)` по пътищата на игра/оценка/обучение, като точният минимакс на крайната игра остава детерминистичен (и `verify_endgame_consistency` се превключи към детерминистично разгръщане оптимално срещу оптимално, така че все още да съответства на минимакс дървото). Резултат: симетрично разпределение **0.54** → **0.013** (проверка 3 ПРОВАЛ→УСПЕХ), случайните победители вече са равномерни ([0.251.0.238.0.251.0.260]). Страничен ефект разкри втори артефакт: впечатляващият ~0.87 процент победи на героя *сам по себе си* беше предимството за играч 0 при развързката (героят винаги седеше на място 0); справедливият брой е **~0.41** спрямо долната граница 0.25. Урок: в игра, която почти винаги завършва с почти равен резултат, **правилото за развързка е носещо**, и симетрична *позиция* не е симетричен *резултат*, докато не бъде непристрастна.

1.10.2 „Коалициите не възникват в голям мащаб“ беше опровергано - неправилно зададено тегло на смесване

Прогноза: коалиционният кредит води до повече коалиционно поведение, отколкото оскъдната награда. *Измерено (единична конфигурация):* вярно при `smoke` ($0.0042 > 0.0013$), но **сриващо се/обръщащо се в голям мащаб** при предварителното изпълнение преди поправката - тогава беше разчетено като „заместващият кредитен сигнал е твърде слаб, кога-

то обучението е по-дълго“. *Съгласуване*: петкратното кръстосано сравнение по двойки опровергава това. α е доминиращият параметър и **0.3 попада в мъртвата зона**; коалициите възникват значително **само при ниско α** (при $\alpha \approx 0$, заместващ/synergy=0.3 дава $+0.0376 \pm 0.0103$, ~4.4 пъти повече от оскъдната награда), докато **всяка клетка с $\alpha \geq 0.3$ е отрицателна** (терминът всичко или нищо за оскъдната награда потиска сигнала за коалиция). Две допълнителни изненади: ефектът **нараства с размера на играта** (обратно на наивното тълкуване „положително при smoke / нулево в голям мащаб“, което беше артефакт от задържането на $\alpha=0.3$ и на двете нива) и **евтиният заместващ показател за критична стойност превъзхожда скъпия контрафактичен** ($+0.038$ срещу $+0.013$). Така че първичният сигнал (raw L560) е **реален и стабилен в правилния режим**, а поправката е „да се придаде голяма тежест на коалиционния кредит“, а не „да се изчисли по-точен кредит“. Методологично това отразява стъпки 9-10: **единична конфигурация скрива това, което обхождането с фиксирани начални стойности разкрива**.

1.10.3 Мета-играта на SLS е силно циклична, но не (още) стриктно циклично доминираща

Прогноза (от стъпка 10): коалиционните игри тип „всеки срещу всеки“ имат голям цикличен компонент. *Измерено*: това зависи изцяло от **коя популация** се разлага. Стандартният **пул на уменията** е транзитивно-доминантен (цикличен $0.25/0.31$), но **коалиционен пул** изтласква цикличността до **~0.57–0.69** - голяма нетранзитивна компонента, която силно потвърждава *посоката* на raw L561, като същевременно остава **честно червена** под строгия праг „>50% доминация“ (цикличен² точно под 0.5). *Съгласуване*: не е грешка - същият урок от стъпка 10, че структурата е свойство на *популацията*. Вероятният остатък е, че **двойната проекция с два типа игнорира ефектите от коалиции с три-/четирима играчи** (raw L600) - въпрос на моделиране на ниво консолидация, а не грешка в решаващия алгоритъм.

1.10.4 Социалното поведение се купува с цената на състезателното представяне (истински компромис)

Прогноза (raw L560): формирането на коалиции е основната цел, а победата - второстепенна. *Измерено*: чистият коалиционен кредит ($\alpha=0$) сваля процента победи на героя до **~0.29** (близо до случайния минимум 0.25), докато $\alpha \geq 0.1$ го поддържа на **~0.52**. *Съгласуване*: прогнозата е вярна и вече е количествено определена - не можете да получите социално поведение безплатно; параметърът α е точно този, който прави компромис между състезателното представяне и социалното поведение.

1.11 Достоверност и достатъчност на извадката

- **Точните опорни стойности са реални.** Кооперативните игри-играчки (ръкавица, мнозинство) възпроизвеждат своите учебникови Shapley стойности и резултатите за ядрото (стабилност) с точност до четири десетични знака; sLS двигателят няма **нула** несъответствия спрямо точната 2-игрочова минимакс крайна игра. Те са детерминистични и напълно възпроизводими.
- **Резултатът от детектора представлява точно възстановяване**, а не оценка: засаде-на коалиция $\{0.1\}$ се възстановява точно с добре разграничен резултат $(10.0 \text{ срещу } 0/-1)$.
- **Твърденията за обучението се основават на петкратно кръстосано сравнение по двойки**, а не на едно изпълнение. Значимите клетки (**) имат средни разлики, надвишаващи два пъти тяхната стандартна грешка; *посоките* (ниско α положително, $\alpha \geq 0.3$ отрицателно, прокси $\geq$ контрафактичен, ефектът нараства с мащаба) са надеждните твърдения, а не величините до третия десетичен знак.
- **Точността на двигателя е постоянното ограничение.** Двигателят е сертифициран спрямо *собствените си* правила, а не спрямо транскрипция на De Carufel & Jerade; грешката при място 0 (съгласуването на *грешката при разпределение на равни резултати*) доказва, че правилото за развързка действително променя резултатите, така че това съгласуване не е козметично.
- **Остарелият `scale_results.json`** е представка-артефакт, използван единствено за демонстрация на съгласуването на *грешката при разпределение на равни резултати*; той не е източник за нито едно твърдение относно мащабните нива.

1.12 Ограничения (подредени според въздействието им върху заключенията)

1. **Вярност към правилата на двигателя спрямо изходния документ (съгласуването на грешка при разпределение на равни резултати, достоверност и достатъчност на извадката)** - грешката при място 0 за развързка и все още червената циклична проверка произлизат от документираните опростявания на двигателя (`_most_chips` развързка, `capturer-plays-next`, `empty-hand skip`). Съгласуването на модела за ред и развързка спрямо De Carufel & Jerade е последващата стъпка с най-висока стойност; именно там се подобряват както коректността, така и цикличният сигнал.
2. **Двойната проекция от 2 типа (съгласуването на циклично, но не доминиращо)** - свеждането на тензора на печалбата за 4 играчи до директни сблъсъци вероятно изхвърля цикличното образуване на коалиции от 3-/4-ма играчи, което е основният заподозрян за цикличния коефициент, който се намира точно под строго доминиране.

3. **α е избор на дизайн, а не настроен в изпратената по подразбиране версия (съгласуването на *алфа мъртва зона*)** - кодът запазва $\alpha=0.3$ (мъртвата зона) с нейния честен пределен резултат; препоръката, базирана на доказателства, за $\alpha \approx 0.05-0.1$, е оставена за човешко решение (§0.1: докладвай, не настройвай).
4. **Общ характер на заместващия кредит (съгласуването на *алфа мъртва зона*)** - евтиният заместител побеждава контрафактичния на *SLS* при ниско α ; дали това важи и за други игри не е тествано.
5. **Играчка мащаб през цялото време** - 4-7 чипа, малки мрежи; нищо оттук не трябва да се екстраполира към големи N-играрови игри.

1.13 Заключение и насоки за бъдещи изследвания

Заключения. Част I удостоверява механизма: sLS двигателят съвпада с точната 2-играрова минимакс игра в крайна фаза (0 несъответствия), детекторът на коалиции възстановява точно засаден съюз ($\{0.1\}$, резултат 10.0), а стойността на Шейпли възпроизвежда точно кооперативните игри-играчки - *включително празното ядро* на играта на мнозинството, което е структурният подпис на нестабилни коалиции. Част II учи и анализира коалиции: Coalition-Aware MAPPO *наистина* произвежда повече коалиционно поведение в сравнение с оскъдна награда - стабилно ($+0.038$, $\sim 4.4x$, 5 семена), но само при **ниско α** , и с измерена конкурентна цена; а мета-играта на sLS е **силно циклична** за коалиционен пул ($\sim 0.57-0.69$), макар и не стриктно циклично доминираща. Две прогнози се провалиха честно и един бър беше открит: „симетричната“ игра скри артефакт на развързката, а твърдението, че „коалициите не възникват в голям мащаб“, се дължеше на неправилно зададено тегло на смесване.

Насоки за бъдещи изследвания (всяка от тях е свързана с установен ефект):

- *Съгласувайте модела за ред и развързка на двигателя спрямо De Carufel & Jerade*, след което проверете отново доминирането на пумпал - съгласуването на *грешка при разпределение на равни резултати* и съгласуването на *циклично, но не доминиращо* вероятно споделят този корен.
- *Приемете $\alpha \approx 0.05-0.1$ като стандартна настройка за обучение на коалиции* - доказателството от обхождането (съгласуването на *алфа мъртва зона*) е оставено като човешко дизайнерско решение.
- *Опитайте 3-/4-играрен EGTA Projection* (не 2-тип сшив), за да видите дали цикличното образуване на коалиции преминава строгата граница от $>50\%$ (съгласуването на *циклично, но не доминиращо*).
- *Формализирайте безопасност при n играчи без Nash/ядро като котва (Принос №2)* - празното ядро (*Експеримент 3*) премахва стабилността, базирана на ядрото, а π KL дава поведенческа базова линия без граница на експлоатируемостта; това е границата на те-

зата, която стъпката очертава, но не затваря.

- *Прегенерирайте остарелия файл `results/scale_results.json`, така че ангажираният турнир в голям мащаб да съответства на обхождането.*
-

1.14 Възпроизвеждане

От `implementation/step11/implementation/` при активирана проектна `.venv`:

```
# validation harness (PASS/FAIL against the raw-step targets)
```

```
python validate.py --config smoke
```

```
# single-config tournament -> results/{smoke,scale}_results.json
```

```
python tournament.py --config smoke
```

```
python tournament.py --config scale
```

```
# the 5-seed paired alpha sweep -> results/sweep_{smoke,scale}.json + plots/sweep_coalition
```

```
python sweep.py --tier smoke
```

```
python sweep.py --tier scale
```

```
# plots from a results JSON -> plots/*.png (needs matplotlib)
```

```
python plotting.py --config scale
```

Семената са фиксирани в `config.py` и в `sweep.py`. Резултатите от средата, детектора и коопериращата игра с теория на игрите са напълно възпроизводими; резултатите от обучението са посочоустойчиви при петте семена. Всички числа в този доклад са извлечени от `results/{smoke_results.json, sweep_smoke.json, sweep_scale.json}` и от дневника за отклонения между измерени и предсказани стойности `EXECUTION_NOTES.md`; префиксът `scale_results.json` е посочен единствено като доказателство за грешката при развързка на място 0 (съгласуването на *грешката при разпределение на равни резултати*).

1 Стъпка 12 - Последователни модели и агенти с голям езиков модел в стратегически ситуации: Доклад от експеримента

Тестова среда: Кун покер (точно Нашово равновесие и точна експлоатируемост от Стъпка 02), с тесен порт към Ледюк Холдем като проверка на сложността.

Сравнявани методи: nash-CFR · поведенческо клониране · Трансформър за вземане на решения · Трансформър за вземане на решения, устойчив на противникови атаки (ARDT) · четири опорни системи за големи езикови модели (извън линия заглушка, gpt-oss-20b, Qwen2.5-7B-Instruct, openThinker3-7B).

Връзка с дисертацията: Принос №1 (поведенческа адаптация), Принос №2 (безопасна експлоатация), Принос №3 (методология за оценяване).

Обхват на резултатите: всички числа са измерени при реални изпълнения (RTX 5090, локални модели чрез LM Studio 0.4.20). Всяка фигура е генерирана от ангажиран JSON файл с резултати.

Забележка относно артефакта (прочетете веднъж). Два резултата бяха **оттеглени по време на сесията** и се появяват тук само като оттегляния: резултат от обучение в контекста с намалена разлика от +1.59 (невъзможно - виж §Прогноза срещу реалност, R5) и резултат за Ледюк Холдем от голям езиков модел от -0.83 жетона/ръка, получен чрез дефектен декодер (R6). Референтният Nash се различава според бюджета на CFR - 0.0162 жетона при 5,000 итерации (сравнителна таблица), 0.0061 при 50,000 (последващи експерименти); и двете стойности са ≈ 0 . Редът с plain-подкана на OpenThinker3 не е сравним с реда му с CoT (34% от вероятностната му маса отива към токени, които не са действия при обикновена подкана).

Как да четете този доклад. Основният набор от резултати отговаря на петте цели за валидиране на суровата стъпка. Последващите експерименти бяха добавени, защото тези пет цели класират методите, без да ги обясняват. Всяко твърдение е свързано с именуван артефакт в `implementation/step12/implementation/`.

1.1 За какво е предназначена тази стъпка

Два посткласически начина за игра на игра. **Моделирането на последователности** преформулира RL като условно предсказване на последователност: подават се тройки (очаквана възвръщаемост до края, състояние, действие) на gPT-style модел и се предсказва следващото **действие**, обусловено от желаната бъдеща възвръщаемост - без функция на стойността, без оператор на Белман, без самообучение. **Абстрактният дървовиден модел на**

решенията добавя минимаксно обуславяне по възвръщаемост, така че стратегията да бъде устойчива спрямо най-лошия случай опонент, вместо да бъде настроена към този, който случайно се е оказал в данните. **агентите с голям езиков модел** изцяло пропускат обучението: на езиковия модел се дават правилата на английски и той играе.


Кун покер е споделената тестова среда, тъй като нейното равновесие на Наш и експлоатируемост могат да бъдат изчислени *точно*, така че всеки метод получава проверен на място резултат, а не просто анекдот. Всички методи са приведени към 12-информационния набор формат на стратегия от Стъпка 02 и се оценяват с една и съща точна метрика.

1.2 Основният резултат от сравнението

Експлоатируемост в жетони (по-ниска стойност означава по-голяма близост до **наш равновесие**); **профил на дим**, извън линия заглушка за редовете с **голям езиков модел**.

Метод	Експлоатируемост			стойностен
	(жетони)	mbb/h	блъф(J)	залог(K)
Nash-CFR (референтен)	0.0162	16.2	0.23	0.68
поведенческо клонирание	0.0550	55.0	0.20	0.68
Абстрактен дървовиден модел на решенията	0.4691	469.1	0.33	0.35
Трансформър за вземане на решения	0.7992	799.2	1.00	0.64
Голям езиков модел (заглушка) × 3 стила на подкана	0.8333	833.3	1.00	1.00

Двата метода, за които става дума в тази стъпка, завършват последни. Обикновеното поведенческо клонирание - най-простата възможна базова линия - се оказва на 0.04 жетона от **наш равновесие** и превъзхожда трансформъра за вземане на решения с условно връщане приблизително 14 пъти. При данни от самообучение, близки до почти равновесие на Наш, поведенческото клонирание просто копира **стратегия**, близка до равновесието на Наш, до-



Фигура 1: Exploitability by method on the exact Kuhn metric - plain behavioural cloning, included only as a contrast baseline, beats both of the methods this step is named after.

като трансформърът за вземане на решения трябва да прекара същата стратегия през канал за условно връщане, който (както е показано по-долу) носи предимно късмет. **Условното връщане тук активно унищожава информация.**

1.2.1 Реални модели

Измерено при температура 0.7 с 24 проби на информационно множество - протоколна точка, която има значение; вижте *протокол за измерване* по-долу.

Бекенд	стил	експл. (жетони)	блъф(J)	стойностен залог(K)	незаконен ход	адапт.
gpt-oss-20b	обикновен	0.2760	0.00	1.00	0%	+0.67
gpt-oss-20b	coT	0.2500	0.08	1.00	1%	+0.79
gpt-oss-20b	теория на игрите	0.3316	0.46	1.00	1%	+0.25
Qwen2.5-7B	обикновен	0.3125	0.00	1.00	0%	+0.00
Qwen2.5-7B	coT	0.3183	0.58	1.00	0%	+0.42

Бекенд	стил	експл. (жетони)	блъф(J)	стойностен залог(K)	незаконен ход	адапт.
Qwen2.5-7B	теория на игрите	0.3032	0.50	1.00	0%	+0.21
openThinker3-7B	соТ (n=12)	0.2882	0.33	1.00	16%	+0.92

7B модел се доближава до 20B модел: Кун възнаграждава прилагането на смесени стратегии с правилната честота, а не знанието или мащаба. Две грешки са универсални - всеки бекенд залага стойност на Попа при 1.00, докато при наш равновесие се смесва при 0.68, и никой не блъфира с Вале под обикновена подкана. Езиковите модели определят правилно *ранга* на ръката, но грешат в *честотите*.

Настройка на разсъжденията в изолирани условия. OpenThinker3-7B е reasoning-SFT върху *същата* Qwen2.5-7B база, така че редовете соТ показват неговия ефект: експлоатируемост $0.318 \rightarrow 0.288$, блъф(J) $0.58 \rightarrow 0.33$ (срещу наш равновесие от 0.23), адаптация $+0.42 \rightarrow +0.92$ - постигнато с **16% честота на незаконни ходове** и **65 пъти повече токени** (~6,500 спрямо ~99 на решение).


1.3 Петте цели за валидиране

validate.py, профил на дим: **3 УСПЕХА / 2 НЕУСПЕХА / 0 ПРОПУСНАТИ** (pyTorch и CUDA бяха активни, така че нищо не беше пропуснато).

#	Цел	Измерено	Присъда
1	DT: по-висока очаквана възвръщаемост до края $\rightarrow$ по-ниска експлоатируемост от по-ниска	high(+2) = 0.6981 срещу low(-2) = 0.6928 жетона	НЕУСПЕХ
2	Действието на DT варира според картата (научава късмета)	корен P(bet) I/Q/K = 1.00/0.03/0.70, разпределение 0.97	УСПЕХ
3	АБДМ < стандартен DT върху същите смесени данни	ARDT 0.5034 срещу DT 0.7212 жетона	УСПЕХ

#	Цел	Измерено	Присъда
4	АБДМ в рамките на ~50 mbb/h от наш равновесие	0.5034 жетона срещу допустима стойност 0.05	НЕУСПЕХ
5	ГЕМ честно по-експлоатируем от наш равновесие	0.8333 > 0.0162; реални модели 0.25–0.33	УСПЕХ

И двата неуспеха са действителни констатации, а не проблеми с настройката, като и двата са разгледани по-долу.




Фигура 2: DT exploitability against the conditioned target return, including an impossible +3. The curve is flat across the real range with a sharp collapse at $R = -1$, the modal payoff and the payoff of folding.

Цел №1 се проваля, защото реакцията на DT към условната възвръщаемост **не е подредена според това колко добра е тази възвръщаемост**. Тя реагира - фино обхождане на корен $P(\text{bet})$ с Поп показва $0.747 \rightarrow 0.020 \rightarrow 0.781$ - но със силен спад точно при $R = -1$, където минава в **11 от 12** информационни множества и постига 1.98 жетона. $R = -1$ е модалната възвръщаемост в данните (41.7% от стъпките) и печалбата от пас.

1.4 МАТЕМАТИЧЕСКИ ФЛАГ Б - посоката на експектила в абстрактния дървовиден модел на решенията

Суровият код задава $\tau = 0.9$ и го определя като „песимистичен“. Реализацията отбелязва това като **обърнат** и по подразбиране използва 0.1 . **Статията потвърждава отбелязването:** Уравнение (6) в абстрактния дървовиден модел на решенията дефинира очаквателната загуба, а Уравнение (7) гласи $\lim_{\alpha \rightarrow 0} g_{\alpha} = \min, \lim_{\alpha \rightarrow 1} g_{\alpha} = \max$ и ред 1 в Алгоритъм 1 изпълнява $\alpha = 0.01$. Това беше независимо потвърдено от собствената самопроверка на модула, която възстановява *аналитичните* експектили на изкривена извадка ($\tau=0.1 \rightarrow -1.951$, $\tau=0.9 \rightarrow 0.000$).



Фигура 3: ARDT exploitability against the expectile tau, with the mean relabel target on the right axis. The relabel target moves monotonically as theory requires, but exploitability is lowest on the optimistic side.

Емпиричното обхождане противоречи на теорията, а причината е показателна. Целта за преозначаване се изменя монотонно с τ ($-0.626 \rightarrow +0.854$), което потвърждава, че механизмът е изграден коректно - но експлоатируемостта е **най-ниска при $\tau = 0.9$** , оптимистичната страна. Ред 7 в Алгоритъм 1 го обяснява: абстрактният дървовиден модел на решенията преозначава с $\check{R}_t = \check{Q}_v(s_t, a_t)$, стойност състояние-действие от две свързани мрежи (Уравнения 8–11), докато тази реализация преозначава със само по състояние $V(s)$. Цел само по състояние не може да различи „това състояние е лошо“ от „това действие е лошо“ - точно дискриминацията, на която разчита абстрактният дървовиден модел на решенията - така че преместването на $\tau \rightarrow 0$ подава на ДТ еднородно отрицателна стойност, което води

до избор на *пас* линията вместо *устойчивата*. EXPECTILE_TAU умишлено е оставено на 0.1, теоретично правилната страна; промяната му на 0.9 за получаване на по-добър резултат би представлявала манипулация на изследването.


1.5 Последващи експерименти: какво крие скаларната оценка

Петте цели класират методите, но не дават обяснение за тях. Проведени бяха още шест допълнителни експеримента.

1.5.1 Извличане на точна стратегия, 24 пъти по-евтино

Четенето на разпределението на действията от **token logprobs** (предварително попълване с "Action:", сумиране на вероятностната маса върху повърхностните форми) замества 288 извадкови извиквания с **12**, като дисперсията на извадката е нула. Валидирано чрез извадка при идентични подкани: средната стойност на разликата $|P(\text{bet})|$ е **0.027** спрямо стандартна грешка на биномно разпределение от 0.102 (резултатът е съгласуван). Не е валидно при използване на подкана тип „верига от мисли“ - предварителното попълване противоречи на принципа „разсъждавай първо“, което води до извънразпределителна стратегия - граница, документирана в кода.

1.5.2 Къде всъщност се проявява загубата



Фигура 4: Each information set's share of total exploitability, beside how far it deviates from Nash. The two orderings barely correspond.

Информационно множество	P(залог)	наш равновесие	отклонение	дял от изтичането
2p (Дама, опонентът е пасувал)	1.000	0.000	1.000	41.4%
2b (Дама, при залог от опонента)	0.253	0.347	0.094	13.1%
3 (Поп, начална позиция)	1.000	0.561	0.439	0.1%




Това **коригира заглавие, заявено по-рано в тази стъпка**. „Всеки голям езиков модел залага с пълна стойност на Попа при 1.00, където наш равновесие смесва при 0.68“ беше съобщено като характерен провал - струва **0.1%** от изтичането. Прекомерното залагане на ръка, която никога не е по-слаба, е почти безплатно. Щетата идва от един възел Дама: винаги залагане на Дамата след като опонентът пасува е **41.4%** от общата експлоатируемост, а поправянето само на това едно решение премества модела от 0.357 на 0.209 жетона. **Величината на отклонението и цената са почти некорелирани**, което е точно това, което се скрива зад едно число.

1.5.3 Моделите играят по-добре, отколкото могат да обяснят

Попитани, на същите информационни множества и с идентичен описателен текст за ситуацията, какъв процент от времето трябва да направят **залог**:

	MAE спрямо наш равновесие (декларирано)	MAE спрямо наш равновесие (изпълнено)	експлоатируемост, ако играе това, което заявява	експлоатируемост при изиграната стратегия
Qwen2.5-7B	0.353	0.246	0.921 жетона	0.357
gpt-oss-20b	0.434	0.328	1.576 жетона	0.392

И двете модели имат **декларирани** стратегии, които са значително по-слаби от техните **изпълнени** - съответно 2.6× и 4.0× по-експлоатируеми. Начините на провал се различават (Qwen отговаря „50%“ в 11 от 12 информационни множества; gpt-oss отговаря ~0% в 8 от 12, включително всичките три възела с Поп, където **наш равновесие** залага 100%), което подсилва общото заключение: **извличането на стратегия от голям езиков модел чрез задаване на въпроси води до резултат, по-лош от проучването на неговото поведение**.



Фигура 5: Stated versus executed betting frequency at each information set for both models, with Nash for reference, and the exploitability of each model's played strategy against a strategy built from its own stated frequencies.


1.5.4 Експлоатативен по подразбиране, а не адаптивен

Сесии от 120 **раздавания** срещу фиксиран архетип, с наблюдаемата история на предишни **раздавания** в контекста. Базовите линии се изчисляват **точно** върху реализираните **раздавания** на самия **агент**, така че нито късметът при раздаването, нито случайността на опонента участват в сравнението.

Опонент	наш равновесие	таван на най-добрия отговор	агент $\pm$ SE	разликата е намалена	обучение (2-ра - 1-ва половина)
alwaysPass	+0.229	+0.981	+0.850 $\pm$ 0.056	+0.83 $\pm$ 0.07	+0.00
AlwaysBet	+0.319	+0.530	+0.383 $\pm$ 0.169	+0.31 $\pm$ 0.80	-0.52

Опонент	наш равновесие	таван на най-добрия отговор	агент $\pm$ SE	разликата е намалена	обучение (2-ра - 1-ва половина)
стегнат- пасивен	+0.088	+0.316	+0.092 $\pm$ 0.122	+0.02 $\pm$ 0.53	-0.15

Средно обучение **-0.22**. При единствената добре подготвена клетка агентът усвоява 83% от наличната експлоатация още от първата половина и не показва допълнително подобрене - фиксирано предварително убеждение, благоприятстващо разпуснат-агресивни стратегии, а не моделиране на противника.



Фигура 6: Exploitation against exploitability, and the per-opponent breakdown showing the gain is confined to passive and random opponents.

Границата експлоатация/експлоатируемост го потвърждава: големият езиков модел **експлоатира с 61% по-голяма интензивност от нашето равновесие, като същевременно е 59 пъти по-експлоатируем** (0.177 спрямо 0.110 жетона/ръка), но цялата печалба е реализирана срещу *пасивни или случайни* опоненти (alwaysPass 0.374 спрямо 0.168). Срещу двата най-компетентни архетипа той се представя **по-зле** от нашето равновесие. Това е компромисът безопасност–експлоатация на Принос №2, измерен.

1.5.5 Директен сблъсък

20,000 раздавания на двойка, с места, разположени шахматно. Наш равновесие срещу наш равновесие е точно 0.0000 и наш равновесие не губи от никого, което валидира турнира.

Играч на ред	срещу наш равновесие	срещу gpt-oss	срещу openThinker3	срещу Qwen	средна стойност	експлоатируемост
nash-CFR	0.0000	+0.1061	+0.1245	+0.0806	+0.104	0.0061
Qwen2.5-7B	-0.0806	+0.1618	+0.1817	0.0000	+0.088	0.3571
gpt-oss-20b	-0.1061	0.0000	+0.1535	-0.1618	-0.038	0.3917
OpenThinker3-7B	-0.1245	-0.1535	0.0000	-0.1817	-0.153	0.8940

7B надминава 20B, а подреждането е строго транзитивно и напълно съответства на подреждането по експлоатируемост - в тази популация експлоатируемостта предсказва резултатите от директен сблъсък.

1.6 Ледюк Холдем - проверка на сложността

Тесен порт (кодировчик, набор от данни, обучение на DT и обхождане с кондициониране по печалба, оценявано в жетони/ръка срещу почти равновесен противник) плюс преглед чрез голям езиков модел. Ледюк разполага с **936** информационни множества спрямо 12 при Кун, **15** различни стойности на печалба спрямо 4, два кръга на залагане и една обща карта.


Kuhn Poker не се възпроизвежда - при модалната възвръщаемост DT е на 0.2 SE от средната стойност на останалите цели. **Кондиционирането обаче все още не насочва**: Pearson $r = +0.062$, Spearman $\rho = -0.054$. То не е инертно (разпределението между целите е 0.60 жетони/ръка, многократно по-голямо от стандартната грешка на точка), а просто не е подредено според целевото качество. Невъзможната цел се насища - единственото предсказание на Kuhn Poker, което се възпроизвежда чисто.

Компетентността на големия езиков модел рязко намалява. В Ледюк големият езиков модел постига резултат от -0.463 ± 0.132 **жетони/ръка** срещу почти равновесие на Наш, който е статистически неразличим от -0.454 на DT; срещу експлоатируемия зоопарк той постига -0.071 , докато Наш прави $+0.582$, губейки дори от **Случаен**. Само **31–54%** от 936-те информационни множества някога са били достигнати, поради което вероятността за достигане прави пълното изброяване ненужно.

Неговият 23.4% незаконен интензитет на действие представлява **едно систематично погрешно схващане**, а не дифузна обърканост: FOLD_WHEN_FREE формира **100%** от незаконната маса, докато RAISE_AT_CAP е 0.0000, а недействие (неуспех на формата) - 0.0001. То се проявява концентрирано в кръг 2 без дължимо (0.5138, до 0.99), при слаби несдвоени



Фигура 7: DT performance against the conditioned target return on Ледюк, with standard errors. There is no collapse at the modal return and no monotone trend.



Фигура 8: Illegal-action intent by category and by situation. A single category accounts for all of it, concentrated in one situation.

раздавания срещу висока маса - моделът смесва „мое то раздаване е слабо“ с „тряб ва да пасна“, забравяйки, че проверката е безплатна. Почти нулевият процент в кръг 1 показ ва, че това е **задействано от текстурата на масата, а не от пропуск в правилата**, което го превръща в откритие от подсказването, а не в таван на възможностите.

1.7 Съгласуване между прогноза и реалност

Предварителните прогнози се съхраняват; към тях се добавя и това, което действително е настъпило (работен процес §0.1).

R1 - Условното връщане никога не насочва и предложеното обяснение беше наполовина вярно. Обяснението за Кун (големината кодира залога, знакът е **късмет с картите**, така че модалната **печалба** при пас избира „**линията на пас**“) предсказва, че ефектът трябва да отслабне при по-богат **набор печалби**. Ледюк премахна вдлъбнатината точно както беше предсказано, **но насочването не се появи вместо това**. Механизмът обяснява *вдлъбнатината*, а не *провала*, който оцелява при 15 стойности на печалбата, два рунда и **обща карта**.

R2 - Математическият флаг В беше правилен относно τ и подцени структурната разлика. Потвърдено е спрямо Ур. 6–7; реалната разлика е между $V(s)$ и $Q(s, a)$, посочено в статията (Алгоритъм 1, ред 7). Цел №4 остава червена.

R3 - Поведенческото клониране печели, а „провалът“ с поп беше почти безплатен. Вижте *Сравнението в заглавието* и *Къде всъщност е загубата*.

R4 - Първоначалната хипотеза беше опровергана. „Знае честотата, но не може да я извади“ предсказва заявено $\approx$ **наш равновесие** и изпълнено $\neq$ **наш равновесие**. Измерено: заявеното е *по-лошо* от изпълненото при двата модела.

R5 - Резултатът от обучение в контекста +1.59 беше оттеглен. Разликата е намалена над 1.0 означава побеждаване на точен най-добър отговор, което е невъзможно; таванът беше проверен ръчно ($K \rightarrow +2$, $Q \rightarrow 0$, $J \rightarrow -1 \Rightarrow +0.333$, съответстващо на изчисленото +0.3387), като така се установи, че стойността на агента е артефакт. Причина: 60-ръчна сесия беше сравнена с базови линии, взети от *различни* раздавания, при което стандартното отклонение на Кун за ръка от ~1.2 дава стандартна грешка, съпоставима с целия диапазон **наш равновесие**→най-добър отговор. При използване на точни двойки базови линии заключението **се обръща** към липса на обучение.

R6 - Резултатът от голям езиков модел за Ледюк от -0.83 беше оттеглен. Токенизаторът разделя RAISE на " RA" и FOLD на " F", докато CALL/CHECK остават цели, поради което съпадението по цяла дума елиминира 70% от вероятностната маса и *обърна* стратегията - модел, който повишава с $p=0.953$, беше оценен като залагащ ~97% от времето. Коригирано

със съвпадение, чувствително към представката, до -0.463 ± 0.132 .

R7 - Смесването на голям езиков модел не може да бъде измерено при температура 0. При тази стойност реалният модел играе *чиста* стратегия, така че всяка измерена честота дегенерира до 0 или 1: блъф(J) отчете 0.75, 0.25 и 1.00 в три изпълнения на една и съща конфигурация, а увеличаването на броя проби от 4 на 24 не помогна. При температура 0.7 честотите стават междинни, а процентът на незаконните ходове придобива ненулева стойност.

1.8 Достоверност и достатъчност на извадката

Четири резултата в тази стъпка изглеждаха като открития и се оказаха измервателни артефакти (R5, R6, възвръщаемост от позиция 0, която беше на 1.7 стандартни грешки от шума от извадката, както и тенденция в Ледюк, която изчезна при 20 пъти повече раздавания). Всеки от тях беше засечен чрез евтина проверка за съгласуваност спрямо нещо, което може да се изчисли точно - точна стойност на играта, точен таван на най-добрия отговор, стандартна грешка или диагностика за запазване на вероятностната маса.

Поотделно, `plotting.py` първоначално съдържаше **само** самопроверка, която изчертаваше твърдо кодирани числа в директорията с резултати и представляваше единствения път за създаване на фигури в тази стъпка; буквалното следване на наръчника за изпълнение би довело до записване на фалшифицирана фигура. Той беше заменен с рендър, който чете **изключително** от записан JSON, което е начинът, по който всяка фигура в този доклад беше създадена.

Достатъчност на извадката: клетките за директен сблъсък използват 20,000 раздавания; съответствията в зоопарка - 4,000; обхождането на Ледюк - 4,000 на цел. Клетките за моделиране на противник за AlwaysBet и стегнат-пасивен са **слабо представителни** ($SE \pm 0.80$ и ± 0.53 , тъй като техните обхвати от наш равновесие към най-добър отговор са тесни), а само клетката за alwaysPass е окончателна.

Вариация на обучението при невронните модели. Наборът от данни, CFR и извънлинейният заглушен блок са инициализирани и се възпроизвеждат точно, но всяко извикване на сравнителната таблица **преобучава** невронните модели, поради което DT/BC/абстрактен дървовиден модел на решенията показват дисперсия от изпълнение до изпълнение. Измерено при две изпълнения на една и съща конфигурация, експлоатируемостта на DT се измести от **0.671** $\rightarrow$ **0.799** (колебание от ~19%), докато двата детерминистични реда (nash-CFR 0.0162, LLM-заглушка 0.8333) се възпроизведоха с точност до четири знака след десетичната запетая. Числата, цитирани тук, са тези от записания артефакт `results/comparison_SMOKE_stub.json`; качествената подредба остава непроменена, но **тези редове не бива да се сравняват с точност до три знака след десетичната запетая**

между различни изпълнения.

1.9 Ограничения (подредени според значимостта им за заключенията)

1. **Всички заключения за голям езиков модел в Ледюк се основават на един модел, един стил на подкана и 600 раздавания** ($SE \pm 0.13$). Достатъчно е да се каже, че предимството на Кун не се пренася; недостатъчно е за класиране на модели в Ледюк.
2. **Абстрактният дървовиден модел на решенията е документирано опростяване на публикувания метод** - едностранен, само със състояние $V(s)$ вместо свързаното състояние-действие $\tilde{Q}(s,a)$. Целите #3–4 тестват заместителя, а не абстрактния дървовиден модел на решенията.
3. **Няма точна експлоатируемост за Ледюк.** Метриката за Ледюк е в Стъпка 03, чийто пакет също се нарича *cfr* и влиза в конфликт със Стъпка 02; вместо това беше използвана експлоатируемост спрямо почти равновесие на Наш.
4. **Резултатите на Кун са SMOKE-профил** (5,000 траектории, 5,000 итерации на CFR, малки мрежи). Качествената подредба е стабилна, но абсолютните стойности биха се изместили при по-голям мащаб.
5. **Извличането на логаритмична вероятност е валидирано само за обикновени подкани**; цифрите за *coT* са получени чрез извадка.
6. **openThinker3 беше измерен само в реда на *coT* ($n=12$)**; пълното изпълнение е ~9 часа при ~38 s на решение.
7. **Двете недостатъчно мощни клетки на B5 (по-горе)** - затягането им изисква приблизително 30 пъти повече раздавания.

1.10 Заключения и насоки за бъдещи изследвания

Заключения. Условното връщане не насочва трансформър за вземане на решения в покер, нито в една от двете игри, и причината не е размерът на набора печалби: в игра с нулева сума с непълна информация реализираната възвръщаемост се доминира от фактори, които агентът не контролира. Обикновеното поведенческо клониране превъзхожда и двата метода, на които тази стъпка е кръстена. Езиковите модели определят правилно класирането на ръка, но грешно честотите на смесване; не могат да вербализират стратегията, която всъщност прилагат, не научават опоненти от наблюдавана игра и губят привидната си компетентност

при добавяне на една улица към играта.

Насоки за бъдещи изследвания (всяка от тях е свързана с измерен ефект):

- *Заменете преетикетирането само на състояние в ARDT с оценителите на състояние-действие, предложени в статията* (уравнения 8–11 плюс загривката в Алгоритъм 1). Това е посочената и подкрепена с доказателства причина за слабото представяне на заместителя и промяната, която трябва да се направи преди фиксираните логове в Стъпка 13.
- *Разглеждайте Return-Conditioned DT като неподходящ инструмент за офлайн покер* - стойността на преетикетирането в ARDT е именно в това, че заменя неконтролируема цел на обуславяне с контролируема такава.
- *Представяйте разложения по решения, вместо скаларна величина* в рамката за оценяване от Стъпка 14; величината на отклонението не е заместител на цената.
- *Проучвайте поведението, вместо да задавате въпроси* във всеки компонент за моделиране на противник чрез езиков модел.
- *Тествайте едноредовото поправяне на подканата в Ледюк* („може да пасувате безплатно“), преди да правите каквито и да било заключения относно възможностите на големите езикови модели при покер с няколко кръга на залагане.

1.11 Възпроизвеждане

from the repository root, with the venv active

`cd implementation/step12/implementation`

```
python validate.py                                # 5 validation targets -> 3 PASS / 2 FAIL / 0 SKI
python comparison_table.py                        # headline table -> results/comparison_SMOKE_<bac
python tau_sweep.py --seeds 3                    # MATH FLAG B, empirical half
python exploitability_decomposition.py --style plain --method logprob
python frequency_elicitation.py --repeats 3 --temp 0.7 --exec-style plain
python opponent_modeling.py --hands 120 --style cot
python exploitation_vs_zoo.py --style plain --hands 4000
python llm_head_to_head.py --tournament --hands 20000
python leduc_stage0.py                           # Leduc DT return-conditioning sweep
python leduc_llm.py --hands 600                  # Leduc LLM scouting
python leduc_illegal_taxonomy.py                 # illegal-action breakdown
python plotting.py                               # all 12 figures, from committed JSON only
```

Реалните изпълнения на модела изискват локален сървър, съвместим с OpenAI. Протоколът, който е от значение: **заредете точно един модел** (`lms unload --all`, след това `lms load <model>`), рестартирайте сървъра след всяко прекратено изпълнение (осиротелите връзки

заемат всички паралелни слотове и по-късните изпълнения блокират безкрайно) и задайте STEP12_LLM_TEMP=0.7 - при температура 0 измерените честоти са безсмислени (R7).

Детерминираност: наборите от данни, CFR и инициализацията на мрежата са **инициализирани**; извънлинейният заместител на голям езиков модел е детерминистичен, така че таблицата SMOKE и валидационната среда се възпроизвеждат точно без GPU или мрежа. Реалните резултати от модела **не** са битово възпроизводими (MoE Routing при партидно обслужване), поради което оценките на честотата използват 24 проби и защо температурният протокол е посочен изрично.