

Обобщения по глави (съкратен вариант)

Изследване на възможностите за приложение на изкуствения интелект в компютърни
игри

Александър Андреев

Юли 2026

Съдържание

Предговор	4
Въведение	4
1 Глава 1 – Основи на обучението с подкрепление	7
1.1 Как обучението с подкрепление се утвърди като самостоятелна дисциплина	7
1.2 Основни принципи – агент, действие, среда	7
1.3 Формулировка на MDP	8
1.4 Информационни множества – когато не можете да видите всичко	9
1.5 Динамично програмиране – при наличие на модел	9
1.6 Обучение с темпорална разлика – обучение без модел	10
1.7 DQN – Дълбоки Q-мрежи	10
1.8 PPO – оптимизация на стратегията с ограничение на близостта	11
1.9 Практическа проверка – собствени реализации срещу Stable-Baselines3	12
2 Глава 2 – Основи на теорията на игрите и CFR	16
2.1 От обучение с подкрепление с един агент към многоагентно стратегическо взаимодействие	16
2.2 Игри в разгърната форма и информационни множества	16
2.3 Теорема за минимакс	17
2.4 Равновесие на Наш	17
2.5 Напасване на съжалението – градивният елемент	18
2.6 Минимизиране на контрафактичното съжаление (CFR)	18
2.7 Математиката на покера	19
2.8 Кун покер – най-простото изпитателно поле	20
2.9 Експлоатируемост – мярка за отклонението от равновесието на Наш	20
2.10 Връзки с Глава 1 и бъдещи насоки	21
2.11 Емпирични визуализации	22
3 Глава 3 – Варианти на CFR и методи на Монте Карло	25
3.1 Защо обикновеният вариант на CFR се проваля при голям мащаб	25
3.2 Търсене с метод Монте Карло в дърво като вдъхновение	25
3.3 Марковски вериги и законът за големите числа	26
3.4 Ледюк покер – по-голяма еталонна игра	26
3.5 CFR+ – Трикът с нулирането на отрицателните съжаления	27
3.6 MCCFR – Извадка от дървото на играта	30
3.7 Компромисът между дисперсия и скорост	33
3.8 Кога MCCFR надделява – точката на пресичане	36
3.9 Връзки с Глава 2 и бъдещи насоки	38
4 Глава 4 – Абстракция на играта и мащабиране на игри с непълна информация	39
4.1 Защо е необходима абстракцията	39
4.2 Пътища към абстракцията	39
4.3 Видове оси на абстракцията	41
4.4 Разлика в експлоатируемостта	42
4.5 Разстояние на Васерщайн: Въведение	43
4.6 Критерият за сливане	43
4.7 Бюджетът на грешките	44
4.8 Избор на абстракция на практика	45
4.9 Решения по време на компилация	46

4.10	Корекция по време на изпълнение	47
4.11	Архитектура: план и корекции в реално време	48
4.12	Практическо валидиране	48
4.13	Връзки и препратки напред	52
5	Глава 5 – Невронни мрежи за игри с непълна информация	53
	Защо невронни мрежи	53
5.1	Основни положения	53
5.2	Архитектура и композиция	55
5.3	Невронни мрежи в CFR	62
5.4	Други невронни приложения	66
6	Глава 6 – Архитектури на игрови изкуствен интелект от край до край	69
6.1	Въведение	69
6.2	DeepStack (2017)	70
6.3	Libratus (2017/2018)	76
6.4	Pluribus (2019)	82
6.5	ReBeL (2020)	89
6.6	Student of Games / SoG (2023)	96
6.7	Синтез	103
7	Глава 7 – Моделиране на противника в игри с непълна информация	110
7.1	Защо е необходимо моделиране на противника	110
7.2	Байесовото ядро – убеждение, наблюдения и реакция	112
7.3	Виждане през ключалка – проблемът с частичната наблюдаемост	115
7.4	Три модела с единен интерфейс	116
7.5	Проблемът на състоятелността и решението в последователна форма	117
7.6	Когато моделът е уверен, но греши	120
7.7	От модела до печалбата – най-добрият отговор, таванът и самонанесената уязвимост	121
7.8	Адаптиране към промяна – нестационарни опоненти	123
7.9	Връзки и бъдещи насоки	125
8	Глава 8 – Безопасна експлоатация в игри с непълна информация	126
8.1	Защо безопасната експлоатация – другата половина на скалата	126
8.2	Експлоатацията като оптимизация с ограничения	127
8.3	Какво означава „безопасен“ – три определения с нарастваща степен на реализъм	129
8.4	Линейно програмиране в последователна форма и генериране на ограничения	132
8.5	Ограничен отговор по Наш и скокообразното превключване	132
8.6	Най-доброто равновесие в Кун – безопасно, но само малко по-печелившо (основният резултат)	135
8.7	Безопасност в реално време – решаване на под-игри (SES)	137
8.8	В мащаб – Кун работи; Ледюк се разпада глобално, но се задържа локално	138
8.9	Връзки и бъдещи насоки	142
9	Глава 9 – Многоагентно обучение с подкрепление: координация, конкуренция и комуникация	143
9.1	Защо многоагентното обучение с подкрепление е различен проблем	143
9.2	Марковски игри – мостът между глави 2–8 и MARL	144
9.3	Семейството от методи	145
9.4	Независимо обучение и начините, по които то се проваля	148
9.5	Централизирано обучение, децентрализирано изпълнение (CTDE)	151

9.6	PSRO – теория на игрите върху популация от стратегии	154
9.7	Научена комуникация (CommNet)	158
9.8	LOLA – моделиране на противника като учещ се агент	159
9.9	Честни бележки, ограничения и връзка със следващите глави	160
9.10	Основни изводи за синтеза на дисертацията	161
10	Глава 10 – Обучение на базата на популации и еволюционна теория на игрите	162
10.1	Защо популации – и защо структурата определя всичко	162
10.2	Семейството от методи	163
10.3	Репликационна динамика – къде една популация може да се установи	164
10.4	„Пумпалът“ – транзитивна и циклична структура	167
10.5	PBT лига в стила на AlphaStar	169
10.6	Разнообразие – наистина ли популацията е разнообразна?	172
10.7	EGTA – оценка на популацията и неочаквано откритие	173
10.8	Честни бележки, ограничения и предаване на щафетата	176
10.9	Основни изводи за синтеза на дисертацията	177
11	Глава 11 – Формиране и засичане на коалиции	178
11.1	Защо появата на трети играч е повратна точка	178
11.2	Детекторът на коалиции – извличане на съюзи от ходовете	179
11.3	Принос по Шапли в състезателна игра	181
11.4	MAPPO с отчитане на коалициите – и кога всъщност расте коалиционният резултат	183
11.5	EGTA и въртящият се пумпал – SLS колело ли е, или стълба?	186
11.6	Бележки, ограничения и връзка със следващите глави	188
11.7	Основни изводи за синтеза на дисертацията	189
12	Глава 12 – Модели на последователности и агенти с голям езиков модел в стратегически среди	190
12.1	Защо да се разглежда обучението с подкрепление като прогнозиране на последователност	190
12.2	Капанът между късмета и умението	190
12.3	ARDT – обуславяне по гарантираната възвръщаемост	191
12.4	Какво всъщност прави обуславянето по възвръщаемостта в покера	192
12.5	Езикови модели като стратегически агенти	194
12.6	Експлоатация, адаптация и ограниченията на опростената игра	197
12.7	Основни изводи за синтеза на дисертацията	198
13	Глава 13 – Поведенчески анализ на реални истории на раздаванията	200
13.1	От решаването на игри към четенето на записи	201
13.2	Данните и парсерът	201
13.3	Описание на играча: статистиките и колко раздавания изискват те	202
13.4	Колко далеч са реалните играчи от силен еталон	204
13.5	Прогнозиране на решенията: поведенческо клониране и капанът на базовата линия	205
13.6	Поведенчески отпечатък: player2ves за покер	207
13.7	Типове, стабилност и онлайн определяне на типа	209
13.8	Тайни съглашения: откриване на вмъкнати съучастници в реални сесии	211
13.9	Може ли конвейерът да открие бот?	213
13.10	Честни бележки, ограничения и връзка със следващите глави	214
13.11	Основни изводи за синтеза на дисертацията	215
14	Глава 14 – Рамки за оценяване и метрики за експлоатируемост	216

14.1	Защо оценяването на адаптивен агент е трудно	216
14.2	Рамката: три слоя и един четвърти въпрос	217
14.3	Слой 2 – класиранията се разминават по предвидим начин	220
14.4	Слой 3 – статистическата увереност и какво показва AIVAT	222
14.5	Обединеният протокол в Кун и Ледюк	223
14.6	Приблизителни най-добри отговори и резултатът RRPS	226
14.7	Трима и четирима играчи	228
14.8	Къде съществуващото оценяване се проваля – контролен списък	229
14.9	Честни бележки, ограничения и връзка със следващите глави	230
14.10	Основни изводи за синтеза на дисертацията	231

Предговор

Въведение

Изследователски контекст и значимост

Многоагентните системи, опериращи в условията на непълна информация (imperfect information), представляват една от най-предизвикателните и практически значими области на изследване в сферата на изкуствения интелект. В подобни системи автономните агенти трябва да вземат стратегически решения без пълно знание за състоянието на средата или намеренията на другите участници — постановка, която възниква естествено в киберсигурността (противоборстваща защита на мрежи), финансовите пазари (конкуриращи се алгоритмични трейдъри), координацията на автономни системи и разпознаването на измами.

Математическата рамка за анализ на подобни взаимодействия се предоставя от игрите в разгърната форма (extensive-form games) с непълна информация — клон на теорията на игрите, който моделира последователно вземане на решения, когато играчите разполагат с частна (скрита) информация. През изминалото десетилетие беше постигнат значителен напредък в изчисляването на равновесни стратегии за мащабни игри с непълна информация. Знакови системи в тази област са Libratus (Brown and Sandholm, 2017) и Pluribus (Brown and Sandholm, 2019), които победиха професионални човешки играчи съответно в покер за двама и шестима участници, както и по-обща архитектура като ReBeL (Brown et al., 2020) и Student of Games (Schmid et al., 2023), които унифицират подходите за решаване на игри както в среди с пълна, така и с непълна информация.

Въпреки този напредък, продължава да съществува едно критично ограничение: системите, представляващи водещия стандарт, изчисляват фиксирани равновесни стратегии, които не се адаптират спрямо специфичните поведенчески модели, демонстрирани от срещаните опоненти. В реалната практика противниците рядко играят оптимално и способността за откриване и експлоатация на систематични отклонения от равновесието — като същевременно се запазват гаранциите срещу бъдеща експлоатация (в отговор) — представлява фундаментален нерешен проблем. Този проблем, известен като безопасна експлоатация на противника (safe opponent exploitation), е изследван предимно в среди за двама играчи с нулева сума. Разширяването му към среди с множество участници, където е възможно динамично формиране и разпадане на коалиции, остава

слабо изследвано в литературата.

Настоящият план за обучение е организиран като прогресивна програма от петнадесет обучителни стъпки, групирани в седем тематични етапа:

- **Основи** (Глави 1–2): Фундаменти от областта на обучението с подкрепление и теорията на игрите, необходими за цялата последваща работа.
- **Машабиране на инструментариума** (Глави 3–4): Монте Карло варианти на CFR и техники за абстракция на игри, предназначени за машабиране към по-големи инстанции.
- **Невронни методи за игри** (Глави 5–6): Невронни мрежови апроксимации на равновесни стратегии и архитектури за изкуствен интелект „от край до край“ в игри.
- **Моделиране и експлоатация на противника** (Глави 7–8): Изводи от поведенчески следи и алгоритми за безопасна експлоатация — същинското ядро на дисертацията.
- **Многоагентна динамика** (Глави 9–11): Многоагентно обучение с подкрепление (MARL), базирано на популации обучение (PBT) и динамика на коалициите в конкурентни среди.
- **Подходи, основани на данни** (Глави 12–13): Секвенционни модели и конвейери за поведенчески анализ, свързващи теорията с реални данни.
- **Интеграция** (Глави 14–15): Изграждане на рамка за оценяване и картографиране на изследователската граница (research frontier).

В рамките на плана за обучение игрите Кун покер и Ледюк холдем служат като основна тестова среда за имплементациите. Те са избрани умишлено поради своята педагогическа стойност: техните малки пространства на състоянията (съответно 12 и приблизително 936 информационни множества) и познатите аналитични равновесия позволяват точна верификация на всеки алгоритъм, докато структурата на непълна информация запазва стратегическата комплексност, която същността на дисертацията изисква. Работейки в рамките на напълно изучени и добре разбрани области, всяка стъпка се концентрира върху алгоритмичните концепции, вместо върху софтуерното инженерство, специфично за конкретната област, което максимизира обема на теоретичния материал, покрит в определеното време. В по-късните етапи планът за обучение валидира обобщимостта отвъд покера, като прилага разработените методи към матрични игри, Goofspiel, So Long Sucker и анонимизирани поведенчески данни от реалния свят.

Планираните приноси на дисертацията са формулирани в термини, независими от конкретната предметна област — нито един от тях не е специфичен изключително за покер или друга единична игра. Рамката за поведенческа адаптация (Принос 1) е насочена към произволни игри с непълна информация; Евристиките за многоагентна безопасна експлоатация (Принос 2) ще бъдат дефинирани върху общи N-играчески структури в разгърнатата форма; а Методологията за оценяване (Принос 3) е предназначена да бъде приложима във всякакви игрови среди.

Планът за обучение е съобразен с ключовите етапи от индивидуалния план към университета. След завършването на всеки тематичен етап, съответният материал ще бъде включен в Глава I на дисертацията — обхващаща анализ на водещия стандарт, както и формулиране на актуалността, целите, задачите и тезисите. По този начин обзорът на литературата и полагането на основите

се натрупват постепенно чрез инкрементално изграждане, вместо да бъдат съставяни ретроспективно. Глава 15 изготвя подробен план на Глава I и план за публикации.

Изследователска цел и очаквани приноси

Основната цел на това докторантско изследване е да се разработи адаптивен AI агент за използване в различни компютърни игри. Агентът ще стартира от безопасна стратегия, но ще бъде способен да подобрява резултата си срещу субоптимални противници, като по този начин премахва ограниченията на предходни системи, които рядко адаптират поведението си динамично. Изследователската програма е структурирана около три планирани приноса:

Принос 1 — Рамка за поведенческа адаптация. Целта е да се разработи общ метод за извличане на изводи относно стратегиите на опонента и адаптиране към тях въз основа на наблюдавани последователности от действия в реално време, приложим към произволни игри с непълна информация. Този принос се стреми да преодолее празнината между изчисляването на статични равновесия и динамичната игра, съобразена с противника.

Принос 2 — Многоагентна безопасна експлоатация. Този принос ще изследва възможни и изчислително реализуеми евристични подходи — включително KL-регуляризирана експлоатация (ограничаваща експлоатиращата политика да остане близка до сигурна базова стратегия чрез налагането на санкция за отклонение посредством дивергенция на Kullback-Leibler) и базови линии за запазване на равен дял — за безопасна експлоатация в малки N-играчески игри (разновидности на Кун и Ледюк за трима играчи), опитвайки се да разшири съществуващите резултати от случаи за двама играчи с нулева сума. Обхватът се ограничава до емпирично валидиране на практически евристики, а не изграждането на генерална теорема за безопасност за произволни среди с N-играчи.

Принос 3 — Методология за оценяване. Целта е да се проектира рамка, независима от конкретната среда, за измерване на адаптивността и устойчивостта на агента в различни игрови условия и противникови популации, с акцент върху идентифицирането на възможни режими на отказ в съществуващи методики на оценяване и демонстриране на ситуации, където стандартните метрики могат да предоставят подвеждащи оценки.

1 Глава 1 – Основи на обучението с подкрепление

1.1 Как обучението с подкрепление се утвърди като самостоятелна дисциплина

Обучението с подкрепление израства от три нишки, които дълги десетилетия почти не са били свързани помежду си: обучението чрез проба и грешка от животинската психология,¹ динамичното програмиране и функцията на стойността от теорията на оптималното управление² и методите на темпоралната разлика.³⁴ Q-обучението на Watkins (1989)⁵ окончателно ги обединява и към учебника на Sutton и Barto (1998 г., актуализиран през 2018 г.)⁶ обучението с подкрепление вече е самостоятелна рамка за последователно вземане на решения при несигурност, а не просто „машинно обучение с награди“. DQN въвежда дълбоките мрежи в областта през 2013–2015 г.,⁷ а PPO се появява през 2017 г.⁸

1.2 Основни принципи – агент, действие, среда

Цялата рамка на обучението с подкрепление се основава на прост цикъл. **Агентът** наблюдава текущото **състояние** на **средата**, избира **действие** и получава сигнал за **награда** заедно с ново **състояние**. След това процесът се повтаря. Целта на агента е да научи **стратегия** – съпоставяне между състояния и действия – която максимизира натрупаната награда във времето.

- **Състояние** (s): описание на средата в даден момент – в CartPole позицията и скоростта на количката и ъгълът и ъгловата скорост на пръта; в покера – раздадените карти и историята на залозите.
- **Награда** (r): скаларна величина за обратна връзка – редки награди (само в края на играта) или чести (на всеки времеви интервал).
- **Стратегия** (π): детерминистична ($\pi(s) = a$) или стохастична, като $\pi(a|s)$ дава разпределение на вероятностите върху възможните действия.

¹Thorndike, E.L. (1911). *Animal Intelligence: Experimental Studies*. Macmillan.

²Bellman, R. (1957). *Dynamic Programming*. Princeton University Press.

³Samuel, A.L. (1959). "Some Studies in Machine Learning Using the Game of Checkers." *IBM Journal of Research and Development*, 3(3), 210-229.

⁴Sutton, R.S. (1988). "Learning to Predict by the Methods of Temporal Differences." *Machine Learning*, 3(1), 9-44. Докторска дисертация: Sutton, R.S. (1984). *Temporal Credit Assignment in Reinforcement Learning*. University of Massachusetts Amherst.

⁵Watkins, C.J.C.H. (1989). *Learning from Delayed Rewards*. Докторска дисертация, University of Cambridge. Сходимостта е доказана в Watkins, C.J.C.H. & Dayan, P. (1992). "Q-learning." *Machine Learning*, 8(3-4), 279-292.

⁶Sutton, R.S. & Barto, A.G. (2018). *Reinforcement Learning: An Introduction*, второ издание. MIT Press. Гл. 1 "Introduction"; гл. 3 "Finite Markov Decision Processes"; гл. 4 "Dynamic Programming"; гл. 5 "Monte Carlo Methods"; гл. 6 "Temporal-Difference Learning"; §11.3 "The Deadly Triad"; гл. 13 "Policy Gradient Methods". <http://incompleteideas.net/book/the-book-2nd.html>

⁷Mnih, V. et al. (2013). "Playing Atari with Deep Reinforcement Learning." arXiv:1312.5602; Mnih, V. et al. (2015). "Human-level control through deep reinforcement learning." *Nature*, 518(7540), 529-533. DOI 10.1038/nature14236

⁸Schulman, J., Wolski, F., Dhariwal, P., Radford, A. & Klimov, O. (2017). "Proximal Policy Optimization Algorithms." arXiv:1707.06347.

- **Функция на стойността** ($V^\pi(s)$): очакваната натрупана награда от състояние s нататък, ако агентът следва стратегия π – колко добро е едно състояние в дългосрочен план, а не само непосредствено.
- **Коефициент на дисконтиране** (γ): стойност $\gamma = 0,99$ означава, че агентът е търпелив; $\gamma = 0,5$ – че е късоглед.

Критичното предизвикателство при проектирането на системи за обучение с подкрепление е **компромисът изследване–експлоатация**: агентът трябва да изследва непознати действия, за да открие потенциално по-добри стратегии, но същевременно и да експлоатира наличните си знания, за да събира награда. Прекомерното изследване води до загуба на време, а прекалената експлоатация може да доведе до заседналост в локален оптимум.

Методите, базирани на стойност (като DQN⁷) научават стойността на състоянията или двойките състояние–действие и извеждат стратегия въз основа на тези стойности; **методите, базирани на стратегията** (като PPO⁸), научават самата стратегия директно.⁶

1.3 Формулировка на MDP

Марковски процес на вземане на решения (Markov decision process, MDP) представлява формалната математическа рамка, върху която са изградени повечето алгоритми за обучение с подкрепление: множество от състояния S , множество от действия A , функция на преход $P(s'|s, a)$, функция на наградата $R(s, a, s')$ и коефициент на дисконтиране $\gamma \in [0, 1)$.

Частта „Марков“ означава, че бъдещето зависи единствено от текущото **състояние**, а не от историята на пътя до него. Това е силно предположение – и такова, което не е валидно в много интересни ситуации (като **покер**, където историята на залозите има значение). Раздел 1.4 разглежда този въпрос.

Целта е да се намери стратегия π^* , която максимизира очакваната дисконтирана възвръщаемост.

$$\pi^* = \arg \max_{\pi} \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right]$$

Ключовата рекурсивна зависимост е **уравнението на Белман**:

$$V^\pi(s) = \sum_a \pi(a|s) \sum_{s'} P(s'|s, a) [R(s, a, s') + \gamma V^\pi(s')]$$

Това означава, че стойността на едно състояние е равна на очакваната непосредствена награда плюс дисконтираната стойност на следващото състояние. Динамичното програмиране, обучението с темпорална разлика (temporal-difference learning, TD) и дълбокото обучение с подкрепление се основават на вариации на това уравнение.⁶

1.4 Информационни множества – когато не можете да видите всичко

Стандартните MDP предполагат, че агентът може напълно да наблюдава състоянието. В действителност обаче често това не е така. В покера например не виждате картите на опонента, а в игрите със стратегия в реално време действа т.нар. **мъгла на войната**. Това са **частично наблюдаеми** среди.

Формалното разширение е **частично наблюдаемият марковски процес на вземане на решения** (Partially Observable MDP, POMDP)⁹, който включва функция за наблюдение – агентът получава наблюдения, представляващи шумни или непълни изгледи на истинското състояние. Но POMDP са печално известни с това, че оптималното им решаване е изключително трудно.

В теорията на игрите същата идея се изразява чрез **информационни множества**. Информационно множество обединява всички състояния на играта, които играчът не може да различи едно от друго въз основа на направените наблюдения. В Кун покер (3 карти, 2 играчи), когато държите Вале и все още не е имало залагания, вие се намирате в информационно множество – знаете своята карта, но не и тази на опонента си, така че не можете да определите дали действителното състояние е „Аз имам Вале, опонентът има Дама“ или „Аз имам Вале, опонентът има Поп“.¹⁰

Алгоритмите, които работят в тези среди – като CFR (минимизиране на контрафактичното съжаление, разгледано в глава 2) – оперират върху информационни множества, а не върху отделни състояния. Това представлява фундаментално различен изчислителен проблем от стандартното RL и е причината игровият изкуствен интелект да се нуждае от собствен набор инструменти, различни от тези, които DQN или PPO предоставят по подразбиране.

1.5 Динамично програмиране – при наличие на модел

Динамичното програмиране (DP) решава MDP, когато разполагате с пълна информация за средата (P и R) – на практика, когато правилата на играта са ви напълно известни. **Итерацията по стратегии** редува оценка на фиксирана стратегия чрез уравнението на Белман и подобрене, при което стратегията става алчна спрямо новите стойности, докато престане да се променя. **Итерацията на стойностите** комбинира оценката и подобренето в една-единствена актуализация. И

⁹Kaelbling, L.P., Littman, M.L. & Cassandra, A.R. (1998). “Planning and acting in partially observable stochastic domains.” *Artificial Intelligence*, 101(1-2), 99-134. DOI 10.1016/S0004-3702(98)00023-X

¹⁰Shoham, Y. & Leyton-Brown, K. (2008). *Multiagent Systems: Algorithmic, Game-Theoretic, and Logical Foundations*. Cambridge University Press. DOI 10.1017/CBO9780511811654. Гл. 3 “Introduction to Noncooperative Game Theory: Games in Normal Form”; гл. 4 “Computing Solution Concepts of Normal-Form Games” (§4.1 – линейната програма за игри на двама с нулева сума); гл. 5 “Games with Sequential Actions: Reasoning and Computing with the Extensive Form” (§5.2 – игри с непълна информация и информационни множества; §5.2.3 – последователната форма, механизмът под всяка линейна програма в Глава 8); гл. 7 “Learning and Teaching” – рамката за учене в повтарящи се игри, включително напрежението, че действията едновременно *експлоатират* и *обучават* опонента. Свободно достъпна: <http://www.masfoundations.org/download.html>

двата алгоритъма дават точни решения с ясни гаранции за сходимост, но изискват пълния модел, а изчислението нараства с броя на състоянията. Всеки следващ метод – методът Монте Карло, TD обучението, DQN, PPO – може да се разглежда като приближение към решението на DP, когато моделът е неизвестен или пространството на състоянията е твърде голямо.⁶

1.6 Обучение с темпорална разлика – обучение без модел

Обучението с темпорална разлика (TD) е пробивът, който прави обучението с подкрепление приложимо на практика. За разлика от динамичното програмиране, то не изисква модел на средата; за разлика от методите на Монте Карло, не чака края на епизода. То актуализира стойностните оценки след всяка стъпка, използвайки самоподкрепяне (bootstrapping): текущата оценка на стойността на следващото състояние замества истинската бъдеща възвръщаемост.

Вариантът на тази идея за задачата за управление е **Q-обучението** (Watkins, 1989):⁵

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t) \right]$$

Изразът в скобите е **TD грешката** – разликата между настъпилото (награда плюс оценена бъдеща стойност) и предвиденото. Ако TD грешката е положителна, състоянието се е оказало по-добро от очакваното; ако е отрицателна, то е било по-лошо. Операторът $\max$ позволява на Q-обучението да се обучава **извън текущата стратегия** (off-policy): то научава оптималната стратегия дори докато следва друга, експериментална стратегия. Самоподкрепянето въвежда известно отместване (bias), но TD обучението се учи онлайн и с по-ниска дисперсия от метода Монте Карло; то е основата, върху която се градят DQN и повечето съвременни алгоритми, базирани на стойности.⁶

1.7 DQN – Дълбоки Q-мрежи

DQN (Mnih и др., 2015)⁷ е алгоритъмът, който доказва възможността дълбоките невронни мрежи да се използват като апроксиматори в обучението с подкрепление в голям мащаб: той се научи да играе 49 игри на Atari директно по суровите пиксели на екрана.

Как работи. DQN заменя Q-таблицата с невронна мрежа, която приема състояние като вход и извежда Q-стойности за всички действия. Обучението на мрежата се извършва чрез минимизиране на квадратичната TD грешка – разликата между предсказаната Q-стойност и целта (награда плюс дисконтираната максимална Q-стойност на следващото състояние). На всяка стъпка агентът избира действието с най-висока Q-стойност (експлоатация) или произволно действие с вероятност ϵ (изследване).

Апроксимацията на функция само с Q-обучение беше известна като нестабилна („смъртоносна

триада⁶: обучение извън текущата стратегия + апроксимация на функции + самоподкрепяне). Два ключови похвата осигуряват достатъчна стабилност, за да работи DQN:

1. **Повторение на натрупан опит.** Вместо да се обучава върху последователни преходи (които са силно корелирани), преходите се съхраняват в голям буфер и се извличат на случаен принцип в минипартиди. Това нарушава корелацията и позволява всеки опит да бъде използван многократно. Принципът е аналогичен на разбъркването на тренировъчните данни при обучение с учител.
2. **Целева мрежа.** Поддържа се отделно копие на Q-мрежата, което се обновява само периодично. Целевата стойност на TD се изчислява с помощта на това замразено копие. Без него целта се измества при всяка тренировъчна стъпка – вие преследвате подвижна цел, което води до колебания и дори до разходимост на обучението.

Ограничения. DQN работи единствено с дискретни пространства на действията и може да надценява Q-стойностите (проблем, който Double DQN¹¹ решава). И най-важното – той научава алчна детерминистична стратегия, без естествен начин за изразяване на стохастични стратегии, което е от значение в игрите, където смесените стратегии са оптимални.

В нашата реализация най-влиятелните хиперпараметри бяха размерът на мрежата, епсилон минимумът и честотата на синхронизация на целевата мрежа.

1.8 PPO – оптимизация на стратегията с ограничение на близостта

PPO (Schulman и др., 2017)⁸ **научава стратегията директно** – невронна мрежа генерира разпределение на вероятностите върху действията и се обучава да увеличава вероятността на действията, които водят до висока възвръщаемост.

Проблемът, който PPO решава. Методите на градиента на стратегията са печално известни с нестабилността си на практика: основният алгоритъм REINFORCE¹² страда от висока дисперсия и може да предприема разрушително големи стъпки, които провалят добра стратегия. TRPO (Schulman и др., 2015)¹³ ограничи колко може да се промени стратегията при всяка актуализация, но стъпката му от втори ред е сложна за реализиране.

Как работи PPO. PPO запазва идеята за стабилност от TRPO, но заменя ограничението с много по-прост механизъм: **изрязване**. Ключовото количество е отношението на вероятностите $r_t(\theta) = \pi_{\theta}(a_t|s_t) / \pi_{\theta_{old}}(a_t|s_t)$ – колко по-вероятно (или по-малко вероятно) е новата стратегия да предприеме същото действие, което старата стратегия е предприела. PPO изрязва това отношение до

¹¹van Hasselt, H., Guez, A. & Silver, D. (2016). “Deep Reinforcement Learning with Double Q-Learning.” *Proceedings of the AAAI Conference on Artificial Intelligence*, 30(1). DOI 10.1609/aaai.v30i1.10295. arXiv:1509.06461

¹²Williams, R.J. (1992). “Simple statistical gradient-following algorithms for connectionist reinforcement learning.” *Machine Learning*, 8(3-4), 229-256. DOI 10.1007/BF00992696

¹³Schulman, J., Levine, S., Abbeel, P., Jordan, M. & Moritz, P. (2015). “Trust Region Policy Optimization.” *Proceedings of the 32nd International Conference on Machine Learning*, 1889-1897.

диапазона $[1 - \epsilon, 1 + \epsilon]$ (обикновено $\epsilon = 0,2$), което означава:

- Ако едно **действие** се окаже добро (положително **предимство**) и отношението на вероятностите надхвърли $1 + \epsilon$, **градиентът** се анулира – **стратегията** не трябва да става прекалено „алчна“ за това **действие**.
- Ако едно **действие** се окаже лошо (отрицателно **предимство**) и отношението на вероятностите падне под $1 - \epsilon$, **градиентът** също се анулира – така се предотвратява прекомерна корекция на **стратегията**.

Това е **изрязаната сурогатна цел**: стабилност, сходна с тази на TRPO, само с обикновени стохастични градиентни стъпки от първи ред.

Архитектура. PPO е актьор-оценител: **мрежа на стратегията** (актьор) извежда вероятности за действия, а **мрежа за стойности** (оценител) оценява стойностите на състоянията, които позволяват оценки на предимството с ниска дисперсия чрез обобщената оценка на предимството (generalized advantage estimation, GAE).¹⁴

Защо PPO е важен в сравнение с DQN: PPO работи както с дискретни, така и с непрекъснати пространства на **действията** и може да усвоява **стохастични стратегии**, което е от решаващо значение в игрови среди, където прилагането на **смесени стратегии** е необходимо. Тъй като се обучава **по текущата си стратегия** (on-policy), той избягва остарелите данни, но използва данните по-малко ефективно от DQN, изисква внимателна настройка (параметъра λ на GAE, бонуса за ентропия, архитектурата на мрежата) и все още може да среща трудности при редки награди.

В нашата реализация PPO успя да реши LunarLander-v3 (средна награда за последните 100 епизода 202,2 при цел 200) след приблизително 264 хиляди стъпки на средата. Решаващата промяна между двете записани изпълнения беше капацитетът на мрежата (удвоен от [64,64] на [128,128], при по-голям бюджет).

1.9 Практическа проверка – собствени реализации срещу Stable-Baselines3


За да проверим дали нашите реализации от нулата функционират коректно, ги сравнихме със Stable-Baselines3 (SB3)¹⁵ – широко използвана и добре тествана RL библиотека. При PPO на SB3 бяха зададени нашите хиперпараметри и същият бюджет от 500 хил. стъпки. При DQN показаното изпълнение на SB3 използва настроените за CartPole хиперпараметри от RL Baselines3 Zoo¹⁶ и бюджет от 100 хил. стъпки, така че там сравнението е с настроен базов агент, а не при еднакви настройки.

¹⁴Schulman, J., Moritz, P., Levine, S., Jordan, M. & Abbeel, P. (2016). “High-Dimensional Continuous Control Using Generalized Advantage Estimation.” *ICLR 2016*. arXiv:1506.02438

¹⁵Raffin, A., Hill, A., Gleave, A., Kanervisto, A., Ernestus, M. & Dormann, N. (2021). “Stable-Baselines3: Reliable Reinforcement Learning Implementations.” *Journal of Machine Learning Research*, 22(268), 1-8.

¹⁶Raffin, A. (2020). *RL Baselines3 Zoo*. Хранилище в GitHub. <https://github.com/DLR-RM/rl-baselines3-zoo>; настройките за CartPole-v1 са в `hyperparams/dqn.yml`.

1.9.1 DQN върху CartPole-v1




Фигура 1: DQN върху CartPole-v1: собствената реализация срещу SB3 (показани са първите 1 061 от 1 255 епизода на SB3). Плъзгаща се средна на наградата за 100 епизода, оцветено – $\pm$ едно стандартно отклонение; пунктирната линия е целта 475.

Нашият собствен DQN решава CartPole около епизод 1011, като достига плъзгаща се средна за 100 епизода 477,5 (над целта от 475). Показаното изпълнение на DQN на SB3 (от 6 април 2026 г.) използва настройките на Zoo с бюджет от 100 хил. стъпки – два пъти повече от 50-те хиляди, за които Zoo ги обучава. През своите 1 255 епизода плъзгащата му се средна достига най-много 222,4 при епизод 695 (около 51 хил. стъпки) и завършва на 134,3, без да се доближи до целта.

Тъй като SB3 използва настроени хиперпараметри, а не същите като нашите, сравнението не е равностойно и причината за разликата не е установена. Две различия не са проверени: показаните награди са от епизоди на обучение, в които SB3 все още избира случайно действие в 4% от случаите (крайно $\epsilon = 0,04$), докато нашият ϵ е спаднал под 1%; и SB3 прави наполовина по-малко обновявания на стъпка на средата от нашия агент. Всяка реализация е изпълнена веднъж, нашата – без фиксирано начално число, така че неуспехът на SB3 трябва да се провери с второ начално число, преди да се тълкува като свойство на SB3, а не на това изпълнение.

1.9.2 PPO върху LunarLander-v3



Фигура 2: PPO върху LunarLander-v3: собствената реализация (спряна при епизод 547) срещу SB3 (показани са първите 577 от 1 224 епизода). Плъзгаща се средна наградата за 50 епизода, оцветено – $\pm$ едно стандартно отклонение; пунктирната линия е целта 200.

Нашият собствен PPO преминава целта от 200 около епизод 543 (след 264 хил. стъпки). PPO на SB3 със същия бюджет от 500 хил. стъпки достига най-добра плъзгаща се средна за 100 епизода 131,2 – все още се покачва и не е достигнал сходимост.

Разликата тук е по-малка, отколкото при DQN, при идентични хиперпараметри на PPO. Оставащата разлика може да се дължи на ортогоналната инициализация на теглата в SB3 и на това, че SB3 нормализира предимството във всяка мини-партида, а не в цялото разгръщане; при едноединствено изпълнение на всяка реализация тя може да е и случайна. При 1–2 млн. стъпки PPO на SB3 вероятно би достигнал целта.

1.9.3 Извод

Чиста реализация от нулата обхваща около 300–500 реда код, докато тази на SB3 достига приблизително 10 000. Компромисът е по-малко функции срещу пълна прозрачност и лесна възможност за отстраняване на грешки. За изследователски цели – особено при планираната работа върху експлоатацията на противника в глави 7–8 – собствените реализации дават възможност за прецизни модификации (например добавяне на наблюдения на състоянието на убежденията), които биха изисквали значително подкласиране в SB3. Именно тази практическа гъвкавост беше причината

да изградим решение от нулата.

2 Глава 2 – Основи на теорията на игрите и CFR

2.1 От обучение с подкрепление с един агент към многоагентно стратегическо взаимодействие

Глава 1 разглеждаше средите като пасивни – количката с прът не оказва съпротива, а кацащият модул не се опитва да предизвика катастрофа. Агентът оптимизира спрямо фиксирана динамика. Глава 2 въвежда фундаментално различен проблем: средата включва друг *стратегически* вземащ решения участник, чиито действия зависят от първия.

В многоагентна среда „най-добрата“ стратегия зависи от действията на противника, а неговата най-добра стратегия – от вашите действия. Тази взаимна зависимост е в основата на предизвикателството, което поставя теорията на игрите, и измества концепцията за решение от „оптимална стратегия“ към **равновесие на Наш**.¹⁷

2.2 Игри в разгърнатата форма и информационни множества

Игра в разгърнатата форма представя стратегическото взаимодействие под формата на дърво: всеки възел е точка за вземане на решение от даден играч (или „случайност“ при случайни събития като раздаване на карти), ребрата обозначават действия, а крайните възли съдържат печалбите на всеки играч. В игрите с **пълна информация** (шах, Го) всеки възел представлява отделно информационно множество и те се решават чрез минимакс и алфа-бета подрязване. В игрите с **непълна информация** (покер) няколко състояния на играта са *неразличими* за действащия играч.

Информационно множество (раздел 1.4) обединява състоянията на играта, които играчът не може да различи, затова той трябва да приложи една и съща стратегия към всички тях. Именно това прави игрите с **непълна информация** фундаментално по-сложни: трябва да се подбере едно действие, което да работи добре *средно* за всички състояния в информационното множество.

В Кун покер информационното множество "2pb" включва две състояния на играта: „Аз държа Дама, опонентът държи Вале, историята е пас–залог“ и „Аз държа Дама, опонентът държи Поп, историята е пас–залог“. Играчът с Дама не може да различи тези състояния и трябва да използва една и съща стратегия (вероятност за плащане) и в двата случая.¹⁷

¹⁷Shoham, Y. & Leyton-Brown, K. (2008). *Multiagent Systems: Algorithmic, Game-Theoretic, and Logical Foundations*. Гл. 3 (игри в нормална форма; §3.3 – най-добър отговор и равновесие на Наш, §3.4.1 – максиминни и минимаксни стратегии); §4.1 (изчисляване на равновесия на Наш в игри за двама играчи с нулева сума); гл. 5 (игри в разгърнатата форма; §5.2 – непълна информация и информационни множества, §5.2.3 – последователната форма); §7.5 “No-regret learning and universal consistency”. Свободно достъпна: <http://www.masfoundations.org/download.html>

2.3 Теорема за минимакс

Теоремата за минимакс (von Neumann, 1928)¹⁸ гласи, че във всяка крайна игра за двама играчи с нулева сума, при смесени стратегии, печалбата, която един играч може да си гарантира (максимин), е равна на печалбата, до която противникът може да го ограничи (минимакс); общата им стойност е „стойността на играта“. В игрите за двама играчи с нулева сума минимаксният стратегически профил е еквивалентен на равновесие на Наш, така че откриването му гарантира защита срещу всяка експлоатираща стратегия, която противникът може да приложи.

2.4 Равновесие на Наш

Равновесие на Наш представлява стратегически профил, при който стратегията на всеки играч е най-добър отговор на стратегиите на всички останали играчи. Формално, за всеки играч i :

$$u_i(\sigma_i^*, \sigma_{-i}^*) \geq u_i(\sigma_i, \sigma_{-i}^*) \quad \forall \sigma_i$$

Нито един играч не може да подобри своята очаквана печалба чрез едностранно отклоняване. Това не означава, че всички са доволни от резултата (дилемата на затворника), а само че никой не може да постигне по-добър резултат, като промени единствено собствената си стратегия. Nash (1950)¹⁹ доказва, че всяка крайна игра има поне едно равновесие на Наш (възможно в смесени стратегии) – основополагаща теорема, която обаче не помага при изчисленията.

За игри за двама с нулева сума (където печалбата на единия играч е загуба за другия) равновесията на Наш са **оптимални по минимакс**: равновесната стратегия гарантира поне стойността на играта, независимо от действията на опонента. Това е гаранцията за безопасност, която прави равновесието на Наш базова линия за изкуствен интелект за покер.

В игрите с N играчи или с обща сума изчисляването на равновесие на Наш е PPAД-пълна задача – дори при игри за двама играчи с обща сума – и затова се смята за изчислително непосилно.^{20,21} Освен това равновесията губят своята гаранция за безопасност: играта по равновесна стратегия в игра с трима играчи не предпазва от двама опоненти, които могат да се отклоняват от равновесие, потенциално формирайки временни коалиции, които експлоатират третия играч.²² Тази динамика изисква изцяло различни обучителни рамки и методи за оценка (като тези, обсъдени в глави 9

¹⁸von Neumann, J. (1928). “Zur Theorie der Gesellschaftsspiele.” *Mathematische Annalen*, 100(1), 295-320. Превод на английски: “On the Theory of Games of Strategy,” in *Contributions to the Theory of Games*, Vol. 4 (1959), 13-42.

¹⁹Nash, J.F. (1950). “Equilibrium Points in N -Person Games.” *Proceedings of the National Academy of Sciences*, 36(1), 48-49.

²⁰Daskalakis, C., Goldberg, P. W. & Papadimitriou, C. H. (2009). “The Complexity of Computing a Nash Equilibrium.” *SIAM Journal on Computing*, 39(1), 195-259.

²¹Chen, X., Deng, X. & Teng, S.-H. (2009). “Settling the Complexity of Computing Two-Player Nash Equilibria.” *Journal of the ACM*, 56(3), 1-57.

²²Szafron, D., Gibson, R. & Sturtevant, N. (2013). “A Parameterized Family of Equilibrium Profiles for Three-Player Kuhn Poker.” *Proc. AAMAS 2013*, 247-254. В тройния Кун покер един играч може да прехвърля печалба от единия противник към другия, без да напуска семейството от равновесия.

и 11), тъй като пряката еквивалентност между равновесието на Наш и минимакс оптималността вече не важи.

2.5 Напасване на съжалението – градивният елемент

Преди CFR да може да минимизира съжалението в дърво на играта, е необходим механизъм за минимизиране на съжалението в отделна точка на вземане на решение. **Напасването на съжалението** изпълнява тази функция.

Идеята е следната: след множество изиграни рундове, за всяко **действие** a се изчислява **натрупаното съжаление** – с колко по-добър резултат бихте се справили, ако винаги бяхте избирали a вместо действително използваната **смесена стратегия**. След това следващата **стратегия** се определя пропорционално на *положителните* стойности на **съжалението**:

$$\sigma^{T+1}(a) = \begin{cases} \frac{R^{T,+}(a)}{\sum_{a'} R^{T,+}(a')} & \text{ако } \sum > 0 \\ \frac{1}{|A|} & \text{в противен случай} \end{cases}$$

Гаранция за сходимост: Blackwell (1956)²³ и Hart и Mas-Colell (2000)²⁴ доказват, че при използване на **напасване на съжалението** средното съжаление клони към нула със скорост $O(1/\sqrt{T})$ (натрупаното съжаление расте не по-бързо от $O(\sqrt{T})$). В игра за двама играчи с нулева сума, ако и двамата играчи прилагат **напасване на съжалението** в своите точки на вземане на решение, **средният стратегически профил** се сближава до **равновесие на Наш**.

Прост пример е **камък-ножица-хартия**. Ако прилагате **напасване на съжалението** срещу постоянен противник, който винаги избира **камък**, вашето натрупано съжаление за **хартия** нараства (тъй като хартията побеждава камъка), докато съжалението за **ножица** става отрицателно и не влияе на стратегията. Стратегията бързо преминава към хартия – правилният най-добър отговор.²⁵

2.6 Минимизиране на контрафактичното съжаление (CFR)

CFR (Zinkevich и др., 2007)²⁶ разширява **напасването на съжалението** към игрите в разгърната форма: общото **съжаление** се разлага на **локални съжаления** във всяко **информационно множество** и всяко от тях се минимизира независимо чрез **напасване на съжалението**. Ако средно-

²³Blackwell, D. (1956). "An Analog of the Minimax Theorem for Vector Payoffs." *Pacific Journal of Mathematics*, 6(1), 1-8.

²⁴Hart, S. & Mas-Colell, A. (2000). "A Simple Adaptive Procedure Leading to Correlated Equilibrium." *Econometrica*, 68(5), 1127-1150.

²⁵Neller, T.W. & Lanctot, M. (2013). "An Introduction to Counterfactual Regret Minimization," §2-3 (версия от 9 юли 2013 г.).

²⁶Zinkevich, M., Johanson, M., Bowling, M. & Piccione, C. (2007). "Regret Minimization in Games with Incomplete Information." *Advances in Neural Information Processing Systems* 20, 1729-1736.

то съжаление във всяко информационно множество клони към нула, цялостната *средна* стратегия клони към равновесие на Наш.

„**Контрафактичната**“ част е от решаващо значение. Във всяко информационно множество I съжалението за действие a не е просто „колко по-добро би било a “. То представлява *контрафактичното* съжаление – подобрението, което би настъпило, ако играчът умишлено бе избрал да достигне до I (вероятност за достигане = 1 за играча), като останалите условия (стратегия на противника и случайни събития) останат непроменени. Формално:

$$R^T(I, a) = \sum_{t=1}^T \pi_{-i}^t \cdot (v^t(I, a) - v^t(I))$$

където π_{-i}^t е вероятността за достигане на противника, а $v^t(I, a)$ представлява контрафактичната стойност на действието a в I при итерация t .

Защо вероятността за достигане на противника? Съжалението в дадено информационно множество има по-голяма тежест, когато съществува по-голяма вероятност противникът да е изиграл така, че да се достигне до него. Претеглянето с π_{-i} прави съжалението пропорционално на честотата, с която информационното множество е „от значение“ за крайния резултат от играта.

В използваната тук реализация (извадка на случайните събития, по Neller и Lanctot, 2013²⁵) всяка итерация изтегля едно раздаване на картите, обхожда дървото с напасване на съжалението във всяко информационно множество и обновява съжаленията, претеглени с вероятността за достигане на противника, и сумите на стратегиите, претеглени със собствената вероятност за достигане на играча. Изходът е **средната** стратегия, а не стратегията от последната итерация.

Сходимост: експлоатируемостта на средната стратегия намалява като $O(1/\sqrt{T})$ с броя на итерациите T , като границата е линейна по броя на информационните множества (Теорема 4, Zinkevich и др. 2007);²⁶ по-късно е доказана и по-тясна граница.²⁷

2.7 Математиката на покера

Покерът съчетава три източника на сложност, които рядко се срещат в комбинация: **скрита информация** (едно и също информационно множество може да съответства на много различни действителни състояния на играта), **стохастични елементи** (раздаването на картите въвежда случайни възли в дървото, така че стратегията трябва да отчита всички възможни раздавания) и **стратегическо заблуждение** (играч, който винаги залага със силни ръце и пасува със слаби, е тривиално експлоатируем, затова равновесието на Наш изисква **рандомизирано блъфиране с математически точно определени честоти**, които Chen и Ankenman извеждат аналитично за

²⁷Lanctot, M., Waugh, K., Zinkevich, M. & Bowling, M. (2009). “Monte Carlo Sampling for Regret Minimization in Extensive Games.” *Advances in Neural Information Processing Systems* 22, 1078–1086.

опростени игри²⁸).

2.8 Кун покер – най-простото изпитателно поле

Кун покер (Kuhn, 1950) е стандартният минимален пример за алгоритми в игри с непълна информация. С едва три карти, двама играчи и 12 информационни множества той е достатъчно малък, за да бъде решен аналитично, но същевременно достатъчно богат, за да демонстрира ключовите явления: блъфиране, информационна асиметрия и смесени равновесия.

Правила: Три карти {J, Q, K}; всеки играч внася начален залог от 1 жетон и получава по една тайна карта. Играч 0 действа пръв – пас или залог. Играч 1 отговаря – пас или залог. Ако Играч 0 е пасувал, а Играч 1 е направил залог, Играч 0 има право да отговори отново. Победител е играчът с по-висока карта при разкриването.

Равновесие на Наш (параметризирано с $\alpha \in [0, 1/3]$):

- **Играч 0 с J:** Залог (блъф) с вероятност α . Ако след пас срещне залог, винаги се отказва.
- **Играч 0 с Q:** Винаги пас. Ако след пас срещне залог, плаща с вероятност $1/3 + \alpha$.
- **Играч 0 с K:** Залог с вероятност 3α . Ако след пас срещне залог, винаги плаща.
- **Играч 1 с J:** След пас – залог (блъф) с вероятност $1/3$. След залог – винаги се отказва.
- **Играч 1 с Q:** След пас – винаги пас. След залог – плаща с вероятност $1/3$.
- **Играч 1 с K:** Винаги залага и винаги плаща.

(Стратегията на Играч 1 е една и съща във всички равновесия; от α зависи само стратегията на Играч 0. Стратегията, до която стига CFR, е показана на последната фигура в раздела „Емпирични визуализации“.)

Стойност на играта: При това равновесие очакваната печалба на Играч 0 е $-1/18 \approx -0,0556$. Играч 0 е в структурно неблагоприятна позиция, тъй като действа пръв. Как обучението се доближава до тази стойност, показва първата фигура в раздела „Емпирични визуализации“.

Защо Кун е важен: всяка ключова концепция при решаването на игри с непълна информация се проявява тук в умален вид. Ако вашият алгоритъм не може да реши Кун коректно, той няма да може да реши нищо друго.²⁹

2.9 Експлоатируемост – мярка за отклонението от равновесието на Наш

Експлоатируемостта е основният оценителен показател за стратегии в игри с непълна информация. Тя измерва доколко една стратегия може да бъде експлоатирана от противник в най-лошия

²⁸Chen, B. & Ankenman, J. (2006). *The Mathematics of Poker*. ConJelCo – аналитично извеждане на равновесия на Наш за опростени варианти на покер.

²⁹Kuhn, H.W. (1950). “Simplified Two-Person Poker.” *Contributions to the Theory of Games*, Vol. 1, Annals of Mathematics Studies 24, Princeton University Press, 97–103.

случай:

$$\text{exploit}(\sigma) = BR_0(\sigma_1) + BR_1(\sigma_0)$$

където $BR_i(\sigma_{-i})$ представлява очакваната печалба на играч i при прилагането на неговия най-добър отговор спрямо стратегията на противника. В игра за двама играчи с нулева сума тази сума се нарича още NashConv; OpenSpiel отчита като „експлоатируемост“ половината от нея, така че стойностите по двете конвенции се различават два пъти. В равновесие на Наш експлоатируемостта е точно нула; за приблизителни равновесия на Наш тя измерва качеството на приближението.

Изчисляването на най-добър отговор в игри с непълна информация е деликатно: най-добре реагиращият играч трябва да избере едно и също действие във всички състояния в рамките на едно информационно множество. Изборът на най-доброто действие за всяко отделно състояние на играта (използвайки знанието за тайната карта на противника) изчислява приблизителна стойност, а не истински най-добър отговор. За Кун покер е достатъчно да се изброят всички $2^6 = 64$ чисти стратегии.

Скорост на сходимост: Теоретично експлоатируемостта на средната стратегия на CFR намалява като $O(1/\sqrt{T})^{26}$ (вж. втората фигура в раздела „Емпирични визуализации“). В двулогаритмична диаграма това се проявява като права линия с наклон $\approx -0,5$. При пет начални числа и контролни точки от 100 до 100 000 итерации измереният наклон е $-0,52 \pm 0,02$, което съответства на границата $O(1/\sqrt{T})$; тя е горна граница, а не точна прогноза за скоростта.

Защо не просто стойност на играта? Една стратегия може да постигне правилната стойност на играта, но въпреки това да бъде експлоатируема. Представете си стратегия за Кун покер, при която Играч 1 винаги блъфира с Вале (вместо в $1/3$ от случаите). Средната стойност на играта може да е близо до $-1/18$, но стратегията е силно експлоатируема – Играч 0 може винаги да плаща с Дама и да печели. Експлоатируемостта улавя това; самата стойност на играта не го прави.

Тази метрика се появява многократно в дисертацията. Глави 7–8 (моделиране на противника, безопасна експлоатация) използват експлоатируемостта като основна мярка. Тя е и отправната точка на методологията за оценяване в дисертацията (Принос №3).

2.10 Връзки с Глава 1 и бъдещи насоки

Локална оптимизация → глобална сходимост. В Глава 1 Q-обучението намалява TD грешката за всяко състояние поотделно, но в табличния случай Q-функцията доказано се сближава до оптималната. В Глава 2 CFR минимизира съжалението за всяко информационно множество поотделно, но цялостната *средна* стратегия се сближава до равновесие на Наш. И двете демонстрират един и


същ принцип: локалните актуализации, когато са правилно структурирани, постигат глобални цели.

Натрупване на стратегии $\approx$ повторение на натрупан опит. CFR извежда *средната* стратегия, а не стратегията от последната итерация. Това осредняване стабилизира сходимостта, по същия начин както повторението на натрупан опит в DQN стабилизира обучението, като предотвратява преобучението на агента върху последните преходи.

Напред: при по-големи игри дори CFR с извадка на случайните събития е изчислително непосилен;³⁰ Глава 3 обхожда само извадка от дървото (Монте Карло CFR), Глава 4 намалява размера на играта чрез абстракция, а Глава 5 заменя табличните стратегии с невронни мрежи.


2.11 Емпирични визуализации

За да се потвърдят **теоретичните гаранции** на CFR и приложението му към **Кун покер**, в хода на обучението бяха наблюдавани няколко показателя.




Фигура 3: Средната печалба на Играч 0 при изтеглените раздавания, усреднена от началото на обучението, се колебае около теоретичната стойност $-1/18$ в рамките на шума от извадката. Точната стойност на средната стратегия след 100 000 итерации е $-0,0555$.

³⁰Bowling, M., Burch, N., Johanson, M. & Tammelin, O. (2015). "Heads-up limit hold'em poker is solved." *Science*, 347(6218), 145–149. С CFR+ хедс-ъп лимит тексаски Холдем е решен по същество (в слаб смисъл) – първата нетривиална игра с непълна информация, играна състезателно от хора, която е решена.



Фигура 4: Експлоатируемост на средната стратегия спрямо броя на итерациите в двулогаритмичен мащаб, средно за пет начални числа; оцветената ивица показва обхвата между тях. Измерените точки следват приблизително еталонния наклон $O(1/\sqrt{T})$ (прекъснатата линия), което съответства на теоретичната граница.



Фигура 5: Средната стратегия, получена с CFR за Кун покер след 100 000 итерации: вероятностите за действие във всяко информационно множество. Честотите на блъф с Вале и на плащане с Дама са близки до семейството от равновесия на Наш ($\alpha \approx 0,18$).

3 Глава 3 – Варианти на CFR и методи на Монте Карло

3.1 Защо обикновеният вариант на CFR се проваля при голям мащаб

В Глава 2 беше създаден работещ решавач с обикновения вариант на CFR за Кун покер – 12 информационни множества, 58 възела (30 от тях крайни), решим за милисекунди. Това създава грешно впечатление. Обикновеният вариант на CFR изисква **пълно обхождане на дървото на играта при всяка итерация**, а истинските игри не са като Кун покер. Ледюк покер има 936 информационни множества (~78 пъти повече), а лимитният тексаски Холдем – над 10^{14} , като едно-единствено обхождане на дървото му е отнело около час на 4800 процесорни ядра (вж. раздел 3.8).

Глава 3 преодолява проблема с мащаба чрез два взаимно допълващи се механизма: **CFR+ (Tammelin, 2014)**³¹, който постига значително по-бърза сходимост и е алгоритъмът, който „реша“ лимитния тексаски Холдем за двама играчи през 2015 г., и **Монте Карло CFR (Lanctot и др., 2009)**³², който взема проба от малка част от дървото, вместо да го обхожда изцяло – всяка итерация е стотици до хиляди пъти по-евтина, за сметка на по-шумни актуализации. Другият път, абстракцията на играта, е предмет на Глава 4.

За дисертацията тези решавачи изчисляват базовата стратегия на равновесие на Наш – опорната точка „играй на сигурно“, от която адаптивният агент се отклонява въз основа на наблюденията върху опонента (Принос №1). В игрите с размера на Кун и Ледюк това е CFR+ (вж. раздел 3.7), а MCCFR става необходим при по-големите игри.

3.2 Търсене с метод Монте Карло в дърво като вдъхновение

Търсене с метод Монте Карло в дърво (MCTS) използва **случайна извадка** за оценка на позиции в дървото на играта без изчерпателно изброяване – „оценявай някои клонове до пълна дълбочина вместо всички клонове до фиксирана дълбочина“. То изгражда асиметрично дърво, като играе случайни игри от обещаващи възли и разпространява резултатите им обратно по посещения път, докато минимакс с алфа-бета подрязване оценява всеки релевантен възел до фиксирана дълбочина и прилага евристика в крайните възли. За Го (коефициент на разклоняване ~250, без добра оценъчна функция преди невронните мрежи) MCTS беше пробивът; същият принцип „извадка вместо изброяване“ се пренася чрез MCCFR към дърветата на игрите с непълна информация.³³

³¹Tammelin, O. (2014). “Solving Large Imperfect Information Games Using CFR+.” arXiv:1407.5042. Резултатът за лимитния тексаски Холдем за двама играчи е Bowling, M., Burch, N., Johanson, M. & Tammelin, O. (2015). “Heads-up limit hold’em poker is solved.” *Science*, 347(6218), 145-149.

³²Lanctot, M., Waugh, K., Zinkevich, M. & Bowling, M. (2009). “Monte Carlo Sampling for Regret Minimization in Extensive Games.” *Advances in Neural Information Processing Systems* 22, 1078-1086.

³³Browne, C. et al. (2012). “A Survey of Monte Carlo Tree Search Methods.” *IEEE Transactions on Computational Intelligence and AI in Games*, 4(1), 1-43.

3.3 Марковски вериги и законът за големите числа

„Метод Монте Карло“ в MCCFR обозначава широко семейство изчислителни методи, които използват **повтаряща се случайна извадка** за получаване на числени резултати. Ключовата теоретична гаранция е **законът за големите числа**: ако се изтеглят независимо достатъчно много траектории, средната стойност на извадката клони към истинската очаквана стойност. За MCCFR, при фиксиран профил от стратегии:

$$\frac{1}{T} \sum_{t=1}^T \hat{v}_I^{(t)} \xrightarrow{T \rightarrow \infty} v_I$$

където $\hat{v}_I^{(t)}$ представлява извадената контрафактична стойност в информационно множество I на итерация t , а v_I е истинската стойност, която обикновеният вариант на CFR изчислява точно. Тези извадкови стойности са **неизместени оценки** – очакваната им стойност съвпада с истинската. Заедно с ограничение отдолу на вероятностите за извадка това осигурява, с вероятност поне $1 - p$, същото намаляване на средното съжаление от порядъка $O(1/\sqrt{T})$ като при CFR с пълно обхождане³².

Цената е **дисперсия**: отделните извадки могат значително да се отклоняват от истинската стойност, което налага повече итерации за постигане на същата прецизност. Този компромис между дисперсия и скорост е основната тема на главата.³⁴

3.4 Ледюк покер – по-голяма еталонна игра

Кун покер улавя същността на непълната информация в най-малкото възможно дърво на играта. Ледюк покер увеличава мащаба с приблизително два порядъка – все още решим точно, но достатъчно голям, за да станат значими разликите между алгоритмите:

Таблица 1: Сравнение между Кун и Ледюк покер: карти, кръгове на залагане, информационни множества и размер на дървото.

Свойство	Кун покер	Ледюк покер
Карти	3 (J, Q, K)	6 ($\{J, Q, K\} \times \{\spadesuit, \heartsuit\}$)
Кръгове	1	2 (префлоп + обща карта)
Обща карта	Няма	1 разкрита между кръговете

³⁴Sutton, R.S. & Barto, A.G. (2018). *Reinforcement Learning: An Introduction*, второ издание. MIT Press. Гл. 1 (областта); гл. 3 (крайни марковски процеси на вземане на решения); гл. 4 (динамично програмиране); гл. 5 (методи на Монте Карло); гл. 6 (обучение с темпорална разлика). <http://incompleteideas.net/book/the-book-2nd.html>

Свойство	Кун покер	Ледюк покер
Класиране на ръка	Само висока карта	Чифт (частна = обща) бие висока карта
Размери на залози	Фиксирани (1 жетон)	Променливи (2 в първи кръг, 4 във втори кръг)
Максимален брой вдигания в кръг	1	2
Информационни множества	12	936
Възли на игрово дърво	58	10 200
Случайни изходи	6	120

Появяват се три качествено нови характеристики: информацията се променя между кръговете (разкриване на общата карта), вале може да стане най-силната ръка, ако и общата карта е вале, а вдигането с 4 жетона във втория кръг придава по-голямо тегло на по-късните решения.

Въпреки че е приблизително 78 пъти по-голям от **Кун**, **Ледюк** остава достатъчно малък за точно изчисление (пълно обхождане на дърво отнема около 50 ms). Това го прави идеална еталонна игра: достатъчно голяма, за да бъдат значими разликите в производителността, и достатъчно малка, така че всички алгоритми да могат да достигнат почти пълна сходимост в рамките на минути.³⁵

3.5 CFR+ – Трикът с нулирането на отрицателните съжаления

CFR+ въвежда три малки изменения в обикновения вариант на CFR, всяко от които е лесно за реализиране, но води до съществени резултати.

Нулиране на отрицателните съжаления. При обикновения вариант на CFR кумулативното **съжаление** може да става произволно отрицателно; CFR+ задава долна граница на съжаленията при нула след всяка итерация:

$$R^{T+1}(I, a) = \max(R^T(I, a) + r^T(I, a), 0)$$

Това предотвратява натрупването на големи отрицателни съжаления за дадено действие, които биха отнели множество итерации, за да се „изплатят“, преди действието отново да бъде разглеждано. Аналогията с активационната функция ReLU в невронните мрежи е пряка: и двете занулават отрицателните стойности.

³⁵Southey, F. et al. (2005). “Bayes’ Bluff: Opponent Modelling in Poker.” *UAI*. arXiv:1207.1411.

Линейно претеглено усредняване на стратегиите. При CFR+ стратегията от итерация t получава тегло t в текущата средна, така че по-късните итерации – които се характеризират с по-малко съжаление и по-добри стратегии – оказват по-голямо влияние, а ранните, шумни итерации получават по-ниска тежест.


Редуващи се актуализации. CFR+ обновява двамата играчи последователно в рамките на всяка итерация, така че обновяването на втория играч вече отчита новата стратегия на първия.

Комбиниран ефект: емпиричната сходимост се подобрява от $O(1/\sqrt{T})$ до приблизително $O(1/T)$. При Ледюк CFR+ достига $2,0 \times 10^{-4}$ след около 1100 итерации; при измерената скорост на обикновения вариант на CFR за същата стойност биха били нужни от порядъка на два милиона итерации (екстраполация). Скоростта $O(1/T)$ се наблюдава последователно, но не е доказана; доказана е само общата за семейството горна граница $O(1/\sqrt{T})$ ³⁶, чието първоначално доказателство е коригирано от Burch и др.³⁷


Тук експлоатируемост означава средната печалба на най-добрия отговор срещу двамата играчи, $(BR_0 + BR_1)/2$; NashConv е сумата им, т.е. двойно по-голяма. При Ледюк след 5000 итерации реализацията на CFR+ в OpenSpiel достига експлоатируемост $\approx 1,8 \times 10^{-5}$, докато обикновеният вариант на CFR все още е около $3,6 \times 10^{-3}$ – подобрене приблизително 190 пъти, постигнато с две от трите модификации (и двата решавача на OpenSpiel редуват актуализациите).³¹

³⁶Tammelin, O., Burch, N., Johanson, M. & Bowling, M. (2015). “Solving Heads-Up Limit Texas Hold’em.” *Proc. IJCAI*, 645–652.

³⁷Burch, N., Moravčík, M. & Schmid, M. (2019). “Revisiting CFR+ and Alternating Updates.” *Journal of Artificial Intelligence Research*, 64, 429–443. DOI 10.1613/jair.1.11370.



Фигура 6: Ледюк покер: експлоатируемост спрямо броя на итерациите при четирите решавача на OpenSpiel



Фигура 7: Ледюк покер: експлоатируемост спрямо времето за обучение при четирите решаваща на OpenSpiel

3.6 MCCFR – Извадка от дървото на играта

MCCFR заменя пълното обхождане на дърво с частично извадково обхождане. Два варианта се разполагат върху една и съща крива дисперсия–скорост в различни точки:


Таблица 2: Външно вземане на проби и извадка по резултати: от какво взема извадка всеки вариант при всеки тип възел и каква е цената на една итерация.

Вариант	Възли на случайността	Възли на обхождащия играч	Възли на опонента	Цена на итерация
Външно вземане на проби	Извадка от едно раздаване	Разглеждане на всички действия	Извадка от едно действие	~42 възела (~945× по-бързо от пълното)
Извадка по резултати	Извадка от едно раздаване	Извадка от едно действие (ε-микс с текущата стратегия)	Извадка от едно действие	~5,5 възела (~2 228× по-бързо)


Външно вземане на проби разглежда всички възможни действия във възлите на играча, който актуализира стратегията си, но взема извадка във възлите на случайността и във възлите на противника, така че всяка итерация обхваща малка част от дървото. **Извадката по резултати** тегли една-единствена траектория до край; тъй като действията във възлите на играча, който актуализира стратегията си, също се изваждат, актуализацията на съжалението трябва да бъде коригирана чрез **извадка по важност** – отношението между истинската вероятност за достигане и вероятността за извадка. Един ε-микс (с вероятност ε действието се избира равномерно, а в противен случай – според текущата стратегия) гарантира, че всички действия се разглеждат, дори когато текущата стратегия им присвоява нулева вероятност.

И за двата подхода извадковите контрафактични стойности са **неизместени оценки** на действителните стойности (Lanctot и др., лема 1); заедно с техните граници за съжалението (теорема 4 и 5) това гарантира сходимост към приблизително равновесие на Наш въпреки шума от извадката. Цената е дисперсията: всяка извадкова актуализация отразява само едно възможно раздаване, а не очакваната стойност за всички раздавания.

При Кун покер всички алгоритми се изпълняват за секунди, а подредбата им вече е същата като при Ледюк: след 5000 итерации CFR+ достига експлоатируемост $\approx 3 \times 10^{-5}$, обикновеният CFR – $\approx 2 \times 10^{-4}$, а външното вземане на проби и извадката по резултати – $\approx 0,013$ и $\approx 0,04$ (решавачът от Глава 2, който тегли по едно раздаване на итерация, е при $\approx 0,006$):



Фигура 8: Кун покер: експлоатируемост спрямо броя на итерациите



Фигура 9: Кун покер: експлоатируемост спрямо времето за обучение

За да се прояви компромисът, дървото на играта трябва да бъде достатъчно голямо, така че разходът на итерация да има значение. Именно затова е необходим **Ледюк**.³²

3.7 Компромисът между дисперсия и скорост

И четирите алгоритъма имат гарантирана горна граница на експлоатируемостта от порядъка $O(1/\sqrt{T})$ – за CFR³⁸, за MCCFR с вероятност поне $1 - p^{32}$ и за CFR+^{36,37}. Измерената скорост обаче се различава: двата варианта на MCCFR следват наклон около $-0,4$ до $-0,5$, обикновеният CFR – около $-0,8$, а CFR+ – около $-1,8$. Затова моделът $\epsilon(T) = C/\sqrt{T}$ по-долу е приближение (при обикновения CFR произведението $\epsilon\sqrt{T}$ намалява от 0,94 до 0,27), а за CFR+ не е приложим. Преобразуването към време за изпълнение става чрез $C_w = C/\sqrt{\text{скорост}}$:

³⁸Zinkevich, M., Johanson, M., Bowling, M. & Piccione, C. (2007). “Regret Minimization in Games with Incomplete Information.” *Advances in Neural Information Processing Systems* 20.

Таблица 3: Измерени константи на сходимост за четирите решавача – на итерация и по време на изпълнение.


Алгоритъм	$C_{\text{итер}}$	Скорост (ите- рации/сек)	C_w (по време на изпълнение)	C_w спрямо обикновения CFR
Обикновен вариант на CFR	0,34	20,6	0,075	1,0×
CFR+	–	20,6	–	не следва $C/\sqrt{T}$ (вж. текста)
MCCFR, външно вземане на проби	107	19 470	0,767	10,2× ($\approx 105 \times$ повече време)
MCCFR, извадка по резултати	245	45 901	1,143	15,3× ($\approx 233 \times$ повече време)

Константата по време на изпълнение определя представянето на практика. Въпреки че външно-то вземане на проби е 945 пъти по-бързо на итерация, неговата константа на дисперсията (107 спрямо 0,34) е 315 пъти по-голяма. Предимството в скоростта **не компенсира наказанието от дисперсията**:

$$\frac{99,000 \times \text{повече итерации}}{945 \times \text{по-бърза итерация}} \approx 105 \times \text{повече време за изпълнение}$$


Защо се наблюдава дисперсия? Обикновеният вариант на CFR изчислява **точни** контрафактични стойности чрез изброяване на всички 120 раздавания. Неговото обновяване на съжалението има нулева дисперсия. MCCFR взема проба от едно раздаване на итерация. Дори ако обходи цялото поддърво за това раздаване, пак ще се наблюдава дисперсия между различните раздавания – следствие от извадката на случайното събитие (раздаването), а не от начина на обхождане в рамките на едно раздаване.

Сравнителен тест с бюджет от 180 секунди за всеки от четирите варианта върху Ледюк прави сравнението по време на изпълнение конкретно. Изглед по итерации (вариантите с извадка извършват милиони обновявания, а вариантите с пълно обхождане – само няколко хиляди):



Фигура 10: Ледюк покер, собствени реализации с бюджет от 180 s за всеки алгоритъм: експлоатируемост спрямо броя на итерациите

Изглед по време на изпълнение – справедливото сравнение (при еднакви изчислителни разходи кой алгоритъм дава най-добрата стратегия?):



Фигура 11: Ледюк покер, собствени реализации с бюджет от 180 s за всеки алгоритъм: експлоатируемост спрямо времето за изпълнение

CFR+ достига експлоатируемост от $2,6 \times 10^{-5}$ – практически точно равновесие на Наш – за 3 минути. Обикновеният вариант на CFR следва с $4,4 \times 10^{-3}$. Двата варианта на MCCFR изостават 12–23 пъти от обикновения CFR и три до четири порядъка от CFR+ при този размер на играта.

3.8 Кога MCCFR надделява – точката на пресичане

Тази закономерност поставя очевиден въпрос: ако MCCFR винаги е по-слаб в Ледюк, защо тогава беше изобретен? Отговорът се крие във факта, че разходът на итерация при обикновения вариант на CFR нараства линейно с размера на дървото $|N|$, докато този на MCCFR расте много по-бавно (при външното вземане на проби – приблизително като $\sqrt{|N|}$ ³²). При достатъчно голям мащаб линейната цена надделява. Критичният размер на дървото е:

$$|N|_{\text{пресичане}} = |N|_{\text{Ледюк}} \cdot \left(\frac{C_{mc}}{C_v} \right)^2 \cdot \frac{\text{скорост}_v}{\text{скорост}_{mc}}$$

При заместване на измерените стойности:

Таблица 4: Размер на играта, при който MCCFR изпреварва обикновения вариант на CFR, по вариант на извадката.

Вариант	$ N _{\text{пресичане}}$
Външно вземане на проби	~1,1 милиона възела
Извадка по резултати	~2,4 милиона възела

Сравнение с реални игри:

Таблица 5: Прагът на пресичане, приложен към три реални игри.

Игра	$ N $	Печели ли външното вземане на проби?	Печели ли извадката по резултати?
Ледюк покер	10 200	Не (105 пъти под прага)	Не (233 пъти под прага)
Лимитен тексаски Холдем за двама играчи	$\sim 3 \times 10^{17}$	Да по модела ($\sim 10^{11}$ пъти над прага), но е решен с CFR+ с пълно обхождане	Да по модела
Безлимитен тексаски Холдем	до $\sim 6 \times 10^{164}$	Да	Да

При Ледюк пълното обхождане доминира, тъй като цялото дърво на играта се побира в паметта и може да бъде изброено за милисекунди. Оценката е от порядъка на величината и важи за тази реализация: константите са измерени само върху Ледюк, обикновеният CFR е моделиран като $C/\sqrt{T}$, въпреки че се сближава по-бързо, а ако цената на итерация на MCCFR расте като $\sqrt{|N|}$, същите данни дават праг около 10^8 възела.

При реалните мащаби на покера заключението се обръща, но не навсякъде. Лимитният тексаски Холдем за двама играчи ($3,16 \times 10^{17}$ състояния) все пак е решен с CFR+ с пълно обхождане – 1579 итерации по около 61 минути на 4800 процесорни ядра³⁹ – като авторите отчитат, че CFR+ изисква значително по-малко изчисления от вариантите на CFR с извадка. Безлимитният тексаски

³⁹Bowling, M., Burch, N., Johanson, M. & Tammelin, O. (2015). “Heads-up limit hold’em poker is solved.” *Science*, 347(6218), 145–149. DOI 10.1126/science.1259433. Използва CFR+ за решаването на лимитния тексаски Холдем за двама играчи – първата нетривиална игра с непълна информация, играна състезателно от хора, която по същество е решена.

Холдем (до $6,31 \times 10^{164}$ състояния във форматите на АСПС⁴⁰) е недостижим за пълно обхождане; там практическият път е извадката – MCCFR в комбинация с абстракция и с разширения за намаляване на дисперсията⁴¹.

3.9 Връзки с Глава 2 и бъдещи насоки

Същият принцип, различен режим. Глава 3 запазва принципа от Глава 2, според който минимизирането на съжалението локално във всяко информационно множество води глобалната стратегия към равновесие на Наш, но въвежда две независими усъвършенствания: CFR+ променя начина на акумулиране на съжаленията (нулиране на отрицателните съжаления + линейно претегляне), а MCCFR модифицира начина на измерването им (извадкова оценка вместо точна очаквана стойност). И двете обикновено извеждат **средната** стратегия, макар че при знаковото решаване на лимитния тексаски Холдем за двама играчи с CFR+ са използвани текущите стратегии на играчите.³⁹

Напред:

- **Глава 4 (Абстракция на играта и мащабиране)** – редуцира самото дърво чрез абстракция на състоянията и действията; в комбинация с MCCFR това прави решаването на реалния покер изчислително постижимо.
- **Глава 5 (Невронни мрежи за игри с непълна информация)** – заменя табличното съхранение на стратегията с невронни апроксиматори на функции, използвайки рамката за извадка на MCCFR като двигател за генериране на данни. Свойствата на дисперсията, установени тук, обясняват защо Деер CFR използва външно вземане на проби и защо неговият наследник DREAM, който преминава към извадка по резултати, добавя обучена базова стойност за намаляване на дисперсията.
- **Глава 6 (Архитектури на игрови изкуствен интелект от край до край)** – надгражда както върху CFR+, така и върху MCCFR за създаване на пълноценни агенти. Реализацията на Ледюк, разработена за тази глава, остава еталонната среда в следващите глави.⁴²

⁴⁰Johanson, M. (2013). “Measuring the Size of Large No-Limit Poker Games.” arXiv:1302.7008.

⁴¹Schmid, M., Burch, N., Lanctot, M., Moravčík, M., Kadlec, R. & Bowling, M. (2019). “Variance Reduction in Monte Carlo Counterfactual Regret Minimization (VR-MCCFR) for Extensive Form Games Using Baselines.” *Proc. AAAI*, 33(01), 2157–2164.

⁴²Brown, N. & Sandholm, T. (2017). “Safe and Nested Subgame Solving for Imperfect-Information Games.” *NeurIPS* – свързва табличния CFR с декомпозицията на под-игра за реалния покер.

4 Глава 4 – Абстракция на играта и мащабиране на игри с непълна информация

4.1 Защо е необходима абстракцията

Глави 1–3 изградиха алгоритмите. Всеки от тях беше демонстриран върху игра с достатъчно малък размер, за да може дървото на играта ѝ да бъде изброено точно: Кун (12 информационни множества) и Ледюк (936). Този набор от инструменти е завършен, но той функционира единствено когато цялото дърво на играта се побира в паметта.

Размерът на реалната игра нараства със скритите карти, с разклоняването по размерите на залога и с дълбочината на залагането: лимитният тексаски Холдем за двама играчи достига $3,16 \times 10^{17}$ състояния,⁴³ а броят на информационните множества в безлимитния тексаски Холдем за двама играчи е $\sim 10^{161}$ – около 10^{80} пъти повече от броя на атомите в наблюдаемата вселена. Нито един от алгоритмите от Глава 3 не може да работи върху това дърво.⁴⁴

Механизмът, който преодолява тази пропаст, е **абстракцията**: умишлено свеждане на части от играта до по-опростен вид, така че същите алгоритми да могат да се прилагат върху по-малък, структурно опростен заместител и да се измери цената на това в качеството на стратегията. Централният въпрос на всеки практически изкуствен интелект за покер след 2007 г. е:

До каква степен може да се намали размерът на играта, преди равновесната стратегия на абстрактната игра да престане да бъде добра стратегия в реалната игра?

Отговорът е крива на Парето: размерът на абстрахираната игра срещу **разликата в експлоатируемостта** – с колко абстрактната стратегия е по-лоша от точното равновесие на Наш в реалната игра.

Рецептата е една и съща за всеки подход: *изгражда се по-малка игра, чиито стратегии могат да бъдат трансформирани в приложими стратегии за реалната игра, изпълняват се алгоритмите от Глава 3 върху тази по-малка игра и след това се оценяват загубите*. Тази рецепта може да се следва по два пътя.

4.2 Пътища към абстракцията

В тази глава думата „абстракция“ се използва в два оперативно различни смисъла; в литературата невронното приближение обикновено се представя като алтернатива на абстракцията, а не като

⁴³Bowling, M., Burch, N., Johanson, M. & Tammelin, O. (2015). “Heads-up limit hold’em poker is solved.” *Science*, 347(6218), 145–149. DOI 10.1126/science.1259433. Използва CFR+ за решаването на лимитния тексаски Холдем за двама играчи – първата нетривиална игра с непълна информация, играна състезателно от хора, която по същество е решена.

⁴⁴Johanson, M. (2013). “Measuring the Size of Large No-Limit Poker Games.” Технически доклад, University of Alberta; arXiv:1302.7008.

неин вид.⁴⁵ Тази глава реализира **явния** път от край до край; тъй като тук не се извършва работа с неявния път, неговите съответствия за всяка фаза са само изброени в таблицата по-долу.

И двата пътя споделят една и съща **интуиция** – компресиране със запазване на стойността – изразена чрез целевата функция на информационното стеснение (по аналогия с едноименния метод⁴⁶), като β е обменният курс между паметта и стойността:

$$\mathcal{L} = \underbrace{\text{Сложност}(Z)}_{\text{цена в памет}} - \beta \cdot \underbrace{\text{Стойност}(\pi_Z)}_{\text{стратегическа стойност}}$$

Когато $\beta = 0$, алгоритъмът компресира цялата игра до едно състояние и играе изключително слабо. Когато $\beta \rightarrow \infty$, той отказва всякакво сливане и използва пълната игра. Всеки алгоритъм в конвейера за абстракции представлява конкретна настройка на този регулатор:

- **Беззагубно сливане** – граничният случай $\beta \rightarrow \infty$: извършва сливане само когато $\text{Стойност}(\pi_Z) = \text{Стойност}(\pi)$ е точно.
- **Ограничена загуба** – средата на кривата с гаранция: избира се β така, че да бъде изпълнено условието $|\text{Стойност}(\pi_Z) - \text{Стойност}(\pi)| \leq \varepsilon_{\text{abs}}$.
- **Емпирична сходност (HSD + разстояние на Васерщайн)** – измерва самата крива: разстоянието на Васерщайн между абстрактното и пълното разпределение служи като заместител на члена за загуба на стойност.
- **Корекция по време на изпълнение** – ортогонален подход: приема се загубата на стойност, произтичаща от избраното β , след което тя се компенсира по време на изпълнение чрез решаване на под-игра.

Таблица 6: Явният и неявният път към абстракцията, сравнени по всеки практически показател.

Аспект	Явен / табличен	Неявен / в стил IB (дълбоко обучение с подкрепление)
Къде се намира компресията	Разбиване на информационните множества / краен избран набор от действия	Непрекъснат латентен вектор $z = f_{\theta}(s)$
Фактор за настройка	k в k -средни, наборът от размери на залога, правилото за изоморфизъм на боите	β умножено по $I(S; Z)$ в загубата

⁴⁵Brown, N., Lerer, A., Gross, S. & Sandholm, T. (2019). “Deep Counterfactual Regret Minimization.” *ICML*.

⁴⁶Tishby, N., Pereira, F. C. & Bialek, W. (1999). “The Information Bottleneck Method.” arXiv:physics/0004057.

Аспект	Явен / табличен	Неявен / в стил IB (дълбоко обучение с подкрепление)
Гаранция	Формална граница на разликата в експлоатируемостта само за беззагубни и ограничени абстракции; за емпиричните (k-средни + EMD) – никаква	Информационнотеоретична граница върху $I(S; Z)$; няма теорема за запазване на равновесието на Наш
Съответствие на всяка фаза	Четири фази на тази глава	Deep Sets, информационно стеснение, научени латентни вграждания; криви скорост–изкривяване и тестова загуба; без отделна фаза на компилация; търсене с ограничена дълбочина с невронни функции на стойността (DeepStack, ReBeL)
Къде се появява в тази дисертация	Тази глава (4)	Глава 5 (Deep CFR), Глава 6 (от край до край), Глава 12 (модели на последователности)

4.3 Видове оси на абстракцията

Всяка конкретна техника се отнася към една от двете взаимно ортогонални оси – *кои състояния агентът разглежда като идентични* (информационна абстракция) и *кои действия агентът обмисля* (абстракция на действията); усъвършенстването по време на изпълнение има собствен раздел по-долу.

4.3.1 Информационна абстракция

Групират се информационните множества, които агентът ще разглежда като едно и също състояние; критерият за сливане, бюджетът на грешките и решенията по време на компилация по-долу са посветени на това *как* и *кога* да се прави. В обикновения вариант на CFR само абстрахирането на **обхождането**, а не единствено на **картата на възлите**, скъсява времето за изпълнение.

4.3.2 Абстракция на действията и проблемът с транслацията

Ограничава се множеството от действия, които решаващът разглежда, изпълнява се CFR върху получената ограничена игра и след това се обработва всичко, което реалният опонент направи извън това ограничение. При непрекъснатите размери на залозите в безлимитния покер това е *задължително* за табличните методи – CFR не може да се изпълнява върху непрекъснатото дърво, без първо да бъде сведено до краен заместител (типичен набор от действия в покера: {отказ, плащане, $0,5 \times \text{пот}$, $1 \times \text{пот}$, $2 \times \text{пот}$, ол-ин}).

Тогава проблемът с транслацията е **значителен**: когато опонентът направи залог от $0,7 \times \text{пот}$, а абстракцията съдържа само $0,5 \times \text{пот}$ и $1 \times \text{пот}$, агентът трябва да транслира този залог към възел, върху който е обучен. Най-често се използват три транслатора:

1. **Най-близко действие** – закръгляне до най-близкия абстрактен залог; най-голяма загуба на стойност, когато залозите се групират между абстрактните размери.
2. **Вероятностно разделяне (линейно)** – масата се разпределя между двата най-близки абстрактни залога според разстоянието.
3. **Псевдохармонично преобразуване** – вероятностно преобразуване, изведено от равновесието на опростена покерна игра; в сравненията на авторите то е значително по-малко експлоатируемо от по-ранните евристични преобразувания и е водещият статичен транслатор преди появата на вложеното решаване на под-игри (по-долу).⁴⁷

Грешките при транслацията се натрупват в отделните рундове на залагане – опонент, който открие закръглянето, може систематично да залага точно под или над точките на решетката, за да предизвика отговори с грешен размер. Такава уязвимост е наблюдавана на практика (агентът Tartanian1, 2007 г.)⁴⁷, и това е оперативната причина за съществуването на корекция по време на изпълнение (по-долу).

4.4 Разлика в експлоатируемостта

За стратегия, изиграна в игра G , експлоатируемостта е стандартният показател от Глава 3. Глава 4 въвежда производна метрика – **разлика в експлоатируемостта**: с колко една абстрактна стратегия е по-лоша от точното равновесие на Наш на реалната игра, *измерено в самата реална игра*.

Нека G е реалната игра, а $\hat{G}$ – нейната абстракция. Нека $\hat{\sigma}^*$ е равновесие на Наш на $\hat{G}$, а $T(\hat{\sigma}^*)$ – неговата транслация обратно в играема стратегия за G (тъждественото преобразуване при чисто информационна абстракция). Тогава

$$\Delta_{\text{abs}}(\hat{G}) = \text{exploit}_G(T(\hat{\sigma}^*)) - \text{exploit}_G(\sigma_G^*)$$

⁴⁷Ganzfried, S. & Sandholm, T. (2013). “Action Translation in Extensive-Form Games with Large Action Spaces: Axioms, Paradoxes, and the Pseudo-Harmonic Mapping.” *IJCAI*, 120–127.

където σ_G^* е точното равновесие на Наш на G . По дефиниция $\Delta_{\text{abs}} \geq 0$, като равенство има, когато абстракцията е беззагубна. Всяка Парето диаграма в тази глава съдържа Δ_{abs} по една от осите; когато директното изчисление е твърде скъпо, бюджетът на грешките по-долу предоставя граница и заместител вместо него.

4.5 Разстояние на Васерщайн: Въведение

Какво измерва. За две вероятностни разпределения върху един и същ носител разстоянието на Васерщайн (Earth Mover's Distance, EMD⁴⁸) е минималното количество „работа“, необходимо за трансформирането на едното в другото, където *работа* = *преместена маса* × *преместено разстояние*. Може да си представим всяко разпределение като купчина пясък върху числова ос – тогава разстоянието на Васерщайн е най-малкото общо усилие за преоформяне на купчина А в купчина Б. За разлика от сравнението на средните стойности, то отчита *геометрията* на разположението на масата: две разпределения, концентрирани в противоположните краища, са далеч едно от друго, независимо къде техните средни стойности съвпадат случайно.

В контекста на тази глава. Всяко информационно множество има *разпределение на силата на ръката (HSD)* – хистограма от вероятностите за победа в края на играта, изчислени чрез разиграване на невидяни карти. Две HSD с една и съща средна стойност могат да имат напълно различна форма: тясно разпределение с един връх („стабилна средна ръка“) или бимодално („успех или провал“). Клъстеризацията по очаквана сила на ръката ги обединява, докато разстоянието на Васерщайн не го прави.

Ефективно при 1-D хистограми. Когато носителът е едномерен и подреден (вероятността за победа $\in [0, 1]$, разделена на интервали), разстоянието на Васерщайн се свежда до **разстоянието на Манхатън** между кумулативните разпределения – едно линейно преминаване през интервалите. Ето защо HSD + разстояние на Васерщайн е достатъчно бързо, за да клъстеризира милиони информационни множества.

4.6 Критерият за сливане

Кога могат две информационни множества да се **обединят** в едно? Три вложени нива на строгост, подредени от най-строгото към най-хлабавото.

4.6.1 Ниво 1 – Беззагубен

Сливане на две информационни множества се допуска единствено когато те са *стратегически еквивалентни*: имат еднаква вероятност за достигане, еднаква рекурсивна структура и водят до ед-

⁴⁸Rubner, Y., Tomasi, C. & Guibas, L. J. (2000). “The Earth Mover's Distance as a Metric for Image Retrieval.” *International Journal of Computer Vision*, 40(2), 99–121.

накви последствия по отношение на полезността срещу всяко възможно продължение от страна на опонента.⁴⁹ Когато това условие е изпълнено, сливането е безплатно: всяка оптимална стратегия в абстрактната игра може да бъде директно приложена към оригиналната игра с **нула** разход за експлоатируемост.

Пример: Червен вале и черен вале в игра, в която боите нямат значение (невъзможни са **флъшове**), могат да се слоят без загуба. Червен вале в игра с **флъшове** не може – боята мълчаливо влияе върху вероятността на опонента да събере **флъш** чрез премахване на карти от тестето.

4.6.2 Ниво 2 – Ограничена загуба

Изискването за „идентични полезности“ се отпуска до „полезностите се различават с най-много ε “. Тогава всяко сливане добавя своето допустимо отклонение към общия бюджет на грешката, който определя граница върху общата експлоатируемост – това е *контролирано* забравяне, а не произволно.

Пример: Обединяването на вале и дама в един „клъстер с ниски карти“ принуждава агента да ги играе еднакво, въпреки че оптимално те се различават леко. Системата поема тази грешка в замяна на значително опростяване на играта.

4.6.3 Ниво 3 – Емпирична сходност

Когато входовете са твърде високодименсионни, за да бъдат изброени (в тексаски Холдем на последния рунд има около $2,4 \times 10^9$ канонични комбинации от скрити и общи карти⁵⁰), границата за сливане се премахва: изчислява се HSD за всяко информационно множество, като мярка за сходство между тях се използва разстоянието на Васерщайн,⁵¹ и се извършва сливане в рамките на клъстерите. Няма формална гаранция – качеството се проверява *след* решаването, а дори по-детайлната абстракция не гарантира по-ниска експлоатируемост.⁵²

4.7 Бюджетът на грешките

Три инструмента за количествена оценка: аналитичната граница оценява сливане от Ниво 2, заместващата оценка чрез разстоянието на Васерщайн оценява сливане от Ниво 3, а третият измерва завършената абстракция, независимо как е била конструирана.

⁴⁹Gilpin, A. & Sandholm, T. (2007). “Lossless Abstraction of Imperfect Information Games.” *Journal of the ACM*, 54(5), art. 25 – GameShrink и резултатът за Род Айлънд Холдем.

⁵⁰Johanson, M., Burch, N., Valenzano, R. & Bowling, M. (2013). “Evaluating State-Space Abstractions in Extensive-Form Games.” *AAMAS*, 271–278.

⁵¹Ganzfried, S. & Sandholm, T. (2014). “Potential-Aware Imperfect-Recall Abstraction with Earth Mover’s Distance in Imperfect-Information Games.” *AAAI*, 28(1).

⁵²Waugh, K., Schnizlein, D., Bowling, M. & Szafron, D. (2009). “Abstraction Pathologies in Extensive Games.” *AAMAS*, 781–788.

4.7.1 Инструмент 1 – Аналитична граница

Допустимите отклонения на отделните сливания се сумират, претеглени с вероятността всяко информационно множество действително да бъде достигнато в игра, и така се получава горна граница на разликата в експлоатируемостта.⁵³ Ключовата идея е претеглянето по вероятността за достигане: небрежното сливане в рядък сценарий от крайната игра почти не оказва влияние върху общия резултат, докато небрежните сливания в гъсти и често посещавани области са катастрофални.

4.7.2 Инструмент 2 – Заместваща оценка чрез разстоянието на Васерщайн

Разстоянието на Васерщайн между хистограмите на силата на ръката на две информационни множества, измерено без изброяване на листата. То е *заместваща оценка*, а не граница, и не носи формална гаранция.⁵⁰ В експериментите на тази глава то не проследява експлоатируемостта: за абстракциите с $k = 3$ и $k = 5$ е нула, а тяхната експлоатируемост остава 0,38–0,57.

4.7.3 Инструмент 3 – Пряка оценка чрез CFR-BR

Най-силната мярка: за абстракции с пълна памет тя намира стратегията в абстракцията с най-ниска експлоатируемост в пълната игра, като по този начин *изолира* грешката на абстракцията от грешката при решаване. Стратегиите на CFR-BR показват експлоатируемост, толкова ниска, колкото $1/3$ от съответните обикновени CFR стратегии при *същата* абстракция – част от измерената „грешка на абстракцията“ се дължи на избора на равновесието на абстрактната игра за цел, а не на самата абстракция.⁵⁰

4.8 Избор на абстракция на практика

Редът на вземане на решения. Първо се използват всички налични беззагубни сливания; след това се приемат сливания с ограничени загуби само когато бюджетът на грешките е приемлив; в противен случай се извършва клъстеризация с HSD + разстояние на Васерщайн и получената абстракция се валидира емпирично.

Глобалната оптимизация е практически неприложима. Изборът на разделяне, което минимизира аналитичната граница, е **NP-пълна** задача дори за игра с един играч и дърво с височина две. Затова практическите конвейери работят ниво по ниво; при разумни условия едно ниво се свежда до клъстеризация около центрове в метрично пространство, което разполага с приблизителни алгоритми с полиномиално време с гаранции с постоянен коефициент.⁵³

Отчитащите разпределения превъзхождат основаните на очакването. При еднакъв брой информационни множества и достатъчно голяма абстракция HSD + разстояние на Васерщайн пре-

⁵³Kroer, C. & Sandholm, T. (2014). “Extensive-Form Game Abstraction with Bounds.” *ACM EC*, 621–638; и Kroer, C. & Sandholm, T. (2016). “Imperfect-Recall Abstractions with Bounds in Games.” *ACM EC*, 459–476.

възхожда клъстеризацията по очаквана сила на ръката както по експлоатируемост, така и в директни срещи; при много малки абстракции очакването може да е по-добро.⁵⁰ Заедно с резултата за паметта по-долу това е причината конвейерът по време на компилация по подразбиране да използва непълна памет, HSD и разстоянието на Васерщайн.


4.9 Решения по време на компилация

Два допълващи се конвейера, по един на ниво строгост на критерия.

4.9.1 Конвейер 1 – GameShrink (беззагубен)

Изчерпателно сливане, което обхожда *сигналното дърво* отдолу-нагоре и слива всяка двойка поддървета братя, преминала проверката за стратегическа еквивалентност. Сигналното дърво е по-малко от дървото на играта, защото колабира всички пътища на залагане, водещи до едни и същи публични и частни сигнали, в един възел: в Род Айлънд Холдем (Rhode Island Hold'em) то е около 6,6 милиона възела спрямо приблизително 3,1 милиарда възела на дървото на играта. Този конвейер, комбиниран с линейно програмиране, решава Род Айлънд Холдем през 2007 г.⁴⁹

4.9.2 Конвейер 2 – HSD + разстояние на Васерщайн + k-средни + непълна памет (със загуби)



Фигура 12: Разпределения на силата на ръката (HSD) в Ледюк. Вляво: всяка частна карта преди общата карта. Вдясно: деветте комбинации (частна, обща карта) дават три различни HSD; цветът е клъстерът на k-средни с разстоянието на Васерщайн, еднакъв при $k = 3$ и 5 .

Когато беззагубното сливане достигне сходимост и играта все още е твърде голяма, се пристъпва към клъстеризация: изчислява се HSD за всяко информационно множество, получените разпределения се групират чрез разстоянието на Васерщайн като метрика на разстояние и всяко информационно множество се съпоставя към идентификатор на клъстер. При *пълна памет* идентификаторът на клъстера включва предишната траектория на клъстерите; при *непълна памет* клъстерът в по-късен рунд може да я забрави, като по този начин освобождава повече клъстери за рунда, в който новата информация има най-голямо значение.

В тексаски Холдем непълната памет надделява при фиксиран бюджет на клъстерите – капацитетът се изразходва за рундовете, които имат значение, вместо за запомняне на историята.⁵⁰ В малкия Ледюк от тази глава предимството не се потвърждава: при сходен размер (108 срещу 132 информационни множества) абстракцията с непълна памет не е по-добра (0,574 срещу 0,571; вж. фигурата за Ледюк с лимит в „Практическо валидиране“).

Резултатът. Замразеният резултат от двата конвейера – стратегията, получена при решаването на абстрактната игра, и началната точка за всичко, което се случва по време на изпълнение – в останалата част от главата се обозначава като **план**.

4.10 Корекция по време на изпълнение

Когато играта премине в под-игра, която абстрактният план покрива твърде грубо, под-играта се преизчислява с по-висока точност *в реално време*. Две корекции са от значение – заедно те бяха носещите елементи на Libratus, първия изкуствен интелект, който победи най-добрите професионалисти в безлимитния тексаски Холдем за двама играчи.⁵⁴

4.10.1 Защо решаването на под-игра не може да се извършва изолирано (хвърляне на монета)

Прост контрапример, наречен *хвърляне на монета*: монета пада с ези или тура с еднаква вероятност, като само P_1 вижда изхода. Играчът P_1 избира между „Продай“ (Sell; с печалба, зависеща от резултата на монетата) и „Играй“ (Play; при която играчът P_2 се опитва да познае коя страна е паднала). Оптималната P_2 стратегия в под-играта „Играй“ **не е** функция единствено на самата тази под-игра – тя зависи от стойността, която P_1 би получил, ако вместо това беше избрал „Продай“. Ако печалбата от „Продай“ се промени, оптималната стратегия за „Играй“ също се променя, въпреки че самата под-игра „Играй“ остава непроменена.⁵⁵

Решението: решаване на *разширена под-игра*, включваща оригиналната под-игра и допълнителни възли „алтернативна печалба“, кодиращи какво всеки играч би могъл да постигне, ако *не беше*

⁵⁴Brown, N. & Sandholm, T. (2018). “Superhuman AI for heads-up no-limit poker: Libratus beats top professionals.” *Science*, 359(6374), 418-424.

⁵⁵Brown, N. & Sandholm, T. (2017). “Safe and Nested Subgame Solving for Imperfect-Information Games.” *NeurIPS*.

влязъл в тази под-игра.⁵⁶

4.10.2 Корекция 1 – Безопасно решаване на под-игри

Разширената под-игра се основава на план-стойности: всяко информационно множество в началото на под-играта получава алтернативна печалба, равна на обещаното от плана за този играч в съответния момент от играта. Решаването ѝ води до усъвършенствана стратегия, чиято експлоатируемост е доказано не по-висока от тази на плана.⁵⁵ Замяната на консервативните план-печалби с *оценки* на равновесната стойност премахва строгата гаранция, но обикновено води до по-ниска експлоатируемост в реална игра.

4.10.3 Корекция 2 – Вложено решаване на под-игри (заместител на трансляцията на действия)

Когато *противникът* извърши действие *a* извън зададената абстракция, *a* не се закръгля до познатото действие чрез трансляция – а *преизчислява се нова под-игра, която включва a*, по схемата на безопасното решаване на под-игри, и новата подстратегия се добавя към плана; планът нараства единствено там, където действително протича играта. В опростен безлимитен вариант (Холдем, игран само до флопа) това има около 10 пъти по-ниска експлоатируемост от псевдохармоничната трансляция (119–150 срещу 1465 хилядни от големия блайнд на раздаване, mbb/g).⁵⁵ Статичните транслятори на действия остават подходящият избор само когато закъснението не позволява решаване с CFR в реално време.

4.11 Архитектура: план и корекции в реално време

Целият конвейер се свежда до един архитектурен модел, използван от водещите системи за безлимитен покер след 2017 г. – Libratus⁵⁴ и Modicum при двама играчи и Pluribus⁵⁷ при шестима (DeepStack⁵⁸ е изключение: той не изчислява предварително стратегия за цялата игра): по време на компилация играта се абстрахира и решава, **планът** се замразява, а по време на изпълнение се преизчислява навсякъде, където планът е груб или противникът излезе извън абстракцията.

4.12 Практическо валидиране

Фазата на имплементация изгради малък конвейер от типа „Ледюк“ – изоморфизъм на боите, групиране на карти, абстракция на действията върху Mini-NL Ледюк, по-голям разширен Ледюк


⁵⁶Burch, N., Johanson, M. & Bowling, M. (2014). “Solving Imperfect Information Games Using Decomposition.” AAAI – пре-решаване и разширената под-игра.

⁵⁷Brown, N. & Sandholm, T. (2019). “Superhuman AI for multiplayer poker.” *Science*, 365(6456), 885-890.

⁵⁸Moravčík, M. et al. (2017). “DeepStack: Expert-level artificial intelligence in heads-up no-limit poker.” *Science*, 356(6337), 508-513.


(четири ранга, две бои) и тяхната комбинация – оценен чрез разлики в експлоатируемостта, заместващи оценки чрез EMD, кръстосана проверка в OpenSpiel и Парето граница.

Основните емпирични изводи съответстват на теорията: **беззагубната абстракция** е почти безплатна стратегически и много полезна изчислително, докато информационната абстракция със загуби и абстракцията на действията въвеждат трайна долна граница на експлоатируемостта. При бюджети от 180 секунди за CFR+, **изоморфизмът на боите** намали броя на информационните множества в Ледюк с лимит от 936 до 288 и достигна по-ниска експлоатируемост от пълната игра, тъй като завърши значително повече **итерации**. В разширения Ледюк същата идея намали броя на информационните множества от 10 304 до 2 968 и подобри крайната експлоатируемост от около $2,7 \times 10^{-2}$ до около $1,3 \times 10^{-3}$.




Фигура 13: Ледюк с лимит: крайна експлоатируемост след 180 s CFR+ за всяка конфигурация на абстракцията (три изпълнения, логаритмична скала); числото над всяка група е броят информационни множества.

Експериментите с клъстери със загуби показват другата страна на компромиса. По-малките игри с клъстери се обучават по-бързо, но грешката не изчезва при повече **итерации** на CFR+, тъй като стратегията решава грешната игра. В Ледюк с лимит грубите абстракции с клъстери останаха на експлоатируемост около 0,38–0,57, въпреки че завършиха повече **итерации** от пълния CFR+. Това е практическото значение на разликата в експлоатируемостта: грешката на абстракцията не е грешка на оптимизатора.




Фигура 14: Mini-NL Ледюк: крайна експлоатируемост след 180 s CFR+ – пълната игра срещу абстракцията на действията (незапълнени маркери, отразяващи текущото правило за внедряване; вж. текста); числата са броят информационни множества.



Фигура 15: Разширен Ледюк: крайна експлоатируемост след 180 s CFR+ за пълната игра, изоморфизма на боите и комбинираните абстракции; незапълнените маркери включват абстракция на действията (вж. текста); числата са броят информационни множества.

Абстракцията на действията беше най-рисковата част от главата. В Mini-NL Ледюк ограничаването на множеството действия намали броя информационни множества от 4704 до 936 и позволи извършването на значително повече **итерации** на CFR+ в рамките на същия времеви бюджет, но експлоатируемостта остана висока. В разширения Ледюк добавянето на абстракция на действията върху изоморфизма на боите доведе до компактно дърво, но внедрената стратегия беше силно експлоатируема. Тези стойности обаче измерват текущото правило за внедряване – всеки

абстрактен малък залог се изиграва като голям, а големите залози на противника се четат като малки – а не качеството на трите транслятора, които в тази реализация не се задействат и дават еднакви резултати. Те показват колко може да струва наивното съпоставяне на абстрактното и реалното множество действия; отговорът на литературата за действията извън дървото е вложеното решаване на под-игри.⁵⁵



Фигура 16: Граница на Парето: брой информационни множества срещу експлоатируемост в пълната игра след 180 s CFR+ (средно от три изпълнения); линиите свързват недоминираните точки; незапълнените маркери са конфигурации с абстракция на действията при текущото правило за внедряване.

Изгледът на Парето е правилната крайна проверка. Беззагубният изоморфизъм на боите се намира в атрактивната част от границата. Грубите клъстери и абстракцията на действията могат да намалят играта още повече, но това води до преминаване към различен режим, при който по-малкият размер се постига за сметка на качеството на стратегията.

4.13 Връзки и препратки напред

Глава 4 променя самата входна игра: преди решаването тя определя кои състояния и действия могат да бъдат обединени, без да се унищожи стратегическият сигнал. Мостът към Глава 5 е неявният път: Деер CFR заменя ръчно изградените и изградени чрез клъстеризация дялове с научени функционални апроксиматори. Мостът към Глава 6 е архитектурният план: Глава 4 предоставя речника – план, транслация на действия, разлика в експлоатируемостта, Парето граница и безопасно/вложено усъвършенстване – а Глава 6 превръща тези елементи в пълни системи за игра на игри.

За дисертацията абстракцията е от значение, защото адаптацията към съперника е ефективна единствено в границите на резолюцията, която представянето на играта запазва. Ако абстракцията обедини две стратегически различни състояния, обърнати към противника, нито един последващ модел на противника не би могъл да възстанови това разграничение. Обратно, представяне, което е прекалено детайлно, може да бъде твърде скъпо за решаване или оценяване. Парето границата от Глава 4 следователно се включва в методологията за оценяване: качеството на стратегията трябва да бъде докладвано заедно с размера и детайлността на представянето на играта, което я е породило.

5 Глава 5 – Невронни мрежи за игри с непълна информация

Това е съкратен обзор на невронни методи за игри с непълна информация – изграждането, обучението и внедряването на невронни мрежи в игри, при които играчите не могат да възприемат пълното състояние – и служи като кратък справочник при четенето на следващите глави. Глава 5 представлява умишлено еднократно отклонение от обичайния учебен цикъл: фазата на реализация от нулата се отлага, а вместо нея се разширява теорията, поради което този документ е карта на областта в ширина, а не запис на код. Разделите за научената абстракция, оценяването на невронни стратегии, експерименталните архитектури и обобщаващата карта на решенията са планирани, но не са включени в тази версия.

Защо невронни мрежи

Табличният CFR и неговите варианти на Монте Карло (Глави 2–4) съхраняват стойност на съжалението и стойност на стратегията във всяко информационно множество, така че разходът им за памет нараства с броя на информационните множества.⁵⁹ Експериментите в тази глава определяха количествено тази граница в Ледюк покер – игра, достатъчно малка, за да се побере в таблица: табличният MCCFR достигна експлоатируемост 0,097, докато Деер CFR при сравнимо време за изпълнение остана над 1,1 при всички изпробвани размери на мрежата. В този мащаб невронната методика не предлага никакво предимство, тъй като таблицата вече се побира изцяло в паметта.

Невронна мрежа заменя таблицата с апроксимация на функцията f_θ , която съпоставя характеристиките на едно състояние към стойност или разпределение на действията и обобщава към състояния, които не са били посетени по време на обучението. Това обръща структурата на разходите: паметта става независима от броя на информационните множества, за сметка на по-скъпи итерации и по-слаби гаранции за сходимост. Двата режима се разделят от праг в размера на играта: под него изброяването е по-евтино и точно, а над него таблицата не може да бъде построена и апроксимацията на функцията е единствената възможност. Игрите, към които е насочена тази работа, са над този праг.

5.1 Основни положения

5.1.1 Основи на невронните мрежи

Главата предполага стандартния инструментариум на дълбокото обучение. Мрежа с директно разпространение поддържа слоеве $h = \sigma(Wx + b)$ – афинно преобразуване, последвано от нелинейност като ReLU – във функцията f_θ . Тя се обучава чрез градиентен спуск върху загуба (средноквадратична грешка за стойности, кръстосана ентропия за разпределения на действията), като обратното разпространение на грешката изчислява градиента, а Adam, оптимизаторът по подразбиране в

⁵⁹Zinkevich, M., Johanson, M., Bowling, M. & Piccione, C. (2007). “Regret Minimization in Games with Incomplete Information.” *Advances in Neural Information Processing Systems* 20, 1729-1736.

тази глава, адаптира размера на стъпката за всеки параметър. Отслабването на теглата, отпадането и ранното спиране противодействат на преобучението (overfitting). От обучението с подкрепление идва *самоподкрепяне* (*bootstrapping*) – обновяване на стойност към собствената оценка на мрежата за следващото състояние (Глава 1), което прави обучението ефективно по отношение на данните, но по-малко стабилно. Подробно изложение има в глави 9 и 11 от Sutton & Barto (2-ро издание) и във всяка стандартна литература за дълбоко обучение.

5.1.2 Обедняване на основите в Ледюк покера

Тези елементи се комбинират в най-простия невронен решаващ за игра. Вземете Ледюк покер, тестовата среда от глави 3–4: неговото информационно състояние – кой играч е на ход, тайната карта, общата карта и историята на залозите – се кодира като вектор от 30 числа. Малка мрежа съпоставя на този вектор стойност за всяко действие; обратното разпространение на грешката с Adam я настройва спрямо целевите стойности, генерирани по време на игра, а леката регуляризация предотвратява запаметяването на шума в тези цели. Използвана правилно, мрежата предоставя две възможности, които таблицата няма: тя обобщава, така че стойността, научена в едно информационно множество, информира подобни невиджани такива, а цената на паметта ѝ е фиксирана от броя на параметрите, а не от броя на информационните множества.

Същата техника се влошава, когато бъде претоварена. При Ледюк най-малката тествана мрежа достигна по-ниска експлоатируемост от мрежа, няколко пъти по-голяма, вероятно защото при толкова малък бюджет по-големите мрежи не получават достатъчно различни извадки, за да се обучат (хипотеза въз основа на едно начално число). Скоростта на обучение, зададена твърде висока, дестабилизира спускането; прекомерната регуляризация изглажда остриите, почти детерминистични стратегии, към които CFR се сближава, тъй като силното отслабване на теглата или отпадане дърпат изхода към равномерното разпределение. Капацитетът и регуляризацията трябва да бъдат съобразени с количеството и качеството на данните, а не да се максимизират по подразбиране – точка, която раздел 5.2 развива в изрични насоки за оразмеряване.

5.1.3 Нестационарност и смъртоносната троица

Комбинирането на тези компоненти въвежда нестабилност. Sutton и Barto идентифицират една *смъртоносна троица*: когато апроксимация на функция, самоподкрепяне и обучение извън текущата стратегия (off-policy) се използват заедно, параметрите могат да се отдалечават неограничено, вместо да клонят към решение, тъй като целевата стойност чрез самоподкрепяне за всяка актуализация зависи от същите параметри, които се променят. Всеки един компонент е безопасен самостоятелно; комбинацията не е. Практическите средства за защита – целева мрежа и буфер за възпроизвеждане, които направиха дълбоките Q-мрежи обучаеми (Глава 1) – се появяват отново в невронните решаващи на игри от раздел 5.3 и раздел 5.4.

Игрите въвеждат втори източник на нестабилност. При обучението с учител разпределението на данните е фиксирано, а при обучението с подкрепление с един агент то се стабилизира, след като

стратегията достигне сходимост. В една игра противникът също се адаптира, така че функцията, която се апроксимира, сама по себе си е подвижна цел. Тази нестационарност не е случайна – тя е централната трудност на средата, към която това изследване е насочено. Няколко метода по-нататък се разбират най-добре като отговор на нея: играта срещу себе си срещу замразени или осреднени във времето противници възстановява стационарна цел, популационните методи заменят подвижната цел с изричен набор от фиксирани противници, а техниките за моделиране на противника и бърза адаптация (глави 7 и 12) се опитват да я проследят пряко.

5.2 Архитектура и композиция


5.2.1 Индуктивно пристрастие: съгласуване на архитектурата със структурата на играта

Всяка архитектура кодира предположения относно структурата на своя вход още преди да види каквито и да е данни; тези вградени предположения представляват нейното *индуктивно пристрастие*. Напълно свързаната мрежа не предполага нищо, което я прави обща, но изисква голям обем данни. Изборът на архитектура, чието пристрастие съответства на структурата на играта, намалява броя на параметрите и количеството необходими данни и подобрява обобщаването към състояния, които не са били част от обучението; решенията за архитектура в останалата част от раздел 5.2 по същество представляват избор на индуктивно пристрастие. Три съответствия покриват повечето игри с непълна информация. Пространственото състояние – дъска или решетка – изисква конволюционна мрежа, чиято *еквивариантност спрямо трансляция* позволява характеристика, научена в една област, да бъде приложена към други.⁶⁰ Неподредената съвкупност – картите в ръката или множеството от останалите играчи – изисква мрежа, *инвариантна спрямо пермутации*, за да не се използва капацитет за научаване на това, че редът е без значение. Историята, разкрита с течение на времето, както при частична наблюдаемост, изисква рекурентна мрежа или механизъм за внимание, който пренася напред изводите от по-ранните наблюдения.

5.2.2 Типове слоеве на практика: MLP, CNN, RNN, внимание/трансформър

Семействата се различават по своята *свързаност* – кои единици са свързани с кои – и дали свързващите *тегла* се *споделят* между позиции или във времето; невронът, нелинейността и обратното разпространение на грешката са идентични. В панела на конволюцията цветът на връзката обозначава теглото: еднаквият цвят означава споделено тегло, а в останалите панели цветът само различава видовете връзки.

⁶⁰LeCun, Y., Bengio, Y. & Hinton, G. (2015). “Deep learning.” *Nature* 521, 436–444. DOI 10.1038/nature14539.



Фигура 17: Свързаност на четирите семейства слоеве: напълно свързан слой (MLP), конволюция, която прилага един и същ филтър към локални прозорци, рекурентна клетка, използвана многократно във времето, и самовнимание.

Напълно свързан слой – многослоен перцептрон, или MLP – свързва всяка единица с всяка единица в следващия слой, като всяка връзка носи свое собствено тегло. Той не предполага никаква структура, броят на теглата е произведение от размерите на двата слоя и цялата структура трябва да бъде научена от данните. Това е правилният избор за плосък вектор на характеристики без пространствено или последователно значение, като например информационно състояние в покер.

Конволюционният слой (CNN) свързва всяка изходна единица само с малък локален прозорец от входа и прилага един и същ малък набор от тегла, *филтърът*, на всяка позиция. Тогава броят на теглата зависи от размера на филтъра, а не от размера на входа, и модел, научен на едно място, се разпознава на всяко друго място; наслабяването на няколко конволюционни слоя комбинира локални модели в по-големи. Това е стандартният избор за дъски и решетки.

Рекурентният слой (RNN) прилага една и съща клетка по дължината на последователността, като съчетава всеки вход със *скритото състояние* от предишната стъпка, което функционира като памет за всичко видяно до момента – свойството, необходимо когато състоянието представлява история, разкривана с течение на времето. Вариантите с гейтове (LSTM, GRU) научават какво

да се запази и какво да се изхвърли, което им позволява да задържат информация за по-дълги интервали от време.

Слой за самовнимание (трансформър) позволява на всеки елемент да взаимодейства директно с всеки друг: изходът за даден елемент представлява претеглена средна стойност на стойностите на всички елементи, като теглата се определят от сходството между неговата заявка и всеки ключ. Операцията е еквивариантна спрямо пермутации, затова редът трябва да бъде подаден изрично чрез позиционни кодировки, когато има значение, а дългосрочните зависимости се улавят за сметка на изчисления, чиято сложност нараства квадратично спрямо броя на елементите. Слойт е подходящ за истории с променлива дължина и входове със стойности от множества.


Вход, който е наистина неподреден, изисква **инвариантност спрямо пермутации**, която не се постига чрез нов тип слой, а чрез подредба: прилага се една и съща малка мрежа към всеки елемент, след което резултатите се комбинират с операция, независима от реда, като сума, средна стойност или максимум. Това е принципът зад Deep Sets.

На практика една мрежа рядко използва само едно семейство архитектури. Обичайният дизайн е конвейер: отделен *кодировчик*, съобразен с всяка част от входа, изходите на кодировчика се *обединяват* чрез конкатенация в общ *ствол*, и една или повече *глави*, които извличат прогнозите от ствола – обикновено глава на стратегията и стойностна глава. Deep Recurrent Q-Network (DRQN) комбинира конволюционен кодировчик, LSTM и изходен MLP – естественият шаблон за агент в решетъчна среда с „мъгла на войната“. ⁶¹ AlphaStar кодира множеството от единици с трансформър, пространствената миникарта с CNN и скаларните величини с MLP, след което обединява трите представяния и ги подава през LSTM ядро към изходните глави за действия. ⁶² Затова „коя архитектура“ обикновено означава „кой кодировчик за всеки вход и как да ги комбинираме“, а не един-единствен избор.

⁶¹Hausknecht, M. & Stone, P. (2015). “Deep Recurrent Q-Learning for Partially Observable MDPs.” *arXiv:1507.06527*.

⁶²Vinyals, O. et al. (2019). “Grandmaster level in StarCraft II using multi-agent reinforcement learning.” *Nature* 575, 350–354. DOI 10.1038/s41586-019-1724-z.


Обща схема: кодировчици → сливане → общ ствол → изходни глави



Пример 1 — DRQN (памет при частична наблюдаемост)



Пример 2 — AlphaStar



Фигура 18: Общата схема с кодировчици, общ ствол и изходни глави (горе) и два нейни примера (долу): DRQN и AlphaStar.

5.2.3 Кодирание на състоянието на играта и историята

Преди някоя от тези архитектури да може да работи, информационното състояние – всичко, което действащият играч може законно да наблюдава – трябва да стане тензор с фиксирана форма, а начинът, по който е подредено, определя коя архитектура може да го използва. Категориалните факти се кодират или като *one-hot* вектори – вектор с дължина k , съдържащ една единствена единица, която маркира коя от k категории е валидна – или, когато k е голямо, като *вграждания*: кратки научени вектори, които се извличат за всяка категория, компресират голям речник и позволяват на подобни категории да споделят структура. Ледюк покер е достатъчно малък, за да използва *one-hot* навсякъде: играчът на ход, тайната карта, общата карта и историята на залозите стават *one-hot* полета, което дава трийсетмерния вектор на OpenSpiel; размерът на пота не се подава отделно, защото следва от историята на залозите.

По-богатите входове изискват по-богати подредби. Пространственото състояние се кодира като поредица от наслоени решетки, по една *канална* равнина за всеки тип обект, така че конволюци-

ята да може да го обработи пряко. Pommerman – игра в стил Bomberman върху решетка – разделя дъската си 11×11 на отделна двоична равнина за всеки тип обект (проходи, стени, бомби, пламъци, бонуси, действащият агент и всеки противник), а скаларни величини като оставащите боеприпаси се добавят като кратък вектор. История, чийто ред има значение, се кодира като *последователност* от вектори за всяка стъпка за рекурентен слой или трансформър; неопределена колекция се кодира елемент по елемент и се обединява. Във всеки случай кодирането е мястото, където индуктивното пристрастие всъщност се прилага: решетката се подава като решетка именно за да са в сила предположенията на конволюцията. Непрекъснати признаци като пота или размера на стака се нормализират до сравним мащаб, а една мрежа може и да се научи да компресираща дълга история в компактен обобщен вектор – идея, която стои в основата на научените абстракции и на научените състояния на убеждение (Глава 6).

Една дисциплина е специфична за игри с непълна информация и лесно може да бъде нарушена: кодирането трябва да съдържа само това, което играчът може да наблюдава, и нищо скрито. Ако каквато и да е привилегирована информация – тайната карта на противника или истинското съдържание на клетка, покрита с мъгла – попадне в тензора за вход, мрежата ще се научи да я използва и ефективно ще „вижда“ през мъглата, което води до стратегия, която не може да бъде приложена срещу реален противник, и до показател за експлоатируемост, който е безсмислен. Ето защо рамки като OpenSpiel дефинират изрично представяне на информационно състояние за всеки играч; правилното получаване на това представяне е изискване за коректност, а не избор за настройка.⁶³


5.2.4 Оразмеряване и капацитет

Капацитетът на една мрежа – определен от нейната ширина, броя на единиците във всеки слой, и нейната дълбочина, броя на слоевете – е размерът на семейството от функции, които тя може да представи. При твърде малък капацитет мрежата остава *недообучена* (underfitting); при твърде голям капацитет тя се *преобучава* (overfitting), като напасва шума в ограничения набор от данни вместо основната структура. Правилният капацитет е този, който съответства на количеството информативни данни, което обучението действително предоставя – а при решаващ на игра това често е значително по-малко от суровия брой състояния, тъй като самите стойности, които се пасват, представляват шумни оценки.

Експериментите в тази глава показваха това пряко. Прилагайки Deep CFR върху Ледюк при фиксирен бюджет, но с различни размери на мрежата, най-малката мрежа – два скрити слоя от тридесет и две единици – постигна по-ниска експлоатируемост (1,14) от трислойната мрежа, четири пъти по-широка (1,49). Вероятното обяснение е, че няколкото хиляди обхождания не стигат, за да се обучат по-големите мрежи; при едно начално число и почти хоризонтални криви това е хипотеза, а не измерен ефект. Трети опит, с два слоя от по шестдесет и четири единици, е изключен: той остава на 1,70 във всяка контролна точка – стойността, която решаващът даваше преди поправката на грешката му (раздел 5.2.5), затова изчаква повторно изпълнение. Изводът не е, че по-малкият

⁶³Lanctot, M. et al. (2019). “OpenSpiel: A Framework for Reinforcement Learning in Games.” *arXiv:1908.09453*.


размер винаги е по-добър, а че капацитетът трябва да съответства на бюджета за данни: при по-голяма игра или с много повече обхождания класирането вероятно би се обърнало.



Фигура 19: Експлоатируемост на Deep CFR в Ледюк при два размера на мрежата (32×32 и 128×128×128; едно начално число). Опитът с 64×64 е изключен до повторното му изпълнение.

Работеща рецепта е да се започне с малък размер и ширината и дълбочината да се увеличават само докато задържан показател – загуба при валидиране или експлоатируемост за решавач – продължава да се подобрява, като се спира, когато достигне плато. Ширината позволява на мрежата да представя повече различни модели на дадено ниво на абстракция; дълбочината ѝ позволява да съставя прости модели в по-абстрактни, поради което пространствените и последователните проблеми се възнаграждават с няколко слоя, докато плосък вектор на характеристики често не.

Ширината на мрежата не е задължително да остава постоянна във всичките ѝ слоеве. *Фунията* се свива към изхода, като компресира входа до малко обобщение; *пясъчният часовник* добавя разширяваща се половина, а неговата тясна среда – *стеснението* – принуждава цялата информация да премине през нискоразмерен код, така че мрежата запазва единствено най-същественото: зародишът на научена абстракция или на състояние на убеждението. Същото стесняване в иначе равномерна поредица от слоеве представлява *яка*.



Фигура 20: Типични форми на мрежата: равномерна поредица от слоеве, стесняваща се фуния, пясъчен часовник с централно стеснение (в оранжево) и равномерна поредица с една тясна „яка“ (в оранжево). Височината на правоъгълника е ширината на слоя.

Остатъчните (residual) връзки решават проблема с дълбочината, а не с ширината: добавянето на входа на даден слой към неговия изход позволява на градиентите да достигат до дълбоките слоеве, така че много дълбоките мрежи стават обучаеми – принципът, залегнал в основата на ResNet и на дълбоките мрежи за стойности от Глава 6.⁶⁴

5.2.5 Стабилност на обучението и диагностиката

Освен целевата мрежа и буфера за възпроизвеждане, в невронните решавачи на игри по-нататък се срещат още две стабилизиращи средства. *Извадката от резервоар* поддържа извадка с фиксиран размер, при която всеки елемент, видян досега, има еднаква вероятност да бъде запазен, така че средна стойност върху цялата история на обучението остава неизместена, без да се съхраняват всички данни; Deep CFR я използва, така че неговата стратегическа мрежа да се обучава върху неизместена извадка през всички итерации (раздел 5.3).⁶⁵ *Намаляване на дисперсията* – чрез изваждане на базова линия от взетите извадкови стойности или използване на контролни променливи⁶⁶ – намалява шума, който извадката внася в градиента, така че мрежата да се сближава с по-малко извадки. Нормализирането на входа и разумната инициализация на теглата поддържат активациите и градиентите в използваем диапазон още от първата стъпка.

Дори и с тези мерки на място, невронният решавач се проваля по-често тихо, отколкото шумно, така че четенето на диагностиката е от значение. Загуба, която се променя, докато оценителният показател – експлоатируемост за решавач – застива, е признак, че мрежата *се обучава, но още не е достигнала сходимост*: обучението работи, но бюджетът е твърде малък, за да може средната стратегия да се установи, което показаха мрежите от експериментите в тази глава при Ледюк на няколко хиляди обхождания. По-опасният случай е, когато обучението изобщо не протича, въпреки

⁶⁴He, K., Zhang, X., Ren, S. & Sun, J. (2016). “Deep Residual Learning for Image Recognition.” *CVPR*, 770–778. DOI 10.1109/CVPR.2016.90.

⁶⁵Brown, N., Lerer, A., Gross, S. & Sandholm, T. (2019). “Deep Counterfactual Regret Minimization.” *ICML*.

⁶⁶Schmid, M., Burch, N., Lanctot, M., Moravčík, M., Kadlec, R. & Bowling, M. (2019). “Variance Reduction in Monte Carlo Counterfactual Regret Minimization (VR-MCCFR) for Extensive Form Games Using Baselines.” *AAAI* 33, 2157–2164.

че изглежда така: при изследването едносимволна грешка в рутина на OpenSpiel остави мрежите за предимство необучени, но програмата завърши изпълнението си и произведе правдоподобен резултат, като експлоатируемостта просто замръзна около 1,69 независимо от броя итерации (равномерно случайната стратегия има 2,37). Дори след поправката опитът с мрежа 64×64 остава на 1,70 във всяка контролна точка, т.е. на същото ниво, затова тази глава не разчита на неговите числа до повторното му изпълнение. Урокът е да се потвърди, че загубата действително се променя и че оценителният показател реагира, преди да се вярва на който и да е резултат – обучение, което тихо не прави нищо, изглежда точно като труден проблем, освен ако кривите не бъдат проверени.

5.3 Невронни мрежи в CFR

5.3.1 От табличен CFR към апроксимация на функция

Табличният CFR поддържа по две стойности за всяко информационно множество: кумулативно контрафактично съжаление за всяко действие, от което се извежда текущата стратегия чрез напасване на съжалението, както и кумулативна стратегия, чиято текуща средна представлява приближението на равновесието на Наш, което алгоритъмът в крайна сметка връща (Глави 2–4). Невронният CFR заменя двете таблици с две мрежи, които приемат тензор на информационно състояние като вход и предсказват това, което таблицата би съхранявала; тъй като една мрежа обобщава подобни информационни състояния, тя никога не трябва да ги изброява. Методите по-долу се различават основно по това коя от двете таблици апроксимират и *как* генерират данните за обучението ѝ: Deep CFR научава предимства от извадкови обхождания на дървото, докато NFSP научава средната стратегия от игра срещу себе си без изобщо да обхожда дървото.⁶⁵

5.3.2 Deep CFR и неговите варианти с една мрежа


Deep CFR (Brown и др., 2019) е прекият невронен аналог на MCCFR. При всяка итерация той обхожда дървото на играта чрез външно вземане на проби и във всяко информационно множество, което посещава, изчислява извадковото контрафактично предимство на всяко действие – колко по-добро е било това действие от текущата стратегия средно. Тези двойки (информационно състояние, предимство) се записват в резервоарен буфер и *мрежа за предимства*, по една за всеки играч, се обучава да ги предсказва; текущата стратегия във всяко информационно множество след това се извежда от предсказаните предимства на мрежата чрез напасване на съжалението, точно както би била използвана таблицата. Отделна *стратегическа мрежа*, обучавана от собствен резервоарен буфер, научава средната стратегия през всички итерации – приближението на равновесието на Наш, което се връща в края.

Единственото уравнение, което отличава Deep CFR от табличния MCCFR, е целевата функция на мрежата за предимства: средноквадратична грешка между нейната прогноза и извадковите предимства,

$$L(\theta) = \frac{1}{|B|} \sum_{(I, \tilde{a}) \in B} \|f_{\theta}(I) - \tilde{a}\|^2,$$

където B е партида, изтеглена от резервоара, I тензор на информационно състояние, $\tilde{a}$ векторът на извадковите предимства за неговите действия и f_{θ} мрежата за предимства (на практика пробите се претеглят според итерацията, отразявайки линейния CFR). Всичко останало се запазва непроменено спрямо табличния алгоритъм.

Последваха усъвършенствания. *Single Deep CFR* премахва отделната стратегическа мрежа и възстановява средната стратегия пряко от запазените мрежи за предимства от всяка итерация, с което отпада грешката от приближаването на средната стратегия; в Ледюк то достига същата или малко по-ниска експлоатируемост от Deep CFR, а в пряк двубой в по-голямата игра 5-Flop Hold'em го побеждава.⁶⁷ *DREAM* прави метода безмоделен: вместо външно вземане на проби използва извадка по резултати и добавя научена базова линия като контролна променлива, която поема допълнителната дисперсия (раздел 5.2).⁶⁸ *ESCHER* премахва изцяло претеглянето по значимост (importance sampling), като оценява съжалението чрез научена функция на стойността на историята, и в пряк двубой в „тъмен шах“ (dark chess) побеждава DREAM и NFSP в над 90% от игрите.⁶⁹



Фигура 21: Single Deep CFR (SD-CFR) достига същата или малко по-ниска експлоатируемост от Deep CFR в Ледюк (хилядни от анте на игра) без мрежа за средната стратегия. По Steinberger (2019), фиг. 1a; не е собствен експеримент.


В Ледюк изследването потвърди както обещанието, така и уловката. Deep CFR се обучаваше – загубите на мрежите за предимства се променяха (и растяха, защото целите се претеглят с номера

⁶⁷Steinberger, E. (2019). “Single Deep Counterfactual Regret Minimization.” *arXiv:1901.07621*.

⁶⁸Steinberger, E., Lerer, A. & Brown, N. (2020). “DREAM: Deep Regret Minimization with Advantage Baselines and Model-free Learning.” *arXiv:2006.10410*.

⁶⁹McAleer, S., Farina, G., Lanctot, M. & Sandholm, T. (2023). “ESCHER: Eschewing Importance Sampling in Games by Computing a History Value Function to Estimate Regret.” *ICLR*; *arXiv:2206.04122*.

на итерацията) – но на 120 итерации експлоатируемостта му остана над 1,1 при всички размери на мрежата (1,14 в най-добрия случай), срещу 0,097 за табличния MCCFR при сравнимо време за изпълнение. Това само по себе си не е дефект: Ледюк е достатъчно малък, за да може табличният подход да спечели категорично, а на Deep CFR е необходим много по-голям бюджет от извадки, за да се доближи до равновесие на Наш (тук с 40 обхождания на итерация срещу 1500 в настройката на Steinberger за Ледюк). Неговото предимство се проявява едва когато играта е твърде голяма, за да съществува таблица – режимът, който раздел 5.3.4 уточнява.




Фигура 22: Експлоатируемост на Deep CFR (32×32 и 128×128×128) и на табличния MCCFR в Ледюк спрямо времето за изпълнение; пунктирната линия е равномерно случайната стратегия.

5.3.3 NFSP – Neural Fictitious Self-Play

NFSP – Neural Fictitious Self-Play (Heinrich & Silver, 2016) – достига приблизително равновесие на Наш от страната на обучението с подкрепление, без никога да обхожда дървото на играта. Всеки играч поддържа две мрежи: *мрежа за най-добър отговор* (DQN), която научава алчен най-добър отговор на текущото поведение на опонента, и *мрежа на средната стратегия*, която чрез обучение с учител върху собствените минали действия на играча при игра с най-добрия отговор научава средното по времето на тези най-добри отговори. Средната стратегия е тази, която клони към равновесие на Наш – същото осредняване, което CFR извършва, но постигнато чрез игра, а не чрез съжаление. *Антиципиращият параметър* η свързва двете мрежи: във всеки епизод агентът играе с мрежата за най-добър отговор с вероятност η , а в останалите случаи – с мрежата на средната стратегия, така че играта с най-добър отговор продължава да генерира свежи данни от разпределението за средната стратегия, докато средната стратегия осигурява стабилен опонент за най-добрия отговор.

Цената е ниската ефективност по отношение на данните. В играта Ледюк изследването стартира

NFSP за десетки хиляди епизоди и наблюдава колебание на експлоатируемостта около 2,5, близо до нивото на равномерно случайната стратегия (2,37), вместо спад, тъй като достигането на използваемо равновесие дори в тази малка игра изисква порядъка на един милион епизоди или повече. NFSP се мащабира до големи игри, където безмоделната му простота е предимство, но в учебна игра като Ледюк той се сближава значително по-бавно от табличния CFR или Deep CFR.⁷⁰



Фигура 23: Експлоатируемост на NFSP в Ледюк в хода на 50 000 епизода обучение: кривата остава около нивото на равномерно случайната стратегия (пунктир, $\approx 2,37$).

5.3.4 Компромиси: кога невронният CFR е от полза

Невронните мрежи дават на CFR обобщаване и ограничена памет: една мрежа споделя структура между сходни информационни множества и съхранява стратегия във фиксиран брой параметри, така че изчисляването на равновесие вече не изисква посещение на всяко информационно множество. Цената е висок разход на итерация и по-слаби гаранции: всяка итерация обучава мрежи вместо да увеличава броячи, а чистото монотонно поведение на табличния CFR става приблизително. Резултатите в Ледюк показват тази страна на компромиса при малки игри: когато таблицата се побира в паметта, тя е по-ефективна.⁶⁵ С разрастването на играта таблиците в крайна сметка изобщо не се побират в паметта, докато отпечатъкът на мрежата остава непроменен; след този преход невронната методика е единствената възможна, затова Deep CFR и неговите разновидности са важни за пълномащабен покер, въпреки че губят в Ледюк.

Едно структурно ограничение определя къде се прилагат невронните методи, базирани на съжаление. CFR изчислява контрафактни стойности чрез разсъждения върху цялото поддърво под едно информационно множество, което е евтино, когато дървото е *широко, но плитко* – покерът има огромен брой раздавания, но завършва след няколко рунда на залагане. В игри, които са дъл-

⁷⁰Heinrich, J. & Silver, D. (2016). "Deep Reinforcement Learning from Self-Play in Imperfect-Information Games." *arXiv:1603.01121*.

боки – със стотици последователни хода, както в една решетъчна среда – това разсъждение става непосилно скъпо и безмоделните методи за игра срещу себе си от раздел 5.4 се превръщат в по-естественото решение. Семейството, базирано на съжаление, продължава да расте в своята ниша – NeuRD, например, променя с един ред обновяването по градиента на стратегията така, че то да следва репликаторната динамика; в табличния случай методът е еквивалентен на softmax CFR⁷¹ – но неговата най-добра област на приложение остават широките, плитките игри с непълна информация.

5.4 Други невронни приложения

5.4.1 Четирите водещи фамилии алгоритми

Приближаването на CFR (раздел 5.3) е едно от четирите големи семейства, по които в тази глава се подреждат съвременните методи, като изборът между тях до голяма степен зависи от съответствието им с мащаба на играта, структурата на дървото и броя на участниците.⁷² Таблицата ги представя; следващите раздели разглеждат трите, които все още не са обхванати.

Таблица 7: Семейства невронни методи за игри с непълна информация: основна идея, приложимост и цена.

Семейство	Основна идея	Най-подходящо за	Цена
Базиран на съжаление (Deer CFR, DREAM, NeuRD)	Приближаване на CFR с невронни мрежи	Широки, плитките игри; неексплоатируемост	Висока
Популационен (PSRO, NFSP, XFP)	Най-добър отговор на нарастваща популация от противници	С n играчи; моделиране на противника	Средна
Търсене + RL (ReBeL, Student of Games)	Научена функция на стойността плюс търсене по време на игра	Игри с високи залози; изчисления по време на игра	Висока
Игра срещу себе си без използване на модел (PPO, DQN, MAPPO, QMIX)	Оптимизиране на награда чрез игра срещу себе си	Пространствени, с дълъг хоризонт (решетки)	Ниска–средна

5.4.2 Популационни методи: PSRO, NFSP, XFP

Популационните методи преформулират намирането на равновесие като итеративен турнир: членовете на набор от стратегии се изиграват един срещу друг и формират *мета-игра*, след това се

⁷¹Hennes, D. et al. (2020). “Neural Replicator Dynamics: Multiagent Learning via Hedging Policy Gradients.” *AAMAS*, 492–501; arXiv:1906.00190.

⁷²Rudolph, M. et al. (2026). “Reevaluating Policy Gradient Methods for Imperfect-Information Games.” *ICLR*; arXiv:2502.08938.

обучава нова стратегия като приблизителен най-добър отговор на текущата популация, добавя се обратно към набора и процесът се повтаря. Това е идеята зад PSRO (Policy-Space Response Oracles); фиктивната игра срещу себе си, включително NFSP от раздел 5.3, е специалният случай, при който най-добрият отговор е насочен към средното по времето на набора. Тъй като популацията представлява изричен набор от противници, а не една подвижна цел, тези методи естествено обхващат сценариите с n играчи и моделиране на противника, които са предмет на тази дисертация; популационно обучение от този вид е в основата и на „лигата“ от агенти, с която AlphaStar достига нивото на гротмайстор в StarCraft II.⁶² Цената е поддържането и съхраняването на множество агенти, а гаранциите за равновесие са по-слаби от тези на CFR.⁷³ Глави 9 и 10 разглеждат тези методи подробно.

5.4.3 Търсене + RL: ReBeL и Student of Games

Методите търсене плюс обучение с подкрепление представляват идеята на AlphaZero, адаптирана към скрита информация: търсещият играч не знае действителното състояние, затова търсенето трябва да обхваща разпределение на вероятностите върху възможни състояния. ReBeL (Brown и др., 2020)⁷⁴ прави това прецизно чрез *публичното състояние на убежденията* (PBS) – разпределение на вероятностите върху частната информация на играчите, предвид всичко публично – и изпълнява CFR върху малка, ограничена по дълбочина под-игра по време на игра, като научена мрежа за стойности предоставя стойностите на листата. Student of Games (Schmid и др., 2023; в предварителната версия – Player of Games)⁷⁵ обобщава този подход в един алгоритъм, който обработва както пълна, така и непълна информация. Тези системи са в основата на най-силните резултати в покера, но зависят от изчисления, извършвани *по време* на игра, а не само по време на обучение; те са предмет на Глава 6.

5.4.4 Игра срещу себе си без използване на модел: PPO, DQN, MAPPO, QMIX

Методите за игра срещу себе си без използване на модел изцяло игнорират дървото на играта и оптимизират директно сигнала за награда, усъвършенствайки стратегия от епизоди на игра срещу собствени копия: PPO⁷⁶ и DQN⁷⁷ за едноагентното ядро и многоагентните разширения MAPPO⁷⁸ и QMIX⁷⁹ за кооперативни сценарии. Тъй като никога не обмислят поддържането под дадено състояние, те не се затрудняват от дълбочината, която пречи на методите, основани на съжалението,

⁷³Lanctot, M. et al. (2017). “A Unified Game-Theoretic Approach to Multiagent Reinforcement Learning.” *NeurIPS* (PSRO).

⁷⁴Brown, N., Bakhtin, A., Lerer, A. & Gong, Q. (2020). “Combining Deep Reinforcement Learning and Search for Imperfect-Information Games.” *NeurIPS* 33; arXiv:2007.13544.

⁷⁵Schmid, M. et al. (2023). “Student of Games: A unified learning algorithm for both perfect and imperfect information games.” *Science Advances* 9(46), eadg3256. DOI 10.1126/sciadv.adg3256.

⁷⁶Schulman, J., Wolski, F., Dhariwal, P., Radford, A. & Klimov, O. (2017). “Proximal Policy Optimization Algorithms.” arXiv:1707.06347.

⁷⁷Mnih, V. et al. (2013). “Playing Atari with Deep Reinforcement Learning.” arXiv:1312.5602; Mnih, V. et al. (2015). “Human-level control through deep reinforcement learning.” *Nature*, 518(7540), 529–533.

⁷⁸Yu, C. et al. (2022). “The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games.” *NeurIPS Datasets and Benchmarks*; arXiv:2103.01955.

⁷⁹Rashid, T. et al. (2018). “QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning.” *ICML*; arXiv:1803.11485.

което ги прави естествения избор за пространствени игри с дълъг хоризонт – решетъчни среди, Rommerman и подобни; частичната наблюдаемост се поема от рекурентните архитектури и архитектурите с внимание от раздел 5.2. Наивната игра срещу себе си с алгоритъм за един агент може да се върти в цикъл и да остане силно експлоатируема. Затова по-новите безмоделни методи променят динамиката на обучението (NeuRD,⁷¹ R-NaD в DeepNash,⁸⁰ магнитно огледално спускане, MMD⁸¹), така че играта да се доближава до равновесие. Мащабно сравнение в пет игри с нулева сума за двама играчи показва, че специализираните методи NFSP, PSRO, ESCHER и R-NaD не превъзхождат по експлоатируемост общите методи с градиент на стратегията като PPO и MMD.⁷² Затова експлоатируемостта на всеки безмоделен агент трябва да се измерва, а не да се предполага.

⁸⁰Perolat, J. et al. (2022). “Mastering the game of Stratego with model-free multiagent reinforcement learning.” *Science* 378, 990–996. DOI 10.1126/science.add4679.

⁸¹Sokota, S. et al. (2023). “A Unified Approach to Reinforcement Learning, Quantal Response Equilibria, and Two-Player Zero-Sum Games.” *ICLR*; arXiv:2206.05825.

6 Глава 6 – Архитектури на игрови изкуствен интелект от край до край

6.1 Въведение

Глава 6 е крайъгълният камък на този изследователски план. Глави 1–5 изграждат поотделно съставните елементи – игровитеоретичния речник на игрите в разгърната форма и равновесията на Наш, минимизирането на контрафактичното съжаление (CFR) и неговите **варианти на Монте Карло**, абстракцията на играта и невронните апроксиматори на функции, които заменят табличното съхранение, когато една игра го надрасне – и тази глава е мястото, където тези елементи се сглобяват в пълноценни системи от състезателно ниво. Подходът е умишлено **архитектурен**: вместо да се извеждат отново математическите зависимости, които са представени в техническите глави и цитираните статии, всяка система се разглежда на нивото на това как е *изградена* – какво изчислява **офлайн**, какво изчислява в **реално време**, къде е обучението и какво всъщност може да гарантира. Всеки раздел започва с кратка обобщаваща таблица по едни и същи девет измерения, така че системите да се сравняват с един поглед.

Петте системи обхващат седем години и, прочетени в ред, проследяват еволюцията на свръхчовешкия игрови изкуствен интелект: **DeepStack** (2017), **Libratus** (2017/2018), **Pluribus** (2019), **ReBeL** (2020) и **Student of Games** (2023). Изкушаващо е да се прочете такъв списък като класация – всяка следваща по-силна от предишната – но това нито се е случило, нито така е организирана тази глава. Прогресията е последователност от *умишлени компромиси*: всяка система придобива нова способност, като се отказва от нещо друго. Прочетена по този начин, главата е изследване на цената на всеки напредък, а не класация на победители.

Под отделните компромиси три оси на движение преминават през всичките пет системи и придават гръбнака на главата. Първата ос е **на представянето**: преходът от ръчно изградена *абстракция* – групиране на подобни ръце и допускане само на няколко размера залози – към *научено невронно приближение*, при което мрежата обобщава ситуации, които таблица никога не би могла да изброи. Втората е **времева**: преходът от *решаване на цялата игра офлайн* в съхранена стратегия към *научаване на компактен модел и търсене с него в реално време*. Третата ос се появява едва в самия край, със Student of Games: обединяването на игра с **пълна и непълна информация** в един коректен алгоритъм, съчетаващ двете големи традиции на игровия изкуствен интелект – линията минимакс / търсене в дърво по метода Монте Карло / AlphaZero и линията CFR / покер.

Една идея свързва тези нишки и заслужава да бъде назована преди самите системи, именно защото тя *не е* една от тях: **ограничено по дълбочина решаване**. Формализирано от Brown, Sandholm & Amos (2018)⁸², то е принципът, че може да се търси само малко напред в игра с непълна информация и остатъкът да се замести с *научена или предварително изчислена стойност* – при условие че заместването се извършва така, че скритата информация да не го прави невалидно. Това е теория-

⁸²Brown, N., Sandholm, T. & Amos, B. (2018). “Depth-Limited Solving for Imperfect-Information Games.” *NeurIPS* 31; arXiv:1805.08195.

та, която поставя в обща рамка непрекъснатото пререшаване на **DeepStack** и вложеното решаване на под-игри на **Libratus**, която стои в основата на стратегиите за продължение на **Pluribus** и която, във формата на състояние на убеждението, се превръща във вътрешния цикъл на **ReBeL** и **Student of Games**. Ние го разглеждаме като свързваща тъкан – споменавано навсякъде, където една система го реализира – а не като шеста точка.

Накрая, още в началото си струва да се посочи единствената нишка, към която синтезът се връща. Всяка система тук е, по умишлен дизайн, „сляпа“ **за противника**: всяка изчислява стратегия, която е трудна за побеждаване *в най-лош случай* и след това я прилага без да обръща внимание кой всъщност седи срещу нея – защото отклонението с цел експлоатация може да бъде контраексплоатирано и, по думите на авторите на **Pluribus**, защото съществуващите техники за експлоатация на противника „изискват твърде много наблюдения, за да се конкурират с човешките способности извън малките игри“; и двете статии посочват консервативната (безопасна) експлоатация като единствено изключение.⁸³⁸⁴ Този подход, поставящ устойчивостта на първо място, е голямата сила на областта и, за дисертацията относно *адаптивна* игра, нейното определящо ограничение: именно отчитането на конкретния противник, което тези системи пропускат, глави 7–12 се стремят да добавят.

6.2 DeepStack (2017)

DeepStack (Moravčík et al., 2017)⁸⁵, от компютърно-покер групата на Университета на Алберта с колаборатори в Прага, беше първата програма, която побеждава професионални покер играчи в безлимитния тексаски Холдем за двама (HUNL) – професионалисти, макар и не специалисти по HUNL – със статистическа значимост и първата, която поставя евристичното търсене – двигателят зад шахмата и Го – на теоретична основа в игра с непълна информация. В рамките на четириседмично проучване той победи група от 33 професионалисти с 492 хилядни от големия блайнд на раздаване (mbb/g, стандартната единица за темп на печалба в покера; 50 mbb/g представлява значително професионално предимство) в 44 852 раздавания и нито една известна техника не успя да открие пропуск в играта му. Въпросът, от който тръгва DeepStack, рамкира цялата тази глава: **може ли програма да играе покер по начина, по който AlphaGo играе Го – търсейки локално от текущата ситуация и доверявайки се на научена функция на стойността за всичко извън хоризонта – дори когато в покера самата ситуация е частично скрита?**

Таблица 8: DeepStack (2017) накратко.

С един поглед	DeepStack (2017)
Играчи	2 (един срещу един)

⁸³Brown, N. & Sandholm, T. (2019). “Superhuman AI for multiplayer poker.” *Science*, 365(6456), 885-890.

⁸⁴Brown, N. & Sandholm, T. (2018). “Superhuman AI for heads-up no-limit poker: Libratus beats top professionals.” *Science*, 359(6374), 418-424.

⁸⁵Moravčík, M. et al. (2017). “DeepStack: Expert-level artificial intelligence in heads-up no-limit poker.” *Science*, 356(6337), 508-513.

С един поглед	DeepStack (2017)
Тип игра	HUNL – безлимитен тексаски Холдем за двама (игра за двама с нулева сума)
План (офлайн)?	Не – офлайн обучението е за мрежите за стойност, а не за съхранена стратегия
Невронна компонента	Дълбоки мрежи за контрафактични стойности (за флопа, търна и спомагателна); само стойности
Механизъм за търсене	Непрекъснато пререшаване (ограничено по дълбочина предвиждане с CFR при всяко решение)
Абстракция?	Никаква абстракция не ограничава играта; групиране в 1000 клъстера само на входа на мрежата, плюс разреден набор от залози и групиране на действията на ривъра при предвиждането
Също и с пълна информация?	Не (само непълна информация)
Изчислителни разходи	Предимно офлайн (~175 процесорни ядро-години за генериране на целите на мрежата за търна); по време на игра работи на един GPU, < 5 s/решение
Ключова иновация	Непрекъснато пререшаване + научени контрафактични стойности: първото <i>коректно</i> евристично търсене за игри с непълна информация

6.2.1 Пропускът, който запълни

Всеки предишен етап в развитието на изкуствения интелект за игри – табла, шах, Го – се основаваше на *локално търсене*: от текущата позиция се разглеждат няколко хода напред и останалото се замества с евристична стойност. Тази рецепта предполага, че позицията е известна, а покерът нарушава това предположение – правилното действие зависи от вероятностното разпределение на скритите карти на опонента, което се разкрива единствено чрез неговите залози. Отвореният въпрос, който DeepStack се опита да реши, е дали евристичното търсене може да бъде направено *коректно* при наличие на скрита информация в мащаба на HUNL – игра с приблизително 10^{160} точки на решение.

Почти две десетилетия доминиращият отговор беше нещо съвсем различно: **абстракция плюс офлайн равновесие плюс трансляция**, както в Глава 4 – свиване на 10^{160} ситуациите на HUNL до приблизително 10^{14} абстрактни, решаване на тази по-малка игра офлайн с CFR в съхранен *план* и *транслиране* по време на игра на всяка реална ситуация и залог на опонента към най-близката абстрактна. Компресията е със загуби и загубата се проявява като експлоатируемост – колко може да спечели опонент в най-лошия случай, основният показател за качество в областта, нула при равновесие на Наш. През 2015 г. основаната на абстракция програма Claudico загуби от професионалисти с 91 mbb/g,⁸⁵ а проверка с локален най-добър отговор (LBR, ефективно изчислима долна граница на експлоатируемостта) по-късно показва, че топ състезателните ботове са експло-

атируеми с повече от 3000 mbb/g – четири пъти по-зле, отколкото ако се откажеш от всяка ръка.⁸⁶ DeepStack затваря тази празнина, като изоставя цялата конструкция: никога не изгражда абстракция на цялата игра и никога не съхранява план, разсъждавайки за всяка ситуация *така както тя действително възниква* и замествайки само далечното остатъчно продължение на играта с научена оценка.

6.2.2 Архитектура

DeepStack се разделя ясно на **офлайн** фаза, в която се изгражда интуицията, и **онлайн** фаза, в която с нея се търси (вж. фигурата по-долу).⁸⁵



Фигура 24: Архитектура на DeepStack: предварителното (офлайн) изграждане на „интуиция“ (горе) обучава обща дълбока мрежа за контрафактични стойности, която след това служи за оценяване на листата в онлайн цикъла на непрекъснато пререшаване (долу).

Офлайн системата генерира милиони случайни покер ситуации и ги решава с CFR решаващ, за да

⁸⁶Lisý, V. & Bowling, M. (2017). “Equilibrium Approximation Quality of Current No-Limit Poker Bots.” *AAAI Workshop on Computer Poker* – локален най-добър отговор (LBR); arXiv:1612.07547.

получи целеви *контрафактични стойности* – хипотетичните печалби, ако агентът държи всяка от възможните ръце – и тези двойки (ситуация → стойност) обучават **дълбоките мрежи за контрафактични стойности (CFV мрежи)**. Онлайн DeepStack не използва план: между отделните решения той запазва само два вектора – своя *диапазон* (разпределението върху възможните ръце, които може да държи) и *контрафактичните стойности* на опонента – а при всеки ход изпълнява CFR върху малко дърво за предвиждане, вкоренено в истинското текущо състояние, като използва CFV мрежата за изчисляване на стойностите на листата на границата на дълбочината. Невронната мрежа се използва *само* на границата на дълбочината като оценител на листата; търсенето се извършва от CFR; и – най-важното – в цикъла не се прилага абстракция на цялата игра.

6.2.3 Ключова иновация: непрекъснато пререшаване с научени контрафактични стойности

Приносът на DeepStack е в обединяването на две идеи, като всяка от тях прави другата осъществима.

Първата е **непрекъснатото пререшаване**: възстановяване на свежа локална стратегия при всяко решение въз основа на поддържащия диапазон и вектора на контрафактичните стойности на опонента, след което тя се изхвърля, така че агентът никога не съхранява или не се ангажира с глобална стратегия. Класическото пререшаване (Burch и др., 2014) показва, че за да се възстанови стратегия за под-игра, не е необходима цялата стратегия – достатъчни са само собственият диапазон при влизане в под-играта и векторът на контрафактичните стойности на опонента.⁸⁷

Всичко това е възможно благодарение на начина, по който се поддържат двата вектора. След всяко събитие DeepStack актуализира своите два вектора по прости правила: при **собствено действие** той заменя пререшените контрафактични стойности за избраното действие и извършва байесови актуализации на своя диапазон; при **случайно събитие** той заменя стойностите на тази карта и анулира вече невъзможните ръце; а при **действието на опонента** той не прави *абсолютно нищо*. Този последен момент е тихият майсторски ход: тъй като той проследява *стойностите* на опонента, а не неговия *диапазон*, и никога не се нуждае от конкретното действие на опонента, за да поддържа тези стойности, той заобикаля стъпката на трансляция на действията, която парализира ботовете, основани на абстракция. Опонентът може да направи всеки залог с всякакъв размер; DeepStack просто пререшава от състоянието, което този залог е произвел.

Втората идея е **научената мрежа за контрафактични стойности** – „интуицията“ на DeepStack. В игра с пълна информация оценителят на листо съпоставя едно състояние към едно число; при непълна информация той трябва да съпостави *цяло публично състояние плюс диапазоните и на двамата играчи* към вектор от контрафактични стойности, по една за всяка ръка, защото стойностите в един възел се променят с диапазоните, които достигат до него. С тази мрежа, която доставя стойности в края на текущия рунд за залози, ограничението по дълбочина свива пререшаваната игра

⁸⁷Burch, N., Johanson, M. & Bowling, M. (2014). “Solving Imperfect Information Games Using Decomposition.” AAAI, pp. 602–608 – пререшаване и разширената под-игра.

от 10^{160} до най-много 10^{17} точки на решение, а описаният по-долу разреден набор от действия – до около 10^7 – достатъчно малко, за да бъде решена за по-малко от пет секунди на един GPU.

Сдвояването е доказуемо коректно.⁸⁵ Ако грешката на мрежата за стойности е най-много ϵ , а пререшаването изпълнява T итерации на CFR, експлоатируемостта на получената стратегия е ограничена от

$$\text{експлоатируемост} < k_1 \epsilon + k_2 / \sqrt{T},$$

с игрово-специфични константи k_1, k_2 . Първият член представлява цената на несъвършената интуиция, а вторият – обичайната **сходимост на CFR**. Тази граница е теоретичното ядро на статията – гаранцията, че евристичното **търсене** може да бъде пренесено в условия на **непълна информация**, без **стратегията** да стане **експлоатируема**.

6.2.4 Уговорки, задънени улици и какво статията не описва

Най-важната забележка е, че **внедрената система не е тази, за която важи теоремата**. За да играе с човешка скорост, DeepStack ограничава своето предвиждане до разреден набор от залози (отказ, плащане, два или три размера на залога, ол-ин) и в статията ясно се посочва, че това „отменя свойството на коректност на Теорема 1“. Така гаранцията на внедрената система е емпирична – подкрепена от резултатите LBR по-долу – а не доказана. Второ отклонение утежнява това: доказателството за коректност предполага стойности на *най-добър отговор*, но DeepStack всъщност използва стойности от *игра срещу себе си*, които нямат теоретично обоснование, но са били по-малко експлоатируеми в ранните тестове. Доказаният алгоритъм и печелившият алгоритъм, строго погледнато, са различни алгоритми.

Абстракцията също така се промъква в периферията. DeepStack рекламира, че не използва абстракция на карти за ограничаване на играта – но *групира* ръцете в 1000 клъстера на входа на мрежата за стойности и на ривъра изцяло се отказва от мрежата, решавайки до края на играта, като използва **абстракция на действия с клъстери** за постигане на управляемост. Нито едно от двете не подкопава резултата, но заедно те показват, че заглавието „коректно търсене без абстракции“ е стремеж, който имплементацията приближава, а не постига.

6.2.5 Изчислителни разходи и достъпност

Разходите на DeepStack са почти изцяло **офлайн и почти изцяло в решаването с CFR, чрез което се получават целевите стойности за мрежите**: само **мрежата за търна** изразходва около **175 процесорни ядро-години** на 6 144-ядрен клъстер, докато по време на игра DeepStack работи на **един стандартен GPU с под пет секунди на решение**.⁸⁵ Така изграждането *от нулата* беше по онова време в обсега само на добре осигурена лаборатория, макар че публична референтна имплементация на **Ледюк Холдем** намалява бариерата за влизане.

6.2.6 Силни страни и ограничения

Централната сила на DeepStack е **коректност с ниска експлоатируемост**: това е първият метод за търсене при непълна информация с реална гаранция, като емпирично LBR – което излага състезателните ботове като губещи хиляди mbb/g – не успява да намери начин да го победи, а самото то губи от DeepStack над 350 mbb/g.⁸⁵ Той **не изисква абстракция на цялата игра и трансляция на действия**, така че залозите на опонента извън дървото се обработват точно, без закръгляне. Допълнително предимство е оценъчната синергия – функцията на стойността на DeepStack съвпада с изискванията на оценяващия метод за намаляване на дисперсията AIVAT, като намалява стандартното отклонение в човешките проучвания с 85% и прави постигането на значимост възможно само в няколко хиляди раздавания.

Ограниченията определят дневния ред за останалата част от главата. DeepStack е приложим **само в игри за двама с нулева сума**; неговата **коректност** се основава на тази структура. Той **пререшава от нулата** при всяко решение и е валидиран единствено срещу хора и LBR – никога в директен сблъсък срещу най-силните ботове, основани на абстракция.

6.2.7 Наследство и съвременна значимост

Отстранете специфичните за покера детайли и основната идея на DeepStack е **търсене с ограничена дълбочина с научен модел на стойност в листата, адаптиран към скрита информация** – аналогът при непълна информация на търсенето с насочване по стойност зад AlphaGo и AlphaZero. Тази идея не остаря и не беше забравена; тя се превърна в шаблон: ReBeL (2020)⁸⁸ преформулира научаването на стойността на листата около публични състояния на убежденията със **игра срещу себе си в стила на AlphaZero**, а Student of Games (2023)⁸⁹ – който споделя няколко автори с DeepStack – обедини **игра с пълна и непълна информация** в един алгоритъм. **Намаляването на дисперсията в стил AIVAT**, което превръща научен модел на стойност в контролна променлива за нискодисперсна оценка на всеки стохастичен агент, остава пряко използваемо; ръчно проектираната техника *около* идеята – клъстеризацията по метода на k-средните с 1000 клъстера, отделните мрежи за всеки рунд, ръчно настроеното пререшаване – е това, което ReBeL и Student of Games заменят. Честната оценка: **като внедрена покер система DeepStack е остарял, но далеч не е просто стъпало** – неговата централна парадигма спечели и сега е основна; а за тази конкретна дисертация неговото състояние (диапазон, контрафактни стойности на опонент) и границата на разпространение на грешката са директни семена за базирано на убеждения моделиране на опонента (**принос 1**) и анализ на безопасната експлоатация (**принос 2**).

⁸⁸Brown, N., Bakhtin, A., Lerer, A. & Gong, Q. (2020). “Combining Deep Reinforcement Learning and Search for Imperfect-Information Games.” *NeurIPS* 33, 17057–17069; arXiv:2007.13544.

⁸⁹Schmid, M. et al. (2023). “Student of Games: A unified learning algorithm for both perfect and imperfect information games.” *Science Advances*, 9(46), eadg3256. doi:10.1126/sciadv.adg3256 (arXiv:2112.03178, first posted in 2021 as “Player of Games”).

6.3 Libratus (2017/2018)

DeepStack отговори на своя водещ въпрос, като изостави парадигмата „абстракция и план“, но все пак запази рядка абстракция на залозите в собственото си предвиждане и никога не беше изпитан в директен двубой срещу най-силните по-ранни ботове или срещу специалисти по HUNL в дълъг и строго проведен мач. Libratus (Brown & Sandholm, 2017; Carnegie Mellon)⁸⁴ беше създаден независимо и обявен същата година, и направи противоположния залог: запази парадигмата „абстракция и план“ и излекува единствения ѝ фатален недостатък. Неговият водещ въпрос е огледален образ на този на DeepStack: **какво ще стане, ако решим груб план на цялата игра офлайн, след това го поправим в реално време там, където абстракцията е твърде груба – с доказуема гаранция, че поправката никога няма да ни направи по-експлоатируеми?** През януари 2017 г. Libratus стана първата програма, която победи най-добрите човешки специалисти по HUNL в дълъг мач, побеждавайки четирима професионалисти със 147 mbb/g в 120 000 раздавания при 99,98% значимост – и, за разлика от DeepStack, първо победи убедително в директен двубой най-добрия дотогава изкуствен интелект за покер.

Таблица 9: Libratus (2017/2018) накратко.

С един поглед	Libratus (2017/2018)
Играчи	2 (един срещу един)
Тип игра	HUNL – безлимитен тексаски Холдем за двама (игра за двама с нулева сума)
План (офлайн)?	Да – абстрахирана стратегия за цялата игра, решена офлайн с MCCFR (подробна в началото, груба в края)
Невронна компонента	Няма – чисто табличен CFR / абстракция (без невронни мрежи никъде)
Механизъм за търсене	Вложено безопасно решаване на под-игри (решаване в реално време на късната игра с CFR+ и изпълнение за всеки залог на противника извън дървото)
Абстракция?	Да – абстракция на карти (търн/ривър, само в плана) + асиметрична абстракция на действията; вътре в под-игрите в реално време отпада изцяло (без абстракция на картите)
Също и с пълна информация?	Не (само непълна информация)
Изчислителни разходи	Високи и офлайн, и онлайн: ~25 милиона процесорни ядро-часа на свръхкомпютъра Bridges; ~50 възела и десетки секунди за всяко късно решение; без GPU
Ключова иновация	План + вложено в реално време <i>безопасно</i> решаване на под-игри + самоусъвършенстване: точни, доказуемо безопасни отговори на залози извън дървото вместо трансляция на действия


6.3.1 Пропускът, който запълни

Предишният раздел очерта парадигмата, която **DeepStack** отхвърли – абстракция плюс офлайн равновесие плюс транслация – и посочи нейния фатален недостатък. **Libratus** се насочва точно към този недостатък, без да отхвърля парадигмата. Планът се решава предварително върху *фиксирано* меню от размери на залози; по време на игра всеки залог на противника, който не е в това меню, се *транслира* – закръгля се до най-близкия размер, който ботът познава. Това закръгляне е единствената най-голяма експлоатируема слабост в покера, основан на абстракция: през 2015 г. предшественикът на **Libratus** – **Claudico** – загуби първия мач *Brains vs. AI* срещу професионалисти с 91 mbb/g, отчасти защото опонентите можеха да усетят и накажат неговите граници на транслация.⁹⁰ Същата година тогава предложи две противоположни решения на един и същ проблем – едно невронно и без план, друго таблично и базирано на план – и **Libratus** е доказателството, че по-старата парадигма, правилно поправена, все още беше достатъчна, за да достигне свръхчовешка игра.

6.3.2 Архитектура

Libratus представлява конвейер от три модула, които функционират на три различни времеви мащаба – **офлайн** (преди мача), **онлайн** (при всяко вземане на решение) и **през нощта** (между отделните дни на игра) – и, за разлика от всички останали системи в тази глава, той не съдържа **никаква невронна мрежа** (вж. фигурата по-долу).⁸⁴

⁹⁰Ganzfried, S. (2016). “Reflections on the First Man vs. Machine No-Limit Texas Hold ’em Competition.” *ACM SIGecom Exchanges*, 14(2), 2–15; arXiv:1510.08578.



Фигура 25: Тримодулният конвейер на Libratus: предварително изчисленият план (горе), онлайн модулът за вложено безопасно решаване на под-игри, чрез който планът се изиграва (в средата), и нощният модул за самоусъвършенстване, който вгражда решените „дупки“ обратно в плана (долу, стрелката за обратна връзка).

Модул 1 – планът (офлайн). Libratus първо компресира приблизително 10^{161} точки на решение на HUNL до около 10^{12} чрез *абстракция на действията*, която запазва само дискретно меню от размери на залозите, и *абстракция на карти*, която групира стратегически сходни ръце и се прилага само за търна и ривъра и само в плана.⁹¹ След това тази абстрактна игра се решава чрез игра срещу себе си с усъвършенстван **метод Монте Карло за минимизиране на контрафактичното съжаление (MCCFR)**, който вероятно премахва клонове с много отрицателно съжаление. Резултатът е **планът**: пълна, но неравномерна стратегия – детайлна в началото, груба в края – чиито стойности от късните рундове се използват не за игра, а единствено за *оценяване на стойността на достигане до под-игра*.

Модул 2 – вложено безопасно решаване на под-игри (онлайн). Libratus използва плана само в ранните кръгове. При достигане на третия рунд за залози – или всяка по-ранна точка, където останалата част от раздаването е достатъчно малка – той изоставя грубия план за късната игра и вместо това **изгражда нова, по-финозърнеста под-игра без абстракция на карти и я решава в реално време** с високо оптимизиран CFR+ (бърз, детерминистичен вариант на CFR). Когато противникът направи залог, който не фигурира в менюто на плана, вместо да го закръгли, Libratus решава нова под-игра, която *съдържа точно този залог*, и повтаря това за всяко следващо действие извън менюто – *вложено решаване на под-игри*.

Модул 3 – модулът за самоусъвършенстване (през нощта). Тъй като решаването в реално време се пропуска в първите два рунда, залозите на противника извън менюто *там* все още се закръглят. Модулът за самоусъвършенстване стеснява тази остатъчна слабост между игралните дни: през нощта той изчислява правилни игровитеоретични отговори на няколко от най-вредните пропуски и присажда тези клонове в плана. Нарочно това **не е експлоатация на противника** – той никога не се опитва да моделира и наказва грешките на хората (което би изложило Libratus на контраексплоатация). Вместо това използва залозите на противниците единствено като насока *кои от собствените пропуски на Libratus да закръпни*, а закръпванията са универсални, подобрявайки играта срещу всеки бъдещ противник.

6.3.3 Ключова иновация: вложено безопасно решаване на под-игри

Централният принос на Libratus е да направи **решаването на под-игра в реално време едновременно безопасно и вложено** – достатъчно силно, за да победи хората, и доказано неспособно да направи стратегията значително по-експлоатируема от плана, който усъвършенства.

Както в Глава 4, под-игра с непълна информация *не може да бъде решена изолирано*: правилната ѝ стратегия зависи от стратегиите в *други, недостигнати* под-игри, а по-ранните програми за решаване в реално време, които просто приемаха, че противникът е следвал плана до този момент – **небезопасно** решаване на под-игра – можеха да бъдат наказани с всяко отклонение. Libratus премахва това предположение с едно малко **приспособление, разширената под-игра**. В корена на

⁹¹Brown, N. & Sandholm, T. (2017). “Libratus: The Superhuman AI for No-Limit Poker (Demonstration).” *IJCAI-17*. <https://www.ijcai.org/proceedings/2017/0772>

под-играта на противника се предоставя избор за всяка ръка, която той може да държи: или да вземе фиксирана **алтернативна печалба** – оценката на плана за това колко струва тази ръка тук – или да *влезе* в детайлната под-игра и да я изиграе. Решаването на тази разширена игра принуждава усъвършенстваната стратегия на Libratus да направи противника **не по-добре от тази оценка за всяка възможна ръка**, което е точното значение на „безопасен“. Libratus изостря това с вариант, който авторите наричат **Estimated-Maxmargin** – той максимизира *най-малкия* резерв за безопасност по всички възможни ръце на противника – като използва оценки на плана за стойностите на противника вместо консервативни **горни граници** и придава по-малка тежест на ръцете, които противникът би могъл да държи само ако е допуснал грешка по-рано.

Комбинацията идва с гаранция, която е паралелна на тази на DeepStack.⁹² Ако σ^* е най-малко експлоатируемата стратегия, която се различава от плана само в рамките на решените под-игри, а оценката на плана за стойностите на под-играта на противника има отклонение не повече от Δ , тогава експлоатируемостта на усъвършенстваната стратегия се подчинява

$$\text{експлоатируемост}(\sigma_{\text{усъв}}) \leq \text{експлоатируемост}(\sigma^*) + 2\Delta.$$

Членът 2Δ представлява цената на несъвършените оценки на стойностите и е структурно аналогичен на члена $k_1\epsilon$ в DeepStack – и двата определят колко една грешка в стойностите, подадени на решавача, може да повлияе върху експлоатируемостта в най-лошия случай.

„Вложено“ е втората половина. Вместо да разширява менюто за залози на плана (което би раздуло предварителното офлайн решаване), Libratus създава **отделен отговор на всеки залог извън менюто в реално време**: когато противникът направи залог с размер, който не е бил изброяван преди, той изгражда разширена под-игра, чиято алтернативна печалба е най-доброто *в менюто* действие, което противникът би могъл да предприеме вместо това, решава я и го прави отново за всеки следващ залог извън менюто по време на раздаването. В контролираните експерименти това превъзхожда предишния стандарт – закръгляне на залога до най-близкия размер в менюто – с повече от порядък по отношение на експлоатируемост в най-лошия случай (119 срещу 1465 mbb/g в докладвания тест с малки игри).⁹²

6.3.4 Уговорки, задънени улици и какво статията не описва

Най-разкривателното ограничение е, че **само планът не е свръхчовешки – той дори не побеждава предишния бот**. Срещу Baby Tartanian8, победителя от състезанието през 2016 г., суровият план на Libratus не го побеждава (-8 ± 15 mbb/g при 95% доверителен интервал); едва когато вложеното решаване на под-игри беше включено, същата система спечели с 63 ± 28 mbb/g.⁸⁴ С други думи, предварителната стратегия е скеле и по същество цялото предимство на Libratus идва от търсене в реално време.

⁹²Brown, N. & Sandholm, T. (2017). “Safe and Nested Subgame Solving for Imperfect-Information Games.” *NeurIPS* 30, 689–699; arXiv:1705.02955.

Няколко други важни детайла си струва да се отбележат. **Транслацията на действия не е премахната, а само ограничена:** в първите два рунда на залагане Libratus все още закръгля залозите на опонента извън менюто, а целият модул за самоусъвършенстване съществува, за да работи върху този остатъчен проблем, по три „дупки“ на нощ, без никога да го отстранява напълно. **Безопасното решаване на под-игри трябваше да бъде преработено, за да стане изобщо приложимо** – в продължение на три години се смяташе за непрактично, тъй като в директен сблъсък учебниково-безопасното решаване губеше от теоретично необоснования *небезопасен* вариант – и дори тогава Libratus умишлено използва *небезопасен* метод за решаване веднъж, при първото си влизане в третия рунд, защото там е по-евтин и емпирично достатъчно добър. Използването на оценки вместо горни граници може по принцип да повиши експлоатируемостта *над* тази на плана, ограничена единствено от 2Δ на теоремата. И накрая, истинската цена на изчисленията излиза наяве едва във вторичните източници, а **кодът никога не е бил публикуван**, оставяйки независимата проверка да се основава единствено на публикувания псевдокод.

6.3.5 Изчислителни разходи и достъпност

Където сметката на DeepStack се плаща почти изцяло онлайн, а играта му е евтина, Libratus е **скъп и в двата края**. Проектът е консумирал приблизително **25 милиона процесорни ядро-часа** на свръхкомпютъра Bridges в Pittsburgh Supercomputing Center за една година – от които около 6 милиона са отишли за изграждане и решаване на плана, около 3 милиона за решаване на под-игри в реално време по време на мача, около 3 милиона за модула за самоусъвършенстване и останалите ~13 милиона за експериментални опити и оценка.⁹¹ Всяко **решаване на под-игра в реално време е използвало около 50 възела и е отнемало порядък на десетки секунди**, без GPU никъде,⁹³ което направи Libratus, както беше внедрен, по същество невъзможен за възпроизвеждане извън голям център за свръхкомпютри.

6.3.6 Силни страни и ограничения

Главното предимство на Libratus е **решителна, строго демонстрирана свръхчовешка игра**: той побеждава всеки от четиримата професионалисти индивидуално и, за разлика от DeepStack, побеждава и **предходния най-добър изкуствен интелект за покер в директен сблъсък с 63 mbb/g**, отделяйки своята сила от въпроса за човешкото умение. Ограниченията му – само за игра за двама с нулева сума, основан на абстракция, все още транслира залози извън менюто в ранните рундове, никакво невронно обобщаване и игра в мащаба на свръхкомпютър – подготвят останалата част от главата, а тъй като както хората, така и изкуственият интелект се адаптираха по време на мача, дори значимостта в заглавието е, стриктно казано, „сякаш-независима“ стойност, въпреки че предимство от 147 mbb/g за 120 000 раздавания не оставя никакво реално съмнение.⁸⁴

⁹³Sandholm, T. (2021). “State-of-the-art for two-player no-limit Texas hold’em: Libratus.” Lecture 13 slides, 15-888 Computational Game Solving (Fall 2021), Carnegie Mellon University.

6.3.7 Наследство и съвременна значимост

Извадете абстракционния механизъм и трайната идея на Libratus е **търсене в реално време, насложено върху груба предварително изчислена стратегия, направено безопасно при скрита информация**: решавайте локалната ситуация точно в момента на вземане на решение, в съответствие с евтин глобален план, и реагирайте на това, което опонентът действително прави, а не на закръглено приближение на него. Вложеното безопасно решаване на под-игри на Libratus е пряк предшественик на търсенето в реално време в **Pluribus** (2019), а същият модел „усъвършенствайте глобална оценка на стойността с локално решаване“ се появява отново, сега с *научени* стойности, заменящи табличната схема, в **ReBeL** (2020). Честната оценка е, че Libratus е *надминат като архитектура, но оправдан като теза*: неговият залог, че **търсенето в реално време има по-голямо значение от по-голяма предварително изчислена стратегия**, беше напълно точен, дори когато залогът му върху табличната абстракция беше надминат. За настоящата дисертация Libratus дава две основи: неговата граница на експлоатируемостта при безопасно решаване на под-игри е шаблон за **безопасна експлоатация при грешка в стойността (Принос 2)**, а умишленият му отказ да експлоатира – „поправете собствените си слабости, не моделирайте противника“ – е точният контрапункт, спрямо който може да бъде дефинирана *ограничена, целенасочена адаптация към противника* (Принос 1).

6.4 Pluribus (2019)

Libratus сложи точка на въпроса за безлимитния Холдем за двама, но неговите гаранции за безопасност – и всъщност самото значение на „решаването“ на играта – се основаваха на структурата на игра с нулева сума за двама играчи. Холдемът, както хората всъщност го играят обаче, събира шестима. Pluribus (Brown & Sandholm, 2019; Carnegie Mellon и Facebook AI)⁸³ се изправи директно пред въпроса за игрите с много играчи: **какво се случва с рецептата план-плюс-търсене в реално време, когато махнете патерицата на игрите за двама и седнете на маса за шестима – обстановка, в която равновесието на Наш не е нито уникално, нито ефективно изчислимо, нито дори гаранция, че няма да загубите?** Отговорът му беше емпиричен и категоричен. В два формата – петима професионалисти, седнали с едно копие на Pluribus, и един професионалист срещу пет копия – той победи петнадесет елитни професионалисти, печелейки около **48 хилядни от големия блайнд на раздаване** срещу петима души наведнъж (приблизително пет големи блайнда на сто раздавания, решаващ марж на маса с шестима) при 95% статистическа значимост. И го направи след обучение в продължение на **осем дни на един 64-ядрен сървър за около \$150 облачни изчисления** – с около хиляда пъти по-малко изчисления, отколкото изразходва свръхкомпютърът на Libratus.

Таблица 10: Pluribus (2019) накратко.

С един поглед	Pluribus (2019)
Играчи	6 (маса с шестима, 6-max) – първият свръхчовешки изкуствен интелект в която и да е еталонна игра с повече от двама играчи/отбора
Тип игра	6-max NLHE – безлимитен тексаски Холдем с шестима играчи (непълна информация; с много играчи, <i>не</i> е игра за двама с нулева сума)
План (офлайн)?	Да – цялостен план за играта, решен офлайн чрез Linear MCCFR; използва се <i>директно</i> само в първия рунд за залози, след това служи като скеле
Невронна компонента	Няма – изцяло табличен CFR / абстракция (без невронни мрежи никъде, както при Libratus)
Механизъм за търсене	Търсене в реално време с <i>ограничена дълбочина</i> с $k=4$ стратегии за продължение в листата (вложени <i>небезопасни</i> решавания, пререшаване от началото на всеки рунд за залози); Linear CFR вътре в под-игрите
Абстракция?	Да – действия (1–14 размера на залозите в плана; 1–6 при търсене) + информационна абстракция (без загуби в първия рунд; със загуби в по-късните, по-детайлни при търсенето, отколкото в плана)
Също и с пълна информация?	Не (само непълна информация)
Изчислителни разходи	Забележително ниски: план ~12 400 ядро-часа / 8 дни / < 512 GB на един 64-ядрен сървър (~\$144); игра на 2 процесора (28 ядра), < 128 GB, без GPU, 1–33 s/решение
Ключова иновация	Свръхчовешка игра с шестима играчи чрез план + търсене с ограничена дълбочина със стратегии за продължение – спечели <i>емпирично</i> , с минимален бюджет, без гаранция за безопасност при N играчи

6.4.1 Пропускът, който запълни


Всеки свръхчовешки игрови изкуствен интелект преди Pluribus – дама, шах, Го и двете предходни покер програми – споделяше едно скрито предположение: двама играчи, нулева сума. В тази обстановка равновесието на Наш носи свойство, което го прави очевидната цел: на всеки играч, който възприеме такова равновесие, е *гарантирано*, че *няма да загуби* средно (по математическо очакване), независимо какво прави противникът, и ако двама играчи независимо изчислят равновесия, техните стратегии все още се комбинират в равновесие. При повече от двама играчи намирането – дори приближаването – на равновесие на Наш е изчислително непосилен проблем в общия случай; обикновено има *много* равновесия; и, фатално, ако всеки играч независимо избере едно, получената съвместна стратегия може да не бъде равновесие изобщо, така че играчът може да *загуби*, докато играе безупречна равновесна стратегия. Заключение е рязко – в покера с мно-

го играчи равновесието на Наш *не е нито уникално, нито гаранция за безопасност*, а дефиницията на успеха в тази област от две десетилетия просто изчезва.

Pluribus затваря тази празнина, като променя целта и след това я постига: той цели единствено *емпирично и последователно да побеждава елитни хора* и предварително приема, че неговите алгоритми не носят гаранция за сближаване към равновесие извън играта за двама с нулева сума. Тази отстъпка е цялата същност – и това е точната празнина, която принос 2 на тази дисертация се стреми да запълни. Другата половина на празнината е механична: с шестима играчи решаването на всяка под-игра в късната фаза *докрай* в реално време, както правеше Libratus, става непрактично, така че Pluribus се нуждаеше от търсене в реално време, което да гледа само малко напред и да спира.

6.4.2 Архитектура

Както и при Libratus, Pluribus се разделя на офлайн фаза, която изгражда план, и онлайн фаза, която извършва търсене – но балансът на силите между тях е обърнат и, отново както при Libratus, **няма невронна мрежа никъде** (вж. фигурата по-долу).



Фигура 26: Двухазната архитектура на Pluribus: предварително изчисленият с Linear MCCFR план (горе) служи като източник на $k=4$ стратегии за продължение в онлайн търсенето с ограничена дълбочина (долу).

Офлайн Pluribus изчислява план за цялата игра чрез игра срещу себе си с **Монте Карло CFR (MCCFR) с външна извадка**, като абстрахира играта само грубо, и използва този план *директно* само в първия от четирите кръга на залагане. Навсякъде другаде – флоп, търн, ривър – Pluribus изхвърля грубия план локално и **търси в реално време** по-детайлна стратегия, точно както направи Libratus, с една решаваща разлика: той не решава до края на играта. Той разглежда само един или два кръга напред до граница на дълбочината и спира, което прави шест играчи изчислително достъпни. За разлика от Libratus, няма **модул за самоусъвършенстване**: Pluribus никога не поправя своя план между сесиите, тъй като търсенето с ограничена дълбочина в три от четирите кръга вече извършва поправките.

6.4.3 Ключова иновация: търсене с ограничена дълбочина със стратегии за продължение

Евристичното търсене в шах или Го работи, като гледа на фиксирано разстояние напред и отчита стойност от хоризонта при предположението, че и двете страни ще играят добре след това. Това предположение напълно се проваля при скрита информация, а Brown и Sandholm илюстрират провала с еднократна последователна игра „камък–ножица–хартия“: ако търсещият приеме, че противникът ще играе равновесие (всеки ход една трета от времето) отвъд хоризонта, тогава всяко действие изглежда еднакво оценено на нула и търсещият може да се установи на „винаги играй камък“ – при което противникът преминава към „винаги хартия“ и истинската стойност рязко спада. Листо в игра с непълна информация следователно няма *една-единствена стойност*: неговата стойност зависи от стратегията, която търсещият ще възприеме, което е именно това, което търсенето се опитва да определи.

Централният принос на Pluribus е начинът, по който все пак се определя стойност за листата. Когато търсенето достигне границата на дълбочината, вместо да се фиксира една стратегия за продължение, **всеки играч, който все още е в раздаването, избира измежду четири различни стратегии за продължение** за остатъка от играта и може да ги смесва. Четирите са умишлено опростени: самият план и три изместени копия, които умножават вероятността за *отказ*, за *плащане* и за *повишаване* (всеки след това се ренормализира). Тъй като противникът винаги може да премине към стратегия за продължение, която най-много наказва търсещия, небалансирана стратегия – покер еквивалентът на винаги играене на камък – вече не се възнаграждава и търсещият се насочва към баланс. Тази идея първоначално беше доказана в предшественика за двама играчи Modicum (Brown, Sandholm & Amos, 2018), който победи двама бивши шампионски бота, докато работеше на 4-ядрен лаптоп с 16 GB памет.⁸²

Pluribus обобщава идеята от двама играчи на шестима. В Modicum само *противникът* избираше измежду стратегии за продължение, докато търсещият винаги следваше плана; Pluribus позволява на **търсещия също да избира измежду стратегиите за продължение**, което балансира играчите. Освен това той не пререшава от текущата точка за вземане на решение, а от *началото на текущия рунд за залози*, като фиксира единствено вече предприетите действия. Това „небезопасно“ търсене – наречено така, защото, за разлика от търсенето на Libratus, не дава гаранция, която да ограничава **експлоатируемостта** – е по-евтино и, тъй като започва непосредствено след слу-

чайното събитие с множество разклонения, на практика се оказва трудно за експлоатиране.

Това, което очевидно липсва от всичко това, е една *гаранция*. DeepStack ограничи своята експлоатируемост до $k_1\epsilon + k_2/\sqrt{T}$,⁸⁵ а Libratus – до 2Δ ;⁹² Pluribus не предлага такова ограничение и пропускането е принципно, а не поради небрежност. Двигателят на CFR все още, във всяка крайна игра, свежда *средното съжаление* на всеки играч до нула,

$$\frac{R_i^T}{T} \longrightarrow 0 \quad (\text{без съжаление}),$$

но изводът, който доведе двамата предшественици от липсата на съжаление до безопасност – *играта без съжаление (no-regret) се сближава към равновесие на Наш и едно равновесие на Наш не може да бъде победено* – важи само когато има двама играчи и играта е с нулева сума. При шестима играчи първото следствие отпада (играта срещу себе си не е задължително да се доближава до равновесие), а второто е безсмислено (едно равновесие не е непобедимо). Самите итерации, които *доказаха* DeepStack и Libratus безопасни, следователно носят на Pluribus само емпирична сила: свръхчовешка на практика, без нищо сертифицирано.

6.4.4 Уговорки, задънени улици и какво статията не описва

Най-същественото признание е, че Pluribus използва **небезопасно** решаване на под-игра – той предполага, че опонентите са играли стратегията, която той изчислява за тях – което, както авторите заявяват ясно, „няма теоретични гаранции за представянето дори в игри за двама с нулева сума и има случаи, в които води до силно експлоатируеми стратегии“. ⁹⁴ Съществуват безопасни алтернативи, но при директен сблъсък те се представиха по-зле, така че Pluribus взема емпиричната победа и смекчава риска само като винаги пререшава от началото на рунда за залози. Втора слабост е наследена и никога не е напълно затворена: в *първия* рунд за залози залозите на опонента, които се отклоняват твърде много от менюто на плана, все още се **закръглят** чрез трансляция на действия, и Pluribus, тъй като няма модул за самоусъвършенстване, просто живее с нея.

Основните нововъведения на Pluribus **никога не са оценени поотделно (чрез аблация)** – авторите признават, че измерването на приноса на всяко едно от тях е „твърде скъпо“ – но статията за предшественика за двама играчи показва, че приемането на *една-единствена* стратегия за продължение (плана) в листата губи от Baby Tartanian8 (-10 ± 8 mbb/g) и не побеждава Slumbot (-1 ± 15), докато версията с четири стратегии за продължение побеждава и двата бота ($+6 \pm 5$ и $+11 \pm 9$);⁸² наборът от стратегии за продължение върши реална работа, а не е украшение. По-малки любопитни факти допълват картината: Pluribus играе стратегията от **последната** итерация на търсенето, а не обичайната усреднена по итерациите стратегия, за да избегне остатъчни лоши действия; по време на играта срещу себе си той се научи да **избягва влизането само с плащане на блайнда („лимпинг“)**, но **залага „донк“ (с изпреварващ залог) много по-често от хората**; и – както Libratus – неговият **код никога не е бил публикуван**, оставяйки само псевдокод за независима

⁹⁴Brown, N. & Sandholm, T. (2019). Supplementary Materials for “Superhuman AI for multiplayer poker.” *Science*, 365(6456).

проверка, тъй като покерът се играе комерсиално.

6.4.5 Изчислителни разходи и достъпност

Планът беше обучен за **осем дни на един 64-ядрен сървър** за около **12 400 ядро-часа** и под 512 GB памет – приблизително **\$144** при спот цени в облака – а на масата Pluribus работи на **два CPU (28 ядра) и под 128 GB, без GPU на който и да е етап**.⁸³ Докато DeepStack концентрира разходите си офлайн, а Libratus плащаше скъпо и в двата края, Pluribus е **евтин и в двата края**. Рязкото поевтиняване не е магия, а резултат от алгоритмите: съчетаването на търсене с ограничена дълбочина (което авторите оценяват, че спестява поне пет порядъка спрямо решаване до края), линеен CFR и агресивно подрязване и пестене на памет. Тъй като код не е публикуван обаче, „достъпен“ описва *метода*, демонстриран в мащаб на лаптоп от Modicum, повече отколкото изтегляема програма.

6.4.6 Силни страни и ограничения

Главното предимство на Pluribus е просто в това, че е **първи**: първият изкуствен интелект, който постига свръхчовешко представяне в която и да е широко призната еталонна игра с повече от двама играчи или два отбора и в най-популярната форма на покера.⁸³ Победата беше решителна и строга – **+48 mbb/g (p = 0,028)** срещу петима елитни професионалисти на масата и **+32 mbb/g (p = 0,014)** с пет копия срещу един-единствен професионалист – измерена с намалителя на дисперсията AIVAT (който намали дисперсията около девет пъти) в 20 000 раздавания.

Ограниченията са именно това, от което се отказва, за да стигне дотук. Pluribus **няма абсолютно никаква гаранция за безопасност** в обстановката с шестима играчи – няма сходимост към равновесие на Наш, няма граница на експлоатируемостта – така че неговото свръхчовешко състояние е *емпиричен* факт за петнадесет силни играчи в 20 000 раздавания, а не теорема. Статията твърди само, че „съществуват мащабни и сложни среди с много играчи и непълна информация, в които внимателно конструиран алгоритъм за игра срещу себе си с търсене може да създаде свръхчовешки стратегии“.⁸³ И неговият темп на печалба от 48 mbb/g на маса с шестима, макар и решителен, не е в същата „валута“ като 147-те mbb/g на Libratus в игра един срещу един – различна игра, петима опоненти, по-висока дисперсия.

6.4.7 Наследство и съвременна значимост

Две идеи надживяват спецификите на покера. Първата е техническа: **търсене с ограничена дълбочина, направено коректно при скрита информация чрез даване на всяко листо на малко меню от избираеми стратегии за продължение вместо една-единствена стойност**. Втората е икономическа: Pluribus е каноничната демонстрация, че **по-труден проблем може да бъде решен с хиляда пъти по-малко изчисления чрез по-добри алгоритми и търсене в момента на вземане на решение**, вместо повече хардуер. В архитектурната дъга на тази глава Pluribus е точката, в която *бариерата на броя играчи* пада; *бариерата на обобщаването*, която той оставя

изправена – всичко все още е таблично и ръчно абстрахирано – е това, което **ReBeL** и **Student of Games** разрушават след това, като заменят плана с научени стойности на състоянието на убеждението. За тази дисертация по-специално Pluribus е ключовият камък на принос 2 – емпиричното доказателство, че методите, съчетаващи равновесие на Наш и търсене, *работят* в игри с N играчи и непълна информация, без да предлагат **абсолютно никаква гаранция за безопасност**, което е точно пропускът, който една теория на многоагентната безопасна експлоатация трябва да затвори.

6.5 ReBeL (2020)

Pluribus преодоля бариерата на броя играчи, но го направи, като остана точно това, което беше Libratus – гигантска, ръчно абстрахирана таблица за търсене без нищо научено, което да се прехвърля от една ситуация в друга – и постигна победата си с шестима играчи, като изцяло се отказа от безопасността. ReBeL (Brown, Bakhtin, Lerer & Gong, 2020; Facebook AI Research)⁸⁸ прави крачка назад от шестима към двама играчи и задава обратния въпрос: **какво ще стане, ако вместо ръчно да създаваме абстракция и предварително да изчисляваме план, пуснем AlphaZero – обучение с подкрепление чрез игра срещу себе си плюс търсене, както по време на обучението, така и по време на игра – в игра със скрита информация, възстановявайки гаранциите, които Pluribus отхвърли?** Неговият отговор, *рекурсивно обучение на основата на убеждения* (Recursive Belief-based Learning), е по думите на авторите първият алгоритъм, който прави обучението с подкрепление и търсенето доказуемо коректни в игри с непълна информация. Трикът е да се преформулира играта като „игра с пълна информация“ върху **публични състояния на убежденията (PBS)** – вероятностни разпределения за това какво може да държи всеки играч при даденото общо знание – върху които функциите на стойността и на стратегията са добре дефинирани; след това цикъл в стил AlphaZero обучава невронна мрежа за стойности (и стратегия) върху тези състояния, като минимизирането на контрафактичното съжаление (CFR) решава под-игри с ограничена дълбочина на листата. ReBeL доказуемо клони към равновесие на Наш във всяка игра за двама с нулева сума и побеждава Донг Ким – професионалист в хедс-ъп, загубил най-малко от Libratus – със 165 mbb/g в рамките на 7 500 раздавания, като използва *значително по-малко* експертни познания от всеки предишен покер изкуствен интелект – и, за разлика от затворените Libratus и Pluribus, неговата реализация (за Liar’s Dice) беше **отворена**.

Таблица 11: ReBeL (2020) накратко.

С един поглед	ReBeL (2020)
Играчи	2 (хедс-ъп) – <i>гаранциите</i> са за игра за двама с нулева сума; формализмът е за N играчи, но гаранциите и експериментите са само за двама

С един поглед	ReBeL (2020)
Тип игра	Произволни игри за двама с нулева сума и непълна информация; оценен върху HUNL покер и Liar's Dice (и опростения вариант turn endgame hold'em). Редуцира се до алгоритъм в стил AlphaZero при игри с пълна информация
План (офлайн)?	Няма съхранен план – офлайн продуктът е <i>научена мрежа за стойности (+ стратегия) върху PBS</i> , получена чрез игра срещу себе си, а не таблица на стратегиите
Невронна компонента	Мрежа за стойности върху PBS + (по избор) мрежа за стратегия върху PBS; MLP (GeLU/LayerNorm), за покера 6 скрити слоя по 1536 неврона; вход = убеждения върху 1326-те възможни ръце на всеки играч + общите карти + пота + флаг за залог
Механизъм за търсене	CFR (CFR-D / CFR-AVG; също FP/FLOP), решаващ под-игра с ограничена дълбочина и корен в PBS, като научената мрежа за стойности дава (зависещите от итерацията) стойности в листата – както по време на обучението , така и по време на игра
Абстракция?	Няма – няма абстракция на карти/информация (със загуби или без); мрежата за стойности я замества. Запазва се само малко (≤ 9) ръчно избрано меню от размери на залозите, като залозите извън дървото се добавят в реално време
Също и с пълна информация?	Не (представен и оценен като метод за игри с непълна информация), с уточнението, че <i>дегенерира</i> до търсене в стил AlphaZero, ако частната информация бъде премахната – пълното обединяване е претенция на Student of Games
Изчислителни разходи	Обучение на GPU: пълният агент за HUNL използва ~90 DGX-1 възела $\times$ 8 V100 GPU за генериране на данни чрез игра срещу себе си (за разлика от ~\$150 само за CPU при Pluribus); CFR в една нишка на CPU; игра < 2 s на раздаване, ≤ 5 s на решение
Ключова иновация	Публични състояния на убежденията + цикъл на игра срещу себе си в стил AlphaZero, който обучава мрежа за стойности/стратегия върху PBS, а CFR работи в пространството на убежденията: по думите на авторите първото <i>коректно</i> съчетание на RL и търсене за игри с непълна информация; възстановява доказуема гаранция за равновесие на Наш при 2p0s без абстракция и без план

6.5.1 Пропускът, който запълни

Libratus и Pluribus бяха, в основата си, *таблични* обекти – стратегия или план, съхранени върху ръчно проектирана абстракция; само DeepStack имаше невронна компонента, но дори и той раз-


читаше на клъстеризация в 1000 клъстера на входа на мрежата и абстракция на ривъра. Междувременно най-успешната парадигма в изкуствения интелект за игри – съчетанието в AlphaZero на обучение с подкрепление чрез игра срещу себе си и търсене – беше *недостъпна* за игри с непълна информация: дотогава алгоритмите, съчетаващи обучение с подкрепление и търсене, не са били теоретично коректни при непълна информация и не е било показано, че са успешни в такива игри.⁸⁸

Причината е концептуалната същност на цялата глава. AlphaZero предполага, че всяко състояние има една единствена добре дефинирана стойност, а скритата информация унищожава това предположение. Примерът в статията е модифициран камък-ножица-хартия, в който ножицата печели (или губи) двойно: равновесието е да се хвърля камък и хартия 40% от времето и ножица 20%, и при това равновесие всяко действие има очаквана стойност нула. Еднопластово търсене в стила на шаха, което използва равновесната стойност в листата, намира всеки ход еднакво добър и може да се спре на „винаги камък“, след което противникът преминава към „винаги хартия“ и истинската стойност на камъка се срива от 0 до -1. **В игра с непълна информация стойността на едно действие зависи от вероятността, с която то се изиграва**, така че състояние, дефинирано само от последователността на действията, няма единствена стойност. Pluribus беше закърпил симптома с избираеми стратегии за продължение в листата⁸²; ReBeL лекува болестта, като предефинира състоянието така, че да включва разпределението на вероятностите върху скритата информация – *публично състояние на убежденията* – върху което стойностите отново стават добре дефинирани. Ръчно създадената абстракция и предварително изчисленият план изчезват, заменени от функция на стойността, научена единствено от игра срещу себе си.

6.5.2 Архитектура

ReBeL е най-добре да се възприема като **AlphaZero за непълна информация**: цикъл на игра срещу себе си, който обучава невронни мрежи за стойности и стратегии, при който „търсенето“, използвано както по време на обучение, така и при игра, представлява решаване с CFR на под-игра с ограничена дълбочина, а всичко се извършва върху *публични състояния на убежденията*, а не върху сурови игрови състояния (вж. фигурата по-долу).⁸⁸⁹⁵

⁹⁵Bakhtin, A. (2020, 3 Dec.). “ReBeL: A general game-playing AI bot that excels at poker and more.” *Meta AI blog*.



Фигура 27: Цикълът на ReBeL в стил AlphaZero: играта срещу себе си (вляво) и играта (вдясно) използват една и съща мрежа за стойности и стратегия върху PBS и решават под-игри с ограничена дълбочина и корен в публичното състояние на убежденията.

Започвайки от коренно PBS, ReBeL построява под-игра с ограничена дълбочина, решава я с CFR (конкретно CFR-D, „CFR с декомпозиция“, или неговия вариант CFR-AVG), записва решените стойности и стратегия като цели на обучението, избира листо, което става следващото коренно PBS, и продължава до края на играта – след това преобучава мрежите и повтаря процеса, по същия начин както AlphaZero редува игра срещу себе си с обучение на мрежата. На всяка итерация на CFR стойността на всяко листо идва от **научената мрежа за стойности върху PBS** – така стойностите в листата се променят от итерация до итерация, което е именно това, което гарантира коректността на търсенето при наличие на скрита информация; незадължителна мрежа за стратегия дава на CFR добра начална стратегия (warm start) и така намалява броя на необходимите итерации. Ня-

ма **предварително изготвен план** – единствените резултати от обучението са двете мрежи – и няма **абстракция** от какъвто и да е вид: ReBeL изчислява отделна стратегия за всяко информационно състояние, като подава на мрежата единствено суровото разпределение на убежденията върху възможните 1326 ръце и на двамата играчи, плюс общите карти, пота и един флаг „дали някой е заложил този рунд“. CFR (Глава 3) изпълнява търсенето, а невронното приближение на стойността (Глава 5) е оценителят на листата – сега обединени в един цикъл „игра срещу себе си плюс търсене“.

6.5.3 Ключова иновация: публични състояния на убежденията и научени стойности в пространството на убежденията

Приносът на ReBeL е един концептуален ход с три технически последствия: да се спре търсенето върху *състояния* и да се започне търсене върху *убеждения за състоянията*.

Публичното състояние на убежденията (PBS) е сърцевината на всичко това, а блогът на Meta AI дава най-ясната интуиция.⁹⁵ Вземете игра с карти и я променете така, че играчите да не могат да виждат собствените си карти – само безпристрастен съдия може; на всеки ход играч обявява, за всяка карта, която *може* да държи, вероятността, с която би предприел всяко действие, и съдията избира хода за истинската карта на играча. Тъй като стратегиите на всички играчи се приемат за общоизвестни, всеки може да проследява, чрез правилото на Бейс, вероятността всеки играч да държи всяка възможна ръка. Тази модифицирана игра е **стратегически еквивалентна** на оригиналната, но тя не съдържа *частна информация*: нейното състояние – векторът от тези вероятности – е напълно наблюдаемо за всички. ReBeL нарича това състояние публично състояние на убежденията: формално, съвместно разпределение на вероятностите върху възможните информационни състояния на играчите при дадени общи публични наблюдения.⁸⁸ Разглеждането на игрите с непълна информация като игри с непрекъснато състояние и пълна информация е стара идея (тя датира от работите върху децентрализирани многоагентни POMDP); постижението на ReBeL е, че за първи път я съчетава с обучение с подкрепление чрез игра срещу себе си в *състезателна* среда.

Първото следствие е, че **стойностите отново стават добре дефинирани**: в игрите за двама с нулева сума всяко публично състояние на убежденията β има единствена стойност $V_i(\beta)$ с $V_1(\beta) = -V_2(\beta)$, определена от това, че и двамата играчи играят равновесие на Наш в под-играта от β . Това формализира и обобщава контрафактичните стойности при дадени убеждения на DeepStack – първия пример за функция на стойността върху PBS. Второто следствие е, че цикълът на AlphaZero може да работи с **CFR като алгоритъм за търсене**: представянето на убежденията е много високодимензионно непрекъснато пространство, в което търсенето с дърво е безполезно, но в игрите за двама с нулева сума то поставя *изпъкнала* оптимизационна задача, а CFR на практика е градиентен метод за решаването ѝ – единствената съществена разлика от AlphaZero.

Третото и най-важно следствие е, че цялата схема е **доказуемо коректна**. По време на игра срещу себе си ReBeL може да приеме, че стратегиите и на двамата играчи са общо знание, така че винаги

знае истинското PBS; срещу реален противник това не е така и при наивен подход търсенето става некоректно. Решението на ReBeL е да изпълнява *същия алгоритъм* по време на игра и **да действа според стратегията на произволно избрана итерация на CFR**. Статията доказва (Теорема 3), че това води до безопасно търсене (изиграната стратегия е равновесие на Наш *по математическо очакване*) без допълнителни ограничения, докато всеки предишен метод за „безопасно търсене“ добавяше ограничения толкова скъпи, че никога не бяха използвани изцяло в състезателен бот. С мрежа за стойности върху PBS, чиято грешка е най-много δ , и T итерации на CFR на под-игра ReBeL играе ε -равновесие на Наш – такова, което никой противник не може да експлоатира за повече от $\varepsilon - c$

$$\varepsilon = \delta C_1 + \frac{\delta C_2}{\sqrt{T}},$$

за специфични за играта константи C_1, C_2 . Структурата отразява тази на $k_1\varepsilon + k_2/\sqrt{T}$ от DeepStack, но докато границата на DeepStack управлява едно пререшаване, тази на ReBeL управлява *сходимостта към равновесие на Наш на цялата игра*, а двата члена се мащабират с грешката на научената стойност δ : с подобряването на мрежата за стойности играта на ReBeL се доближава до точно равновесие на Наш. Това е точният смисъл, в който ReBeL се връща към игрите за двама с нулева сума и възстановява гаранциите, от които Pluribus се отказа.

6.5.4 Уговорки, задънени улици и какво статията не описва

Теорията е в основния текст, а *инженерната честност* – в приложенията. Приложение D каталогизира това, което ReBeL умишлено **отхвърля**. Той не използва *никаква* информационна абстракция, нито със загуби, нито без загуби. DeepStack обучаваше своята мрежа за стойности върху *случайно генерирани* PBS, извлечени от ръчно настроен генератор; ReBeL генерира своите тренировъчни PBS изцяло от игра срещу себе си, твърдейки, че случайната извадка „би била като да се научи функция на стойността за Го чрез случайно поставяне на камъни върху дъската“ – и показва (фиг. 2 в статията), че мрежа за стойности, обучена върху случайни убеждения, „се проваля в научаването на нещо ценно“. Той се отказва и от предварително изчислените таблици със стойността при отиграване докрай, и от решаването *до края на играта* на третия рунд за залози, като винаги решава само до края на *настоящия* рунд. Резултатът е с двойно острие: ReBeL трябва да научи *шест* „слоя“ от стойности, където DeepStack се нуждаеше от три, което *увеличава* повърхността за разпространение на грешка. И не е без експертни познания: запазва ръчно избран списък с най-много осем или девет размера на залози, като залозите извън дървото се добавят към под-играта и тя се пререшава, както в Libratus и Pluribus.

Чистите теореми стъпват върху **идеализации**: сходимостта в Теорема 2 предполага съвършен апроксиматор на функции. Вариантът, който агентът реално използва за ефективност – модифициран **CFR-AVG** – според самите автори *не е доказано коректен* („дали тази модифицирана форма на CFR-AVG е теоретично коректна, остава отворен въпрос“)⁸⁸, въпреки че се представя добре в

покера – позната празнина между доказвания алгоритъм и внедрения. А гаранцията за безопасно търсене зависи от избора на *случайна* итерация на CFR, която може да се окаже много лоша в ранните етапи; това се смекчава единствено чрез използването на Linear CFR, който намалява тежестта на ранните итерации.

6.5.5 Изчислителни разходи и достъпност

Докато планът на Pluribus идваше от CFR само с процесори на един сървър за около \$150, интуицията на ReBeL е невронна мрежа, обучена в мащаба на **клъстер от графични процесори**: пълният агент за HUNL използва **около 90 възела DGX-1, всеки с осем GPU Nvidia V100 с 32 GB**, за генериране на данни чрез игра срещу себе си, докато самото търсене с CFR се изпълнява в една процесорна нишка, а играта отнема средно под две секунди на раздаване. **Реализацията му беше с отворен код** (за Liar's Dice), докато Libratus и Pluribus публикуваха само псевдокод,⁸⁸⁴⁸³ но покер агентът беше задържан, защото ReBeL „може да изчисли стратегия за произволни размери на стакове и произволни размери на залози за секунди“, което го прави готов инструмент за измама – отвореният артефакт е изследователската игра, а не свръхчовешкият покер бот.

6.5.6 Силни страни и ограничения

ReBeL подкрепя теорията си с резултати: побеждава предишните шампиони Slumbot (+45 mbb/g) и BabyTartanian8 (+9 mbb/g), побеждава с голяма разлика локалния най-добър отговор (LBR)⁸⁶ и побеждава Донг Ким със 165 mbb/g в 7 500 раздавания, без абстракция на картите. Същият алгоритъм, непроменен, клони към приблизително равновесие на Наш в Liar's Dice, а в игри с пълна информация се свежда до метод, подобен на AlphaZero – *рамка*, а не покер програма.

Ограниченията подготвят финалната система. Гаранциите на ReBeL важат **само за игри за двама с нулева сума**: единствената стойност на PBS, изпъкналостта, която позволява CFR да се използва като търсене, и доказателствата за коректност се основават на тази структура (формализмът е записан за N играчи, но всички експерименти и гаранции са за двама). Най-конкретната му стена на мащабиране е, че **пространството на убежденията нараства с количеството скрита информация**: входът на мрежата се мащабира с броя на информационните състояния в едно публично състояние, така че игри с голяма стратегическа дълбочина, но малко общо знание – статията посочва Reconnaissance Blind Chess – раздуват представянето, а добавянето на играчи само увеличава пространството на убежденията. Алгоритъмът предполага също, че **точните правила на играта са известни** (разширение в стил MuZero е посочено като бъдеща работа), наследява остатъчна **грешка на приближението на стойността δ** , а най-силният му емпиричен резултат се основава на **един човешки противник** в 7 500 раздавания.

6.5.7 Наследство и съвременна значимост

Трайната идея на ReBeL е свързана с представянето: **превърнете скритата информация в състояние на убежденията и цялата мощ на обучението с подкрепление чрез игра срещу себе**

си плюс търсене може да се пренесе. Най-близкият му наследник е Student of Games, чиито автори определят ReBeL като „най-близкия“ до своя алгоритъм⁸⁹; линията „обучение с подкрепление плюс търсене с научени модели“ води и до CICERO (2022)⁹⁶ – агент за Diplomacy със седем играчи, далеч извън гаранциите на ReBeL за двама играчи. Представянето чрез PBS, обучената чрез игра срещу себе си функция на стойността/стратегията върху състояния на убежденията, схемата „CFR като търсене с научен оценител на листата“, трикът за „безопасно търсене безплатно“ чрез произволни итерации и бързият търсач на равновесие FLOP остават използвани. За тази дисертация ReBeL действа в две посоки: PBS е отправната точка за Принос 1, който го разширява, така че да включва убежденията относно *типа стратегия* на противника, а не само неговите карти; а ReBeL е доказателството, че коректността, изоставена от Pluribus, *може* да бъде възстановена – макар все още не и при повече от двама играчи, което е точно границата, която Принос 2 се стреми да премине.

6.6 Student of Games / SoG (2023)

ReBeL възстанови коректността в покера като игра за двама с нулева сума, но остана метод с непълна информация, който просто *се свеждаше* до AlphaZero в игри с пълна информация, решаваше *фиксирана* под-игра с ограничена дълбочина и обвързваше търсенето си по време на игра с процедурата си за обучение. Student of Games (Schmid et al., 2023; Google DeepMind, с партньори от Университета на Алберта и EquiLibre Technologies в Прага) задава най-амбициозния въпрос в главата: **какво ще стане, ако един единствен алгоритъм, който се учи чрез игра срещу себе си, без човешки данни, може да играе шах, Го, покер един на един и Scotland Yard – разраствайки собственото си дърво за търсене според нуждите и оставайки доказуемо коректен както за игри с пълна, така и с непълна информация?** Неговият двигател е **минимизирането на контрафактичното съжаление с растящо дърво (Growing-Tree CFR, GT-CFR):** търсене, което може да бъде прекъснато във всеки момент (anytime) и изгражда дървото на играта постепенно, насочвано от мрежа за стратегия, с научена мрежа за стойности, оценяваща листата, които все още не са разширени. Върху поддървета с пълна информация GT-CFR се държи като MCTS на AlphaZero; върху тези с непълна информация – като CFR; и една единствена теорема за коректност покрива и двете. Системата достига **силно аматьорско до професионално ниво в шах и Го, побеждава Slumbot – най-силния публично достъпен бот за HUNL – и побеждава най-силния съществуващ агент за Scotland Yard**, като същевременно е **доказано, че клони към минимално оптимална игра с нарастването на изчислителния ресурс и точността на мрежата.** Той споделя няколко автори от DeepStack (Bowling, Moravčík, Burch, Schmid) и първоначално се появи през 2021 г. под името *Player of Games*.

⁹⁶Meta Fundamental AI Research Diplomacy Team (FAIR), Bakhtin, A., Brown, N., Dinan, E. et al. (2022). “Human-level play in the game of Diplomacy by combining language models with strategic reasoning.” *Science*, 378(6624), 1067–1074. doi:10.1126/science.ade9097.

Таблица 12: Student of Games (2023) накратко.

С един поглед	Student of Games (2023)
Играчи	2 (игра за двама с нулева сума) – гаранциите <i>и</i> оценката са за 2p0s (в Scotland Yard детективите действат като един отбор, т.е. като един играч); основната формализация е по-обща, но извън 2p0s гаранцията на равновесието на Наш е „по-малко смислена“
Тип игра	Както с пълна, така и с непълна информация – единствената унифицирана система: шах + Го (пълна) и HUNL покер + Scotland Yard (непълна)
План (офлайн)?	Не – офлайн продуктът е научена мрежа за стойности и стратегия, а не съхранена таблица на стратегиите (както в ReBeL)
Невронна компонента	Една-единствена контрафактична мрежа за стойности и стратегия (CVPN) : една мрежа извежда контрафактични <i>стойности</i> за всяко информационно състояние и априорна <i>стратегия</i> , за всички етапи на играта
Механизъм за търсене	GT-CFR – редува фаза на обновяване на съжалението в CFR (стойности на CVPN в листата) с фаза на разширяване по PUCT в стил AlphaZero, която <i>разраства</i> публичното дърво; работи вътре в непрекъснатото пререшаване, както по време на обучение , така и по време на игра
Абстракция?	Няма от вида на картите/информацията (CVPN я заменя); запазва само малко <i>рандомизирано</i> меню от залози (действия) в покера ($\approx 20\,000 \rightarrow 4\text{--}5$ действия), както ReBeL
Също и с пълна информация?	Да – отличителният ред; единствената система в главата, демонстрирана върху игри с пълна информация, със <i>същия</i> алгоритъм и коректност, покриваща и двата класа
Изчислителни разходи	Обучена на TPU, умишлено съпоставена с бюджета на AlphaZero (Google TPUv4; Го е най-скъпата); докладвано <i>относително</i> спрямо AlphaZero, без една единствена сума в долари; търсенето е $O(kT^2)$ ($O(T)$ за игри с пълна информация); пълният агент/код не беше публикуван
Ключова иновация	Growing-Tree CFR + коректна игра срещу себе си: един алгоритъм за игра срещу себе си с търсене, коректен и за двата класа игри , който разраства дървото си постепенно с CVPN в листата и доказуемо клони към равновесие на Наш


6.6.1 Пропускът, който запълни

От програмата за игра на дама на Самюъл през 50-те години насам двете големи традиции в изкуствения интелект за игри се развиваха поотделно.⁸⁹ Едната – минимакс, алфа–бета, търсене в

дърво на Монте Карло и в крайна сметка AlphaZero – завладя игрите с *пълна информация*, като комбинира търсенето с научена функция на стойността; другата – минимизиране на контрафактичното съжаление и покер системите в тази глава – завладя покера с непълна информация чрез игровитеоретично разсъждение. AlphaZero не можеше да играе покер, защото неговото търсене в дърво е *некоректно* при скрита информация по причината, която разделът за ReBeL изясни; покер системите не можеха да играят Го, тъй като бяха изградени около структурата на залаганията на една игра; а дори ReBeL имаше гаранции само за непълна информация. Отвореният въпрос, на който Student of Games отговаря, е дали *един* алгоритъм – една процедура за търсене, една архитектура на мрежата, един цикъл на игра срещу себе си – може да бъде **коректен и силен и в двата класа игри едновременно**. Трудността не е просто инженерна: търсенето при пълна информация цели да разшири най-добрата линия дълбоко и да прочете една-единствена стойност от всяко листо, докато търсенето при непълна информация трябва да поддържа *разпределение* върху действията (за да не изтича частна информация) и да разсъждава за *убеждение* относно скритите състояния във всяко листо. Student of Games запълва пропуска с търсене, GT-CFR, което разширява дърво по начина, по който го прави AlphaZero – насочено, асиметрично и с възможност за прекъсване във всеки момент – като същевременно изчислява игровитеоретично коректните величини, които изчислява CFR; то стъпва върху представянето чрез публични състояния на убежденията на ReBeL и се обучава чрез *коректна игра срещу себе си*.

6.6.2 Архитектура

Student of Games е, по своята структура, **цикълът на игра срещу себе си на AlphaZero, при който търсенето в дърво на Монте Карло е заменено от GT-CFR и при който мрежата за стойности и стратегия е дефинирана върху публични състояния на убежденията**, като същото търсене се изпълнява и офлайн, и онлайн (вж. фигурата по-долу).



Фигура 28: Student of Games: цикълът на търсене GT-CFR (вляво) и цикълът на коректна игра срещу себе си, който го захранва (вдясно), използват една и съща CVPN; долната лента назовава обединяването на игрите с пълна и с непълна информация.

Публичното състояние на убежденията $\beta = (s_{\text{pub}}, r)$ съчетава публичното състояние (в покера – историята на залаганията и общите карти) с **диапазон** r – двойка разпределения върху информационните състояния, в които всеки играч може да се намира, без другите да знаят.⁸⁹ Игрите с пълна информация са просто дегенеративният случай, при който всяко публично състояние има точно *едно* информационно състояние и убеждението е точкова маса, което е именно причината едно и също представяне да може да обслужва и двата класа. **Контрафактичната мрежа за стойности и стратегия (CVPN)** е *една-единствена* мрежа, която при подадено състояние на убежденията извежда както вектор от контрафактични стойности (по една за всяко информационно

състояние и всеки играч), така и априорна стратегия, за всеки етап от играта, докато DeepStack използваше отделни мрежи само за стойности, по една за всеки рунд. Офлайн процесите за генериране на данни (actors) генерират данни чрез игра срещу себе си с търсене GT-CFR при всяко решение, докато обучаващите процеси (trainers) обучават нова CVPN; онлайн агентът изпълнява същото търсене (чрез непрекъснато пререшаване), за да избере всеки ход. CFR⁺ (Глава 3) е вътрешният цикъл на търсенето, а приближението на стойността и стратегията (Глава 5) е CVPN; свързващата новост е GT-CFR, търсенето, което *разраства* своето дърво, и коректната игра срещу себе си, която поддържа всяко търсене съгласувано с всяко друго.⁸⁹

6.6.3 Ключова иновация: Growing-Tree CFR и коректна игра срещу себе си

Приносът на Student of Games е търсещ алгоритъм, който за игри с непълна информация прави това, което търсенето в дърво на Монте Карло направи за игри с пълна информация – интелигентно разраства дърво към линиите, които имат значение – без да жертва коректността, която изисква скритата информация.

Първата идея е **разрастване на дървото чрез редуване на две фази**. MCTS на AlphaZero разширява един възел при всяка симулация и никога не се връща назад, защото в игра с пълна информация стойността на даден възел, след като бъде изчислена, вече не се променя – бъдещето не влияе върху миналото. При непълна информация това не е вярно: както отбелязва Schmid, наблюдението на *бъдещо* действие на противника променя вашето *убеждение* за частното състояние, което той е държал в миналото, така че всяка промяна на стратегията в дървото се разпространява навсякъде и след всяко разширяване *цялото* дърво трябва да се пререши. Затова всяка итерация на GT-CFR изпълнява последователно две фази. **Фазата на обновяване на съжалението** извършва няколко итерации на Public-Tree CFR⁺ върху *текущото* дърво и в неговите гранични листа запитва CVPN за контрафактичните стойности на под-играта отдолу, точно както решаването с ограничена дълбочина използва научена стойност на хоризонта. **Фазата на разширяване** след това симулира една единствена траектория от корена, избирайки действия по правилото PUCT, което *смесва* априорната стратегия на мрежата с текущата стратегия на CFR, и добавя първото публично състояние, до което достига и което все още не е в дървото. Резултатът е търсене, което *може да бъде прекъснато във всеки момент* и което, подобно на MCTS, насочва изчисленията към релевантните линии, но за разлика от него на всяка стъпка търси игровитеоретично коректна стратегия.⁸⁹

Втората идея е **единственият параметър, който адаптира това едно търсене към двата класа игри**. Когато разширява, AlphaZero добавя само едното най-обещаващо действие, което е идеално, когато оптималната игра може да бъде детерминистична; оптималната игра с непълна информация обаче обикновено е *стохастична*, така че ангажирането само с едно действие е грешно. Затова GT-CFR разширява k -те действия с най-голяма априорна вероятност, като $k = 1$ за игри с пълна информация (търсенето тогава на практика е това на AlphaZero) и $k = \infty$ – всички деца – за игри с непълна информация, при които търсенето има дори гаранция за качеството на стратегията *при краен брой итерации*. Така същият код се свежда до търсене, подобно на MCTS, върху шахматна позиция и до итерация, подобна на CFR, върху покер решение.

Третият елемент е **коректната игра срещу себе си**, която обучава CVPN. Подобно на AlphaZero, агентът се обучава да предсказва резултата от собственото си търсене: всяко запитване към мрежата, направено по време на търсене, дефинира под-игра, тази под-игра се пререшава чрез *друго* GT-CFR търсене и мрежата се обучава към изхода от търсенето (стойностите – чрез функцията на загуба на Хюбер (Huber loss), стратегията – чрез кръстосана ентропия). Думата *коректно* е ключовата: всяко търсене, използвано за генериране на данни, трябва да бъде съгласувано с мрежата и с другите търсения по траекторията (то не трябва да сглобява фрагменти от две различни равновесия), което се осигурява чрез изпълнение на търсенията върху спомагателна игра за безопасно пререшаване.

Теорема 1 завършва семейството от граници на коректност в тази глава: съжалението на средната стратегия на GT-CFR след T итерации се разделя на член, който акумулира грешката ϵ на мрежата за стойности върху *границата* на дървото, и обикновен член на съжалението на CFR върху *вътрешността* на дървото; разделяйки на T , експлоатируемостта на средната стратегия е ограничена от

$$\text{експлоатируемост}(\bar{\pi}^T) \lesssim \underbrace{|\mathcal{F}| \epsilon}_{\text{грешка на мрежата (граница)}} + \underbrace{\frac{|\mathcal{N}| U \sqrt{A}}{\sqrt{T}}}_{\text{сходимост на CFR (вътрешност)}},$$

като $|\mathcal{F}|$ е размерът на границата, $|\mathcal{N}|$ – броят на информационните състояния във вътрешността, U най-голямата разлика в стойностите и A максималният брой действия. Формата е пряк структурен наследник на границите на DeepStack ($k_1 \epsilon + k_2 / \sqrt{T}$) и на ReBeL ($\delta C_1 + \delta C_2 / \sqrt{T}$), с две отлики: коефициентите са *размерите на растящата граница и вътрешност на дървото*, така че добавянето на възли с течение на времето не струва нищо по отношение на реда на сходимост; и, решаващо, **това същото твърдение важи както за дърво на игра с пълна информация, така и за публично дърво с непълна информация**. Теорема 2 добавя, че извикването на GT-CFR чрез непрекъснато пререшаване в рамките на цял епизод поддържа агента коректен, като експлоатируемостта нараства само *линейно* с дължината на играта (фактор приблизително $5D + 2$ за D стъпки на пререшаване) – свойството, което позволява на Student of Games да оцелее в хоризонта от двадесет и четири рунда на Scotland Yard. С подобряването на мрежата ($\epsilon \rightarrow 0$) и задълбочаването на търсенето ($T \rightarrow \infty$) играта клони към равновесие на Наш – както в покера, така и в шаха.

6.6.4 Уговорки, задънени улици и какво статията не описва

Основният текст формулира теоремите „само неформално“; архитектурите, хиперпараметрите, псевдокодът, изчислителните разходи и доказателствата са в Допълнителния текст. Основното ограничение е открито признато: **Student of Games е по-слаб от AlphaZero в шах и Го при еднакви ресурси**, а разликата не е малка в Го – най-силната му конфигурация спечели само *2 от 400* игри срещу напълно обучен AlphaZero с 8000 симулации на ход, макар че разгроми класическата програма Pachi с над 1100 точки Ело. Авторите наричат това „цената на общността на SoG“ и

я отдават на това, че CFR е по-малко ефективен от търсенето в дърво на Монте Карло при игри с пълна информация: унификацията е доказателство за *коректност и компетентност* в различните класове, а не за доминация в нито един от тях.

Две стени за мащабиране са реалните ограничения. Първата е **експлозията в пространството на убежденията**, която Schmid определя като основното ограничение: CVPN трябва да *изброи* *информационните състояния* за всяко публично състояние – управляемо за 1326-те възможни ръце в покера, но „непосилно скъпо в някои игри“⁸⁹. Това е същото ограничение на ReBeL, свързано с входа от PBS, наследено непроменено; статията предлага генеративен модел, който *генерира извадка* от състояния на света вместо да ги изброява, но не изгражда такъв. Втората е **изискването за известен модел**: подобно на AlphaZero и ReBeL, Student of Games се нуждае от точен симулатор на правилата, за разлика от MuZero, който *научава* своя модел. По-малки детайли: в покера остава **рандомизирана абстракция на залозите** (около двадесет хиляди действия, сведени до четири или пет), търсенето е **квадратично спрямо броя на итерациите** ($O(kT^2)$ извиквания на мрежата), а аргументът за сходимост на обучението е валиден само „асимптотично, когато $T \rightarrow \infty$ и при много голяма (експоненциална) памет“. Заедно те определят Student of Games като първо, умишлено общо доказателство за концепция, а не като настроен и мащабируем продукт.

6.6.5 Изчислителни разходи и достъпност

Обучението е игра срещу себе си в мащаба на TPU клъстери и е отчетено *спрямо AlphaZero*, а не в абсолютни стойности: базовата версия на AlphaZero използва 3500 паралелни процеса за генериране на данни (actors), всеки на един Google TPUV4, а Student of Games „е обучен с подобно количество TPU ресурси“⁸⁹ – няма една единствена сума в долари от рода на тази, с която Pluribus стана известен. Пълният агент и неговите обучени мрежи **не бяха публикувани**, макар че **OpenSpiel** на същата група предоставя семейството алгоритми CFR и еталонните игри: *отворен метод върху отворена основа със затворен флагман*.

6.6.6 Силни страни и ограничения

Широчината подкрепя теорията. В един-единствен дизайн Student of Games достига експертно до професионално ниво в **шах и Го**, **побеждава Slumbot** (с около +7 mbb/g, които тази статия записва като mbb/hand) и **побеждава PimBot**, най-силния съществуващ агент за Scotland Yard, дори когато на PimBot са дадени десет милиона симулации за търсене спрямо няколкостотин на Student of Games – без човешки данни, предварително изчислен план или абстракция на картите, като експлоатируемостта му намалява с нарастването на търсенето и обучението, което е емпиричното лице на Теорема 1. Ограниченията са точната форма на неговата амбиция: той е **по-слаб от специалистите** в техните собствени области; гаранциите му важат само за **игри за двама с нулева сума** (детективите в Scotland Yard са обединени в един отбор), така че празнината в *безопасността при много играчи*, разкрита от Pluribus, остава незасегната дори тук; неговото **представяне на убеждения не се мащабира** до огромни пространства от частни състояния; той **изисква известен модел**; и **флагманският код никога не беше публикуван**.

6.6.7 Наследство и съвременна значимост

Student of Games обединява трите сюжетни линии на главата едновременно: от ръчно изградена абстракция към научено приближение, от решаване офлайн към обучение и търсене и накрая **пълна и непълна информация в един алгоритъм**. Концептуалният извод е, че рецептата на AlphaZero (игра срещу себе си, научена мрежа за стойности и стратегия и дърво, разраствано чрез насочено търсене) никога не е била специфична за пълна информация; тя просто се нуждаеше от *коректно* търсене върху *убеждения*, а не върху състояния. Заменете търсенето в дърво на Монте Карло с GT-CFR, изпълнете го върху публични състояния на убежденията и същата рецепта обхваща шах и покер с една единствена гаранция за сходимост.⁸⁹ Непокритите му съседи очертават границата: **MuZero** научава модела, който Student of Games все още предполага, а **CICERO** пренася търсене плюс обучение в игра със седем играчи и смесени мотиви – Student of Games уеднаквява *информационната структура*, но не и *броя играчи*. GT-CFR, CVPN и коректната игра срещу себе си са използвани и сами по себе си.

За тази дисертация Student of Games е едновременно таван и пътепоказател. Неговото убеждение – разпределение върху възможните информационни състояния на противника – е точно субстратът, който **Принос 1** предлага да бъде *обогащен* с убеждения относно *типа* стратегия на противника, превръщайки убеждение, насочено към равновесие на Наш, в адаптивно. А внимателното ограничаване на всички гаранции до игри за двама с нулева сума – статията изрично посочва, че извън тях гаранцията на равновесието на Наш е „по-малко смислена“ – преформулира, от най-напредналата гледна точка в литературата, точния пропуск, към който е насочен **Принос 2**: уеднаквяването на *информационната структура* на игрите не затвори *празнината в безопасността при много агенти*, която Pluribus разкри първи.

6.7 Синтез

Синтезът обединява петте системи – не за да определи победител, а за да открие формата на еволюцията, общите механизми и нерешените проблеми, които тази глава предава на останалата част от дисертацията.


6.7.1 Развитието накратко

По трите оси от въведението всяка стъпка напред по една ос беше платена с нещо друго. DeepStack и Libratus атакуваха парадигмата „абстракция и план“ със загуби от противоположни посоки.⁸⁵⁸⁴ И двете системи останаха за двама играчи и нито една не съобщи резултат по основната метрика на другата (DeepStack не игра мачове срещу други ботове, а за Libratus не е публикуван резултат срещу LBR)⁸⁸, така че още в началото „по-добър“ вече беше многоизмерен. Pluribus придвижи оста *брой играчи* до шест, като се отказа напълно от безопасността и остана табличен; ReBeL се върна към двама играчи, за да *възстанови* гаранция за коректност, като стигна най-далеч по оста на представянето; а Student of Games добави третата ос, обединявайки игра с пълна и непълна информация, за сметка на пиковата сила. Областта замени *ръчно изградена широчина* с *научена*

общност и предварително изчисление с търсене в реално време, а нито една система не доминира по всички оси наведнъж. Таблицата представя какво е добавила всяка система и каква е била цената; стойностите по отделните измерения са в обобщаващата таблица на всеки раздел.

Таблица 13: Петте системи по ред: какво добавя всяка и от какво се отказва в замяна.

Система (година)	Какво добавя	Какво жертва / каква е цената
DeepStack (2017)	Първо <i>коректно</i> търсене с ограничена дълбочина при скрита информация; научени контрафактични стойности вместо съхранена стратегия; изоставя парадигмата „абстракция и план“ на цялата игра	Все още запазва разредена абстракция на залозите в рамките на своето предвиждане; никога не е тестван директно срещу предишни ботове; приблизително 175 CPU-години офлайн етикетирание на стойности
Libratus (2017/18)	Първа победа както срещу ботове, така и срещу хора, чрез вложено безопасно решаване на под-игри в реално време с доказуема граница; нощен модул за самоусъвършенстване, който запълва собствените пропуски на плана	Запазва и зависи от абстракция + петабайтов план; без невронно обобщаване; изчислителни разходи в мащаба на суперкомпютър (~25 милиона ядро-часа)
Pluribus (2019)	Първа свръхчовешка игра с много играчи (шестима); известна с ниската си цена (~150 долара на един сървър)	Отказва се от <i>всички</i> гаранции за безопасност (без граници за N играчи); разчита на <i>небезопасно</i> търсене; остава изцяло табличен и абстрахиран
ReBeL (2020)	„AlphaZero за непълна информация“: публични състояния на убежденията + научени стойности/стратегия + CFR в пространството на убежденията; <i>възстановява</i> гаранцията за 2p0s; елиминира абстракцията и плана; с отворен код за Liar's Dice	Гаранциите се връщат към двама играчи; експлозия в пространството на убежденията там, където общото знание е оскъдно; обучение върху GPU клъстер; изисква известен модел
Student of Games (2023)	Обединява пълна и непълна информация в един коректен алгоритъм (GT-CFR + една мрежа за стойности и стратегия + коректна игра срещу себе си)	По-слаб от специалистите (осезаемо при Го); гаранциите все още са 2p0s; експлозия в пространството на убежденията; изисква известен модел; основният код не е публикуван



Фигура 29: Седемгодишното развитие като поредица от компромиси: петте системи по три оси (абстракция → невронни мрежи; предварително изчисление → търсене в реално време; само непълна информация → обединение), със стрелки на наследяване и бележки за спечеленото и изгубеното.

6.7.2 Какво се пренася напред

Почти нищо в тези системи не е изцяло ново. **CFR и CFR⁺** (глава 3) са вътрешният решаващ на всяка система; **Монте Карло CFR** (глава 3) обучава планове на Libratus и Pluribus; **абстракцията на картите и на действията** (глава 4) е в основата на Libratus и Pluribus и оцелява само като остатъчно меню за залагания в ReBeL и Student of Games; а **невронното приближение на стойността – а след това на стойността и стратегията** (глава 5) е именно това, което позволява на DeepStack, ReBeL и Student of Games да премахнат абстракцията, от която зависят останалите. Върху тези главатата наслагва свои собствени примитиви, всеки въведен от една система и използван повторно от нейните наследници: **решаване с ограничена дълбочина, непрекъснато прере-**

шаване, безопасно вложено решаване на под-игри, публично състояние на убежденията и Growing-Tree CFR.

	DeepStack	Libratus	Pluribus	ReBeL	Student of Games	
CFR / CFR ⁺	●	●	●	●	●	наследено от глави 3-5
MCCFR	○	●	●	○	○	
Абстракция на картите / информацията	●	●	●	○	○	
Абстракция на действията	●	●	●	○	○	
Невронна мрежа за стойности	●	○	○	○	○	
Невронна мрежа за стойности и стратегия	○	○	○	●	●	
Решаване с ограничена дълбочина	★	○	●	●	●	въведено в тази глава
Непрекъснато пререшаване	★	○	○	○	●	
Намаляване на дисперсията (AIVAT)	★	○	●	●	●	
Безопасно (вложено) решаване на под-игри	○	★	○	●	●	
Публично състояние на убежденията	○	○	○	★	●	
GT-CFR	○	○	○	○	★	

★ = системата, въвела блока (само за примитивите от тази глава) ·
редовете за абстракция се изправят след Pluribus; невронните
редове се връщат (като стойности + стратегия) от ReBeL нататък

Фигура 30: Карта на повторно използваните компоненти: градивните елементи от глави 3–5 и примитивите, въведени в тази глава (редове), срещу петте системи (колони); звездите отбелязват системата, въвела съответния примитив.

6.7.3 Защо това е важно за нашето изследване

Всяка система, разгледана тук, е „сляпа“ за противника по замисъл: всяка изчислява стратегия, устойчива в най-лошия случай (приближение на равновесие), и не я адаптира към конкретния противник. Статията за Pluribus го казва изрично: системата „играе фиксирана стратегия, която не се адаптира към наблюдаваните тенденции на противниците“, не знае кои са противниците ѝ, а отклонението към експлоатираща стратегия се отхвърля, защото прави самата система уязвима за експлоатация.⁸³ Така пет системи от световна класа споделят точно един пропуск – нито една

не се адаптира към конкретния, погрешим противник пред себе си – и именно този пропуск е нишата, в която работи дисертацията.

За Принос 1 (Рамка за поведенческа адаптация). Най-прекият принос на главата е **публично-то състояние на убежденията (PBS)**, въведено от ReBeL и наследено от Student of Games, което Принос 1 разширява, за да носи убеждения относно *типа стратегия* на противника, а не само неговите карти. PBS е въведено, за да направи *търсенето доказуемо коректно*, а коректността е ортогонална на моделирането на противника – така че изграждането на адаптация върху PBS наследява механизма за пререшаване и неговите гаранции за сходимост *непроменени*, позволявайки на адаптивното убеждение да бъде актуализирано вътре в доказуемо коректно търсене, вместо да бъде добавено отвън. И всяка система в главата споделя **двустепенна архитектура** – евтина глобална стратегия (план или научена мрежа за стойности), усъвършенствана чрез локално решаване в реално време – която е собственият дизайн на дисертацията, „започнете от безопасна стратегия и се подобрявайте срещу слаби противници“, с цел на второто ниво, променена от *точност* към *ограничена експлоатация*.

За Принос 2 (Многоагентна безопасна експлоатация). Ключовият елемент е Pluribus: свръхчовешки покер за шестима играчи, постигнат *без каквато и да е гаранция за безопасност*. Позадълбочен прочит превръща собствената уговорка на системите в оправдание за приноса. Статията за Pluribus посочва, че при повече от двама играчи равновесията на Наш не са единствени, намирането им е изчислително трудно, а независимо избрани равновесни стратегии може да не образуват равновесие – т.е. равновесната игра не гарантира, че играчът няма да загуби;⁸³ Student of Games ограничава гаранциите си до игри за двама с нулева сума, защото извън тях гаранцията на равновесието е „по-малко смислена“.⁸⁹ Ако при много играчи равновесието изначално не осигурява безопасност, тогава отказът да се експлоатира видимо слаб противник означава отказ от гаранция, която никога не е била притежавана – което преформулира умишлената експлоатация от безразсъдно отклонение от безопасността в *рационална цел*, след като безопасността е недостижима само чрез равновесие.

За Принос 3 (Методология за оценяване). Главата стандартизира **експлоатируемостта** – най-лошата загуба спрямо най-добре реагиращ противник – прилагана еднакво към всичките пет системи, и тази однородност е шаблон за рамка за оценяване между системи. Два инструмента се пренасят, предназначени за нова употреба. **Локалният най-добър отговор (LBR)**, използван в цялата глава за *сертифициране* на неексплоатируемост, се превръща в *тест за безопасност*, когато бъде насочен към адаптивен агент – не става ли агентът контраексплоатируем, когато преследва слаб противник? – което е точно състезателната оценка от типа на „обучаващата атака“, за която настоява глава 8. А **AIVAT**, методът за намаляване на дисперсията чрез научени стойности зад докладваните резултати на DeepStack и Pluribus, прави малкото, но *растящо* предимство на адаптацията статистически видимо там, където суровите печалби биха подвели.

По-нататъшни опорни точки. Следващите бележки са кратки екстраполации, а не твърдения на самите системи.

- **Многократно използвана форма на доказателство (Принос 2).** Гаранциите в главата имат сходна форма – член за грешката на приближението на стойността и (без Libratus) член за сходимост от вида $1/\sqrt{T}$ (DeepStack: $k_1\epsilon + k_2/\sqrt{T}$; Libratus: 2Δ ; ReBeL: $\delta C_1 + \delta C_2/\sqrt{T}$; SoG: $|\mathcal{F}|\epsilon + |\mathcal{N}|U\sqrt{A}/\sqrt{T}$) – което дава на Принос 2 готов шаблон за ограничаване на експлоатируемостта, породена от умишлено отклонение.
- **Експлоатация с ограничена дълбочина (Принос 1/Принос 2).** Многозначните листа на Pluribus (k избираеми стратегии за продължение)⁸² структурно представляват меню от поведени на противника на хоризонта; ако това меню се тълкува като *типове* противници, се получава ефективно изчислима експлоатация отвъд дълбочината на търсенето – точно проблемът, с който се занимават Miles и др. (2025), цитирани в глава 8.
- **Абстракция, прехвърлена към типово пространство (Принос 3).** Урокът от глава 4, че абстракцията със загуби създава експлоатируеми шевове, се пренася от пространството на състоянията към пространството на *типовете* на противника: твърде грубият типов модел е експлоатируем по същия начин, както твърде грубата абстракция на картите, което предсказва вид провал, който Принос 3 трябва да може да улови.

6.7.4 Нерешени проблеми и връзка с глави 7–12

Четири нерешени проблема произтичат пряко от синтеза и всеки от тях е отправна точка за някоя от следващите глави. Първият е самата „**слепота**“ **за противника**: всички най-съвременни системи изчисляват фиксирана стратегия, оптимална в най-лошия случай, и я играят безусловно, оставяйки празнината между статично равновесие и динамичен, съобразен с противника начин на игра широко отворена – предмет на глава 7 (извеждане на поведението на противника от следи от действия) и частта от Принос 1, посветена на извеждането. Вторият е **безопасността при много играчи**: Pluribus показва, че методите, съчетаващи игра срещу себе си и търсене, *печелят* в игри с N играчи и непълна информация, макар да нямат известни теоретични гаранции извън игрите за двама с нулева сума⁸³, а Student of Games потвърди, че дори най-общата рамка за коректно търсене все още ограничава своите гаранции до двама играчи – така че ефективно изчислима теория на *безопасната експлоатация отвъд игрите за двама с нулева сума* (глава 8, Принос 2) остава нерешен проблем. Третият е **адаптация отвъд границата на дълбочината**: системите за решаване в реално време в главата гледат само малко напред и коректното пренасяне на модела на противника отвъд този хоризонт – вместо той да се изоставя в листата – е нерешен проблем; глава 8 само го очертава чрез работата на Miles и др. (2025). Четвъртият е **бюджетът за изчисления в реално време**: разходите на системите се различават с няколко порядъка и адаптивен агент, който трябва да пререшава и да преоценява противник онлайн, наследява най-строгата версия на това ограничение.

Тези проблеми са в основата на глави 7 и 8 – ядрото на дисертацията – и се пренасят в многоагентното обучение, популациите и образуването на коалиции (глави 9–11) и моделите на последователности и агентите с големи езикови модели (глава 12); междудомейнната рамка за оценяване остава за бъдеща работа. Петте системи са платформата, върху която стъпва дисертацията, и кон-

трапунктът, спрямо който тя се определя: тя наследява техните представяния на състояния на убежденията, тяхното търсене в реално време и тяхната дисциплина по отношение на експлоатируемостта и се стреми да добави една способност, която всички те по замисъл пропускат – способността да забележи, че противникът не играе оптимално и да предприеме действия по въпроса, без самата тя да стане експлоатируема в замяна.

7 Глава 7 – Моделиране на противника в игри с непълна информация

Това е цялостна глава за моделиране на противника: формулировката на проблема, математическият му апарат, семейството от методи и набор от контролирани експерименти върху Кун покер и Ледюк Холдем, чиито резултати, когато е възможно, са поставени в *точни* аналитични граници, а не в симулирани.

Къде се вписва това в дисертацията. Игровитеоретичният агент от предходните глави изчислява *равновесие на Наш*. Настоящата глава изгражда противоположната способност: **сензор**, който наблюдава как *конкретен* противник действително играе и превръща тези наблюдения в оценка на неговата стратегия, така че агентът да може да се отклони от равновесието с цел да накаже грешките на този противник. Този сензор представлява първата половина от рамката за поведенческа адаптация на дисертацията (Принос №1); втората половина – *безопасната* експлоатация – е предмет на Глава 8.

7.1 Защо е необходимо моделиране на противника


Равновесна стратегия на Наш е изградена така, че в дългосрочен план никога да не води до загуба, *независимо срещу кого се играе*. По същата причина тя играе **идентично** както срещу световен шампион, така и срещу някой, който се отказва всеки път при направен залог.

Моделирането на противника е актът на наблюдение на действията на конкретен противник, формиране на убеждение относно неговата стратегия и **отклонение от равновесието на Наш, за да се използва забелязаната закономерност** – повече блъфове срещу някой, който се отказва твърде често, и залози за стойност с по-слаби ръце срещу някой, който плаща твърде често.

Стойността се вижда най-ясно в примера с „камък-ножица-хартия“. Вашият противник тайно хвърля камък 70% от времето. Безопасната стратегия е да избирате трите хода с равни вероятности и така завинаги да излизате на нула. Но ако *забележите* пристрастието, хвърляте повече хартия и започвате да печелите. Този пример съдържа цялата глава в умален вид по две причини: пристрастието трябва да се **изведе** от шумен поток от хвърляния, а ако **заложите прекалено много** на хартията, ставате предвидими и противникът ви смазва с ножица. Извеждането на пристрастието е моделиране на противника; знанието докъде да се наклоните е компромисът между експлоатация и безопасност, който преминава през всичко по-долу.

БЕЗОПАСНОСТ

ЭКСПЛОАТАЦИЯ



тук действа моделирането на противника: стойност се извлича от обосновани преценки, а собствената експлоатируемост се ограничава

Глава 7 изгражда СЕНЗОРА (модела)

Глава 8 изгражда ИЗПЪЛНИТЕЛНИЯ МЕХАНИЗЪМ (безопасната експлоатация)

Фигура 31: Скалата безопасност–експлоатация: равновесната игра е неексплоатируема, но „сляпа“; чистият най-добър отговор извлича най-голяма стойност, но носи най-голям риск. Глава 7 изгражда сензора, а Глава 8 – изпълнителния механизъм.

7.1.1 Колко е заложено – измерено в Кун покер

Кун покер (раздел 2.8) е достатъчно малка игра, за да бъде решена *точно*. За всеки от няколко постоянни противникови стила изчислим **очакваната стойност при равновесие на Наш** (това, което равновесната стратегия носи срещу този противник, на раздаване), **стойността на най-добрия отговор** (точният таван за експлоатация) и **разликата** между тях – сумата, която равновесната игра оставя неизползвана.

Таблица 14: Потенциал за експлоатация в Кун: очаквана стойност при равновесие на Наш, при най-добър отговор и разликата между тях, по тип опонент.

Противник (Кун)	Очаквана стойност		Разлика
	при равновесие на Наш	Стойност на най-добрия отговор	
Пасивен играч (никога не се отказва)	+0,119	+0,333	0,215
Rock (ангажира се само с Поп)	-0,060	+0,167	0,227
Maniac (винаги залага/плаща)	+0,121	+0,333	0,213
„Наш“ (равновесна игра)	-0,055	-0,052	0,004

Срещу трите експлоатируеми стила разликата е огромна – **около 0,21–0,23 на раздаване** (от

0,11 до 0,28, ако се вземат предвид и двете позиции на масата), в игра, чиято цялостна равновесна стойност е около една двадесета от жетон. Срещу противник, който играе равновесие на Наш, разликата е по същество **нула**, точно както изисква теорията: не можете да експлоатирате равновесие, защото най-добрият отговор не може да надмине стойността на играта. (Малките отрицателни стойности при равновесие на Наш са известният недостатък на първия играч в Кун покер от $-1/18 \approx -0,056$; равновесието е приближение, получено с 20 000 итерации на CFR, затова може да падне с няколко хилядни под тази стойност.)

Два урока вече се открояват. Първо, **моделирането си струва**: стойността е значителна и реална. Второ, **експлоатацията зависи от вида на слабостта** – точният най-добър отговор на Rock *блъфира повече* (той залага най-слабата ръка в отворен пот, защото Rock се отказва от всичко освен Поп).⁹⁷

7.2 Байесовото ядро – убеждение, наблюдения и реакция

Под всеки метод в тази глава стои един цикъл. Представете си, че сте детектив. Започвате с предположение за начина, по който играе противникът (**априорно разпределение**). Всяко негово действие е следа: то прави някои обяснения по-вероятни, а други – по-малко вероятни. Вие включвате тази следа в подозренията си (**апостериорно разпределение**) и повтаряте процеса. Моделирането на противника *представява* именно този цикъл:


убеждение за стратегията → наблюдавано действие → обновяване на убеждението → най-добър отговор → повторение.

Формално, обновяването се извършва по правилото на Бейс. Ако σ обозначава кандидат-стратегия на противника и a е действието, което току-що беше наблюдавано,

$$P(\sigma | a) \propto P(\sigma) \cdot P(a | \sigma),$$

с думи: **апостериорното разпределение** $\propto$ **априорното разпределение** $\times$ **колко добре дадена стратегия обяснява току-що извършеното действие**. След множество раздавания убеждението се съсредоточава върху най-подходящото обяснение.

⁹⁷Southey, F. et al. (2005). “Bayes’ Bluff: Opponent Modelling in Poker.” *UAI*.



Фигура 32: Цикълът на моделиране на противника: априорното убеждение се умножава по правдоподобие на всяко наблюдавано действие и дава апостериорното разпределение, спрямо което се изчислява най-добрият отговор; резултатът от раздаването захранва следващото наблюдение.

7.2.1 „Зоопарк“ от типове

Най-простият начин да направим това конкретно е да разсъждаваме върху малък набор от предварително дефинирани противникови **типове**, всеки от които изпълнява двойна роля в цялата глава: като противник, срещу когото да играем, и като хипотеза, която детекторът обмисля:

Таблица 15: „Зоопаркът“ от типове опоненти: поведението на всеки постоянен стил.

Тип	Поведение
Пасивен играч	Никога не залага и никога не се отказва – пропуска хода без залог (чек), когато може, и плаща всеки залог.
Rock (стегнато-пасивен)	Вкарва жетони само с най-добрата ръка; с всичко останало се отказва. Най-експлоатируемият тип.
Maniac (разпуснато-агресивен)	Винаги залага или плаща, независимо от ръката си.
„Наш“	Балансирана равновесна игра; използва смесени стратегии; неексплоатируем.

7.2.2 Актуализацията, изчислена на ръка

Механиката е най-лесна за разбиране, когато сами завъртите механизма веднъж. Да предположим, че трима кандидати залагат определена ръка с вероятност 0,8, 0,5 и 0,1 съответно, като започват от равномерно априорно разпределение $(\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$. Наблюдават **зalog**:

$$\text{апостериорно} \propto (\frac{1}{3} \cdot 0,8, \frac{1}{3} \cdot 0,5, \frac{1}{3} \cdot 0,1) = (0,267, 0,167, 0,033) \xrightarrow{\text{нормализиране}} (0,571, 0,357, 0,071).$$

Наблюдаваме **втори** залог и отново умножаваме по $(0,8, 0,5, 0,1)$:

$$(0,711, 0,278, 0,011).$$

Убеждението се натрупва върху типа играчи, които правят чести залози, и би го направило *още по-бързо*, колкото повече кандидатите се разминават в мненията си. Тази интуиция „колко много се разминават“ се появява отново в раздел 7.6 като обяснение защо някои опоненти се идентифицират след четири раздавания, а други – след двеста.

7.2.3 Защо Дирихле и защо е нужна само средната стойност

Когато оценяват разпределение на действия чрез броене, естественото априорно разпределение е **разпределението на Дирихле**, защото то е *спрегнатото* априорно разпределение за мултиномиялното разпределение: наблюдаваните броеве просто се **добавят** към псевдоброевете на априорното разпределение, така че апостериорната средна стойност на действие i е

$$\mathbb{E}[p_i] = \frac{\alpha_i + n_i}{\sum_j (\alpha_j + n_j)},$$


където α_i са априорните псевдоброеве (които едновременно изпълняват ролята на *изглаждане*, като предотвратяват стойността нула за което и да е действие), а n_i са наблюдаваните броеве. Тази затворена форма съответства на „непрекъснатия“ модел, разгледан в раздел 7.4.

За да се избере оптималният отговор, не е нужно цялото апостериорно разпределение върху стратегиите; достатъчна е само неговата **средна стойност**: очакваната печалба срещу *разпределение* от стратегии на опонента е равна на печалбата срещу единствената осреднена стратегия. (Раздел 7.5 се връща към това: отговорът на средната стойност е оптимален по отношение на печалбата, но оценката може да не *клони* към истинската стратегия на опонента.)⁹⁸

⁹⁸Ganzfried, S. & Sun, Q. (2018). “Bayesian Opponent Exploitation in Imperfect-Information Games.” *IEEE Conference on Computational Intelligence and Games (CIG)*, DOI 10.1109/CIG.2018.8490452; препринт arXiv:1603.03491 (2016). (Теорема 2.1: печалбата срещу средната стойност на апостериорното разпределение е равна на печалбата срещу цялото разпределение.)

7.3 Виждане през ключалка – проблемът с частичната наблюдаемост

В покера наблюдавате **действия** – залог, плащане, отказ – но **не** и частната ръка, която ги е породила. Един и същ „залог“ може да произтича както от силна ръка, така и от блъф. Единственото изключение е **разкриването**, когато картите се показват в края на раздаването, ако то не е приключило с отказ. Разкриването дава **причина и следствие**: виждате както действията на противника, *така и* частната ръка зад тях – златният стандарт за наблюдение. Отказът дава **само следствие**: видяхте *какво* са направили, но не и *какво са държали*.




Фигура 33: Частична наблюдаемост: при разкриване действието се свързва с разкритата карта на противника; при отказ картата остава скрита и наблюдението се разпределя между всички карти, които той би могъл да държи.

Следствието е истинско теоретично ограничение, а не неудобство при имплементацията: **без да наблюдавате частната информация на противника, можете да научите колко често той избира всяко действие, но не и с кои карти го прави**. Много различни стратегии пораждат едни и същи честоти на действията и повече раздавания не могат да ги различат.

Как се справя моделът с отказ? Като разсъждава върху **всички карти, които противникът би могъл да държи**: преиграва решенията на противника при всяка хипотетична тайна карта и разпределя наблюдението между тях – като претегля всяка хипотеза според нейната правдоподобност. Този ход „маргинализиране върху скритата карта“ е техническото ядро на всеки модел в следващите два раздела и формалният обект, около който е изградена теорията на състоятелността от раздел 7.5.

7.4 Три модела с единен интерфейс

Няма един-единствен модел на противника. Има семейство, което прави компромис между скорост на сходимост, устойчивост към изненади, интерпретируемост и изчислителни разходи. Този проект имплементира три точки от този спектър зад **общ интерфейс** – всеки приема поток от наблюдавани раздавания и генерира прогнозирана стратегия на противника – така че *същият* последващ най-добър отговор да може да бъде приложен към всичките три.



Фигура 34: Три модела с общ интерфейс: убеждение върху типове, преброяване по ситуации и глобално съгласувана оценка в последователна форма; и трите постъпват в една и съща стъпка за най-добър отговор.

- **Типово базиран.** Байесово убеждение върху фиксирано меню от типове (раздел 7.2); най-бърз и интерпретируем („80% Rock, 20% Maniac“), **когато противникът е в менюто**, но без честен начин да го каже, ако противникът не прилича на нито един от типовете (раздел 7.6).
- **Непрекъснат.** Броеве във всяка ситуация, изгладени с априорно разпределение на Дирихле (раздел 7.2); може да представи **всяка** стратегия, но научава всяка ситуация независимо и затова се нуждае от много повече наблюдения – нужда, която, както показва раздел 7.7, се оказва сериозен проблем в по-голямата игра.
- **Състоятелен.** Една-единствена *глобално съгласувана* стратегия, валидна в цялото дърво на играта; най-строго обоснованият и най-новият модел (раздел 7.5).

Таблица 16: Трите модела на противника, сравнени по представяне, сходимост, устойчивост, интерпретируемост и цена.

Модел	Представява	Сближаване	Устойчив на непознати противници?	Интерпретируемост	Изчислителна цена
Типово базиран	няколко известни типа	най-бързо	не	висока (именувани типове)	евтина
Непрекъснат	всяка стратегия за конкретна ситуация	по-бавно (жаден за данни)	да	средна (за конкретна ситуация)	евтина
Състоятелен	една валидна глобална стратегия	доказуемо към истината	да	средна	скъпа (оптимизация)

Нито един модел не печели във всички случаи и това само по себе си е откритие. Естествената цел е хибриден подход: да се разчита на структурни априорни знания (типове), когато данните са оскъдни, и постепенно да се приближава към състоятелната оценка с натрупването на наблюдения.⁹⁹

7.5 Проблемът на състоятелността и решението в последователна форма

Този раздел е най-напредналата теоретична част на главата и е частта, която дисертацията най-пряко доразвива. Той поставя въпрос, който по-ранните модели подценяват: *ако даден модел добре описва наблюдаваното поведение, означава ли това непременно, че сме възстановили истинската стратегия на опонента?* Изненадващият отговор е **не** – дори при наличие на безкрайни данни – и съществува принципно решение.¹⁰⁰

7.5.1 Недостатъкът: напасването към средната стойност не е равносилно на откриването на истината

Класическата байесова рецепта отговаря на **средната стойност** на апостериорното разпределение на стратегията (раздел 7.2). Един метод за моделиране на противника ще наречем **състояте-**

⁹⁹Bard, N., Johanson, M., Burch, N. & Bowling, M. (2013). "Online Implicit Agent Modelling." AAMAS, 255–262 – ос „явни срещу неявни“, която рамкира тази таксономия.

¹⁰⁰Ganzfried, S. (2025). "Consistent Opponent Modeling in Imperfect-Information Games." *arXiv:2508.17671*.

лен, ако неговата оценка се сближава със същинската стратегия на опонента σ^* при натрупване на наблюдения срещу постоянен противник. Класическата рецепта не е такава.

Най-ясният контрапример е камък-ножица-хартия. Да предположим, че моделиращият разсъждава върху множество от *извадени* кандидатски стратегии и винаги реагира на някаква тяхна средна стойност. Ако истинската стратегия $\sigma^* = (0,8, 0,1, 0,1)$ лежи **извън** областта, до която тези извадки могат да се комбинират, моделът – тъй като винаги е претеглена средна стойност на извадките – просто **не може да я достигне**, независимо колко много данни постъпват. По-дълбокият резултат е, че методът може да се провали **дори когато истината лежи вътре** в достижимата област: ако истинската стратегия се намира в центъра на три извадки, чиято средна стойност съвпада с нея, апостериорното тегло на единствената най-добре пасваща извадка нараства неограничено спрямо останалите, така че асимптотично убеждението **колабира върху една извадка**, вместо да се установи на истинската смес.¹⁰⁰ Колкото по-плътно моделът напасва данните, толкова повече се сближава с *грешната* стратегия.



Фигура 35: Напасването към средната стойност може да пропусне истината: моделът поражда само точки в обвивката на своите извадки. Истина извън обвивката е недостижима, а такава вътре в нея бива изоставена, защото апостериорното разпределение се свива към един връх.

Това обезсилва интуитивната представа за „сигурност чрез натрупване на повече данни“. Състоятелността не е автоматична; тя трябва да бъде изградена.

7.5.2 Решението: задача на изпъкналата оптимизация в последователна форма

Ключовата промяна на променливите е **последователната форма**: вместо вероятности за действие във всяка ситуация, стратегията на опонента се представя чрез **реализационни тегла** y_r върху последователности от действия. Допустимите стратегии тогава са точно тези, които удовлетворяват набор от **линейни** ограничения $Fy = f, y \geq 0$ – полиномиални по размер на дървото на играта, вместо експоненциални.

Частичната наблюдаемост (раздел 7.3) се въвежда чрез **функция на наблюдаемост**: за всяко наблюдавано раздаване множеството от траектории, съгласувани с това, което действително е било видно. Поставянето на **априорно разпределение на Дирихле** върху теглата и максимизирането на **логаритъма на апостериорната вероятност** води до програмата

$$\max_y \sum_r (\alpha_r - 1) \log y_r + \sum_t \log \left(\sum_{r \in o(\ell_t)} q_r y_r \right) \quad \text{при } Fy = f, y \geq 0,$$

където $o(\ell_t)$ е множеството от съгласувани траектории за наблюдение t и q_r са (нормализирани) вероятности на случайността. Когато $\alpha_r \geq 1$, тази целева функция е **вдлъбната**, а ограниченията са афинни, така че това е **изпъкнала** задача без **локални оптимуми**; стандартен **градиентен метод с проекция** (стъпка на градиента, след която резултатът се проектира обратно върху множеството от ограничения) намира глобалния оптимум.

Този метод връща **модата** на апостериорното разпределение (неговата единствена най-вероятна точка), а не средната стойност. Това е ключовият компромис: модата е **състоятелна** – при стандартни условия (истинската стратегия лежи във вътрешността на множеството от допустими стратегии и има положителна априорна плътност, различни стратегии водят до различни наблюдения и всяка ситуация на противника се посещава безкрайно често) оценката доказано се сближава към σ^{*100} – докато оптималната по отношение на печалбата средна стойност по правило е изчислително непосилна за точно пресмятане. Следователно основната ос на дизайна, върху която стъпва целият процес, е **средна стойност срещу мода**: оптимална по отношение на печалбата, но изчислително непосилна, спрямо ефективно изчислима и състоятелна.

7.5.3 Практически заключения

Внедрих този състоятелен оценител и проверих работата му при възстановяване на стратегия в играта Кун, където той се представя според очакванията: възстановената стратегия е много близка до истинската (разстоянието по обща вариация е приблизително **0,004 до 0,021**), като съвпада или превъзхожда резултатите от възстановяването на непрекъснатия модел в същата игра.

Не го стартирах в рамките на онлайн цикъла на експлоатация, нито върху по-голямата игра. Оценката представлява решението на оптимизация, която се **пререшава с натрупването на наблюдения**, като цената ѝ нараства с историята – от части от секундата в началото до много секунди за всяко повторно решаване след изиграването на десетки хиляди раздавания. Приемам това като

емпиричен отговор на въпрос, който главата поставя изрично – *достатъчно бързо ли е решаването на изпъкналата задача при всяка актуализация за игра в реално време?* – а именно **не, без инкрементални методи** (всяко решаване да започва от предишното решение, а членовете за отделните раздавания да се кешират). Разбирането и резултатът от възстановяването са това, от което дисертацията се нуждае от този модел сега; онлайн инженерството остава за бъдеща работа.¹⁰⁰

7.6 Когато моделът е уверен, но греши

Раздел 7.5 беше за неочевиден провал при безкрайни данни. Този раздел разглежда груб провал при крайни данни и именно той най-пряко мотивира *безопасната* експлоатация: **неправилно зададено меню** – противник, който типово базираният модел просто не може да представи.

Изградихме скрит противник, който представлява 50/50 смес от действията на Rock и Maniac – съзнателно **ниито един** от четирите кандидата. Очаквано е апостериорното разпределение да раздели убеждението си между двата най-близки типа. Това обаче не се случва. Апостериорното разпределение, изчислено като произведение на вероятностите, се концентрира върху *единственото най-добро обяснение*, поради което убеждението прескача от един тип към друг и в крайна сметка твърдо се ангажира с типа „**Наш**“ – единственият кандидат, който приписва реална вероятност както на залог, така и на чек със средна ръка и по този начин никога не е категорично опроверган. В резултат моделът става **уверен** (апостериорното разпределение е близо до 1,0 върху един тип) и същевременно **грешен** (този тип не отговаря на действителния противник).

Това разкрива един капан, който си струва да бъде изказан ясно: апостериорното разпределение е **относителна** величина. „Деветдесет и пет процента хипотеза на Наш“ означава „най-добро приближение *сред тези четири кандидата*“, а не „добро приближение в абсолютен смисъл“. Измерването на *абсолютното* съответствие на победителя разкрива проблема – същата хипотеза на Наш, която се представя добре срещу противник, който наистина играе равновесие на Наш, се представя значително по-зле срещу тази смес, като същевременно отчита еднаква увереност на хартия.

7.6.1 Колко дълго може да остане грешен? Проверка на устойчивостта

Подложихме феномена на стрес-тест върху **300 изпълнения (с различни начални числа) от по 500 раздавания**, като разграничихме две неща, които една наивна метрика обединява: *бавна сходимост* и *отпадане след сходимостта*.

Таблица 17: Надеждност на детектора при 300 начални числа по 500 раздавания.

Измерване (300 начални числа × 500 раздавания)	Резултат
Правилен дългосрочен победител до раздаване 500	300 / 300 (100%)
Някога отстъпва, след като трайно поеме лидерството	0 / 300 (никога)
Грешен тип все още води след раздаване 100	40 / 300 (~13%)
Грешен тип все още води след раздаване 200	14 / 300 (~5%)
Раздаване, на което истината окончателно се установява	медиана 23 – 90-ти персентил 125 – най-лош случай 461

Добрата новина е, че убеждението в крайна сметка винаги се установява върху най-близката представима стратегия и след като се заключи, никога не отстъпва. Тревожната новина са средните редове: в немалка част от случаите моделът поддържаше **уверено грешно убеждение за повече от сто раздавания**. На модела може да се вярва в *крайна сметка*, но „в крайна сметка“ понякога е след 200 раздавания.

Честната поправка не е по-голямо меню, а да се опрем на модели, които могат да представят смеси (непрекъснатият и състоятелният модел от раздели 7.4–7.5), и да **мащабираме степента на експлоатация според това доколко е обоснована преценката за противника**. Този принцип е нишката, която води към Глава 8.

7.7 От модела до печалбата – най-добрият отговор, таванът и самонанесената уязвимост

За да измерим дали действията, основани на модела, носят печалба, подаваме оценката на всеки модел в **същия** точен най-добър отговор и играем пълни мачове и в двете игри, като поставяме всеки резултат между два аналитични критерия: **очакваната стойност при равновесие на Наш** (това, което безопасната равновесна игра носи срещу този опонент) и **тавана** (точната стойност на най-добрия отговор, максималното, което може да бъде извлечено при пълно познаване на опонента).


Кун – и двата модела достигат тавана (Rock: таван 0,167, типowo базиран 0,168, непрекъснат 0,168; Maniac: 0,333, 0,337, 0,330; „Наш“: –0,055, –0,055, –0,053).

Ледюк – започва да се проявява значението на класа на модела. Ледюк Холдем (раздел 3.4) е все още точно решима игра, но вече достатъчно голяма, за да различи моделите.

Таблица 18: Ледюк: таванът на експлоатация спрямо реално постигнатото от всеки модел.

Опонент	таван	типово базиран	непрекъснат
Ниво 1	3,056	3,061	2,672
Maniac	2,177	2,199	2,038
Пасивен играч	1,464	1,451	1,434
Rock	0,937	0,912	0,848
„Наш“	-0,083	-0,085	-0,175

(„Ниво 1“ е противник, който играе най-добър отговор срещу случаен играч; в Ледюк менюто на типово базирания модел съдържа девет типа, показани на следващата фигура.)



Фигура 36: Експлоатация в Ледюк: типово базираният модел следва плътно точния таван на най-добрия отговор, а непрекъснатият остава под тавана при най-трудните за нападение типове и под безопасната базова стойност срещу „Наш“.

Два резултата подчертават извода, като вторият е от съществено значение:

1. **Не можете да експлоатирате равновесие.** Срещу противника „Наш“ всеки модел реализира приблизително (отрицателната) стойност на играта и не повече. Това потвърждава, че наблюдаваната експлоатация другаде е реална, а не артефакт на средата за тестване.

2. **Уверен, но недообучен модел ви прави уязвими.** В Ледюк непрекъснатият модел *губи* срещу „Наш“ – $-0,175$ при таван от $-0,083$. С несъвършени данни за множеството ситуации в Ледюк той реагира най-добре на *грешна* оценка на противник, който изобщо не подлежи на експлоатация, и по този начин създава **уязвимост** в собствената си игра.

Когато класът на модела пасва на противника, най-добрият отговор извлича пълната теоретична стойност; когато не съвпада, агентът както оставя пари на масата и – по-опасно – връща част от тях обратно. Тази втора цена е именно това, което предпазният механизъм от Глава 8 (ограничаване на отклонението от равновесието на Наш според увереността на самия модел) съществува, за да предотврати.

Разликите тук не се дължат на начална случайност. При пет различни начални числа стандартната грешка на печалбата на раздаване е незначителна в сравнение с наблюдаваните ефекти: типово базираният модел остава в рамките на 3% от тавана за всеки тип и в двете игри (и в рамките на две стандартни грешки за почти всички типове), а недостигът на непрекъснати модел в Ледюк и неговата уязвимост срещу „Наш“ са многократно по-големи от стандартната грешка.¹⁰¹


7.8 Адаптиране към промяна – нестационарни опоненти

Досега всичко се основаваше на постоянен противник. Реалните опоненти обаче се променят и адаптират, а модел, който е учил търпеливо десет хиляди раздавания, става безполезен в момента, в който неговият обект промени стила си – той вече *уверено* описва играч, който вече не съществува.

Адаптивният агент изпълнява цикъла от раздел 7.2: **наблюдава** раздавания, **актуализира** модела, периодически преизгражда собствената си стратегия като най-добър отговор на текущата оценка и **действа**. За да се справи с промяната, той добавя лек статистически монитор върху агресията на опонента (байесово онлайн откриване на точки на промяна¹⁰²), който при задействане **нулира** модела и преминава към безопасна игра, докато отново се учи.

¹⁰¹Ganzfried, S. & Sandholm, T. (2015). “Safe Opponent Exploitation.” *ACM Transactions on Economics and Computation* 3(2), DOI 10.1145/2716322 – статията, която характеризира кога е възможен принципът „експлоатирай, но никога не губи спрямо базовата линия“; безопасната половина от скалата и основата за Глава 8.

¹⁰²Adams, R. P. & MacKay, D. J. C. (2007). “Bayesian Online Change-point Detection.” *arXiv:0710.3742*.



Фигура 37: Цикълът на адаптивна експлоатация: наблюдение, обновяване на модела, най-добър отговор (смесен с равновесието на Наш) и действие; детекторът на точки на промяна може да нулира модела, когато противникът смени стила си.

Сменихме стила на опонента в средата на мач от 20 000 раздавания и сравнихме **статичен** модел (който никога не забравя) с такъв, който прилага **забравяне на точка на промяна**. Резултатът е **сценарийно-зависим**:

Таблица 19: Статичен модел срещу забравяне при точка на промяна, след смяна на стила по средата на мача.

Игра	Смяна на стила (в средата)	статичен (след смяната)	точка на промяна (след смяната)
Кун	TightPassive → LooseAggressive	-0,106 ± 0,007	+0,211 ± 0,008
Ледюк	Rock → Maniac	+1,834 ± 0,054	+0,552 ± 0,017

- **В Кун забравянето печели.** Стратегията, научена срещу Rock, е блъф-ориентирана; пусната срещу Maniac, който плаща всеки залог, тя *активно губи*. Откриването на смяната и повторното обучение връщат стабилна печалба.
- **В Ледюк забравянето губи.** Там Maniac губи над два жетона на раздаване, така че непрекъснато адаптиращ се модел го експлоатира успешно и без нулиране – докато детекторът, твърде нетърпелив, задейства десетки **фалшиви аларми** по време на стабилните периоди (около шестдесет нулирания срещу една истинска промяна), всяко от които изхвърля трудно спечелени данни и преминава към безопасна игра.

Урокът е, че **реакцията при открита промяна има толкова голямо значение, колкото и самото откриване**. Детектор, който задейства твърде често, съчетан с пълно връщане в безопасен режим, може да струва повече от остарелия модел, когато новият опонент е толкова експлоатируем, че остарелият модел губи малко. По-меки реакции – частично забравяне вместо твърдо нулиране, по-малко чувствителен детектор – са ясна следваща стъпка и те се свързват пряко с експлоатацията, мащабирана според увереността, от Глава 8. (Стойностите са средни от пет начални числа $\pm$ стандартната грешка; посоката на ефекта е една и съща при всяко от тях.)

7.9 Връзки и бъдещи насоки

Какво установява тази глава. Добрият модел на противника е *необходим, но не и достатъчен* за печеливша и безопасна адаптация. Когато класът на модела съответства на противника, най-добрият отговор достига точния таван на извличимата стойност. Но при частична наблюдаемост и ограничени данни, недообученият модел както оставя пари на масата, така и срещу противник, който не може да бъде експлоатиран, реагира най-добре на химера и губи. Забравянето на остарял модел е полезно само когато остарялостта е активно вредна. Един принцип се повтаря през всичко това: **степената на експлоатация трябва да съответства на това доколко е обоснована преценката за противника.**

Напред към Глава 8 и дисертацията. Тази глава изгради **сензора**, а Глава 8 изгражда **изпълнителния механизъм** – механизма, който превръща модела в *безопасна* експлоатация, като ограничава отклонението от равновесието според това доколко е обоснована преценката за противника. Самонанесената уязвимост на непрекъснатия модел срещу „Наш“ (раздел 7.7) е емпиричният аргумент за този механизъм; проверката на увереното, но грешно убеждение (раздел 7.6) определя неговия бюджет; теорията на състоятелността (раздел 7.5) е принципният гръбнак, върху който рамката се разширява.¹⁰³

¹⁰³Shoham, Y. & Leyton-Brown, K. (2008). *Multiagent Systems: Algorithmic, Game-Theoretic, and Logical Foundations*. Гл. 3 (игри в нормална форма); гл. 4 (изчисляване на решения на игри в нормална форма, §4.1 – линейно програмиране за игри с нулева сума); гл. 5 (игри в разгърната форма; §5.2 – игри с непълна информация и последователната форма, механизмът под всяка линейна програма в Глава 8); гл. 7 “Learning and Teaching” – рамката за учене в повтарящи се игри, включително напрежението, че действията едновременно *експлоатират* и *обучават* опонента. Свободно достъпна: <http://www.masfoundations.org/download.html>

8 Глава 8 – Безопасна експлоатация в игри с непълна информация

Тази глава въвежда *безопасната* експлоатация на противника: формулировката на проблема, математическият апарат, семейството от методи и контролирани експерименти върху Кун покер и Ледюк Холдем. Всички числа са **измерени** при възпроизводими изпълнения и където е възможно, са поставени в *точни* аналитични граници. Когато резултатът противоречи на онова, което теорията ме е карала да очаквам, казвам го изрично и обяснявам разминаването.

Къде се вписва това в дисертацията. Глава 7 изгради **сензор**: модел, който оценява стратегията на конкретен противник. Глава 8 изгражда **изпълнителен механизъм**: механизма, който превръща модел в печалба, **без да става експлоатируем**. Той е втората половина на рамката за поведенческа адаптация (принос №1), а определянето *точно къде неговите гаранции зависят от предположението за игра с нулева сума за двама играчи* е отправната точка за многоагентното разширение (принос №2).

8.1 Защо безопасната експлоатация – другата половина на скалата

Стратегия в **равновесие на Наш** е изградена така, че никога да не губи в дългосрочен план: в игра с нулева сума за двама играчи тя има фиксирана *стойност* v^* и никой противник не може да ви свали под нея. Моделирането на противника (Глава 7) ви дава възможността да се *отклоните* от тази безопасна стратегия, за да накажете грешките на конкретен противник. Очевидният начин да реализирате печалба от модел е да играете **най-добър отговор** към него. Проблемът е, че най-добрият отговор обикновено сам по себе си е **силно експлоатируем**: за да накаже „винаги се отказваш при залог“, той напълно спира да блъфира с определени карти, а по-умен противник – или същият противник, след като спре да се преструва – минава право през отворения пробив.

Представете си **скала**. Докрай към *безопасност* е равновесието на Наш: непобедимо, но без да наказва слаб противник. Докрай към *експлоатация* е чист най-добър отговор на текущата ви преценка: максимална печалба, **ако** преценката е вярна, но сериозен риск, ако грешите, извадката ви е малка или противникът нарочно ви е подвел (показвал ви е слаб стил, за да ви примамва към голямо отклонение). **Безопасната експлоатация** поставя *ограничител* върху тази скала: можете да се наклоните към експлоатацията колкото желаете, но никога не бива да минавате отвъд точката, в която най-неблагоприятният противник може да ви свали под вашата безопасна базова линия.



Фигура 38: Скалата безопасност–експлоатация с ограничител: равновесието на Наш е неексплоатируемо, но „сляпо“, пълният най-добър отговор носи най-голям риск; безопасната експлоатация действа между тях, а методите се различават единствено по прага.

Това не е прекомерна предпазливост: пълният най-добър отговор на стегнатия стил Rock в Кун носи **+0,167 на раздаване**, но стойността му в най-лошия случай е **–0,5** – противник, който на свой ред играе най-добър отговор срещу него, може да му взема по половин жетон на раздаване, докато стойността в най-лошия случай при равновесие на Наш е самата стойност на играта. Безопасната експлоатация взема от този потенциал толкова, колкото позволяват грешките на противника, без да се поема рискът от –0,5.

Какво означава „безопасен“ в неформален план. Вашата *очаквана стойност за целия мач* никога не бива да пада под избран праг, **независимо какво прави противникът**. Целият въпрос на дизайна в тази глава е *какъв праг* да бъде избран и как да се извлече възможно най-много над него.¹⁰⁴

8.2 Експлоатацията като оптимизация с ограничения

Най-полезната идея в тази глава е, че **всеки метод за безопасна експлоатация е една и съща оптимизационна задача**, в която се сменя само една част:

максимизиране на очакваната стойност на собствения агент спрямо модела на противника **при ограничение**: стойността му в най-лошия случай да не пада под прага на безопасност.


¹⁰⁴Ganzfried, S. & Sandholm, T. (2015). “Safe Opponent Exploitation.” *ACM Transactions on Economics and Computation* 3(2), статия 8. DOI 10.1145/2716322 – статията, която показва, че в повтаряща се игра за двама с нулева сума отклонението от равновесието може да е безопасно точно когато противникът прави „подаръци“, и дава алгоритми, които рискуват само вече спечеленото; безопасната половина от скалата и основата за Глава 8.

За да се превърне това в *изчислима* задача, представете стратегията на агента в **последователната форма** от раздел 7.5: **планът за реализация** x присвоява тегло на всяка от последователностите от действия на агента, подчинени на линейните ограничения на **дървовидния политоп** (treeplex). Тогава срещу **фиксирана** стратегия на противника очакваната стойност на агента е **линейна** по x ,

$$EV(x) = \sum_{z \in Z} [\pi_c(z) \cdot \pi_{-h}(z) \cdot u_h(z)] x_{\text{seq}(z)} = c \cdot x,$$

където Z са крайните състояния, $\pi_c(z)$ е вероятността на случайните ходове, $\pi_{-h}(z)$ – вероятността на ходовете на противника, а $u_h(z)$ – печалбата на агента. Така „максимизиране на очакваната стойност спрямо модела“ е **линейна целева функция** $c \cdot x$ при линейни ограничения, а целият метод е **задача на линейното програмиране (LP)**. Пълният най-добър отговор е просто $\max_x c \cdot x$ върху дървовидния политоп – което ни позволява да проверим LP-задачата спрямо кода за точен най-добър отговор от Глава 7 (те съвпадат до 10^{-6}).

Прагът на безопасност – „за всеки противник σ' , $EV(x, \sigma') \geq \text{праг}$ “ – съдържа вътрешна задача за най-добър отговор (минимакс), поради което вместо една гигантска билинейна задача използваме **генериране на ограничения** (метод на двойния предсказвач / метод на отсичащите равнини): решаваме LP-задачата, извикваме **точния най-добър отговор като предсказвач за най-лошия случай** и ако стойността в най-лошия случай е под прага, добавяме единственото линейно отсичащо ограничение, което той поражда, и решаваме отново. Процедурата е крайна (съществува краен брой чисти най-добри отговори), прозрачна и лесна за отстраняване на грешки.



Фигура 39: Една LP-задача, пет прага: точният най-добър отговор служи като предсказвач за най-лошия случай и добавя отсичащи ограничения, докато прагът не бъде спазен; RNR, най-доброто равновесие, prime-safe, SES и адаптацията се различават единствено по прага.

Ползата е **пет метода, един двигател**: те се различават единствено по прага и всички се опират на *проверения* код за най-добър отговор от Глава 7.¹⁰⁵

8.3 Какво означава „безопасен“ – три определения с нарастваща степен на реализъм

„Безопасността“ звучи като абсолютна характеристика, но всъщност не е еднозначна. От значение са три различни определения, а изследователската линия по същество представлява *отслабване* на изискването, за да стане то приложимо в практиката.

(а) Безопасност по Ganzfried и Sandholm (2015): никога да не се печели по-малко от стойността на играта. Определението им се отнася до повтарящата се игра: средно поне v^* на раздаване, каквото и да прави противникът. Тук то се налага на стратегията за всяко отделно раздаване, с точно равновесие на Наш σ^* като базова линия:

¹⁰⁵Shoham, Y. & Leyton-Brown, K. (2008). *Multiagent Systems: Algorithmic, Game-Theoretic, and Logical Foundations*. Гл. 3 (игри в нормална форма); гл. 4 (изчисляване на решения на игри в нормална форма); §4.1 – линейно програмиране за игри с нулева сума; гл. 5 (игри в разгърната форма); §5.2 – игри с непълна информация и последователната форма, механизмът под всяка LP-задача в Глава 8); гл. 7 “Learning and Teaching” – рамката за учене в повтарящи се игри, включително напрежението, че действията едновременно *експлоатират* и *обучават* противника. Свободно достъпна: <http://www.masfoundations.org/download.html>

$$EV(x, \sigma') \geq v^* \quad \text{за всеки противник } \sigma'.$$

Това е най-силното и най-чистото понятие и се опира на **теоремата за минимакса**. На прага за всяко отделно раздаване обаче отговарят само равновесните стратегии, затова методът избира онази равновесна стратегия, която печели най-много срещу модела (вариантът „най-добро равновесие“ при Ganzfried и Sandholm; по-нататък методът се нарича **най-доброто равновесие**, в кода ganzfried). Уловката е в предпоставката: нужно е точно равновесие на Наш, а то е практически неизчислимо във всяка голяма игра.

Какво биха добавили пълните алгоритми. Техният алгоритъм RWYWE (Risk What You've Won in Expectation – „рисувай средно спечеленото дотук“) понижава прага при всяко раздаване до $v^* - k_t$, където k_t е средната стойност на натрупаните дотук *подаръци* (грешките на противника), а BEFFE играе най-доброто равновесие, докато натрупаните подаръци не покрият пълна експлоатация; и двата алгоритъма са доказуемо безопасни в повтарящата се игра; реализацията и изпитването им остават за бъдеща работа (RWYWE е естественият базов метод за двама играчи за Принос №2).

(б) Безопасност prime-safe (Jeary & Turrini 2023): корекция за несъвършена базова линия. Всяка реална базова линия е **ϵ -равновесие** (поради абстракция и ограничени изчислителни ресурси, Глава 4), така че самата тя е експлоатируема в известна степен ϵ . Методът prime-safe понижава прага точно с експлоатируемостта на самата базова линия,

$$\text{праг} = v^* - \epsilon, \quad \epsilon = \text{експлоатируемост(базова линия)} \geq 0,$$

т.е. „никога не печели по-малко от стойността в най-лошия случай на стратегията, която така или иначе щеше да играеш“. ϵ трябва да бъде **измерена**, а не приета наготово – точка, която експериментите приемат буквално.

(в) Безопасност на адаптацията (Ge и др. 2024): да не бъдеш по-експлоатируем от своя план (blueprint). Най-практичното понятие. Една експлоатираща стратегия е *безопасна за адаптация*, ако и само ако

$$\begin{aligned} \text{експлоатируемост}(x) &\leq \text{експлоатируемост(план)} \\ \Leftrightarrow \text{най-лош случай}(x) &\geq \text{най-лош случай(план)}. \end{aligned}$$

Това е по-слабо от абсолютния праг на Ganzfried и Sandholm (точно с ϵ) и следователно *постижимо* там, където строгата безопасност не е. Опасността му е огледален образ: ако планът е *ужасен*, почти всичко го удовлетворява, така че безопасността на адаптацията има смисъл само при разумна базова линия (отворено изискване, което отбелязвам, вместо да реша).

Таблица 20: Три понятия за безопасност: прагът, който всяко гарантира, какво изисква и къде е слабо.

Понятие за безопасност	Неформален праг	Изисква	Слабост
Ganzfried и Sandholm (2015)	$\geq v^*$	точно равновесие на Наш като базова линия	точното равновесие на Наш е практически неизчислимо в големи игри
Prime-safe (2023)	$\geq v^* - \varepsilon$	измерената експлоатируемост на базовата линия	трябва честно да измерите ε
Адаптация (2024)	$\leq$ експлоатируемостта на плана	произволен план	безсъдържателно, ако планът е лош

8.3.1 Къде се крие предположението за игра с нулева сума за двама играчи – точката, от която тръгва дисертацията

Всеки от горните прагове се основава на един факт: **в игра с нулева сума за двама играчи равновесната стратегия на Наш гарантира стойността v^* срещу всеки противник** ($\min_{\sigma'} EV(\sigma^*, \sigma') = v^*$). Именно това прави „отклонявай се към модела, но никога под прага“ последователно и приложимо ограничение, което произтича директно от теоремата за минимакса. В игра с $N > 2$ играчи това се срина: равновесната стратегия на Наш *не* гарантира фиксирана стойност срещу произволни противници (печалбата на отделния противник вече не е равна на вашата със знак минус – в игра с нулева сума това важи само за сумата от печалбите на всички противници, – затова противниците могат да действат координирано срещу вас, а различните равновесия ви носят различни печалби), така че няма единна v^* , към която да се закотви. Равновесията в игри с повече от двама играчи не са „нито единствени, нито неексплоатируеми“. ¹⁰⁶ Понятия за безопасност при N играчи съществуват, но са или много консервативни (максиминната стойност срещу координирана коалиция¹⁰⁷), или цел, която по принцип не може да бъде гарантирана (равният дял – справедливата част C/n – доказано не може да бъде осигурен срещу противници с различни фиксирани стратегии¹⁰⁶). **Това е отвореният проблем за Принос №2** – експлоатация на слаби противници в малки игри с N играчи при ограничена загуба спрямо базова линия, включително срещу противници, действащи в сговор. Тази глава не го решава; тя

¹⁰⁶Ge, J., Wang, Y., Li, W. & Jin, C. (2025). “Securing Equal Share: A Principled Approach for Learning Multiplayer Symmetric Games.” *ICML*; arXiv:2406.04201.

¹⁰⁷Celli, A. & Gatti, N. (2018). “Computational Results for Extensive-Form Adversarial Team Games.” *AAAI* 32(1). DOI 10.1609/aaai.v32i1.11462.

8.4 Линеино програмиране в последователна форма и генериране на ограничения

Реализацията (HeroTreeplex върху кода в последователна форма от Глава 7, решаващът HiGHS на SciPy и пълният цикъл на генериране на ограничения) е описана в доклада. Всяко генерирано ограничение представлява вектора на печалбата спрямо *конкретен* най-добър отговор на противника – валидна линеина долна граница на истинския най-лош случай, поради което добавянето на ограничения монотонно затяга релаксираното ограничение за безопасност. Между методите се мени само прагът: най-доброто равновесие използва v^* , prime-safe – $v^* - \varepsilon$, адаптацията – стойността в най-лошия случай на плана, а RNR – максимин по параметъра p (§ 8.5); методът на под-игра (§ 8.7) добавя *фиксирувани тегла*, които задържат играта на агента извън под-играта такава, каквато е в плана.

Една числова особеност решава безопасността. Стойността, която *приблизителното* равновесие на Наш постига срещу самото себе си, може да бъде съвсем малко **над** истинската максиминна стойност на играта, така че изискването за точно $wc \geq floor$ може да направи LP-задачата недопустима (без допустимо решение) и, при неблагоприятна поредица от отсичащи ограничения, да върне *небезопасна* стратегия. Малък резерв за допустимост в ограниченията ($floor - slack$, като $slack \approx 5 \cdot 10^{-4}$, независим от допустимата грешка при сходимост) запазва истинската максиминна стратегия допустима.¹¹¹

8.5 Ограничен отговор по Наш и скокообразното превключване

Един от най-ранните строго обосновани методи, **ограниченият отговор по Наш** (Johanson 2007; близък до ε -безопасните стратегии на McCracken и Bowling от 2004 г.), въвежда *настройваемия параметър*: да се изчисли равновесието на агента срещу p -**ограничен** противник – такъв, който е принуден да играе фиксирания модел с вероятност p и е свободен да играе противнически с вероятност $1 - p$. При изменение на p от 0 до 1 се проследява път от равновесието на Наш ($p = 0$) до пълния най-добър отговор ($p = 1$). Тъй като свободният компонент дава най-добър отговор на агента, RNR е **максимин**:

¹⁰⁸Johanson, M., Zinkevich, M. & Bowling, M. (2007). “Computing Robust Counter-Strategies.” *NIPS 2007*, 721–728 – ограниченият отговор по Наш (RNR), настройваемият предшественик на методите по-горе.

¹⁰⁹Jeary, L. & Turrini, P. (2023). “Safe Opponent Exploitation For Epsilon Equilibrium Strategies.” *arXiv:2307.12338*.

¹¹⁰Ge, Z., Xu, Z., Ding, T., Meng, L., An, B., Li, W. & Gao, Y. (2024). “Safe and Robust Subgame Exploitation in Imperfect Information Games.” *ICML, PMLR 235*, 15255–15270.

¹¹¹Идеята за генериране на ограничения / двоен предсказвач идва от McMahan, H. B., Gordon, G. J. & Blum, A. (2003). “Planning in the Presence of Cost Functions Controlled by an Adversary.” *ICML* – общата рецепта за „оптимизиране срещу най-лош случай, който се открива в хода на решаването“.

$$\text{RNR}(p) = \arg \max_x \left[p \cdot \text{EV}(x, \text{модел}) + (1 - p) \cdot \min_{\sigma'} \text{EV}(x, \sigma') \right],$$


който решаваме със същия метод на отсичащите равнини плюс допълнителна променлива за най-лошия случай.

Уговорка, която си струва да се запомни. В първоначалните бележки на проекта RNR беше описан като *наивно смесване*, $(1 - p) \cdot \text{Наш} + p \cdot \text{BR}$. Това **не е** алгоритъмът на Johanson; реализирахме и обозначихме *и двата*. Наивното смесване проследява плавна крива (сивата линия на следващата фигура): печалбата и експлоатируемостта се увеличават заедно – от равновесието на Наш до пълния най-добър отговор.

Измерената изненада – каноничният RNR превключва скокообразно. Предвидих гладка, монотонна граница, която доминира смесването навсякъде. Вместо това в Кун срещу Rock каноничният RNR връща **една и съща безопасна стратегия** за всички $p \in [0, 0,6]$ (EV $-0,044$, експлоатируемост ≈ 0) и след това **преминава направо към пълния най-добър отговор** при $p \approx 0,7$ (EV $+0,167$, експлоатируемост $0,444$), без междинни точки между изпробваните стойности на p (през $0,1$).

Таблица 21: Ограничен отговор по Наш по стойността на параметъра на смесване: каноничната форма срещу наивно смесване.

p	каноничен RNR –			наивно	
	каноничен RNR – EV	експлоатируемост	наивно смесване – EV	смесване – експлоатируемост	
0,0	-0,044	~0,000	-0,047	0,000	
0,3	-0,044	~0,000	+0,017	0,133	
0,6	-0,044	~0,000	+0,081	0,266	
0,7	+0,167	0,444	+0,103	0,311	
1,0	+0,167	0,444	+0,167	0,444	



Фигура 40: Границата между експлоатация и безопасност в Кун: каноничният RNR дава само безопасна група точки ($p \leq 0,6$) и група на пълния най-добър отговор ($p \geq 0,7$); сивата линия е доминираното наивно смесване; звездите са LP-методите в безопасния ъгъл.

Защо (проверих, преди да се доверя на обяснението). Целевата функция на RNR е **линейна** по x върху **политоп**, така че нейният оптимум е **върх** и сменя върховете само когато p премине през критично съотношение; политопът на стратегиите в Кун е малък – малко върхове – така че преходът е единичен скок. Гладката крива на Johanson е явление от *големи игри* (много върхове) или идва от варианта *със смещение към данните* (data-biased), който задава отделно p за всяко информационно множество. Наивното смесване е **доминирано в безопасния ъгъл** (при експлоатируемост ≈ 0 LP-методите достигат EV $-0,044$ спрямо $-0,047$ на смесването). Скокообразно обаче е само съответствието между p и стратегията, а не самата граница: смесването на двете RNR стратегии достига всяка точка от отсечката между двата ъгъла, защото очакваната стойност е линейна по смесването, а стойността в най-лошия случай е вдлъбната. Превключването става при $p \approx 0,68$, а евентуален междинен връх би бил оптимален само за p между 0,6 и 0,7 – стойности, които серията не е включвала. В Кун срещу Rock тази отсечка подобрява наивното смесване само с около 0,002, така че тук изборът *къде* да се отклониш почти не носи предимство; силно вдлъбнати граници Johanson и др. отчитат в голяма абстрахирана игра на Холдем. Малката игра показва друго: p не е плавна скала – прагът на превключване се *измества според това колко експлоатируем е против-*

8.6 Най-доброто равновесие в Кун – безопасно, но само малко по-печелившо (основният резултат)

Централният експеримент решава всеки метод срещу *точен* модел на всеки тип противник и го оценява по **печалба** (EV срещу този противник) и **безопасност** (стойност в най-лошия случай), като прагът на Наш е $v^* = -0,056$ (стойността на Кун за първия играч, $\approx -1/18$). Всички числа са точни (пълно дърво) и са от изпълнението в пълен мащаб (*scale*).


Таблица 22: Кун: очаквана стойност и стойност в най-лошия случай за всеки метод срещу всеки противник („най-добро равн.“ е базовият вариант „най-добро равновесие“ на Ganzfried и Sandholm, в кода ganzfried).

Противник	метрика	nash	full_br	rnr_0.5	най-добро равн.	prime_safe	adaptation
Rock (стегнато-пасивен)	EV	-0,047	+0,167	-0,044	-0,044	-0,040	-0,040
	най-лош случай	-0,056	-0,500	-0,056	-0,056	-0,063	-0,063
Maniac (разпуснато-агресивен)	EV	+0,118	+0,333	+0,278	+0,131	+0,151	+0,151
	най-лош случай	-0,056	-0,167	-0,111	-0,056	-0,063	-0,063
AlwaysBet	EV	+0,113	+0,333	+0,333	+0,115	+0,131	+0,131
	най-лош случай	-0,056	-0,167	-0,167	-0,056	-0,063	-0,063
AlwaysPass (най-експлоатируем)	EV	+0,146	+0,975	+0,975	+0,222	+0,266	+0,266
	най-лош случай	-0,056	-0,500	-0,333	-0,056	-0,063	-0,063
„Наш“ (контролен)	EV	-0,056	-0,055	-0,056	-0,056	-0,055	-0,055

¹¹²Johanson, M. & Bowling, M. (2009). “Data Biased Robust Counter Strategies.” *AISTATS*, PMLR 5, 264–271 – прави параметъра p зависим от това колко данни подкрепят всяка част от стратегията – и именно това изглажда границата на практика.

Противник	метрика	nash	full_br	rnр_0.5	най-добро равн.	prime_safe	adaptation
	най-лош случай	-0,056	-0,333	-0,056	-0,056	-0,063	-0,063

(ses_subgame не е показан: в Кун под-играта е цялата игра и методът съвпада с адаптацията.)



Фигура 41: Методите срещу Rock в Кун: в зелено е очакваната стойност, в червено – стойността в най-лошия случай, пунктирът е прагът на Наш. Само при пълния най-добър отговор тя пада до -0,5; всички строго обосновани методи остават близо до прага.

Три основни резултата обобщават тази глава.

1. **Пълният най-добър отговор е поучителният пример.** Той винаги печели най-много срещу фиксиран модел – до **+0,975** срещу AlwaysPass – но стойността му в най-лошия случай се срива до **-0,5**. Това е единственият метод, който е небезопасен срещу *всеки* противник (rnр_0.5 е небезопасен срещу три от петте), защото противникът винаги може да отговори с най-добър отговор на уязвимостта, която той създава.
2. **Най-доброто равновесие е безопасно и все пак печели – но съвсем малко.** Срещу *всеки* противник стойността му в най-лошия случай остава на прага на Наш (безопасно в рамките

на 10^{-3}) и печели повече от стратегията на Наш срещу всеки експлоатируем тип – най-ярко **+0,222 срещу +0,146 за Наш** срещу AlwaysPass и +0,131 срещу +0,118 при Maniac. *Може да се експлоатира, като доказуемо никога не се пада под равновесната стойност* – но само малко: срещу четирите експлоатируеми типа най-доброто равновесие печели с 0,002–0,076 на раздаване повече от Наш, т.е. 1–9 % от онова, което печели пълният най-добър отговор, защото прагът v^* за всяко отделно раздаване допуска само равновесни стратегии (§ 8.3).

3. **Един глобален p не е настройка за безопасност.** gnr_0.5 е безопасен срещу Rock, но вече е *скочил* до пълния най-добър отговор срещу силно експлоатируемите AlwaysPass / AlwaysBet (същата стойност като full_br , стойност в най-лошия случай $-0,33 / -0,17$ – небезопасен). Това е прагът на превключване от § 8.5, който се измества според експлоатируемостта на противника – и конкретната причина най-доброто равновесие, което ограничава *стойността*, а не параметър, да е по-добрата основа.

Prime-safe и адаптацията изразходват измерен ϵ -бюджет. При изпълнението експлоатируемостта на базовата линия (CFR, спрян преждевременно) е *измерена*: $\epsilon = 0,0074$; стойността им в най-лошия случай излиза $-0,063 = v^* - 0,008$ срещу всеки противник, което съответства на коригирания с ϵ праг, и те печелят малко повече от най-доброто равновесие (+0,266 спрямо +0,222 срещу AlwaysPass). Те изглеждат „небезопасни“ в таблицата само защото флагът ги сравнява с v^* ; спрямо *собствения* си праг те са безопасни по конструкция. Двата метода съвпадат, защото една и съща стратегия (CFR, спрян преждевременно) служи и като базова линия за prime-safe, и като план за адаптацията.¹⁰⁴


8.7 Безопасност в реално време – решаване на под-игри (SES)

Гаранцията на най-доброто равновесие е *глобална*: ограничението за безопасност се прилага върху **цялото** дърво на играта, а в реална игра не можете да го решавате наново всеки път, когато моделът се актуализира. Идеята за **търсене на безопасна експлоатация** (Liu и др. 2022) прави безопасността **локално** свойство на една единствена **под-игра**: играйте навсякъде плана (равновесието на Наш), но в избрана под-игра оптимизирайте отново играта на агента, за да експлоатира модела – с **приспособление**, което ограничава отгоре колко локалното отклонение може да увеличи експлоатируемостта (границата расте с нивото на експлоатация и с грешката на модела на противника). По-строгата гаранция, използвана тук – никога да не си по-експлоатируем от плана, – е безопасността на адаптацията на Ge и др., която техният метод OX-Search постига при повторното решаване на под-игри.

Реализацията налага тази гаранция директно върху дървовидния политоп: **фиксирайте** всяка последователност на агента *извън* под-играта на теглото, което тя има в плана, и задайте прага на безопасност равен на стойността в най-лошия случай на самия план. Тъй като „играйте плана и вътре в под-играта“ винаги е допустимо и достига точно този праг, локалната експлоатация е безопасна по конструкция. Единственото изискване е под-играта да бъде **затворена надолу** (вед-


нъж влезли в нея, оставате в нея), което важи за естествени избори като „втори рунд в Ледюк“ или „след като се падне поп“.

ГЛОБАЛНА безопасност
(най-добро равновесие / prime-safe / адаптация)



Ледюк: спрени при лимит 40 итерации,
БЕЗ сходимост; най-лош случай
от $-0,64$ до $-1,33$ (силно небезопасни)

ЛОКАЛНА безопасност
(SES: под-игра + приспособление)



Ледюк: сходимост за 194-350 итерации (лимит 400);
най-лош случай $\approx -0,13$ (почти безопасен);
от $+0,25$ до $+0,68$ срещу слабите типове

Фигура 42: Глобална срещу локална безопасност. Глобалните методи решават наново цялото дърво; методът с под-игра фиксира играта извън избраната под-игра според плана и решава наново само нея с приспособление – много по-малка задача.

§ 8.8 показва защо „локално“ е важно: в Ледюк решаването на под-игра достига сходимост в рамките на своя бюджет, а глобалното – не.¹¹³¹¹⁴¹¹⁵

8.8 В мащаб – Кун работи; Ледюк се разпада глобално, но се задържа локално

Ледюк Холдем (раздел 3.4) е все още точно решима игра, но достатъчно голяма, за да натовари методите. Изпълнението ограничи цикъла на генериране на ограничения до 40 итерации (допустимо отклонение 10^{-2} , под-игра „поп на масата“), като за всяка клетка е записано дали решаването

¹¹³Liu, M., Wu, C., Liu, Q., Jing, Y., Yang, J., Tang, P. & Zhang, C. (2022). “Safe Opponent-Exploitation Subgame Refinement.” *NeurIPS* – търсене на безопасна експлоатация (SES) с приспособление; добавената експлоатируемост е ограничена отгоре (теорема 4.1).

¹¹⁴Ge, Z. et al. (2024), *op. cit.* – OX-Search: повторно решаване на под-игри с приспособление, което гарантира, че експлоатируемостта не надвишава тази на плана (безопасност на адаптацията, теорема 4.3); може да се прилага вложено при всяко ново информационно множество и е насочено срещу противник, който първо „обучава“ модела, а после го експлоатира; изпитано в Ледюк и Flop Hold'em, за двама играчи.

¹¹⁵Milec, D., Kovařík, V. & Lisý, V. (2025). “Adapting Beyond the Depth Limit: Counter Strategies in Large Imperfect Information Games.” *AAMAS 2025* (разширено резюме), 2675–2677; arXiv:2501.10464 – използване на информация от модел на противника *отвъд* хоризонта на търсене.

е достигнало **сходимость**, или лимита. Стойност на играта $v^* = -0,086$.

Таблица 23: Ледюк: методът с под-игри срещу глобалните решаващи („ит.“ – итерации; „лимит“ – спрял при лимита от 40 итерации).

Противник	метрика	nash	full_br	ses_subgame	най-добро равн.	prime_safe / adaptation
Rock	EV	+0,201	+0,937	+0,247	+0,624	+0,635
	най-лош случай	-0,089	-1,633	-0,130	-0,838	-0,744
	сходим?	✓	✓	✓ (194 ит.)	✗ лимит	✗ лимит
Maniac	EV	+0,438	+2,177	+0,682	+1,806	+1,842
	най-лош случай	-0,089	-1,100	-0,130	-0,638	-0,657
	сходим?	✓	✓	✓ (211 ит.)	✗ лимит	✗ лимит
Пасивен играч (CallingStation)	EV	+0,559	+1,464	+0,663	+1,342	+1,363
	най-лош случай	-0,089	-1,000	-0,130	-0,915	-0,686
	сходим?	✓	✓	✓ (350 ит.)	✗ лимит	✗ лимит
Разпуснато- пасивен (LoosePassive)	EV	+0,449	+1,405	+0,559	+1,306	+1,309
	най-лош случай	-0,089	-4,200	-0,133	-1,239	-1,334
	сходим?	✓	✓	✗ (400 ит.)	✗ лимит	✗ лимит

Основната констатация е отрицателна и емпирична: при лимит от 40 итерации глобалното решаване не достига сходимость дори в Ледюк. Предвидих, че най-доброто равновесие ще бъде безопасно в Ледюк, както в Кун. Вместо това **глобалните** решаващи (най-доброто равновесие ganzfried, prime_safe, adaptation и rnr_0.5) всички достигнаха лимита, оставяйки стойности в най-лошия случай от **-0,64 до -1,33** – силно небезопасни. Причината, която потвърдих, вместо да предполагам: методът на отсичащите равнини добавя по едно отсичащо ограничение на итерация и в Ледюк множеството от релевантни чисти най-добри отговори е голямо, така че 40 отсичащи ограничения изобщо не фиксират истинския най-лош случай; главната LP-задача продължава да връща оптимистични, но небезопасни стратегии.

Положителната половина е методът на под-играта. SES достигна сходимость при трима от четиримата експлоатируеми противници (194–350 итерации), тъй като решава наново само малката под-игра „поп на масата“ – значително по-малка LP-задача с далеч по-малко множество от

отговори на противника. Той извлича реална стойност (+0,25 до +0,68 – повече от стратегията на Наш) при стойност в най-лошия случай $\approx -0,13$, което е с порядък по-близо до безопасността в сравнение с глобалните методи: разграничението *глобална срещу локална безопасност* от § 8.7 като измерим факт. Сравнението обаче не е при равни условия: глобалните решавачи са спрени след 40 итерации (около 2,5 s на клетка), а SES е имал лимит 400 и е използвал 194–400 итерации (30–79 s на клетка). Следователно глобалният цикъл е бавен и небезопасен *в рамките на този бюджет*, но не непременно при по-голям. Глава 14 решава въпроса за мащабирането: нейната еднократно решавана двойствена LP-задача, която заменя цикъла, решава задачата за пълния Ледюк за 0,02–0,04 s, така че препятствието е било в цикъла, а не в глобалната задача.


За SES обаче трябва да се отбележи: неговата остатъчна експлоатируемост ($\approx 0,043$) надвишава допустимото отклонение от 0,01, така че и той е маркиран като небезопасен, а при LoosePassive изпълни всичките 400 итерации, без да достигне сходимост. Но собственият праг на SES е стойността в най-лошия случай на плана – спряното преждевременно CFR ($-0,120$), а не равновесието на Наш ($-0,089$) – и трите клетки със сходимост са с 0,010 под този праг, т.е. точно на границата на допустимото отклонение. Следователно SES е спазил своя праг, а остатъкът се дължи главно на експлоатируемостта на самия план; дали методът е *доказуемо* безопасен, ще покаже повторно изпълнение с по-малко допустимо отклонение.

8.8.1 Обучаващата атака – и защо осъществената печалба е погрешен критерий

Последният експеримент е проверка при измама – изпитанието, което системата за безопасност трябва да издържи. Измамлив противник играе слабия стил Rock като примамка в продължение на 10 000 раздавания, след което „разкрива“ силната си игра и още 10 000 раздавания играе равновесие на Наш; на всеки 500 раздавания моделът от Глава 7 подава обновената си оценка на всеки решавач (5 начални числа).

Таблица 24: Обучаващата атака: реализирана печалба и нарушения на безопасността по метод.

метод	средно на раздаване (общо)	средно на раздаване (след смяната)	нарушения на безопасността / начално число
full_br	+0,051	-0,061	40, 40, 40, 40, 40
най-добро равн. (ganzfried)	-0,048	-0,055	0, 0, 0, 0, 0
adaptation	-0,046	-0,055	40, 40, 40, 40, 40
nash	-0,051	-0,061	0, 0, 0, 0, 0



Фигура 43: Обучаваща атака в Кун, натрупана печалба (начално число 0). Пълният най-добър отговор (синьо) се изкачва до около +1700 по време на примамката и завършва далеч напред; безопасните методи не се хващат на примамката и плащат „данъка“ на първия играч.

Наивният разказ – „обучаващата атака наказва алчния експлоататор“ – **не се потвърди по отношение на осъществената печалба**. Пълният най-добър отговор завършва със *значителна печалба* (+0,051 на раздаване общо): той реализира неочаквана печалба по време на примамката, а „разкриващият“ противник „Наш“ си връща едва малко повече от стойността на играта на раздаване, така че тази печалба не бива върната в рамките на 10 000 раздавания. Това, което *наистина* отличава безопасните от небезопасните методи, е **точната стойност в най-лошия случай / броят нарушения на безопасността**: пълният най-добър отговор наруши прага на Наш в **40 от 40** повторни настройки, а най-доброто равновесие – в **0 от 40**. Най-лошият случай за една стратегия се реализира от противник, който *играе най-добър отговор срещу нея* – а стационарният противник, който след „разкриването“ играе равновесие на Наш, просто не е такъв противник. Урокът при проектирането: **измервайте безопасността чрез най-лошия случай, а не чрез осъществената печалба срещу безобиден противник**; за да накажете алчния експлоататор *по отношение на печалбата*, разкриващият противник трябва да бъде адаптивен контраексплоататор, а не фиксирано равновесие на Наш. (40-те нарушения на адаптацията са по замисъл: тя умишлено се насочва към праг *под v^** , така че задейства брояча, който се отчита спрямо v^* .)

8.9 Връзки и бъдещи насоки

Какво установява тази глава. Безопасната експлоатация е една идея – *максимизиране на стойността спрямо модела при спазване на праг на безопасност*. В напълно решима игра най-доброто равновесие е безопасно срещу всеки противник и срещу всеки експлоатируем противник печели малко повече от стратегията на Наш, докато наивният най-добър отговор носи повече печалба, но е катастрофално експлоатируем; prime-safe и адаптацията разширяват гаранцията към несъвършени базови линии, като изразходват *измерен ϵ -бюджет*. Най-ценният резултат е отрицателен: в Ледюк глобалното решаване не достигна сходимост при лимит от 40 итерации, докато локалният метод на под-играта (с лимит 400) достигна, макар и при неравни бюджети.

Обратни връзки. Сензорът от Глава 7 дава *целевата функция* на тази глава, точният най-добър отговор от Глава 7 е *предсказвачът за най-лошия случай*, а последователната форма е *променливата*, която LP-задачата оптимизира. Прагът на безопасност е предназначен да предотврати именно самонанесената уязвимост на непрекъснатия модел срещу „Наш“ в Ледюк (Глава 7, § 7.7).

Напред към дисертацията. Липсата на сходимост в Ледюк е аргумент за два мащабируеми пътя: **точна двойнствена LP-задача, решавана еднократно**, за ограничението за най-лошия случай, или **локална безопасност на ниво под-игра** (SES, OX-Search) в реално време; Глава 14 избира първия (пълният Ледюк за 0,02–0,04 s). RWYWE (§ 8.3) – по-силният базов метод за двама играчи за Принос №2 – изисква само съществуващата LP-задача с праг, който се мени според натрупаните подаръци, а реализирането му остава за бъдеща работа. И в двата случая прагът на безопасност е това, което превръща крехкия сензор от Глава 7 в приложим адаптивен агент.

9 Глава 9 – Многоагентно обучение с подкрепление: координация, конкуренция и комуникация

Тази глава разглежда многоагентното обучение с подкрепление (MARL): проблемът, който го отличава, математиката, която го рамкира, методите, които се използват за решаването му, и контролирани експерименти в малки, точно решими игри. **Всички експериментални числа са измерени** при възпроизводими изпълнения и, където това е възможно, са поставени в *точни* граници (равновесия на Наш, точни стойности на най-добрия отговор), а не в граници, получени от други симулации. Когато дадено изпълнение противоречи на очакването ми, запазвам очакването и го съпоставям с получения резултат – тези разминавания са най-поучителните части.


Къде се вписва това в дисертацията. Глави 2–8 работят почти изцяло в рамките на **игри за двама с нулева сума** (Pluribus в Глава 6 е изключението, което се отказва от гаранциите): има стойност v^* , равновесната стратегия на Наш я осигурява срещу *всеки* противник и CFR доказуемо се сближава към нея. Глава 9 е повратната точка към **многоагентния** свят, където тези три удобства отслабват или изчезват. Тя предлага три връзки с дисертацията. **LOLA** (Foerster и др., 2018) – диференциране през *стъпката на обучение* на противника – може да се разглежда като *динамично* моделиране на противника, допълнение към статичната преценка за противника от Глава 7, насочено към противник, който се променя (Принос №1). **PSRO** – игра, която се играе върху *популация от стратегии* – е кандидат-рамка за безопасна експлоатация там, където няма теорема за минимакса (Принос №2), и обща многоагентна *методология за оценяване* (Принос №3). Липсващата минимаксна опора при $N > 2$, където се нарушава всяка гаранция за игри с двама играчи, е назована тук и оставена като отворен проблем, към който е насочена дисертацията.

9.1 Защо многоагентното обучение с подкрепление е различен проблем

Един агент (Глава 1) се учи в **непроменяща се** среда: стационарен MDP, чиято фиксирана оптимална стойност Q^* той може да достигне чрез сходимост. Глави 2–8 вместо това изчисляваха **равновесия** – стратегии, които са оптимални срещу *съвършено рационален* противник, който вече е завършил своите разсъждения.

Многоагентното обучение с подкрепление се намира между тези два подхода и е по-трудно и от двете. Няколко агента **се учат едновременно в споделена среда**, така че от гледната точка на всеки един агент „средата“ – която вече *включва и другите агенти* – **непрекъснато се изменя**, докато всички се обновяват. Това е **нестационарност**: ефективните преходи и награди на агент i зависят от стратегиите π_{-i} на другите агенти, които се променят при всяко обновяване, така че целта Q^* , която агентът преследва, самата тя е в движение. Това също така поражда два проблема, които просто не съществуват за агент, който действа сам: **координация** (как агентите, които си сътрудничат, се научават да действат заедно, без някой да им казва как?) и **разпределяне на заслугата** (когато отборът успее, чии действия са имали значение?).

Образ, който си струва да запомните: **учене на танц с партньор, който също се учи да танцува**. Ако стъпките на вашия партньор бяха фиксирани, бихте могли да научите наизуст последователност от стъпки, която им подхожда – това е едноагентното обучение с подкрепление. Ако вашият партньор беше безупречен професионалист, бихте могли да изучите известния му стил и да се подготвите с перфектен отговор – това е изчисляване на равновесие. Но когато *и двамата* се подобряват в реално време, всяка промяна, която правите, променя това, което другият трябва да направи, и обратното; вие си стъпвате един на друг по краката, прекоригирате и осцилирате – докато или не намерите общ ритъм (координирано равновесие), или не започнете да се въртите в кръг безкрайно (както в „съвпадение на монети“, Matching Pennies, раздел 9.4). Цялата област е изкуството да *подредите картите така, че синхронизацията да се случва надеждно*.¹¹⁶



Фигура 44: Нестационарността като двама партньори, които се учат да танцуват едновременно: всеки оптимизира спрямо текущата стратегия на другия, която също се променя. Всеки метод в тази глава задържа тази движеща се цел неподвижна достатъчно дълго, за да може агентът да се научи спрямо нея.

9.2 Марковски игри – мостът между глави 2–8 и MARL

Глави 2–8 разсъждаваха върху **игри в екстензивна форма (EFGs)**: дърво на играта, **информационни множества** и контрафактични стойности, подавани към CFR. Стандартната формализация

¹¹⁶Zhang, K., Yang, Z. & Başar, T. (2021). “Multi-Agent Reinforcement Learning: A Selective Overview of Theories and Algorithms.” *Handbook of RL and Control* – §1–2 за нестационарността и таксономията, използвана тук.

на MARL е **марковската (стохастична) игра** и изясняването на връзката не позволява преминаването да изглежда като започване отначало. **Марковската игра** е наредената n -торка

$$(\mathcal{S}, \{\mathcal{A}_i\}_{i=1}^N, P, \{R_i\}_{i=1}^N, \{\Omega_i\}, O, \gamma),$$

с множество състояния $s \in \mathcal{S}$, по едно множество действия $\mathcal{A}_i$ за всеки агент, закон за преход $P(s' \mid s, a_1, \dots, a_N)$, управляван от **съвместното** действие, наградите на отделните агенти $R_i(s, a_1, \dots, a_N)$ и (при частично наблюдавания случай) наблюдения $o_i = O_i(s)$. Всеки агент има стратегия $\pi_i(a_i \mid o_i)$; заедно те формират **съвместна стратегия** $\pi = (\pi_1, \dots, \pi_N)$. Специалните случаи са именно предишните глави:

- $N = 1$ възстановява обикновено **MDP** (Глава 1).
- $N = 2$ и едно състояние дава **матрична игра** (с нулева сума при $R_1 = -R_2$; тестовата среда на тази глава, раздел 9.4).
- Последователна игра с непълна информация и нулева сума дава **EFG** (глави 2–8): марковска игра, при която „**състоянието**“ е *история*, а **частичната наблюдаемост** се изразява чрез **информационно множество**.

Това, което преминава през моста, е *речникът*: поведенческата стратегия на EFG в информационно множество е точно стратегията в марковската игра $\pi_i(a_i \mid o_i)$, информационното множество се превръща в наблюдението o_i , а контрафактичната стойност на история става оценка на централизиран оценител в състояние. Това, което **не** преминава през моста, са *гаранциите*. Контрафактичното разлагане на CFR изисква дърво на играта с пълна памет, каквото общите марковски игри (с цикли и едновременни ходове) не предоставят, а при $N > 2$ играчи CFR губи гаранцията за сходимост към равновесие на Наш дори в дърво с пълна памет (Abou Risk и Szafron, 2010),¹¹⁷ така че MARL се връща към обучение чрез градиент/стойност, чиято сходимост не е гарантирана (оттук и цикличността в раздел 9.4). Най-съществено, изчезва **опората на минимаксната стойност**: в игра за двама с нулева сума равновесната стратегия на Наш гарантира v^* срещу всеки противник – фактът, на който се крепи безопасната експлоатация в Глава 8 – и за $N > 2$ няма такава единична стойност. Именно тази липсваща опора е празнината, която наследява Принос №2.¹¹⁸

9.3 Семейството от методи

Всеки метод тук представлява различно структурно решение на въпроса „другите агенти се учат, докато аз се уча“.¹¹⁹ MADDPG и MAPPO са двата варианта на централизирано обучение с децен-

¹¹⁷Abou Risk, N. & Szafron, D. (2010). “Using Counterfactual Regret Minimization to Create Competitive Multiplayer Poker Agents.” AAMAS, 159–166 – гаранцията за сходимост на CFR обхваща игрите за двама с нулева сума и пълна памет; при повече играчи тя се губи.

¹¹⁸Littman, M. L. (1994). “Markov Games as a Framework for Multi-Agent Reinforcement Learning.” ICML – статията, която въведе тази рамка и алгоритъма minimax-Q.

¹¹⁹Albrecht, S. V., Christianos, F. & Schäfer, L. (2024). *Multi-Agent Reinforcement Learning: Foundations and Modern Approaches* (MIT Press), гл. 5 и 9 – съвременно учебно изложение на тези предизвикателства и методи.

трализирано изпълнение (CTDE), изпитани тук; варианти с факторизиране на стойността като QMIX¹²⁰ не се използват.


Таблица 25: Семействата методи в MARL: какво прави всеки, кога да се използва и основната му слабост.

Подход	Какво прави	Кога да го използвате	Основна слабост
Независимо обучение (IL)	всеки агент използва собствен алгоритъм за едноагентно обучение и третира останалите като част от средата	бърза базова линия; почти стационарни среди	нестационарност → цикличност, провал на координацията
MADDPG (CTDE)	оценителят на всеки агент вижда наблюденията и действията на всички агенти по време на обучението; всеки актьор вижда само собственото си наблюдение при изпълнение	смесени кооперативно-конкурентни задачи; каноничният CTDE шаблон	входът на оценителя нараства с N ; актьорското обновяване е сложно за настройка
MAPPO (CTDE)	обикновен PPO с централизирана функция на стойността $V(s)$ на глобалното състояние и споделени параметри	кооперативен MARL, когато искате проста и надеждна базова линия	висока цена на данните при обучение по текущата стратегия (on-policy); „прост“, но чувствителен към настройката
PSRO	поддържа популация от стратегии; намира мета-Наш сместа върху нея; обучава най-добър отговор на тази смес; добавя го; цикълът се повтаря	конкурентни/общии игри; когато искате игровитеоретична цел на сходимост	пълен най-добър отговор във всеки кръг; приблизителният предсказвач отслабва гаранцията

¹²⁰Rashid, T., Samvelyan, M., Schroeder de Witt, C., Farquhar, G., Foerster, J. & Whiteson, S. (2018). “QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning.” *ICML*. arXiv:1803.11485.

Подход	Какво прави	Кога да го използвате	Основна слабост
LOLA	оптимизира, като приема, че противникът ще направи една стъпка на обучение ; диференцира през неговото обновяване	диференцируеми игри с двама играчи, в които наивното обучение се проваля (IPD)	предполага, че знаете и можете да диференцирате обновяването на противника
CommNet	агентите излъчват диференцируемо съобщение ; всеки получава средното от останалите и го подава на входа на своята стратегия	кооперативни задачи с частична наблюдаемост	усредняването губи информацията <i>кой</i> какво е казал

Две оси пресичат таблицата. **Какво е централизирано и кога?** Нищо при IL; оценителят само по време на обучение при CTDE; цялостното решаване на мета-играта между кръговете при PSRO; информацията по време на изпълнение при CommNet. **Статичен ли е противникът, или учещ се агент?** Всичко освен LOLA третира стратегията на противника като фиксирана, докато агентът ѝ отговаря; LOLA предвижда *следващото обновяване* на противника.



Фигура 45: Семейството методи по две оси: кооперативна или конкурентна целева среда и какво и кога се централизира. LOLA е изключението, което моделира противника като учещ се агент, а не като фиксирана стратегия.

9.4 Независимо обучение и начините, по които то се проваля

Най-ясният начин да се разбере *защо* останалата част от областта изобщо съществува, е чрез изпълнението на контролен експеримент, който води до провал. При независимото обучение всеки агент се поставя в собствен градиентен цикъл и се приема, че останалите агенти са част от средата. Върху четири канонични 2×2 матрични игри – всяка от които представлява различен качествен случай – това води до четири различни изхода.

Игрите и техните аналитични равновесия на Наш (обективна истина): **дилемата на затворника** (предателството строго доминира, така че единственото равновесие е взаимно предателство); **„съвпадение на монети“** (Matching Pennies; игра с нулева сума; единственото равновесие е напълно смесеното $(\frac{1}{2}, \frac{1}{2})$ със стойност 0); **лов на елен** (две чисти равновесия на Наш – доминиращото по печалба (Елен, Елен) и рисков доминиращото (Заек, Заек) – плюс едно смесено); **битка на половете** (две чисти равновесия на Наш, които не са съгласни кое да изберат, плюс едно смесено). Два независими градиентни агента с точни градиенти (чиста динамика без шум) дават следните

измерени резултати:

Таблица 26: Независими обучаващи се агенти в четири матрични игри, сравнени с аналитичното равновесие на Наш.

Игра	Измерен резултат	NashConv	Съвпада ли с аналитичното равновесие на Наш?
дилемата на затворника	$x \rightarrow [0,001, 0,999]$ (предателство)	0,0013	да – равновесието при доминиращи стратегии
лов на елен	всички начални числа $\rightarrow$ (Заек, Заек)	0,0013	да – <i>рисково доминиращото</i> чисто равновесие на Наш
битка на половете	всички начални числа $\rightarrow$ едно чисто равновесие на Наш	0,0013	да – чисто равновесие на Наш
„съвпадение на монети“	не се сближава (последната итерация се отклонява към границата)	от 1,4 до 1,8	не – никога не се установява

В три от четирите игри агентите се сближават с истинско равновесие на Наш, а интересните детайли са в „как“. В **лов на елен** агентите надеждно избират **рисково доминиращото** равновесие (Заек), въпреки че „Елен“ носи по-голяма печалба – едностранният ход към „Елен“ се наказва, така че градиентната динамика се плъзга към безопасния ъгъл. В **битка на половете** всяко начално число води до *едно и също* чисто равновесие: координацията е решена, но не по начин, разнообразен според началните числа. Това са проблемите с избора на равновесие и координацията, представени в конкретен вид.


Играта „съвпадение на монети“ е показателна: тя **никога не се сближава с равновесие**, което е именно същината на проблема.¹²¹

Съпоставка (запазена прогноза $\rightarrow$ какво всъщност се случи). Прогнозирах, че в „съвпадение на монети“ траекторията ще опише чиста орбита с приблизително постоянен радиус около $(\frac{1}{2}, \frac{1}{2})$. И двата вида обучаващи се агенти не успяха да **се сближат с равновесие** – но нито един не описа чиста орбита. Агентът с градиентен метод с проекция (IGA) от изследователските скриптове *спираловидно се отдалечава* (разстоянието


¹²¹Singh, S., Kearns, M. & Mansour, Y. (2000). “Nash Convergence of Gradient Dynamics in General-Sum Games.” *UAI* – анализ на това защо градиентното изкачване циклира, вместо да се сближи с равновесие, в игри като „съвпадение на монети“.

до равновесието на Наш нарасна през времевите прозорци от 0,30 до 0,48); агентът със softmax параметризация от имплементацията *се отклонява към ъглите* (последни профили като $x = [0,96, 0,04]$, $y = [0,03, 0,97]$, $\text{NashConv} \approx 1,8$). Затворената орбита е верният модел само за непрекъснатата динамика (Singh и др., 2000); при фиксирана стъпка 0,1 всяко обновяване излиза леко навън от кривата и траекторията се отдалечава по спирала към границата. **Изводът остава непроменен и дори е по-ясен:** при наивно едновременно учене *последната итерация* не се сближава с равновесие в игра само със смесено равновесие – това, което се сближава, е *средното по времето* (раздел 9.6).

Независими обучаващи се агенти в игри 2×2 (траектории в пространството на стратегиите)



Фигура 46: Независими обучаващи се агенти в четирите матрични игри: в дилемата на затворника те стигат до взаимно предателство, в „лов на елен“ и „битка на половете“ се установяват в чисто равновесие, а в „съвпадение на монети“ се отдалечават от смесеното равновесие на Наш.




Фигура 47: „Съвпадение на монети“: разстоянието до смесеното равновесие на Наш расте през последователните времеви прозорци (от 0,30 до 0,48), докато траекторията се отдалечава по спирала към границата; последната итерация никога не се сближава.

9.5 Централизирано обучение, децентрализирано изпълнение (CTDE)

Първата структурна корекция запазва изпълнението реалистично – всеки агент все още действа въз основа на собственото си наблюдение – като същевременно дава на *обучаващия се агент* привилегирован достъп до информация по време на обучение. В **MADDPG** (Lowe и др., 2017) актьорът $\pi_i(a_i \mid o_i)$ на всеки агент вижда само собственото си наблюдение, но централизираният оценител $Q_i(s, a_1, \dots, a_N)$ вижда глобалното състояние и действието на *всеки* агент. Оценителят за всеки агент, който наблюдава само o_i , се сблъсква с нестационарен, частично наблюдаван свят, така че неговата целева стойност е шумна; оценителят, който отчита цялата информация, вижда (почти)

детерминистична целева стойност и дава обучаващ сигнал със значително по-ниска дисперсия. **MAPPO** (Yu и др., 2022) е минималната версия – обикновен PPO с една централизирана функция на стойността $V(s)$ на глобалното състояние – и е силна базова линия, която често не отстъпва на по-сложни методи.



Фигура 48: CTDE: по време на обучението централизиран оценител вижда глобалното състояние и съвместното действие; по време на изпълнението всеки актьор действа само въз основа на собственото си наблюдение, без оценител и без съобщения.

Има ли централизираният оценител действително по-ниска дисперсия? Измерено в едностъпкова кооперативна „референциална“ задача (говорителят вижда целта, слушателят – не, а двамата трябва да я назоват), след обучение до сходимост:

Таблица 27: Централизиран срещу независим оценител: краен остатък на грешката на функцията на стойността.

Оценител	Краен остатък (грешка на функцията на стойността)
централизиран $Q(s, a_1, \dots, a_N)$	$3,2 \times 10^{-11}$
независим $Q_i(o_i)$	0,077

Централизираният оценител свежда остатъка си практически до нула – наградата е детерминистична функция на неговите входове – докато независимият оценител не може да види целта и

остава блокиран в прогнозирането на базовата честота. Следователно централизираният оценител напасва целевата си стойност много по-точно. Това само по себе си не означава по-ниска дисперсия на градиента на стратегията: при сходили оценители централизираният оценител може дори да я увеличи (Lyu и др., 2021).¹²² А по-точният оценител не е същото като решаването на координацията и именно тук една прогноза се провали.

Съпоставка (запазена прогноза → какво всъщност се случи). Прогнозирах, че в играта „изкачване“ на Claus и Boutilier¹²³ – кооперативна матрична игра без състояние, чийто оптимум (11) е фланкиран от -30 санкции за некоординация, с „безопасен“ атрактор при 5 – централизираният оценител ще избяга от капана и ще достигне оптимума, побеждавайки независимите обучаващи се агенти. Това не се случи. Измерени награди при алчна стратегия: **независими обучаващи се агенти 7, MADDPG 5, MAPPO 7** (оптимум 11, безопасна стойност 5). Нито един метод не достигна оптимума, а MADDPG всъщност *изостана* както спрямо IL, така и спрямо MAPPO. (Използваният вариант на MADDPG за дискретни действия заменя детерминистичния градиент на стратегията с контрафактична базова линия в стила на COMA (Foerster и др., 2018),¹²⁴ затова резултатът се отнася до този вариант, а не до MADDPG в оригиналния му вид, и обновяването на актьора му трябва да бъде проверено първо.) Честното тълкуване: по-точният оценител **не е достатъчен**, за да преодолее относителното свръхобобщаване¹²⁵ и трудното изследване, което санкциите от -30 налагат – агентите няма да опитат рискованото съвместно действие достатъчно дълго, за да открият 11. **CTDE осигурява по-добър оценител, но не и автоматична координация.**

Методологическа бележка, която си струва да се запомни: и двата ефекта на CTDE по-горе, както и ползата от комуникацията (раздел 9.7), бяха **невидими при бързата конфигурация за проверка (smoke)** и се проявиха едва след обучение в по-голямата конфигурация в пълен мащаб (scale). Бързата проверка показва, че кодът работи; за да се наблюдават явленията, е необходимо обучение до сходимост.¹²⁶


¹²²Lyu, X., Xiao, Y., Daley, B. & Amato, C. (2021). “Contrasting Centralized and Decentralized Critics in Multi-Agent Reinforcement Learning.” AAMAS, 844–852. arXiv:2102.04402 – при сходили оценители по текущата стратегия централизираният оценител дава на децентрализираните актьори обновявания с по-висока дисперсия. Версия в списание: Lyu, X., Baisero, A., Xiao, Y., Daley, B. & Amato, C. (2023). JAIR 77, 295–354. DOI 10.1613/jair.1.14386.

¹²³Claus, C. & Boutilier, C. (1998). “The Dynamics of Reinforcement Learning in Cooperative Multiagent Systems.” AAAI, 746–752.

¹²⁴Foerster, J., Farquhar, G., Afouras, T., Nardelli, N. & Whiteson, S. (2018). “Counterfactual Multi-Agent Policy Gradients.” AAAI 32(1). DOI 10.1609/aaai.v32i1.11794 (COMA).

¹²⁵Matignon, L., Laurent, G. J. & Le Fort-Piat, N. (2012). “Independent reinforcement learners in cooperative Markov games: a survey regarding coordination problems.” Knowledge Engineering Review 27(1), 1–31. DOI 10.1017/S0269888912000057.

¹²⁶Lowe, R. et al. (2017). “Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments.” NeurIPS (MADDPG); и Yu, C., Velu, A., Vinitsky, E., Gao, J., Wang, Y., Bayen, A. & Wu, Y. (2022). “The Surprising Effectiveness of PPO in Cooperative, Multi-Agent Games.” NeurIPS Datasets and Benchmarks Track. arXiv:2103.01955 (MAPPO).




Фигура 49: Резултати за кооперативното CTDE и за комуникацията (конфигурация в пълен мащаб): остатъкът на централизирания оценител е с порядъци по-малък; комуникацията издига слушателя далеч над $1/K$; в играта „изкачване“ нито един метод не достига оптимума (11), а MADDPG (5) изостава от IL и MAPPO (7).

9.6 PSRO – теория на игрите върху популация от стратегии

Втората структурна корекция е водещата нишка на главата и прекият наследник на **итерирания най-добър отговор** от Глава 2. **PSRO** (Policy-Space Response Oracles; Lanctot и др., 2017) разглежда цели стратегии като атомите на една по-висша игра. То поддържа **популация** от стратегии за всеки играч, изгражда емпиричната матрица на печалбите на **мета-играта** между популациите, решава **мета-Наш равновесие** върху нея, обучава **най-добър отговор** (предсказвач) на мета-Наш сместа на противника и добавя този отговор към популацията; цикълът се повтаря. То обединява играта срещу себе си, фиктивната игра и метода на **двойния предсказвач** в една рамка, а неговата метрика за прогрес е *експлоатируемост* – същата NashConv, използвана в Глави 2–8.

PSRO = итерираният най-добър отговор от Глава 2, пренесен от действия към цели стратегии.



Фигура 50: Цикълът на двойния предсказвач в PSRO: построява се мета-играта, намира се нейната мета-Наш смес и се добавя най-добър отговор на сместа на противника. Тук предсказвачът е точният най-добър отговор от Глава 7, затова сходимостта се измерва със същата мярка за експлоатируемост.

Имплементацията е точна, а не приблизителна: предсказвачът е **точният най-добър отговор** от Глава 7 за Кун и Ледюк, приложен към мета-Наш сместа на противника, сведена (съгласно теоремата на Кун¹²⁷) до една поведенческа стратегия.

Защо популация, а не просто последната стратегия от играта срещу себе си? Защото играта срещу себе си се сближава в *средното*, а не в последната итерация. Измерено върху **Кун** при игра срещу себе си по метода на фиктивната игра: експлоатируемостта на **средната** итерация спадна от 0,24 до 0,031 за 200 итерации, докато експлоатируемостта на **последната** итерация продължи да осцилира между 0,33 и 0,83. Мета-сместа на PSRO е популационната версия на осредняването, върху което се основават CFR и фиктивната игра.

Сходимост на PSRO, измерена (експлоатируемост = NashConv на мета-Наш сместа в цялата игра):

¹²⁷Kuhn, H. W. (1953). "Extensive Games and the Problem of Information." *Contributions to the Theory of Games II*, 193–216. DOI 10.1515/9781400881970-012.

Таблица 28: Траектория на експлоатируемостта при PSRO, по семейство игри.


Игра	Траектория на експлоатируемостта	Извод
Кун покер	$0,917 \rightarrow \sim 2 \times 10^{-16}$ до кръг 6	сближава се до машинна нула
матрична игра („съвпадение на монети“)	$2,0 \rightarrow 0$ до кръг 2	сближава се
камък-ножица-хартия (изследване)	$2,0 \rightarrow 0,017$; популация $\rightarrow \{R,P,S\}$, смес $\rightarrow$ равномерна	сближава се
Ледюк Холдем	$4,75 \rightarrow 2,16$ за 20 кръга	намалява, но е далеч над целта
Goofspiel ($K = 3$, бърза проверка)	$1,33 \rightarrow 0$	сближава се
Goofspiel ($K = 4$)	колебае се $1,24 \leftrightarrow 2,0$ (8 кръга)	не се установява

При малките игри популацията бързо обхваща необходимите стратегии и експлоатируемостта рязко спада. Два резултата не се развиха според очакванията.¹²⁸


Съпоставка 1 (Ледюк). Прогнозирах, че PSRO ще намали експлоатируемостта на Ледюк под 0,5 в рамките на 20 итерации. Измерено, тя спадна от 4,75 до 2,16 – след силни колебания през първите осем кръга (до 6,83) следва ясно намаление, но стойността остава далеч от 0,5. Това е **истинска бавна сходимост**, а не грешка: игровото дърво на Ледюк е много по-голямо от това на Кун и популация от 20 *чисти* най-добри отговора е твърде малка, за да приближи добре неговото смесено равновесие на Наш. Изводът – експлоатируемостта намалява с нарастването на популацията – остава валиден; *скоростта* е стената на мащабиране и тя се вписва в откритието от Глава 8 за глобално спрямо локално мащабиране.

Съпоставка 2 (Goofspiel $K = 4$). Прогнозирах ненарастваща експлоатируемост. При $K = 3$ (бърза проверка) тя се сближи до 0 напълно; при $K = 4$ тя осцилира между $\sim 1,2$ и $2,0$ и не се установява. Това е единственият резултат, който все още не мога да обясня, и съгласно работния процес аз го **документирам, а не го коригирам**. Подозрения: драйверът на PSRO за Goofspiel никога не премахва дублиращите се стратегии за най-добър отговор, а популация от чисти стратегии вероятно е твърде слаба за смесения мета-Наш на по-голямата игра. Маркирано като отворен елемент в кода, а не като валидиран резултат.

¹²⁸Lanctot, M. et al. (2017). “A Unified Game-Theoretic Approach to Multiagent Reinforcement Learning.” *NeurIPS* (PSRO).
Свързани: McMahan, H. B., Gordon, G. & Blum, A. (2003). “Planning in the Presence of Cost Functions Controlled by an Adversary.” *ICML* (методът на двойния предсказвач, който PSRO обобщава); Tuyls, K. et al. (2020). “Bounds and dynamics for empirical game theoretic analysis.” *Autonomous Agents and Multi-Agent Systems* 34(1), art. 7. DOI 10.1007/s10458-019-09432-y (EGTA).



Фигура 51: Експлоатируемост при PSRO спрямо размера на популацията (конфигурация в пълен мащаб): при Кун и при матричната игра спада почти до нула; при Ледюк се колебае, след което намалява, но остава далеч над 0,5; при Goofspiel с $K = 4$ се колебае (отбелязана аномалия).



Фигура 52: Игра срещу себе си в Кун: експлоатируемостта на средната стратегия спада към нула, докато последната итерация продължава да се колебае; затова играта срещу себе си и PSRO разчитат на осредняване.

9.7 Научена комуникация (CommNet)

CTDE централизира информацията по време на *обучение*; комуникацията я централизира по време на *изпълнение* чрез канал, който агентите **научават**. В **CommNet** (Sukhbaatar и др., 2016) всеки агент кодира своето наблюдение, излъчва **съобщение** и получава **средната стойност** на съобщенията на останалите като допълнителен вход за своята стратегия. При обучение от край до край протоколът възниква: в референциалната задача говорителят (който единствен вижда целта) трябва да се научи да я кодира, а слушателят – да я декодира.

Тестът е показателен, тъй като без канал слушателят е ограничен единствено до чисто отгатване, $1/K$. Измерено (конфигурация в пълен мащаб, $K = 5$, при което таванът при случайно отгатване е 0,2):

Таблица 29: Научена комуникация: отборна награда при включен и изключен канал.

Канал	Отборна награда (алчна стратегия)
с комуникация	0,795
без комуникация	0,204

С канала слушателят се издига далеч над тавана от $1/K$; без него той остава точно на тавана. Комуникацията върши реална работа – и бележката от раздел 9.5 важи и тук: при конфигурацията за бърза проверка и двете числа бяха 0,24, а ползата се появи едва в пълен мащаб.¹²⁹

9.8 LOLA – моделиране на противника като учещ се агент

Всеки метод досега разглежда стратегията на противника като фиксирана, докато агентът реагира. **LOLA** (обучение с осъзнаване за ученето на противника; Foerster и др., 2018) е изключението и е този, който е най-пряко свързан с дисертацията. Всеки агент се оптимизира спрямо стратегията, която противникът ще има *след една стъпка на обучение*, като диференцира *през* тази стъпка. Допълнителният член представлява смесена втора производна – как актуализацията на стратегията на противника зависи от *моите* параметри – и именно той превръща егоистичните агенти в кооперативни.

Класическата демонстрация е **повтарящата се дилема на затворника** с памет 1 (пет вероятности за сътрудничество на агент; затворена форма на дисконтираната възвръщаемост). Наивните градиентни агенти, всеки от които максимизира собствената си възвръщаемост спрямо текущата стратегия на другия, стигат до взаимно предателство, докато агентите с **LOLA**, всеки от които отчита предстоящото обновяване на другия, достигат взаимно сътрудничество. Измерено (дисконтирана възвръщаемост на стъпка; пълно сътрудничество ≈ 3 , взаимно предателство ≈ 1):

Таблица 30: LOLA срещу наивни обучаващи се агенти в повтарящата се дилема на затворника.


Обучаващи се	Възвръщаемост
наивни срещу наивни	1,04
LOLA срещу LOLA	2,82

Сътрудничеството възниква там, където наивното обучение води до предателство (моята прогноза за ≈ 3 беше малко завишена; 2,82 е близо до пълно сътрудничество). Вградена проверка за ко-

¹²⁹Sukhbaatar, S., Szlam, A. & Fergus, R. (2016). “Learning Multiagent Communication with Backpropagation.” *NeurIPS* (CommNet).

ректност потвърждава механизма: при скорост на обучение при предвиждане, зададена на нула, градиентът на LOLA се редуцира точно до наивния градиент, така че сътрудничеството произтича именно от члена за предвиждане от втори ред.

Концептуално това представлява **динамично** моделиране на противника: Глава 7 извежда *текущата* стратегия на противника; LOLA предвижда неговата *траектория на обучение*. Съчетаването на двете – статична преценка, която задава началото на динамичното предвиждане – е кандидат за Принос №1, а не нещо вече решено.¹³⁰



Фигура 53: LOLA срещу наивни обучаващи се агенти в повтарящата се дилема на затворника: при наивните агенти възвръщаемостта спада към взаимно предателство (~ 1), а при LOLA нараства към взаимно сътрудничество ($\sim 2,8$).

9.9 Честни бележки, ограничения и връзка със следващите глави

Какво не се разви според прогнозата. (1) В „съвпадение на монети“ при фиксирана стъпка траекторията се отдалечава по спирала към границата, вместо да обикаля. (2) PSRO при Ледюк спира при $\sim 2,16$ след 20 кръга, а не $< 0,5$ – стената на мащабиране на популацията с чисти стратегии. (3) Goofspiel $K = 4$ се колебае – необяснена аномалия в кода, документирана, но не поправена. (4)

¹³⁰Foerster, J., Chen, R. Y., Al-Shedivat, M., Whiteson, S., Abbeel, P. & Mordatch, I. (2018). “Learning with Opponent-Learning Awareness.” AAMAS, 122–130. arXiv:1709.04326 (LOLA).

При играта „изкачване“ нито един метод не достигна оптимума и MADDPG изостана от IL. Двата елемента на кода (Goofspiel $K = 4$; контрафактична базова линия на MADDPG) трябва да бъдат разгледани, преди тези части да бъдат използвани отново, а твърденията за невронните мрежи почиват на числата в пълен мащаб, а не на тези от бързата проверка.

Доверие. Всяка цел на равновесие е *точна* (аналитично равновесие на Наш за матричните игри; точен най-добър отговор и NashConv от Глава 7 за Кун/Ледюк/Goofspiel), така че игровитеоретичните резултати се ограничават от обективната истина. Невронните резултати представляват качествени неравенства (централизиран $<$ независим; с комуникация $>$ без комуникация), по конструкция чувствителни към началното число и версията. Графиките са генерирани от JSON файловете с резултати, записани в хранилището (вж. `../figures/README.md`).

Връзки с предходните и следващите глави. PSRO представлява итерираният най-добър отговор от Глава 2, издигнат до ниво популация, и използва модула за точен най-добър отговор от Глава 7; стената при Ледюк отеква откритието от Глава 8. Напред трите връзки с дисертацията вече са конкретни: LOLA като динамично моделиране на противника (Принос №1), мета-играта на PSRO като методология за оценяване (Принос №3) и, преди всичко, **липсващата минимаксна опора при $N > 2$** (Принос №2).

9.10 Основни изводи за синтеза на дисертацията

- **Нестационарността е основният проблем и тя е структурна, а не въпрос на изчислителен бюджет** – в „съвпадение на монети“ последната итерация не се сближава, колкото и дълго да продължи обучението.
- **CTDE осигурява по-добър оценител, но не и координация:** остатък $3,2 \times 10^{-11}$ спрямо 0,077, а играта „изкачване“ остана нерешена.
- **PSRO е мостът между теорията на игрите и MARL:** Кун до експлоатируемост, равна на машинната нула, RPS – до равномерна смес; Ледюк намалява, но достига стената на мащабиране, която мотивира мащабируемите методи в дисертацията.
- **Играта срещу себе си и PSRO успяват чрез средното и популацията, а не чрез последната итерация** (средната NashConv на Кун $0,24 \rightarrow 0,031$, докато последната итерация се колебае) – причината да съществува популация.
- **LOLA разглежда противника като учещ се агент** и превръща предателството в IPD в сътрудничество ($1,04 \rightarrow 2,82$) – динамичното допълнение към статичния модел на противника от Глава 7 (Принос №1).
- **Липсата на минимаксна стойност при $N > 2$ е отворената врата към дисертацията** (Принос №2): речникът на глави 2–8 преминава в MARL, но опората на безопасността – не.

10 Глава 10 – Обучение на базата на популации и еволюционна теория на игрите

Тази глава изгражда от основите темата за обучение и оценка на **популации** от агенти: еволюционната математика, която определя дали дадена популация изобщо може да се установи в равновесие, транзитивната/циклична структура, която решава дали процесът на игра срещу себе си ще се сближи или ще се завърти, и малка **лига** в стила на AlphaStar, изградена върху решим вариант на покер. **Всички експериментални резултати, представени тук, са получени** от възпроизводими изпълнения и, когато е възможно, са съпоставени с *точни* еталонни стойности (аналитичните ESS и равновесия на Наш за матричните игри; точният най-добър отговор от Глава 7 за Ледюк). Когато дадено изпълнение противоречи на очакванията ми, запазвам очакването и го съпоставям с получените резултати.

Място в дисертацията. Глави 2–8 решават *една* фиксирана игра; Глава 9 добавя *втори* обучаващ се агент; Глава 10 преминава към *цяла популация*. Три връзки с приносите на дисертацията: **основните експлоататори** на практика са автоматизирани модели на противника (Принос №1); **лигата на AlphaStar** използва експлоататори, за да направи основните агенти устойчиви – механизъм, близък до безопасната експлоатация на ниво популация, но устойчивостта му е показана само емпирично, без формална гаранция¹³¹ – точно тук се намира Принос №2; а **EGTA / мета-Наш** е методологията за оценяване на популацията (Принос №3).

10.1 Защо популации – и защо структурата определя всичко

Играта срещу себе си има известен **режим на отказ**: играч, който тренира единствено срещу самия себе си, може да се върти в кръг. Ако играта е **камък-ножица-хартия**, „да станеш по-добър“ няма смисъл – камък побеждава ножица, губи от хартия и подобряването срещу един противник просто те прави по-лош срещу друг. Най-важната идея в тази глава е, че игрите имат два вида структура, смесени заедно: **транзитивна** част (истинска **стълбица на уменията** – съществува *по-добър играч*) и **циклична** част (**кръг от контрастратегии** – има само *какво побеждава какво*). Дали една **популация, обучавана чрез игра срещу себе си** ще се сближи до нещо добро или ще се върти вечно, зависи от това *коя част е доминираща*, а не от **скоростта на обучение**.

Една представа, която да запомните: **доджо**. **Основните** ученици са това, което се опитвате да създадете. Поддържате зала, пълна със **спаринг партньори**, чиято единствена задача е да откриват и наказват конкретна слабост в настоящите ученици (експлоататори). И поддържате **музей на минали шампиони** – замразени „снимки“ – така че никой да не печели, като забрави как да победи стар стил. Обучението тогава представлява цикъл: учениците тренират помежду си, по-силните се копират и леко се изменят (**обучение на базата на популации**), а периодично копие

¹³¹Vinyals, O. et al. (2019). “Grandmaster level in StarCraft II using multi-agent reinforcement learning.” *Nature* 575(7782), 350–354. DOI 10.1038/s41586-019-1724-z (AlphaStar; лигата и PFSP).

на всички се замразява в музея. Лигата е това доджо, превърнато в математическа форма.¹³¹

10.2 Семейството от методи

Таблица 31: Семействата методи, базирани на популации: какво прави всеки, кога да се използва и основната му слабост.

Подход	Какво прави	Кога да се използва	Основна слабост
Игра срещу себе си	обучава последната стратегия срещу самата себе си	транзитивни игри; бърза базова линия	зацикля в цикличните игри; последната итерация не се сближава
PSRO	популация + мета-Наш + предсказвач за най-добър отговор; добавя най-добрия отговор, повтаря	търси се игровитеоретична цел	пълен най-добър отговор на всеки кръг; <i>сместа</i> не е решението (вж. §10.7)
PBT	копира по-приспособените агенти (експлоатация) + променя хиперпараметри (изследване)	онлайн търсене на хиперпараметри	може да загуби разнообразието си или да регресира (вж. §10.5)
Лига в стила на AlphaStar	PBT с три типа агенти (основни агенти / основни експлоататори / експлоататори на лигата) + замразяване + PFSP	нетранзитивни игри, където играта срещу себе си зацикля	големи изчислителни разходи; евристичен метод без гаранция за безопасност

Два диагностични инструмента са общи за всички тях: **репликаторната динамика** (§10.3) показва къде една популация може да се *установи*, а **декомпозицията „пумпал“** (§10.4) измерва доколко тя е транзитивна или циклична – заедно те предсказват, *преди* да бъдат направени изчислителните разходи, дали лигата от §10.5 ще се установи или ще се завърти. Линията е следна-

та: PBT¹³² и PSRO¹³³ (2017) → лигата на AlphaStar, достигнала ниво „гросмайстор“ в StarCraft II – над 99,8% от класираните човешки играчи (2019)¹³¹ → „пумпалът“ (2020)¹³⁴. Такива популации се оценяват с емпиричен теоретико-игрови анализ (EGTA)¹³⁵¹³⁶.

10.3 Репликаторна динамика – къде една популация може да се установи

Репликаторното уравнение е най-простият модел на подбора: делът на дадена стратегия нараства пропорционално на това колко тя превъзхожда средната за популацията.

$$\dot{x}_i = x_i [f_i(x) - \bar{f}(x)], \quad \bar{f}(x) = \sum_j x_j f_j(x).$$

Всяко равновесие на Наш е точка на покой, но не и обратното – например всяка чиста стратегия също е точка на покой. Устойчивите точки на покой обаче винаги са равновесия на Наш, а всяка **еволюционно стабилна стратегия (ESS)** – стратегия, която, възприета от цялата популация, не може да бъде изместена от малък дял мутанти – е асимптотично устойчива¹³⁷. PBT лигата прави същото дискретно: копира по-успешните агенти (подбор) и внася малки случайни промени в тях (мутация).

¹³²Jaderberg, M., Dalibard, V., Osindero, S., Czarnecki, W. M. et al. (2017). “Population Based Training of Neural Networks.” *arXiv:1711.09846*.


¹³³Lanctot, M. et al. (2017). “A Unified Game-Theoretic Approach to Multiagent Reinforcement Learning.” *NeurIPS* (PSRO). Вж. също: McMahan, H. B., Gordon, G. & Blum, A. (2003). “Planning in the Presence of Cost Functions Controlled by an Adversary.” *ICML*, 536–543 (методът на двойния предсказвач, който PSRO обобщава).

¹³⁴Czarnecki, W. M., Gidel, G., Tracey, B., Tuyls, K., Omidshafiei, S., Balduzzi, D. & Jaderberg, M. (2020). “Real World Games Look Like Spinning Tops.” *NeurIPS*; arXiv:2004.09468 – геометрията „пумпал“ и защо обучението изисква популации.

¹³⁵Wellman, M. P. (2006). “Methods for Empirical Game-Theoretic Analysis.” *AAAI*, 1552–1555.

¹³⁶Tuyls, K., Pérolat, J., Lanctot, M., Hughes, E., Everett, R., Leibo, J. Z., Szepesvári, C. & Graepel, T. (2020). “Bounds and dynamics for empirical game theoretic analysis.” *Autonomous Agents and Multi-Agent Systems* 34(1), 7. DOI 10.1007/s10458-019-09432-y.

¹³⁷Hofbauer, J. & Sigmund, K. (2003). “Evolutionary game dynamics.” *Bulletin of the American Mathematical Society* 40(4), 479–519 – т.нар. „фолклорна теорема“ за репликаторната динамика (§2.3), асимптотичната устойчивост на ESS (§2.6) и затворените орбити при „камък-ножица-хартия“ (теорема 2).



пунктир = „дискретен аналог на“: лигата е репликаторна динамика с обучаващи се агенти вместо фиксирани дялове на стратегиите

Фигура 54: Еволюционната теория на игрите като непрекъсната идеализация на PBT лигата: подборът съответства на копирането на по-успешните агенти, мутацията – на промяната на хиперпараметрите, а устойчивите точки на покой (ESS) – на мета-Наш сместа, към която се стреми лигата.

При четири канонични симетрични игри (динамиката е детерминистична) измерените резултати съвпадат напълно с теорията:


Таблица 32: Репликаторна динамика върху четири симетрични игри, спрямо аналитичния еталон.

Игра	Аналитичен еталон	Измерено крайно състояние	Сходим?
Дилемата на затворника	предателството доминира; ESS (0, 1)	[0,0, 1,0]	да

Игра	Аналитичен еталон	Измерено крайно състояние	Сходим?
Ястреб-гълъб	вътрешна ESS $p(\text{ястреб}) = V/C = 0,5$	$[0,5, 0,5]$ (орбитален радиус 0,0)	да
Камък-ножица-хартия	равновесие на Наш = равномерна стратегия; няма ESS	обикаля около центъра на разстояние 0,095	не
Лов на елен	две чисти ESS (според басейна на привличане)	$[0,8, 0,2] \rightarrow [1, 0]$; $[0,2, 0,8] \rightarrow [0, 1]$	да

Камък-ножица-хартия никога не се сближава – вътрешната ѝ неподвижна точка е *център*, така че популацията обикаля около нея завинаги (в непрекъснато време орбитите са затворени; явният метод на Ойлер ги превръща в бавно разширяваща се спирала). Този последен ред е цялата мотивация за останалата част от главата: цикличната игра няма стабилна популация.¹³⁸

¹³⁸Hofbauer, J. & Sigmund, K. (1998). *Evolutionary Games and Population Dynamics* (Cambridge) – репликаторна динамика, ESS и център при „камък-ножица-хартия“; вж. също обзора на Bloembergen, Tuyls, Hennes & Kaisers (JAIR 53, 659–697, 2015), който свързва репликаторната динамика с многоагентното обучение.




Фигура 55: Траектории на репликаторната динамика (дял на първата стратегия): дилемата на затворника стига до всеобщо предателство, „ястреб-гълъб“ – до ESS с дял 0,5, „камък-ножица-хартия“ обикаля, без да се сближава, а „лов на елен“ – до „всички ловуват елен“ или „всички ловуват заек“ според началната точка.

10.4 „Пумпалът“ – транзитивна и циклична структура

Ако цикличните игри са проблемът, необходимо е да измерим степента им на цикличност. **Декомпозицията „пумпал“** разделя матрицата на печалбите на **транзитивна** компонента (стълбица на уменията, изразена чрез рейтинг на всяка стратегия) и **циклична** компонента (остатъкът – частта „камък-ножица-хартия“)¹³⁹. Името идва от формата, която Szarneski и др. откриват при реални игри: те са най-широки (най-циклични) при стратегиите със средна сила и се стесняват

¹³⁹Balduzzi, D., Tuyls, K., Pérolat, J. & Graepel, T. (2018). “Re-evaluating Evaluation.” *NeurIPS*; arXiv:1806.02643 – разлагане на Ходж на антисиметричната матрица на печалбите на транзитивна и циклична компонента; усредняване по Наш.

към крайностите на уменията¹³⁴.



една и съща игра, различни популации: популацията от най-добри отговори (PSRO) е в широката циклична част, а популацията от моментни снимки (лигата) се изкачва по транзитивната ос.


Фигура 56: „Пумпалът“ (схема): вертикалната ос е транзитивната сила (умението), ширината – цикличното измерение. „Камък-ножица-хартия“ е в най-широката част ($T = 0,0$), стълбицата на уменията – върху оста ($T = 1,0$); PSRO в Ледюк $\sim 0,45$, моментните снимки на лигата $\sim 0,94-0,98$.

Реализацията използва **комбинаторното разлагане на Ходж** (по разлики в рейтингите)¹³⁹, а не декомпозицията чрез SVD с ранг 1 от първоначалния план, която неправилно дава транзитивно съотношение $\approx 0,707$ за „камък-ножица-хартия“ – и за чиста стълбица на уменията (сингулярните стойности на антисиметрична матрица винаги са по двойки). Разлагането на Ходж дава 0,0 за „камък-ножица-хартия“ и 1,0 за стълбицата. Двете *реални* популации са основният извод – и те си противоречат в рамките на една и съща игра.¹⁴⁰

Съпоставка (запазена прогноза → какво всъщност се случи). Бях приел, че покерът

¹⁴⁰Balduzzi, D. et al. (2019). “Open-ended Learning in Symmetric Zero-sum Games.” *ICML* – разлагане на функционалните игри на транзитивна и циклична част; PSRO_{T,N}.

е стълбица на уменията, и очаквах мета-играта на Ледюк да бъде предимно транзитивна. Измерванията показват, че тя зависи изцяло от това *коя популация се разлага*. Популация от **най-добри отговори** (PSRO) е предимно **циклична** (транзитивно съотношение $\approx 0,45$, циклично $0,89-0,91$, 27 цикъла от три стратегии): най-добрият отговор побеждава текущата смес, по-нов най-добър отговор побеждава *него*, и така натаък – „пумпалът“ на Czarnecki и др. в действие. Популация от **моментни снимки на траекториите на обучение** (лигата) е предимно **транзитивна** ($\approx 0,94-0,98$), защото по-късните моментни снимки обикновено са по-силни от по-ранните. Нито едното не е грешка; съотношението транзитивно/циклично е свойство на *популацията*, а изборът как да изградите популацията е избор дали ще видите кръг или стълбица.




Фигура 57: Транзитивно съотношение на четири популации: „камък-ножица-хартя“ 0,0, чиста стълбица на уменията 1,0, мета-играта на най-добрите отговори в PSRO за Ледюк $\sim 0,41-0,46$ (предимно циклична), мета-играта на моментните снимки на лигата $\sim 0,94-0,98$ (предимно транзитивна).

10.5 PBT лига в стила на AlphaStar

С помощта на диагнозата изграждаме доджото върху **Ледюк Холдем**: невронни PPO агенти от три типа – **основни** агенти (продуктът; те играят срещу всички чрез PFSP игра срещу себе си), **основни експлоататори** (търсят слабости в *текущите* основни агенти) и **експлоататори на лигата** (търсят слабости в *замразената история*). PBT копира най-добрите агенти и променя тяхна-

та скорост на обучение / ентропия; периодически замразени моментни снимки се добавят в музея; сдвояването по **PFSP** (приоритизирана фиктивна игра срещу себе си, Prioritized Fictitious Self-Play) избира противниците толкова по-често, колкото по-трудно е да бъдат победени. Всяка невронна мрежа се извлича до **таблична** стратегия, така че **точният** най-добър отговор от Глава 7 да измерва нейната експлоатируемост – същият NashConv, използван още от Глава 2 (сумата от печалбите на двата най-добри отговора; в конвенцията на OpenSpiel експлоатируемостта е половината от нея).

Сдвояване по PFSP: всеки противник се избира с вероятност, която расте с трудността да бъде победен (обучението се съсредоточава там, където агентът губи).



Фигура 58: Лигата: основни агенти, основни експлоататори (срещу текущите основни агенти) и експлоататори на лигата (срещу замразената история), с периодически замразяване в „музей“ от моментни снимки и сдвояване по PFSP към противниците, срещу които агентът губи.


Подобрява ли се лигата? Резултатите от двете конфигурации (бърза проверка: 7 агента, 15 епохи; пълен мащаб: 8 агента, 120 епохи, 48 замразени моментни снимки) са следните:

Таблица 33: Показатели от обучението на лигата при два-та мащаба.

Показател	Бърза проверка	Пълен мащаб
минимална експлоатируемост	4,67 → 3,04 (най-ниската	4,73 → мин $\approx$ 1,21 → 2,05
сред основните агенти	стойност е в края)	
експлоатируемост на	4,73 → 3,04	5,01 → мин $\approx$ 1,32 (плато
мета-Наш сместа		1,60) → 2,96
краен рейтинг по Ело	1176–1211	1198–1210
(активни агенти)		

(Стойността 2,96 е за мета-Наш сместа на популацията в началото на епоха 119, преди последната стъпка на обучение; стойността 3,418 в §10.7 е за крайната популация от 56 агента.)


Съпоставка (запазена прогноза → какво всъщност се случи). Очаквах *монотонно* намаляване на експлоатируемостта. При бързата проверка (15 епохи) очакването се потвърждава, а при пълния мащаб (120 епохи) – не: експлоатируемостта спада рязко през първите около 15 епохи и е най-ниска около епохи 20–40 (мета-Наш сместа достига $\approx$ 1,32 в епоха 21, а най-добрата моментна снимка е от епоха 29; единичният минимум сред основните агенти, $\approx$ 1,21, е в епоха 66). След плато ($\approx$ 1,60 за мета-Наш сместа) тя **нараства отново** до $\approx$ 2,05 / $\approx$ 2,96 в епоха 119. Най-добрите агенти са *замразените моментни снимки* от първата половина на обучението; *активните* основни агенти се влошават към края – стратегиите им непрекъснато се сменят и част от наученото се забравя. Играта срещу себе си, която няма експлоататори, също се влошава след епоха 100, така че натискът на експлоататорите не е единственото обяснение. Възможното решение (непроверено тук) е запазване на най-добрата моментна снимка или регуляризация на популацията. Както в Глава 9: **пълният мащаб разкрива това, което бързата проверка скрива.**



Фигура 59: Експлоатируемост (NashConv) на лигата за 120 епохи (пълен мащаб): минимумът сред основните агенти и мета-Наш сместа спадат рязко през първите около 15 епохи, най-ниски са около епохи 20–40 и нарастват отново в края. Пунктирна сива линия: играта срещу себе си, която също се влошава след епоха 100.

10.6 Разнообразие – наистина ли популацията е разнообразна?

Лигата е толкова добра, колкото и *разнообразието* от стратегии, които съдържа. Според **ефективния размер на популацията** (коефициентът на участие на мета-Наш теглата), **поведенческата клъстеризация** и **покритието на експлоатация** популацията е само слабо разнообразна: коефициентът на участие нараства от 1,0 (бърза проверка) до 1,9 (пълен мащаб), но поведенческата клъстеризация свежда всичко до **един клъстер** и при двата мащаба – дори при пълен мащаб, където максималното поведенческо разстояние между двойки (0,48) надвишава прага за клъстеризация (0,30), методът на единичното свързване обединява агентите във верига. Разнообразието тук е *на ниво тегла*, а не *на ниво поведение* (агентите играят почти еднакво). Механизмът се проявява най-ясно при мини-RBT върху матрични игри:




Фигура 60: Разнообразие при мини-PBT през поколенията: в транзитивната дилема на затворника популацията се свежда до една стратегия (разнообразие $\rightarrow 0$), а в цикличната игра „камък-ножица-хартия“ стратегиите непрекъснато се сменят (0,07–0,29).

Транзитивните игри *унищожават* разнообразието (има една най-добра стратегия и всички се сближават към нея), а цикличните игри го *налагат*. Лигата в Ледюк е близо до транзитивния край – затова разнообразието ѝ е ниско и затова ползите от разнообразието, описани за AlphaStar, където по време на обучението са създадени близо 900 различни агента, не се проявяват в този мащаб.¹³¹

10.7 EGTA – оценка на популацията и неочаквано откритие

Последният инструмент е **емпиричният теоретико-игрови анализ (EGTA)**: цели агенти (стратегии за цялата игра) се разглеждат като „чисти стратегии“ на игра от по-високо ниво, всяка двойка агенти се изиграва, за да се попълни емпиричната матрица на печалбите, намира се **мета-Наш** сместа на тази матрица и тя се оценява – така експлоатируемостта се пренася на ниво популация.

EGTA = равновесие на Nash на игра, чиито „стратегии“ са цели агенти – експлоатируемостта, пренесена на ниво популация.



Фигура 61: Процесът на EGTA: всяка двойка агенти се изиграва, намира се мета-Наш сместа на емпиричната матрица на печалбите, тя се свежда до една поведенческа стратегия и се измерва точната ѝ експлоатируемост в пълната игра.

Първоначалният план очакваше мета-Наш сместа на лигата да бъде *по-малко* експлоатируема от всеки отделен член. Измерено:

Таблица 34: Експлоатируемост на мета-Наш сместа спрямо най-добрия отделен агент, по конфигурация.

Конфигурация	експлоатируемост на мета-Наш сместа	най-добър отделен агент	мета-Наш $\leq$ най-добрия?
Бърза проверка	2,665	2,665	да (цялото тегло е върху най-добрия агент)
Пълен мащаб	3,418	1,305	не

Съпоставка (запазена прогноза → какво всъщност се случи). Бързата проверка потвърди очакването тривиално: мета-Наш даде *цялото* тегло на единствения най-добър агент, така че сместа = най-добрия = 2,665. При пълния мащаб мета-Наш разпределя теглото (0,645 върху един агент и по-малки тегла върху още два), а сместа, сведена до една поведенческа стратегия, има експлоатируемост 3,418 – **по-висока** от


тази на най-добрата отделна моментна снимка (1,305). Това не е грешка в смесването: същият код дава смес = най-добрия при бързата проверка, а сместа е по-малко експлоатируема от всеки от трите си компонента (3,558, 3,932 и 4,262). Причината е в целта: мета-Наш минимизира **съжалението в мета-играта** (доколко добре се представя *срещу популацията*), а не **експлоатируемостта в пълната игра**, затова най-малко експлоатируемите агенти получиха тегло нула. Като резултат от лигата трябва да се използва избран член, устойчив срещу най-добър отговор, а не мета-Наш сместа.

Как се представя лигата спрямо останалите методи по експлоатируемост в Ледюк?

Таблица 35: Експлоатируемост в Ледюк (NashConv) по метод; при играта срещу себе си са дадени и крайният агент, и най-добрата итерация.

Метод (пълен мащаб)	Експлоатируемост (NashConv)
CFR, равновесие на Наш (долна граница)	0,0099
Лига – най-добър отделен агент (за цялото обучение)	1,305
Игра срещу себе си – най-добра итерация (епоха 100)	1,396
PSRO (точен предсказвач за най-добър отговор)	2,163
Лига – мета-Наш смес	3,418
Игра срещу себе си – краен агент	3,683

Най-добрият отделен агент на лигата е най-добрият резултат сред методите, основани на обучение, но предимството му трябва да се чете внимателно: при играта срещу себе си най-добрата итерация е 1,396 и едва накрая се влошава до 3,683, а PSRO достига 2,163 – по едно изпълнение за всеки метод, и всички остават далеч над долната граница, зададена от CFR. Мета-Наш сместа на лигата (3,418) е по-добра само от крайния агент на играта срещу себе си. Затова като резултат от лигата трябва да се използва избран отделен агент, а не сместа.¹³³



Фигура 62: Експлоатируемост (NashConv) в Ледюк по методи (пълен мащаб): CFR (равновесие на Наш) $\sim 0,01$; най-добрият отделен агент на лигата (1,31) е сравним с най-добрата итерация на играта срещу себе си (1,40) и е под PSRO (2,16), мета-Наш сместа (3,42) и крайния агент от играта срещу себе си (3,68).

10.8 Честни бележки, ограничения и предаване на щафетата

Какво се потвърди. Репликаторната динамика възпроизвежда всеки аналитичен резултат за матричните игри¹³⁷; разлагането на Ходж правилно определя чистите случаи; лигата дава отделен агент с експлоатируемост 1,305; а EGTA дава работеща мярка за експлоатируемост на ниво популация.

Какво не се получи и защо това има значение. Три уговорки остават валидни и за следващите глави. (1) При пълен мащаб експлоатируемостта на лигата **нараства отново в края на обучението** ($4,73 \rightarrow \approx 1,21 \rightarrow \approx 2,05$); най-добрите агенти са замразени моментни снимки. (2) При пълен мащаб **мета-Наш сместа е по-експлоатируема от най-добрия член на популацията** (3,42 срещу 1,31), защото не му дава никакво тегло – изборът на мета-Наш не гарантира устойчивост. (3) Мета-играта на Ледюк е **циклична като популация от най-добри отговори, но транзитивна като популация от моментни снимки**. И един методологичен извод: късната регресия и слабостта на сместа не се виждат при бързата проверка.

Доверие. Всяка еволюционна цел е *аналитична*, а всяка стойност на експлоатируемостта в лигата е *точният* NashConv от Глава 7, изчислен върху таблично извлечените стратегии. Невронните резултати идват от едно изпълнение на PBT за всяка конфигурация: надеждни са *посоките* (ранно подобрене; най-добрата моментна снимка < PSRO < крайния агент на играта срещу себе си;

късна регресия; мета-Наш сместа $>$ най-добрия член на популацията), а не точните стойности до третия десетичен знак.

Връзки с предходните и следващите глави. С предходните: лигата е асинхронен вариант на PSRO от Глава 9 с невронни предсказвачи и изцяло използва точния най-добър отговор от Глава 7; „мета-Наш на популация“ е равновесието на Наш от Глава 2, пренесено едно ниво по-горе. Със следващите: основните експлоататори на практика са автоматизирани модели на противника (Принос №1); EGTA/мета-Наш е методологията за оценяване (Принос №3); а липсващата гаранция на лигата – тя може да се влоши и сместа ѝ може да е експлоатируема – е популационната форма на **липсващата опора за безопасност при $N > 2$ играчи** (Принос №2). Транзитивната/цикличната диагностика предсказва, че коалиционните игри всеки срещу всеки от Глава 11 ще бъдат силно циклични, така че наивното PBT там ще зацикли.

10.9 Основни изводи за синтеза на дисертацията

- **Структурата определя сходимостта.** Транзитивното/цикличното съотношение („пумпал“) е *диагностика преди обучението*: транзитивните игри се установяват (и потискат разнообразието), цикличните игри се въртят (и налагат разнообразие). Измерено транзитивно съотношение: „камък-ножица-хартия“ 0,0, стълбица на уменията 1,0, PSRO в Ледюк $\approx 0,45$ (циклична), моментни снимки на лигата $\approx 0,94$ – $0,98$ (транзитивна).
- **Лигата произвежда силни отделни агенти, но не носи гаранция.** Най-добрата моментна снимка (1,305) е по-добра от PSRO (2,163) и сравнима с най-добрата итерация на играта срещу себе си (1,396; крайният ѝ агент е 3,683) – по едно изпълнение за всеки метод; въпреки това експлоатируемостта *нараства отново* към края ($\rightarrow 2,05$), а мета-Наш сместа (3,42) е по-лоша от най-добрия член на популацията (1,31): мета-Наш оптимизира съжалението в мета-играта, а не експлоатируемостта в пълната игра, затова експлоатируемостта на сместа трябва да се измерва пряко, а като резултат да се използва избран отделен агент.
- **Точната оценка е опората.** Оценяването на таблично извлечените невронни стратегии с точния най-добър отговор от Глава 7 прави всяко твърдение за популацията проверимо спрямо точни стойности.
- **Липсата на гаранция за безопасност на ниво популация е отворен проблем (Принос №2):** механизмът с експлоататори в лигата на AlphaStar е аналог на ниво популация на безопасната експлоатация от Глава 8, но е евристичен: устойчивостта му е показана само емпирично¹³¹, а в малката лига от тази глава той не осигури нито монотонно подобрене, нито неексплоатируема смес.

11 Глава 11 – Формиране и засичане на коалиции

Тази глава е за нещо, което възниква едва когато една игра има **трети играч**: временни **съюзи**, които се формират, експлоатират и предават. Тя използва **So Long Sucker (SLS)** – играта за четирима на Hausner, Nash, Shapley и Shubik, публикувана през 1964 г., в която изходът зависи почти изцяло от договарянето между играчите¹⁴¹, – и допълва единствения публикуван подход с обучение с подкрепление за нея¹⁴², чиито агенти не отчитат **коалициите**, с детектор на коалиции и награда по Шапли. При $N \geq 3$ **равновесието на Наш и експлоатируемостта стават изчислително непосилни и губят смисъла си**, така че на въпроса „проработи ли?“ вече не може да се отговори с едно-единствено число. Числата са измерени и, когато е възможно, са поставени в рамките на *точни* еталонни стойности (учебниковите стойности на Шапли и ядрото; точен минимаксен решаващ за крайната фаза на SLS с двама играчи). Когато някое изпълнение противоречи на очакванията ми – включително истинска грешка в двигателя на играта – запазвам очакването и го съпоставям с действителния резултат.

Къде се вписва това в дисертацията. Глава 11 се отказва от *точния* предсказвач за най-добър отговор при двама играчи, на който разчитаха глави 2–10. **Детекторът на коалиции** пренася моделирането на противника от въпроса „какъв тип играч е това?“ към въпроса „кой с кого е в съюз?“ (Принос №1). **Безопасната базова линия губи опората си в равновесието на Наш** – без минимаксна стойност и при празно ядро няма стабилно разпределение, на което да се опре безопасността; поведенческа опорна стратегия по подобие на piKL е кандидат без гаранция – празнина, която главата очертава, но не запълва (Принос №2). Мета-играта на **ЕГТА** и **приносът по Шапли** заместват експлоатируемостта, която при повече от двама играчи вече не показва какво е гарантирано на агента, още по-малко срещу коалиция (Принос №3).

11.1 Защо появата на трети играч е повратна точка

С двама играчи една игра с нулева сума има *стойност*: съществува оптимална по минимакс стратегия и „колко далеч сте от оптималната?“ (експлоатируемост) е едно-единствено смислено число, на което се опираше всяка глава от Глава 2 насам. С трети играч двама играчи могат да **се обединят** срещу третия и интересният въпрос става „с кого се съюзява кой, за колко дълго и кой предава пръв?“. Равновесието на Наш в игра всеки срещу всеки с четирима играчи е едновременно **изчислително непосилно и лишено от гаранции**: намирането му е поне толкова трудно, колкото при общите игри с двама играчи¹⁴³, ако всеки играч избере равновесие независимо от другите, получената комбинация може изобщо да не е равновесие¹⁴⁴, а освен това то защитава само от едно-

¹⁴¹Hausner, M., Nash, J., Shapley, L. & Shubik, M. (1964). “So Long Sucker – A Four-Person Game.” B M. Shubik (Ed.), *Game Theory and Related Approaches to Social Behavior*, 359–361. New York: Wiley.

¹⁴²Sharan, M. & Adak, C. (2024). “Reinforcing Competitive Multi-Agents for Playing ‘So Long Sucker’.” *arXiv:2411.11057*.

¹⁴³Daskalakis, C., Goldberg, P. W. & Papadimitriou, C. H. (2009). “The Complexity of Computing a Nash Equilibrium.” *SIAM Journal on Computing*, 39(1), 195–259.

¹⁴⁴Brown, N. & Sandholm, T. (2019). “Superhuman AI for multiplayer poker.” *Science*, 365(6456), 885–890.

транни отклонения, а не от съвместните отклонения на коалициите, които всъщност определят изхода от играта¹⁴⁵.

Полезна аналогия: **вечеря** с четирима гости и една къща. Всеки се съюзява по двойки, за да свърши работата, но най-умният ход е тихо да предадете партньора си един ход *преди* той да ви предаде. So Long Sucker прави това буквално: държите цветни **жетони**, поставяте ги в купчините на други играчи (ръкостискане) или вземате техните купчини (ножът), и бивате елиминирани, когато останете без **жетони**. В двигателя на тази глава съюзът е **кодиран изцяло в ходовете**: преговорите, които в истинската игра са свободни и необвързващи, не се моделират, затова детекторът може да прочете коалицията директно от потока от ходове.


Последствието за методологията е най-важната идея в тази глава: **при $N \geq 3$ точната оценка отстъпва място на емпиричната**. Вместо експлоатируемост се използват делът на победите, коалиционният резултат от детектора и цикличното съотношение на емпиричната мета-игра, закотвени в единствената подигра, която е точно решима: крайната фаза с двама играчи.

11.2 Детекторът на коалиции – извличане на съюзи от ходовете

Вместо да извежда скрит *тип* или *ръка* (Глава 7), детекторът извежда скрита *социална структура*. Той следи дневника на ходовете и натрупва две матрици: **помощ** (играч i поставя жетон в купчината на играч j) и **вреда** (играч i взема купчината на играч j). Разликата между тях е **нетна подкрепа**, а двойката с най-висока взаимна нетна подкрепа представлява най-силната коалиция.


¹⁴⁵Bernheim, B. D., Peleg, B. & Whinston, M. D. (1987). "Coalition-Proof Nash Equilibria I. Concepts." *Journal of Economic Theory* 42(1), 1–12. DOI 10.1016/0022-0531(87)90099-8.

В този двигател съюзът се вижда само в ходовете - преговорите не се моделират.



Фигура 63: Детекторът на коалиции: поставянето на жетон се отчита като ПОМОЩ, вземането на купчина – като ВРЕДА; в нетната подкрепа взаимният съюз се вижда като силна двупосочна връзка (Принос №1).

Когато двама програмирани играчи систематично си помагат и вредят на останалите, детекторът, без да получи никаква информация, разпознава **ТОЧНО** предварително зададената коалиция $\{0, 1\}$, с отчетливо по-висок резултат (10,0 за съюзническата двойка, 0 или —1 навсякъде другаде). Това е проверка срещу една програмирана, открито действаща двойка; честотата на фалшивите тревоги при игра без съюзи и разпознаването на прикрити съучастници не са проверявани.



Фигура 64: Матрица на коалиционния резултат, изведена само от поставянето на жетоните: предварително зададеният съюз между играчи 0 и 1 има резултат 10; останалите двойки са неутрални (0) или враждебни (-1).


11.3 Принос по Шапли в състезателна игра

За да се научи да формира коалиции, **агентът** се нуждае от **награда**, която да показва „ти допринесе за една коалиция“. Класическият инструмент е **стойността на Шапли**: единственото разпределение на стойността на коалицията между членовете ѝ, което удовлетворява аксиомите на Шапли (ефективност, симетрия, нулев играч, адитивност); то осреднява пределния принос на всеки член по всички възможни редове на присъединяване. Две учебникови игри определят какво означават „справедливо“ и „стабилно“, като и двете се възпроизвеждат точно:

Таблица 36: Стойност на Шапли и стабилност на ядрото при два опростени кооперативни модела.

Опростена кооперативна игра	Стойност на Шапли	Ядро (стабилност)
Игра с ръкавиците	$(2/3, 1/6, 1/6)$	непразно (съществува стабилно разпределение)
Мнозинство от трима играчи	$(1/3, 1/3, 1/3)$	празно (няма стабилно разпределение)

Празното ядро на играта на мнозинството е ключовата идея на главата: *всяко* разпределение може да бъде оспорено от някаква коалиция, така че сътрудничеството е *по своята същност нестабилно*. SLS е игра с постоянна сума (печели само един), а всяка съществена игра с постоянна сума има празно ядро¹⁴⁶; следователно и коалиционната игра на SLS, в която стойността на коалицията е гарантираната ѝ вероятност за победа, няма стабилно разпределение (играта е съществена, защото никой играч не може сам да си гарантира победа). Заедно с липсата на минимаксна стойност при повече от двама играчи това обяснява защо „безопасната“ игра при N играчи не може да се опре на стабилно равновесие (Принос №2).




Фигура 65: Принос по Шапли в състезателна игра: стойността на коалицията става оценената чрез симулации вероятност неин член да спечели. Празното ядро на играта на мнозинството илюстрира защо коалициите в SLS рано или късно се разпадат.

В SLS няма обща печалба, която да се поделя, затова **предефинираме стойността на коалицията** като *вероятността неин член да спечели*, оценена чрез симулации по метода Монте Карло; приносът на всеки играч е стойността на Шапли на тази функция на вероятността за победа. Резултати върху позиции в SLS: наистина симетрична позиция дава почти равни приноси (размах 0,013), а асиметричната позиция [8, 8, 1, 1] приписва *целия* принос на силната двойка (стойност на коалицията 1,0). Симетричният резултат е получен **след** отстраняване на грешка.¹⁴⁷

¹⁴⁶Ferguson, T. S. *Game Theory* (лекционни записки, UCLA), Part IV “Games in Coalitional Form”, § 2.3, Theorem 1.

¹⁴⁷Shapley, L. S. (1953). “A value for n-person games.” В *Contributions to the Theory of Games II* (Annals of Mathematics Studies 28), 307–318. Princeton University Press; Chalkiadakis, G., Elkind, E. & Wooldridge, M. (2011). *Computational Aspects of Cooperative Game Theory*. Morgan & Claypool (ядро, стойност на Шапли, нуклеолус); Wang, J., Zhang, Y., Kim, T.-K. & Gu, Y. (2020). “Shapley Q-Value: A Local Reward Approach to Solve Global Reward Games.” *AAAI* 34(5), 7285–7292 (разпределяне на приноса в MARL чрез стойността на Шапли).



Фигура 66: Принос по Шапли в две позиции на SLS: почти равен в симетричната позиция (размах 0,013 след поправката) и изцяло съсредоточен върху силната двойка в [8, 8, 1, 1].


Съпоставка (запазена прогноза → действителен резултат). Прогнозирах, че симетрична позиция ще даде симетрично разпределение на приноса (размах $< 0,15$). Първото изпълнение даде 0,54 (неуспешна проверка), като играч 0 печелеше около два пъти повече от справедливия си дял в три независими скрипта. Механизмът: **~99,5% от случайните игри в този двигател завършват с пат** (всички играчи, останали в играта, са без жетони в ръка – опростените правила пропускат играч с празна ръка), затова победителят се определя от правилото при равенство по брой жетони, а то тихомълком даваше предимство на място 0, защото избираше играча с най-малък индекс. **Безпристрастното случайно разрешаване на равенството** отстрани проблема: размахът на симетричния принос спадна от 0,54 на 0,013, а победите вече се разпределят равномерно. Това разкри също, че впечатляващият дял победи $\sim 0,87$ на собствения агент е бил *същият* артефакт (агентът винаги е заемал място 0); реалната стойност е $\sim 0,41$. В игра, която почти винаги завършва с почти равен резултат, правилото при равенство е най-важният ред в кода на двигателя.

11.4 MAPPO с отчитане на коалициите – и кога всъщност расте коалиционният резултат

Всяко място в SLS се заема от отделен агент PPO с маскиране на недопустимите ходове, който се обучава по цели епизоди чрез игра срещу себе си. Наградата е **смес**:

$$r = \alpha r_{\text{sparse}} + (1 - \alpha) (\text{коалиционен принос по Шапли}),$$

където r_{sparse} е рядката награда „победителят взема всичко“, а вторият член е центрираният принос по Шапли от раздел 11.3 – изчислен или евтино, от оценките на оценителя (заместител), или по-скъпо, чрез симулации (в кода counterfactual). Теглото α определя баланса между „просто победи“ ($\alpha = 1$) и „формирай коалиции“ ($\alpha = 0$).



Фигура 67: Смесване на наградите в MAPPO с отчитане на коалициите: рядката награда за победа се смесва с коалиционния принос по Шапли с тегло α (1 – само рядка награда, 0 – само принос).

Формират ли агентите, обучени с коалиционен принос, повече коалиции от агентите с рядка награда? Отговорът изискваше **сдвоени сравнения с 5 начални числа** за всички комбинации на α , вида на приноса и синергията, тъй като една-единствена конфигурация ме подведе сериозно. Сравненията са на две нива: бърза проверка (5 жетона, 400 игри за обучение) и пълен мащаб (7 жетона, 1500 игри). Сдвоена разлика = коалиционен резултат на агентите с принос по Шапли минус този на агентите с рядка награда; ** = разлика, по-голяма от две стандартни грешки, което при 5 начални числа отговаря приблизително на $p < 0,12$:


Таблица 37: Сдвоена разлика в коалиционния резултат между агентите с принос по Шапли и базовата линия с рядка награда, по режим.

Режим	Сдвоена разлика (Шапли – рядка награда)
пълен мащаб, заместител, $\alpha = 0$, синергия 0,3	$+0,0376 \pm 0,0103$ (резултатът на агентите с принос е $\sim 4,5$ пъти този на базовата линия)

Режим	Сдвоена разлика (Шапли – рядка награда)
пълнен мащаб, чрез симулации, $\alpha = 0$	$+0,0128 \pm 0,0026$
пълнен мащаб, $\alpha \geq 0,3$	$-0,0003 \dots - 0,0035$ (навсякъде отрицателна; при бързата проверка: $-0,003 \dots + 0,001$, без значими)
бърза проверка, заместител, $\alpha = 0$, синергия 0,1	$+0,0024 \pm 0,0008$ (много малка)

Съпоставка (запазена прогноза → действителен резултат). Експериментите ми с една-единствена конфигурация използваха стойността по подразбиране $\alpha = 0,3$ и показаха, че коалиционният сигнал изчезва при пълния мащаб, което първоначално тълкувах като „приносът от заместителя е твърде слаб при по-дълго обучение“. Серията експерименти обърна този извод: **α е доминиращият параметър, а $0,3$ е мъртва зона.** Коалиционният резултат нараства статистически значимо *само при ниски стойности на α* (при $\alpha \approx 0$ агентите с принос по Шапли надминават базовата линия с $+0,038$), докато *всяка* клетка с $\alpha \geq 0,3$ при пълния мащаб е отрицателна – членът с рядка награда заглушава коалиционния сигнал. Ефектът е също **по-голям при пълния мащаб** (там размерът на играта и продължителността на обучението не са разделени), а **евтиният заместител дава по-силен ефект от скъпата оценка чрез симулации**. Решението е „да се даде голяма тежест на коалиционния принос“, а не „да се изчисли по-точен принос“; дали ефектът отразява формиране на коалиции, още не е проверено.

Уговорка за механизма. В `shapley.py` стойността от симулациите е $v(S) = \sum_{i \in S} P(i \text{ печели})$ – адитивна игра, в която стойността на Шапли на всеки играч е просто собствената му вероятност за победа (а в обучението тя се изчислява веднъж за партида, от началното състояние). Центрираният принос на заместителя е пропорционален на собствената оценка на оценителя за агента минус средната за масата; синергията само го мащабира. Нито един от двата сигнала не показва кой на кого помага, а коалиционният резултат е средната *абсолютна* взаимна нетна подкрепа и расте и при взаимна враждебност. Ефектът при ниско α следователно показва, че замяната на наградата за победа с пътен сигнал променя взаимодействията между агентите; дали така възникват коалиции, изисква контролен експеримент с еднакво плътна награда без коалиционна информация.



Фигура 68: Сдвоена разлика в коалиционния резултат за $\alpha \times$ вид на приноса $\times$ синергия (5 начални числа, $\pm$ една стандартна грешка): значима само при ниско α (максимум +0,038, заместител, $\alpha = 0$); при пълен мащаб е отрицателна при всяко $\alpha \geq 0,3$.


Няма безплатен обяд: при изцяло коалиционен принос ($\alpha = 0$) делът на победите спада до $\sim 0,29$ (близо до нивото на случайната игра 0,25), докато $\alpha \geq 0,1$ го запазва на $\sim 0,52$. Основната цел е формирането на коалиции, а победата е второстепенна, както беше заложено в плана на главата – вече количествено.¹⁴⁸

11.5 EGTA и въртящият се пумпал – SLS колело ли е, или стълба?

Крайният инструмент оценява *популацията* чрез **емпиричния игровотеоретичен анализ (EGTA)**, както в раздел 10.7. За да се използват повторно решаващът за мета-равновесие на Наш от Глава 9 и разлагането „пумпал“ (на Ходж) от Глава 10 – и двата инструмента за игри с двама играчи – тензорът на печалбите за четирима играчи се **проецира** в матрица на сблъсъците по двойки, която след това се разлага на **транзитивна** (стълба на уменията) и **циклична** (камък-ножица-хартия) компонента.

¹⁴⁸Реализацията на MAPPO с централизиран оценител е от Глава 9. piKL (регуларизация на търсенето към стратегия, наподобяваща човешката игра) е въведен от Jacob, A. P. и др. (2022). “Modeling Strong and Human-Like Gameplay with KL-Regularized Search.” *ICML*, arXiv:2112.07544, и е приложен в Diplomacy от Bakhtin, A. и др. (2023). “Mastering the Game of No-Press Diplomacy via Human-Regularized Reinforcement Learning and Planning.” *ICLR*, arXiv:2210.05492. Опорната стратегия там е имитация на човешка игра и не дава гаранция за безопасност; използването ѝ като опора за безопасна експлоатация при N играчи е предложение на дисертацията.

EGTA = емпирична мета-игра, чиито „стратегии“ са цели обучени агенти;
експлоатируемостта не дава гаранция срещу коалиция.



Фигура 69: EGTA и разлагането „пумпал“ за SLS: тензорът на печалбите за четирима играчи се проектира в матрица по двойки и се разлага на транзитивна и циклична компонента; проекцията може да подценява цикличното съотношение.

Глава 10 предвиди, че коалиционните игри всеки срещу всеки ще бъдат силно циклични. Измерванията показват, че това зависи изцяло от **популацията, която се разлага**:¹⁴⁹

Таблица 38: Циклично съотношение и структура на две популации в SLS.

Популация	Циклично съотношение	Структура
Популация тип „стълба на уменията“	0,25–0,31	преобладаващо транзитивна (стълба)
Коалиционна популация (стратегии „съюзник/предател“)	~ 0,57–0,69	силна циклична компонента; транзитивната е малко по-голяма

Съпоставка (запазена прогноза → действителен резултат). Очаквах голяма циклична компонента и първоначално видях почти съвършена стълба на уменията (циклично съотношение ~ 0,07). Причината беше отчасти грешката с място 0 (раздел 11.3) и отчасти **съставът на популацията**: базовата популация по подразбиране е стълба на уменията.

¹⁴⁹Balduzzi, D. et al. (2019). “Open-ended Learning in Symmetric Zero-sum Games.” *ICML*, PMLR 97, 434–443 – разлагане на транзитивна и циклична компонента; Czarnecki, W. M. и др. (2020). “Real World Games Look Like Spinning Tops.” *NeurIPS*, arXiv:2004.09468 – геометрията „пумпал“.

ята. Популация с коалиции (фиксиран съюзник + стратегии „предател“) повишава цикличното съотношение до стойности между $\sim 0,57$ и $0,69$, което потвърждава *посоката* на прогнозата, но остава **под прага на строго доминиране** (квадратът на цикличното съотношение е малко под $0,5$). Основната вероятна причина е, че **проекцията върху двойки типове губи коалиционните ефекти между трима и четирима играчи**; разлагането директно на тензора остава отворен въпрос.

11.6 Бележки, ограничения и връзка със следващите глави

Точните опорни точки са надеждни: двигателят съвпада с минимаксното решение на крайната фаза с двама играчи без **нищо едно** несъответствие, а кодът за стойността на Шапли възпроизвежда опростените кооперативни игри, *включително тяхното ядро*, с точност до четвъртия знак след десетичната запетая.

Две поправки остават в сила и за следващите глави. (1) „Симетричната“ игра не беше симетрична – **грешка в правилото при равенство** по брой жетони даде на място 0 около два пъти по-голям дял от справедливия и завиши дела на победите на собствения агент от реалните $\sim 0,41$ до фалшивите $\sim 0,87$; грешката е поправена, но показва, че рискът се крие в *правилата* на двигателя, а не в решавача. (2) „Коалициите не възникват при пълния мащаб“ се оказа следствие от **неподходящо тегло на смесване** ($\alpha = 0,3$ е мъртва зона), а не провал на метода. Както в глави 9–10, **една-единствена конфигурация скрива онова, което разкрива серия експерименти с няколко начални числа**.

Доверие. Точните проверки са детерминирани; твърденията за обучението се основават на сдвоени сравнения с 5 начални числа и интервали на грешката, така че *посоките* са надеждните твърдения, а не величините до третия знак след десетичната запетая. Основната уговорка остава **верността на двигателя спрямо правилата**: двигателят е сертифициран спрямо собствения си правилник, а не спрямо формализацията на De Carufel & Jerade¹⁵⁰, и грешката в правилото при равенство показва, че тази сверка не е козметична.

Връзки. Назад: моделът на противника от Глава 7 е пренесен към социалната структура; метаравновесието на Наш и разлагането „пумпал“ от глави 9–10 се прилагат повторно върху проектаната мета-игра; определението от Глава 8 „безопасно = ограничено отклонение от равновесието на Наш“ губи опората си. Напред: Глава 12 разглежда езиковите модели като стратегически агенти, но не и договарянето; безопасността при N играчи (Принос №2) и оценката чрез EGTA върху тензора на печалбите като многоагентно обобщение на експлоатируемостта (Принос №3) остават задачи на дисертацията.

¹⁵⁰De Carufel, J.-L. & Jerade, M. R. (2024). “So Long Sucker: Endgame Analysis.” *arXiv:2403.17302*.

11.7 Основни изводи за синтеза на дисертацията

- **При $N \geq 3$ точната оценка отпада.** Оценката става емпирична (дял на победите, коалиционен резултат и циклично съотношение от EGTA), закотвена в минимаксното решение на крайната фаза с двама играчи (0 несъответствия).
- **Плътният принос повишава коалиционния резултат, но това още не доказва научени коалиции.** При $\alpha \approx 0$ разликата е $+0,038$ (5 начални числа, пълен мащаб), а при $\alpha \geq 0,3$ изчезва. Както е реализиран, приносът не показва кой на кого помага; нужна е контролна плътна награда без коалиционна информация (раздел 11.4).
- **Голямата тежест на приноса намалява дела на победите.** $\alpha = 0$ понижава дела на победите до $\sim 0,29$, близо до нивото на случайната игра (0,25); при $\alpha \geq 0,1$ той се възстановява до $\sim 0,52$.
- **Празното ядро означава структурна нестабилност.** Няма стабилно разпределение, затова коалициите *ще* се разпаднат, а „безопасната“ игра при N играчи се нуждае от опора, различна от равновесието на Наш или ядрото (Принос №2).
- **Съставът на разлаганата популация определя дали се вижда стълба, или колело** (урокут от Глава 10): популацията „стълба на уменията“ има циклично съотношение $\sim 0,3$, а коалиционната – между $\sim 0,57$ и $0,69$, като транзитивната компонента остава малко по-голяма.
- **Верността към правилата на двигателя е по-важна от кода на решавача.** Пристрастието към място 0 и цикличното съотношение под прага на доминиране се дължат на опростяванията на двигателя; математиката на Шапли и EGTA издържа точно учебниковите проверки.

12 Глава 12 – Модели на последователности и агенти с голям езиков модел в стратегически среди

12.1 Защо да се разглежда обучението с подкрепление като прогнозиране на последователност

Класическото обучение с подкрепление оптимизира, като оценява функцията на стойността, разпространява наградите назад (белманово обновяване) и подобрява стратегията. Decision Transformer (DT, „трансформър за вземане на решения“; Chen и др., 2021) предлага друг подход: разглежда целия проблем като **моделиране на последователности чрез обучение с учител**. На модел от типа GPT се подава траектория от тройки

$$(\hat{R}_1, s_1, a_1, \hat{R}_2, s_2, a_2, \dots)$$

където $\hat{R}_t = \sum_{t' \geq t} r_{t'}$ е *остатъчната възвръщаемост* (return-to-go), а моделът се обучава да предсказва a_t въз основа на всичко, случващо се до s_t . Не се използва оператор на Белман и не се извършва стъпка за подобряване на стратегията. При използването на модела той просто се **обулавя**: задава се желана висока остатъчна възвръщаемост и моделът генерира действията, които в данните са предшестващи такива възвръщаемости.

За дисертацията подходът е привлекателен, защото работи изцяло **офлайн** – върху фиксиран набор от записани данни, какъвто е случаят с историите на реални игри, при които играта срещу себе си не е възможна.¹⁵¹

12.2 Капанът между късмета и умението

Преформулирането прикрива едно предположение: че остатъчната възвръщаемост е нещо, което агентът *е заслужил*. В стохастична среда това не е вярно. Paster и др. (2022) показват, че стратегии-те, обусловени от възвръщаемостта, систематично преследват късмета; най-простият пример го прави очевидно.

Разгледайте едностъпкова задача с два възможни избора (двурък бандит). Действие А изплаща 0,5 детерминистично, а действие В изплаща 1,0 с вероятност 0,4 и 0 в останалите случаи, така че очакваната му стойност е $\mathbb{E}[B] = 0,4 < 0,5$. Действие А е оптимално по очаквана стойност. Единственият начин обаче една траектория да постигне възвръщаемост от 1,0 е чрез избор на действие В и получаване на късмет. Ако обусловим по „възвръщаемост = 1,0“, ще получим единствено траектории с действие В:

$$P(a = B \mid \hat{R} = 1,0) = 1,00 \quad (\text{измерено в собствена симулация})$$

¹⁵¹Chen et al., *Decision Transformer: Reinforcement Learning via Sequence Modeling*, NeurIPS 2021 (arXiv:2106.01345).

Обучаваният модел, обусловен по възвръщаемостта, уверено избира действието с по-ниска очаквана стойност. Това не е грешка в модела, а самата същност на обуславянето по изхода, когато изходът отчасти зависи от случайността.¹⁵²

12.3 ARDT – обуславяне по гарантираната възвръщаемост


Решението е да се обуславя не по възвръщаемостта, която *се е случила*, а по възвръщаемостта, която агентът може да си гарантира срещу противник в най-лошия случай – минимаксната остатъчна възвръщаемост. ARDT (Tang и др., 2024) я оценява чрез **регресия с експектили**, която минимизира асиметричната квадратична загуба

$$L_{\text{ER}}^{\alpha}(u) = \mathbb{E}_u[|\alpha - \mathbf{1}(u > 0)| \cdot u^2]$$

чиито граници дават необходимите оператори: $\alpha \rightarrow 0$ възстановява **минимума**, а $\alpha \rightarrow 1$ – **максимума**. Траекториите се преетикетират с оценената минимаксна възвръщаемост и върху тях се обучава стандартен DT.

Два детайла от публикувания метод, и двата проверени в самата статия, са съществени. Песимистичната страна съответства на **ниско** α (в първоначалния план на главата $\tau = 0,9$ погрешно е описано като песимистично; статията използва $\alpha = 0,01$). А целевата стойност при преетикетирането е стойност на двойката **състояние-действие**, $\tilde{R}_t = \tilde{Q}_{\nu}(s_t, a_t)$, получена от два *свързани* оценителя, които се напасват редуващо се със загуби α и $1 - \alpha$. Стойност на състояние $V(s)$ не може да различи „това състояние е лошо“ от „това действие в това състояние е лошо“, а точно на това разграничение се основава методът.

¹⁵²Paster, McIlraith & Ba, *You Can't Count on Luck: Why Decision Transformers and RvS Fail in Stochastic Environments*, NeurIPS 2022 (arXiv:2205.15967).



Фигура 70: Експлоатируемост на ARDT спрямо τ (по втората ос – средната целева стойност при преетикетирането); средни стойности от три начални числа (стандартен DT – 0,731, равновесие – 0,017 жетона).

Измерена върху **Кун** с умишлено опростен заместител, който отчита само състоянието, целевата стойност при преетикетирането се изменя монотонно с τ , както изисква теорията – но експлоатируемостта е *най-ниска* от оптимистичната страна. Най-вероятната причина е, че действието липсва като аргумент на оценката; вариант с $\tilde{Q}(s, a)$ още не е изпълнен, така че резултатът нито опровергава, нито потвърждава ARDT.¹⁵³

12.4 Какво всъщност прави обуславянето по възвръщаемостта в покера


Равновесието и експлоатируемостта на **Кун покер** могат да бъдат изчислени точно (вж. Глава 2),¹⁵⁴ поради което въпросът може да бъде решен, а не само обсъждан. Обуславянето по възвръщаемостта **променя** стратегията съществено, но не я **насочва**: експлоатируемостта остава почти една и съща в целия диапазон на реално постижимите целеви стойности, с изключение на рязък скок (до $\approx 1,9$ жетона) при най-честата печалба, която в Кун е печалбата при пас. На същите данни обикно-

¹⁵³Tang, X., Marques, A., Kamalaruban, P. & Bogunovic, I., *Adversarially Robust Decision Transformer*, NeurIPS 2024 (arXiv:2407.18414) – Section 3 и Algorithm 1.

¹⁵⁴Kuhn, H. W. (1950). “A Simplified Two-Person Poker.” In H. W. Kuhn & A. W. Tucker (Eds.), *Contributions to the Theory of Games*, Vol. I (Annals of Mathematics Studies 24), pp. 97–103. Princeton University Press. DOI 10.1515/9781400881727-010.

веното поведенческо клониране достига експлоатируемост 0,055 жетона – близо до равновесието (0,016) – срещу 0,799 за DT: обуславянето по възвръщаемостта активно унищожава информация (стойността за DT варира между повторни обучения, 0,67–0,80).

Естественото обяснение е, че в игра само с четири възможни стойности на печалбата *големината* на възвръщаемостта кодира коя последователност от залози е изиграна, а *знакът ѝ* – кой е държал по-добрата карта. Следователно обуславянето избира хода на раздаването, а не качеството на играта.



Фигура 71: Резултат на DT в Ледюк Холдем (жетони на раздаване срещу почти равновесен противник) според целевата възвръщаемост, $\pm$ стандартна грешка (Пирсън $r = +0,062$). Прекъсната линия: най-честата възвръщаемост (-1); точкова: недостижима цел (+15).

Ледюк Холдем тества това обяснение с петнадесет стойности на печалбата вместо четири, два рунда на залагане и обща карта. **Спадът при най-честата възвръщаемост изчезва, както предвижда обяснението, но насочване пак не се наблюдава** (Пирсън $r = +0,062$); остават обаче два необяснени спада – при 0 (втората по честота възвръщаемост) и при -5. Следователно обяснението чрез малкия брой възможни печалби обяснява срива, но не и провала, който е по-фундаментален: в игра с нулева сума и непълна информация реализираната възвръщаемост се определя основно от тайната карта и действията на опонента, които агентът не контролира.

Това е основният извод на главата: при обучение върху записани партии DT, обусловен по възвръщаемостта, е неподходящ инструмент, а предимството на преетикетирането при ARDT е, че заменя целева стойност, която агентът не контролира, с такава, която зависи главно от собствените му действия.


12.5 Езикови модели като стратегически агенти

Втората парадигма изцяло пропуска обучението: опишете правилата на английски и оставете езиков модел да играе. Тествани са три модела с отворени тегла, изпълнявани локално (квантизацията на теглата не е записана): gpt-oss-20b, Qwen2.5-7B-Instruct и OpenThinker3-7B (Qwen2.5-7B-Instruct, дообучен за разсъждения). Резултатите са за Qwen2.5-7B-Instruct, ако не е посочено друго; всички са от собствени измервания. Сходни експерименти в Кун, Ледюк и лимитен Холдем показват, че и по-големи модели са далеч от равновесието, а действията им често се разминават със заявените разсъждения¹⁵⁵; изричното разсъждение за противника в подканата позволява на GPT-4 да се адаптира.¹⁵⁶ Измерени със същия точен критерий, големите езикови модели се оказват **действително експлоатируеми**, но по-интересно е *къде* грешат.

Те разбират правилно **ранга** на ръцете, но грешат в **честотите** на смесените стратегии. Всеки от тестваните реални модели залага за стойност с поп с вероятност 1,00, докато изчисленото с CFR равновесие смесва с 0,68, и при обикновена подкана нито един не блъфира с вале в извадка от 24 опита на информационно множество. (В Кун равновесието на първия играч образуват еднопараметрично семейство – блъф с вале с вероятност $\alpha \in [0, 1/3]$ и залог с поп с вероятност 3α ,¹⁵⁴ така че поотделно и двете поведения са равновесни; неравновесна е само комбинацията им.) Модел със 7 млрд. параметъра се представя наравно с gpt-oss-20b – модел със смес от експерти с 21 млрд. параметъра общо, но само 3,6 млрд. активни при всеки токен; при три модела и една опростена игра това не позволява извод за ролята на мащаба.


¹⁵⁵Lin, M., Dai, E., Liu, H. et al., *How Far Are LLMs from Professional Poker Players? Revisiting Game-Theoretic Reasoning with Agentic Tool Use*, ICLR 2026 (arXiv:2602.00528).

¹⁵⁶Guo, J., Yang, B., Yoo, P., Lin, B. Y., Iwasawa, Y. & Matsuo, Y., *Suspicion-Agent: Playing Imperfect Information Games with Theory of Mind Aware GPT-4*, 2023 (arXiv:2309.17277).



Фигура 72: Дял на всяко информационно множество в общата експлоатируемост на Qwen2.5-7B-Instruct в Кун покер (0,357 жетона) и отклонението му от равновесието на Наш (1/2/3 – вале/дама/поп; p – пас, b – залог). Двете подредби почти не си съответстват.


Разлагането на загубата по решение обръща очевидното тълкуване. „Провалът“ с поп – най-голямото видимо отклонение от равновесието – носи само **0,1%** от общата загуба, защото прекомерното залагане с ръка, която никога не е по-слаба, почти не струва нищо. Едно-единствено решение с дама струва **41,4%**. Големината на отклонението и цената му почти не са корелирани – конкретен аргумент при оценяването да се отчита диагностика по отделни решения, а не само едно число за експлоатируемост.



Фигура 73: Заявени и изиграни честоти на залагане на gpt-oss-20b и Qwen2.5-7B-Instruct по информационни множества спрямо равновесието (горе; средно абсолютно отклонение, заявени срещу изиграни: 0,43 срещу 0,33, 0,35 срещу 0,25) и експлоатируемост на двете стратегии (долу).

Питането на модел какво възнамерява е *по-лошо* от измерването на това, което прави. Оценени като стратегии, заявените от тези модели честоти са 2,6 и 4,0 пъти по-експлоатируеми в сравнение със стратегиите, които те реално играят. Един модел отговаря „50%“ почти навсякъде, а другият – „почти 0%“, дори с най-силната ръка. Поведенческото проучване тук не е просто по-удобно от самоанализа – то е по-точно.


12.6 Експлоатация, адаптация и ограничения на опростената игра



Фигура 74: Печалба срещу всеки противник от набора: Qwen2.5-7B-Instruct печели средно 0,177 жетона на раздаване (равновесие 0,110) при експлоатируемост 0,357 (равновесие 0,006).

Мерките за експлоатируемост показват доколко съвършен противник ви наказва; те не казват нищо за това колко добре вие сами наказвате слабостите. Измерено спрямо набор от умишлено експлоатируеми архетипи, езиковият модел **печели средно 0,177 жетона на раздаване срещу 0,110 за равновесната игра (с 61% повече), но експлоатируемостта му е 0,357 жетона срещу 0,006** – и близо 90% от предимството идва от пасивния и случайния противник. Срещу двата най-компетентни архетипа той се представя *по-зле* от равновесието. Това е компромисът между безопасност и експлоатация, с който се занимава вторият принос на дисертацията – тук наблюдаван, а не предположен.

Когато историята на сесията (последните 20 раздавания) е подадена в контекста, моделът **не** се адаптира: срещу тривиално пасивен противник той улавя 83% от наличната експлоатация още в първата половина на сесията и не се подобрява във втората (0,824 срещу 0,827); при другите два противника резултатът не е статистически надежден. Това, което изглежда като моделиране на противника, всъщност е фиксирано априорно убеждение, благоприятстващо разпуснато-агресивна игра. Когато обаче типът на противника е *описан* в подканата, моделите променят честотата на блъфиране с до 0,92 – липсва изводът от историята, а не способността да се реагира на описание.



Фигура 75: Склонност към недопустими действия в Ледюк Холдем (Qwen2.5-7B-Instruct) по категории и ситуации (средно 0,234 от вероятностната маса в 220 информационни множества): почти всичко е отказ от ръката при безплатен чек, във втория рунд.

Накрая опростената игра ласкае тези модели. С един рунд на залагане и една обща карта повече големият езиков модел вече е статистически неразличим от DT, губи средно срещу набора от слаби противници (печели само срещу двата пасивни типа) и насочва приблизително една четвърт от вероятностната си маса към недопустими действия. Този провал се дължи на *едно* погрешно схващане, а не на обща обърканост: моделът иска **да се откаже от ръката, когато може безплатно да направи чек**, почти изключително със слаби ръце без чифт при висока обща карта, и нито веднъж не се опитва да повиши над лимита за залагане. Всеки оптимизъм, произтичащ от опростената игра, е свойство на самата опростена игра.

12.7 Основни изводи за синтеза на дисертацията

- **Обулавянето по величина, която агентът контролира само отчасти, не насочва поведението му.** Наблюдавано е в две опростени игри и съответства на теорема 2.1 на Paster и др.; затова за записани покер партии по-обещаващо е преетикетирането на ARDT, а не самият DT – при условие че се отчетат и случайните ходове (раздаването на картите), при които минимаксната цел на ARDT вече не е точна.¹⁵⁷ Най-вероятно е нужна публикуваната стойност на двойката състояние-действие $\tilde{Q}(s, a)$, а не $V(s)$ – това предстои да се провери.

¹⁵⁷Tang, X., Cheng, Z. & Kumar, S., *Robust Adversarial Reinforcement Learning in Stochastic Games via Sequence Modeling*, Reliable ML Workshop @ NeurIPS 2025 (arXiv:2510.11877) – метод CART; отбелязва, че минимаксната цел на ARDT е точна само при детерминирани преходи.

- **Скаларната оценка не диагностицира, а самоотчетът е по-лош от поведението:** едно решение носи 41,4% от загубата, а най-забележимото отклонение носи 0,1%; заявената стратегия е по-лоша от изиграната за всеки тестван модел.
- **Моделът не изведе противника от историята в контекста** (един модел със 7 млрд. параметъра, прозорец от 20 раздавания), но реагира, когато типът на противника му е съобщен: моделът на противника трябва да се изгради изрично и резултатът му да се подава на стратегията – пряко свързано с първия принос на дисертацията.
- **Протоколът за измерване е част от резултата.** При алчно декодиране (температура 0) езиковият модел играе чиста стратегия и всяка честота дегенерира до 0 или 1; четири открития в тази глава се оказаха измервателни артефакти, всеки от които беше открит чрез евтина проверка спрямо точно изчисливо количество.

13 Глава 13 – Поведенчески анализ на реални истории на раздаванията

Глави 2–12 изследваха игри, които могат да бъдат решени или симулирани, в които всяка стратегия е известна и всеки резултат може да се провери спрямо точна еталонна стойност. Тази глава се обръща към това, което правят реалните хора. Тя взема два милиона раздавания от онлайн покер и пита какво може да се научи за играчите само от записа – чак до това дали два акаунта си помагат и дали даден акаунт е бот. **Всички числа, докладвани тук, са измерени** при възпроизводими изпълнения, с три начални числа навсякъде, където има обучение или извадка. Когато някое изпълнение противоречи на прогнозата от плана, прогнозата е запазена и съпоставена с действителния резултат.

Данните. Всички използвани данни са публични. Наборът от данни PNH¹⁵⁸ съдържа 21,6 милиона анонимизирани раздавания на безлимитен Холдем от юли 2009 г., събрани от шест онлайн зали от HandHQ – доставчик на истории на раздавания. Частта му от iPoker включва **2 032 655 раздавания при блайндове \$0,50/\$1** и тук се използват те. Вторият източник са **10 000-те публикувани раздавания на Pluribus**¹⁵⁹, във всяко от които играят програмата и петима професионалисти. Това е единствената публична извадка, в която ботът е известен, и затова тя е еталонът за откриване на ботове.

Къде се вписва това в дисертацията. Главата е практическото ядро на Принос №1 – рамката за поведенческа адаптация – и покрива страната на данните в тази рамка; самият адаптивен агент е извън обхвата ѝ. Моделиране на противника в реално време с консервативна резервна стратегия вече работи в игри за двама играчи, включително в малки покер игри¹⁶⁰¹⁶¹, а моделиране на противника при N играчи съществува без какъвто и да е критерий за безопасност¹⁶². Следователно на Принос №1 все още липсва вариантът с N играчи, в рамките на една партия и обвързан с безопасността. Главата покрива и задачата за честна игра (fair play) от индивидуалния план – откриването на тайни съглашения и ботове. В литературата откриването на тайни съглашения се

¹⁵⁸Kim, J. (2024). “Recording and Describing Poker Hands.” *IEEE Conference on Games (CoG 2024)*, 1–8. DOI 10.1109/CoG60054.2024.10645611; arXiv:2312.11753 – форматът PNH. Наборът от данни е github.com/uoftcprg/phh-dataset (лиценз MIT; подмножество HandHQ от 21 605 687 безлимитни раздавания, юли 2009 г., шест зали, 5 996 345 от тях в мрежата iPoker).

¹⁵⁹Brown, N. & Sandholm, T. (2019). “Superhuman AI for multiplayer poker.” *Science* 365(6456), 885–890. DOI 10.1126/science.aay2400 – 10 000 раздавания срещу петима от 13 професионалисти, по 100 големи блайнда на раздаване; за стила: влизането с плащане (limping) е „suboptimal for any player except the ‘small blind’ player“, а Pluribus прави донк залози „far more often than professional humans do“.

¹⁶⁰Fu, H., Tian, Y., Yu, H., Liu, W., Wu, S., Xiong, J., Wen, Y., Li, K., Xing, J., Fu, Q. & Yang, W. (2022). “Greedy when Sure and Conservative when Uncertain about the Opponents.” *ICML*, PMLR 162, 6829–6848.

¹⁶¹Caen, A., Winands, M. H. M. & Soemers, D. J. N. J. (2026). “StratFormer: Adaptive Opponent Modeling and Exploitation in Imperfect-Information Games.” *Computers and Games 2026* (приета); arXiv:2604.25796. Вж. също Murgoci, V., Spaan, M. & Oren, Y. (2026). “AlphaExploit: Going beyond the Nash equilibrium in poker by learning to exploit suboptimal play.” arXiv:2605.09150 – и двете работи са за двама играчи.

¹⁶²Ganzfried, S., Wang, K. A. & Chiswick, M. (2024). “Opponent Modeling in Multiplayer Imperfect-Information Games.” *Proc. 6th Int. Conf. Distributed Artificial Intelligence (DAI '24)*, 39–45. DOI 10.1145/3719545.3721108.

оценява офлайн, като задача за откриване¹⁶³¹⁶⁴. Не беше намерен контрапример на твърдението, че нито един от тези методи не обвързва откриването с това, което откриващият агент прави след това. Тази глава също остава от офлайн страната на тази граница.

13.1 От решаването на игри към четенето на записи

Представете си стаята за наблюдение в казино, в която камерите са изключени и е останал само дневникът на крупиеето. Всеки ред гласи нещо от рода на „място 3 вдига до 4, място 5 се отказва“. Управителят на залата, който прочете достатъчно страници, научава навиците на всеки редовен играч и забелязва двама играчи, които никога не вдигат един срещу друг. Забелязва и акаунта, който цял ден играе на три маси с един и същ ритъм. Конвейерът в тази глава е този управител на залата, превърнат в процедура, с едно допълнение, което управителят рядко има: начин да се провери колко често всяко подозрение се оказва вярно.

Дневникът има своите ограничения. В записите на iPoker стековете (жетоните пред всеки играч) са записани като безкрайни, така че ол-инът (all-in) е невидим. Полето за печалбата е нула във всяко раздаване, затова резултатите трябва да се изчисляват наново от действията. Имената на масите са еднакви, а скритите карти (hole cards) са известни само когато бъдат показани, поради което в 86 % от раздаванията няма нито една известна карта. Затова всяка статистика в тази глава е дефинирана върху това, което записът съдържа, и главата го казва там, където това е от значение. По същата причина главата започва с парсер, а не с модел. Грешката при разбора не се проявява шумно; тя тихо поврежда всяко число по-нататък по веригата.


13.2 Данните и парсерът

Парсерът (parser) възпроизвежда всяко раздаване със собствен двигател за безлимитен покер. Втори, независим валидатор е pokerkit – двигател на правилата от автора на формата РНН¹⁶⁵. Обработените раздавания се превръщат в четири продукта от данни и всеки анализ чете един от тях (фигурата на конвейера по-долу).

¹⁶³Mazrooei, P., Archibald, C. & Bowling, M. (2013). “Automating Collusion Detection in Sequential Games.” *AAAI* 27(1), 675–682. DOI 10.1609/aaai.v27i1.8674 – лимитен Холдем с трима играчи, синтетични съучастници. Вж. също Greige, L. и др. (2022). “Collusion Detection in Team-Based Multiplayer Games.” arXiv:2203.05121 (признаци от социалния граф върху реални данни, не за покер).

¹⁶⁴Bonjour, T., Aggarwal, V. & Bhargava, B. (2022). “Information Theoretic Approach to Detect Collusion in Multi-Agent Games.” *UAI*, PMLR 180, 223–232.

¹⁶⁵Kim, J. (2025). “PokerKit: A Comprehensive Python Library for Fine-Grained Multivariant Poker Game Simulations.” *IEEE Transactions on Games* 17(1), 32–39. DOI 10.1109/TG.2023.3325637.




Фигура 76: Конвейерът на главата: историите на раздаванията във формат РНН се възпроизвеждат от парсера и се проверяват от два валидатора; обработените раздавания се превръщат в четири продукта от данни, всеки от които захранва един или два анализа. Червените блокове са анализите за честна игра.

Три конвенции на формата излязоха наяве само защото две независими възпроизвеждания не съвпаднаха: обърнатите блайндове при раздаване между двама играчи, отрицателните блайндове, които са *вноски* (post), а не връщане на пари, и ол-ините, които изглеждат като рунд на залагане, чиито карти са раздадени, но в който няма залози (4,3 % от раздаванията). След като тези конвенции са отчетени, парсерът възпроизвежда 99,77 % от раздаванията от iPoker и всички раздавания на Pluribus.

13.3 Описание на играча: статистиките и колко раздавания изискват те

Покер играчите се описват един друг с няколко статистики от програмите за следене на играта (trackers): колко често играчът доброволно слага пари в пота преди флопа (VPIP), колко често вдига преди флопа (PFR), колко често вдига повторно срещу едно-единствено вдигане (3-bet), колко често вдигналият преди флопа залага и на флопа – продължаващ залог (c-bet), и колко често играч, видял флопа, стига до разкриване на картите (WTSD). Всяка от тях е брой спрямо собствените ѝ *възможности*. 3-bet е възможен само когато играчът е изправен точно пред едно вдигане, затова


честотата на 3-bet се дели на броя на тези ситуации, а не на всички раздавания.



Фигура 77: Класическата карта VPIP × PFR за 2 906-те редовни играчи в iPoker (сиво), 13-те професионалисти от игрите на Pluribus (синьо) и Pluribus (оранжево). Прекъснати линии: разпуснат при $VPIP \geq 27,5 \%$, агресивен при $PFR \geq VPIP / 2$.

Тези 2 906 играчи с поне 500 раздавания (прагът от плана) заемат 84,6 % от всички места в раздаванията. На класическата карта 1 323 от тях са стегнато-агресивни (tight-aggressive, TAG), 730 – разпуснато-пасивни, 462 – стегнато-пасивни и 391 – разпуснато-агресивни (loose-aggressive, LAG).

Колко раздавания изисква всяко число? Честният начин да се отговори е то да се измери. Тестът взема две непресичащи се случайни извадки от по m раздавания от всеки играч, който има поне $2m$, изчислява статистиката върху двете и ги корелира по всички играчи. Статистика, която описва играча, дава една и съща стойност и в двете извадки; статистика, която описва главно картите, не дава.




Фигура 78: Корелация между двете половини (split-half) на шест статистики сред редовните играчи в iPoker в зависимост от броя раздавания във всяка половина (3 начални числа). VPIP и PFR преминават $r = 0,8$ под 100 раздавания, 3-bet – около 500; статистиките след флопа остават под 0,8 и при 1 000.

VPIP достига корелация 0,92 при 100 раздавания на половина, а PFR – 0,87. На 3-bet са нужни около 500 раздавания, за да достигне 0,82. Статистиките след флопа се стабилизират много по-бавно: продължаващият залог и честотата на разкриване на картите са на 0,57 след 500 раздавания и около 0,7 след 1 000, а отказът при продължаващ залог (fold to c-bet) е на 0,25 след 1 000. Емпиричното правило от плана – 500 раздавания за стабилни статистики – е вярно за числата преди флопа и невярно за тези след флопа. Затова главата запазва 500 раздавания като праг за включване и добавя минимален брой *възможности* за всяка статистика. Печалбата при разкриване (win-at-showdown) отпада изцяло, защото картите са известни само при медиана от 41 % от разкриванията на даден редовен играч.

13.4 Колко далеч са реалните играчи от силен еталон

Планът изисква разликата между реалната и равновесната игра – „възможността за експлоатация“, върху която би действал Принос №2. За безлимитен Холдем с шестима играчи не е налично изчислено равновесие. Защитимият еталон е най-силната стратегия за шестима играчи с публични раздавания: собствените честоти на Pluribus в неговите 10 000 раздавания на маса с шестима. Pluribus не е равновесие, а честотната разлика не е очаквана стойност. Тя показва къде би търсил един експлоататор, а не колко би спечелил.



Фигура 79: Медианна разлика спрямо честотите на Pluribus на маса с шестима (в процентни пунктове) за 1 046-те редовни играчи в iPoker с поне 500 раздавания на маса с шестима и за 13-те професионалисти. Редовните играчи защитават големия блайнд много по-рядко и правят продължаващ залог много по-често.


Двете популации се разделят ясно. Осреднен по единадесет честоти преди флопа и на флопа, медианният редовен играч в iPoker се отличава от Pluribus с 9,3 процентни пункта, а медианният професионалист – с 3,9. Само 0,19 % от 1 046-те редовни играчи с достатъчно раздавания на маса с шестима са по-близо до Pluribus от медианния професионалист. Редовните играчи от 2009 г. защитават големия блайнд много по-рядко: медианният им VPIP от големия блайнд е с 22 пункта под този на Pluribus. След флопа правят продължаващ залог с 10,5 пункта по-често и се отказват срещу продължаващ залог със 7,1 пункта по-често. Двете разлики на флопа действат в противоположни посоки: тези играчи залагат на флопа твърде често и се отказват на него твърде често. На езика на Глава 8 това са честотите, спрямо които би се отклонил един безопасен експлоататор.

13.5 Прогнозиране на решенията: поведенческо клониране и капанът на базовата линия

Поведенческото клониране е най-простият модел на поведението: да се предскаже действието, което играчът е избрал, по ситуацията, в която се е намирал. Тук ситуацията е публичното състояние – рунд на залагане, позиция, брой играчи на масата, пот, цена за плащане, досегашните

залози и общите карти. Скрытите карти са изключени при данните от iPoker, защото в 86 % от раздаванията не е известна нито една карта, а там, където са известни, са подбрани по това, че са били показани. Действията са шест класа: отказ, чек, плащане и малък, среден или голям залог или вдигане спрямо пота. Моделът се обучава върху дни 1–18 от месеца и се тества върху дни 19–25, така че тестът е следващата седмица на същите хора.

Планът поставя цел от 55 % точност „при случайна базова линия от 14 %“. Моделът достига 72,0 %, но това число казва малко. Повече от половината решения са откази, а модел, който винаги предсказва най-честото допустимо действие, постига 70,2 %. Информативната величина е приръстът над тази базова линия. Честотна таблица по грубо описание на ситуацията добавя 0,4 пункта, невронната мрежа – 1,4 пункта, а подаването на мрежата на вектора на стила на действащия играч – дванадесет статистики, изчислени само от дните за обучение – добавя още 0,4 пункта. Същият вектор на стила намалява ясно логаритмичната загуба (log-loss) – от 0,800 до 0,751 ната (3 начални числа, стандартна грешка 0,0002). Това е количествената форма на едно твърдение на Принос №1: представянето на това *кой* действа подобрява прогнозата за това какво ще направи той и подобрява калибровката на прогнозата повече, отколкото точността на първия ѝ избор.



Фигура 80: Поведенческо клониране в тестовите дни от iPoker: (а) точност по рундове на залагане за мажоритарната базова линия (majority baseline), честотната таблица, MLP и MLP с вектора на стила (3 начални числа); (б) точност над мажоритарната базова линия по тип играч.

Съпоставка (запазена прогноза → действителен резултат). Планът прогнозираше, че решенията преди флопа ще бъдат най-предсказуеми, бутонът (button) – най-предсказуемата позиция, а стегнато-агресивните играчи – по-предсказуеми от разпуснато-агресивните, а те – повече от слабите разпуснати играчи. Префлопът

наистина е най-предсказуемият рунд на залагане (0,748 срещу 0,626–0,659 след флопа), но мажоритарната базова линия показва същия ред. Бутонът е *най-малко* предсказуемата позиция (0,639), а ранната позиция – най-предсказуемата (0,813). Суровата точност наистина подрежда типовете според прогнозата (стегнато-агресивни 0,786, разпуснато-агресивни 0,650, разпуснато-пасивни 0,642). Измерен *над базовата линия*, редът се обръща: +1,2 пункта за стегнато-агресивните, +4,6 за разпуснато-пасивните и +5,6 за разпуснато-агресивните. Първо заподозрях, че тестови данни са проникнали в обучението, и проверих, че векторът на стила използва само дните за обучение и че тестовата седмица не се припокрива с тях; и двете условия са изпълнени. Прогнозите бъркаха „лесен за предсказване“ с „често се отказва“. Урокът оцелява в по-остра форма: векторът на стила добавя най-много за играчите, които са най-далеч от популацията (+3,2 пункта за разпуснато-пасивните играчи, +0,2 за стегнато-агресивните).

На масата на Pluribus всички скрити карти са известни и същата мрежа достига 81,8 % (84,5 % с вектора на стила, мажоритарна базова линия 69,7 %), с 92,6 % преди флопа. Това е размерът на частта от поведението, която данните от iPoker скриват. Kumar и др.¹⁶⁶ твърдят, че при шумни данни с редки награди офлайн обучението с подкрепление може да превъзхожда клонирането. Записите от покер са точно такива данни, затова тук клонирането се използва само като описание на поведението, а не като стратегия за игра.

13.6 Поведенчески отпечатък: player2vec за покер

Дванадесетте статистики са ръчно съставено обобщение. Подходът player2vec¹⁶⁷ ги заменя с научно обобщение. Всяко събитие в играта става токен, а трансформър (Transformer)¹⁶⁸ се обучава да предсказва маскирани токени по техния контекст, както в BERT¹⁶⁹. Оригиналната статия прилага това към казуална мобилна игра и тълкува клъстерите ѝ качествено; тя не проверява какво улавя вграждането.

При покера всяко раздаване, в което играчът участва, се превръща в кратко изречение: позицията и броят играчи на масата, по един токен за всяко решение и токен за начина, по който е приключило раздаването. 4-слоен кодировчик се обучава върху потока на всеки играч само от дни 1–18.

Какво трябва да улавя вграждането на играча? Най-малкото самия играч. Това дава тест, който не изисква етикети. Всеки играч се вгражда два пъти – веднъж от N раздавания от дните за обуче-


¹⁶⁶Kumar, A., Hong, J., Singh, A. & Levine, S. (2022). “When Should We Prefer Offline Reinforcement Learning Over Behavioral Cloning?” *ICLR 2022*; arXiv:2204.05618.

¹⁶⁷Wang, T., Honari-Jahromi, M., Katsarou, S., Mikheeva, O., Panagiotakopoulos, T., Asadi, S. & Smirnov, O. (2024). “player2vec: A Language Modeling Approach to Understand Player Behavior in Games.” arXiv:2404.04234 (предварителна публикация).

¹⁶⁸Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł. & Polosukhin, I. (2017). “Attention Is All You Need.” *NeurIPS 30*; arXiv:1706.03762.

¹⁶⁹Devlin, J., Chang, M.-W., Lee, K. & Toutanova, K. (2019). “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.” *NAACL-HLT*, 4171–4186. DOI 10.18653/v1/N19-1423.


ние и веднъж от N други раздавания от последната седмица, която моделът никога не е виждал. След това за вектора на всеки играч от последната седмица всички играчи се подреждат по сходство. Въпросът е дали собственият първи вектор на играча ще излезе на първо място. Векторът от статистики минава същия тест.



Фигура 81: Повторно разпознаване (re-identification) в невиджани дни: дял на играчите, чиито собствени по-късни раздавания се класират първи (а) или в първите десет (б), за player2vec и за вектора от статистики, в зависимост от броя раздавания от всяка страна (3 начални числа, ± 1 SE).

Вграждането разпознава играча поне два пъти по-често от статистиките при всеки размер на извадката. При 400 раздавания от всяка страна то класира правилния играч на първо място сред 834 за 15,6 % от тях ($\pm 0,2$, 3 начални числа) и в първите десет – за 45,2 %, срещу 7,1 % и 23,8 % за статистиките; случайното ниво е 0,12 %. При 100 раздавания стойностите са 4,2 % срещу 1,6 %. Повторното разпознаване е и въпросът за множеството акаунти (multi-accounting) – дали един човек може да бъде разпознат в различни акаунти. Отговорът тук е „понякога, от няколкостотин раздавания“: достатъчно, за да се подредят кандидати за преглед от човек, и далеч от доказателство.

Вграждането носи и класическите оси, макар никога да не вижда стойност на VIP. Класификатор по петнадесетте най-близки съседа възстановява квадранта VIP $\times$ PFR на редовния играч от вграждането с 90 % точност – малко повече, отколкото от вектора от статистики, който съдържа VIP и PFR (88 %). Косинусовото сходство е 0,87 в рамките на един квадрант и 0,75 между квадранти, така че проверката от плана „сходството вътре в клъстера е по-голямо от сходството между клъстерите“ е изпълнена.



Фигура 82: UMAP проекция на вгражданията player2vec на 2 906-те редовни играчи в iPoker (начално число 0), по един панел за всеки квадрант VPIP × PFR, в синьо върху всички играчи в сиво.

13.7 Типове, стабилност и онлайн определяне на типа


Планът очакваше четири клъстера на k -средни (k -means), съответстващи на четирите архетипа: стегнато-агресивен, разпуснато-агресивен, стегнато-пасивен („нит“) и разпуснато-пасивен („риба“). Данните нямат четири естествени клъстера. Силуетът (silhouette)¹⁷⁰ – мярка за това колко добре са разделени клъстерите – е 0,16 за два или три клъстера и 0,13 за четири, т.е. навсякъде е нисък. Методът k -средни с четири клъстера е стабилен при различните начални числа (коригиран индекс на Ранд¹⁷¹ 0,94 и 0,97), но това, което намира, са две стегнато-агресивни групи, една разпуснато-агресивна и една разпуснато-пасивна, без стегнато-пасивен клъстер. Стилите на иг-

¹⁷⁰Rousseeuw, P. J. (1987). “Silhouettes: A graphical aid to the interpretation and validation of cluster analysis.” *Journal of Computational and Applied Mathematics* 20, 53–65. DOI 10.1016/0377-0427(87)90125-7.

¹⁷¹Hubert, L. & Arabie, P. (1985). “Comparing partitions.” *Journal of Classification* 2(1), 193–218. DOI 10.1007/BF01908075.

ра образуват континуум с плътно стегнато-агресивно ядро, а „четирите архетипа“ са условност за описанието му.

Остават ли играчите в своя клъстер? Тестът от плана разделя раздаванията на всеки редовен играч на първа и втора половина на месеца и проверява дали двете половини попадат в един и същ клъстер; целта е над 70 %. Измерената стойност е 73,6 % ($\pm 0,2$, 3 начални числа), така че целта е постигната. Един контролен тест показва колко малко казва това: *случайното* разделяне на същите раздавания, което премахва всякаква промяна във времето, дава 78,2 %. Следователно повечето преминавания в друг клъстер са шум от извадката по границите на клъстерите, а истинската промяна през месеца отговаря за около пет пункта.



Фигура 83: (а) Дял на редовните играчи, попаднали в един и същ клъстер на стила в двете половини на своите раздавания – хронологични и случайни половини, заедно със случайното ниво; (б) онлайн байесово определяне на типа: дял на играчите, при които модата на апостериорното разпределение след n раздавания съвпада с по-късния им клъстер.

Клъстерите все пак са полезни като *априорно разпределение* (prior) на онлайн модел, което затваря един цикъл, оставен отворен в плана: данни $\rightarrow$ клъстери $\rightarrow$ априорно разпределение $\rightarrow$ байесово обновяване. Това е байесовото моделиране на противника от Глава 7 и от *Bayes' Bluff*¹⁷², приложено към реални играчи. Четирите клъстера стават четири типа, всеки със собствени честоти на събитията във всяко раздаване. След това апостериорното разпределение (posterior) върху типа на играча се обновява раздаване след раздаване. Истината е клъстерът на *по-късните* раздавания на същия играч, така че тестът не награждава запомнянето на данните, които предсказва. Сред 1 702-мата играчи с поне 1 000 раздавания най-вероятният тип според апостериорното разпределение е верен за 49 % след 10 раздавания, за 62 % след 100 и за 68 % след 500; ако винаги се залага

¹⁷²Southey, F., Bowling, M., Larson, B., Piccione, C., Burch, N., Billings, D. & Rayner, C. (2005). "Bayes' Bluff: Opponent Modelling in Poker." *UAI 2005*, 550–558; arXiv:1207.1411.

на най-големия клъстер, резултатът е 44 %. Две трети от играчите достигат апостериорна вероятност поне 0,9 за по-късния си тип в рамките на 500 раздавания – след медиана от 85 раздавания. Таванът около 70 % е описаната по-горе стабилност във времето: моделът не може да предсказва по-късния клъстер по-надеждно, отколкото играчите остават в него.


13.8 Тайни съглашения: откриване на вмъкнати съучастници в реални сесии

Тайните съглашения (collusion) в онлайн покера имат три класически форми: съучастниците си споделят информация за картите, *играят пасивно* един срещу друг (soft play), като не залагат срещу партньора, или *прехвърлят жетони* (chip dumping), като губят нарочно, за да преместят пари. Няма публични данни с етикети за тайни съглашения. Основните детектори за покер са проверени върху синтетични съучастници¹⁶³¹⁶⁴. Работа върху синтетични тестови среди твърди, че синтетичните данни трябва да са първи, а проверката върху реални случаи – по-късно¹⁷³.

Тази глава запазва еталона синтетичен, но поставя съучастниците в *реални* сесии. За всяко начално число се избират 40 двойки реални играчи, които вече споделят поне 300 раздавания и 30 сблъсъка един срещу друг (heads-up), така че самото им присъствие на една маса да не може да ги издаде. В дял q от сблъсъците им един срещу друг останалата част от раздаването се пренаписва: при пасивната игра и двамата играчи правят чек или плащат до края; при прехвърлянето на жетони единият залага колкото пота, другият вдига до трикратния размер, а първият се отказва. Всяко пренаписано раздаване беше прието и от парсера, и от pokerkit, така че вмъкнатите раздавания са допустим покер, а не шум.

Детекторът пренася идеята за помощ и вреда от Глава 11: да се сравни това, което играчът прави *спрямо партньора*, с това, което прави спрямо всички останали. Спестената вреда е пасивната игра: агресията на играча срещу партньора, стандартизирана спрямо агресията на същия играч, когато остане един срещу един с когото и да е друг. Оказаната помощ е прехвърлянето: потокът от жетони между двамата в раздаванията им един срещу друг, стандартизиран спрямо собственото си разсейване. Резултатът от Глава 11 със сурови броеве на събития е запазен като базова линия. Първото изпълнение маркира двойки с резултат за пасивна игра над 100, всички от *маси* за двама, където двамата играчи се срещат във всяко раздаване: то беше сравнявало играта на маса за двама с оставането един срещу един на маса за шестима, което е различна игра. Основното изпълнение сравнява сходно със сходно и използва само маси с поне трима играчи.

¹⁷³Smed, J., Knuutila, T. & Hakonen, H. (2007). "Towards Swift and Accurate Collusion Detection." *GAME-ON 2007*, 103–107.



Фигура 84: Тайни съглашения, вмъкнати в реални сесии от iPoker (маси с поне трима играчи, 3 начални числа, ± 1 SE): (а) AUC на обединения детектор и на суровия резултат за помощ и вреда от Глава 11 в зависимост от дела на пренаписаните раздавания; (б) дял на откритите двойки при 1 % и 0,1 % фалшиво положителни резултати.

Спрямо 2 802-те реални двойки от същия слой, за които се приема, че са чисти, пасивната игра е по-лесният за откриване модел. Ако една четвърт от сблъсъците са пасивни, детекторът класира двойката съучастници над случайна реална двойка в 94 % от случаите ($AUC\ 0,940 \pm 0,011$) и открива 65 % от двойките при 1 % дял на фалшиво положителните резултати. От половината сблъсъци нагоре той открива всички. Прехвърлянето изисква повече: при 1 % фалшиво положителни резултати се откриват 62 % от двойките, когато половината сблъсъци са прехвърляния, и 97 %, когато всички са такива. Съглашението с ниска интензивност – един сблъсък от десет – остава предимно невидимо (открити са 26 % и 3 %).


Съпоставка (запазена прогноза → действителен резултат). Планът поставяше за цел „открива 100 % от вмъкнатото синтетично съглашение при избрания праг, дял на фалшиво положителните резултати върху данни, за които се знае, че са чисти, $< 5\%$ “. Измерено: целта е постигната за пасивната игра, щом половината сблъсъци са пасивни (дял на фалшиво положителните резултати 0,1 % при пълнота (recall) 90 %), и за прехвърлянето – само когато всеки сблъсък е прехвърляне (0,4 %). Резултатът за помощ и вреда от Глава 11 не се пренася със сурови броеве: неговият AUC е 0,04–0,33 при всяка конфигурация, т.е. по-лош от случайния. Първо заподозрях обърнат знак; кодът

е правилен, а механизмът е в данните. Пасивната игра премахва не само залозите, но и отказите пред партньора, така че помощта намалява заедно с вредата, а прехвърлянето *добавя* залози, които се броят за вреда. Идеята зад детектора оцелява; суровите броеве – не. Той работи, щом всеки играч се сравнява със собственото си поведение и щом се сравнява сходно със сходно.

Най-високите резултати сред реалните двойки – 7,29, 4,71 и 4,16 – са над 99,9-ия перцентил на нулевото разпределение. Те са кандидати за преглед от човек, а не открития; това са данни от 2009 г. без етикети, а по построение една двойка на хиляда е над този перцентил.

13.9 Може ли конвейерът да открие бот?

Ботът в игра между хора е другият проблем на честната игра. Раздаванията на Pluribus позволяват пряк тест: раздаванията на всеки играч се разделят на блокове по 250, на конвейера не се дават етикети и се проверява дали оценките му за аномалност ще отделят блоковете на Pluribus. Математическият флаг в плана прогнозираше, че ботът ще бъде *необичайно последователен*, така че загубата му при предсказване на маскираните токени ще бъде ниска.



Фигура 85: (а) Пет детектора без учител (unsupervised) върху блокове от 250 раздавания от игрите на Pluribus: AUC на блоковете на Pluribus спрямо тези на професионалистите и мястото на Pluribus сред 14 играчи; (б) дял на различните размери на залога сред 50 залога след флопа на всеки играч.

Нито един от петте детектора без учител не открива Pluribus. Isolation Forest („изолираща гора“)¹⁷⁴ върху три набора от признаци, ниската загуба при решенията и разстоянието от популацията на

¹⁷⁴Liu, F. T., Ting, K. M. & Zhou, Z.-H. (2008). “Isolation Forest.” *IEEE International Conference on Data Mining (ICDM)*, 413–422. DOI 10.1109/ICDM.2008.17.

iPoker постигат AUC от 0,298 до 0,475, а Pluribus се класира между 10-о и 14-о място от 14 играчи. Всеки AUC е *под* половината: Pluribus е по-типичен за тези игри от средния професионалист. Загубата му при решенията, 0,691, е в рамките на човешкия диапазон (0,529–0,829). Бот, който играе фиксирана смесена стратегия, е предсказуем по *разпределението* на действията си, а не по самите действия. Ниската загуба би маркирала детерминиран скрипт, а не бот, играещ близо до равновесие.

Погледът с известния етикет показва две неща, които наистина го отличават. Първо, Pluribus залага от малко „меню“ от размери. Сред 50 от залозите му след флопа само 14 % от размерите са различни, срещу 32–67 % при професионалистите, а толкова ниски стойности имат 16 от 1 275 редовни играчи в iPoker (1,3 %). Второ, той избира на случаен принцип при дадени карти. Преди флопа, при фиксирани позиция, ситуация и точна начална ръка, изборът му на действие има ентропия 0,143 ната – най-високата сред деветте играчи с достатъчно данни (при хората 0,059–0,107). Менюто от размери и случайният избор бяха открити при наблюдение на един бот с известен етикет. Те са хипотези, които тепърва трябва да се проверят върху данни с повече известни ботове, а не проверени детектори, и създател на ботове, който ги познава, би могъл да премахне и двата.

13.10 Честни бележки, ограничения и връзка със следващите глави

Какво не се получи и защо това е важно. Четири от очакванията на плана не се потвърдиха върху реални данни. Целите за точност, поставени спрямо случайна базова линия, са безсмислени, когато повечето решения са откази. Четирите учебникови архетипа не са естествени клъстери. Суровият резултат за помощ и вреда от Глава 11 сочи в грешната посока при покера. И силният бот не е отклоняваща се стойност (outlier). Всеки неуспех беше проверен за грешка в кода, преди да бъде приет, и за всеки главата може да посочи механизма.

Ограничения. (1) Данните обхващат един месец от една мрежа през 2009 г.: оттогава играчите, нивата на залозите и софтуерът са се променили и всеки праг трябва да се измери отново, преди да се приложи към съвременна игра. (2) Съглашенията са синтетични и обхващат два предварително програмирани модела. Споделянето на информация – най-честата форма – не е моделирано и не би се проявило в тези сигнали. (3) Незадължителният експеримент с Decision Transformer („трансформър за вземане на решения“) върху реални данни не е изпълнен. Изходите на раздаванията в iPoker са непълни, а за игрите на Pluribus няма симулатор, с който да се оцени стратегия, обусловена по възвръщаемостта. Можеше да се измери само проникването на късмета в стратегията, срещу което предупреждават Paster и др.¹⁷⁵

Връзки с другите глави. Глава 14 се обръща към методологията за оценяване (Принос №3), където досега тайните съглашения се измерваха отделно от играта. Адаптивният агент на дисертацията би използвал онлайн определянето на типа и сигналите за тайни съглашения в самите си

¹⁷⁵Paster, K., McIlraith, S. & Ba, J. (2022). “You Can’t Count on Luck: Why Decision Transformers and RvS Fail in Stochastic Environments.” *NeurIPS* 35, 38966–38979.

решения (приноси №1 и №2) – обвързване, което тази глава не предприема.

13.11 Основни изводи за синтеза на дисертацията

- **Първо разбор, после модел.** Всяка от трите конвенции в данните изкривяваше резултатите, докато не бяха сравнени две независими възпроизвеждания.
- **Всяко число има нужда от своята базова линия и своя размер на извадката.** 72 % точност при действията са 1,8 пункта над „най-честото действие“; 73,6 % стабилност на стила са 4,6 пункта *под* случайното разделяне; VPIP е надеждна статистика след 100 раздавания, а отказът при продължаващ залог не е и след 1 000.
- **Представянето на играча помага (Принос №1).** Векторът на стила на играча намалява загубата на прогнозата от 0,800 до 0,751 ната. Вграждане, научено без етикети, разпознава играча в неவிждани дни в 15,6 % от случаите сред 834 (7,1 % за статистиките, 0,12 % при случаен избор).
- **Стиловете са континуум, а типовете все пак служат като априорно разпределение.** Няма четири естествени клъстера, но онлайн байесов модел върху четири научени типа достига уверено определяне на типа след медиана от 85 раздавания.
- **Откриването на тайни съглашения работи, когато всеки играч се сравнява със самия себе си.** Интензивната пасивна игра и интензивното прехвърляне на жетони се откриват при 1 % фалшиво положителни резултати; съглашението с ниска интензивност – не. Суровите броеве за помощ и вреда не работят при покера.
- **Силният бот не е отклоняваща се стойност.** Детекторите без учител класират Pluribus между 10-о и 14-о място от 14. Отличават го размерите на залозите му и случайният му избор, а това са хипотези, които тепърва трябва да се проверят върху други данни.

14 Глава 14 – Рамки за оценяване и метрики за експлоатируемост

Тази глава разглежда как се оценяват агенти за игри, които **се адаптират** – агенти, които наблюдават противниците си и променят играта си. Тя изгражда стандартния инструментариум – точна експлоатируемост (exploitability), популационни класирания (population rankings) и намаляване на дисперсията (variance reduction) – проверява го и го използва, за да измери какво той пропуска. **Всички експериментални числа са измерени** върху три малки покер игри (Кун покер и Ледюк Холдем за двама играчи и Кун покер за трима) и върху So Long Sucker за четирима играчи от Глава 11, *точно* навсякъде, където играта позволява; когато някое изпълнение противоречи на очакванията ми, запазени са и очакването, и резултатът.

Къде се вписва това в дисертацията. Тази глава е Принос №3 (методология за оценяване). Проверката на литературата от септември 2026 г. стесни този принос: съчетаването на експлоатируемост, популационно класиране и статистическа увереност само по себе си не е ново – еталонен тест (benchmark) с повтаряща се игра „камък-ножица-хартия“ вече оценява възвръщаемостта и експлоатируемостта заедно, за една игра¹⁷⁶. Това, което нито един от намерените протоколи не докладва заедно, е (а) **приръстът** срещу неоптимална популация, (б) **скоростта** на адаптация и **възстановяването** след смяна на стратегията на противника и (в) **най-лошият случай**, а при повече от двама играчи – заместител, който отчита коалициите, всяко от тях с доверителни граници и приложено без промени в няколко игри с непълна информация. Главата изгражда такъв протокол и показва върху конкретни зоопарци от агенти къде съществуващите мерки се провалят. Тя е и мерилото за адаптивните агенти от Глава 7 (Принос №1) и за въпроса, който Глава 8 остави отворен – какво може да означава „безопасно“ при трима играчи (Принос №2).

14.1 Защо оценяването на адаптивен агент е трудно

Един агент за игри може да бъде оценен по два начина. Първият пита *колко тежко може да бъде победен?* В игра с нулева сума за двама играчи отговорът е **експлоатируемостта**: колко под стойността на играта може да го свали противник, който играе най-добър отговор. Вторият пита *колко добре се справя срещу противниците, които ще срещне?*, а отговорите са темпът на печалба в преки срещи и рейтингите – от рейтинга по Ело (Elo)¹⁷⁷ до усредняването по Наш (Nash averaging)¹⁷⁸, α -Rank (еволюционно класиране на агенти)¹⁷⁹ и оценяването чрез гласуване (voting-

¹⁷⁶Lanctot, M., Schultz, J., Burch, N., Smith, M. O., Hennes, D., Anthony, T. & Pérolat, J. (2023). “Population-based Evaluation in Repeated Rock-Paper-Scissors as a Benchmark for Multiagent Reinforcement Learning.” *Transactions on Machine Learning Research*; arXiv:2303.03196 – 43 бота, мачове от 1 000 хвърляния; възвръщаемост срещу популацията, експлоатируемост в рамките на популацията и разликата между тях като обобщен резултат.

¹⁷⁷Elo, A. E. (1978). *The Rating of Chessplayers, Past and Present*. New York: Arco.

¹⁷⁸Balduzzi, D., Tuyls, K., Pérolat, J. & Graepel, T. (2018). “Re-evaluating Evaluation.” *NeurIPS*; arXiv:1806.02643 – рейтингът по Ело се завишава от копия на победени агенти; усредняването по Наш е инвариантно спрямо излишни агенти.

¹⁷⁹Omidshafiei, S., Papadimitriou, C., Piliouras, G., Tuyls, K., Rowland, M., Lespiau, J.-B., Czarnecki, W. M., Lanctot, M., Pérolat, J. & Munos, R. (2019). “ α -Rank: Multi-Agent Evaluation by Evolution.” *Scientific Reports* 9, 9937. DOI 10.1038/s41598-019-45619-9.

based evaluation)¹⁸⁰. Известно е, че двете се разминават: ботове, неразличими в преки срещи, се различаваха с около 1 300 хилядни от големия блайнд на раздаване (mbb/g) по експлоатируемост¹⁸¹, а състезанието по компютърен покер използваше две правила за определяне на победителя¹⁸².

При адаптивния агент разминаването става структурно. Той напуска равновесието умишлено, така че експлоатируемостта може само да работи срещу него, колкото и да печели, а печалбата му зависи от това колко дълго играе и какво е видял, така че той няма една-единствена клетка в матрицата на печалбите, каквато предполагат популационните класирания. При трима или повече играчи най-лошият случай променя смисъла си: NashConv измерва разстоянието до *някакво* равновесие¹⁸³, а в Кун покер с трима играчи един играч може да прехвърля полезност към втори за сметка на третия, докато всички играят равновесни стратегии¹⁸⁴. Единственият най-лош случай при коалиции, който проверката на литературата откри, е отборната максиминна стойност (team-maxmin)¹⁸⁵ – понятие за решение, а не протокол за оценяване.

Помага една аналогия. Когато се наема преговарящ, една препоръка гласи „най-лошата сделка, която безмилостна отсрещна страна би могла да му наложи“, а друга – „как се е справил в последните си двадесет преговора“. Нито една не казва колко бързо той разгадава нова отсрещна страна, дали забелязва смяна на тактиката или дали може да бъде изигран от някого, който първо се прави на наивен, а после обръща играта – нито пък, при три страни, какво става, когато другите две действат координирано. Протоколът на главата задава всички тези въпроси – с интервали на грешката.

14.2 Рамката: три слоя и един четвърти въпрос

Слой 1 е най-лошият случай: точна експлоатируемост в малките игри и научен най-добър отговор в големите¹⁸⁶. **Слой 2** е популацията: печалби от кръгов турнир (round robin), рейтинг по Ело, усредняване по Наш, мета-Наш сместа (глави 9–10), α -Rank, максималните лотарии (maximal

¹⁸⁰Lanctot, M., Larson, K., Bachrach, Y., Marris, L., Li, Z., Bhoopchand, A., Anthony, T., Tanner, B. & Koop, A. (2023). “Evaluating Agents using Social Choice Theory.” *arXiv:2312.03121* (v4, 2025) – Voting-as-Evaluation; препоръчват се максималните лотарии.

¹⁸¹Moravčík, M. и др. (2017). “DeepStack: Expert-level artificial intelligence in heads-up no-limit poker.” *Science* 356(6337), 508–513; arXiv:1701.01724 – отчита също 85 % намаление на стандартното отклонение с AIVAT.

¹⁸²Bard, N., Hawkin, J., Rubin, J. & Zinkevich, M. (2013). “The Annual Computer Poker Competition.” *AI Magazine* 34(2), 112–114 – правила за победителя по общ банкрол (total bankroll) и по последователно отпадане (instant runoff); дублирана игра.


¹⁸³Lanctot, M. и др. (2019). “OpenSpiel: A Framework for Reinforcement Learning in Games.” *arXiv:1908.09453* – NashConv като сума от стимулите на всеки играч да се отклони; експлоатируемост = NashConv / n.

¹⁸⁴Szafron, D., Gibson, R. & Sturtevant, N. (2013). “A Parameterized Family of Equilibrium Profiles for Three-Player Kuhn Poker.” *AAMAS*, 247–254.

¹⁸⁵Celli, A. & Gatti, N. (2018). “Computational Results for Extensive-Form Adversarial Team Games.” *AAAI* 32(1). DOI 10.1609/aaai.v32i1.11462; вж. също Zhang, Y., An, B. & Černý, J. (2021). “Computing Ex Ante Coordinated Team-Maxmin Equilibria in Zero-Sum Multiplayer Extensive-Form Games.” *AAAI* 35(6), 5813–5821.

¹⁸⁶Timbers, F., Bard, N., Lockhart, E., Lanctot, M., Schmid, M., Burch, N., Schrittwieser, J., Hubert, T. & Bowling, M. (2022). “Approximate Exploitability: Learning a Best Response.” *IJCAI*; arXiv:2004.09677.

lotteries) на VasE и декомпозицията „пумпал“ (spinning top)¹⁸⁷¹⁸⁸. **Слой 3** е статистическата увереност (confidence): начални числа, дублирано раздаване на картите (duplicate dealing) и AIVAT (техника за намаляване на дисперсията)¹⁸⁹. Четвъртият въпрос е собственият въпрос на главата: как се държи адаптивният агент *във времето*.



Само контекст: Ело, усредняване по Наш, α -Rank (по α), VasE, „пумпал“

Фигура 86: Обединеният протокол. Зоопарк от агенти, включително противници, които сменят стратегията си или провеждат обучаваща атака, играе дублирани мачове с фиксирани места; всяко раздаване се оценява с три оценки, а четирите показателя се докладват заедно.

Всичко се опира на един точен двигател. Всяка игра се изброява еднократно от дефиницията ѝ в OpenSpiel, така че стратегията е вектор, а очакваната ѝ печалба, най-добрият отговор срещу нея и експозицията ѝ (exposure) са матрични операции (Ледюк: 9 457 възела и 468 информационни множества на играч, изградени за 0,04 s). Адаптивният агент е *последователност* от стратегии, по една за всяко преизчисляване, всяка от които се оценява точно. Двигателят възпроизвежда OpenSpiel, Глава 3 и Глава 7 до грешката от закръгляването (validation.json).

Четирите показателя (readouts) се определят, както следва (навсякъде в жетони на раздаване).

¹⁸⁷Balduzzi, D. и др. (2019). “Open-ended Learning in Symmetric Zero-sum Games.” *ICML*, PMLR 97, 434–443 – транзитивно-цикличната декомпозиция.

¹⁸⁸Czarnecki, W. M., Gidel, G., Tracey, B., Tuyls, K., Omidshafiei, S., Balduzzi, D. & Jaderberg, M. (2020). “Real World Games Look Like Spinning Tops.” *NeurIPS*; arXiv:2004.09468.

¹⁸⁹Burch, N., Schmid, M., Moravčík, M., Morrill, D. & Bowling, M. (2018). “AIVAT: A New Variance Reduction Technique for Agent Evaluation in Imperfect Information Games.” *AAAI* 32(1); arXiv:1612.06915 – неизместена при всяка функция на стойността (теорема 1); в Ледюк – с 48–75 % по-ниско стандартно отклонение при несходни стратегии.

- **Приръст** (gain): очакваната печалба на агента минус тази на равновесния план (blueprint) срещу същия противник на същото място; **реализираният дял** (capture) дели приръста на приръста, който би постигнал точният най-добър отговор.
- **Скорост и възстановяване** (speed and recovery): $h50$ е първото раздаване, при което реализираният дял достига половина и остава на това ниво средно през следващите 100 раздавания; $r50$ е същият брой, отчетен след смяната на противника. Адаптивните агенти преизчисляват стратегията си на всеки 50 раздавания, така че и двете величини са определени с точност до 50 раздавания.
- **Експозиция**: при двама играчи – колко под стойността на играта v^* би могъл да свали действащата стратегия противник, който играе най-добър отговор, т.е. експлоатируемостта, приложена към текущата стратегия, а не към фиксиран агент; плюс реализираната загуба при обучаваща атака тип „бяла кутия“ (white-box teaching attack). При трима играчи – **стойността срещу коалиция** (coalition value): най-малкото, до което другите двама могат да ограничат агента с координирани стратегии.
- **Статистическа увереност**: 95 % интервали по началните числа, като се посочва използваната оценка (estimator). Оценките са три: суровите резултати в жетони; AIVAT при известна собствена стратегия на агента; и *точната по стратегиите* (policy-exact) очаквана печалба на двете действащи стратегии, достъпна само когато и двамата играчи са ботове.

Зоопарците включват 16 агента в Кун и 12 в Ледюк: **равновесния** план (CFR+ на OpenSpiel); **типове, основани на правила**, от Глава 7 (AlwaysPass, AlwaysBet, TightPassive, LooseAggr, Threshold в Кун; CallingStation, Maniac, Rock, LoosePassive в Ледюк), плюс Random; в Кун – три **стратегии, извлечени от езикови модели** в Глава 12 (Qwen2.5-7B-Instruct, gpt-oss-20b и OpenThinker3-7B, разчетени от логаритмичните вероятности на токена за действие; квантизацията не е записана; OpenThinker3-7B е слаб заместител, тъй като 34 % от вероятностната му маса не можаха да бъдат съпоставени с действие); **специалист** – статичен най-добър отговор на един слаб тип; и пет **адаптивни агента**, които съчетават моделите от Глава 7 с отговорите от Глава 8:

- *TypeBR*: байесово апостериорно разпределение върху типовете, срещу което се играе най-добър отговор;
- *DirBR*: непрекъснатият модел на Дирихле, срещу който се играе най-добър отговор;
- *DirBR-CP*: DirBR с нулирането на модела при точка на промяна (change point) от Глава 7;
- *RNR(0,5)*: непрекъснатият модел в ограничен отговор по Наш (restricted Nash response) с $p = 0,5$ ¹⁹⁰;
- *BestEq*: най-доброто равновесие срещу модела – най-много, което агентът може да спечели, без никога да пада под v^* ; това е базовият вариант „най-добро равновесие“ на Ganzfried и Sandholm¹⁹¹.

¹⁹⁰Johanson, M., Zinkevich, M. & Bowling, M. (2007). “Computing Robust Counter-Strategies.” *NIPS 2007* – ограничен отговор по Наш (Restricted Nash Response).

¹⁹¹Ganzfried, S. & Sandholm, T. (2015). “Safe Opponent Exploitation.” *ACM Transactions on Economics and Computation* 3(2), статия 8. DOI 10.1145/2716322 – стратегията на най-доброто равновесие е техният базов вариант; техните безопасни алгоритми рискуват само вече спечелените подаръци.

Цикълът за генериране на ограничения от Глава 8 не достигна сходимост за последните два върху пълния Ледюк. Тук те се решават с двойствената задача на линейното програмиране в последователна форма¹⁹²¹⁹³: по една LP-задача за всеки метод решава пълния Ледюк за 0,02–0,04 s и възпроизвежда резултатите от Глава 8 за Кун.

14.3 Слой 2 – класиранията се разминават по предвидим начин

Всяка двойка играе мачове от 2 000 раздавания на двете места с дублирани карти при 10 начални числа (стационарните двойки – точно); рейтингът по Ело се напасва към вероятността сесия от 100 раздавания да завърши на печалба (`population_{kuhn,leduc}.json`).

DirBR	10	2	1	2	6	4	4	5
RNR(0,5)	3	1	2	1	5	3	1	4
TypeBR	8	6	3	7	3	5	6	3
BR-Rock	5	5	4	6	4	5	5	7
DirBR-CP	12	7	5	5	8	5	7	6
BestEq	1	3	6	3	1	1	2	2
„Наш“	1	4	7	4	1	2	3	1
Rock	4	8	8	8	7	8	8	7
LoosePassive	7	9	9	9	10	9	9	7
CallingStation	6	11	10	10	11	11	9	7
Maniac	9	10	11	11	9	10	9	7
Random	11	12	12	12	12	12	9	7

метод на класиране (място 1 = най-добро)


Фигура 87: Място на всеки агент в Ледюк според осем метода (1 = най-добро). RNR(0,5) и DirBR водят по Ело, по възвръщаемост срещу популацията и по RRPS; BestEq и „Наш“ водят по експлоатируемост и по усредняване по Наш.

¹⁹²Koller, D., Megiddo, N. & von Stengel, B. (1996). "Efficient Computation of Equilibria for Extensive Two-Person Games." *Games and Economic Behavior* 14(2), 247–259.

¹⁹³von Stengel, B. (1996). "Efficient Computation of Behavior Strategies." *Games and Economic Behavior* 14(2), 220–246 – последователната форма.

Класиранията се делят на два лагера. **Експлоатируемостта, усредняването по Наш и VasE** предпочитат агенти, които никога не губят: в Ледюк сместа на Наш с максимална ентропия в мета-играта е BestEq 0,88, „Наш“ 0,11, TypeBR 0,01, а RNR(0,5) и DirBR получават нулево тегло въпреки най-високата възвръщаемост срещу популацията (population return) (+0,807 и +0,890 жетона на раздаване). **Ело, възвръщаемостта срещу популацията и резултатът RRPS** предпочитат агенти, които побеждават много противници: подредбата по Ело в Ледюк е RNR(0,5) 1892, DirBR 1848, BestEq 1779, „Наш“ 1763. Корелацията на Кендъл между класиранията по Ело и по експлоатируемост е 0,45 в Кун и 0,36 в Ледюк. За експлоатиращ агент двата въпроса имат противоположни отговори, а едно-единствено класиране мълчаливо избира единия.

Проявяват се още три предвидени режима на отказ (failure modes). **Клонингите завишават рейтинга по Ело.** Добавянето на до осем копия на най-слабия бот увеличава преднината на DirBR пред „Наш“ по Ело от +166 на +181 точки в Кун и от +84 на +113 в Ледюк, докато нито една оценка на уменията чрез усредняване по Наш не се променя с повече от $6e-6$ ¹⁷⁸. **α -Rank зависи от α .** При нарастване на α от 0,01 до 100 в Кун водят три различни агента (DirBR, RNR(0,5), „Наш“), а в Ледюк – четири (DirBR, RNR(0,5), BestEq, „Наш“). **Хоризонтът има значение.** Съкращаването на същите изпълнения до 100 раздавания поставя TypeBR на първо място по Ело в Кун, а *статичния* специалист BR-Rock – в Ледюк; от 300 раздавания нататък водят DirBR-CP, после DirBR (Кун) и RNR(0,5) (Ледюк). Мястото на адаптивния агент в мета-играта е определено едва когато продължителността на мача е фиксирана.



Фигура 88: Маса по α -Rank на основните агенти при нарастване на селекционния натиск (selection pressure) α ; водачеството преминава от DirBR през RNR(0,5) към „Наш“ в Кун и през BestEq към „Наш“ в Ледюк.

Увереността в класиранията също е неравномерна: при 200 повторни извадки от началните числа Ело запазва победителя си в Кун всеки път, а α -Rank при $\alpha = 10$ – само в 22 %, защото почти равностойните равновесни агенти правят върха му нестабилен¹⁹⁴. А рейтинг в стила на арените за езикови модели подрежда погрешно стратегиите, извлечени от езикови модели: Ело поставя стратегията на Qwen2.5-7B на 7-о място от 16, а бота Threshold – на 10-о, въпреки че експлоатируемостта на Qwen е 0,179 жетона на раздаване срещу 0,118 за Threshold (стойността 0,357 от Глава 12 е NashConv; тук – NashConv/2). Арените за езикови модели, които класират само по рейтинг, наследяват този проблем.

14.4 Слой 3 – статистическата увереност и какво показва AIVAT

AIVAT коригира резултата от всяко раздаване с контролни променливи (control variates) за случайните събития и за действията на всеки играч, чиято стратегия е известна, плюс „въображаеми наблюдения“ върху останалите възможни частни карти на този играч; оценката е неизместена при всяка функция на стойността¹⁸⁹. Изчисляването на стойността на AIVAT за всяко крайно състояние еднократно за всяка стратегия дава *точните* средна стойност и дисперсия на оценката.


Първата реализация имаше истинска грешка и проверката, която я улови, си заслужава да бъде запазена: когато и двете стратегии са известни и функцията на стойността е съвършена, дисперсията на AIVAT трябва да е нула. Тя не беше: раздаването на собствената карта на известния играч беше получило член за корекция на случайността, макар че въображаемите наблюдения вече усредняват по тази карта, така че късметът ѝ се отчиташе два пъти. Премахването му възстанови точно нулевата дисперсия и направи реалистичния вариант – само със собствената стратегия на агента известна – по-добър навсякъде от корекцията само на случайността.

Със стойностите на плана при игра срещу себе си като функция на стойността целите на плана на главата – дисперсията да намалее поне 5 пъти в Кун и 10 пъти в Ледюк – са постигнати за 18 от 20 двойки в Кун (медианен коефициент 48) и за 7 от 12 двойки в Ледюк (медиана 12,2); пропуските са противници, чиято игра стойностите от играта срещу себе си предсказват лошо. AIVAT не може да се използва за хора, чиято стратегия е неизвестна¹⁹⁵, а функцията му на стойността трябва да бъде фиксирана, преди данните да бъдат видени¹⁹⁶ – тук това е планът.

¹⁹⁴Rowland, M., Omidshafiei, S., Tuyls, K., Pérolat, J., Valko, M., Piliouras, G. & Munos, R. (2019). “Multiagent Evaluation under Incomplete Information.” *NeurIPS*; arXiv:1909.09849.

¹⁹⁵Brown, N. & Sandholm, T. (2019). “Superhuman AI for multiplayer poker.” *Science* 365(6456), 885–890. DOI 10.1126/science.aay2400 – 48 mbb/g, стандартна грешка 25, при 10 000 раздавания; AIVAT не може да се приложи към играчите хора.

¹⁹⁶Kim, J. & Sandholm, T. (2026). “Heuristic Pathologies and Further Variance Reduction via Uncertainty Propagation in the AIVAT Family of Techniques.” *arXiv:2605.14261*.



Фигура 89: Дял от постижимия приръст, оценен в прозорци от 100 раздавания по суровите резултати, чрез AIVAT и по точните стойности на стратегиите, за DirBR срещу LooseAggr (Кун) и Maniac (Ледюк); средно ± 1 стандартно отклонение по 20 мача.

Измерването на *адаптацията* вместо на крайния темп на печалба рязко повишава цената, защото интересуващата ни величина се съдържа в кратки прозорци. За да се оцени реализираният дял в един прозорец от 100 раздавания с точност $\pm 0,25$ при доверителна вероятност 95 %, на медианната двойка агент–противник са нужни 3 383 раздавания със суровите резултати в Кун и 379 с AIVAT; в Ледюк – 1 313 и 354. При реални данни 10 000-те публикувани раздавания на Pluribus (Глава 13) дават суров темп на печалба $-70,9 \pm 172,8$ mbb/g (95 % интервал) срещу 48 mbb/g със стандартна грешка 25 с AIVAT и стратегията на Pluribus¹⁹⁵. Трета страна, която разполага само с историите на раздаванията, не може да достигне статистическа значимост за темпа на печалба, камо ли за това колко бързо агентът се адаптира.


14.5 Обединеният протокол в Кун и Ледюк

Седем агента играха срещу всеки неоптимален стационарен член на зоопарка, срещу три противника, които сменят стратегията си на раздаване 1 000 от 2 000, и срещу три обучаващи атаки, всяко условие при 10 начални числа на двете места (`adaptation_{kuhn,leduc}.json`). Обучаващата атака играе примамваща стратегия до раздаване 1 000, а след това – точния най-добър отговор на текущата стратегия на агента, обновяван на всеки 50 раздавания; това е сценарият „обучен, после

експлоатиран“, който стои зад безопасността на адаптацията (adaptation safety)¹⁹⁷.

Таблица 39: Приръст срещу неоптималната популация, средна експозиция на действащата стратегия и загуба под v^* след обучаваща атака в Кун (К) и Ледюк (Л), в жетони на раздаване. 95 % интервали на приръстите не надхвърлят 0,007.

Агент	Приръст К	Експозиция К	Загуба от атака К	Приръст Л	Експозиция Л	Загуба от атака Л
„Наш“	0	0,000	0,000	0	0,000	0,000
BestEq	+0,020	0,000	0,000	+0,047	0,000	0,000
RNR(0,5)	+0,210	0,090	0,045	+0,797	0,264	0,179
DirBR	+0,273	0,338	0,246	+0,988	2,461	1,241
DirBR-CP	+0,230	0,305	0,199	+0,441	2,459	1,757
TypeBR	+0,229	0,352	0,337	+0,961	1,885	2,000




Фигура 90: Приръст спрямо равновесния план („Наш“) срещу неоптималната популация в зависимост от експозицията. Интервалите на грешката са 95 % интервали по 10 начални числа и са по-малки от маркерите.

Разгледани заедно, числата разделят агенти, които всяко отделно класиране смесва. **BestEq** е безопасен по конструкция и не печели почти нищо: 0,020 и 0,047 жетона на раздаване. **RNR(0,5)** печели от 10 до 17 пъти повече при експозиция 0,090 в Кун и 0,264 в Ледюк и губи най-много 0,274

¹⁹⁷Ge, Z., Xu, Z., Ding, T., Meng, L., An, B., Li, W. & Gao, Y. (2024). “Safe and Robust Subgame Exploitation in Imperfect Information Games.” *ICML*, PMLR 235, 15255–15270 – безопасност на адаптацията и проблемът „обучен и експлоатиран“.

жетона на раздаване при която и да е обучаваща атака. **DirBR** печели още малко повече (0,988 в Ледюк), но при експозиция 2,46 – почти тридесет пъти стойността на играта – а обучаващият нападател си връща 1,0–1,5 жетона на раздаване. Експлоатируемостта поставя BestEq и „Наш“ на първо място; Ело ги подрежда обратно. Само двойката (приръст, експозиция) показва, че RNR(0,5) купува по-голямата част от приръста срещу малък, измерен риск. Експозицията е и горната обвивка на загубата от обучаващата атака: нападател, синхронизиран с преизчисляванията, взема точно експозицията на текущата стратегия, а измерените загуби са равни на нея за всички агенти освен DirBR-CP, чиито нулирания правят отговора на нападателя остарял.



Фигура 91: Горе: приръст спрямо „Наш“, когато противникът сменя стратегията си на раздаване 1 000. Долу: очаквана печалба минус стойността на играта при обучаваща атака (примамка до раздаване 1 000, а след това точният най-добър отговор, обновяван на всеки 50 раздавания).


Скоростта и възстановяването разделят агенти със сходен приръст. В Кун всеки адаптивен агент

достига половината от постижимия приръст при първото преизчисляване (медиана $h50 = 50$ раздавания) – в 100 % от мачовете за DirBR-CP и до 73 % за RNR(0,5). След смяната в Кун от TightPassive на LooseAggr, при която старата експлоатация се проваля, DirBR-CP се възстановява за медиана от 50 раздавания, RNR(0,5) – за 400 (30 % от мачовете), DirBR – за 850 (45 %), а TypeBR, чието апостериорно разпределение е поело 1 000 раздавания на TightPassive, изобщо не се възстановява. Експлоататорът с откриване на точка на промяна показва защо една игра не е достатъчна: в Кун той се възстановява най-бързо и губи най-малко от обучаващата атака сред агентите с най-добър отговор; в Ледюк детекторът му се задейства срещу *стационарни* противници, той реализира само 0,34 от постижимия приръст и губи 1,76 жетона на раздаване при обучаващата атака срещу 1,24 за DirBR.

14.6 Приблизителни най-добри отговори и резултатът RRPS

В игри, които са твърде големи, за да бъдат обходени изцяло, експлоатируемостта се оценява чрез научаване на най-добър отговор, което дава долна граница¹⁸⁶¹⁹⁸; Кун и Ледюк позволяват точна проверка.

¹⁹⁸Lisý, V. & Bowling, M. (2017). “Equilibrium Approximation Quality of Current No-Limit Poker Bots.” *AAAI-17 Workshop on Computer Poker and Imperfect Information Games*; arXiv:1612.07547 – локален най-добър отговор, долна граница на експлоатируемостта.




Фигура 92: Експлоатируемост, открита от научен най-добър отговор (таблично управление по метода Монте Карло, $\epsilon = 0,1$), разделена на точната експлоатируемост, при нарастване на бюджета за обучение; средно по 3 начални числа и двете места.

В Кун обучаващият се агент попада в рамките на 4 % от точната стойност до 10^4 раздавания за всеки от атакуваните ботове; в Ледюк той достига от 71 % (Rock) до 98 % (CallingStation) след 10^5 раздавания на място, а след 10^3 раздавания губи срещу Rock и Maniac, така че оценяващ с ограничен бюджет би обявил и двата бота за безопасни. Срещу адаптивните агенти разликата е още по-рязка: същият обучаващ се агент, играейки онлайн мач от 2 000 раздавания, не нанася никакви щети в Ледюк (агентите печелят срещу него 0,35–0,86 жетона на раздаване над стойността на играта), докато атаката тип „бяла кутия“ взема 1,0–1,5 от DirBR. Експлоатируемостта в рамките на популацията (within-population exploitability) от еталонния тест RRPS има същото сяпо петно: тя е 0,279 жетона на раздаване за DirBR в Ледюк срещу експозиция 2,461 и поставя DirBR на второ място от дванадесет. Противниковите стратегии (adversarial policies) срещу свръхчовешки програми за Го са версията на тази находка в голям мащаб¹⁹⁹. Числото на един експлоататор означава малко без неговия бюджет и сила.

¹⁹⁹Wang, T. T., Gleave, A., Tseng, T., Pelrine, K., Belrose, N., Miller, J., Dennis, M. D., Duan, Y., Pogrebnik, V., Levine, S. & Russell, S. (2023). “Adversarial Policies Beat Superhuman Go AIs.” *ICML*, PMLR 202, 35655–35739.

14.7 Трима и четирима играчи

При трима играчи протоколът се променя на едно място – в най-лошия случай. Петте приблизителни равновесия на Кун покер с трима играчи (CFR, CFR+ и MCCFR при три начални числа) имат почти нулев NashConv, но не са взаимозаменяеми: полезността се премества между местата в рамките на множеството от равновесия, както Szafron и др. описват¹⁸⁴, а профили, съчетаващи компоненти от различни решавачи, достигат NashConv 0,125. Още по-лошо, компонентата на едно равновесие не гарантира нищо срещу двойка. Стойността ѝ срещу коалиция се изчислява точно, като се изброяват 2^{16} -те чисти стратегии на единия член, а другият играе най-добър отговор. За равновесията от CFR и CFR+ тя е от -0,094 до -0,125 жетона на раздаване при равновесни стойности от -0,029 до +0,050 (npplayer_kuhn3.json).



Фигура 93: Вляво: равновесната стойност и стойността срещу коалиция на всяко място в равновесията от CFR+ и CFR. Вдясно: „Наш“, Blend3P и DirBR3P срещу фиксирана двойка съучастници, при коалиционна обучаваща атака, и крайната им стойност срещу коалиция.

Адаптивният агент за трима играчи DirBR3P разширява непрекъснатия модел от Глава 7 до двама противници и играе най-добър отговор срещу моделираната двойка. Срещу независими неоптимални двойки той постига приръст $+0,372 \pm 0,038$ жетона на раздаване спрямо плана (реализиран дял 0,99 в рамките на 50 раздавания), а възвръщаемостта срещу популацията, Ело по дял на победите, α -Rank при $\alpha = 0,1$ и усредняването по Наш го поставят на първо място. Показателят, който отчита коалициите, не е съгласен. Срещу двама противници, които примамват до раздаване 1 000, а след това играят точния коалиционен най-добър отговор на текущата му стратегия, DirBR3P получава -0,466 жетона на раздаване – четири пъти колкото -0,119 на плана; стойността срещу коалиция на крайната му стратегия е -0,386. Смесването с плана (Blend3P) намалява приблизително наполовина и приръста, и загубата от обучаващата атака (+0,213; -0,242). Фиксирана двойка съучастници, насочена срещу плана, струва на плана 0,119 на раздаване, но самата тя е експло-

атируема: DirBR3P печели +0,354 срещу нея. Адаптацията е защита срещу *статична* коалиция и слабост срещу адаптивна. Никое класиране, изградено от противници, седнали на масата независимо един от друг, не може да ги различи – това е режим на отказ 8 в анализа на пропуските.

So Long Sucker поддържа само популационния слой: транзитивното съотношение на проекцията върху двойки е 0,955 и усредняването по Наш избира „предателя“, но предварително зададен съюз намалява дела на победите на наблюдавания базов агент само с 0,8–1,9 процентни пункта, тъй като около 99,5 % от случайните игри завършват с пат (Глава 11).

14.8 Къде съществуващото оценяване се проваля – контролен списък

Таблица 40: Режимите на отказ от `lit_evaluation.md` (точка 6, наборите за проверка на обобщаването, се отнася до кооперативни среди и не се проверява тук) и какво измери тази глава.

Режим на отказ (анализ на пропуските)	Доказателство в тази глава	Какво докладва протоколът вместо това
1. Експлоатируемостта само наказва адаптацията	BestEq дели първото място по експлоатируемост с „Наш“ при приръст 0,02–0,05	приръст и експозиция като двойка
2. Експлоатируемостта няма смисъл при N играчи	компоненти с $\text{NashConv} \approx 0$ губят с 0,06–0,17 повече срещу двойка	точната стойност срещу коалиция
3. Приблизителните най-добри отговори са долни граници	обучаващият се агент е на загуба след 10^3 раздавания; онлайн обучаващият се агент не открива нищо	точна експозиция; посочен бюджет на експлоататора
4. Класиранията надценяват или подценяват експлоатацията	клонингите, α и хоризонтът сменят победителя	класиранията се докладват като контекст
5. Дисперсията се натрупва с адаптацията	3 383 срещу 379 раздавания на прозорец; $\text{Pluribus} \pm 173$	посочена оценка; AIVAT, където е възможно
7. Измамните противници не се проверяват	обучаващата атака взема 1,0–2,2 жетона на раздаване в Ледюк	загуба от обучаващата атака

Режим на отказ (анализ на пропуските)	Доказателство в тази глава	Какво докладва протоколът вместо това
8. Тайните съглашения се оценяват отделно от играта	DirBR3P е първи по възвръщаемост, Ело и усредняване по Наш; -0,47 срещу коалиция	коалиционна обучаваща атака
9. Арените за езикови модели наследяват горното	Ело поставя стратегията на Qwen над по-малко експлоатируем бот	същите показатели за агентите с езикови модели

14.9 Честни бележки, ограничения и връзка със следващите глави

Какво не се получи и защо това е важно. Всяка точна величина съвпада с независим еталон, но три прогнози от плана на главата не се потвърдиха и са запазени във вида, в който са формулирани: „Random губи от всички“ (в Кун той побеждава AlwaysPass); „AIVAT $\geq 10\times$ в Ледюк“ (7 от 12 двойки); „приблизителната стойност е в рамките на 10 % в Ледюк“ (4 от 6 атакувани бота и само при 10^5 раздавания). Две от собствените ми грешки в реализацията бяха уловени от проверки, а не случайно: двойното отчитане в AIVAT и решавач за усредняване по Наш, който връщаше недопустими „оптимални“ точки при почти равностойни агенти, докато не беше заменен с фиксирано допустимо отклонение и LP-задачи върху носителя.

Ограничения. Това са опростени (учебни) игри. Точният най-лош случай и точната стойност срещу коалиция (2^{16} стратегии на член) съществуват само защото игрите са миниатюрни; в голям мащаб научен нападател дава само долна граница и за двете. Точната по стратегиите оценка съществува само за ботове. Обучаващият нападател тип „бяла кутия“ е силен противник, но не и най-лошият адаптивен. Адаптивните агенти са базовите методи от глави 7–8: протоколът *измерва* липсващата граница на загубата при N играчи, но не я осигурява. So Long Sucker е слабо доказателство.

Връзки с другите глави. Двигателят обединява резултати от глави 3, 7, 8 (вече като една LP-задача), 10, 11 и 12. За Принос №2 той дава измерването, което безопасен агент за N играчи трябва да издържи – приръст срещу независими двойки, стойност срещу коалиция и загуба от коалиционна обучаваща атака – а еднократно решаваната LP-задача премахва препятствието пред мащабирането, на което се натъкна Глава 8.

14.10 Основни изводи за синтеза на дисертацията

- **За експлоатиращите агенти експлоатируемостта и класиранията дават противоположни отговори.** В един и същ зоопарк в Ледюк BestEq и „Наш“ водят по експлоатируемост и по усредняване по Наш; RNR(0,5) и DirBR водят по Ело, по възвръщаемост срещу популацията и по резултата RRPS. Ранговата корелация между Ело и експлоатируемостта е 0,36.
- **Приръстът и експозицията, докладвани заедно, разделят това, което отделните числа смесват.** В Ледюк BestEq постига 0,047 при нулева експозиция, RNR(0,5) – +0,797 при 0,264, DirBR – +0,988 при 2,461.
- **При трима играчи най-лошият случай трябва да отчита коалициите.** Компонентите на равновесията ($\text{NashConv} \approx 0$) губят срещу координирана двойка с 0,06–0,17 жетона на раздаване повече; DirBR3P е първи по популационните показатели и губи 0,47 при коалиционна обучаваща атака.
- **Статистическата увереност е основното ограничение при измерването на адаптацията.** Оценката по прозорци изисква около 3 400 раздавания със суровите резултати срещу около 380 с AIVAT в Кун; при публикуваните раздавания на Pluribus суровият 95 % интервал е $\pm 173 \text{ mbb/g}$.
- **Докладваните експлоататори се нуждаят от посочен бюджет.** Научен най-добър отговор обявява два експлоатируеми бота в Ледюк за безопасни след 10^3 раздавания, а експлоатируемостта в рамките на популацията подценява експозицията на DirBR деветкратно.
- **Твърдението на Принос №3 остава тясно.** Отделните части съществуват; главата добавя съвместното им прилагане без промени в игри с непълна информация за двама и за трима играчи и показва къде се проваля всяка от съществуващите мерки – засега само върху опростени игри.