

Глава 1 Резюме – Основи на обучението с подкрепление

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

April 2026

Проблем. Всичко по-нататък в този план – намиране на равновесие с невронни мрежи (Глава 5), изпълнителният механизъм с модел на противника (Глави 7–8), многоагентно обучение (Глава 9) – се основава на мрежи за стойност, градиенти на стратегията и повторение на натрупан опит. Глава 1 полага основите: как един агент подобрява стратегията си само въз основа на награда в напълно наблюдаема едноагентна среда, преди тази картина да бъде усложнена от втори, скрит, състезателен играч. Тя косвено подпомага Принос №1 (архитектурните модели се използват повторно от адаптивния модел на противника) и пряко осигурява понятийния апарат за реализацията, който всяка следваща глава предполага.

Подход. По един алгоритъм от всяко семейство, написан от нулата в PyTorch: **DQN** (базиран на стойността, с обучение извън текущата стратегия) върху CartPole-v1 – Q-мрежа [4->128->128->2], кръгов буфер за повторение на опит, замразена целева мрежа, синхронизирана на всеки 5 епизода – и **PPO** (градиент на стратегията, обучение по текущата стратегия) върху LunarLander-v3 – отделен актьор [8->128->128->4] и оценител, GAE ($\lambda=0.95$) чрез обратно обхождане, изрязана сурогатна цел при $\epsilon=0.2$. Всеки от тях беше сравнен с аналога си от **Stable-Baselines3** (PPO – при същите основни хиперпараметри и същия бюджет от 500 хил. стъпки; DQN – с настроените за CartPole стойности от RL Zoo при 100 хил. стъпки, изпълнение от 6 април 2026 г.), като резултатът се оценява по най-добрата плъзгаща се средна за 100 епизода, така че ранното спиране да не може да повлияе на крайния резултат. **Всички числа по-долу са измерени.**

Ключови резултати (измерени).

- *И двете цели са постигнати.* DQN решава **CartPole** на **епизод 1011**, със средна стойност за 100 епизода **477,5** (цел 475); PPO решава **LunarLander** на **264 192 стъпки** при **202,2** (цел 200) – 236 хил. стъпки преди изчерпването на бюджета.
- *Версиите, написани от нулата, постигат по-високи резултати от изпълненията на SB3 при тези задачи.* Най-добра плъзгаща се средна за 100 епизода: DQN **477,5 срещу 222,4**, PPO **203,6 срещу 131,2**. Причините не са проверени: всяка страна е изпълнена веднъж (нашата – без фиксирано начално число), а DQN на SB3 с настройките на Zoo не достига целта при бюджет, два пъти по-голям от техните 50 хил. стъпки, което трябва да се провери с второ начално число, преди да се тълкува като свойство на SB3.
- *$\epsilon_{\text{ps_min}}$ беше решаващият параметър за DQN.* При стойност 0,01 изпълнението достигна връх от **479,1** (епизод 810) и спадна до **302,6**; стойност 0,001 заедно със запазването на най-добрия модел превърна влошаващата се стратегия в стабилна.
- *Капацитетът, а не бюджетът, беше тясното място за PPO.* [64, 64] достигна връх от **179,9** и никога не премина 200; [128, 128] го преодоля. Нормализирането на предимството беше използвано навсякъде (наградите са в диапазона от -500 до +300), а без **бонус за ентропия** от 0,01 стратегията колабираше до задържане на място.
- *Честно тълкуване на сравнението.* PPO на SB3 все още се покачваше при 500 хил. стъпки и вероятно би достигнал целта при 1–2 млн. стъпки, а базовият DQN е едно-единствено изпълнение с настроени параметри. Твърдението е за предимство при тези конкретни задачи, а не за по-добър алгоритъм.

Връзка с дисертацията. Стекът от 300–500 реда (срещу около 10 000 при SB3) е съзнателно платената цена за висока степен на модифицируемост: вмъкването на наблюдения на състоянието на убежденията в актьор-оценител изисква дълбоко подклаждане в рамките на SB3, докато тук това се свежда до локална редакция – точно от което има нужда работата по експлоатацията в глави 7–8. Същата двойка актьор-оценител се използва отново като MAPPO/MADDPG в глава 9, а механизмът на мрежата за стойност се появява повторно като мрежа за предимства на Deer CFR в глава 5.

Отворени въпроси. Предположението на MDP, което прави всичко това възможно – напълно наблюдаемо състояние – е именно това, което покерът нарушава: върху информационно множество стойността на действието зависи от стратегията на противника, която се променя, докато той се учи, а алчният $\max$ на DQN не може да изрази смесените стратегии, които изисква равновесната игра; затова глава 2 сменя инструмента, а не мащаба. Остава отворен въпросът: доколко от набора инструменти за стабилност при един агент (целеви мрежи, доверителни области, нормализиране на предимството) се запазва, когато средата сама по себе си е учаш се агент (отложено за нестационарността в глава 9), и дали измереното тук предимство в ефективността по отношение на данните е реално свойство или артефакт на две малки, добре обусловени задачи за управление.