

Стъпка 1 Резюме - Основи на обучението с подкрепление

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

April 2026

Проблем. Всичко по-нататък в този план - намиране на **невронно** равновесие (Стъпка 5), изпълнителният механизъм с модел на противника (Стъпки 7–8), многоагентно обучение (Стъпка 9) - се основава на мрежи за стойност, градиенти на стратегията и повторение на натрупан опит. Стъпка 1 полага основите: как един агент подобрява стратегията си само въз основа на награда в напълно наблюдаема едноагентна среда, преди тази картина да бъде усложнена от втори, скрит, състезателен играч. Тя косвено подпомага Принос №1 (архитектурните модели се използват повторно от адаптивния модел на противника) и директно осигурява речниковия запас за изпълнение, който всяка следваща стъпка предполага.

Подход. По един алгоритъм от всяко семейство, написан от нулата в pyTorch: **DQN** (базиран на стойност, извънполитиков) върху cartPole-v1 - q-мрежа [4->128->128->2], кръгов буфер за повторение на опит, замразена целева мрежа, синхронизирана на всеки 5 епизода - и **PPO** (градиент на политиката, политика на работа) върху lunarLander-v3 - отделен актьор [8->128->128->4] и оценител, GAE ($\lambda=0.95$) чрез обратно обхождане, изрязан заместител при $\epsilon=0.2$. Всеки от тях беше сравнен с неговия аналог от **stable-Baselines3** при съответстващи основни хиперпараметри и бюджети за стъпки (DQN 750K, PPO 500K), като резултатът се оценява по най-доброто плъзгащо средно от 100, така че ранното спиране да не може да повлияе на крайния резултат. **Всички числа по-долу са измерени.**

Ключови резултати (измерени).

- *И двете цели са постигнати.* DQN решава **cartPole** на **епизод 1011**, със средна стойност за 100 епизода **477.5** (цел 475); PPO решава **lunarLander** на **264,192 стъпки** при **202.2** (цел 200) - 236K стъпки в рамките на бюджета.
- *Версиите, написани от нулата, превъзхождат настройките по подразбиране на SB3 при тези задачи.* Най-добро плъзгащо средно от 100: DQN **477.5 срещу 293.9**, PPO **203.6 срещу 131.2**. Причината е алгоритмична, а не несправедливо настройване: намаляване на **епсилон** на база епизоди спрямо намаляване на база стъпки при SB3, адаптивна **синхронизация на целта** (5 епизода са приблизително 100 стъпки по-рано и около 2500 след решаването) спрямо фиксирани 1000 стъпки, както и **ранно спиране** вместо изпълнение на пълния бюджет.
- *eps_min беше решаващият параметър за DQN.* При стойност 0.01 изпълнението достигна връх от **479.1** (епизод 810) и спадна до **302.6**; 0.001 плюс **най-добър модел с контролна точка** превърна влошаващата се стратегия в стабилна.
- *Капацитетът, а не бюджетът, беше тясното място за PPO.* [64, 64] достигна връх от **179.9** и никога не премина 200; [128, 128] го преодоля. **Нормализиране на предимството** се оказа незаменимо при награди в диапазона -500 до +300, а без **бонус за ентропия** от 0.01 стратегията колабираше до задържане на място.
- *Честно тълкуване на сравнението.* Настройките по подразбиране на SB3 са настроени за **устойчивост** в различни среди, а не за класически контрол; неговият PPO все още се покачваше при 500K и вероятно би достигнал целта при 1–2M стъпки. Твърдението е за специфично предимство на задачата, а не за по-добър алгоритъм.

Връзка с дисертацията. Стекът от 300–500 реда (срещу около 10,000 при SB3) е съзнателно платената цена за висока степен на модифицируемост: вмъкването на наблюдения на състоянието на убежденията в актьор-оценител изисква дълбоко подкласиране в рамките на SB3, докато тук това се свежда до локална редакция - точно от какво има нужда работата по експлоатацията в стъпки 7–8. Същата двойка актьор-оценител се използва отново като MAPPO/MADDPG в стъпка 9, а механизмът на мрежата за стойност се появява повторно като мрежа за предимства на Deep CFR в стъпка 5.

Отворени въпроси. Предположението на MDP, което прави всичко това възможно - напълно наблюдаемо състояние - е именно това, което покерът нарушава: върху информационно множество π на DQN и стратегията по състояния на PPO са и двете некоректно дефинирани, поради което стъпка 2 променя инструмента, а не мащаба. Остава отворен въпросът: доколко от набора инструменти за стабилност при един агент (целеви мрежи, доверителни региони, нормализиране на предимството) се запазва, когато средата сама по себе си е учаш се агент (отложено за нестационарността в стъпка 9), и дали измереното тук предимство по отношение на изискванията за проби е реално свойство или артефакт на две малки, добре обусловени задачи за контрол.