

Стъпка 8 Едностраничен документ — Безопасно използване на експлойти

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Проблем. Стъпка 7 изгради *сензора* — модел на противника — и показва неговата опасност: най-добре реагиращият към несвършен модел може да отвори пропуск в собствената си игра (непрекъснатият модел *загуби* от наш равновесие в ледюк). Стъпка 8 изгражда *изпълнителния механизъм*: превръщане на модел в печалба, **без да става експлоатируем**. Това е втората половина на рамката за поведенческа адаптация на дисертацията (Принос №1) и отправната точка за многоагентна безопасна експлоатация (Принос №2).

Подход. Всеки метод за безопасно използване представлява една и съща програма — *максимизиране на очакваната стойност спрямо модела на противника при условие за праг на безопасност върху най-лошия стойностен случай* — която е линейна по отношение на последователната форма за реализация на героя. Един LP двигател я решава чрез **генериране на ограничения** (решаване → прочитане на политиката → извикване на точен най-добър отговор като най-лошия случай оракул → добавяне на разрез, ако е небезопасен → повторно решаване), използвайки повторно двигателите от Стъпка 7, най-добрия отговор, наш равновесие и „зоологията“ на противниците. Пет семейства се различават единствено по прага: **RNR** (настройваем p), **Ganzfried** ($\geq$ стойността на наш равновесие v^*), **prime-safe** ($\geq v^* - \epsilon$ за базова линия на ϵ -равновесие), **SES** (стойност на плана, наложена локално върху подигра чрез джаджа), **adaptation** (не по-експлоатируем от плана). Тестови среди: Kuhn и Leduc, и двете точно решими, така че всеки резултат е ограничен от точни аналитични препратки. **Всички числа по-долу са измерени.**

Ключови резултати (измерени).

- **Безопасното използване работи в Kuhn. Ganzfried е безопасен срещу всеки противник** (най-лошият случай $\geq v^*$ в рамките на $1e-3$) **и превъзхожда собствената очаквана стойност на Наш за всеки експлоатируем тип** — например **+0,222 срещу +0,146 на Наш** при AlwaysPass. Пълният най-добър отговор носи повече (+0,975), но неговият най-лош случай се срива до **-0,5** (катастрофално експлоатируем). Това е централният валидиран резултат.
- ϵ **се измерва, а не се конструира**. Prime-safe/adaptation понижават прага до $v^* - \epsilon$, като експлоатируемостта на базовата линия се измерва при $\epsilon = 0,0074$, и печелят малко повече от Ganzfried, като използват този бюджет (+0,266 срещу +0,222 при AlwaysPass).
- **Каноничният RNR е превключващ, а не с гладка граница** (противоречащо предсказание). В игра толкова малка, LP max-min скача от безопасния връх право към пълния най-добър отговор при $p \approx 0,7$ — гладката крива е на *наивното смесване*, и тя се доминира в безопасния ъгъл.
- **Заглавие — глобалната безопасна експлоатация не се мащабира; локалната да.** В Leduc, глобалните решаващи (Ganzfried/prime-safe/adaptation) **не успяват да се сближат в рамките на 40 итерации** (най-лош случай **-0,64 до -1,33**, грубо небезопасен), докато **методът на под-играта (SES) се сближава** (194–350 итерации) и остава почти безопасен (най-лош случай $\approx -0,13$), като същевременно извлича **+0,25 до +0,68** срещу слабите типове. Това е разрыв между теория и практика на глобалното и локалното равнище на безопасността, измерен върху миниатюрна игра.
- **Гаранцията за безопасност действа срещу най-лошия възможен противник, а не срещу добронамерен.** При обучаващата атака (примамка → разкриване на Наш), честният разграничителен сигнал е броят нарушения на безопасността (**full_br 40/40 пренастройвания, Ganzfried 0/40**), а не осъществената печалба — нежен разкривател на равновесие на Наш никога не си връща вятърничавата печалба от фазата на примамка. За наказателен тест е необходим адаптивен контраексплойтър.

Връзка с дисертацията. Стъпка 7 представлява сензор; Стъпка 8 — изпълнителен механизъм. Резултатите на Кун потвърждават коректността на изпълнителния механизъм; несъходимостта на Ледюк е конкретният аргумент в полза на методи за под-игри в реално време (SES / OX-Search) и/или точна двойствена линейнопрограмна задача, като същевременно представлява емпиричния мост към мащабируемата многоагентна безопасна експлоатация от Принос №2.

Отворени въпроси. Мащабируема безопасност (точна двойствена линейнопрограмна задача срещу подлокална игра — стената на Ледюк); остатъчната експлоатируемост на приспособлението SES ($0,04 > \text{tol}$ — доказуемо или само приблизително безопасен?); наказателна обучаваща атака (адаптивно разкриване); и **безопасност при n играчи** — всяка гаранция тук се основава на факта за двуигрови игри с нулева сума, че равновесието на Наш осигурява v^* срещу всеки противник, котва, която изчезва при $N > 2$ (Принос №2).