

Глава 8 Резюме – Безопасна експлоатация

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Проблем. Глава 7 изгради *сензора* – модел на противника – и показва неговата опасност: най-добрият отговор на несъвършен модел може да създаде уязвимост в собствената игра (непрекъснатият модел *загуби* срещу „Наш“ в Ледюк). Глава 8 изгражда *изпълнителния механизъм*: превръщане на модел в печалба, **без да става експлоатируем**. Това е втората половина на рамката за поведенческа адаптация на дисертацията (Принос №1) и отпращащата точка за многоагентна безопасна експлоатация (Принос №2).

Подход. Всеки метод за безопасна експлоатация е една и съща задача – *максимизиране на очакваната стойност спрямо модела на противника при ограничение стойността в най-лошия случай да не пада под прага на безопасност* – която е линейна по плана за реализация на агента в последователна форма. Един LP двигател я решава чрез **генериране на ограничения** (решаване → точният най-добър отговор като предсказвач за най-лошия случай → отсичащо ограничение, ако стратегията е небезопасна → ново решаване) върху двигателите, равновесието на Наш и „зоопарка“ от противници на Глава 7. Пет семейства се различават единствено по прага: **RNR** (настройваем p), **най-доброто равновесие** (базовият вариант на Ganzfried и Sandholm; $\geq$ стойността на играта v^*), **prime-safe** ($\geq v^* - \epsilon$ за базова линия, която е ϵ -равновесие), **SES** (стойността на плана, наложена локално в под-игра чрез приспособление), **адаптация** (не по-експлоатируема от плана). Тестови среди: Кун и Ледюк, и двете точно решими. **Всички числа по-долу са измерени.**

Ключови резултати (измерени).

- **Безопасната експлоатация в Кун работи, но печели малко. Най-доброто равновесие е безопасно срещу всеки противник** (най-лош случай $\geq v^*$ в рамките на $1e-3$) и надминава Наш срещу всеки експлоатируем тип: **+0,222 срещу +0,146** при AlwaysPass. Печалбата над Наш е само 0,002–0,076 на раздаване (1–9% от печалбата на пълния най-добър отговор), защото прагът v^* допуска само равновесни стратегии. Пълният най-добър отговор печели +0,975, но пада до **-0,5** в най-лошия случай.
- ϵ се измерва, а не се приема наготово. Prime-safe и адаптацията понижават прага до $v^* - \epsilon$, като експлоатируемостта на базовата линия е измерена: $\epsilon = 0,0074$; изразходвайки този бюджет, те печелят малко повече от най-доброто равновесие (+0,266 срещу +0,222 при AlwaysPass).
- **Каноничният RNR превключва скокообразно, а не по плавна граница** (предсказанието не се потвърди). В толкова малка игра максиминната LP-задача скача от безопасния връх направо към пълния най-добър отговор между $p = 0,6$ и $0,7$ (изпробвани през $0,1$); смесването на двата върха дава отсечка, която тук подобрява наивното смесване само с около 0,002.
- **Основен резултат.** В **Ледюк** глобалните решавачи (най-доброто равновесие/prime-safe/адаптация) **не достигат сходимост при лимит 40 итерации** (най-лош случай **-0,64 до -1,33**). Локалният **SES достига сходимост** за 194–350 итерации при лимит 400, остава почти безопасен ($\approx -0,13$) и печели **+0,25 до +0,68** срещу слабите типове. Неравните бюджети показват, че глобалният цикъл е бавен, не невъзможен за довеждане до сходимост. Двойнствената LP-задача от Глава 14 решава пълния Ледюк за 0,02–0,04 s.
- **Гаранцията действа срещу най-неблагоприятния противник, а не срещу безобиден.** При обучаващата атака (примамка → „разкриване“ с равновесие на Наш) разграничителният сигнал е броят нарушения на безопасността (**full_br 40/40, най-доброто равновесие 0/40**), а не печалбата: „разкриващият“ „Наш“ е твърде мек, за да си върне неочакваната печалба на full_br. За наказващ тест е нужен адаптивен контраексплоататор.

Връзка с дисертацията. Глава 7 изгражда модела на противника; Глава 8 използва модела безопасно. Кун потвърждава теорията при точен модел; Ледюк мотивира търсене в под-игри (SES / OX-Search) или точна двойнствена LP-задача и води към Принос №2.

Отворени въпроси. RWYWE на Ganzfried и Sandholm като по-силен базов метод за двама играчи (същата LP-задача с подвижен праг; бъдеща работа). Безопасност отвъд Ледюк: точна двойнствена LP-задача или под-игри? Доказуемо безопасен ли е SES (остатък 0,04 спрямо v^* , 0,01 спрямо плана)? Нужна е наказваща обучаваща атака. При $N > 2$ играчи равновесието на Наш вече не гарантира v^* ; остават открити безопасната експлоатация спрямо базова линия и защитата от противници в сговор (Принос №2).