

Глава 8 Резюме - Безопасна експлоатация

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Проблем. Глава 7 изгради *сензора* - модел на противника - и показва неговата опасност: най-добрият отговор на не-съвършен модел може да създаде уязвимост в собствената игра (непрекъснатиот модел загуби срещу „Наш“ в Ледюк). Глава 8 изгражда *изпълнителния механизъм*: превръщане на модел в печалба, **без да става експлоатируем**. Това е втората половина на рамката за поведенческа адаптация на дисертацията (Принос №1) и отправната точка за многоагентна безопасна експлоатация (Принос №2).

Подход. Всеки метод за безопасна експлоатация е една и съща задача - *максимизиране на очакваната стойност спрямо модела на противника при ограничение стойността в най-лошия случай да не пада под прага на безопасност* - която е линейна по плана за реализация на агента в последователна форма. Един LP двигател я решава чрез **генериране на ограничения** (решаване → точният най-добър отговор като оракул за най-лошия случай → отсичащо ограничение, ако стратегията е небезопасна → ново решаване) върху двигателите, равновесието на Наш и „зоопарк“ от противници на Глава 7. Пет семейства се различават единствено по прага: **RNR** (настройваем p), **най-доброто равновесие** (базовият вариант на Ганцфрид и Сандхолм; $\geq$ стойността на играта v^*), **prime-safe** ($\geq v^* - \epsilon$ за базова линия, която е ϵ -равновесие), **SES** (стойността на плана, наложена локално в под-игра чрез приспособление), **адаптация** (не по-експлоатируема от плана). Тестови среди: Кун и Ледюк, и двете точно решими. **Всички числа по-долу са измерени.**

Ключови резултати (измерени).

- *Безопасната експлоатация работи в Кун, но печели малко. Най-доброто равновесие е безопасно срещу всеки противник* (стойност в най-лошия случай $\geq v^*$ в рамките на $1e-3$) **и печели повече от стратегията на Наш срещу всеки експлоатируем тип** - например **+0.222 срещу +0.146 за Наш** при AlwaysPass - но само с 0.002–0.076 на раздаване (1–9% от печалбата на пълния най-добър отговор): прагът v^* за всяко раздаване допуска само равновесни стратегии. Пълният най-добър отговор носи повече (+0.975), но стойността му в най-лошия случай се срива до **–0.5** (катастрофално експлоатируем).
- *ϵ се измерва, а не се приема наготово.* Prime-safe и адаптацията понижават прага до $v^* - \epsilon$, като експлоатируемостта на базовата линия е измерена: **$\epsilon = 0.0074$** ; изразходвайки този бюджет, те печелят малко повече от най-доброто равновесие (+0.266 срещу +0.222 при AlwaysPass).
- *Каноничният RNR превключва скокообразно, а не по плавна граница* (предсказанието не се потвърди). В толкова малка игра максиминната LP-задача скача от безопасния връх направо към пълния най-добър отговор между $p = 0.6$ и 0.7 (изпробвани през 0.1); смесването на двата върха дава отсечка, която тук подобрява наивното смесване само с около 0.002.
- *Основен резултат - при лимит от 40 итерации глобалните решаващи не достигат сходимост, а локалният метод (с лимит 400) достига.* В Ледюк глобалните решаващи (най-доброто равновесие/prime-safe/адаптация) **не достигат сходимост в рамките на 40 итерации** (най-лош случай **от –0.64 до –1.33**, силно небезопасни), **докато методът на под-играта (SES) достига сходимост** (194–350 итерации) и остава почти безопасен (най-лош случай ≈ -0.13), като същевременно извлича **+0.25 до +0.68** срещу слабите типове. Бюджетите обаче са неравни: резултатът показва, че глобалният цикъл е бавен, а не че не може да достигне сходимост.
- *Гаранцията действа срещу най-неблагоприятния противник, а не срещу безобиден.* При обучаващата атака (приамка → „разкриване“ с равновесие на Наш) разграничителният сигнал е броят нарушения на безопасността (**full_br 40/40, най-доброто равновесие 0/40**), а не печалбата: „разкриващият“ „Наш“ е твърде мек, за да си върне неочакваната печалба на full_br. За наказващ тест е нужен адаптивен контраексплоататор.

Връзка с дисертацията. Глава 7 е сензорът; Глава 8 - изпълнителният механизъм. Резултатите в Кун показват, че той работи според теорията (при точни модели, в точно решима игра); липсата на сходимост в Ледюк е аргумент за методи за под-игри в реално време (SES / OX-Search) и/или точна двойствена LP-задача и мост към многоагентната безопасна експлоатация от Принос №2.

Отворени въпроси. RYWE - алгоритъмът на Ганцфрид и Сандхолм, който рискува натрупаните подаръци, като посилен базов метод за двама играчи (същата LP-задача с подвижен праг; бъдеща работа); мащабируема безопасност (точна двойствена LP-задача срещу под-игри - „стената“ на Ледюк, при равни бюджети); доказуемо безопасен ли е SES (остатъкът 0.04 е спрямо v^* ; прага на плана спазва до допустимото отклонение 0.01); наказваща обучаваща атака; и **безопасност при N играчи** - гаранциите тук стъпват на това, че в игра с нулева сума за двама играчи равновесието на Наш осигурява v^* ; при $N > 2$ тази опора изчезва, а известните понятия са много консервативни (максимин срещу коалиция) или неосигурими (равният дял) - отворена остава експлоатацията с ограничена загуба спрямо базова линия, и срещу противници в сговор (Принос №2).