

Глава 9 Резюме - Многоагентно обучение с подкрепление

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Проблем. Глави 2–8 се развиваха почти изцяло в рамките на игри за двама с нулева сума, където равновесната стратегия на Наш осигурява стойност v^* срещу всеки и CFR доказуемо се сближава към нея. Глава 9 е повратната точка към многоагентния свят, където определящата трудност е **нестационарността**: всички агенти се учат едновременно, така че от гледната точка на който и да е агент средата (която съдържа останалите) никога не остава непроменена. Това е отправната точка за многоагентните приноси на дисертацията - динамично **моделиране на противника** (#1), **безопасна експлоатация без минимаксна опора** (#2) и оценка на ниво **популация** (#3).

Подход. Изграждане и сравняване на контролен вариант и на четирите структурни отговора, които областта дава на нестационарността, върху малки, *точно решими* тестови среди, така че всеки обучаващ се агент да бъде оценен спрямо обективната истина. **Независимо обучение** (контролният вариант, който се проваля) върху четири канонични матрични игри; **CTDE** - централизиране на оценителя по време на обучение и децентрализиране на актьора при изпълнение - чрез MADDPG и MAPPO върху кооперативни задачи; **PSRO** - игра, изиграна върху *популация* от стратегии (мета-Наш + оракул за най-добър отговор), като се използва точният най-добър отговор от Глава 7 както като оракул, така и като мярка за експлоатируемост - върху Кун, Ледюк, матрична игра и собствена реализация на Goofspiel; **научена комуникация** (CommNet); и **LOLA** (диференциране през стъпката на обучение на противника) върху повтарящата се дилема на затворника. **Всички числа по-долу са измерени.**

Ключови резултати (измерени).

- *Независимото обучение се проваля точно там, където го предвижда теорията.* То се сближава с равновесие на Наш при дилемата на затворника (предателство), лова на елен (рисково доминиращия ъгъл) и битката на полете, но **в „съвпадение на монети“ обучението никога не се сближава** - разстоянието на траекторията до равновесието на Наш всъщност *нараства* ($0.30 \rightarrow 0.48$), което е по-рязко от предвидената несходимост (опровергано предсказание, §9 от доклада).
- *PSRO е мостът между теорията на игрите и MARL и работи в малките игри.* Експлоатируемостта $\rightarrow$ машинна нула при Кун ($0.917 \rightarrow 2 \times 10^{-16}$, 6 кръга), $\rightarrow 0$ при матричната игра и камък–ножица–хартия. Самообучението потвърждава механизма: при Кун NashConv на **средната** стратегия спада $0.24 \rightarrow 0.031$, докато **последната** итерация продължава да осцилира - затова е необходима популация/усредняване.
- *Централизиращият оценител напасва целевата си стойност почти точно.* При CoopSignal остатъкът на централизиращия оценител е $3.2e-11$ срещу 0.077 на независимия - много по-точно напасване на целевата стойност (което не е същото като по-ниска дисперсия на градиента на стратегията).
- *Комуникацията надхвърля тавана при случайно отгатване.* CommNet с включен канал постига 0.795 срещу 0.204 при изключен (таван $1/K = 0.2$) - протокол, който агентите научават, а не който някой е проектирал.
- *LOLA превръща предателството в сътрудничество.* Възвръщаемостта на стъпка в IPD се повишава от 1.04 (наивните агенти стигат до предателство) до 2.82 (сътрудничество с LOLA); нулирането на предвиждането възстановява точно наивния градиент (проверка на механизма).
- *Отрицателни резултати, запазени честно (опровергани предсказания, §9 от доклада).* PSRO при Ледюк намалява, но достига стената на мащабиране ($4.75 \rightarrow 2.16$ след 20 кръга, а не <0.5); **Goofspiel K=4** осцилира, вместо да се сближава (отбелязана аномалия в кода, документирана, но не поправена); и в играта „изкачване“ нито един метод не достига оптимума 11 (IL/MAPPO 7; MADDPG във вариант в стила на COMA - 5) - централизиращият оценител напасва по-добре целевата стойност, но сам по себе си не решава координацията, когато изследването е трудно.

Връзка с дисертацията. PSRO представлява итерирания най-добър отговор от Глава 2, издигнат до популационно равнище и служещ като емпиричен гръбнак на настоящата работа; LOLA е *динамично* моделиране на противника - насочено към движеща се цел допълнение към статичната преценка за противника от Глава 7 (Принос №1); мета-играта на PSRO е методология за оценка на популационно равнище (Принос №3). Стената на мащабиране при Ледюк отразява откритието глобално срещу локално от Глава 8, а мястото, където престава да важи всяка гаранция за игри с двама играчи - **липсващата минимаксна опора за $N \geq 2$** - е именно проблемната постановка на Принос №2.

Отворени въпроси. Може ли приблизителен (RL) оракул да доближи PSRO в Ледюк до равновесието на Наш и до колко това отслабва гаранцията? Какво прекъсва колебанието при Goofspiel-K=4 (премахване на дубликати? смесена популация? различен мета-решател?) и защо централизиращият оценител *вреди* в играта „изкачване“? И под всичко това: без минимаксна стойност за $N \geq 2$, какво означава „безопасен“ за една популация и може ли мета-играта на PSRO да осигури заместител (Принос №2)?