

Стъпка 9 Едностраничник — Обучение с подкрепление за множество агенти

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Проблем. Стъпки 2–8 се развиваха в рамките на двуйгрови игри с нулева сума, където една наша стратегия осигурява стойност v^* срещу всеки и CFR доказуемо се сближава към нея. Стъпка 9 е повратната точка към многоагентния свят, където определящата трудност е **нестационарност**: всеки агент се учи едновременно, така че от гледната точка на който и да е агент средата (която съдържа останалите) никога не остава непроменена. Това е отправната точка за многоагентните приноси на дисертацията — динамично **моделиране на противника** (#1), **безопасна експлоатация** без **минимакс котва** (#2) и оценка на ниво **популация** (#3).

Подход. Изграждане и сравняване на четирите структурни отговора на полето на нестационарност върху малки, *точно решими* тестови среди, така че всеки обучаващ се да бъде оценен спрямо обективната истина. **Самостоятелно обучение** (контролният вариант, който се проваля) върху четири канонични матрични игри; **CTDE** — централизиране на критика по време на обучение и децентрализиране на актьора при изпълнение — чрез MADDPG и MAPPO върху кооперативни задачи; **PSRO** — игра, изиграна върху *популация* от политики (мета-Наш + предсказвач за най-добър отговор), като се използва точният най-добър отговор от Стъпка 07 както като оракул, така и като метрика за експлоатируемост — върху Kuhn, Leduc, матрична игра и родна Goofspiel; **научена комуникация** (CommNet); и **LOLA** (диференциране през стъпката на обучение на противника) върху Итерираната дилема на затворника. **Всички числа по-долу са измерени.**

Ключови резултати (измерени).

- *Самостоятелното обучение се проваля точно там, където теорията предсказва.* То се сближава към Нашово равновесие при Дилемата на затворника (дефекция), Ловът на елени (рисково доминиращият ъгъл) и Битката на половете, но **игра „хвърляне на монета“ никога не се сближава** — разстоянието ѝ до Нашово равновесие всъщност *нараства* ($0.30 \rightarrow 0.48$), което е по-рязко от предвидената несходимост (противоречиво предсказание, §9 от доклада).
- *PSRO е мостът между теория на игрите и MARL и работи върху малките игри.* Експлоатируемостта $\rightarrow$ машинна нула при Kuhn ($0.917 \rightarrow 2 \times 10^{-16}$, 6 рунда), $\rightarrow 0$ при матричната игра и Камък–ножица–хартия. Самообучението потвърждава механизма: при Kuhn **средният** итеративен NashConv пада до $0.24 \rightarrow 0.031$, докато **последният** итерат продължава да осцилира — затова е необходима популация/усредняване.
- *Централизиран оценител е почти нулев дисперсионен учител.* При CoopSignal остатъкът на централизирания оценител е $3.2e-11$ срещу 0.077 на независимия оценител — потвърждение на твърдението за намаляване на дисперсията в CTDE.
- *Комуникацията премахва прага на отгатваемост.* CommNet с ВКЛЮЧЕН канал постига резултат 0.795 срещу 0.204 при ИЗКЛЮЧЕН (праг $1/K = 0.2$) — научен, а не проектиран протокол.
- *LOLA превръща дефекторите в кооператори.* Възвръщаемостта на IPD за стъпка се повишава от 1.04 (наивна дефекция) до 2.82 (кооперация с LOLA); нулирането на предвиждането възстановява точно наивния градиент (проверка на механизма).
- *Честни отрицателни (запазени предсказания, §9).* PSRO при Leduc намалява, но достига скалираща стена ($4.75 \rightarrow 2.16$ след 20 рунда, а не < 0.5); Goofspiel $K=4$ осцилира вместо да се сближава (отбелязана аномалия в кода, документирана, но не поправена); и при **изкачващата се игра** нито един метод не достига оптимума 11 (IL/MAPPO 7, MADDPG 5) — централизиран оценител намалява дисперсията, но сам по себе си не решава координатията при риск от прекомерно изследване.

Връзка с дисертацията. PSRO представлява итерирания най-добър отговор от Стъпка 2, издигнат до популационно равнище и служещ като емпиричен гръбнак на настоящата работа; LOLA е *динамично* моделиране на противника — допълнение към статичното четене от Стъпка 7, насочено към движеща се цел (Принос №1); мета-играта на PSRO е методология за оценка на популационно равнище (Принос №3). Стената на мащабиране при ледюк отразява откритието глобално срещу локално от Стъпка 8, а мястото, където всяка двуйгрова гаранция престава да важи — **липсващата минимакс котва за $N>2$** — е именно проблемната постановка на Принос №2.

Отворени въпроси. Може ли приблизителен (RL) оракул да доближи Leduc PSRO до Нашовото равновесие и каква е цената на тази гаранция? Какво прекъсва колебанието при Goofspiel- $K=4$ (премахване на дубликати? смесена популация? различен мета-решател?) и защо централизираният оценител *вреди* в изкачващата се игра? И под всичко това: без минимаксна стойност за $N>2$, какво означава „безопасен“ за една популация и може ли мета-играта на PSRO да осигури заместител (Принос №2)?