

Съдържание

Резюме	1
1 Въведение	2
2 Преглед на съществуващите решения	5
3 Предлагащо решение	6
3.1 Принос 1: Рамка за поведенческа адаптация	7
3.2 Принос 2: Безопасна мултиагентна експлоатация	8
3.3 Принос 3: Методология за оценка	8
3.4 Очаквани резултати	9
4 Заключение	10
Литература	10

Резюме

Все повече автономни AI агенти (агенти с изкуствен интелект) действат в конкурентни, мултиагентни среди — от финансовите пазари през киберсигурността до онлайн платформите — и способността им да разсъждават за другите стратегически участници, да се адаптират към тях и да взаимодействат с тях безопасно в условия на скрита информация се превърна в належащо изследователско предизвикателство. Математическа рамка за изучаване на такива взаимодействия предоставят игрите с непълна информация в разгъната форма (extensive-form games — модел на последователно вземане на решения, в който всеки ход и неговите възможни изходи са представени явно; просто: дърво от ходове и избори).

През изминалото десетилетие алгоритми като Counterfactual Regret Minimization (CFR — алгоритъм за намиране на равновесие чрез минимизиране на „съжалението“ за неизбраните действия; просто: учене от пропуснати ходове) и невронните му разширения постигнаха свръхчовешки резултати в мащабни игри, в това число покер както за двама, така и за шестима играчи. Същевременно аналогични теоретико-игрови решители, произлезли от същите основи, вече имат оперативни приложения в различни сфери на сигурността.

Тези системи обаче изчисляват фиксирани равновесни стратегии, които играят еднакво срещу всеки противник, а формалните гаранции за безопасност, върху които стъпва експлоатацията в сценариите с двама играчи, доказано не важат в мултиплейър среди. Настоящият труд прави преглед на актуалното състояние в изчисляването на равновесия, моделирането на противници и безопасната експлоатация при игри с непълна информация, идентифицира отворения пропуск на пресечната точка между адаптивната игра и мултиплейър безопасността и предлага докторантска изследователска програма, насочена към три приноса:

Рамка за поведенческа адаптация (Behavioral Adaptation Framework) за извеждане на поведението на противника в реално време, Евристики за безопасна мултиагентна експлоатация (Multi-Agent Safe Exploitation), базирани на регуляризация, и независима от домейна Методология за оценка (Evaluation Methodology) за измерване на адаптивността и устойчивостта на агентите в разнородни игрови среди.

1 Въведение

Бързото разпространение на автономни AI агенти, действащи в отворени конкурентни среди, бележи качествен преход в изследванията по изкуствен интелект. На фондовите и деривативните борси алгоритми за високочестотна търговия (high-frequency trading — автоматизирана търговия с финансови инструменти в микросекунден мащаб) се конкурират със скрити позиции, частни сигнали и стратегически реакции към динамиката на поръчковата книга. Автономни флотове от превозни средства договарят преминаване през несигнализирани кръстовища и маневри на сливане, при които намеренията на околните коли са само частично наблюдаеми. Ботнет мрежи в социалните платформи — документиращи в голям мащаб по време на последните изборни цикли и при координирани дезинформационни кампании — взаимодействат с потребители, чиито намерения (кооперативни, конкурентни или измамни) не са обявени. Във всяка от тези ситуации агентът трябва да взема последователни решения при несигурност, изправен срещу други стратегически участници, чиято частна информация и поведенчески модели са непознати. Основното предизвикателство вече не е обучението на отделен агент в изолация, а това да се даде възможност на агентите да разсъждават, да се адаптират и да взаимодействат безопасно с други агенти, чието поведение е скрито и потенциално враждебно.

В своята математическа основа това предизвикателство е теоретико-игрови проблем — по-конкретно, проблем от теорията на игрите с непълна информация в разгъната форма. Такива игри моделират последователното вземане на решения от множество играчи, които притежават частна информация, сблъскват се със стохастични изходи и трябва да действат, без да познават изцяло състоянието на средата или стратегиите на останалите. Важно е да се подчертае, че те не са просто академични тестови задачи: те са компактни и математически проследими модели на стратегическите взаимодействия, които възникват винаги когато множество самозаинтересовани агенти действат при несигурност.

Знаковите резултати в областта — Counterfactual Regret Minimization [1], Libratus [2], Pluribus [3] и ReBeL [4] — бяха валидирани върху покер варианти, но базовите им алгоритми не зависят от конкретния домейн. Покерът беше избран като канонична тестова среда, защото е най-малкото семейство игри, в което едновременно присъстват четирите структурни характеристики, общи за реалните стратегически ситуации — скрита частна информация, после-

дователни действия, стохастични изходи и множество самозаинтересовани играчи — и което същевременно позволява недвусмислен критерий за победа, подходящ за алгоритмично валидиране.

След като бе утвърден в покера, същият теоретичен апарат се пренесе в приложения с по-високи залози. Решители за игрите на Щакелберг в сферата на сигурността (Stackelberg security games — модел за разпределяне на защитни ресурси срещу стратегически нападател), които споделят равновесно-изчислителните основи на CFR, се използват оперативно за рандомизиране на патрулни и проверочни графици в гражданската авиация и морската сигурност. Публични изследователски програми в симулирани въздушни боеве показваха, че агенти, обучени чрез дълбоко обучение с подкрепление (deep reinforcement learning — обучение на агент чрез опит и възнаграждение, съчетано с невронни мрежи; просто: учене чрез опит и награда), могат да побеждават опитни човешки пилоти във въздушни двубои извън визуален обхват. Масштабните търгове за радиочестотен спектър — при които се разпределят десетки милиарди долари безжична честотна лента — също се проектират с помощта на алгоритми за намиране на равновесие от същата теоретична линия.

В рамките на изследователската литература подходът е скалиран отвъд покера и към играта с преговори за седем играчи Diplomacy [7], и към настолната игра Stratego [8].

През изминалото десетилетие в областта се наблюдава забележителен напредък, следващ ясна траектория: прилагане на алгоритми за намиране на равновесие върху все по-големи игри. CFR беше скалиран чрез Monte Carlo извадкови методи (Monte Carlo sampling — стохастична оценка чрез случайни извадки; просто: оценяване чрез случаен избор), невронна функционална апроксимация и решаване на подигри в реално време, като достигна кулминация в свръхчовешки резултати както в покер за двама [2] и покер за шестима [3], така и в Stratego — игра, чието пространство от състояния е 10^{175} пъти по-голямо от това на Go [8]. Това са истински крайъгълни камъни.

Всички те обаче споделят едно фундаментално ограничение: получените агенти изчисляват *фиксиран* равновесни стратегии и играят еднакво срещу всеки противник. Срещу неоптимални противници — а това на практика означава почти всеки реален противник, човешки или изкуствен — равновесната стратегия е безопасна, но сляпа: тя систематично не успява да експлоатира откриваемите слабости.

Нещо повече, с нарастването на броя играчи дори самото понятие „безопасен“ става проблематично: равновесието на Неш (Nash equilibrium — състояние, в което никой играч няма изгода да промени едностранно стратегията си; просто: стабилен баланс на стратегии) губи своята минимакс гаранция (minimax — принцип за минимизиране на максималната възможна загуба; просто: план за най-лошия случай). Точното му изчисление става неизпълнимо (PPAD-пълнен проблем — клас на изчислителна сложност за задачи по намиране на

равновесия в игри с N играчи; просто: практически нерешим проблем), а изследователската парадигма трябва да се измести: от изчисляването на съвършени решения в контролирани условия към осигуряването на бърза адаптация в среди, твърде сложни, за да може едно-единствено равновесие да бъде достатъчно.

Тази ситуация разкрива три взаимосвързани отворени проблема. Първо, *адаптация*: как агент може да извежда поведенческите наклонности на противника от наблюдаваните действия и да коригира собствената си стратегия в реално време, когато частната информация и намеренията на противника остават скрити? Второ, *безопасност при адаптация*: как агент може да експлоатира откритите слабости, без да допуска прекомерни загуби в най-лошия случай — особено в среди с N играчи, където формалните гаранции за безопасност от теорията за двама играчи доказано не важат? Трето, *оценка*: как да измерим надеждно дали даден агент се адаптира добре в различни игри, популации от противници и условия на средата, когато съществуващите метрики улавят само по едно измерение на представянето? Заслужава да се спомене и един практически страничен ефект: агент, способен да моделира поведението на противника, е способен и да *открива* аномално или злонамерено поведение — неоторизирани ботове, участници в тайни съглашения или враждебни субекти — което има непосредствени приложения в защитата на целостта на онлайн платформите и в откриването на измами.

Настоящото докторантско изследване адресира тези три отворени проблема чрез структурирана учебна програма от петнадесет стъпки, която обхваща: основи на обучението с подкрепление и изчисляване на равновесия чрез CFR; скалиране чрез Monte Carlo извадкови методи и игрова абстракция; невронна апроксимация и архитектури от край до край (DeepStack, Libratus, Pluribus, ReBeL); моделиране на противника и безопасна експлоатация; мултиагентна динамика, обучение, базирано на популации, и формиране на коалиции в игри „всеки срещу всеки“; подходи, базирани на данни, чрез последователностни модели, LLM агенти (large language model — голям езиков модел; просто: голям езиков модел тип ChatGPT) и конвейери за обработка на реални поведенчески данни; както и единна рамка за оценка с картографиране на изследователската граница. Всяка стъпка съчетава целево четене на знакови статии с имплементации „от нулата“, валидирани спрямо аналитични решения или еталонни рамки. По този начин трите приноса на дисертацията — Рамката за поведенческа адаптация, Евристиките за безопасна мултиагентна експлоатация и независимата от домейна Методология за оценка — стъпват върху работещ код, а не само върху синтез на литературата. Реалистичният обхват на всеки принос, с оглед на наличните ресурси, е обсъден паралелно с предложените методи.

2 Преглед на съществуващите решения

Алгоритмичната основа за изчисляване на стратегии в игри с непълна информация беше положена от Counterfactual Regret Minimization (CFR) [1]. Алгоритъмът разлага задачата за намиране на равновесие на Неш на независими локални подзадачи във всяка точка на вземане на решение и гарантира сходимост на усреднената стратегия със скорост $O(1/\sqrt{T})$. CFR направи изчислителната теория на игрите практически приложима, но за да се справя с големи игри, бяха нужни допълнителни усилия по скалиране: Monte Carlo извадковите методи намалиха цената на една итерация, а невронната функционална апроксимация замени таблично съхраняваните стойности с дълбоки невронни мрежи.

Практическият резултат от тези постижения беше демонстриран от Libratus [2], който победи водещи професионалисти в безлимитен покер за двама, и от Pluribus [3], който разшири този успех до покер за шестима. ReBeL [4] впоследствие обедини обучението с подкрепление и търсенето в рамките на *публичното състояние на убежденията* (public belief state — вероятно разпределение върху скритата информация, което се обновява чрез Бейсов извод в хода на играта; просто: обща карта на скритото) и с това пренесе методите в стил AlphaZero към игрите с непълна информация.

Взети заедно, тези системи са равностойни на десетилетие прогрес в изчисляването на равновесни стратегии за все по-големи и по-сложни игри.

Всички тези системи обаче споделят едно ключово ограничение: те изчисляват *фиксиран* стратегии и играят еднакво срещу всеки противник. Въпросът за адаптацията към конкретен противник беше разгледан от Southey и съавтори [5], които разработиха Бейсова рамка (Bayesian framework — статистически подход, основан на условни вероятности и обновяване на убежденията спрямо наблюденията; просто: учене от натрупани доказателства) за моделиране на противника. Рамката поддържа априорно разпределение върху възможните типове стратегии на противника и го обновява въз основа на наблюдаваните действия; дори приблизителни модели на противника доведоха до значителни печалби от експлоатация в сравнение с чисто равновесна игра.

Формалното разглеждане на *безопасността* по време на експлоатация беше предоставено от Ganzfried и Sandholm [6], които доказаха Теоремата за безопасност: в игра за двама играчи с нулева сума всяка експлоатираща стратегия, която е закотвена за равновесна базова линия на Неш, не може да загуби повече от тази базова линия срещу който и да е противник, независимо от точността на модела. Параметърът на безопасност $p \in [0, 1]$ контролира компромиса между потенциала за експлоатация и защитата в най-лошия случай. Това е основополагащ резултат, но Теоремата за безопасност разчита на минимакс свойството на равновесието на Неш, което е в сила единствено в игри за двама играчи с нулева сума.

При повече играчи или при игри с ненулева сума равновесието на Неш не предпазва от ко-

алиции или корелирани отклонения, а самата статия идентифицира разширението за мултиплейър като отворен проблем.

Две неотдавнашни системи очертават посока напред. Bakhtin и съавтори [7] постигнаха игра на човешко ниво в Diplomacy — игра за седем играчи с формиране на коалиции и предателство — чрез π KL регуляризация (метод, който ограничава отклонението на текущата политика от дадена референтна политика посредством Кулбак-Лайблерова дивергенция; просто: наказание за твърде смело отклонение). Тя не закотвя агента към равновесие на Неш (което в такава среда е изчислително неизпълнимо и стратегически безсмислено), а към *поведенческо априорно разпределение, научено от човешки данни*, като санкция по KL-дивергенция (KL-divergence — мярка за разлика между две вероятностни разпределения; просто: разлика между две вероятности) предотвратява прекомерно отклонение.

Независимо от тях Perolat и съавтори [8] решиха Stratego чрез Regularized Nash Dynamics (R-NaD — безмоделен алгоритъм, който използва регуляризация, за да доведе обучението до равновесие на Неш вместо до зацикляне; просто: стабилно обучение към баланс). И двете системи показват, че методите, базирани на регуляризация, могат да обуздаят динамиката на обучение в огромен мащаб; но нито една от тях не се адаптира към конкретни противници.

Освен това до момента няма работа, която систематично да изследва компромиса между експлоатация и безопасност в мултиплейър среди, нито такава, която да предоставя рамка за оценка на адаптивното поведение в разнородни игрови среди.

Показателно е, че теоретико-игровите решители, които в момента са в оперативна или близка до оперативната употреба — системи за рандомизиране на охранителни патрули, изследователски агенти за симулирани въздушни боеве и проектантски механизми за търгове, на чиято основа се извършват многомилиардни разпределения на радиочестотен спектър — всички разчитат на *фиксиран* равновесни или близки до равновесни стратегии. По самата си конструкция те наследяват именно трите ограничения, към които е насочена настоящата дисертация: липса на адаптация в реално време към конкретни противници, липса на формални гаранции за безопасност, щом средата надхвърли двама играчи, и липса на стандартизирана методология за оценка на адаптивното поведение в разнородни стратегически среди. Затова идентифицираният в литературата пропуск не е само академичен; той е пропускът, който отделя днешните внедрени системи от следващото поколение мултиагентен AI — адаптивен в реално време и отчитащ безопасността.

3 Предлагамо решение

Прегледът разкрива прецизно очертан пропуск в съвременното състояние на областта: разполагаме с формални гаранции за безопасност при експлоатация в среди с двама играчи и с

практически приложима регуляризация за големи мултиагентни игри, но липсва рамка, която да свързва двете — такава, която да осигурява адаптивна и отчитаща безопасността експлоатация в мултиплейър среди, съчетана със систематична оценка. Трите приноса по-долу адресират този пропуск от допълващи се ъгли: извод (как да моделираме противниците), действие (как да ги експлоатираме безопасно) и измерване (как да оценим резултата).

3.1 Принос 1: Рамка за поведенческа адаптация

Съществуващите системи за игрови AI изчисляват равновесни стратегии, които са слепи за специфичните за противника поведенчески модели. Методите за моделиране на противника [5] могат да извеждат поведение, но не са интегрирани с процеса по намиране на равновесие и не отчитат риска от неправилно специфициран модел.

Първият принос е насочен към общ метод за извеждане на стратегиите на противника от наблюдаваните последователности от действия в реално време и за включване на тези изводи във вземането на решения от агента. Кандидат-архитектурите включват разширяване на представянето на публичното състояние на убежденията [4] с поведенчески убеждения за наклонностите на противника — т.е. преминаване от „каква частна информация може да държи противникът?“ към „какъв тип играч е противникът?“ — както и техники за консистентно моделиране на противника (consistent opponent modeling — методи, които гарантират сходимост на оценката към истинската стратегия на противника при достатъчен брой наблюдения).

Критично проектно ограничение е плавното деградиране (graceful degradation — свойство на системата да запазва приемливо поведение при недостатъчни данни или частичен отказ; просто: плавно отстъпление при липса на данни): когато събраните наблюдения са недостатъчни, агентът трябва по подразбиране да играе равновесната стратегия, вместо да действа въз основа на ненадеждни изводи. Рамката ще бъде валидирана върху структурно разнообразни игри — игри с карти и скрити ръце (Kuhn Poker, Leduc Hold'em — опростени изследователски варианти на покер), последователни наддавателни игри със скрити оценки на картите (Goofspiel — игра с карти и едновременни скрити наддавания) и мултиагентни среди с частична наблюдаемост (преследване-бягство в решетъчни светове, опростени варианти на Diplomacy) — за да се демонстрира приложимост, независима от конкретен домейн. Естествен страничен ефект на тази работа е способността за откриване и класифициране на аномално поведение, с преки приложения при откриване на измами, идентификация на ботове и разкриване на тайни съглашения в мултиплейър платформи.

3.2 Принос 2: Безопасна мултиагентна експлоатация

Теоремата за безопасност [6] предоставя формални гаранции за експлоатация в игри за двама играчи с нулева сума, но тези гаранции доказано не важат в среди с N играчи, където динамиката на коалициите обезсилва минимакс основата. Pluribus [3] показва емпиричен успех в покера за шестима играчи без каквато и да е рамка за безопасност, но не предлага теоретична основа за това кога или защо подобен успех се обобщава. Вторият принос е насочен към практически приложими подходи за безопасна експлоатация в игри с N играчи и непълна информация и изследва няколко кандидат-направления.

Най-обещаващата посока адаптира парадигмата на π KL регуляризацията от Diplomacy [7], като ограничава експлоатиращата политика да остава близо до безопасна референтна стратегия чрез санкция по KL-дивергенция. Референтната стратегия не е задължително да бъде равновесие на Неш — тя може да бъде средна стойност по популацията, поведенческо априорно разпределение, научено от данни, или приблизително равновесие — което прави подхода приложим и в случаите, когато точното изчисление на равновесие е неизпълнимо. Алтернативна посока изследва еталонните линии „равен дял“ (equal-share baselines — безопасна референтна стойност, основана на минималния гарантиран дял на всеки играч): тук гарантираната минимална печалба на всеки играч служи за безопасна котва, която напълно заобикаля изчисляването на равновесие. Валидацията е планирана върху варианти на игри с N играчи, включително игри с карти за трима, играта за формиране на коалиции за четирима So Long Sucker и мултиагентни решетъчни среди с частична наблюдаемост.

3.3 Принос 3: Методология за оценка

В момента не съществува стандартизирана рамка за оценка на адаптивни агенти в различни игрови среди и популации от противници. Експлоатируемостта (exploitability — мярка за това колко силно най-добрият възможен противник може да експлоатира дадена стратегия; просто: колко лесно можеш да бъдеш бит) измерва уязвимостта в най-лошия случай, но игнорира качеството на адаптацията; рейтингът Ело (Elo rating — система за относително класиране на играчи) измерва относителната сила, но не може да улови структури с циклично доминиране; а високата дисперсия в игрите с непълна информация прави необработените статистики на победите статистически ненадеждни. Третият принос е насочен към независима от домейна рамка за оценка, която съчетава индивидуални метрики за безопасност (експлоатируемост и нейното разширение за игри с N играчи), методи за класиране на популационно ниво, чувствителни към нетранзитивни динамики (α -Rank [9] — метод за оценка на мултиагентни системи чрез еволюционен модел, устойчив на циклично доминиране; просто: класацията устойчива на „камък-ножица-хартия“), и техники за намаляване на дисперсията (AIVAT [10] — техника за намаляване на дисперсията при оценка на агенти в игри с непълна информация; просто: изчистване на шума в оценката), за да осигури статис-

тически надеждна оценка при високата дисперсия, присъща на тези игри. Рамката ще бъде валидирана върху разнородни типове игри, за да се гарантира, че оценките са сравними между структурно различни стратегически взаимодействия.

3.4 Очаквани резултати

Обхватът на всеки принос зависи от взаимодействието между алгоритмичните избори, направени в хода на текущата учебна програма (която продължава до октомври 2026 г.), и наличните ресурси. Описаните по-долу траектории очертават как се очаква да се развие всеки принос — от стабилната си отправна точка до реалистичната цел за дисертацията. По-голяма дълбочина отвъд тези цели е оставена като възможна посока, а не е обещана като резултат.

Работата по **Принос 1** започва с демонстрация, че адаптационната рамка превъзхожда статичната равновесна игра върху основните тестови игри (Kuhn Poker, Leduc Hold'em). Реалистичната цел е тази валидация да бъде разширена до структурно различни семейства игри — игри с карти, наддавателни игри и среди, базирани на решетка — така че печалбите от адаптацията да се проявяват в различни домейни, а не само в игрите с карти. Дали рамката може допълнително да предостави гаранции за сходимост при извеждането на типа на противника и по този начин да свърже емпиричната работа с наскорошни теоретични резултати за консистентност в моделирането на противника, ще зависи от развитието на по-късните стъпки на учебната програма и е оставено като отворена посока.

Принос 2 започва с емпирична валидация на съществуващите евристики — π KL регуляризация и еталонни линии „равен дял“ — върху малки игри с N играчи, като режимите им на провал ще бъдат охарактеризирани, така че компромисът експлоатация–безопасност да бъде картографиран, а не просто твърдян декларативно. Реалистичната цел е метод, който комбинира тези евристики с динамики, отчитащи противника или базирани на популации, по начини, които литературата все още не е разгледала. Всяка следваща стъпка — към по-теоретично обоснована трактовка на безопасната експлоатация при N играчи, която би разширила Теоремата за безопасност отвъд случая с двама играчи и нулева сума — би била съществен самостоятелен принос; дисертацията го държи в полезрението си, но не зависи от постигането му.

Принос 3 започва с гарантирането, че рамката за оценка възпроизвежда известни подреждания на агенти и открива известни нетранзитивни структури в референтните игри; това е минималният праг, за да може тя да бъде приемана за надеждна. Реалистичната цел е рамката да бъде разширена към реални поведенчески данни, например анонимизирани игрови логове, така че да дава приложими прозрения отвъд синтетичните референтни тестове. Отвъд това стойността на рамката се крие в онова, което тя разкрива при прилагане; конкретни находки не могат да бъдат предварително заявени по честен начин.

Взети заедно, тези приноси са проектирани така, че техните основни резултати — валидиран метод за адаптация, емпирично охарактеризирани евристики за безопасност и работеща рамка за оценка — сами по себе си вече съставляват съгласувана дисертация. Допълнителната дълбочина, която евентуално произтече от по-късните стъпки на учебната програма, би надградила тази основа, а не би я заменила.

4 Заключение

Основополагащата фаза на настоящото докторантско изследване е завършена. Литературният преглед разкрива прецизно очертан пропуск: съвременното състояние на областта позволява да се изчисляват равновесни стратегии на свръхчовешко ниво и да се експлоатират конкретни противници безопасно в среди с двама играчи, но не съществува рамка, която да осигурява адаптивна и отчитаща безопасността експлоатация в мултиагентни среди, съчетана със систематична оценка. Трите предложени приноса — Поведенческа адаптация, Безопасна мултиагентна експлоатация и Методология за оценка — адресират този пропуск от допълващи се ъгли, с изрично очертани очаквания, калибрирани спрямо наличните ресурси и времеви хоризонт.

Методите, които са в процес на разработка, не са специфични за една игра или един домейн. Те се занимават с общия проблем на адаптивното стратегическо вземане на решения при несигурност и множество противници — ситуация, която възниква навсякъде, където автономни агенти взаимодействат в среди със скрита информация. С нарастващото навлизане на AI агенти в реални системи, осигуряването на това тези агенти да се адаптират безопасно и да могат да бъдат оценявани надеждно, се превръща не просто в академично занимание, а в практическа необходимост.

Литература

- [1] Zinkevich, M., Johanson, M., Bowling, M. and Piccione, C. (2007). “Regret Minimization in Games with Incomplete Information.” *Advances in Neural Information Processing Systems 20 (NeurIPS)*.
- [2] Brown, N. and Sandholm, T. (2018). “Superhuman AI for Heads-Up No-Limit Poker: Libratus Beats Top Professionals.” *Science*, 359(6374), pp. 418–424.
- [3] Brown, N. and Sandholm, T. (2019). “Superhuman AI for Multiplayer Poker.” *Science*, 365(6456), pp. 885–890.
- [4] Brown, N., Bakhtin, A., Lerer, A. and Hu, Q. (2020). “Combining Deep Reinforcement Learning and Search for Imperfect-Information Games.” *Advances in Neural Information Processing Systems (NeurIPS)*.
- [5] Southey, F., Bowling, M., Larson, B., Piccione, C., Burch, N., Billings, D. and Rayner, C. (2005). “Bayes’ Bluff: Opponent Modelling in Poker.” *Proceedings of the 21st Conference on Uncertainty in Artificial Intelligence*

(UAI).

[6] Ganzfried, S. and Sandholm, T. (2015). “Safe Opponent Exploitation.” *ACM Transactions on Economics and Computation*, 3(2).

[7] Bakhtin, A., Wu, D.J., Lerer, A., Gray, J., Jacob, A.P., Farina, G., Miller, A.H. and Brown, N. (2022). “Human-Level Play in the Game of No-Press Diplomacy via Human-Regularized Reinforcement Learning and Planning.” *Science*, 378(6624), pp. 1067–1074.

[8] Perolat, J., De Vylder, B., Hennes, D. et al. (2022). “Mastering the Game of Stratego with Model-Free Multiagent Reinforcement Learning.” *Science*, 378(6623), pp. 990–996.

[9] Omidshafiei, S., Papadimitriou, C., Piliouras, G., Tuyls, K. et al. (2019). “ α -Rank: Multi-Agent Evaluation by Evolution.” *Nature Scientific Reports*.

[10] Burch, N., Johanson, M. and Bowling, M. (2019). “AIVAT: A New Variance Reduction Technique for Agent Evaluation in Imperfect Information Games.” *Proceedings of the 33rd AAAI Conference on Artificial Intelligence*.