

Съдържание

1 Стъпка 01 - Основи на обучението с подкрепление: Доклад за реализацията	1
1.1 Съдържание	1
1.2 Преглед	2
1.3 DQN - Дълбока Q-мрежа	2
1.4 PPO - Оптимизация на проксималната стратегия	5
1.5 Сравнение с базовите решения на SB3	6
1.6 Ключови изводи	9
1.7 Приложение - Възпроизвеждане	11

1 Стъпка 01 - Основи на обучението с подкрепление: Доклад за реализацията

Среда: април 2026 г.

Алгоритми: DQN (cartPole-v1), PPO (lunarLander-v3)

Цели: DQN ≥ 475 , PPO ≥ 200 (средна стойност от 100 епизода)

Статус: И двете цели са постигнати ✓

1.1 Съдържание

- Преглед
- DQN - Дълбока Q-мрежа
 - Архитектура
 - Ключови проектни решения
 - Итерации на хиперпараметри
 - Окончателни резултати
- PPO - оптимизация на проксималната стратегия
 - Архитектура
 - Ключови проектни решения
 - Итерации на хиперпараметри

– Окончателни резултати

- Сравнение с базовите линии на SB3
 - Ключови изводи
-

1.2 Преглед

Стъпка 01 реализира два фундаментални RL алгоритъма от нулата с **pyTorch**, като включва подробни коментари в кода, обясняващи *защо* зад всяко проектно решение. И двата алгоритъма използват еднакви набори от **хиперпараметри** при сравнение с еквивалентите от **stable-Baselines3** (SB3).

Структура на изходния код:

```
implementation/step01/
├─ dqn/
│   ├── replay_buffer.py    # Circular buffer, random batch sampling
│   ├── q_network.py        # MLP Q-function
│   ├── agent.py            # DQNAgent: select/store/train/sync/save
│   └─ train.py             # Training loop, best-model checkpointing, early stop
├─ ppo/
│   ├── networks.py         # PolicyNetwork (actor), ValueNetwork (critic)
│   ├── gae.py              # Generalized Advantage Estimation (reverse sweep)
│   ├── agent.py            # PPOAgent: rollout → GAE → clipped SGD
│   └─ train.py             # Training loop, rollout collection, logging
├─ compare_sb3.py           # Comparison script - reads TB logs, trains SB3
├─ config.py                # DQN_CONFIG, PPO_CONFIG
└─ utils/
    └─ logger.py            # TensorBoard SummaryWriter wrapper
```

1.3 DQN - Дълбока Q-мрежа

1.3.1 Архитектура

Среда: CartPole-v1 - четиримерен непрекъснат вектор на наблюдение, два вида дискретни действия и максимум от 500 стъпки в един епизод.

q-мрежа: Два скрити слоя с ReLU активации и без изходна активация (тъй като q-стойностите могат да приемат всяка реална стойност). Размерът ѝ е [obs_dim=4 → 128 → 128 → 2].

Буфер за възпроизвеждане: Предварително заделени numpy масиви с кръгов курсор за запис, които съхраняват кортежи от вида (състояние, действие, награда, следващо състояние, приключено). Случайната извадка от минипакет прекъсва времевата корелация между последователните преходи.

Целева мрежа: Замразено копие на q-мрежата, което се синхронизира на всеки target_update_freq епизода. Предотвратява нестабилния цикъл на обратна връзка, при който целта се изменя със същата скорост като прогнозите, които се обучават.

1.3.2 Ключови проектни решения

Решение	Избор	Обосновка
График на изследване	Епизодно базирано ϵ -затихване ($\epsilon \times 0.995$ на епизод)	По-предвидимо е от базираното на стъпка, когато дължината на епизода варира
Минимален епсилон	$\epsilon_{\min} = 0.001$	Избягва смъртоносни случайни действия след сходимост; по-нисък от стандартния 0.05 на SB3
Синхронизация на целта	На всеки 5 епизода	Балансира стабилност и скорост; твърде рядка (на всеки 10) водеше до по-бавни плато
Размер на мрежата	[128, 128]	С мрежа [64, 64] се достигаше плато около 300 средна награда; по-голяма мрежа се учеше по-бързо
Размер на буфера	50,000	По-малък (10K) водеше до преобучение към скорошен опит

1.3.3 Итерации на хиперпараметри

Окончателната **конфигурация** беше достигната след три кръга от настройки:

Run 1 - Базова линия (500 епизода)

- Конфигурация: `buffer=10K`, `hidden=[64,64]`, `episodes=500`, `target_freq=10`, `ε_min=0.01`
- Резултат: Крайна средна стойност 225; не се премина целта от 475
- Проблем: Малък буфер и мрежа; редки актуализации на целта

Run 2 - Първа настройка (1000 епизода)

- Конфигурация: `buffer=50K`, `hidden=[128,128]`, `episodes=1000`, `target_freq=5`, `ε_min=0.01`
- Резултат: Постигната пикова средна стойност **479.1** на епизод 810, но в края тя спадна до 302.6
- Проблем: `ε_min=0.01` означава постоянно 1% случайни действия - достатъчно, за да се прекратят дългите епизоди
- Необходима корекция: Намаляване на стойността на `ε_min` + добавяне на най-добър модел с контролна точка

Run 3 - Финална (1500 епизода, добавено ранно спиране)

- Конфигурация: същата + `ε_min=0.001`, `episodes=1500`
- Добавено запазване на най-добър модел и ранно спиране (запазва при първо достигане на целта от 475 и прекратява обучението)
- Резултат: **Решена в епизод 1011**, Средна стойност(100) = **477.5** ✓

1.3.4 Крайни резултати

Метрика	Стойност
Решена в епизод	1011
Финална средна награда (100 еп.)	477.5
Цел	475.0
Общо обучени епизоди	1011 (ранно спиране)
Най-добър модел	<code>models/dqn_cartpole_best.pt</code>

1.4 PPO - Оптимизация на проксималната стратегия

1.4.1 Архитектура

Среда: LunarLander-v3 - 8-измерно непрекъснато наблюдение и 4 дискретни действия. Успешното кацане носи +200 точки, катастрофата води до -100, а разходът на гориво се санкционира.

Актьор-оценител (отделни мрежи): - **PolicyNetwork:** [obs=8 → 128 → 128 → 4] с логити, преобразувани в Categorical разпределение - **ValueNetwork:** [obs=8 → 128 → 128 → 1] с изход като неограничена скаларна величина

Отделните мрежи предотвратяват смущението в градиента между стратегията и стойностната цел. Един Adam optimizer обучава и двете чрез комбинираната загуба.

Generalized Advantage Estimation ($\lambda=0.95$): Изчислява се чрез обратно обхождане на буфера за разгръщане. Маската (1 - done) нулира стойностите от буутстрапинга в границите между епизодите, като по този начин коректно обработва разгръщанията, които преминават през множество епизоди.

Изрязана сурогатна цел:

$$L^{CLIP} = \mathbb{E} \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]$$

където $r_t(\theta) = \pi_{\theta}(a|s) / \pi_{old}(a|s)$ и $\epsilon = 0.2$.

1.4.2 Ключови решения в проектирането

Решение	Избор	Обосновка
Нормализиране на предимството	Средна стойност нула, единично стандартно отклонение за всяко разгръщане	Стабилизира големината на градиента при различни мащаби на наградата
Бонус за ентропия	coef = 0.01	Предотвратява преждевременен колапс на стратегията; насърчава изследването
Отсичане на градиента	max_norm = 0.5	Избягва експлодиращ градиент по време на ранното обучение
Дължина на разгръщане	n_steps = 2048	Достатъчно дълго за многостъпково разпределяне на заслугата при кацания

Решение	Избор	Обосновка
Mini-batch SGD	10 епохи, партида=64	Стандартен PPO; всяко разгръщане се използва повторно 10 пъти преди изхвърляне

1.4.3 Итерации на хиперпараметрите

Изпълнение 1 - Базова линия (300K стъпки, hidden=[64,64])

- Резултат: Постигната пикова средна стойност **179.9**, без преминаване на целта от 200
- Проблем: Малката мрежа е недообучена за 8-измерното наблюдение на lunarLander
- Също така: 300K стъпки са едва достатъчни за пълна сходимост

Изпълнение 2 - Финално (500K стъпки, hidden=[128,128])

- Размерът на мрежата е удвоен; обучителният бюджет е увеличен с 67%
- Резултат: **Решено на 264K стъпки** (задействано е ранно спиране), средната стойност за 100 епизода = **202.2 ✓**
- Забележително: проблемът е решен 236K стъпки *преди* изчерпването на обучителния бюджет


1.4.4 Финални резултати

Метрика	Стойност
Решено на стъпка	264,192
Финална средна награда (100 епизода)	202.2
Цел	200.0
Общо обучени стъпки	264,192 (ранно спиране)
Най-добър модел	models/ppo_lunarlander_best.pt

1.5 Сравнение с базовите решения на SB3

SB3 беше обучен с еднакви основни хиперпараметри (скорост на обучение, γ , размер на мрежата, диапазон на изрязване и др.) и **съответстващи бюджети за стъпки**. Източник: `implementation/step01/compare_sb3.py`.

1.5.1 4.1 DQN върху cartPole-v1



Фигура 1: DQN Learning Curves

Персонализираният DQN решава cartPole около **епизод** ~1011 и достига **целта** от 475 (средна стойност за **епизод**, изчислена върху 100 **епизода**). SB3 DQN, обучен със 750K стъпки ($\approx 17K$ **епизода**), достига максимум с най-добра пълзяща средна стойност за 100 **епизода** от 293.9 - започва да се подобрява около **епизод** 12K и показва пикове, достигащи 500, но никога не поддържа средна стойност за 100 **епизода** над 300.


Защо тази разлика? Три различия в реализацията я обясняват:

1. **График на изследване:** Нашият ϵ намалява с всеки **епизод** ($\times 0.995$), което позволява графикът на изследване да насочи обучителния бюджет към по-информативни **епизоди**, докато тяхната продължителност нараства. При SB3 ϵ намалява линейно спрямо броя *стъпки* ($\text{exploration_fraction} = 0.36 \rightarrow 270K$ стъпки). В среди с кратки **епизоди** като cartPole, намаляването на базата на стъпки води до пропиляване на множество **епизоди** в почти случайна **мода**, преди да започне експлоатацията.
2. **Честота на синхронизация на целевата мрежа:** Нашият код синхронизира на всеки 5 **епизода** - *адаптивен план*: около 100 стъпки в началото и около 2500 стъпки, когато задачата е решена. SB3 използва фиксиран интервал от 1000 стъпки. Адаптивният план осигурява по-бърза обратна връзка в началните етапи на обучението.
3. **Ранно спиране:** Нашият агент прекратява обучението при достигане на пикова производителност, като така се избягва катастрофално забравяне. SB3 изпълнява целия предвиден бюджет и в тази среда неговата стратегия колебае се - решава задачата от време на време, но не успява да задържи решението.

Това са реални алгоритмични различия, а не несправедливост при настройката на хиперпа-

параметрите. За рамка с общо предназначение като SB3 граfiците, базирани на стъпки, са подходящи за разнообразни среди; нашият избор, специфичен за задачата, просто дава по-добри резултати на cartPole.

1.5.2 4.2 PPO на lunarLander-v3



Фигура 2: PPO Learning Curves


Персонализираният PPO достига целта от 200 около **епизод ~543** (264K стъпки). **SB3 PPO**, със същия бюджет от стъпки (500K стъпки), постига най-добър пълзящ среден за последните 100 **епизода** от **131.2** и продължава да се покачва в края на обучението.

Разликата тук е по-малка, отколкото при DQN. И двата алгоритъма използват идентични хиперпараметри на PPO. Оставащата разлика вероятно се дължи на: - ортогоналната инициализация на теглата и вграденото нормализиране на наблюденията на SB3, които подпомагат по-дългите изпълнения, но могат да забавят ранната сходимост; - по-консервативното вътрешно конструиране на минипакети и графика за промяна на скоростта на обучение на SB3.

При предоставяне на по-голям обучителен бюджет (напр. 1–2 милиона стъпки), SB3 PPO вероятно би сходил към целта. Нашият персонализиран PPO е просто по-ефективен по отношение на пробите за тази конкретна задача.

1.5.3 4.3 Обобщение на постигнатата максимална производителност

Peak Performance — Custom vs SB3 (best rolling-100 avg)



Фигура 3: Peak Performance

Алгоритъм	Среда	Най-добра средна стойност (подвижна 100)	Най-добра средна стойност на SB3 (подвижна 100)	Цел
DQN	cartPole-v1	477.5	293.9	475
PPO	lunarLander-v3	180.3	131.2	200

Методологична бележка: „Най-добра средна стойност (подвижна 100)“ е максимумът на 100-епизодния подвижен среден по цялата крива на обучение. Тази метрика е справедлива независимо от ранно спиране: тя измерва пиковата способност, а не къде обучението се е случило да приключи. Бюджетите за стъпки са съпоставени (DQN: 750K, PPO: 500K).

1.6 Ключови изводи

1.6.1 5.1 DQN

- Най-добър модел с контролна точка е от съществено значение:** DQN е податлив на катастрофално забравяне, след като епсилон достигне своя минимум. Запазването на най-добрия модел предотвратява загубата на добро решение.

2. **$\epsilon_{\min}$ има по-голямо значение от очакваното:** Намалването от 0.01 до 0.001 беше разликата между деградираща стратегия и стабилна такава.
3. **Честота на синхронизация на целевата мрежа:** Синхронизирането на всеки 5 епизода последователно даваше по-добри резултати от това на всеки 10. Твърде рядко → бавно обучение; твърде често → нестабилност (еквивалентно на липса на целева мрежа).
4. **Изследване, базирано на епизод срещу стъпково изследване:** За среди с нарастваща дължина на епизода (като cartPole), намаляването, базирано на епизод, е поестествено - агентът наблюдава повече от динамиката на средата, преди да прекрати изследването.

1.6.2 5.2 PPO

1. **Тясно място в размера на мрежата:** [64, 64] създаде тясно място в обучението върху 8-измерното пространство на lunarLander. Удвояването до [128, 128] беше решаващата промяна.
2. **Нормализирането на предимството е задължително:** Без него величините на градиента се мащабират спрямо абсолютните награди. Наградите в lunarLander варират от -500 до +300, което води до катастрофално големи актуализации без нормализиране.
3. **GAE $\lambda = 0.95$ е устойчив:** Стандартната стойност работеше добре без настройка.
4. **Бонусът за ентропия предотвратява застой:** Без него стратегията сходи към „висяне на място“ (локално безопасна, но неоптимална стратегия) в ранните етапи на обучението на lunarLander.

1.6.3 5.3 Реализация от нулата срещу SB3

- Чиста реализация от нулата е с обем 300–500 реда, докато SB3 има ~10,000 реда. Компромисът е по-малко функции, но пълна прозрачност и възможност за отстраняване на грешки.
- Настройките по подразбиране в SB3 са оптимизирани за устойчивост в широк кръг среди (като Atari Games с милиони стъпки и дискретни входни данни от изображения), а не за класически задачи за управление като cartPole. Това кара алгоритъма по подразбиране на SB3 да се затруднява или да се проваля без обширна настройка в сравнение с нашите специфични за средата хиперпараметри.
Специфичните за задачата реализации могат да превъзхождат настройките по подразбиране на SB3 при подходящи хиперпараметри.
- За изследователски цели (дипломна работа върху експлоатация на противника, стъпки 7–8), персонализираните реализации позволяват целенасочени модификации (например инжектиране на наблюдения на състоянието на убежденията), които биха изиск-

вали дълбоко подкласиране в SB3.

1.7 Приложение - Възпроизвеждане

From repo root, with .venv activated:

Train DQN (early stops ~episode 1000):

`python implementation/step01/dqn/train.py`

Train PPO (early stops ~step 264K):

`python implementation/step01/ppo/train.py`

Regenerate comparison figures (caches SB3 results after first run):

`python implementation/step01/compare_sb3.py`

View training curves in TensorBoard:

`tensorboard --logdir implementation/step01/logs/`

Генерираните фигури са в deliverables/reports/step01/figures/.