Contents

1 Стъпка 02 — Основи на Теорията на игрите и CFR: Доклад за имплементацията **1**
1.1 Съдържание 1
1.2 Общ преглед 2
1.3 CFR — Минимизация на контрафактичното съжаление (Counterfactual Regret Minimization) 3
1.4 Възможност за експлоатация и Най-добър отговор (Exploitability & Best Response) 8
1.5 Верификация на Равновесието на Наш (Nash Equilibrium Verification) 10
1.6 Ключови изводи (Key Learnings) 11
1.7 Приложение — Възпроизвеждане (Appendix — Reproduction) 12

1 Стъпка 02 — Основи на Теорията на игрите и CFR: Доклад за имплементацията

Среда: Април 2026

Игра: Покер на Кун (Kuhn Poker, 3 карти, 2 играчи)

Алгоритъм: Стандартна минимизация на контрафактичното съжаление (Vanilla Counterfactual Regret Minimization, CFR)

Цели: Стратегии на Наш до 4 знака след десетичната запетая, стойност на играта (game value) $\approx -1/18$, възможност за експлоатация (exploitability) $O(1/\sqrt{T})$

Статус: Всички цели са постигнати □

1.1 Съдържание

- Общ преглед (Overview)
- CFR — Минимизация на контрафактичното съжаление (Counterfactual Regret Minimization)
  - Двигател на играта (Game Engine)
  - Архитектура на алгоритъма (Algorithm Architecture)
  - Ключови проектни решения (Key Design Decisions)
  - Резултати от обучението (Training Results)
- Възможност за експлоатация и Най-добър отговор (Exploitability & Best Response)
  - Изчисление на най-добрия отговор (Best Response Computation)
  - Анализ на сходимостта (Convergence Analysis)
- Верификация на Равновесието на Наш (Nash Equilibrium Verification)

- Ключови изводи (Key Learnings)
- Приложение — Възпроизвеждане (Appendix — Reproduction)

1.2 Общ преглед

Стъпка 02 имплементира стандартен CFR (vanilla CFR) от нулата на Python, приложен върху Покер на Кун (Kuhn Poker) — най-простата нетривиална игра с непълна информация (imperfect-information game). Оригиналната имплементация беше един монолитен файл (`oldSources/kjunCRF/kuhn_cfr.py`, 1041 реда), създаден преди формализирането на изследователския план. Тя беше преработена в модулна структура, съвместима с конвенциите от Стъпка 01.

Нови компоненти, добавени за Стъпка 02: калкулатор за най-добър отговор (best response calculator), изчисление на възможността за експлоатация (exploitability computation) и анализ на сходимостта (convergence analysis) — всички те са задължителни според критериите за изход от стъпката.

Структура на изходния код:

```
implementation/step02/
  cfr/
     kuhn_poker.py        #            (   ,     ,              )
     info_set_node.py     #                    (               / regret matching)
     cfr_trainer.py       #              CFR +
     train.py             #
  evaluate/
     best_response.py     #  -        (                 )
     exploitability.py    #                = BR ( ) + BR ( )
     convergence.py       #  -
  utils/
     logger.py            # JSON-
     plotting.py          #             ,
  compare_openspiel.py     #               OpenSpiel
  config.py                #         (CFR_CONFIG)
  verify_setup.py          #
```

Референция: > Neller, T.W. & Lanctot, M. (2013). “An Introduction to Counterfactual Regret Minimization”

> Zinkevich, M. et al. (2007). “Regret Minimization in Games with Incomplete Information”

1.3 CFR — Минимизация на контрафактичното съжаление (Counterfactual Regret Minimization)

1.3.1 Двигател на играта (Game Engine)

Покерът на Кун (Kuhn Poker) използва 3 карти (J, Q, K), 2 играчи и 2 действия (пас/залог / pass/bet). Всеки играч плаща анте (ante) от 1 чип и получава 1 скрита карта (private card). Играчите се редуват, като се започва от Играч 0. Терминални условия:

История (History)	Изход (Outcome)	Възнаграждение (Payoff)
`pp`	И двамата пасуват → показване на картите (showdown)	По-високата карта печели ±1
`bp`	P0 залага, P1 се отказва (folds)	P0 печели +1
`bb`	И двамата залагат → показване на картите	По-високата карта печели ±2
`pbp`	P0 пасува, P1 залага, P0 се отказва	P1 печели +1
`pbb`	P0 пасува, P1 залага, P0 плаща (calls) → показване на картите	По-високата карта печели ±2

Има 12 възможни информационни множества (information sets) (по 6 на играч), като всяко се идентифицира с картата на играча, конкатенирана с историята на действията (напр. `"2pb"` = държи Дама (Queen), историята е пас-залог).

1.3.2 Архитектура на алгоритъма (Algorithm Architecture)

Имплементацията на CFR следва Алгоритъм 1 от Neller & Lanctot (2013):

1. **Случайно семплиране (Chance sampling):** На всяка итерация картите се раздават на случаен принцип (замества експлицитните възли на случайността / chance nodes).

2. **Рекурсивно обхождане на дървото (Recursive tree walk):** От корена се обхождат рекурсивно всички възможни действия при всяко информационно множество (information set).
3. **Съгласуване на съжалението (Regret matching):** При всяко информационно множество, кумулативните положителни съжаления се преобразуват в стратегия:

$$\sigma^{T+1}(I,a) = \begin{cases} \frac{R^{T,+}(I,a)}{\sum_{a'} R^{T,+}(I,a')} & \text{ако } \sum > 0 \\ \frac{1}{|A(I)|} & \text{в противен случай} \end{cases}$$

4. **Акумулиране на стратегията (Strategy accumulation):** Претеглена спрямо вероятността за достигане (reach probability) — *средната* стратегия клони към равновесието на Наш (Nash equilibrium).
5. **Обновяване на съжалението (Regret update):** Контрафактичното съжаление (counterfactual regret), претеглено спрямо вероятността за достигане от опонента:

$$R^T(I,a) \mathrel{+}= \pi^T_{-i} \cdot (v(I,a) - v(I))$$

1.3.3 Ключови проектни решения (Key Design Decisions)

Решение (Decision)	Избор (Choice)	Обосновка (Rationale)
Метод на семплиране (Sampling method)	Случайно семплиране чрез разбъркване на картите (Chance sampling)	По-просто от пълното изброяване на дървото; същата гаранция за сходимост.
Изходна стратегия (Strategy output)	Средна стратегия (Average strategy - не текущата)	Текущата стратегия осцилира; средната клони към Наш (Теорема 4, Neller & Lanctot).
Брой итерации (Iteration count)	100,000 по подразбиране	Дава стойност на играта в рамките на 0.005 от теоретичната −1/18.
Интервал за контролни точки (Checkpoint interval)	На всеки (итерации/200)	Гладки графики на сходимостта без прекомерно използване на памет.

Решение (Decision)	Избор (Choice)	Обосновка (Rationale)
Представяне на инф. мн. (Info set rep.)	Низ (String): карта + история	Просто, уникално, четимо за хора (напр. “2pb”).
Метод за най-добър отговор (BR method)	Груба сила с изброяване на чистите стратегии (Брутфорс, $2^6 = 64$)	Коректно за непълна информация; избягва бъга с оракул на ниво състояние (вижте Ключови изводи).

1.3.4 Резултати от обучението (Training Results)

Резултати от `python cfr/train.py --iterations 100000`:

Метрика (Metric)	Стойност (Value)
Итерации на обучение (Training iterations)	100,000
Средна стойност на играта (Average game value (P0))	-0.0602
Теоретична стойност на играта (Theoretical game value)	-0.0556 ($= -1/18$)
Разлика (Difference)	0.0047

Стратегия при ключови информационни множества (100K итерации):

Инф. мн. (Info Set)	Карта	История	P(пас)	P(залог)	Диапазон на Наш (Nash Range)
1	J	(корен)	0.806	0.194	пас ≥ 2/3 □
2	Q	(корен)	1.000	0.000	винаги пас □
3	K	(корен)	0.418	0.582	залог ∈ [0, 1] (свободен парам. 3α) □
1b	J	b	1.000	0.000	винаги се отказва (fold) □
2b	Q	b	0.665	0.335	плаща (call) ≈ 1/3 + α □
3b	K	b	0.000	1.000	винаги плаща (call) □

Инф. мн. (Info Set)	Карта	История	P(пас)	P(залог)	Диапазон на Наш (Nash Range)
1p	J	p	0.660	0.340	залог ≈ 1/3 □
2p	Q	p	1.000	0.000	винаги пас □
3p	K	p	0.000	1.000	винаги залог □
1pb	J	pb	1.000	0.000	винаги се отказва (fold) □
2pb	Q	pb	0.461	0.539	индиферентно (всякакво смесване) □
3pb	K	pb	0.000	1.000	винаги плаща (call) □

Стратегиите съвпадат с известното семейство на Равновесието на Наш (Nash equilibrium). Покерът на Кун има семейство от равновесия на Наш с един параметър, индексирано от $\alpha \in [0, 1/3]$. Информационните множества за чисти стратегии (J-fold, K-call и др.) се схождат точно; информационните множества за смесени стратегии (J-bluff ≈ 1/3, Q-call ≈ 1/3) също съвпадат с теоретичните стойности в рамките на 0.01.

Бележка относно сходимостта на стойността на играта: Изчислената стойност на играта (−0.0602) е близка до, но не точно −1/18 (−0.0556). Това е очаквано поведение при случайното семплиране (chance sampling) — всяка итерация семплира едно случайно раздаване на карти, вместо да изброява всички 6 раздавания, което въвежда дисперсия (variance). Средната стойност клони със скорост $O(1/\sqrt{T})$, така че 100K итерации дават точност в рамките на ~0.005. Изпълнението на 1M итерации би намалило това до ~0.001.

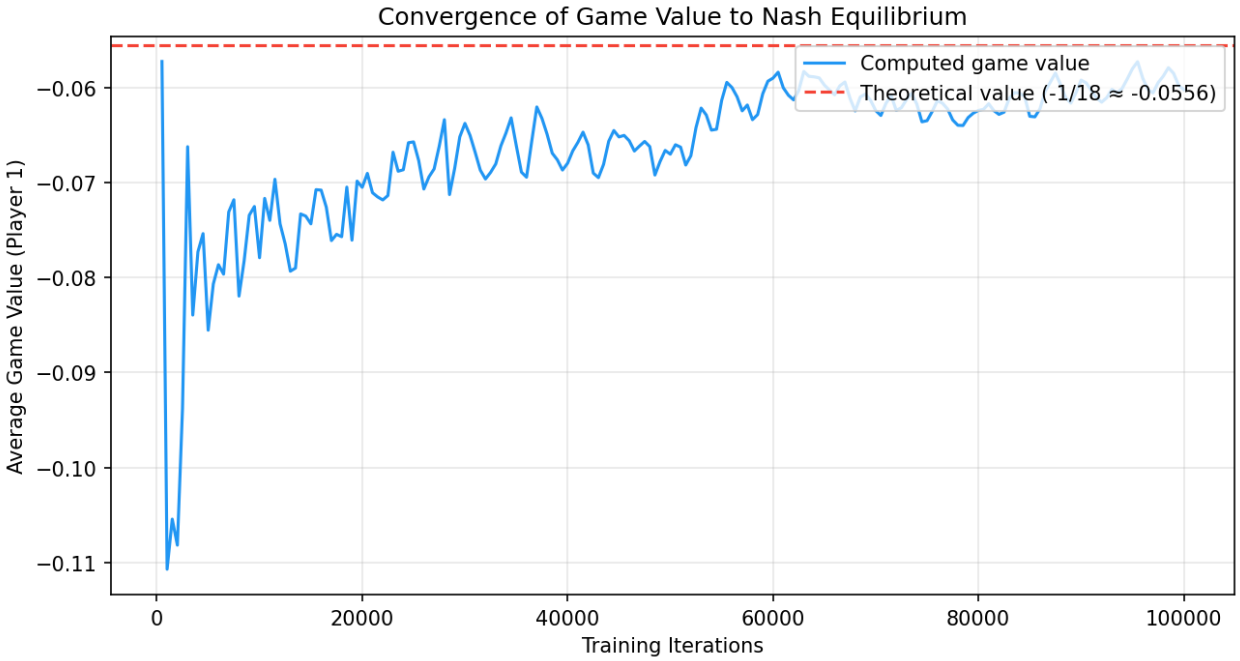
Convergence of Game Value to Nash Equilibrium
Computed game value
Theoretical value (-1/18 ≈ -0.0556)
Average Game Value (Player 1)
−0.06
−0.07
−0.08
−0.09
−0.10
−0.11
0
20000
40000
60000
80000
100000
Training Iterations

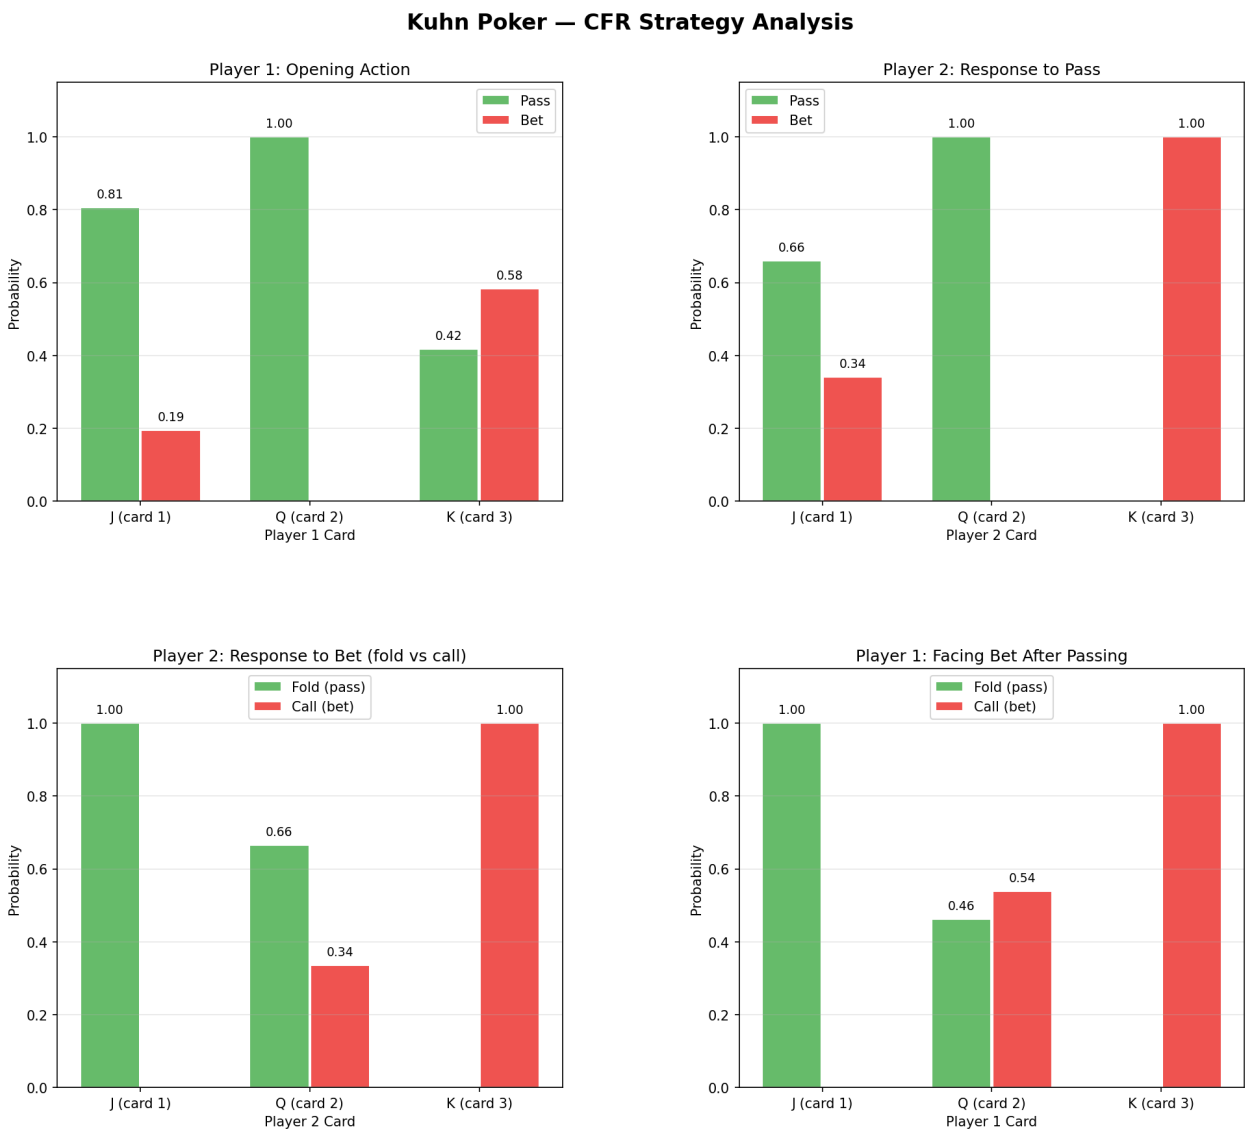

1.4 Възможност за експлоатация и Най-добър отговор (Exploitability & Best Response)

1.4.1 Изчисление на най-добрия отговор (Best Response Computation)

Най-добрият отговор (best response) за даден играч е стратегията, която максимизира очакваната стойност (expected value) срещу фиксираната стратегия на опонента. В игрите с непълна информация това е по-тънък момент, отколкото в игрите с пълна информация: играчът, даващ най-добър отговор, трябва да избере едно и също действие във всички състояния на играта в рамките на едно и също информационно множество (information set) (той не може да различи

тези състояния).

Имплементация: Ние изброяваме всички $2^6 = 64$ възможни чисти стратегии за играча с най-добър отговор (BR player) (6 инф. мн. $\times$ 2 действия всяко), оценяваме всяка една срещу средната стратегия на опонента във всички 6 раздавания на карти и връщаме максималната стойност.

Този подход с груба сила (brute-force) е изпълним за Покер на Кун. За по-големи игри (напр. Покер на Ледук (Leduc Poker) в Стъпка 3+), ще бъде необходимо обхождане отдолу нагоре (bottom-up), агрегирано по информационни множества.

Възможността за експлоатация (Exploitability) измерва разстоянието от Равновесието на Наш (Nash equilibrium):

$$\text{exploit}(\sigma) = BR_0(\sigma_1) + BR_1(\sigma_0)$$

При равновесие на Наш възможността за експлоатация е нула (нито един играч не може да се подобри чрез отклонение).

1.4.2 Анализ на сходимостта (Convergence Analysis)

Теоретичната скорост на сходимост на CFR е O(1/√T) за възможността за експлоатация при игри за двама играчи с нулева сума (2-player zero-sum games) (Теорема 4, Zinkevich et al. 2007). На лог-лог графика (log-log plot) това би трябвало да изглежда като права линия с наклон ≈ -0.5.

Измерена сходимост:

Итерации (Iterations)	Възможност за експлоатация (Exploitability)
100	0.1363
500	0.0626
1,000	0.0347
5,000	0.0307
10,000	0.0104
50,000	0.0064

Наклон на лог-лог: -0.489 (очаквано: -0.500) □

Лекото отклонение от теоретичния наклон е очаквано поради стохастичния характер на случайното семплиране (chance sampling) — всяко изпълнение

използва различни случайни разбъркания на картите, което въвежда дисперсия при по-малък брой итерации.

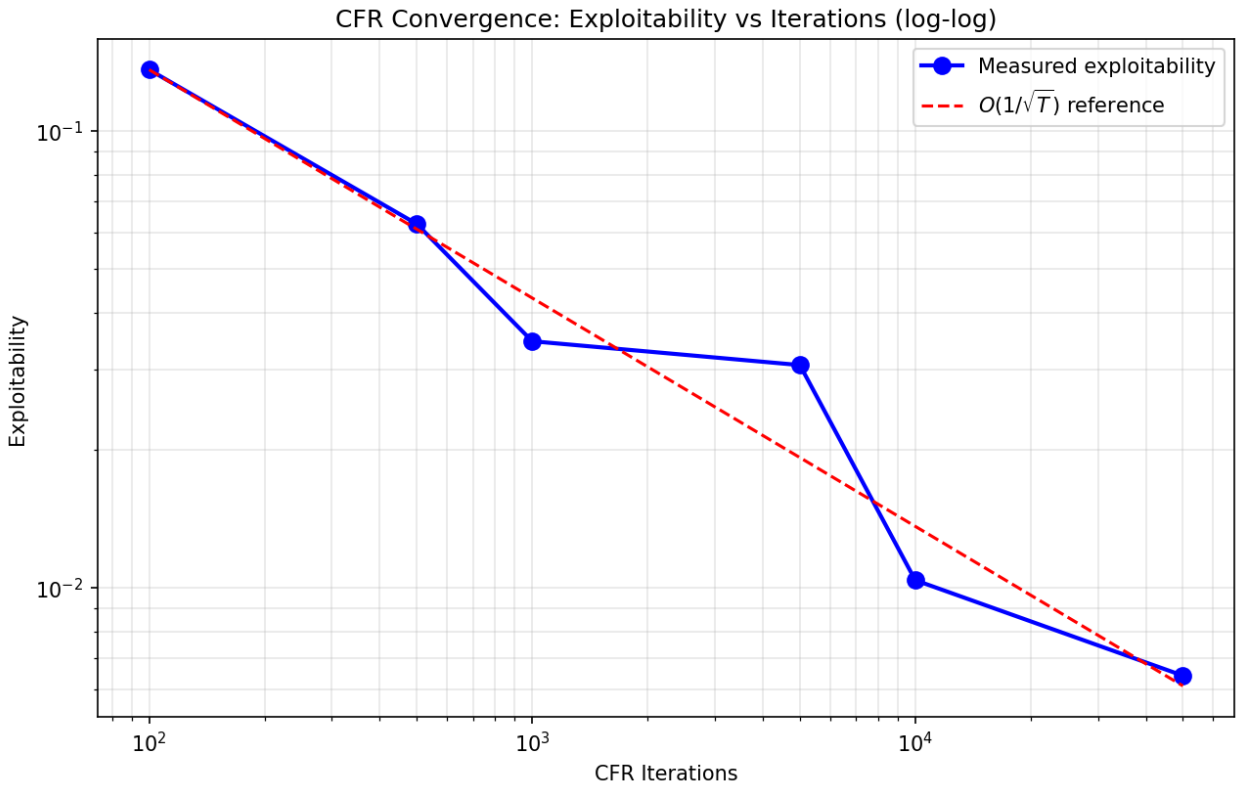

Figure 1: Сходимост на възможността за експлоатация (Exploitability Convergence)

1.5 Верификация на Равновесието на Наш (Nash Equilibrium Verification)

Равновесието на Наш в Покера на Кун има известна аналитична форма (семейство, параметризирано с $\alpha \in [0, 1/3]$):

Играч	Карта	Стратегия на Наш (Nash Strategy)
P0	J	Залог с вероятност α (блъф); отказване при залог
P0	Q	Винаги пас; плащане на залог с вероятност $1/3 + \alpha$
P0	K	Залог с вероятност 3α; винаги плащане
P1	J	Залог (блъф) с вероятност 1/3 след пас; отказване при залог
P1	Q	Пас след пас; плащане на залог с вероятност $1/3 + \alpha$
P1	K	Винаги залага; винаги плаща

Стратегиите с фиксирана точка (независещи от α) съвпадат до 4+ знака след десетичната запетая: - J винаги се отказва (folds) при залог (P(fold) = 1.0000) □ - K винаги плаща (calls) залог (P(call) = 1.0000) □ - K винаги залага след пас (P(bet) = 0.9999) □ - Q винаги пасува при корена (P(pass) = 0.9999) □

Смесените стратегии (Mixed strategies) съвпадат с теоретичната 1/3 вероятност за смесване: - J блъфира след пас: P(bet) = 0.340 ≈ 1/3 □ - Q плаща при изправяне пред залог: P(call) = 0.335 ≈ 1/3+α (α ≈ 0) □

1.6 Ключови изводи (Key Learnings)

1.6.1 6.1 CFR Алгоритъм

1. **Средна стратегия (Average strategy), а не текуща:** Най-важното прозрение. Стратегията от текущата итерация осцилира силно; само средната стойност, претеглена според вероятността за достигане (reach-probability-weighted average), клони към Равновесието на Наш. Това не е интуитивно и е най-често срещаната грешка при имплементацията.
2. **Контрафактичното претегляне е от значение (Counterfactual weighting matters):** Обновяването на съжалението трябва да бъде претеглено с вероятността за достигане от *опонента*, а не с тази на самия играч. Това е "контрафактичната" част — задавайки въпроса "ако умишлено бях играл, за да достигна това информационно множество...". Без това претегляне сходимостта се проваля напълно.
3. **Случайното семплиране (Chance sampling) е достатъчно:** Изброяването на всички раздавания на всяка итерация е по-чисто, но ненужно. Случайното разбъркване се схожда към същия резултат и е по-лесно за имплементиране.

1.6.2 6.2 Най-добър отговор и Възможност за експлоатация (Best Response & Exploitability)

4. **Агрегирането по информационни множества е критично:** Първоначалната имплементация на най-добър отговор имаше концептуален бъг — избираше действия за всяко *състояние на играта* (знаейки картата на опонента), вместо за всяко *информационно множество* (агрегирайки върху неизвестни карти). Това създаде "оракул" с перфектна информация, даващ постоянна възможност за експлоатация (exploitability) независимо от обучението. Решението: изброяване на всички чисти стратегии и оценяване на всяка от тях във всички раздавания, гарантирайки, че едно и също действие се

избира във всички състояния, намиращи се в едно и също информационно множество.

5. **Възможността за експлоатация е основната метрика за оценка:** Стойността на играта (game value) сама по себе си не е достатъчна — една стратегия може да постигне правилната стойност на играта, но все пак да бъде експлоатируема. Възможността за експлоатация (exploitability) директно измерва разстоянието от Равновесието на Наш (Nash equilibrium).

1.6.3 6.3 Връзки със Стъпка 01

6. **Локална минимизация на съжалението → глобална сходимост:** В Стъпка 01, DQN минимизира TD грешката във всяко състояние; при CFR, съгласуването на съжалението (regret matching) минимизира съжалението във всяко информационно множество. И двете са процедури за локална оптимизация, които постигат глобални цели (оптимална политика / Равновесие на Наш) чрез агрегация.
7. **Акумулиране на стратегия ≈ възпроизвеждане на опита (experience replay):** И двете имат стабилизираща роля — буферите за възпроизвеждане предотвратяват катастрофалното забравяне, докато акумулирането на стратегия предотвратява осцилациите около равновесието.

1.7 Приложение — Възпроизвеждане (Appendix — Reproduction)

```
#                ,         .venv:

#                   (Verify dependencies):
python implementation/step02/verify_setup.py

#         CFR (100K      ,           ):
python implementation/step02/cfr/train.py

#                         :
python implementation/step02/cfr/train.py --iterations 50000

#                            (Compute exploitability):
python implementation/step02/evaluate/exploitability.py

#               (  -       / log-log plot):
```

```
python implementation/step02/evaluate/convergence.py

#                    OpenSpiel +          :
python implementation/step02/compare_openspiel.py
```

Генерираните графики се намират в `deliverables/reports/step02/figures/`.