

Съдържание

1	Стъпка 9 — Многоагентно обучение с подкрепление: Доклад за експериментите	1
2	ЧАСТ I — ЗАЩО МНОГОАГЕНТНОТО ОБУЧЕНИЕ Е ТРУДНО	2
2.1	1. Какво разглеждаме тук	2
2.2	2. Експеримент 1 — независими обучаващи агенти в четирите матрични игри	2
2.3	3. Експеримент 2 — орбитата на нестационарност (игра „хвърляне на монета“ спрямо Дилемата на затворника)	3
2.4	4. Експеримент 3 — самообучение на кун: средна спрямо последна итерация	4
3	ЧАСТ II — СТРУКТУРНИТЕ РЕШЕНИЯ	5
3.1	5. Експеримент 4 — PSRO при различни семейства игри	5
3.2	6. Експеримент 5 — CTDE: дисперсия на оценителя и изкачваща се игра	6
3.3	7. Експеримент 6 — научена комуникация (commNet)	7
3.4	8. Експеримент 7 — LOLA в дилемата на затворника (Iterated Prisoner’s Dilemma)	7
3.5	9. Съгласуване на прогноза и реалност	8
3.6	10. Достоверност и достатъчност на извадката	9
3.7	11. Ограничения (подредени според влиянието им върху изводите)	9
3.8	12. Заключение и насоки за бъдещи изследвания	10
3.9	13. Възпроизвеждане на резултатите	11

1 Стъпка 9 — Многоагентно обучение с подкрепление: Доклад за експериментите

Тестови среди: четири канонични матрични игри 2×2 (дилемата на затворника, игра „хвърляне на монета“, лов на елен, битка на половете); кун покер и ледюк холдем (чрез точния стек от Стъпка 07); собствен двигател за Goofspiel ($K = 3, 4$); две малки кооперативни среди (едностъпковата референтна игра „coosignal“ и изкачващата се игра claus–Boutilier climbing game); както и Iterated Prisoner’s Dilemma с памет 1. Покер игрите използват повторно двигателя за кун от Стъпка 02, двигателя за ледюк от Стъпка 03 и кода за точен най-добър отговор / NashConv от Стъпка 07 изцяло.

Връзка с дисертацията: преминаването от двуигрови игри с нулева сума (Стъпки 2–8) към многоагентно обучение с подкрепление. Три ключови момента: **LOLA** като *динамично моделиране на противника* (Принос №1); **PSRO** като *методология за оценяване на популационно равнище* (Принос №3); и *липсващата $N > 2$ минимакс котва*, при която гаранциите за безопасност, характерни за двуигровите ситуации, се губят (Принос №2).

Обхват на резултатите: всяко число в този доклад е **измерено от реално изпълнение** и прочетено от артефактите от изпълнението под `implementation/step09/implementation/results/{smoke,scale}_results.` и `implementation/step09/exploration/figures/*.json`. Когато е възможно, симулираните числа са оградени с *точен* аналитичен ориентир (аналитично равновесие на Наш за матричните игри; точен най-добър отговор / NashConv от Стъпка 07 за кун, ледюк и Goofspiel). Четири прогнози от фаза 4 бяха **опровергвани** от изпълненията; съгласно работния процес на проекта (§0.1) те са запазени

в първоначалния си вид и съгласувани с това, което действително се случи (§9).

Как да четете този доклад. И двете части следват една и съща дъга: **какво тестваме** → **как** → **резултати** → **заключение**. **Част I (§1–§4)** показва *защо* многоагентното обучение е трудно, върху матрични игри и самообучение в кун. **Част II (§5–§8)** оценява структурните корекции — PSRO, CTDE, комуникация, LOLA — спрямо точни мерки. §9 съгласува четирите опровергани прогнози; §10–§12 обхващат доверие, ограничения и насоки; §13 изброява команди за възпроизвеждане.

2 ЧАСТ I — ЗАЩО МНОГОАГЕНТНОТО ОБУЧЕНИЕ Е ТРУДНО

2.1 1. Какво разглеждаме тук

Single-agent RL предполага **стационарна** среда; многоагентното обучение с подкрепление не, тъй като другите агенти *също се учат*, което прави ефективната среда на всеки агент подвижна цел (**нестационарност**). Част I показва този проблем чрез най-простите възможни контроли — независими градиентни обучаеми в игри с точно известни равновесия на Наш — преди Част II да представи механизма за неговото преодоляване. Всички данни от Част I произлизат от инициализираните скриптове за изследване (`exploration/figures/*.json`); обучаемите използват **точни градиенти**, така че динамиката не съдържа шум от извадката и въпросът „сходя ли се?“ има еднозначен отговор.

2.2 2. Експеримент 1 — независими обучаващи агенти в четирите матрични игри

Какво изследваме. Достигат ли два независими градиентни обучаеми до аналитичното равновесие на Наш за всяка канонична 2×2 игра и ако не, по какъв начин се провалят?

Как. Двама обучаващи с точен градиент, 4000 стъпки, скорост на обучение 0.1, симетричен старт (0.5, 0.5) и начално число 0. „Сходим“ означава, че последните 100 стъпки са останали почти непроменени. Данни: `exploration/figures/matrix_games_playground.json`.

Игра	p_{final} (ред)	q_{final} (колона)	печалба на реда	сходим?	аналитично равновесие на Наш
дилемата на затворника	0.0025	0.0025	1.008	да	(дефект, дефект), стойност 1

Игра	p_{final} (ред)	q_{final} (колона)	печалба на реда	сходим?	аналитично равновесие на Наш
игра „хвърляне на монета”	0.508	0.496	−0.0001	не	смесено ($\frac{1}{2}, \frac{1}{2}$), стойност 0
лов на елен	0.0009	0.0009	2.997	да	(заек, заек), рисково доминиращ, стойност 3
битка на половете	0.0029	0.0014	0.996	да	(футбол, футбол), ред 1 / колона 2

(Тук индекс на действие 0 е Сътрудничество/Елен/Опера; $p \rightarrow 0$ означава, че обучаемият от реда играе *второто* действие — дефект/заек/футбол.)

Резултати. Три от четири сходяват към истинско равновесие на Наш. Дилемата на затворника завършва във взаимно предателство (доминираща стратегия). Ловът на елен се установява върху **рисково доминиращия** вариант (заек, заек), вместо върху доминиращия по печалба (елен, елен) — безопасният ъгъл надделява при градиентна динамика. Битката на половите се координира в едно чисто равновесие. Играта „хвърляне на монета“ **не сходява**: обучаемите остават близо до (0.51, 0.50) на стъпка 4000, но изпълнението отчита *несходим*, а §3 показва, че траекторията продължава да се движи.

Заключение. Самостоятелното обучение е контролът, който се проваля *умишлено*: то работи там, където играта има доминираща стратегия или достижимо чисто равновесие, и се проваля там, където единственото равновесие е смесено. Този провал е случаят за всичко в Част II.

2.3 3. Експеримент 2 — орбитата на нестационарност (игра „хвърляне на монета“ спрямо Дилемата на затворника)

Какво тестваме. При играта „хвърляне на монета“ намалява ли разстоянието до смесеното равновесие на Наш с времето (сходимост), или остава непроменено (нестационарност)?

Как. Проследяваме разстоянието до нашово равновесие в последователни времеви прозорци и го сравняваме с разстоянието до (дефект, дефект) при дилемата на затворника. Стъпки 6000, lr 0.1, начално число 0, изследване от нецентрична позиция (0.7, 0.3). Данни: `exploration/figures/nonstationarity_demo.json`

Времеви прозорец	Радиус на игра „хвърляне на монета“	Радиус на дилемата на затворника
1	0.301	0.079
2	0.349	0.010
3	0.391	0.0058
4	0.425	0.0041
5	0.453	0.0032
6	0.476	0.0026

Резултати. Радиусът на дилемата на затворника клони към нула (сходимост). Радиусът на игра „хвърляне на монета“ **нараства**, от 0.30 до 0.48 — траекторията спираловидно се отдалечава *навън* към границата, вместо да се установява или да поддържа постоянна орбита.

Заклучение. Нестационарността е структурна: по-голяма изчислителна мощност води до по-силно разминаване, а не до сходимост. (Това противоречи на прогнозата за „постоянна радиус орбита“ във Фаза 4; виж §9.)

2.4 4. Експеримент 3 — самообучение на кун: средна спрямо последна итерация

Какво изследваме. При самообучение чрез фиктивна игра в реална игра с непълна информация, сходява ли се *средната* стратегия към наш равновесие, дори когато *последната* итерация не го прави?

Как. Фиктивна игра на кун (всеки играч дава точен най-добър отговор на плъзгащата средна на опонента чрез точния най-добър отговор от Стъпка 07), 200 итерации, измервани през всеки 5. Проследяваме NashConv на средната итерация и NashConv на последната итерация. Данни: `exploration/figures/selfplay_vs_nash.json`.

Итерация	NashConv на средната итерация	NashConv на последната итерация
5	0.240	0.500
50	0.063	0.500
100	0.046	0.500
150	0.038	0.500
200	0.031	0.500

(Стойността на последната итерация се колебае в $\{0.33, 0.50, 0.67, 0.83\}$ през цялото време — тя никога не показва тенденция към намаляване.)

Резултати. Експлоатируемостта на средната итерация намалява монотонно от 0.24 до 0.031, а стойността на последната итерация продължава да осцилира в $[0.33, 0.83]$.

Заклучение. Самообучението се сближава **в средното, а не при последната итерация** — това е конкретната причина за осредняването (CFR, фиктивна игра) и за използването на смес от мета-Наш популации в PSRO вместо да се разчита единствено на най-новата стратегия (§5).

3 ЧАСТ II — СТРУКТУРНИТЕ РЕШЕНИЯ

3.1 5. Експеримент 4 — PSRO при различни семейства игри

Какво изследваме. Дали PSRO (популация + мета-Наш + предсказвач за най-добър отговор) свежда експлоатируемостта на мета-Наш сместа до нула и дали това се запазва при игри с различни мащаби?

Как. PSRO с **точния** двигател за най-добър отговор от Стъпка 07. Мета-Наш сместа на опонента върху поведенчески стратегии се свежда до една единствена стратегия на поведение, реализационно еквивалентна (Kuhn’s Theorem, пълна памет), така че да може да се приложи двигателят за точен BR. Експлоатируемостта се изчислява като NashConv на мета-сместа в пълната игра. Данни: results/scale_results.json (psro блок); RPS от exploration/figures/psro_peek.json.

Игра	кръг 0	финален (кръг)	присъда
кун покер	0.917	$\sim 2 \times 10^{-16}$ (6)	конвергира към Machine Zero
матрица (игра „хвърляне на монета”)	2.0	0.0 (2)	конвергира
камък-ножица-хартия	2.0	0.017 (4)	конвергира; смес $\rightarrow$ (0.335, 0.336, 0.329)
Ледюк Холдем	4.75	2.16 (19)	намалява, над целта от 0.5
Goofspiel ($K = 3$)	1.33	0.0 (1)	конвергира
Goofspiel ($K = 4$)	1.50	1.71; колебае се 1.4–2.0	не достига установяване

Резултати. При малките игри (кун, матрица, RPS, Goofspiel $K = 3$) експлоатируемостта спада до практически нула в рамките на няколко рунда — типично поведение при двойно предсказание. Ледюк намалява постепенно ($4.75 \rightarrow 2.16$), но остава значително над 0.5 целта след 20 рунда. Goofspiel $K = 4$ продължава да се колебае между ~ 1.4 и ~ 2.0 , без да достига установяване.

Заклучение. PSRO е потвърден като MARL при малките игри, използвайки същия показател за точна експлоатируемост както в стъпки 2–8. Два резултата — бавната сходимост на **ледюк** и колебанието на Goofspiel $K = 4$ — не съответстваха на прогнозите и са разгледани в §9.

3.2 6. Експеримент 5 — CTDE: дисперсия на оценителя и изкачваща се игра

Какво тестваме. (а) Притежава ли *централизираният* оценител по-ниска дисперсия на целевата стойност в сравнение с *независимите* оценители? (б) Дава ли централизираният оценител възможност на сътрудническите се обучаеми да избегнат капан на нескоординираност и да превъзхождат независимите обучаващи агенти?

Как. (а) MADDPG върху задачата CoopSignal с една стъпка, обучавайки централизиран $Q(s, \text{joint } a)$ и на агент $Q_i(o_i)$ върху едни и същи данни; сравняване на остатъчната загуба в края. (б) Независими обучаващи агенти, MADDPG и MAPPO върху claus–Boutilier climbing game (оптимум 11, фланкиран от наказания —30; безопасен атрактор 5); сравняване на наградата за отборна алчност. Данни: results/scale_results.json (coop блок).

(а) Дисперсия на оценителя (CoopSignal):

Оценител	остатъчна загуба (загуба на стойност)
централизираният $Q(s, \text{joint } a)$	3.17×10^{-11}
независимият $Q_i(o_i)$	0.0766

(б) Награда за алчност в изкачващата се игра:

Обучаващ агент	награда	(оптимум 11, безопасен 5)
независими обучаващи агенти	7.0	—
MADDPG	5.0	—
MAPPO	7.0	—

Резултати. (а) Остатъкът на централизирания оценител е практически нула (той се обуславя от целта и съвместното действие, така че наградата е детерминистична спрямо неговите входове), с порядъци по-нисък от остатъка на независимия оценител 0.077 — твърдението за намаляване на дисперсията на CTDE е потвърдено. (б) **Нито един метод не достига оптимума**; независимите обучаващи агенти и MAPPO достигат 7, а **MADDPG изостава при 5** (безопасният атрактор).

Заклучение. Централизираният оценител е учител с по-ниска дисперсия (потвърдено), но това само по себе си **не** решава координацията при сложно проучване — наказанията —30 възпират агентите

да опитат съвместното действие, което достига 11. Недостатъчното представяне на MADDPG спрямо независимите обучаващи агенти конкретно насочва вниманието към неговия дискретен актьор с контрафактна базова линия за преглед (§9, §11).

3.3 7. Експеримент 6 — научена комуникация (commNet)

Какво тестваме. Дали научен съобщителен канал позволява на слушател, който не вижда целта, да надхвърли прага на отгатваемост $1/K$?

Как. CommNet върху CoopSignal ($K = 5$, праг на отгатваемост 0.2), обучен при включена и изключена комуникация; сравняване на награда за отборна алчност. Данни: `results/scale_results.json` (`coop.communication`).

Канал	награда за алчност
комуникация върху	0.795
изключена комуникация	0.204

Резултати. При използване на канала наградата е 0.795, значително над прага от 0.2; без него тя е 0.204, точно на прага.

Заклучение. Комуникацията се усвоява от край до край и има реален ефект — говорещият се научава да кодира целта, а слушателят да я декодира. (При конфигурация на дима и двамата бяха 0.24; ефектът изисква обучение до сходимост — §9.)

3.4 8. Експеримент 7 — LOLA в дилемата на затворника (Iterated Prisoner’s Dilemma)

Какво тестваме. Дали учащите, които диференцират спрямо следващата стъпка на обучение на опонента, ще сътрудничат там, където наивните учащи дефектират?

Как. IPD с памет 1 и точна затворена форма на възвръщаемостта; наивни градиентни обучаеми срещу LOLA learners (предвиждане чрез вложени крайни разлики). Сравнение на дисконтираната възвръщаемост на стъпка при пълно сътрудничество ≈ 3 и взаимно предателство ≈ 1 . Данни: `results/scale_results.json(lola)`; крива на изследване в `exploration/figures/lola_ipd_playground.json`.

Обучаеми	възвръщаемост на стъпка
наивни срещу наивни	1.04
LOLA срещу LOLA	2.82

(Изследователският прогон с по-висока степен на предвиждане достига LOLA възвръщаемост от ~ 2.67 – 2.93 в сравнение с наивни ~ 1.06 .)

Резултати. Наивното обучение се сближава до взаимно предателство (1.04); LOLA достига почти пълно сътрудничество (2.82). Вградена проверка потвърждава механизма: при нулева степен на предвиждане градиентът на LOLA съвпада точно с наивния градиент, поради което сътрудничеството се дължи на втория ред.

Заклучение. LOLA преоформя динамиката на учене — *динамично* моделиране на противника — превръщайки дефектзорите в IPD в сътрудници. Това е допълнението с подвижна цел към статичния противник прочит от Стъпка 7 (Принос №1).

3.5 9. Съгласуване на прогноза и реалност

Съгласно работния процес §0.1, противоречащите прогнози от фаза 4 се запазват и съгласуват, а не се редактират мълчаливо. Четири разминавания:

1. **Игра „хвърляне на монета“ орбита (§3).** *Прогнозирано:* чиста орбита с приблизително постоянен радиус около $(\frac{1}{2}, \frac{1}{2})$. *Измерено:* радиусът нарасна $0.30 \rightarrow 0.48$ (външна спирала); софтвак обучаващият в имплементацията се отклони към ъглите ($\text{NashConv} \sim 1.8$). *Съгласуване:* урокът за несходимост остава валиден и е по-ясен; мисловният модел „енергозапазваща орбита“ беше погрешен, а действителното отклонение на границата представлява по-силен аргумент в полза на методи на осредняване. Това не е грешка — наблюдавани са две различни, но валидни градиентни динамики.
2. **PSRO върху ледюк (§5).** *Прогнозирано:* експлоатируемост < 0.5 в рамките на 20 итерации. *Измерено:* $4.75 \rightarrow 2.16$ за над 20 рунда — намаляваща, но далеч над 0.5. *Съгласуване:* действително наблюдаваме бавна сходимост, а не бърз — кун достигна Machine Zero за 6 рунда, но дървото на ледюк е значително по-голямо и популация от 20 члена с чисти стратегии не може да апроксимира достатъчно добре неговото смесено равновесие на Наш. Поставената цел беше прекалено оптимистична; наблюдаемата низходяща тенденция е правилното поведение. Това се потвърждава от чистата сходимост на кун/матрица/RPS по същия път в кода.
3. **Goofspiel $K = 4$ (§5).** *Прогнозирано:* неувеличаваща се експлоатируемост. *Измерено:* $K = 3$ сходи към 0; $K = 4$ колебае се в интервала 1.4–2.0. *Съгласуване:* единствената неразрешена аномалия. Документирана, но не поправена (съгласно избрания път). Основните заподозрени за последващо проучване: драйверът на Goofspiel PSRO никога не премахва дублираните най-добри отговорни политики и една популация от чисти стратегии вероятно е твърде слаба, за да апроксимира достатъчно добре смесеното мета-Наш равновесие на по-голямата игра. Отбелязана като открит елемент в кода — **не** представена като валидиран резултат от PSRO.

4. **Изкачваща се игра (§6).** *Прогнозирано:* централизираният оценител достига оптимума 11 и превъзхожда независимите обучаващи агенти. *Измерено:* никой не достигна 11; независимите обучаващи агенти и MAPPO достигнаха 7, а MADDPG изостана на 5. *Съгласуване:* отделното твърдение за дисперсията на оценителя се потвърди (централен остатък $\sim 3 \times 10^{-11}$ срещу 0.077), така че коректното разделение е „CTDE намалява дисперсията на оценителя $\neq$ CTDE решава координацията при риск от прекомерно изследване“. MADDPG, представяйки резултати под тези на независимите обучаващи агенти, допълнително подчертава неговия контрафактичен базов актьор. Изводът остава валиден, но в по-умерен вид.

Забележка по методологията, която се отнася до всички раздели: двата **невронни** ефекта (дисперсия на оценителя §6а; комуникация §7) бяха **невидими при бързата smoke конфигурация** — включена комуникация = изключена комуникация = 0.24, загубите на оценителя почти еднакви (0.0897 срещу 0.0927) — и се проявиха единствено при **scale** конфигурацията. Числата от **scale** конфигурацията са тези, върху които почиват твърденията за **невронните** мрежи.

3.6 10. Достоверност и достатъчност на извадката

- **Игровитеоретичните резултати са ограничени от точни референтни стойности.** Матричните резултати се проверяват спрямо аналитично равновесие на Наш; експлоатируемостта на Kuhn/Leduc/Goofspiel е *точно* NashConv от Стъпка 07 (не симулация). Резултатът на PSRO за Kuhn, достигащ $\sim 2 \times 10^{-16}$, е нула с машинна точност — най-силното възможно потвърждение.
- **Матричните и PSRO обучаемите са детерминистични** (използват точни градиенти / точен BR двигател + фиксирани начални стойности), така че тези числа са напълно възпроизводими.
- **Невронните резултати са ограничени от началните стойности.** Резултатите за кооперация/комуникация/LOLA са докладвани при една основна начална стойност (мащабът позволява 3); те представляват *качествени неравенства* (централната $<$ е независима; комуникация ВКЛ. $>$ ИЗКЛ.; LOLA $>$ наивна), устойчиви по посока, но чувствителни към началната стойност и версията на библиотеката по големина. Те не трябва да се тълкуват като точни точкови оценки.
- **Не са заснети при това изпълнение:** журналът за преминати и непреминати тестове от validate.py и експерименталните PNG файлове (само JSON artifacts са запазени). Посочени като „за затваряне“ в ../figures/README.md.

3.7 11. Ограничения (подредени според влиянието им върху изводите)

1. **Колебание на Goofspiel $K = 4$ (§5, §9.3)** — необяснима аномалия на PSRO; липсата на премахване на дубликати в BR и популацията от чисти стратегии на драйвера за Goofspiel PSRO

са заподозрените. Докато не бъде разрешено, трябва да се разчита само на резултата $K = 3$ за Goofspiel.

2. **MADDPG се представя по-слабо от IL в изкачващата се игра (§6, §9.4)** — сочи към дискретното актьорско обновяване с контрафактична базова линия; резултатите на MADDPG за *награда* следователно не са надеждни, въпреки че резултатът му за *дисперсия на оценител* (отделно, чисто измерване) е.
3. **PSRO за Leduc не достига целта (§5, §9.2)** — истинско, но означава, че твърдението „PSRO се мащабира“ е демонстрирано само качествено (намаляваща тенденция), а не до ниска експлоатируемост, в по-голямата игра.
4. **Еднократни невронни резултати (§10)** — устойчиви по посока, но несигурни по големина.
5. **Игрови мащаб навсякъде** — матрични игри, едностъпкови кооперативни задачи, миниатюрен покер; нищо оттук не трябва да се екстраполира към дълбоко обучение с подсилване MARL в голям мащаб. (Политиката за изчислителна мощност правилно ги запази малки; GPU беше без значение.)
6. **Липсващи артефакти от изпълнението** — не е записан журналът от `validate.py` или PNG файловете; фигурите се генерират пост-фактум от JSON.

3.8 12. Заключение и насоки за бъдещи изследвания

Заключения. Стъпката изпълнява своята дъга от край до край: самостоятелното обучение се проваля точно там, където теорията предсказва (игра „хвърляне на монета“), а структурните корекции поправят конкретни проблеми — PSRO намалява експлоатируемостта до (почти) нула в малки игри със същия точен показател като стъпките от теорията на игрите; самостоятелното обучение работи средно, а не при последна итерация; централизираният оценител е учител с почти нулева дисперсия; научената комуникация преодолява прага на отгатваемост; и LOLA превръща дефектзорите в IPD сътрудници. Честните отрицателни също са ценни: PSRO достига стена на мащабиране при Leduc, централизираният оценител сам по себе си не решава координацията при риск от прекомерно изследване и един вариант на PSRO (Goofspiel $K = 4$) се държи неправилно.

Насоки за бъдещи изследвания (всяка от тях е свързана с установен ефект):

- *Приблизителни оракули за мащабиране на PSRO* — 2.16 след 20 рунда в Leduc (§5) мотивира RL/приблизителен **предсказвач** за най-добър отговор и измерване на гаранцията, която той струва.
- *Поправка и повторна валидация на двете маркирани части* — премахване на дубликати в Goofspiel $K = 4$ + популация от смесени стратегии (§9.3); контрафактична базова линия на MADDPG (§9.4).
- *Динамично + статично моделиране на противника* — комбиниране на предвиждането на LOLA (§8) със статичното четене от Стъпка 7 (Принос №1).

- *Безопасност без минимакс котва* — пролуката $N > 2$, посочена в резюмето (§2 там): може ли мета-играта на PSRO да осигури използвана безопасна алтернатива там, където не съществува единична стойност на играта (Принос №2)?
-

3.9 13. Възпроизвеждане на резултатите

От `implementation/step09/implementation/` с активирана проектна `.venv`:

```
# validation harness (PASS/FAIL/SKIP against the raw-step targets)
```

```
python validate.py
```

```
# full comparison runs -> results/{smoke,scale}_results.json
```

```
python tournament.py --config smoke
```

```
python tournament.py --config scale
```

```
# plots from a results JSON -> plots/*.png (needs matplotlib)
```

```
python plotting.py --config scale
```

От `implementation/step09/` / (фигури от Част I и съответните JSON файлове):

```
python matrix_games_playground.py
```

```
python nonstationarity_demo.py
```

```
python selfplay_vs_nash.py
```

```
python psro_peek.py
```

```
python lola_ipd_playground.py
```

Семената са фиксирани в `config.py` (реализация) и в `CONFIG` на всеки сценарий за изследване. Резултатите от матричните игри и PSRO са точно възпроизводими; невронните резултати са посокоустойчиви при различни семена. Всички резултати в настоящия доклад са прочетени от `results/{smoke,scale}_results.json` и `exploration/figures/*.json`.