

Съдържание

1	Глава 9 – Многоагентно обучение с подкрепление: Доклад за експериментите	1
2	ЧАСТ I – ЗАЩО МНОГОАГЕНТНОТО ОБУЧЕНИЕ Е ТРУДНО	2
2.1	1. Какво разглеждаме тук	2
2.2	2. Експеримент 1 – независими обучаващи се агенти в четирите матрични игри	2
2.3	3. Експеримент 2 – орбитата на нестационарността („съвпадение на монети“ спрямо дилемата на затворника)	4
2.4	4. Експеримент 3 – игра срещу себе си в Кун: средна срещу последна итерация	4
3	ЧАСТ II – СТРУКТУРНИТЕ РЕШЕНИЯ	5
3.1	5. Експеримент 4 – PSRO при различни семейства игри	5
3.2	6. Експеримент 5 – CTDE: остатък на оценителя и играта „изкачване“	6
3.3	7. Експеримент 6 – научена комуникация (CommNet)	8
3.4	8. Експеримент 7 – LOLA в повтарящата се дилема на затворника	8
3.5	9. Съпоставка на прогнозите с реалността	9
3.6	10. Достоверност и достатъчност на извадката	10
3.7	11. Ограничения (подредени според влиянието им върху изводите)	11
3.8	12. Заключение и насоки за бъдещи изследвания	11
3.9	13. Възпроизвеждане на резултатите	12

1 Глава 9 – Многоагентно обучение с подкрепление: Доклад за експериментите

Тестови среди: четири канонични матрични игри 2×2 (дилемата на затворника, „съвпадение на монети“ (Matching Pennies), лов на елен, битка на половете); Кун покер и Ледюк Холдем (чрез точните инструменти от Глава 7); собствена реализация на Goofspiel ($K = 3, 4$); две малки кооперативни среди (едностъпковата референциална игра CoopSignal и играта „изкачване“ на Claus и Boutilier); както и повтарящата се дилема на затворника с памет 1. Покер игрите използват изцяло модула за Кун от Глава 2, модула за Ледюк от Глава 3 и кода за точен най-добър отговор / NashConv от Глава 7.

Връзка с дисертацията: преминаването от **игри за двама с нулева сума** (глави 2–8) към **многоагентно обучение с подкрепление**. Три връзки: **LOLA** като *динамично моделиране на противника* (Принос №1); **PSRO** като *методология за оценяване на популационно равнище* (Принос №3); и **липсващата минимаксна опора при $N > 2$** , където гаранциите за безопасност от игрите за двама се губят (Принос №2).

Обхват на резултатите: всяко число в този доклад е **измерено при реално изпълнение** и прочетено от файловете с резултати `implementation/step09/implementation/results/{smoke,scale}_` и `implementation/step09/exploration/figures/*.json`. Когато е възможно, симулираните числа са оградени с *точен* аналитичен ориентир (аналитично равновесие на Наш за

матричните игри; точен най-добър отговор / NashConv от Глава 7 за Кун, Ледюк и Goofspiel). Четири прогнози от фаза 4 бяха **опровергани** от изпълненията; съгласно работния процес на проекта (§0.1) те са запазени в първоначалния си вид и съпоставени с това, което действително се случи (§9).

Как да четете този доклад. И двете части следват една и съща дъга: **какво тестваме → как → резултати → заключение**. **Част I (§1–§4)** показва *защо* многоагентното обучение е трудно, върху матрични игри и игра срещу себе си в Кун. **Част II (§5–§8)** оценява структурните решения – PSRO, CTDE, комуникация, LOLA – спрямо точни мерки. §9 съпоставя четирите опровергани прогнози с резултатите; §10–§12 обхващат доверието, ограниченията и насоките; §13 изброява командите за възпроизвеждане.

2 ЧАСТ I – ЗАЩО МНОГОАГЕНТНОТО ОБУЧЕНИЕ Е ТРУДНО

2.1 1. Какво разглеждаме тук

Едноагентното обучение с подкрепление предполага **стационарна** среда; многоагентното обучение с подкрепление – не, тъй като другите агенти *също се учат*, което превръща ефективната среда на всеки агент в подвижна цел (**нестационарност**). Част I показва този проблем чрез най-простите възможни контролни експерименти – независими градиентни агенти в игри с точно известни равновесия на Наш – преди Част II да представи механизмите за неговото преодоляване. Всички данни от Част I идват от изследователските скриптове с фиксирани начални числа (exploration/figures/*.json); агентите използват **точни градиенти**, така че динамиката не съдържа шум от извадката и въпросът „сближава ли се?“ има еднозначен отговор.

2.2 2. Експеримент 1 – независими обучаващи се агенти в четирите матрични игри

Какво изследваме. Достигат ли два независими градиентни агента аналитичното равновесие на Наш във всяка канонична игра 2×2 и ако не, по какъв начин се провалят?

Как. Два агента с точен градиент, 4000 стъпки, скорост на обучение 0,1, симетрично начало (0,5, 0.5) и начално число 0. „Сближил се“ означава, че последните 100 стъпки са останали почти непроменени. Данни: exploration/figures/matrix_games_playground.json.

Игра	p_{final} (ред)	q_{final} (колона)	печалба на реда	сближил ли се?	аналитично равновесие на Наш
дилемата на затворника	0,0025	0,0025	1,008	да	(предателство, предателство), стойност 1
„съвпадение на монети“	0,508	0,496	−0,0001	не	смесено $(\frac{1}{2}, \frac{1}{2})$, стойност 0
лов на елен	0,0009	0,0009	2,997	да	(заек, заек), рисково доминиращо, стойност 3
битка на половете	0,0029	0,0014	0,996	да	(футбол, футбол), ред 1 / колона 2

(Тук действието с индекс 0 е сътрудничество/елен/опера; $p \rightarrow 0$ означава, че агентът на реда играе *второто* действие – предателство/заек/футбол.)

Резултати. В три от четирите игри агентите се сближават с истинско равновесие на Наш. В дилемата на затворника те стигат до взаимно предателство (доминираща стратегия). В лова на елен се установяват в **рисково доминиращото** равновесие (заек, заек) вместо в доминиращото по печалба (елен, елен) – безопасният ъгъл надделява при градиентна динамика. В битката на половете се координират в едно чисто равновесие. В „съвпадение на монети“ агентите **не се сближават**: на стъпка 4000 те са близо до $(0,51, 0.50)$, но изпълнението отчита *липса на сходимост*, а §3 показва, че траекторията продължава да се движи.

Заклучение. Независимото обучение е контролният експеримент, който се проваля *умишлено*: то работи там, където играта има доминираща стратегия или достижимо чисто равновесие, и се проваля там, където единственото равновесие е смесено. Именно този провал обосновава всичко в Част II.

2.3 3. Експеримент 2 – орбитата на нестационарността („съвпадение на монети“ спрямо дилемата на затворника)

Какво тестваме. В „съвпадение на монети“ намалява ли с времето разстоянието до смесеното равновесие на Наш (сходимост), или не намалява (нестационарност)?

Как. Проследяваме разстоянието до равновесието на Наш в последователни времеви прозорци и го сравняваме с разстоянието до (предателство, предателство) в дилемата на затворника. Стъпки 6000, скорост на обучение 0,1, начало извън центъра (0,7, 0.3), начално число 0. Данни: `exploration/figures/nonstationarity_demo.json`.

Времеви прозорец	Радиус при „съвпадение на монети“	Радиус при дилемата на затворника
1	0,301	0,079
2	0,349	0,010
3	0,391	0,0058
4	0,425	0,0041
5	0,453	0,0032
6	0,476	0,0026

Резултати. Радиусът при дилемата на затворника клони към нула (сходимост). Радиусът при „съвпадение на монети“ **нараства** от 0,30 до 0,48 - траекторията се отдалечава по спирала *навън* към границата, вместо да се установи или да поддържа постоянна орбита.

Заклучение. Последната итерация не се сближава. При непрекъснато време (безкрайно малка стъпка) траекторията би обикаляла около равновесието по затворена крива (Singh и др., 2000); при фиксирана стъпка 0,1 всяко обновяване излиза леко навън от кривата, затова траекторията бавно се отдалечава по спирала и при тази стъпка повече изчисления водят до по-голямо отдалечаване, а не до сходимост. (Това опровергава прогнозата от фаза 4 за „орбита с постоянен радиус“; вж. §9.)

2.4 4. Експеримент 3 – игра срещу себе си в Кун: средна срещу последна итерация

Какво изследваме. При игра срещу себе си чрез фиктивна игра в реална игра с непълна информация сближава ли се *средната* стратегия с равновесието на Наш, дори когато *последната* итерация не се сближава?

Как. Фиктивна игра в Кун (всеки играч дава най-добър отговор на текущата средна стратегия на противника чрез точния най-добър отговор от Глава 7), 200 итерации, с измерване на

всеки 5. Проследяваме NashConv на средната стратегия и NashConv на последната итерация. Данни: exploration/figures/selfplay_vs_nash.json.

Итерация	NashConv на средната стратегия	NashConv на последната итерация
5	0,240	0,500
50	0,063	0,500
100	0,046	0,500
150	0,038	0,500
200	0,031	0,500

(Стойността на последната итерация се колебае в $\{0,33, 0,50, 0,67, 0,83\}$ през цялото време – тя никога не показва тенденция към намаляване.)

Резултати. Експлоатируемостта на средната стратегия намалява монотонно от 0,24 до 0,031, а стойността на последната итерация продължава да осцилира в $[0,33, 0,83]$.

Заклучение. Играта срещу себе си се сближава **в средното, а не в последната итерация** – това е конкретната причина за осредняването (CFR, фиктивна игра) и за мета-Наш сместа върху популация в PSRO, вместо да се разчита на най-новата стратегия (§5).

3 ЧАСТ II – СТРУКТУРНИТЕ РЕШЕНИЯ

3.1 5. Експеримент 4 – PSRO при различни семейства игри

Какво изследваме. Свежда ли PSRO (популация + мета-Наш + предсказвач за най-добър отговор) експлоатируемостта на мета-Наш сместа до нула и запазва ли се това при игри с различен размер?

Как. PSRO с **точния** предсказвач за най-добър отговор от Глава 7. Мета-Наш сместа на противника върху поведенчески стратегии се свежда до една реализационно еквивалентна поведенческа стратегия (теоремата на Кун, пълна памет), за да може да се приложи модулът за точен BR. Експлоатируемостта е NashConv на мета-сместа в цялата игра. Данни: results/scale_results.json (блок psro); RPS от exploration/figures/psro_peek.json; Goofspiel $K = 3$ от results/smoke_results.json (конфигурацията в пълен мащаб изпълни само $K = 4$).

Игра	кръг 0	крайна стойност (кръг)	извод
Кун покер	0,917	$\sim 2 \times 10^{-16}$ (6)	сближава се до машинна нула
матрична игра („съвпадение на монети“)	2,0	0,0 (2)	сближава се
камък-ножица-хартя	2,0	0,017 (4)	сближава се; смес $\rightarrow$ (0,335, 0.336, 0.329)
Ледюк Холдем	4,75	2,16 (19)	намалява, далеч над целта 0,5
Goofspiel ($K = 3$, бърза проверка)	1,33	0,0 (1)	сближава се
Goofspiel ($K = 4$)	1,50	1,71 (7); колебае се 1,24–2,0	не се установява

Резултати. В малките игри (Кун, матрична игра, RPS, Goofspiel $K = 3$) експлоатируемостта спада до практически нула за няколко кръга – типично поведение на метода на двойния предсказвач. Ледюк се колебае през първите осем кръга (между 3,73 и 6,83; максимумът е в кръг 1), след което намалява до 2,16, но след 20 кръга остава далеч над целта 0,5. Goofspiel $K = 4$ се колебае между $\sim 1,2$ и 2,0 през своите 8 кръга, без да се установи.

Заклучение. PSRO е потвърден като мост между теорията на игрите и MARL в малките игри, със същия точен показател за експлоатируемост както в глави 2–8. Два резултата – бавната сходимост при Ледюк и колебанието при Goofspiel $K = 4$ - не съответстваха на прогнозите и са разгледани в §9.

3.2 6. Експеримент 5 – CTDE: остатък на оценителя и играта „изкачване“

Какво тестваме. (а) Има ли *централизираният* оценител по-ниска дисперсия на целевата стойност от *независимите* оценители? (б) Позволява ли централизираният оценител на кооперативните агенти да избегнат капана на некоординираността и да надминат независимите обучаващи се агенти?

Как. (а) MADDPG в едностъпковата задача CoopSignal: централизиран $Q(s, a_1, \dots, a_N)$ и отделни $Q_i(o_i)$ за всеки агент се обучават върху едни и същи данни; сравнява се крайният остатък. (б) Независими обучаващи се агенти, MADDPG и MAPPO в играта „изкачване“ на

Claus и Boutilier (оптимум 11, заобиколен от наказания —30; безопасен атрактор 5); сравнява се отборната награда при алчна стратегия. Данни: results/scale_results.json (блок coop).

(a) *Остатък на оценителя (CoopSignal):*

Оценител	краен остатък (грешка на функцията на стойността)
централизиран $Q(s, a_1, \dots, a_N)$	$3,17 \times 10^{-11}$
независим $Q_i(o_i)$	0,0766

(b) *Награда при алчна стратегия в играта „изкачване“:*

Обучаващ се агент	награда	(оптимум 11, безопасна стойност 5)
независими обучаващи се агенти	7,0	–
MADDPG	5,0	–
MAPPO	7,0	–

Резултати. (a) Остатъкът на централизирания оценител е практически нула (той отчита целта и съвместното действие, така че наградата е детерминистична функция на входовете му) – с порядъци под остатъка 0,077 на независимия оценител: централизираният оценител напасва целевата си стойност много по-точно. Това само по себе си не означава по-ниска дисперсия на градиента на стратегията; при сходили оценители централизираният оценител може дори да я увеличи (Луи и др., 2021). (b) **Нито един метод не достига оптимума;** независимите обучаващи се агенти и MAPPO достигат 7, а **MADDPG изостава с 5** (безопасният атрактор). Тук MADDPG е вариант за дискретни действия, чийто актьор се обновява с контрафактна базова линия в стила на COMA (Foerster и др., 2018) вместо с детерминистичния градиент на стратегията, затова резултатът се отнася до този вариант, а не до MADDPG в оригиналния му вид.

Заклучение. Централизираният оценител напасва целевата си стойност много по-добре (потвърдено), но само това **не** решава координацията, когато изследването е трудно – наказанията —30 възпират агентите да опитат съвместното действие, което води до 11. Това, че MADDPG остава под независимите агенти, насочва вниманието към неговия дискретен актьор с контрафактна базова линия (§9, §11).

3.3 7. Експеримент 6 – научена комуникация (CommNet)

Какво тестваме. Позволява ли канал за съобщения, който агентите научават сами, слушател, който не вижда целта, да надхвърли тавана при случайно отгатване $1/K$?

Как. CommNet в CoopSignal ($K = 5$, таван при случайно отгатване 0,2), обучен с включен и с изключен канал; сравнява се отборната награда при алчна стратегия. Данни: results/scale_results.json (coop.communication).

Канал	награда при алчна стратегия
с комуникация	0,795
без комуникация	0,204

Резултати. С канала наградата е 0,795, далеч над тавана 0,2; без него е 0,204, точно на тавана.

Заклучение. Комуникацията се научава от край до край и върши реална работа – говорителят се научава да кодира целта, а слушателят – да я декодира. (При конфигурацията за бърза проверка и двете стойности бяха 0,24; ефектът изисква обучение до сходимост – §9.)

3.4 8. Експеримент 7 – LOLA в повтарящата се дилема на затворника

Какво тестваме. Сътрудничат ли агентите, които диференцират през *следващата* стъпка на обучение на противника, там, където наивните агенти стигат до предателство?

Как. Повтаряща се дилема на затворника с памет 1 и точна затворена форма на възвръщаемостта; наивни градиентни агенти срещу агенти с LOLA (предвиждане чрез вложени крайни разлики). Сравнява се дисконтираната възвръщаемост на стъпка (пълно сътрудничество ≈ 3 , взаимно предателство ≈ 1). Данни: results/scale_results.json (lola); изследователска крива в exploration/figures/lola_ipd_playground.json.

Обучаващи се агенти	възвръщаемост на стъпка
наивни срещу наивни	1,04
LOLA срещу LOLA	2,82

(Изследователското изпълнение с по-голяма скорост на обучение при предвиждане достигна възвръщаемост с LOLA 2,67 и 2,93 за двамата агенти (средно 2,80) срещу $\sim 1,06$ при наивните.)

Резултати. Наивното обучение стига до взаимно предателство (1,04); LOLA достига почти пълно сътрудничество (2,82). Вградена проверка потвърждава механизма: при нулева скорост на обучение при предвиждане градиентът на LOLA съвпада точно с наивния градиент, така че сътрудничеството се дължи на члена от втори ред.

Заклучение. LOLA променя динамиката на обучението – динамично моделиране на противника – и превръща предателството в повтарящата се дилема на затворника в сътрудничество. Това е допълнението за движеща се цел към статичната преценка за противника от Глава 7 (Принос №1).

3.5 9. Съпоставка на прогнозите с реалността

Съгласно работния процес (§0.1) опроверганите прогнози от фаза 4 се запазват и се съпоставят с резултатите, а не се редактират мълчаливо. Четири разминавания:

1. **Орбитата в „съвпадение на монети“ (§3).** *Прогнозирано:* чиста орбита с приблизително постоянен радиус около $(\frac{1}{2}, \frac{1}{2})$. *Измерено:* радиусът нарасна $0,30 \rightarrow 0.48$ (спирала навън); агентът със softmax параметризация в имплементацията вместо това се отклони към ъглите ($\text{NashConv} \sim 1,8$). *Съпоставка:* урокът за липсата на сходимост остава в сила. Моделът на „енергозапазващата орбита“ е верен за непрекъснатата динамика (безкрайно малка стъпка): тогава траекторията обикаля около равновесието по затворена крива (Singh и др., 2000); при фиксирана стъпка 0,1 всяко обновяване излиза леко навън от кривата и траекторията бавно се отдалечава по спирала към границата. И в двата случая последната итерация не се сближава, а това е аргумент в полза на методите с осредняване и популация. Това не е грешка – наблюдавани са две различни, но валидни градиентни динамики.
2. **PSRO в Ледюк (§5).** *Прогнозирано:* експлоатируемост $< 0,5$ в рамките на 20 итерации. *Измерено:* $4,75 \rightarrow 2.16$ за 20 кръга – колебания през първите осем кръга (до 6,83), след това намаление, но далеч над 0,5. *Съпоставка:* истинска бавна сходимост, а не програмна грешка – Кун достигна машинна нула за 6 кръга, но дървото на Ледюк е много по-голямо и популация от 20 *чисти* стратегии не може да приближи добре неговото смесено равновесие на Наш. Целта беше прекалено оптимистична; низходящата тенденция е правилното поведение. Това се потвърждава от чистата сходимост при Кун, матричната игра и RPS по същия път в кода.
3. **Goofspiel $K = 4$ (§5).** *Прогнозирано:* ненараставаща експлоатируемост. *Измерено:* $K = 3$ (бърза проверка) се сближи до 0; $K = 4$ се колебае в интервала 1,24–2,0. *Съпоставка:* единствената необяснена аномалия. Документирана, но не поправена (съгласно избрания път). Основните заподозрени за последваща проверка: драйверът на PSRO за

Goofspiel никога не премахва дублиращите се стратегии за най-добър отговор, а популация от чисти стратегии вероятно е твърде слаба, за да представи смесеното мета-Наш равновесие на по-голямата игра. Отбелязана като отворен въпрос в кода – **не** е представена като валидиран резултат на PSRO.

4. **Играта „изкачване“ (§6).** *Прогнозирано:* централизиращият оценител достига оптимума 11 и надминава независимите обучаващи се агенти. *Измерено:* никой не достигна 11; независимите агенти и MAPPO достигнаха 7, а MADDPG изостана с 5. *Съпоставка:* отделният резултат за нападането на оценителя се потвърди (остатък на централизиращия оценител $\sim 3 \times 10^{-11}$ срещу 0,077), така че честното разграничение е „CTDE дава по-точен оценител $\neq$ CTDE решава координацията, когато изследването е трудно“. Това, че MADDPG остава под независимите агенти, освен това насочва вниманието към неговия актьор с контрафактична базова линия в стила на СОМА. Изводът остава в сила, но в по-сдържан вид.

Методологична бележка, която засяга всички раздели: двата **невронни** ефекта (остатък на оценителя, §6а; комуникация, §7) бяха **невидими при бързата проверка** – с комуникация = без комуникация = 0,24, загубите на оценителите почти еднакви (0,0897 срещу 0,0927) – и се проявиха едва в конфигурацията в пълен мащаб. Твърденията за невронните мрежи почиват на числата от пълния мащаб.

3.6 10. Достоверност и достатъчност на извадката

- **Игровитеоретичните резултати са ограничени от точни референтни стойности.** Матричните резултати се проверяват спрямо аналитичното равновесие на Наш; експлоатируемостта при Кун/Ледюк/Goofspiel е *точно* NashConv от Глава 7 (не симулация). Резултатът на PSRO за Кун, $\sim 2 \times 10^{-16}$, е нула с машинна точност – най-силното възможно потвърждение.
- **Матричните агенти и агентите в PSRO са детерминистични** (точни градиенти / точен BR + фиксирани начални числа), така че тези числа са напълно възпроизводими.
- **Невронните резултати са ограничени от броя начални числа.** Резултатите за кооперация, комуникация и LOLA са докладвани при едно основно начално число (конфигурацията в пълен мащаб позволява 3); те са *качествени неравенства* (централизиран < независим; с комуникация > без комуникация; LOLA > наивни), устойчиви по посока, но по големина чувствителни към началното число и версията на библиотеката. Не трябва да се тълкуват като точни точкови оценки.
- **Не е записан при това изпълнение:** журналът с преминатите и непреминатите проверки от `validate.py` (запазени са само JSON файловете с резултати). Графиките са построени от тези JSON резултати (вж. `../figures/README.md`).

3.7 11. Ограничения (подредени според влиянието им върху изводите)

1. **Колебание при Goofspiel $K = 4$ (§5, §9.3)** – необяснена аномалия на PSRO; заподозрени са липсата на премахване на дублиращите се BR в драйвера на PSRO за Goofspiel и популацията му от чисти стратегии. Докато не бъде изяснена, може да се разчита само на резултата за Goofspiel с $K = 3$.
2. **MADDPG се представя по-слабо от IL в играта „изкачване“ (§6, §9.4)** – сочи към дискретното обновяване на актьора с контрафактична базова линия (в стила на COMA); резултатите на MADDPG за *наградата* следователно не са надеждни, но резултатът му за *напасването на оценителя* (отделно, чисто измерване) е надежден.
3. **PSRO в Ледюк не достига целта (§5, §9.2)** – резултатът е истински, но означава, че твърдението „PSRO се мащабира“ е показано само качествено (низходяща тенденция), а не до ниска експлоатируемост в по-голямата игра.
4. **Невронни резултати с едно начално число (§10)** – устойчиви по посока, несигурни по големина.
5. **Мащаб на опростен модел навсякъде** – матрични игри, едностъпкови кооперативни задачи, миниатюрен покер; нищо от тук не бива да се екстраполира към дълбокото многоагентно обучение с подкрепление в голям мащаб. (Политиката за изчислителните разходи правилно ги запази малки; GPU не беше нужен.)
6. **Липсващ артефакт от изпълнението** – журналът от `validate.py` не е записан; графиките се генерират впоследствие от JSON резултатите.

3.8 12. Заключение и насоки за бъдещи изследвания

Заключения. Главата изпълнява своята дъга от край до край: независимото обучение се проваля точно там, където теорията предсказва („съвпадение на монети“), а структурните решения поправят конкретни проблеми – PSRO свежда експлоатируемостта до (почти) нула в малките игри със същия точен показател като в главите по теория на игрите; играта срещу себе си работи в средното, а не в последната итерация; централизираният оценител напасва целевата си стойност почти точно; научената комуникация надхвърля тавана при случайно отгатване; и LOLA превръща предателството в IPD в сътрудничество. Отрицателните резултати са не по-малко ценни: PSRO достига стената на мащабиране в Ледюк, централизираният оценител сам по себе си не решава координацията, когато изследването е трудно, а един вариант на PSRO (Goofspiel $K = 4$) се държи неправилно.

Насоки за бъдещи изследвания (всяка е свързана с измерен ефект):

- *Приблизителни предсказвачи за мащабиране на PSRO* - 2,16 след 20 кръга в Ледюк (§5) мотивира RL/приблизителен предсказвач за най-добър отговор и измерване на това доколко той отслабва гаранцията.
- *Поправка и повторна проверка на двете отбелязани части* – премахване на дубликати в Goofspiel $K = 4$ + популация от смесени стратегии (§9.3); контрафактичната базова линия на MADDPG (§9.4).
- *Динамично + статично моделиране на противника* – съчетаване на предвиждането на LOLA (§8) със статичната преценка за противника от Глава 7 (Принос №1).
- *Безопасност без минимаксна опора* – празнината при $N > 2$, посочена в обобщението (раздел 9.2 там): може ли мета-играта на PSRO да осигури използваем заместител на безопасността там, където не съществува единствена стойност на играта (Принос №2)?

3.9 13. Възпроизвеждане на резултатите

От `implementation/step09/implementation/` с активирана проектна `.venv`:

```
# validation harness (PASS/FAIL/SKIP against the raw-step targets)
python validate.py
```

```
# full comparison runs -> results/{smoke,scale}_results.json
python tournament.py --config smoke
python tournament.py --config scale
```

```
# plots from a results JSON -> plots/*.png (needs matplotlib; reads only, default --config scale)
python plotting.py --config scale
```

От `implementation/step09/exploration/` (фигури от Част I и съответните JSON файлове):

```
python matrix_games_playground.py
python nonstationarity_demo.py
python selfplay_vs_nash.py
python psro_peek.py
python lola_ipd_playground.py
```

```
# redraw all Part I figures from the saved JSON, without rerunning anything
python plot_results.py
```

Началните числа са фиксирани в `config.py` (реализация) и в `CONFIG` на всеки изследователски скрипт. Резултатите от матричните игри и PSRO са точно възпроизводими; невронните резултати са устойчиви по посока при различни начални числа. Всички ре-

зултати в настоящия доклад са прочетени от `results/{smoke,scale}_results.json` и `exploration/figures/*.json`.