

Съдържание

1	Глава 10 - Обучение на базата на популации и еволюционна теория на игрите: експериментален доклад	1
2	ЧАСТ I - ЕВОЛЮЦИОННА ТЕОРИЯ НА ИГРИТЕ КАТО ДИАГНОСТИЧЕН ИНСТРУМЕНТ	2
2.1	1. Какво разглежда тази глава	2
2.2	2. Експеримент 1 - репликаторна динамика върху четири матрични игри	2
2.3	3. Експеримент 2 - „пумпалът“: транзитивна и циклична структура	5
3	ЧАСТ II - ЛИГАТА С РВТ	8
3.1	4. Какво представлява лигата и как се оценява	8
3.2	5. Експеримент 3 - динамика на обучението в лигата	8
3.3	6. Експеримент 4 - EGTA, мета-Наш и разнообразие	10
3.4	7. Експеримент 5 - лигата срещу PSRO, самообучението и CFR (равновесие на Наш)	12
3.5	8. Съпоставка на прогнозите с резултатите	14
3.6	9. Достоверност и достатъчност на извадката	15
3.7	10. Ограничения (подредени според степента на влияние върху заключенията)	16
3.8	11. Заключение и насоки за бъдещи изследвания	17
3.9	12. Възпроизвеждане на резултатите	17

1 Глава 10 - Обучение на базата на популации и еволюционна теория на игрите: експериментален доклад

Тестови среди: четири симетрични матрични игри за еволюционната част (дилемата на затворника, „ястреб-гълъб“, „камък-ножица-хартия“, „лов на елен“); синтетична стълбица на уменията; мета-играта на най-добрите отговори в PSRO за Ледюк Холдем; и малка **РВТ лига** в стила на AlphaStar от невронни PPO агенти, които играят Ледюк Холдем. Средата за Ледюк, точният оракул за най-добър отговор и NashConv/експлоатируемостта са взети от Глава 7 (използвани без промени); PSRO и решавателят за мета-Наш са от Глава 9. Невронните агенти се обучават с PyTorch и след това се извличат в *таблични* стратегии, за да може **точният** най-добър отговор от Глава 7 да ги оцени.

Връзка с дисертацията: популационното ниво на дисертацията. Три връзки: **основните експлоататори като автоматизирани модели на противника** (Принос №1 - байесовата преценка за противника от Глава 7, пренесена на ниво популация); **лигата на AlphaStar като механизъм за безопасна експлоатация на ниво популация, чиято гаранция липсва** (Принос №2); и **EGTA / мета-Наш като методология за оценяване на популацията** (Принос №3).

Обхват на резултатите: всяко число в този доклад е **измерено при реално изпълнение** и е взето от файловете `implementation/step10/implementation/results/{smoke,scale}_results.json`

и `implementation/step10/exploration/figures/*.json`. Еволюционните резултати са съпоставени с *аналитични* еталони (ESS / равновесие на Наш за всяка матрична игра), а резултатите от лигата - с *точната* експлоатируемост от Глава 7. Три прогнози от фаза 4 бяха **опровергани** от изпълнението при пълен мащаб; съгласно WORKFLOW §0.1 те се запазват така, както са формулирани, и се съпоставят с действителния резултат (§8).

Как да се чете този доклад. И двете части следват една и съща последователност: **какво проверяваме → как → резултати → заключение.** **Част I (§1-§3)** използва еволюционната теория на игрите като *диагностичен инструмент*: репликаторна динамика върху решими матрични игри и след това транзитивно-цикличното разлагане „пумпал“. **Част II (§4-§7)** изгражда и оценява **РВТ лигата**: динамика на обучението, EGTA/мета-Наш, разнообразие и рейтинг по Ело и пряко сравнение с PSRO, самообучението и CFR (равновесие на Наш). §8 съпоставя трите опровергани прогнози с резултатите; §9-§11 разглеждат достоверността, ограниченията и насоките; §12 изброява командите за възпроизвеждане.

2 ЧАСТ I - ЕВОЛЮЦИОННА ТЕОРИЯ НА ИГРИТЕ КАТО ДИАГНОСТИЧЕН ИНСТРУМЕНТ

2.1 1. Какво разглежда тази глава

Глави 2–9 разглеждаха равновесията на *фиксирана* игра. Глава 10 преминава на по-високо ниво - към **популации от стратегии, които се променят във времето**, - и поставя два въпроса, на които гледната точка на един агент не може да отговори: *кои стратегии нарастват?* (репликаторна динамика) и *има ли тази игра изобщо „най-добра“ стратегия, или само кръг от контрастратегии?* (транзитивно-цикличното разлагане). Тези два инструмента са диагностиката, от която се нуждае обучението на базата на популации в Част II, защото дали една самообучаваща се популация ще се сближи, или ще зацikli, зависи от структурата на играта, а не от скоростта на обучение. Всички еволюционни числа в Част I са детерминистични (фиксирани начални числа, точна динамика), така че въпросът „сближи ли се?“ има еднозначен отговор.

2.2 2. Експеримент 1 - репликаторна динамика върху четири матрични игри

Какво проверяваме. Възпроизвежда ли репликаторната динамика *аналитичния* еволюционен резултат за всяка игра - сближаване с доминираща стратегия, с вътрешна ESS, с чиста

ESS според басейна на привличане, или несходяща орбита? (Проверка по първоначалния план, L530–533.)


Как. Репликаторната динамика се интегрира с дискретния метод на Ойлер от зададена вътрешна начална точка; „сходим“ означава, че последната итерация е спряла да се променя; „орбитален радиус“ е разстоянието, на което траекторията се държи от равномерната точка. Еталон са аналитичните ESS и равновесия на Наш. Данни: `results/smoke_results.json` (блок replicator), траекториите - в `exploration/figures/replicator_playground.json`.

Игра	Аналитичен			Сходим?	Орбитален радиус
	еталон	Начало x_0	Краен x		
Дилемата на затворника	предателството доминира; единствена ESS (0, 1)	[0.666, 0.334]	[0.0, 1.0]	да	0.707
Ястреб-гълъб	вътрешна ESS $p(\text{ястреб}) = V/C = 0.5$	[0.548, 0.452]	[0.5, 0.5]	да	0.0
Камъчножицартия	равновесие на Наш = равномерна стратегия; няма ESS (център)	[0.347, 0.385, 0.268]	[0.299, 0.288, 0.413]	не	0.095
Лов на елен ($x_0 = [0.8, 0.2]$)	две чисти ESS (според басейна на привличане)	[0.8, 0.2]	[1.0, 0.0]	да	0.707

Игра	Аналитичен еталон	Начало x_0	Краен x	Сходим?	Орбитален радиус
Лов на елен ($x_0 = [0.2, 0.8]$)	две чисти ESS (според басейна на привличане)	$[0.2, 0.8]$	$[0.0, 1.0]$	да	0.707

Резултати. И четирите съвпадат напълно с теорията. Дилемата на затворника стига до всеобщо предателство (доминиращата стратегия). „Ястреб-гълъб“ се сближава с вътрешната смесена ESS точно при 0.5 (орбитален радиус 0.0 - траекторията *достига* точката на покой). „Камък-ножица-хартия“ **не се сближава**: траекторията обикаля около равномерния център (радиус ≈ 0.095), тъй като вътрешната неподвижна точка е център, а не атрактор. В непрекъснато време орбитите са затворени; използваният явен метод на Ойлер ги превръща в бавно разширяваща се спирала, така че радиусът леко нараства по време на изпълнението. „Лов на елен“ стига до *различни* чисти ESS в зависимост от началото - $[0.8, 0.2] \rightarrow$ всички ловуват елен, $[0.2, 0.8] \rightarrow$ всички ловуват заек - двата басейна на привличане се виждат ясно.

Заключение. Репликаторната динамика е непрекъснатата идеализация на подбора в популация: всяко равновесие на Наш е нейна точка на покой, а всяка ESS - асимптотично устойчива точка на покой (Hofbauer & Sigmund, 2003; обратното в общия случай не е вярно - например всяка чиста стратегия е точка на покой). Играта, която *не се сближава* - „камък-ножица-хартия“, - е основната причина за Част II: цикличната игра няма устойчива популация, затова самообучаваща се популация в нея ще се върти, вместо да се установи.



Фигура 1: Траектории на репликаторната динамика (дял на първата стратегия във времето) в четирите матрични игри: в дилемата на затворника популацията стига до всеобщо предателство, в „ястреб-гълъб“ - до вътрешната ESS с дял 0.5, в „камък-ножица-хартия“ обикаля около центъра, без да се сближава, а в „лов на елен“ се разделя на два басейна (всички ловуват елен или всички ловуват заек) в зависимост от началото. Несходящата орбита при „камък-ножица-хартия“ е най-нагледният аргумент за механизмите за разнообразие в Част II.

2.3 3. Експеримент 2 - „пумпалът“: транзитивна и циклична структура

Какво проверяваме. Можем ли да разложим матрицата на печалбите на една игра на **транзитивна** компонента (стълбица на уменията) и **циклична** компонента („камък-ножица-хартия“) и разпознава ли това разлагане правилно чистите случаи и реалните популации? (Проверка по първоначалния план, L532, L534.)


Как. Комбинаторното разлагане на Ходж (по разлики в рейтингите) на антисиметричната част на матрицата на печалбите дава транзитивно и циклично съотношение (компонентите са ортогонални, затова квадратите им се събират до 1). За „камък-ножица-хартя“ даваме и транзитивното съотношение по метода SVD с ранг 1 от първоначалния план, за да документираме известния му недостатък. Данни: results/{smoke,scale}_results.json (блок spinning_top), exploration/figures/game_landscape.json.

Популация	Транзитивно съотношение (Ходж)	Циклично съотношение (Ходж)	Цикли от три стратегии	Бележка
Камък- ножица- хартя	0.0	1.0	1	SVD с ранг 1 неправилно дава 0.707
Чиста стълбица на уменията	1.0	0.0	0	монотонна сила
Мета-игра на PSRO за Ледюк (бърза проверка, 8 кръга)	0.457	0.890	-	предимно циклична
Мета-игра на PSRO за Ледюк (пълен мащаб, 20 кръга)	0.411	0.912	27	предимно циклична
Мета-игра на моментните снимки на лигата (бърза проверка / пълен мащаб)	0.981 / 0.937	-	-	предимно транзитивна

Резултати. Разлагането на Ходж разпознава точно чистите случаи: „камък-ножица-хартя“ има транзитивно съотношение 0.0 и циклично 1.0 (един цикъл от три стратегии), а стълбицата на уменията - 1.0 и 0.0. Методът **SVD с ранг 1**, предложен в първоначалния план, дава за „камък-ножица-хартя“ транзитивно съотношение ≈ 0.707 - грешно, защото сингуляр-

ните стойности на антисиметрична матрица винаги са по двойки, затова приближението с ранг 1 обхваща най-много половината от квадрата на нормата ѝ при всяка игра (чистата стълбица на уменията също получава 0.707); затова за диагностиката се използва методът на Ходж. Двете *реални* популации се различават рязко: **мета-играта на най-добрите отговори в PSRO за Ледюк е предимно циклична** (транзитивно съотношение ≈ 0.41 –0.46, 27 цикъла от три стратегии), докато **мета-играта на моментните снимки на лигата е предимно транзитивна** (≈ 0.94 –0.98).

Заклучение. Транзитивното/цикличното съотношение е *диагностика преди обучението*. Две популации от една и съща игра (Ледюк) имат противоположна структура в зависимост от начина, по който са изградени (най-добри отговори или моментни снимки от обучението - вж. §8.2). Точно този инструмент предсказва дали наивното самообучение/PBT ще се сближи, или ще зацikli, и дисертацията го пренася в следващите глави.



Фигура 2: Транзитивно съотношение на четири популации: „камък-ножица-хартя“ (0.0, чисто циклична), чиста стълбица на уменията (1.0, чисто транзитивна), мета-играта на най-добрите отговори в PSRO за Ледюк (~ 0.41 –0.46, предимно циклична, 27 цикъла от три стратегии) и мета-играта на моментните снимки на лигата (~ 0.94 –0.98, предимно транзитивна). От това коя популация се разлага зависи дали Ледюк изглежда като кръг, или като стълбица.

3 ЧАСТ II - ЛИГАТА С РВТ

3.1 4. Какво представлява лигата и как се оценява

Втората част изгражда малка **лига в стила на AlphaStar** върху Ледюк Холдем с три типа агенти - **основни** агенти (крайният продукт), **основни експлоататори** (търсят слабости в текущите основни агенти) и **експлоататори на лигата** (търсят слабости навсякъде в замразената история) - плюс периодично **замразяване** на моментни снимки в „музей“ и сдвояване по **PFSP** (по-трудните противници се избират по-често). Агентите са **невронни PPO мрежи** върху кодиране на информационното състояние в Ледюк; РВТ копира най-добрите агенти (експлоатация) и променя тяхната **скорост на обучение и ентропия** (изследване). От решаващо значение е, че всяка мрежа се извлича в **таблична стратегия**, така че **точният** най-добър отговор от Глава 7 измерва нейната **експлоатируемост** - същият показател NashConv, използван още от Глава 2. NashConv е сумата от печалбите на двата най-добри отговора (по един за всеки играч); в конвенцията на OpenSpiel експлоатируемостта е половината от нея, затова всички стойности на експлоатируемостта в този доклад са стойности на NashConv и трябва да се разделят на две, преди да се сравняват с числа в конвенцията на OpenSpiel. Две конфигурации: **бърза проверка** (7 активни агента, 15 епохи) и **пълен мащаб** (8 активни агента, 120 епохи, 48 замразени моментни снимки).

3.2 5. Експеримент 3 - динамика на обучението в лигата

Какво проверяваме. Намалява ли експлоатируемостта на лигата по време на обучението и следва ли мета-Наш сместа на популацията това подобрение? (Проверка по първоначалния план, L535, L537.)


Как. На всяка епоха се записват минималната експлоатируемост сред основните агенти и експлоатируемостта на текущата мета-Наш смес; записват се също транзитивното съотношение на мета-играта на моментните снимки на лигата и крайният рейтинг по Ело. Данни: `results/{smoke,scale}_results.json` (блок league).

Показател	Бърза проверка (15 епохи)	Пълен мащаб (120 епохи)
минимална експлоатируемост сред основните агенти	4.67 → 3.04 (монотонно, най-ниската стойност е в края)	4.73 → мин ≈ 1.21 (еп 66) → 2.05 (еп 119)
експлоатируемост на мета-Наш сместа	4.73 → 3.04	5.01 → мин ≈ 1.32 (плато 1.60) → 2.96 (еп 119)

Показател	Бърза проверка (15 епохи)	Пълен мащаб (120 епохи)
транзитивно съотношение	0.981	0.937
на мета-играта на лигата		
краен рейтинг по Ело	1176–1211	1198–1210
(активни агенти)		

Резултати. Бързата проверка показва ясно монотонно намаляване и завършва с най-ниската си стойност (3.04) - но 15 епохи са твърде малко, за да се види какво следва. Пълният мащаб го показва: експлоатируемостта спада рязко през първите около 15 епохи и е най-ниска около епохи 20–40 (мета-Наш сместа достига ≈ 1.32 в епоха 21, а най-добрата моментна снимка е от епоха 29; единичният минимум сред основните агенти, ≈ 1.21 в епоха 66, е изолиран спад), след това се задържа на плато ≈ 1.60 за мета-Наш сместа и накрая **нараства отново** до ≈ 2.05 (минимумът сред основните агенти) и ≈ 2.96 (мета-Наш) в епоха 119. Рейтингите по Ело са близки (всички активни агенти са в рамките на ≈ 15 точки), което съответства на популация с близко поведение.

Заклучение. Лигата наистина води до силно ранно подобрене, но **при пълен мащаб подобренето не е монотонно**: в края на обучението активните основни агенти губят позиции по абсолютна експлоатируемост. Натискът на експлоататорите може да допринася за това, но базовото самообучение, което няма експлоататори, също се влошава след епоха 100, така че той не е единствената причина. Най-добрите агенти са запазени като *замразени моментни снимки* от първата половина на обучението. Тази немонотонност е честният основен извод от изпълнението при пълен мащаб и е разгледана в §8.3.



Фигура 3: Експлоатируемост (NashConv) на лигата по време на обучението (пълен мащаб, 120 епохи): минимумът сред основните агенти и експлоатируемостта на мета-Наш сместа спадат рязко през първите около 15 епохи, най-ниски са около епохи 20-40 (мета-Наш ~ 1.32 в епоха 21) и след това отново нарастват (~ 2.05 / ~ 2.96) до епоха 119. Пунктирната сива линия е базовото самообучение, което също се влошава след епоха 100. Лигата не се подобрява монотонно; най-добрите агенти са замразени моментни снимки от първата половина на обучението.

3.3 6. Експеримент 4 - EGTA, мета-Наш и разнообразие

Какво проверяваме. (а) По-малко експлоатируема ли е мета-Наш сместа на крайната популация от всеки отделен агент (очакването от първоначалния план, L536)? (б) Колко разнообразна е популацията (ефективен размер, поведенческа клъстеризация, покритие на експлоатацията - L538)?

Как. Строи се емпиричната симетрична матрица на печалбите за всички агенти (активни и замразени), намира се мета-Наш сместа, тя се свежда до една поведенческа стратегия и точната ѝ експлоатируемост се сравнява с тази на най-добрия отделен агент. Разнообразие: ефективен размер на популацията (коефициент на участие на мета-Наш теглата), поведенческа клъстеризация чрез единично свързване и покритие на експлоатацията. Данни: `results/{smoke,scale}_results.json(league.egta, league.diversity)`. Интуиция от

опростен модел: exploration/figures/mini_pbt.json.

(а) Мета-Наш сместа спрямо най-добрия отделен агент:


Конфигурация	експлоатируемост на мета-Наш сместа	най-добър отделен агент	мета-Наш $\leq$ най-добрия?
Бърза проверка	2.665	2.665	да (цялото тегло е върху най-добрия агент)
Пълен мащаб	3.418	1.305	не (теглото е разпределено: 0.645 и два по-малки дяла)

(б) Разнообразието:

Показател	Бърза проверка	Пълен мащаб
агенти / активни (участие)	16 / 1 (1.00)	56 / 3 (1.92)
поведенчески клъстери (праг 0.30)	1 (максимално разстояние между двойки 0.255)	1 (максимално разстояние между двойки 0.484)
покриване на експлоатацията	0.625	0.571

Резултати. (а) При бързата проверка мета-Наш дава цялото тегло на единствения най-добър агент, така че мета-Наш = най-добрия = 2.665 (прогнозата се потвърждава тривиално). При пълен мащаб мета-Наш разпределя теглото и сместа, сведена до една поведенческа стратегия, е по-експлоатируема (3.418) от най-добрия отделен член на популацията (1.305), който получава тегло нула - прогнозата **не се потвърждава** (§8.1). (б) Популацията е само слабо разнообразна: коефициентът на участие нараства от 1 до 1.9, но поведенческата клъстеризация свежда всичко до **един клъстер** и при двете конфигурации (въпреки че при пълен мащаб максималното разстояние между двойки, 0.484, надвишава прага 0.30 - единичното свързване обединява агентите във верига). Опростеният модел мини-RBT показва механизма нагледно: в транзитивната дилема на затворника разнообразието спада до 0, а в цикличната игра „камък-ножица-хартия“ стратегиите непрекъснато се сменят (0.07–0.29).

Заклучение. EGTA дава експлоатируемост на ниво популация, но се открояват два извода: мета-Наш сместа **не** е непременно по-малко експлоатируема от най-добрия член на популацията (§8.1), а разнообразието в RBT тук е *на ниво тегла*, а не *на ниво поведение* - агентите са почти еднакви, така че „популацията“ е по-бедна, отколкото подсказва размерът ѝ.



Фигура 4: Разнообразие при мини-PBT през поколенията: в транзитивната дилема на затворника разнообразието на стратегиите в популацията спада до нула (всички преминават към предателство), а в цикличната игра „камък-ножица-хартия“ стратегиите непрекъснато се сменят (0.07-0.29), докато популацията следва кръга от контрастратегии. Дали разнообразието ще се запази, зависи от структурата на играта (изпълнен е само един размер на популацията).

3.4 7. Експеримент 5 - лигата срещу PSRO, самообучението и CFR (равновесие на Наш)

Какво проверяваме. Как се сравнява лигата с алтернативите - точния PSRO, обикновеното самообучение и CFR (равновесие на Наш) - по експлоатируемост в Ледюк? (Проверка по първоначалния план, L539.)


Как. Всеки метод се изпълнява до бюджета на своята конфигурация и се отчита експлоатируемостта. За лигата се взема **най-добрият отделен агент** (най-силната замразена моментна снимка, т.е. най-добрата стойност за цялото обучение); самообучението е дадено както с крайния агент, така и с най-добрата си итерация по епохи, за да се сравнява най-доброто с най-доброто; PSRO използва точния оракул за най-добър отговор (крайната му стойност е и най-добрата); CFR дава долната граница, близка до равновесие на Наш. Данни: `results/{smoke,scale}_results.json` (league, baselines).

Метод	Бърза проверка	Пълен мащаб	Бележка
CFR, равновесие на Наш (долна граница)	0.033 (2 хил. итерации)	0.0099 (20 хил. итерации)	приблизително равновесие на Наш, целевата долна граница
Лига - най-добър отделен агент	2.665	1.305	най-силната замразена моментна снимка (най-добрата за цялото обучение)
Самообучение - най-добра итерация	3.111	1.396 (еп 100)	най-добрата за цялото обучение, пряко сравнима с лигата
PSRO (точен оракул за най-добър отговор)	3.037 (12 кръга)	2.163 (20 кръга)	бавната „стена“ на Ледюк от Глава 9
Лига - мета-Наш смес	2.665	3.418	вж. §8.1
Самообучение - краен агент	3.140	3.683	най-добър отговор само на последната версия

Резултати. При пълен мащаб **най-добрият отделен агент** на лигата (1.305) има най-ниската стойност сред методите, основани на обучение - по-добър от точния PSRO (2.163) и от крайния агент на самообучението (3.683), но сравним с най-добрата итерация на самото самообучение (1.396 в епоха 100; и двете са от едно изпълнение, така че разликата не е значима), - и всички остават далеч над долната граница на CFR (0.0099). **Мета-Наш сместа** на лигата (3.418) е по-лоша от PSRO и от най-добрия отделен агент, но по-добра от крайния агент на самообучението (§8.1). Крайният агент на самообучението всъщност се *влошава* от бързата проверка към пълния мащаб, което съответства на липсата на сходимост на последната итерация: при пълен мащаб самообучението достига 1.396 и след това се влошава през последните 20 епохи.

Заклучение. Лигата създава силни *отделни агенти* - най-добрата ѝ моментна снимка е по-добра от PSRO и от крайния агент на самообучението и е сравнима с най-добрата итерация

на самообучението, - но сместа не е силна, а нито един от методите, основани на обучение, не се доближава до долната граница на точния CFR за Ледюк. Като резултат от лигата трябва да се използва избран отделен агент, а не мета-Наш сместа (§8.1).



Фигура 5: Експлоатируемост (NashConv) в Ледюк по методи (пълен мащаб): долна граница CFR (равновесие на Наш) ~0.01; най-добрият отделен агент на лигата (1.31, най-добрият за цялото обучение) е сравним с най-добрата итерация на самообучението (1.40) и е под PSRO (2.16), под мета-Наш сместа на лигата (3.42) и под крайния агент от самообучението (3.68). Като резултат трябва да се използва избран отделен агент, а не сместа.

3.5 8. Съпоставка на прогнозите с резултатите

Съгласно WORKFLOW §0.1 опроверганите прогнози от фаза 4 се запазват и се съпоставят с резултатите, а не се редактират мълчаливо. Три разминавания.

1. **Мета-Наш сместа на лигата $\leq$ най-добрият отделен агент (§6a).** Прогноза (контролният списък от първоначалния план, L536): мета-Наш сместа е по-малко експлоатируема от всеки отделен агент. Измерено: вярно при бързата проверка ($2.665 = 2.665$, цялото тегло е върху най-добрия агент), **невярно при пълен мащаб** ($3.418 > 1.305$). Съпоставка: не е грешка в смесването - същият код (mixture_behavioral_policy) дава мета = най-добрия при бързата проверка. Мета-Наш минимизира **съжалението в мета-играта** (резултата срещу популацията), а това е *различна цел* от минимизирането на **експлоатируемостта в пълната игра**. Сместа всъщност е *по-малко* експлоатируема от всеки от трите си компонента (3.558, 3.932, 4.262 при тегла 0.322, 0.645,

0.032); най-малко експлоатируемият агент (1.305, main_2#e29) и другите ранни моментни снимки просто получават тегло нула в мета-Наш. Изводът се обръща и изостря: оценката на популацията трябва да измерва пряко експлоатируемостта на сместа, а на практика като резултат да се използва избран отделен агент, а не самата смес.

2. **Мета-играта на Ледюк е транзитивна (§3).** *Прогноза:* документът с интуицията представяше покера като стълбица на уменията. *Измерено:* мета-играта на **най-добрите отговори** в PSRO е предимно циклична (транзитивно съотношение ≈ 0.41 - 0.46 , 27 цикъла от три стратегии), докато мета-играта на **моментните снимки** на лигата е предимно транзитивна (≈ 0.94 - 0.98). *Съпоставка:* не е грешка - популацията от най-добри отговори заикля (А побеждава сместа, Б побеждава А, по-късен най-добър отговор побеждава Б; „пумпалът“ на Czarneski и др.), докато популацията от моментни снимки от траекторията на обучение образува стълбица, защото по-късните моментни снимки обикновено са по-силни. Структурата е свойство на *популацията*, а не само на играта; и двете измервания са верни и поучителни.
3. **Експлоатируемостта на лигата намалява монотонно (§5).** *Прогноза:* монотонно намаляване. *Измерено:* при бързата проверка (15 епохи) спадът е плавен и най-ниската стойност е в края (3.04); при пълен мащаб (120 епохи) експлоатируемостта спада рязко през първите около 15 епохи, най-ниска е около епохи 20–40 (мета-Наш ≈ 1.32 в епоха 21, най-добрата моментна снимка е от епоха 29; единичен минимум сред основните агенти ≈ 1.21 в епоха 66; плато на мета-Наш 1.60) и след това **нараства отново** до ≈ 2.05 / ≈ 2.96 в епоха 119. *Съпоставка:* честна и вероятно реална нестабилност на обучението, която се вижда само при достатъчно дълго обучение - в края активните основни агенти губят позиции по абсолютна експлоатируемост (стратегии им непрекъснато се сменят и част от наученото се забравя); натискът на експлоататорите може да допринесе, но самообучението без експлоататори също се влошава след епоха 100, така че той не е единствената причина. Най-добрите агенти са замразените моментни снимки от първата половина на обучението - точно затова показателят за най-добрия отделен агент (§7) е силен, а късните активни агенти не са. Проблемът е документиран, но не е отстранен; естественото решение е запазване на най-добрата моментна снимка или регуляризация на популацията (§11). Това повтаря методологичното правило от Глава 9: **пълният мащаб разкрива това, което бързата проверка скрива.**

3.6 9. Достоверност и достатъчност на извадката

- **Еволюционните резултати са съпоставени с аналитични еталони.** Всеки резултат на репликаторната динамика се проверява спрямо аналитичните ESS и равновесия на Наш на играта; съотношенията „пумпал“ се проверяват спрямо чистите случаи („камък-

ножица-хартия“ = 0.0, стълбица на уменията = 1.0). Те са детерминистични и напълно възпроизводими.

- **Експлоатируемостта на лигата е *точният* NashConv от Глава 7**, а не симулация: всяка невронна стратегия се извлича в таблична стратегия и се оценява с точен най-добър отговор, така че въпросът „колко експлоатируем е този агент/смес?“ е проверен спрямо точни стойности, а не оценен приблизително.
- **Обучението на невронните мрежи е чувствително към началното число и към използваната библиотека.** Лигата е едно изпълнение на PBT за всяка конфигурация; надеждни са *качествените* изводи (ранно подобрене; най-добрата моментна снимка < PSRO < крайния агент на самообучението; късна регресия при пълен мащаб; мета-Наш сместа > най-добрия член на популацията при пълен мащаб), а не стойностите до третия знак след десетичната запетая.
- **Показателите за разнообразие зависят от прага.** Резултатът с един клъстер зависи от прага 0.30 при единичното свързване; той трябва да се чете като „поведенчески сходни“, а не като „доказано една стратегия“.

3.7 10. Ограничения (подредени според степента на влияние върху заключенията)

1. **Регресия в късната фаза на обучението при пълен мащаб (§5, §8.3)** - лигата не се подобрява монотонно; докато не се добави запазване на най-добрата моментна снимка или регуляризация и изпълнението не се повтори, твърдението „лигата се подобрява“ важи само за *първата половина* от обучението и за *най-добрата замразена* моментна снимка, а не за активните агенти.
2. **Мета-Наш сместа е по-експлоатируема от най-добрия член на популацията, на когото дава тегло нула (§6a, §8.1)** - затова при оценката на популацията сместа не трябва да се представя като силата на лигата; правилният резултат е избраният отделен агент.
3. **Слабо поведенческо разнообразие (§6b)** - коефициентът на участие 1.9 и единственият поведенчески клъстер показват, че „популацията“ е почти изродена; ползите от разнообразието, описани за AlphaStar, където по време на обучението са създадени близо 900 различни агента, не се проявяват в този мащаб.
4. **Невронните резултати са от едно изпълнение (§9)** - посоката е надеждна, но стойностите са несигурни.
5. **Мащаб на опростен модел навсякъде** - Ледюк и малки матрични игри; нищо оттук не бива да се екстраполира към лиги с дълбоко обучение с подкрепление в мащаба на AlphaStar.

3.8 11. Заключение и насоки за бъдещи изследвания

Заключения. Част I дава диагностиката: репликаторната динамика възпроизвежда всеки аналитичен резултат (ESS или равновесие на Наш), включително несходящата орбита при „камък-ножица-хартия“, а разлагането „пумпал“ на Ходж ясно отделя умението от цикличността - и показва, че *една и съща* игра (Ледюк) е циклична като популация от най-добри отговори, но транзитивна като популация от моментни снимки. Част II изгражда лигата и я оценява с точна експлоатируемост: тя създава силни *отделни агенти* (най-добрата моментна снимка е 1.305 - по-добра от PSRO, 2.163, и сравнима с най-добрата итерация на самообучението, 1.396; крайният агент на самообучението е 3.683; всички от едно изпълнение), но три прогнози честно се оказаха неверни - при пълен мащаб мета-Наш сместа е *по-експлоатируема* от най-добрия член на популацията, мета-играта на най-добрите отговори в Ледюк е *циклична*, а не транзитивна, а експлоатируемостта на лигата *нараства отново* в края на дългото обучение. Популационният механизъм работи, но не дава гаранция за монотонност или безопасност - а точно това е празнината, към която е насочена дисертацията.

Насоки за бъдещи изследвания (всяка е свързана с измерен ефект):

- *Запазване на най-добрата моментна снимка / регуляризация на популацията* - насочено е пряко към късната регресия (§8.3); повторно изпълнение ще покаже дали липсата на гаранция е проблем на обучението, или на дизайна.
- *Отчитане на избрания отделен агент или мета-решавател с регуляризация за разнообразие* - слабостта на мета-Наш сместа (§8.1) мотивира или използването на избран агент, устойчив срещу най-добър отговор, или смяна на целта на мета-решавателя.
- *Прилагане на транзитивно-цикличната диагностика към игрите всеки срещу всеки от Глава 11* - пряка проверка на прогнозата за „голяма циклична компонента“, при която се очаква наивното PBT да зацикли.
- *Формализиране на безопасността на популацията без опора в минимаксна стойност (Принос №2)* - механизмът с експлоататори е евристичен; §8.1 и §8.3 показват, че той не гарантира неексплоатируема популация.

3.9 12. Възпроизвеждане на резултатите

От `implementation/step10/implementation/`, с активирана проектна виртуална среда `.venv`:

```
# validation harness (PASS/FAIL/SKIP against the raw-step targets)
python validate.py
```

```
# full comparison runs -> results/{smoke,scale}_results.json
```

```
python tournament.py --config smoke
```

```
python tournament.py --config scale
```

```
# plots from a results JSON -> plots/*.png (needs matplotlib)
```

```
python plotting.py --config scale
```

От implementation/step10/exploration/ (фигурите от Част I и съответните JSON файлове):

```
python replicator_playground.py      # replicator phase portraits + JSON
```

```
python game_landscape.py             # transitive/cyclic ratios (RPS / skill / PSRO-Leduc)
```

```
python mini_pbt.py                   # diversity collapse vs churn
```

```
python psro_population_peek.py        # PSRO population dynamics on Leduc
```

Началните числа са фиксирани в config.py (реализацията) и в конфигурацията на всеки скрипт за изследване. Еволюционните резултати и тези за „пумпала“ са точно възпроизводими; при невронната лига посоката на резултатите е устойчива при различни начални числа. Всички числа в този доклад са взети от results/{smoke,scale}_results.json и exploration/figures/*.json.