

Съдържание

1	Стъпка 10 - Обучение, базирано на популации и еволюционна теория на игрите: Експериментален доклад	1
2	ЧАСТ I - ЕВОЛЮЦИОННА ТЕОРИЯ НА ИГРИТЕ КАТО ДИАГНОСТИЧЕН ОБЕКТИВ	2
2.1	1. Какво разглежда тази стъпка	2
2.2	2. Експеримент 1 - репликаторна динамика върху четири матрични игри . . .	2
2.3	3. Експеримент 2 - пумпалът: транзитивна спрямо циклична структура	4
3	ЧАСТ II - ЛИГАТА С РВТ	6
3.1	4. Какво представлява лигата и как се оценява	6
3.2	5. Експеримент 3 - динамика на обучението в лига	7
3.3	6. Експеримент 4 - EGTA, мета-Наш и разнообразие	8
3.4	7. Експеримент 5 - сравнение между лига, PSRO, самообучение и cFR-Nash . .	10
3.5	8. Съгласуване на прогноза <-> реалност	12
3.6	9. Достоверност и достатъчност на извадката	13
3.7	10. Ограничения (подредени според степента на влияние върху заключенията)	14
3.8	11. Заключения и насоки за бъдещи изследвания	14
3.9	12. Възпроизвеждане на резултатите	15

1 Стъпка 10 - Обучение, базирано на популации и еволюционна теория на игрите: Експериментален доклад

Тестови среди: четири симетрични матрични игри за еволюционно-динамичната половина (Дилемата на затворника, Ястреб–Гълъб, Камък–Ножица–Хартия, Лов на елен); синтетична стълбица на чистото умение; мета-играта на най-добър отговор PSRO върху Ледюк Холдем; и малка **РВТ лига** в стил alphaStar от невронни PPO агенти, играещи Ледюк Холдем. Двигателят за Ледюк, точният предсказвач за най-добър отговор и NashConv/експлоатируемост са взети от стъпка 07 (използвани изцяло); PSRO и решавачът на мета-Наш са от стъпка 09. Невронните агенти се обучават с pyTorch, след което се извличат към *таблични* политики, така че **точният** най-добър отговор от стъпка 07 да може да ги оценява.

Връзка с дисертацията: популационното ниво на тезата. Три връзки: **основните експлоатори като автоматизирани моделиращи съперника** (Принос №1, популационният лифт на байесовото четене от стъпка 07); **AlphaStar League като механизъм за безопасна експлоатация на популацията, чиято гаранция липсва** (Принос №2); и **EGTA / мета-Наш като методология за оценяване на популацията** (Принос №3).

Обхват на резултатите: всяко число в този доклад е **измерено от реален прогон** и извлечено от артефактите в `implementation/step10/implementation/results/{smoke,scale}_results.json` и `implementation/step10/exploration/figures/*.json`. Еволюционните резултати са

съпоставени с *аналитични* препратки (ESS / наш равновесие за всяка матрична игра), а резултатите от лигата - с **точния** експлоатируемост от стъпка 07. Три прогнози от фаза 4 бяха **опровергвани** от прогона в мащаб; съгласно РАБОТЕН ПРОЦЕС §0.1 те се запазват така, както са формулирани и се съгласуват с действително настъпилото (§8).

Как да се чете този доклад. И двете части следват една и съща дъга: **какво тестваме -> как -> резултати -> заключение.** **Част I (§1-§3)** използва еволюционна теория на игрите като *диагностичен обектив*: репликаторна динамика върху решими матрични игри, след това транзитивното/цикличното разлагане „пумпал“. **Част II (§4-§7)** изгражда и оценява **PBT лигата**: динамика на обучението, EGTA/мета-Наш, разнообразие + Elo и директен сблъсък срещу PSRO / самообучение / CFR-Nash. §8 съгласува трите опровергвани прогнози; §9-§11 обхващат доверие, ограничения и насоки; §12 изброява командите за възпроизвеждане.

2 ЧАСТ I - ЕВОЛЮЦИОННА ТЕОРИЯ НА ИГРИТЕ КАТО ДИАГНОСТИЧЕН ОБЕКТИВ

2.1 1. Какво разглежда тази стъпка

Стъпки 2–9 разглеждаха равновесията на *фиксирана* игра. Стъпка 10 преминава към по-високо ниво - **популации от стратегии, които се променят във времето**, и поставя два въпроса, на които един агент не може да отговори: *кои стратегии нарастват?* (репликаторна динамика) и *тази игра изобищо ли има „най-добра“ стратегия или само колело от броячи?* (транзитивно/циклично разлагане). Тези два инструмента представляват диагностиката, необходима за обучението, базирано на популации в Част II - защото дали една самообучаваща се популация ще сходява или ще циклира зависи от структурата на играта, а не от скоростта на обучение. Всички еволюционни числа в Част I са детерминистични (фиксирани начални стойности, точна динамика), така че въпросът „сходи ли?“ има еднозначен отговор.

2.2 2. Експеримент 1 - репликаторна динамика върху четири матрични игри

Какво тестваме. Възпроизвеждат ли репликаторната динамика еволюционния *аналитичен* резултат за всяка игра - сходимост към доминираща стратегия, към вътрешно ESS, към басейнозависим чисто ESS или неконвергентна орбита? (Проверка на суровите стъпки, L530–533.)

Как. Дискретна интеграция на репликатора на Ойлер от инициализирано начало от


вътрешността; „сходим“ означава, че последната итерация е спряла да се променя; „орбитален радиус“ е разстоянието, което траекторията поддържа от равномерната точка. Аналитично равновесие на Еволюционно стабилни стратегии/Наш служи като референтна стойност. Данни: results/smoke_results.json (блок „replicator“), фазови портрети в exploration/figures/replicator_playground.json.

Игра	Аналитична референ- ция	Начало x_0	Краен x	Сходим?	Орбитален радиус
Дилемата на затворника	Дефектът доминира; уникално ESS (0, 1)	[0.666, 0.334]	[0.0, 1.0]	да	0.707
Ястреб-гълъб	вътрешно ESS $p(\text{Hawk}) = V/C = 0.5$	[0.548, 0.452]	[0.5, 0.5]	да	0.0
Камък-ножица-хартия	Наш равновесие = равномерно; няма ESS (център)	[0.347, 0.385, 0.268]	[0.299, 0.288, 0.413]	не	0.095
Лов на елен ($x_0 = [0.8, 0.2]$)	две чисто ESS (басейно-зависим)	[0.8, 0.2]	[1.0, 0.0]	да	0.707
Лов на елен ($x_0 = [0.2, 0.8]$)	две чисто ESS (басейно-зависим)	[0.2, 0.8]	[0.0, 1.0]	да	0.707

Резултати. И четирите съвпадат напълно с теорията. Дилемата на затворника се свежда до all-Defect (доминиращата стратегия). Ястреб–гълъб сходява към вътрешната смесена ESS точно при 0.5 (орбитален радиус 0.0 - тя *достига* равновесната точка). Камък–ножица–хартия **не сходява**: тя обикаля около равновесната точка с постоянен радиус (0.095), тъй като вътрешната неподвижна точка е център, а не атрактор. Лов на елен попада върху

различни чисто ESS в зависимост от началото - $[0.8, 0.2] \rightarrow \text{all-Stag}$, $[0.2, 0.8] \rightarrow \text{all-Hare}$ - двата басейна се проявяват ясно.

Заклучение. Репликаторната динамика представлява непрекъсната идеализация на подбора на популация, а нейните равновесни точки съответстват точно на nash/ESS. Тази, която *не сходява* - RPS - е основната причина за съществуването на Част II: циклична игра няма стабилна популация, поради което самообучаваща се популация в нея ще се върти, вместо да достигне равновесие.



Фигура 1: Replicator phase portraits on the four matrix games: Prisoner's Dilemma collapses to all-Defect, Hawk-Dove converges to the interior 0.5 ESS, Rock-Paper-Scissors orbits the centre without converging, and Stag Hunt splits into two basins (all-Stag or all-Hare) depending on the start. The non-converging RPS orbit is the visceral case for the diversity machinery in Part II.

2.3 3. Експеримент 2 - пумпалът: транзитивна спрямо циклична структура


Какво тестваме. Можем ли да разложим матрицата на печалбата на една игра на **транзитивен** (скала на уменията) компонент и **цикличен** (камък-ножица-хартия) компонент, и дали това разлагане правилно идентифицира чистите случаи и диагностицира реални популации? (проверка на суровите стъпки, L532, L534.)

Как. Комбинаторно-**Hodge** разлагане (на база разлика в рейтингите) на антисиметризираната матрица на печалбата, което отчита транзитивно и циклично съотношение (ортогонални величини, които се събират квадратурно до 1). Допълнително представяме **sVD rank-1** транзитивното съотношение, изчислено чрез суровите стъпки за RPS, с цел да документираме неговия известен провал. Данни: `results/{smoke,scale}_results.json` (блок `spinning_top`), `exploration/figures/game_landscape.json`.

Популация	Транзитивно съотношение (Hodge)	Циклично съотношение (Hodge)	Трицикли	Бележка
Камък- ножица- хартя	0.0	1.0	1	sVD rank-1 неправилно дава 0.707
Чиста скала на уменията	1.0	0.0	0	монотонна сила
Мета-игра PSRO-Ледюк (smoke, 8 рунда)	0.457	0.890	-	предимно циклична
Мета-игра PSRO-Ледюк (мащаб, 20 рунда)	0.411	0.912	27	предимно циклична
Моментна снимка на лигата мета-игра (smoke / мащаб)	0.981 / 0.937	-	-	предимно транзитивна

Резултати. Разлагането на Ходж точно определя чистите случаи: RPS е 0.0 транзитивен / 1.0 цикличен (един трицикъл), а скалата на уменията е 1.0/0.0. Методът **sVD rank-1**, предложен вместо това от суровите стъпки, неправилно отчита RPS като ≈ 0.707 транзитивен - грешно, тъй като антисиметрично приближение с ранг 1 не може да представи чист цикъл; за диагнозата се използва именно методът на Ходж. Двете *реални* популации се различават рязко: **мета-играта на най-добър отговор PSRO върху Ледюк е предимно циклична** (≈ 0.41 – 0.46 транзитивен, 27 трицикли), докато **моментната снимка на лигата мета-игра е предимно транзитивна** (≈ 0.94 – 0.98).

Заключение. Транзитивното/цикличното съотношение представлява *предварителна диагностика на обучението*. Две популации, извлечени от една и съща игра (Ледюк), имат противоположна структура в зависимост от начина им на формиране (най-добри отговори спрямо моментни снимки на обучението - виж §8.2). Това е именно инструментът, който предсказва дали наивното самообучение/PBT ще сходи или ще циклира, и това е диагностиката, която дисертацията прилага в следващите стъпки.



Фигура 2: Transitive-ratio bar chart: Rock-Paper-Scissors (0.0, purely cyclic), a pure skill ladder (1.0, purely transitive), the PSRO-Ледюк best-response meta-game (~0.41-0.46, mostly cyclic with 27 three-cycles), and the league snapshot meta-game (~0.94-0.98, mostly transitive). Which population you decompose decides whether Ледюк looks like a wheel or a ladder.

3 ЧАСТ II - ЛИГАТА С РВТ

3.1 4. Какво представлява лигата и как се оценява

Втората половина изгражда малка **AlphaStar-style League** върху Ледюк Холдем с три типа агенти - **основни агенти** (продуктът), **основни експлоатъори** (търсят слабости в настоящите основни) и **експлоатъори в лигата** (търсят слабости навсякъде във замразената история) - плюс периодично **замразяване** на снимки в музей и **PFSP** сдвояване (по-често срещане с по-трудни опоненти). Агентите са **невронни PPO мрежи** върху **кодиране на информационно състояние** за Ледюк; РВТ копира най-добрите агенти (експлоатация) и променя тяхната **скорост на обучение** / **ентропия** (изследване). От решаващо значение е, че всяка мрежа се извлича в **таблична стратегия**, така че **точният** най-добър отговор от Стъпка 07 измерва нейната **експлоатируемост** - същият NashConv показател, използван още от Стъпка 2. Две конфигурации: **smoke** (7 активни агенти, 15 епохи) и **scale** (8 активни агенти, 120 епохи, 48 замразени снимки).

3.2 5. Експеримент 3 - динамика на обучението в лига


Какво тестваме. Намалява ли експлоатируемостта на лигата по време на обучението и отразява ли мета-Наш равновесието на популацията това подобрение? (Проверка на суровите стъпки, L535, L537.)

Как. На всяка епоха се записва минималната експлоатируемост сред основните агенти и експлоатируемостта на текущата мета-Наш смес; също така се записват транзитивното съотношение на мета-играта в моментната снимка на лигата и крайното ЕЛО. Данни: `results/{smoke,scale}_results.json` (блок `league`).

Метрика	Smoke (15 епохи)	Scale (120 епохи)
минимална експлоатируемост при основен отговор	4.67 → 3.04 (монотонно, завършва на мин)	4.73 → мин $\approx$ 1.21 (еп ~64) → 2.05 (еп 119)
експлоатируемост на мета-Наш равновесие	4.73 → 3.04	5.01 → мин $\approx$ 1.32 (плато 1.60) → 2.96 (еп 119)
транзитивно съотношение на мета-играта в лигата	0.981	0.937
крайно ело на активните агенти	1176–1211	1198–1210

Резултати. Smoke показва ясно монотонно намаляване и достига своя минимум (3.04) - но 15 епохи са твърде кратки, за да се разкрие какво следва. Мащабът обаче показва друго: експлоатируемостта спада рязко до минимум около епоха 60–65 (**мин-основен** $\approx$ 1.21, мета-Наш достига дъно $\approx$ 1.32 и след това се задържа на $\approx$ 1.60 плато), а впоследствие **регресира** обратно до $\approx$ 2.05 (мин-основен) и $\approx$ 2.96 (мета-Наш) към епоха 119. Разпределението на ЕЛО е стеснено (всички активни агенти са в рамките на $\approx$ 15 точки), което съответства на популация с близко поведение.

Заключение. Лигата действително води до силно ранно подобрение - но подобрението **не е монотонно при мащаб**: под постоянен натиск на експлоаторите, активните основни агенти ги преследват и губят позиции спрямо абсолютната експлоатируемост в късния етап на обучението. Най-добрите агенти се улавят като *замразени моментни снимки* по средата на изпълнението. Тази немонотонност е честното заключение от мащабния експеримент и е разгледана в §8.3.



Фигура 3: League exploitability over training (scale, 120 epochs): min-main and meta-Nash exploitability both fall steeply to a minimum near epoch 60 (min-main ~ 1.21 , meta-Nash ~ 1.32) and then regress upward (~ 2.05 / ~ 2.96) by epoch 119. A running league is not a monotonically improving one; the best agents are frozen snapshots from mid-run.

3.3 6. Експеримент 4 - EGTA, мета-Наш и разнообразие

Какво изследваме. (а) Дали мета-Наш равновесието на финалната популация е по-малко експлоатируемо от всеки отделен агент (очакваната стойност за стъпка, L536)? (b) Колко разнообразна е популацията (ефективен размер, поведенческо групиране, покритие на експлоатация - L538)?

Как. Изграждане на емпирична симетрична матрица на печалбата върху всички агенти (живи и замразени), определяне на мета-Наш сместа, свеждането ѝ до една поведенческа стратегия и измерване на нейната точна експлоатируемост спрямо най-добрия индивид. Разнообразие: ефективен размер на популацията (коефициент на участие на мета-Наш тегла), клъстеризация на поведенчески стратегии чрез единична връзка и покритие на експлоатация. Данни: results/{smoke,scale}_results.json (league.egta, league.diversity). Игрова интуиция: exploration/figures/mini_pbt.json.

(а) Мета-Наш спрямо най-добрия индивид:


Конфигурация	експлоатируемост на мета-Наш равновесие	най-добър индивид	мета-Наш $\leq$ най-добър?
Smoke	2.665	2.665	да (всички тегла върху най-добрия агент)
Scale	3.418	1.305	не (разпределение на тегла 0.645+опашка)

(б) Разнообразието:

Метрика	Smoke	Мащаб
агенти / активни (участие)	16 / 1 (1.00)	56 / 3 (1.92)
поведенчески клъстери (праг 0.30)	1 (максимално разстояние между двойки 0.255)	1 (максимално разстояние между двойки 0.484)
покриване на експлоатация	0.625	0.571

Резултати. (а) В smoke мета-Наш равновесието поставя всички тегла върху единствения най-добър агент, така че мета-Наш = най-добър = 2.665 (прогнозата се потвърждава тривиално). При мащаб мета-Наш равновесието разпределя тегла и неговата колапсирала смес е *повече* експлоатируема (3.418), отколкото най-добрият единичен член (1.305) - прогнозата **не се потвърждава** (§8.1). (б) Популацията е само слабо разнообразна: коефициентът на участие нараства от 1 до 1.9, но поведенческото групиране колапсира всичко в един **единствен клъстер** и при двата мащаба (въпреки че максималното разстояние между двойки в популацията при мащаб 0.484 надвишава прага от 0.30 - единичната връзка обединява веригата). Играчката mini-PBT прави механизма ясен: при транзитивен дилемата на затворника разнообразието колапсира до 0; при цикличен RPS то се върти безкрайно (0.07–0.29).

Заклучение. EGTA предоставя експлоатируемост на ниво популация, но се открояват два извода: смесването на поведенчески стратегии чрез мета-Наш равновесието **не** гарантира по-малко експлоатируем резултат (§8.1), а разнообразието в PBT тук е *на ниво тегло*, а не *на ниво поведение* - агентите са почти идентични, така че „популацията“ е по-оскъдна, отколкото размерът ѝ предполага.



Фигура 4: Mini-PBT diversity over generations: on the transitive Prisoner’s Dilemma the population’s strategy diversity collapses to zero (everyone converges to Defect), while on cyclic Rock-Paper-Scissors it churns indefinitely (0.07-0.29) as the population chases the wheel of counters. Game structure, not population size, sets whether diversity survives.

3.4 7. Експеримент 5 - сравнение между лига, PSRO, самообучение и cFR-Nash

Какво тестваме. Как се сравнява лигата с алтернативните методи - точен PSRO, обикновено самообучение и cFR-Nash - по отношение на експлоатируемостта в Ледюк? (проверка на суровите стъпки, ред L539.)


Как. Изпълнете всеки метод до бюджета в неговата конфигурация и отчетете крайната експлоатируемост. Записът за лигата е нейният **най-добър индивид** (най-силната замразена моментна снимка); PSRO използва точния BR предсказвач; cFR-Nash представлява долната граница на Наш. Данни: `results/{smoke,scale}_results.json` (league, baselines).

Метод	Smoke	Scale	Бележка
CFR-Nash (долна граница)	0.033 (2k итерации)	0.0099 (20k итерации)	приблизително равновесие на Наш, целевата долна граница

Метод	Smoke	Scale	Бележка
Лига - най-добър индивид	2.665	1.305	най-силната замразена моментна снимка
PSRO (точен BR двигател)	3.037 (12 рунда)	2.163 (20 рунда)	Стъпка 09's стената на Ледюк
Самообучение	3.140	3.683	обикновен най-добър отговор към последната итерация
Лига - мета-Наш смес	2.665	3.418	виж §8.1

Резултати. В мащаб **най-добрият индивид** на лигата (1.305) е най-силният сред научените методи - по-добър от точния PSRO (2.163) и самообучението (3.683) - въпреки че всички остават далеч над долната граница на CFR-Nash (0.0099). **Мета-Наш сместа** на лигата (3.418), напротив, е *най-слабата*, дори по-лоша от самообучението (§8.1). Самообучението всъщност се *влошава* при преминаване от smoke към scale, което е съгласувано с несходимост при последна итерация.

Заклучение. Лигата се оказва добър производител на силни индивиди - най-добрата ѝ моментна снимка превъзхожда PSRO и самообучението - но сместа не е такава, като нито един от научените методи не достига долната граница на exact-CFR за Ледюк. От една лига следва да се изпрати избран член, а не мета-Наш сместа (§8.1).



Фигура 5: Final Ледюк exploitability by method (scale): CFR-Nash floor ~0.01; the league's best individual (1.31) beats PSRO (2.16) and self-play (3.68); the league's meta-Nash mixture (3.42) is the weakest learned result. Ship a selected member, not the mixture.

3.5 8. Съгласуване на прогноза <-> реалност

Съгласно РАБОТЕН ПРОЦЕС §0.1, опроверганите прогнози от фаза 4 се запазват и се съгласуват, а не се редактират мълчаливо. Три пропуски.

1. **Мета-Наш на лигата $\leq$ най-добър индивид (§6a).** *Предвидено* (суров стъпков изходен контролен списък, L536): мета-Наш е по-малко експлоатируем от всеки отделен агент. *Измерено*: вярно при smoke ($2.665 = 2.665$, всички тегла върху най-добрия агент), **невярно при мащаб** ($3.418 > 1.305$). *Съгласуване*: не е грешка в смесването - идентичният път на кода `mixture_behavioral_policy` даде мета = най-добър при smoke. Мета-Наш минимизира **мета-игрово съжаление** (победа срещу популацията), което е *различна цел* от минимизиране на ****пълната експлоатируемост на играта; и реализационно претеглена смес от поведенчески стратегии може да бъде повече*** експлоатируема от своите компоненти, защото сместа въвежда „разкриващи“ знаци в информационен набор, които най-добрият отговорчик наказва. Урокът се обръща и изостря: оценката на популацията трябва да измерва експлоатируемостта на колапсирала смес директно и, на практика, да изпраща избран член, а не самата смес.
2. **Мета-играта на Ледюк е транзитивна (§3).** *Предвидено*: интуитивният документ

представи покера като скала на уменията. *Измерено*: мета-играта с **най-добри отговори** на PSRO е предимно циклична (≈ 0.41 - 0.46 транзитивна, 27 трицикли), докато мета-играта с **моментни снимки** на лигата е предимно транзитивна (≈ 0.94 - 0.98). *Съгласуване*: не е грешка - популация от най-добри отговори циклира (А побеждава сместа, Б побеждава А, по-късен най-добър отговор побеждава Б; пумпалът на Балдуци), докато популация от моментни снимки на траекториите на обучение формира стълба, защото по-късните моментни снимки са предимно по-силни. Структурата е свойство на *популацията*, а не само на играта; и двете измервания са верни и поучителни.

3. **Експлоатируемостта на лигата намалява монотонно (§5).** *Предвидено*: монотонно намаляване. *Измерено*: при smoke (15 епохи) намалява чисто и завършва в своя минимум (3.04); при мащаб (120 епохи) спада до минимум около епоха 60 (мин-основни ≈ 1.21 , мета-Наш ≈ 1.32 /плато 1.60) и след това **регресира** до ≈ 2.05 / ≈ 2.96 към епоха 119. *Съгласуване*: честна, вероятно реална нестабилност при обучението, видима едва когато обучението е достатъчно дълго - под постоянен натиск на експлоаторите активните основни агенти преследват своите експлоатори и губят позиции в абсолютната експлоатируемост (разместване / частично забравяне). Най-добрите агенти са замразените моментни снимки от средата на изпълнението, което е точно причината най-добрият индивидуален показател (§7) да е силен, докато късните активни агенти не са. Документирано, но не поправено; естественото средство за защита е съхраняване на най-добрия модел / регуляризация на популацията (§11). Това отразява методологичното правило от Стъпка 09: **мащабът разкрива онова, което smoke скрива.**

3.6 9. Достоверност и достатъчност на извадката

- **Еволюционните резултати са ограничени от аналитични референции.** Всеки изход на репликатора се проверява спрямо аналитичното равновесие на Еволюционно стабилни стратегии/Наш на играта; съотношенията на пумпала се проверяват спрямо чистите случаи ($RPS = 0.0$, скала на уменията = 1.0). Те са детерминистични и абсолютно възпроизводими.
- **Експлоатируемостта на лигата е *точният* NashConv от Стъпка 07**, а не симулация: всяка невронна стратегия се извлича в таблична стратегия и се оценява чрез точен най-добър отговор, така че въпросът „колко експлоатируем е този агент/смес?“ е проверен на място, а не оценен.
- **Обучението на невронна мрежа е чувствително към seed и използваната библиотека.** Лигата представлява едно PBT изпълнение за всяка конфигурация; *качествените* констатации (ранно подобрене; най-добрият индивид < PSRO < самообучение; късна

регресия при мащаб; мета-Наш > най-добър член при мащаб) са надеждните твърдения, а не величините с трети знак след десетичната запетая.

- **Метриките за разнообразие са чувствителни към прагове.** Резултатът от единствената група зависи от прага на 0.30 единична връзка; той трябва да се чете като „поведенчески сходни“, а не „доказуемо една стратегия“.
-

3.7 10. Ограничения (подредени според степента на влияние върху заключенията)

1. **Регресия при късно обучение при мащаб (§5, §8.3)** - лигата не показва монотонно подобрене; докато съхраняване на най-добрия модел/регуляризация не бъдат добавени и изпълнението не бъде повторено, твърдението „лигата се подобрява“ е валидно единствено за *първата половина* от обучението и за *замразения най-добър*, а не за активните агенти.
 2. **Мета-Наш смес по-експлоатируема от най-добрия член (§6a, §8.1)** - това означава, че оценката на популацията не трябва да представя сместа като силата на лигата; правилният артефакт е избраният член.
 3. **Ниско поведенческо разнообразие (§6b)** - коефициентът на участие 1.9 и единственият поведенчески клъстер показват, че „популацията“ е почти дегенерирала; ползите от разнообразието, които AlphaStar докладва при ~600 агента, не се проявяват в този мащаб.
 4. **Еднократно изпълнение на невронните резултати (§9)** - посоката е надеждна, но величината е несигурна.
 5. **Игрови мащаб през цялото време** - Ледюк и малки матрични игри; нищо оттук не трябва да се екстраполира към дълбоко обучение с подкрепление в лиги с мащаба на AlphaStar.
-

3.8 11. Заключение и насоки за бъдещи изследвания

Заключения. Част I представя диагнозата: репликаторната динамика възпроизвежда всяко аналитично равновесие на Еволюционно стабилни стратегии/Наш (включително неконвергиращата орбита на RPS), а декомпозицията тип пумпал на Ходж ясно разграничава уменията от циклите - показвайки, че *същата* игра (Ледюк) е цикличена като популация на най-добри отговори, но транзитивна като моментна популация. Част II изгражда лигата и я оценява чрез точна експлоатируемост: тя създава силни *индивиди* (най-добър моментен модел 1.305, побеждаващ PSRO 2.163 и самообучение 3.683), но три прогнози се оказаха невер-

ни - мета-Наш сместа е *по-* експлоатируема от най-добрия си член в мащаб, мета-играта на най-добър отговор за Ледюк е *циклична*, а не транзитивна, и експлоатируемостта на лигата *регресира* късно при дълго обучение. Популационният механизъм функционира, но не предоставя гаранция за монотонност или безопасност - което представлява самата празнина в тезата.

Насоки за бъдещи изследвания (всяка е свързана с измерен ефект):

- *Съхраняване на най-добрия модел / регуляризация на популацията* - насочено е директно към късната регресия (§8.3); повторно изпълнение, за да се установи дали празнината в гаранциите е проблем на обучението или на дизайна.
- *Докладване на избрания елемент или метарешавател с регуляризация за разнообразие* - провалът на мета-Наш-смесването (§8.1) мотивира или изпращане на най-добър устойчив на отговор елемент, или промяна на метацелта.
- *Прилагане на транзитивната/циклична диагностика към игрите всеки срещу всеки в стъпка 11* - директно тестване на прогнозата за „голям цикличен компонент“, където се очаква наивният РВТ да проявява цикъл.
- *Формализиране на безопасността на популацията без минимакс котва (Принос №2)* - експлоатационният механизъм е евристичен; §8.1/§8.3 показват, че той не гарантира неексплоатируема популация.

3.9 12. Възпроизвеждане на резултатите

От `implementation/step10/implementation/`, с активирана проектна виртуална среда `.venv`:

```
# validation harness (PASS/FAIL/SKIP against the raw-step targets)
python validate.py
```

```
# full comparison runs -> results/{smoke,scale}_results.json
python tournament.py --config smoke
python tournament.py --config scale
```

```
# plots from a results JSON -> plots/*.png (needs matplotlib)
python plotting.py --config scale
```

От `implementation/step10/exploration/` (фигурите от Част I и съответните JSON файлове):

```
python replicator_playground.py      # replicator phase portraits + JSON
python game_landscape.py              # transitive/cyclic ratios (RPS / skill / PSR0-Leduc)
```

```
python mini_pbt.py           # diversity collapse vs churn
python psro_population_peek.py # PSRO population dynamics on Leduc
```

Семената са фиксирани в `config.py` (реализация) и в конфигурацията на всеки сценарий за изследване. Еволюционните резултати и тези от пумпал са точно възпроизводими; резултатите от невронната лига са посокоустойчиви при различни семена. Всички числа в този доклад са прочетени от `results/{smoke,scale}_results.json` и `exploration/figures/*.json`.