

Съдържание

1 Стъпка 12 - Последователни модели и агенти с голям езиков модел в стратегически ситуации: Доклад от експеримента	1
1.1 За какво е предназначена тази стъпка	2
1.2 Основният резултат от сравнението	2
1.3 Петте цели за валидиране	4
1.4 МАТЕМАТИЧЕСКИ ФЛАГ Б - посоката на експектила в абстрактния дървовиден модел на решенията	6
1.5 Последващи експерименти: какво крие скаларната оценка	7
1.6 Ледюк Холдем - проверка на сложността	11
1.7 Съгласуване между прогноза и реалност	13
1.8 Достоверност и достатъчност на извадката	14
1.9 Ограничения (подредени според значимостта им за заключенията)	15
1.10 Заключения и насоки за бъдещи изследвания	16
1.11 Възпроизвеждане	16

1 Стъпка 12 - Последователни модели и агенти с голям езиков модел в стратегически ситуации: Доклад от експеримента

Тестова среда: Кун покер (точно Нашово равновесие и точна експлоатируемост от Стъпка 02), с тесен порт към Ледюк Холдем като проверка на сложността.

Сравнявани методи: nash-CFR · поведенческо клониране · Трансформър за вземане на решения · Трансформър за вземане на решения, устойчив на противникови атаки (ARDT) · четири опорни системи за големи езикови модели (извън линия заглушка, gpt-oss-20b, Qwen2.5-7B-Instruct, openThinker3-7B).

Връзка с дисертацията: Принос №1 (поведенческа адаптация), Принос №2 (безопасна експлоатация), Принос №3 (методология за оценяване).

Обхват на резултатите: всички числа са измерени при реални изпълнения (RTX 5090, локални модели чрез LM Studio 0.4.20). Всяка фигура е генерирана от ангажиран JSON файл с резултати.

Забележка относно артефакта (прочетете веднъж). Два резултата бяха **оттеглени по време на сесията** и се появяват тук само като оттегляния: резултат от обучение в контекста с намалена разлика от +1.59 (невъзможно - виж §Прогноза срещу реалност, R5) и резултат за Ледюк Холдем от голям езиков модел от -0.83 жетона/ръка, получен чрез дефектен декодер (R6). Референтният Nash се различава според бюджета на CFR - 0.0162 жетона при 5,000 итерации (сравнителна таблица), 0.0061 при 50,000 (последващи експерименти); и двете стойности са ≈ 0 . Редът с plain-подкана на OpenThinker3 не е сравним с реда му с CoT (34% от вероятностната му маса отива към токени, които не са действия при обикновена

подкана).

Как да четете този доклад. Основният набор от резултати отговаря на петте цели за валидиране на суровата стъпка. Последващите експерименти бяха добавени, защото тези пет цели класират методите, без да ги обясняват. Всяко твърдение е свързано с именуван артефакт в `implementation/step12/implementation/`.

1.1 За какво е предназначена тази стъпка

Два посткласически начина за игра на игра. **Моделирането на последователности** преформулира RL като условно предсказване на последователност: подават се тройки (очаквана възвръщаемост до края, състояние, действие) на gPT-style модел и се предсказва следващото **действие**, обусловено от желаната бъдеща възвръщаемост - без функция на стойността, без оператор на Белман, без самообучение. **Абстрактният дървовиден модел на решенията** добавя минимаксно обуславяне по възвръщаемост, така че стратегията да бъде устойчива спрямо най-лошия случай опонент, вместо да бъде настроена към този, който случайно се е оказал в данните. **агентите с голям езиков модел** изцяло пропускат обучението: на езиковия модел се дават правилата на английски и той играе.


Кун покер е споделяната тестова среда, тъй като нейното равновесие на Наш и експлоатируемост могат да бъдат изчислени *точно*, така че всеки метод получава проверен на място резултат, а не просто анекдот. Всички методи са приведени към 12-информационния набор формат на стратегия от Стъпка 02 и се оценяват с една и съща точна метрика.

1.2 Основният резултат от сравнението

Експлоатируемост в жетони (по-ниска стойност означава по-голяма близост до **наш равновесие**); **профил на дим**, извън линия заглушка за редовете с **голям езиков модел**.

Метод	Експлоатируемост			стойностен залог(K)
	(жетони)	mbb/h	блъф(J)	
Nash-CFR	0.0162	16.2	0.23	0.68
(референтен)				
поведенческо клониране	0.0550	55.0	0.20	0.68
Абстрактен дървовиден модел на решенията	0.4691	469.1	0.33	0.35

Метод	Експлоатируемост		стойностен	
	(жетони)	mbb/h	блъф(J)	залог(K)
Трансформър за вземане на решения	0.7992	799.2	1.00	0.64
Голям езиков модел (заглушка) × 3	0.8333	833.3	1.00	1.00
стила на подкана				



Фигура 1: Exploitability by method on the exact Kuhn metric - plain behavioural cloning, included only as a contrast baseline, beats both of the methods this step is named after.

Двата метода, за които става дума в тази стъпка, завършват последни. Обикновеното поведенческо клониране - най-простата възможна базова линия - се оказва на 0.04 жетона от **наш равновесие** и превъзхожда трансформъра за вземане на решения с условно връщане приблизително 14 пъти. При данни от самообучение, близки до почти равновесие на Наш, поведенческото клониране просто копира **стратегия**, близка до равновесието на Наш, докато трансформърът за вземане на решения трябва да прекара същата стратегия през канал за условно връщане, който (както е показано по-долу) носи предимно късмет. **Условното връщане тук активно унищожава информация.**

1.2.1 Реални модели

Измерено при температура 0.7 с 24 проби на информационно множество - протоколна точка, която има значение; вижте *протокол за измерване* по-долу.

Бекенд	стил	експл. (жетони)	блъф(J)	стойностен залог(K)	незаконен ход	адапт.
gpt-oss-20b	обикновен	0.2760	0.00	1.00	0%	+0.67
gpt-oss-20b	coT	0.2500	0.08	1.00	1%	+0.79
gpt-oss-20b	теория на игрите	0.3316	0.46	1.00	1%	+0.25
Qwen2.5-7B	обикновен	0.3125	0.00	1.00	0%	+0.00
Qwen2.5-7B	coT	0.3183	0.58	1.00	0%	+0.42
Qwen2.5-7B	теория на игрите	0.3032	0.50	1.00	0%	+0.21
openThinker3-7B	coT (n=12)	0.2882	0.33	1.00	16%	+0.92

7B модел се доближава до 20B модел: Кун възнаграждава прилагането на смесени стратегии с правилната честота, а не знанието или мащаба. Две грешки са универсални - всеки бекенд залага стойност на Попа при 1.00, докато при наш равновесие се смесва при 0.68, и никой не блъфира с Вале под обикновена подкана. Езиковите модели определят правилно *ранга* на ръката, но грешат в *честотите*.

Настройка на разсъжденията в изолирани условия. OpenThinker3-7B е reasoning-SFT върху *същата* Qwen2.5-7B база, така че редовете coT показват неговия ефект: експлоатируемост $0.318 \rightarrow 0.288$, блъф(J) $0.58 \rightarrow 0.33$ (срещу наш равновесие от 0.23), адаптация $+0.42 \rightarrow +0.92$ - постигнато с **16% честота на незаконни ходове** и **65 пъти повече токени** (~6,500 спрямо ~99 на решение).


1.3 Петте цели за валидиране

validate.py, профил на дим: **3 УСПЕХА / 2 НЕУСПЕХА / 0 ПРОПУСНАТИ** (pyTorch и CUDA бяха активни, така че нищо не беше пропуснато).

#	Цел	Измерено	Присъда
1	DT: по-висока очаквана възвръщаемост до края → по-ниска експлоатируемост от по-ниска	high(+2) = 0.6981 срещу low(-2) = 0.6928 жетона	НЕУСПЕХ
2	Действието на DT варира според картата (научава късмета)	корен P(bet) J/Q/K = 1.00/0.03/0.70, разпределение 0.97	УСПЕХ
3	АБДМ < стандартен DT върху същите смесени данни	ARDT 0.5034 срещу DT 0.7212 жетона	УСПЕХ
4	АБДМ в рамките на ~50 mbb/h от наш равновесие	0.5034 жетона срещу допустима стойност 0.05	НЕУСПЕХ
5	ГЕМ честно по-експлоатируем от наш равновесие	0.8333 > 0.0162; реални модели 0.25–0.33	УСПЕХ

И двата неуспеха са действителни констатации, а не проблеми с настройката, като и двата са разгледани по-долу.

Цел №1 се проваля, защото реакцията на DT към условната възвръщаемост **не е подредена според това колко добра е тази възвръщаемост**. Тя реагира - фино обхождане на корен P(bet) с Поп показва 0.747 → 0.020 → 0.781 - но със силен спад точно при R = -1, където минава в **11 от 12** информационни множества и постига 1.98 жетона. R = -1 е модалната възвръщаемост в данните (41.7% от стъпките) и печалбата от пас.




Фигура 2: DT exploitability against the conditioned target return, including an impossible +3. The curve is flat across the real range with a sharp collapse at $R = -1$, the modal payoff and the payoff of folding.

1.4 МАТЕМАТИЧЕСКИ ФЛАГ Б - посоката на експектила в абстрактния дървовиден модел на решенията

Суровият код задава $\tau = 0.9$ и го определя като „песимистичен“. Реализацията отбелязва това като **обърнат** и по подразбиране използва 0.1 . **Статията потвърждава отбелязването:** Уравнение (6) в абстрактния дървовиден модел на решенията дефинира очаквателната загуба, а Уравнение (7) гласи $\lim_{\alpha \rightarrow 0} g_{\alpha} = \min$, $\lim_{\alpha \rightarrow 1} g_{\alpha} = \max$ и ред 1 в Алгоритъм 1 изпълнява $\alpha = 0.01$. Това беше независимо потвърдено от собствената самопроверка на модула, която възстановява *аналитичните* експектили на изкривена извадка ($\tau=0.1 \rightarrow -1.951$, $\tau=0.9 \rightarrow 0.000$).

Емпиричното обхождане противоречи на теорията, а причината е показателна. Целта за преозначаване се изменя монотонно с τ ($-0.626 \rightarrow +0.854$), което потвърждава, че механизмът е изграден коректно - но експлоатируемостта е **най-ниска при $\tau = 0.9$** , оптимистичната страна. Ред 7 в Алгоритъм 1 го обяснява: абстрактният дървовиден модел на решенията преозначава с $\tilde{R}_t = \tilde{Q}_v(s_t, a_t)$, стойност състояние-действие от две свързани мрежи (Уравнения 8–11), докато тази реализация преозначава със само по състояние $V(s)$. Цел само по състояние не може да различи „това състояние е лошо“ от „това действие е лошо“ -



Фигура 3: ARDT exploitability against the expectile tau, with the mean relabel target on the right axis. The relabel target moves monotonically as theory requires, but exploitability is lowest on the optimistic side.

точно дискриминацията, на която разчита абстрактният дървовиден модел на решенията - така че преместването на $\tau \rightarrow 0$ подава на ДТ еднородно отрицателна стойност, което води до избор на *пас* линията вместо *устойчивата*. EXPECTILE_TAU умишлено е оставено на 0.1, теоретично правилната страна; промяната му на 0.9 за получаване на по-добър резултат би представлявала манипулация на изследването.

1.5 Последващи експерименти: какво крие скаларната оценка


Петте цели класират методите, но не дават обяснение за тях. Проведени бяха още шест допълнителни експеримента.

1.5.1 Извличане на точна стратегия, 24 пъти по-евтино

Четенето на разпределението на действията от **token logprobs** (предварително попълване с "Action:", сумиране на вероятностната маса върху повърхностните форми) замества 288 извадкови извиквания с **12**, като дисперсията на извадката е нула. Валидирано чрез извадка при идентични подкани: средната стойност на разликата $|P(\text{bet})|$ е **0.027** спрямо стандартна грешка на биномно разпределение от 0.102 (резултатът е съгласуван). Не е валидно при използване на подкана тип „верига от мисли“ - предварителното попълване противоречи на

принципа „разсъждавай първо“, което води до извънразпределителна стратегия - граница, документирана в кода.

1.5.2 Къде всъщност се проявява загубата




Фигура 4: Each information set's share of total exploitability, beside how far it deviates from Nash. The two orderings barely correspond.

Информационно множество	P(залог)	наш равновесие	отклонение	дъл от изтичането
2p (Дама, опонентът е пасувал)	1.000	0.000	1.000	41.4%
2b (Дама, при залог от опонента)	0.253	0.347	0.094	13.1%
3 (Поп, начална позиция)	1.000	0.561	0.439	0.1%

Това **коригира заглавие, заявено по-рано в тази стъпка**. „Всеки голям езиков модел залага с пълна стойност на Попа при 1.00, където наш равновесие смесва при 0.68“ беше съобщено като характерен провал - струва **0.1%** от изтичането. Прекомерното залагане на ръка, която никога не е по-слаба, е почти безплатно. Щетата идва от един възел Дама: винаги залагане на Дамата след като опонентът пасува е **41.4%** от общата експлоатируемост, а поправянето само на това едно решение премества модела от 0.357 на 0.209 жетона. **Величината**

на отклонението и цената са почти некорелирани, което е точно това, което се скрива зад едно число.

1.5.3 Моделите играят по-добре, отколкото могат да обяснят



Фигура 5: Stated versus executed betting frequency at each information set for both models, with Nash for reference, and the exploitability of each model's played strategy against a strategy built from its own stated frequencies.

Попитани, на същите информационни множества и с идентичен описателен текст за ситуацията, какъв процент от времето трябва да направят **залог**:

	MAE спрямо наш равновесие (декларирано)	MAE спрямо наш равновесие (изпълнено)	експлоатируемост, ако играе това, което заявява	експлоатируемост, при изиграната стратегия
Qwen2.5-7B	0.353	0.246	0.921 жетона	0.357
gpt-oss-20b	0.434	0.328	1.576 жетона	0.392

И двете модели имат **деклариращи** стратегии, които са значително по-слаби от техните **изпълнени** - съответно 2.6× и 4.0× по-експлоатируеми. Начините на провал се различават (Qwen отговаря „50%“ в 11 от 12 информационни множества; gpt-oss отговаря ~0% в 8 от 12, включително всичките три възела с Поп, където **наш равновесие** залага 100%), което подсилва общото заключение: **извличането на стратегия от голям езиков модел чрез задаване на въпроси води до резултат, по-лош от проучването на неговото поведение.**


1.5.4 Експлоатативен по подразбиране, а не адаптивен

Сесии от 120 **раздавания** срещу фиксиран архетип, с наблюдаемата история на предишни **раздавания** в контекста. Базовите линии се изчисляват **точно** върху реализираните **раздавания** на самия **агент**, така че нито късметът при раздаването, нито случайността на опонента участват в сравнението.

Опонент	наш равновесие	таван на най-добрия отговор	агент $\pm$ SE	разликата е намалена	обучение (2-ра - 1-ва половина)
alwaysPass	+0.229	+0.981	+0.850 $\pm$ 0.056	+0.83 $\pm$ 0.07	+0.00
AlwaysBet	+0.319	+0.530	+0.383 $\pm$ 0.169	+0.31 $\pm$ 0.80	-0.52
стегнат- пасивен	+0.088	+0.316	+0.092 $\pm$ 0.122	+0.02 $\pm$ 0.53	-0.15

Средно обучение **-0.22**. При единствената добре подготвена клетка агентът усвоява 83% от наличната експлоатация още от първата половина и не показва допълнително подобрение - фиксирано предварително убеждение, благоприятстващо разпуснат-агресивни стратегии, а не моделиране на противника.

Границата експлоатация/експлоатируемост го потвърждава: големият езиков модел **експлоатира с 61% по-голяма интензивност от нашето равновесие, като същевременно е 59 пъти по-експлоатируем** (0.177 спрямо 0.110 жетона/ръка), но цялата печалба е реализирана срещу *пасивни или случайни* опоненти (alwaysPass 0.374 спрямо 0.168). Срещу двата най-компетентни архетипа той се представя **по-зле** от нашето равновесие. Това е компромисът безопасност-експлоатация на Принос №2, измерен.



Фигура 6: Exploitation against exploitability, and the per-opponent breakdown showing the gain is confined to passive and random opponents.

1.5.5 Директен сблъсък

20,000 раздавания на двойка, с места, разположени шахматно. Наш равновесие срещу наш равновесие е точно 0.0000 и наш равновесие не губи от никого, което валидира турнира.

Играч на ред	срещу наш					експлоатируемост
	равнове-сие	срещу gpt-oss	срещу openThinker3	срещу Qwen	средна стойност	
nash-CFR	0.0000	+0.1061	+0.1245	+0.0806	+0.104	0.0061
Qwen2.5-7B	-0.0806	+0.1618	+0.1817	0.0000	+0.088	0.3571
gpt-oss-20b	-0.1061	0.0000	+0.1535	-0.1618	-0.038	0.3917
OpenThinker3-7B	-0.1245	-0.1535	0.0000	-0.1817	-0.153	0.8940

7B надминава 20B, а подреждането е строго транзитивно и напълно съответства на подреждането по експлоатируемост - в тази популация експлоатируемостта предсказва резултатите от директен сблъсък.

1.6 Ледюк Холдем - проверка на сложността

Тесен порт (кодировчик, набор от данни, обучение на DT и обхождане с кондициониране по печалба, оценявано в жетони/ръка срещу почти равновесен противник) плюс преглед чрез

голям езиков модел. Ледюк разполага с **936** информационни множества спрямо 12 при Кун, **15** различни стойности на печалба спрямо 4, два кръга на залагане и една обща карта.




Фигура 7: DT performance against the conditioned target return on Ледюк, with standard errors. There is no collapse at the modal return and no monotone trend.

Kuhn Poker не се възпроизвежда - при модалната възвръщаемост DT е на 0.2 SE от средната стойност на останалите цели. **Кондиционирането обаче все още не насочва**: Pearson $r = +0.062$, Spearman $\rho = -0.054$. То не е инертно (разпределението между целите е 0.60 жетони/ръка, многократно по-голямо от стандартната грешка на точка), а просто не е подредено според целевото качество. Невъзможната цел се насища - единственото предсказание на Kuhn Poker, което се възпроизвежда чисто.

Компетентността на големия езиков модел рязко намалява. В Ледюк големият езиков модел постига резултат от -0.463 ± 0.132 **жетони/ръка** срещу почти равновесие на Наш, който е статистически неразличим от -0.454 на DT; срещу експлоатируемия зоопарк той постига -0.071 , докато Наш прави $+0.582$, губейки дори от **Случаен**. Само **31–54%** от 936-те информационни множества някога са били достигнати, поради което вероятността за достигане прави пълното изброяване ненужно.

Неговият 23.4% незаконен интензитет на действие представлява **едно систематично погрешно схващане**, а не дифузна обърканост: FOLD_WHEN_FREE формира **100%** от незаконната маса, докато RAISE_AT_CAP е 0.0000, а недействие (неуспех на формата) - 0.0001. То се проявява концентрирано в кръг 2 без дължимо (0.5138, до 0.99), при слаби несдвоени



Фигура 8: Illegal-action intent by category and by situation. A single category accounts for all of it, concentrated in one situation.

раздавания срещу висока маса - моделът смесва „моето раздаване е слабо“ с „трябва да пасна“, забравяйки, че проверката е безплатна. Почти нулевият процент в кръг 1 показва, че това е **задействано от текстурата на масата, а не от пропуск в правилата**, което го превръща в откритие от подсказването, а не в таван на възможностите.

1.7 Съгласуване между прогноза и реалност

Предварителните прогнози се съхраняват; към тях се добавя и това, което действително е настъпило (работен процес §0.1).

R1 - Условното връщане никога не насочва и предложеното обяснение беше наполовина вярно. Обяснението за Кун (големината кодира залога, знакът е **късмет с картите**, така че модалната **печалба** при **пас** избира „**линията на пас**“) предсказва, че ефектът трябва да отслабне при по-богат **набор печалби**. **Ледюк** премахна вдлъбнатината точно както беше предсказано, **но насочването не се появи вместо това**. Механизмът обяснява *вдлъбнатината*, а не *провала*, който оцелява при 15 стойности на печалбата, два рунда и **обща карта**.

R2 - Математическият флаг В беше правилен относно τ и подцени структурната разлика. Потвърдено е спрямо Ур. 6–7; реалната разлика е между $V(s)$ и $Q(s, a)$, посочено в статията (Алгоритъм 1, ред 7). Цел №4 остава червена.

R3 - Поведенческото клониране печели, а „провалът“ с поп беше почти безплатен. Вижте *Сравнението в заглавието* и *Къде всъщност е загубата*.

R4 - Първоначалната хипотеза беше опровергана. „Знае честотата, но не може да я извади“ предсказва заявено $\approx$ **наш равновесие** и изпълнено $\neq$ **наш равновесие**. Измерено:

заявеното е *по-лошо* от изпълненото при двата модела.

R5 - Резултатът от обучение в контекста +1.59 беше оттеглен. Разликата е намалена над 1.0 означава побеждаване на точен най-добър отговор, което е невъзможно; таванът беше проверен ръчно ($K \rightarrow +2$, $Q \rightarrow 0$, $J \rightarrow -1 \Rightarrow +0.333$, съответстващо на изчисленото $+0.3387$), като така се установи, че стойността на агента е артефакт. Причина: 60-ръчна сесия беше сравнена с базови линии, взети от *различни* раздавания, при което стандартното отклонение на Кун за ръка от ~ 1.2 дава стандартна грешка, съпоставима с целия диапазон наш равновесие $\rightarrow$ най-добър отговор. При използване на точни двойки базови линии заключението **се обръща** към липса на обучение.

R6 - Резултатът от голям езиков модел за Ледюк от -0.83 беше оттеглен. Токенизаторът разделя RAISE на " RA" и FOLD на " F", докато CALL/CHECK остават цели, поради което съвпадението по цяла дума елиминира 70% от вероятностната маса и *обърна* стратегията - модел, който повишава с $p=0.953$, беше оценен като залагащ $\sim 97\%$ от времето. Коригирано със съвпадение, чувствително към представката, до -0.463 ± 0.132 .

R7 - Смесването на голям езиков модел не може да бъде измерено при температура 0. При тази стойност реалният модел играе *чиста* стратегия, така че всяка измерена честота дегенерира до 0 или 1: блъф(J) отчете 0.75, 0.25 и 1.00 в три изпълнения на една и съща конфигурация, а увеличаването на броя проби от 4 на 24 не помогна. При температура 0.7 честотите стават междинни, а процентът на незаконните ходове придобива ненулева стойност.

1.8 Достоверност и достатъчност на извадката

Четири резултата в тази стъпка изглеждаха като открития и се оказаха измервателни артефакти (R5, R6, възвръщаемост от позиция 0, която беше на 1.7 стандартни грешки от шума от извадката, както и тенденция в Ледюк, която изчезна при 20 пъти повече раздавания). Всеки от тях беше засечен чрез евтина проверка за съгласуваност спрямо нещо, което може да се изчисли точно - точна стойност на играта, точен таван на най-добрия отговор, стандартна грешка или диагностика за запазване на вероятностната маса.

Поотделно, `plotting.py` първоначално съдържаше **само** самопроверка, която изчертаваше твърдо кодирани числа в директорията с резултати и представляваше единствения път за създаване на фигури в тази стъпка; буквалното следване на наръчника за изпълнение би довело до записване на фалшифицирана фигура. Той беше заменен с рендър, който чете **изключително** от записан JSON, което е начинът, по който всяка фигура в този доклад беше създадена.

Достатъчност на извадката: клетките за директен сблъсък използват 20,000 раздавания; съответствията в зоопарка - 4,000; обхождането на Ледюк - 4,000 на цел. Клетките за модели-

ране на противник за AlwaysBet и стегнат-пасивен са **слабо представителни** ($SE \pm 0.80$ и ± 0.53 , тъй като техните обхвати от наш равновесие към най-добър отговор са тесни), а само клетката за alwaysPass е окончателна.

Вариация на обучението при невронните модели. Наборът от данни, CFR и извънлинейният заглушен блок са инициализирани и се възпроизвеждат точно, но всяко извикване на сравнителната таблица **преобучава** невронните модели, поради което DT/BC/абстрактен дървовиден модел на решенията показват дисперсия от изпълнение до изпълнение. Измерено при две изпълнения на една и съща конфигурация, експлоатируемостта на DT се измести от **0.671 $\rightarrow$ 0.799** (колебание от $\sim 19\%$), докато двата детерминистични реда (nash-CFR 0.0162, LLM-заглушка 0.8333) се възпроизведоха с точност до четири знака след десетичната запетая. Числата, цитирани тук, са тези от записания артефакт results/comparison_SMOKE_stub.json; качествената подредба остава непроменена, но **тези редове не бива да се сравняват с точност до три знака след десетичната запетая между различни изпълнения.**

1.9 Ограничения (подредени според значимостта им за заключенията)

1. **Всички заключения за голям езиков модел в Ледюк се основават на един модел, един стил на подкана и 600 раздавания** ($SE \pm 0.13$). Достатъчно е да се каже, че предимството на Кун не се пренася; недостатъчно е за класиране на модели в Ледюк.
2. **Абстрактният дървовиден модел на решенията е документирано опростяване на публикувания метод** - едностранен, само със състояние $V(s)$ вместо свързаното състояние-действие $\tilde{Q}(s,a)$. Целите #3–4 тестват заместителя, а не абстрактния дървовиден модел на решенията.
3. **Няма точна експлоатируемост за Ледюк.** Метриката за Ледюк е в Стъпка 03, чийто пакет също се нарича cfr и влиза в конфликт със Стъпка 02; вместо това беше използвана експлоатируемост спрямо почти равновесие на Наш.
4. **Резултатите на Кун са SMOKE-профил** (5,000 траектории, 5,000 итерации на CFR, малки мрежи). Качествената подредба е стабилна, но абсолютните стойности биха се изместили при по-голям мащаб.
5. **Извличането на логаритмична вероятност е валидирано само за обикновени подкани**; цифрите за coT са получени чрез извадка.
6. **openThinker3 беше измерен само в реда на coT** ($n=12$); пълното изпълнение е ~ 9

часа при ~38 s на решение.

7. **Двете недостатъчно мощни клетки на B5** (по-горе) - затягането им изисква приблизително 30 пъти повече раздавания.

1.10 Заключение и насоки за бъдещи изследвания

Заключения. Условното връщане не насочва трансформър за вземане на решения в покер, нито в една от двете игри, и причината не е размерът на набора печалби: в игра с нулева сума с непълна информация реализираната възвръщаемост се доминира от фактори, които агентът не контролира. Обикновеното поведенческо клониране превъзхожда и двата метода, на които тази стъпка е кръстена. Езиковите модели определят правилно класирането на ръка, но грешно честотите на смесване; не могат да вербализират стратегията, която всъщност прилагат, не научават опоненти от наблюдавана игра и губят привидната си компетентност при добавяне на една улица към играта.

Насоки за бъдещи изследвания (всяка от тях е свързана с измерен ефект):

- *Заменете преетикетирането само на състояние в ARDT с оценителите на състояние-действие, предложени в статията* (уравнения 8–11 плюс загревката в Алгоритъм 1). Това е посочената и подкрепена с доказателства причина за слабото представяне на заместителя и промяната, която трябва да се направи преди фиксираните логове в Стъпка 13.
- *Разглеждайте Return-Conditioned DT като неподходящ инструмент за офлайн покер* - стойността на преетикетирането в ARDT е именно в това, че заменя неконтролируема цел на обуславяне с контролируема такава.
- *Представяйте разложения по решения, вместо скаларна величина* в рамката за оценяване от Стъпка 14; величината на отклонението не е заместител на цената.
- *Проучвайте поведението, вместо да задавате въпроси* във всеки компонент за моделиране на противник чрез езиков модел.
- *Тествайте едноредовото поправяне на подканата в Ледюк* („може да пасувате безплатно“), преди да правите каквито и да било заключения относно възможностите на големите езикови модели при покер с няколко кръга на залагане.

1.11 Възпроизвеждане

```
# from the repository root, with the venv active
cd implementation/step12/implementation
```

```
python validate.py
```

```
# 5 validation targets -> 3 PASS / 2 FAIL / 0 SKI
```

```
python comparison_table.py # headline table -> results/comparison_SMOKE_<back>
python tau_sweep.py --seeds 3 # MATH FLAG B, empirical half
python exploitability_decomposition.py --style plain --method logprob
python frequency_elicitation.py --repeats 3 --temp 0.7 --exec-style plain
python opponent_modeling.py --hands 120 --style cot
python exploitation_vs_zoo.py --style plain --hands 4000
python llm_head_to_head.py --tournament --hands 20000
python leduc_stage0.py # Leduc DT return-conditioning sweep
python leduc_llm.py --hands 600 # Leduc LLM scouting
python leduc_illegal_taxonomy.py # illegal-action breakdown
python plotting.py # all 12 figures, from committed JSON only
```

Реалните изпълнения на модела изискват локален сървър, съвместим с OpenAI. Протоколът, който е от значение: **заредете точно един модел** (`lms unload --all`, след това `lms load <model>`), рестартирайте сървъра след всяко прекратено изпълнение (осиротелите връзки заемат всички паралелни слотове и по-късните изпълнения блокират безкрайно) и задайте `STEP12_LLM_TEMP=0.7` - при температура 0 измерените честоти са безсмислени (R7).

Детерминираност: наборите от данни, CFR и инициализацията на мрежата са **инициализирани**; извънлинейният заместител на голям езиков модел е детерминистичен, така че таблицата SMOKE и валидационната среда се възпроизвеждат точно без GPU или мрежа. Реалните резултати от модела **не** са битово възпроизводими (MoE Routing при партидно обслужване), поради което оценките на честотата използват 24 проби и защо температурният протокол е посочен изрично.