Резюме за стъпка 1 — Основи на обучението с подкрепление

Адаптивно учене на стратегии в многоагентни среди с несъвършена информация

Александър Андреев

Април 2026

Съдържание

1 Стъпка 1 — Основи на обучението с подкрепление (Reinforcement Learning) 1

1.1 1. Как обучението с подкрепление стана дисциплина 1
1.2 2. Основни принципи — Агент, Действие, Среда 3
1.3 3. Математическа формулировка (MDP) 3
1.4 4. Информационни множества — Когато не виждате всичко 3
1.5 5. Динамично програмиране и Времеви разлики 4
1.6 6. DQN — Deep Q-Networks 4
1.7 7. PPO — Proximal Policy Optimization 4
1.8 8. Практическо валидиране — Собствени имплементации срещу Stable-Baselines3 4

1 Стъпка 1 — Основи на обучението с подкрепление (Reinforcement Learning)

Това е съкратено резюме на основните материали по обучение с подкрепление, разгледани в Стъпка 1. То служи за две цели: като бърз справочник по време на преминаването към следващите стъпки и като основен източник за финалния доклад в Стъпка 15.

1.1 1. Как обучението с подкрепление стана дисциплина

Обучението с подкрепление не се появи изведнъж. Корените му се простират в няколко области, които до голяма степен не са знаели една за друга в продължение на десетилетия.

Най-ранната нишка идва от **животинската психология** в началото на 1900-те — „Законът за ефекта“ на Торндайк (1911) предполага, че действията, последвани от удовлетворяващи резултати, стават по-вероятни. Това по същество е идеята за сигнала за възнаграждение. Паралелна нишка минава през **теорията на оптималното управление** (optimal control theory) през 50-те години на миналия век, когато Белман разработва динамичното програмиране за решаване на последователни задачи за вземане на решения. Той въвежда функцията на стойността (value function) и принципа на оптималността, които стоят в основата на съвременния RL. Трета нишка идва от **ученето чрез проби и грешки** в ранните изследвания на изкуствения интелект — програмата за дама на Самюел (1959) се учи, като играе сама срещу себе си, коригирайки своята оценъчна функция въз основа на победи и загуби.

Тези клонове остават разделени до 80-те и 90-те години. Докторската работа на Сътън върху обучението по времеви разлики (temporal-difference learning, 1988) преодолява пропастта между теориите за учене при животните и динамичното програмиране на Белман. След това Уоткинс формализира Q-learning (1989), давайки на областта нейния първи изчистен алгоритъм за управление без модел с гаранции за сходимост. До момента, в който Сътън и Барто публикуват своя учебник през 1998 г. (актуализиран през 2018 г.), обучението с подкрепление (RL) се консолидира в разпознаваема дисциплина със собствена нотация, таксономия на задачите и набор от алгоритми.

Революцията в дълбокото обучение засегна RL през 2013-2015 г., когато алгоритъмът DQN на DeepMind се научи да играе игри на Atari от сурови пиксели. Тази демонстрация показа ясно, че RL алгоритмите, съчетани с невронни апроксиматори на функции, могат да се справят с многомерни реални проблеми. PPO последва през 2017 г. като практичен метод за градиент на политиката (policy gradient) и оттогава RL се разшири в роботиката, игровия ИИ, системите за препоръки и настройването на езикови модели (RLHF).

Важният извод е, че RL не е просто „машинно обучение с награди“. Това е отделна рамка за последователно вземане на решения в условия на несигурност, със собствени теоретични основи, извлечени от теорията на управлението, психологията и статистиката.

> **Прочетете повече:** Sutton, R.S. & Barto, A.G. (2018). *Reinforcement Learning: An Introduction*, 2nd edition — Chapter 1.

1.2 2. Основни принципи — Агент, Действие, Среда

Цялата рамка на RL се основава на един прост цикъл. Един **агент** наблюдава текущото състояние на дадена **среда**, избира **действие** и получава сигнал за **награда** плюс ново състояние. След това повтаря. Целта на агента е да научи **стратегия** (policy) — съпоставяне от състояния към действия — която максимизира кумулативната награда във времето.

Няколко термина, които трябва да са ясни:

- **Състояние** (s): описание на средата в даден момент. При CartPole това е позицията и скоростта на количката, и ъгълът и ъгловата скорост на стълба. В покер би включвало раздадените карти и историята на залозите.
- **Действие** (a): това, което агентът може да направи.
- **Награда** (r): скаларен сигнал за обратна връзка.
- **Стратегия (Policy)** (π): поведението на агента.
- **Функция на стойността** ($V^\pi(s)$): очакваната кумулативна награда.
- **Фактор на дисконтиране** (γ): число между 0 и 1, определящо тежестта на бъдещите награди спрямо текущите.

Изключително важно тук е **компромисът между изследване и експлоатация** (exploration-exploitation tradeoff).

Две широки семейства от алгоритми съществуват: базирани на стойността (value-based, като DQN) и базирани на политиката (policy-based, като PPO).

1.3 3. Математическа формулировка (MDP)

Марковският процес на вземане на решения (Markov Decision Process, MDP) е формалната математическа рамка, върху която са изградени повечето RL алгоритми. Състои се от: S, A, $P(s'|s,a)$, $R(s,a,s')$ и γ. Уравнението на Белман (Bellman equation) лежи в основата на намирането на $V^\pi(s)$.

1.4 4. Информационни множества — Когато не виждате всичко

Стандартните MDP предполагат напълно наблюдаемо състояние. Реалните проблеми често нарушават това (покер, стратегии в реално време) - което води до **несъвършена информация** (imperfect information). Тук използваме **информационно множество** (information set), обединяващо всички състояния на играта,

които играчът не може да различи едно от друго въз основа на това, което е наблюдавал. Например алгоритъмът за свеждане до минимум на контрафактуалното съжаление (Counterfactual Regret Minimization, CFR) оперира над информационни множества.

1.5 5. Динамично програмиране и Времеви разлики

Динамичното програмиране (DP) работи, когато познавате модела. Обучението по времеви разлики (Temporal-Difference, TD learning) обаче работи без модел и учи стъпка по стъпка, изчисляйки TD грешката между предвиждане и получена награда + бъдеща стойност чрез bootstrap. Q-learning е метод извън политиката (off-policy) за управление.

1.6 6. DQN — Deep Q-Networks

DQN замени Q-таблицата с невронна мрежа. Поддържа се от две иновации: 1. **Буфер за преиграване** (Experience replay). 2. **Целева мрежа** (Target network). DQN работи най-добре за дискретни пространства от действия.

1.7 7. PPO — Proximal Policy Optimization

PPO учи направо стратегията. PPO задържа стъпката на обновяване малка чрез съотношение на вероятностите, ограничавайки го в интервал (клипинг, clipping). PPO има естествена способност да се справя с непрекъснати и дискретни действия и е алгоритъм вътре в политиката (on-policy).

1.8 8. Практическо валидиране — Собствени имплементации срещу Stable-Baselines3

За да проверим, че имплементациите ни от нулата работят, ги сравнихме срещу Stable-Baselines3 (SB3).

1.8.1 DQN на CartPole-v1

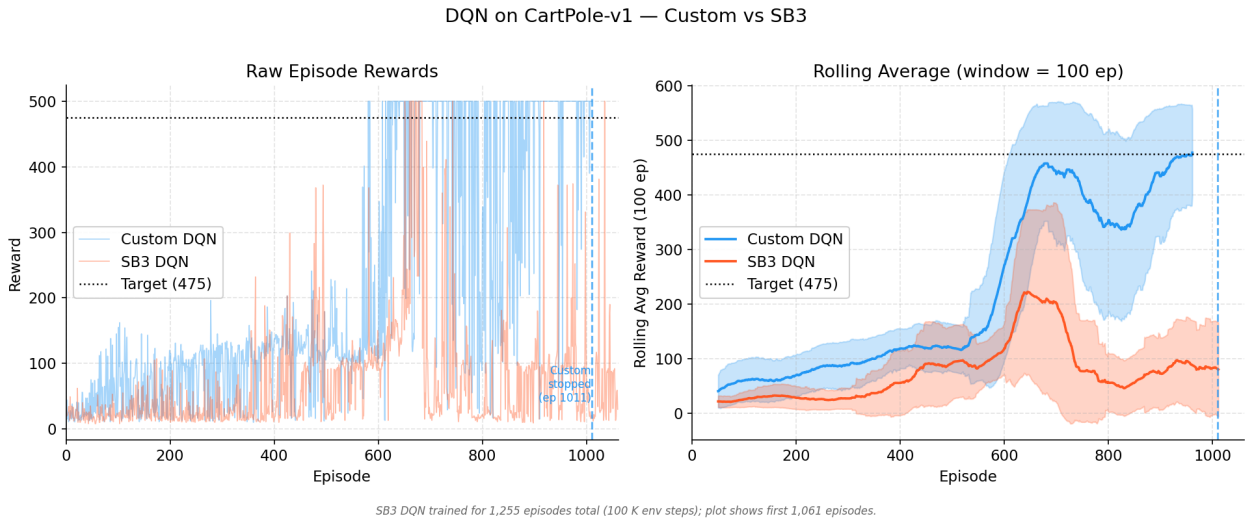

Собственият ни DQN "научи" CartPole до епизод ~1011 (достигна средно над 475). DQN от SB3 при предвидения бюджет не успя да конвергира и остана на ниво 30. По подразбиране SB3 са настроени за игри на Atari с милиони стъпки и дискретни визуални входове, а не за задачи от класическо управление (classic control) като CartPole, където са необходими бързи ранни настройки. Това е причината стандартният SB3 алгоритъм да изпитва трудности тук без значителна настройка. Нашите реализации ползват график, адаптиран спрямо специфичните дължини на епизодите и по-честа синхронизация на целевата мрежа, заедно с ранно спиране.

1.8.2 PPO на LunarLander-v3

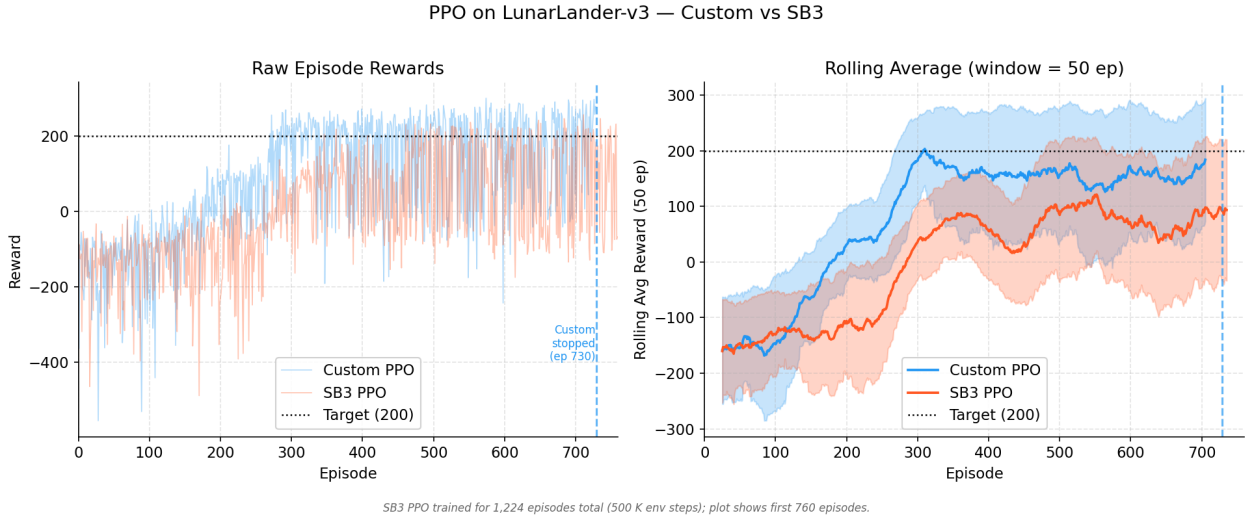

Нашето решение пресече поставената граница от 200 точки при епизод ~543 (264 хиляди стъпки). При същите стъпки SB3 PPO постигна 131.2 и все още

покачваше представянето си. За по-дълга тренировка SB3 със сигурност ще конвергира, но нашата имплементация ползва по-добра ефективност по отношение на данните за тази конкретна задача.