Резюме на Стъпка 2 — Основи на Теорията на игрите и CFR

Изследване на възможностите за приложение на изкуствения интелект в компютърни игри

Александър Андреев

Април 2026

Съдържание

1 Стъпка 2 — Основи на Теорията на игрите и CFR **1**
1.1 От едноагентно обучение с подкрепление към многоагентно стратегическо взаимодействие . . . 2
1.2 Игри в екстензивна форма и Информационни множества . . . 2
1.3 Теорема за Минимакс (Minimax Theorem) . . . 3
1.4 Равновесие на Наш (Nash Equilibrium) . . . 4
1.5 Съвпадение на съжалението (Regret Matching) — Основният градивен елемент . . . 5
1.6 Минимизация на контрафактичното съжаление (Counterfactual Regret Minimization - CFR) . . . 5
1.7 Покер на Кун (Kuhn Poker) — Най-простата тестова среда . . . 7
1.8 Експлоатируемост (Exploitability) — Измерване на разстоянието от Наш 8
1.9 Връзки към Стъпка 1 и насоки за бъдещето . . . 9
1.10 Емпирични визуализации . . . 9

1 Стъпка 2 — Основи на Теорията на игрите и CFR

Това е съкратено резюме на материала за теория на игрите и минимизация на контрафактичното съжаление (counterfactual regret minimization), разгледан в Стъпка 2. То служи за две цели: като бързо опресняване на знанията при преминаване към следващите стъпки и като основен източник за синтезиране на публичния доклад в Стъпка 15.

1.1 От едноагентно обучение с подкрепление към многоагентно стратегическо взаимодействие

Стъпка 1 разглеждаше средите като пасивни — количката с прът (cart-pole) не отвръща на удара, лунният модул (lander) не се опитва да ви разбие. Агентът оптимизираше спрямо фиксирана динамика. Стъпка 2 въвежда фундаментално различен проблем: средата включва друг *стратегически* (strategic) вземащ решения субект, чиито действия зависят от вашите.

Тази промяна нарушава рамката на Марковския процес на вземане на решения (MDP). В едноагентна среда оптималната политика е фиксирана — съществува един-единствен най-добър начин на действие, независимо от това каква стратегия сте обмисляли преди това. В многоагентна среда "най-добрата" стратегия зависи от това какво прави опонентът, а най-добрата стратегия на опонента зависи от това какво правите вие. Тази цикличност (circularity) е основното предизвикателство в теорията на игрите.

Формализацията започва с **игри в нормална форма (normal-form games)** (едновременни ходове, като Камък-Ножица-Хартия) и се разширява до **игри в екстензивна форма (extensive-form games)** (последователни ходове с дървовидна структура, като покер). И в двата случая концепцията за решение се измества от "оптимална политика" към **Равновесие на Наш (Nash equilibrium)** — стратегически профил, при който нито един играч не може да подобри резултата си чрез едностранна промяна на собствената си стратегия.

> **Прочетете повече:** Shoham, Y. & Leyton-Brown, K. (2008). *Multiagent Systems*, Глави 3–4. Безплатно: http://www.masfoundations.org/download.html

---

1.2 Игри в екстензивна форма и Информационни множества

Една **игра в екстензивна форма** представя стратегическото взаимодействие като дърво. Всеки възел е точка за вземане на решение за един от играчите (или "случайност" (chance) за случайни събития като раздаване на карти). Ребрата представляват действия, а листата носят възнаграждения (payoffs) за всеки играч.

Критичното разграничение е между **пълна (perfect)** и **непълна (imperfect)** информация:

- **Пълна информация** (шах, Го): всеки играч вижда пълното състояние на играта. Дървото на играта няма групирани възли — всеки възел е собствено информационно множество. Minimax и alpha-beta отрязването (alpha-beta pruning) решават тези игри.

- **Непълна информация** (покер, много проблеми от реалния свят): играчите не могат да наблюдават някои аспекти на състоянието. В покера виждате собствените си карти, но не и тези на опонента. Това означава, че множество игрови състояния са *неразличими (indistinguishable)* за действащия играч.

Едно **информационно множество (information set)** групира всички игрови състояния, които даден играч не може да различи. В дадено информационно множество играчът трябва да избере една и съща стратегия за всички състояния в групата (тъй като не може да ги различи). Това ограничение прави игрите с непълна информация фундаментално по-трудни от тези с пълна информация — не можете просто да изберете най-доброто действие за всяко състояние; трябва да изберете едно действие, което работи добре *средно (on average)* за всички състояния в информационното множество.

В Покера на Кун (Kuhn Poker), информационното множество `"2pb"` съдържа две игрови състояния: "Държа Дама (Queen), опонентът държи Вале (Jack), историята е пас-залог" и "Държа Дама, опонентът държи Поп (King), историята е пас-залог." Играчът, държащ Дама, не може да ги различи и трябва да използва една и съща стратегия (вероятност за плащане / call probability) и за двете.

> **Прочетете повече:** Shoham & Leyton-Brown (2008). *Multiagent Systems*, Глава 5 — Extensive-form games.

1.3 Теорема за Минимакс (Minimax Theorem)

Теоремата за минимакс, установена от Джон фон Нойман през 1928 г., предоставя основополагаща концепция за решение на игри с двама играчи с нулева сума. Тя гласи, че за всяка крайна игра с двама играчи с нулева сума съществува стратегия за двамата играчи, при която максималната очаквана загуба се свежда до минимум. С други думи, всеки играч може да си гарантира определена очаквана печалба, известна като "стойност на играта" (value of the game), независимо от стратегията на опонента. Това създава сценарий, при който оптималната стратегия на единия играч е да максимизира минималната си печалба (maximin), докато опонентът се стреми да минимизира максималната печалба на първия играч (minimax). Когато тези две стойности се изравнят, играта е в равновесие. Този алгоритъм пряко се свързва с Равновесието на Наш: в конкретния случай на игри с двама играчи с нулева сума, профил на минимакс стратегия е еквивалентен на Равновесие на Наш. Откриването на това минимакс решение гарантира безопасност срещу всяка експлоатираща стратегия, която опонентът би могъл да приложи.

1.4 Равновесие на Наш (Nash Equilibrium)

Равновесието на Наш е стратегически профил, при който стратегията на всеки играч е най-добрият отговор (best response) на стратегията на всеки друг играч. Формално, за всеки играч i:

$$u_i(\sigma_i^*, \sigma_{-i}^*) \geq u_i(\sigma_i, \sigma_{-i}^*) \quad \forall \sigma_i$$

Нито един играч не може да подобри очакваната си печалба чрез едностранно отклоняване. Това не означава, че всички са доволни от резултата (Дилемата на затворника), а само че никой не може да постигне по-добър резултат чрез промяна само на собствената си стратегия.

В игри, разширени до повече от двама играчи (N-player games) или игри с обща сума (general-sum games), свойствата на равновесието на Наш стават значително по-сложни. В тези условия намирането на точно равновесие на Наш е известно като изчислително нерешимо (computationally intractable), като често попада в класа на сложност PPAD-complete. Освен това, равновесията губят своята гаранция за безопасност: играенето на Наш стратегия в игра с 3-ма играчи не предпазва от двама опоненти, които биха могли да се отклонят от равновесието, потенциално образувайки временни коалиции, които експлоатират третия играч. Тази динамика налага напълно различни рамки за оценка и обучение (като тези, обсъдени в Стъпки 9 и 11), тъй като пряката еквивалентност между Наш и минимакс оптималността вече не е валидна.

Основни свойства: - **Съществуване (Existence):** Наш (1950) доказва, че всяка крайна игра има поне едно равновесие на Наш (евентуално в смесени стратегии). Това е основополагаща теорема, но не помага при изчисленията. - **Уникалност (Uniqueness):** Игрите могат да имат множество равновесия. Покерът на Кун има еднопараметрично *семейство* от равновесия на Наш, индексирано с $\alpha \in [0, 1/3]$. - **Смесени стратегии (Mixed strategies):** В много игри равновесието изисква рандомизация. В Покера на Кун равновесието на Наш предвижда Играч 2 да блъфира с Вале точно в 1/3 от случаите — всяка друга честота е експлоатируема.

За игри с двама играчи с нулева сума (където печалбата на единия играч е загуба за другия), равновесията на Наш имат специално свойство: те са **минимакс оптимални (minimax optimal)**. Прилагането на вашата Наш стратегия ви гарантира поне стойността на играта, независимо какво прави опонентът. Точно тази гаранция за безопасност прави равновесието на Наш основен стандарт (baseline) за AI в покера.

> **Прочетете повече:** Nash, J.F. (1950). “Equilibrium points in n-person games.” *PNAS*, 36(1), 48–49.

1.5 Съвпадение на съжалението (Regret Matching) — Основният градивен елемент

Преди CFR да може да минимизира съжалението (regret) в цялото дърво на играта, се нуждаем от механизъм за минимизиране на съжалението в единична точка за вземане на решение. **Съвпадението на съжалението (Regret matching)** е този механизъм.

Идеята: след много рундове на игра, за всяко действие a, изчислете **кумулативното съжаление (cumulative regret)** — колко по-добре бихте се справили, ако винаги бяхте играли a вместо действителната си смесена стратегия. След това задайте следващата си стратегия пропорционално на *положителните (positive)* съжаления:

$$\sigma^{T+1}(a) = \begin{cases} \frac{R^{T,+}(a)}{\sum_{a'} R^{T,+}(a')} & \text{if } \sum > 0 \\ \frac{1}{|A|} & \text{otherwise} \end{cases}$$

Гаранция за сходимост (Convergence guarantee): Blackwell (1956) и Hart & Mas-Colell (2000) доказват, че съвпадението на съжалението гарантира, че средното съжаление клони към нула със скорост $O(\sqrt{T})$. В игра с двама играчи с нулева сума, ако и двамата играчи използват съвпадение на съжалението в съответните си точки за вземане на решения, средният стратегически профил клони към Равновесие на Наш.

Прост пример е Камък-Ножица-Хартия. Ако играете чрез съвпадение на съжалението срещу фиксиран опонент, който винаги играе Камък, кумулативното ви съжаление за Хартия ще расте (Хартия бие Камък), докато съжалението за Ножица ще остане нула. Стратегията ви постепенно ще се измести към игра на Хартия с нарастваща вероятност, което е правилният най-добър отговор.

> **Прочетете повече:** Neller, T.W. & Lanctot, M. (2013). "An Introduction to Counterfactual Regret Minimization," Sections 1–2.

1.6 Минимизация на контрафактичното съжаление (Counterfactual Regret Minimization - CFR)

CFR (Zinkevich et al., 2007) разширява съвпадението на съжалението до игри в екстензивна форма. Ключовото прозрение: разделете общото съжаление на стратегията в играта на **локални съжаления (local regrets)** във всяко информационно множество, след което минимизирайте всяко локално съжаление независимо, използвайки съвпадение на съжалението. Ако съжалението на всяко информационно множество клони към нула, цялостната стратегия клони към Равновесие на Наш.

Частта "контрафактично" (counterfactual) е от решаващо значение. В дадено ин-

формационно възлово множество I, съжалението за действие a не е просто "колко по-добро би било a". То е *контрафактично* съжаление — подобрението при предположението, че играчът умишлено е играл, за да достигне I (вероятност за достигане = 1 за играча), но всичко останало (стратегията на опонента, случайни събития) е останало същото. Формално:

$$R^T(I, a) = \sum_{t=1}^{T} \pi_{-i}^t \cdot (v^t(I, a) - v^t(I))$$

където π_{-i}^t е вероятността за достигане на опонента (opponent's reach probability), а $v^t(I, a)$ е контрафактичната стойност на действието a в I при итерация t.

Защо вероятност за достигане на опонента? Съжалението в едно информационно множество има по-голямо значение, когато е вероятно опонентът да е играл така, че да достигнем това информационно множество. Претеглянето чрез π_{-i} гарантира, че съжалението е пропорционално на честотата, с която информационното множество е "релевантно" за резултата от играта.

Алгоритъм (стандартен CFR с вземане на проби при случайни събития - vanilla CFR with chance sampling): 1. Инициализиране на всички кумулативни съжаления и суми на стратегиите на нула 2. За T итерации: a. Изтегляне на случайни карти (chance sampling) b. Рекурсивно обхождане на дървото на играта от корена c. Във всяко информационно множество - изчисляване на стратегията чрез съвпадение на съжалението d. За всяко действие - рекурсивно връщане в поддървото (с отрицателна полезност за игри с нулева сума) e. Актуализиране на кумулативните съжаления, претеглени според вероятността за достигане на опонента f. Натрупване на стратегия, претеглена според вероятността за достигане на самия играч 3. Извеждане на **средната** стратегия (не стратегията от последната итерация)

Сходимост: Средният стратегически профил клони към Равновесие на Наш със скорост $O(1/\sqrt{T})$ за експлоатируемост, където T е броят на итерациите (Теорема 4, Zinkevich et al. 2007). Границата на сходимост е:

$$\text{exploit}(\bar{\sigma}^T) \leq O\left(\Delta\sqrt{|I|/T}\right)$$

където Δ е максималният диапазон на възнагражденията, а $|I|$ е броят на информационните множества.

> **Прочетете повече:** Zinkevich, M. et al. (2007). "Regret Minimization in Games with Incomplete Information." *NeurIPS*. Neller & Lanctot (2013). Глави 3–5 (пълно ръководство за Покера на Кун).

1.7 Покер на Кун (Kuhn Poker) — Най-простата тестова среда

Покерът на Кун (Kuhn, 1950) е стандартният минимален пример за алгоритми на игри с непълна информация. Със своите 3 карти, 2-ма играчи и 12 информационни множества, той е достатъчно малък, за да бъде решен аналитично, но достатъчно богат, за да демонстрира ключовите явления: блъфиране, информационна асиметрия, смесени равновесия.

Правила: 3 карти {Вале, Дама, Поп} (J, Q, K), всеки играч поставя начален залог от 1 чип, всеки получава по 1 скрита карта. Играч 0 действа първи: пас или залог (bet). Играч 1 отговаря: пас или залог. Ако Играч 0 пасува, а Играч 1 заложи, Играч 0 има право на нов отговор. Показване на картите (showdown) приключва с победа за по-високата карта.

Равновесие на Наш (Nash equilibrium), параметризирано с $\alpha \in [0, 1/3]$: - **Играч 0 с Вале:** Залага (блъфира) с вероятност α. Ако срещне залог след като е пасувал, винаги се отказва (fold). - **Играч 0 с Дама:** Винаги пасува. Ако срещне залог след като е пасувал, плаща (call) с вероятност $1/3 + \alpha$. - **Играч 0 с Поп:** Залага с вероятност 3α. Ако срещне залог след като е пасувал, винаги плаща. - **Играч 1 с Вале:** След пас, залага (блъфира) с вероятност 1/3. След залог, винаги се отказва. - **Играч 1 с Дама:** След пас, винаги пасува. След залог, плаща с вероятност $1/3 + \alpha$. - **Играч 1 с Поп:** Винаги залага, винаги плаща.

Стойност на играта: Очакваната печалба на Играч 0 при Наш е $-1/18 \approx -0.0556$. Играч 0 има структурно неблагоприятно положение от факта, че действа първи.

Защо Покерът на Кун е важен: Всяка ключова концепция при решаването на игри с непълна информация се появява тук в умален мащаб — блъфиране (Вале залага, въпреки че е най-лошата карта), информационна асиметрия (Играч 2 вижда действието на Играч 1 преди да вземе решение), смесени стратегии (точна 1/3 честота на блъфиране), безразличие (Дамата е безразлична (indifferent) между плащане и отказ в определени информационни множества). Ако алгоритъмът ви не може да реши коректно Покера на Кун, той не може да реши нищо.

> **Прочетете повече:** Kuhn, H.W. (1950). “Simplified Two-Person Poker.” *Contributions to the Theory of Games*, Vol. 1.

1.8 Експлоатируемост (Exploitability) — Измерване на разстоянието от Наш

Експлоатируемостта (Exploitability) е основната метрика за оценка на стратегии в игри с непълна информация. Тя измерва колко може да бъде експлоатирана дадена стратегия от опонент, играещ в най-лошия случай (worst-case opponent):

$$\text{exploit}(\sigma) = BR_0(\sigma_1) + BR_1(\sigma_0)$$

където $BR_i(\sigma_{-i})$ е очакваната печалба от най-добрия отговор на играч i срещу стратегията на опонента.

При Равновесие на Наш експлоатируемостта е точно нула — нито един играч не може да подобри резултата си чрез отклоняване от стратегията. За приблизителни равновесия на Наш експлоатируемостта количествено определя качеството на приближението.

Изчисляването на най-добър отговор (Best response computation) в игрите с непълна информация е деликатно. Играчът, даващ най-добър отговор, трябва да избере едно и също действие за всички състояния в дадено информационно множество (той не може да ги различи). Наивен подход, който избира най-доброто действие за всяко игрово състояние (използвайки знание за скритата карта на опонента), изчислява "оракулска" стойност, а не истински най-добър отговор. За Покера на Кун правилният подход изброява всички $2^6 = 64$ чисти стратегии и оценява всяка от тях.

Скорост на сходимост (Convergence rate): За стандартния CFR експлоатируемостта намалява с $O(1/\sqrt{T})$. На логаритмична-логаритмична графика това изглежда като права линия с наклон ≈ -0.5. Измереният от нас наклон беше -0.489, което потвърждава теоретичните прогнози.

Защо не просто стойността на играта? Една стратегия може да постигне правилната стойност на играта, докато същевременно е силно експлоатируема. Разгледайте Кун стратегия, при която Играч 1 винаги блъфира с Вале (вместо в 1/3 от случаите). Средната стойност на играта може да е близка до $-1/18$, но стратегията е силно експлоатируема — Играч 0 винаги може да плаща с Дама и да излезе на печалба. Експлоатируемостта хваща това; стойността на играта сама по себе си - не.

> **Тази метрика се повтаря през цялата дисертация.** Стъпки 7–8 (моделиране на опонента (opponent modeling), безопасна експлоатация (safe exploitation)) използват експлоатируемостта като основна мярка. Стъпка 14 изгражда обща рамка за оценка около нея.

1.9 Връзки към Стъпка 1 и насоки за бъдещето

Локална оптимизация → глобална сходимост (Local optimization → global convergence). В Стъпка 1, DQN минимизира TD грешката във всяко състояние независимо, но въпреки това цялостната Q-функция клони към оптималната. В Стъпка 2, CFR минимизира съжалението във всяко информационно множество независимо, но въпреки това цялостната стратегия клони към Наш. И двете демонстрират един и същи принцип: локалните актуализации, когато са правилно структурирани, постигат глобални цели.

Натрупване на стратегия ≈ възпроизвеждане на опита (Strategy accumulation ≈ experience replay). CFR извежда *средната* стратегия, а не стратегията от последната итерация. Това осредняване стабилизира сходимостта, също както възпроизвеждането на опита (experience replay) в DQN стабилизира обучението, предотвратявайки пренастройването (over-fitting) на агента към скорошни преходи. И двете са механизми за памет, които изглаждат шума (smooth out noise).

Напред (Forward): Стъпка 2 покрива CFR с *пълно обхождане на дървото (full tree traversal)* — всяко информационно множество се посещава при всяка итерация. За по-големи игри това е нерешимо. Стъпка 3 въвежда Монте Карло CFR (Monte Carlo CFR - MCCFR), който взема проби (samples) от части на дървото, като разменя точност за мащабируемост. Стъпка 4 добавя абстракция на играта (game abstraction), намалявайки размера ѝ. Стъпка 5 заменя табличните стратегии с невронни мрежи.

Отворени въпроси: - Защо *средната* стратегия постига сходимост, но текущата стратегия не? (Интуиция: текущата стратегия прехвърля корекциите (overshoots corrections), докато осредняването заглушава осцилациите — същата причина като осредняването на Polyak в оптимизацията.) - CFR е доказан за игри с двама играчи с нулева сума. Ами за N-играчи или игри с обща сума (general-sum)? (Стъпки 9 и 11 изследват тази граница.) - Как се справяме с игри, които са твърде големи за пълно обхождане на дървото? (Стъпка 3 — Монте Карло CFR.)

> **Прочетете повече:** Bowling, M. et al. (2015). “Heads-up limit hold’em poker is solved.” *Science*, 347(6218), 145–149. В тази статия се използва CFR+ (вариант) за решаване на Heads-up limit Texas Hold’em — първата нетривиална игра с непълна информация, която по същество е решена.

1.10 Емпирични визуализации

За потвърждаване на теоретичните гаранции на CFR и приложението му към Покера на Кун, бяха проследени няколко показателя по време на тренировъчния процес:

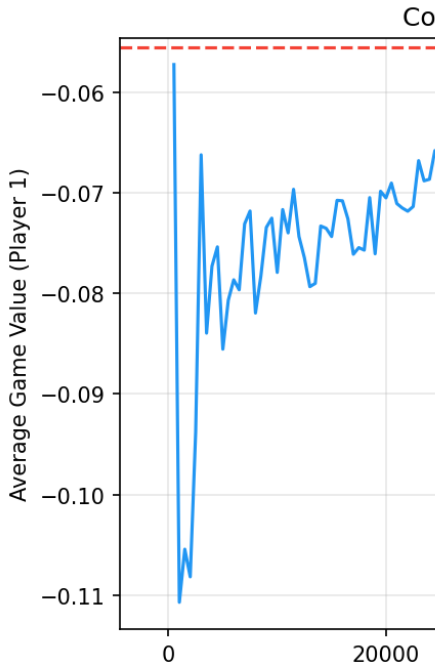

Сходимост на стойността на играта (Game Value Convergence)

Тази графика илюстрира как емпиричната средна стойност на играта се доближава до теоретично очакваната стойност от $-1/18$ с увеличаване на итерациите на CFR, потвърждавайки стабилизирането на стратегията.

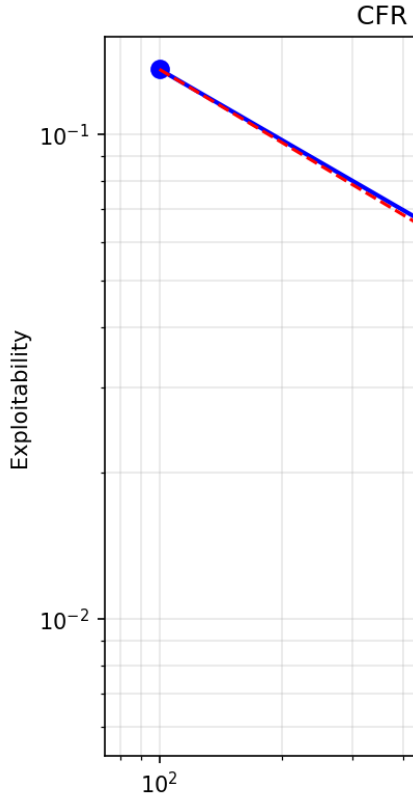

Сходимост на експлоатируемостта (Exploitability Convergence)

Проследяването на експлоатируемостта във времето показва скоростта на сходи-

мост $O(1/\sqrt{T})$. Логаритмичната-логаритмична графика (log-log plot) демонстрира линейно затихване, утвърждавайки, че средната стратегия формира приблизително Равновесие на Наш.

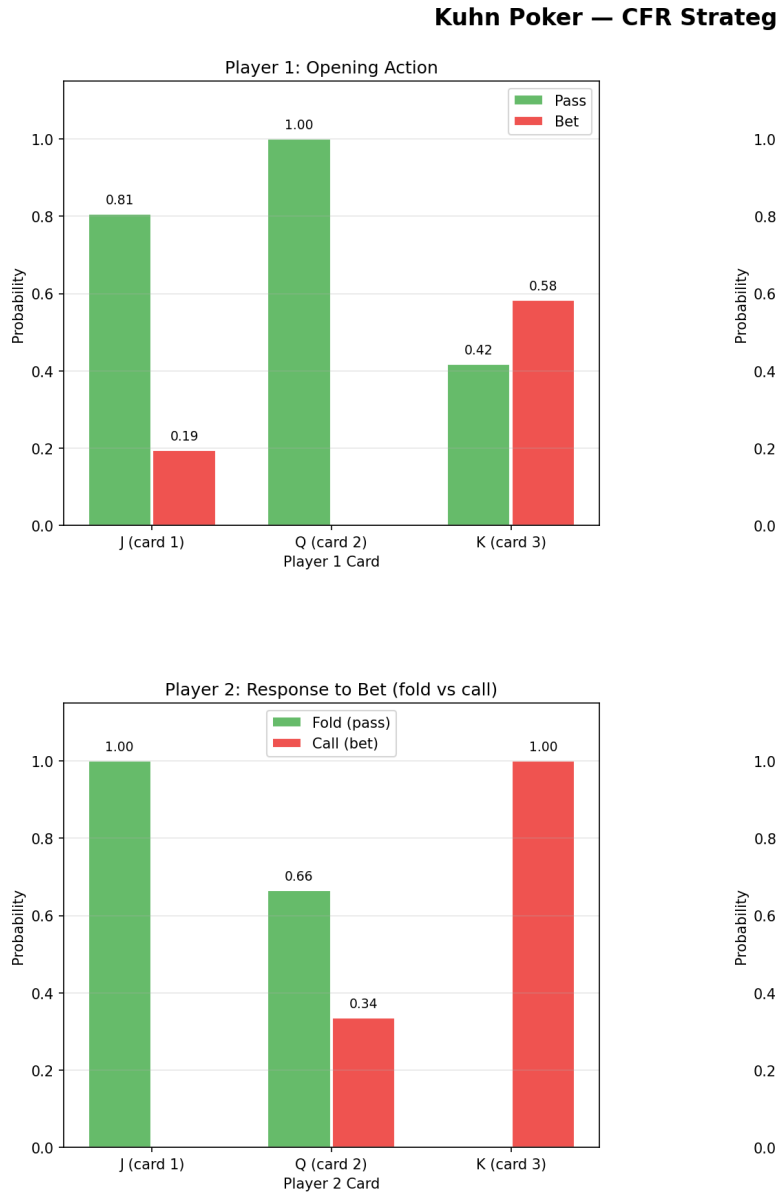

Анализ на стратегията (Strategy Analysis)

Тази визуализация разбива специфичните вероятности за действия в различни информационни множества, демонстрирайки появата на оптималните честоти за блъфиране и плащане, продиктувани от семейството равновесия на Наш за Покера на Кун.