Резюме на Стъпка 3 — Варианти на CFR и Монте Карло методи

Изследване на възможностите за приложение на изкуствения интелект в компютърни игри

Александър Андреев

Април 2026

Съдържание

3 Стъпка 3 — Варианти на CFR и Монте Карло методи **1**
3.1 Защо стандартният CFR се срива при мащаб . . . 1
3.2 Монте Карло търсене . . . 2
3.3 Марковски вериги и Законът за големите числа . . . 3
3.4 Математика на покера . . . 4
3.5 Покерът Ледюк — Увеличаване на мащаба на еталонната игра . . . 5
3.6 CFR+ — Трикът с ограничаването отдолу на съжаленията . . . 6
3.7 MCCFR — Вземане на извадки от дървото на играта . . . 8
3.8 Компромисът „дисперсия срещу скорост” . . . 10
3.9 Кога MCCFR печели — Пресечната точка . . . 12
3.10 Връзки към Стъпка 2 и насоки за следващи Стъпки . . . 13

3 Стъпка 3 — Варианти на CFR и Монте Карло методи

Това е съкратено резюме на материала относно мащабируемостта, разгледан в Стъпка 3. То служи за две цели: като бърз справочник по време на преминаването към следващите стъпки и като основен източник за създаване на финалния публичен доклад в Стъпка 15 (Глава 1 от Дисертацията).

3.1 Защо стандартният CFR се срива при мащаб

Стъпка 2 установи работеща реализация на стандартния CFR върху Покера на Кун (Kuhn Poker) — 12 информационни множества, 58 терминални възела, разрешима за милисекунди, но този опит е подвеждащ. Стандартният CFR изисква **пълно обхождане на дървото на играта при всяка итерация**, а реалните игри са значително по-големи от Кун. Покерът Ледюк (Leduc Poker) има 936 информационни множества (~78× по-голям); Texas Hold’em с лимит (Limit Texas Hold’em) има над 10^{14}. Никой компютър не може да изброи това дърво дори веднъж.

Стъпка 3 затваря пропастта в мащаба чрез два допълващи се механизма, разработени независимо в литературата по теория на игрите и по-късно комбинирани на практика:

1. **CFR+ (Tammelin, 2014)** — модификация на стандартния CFR, която постига драматично по-бърза сходимост чрез ограничаване дъното на съжаленията (regret flooring), линейно осредняване на стратегиите и редуващи се актуализации. CFR+ е алгоритъмът, чрез който се реши Heads-Up Limit Texas Hold'em през 2015 г. — първият нетривиален вариант на покер, който по същество беше решен.
2. **Монте Карло CFR (Monte Carlo CFR, MCCFR; Lanctot et al., 2009)** — вместо да обхожда цялото дърво на играта при всяка итерация, MCCFR взема извадка (samples) от малка негова част. Всяка итерация е в пъти по-евтина, за сметка на по-шумни актуализации. Това е единственият осъществим подход за игри, при които пълното обхождане е физически невъзможно.

За дисертацията MCCFR е алгоритъмът, който изчислява базовата Наш стратегия — опорната точка, от която адаптивен агент се отклонява въз основа на наблюдения на опонента (Принос №1). CFR+ прави това изчисление осъществимо върху междинните еталонни игри, използвани в Стъпки 5–8.

> **Прочетете повече:** Bowling, M., Burch, N., Johanson, M. & Tammelin, O. (2015). "Heads-up limit hold'em poker is solved." *Science*, 347(6218), 145–149.

3.2 Монте Карло търсене

Монте Карло търсене в дърво (Monte Carlo Tree Search, MCTS) е каноничното семейство алгоритми, които използват **случайно вземане на извадки** за оценка на позиции в дърво на играта без изчерпателно изброяване. Проектантската му философия — „оценявай някои клонове до пълна дълбочина, вместо всички клонове до фиксирана дълбочина" — пряко мотивира MCCFR.

MCTS изгражда асиметрично дърво за търсене чрез четири повтарящи се фази:

1. **Избор (selection)** — слизане от корена чрез дадена политика (обикновено UCB1, Upper Confidence Bound), която балансира експлоатацията на известни добри ходове с изследването на рядко посещавани.
2. **Разширение (expansion)** — от листо се добавят един или повече дъщерни възела към дървото.
3. **Симулация (разиграване, rollout)** — от новия възел се играе случайна игра до край.
4. **Обратно разпространение (backpropagation)** — финалният резултат се разпространява обратно по посетения път, като се актуализират броят посещения и събраните възнаграждения.

След много итерации, детето на корена с най-висок брой посещения се избира като най-добър ход. Случайните разигравания, агрегирани през хиляди итерации, клонят към точни оценки на стойността — дори без никакви знания за предметната област извън правилата на играта.

Класическите алтернативи като **Минимакс с alpha-beta отрязване (Minimax with alpha-beta pruning)** оценяват всеки релевантен възел до фиксирана дълбочина, след което прилагат евристика на листата. И двата подхода имат своите области на приложение:

Свойство	Минимакс + α–β	MCTS
Покритие на дървото	Всички клонове до дълбочина d	Избрани клонове до терминални възли
Оценка	Евристика при лимит на дълбочината	Точна (терминална печалба) или невронна мрежа
Чувствителност към коефициента на разклоняване	Експоненциална: $O(b^d)$	Плавна: фокусира се върху обещаващи клонове
Нужни знания за предметната област	Силна оценъчна функция	Никакви (случайно разиграване) или научени
Най-подходящо за	Умерено разклоняване, добри евристики	Високо разклоняване, слаби или липсващи евристики

За Го (коефициент на разклоняване ~250, без добра оценъчна функция преди невронните мрежи) Минимакс е непрактичен. MCTS беше пробивът, който направи Го AI конкурентен; същият принцип „вземи извадка, вместо да изброяваш” се пренася към дървета на игри с несъвършена информация чрез MCCFR.

> **Прочетете повече:** Browne, C. et al. (2012). “A Survey of Monte Carlo Tree Search Methods.” *IEEE Transactions on Computational Intelligence and AI in Games*, 4(1), 1–43.

3.3 Марковски вериги и Законът за големите числа

„Монте Карло” в MCCFR се отнася до широко семейство изчислителни методи, които използват **многократно случайно вземане на извадки** за получаване на числени резултати. Името произлиза от проекта „Манхатън”, където Станислав Улам и Джон фон Нойман използваха случайно вземане на извадки за симулация на неутронна дифузия — задача, твърде сложна за аналитично решение.

Математическата основа се базира на **Марковските вериги (Markov chains)** — стохастични процеси, при които следващото състояние зависи само от текущото състояние, а не от историята на пътя, по който е достигнато (Марковско свойство). Обхождането на дърво на играта е Марковска верига: от всяко игрово състояние преходът зависи само от текущото състояние и избраното действие.

Ключовата теоретична гаранция е **Законът за големите числа (Law of Large Numbers)**: ако вземем доста-

тъчно траектории през Марковската верига, средната стойност на взетите извадки клони към истинската очаквана стойност. За MCCFR:

$$\frac{1}{T}\sum_{t=1}^{T}\hat{v}_I^{(t)} \xrightarrow{T\to\infty} v_I$$

където $\hat{v}_I^{(t)}$ е извадковата контрафактична стойност при информационно множество I на итерация t, а v_I е истинската стойност, която стандартният CFR изчислява точно. Взетите в извадка стойности са **неизместени оценители (unbiased estimators)** — тяхната очаквана стойност е равна на истинската — което гарантира сходимост към същото Равновесие на Наш като CFR с пълно обхождане.

Цената е **дисперсията (variance)**. Отделните извадки могат да се отклоняват значително от истинската стойност, което изисква повече итерации за достигане на същата прецизност. Този компромис „дисперсия срещу скорост” е централната тема на тази стъпка.

> **Прочетете повече:** Sutton, R.S. & Barto, A.G. (2018). *Reinforcement Learning: An Introduction*, Глава 5 — Monte Carlo Methods.

3.4 Математика на покера

Покерът е каноничната тестова среда за теорията на игрите с несъвършена информация, защото съчетава три източника на сложност, които рядко се срещат заедно:

1. **Скрита информация** — всеки играч вижда само собствените си карти. Едно и също наблюдаемо игрово състояние (информационно множество) може да съответства на много различни реални игрови състояния.
2. **Стохастични елементи** — раздаването на карти въвежда възли на случайността в дървото на играта. Оптималната стратегия трябва да отчита всички възможни раздавания, а не само наблюдаваното.
3. **Стратегическа измама** — за разлика от игрите с пълна информация, покерът възнаграждава смесените стратегии. Играч, който винаги залага със силни ръце и пасува със слаби, е тривиално експлоатируем. Равновесието на Наш изисква **рандомизирано блъфиране с математически прецизни честоти**.

Рамката на игрите в разгърната форма от Стъпка 2 се пренася: дърво на играта, информационни множества, стратегии (преобразувания от информационни множества към разпределения над действията), Равновесие на Наш. Ключовите величини за оценка на стратегиите са:

- **Очаквана печалба (expected value, EV)** — средна печалба при даден стратегически профил.
- **Най-добър отговор (best response)** — оптималната контрастратегия срещу фиксирана стратегия на опонента; възможно най-силната експлоатация.
- **Експлоатируемост (exploitability)** — средната печалба, която опонент би могъл да получи, играейки идеален най-добър отговор. Равновесието на Наш има нулева експлоатируемост.

Chen & Ankenman формализират тези концепции чрез решения на опростени игри, в които Наш честотите за блъфиране могат да бъдат извлечени аналитично. Техните модели „half-street” и „full-street” изграждат интуиция защо изходните стратегии на CFR съдържат точните съотношения блъф/плащане, които съдържат — балансиран играч трябва да блъфира с честота, пропорционална на шансовете за пота (pot odds), които предлага.

> **Прочетете повече:** Chen, B. & Ankenman, J. (2006). *The Mathematics of Poker*. ConJelCo — аналитични Наш извличания за опростени покер игри.

3.5 Покерът Ледюк — Увеличаване на мащаба на еталонната игра

Покерът на Кун улавя същността на несъвършената информация в най-малкото възможно дърво на играта. Покерът Ледюк увеличава мащаба с около два порядъка — все още точно разрешим, но достатъчно голям, за да станат алгоритмичните разлики значими:

Свойство	Покер на Кун	Покер Ледюк
Карти	3 (J, Q, K)	6 ({J, Q, K} × {♠, ♥})
Рундове	1	2 (пре-флоп + обща карта)
Обща карта	Няма	1, разкрита между рундовете
Подреждане на ръце	Само висока карта	Двойка (скрита = обща) бие висока карта
Размер на залози	Фиксиран (1 чип)	Променлив (2 в рунд 1, 4 в рунд 2)
Макс. повишения/рунд	1	2
Информационни множества	12	936
Възли на дървото	58	10 200
Случайни изходи	6	120

Появяват се три качествено нови характеристики:

- **Многорундова структура** — информацията се променя между рундовете (разкриване на общата карта), което изисква стратегии, адаптиращи се към новата информация.
- **Ръце с двойка** — подреждането на ръцете сега зависи от общата карта; Вале може да стане най-добрата ръка, ако Вале се раздаде на борда.
- **По-големи залози в по-късните рундове** — повишението от 4 чипа в рунд 2 означава, че решенията в по-късните рундове имат по-голяма тежест.

Въпреки че е ~78× по-голям от Кун, Ледюк остава достатъчно малък за точно изчисление (пълно обхождане на дървото отнема ~50 мс). Това го прави идеалната еталонна игра: достатъчно голяма, за да са значими разликите в производителността, достатъчно малка, за да могат всички алгоритми да бъдат изпълнени до почти пълна сходимост в рамките на минути.

Прочетете повече: Southey, F. et al. (2005). “Bayes’ Bluff: Opponent Modelling in Poker.” *UAI*.

3.6 CFR+ — Трикът с ограничаването отдолу на съжаленията

CFR+ прави три малки промени в стандартния CFR, всяка тривиална за имплементация, но драматична по ефект.

Ограничаване отдолу на съжаленията. В стандартния CFR кумулативните съжаления могат да станат произволно отрицателни:

$$R^{T+1}(I,a) = R^T(I,a) + r^T(I,a)$$

CFR+ ограничава отдолу съжаленията до нула след всяка актуализация:

$$R^{T+1}(I,a) = \max\left(R^T(I,a) + r^T(I,a),\ 0\right)$$

Това предотвратява натрупването на голямо отрицателно съжаление от действия, което отнема много итерации, за да се „върне назад”, преди действието да бъде разгледано отново. Аналогията с ReLU активациите в невронните мрежи е пряка: и двете обрязват отрицателните стойности до нула, като предотвратяват „мъртви” единици (или мъртви действия) да изискват дълъг период на възстановяване.

Линейно осредняване на стратегиите. Стандартният CFR претегля стратегията от всяка итерация с равна тежест в текущата средна. CFR+ претегля итерация t със самото t:

$$\bar{\sigma}^T(I,a) = \frac{\sum_{t=1}^{T} t \cdot \sigma^t(I,a)}{\sum_{t=1}^{T} t}$$

По-късните итерации — които имат по-ниско съжаление и по-добри стратегии — допринасят повече за средната. Ранните, шумни итерации се претеглят с по-ниска тежест.

Редуващи се актуализации. Вместо да актуализира съжаленията на двамата играчи при всяка итерация, CFR+ актуализира играч 0 при нечетни итерации и играч 1 при четни. Това намалява работата на итерация наполовина и осигурява малка полза за сходимостта, като избягва едновременни промени в стратегиите.

Комбиниран ефект: емпиричната сходимост се подобрява от $O(1/\sqrt{T})$ до приблизително $O(1/T)$. CFR+ с 1000 итерации постига това, за което стандартният CFR се нуждае от ~1 000 000 итерации. Това направи възможно решаването на Heads-Up Limit Texas Hold’em през 2015 г. Забележка: докато скоростта $O(1/T)$ се наблюдава последователно емпирично, тя няма формално доказателство — Tammelin et al. дават алгоритъма, но не и теорема за сходимост, съответстваща на наблюдаваната скорост.

Емпирично, на Ледюк при 5000 итерации CFR+ достига експлоатируемост ≈ 5,4×10 ^{5}, докато стандартният CFR все още е на ~7,6×10 ^{3} — подобрение от ~140× от три малки модификации.

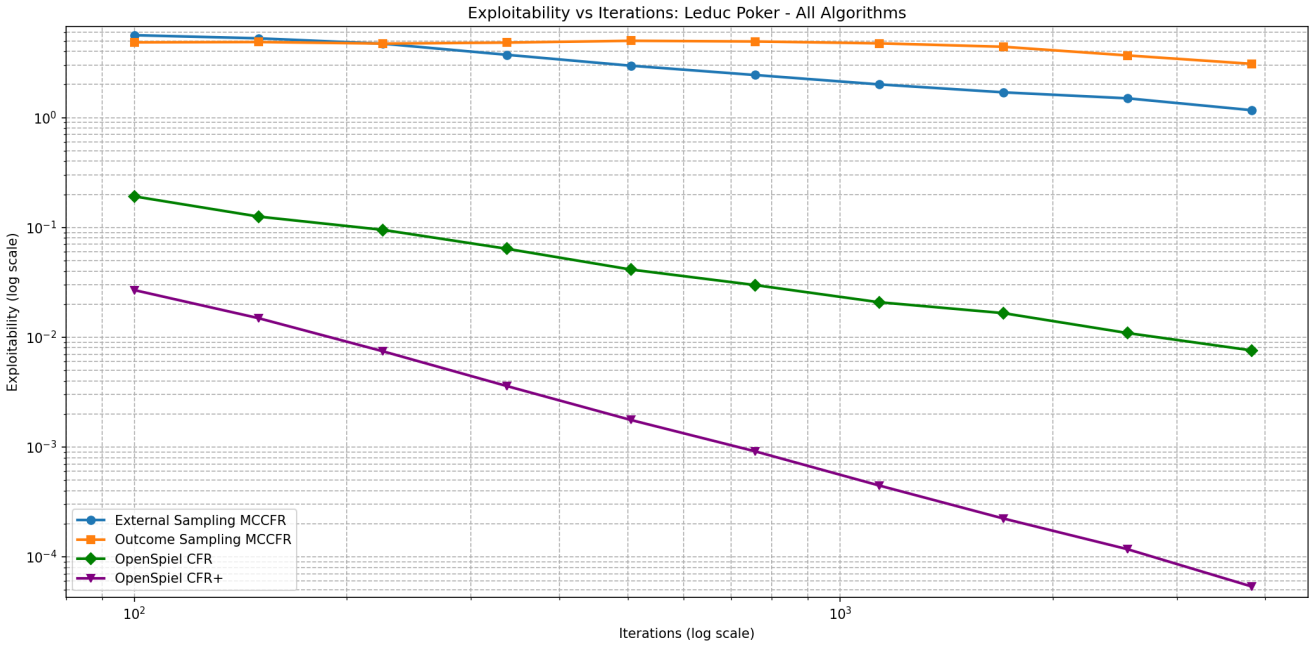

Фигура 1: Покер Ледюк — Експлоатируемост спрямо Итерации

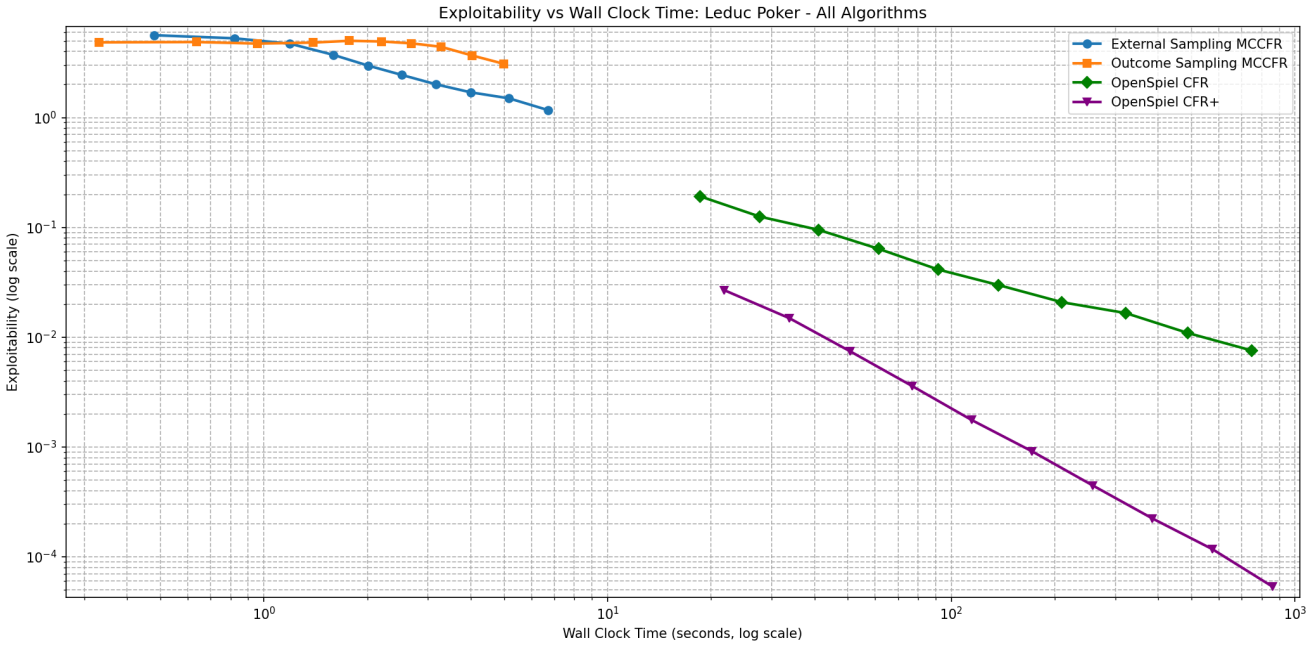

Фигура 2: Покер Ледюк — Експлоатируемост спрямо Реално време

Прочетете повече: Tammelin, O. (2014). “Solving Large Imperfect Information Games Using CFR+.” *AAAI*.

3.7 MCCFR — Вземане на извадки от дървото на играта

MCCFR замества пълното обхождане на дървото с частично вземане на извадки. Два варианта стоят на една и съща крива „дисперсия срещу скорост” в различни точки:

Вариант	Възли на случайността	Възли на обхождащия играч	Възли на опонента	Цена на итерация
External Sampling	Извадка от едно раздаване	Изследва **всички** действия	**Извадка** от едно действие	~42 възела (~945× по-бързо от пълното)
Outcome Sampling	Извадка от едно раздаване	Извадка от едно действие (ε-on-policy)	Извадка от едно действие	~5,5 възела (~2228× по-бързо)

External Sampling изследва всяко действие във възлите на актуализиращия играч, но взема извадки при възлите на случайността и на опонента. Съжаленията за обхождащия играч се актуализират въз основа на извадковото поддърво. Тъй като се посещава само едно раздаване и един път на опонента, всяка итерация докосва малка част от дървото.

Outcome Sampling тласка вземането на извадки по-нататък: извлича се една траектория от корен до терминал. Тъй като действията във възлите на актуализиращия играч също се вземат чрез извадка, актуализацията на съжалението трябва да бъде коригирана чрез **извадка по важност (importance sampling)** — съотношението между истинската вероятност за достигане и вероятността за извадка. Смес ε-on-policy (с вероятност ε избираме равномерно; иначе следваме текущата стратегия) гарантира, че всички действия са изследвани дори когато текущата стратегия им присвоява нулева вероятност.

Критичното теоретично свойство и за двата: извадковите контрафактични стойности са **неизместени оценители** на истинските стойности (Lanctot et al., Теорема 1). Това гарантира сходимост към същото Равновесие на Наш като стандартния CFR, въпреки шума от вземането на извадки. Цената, както винаги при Монте Карло, е дисперсията. Всяка извадкова актуализация се отклонява от истинската контрафактична стойност, защото отразява само едно възможно раздаване, а не очакваната стойност по всички раздавания.

Върху 12-те информационни множества на Покера на Кун, всички четири алгоритъма (стандартен CFR, CFR+, и двата варианта на MCCFR) достигат почти Наш в рамките на секунди — компромисът „дисперсия срещу скорост” е невидим в този мащаб и изборът на алгоритъм е академичен:

За да се прояви компромисът, дървото на играта трябва да е достатъчно голямо, за да има значение цената на итерация. Това е ролята на Ледюк.

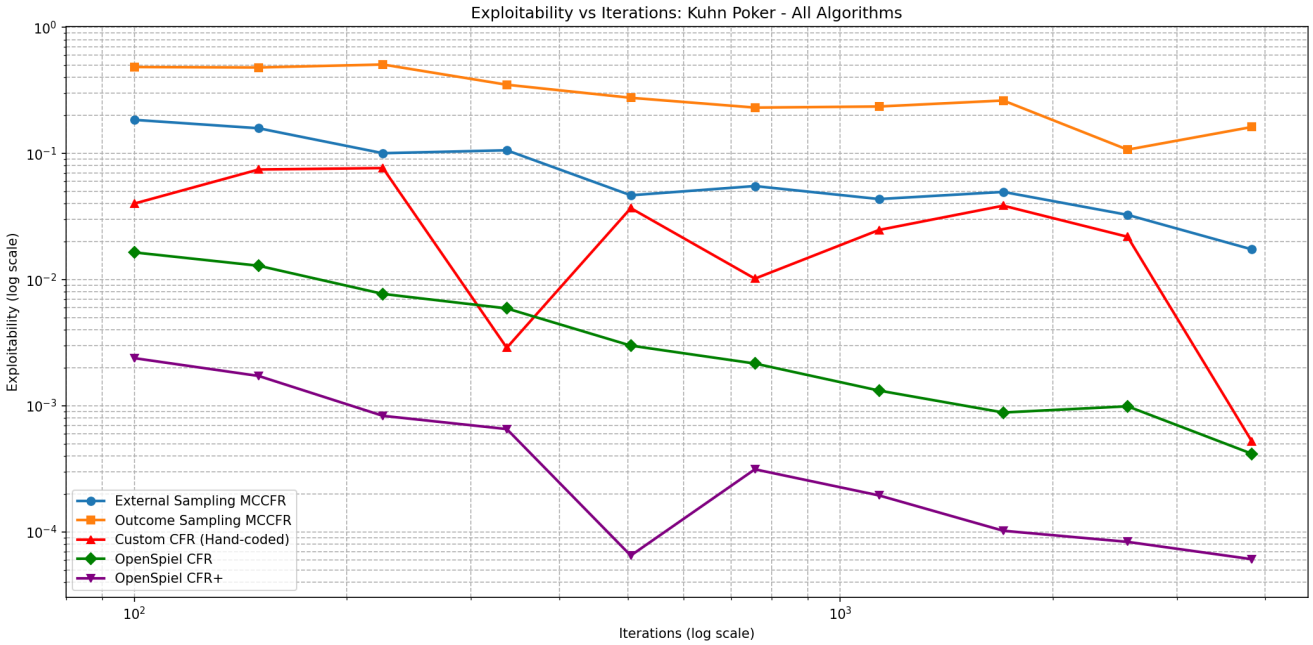

Фигура 3: Покер на Кун — Експлоатируемост спрямо Итерации

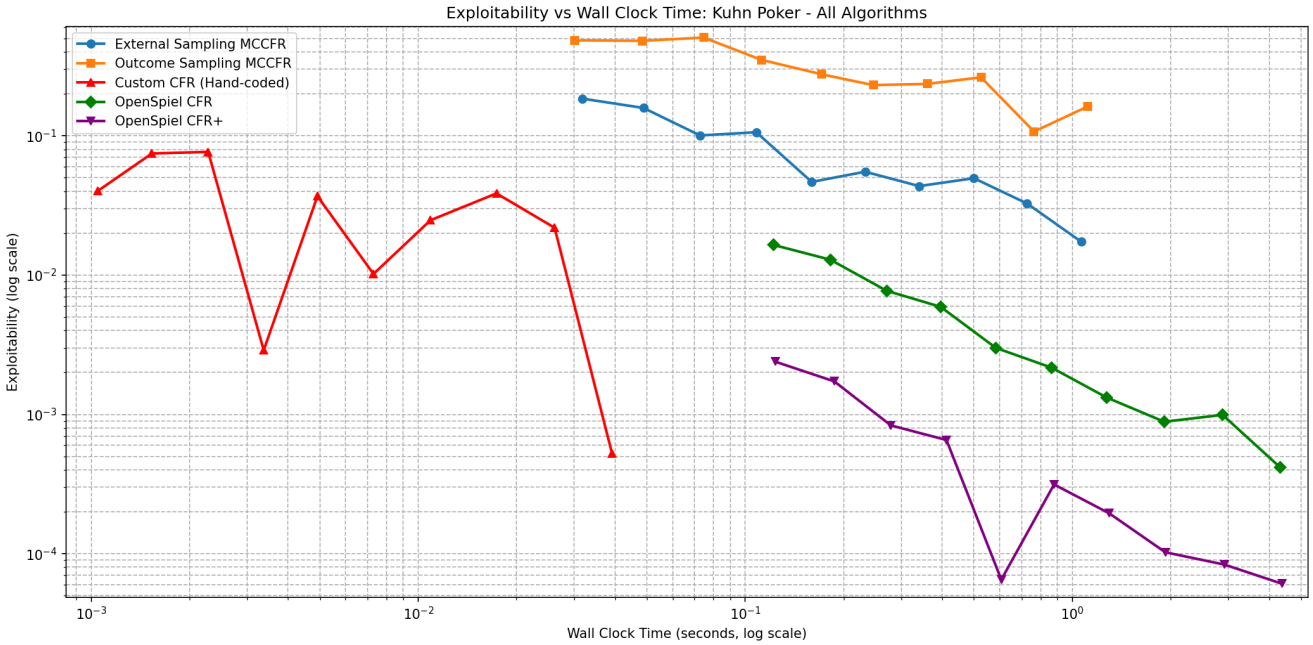

Фигура 4: Покер на Кун — Експлоатируемост спрямо Реално време

Прочетете повече: Lanctot, M., Waugh, K., Zinkevich, M. & Bowling, M. (2009). “Monte Carlo Sampling for Regret Minimization in Extensive Games.” *NeurIPS*.

3.8 Компромисът „дисперсия срещу скорост”

И четирите алгоритъма следват сходимост $O(1/\sqrt{T})$, но константите се различават огромно. Записвайки експлоатируемостта като $\epsilon(T) = C/\sqrt{T}$ и превръщайки към реално време чрез $C_w = C/\sqrt{\text{скорост}}$:

Алгоритъм	$C_{\text{итер}}$	Скорост (итер/с)	C_w (реално време)	Спрямо стандартния
Стандартен CFR	0,34	20,6	**0,075**	1,0×
CFR+	0,34	20,6	**~0,002**	~38× по-бърз
MCCFR External	107	19 470	**0,767**	10,2× по-бавен
MCCFR Outcome	245	45 901	**1,143**	15,3× по-бавен

Константата за реално време е това, което определя производителността в практически условия. Въпреки че е 945× по-бърз на итерация, константата на дисперсията на External Sampling (107 срещу 0,34) е 315× по-голяма. Предимството в скоростта **не преодолява наказанието от дисперсията**:

$$\frac{99\,000 \times \text{повече нужни итерации}}{945 \times \text{по-бърз на итерация}} \approx 105 \times \text{повече реално време}$$

Защо съществува дисперсия? Стандартният CFR изчислява **точни** контрафактични стойности чрез изброяване на всички 120 раздавания. Актуализацията му на съжалението има нулева дисперсия. MCCFR взема извадка от едно раздаване на итерация. Дори ако изследваше пълното поддърво за това раздаване, пак би имал дисперсия между раздаванията — следствие от самата скрита информация, а не недостатък на схемата за вземане на извадки:

$$\text{Var}[\hat{v}_I] = \mathbb{E}_{\text{раздаване}}\left[(\hat{v}_I - v_I)^2\right] \propto \frac{|N|}{|I|}$$

Формален еталонен тест от 180 секунди върху Ледюк за всички четири варианта прави сравнението в реално време конкретно. Изглед на итерация (вариантите с извадки изпълняват милиони актуализации, тези с пълно обхождане — няколко хиляди):

Изглед в реално време — честното сравнение (при равно изчислително време кой алгоритъм произвежда най-добрата стратегия?):

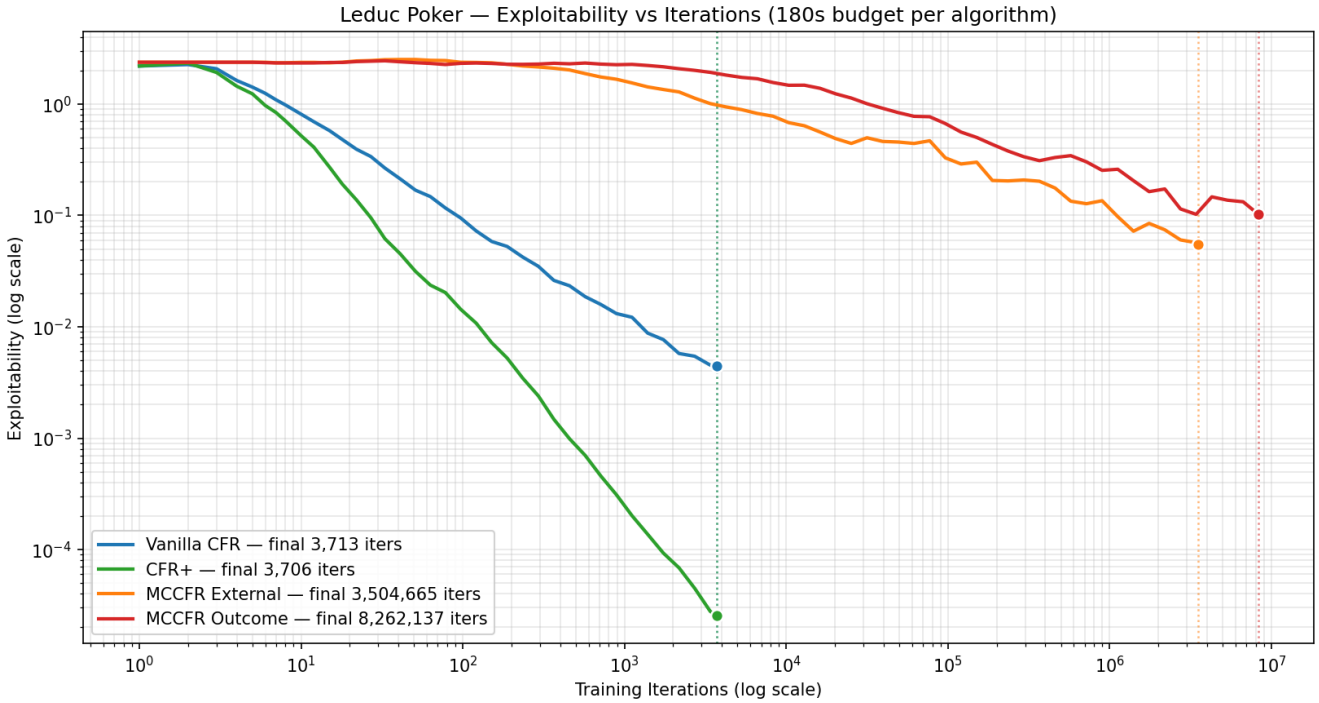

Фигура 5: Експлоатируемост спрямо Итерации

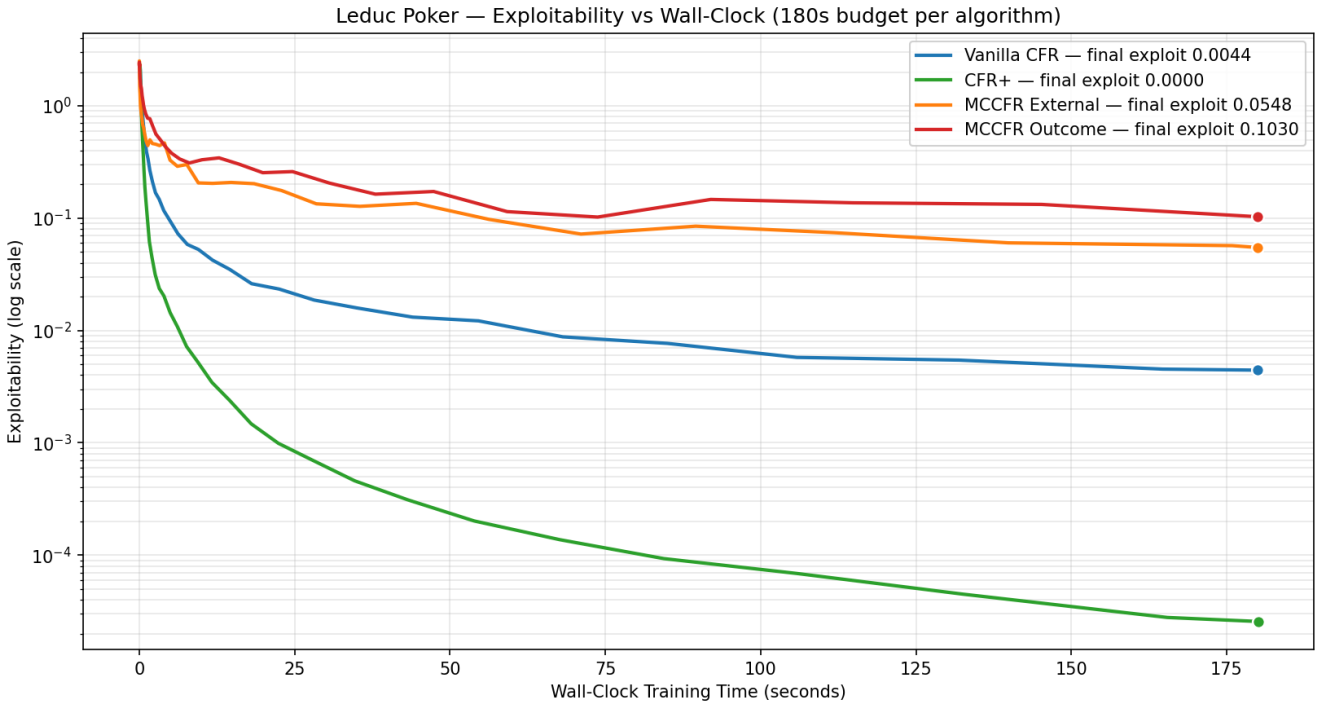

Фигура 6: Експлоатируемост спрямо Реално време

CFR+ достига експлоатируемост 2,6×10 ^{5} — почти точно Наш — за 3 минути. Стандартният CFR следва с 4,4×10 ^{3}. И двата варианта на MCCFR изостават с няколко порядъка на тази големина на играта.

3.9 Кога MCCFR печели — Пресечната точка

Моделът по-горе повдига очевиден въпрос: ако MCCFR винаги е по-лош на Ледюк, защо въобще е изобретен? Отговорът е, че цената на итерация на стандартния CFR расте линейно с размера на дървото $|N|$, докато тази на MCCFR е приблизително постоянна. При достатъчен мащаб линейната цена побеждава. Критичният размер на дървото е:

$$|N|_{\text{пресечна}} = |N|_{\text{Ледюк}} \cdot \left(\frac{C_{mc}}{C_v}\right)^2 \cdot \frac{\text{скорост}_v}{\text{скорост}_{mc}}$$

С измерените стойности:

Вариант	$\lvert N\rvert_{\text{пресечна}}$
External Sampling	~2,1 милиона възела
Outcome Sampling	~4,8 милиона възела

Сравнени с реални игри:

Игра	$\lvert N\rvert$	External печели?	Outcome печели?
Покер Ледюк	10 200	Не (210× твърде малка)	Не (466× твърде малка)
Limit Texas Hold'em	~10^{14}	Да (10^{7}× над прага)	Да
No-Limit Texas Hold'em	~10^{17}	Да (10^{10}× над прага)	Да

Ледюк стои 210× под пресечната точка за External Sampling и 466× под тази за Outcome Sampling. Пълното обхождане доминира, защото цялото дърво на играта се събира в паметта и може да бъде изброено за милисекунди. При мащаба на реалния покер заключението се обръща изцяло — дори една итерация с пълно обхождане на Hold'em би отнела повече време от възрастта на Вселената. В този мащаб MCCFR (с разширения за намаляване на дисперсията) става **единственият** осъществим подход.

3.10 Връзки към Стъпка 2 и насоки за следващи Стъпки

Същият принцип, различен режим. Стъпка 2 установи CFR с пълно обхождане върху Кун и доказа, че локалното минимизиране на съжалението във всяко информационно множество води глобалната стратегия към Равновесие на Наш. Стъпка 3 запазва този принцип, но въвежда две независими подобрения: CFR+ модифицира как се натрупват съжаленията (ограничаване отдолу + линейно претегляне), а MCCFR модифицира как се измерват съжаленията (извадков оценител вместо точна очаквана стойност). И двете все още извеждат **средната** стратегия, а не тази от последната итерация — същият механизъм на осредняване, който стабилизира стандартния CFR, стабилизира всеки вариант.

Скорости на сходимост. Стъпка 2 измери log-log наклон близо до $-0,5$ за експлоатируемостта на Кун, потвърждавайки $O(1/\sqrt{T})$. Стъпка 3 показва, че тази скорост е свойство на алгоритмичното семейство, а не на конкретна имплементация — само емпиричният $O(1/T)$ на CFR+ е по-бърз и му липсва формално доказателство. MCCFR остава при $O(1/\sqrt{T})$ с драматично по-голяма константа.

Напред:

- **Стъпка 4 (Абстракция на играта и Мащабиране)** — атакува мащабируемостта от противоположната посока: вместо да взема извадки от дървото, намалява самото дърво чрез абстракция на състоянието и абстракция на действията. Комбинира се с MCCFR, за да направи реалния покер осъществим.
- **Стъпка 5 (Невронно равновесие / Deep CFR)** — замества табличното съхранение на стратегията с невронна апроксимация на функции, използвайки рамката за вземане на извадки на MCCFR като двигател за генериране на данни. Свойствата на дисперсията, установени тук, обясняват защо Deep CFR изисква специфични техники за намаляване на дисперсията (мрежи за предимство, таргети с претегляне по важност).
- **Стъпка 6 (Цялостен AI за игри)** — надгражда върху CFR+ и MCCFR за пълни агенти. Двигателят за Ледюк, изграден за тази стъпка, става еталонна среда до Стъпка 8 включително.

Отворени въпроси:

- Защо CFR+ емпирично постига $O(1/T)$, когато нито едно доказателство не съответства на тази скорост? Най-добрата текуща хипотеза е, че ограничаването отдолу на съжаленията преформатира траекторията на динамиката по минимизация на съжалението по начин, който класическите граници на сходимост не улавят.
- При какъв размер на дървото намаляването на дисперсията (weighted average sampling, variance-reduced MCCFR) става съществено, а не опционално? Формулата за пресечната точка ни казва къде печели простият MCCFR — но не къде спира да печели без допълнителни трикове.

Прочетете повече: Brown, N. & Sandholm, T. (2017). “Safe and Nested Subgame Solving for Imperfect-Information Games.” *NeurIPS* — свързва табличния CFR с декомпозицията на подигри за реалния покер.