

Стъпка 3 Обобщение - Варианти на CFR и методи на Монте Карло

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

April 2026

Съдържание

3 Стъпка 3 - Варианти на CFR и методи на Монте Карло	1
3.1 Защо обикновеният вариант на CFR се проваля при голям мащаб	1
3.2 Търсене с метод Монте Карло в дърво като вдъхновение	2
3.3 Маркови вериги и законът за големите числа	3
3.4 Математиката на покера	4
3.5 Ледюк покер - Разширяване на еталонния тест	5
3.6 CFR+ - Трикът с подовото ограничаване на съжалението	6
3.7 MCCFR - Извадка от дървото на играта	9
3.8 Компромисът скорост-вариация	11
3.9 Кога MCCFR надделява - точката на пресичане	13
3.10 Връзки със стъпка 2 и бъдещи насоки	14

3 Стъпка 3 - Варианти на CFR и методи на Монте Карло

Това е сбит преглед на разгледания в Стъпка 3 материал, свързан с мащабируемостта. Той има две предназначения: да служи като бързо опресняване при преминаването към следващите стъпки и като основен източник за синтеза на публичния доклад от Стъпка 15.

3.1 Защо обикновеният вариант на CFR се проваля при голям мащаб

Стъпка 2 установи работещ обикновен вариант на CFR решаващ за Кун покер - 12 информационни множества, 58 крайни възли, решим за милисекунди. Този опит е подвеждащ. Обикновеният вариант на CFR изисква **пълно обхождане на дървото на играта при всяка итерация**, а истинските игри не са като Кун покер. Ледюк покер има 936 информационни множества (~78 пъти повече), а тексас холдем с лимит - над 10^{14} . Нито един компютър не може да изброи това дърво дори веднъж.

Стъпка 3 преодолява проблема с мащаба чрез два взаимнодопълващи се механизма, разработени независимо в литературата по теория на игрите и по-късно комбинирани на практика:

1. **CFR+ (Tammelin, 2014)** - модификация на обикновения вариант на CFR, която постига значително по-бърза сходимост чрез подово ограничаване на съжалението, усредняване на линейни стратегии и редуващи се актуализации. CFR+ е алгоритъмът, който „реши“ хедс-ъп лимит тексаски холдем през 2015 г. - първият нетривиален вариант на покер, който по същество беше решен.
2. **Монте Карло CFR (Lanctot и др., 2009)** - вместо да извършва пълно обхождане на дървото на играта при всяка итерация, MCCFR взема проба от малка част от него. Всяка итерация е с порядъци по-евтина, за сметка на по-шумни актуализации. Това е единственият осъществим подход за игри, при които пълното обхождане е физически невъзможно.

За дисертацията MCCFR е алгоритъмът, който изчислява базовата **нашева стратегия** - опорната точка „играй на сигурно“, от която адаптивният агент се отклонява въз основа на наблюденията върху опонента (Принос №1). CFR+ прави това изчисление осъществимо върху междинните **еталонни тестове**, използвани в стъпки 5–8.

Прочетете повече: Bowling, M., Burch, N., Johanson, M. & Tammelin, O. (2015). “Хедс-ъп лимит холдем е решен.” *Science*, 347(6218), 145–149.

3.2 Търсене с метод Монте Карло в дърво като вдъхновение

Търсене с метод Монте Карло в дърво (MCTS) представлява каноничното семейство алгоритми, които използват **случайна извадка** за оценка на позиции в **дърво на играта**, без да прибегват до изчерпателно изброяване. Философията на проектирането му - „оценявай някои клонове до пълна дълбочина вместо всички клонове до фиксирана дълбочина“ - е пряка мотивация за MCCFR.

MCTS изгражда асиметрично **дърво на търсенето** чрез четири повтарящи се фази:

1. **Подбор** - слизване от корена чрез стратегия (обикновено UCB1, горна граница на доверителен интервал), която балансира експлоатацията на известни добри ходове и изследването на недостатъчно посетени такива.
2. **Разширяване** - във възел се добавят един или повече дъщерни възли към дървото.
3. **Симулация (разгръщане)** - от новия възел се играе случайна игра до нейния край.
4. **Обратно разпространение на грешката** - пропагиране на крайния резултат обратно по посещения път, като се актуализират броят посещения и кумулативните награди.

След множество **итерации**, детето на корена с най-голям брой посещения се избира за най-добър ход. Случайните разгръщания, агрегирани в хиляди **итерации**, **сходяват** към точни **стойностни оценки** - дори без никакви **експертни познания** извън правилата на играта.

Класически алтернативи като **минимакс с алфа-бета подрязване** оценяват всеки релевантен

възел до фиксирана дълбочина и след това прилагат евристика в крайните възли. И двата подхода имат своите области на приложение:

Свойство	Минимакс + α - β	MCTS
Покритие на дървото	Всички разклонения до дълбочина d	Подбрани разклонения до терминал
Оценка	Евристика при границата на дълбочината	Точна (крайна печалба) или чрез невронна мрежа
Чувствителност към коефициента на разклоняване	Експоненциална: $O(b^d)$	Грациозна: съсредоточава се върху обещаващи разклонения
Необходими експертни познания	Силна оценъчна функция	Никакви (случайно разгръщане) или придобити чрез обучение
Най-подходящ за	Умерен коефициент на разклоняване, добри евристики	Висок коефициент на разклоняване, слаби/никакви евристики

За Го (коефициент на разклоняване ~ 250 , без добра оценъчна функция преди невронните мрежи) минимакс е непрактичен. MCTS беше пробивът, който направи изкуствения интелект за Го конкурентоспособен; същият принцип „извадка вместо изброяване“ се пренася към игра с непълна информация дървета чрез MCCFR.

Прочетете повече: Browne, C. и др. (2012). “A Survey of Monte Carlo Tree Search Methods.” *IEEE Transactions on Computational Intelligence and AI in Games*, 4(1), 1–43.

3.3 Маркови вериги и законът за големите числа

„Метод Монте Карло“ в MCCFR обозначава широко семейство изчислителни методи, които използват **повтаряща се случайна извадка** за получаване на числени резултати. Наименованието произхожда от проекта „Манхатън“, където Станислав Улам и Джон фон Нойман прилагат **случайна**

изводка за симулиране на дифузията на неутрони - проблем, твърде сложен за аналитично решаване.

Математическата основа се крепи на **марковски вериги** - стохастични процеси, при които следващото състояние зависи единствено от текущото състояние и не от историята на достигането му (марковска свойственост). Обхождането на дърво на играта представлява марковска верига: от всяко **състояние на играта** преходът зависи само от текущото състояние и избраното действие.

Ключовата теоретична гаранция е **законът за големите числа**: ако се извлекат достатъчно траектории през марковската верига, средната **стойност** на извадените стойности се сближава до истинската очаквана **стойност**. За MCCFR:

$$\frac{1}{T} \sum_{t=1}^T \hat{v}_I^{(t)} \xrightarrow{T \rightarrow \infty} v_I$$

където $\hat{v}_I^{(t)}$ представлява извадената контрафактична стойност в информационно множество I на итерация t , а v_I е истинската стойност, която обикновеният вариант на CFR изчислява точно. Тези извадени стойности са **непристрастни оценители** - тяхната очаквана стойност съвпада с истинската стойност - което гарантира сходимост към същото равновесие на Наш като при Full-Traversal CFR.

Цената е **дисперсия**. Отделните извадки могат значително да се отклоняват от истинската стойност, което налага повече итерации за постигане на същата прецизност. Този компромис между вариация и скорост е основната тема на тази стъпка.

Прочетете повече: Сътон, Р.С. и Барто, А.Г. (2018). *Обучение с подкрепление: Въведение*, Глава 5 - Методи на Монте Карло.

3.4 Математиката на покера

Покерът е каноничният тестов полигон за теорията на игрите с непълна информация, тъй като съчетава три източника на сложност, които рядко се срещат в комбинация:

1. **Скрита информация** - всеки играч вижда само своите карти. Едно и също наблюдавано състояние на играта (информационно множество) може да съответства на множество различни основни състояния на играта.
2. **Стохастични елементи** - раздаването на картите въвежда случайни възли в дървото на играта. Оптималната стратегия трябва да отчита всички възможни раздавания, а не само наблюдаваното.

3. **Стратегическо заблуждение** - за разлика от игрите с пълна информация, покерът възнаграждава смесените стратегии. Играч, който винаги залага със силни ръце и пасува със слаби, е тривиално експлоатируем. Равновесието на Наш изисква **рандомизирано блъфиране с математически точно определени честоти**.

Разширената форма на играта от Стъпка 2 се запазва: дърво на играта, информационни множества, стратегии (съответствия между информационни множества и разпределения на действия), равновесие на Наш. Ключовите величини за оценяване на стратегиите са:

- **Очаквана стойност (EV)** - средната печалба при дадена двойка стратегии.
- **Най-добър отговор** - оптималната контрастратегия срещу постоянен противник; най-силната възможна експлоатация.
- **Експлоатируемост** - средната печалба, която противник може да реализира, като играе перфектен най-добър отговор. Равновесието на Наш има нулева експлоатируемост.

Чен и Анкенман формализират тези концепции чрез решения на опростени игрови модели, при които честотите на блъфиране в наш равновесие могат да бъдат изведени аналитично. Техните полуулични и пълни модели изграждат интуиция защо изходните стратегии на CFR съдържат точните съотношения между блъф и залог - балансираният играч трябва да блъфира с честота, пропорционална на шансовете на пота, които предлага.

Прочетете повече: Chen, B. & Ankenman, J. (2006). *Математиката на покера*. ConjeLCo - аналитични извеждания на **наш равновесие** за опростени **покер** игри.

3.5 Ледюк покер - Разширяване на еталонния тест

Кун покер улавя същността на непълната информация в най-малкото възможно дърво на играта. Ледюк покер увеличава мащаба с приблизително два порядъка - все още решимо точно, но достатъчно голямо, за да станат значими разликите между алгоритмите:

Свойство	Кун покер	Ледюк покер
Карти	3 (J, Q, K)	6 ($\{J, Q, K\} \times \{\spadesuit, \heartsuit\}$)
Кръгове	1	2 (префлоп + обща карта)
Обща карта	Няма	1 разкрита между кръговете
Класиране на ръка	Само висока карта	Чифт (частна = обща) бие висока карта
Размери на залози	Фиксирани (1 чип)	Променливи (2 в първи кръг, 4 във втори кръг)

Свойство	Кун покер	Ледюк покер
Максимални повишения/кръг	1	2
Информационни множества	12	936
Възли на игрово дърво	58	10,200
Случайни изходи	6	120

Три нови качествени характеристики се появяват:

- **Многорунтов строеж** - информацията се променя между кръговете (разкриване на обща карта), което изисква стратегии, адаптиращи се към новата информация.
- **Чифтове раздавания** - класирането на ръка вече зависи от общата карта; вале може да стане най-добрата ръка, ако вале бъде раздадено на борда.
- **По-големи залози в по-късните кръгове** - повишаването с 4 чипа във втори кръг означава, че решенията в по-късните кръгове имат по-голямо тегло.

Въпреки че е приблизително 78 пъти по-голям от **Кун**, **Ледюк** остава достатъчно малък за точно изчисление (пълно обхождане на дърво отнема около 50 ms). Това го прави идеален **еталонен тест**: достатъчно голям, за да бъдат значими разликите в производителността, и достатъчно малък, така че всички алгоритми да могат да достигнат почти пълна сходимост в рамките на минути.

Прочетете повече: Southey, F. и др. (2005). „Блъфът на Бейс: моделиране на противника в покера.“ *UAI*.

3.6 CFR+ - Трикът с подовото ограничаване на съжалението

CFR+ въвежда три малки изменения в обикновения вариант на CFR, всяко от които е лесно за реализиране, но води до съществени резултати.

Подово ограничаване на съжалението. При обикновения вариант на CFR кумулативното **съжаление** може да става произволно отрицателно:

$$R^{T+1}(I, a) = R^T(I, a) + r^T(I, a)$$

CFR+ задава долна граница на съжаленията при нула след всяка итерация:

$$R^{T+1}(I, a) = \max(R^T(I, a) + r^T(I, a), 0)$$

Това предотвратява натрупването на големи отрицателни съжаления за дадено действие, които биха отнели множество итерации, за да се „изплатят“, преди действието отново да бъде разглеждано. Аналогията с ReLU активациите в невронните мрежи е пряка: и двете ограничават отрицателните стойности до нула, като по този начин предотвратяват мъртви единици (или мъртви действия) да изискват дълъг период на възстановяване.

Усредняване на линейни стратегии. Обикновен вариант на CFR включва стратегията от всяка итерация с еднаква тежест в плъзгащата средна. При CFR+ всяка итерация t се претегля със самата нея, тоест t .

$$\bar{\sigma}^T(I, a) = \frac{\sum_{t=1}^T t \cdot \sigma^t(I, a)}{\sum_{t=1}^T t}$$


По-късните итерации - които се характеризират с по-малко съжаление и по-добри стратегии - оказват по-голямо влияние върху средната стойност. Ранните, шумни итерации получават по-ниска тежест.

Редуващи се актуализации. Вместо при всяка итерация да се актуализират съжаленията и на двамата играчи, CFR+ актуализира съжаленията на играч 0 при нечетни итерации, а на играч 1 - при четни. Това намалява наполовина изчислителната работа за една итерация и носи малка полза по отношение на сходимостта, като предотвратява едновременните промени в стратегията.


Комбиниран ефект: емпиричната сходимост се подобрява от $O(1/\sqrt{T})$ до приблизително $O(1/T)$. С 1000 итерации CFR+ постига резултат, за който на обикновения вариант на CFR са необходими около 1,000,000 итерации. Именно това направи възможно решаването на хедс-ъп лимит тексаски холдем през 2015 г. Забележка: макар че скоростта $O(1/T)$ се наблюдава последователно, тя няма формално доказателство - Tammelin и др. представят алгоритъма, но не и теорема за сходимост, съответстваща на наблюдавана скорост.

Емпирично, при Ледюк с 5000 итерации CFR+ достига експлоатируемост $\approx 5.4 \times 10^{-5}$, докато обикновеният вариант на CFR все още е около $\sim 7.6 \times 10^{-3}$ - подобрение приблизително 140 пъти, постигнато чрез три малки модификации.

Прочетете повече: Tammelin, O. (2014). “Решаване на големи игри с непълна информация чрез CFR+.” AAAI.



Фигура 1: Ледюк Poker - Exploitability vs Iterations



Фигура 2: Ледюк Poker - Exploitability vs Wall-Clock Time

3.7 MCCFR - Извадка от дървото на играта

MCCFR заменя пълното обхождане на дърво с частично извадково обхождане. Два варианта се разполагат върху една и съща крива дисперсия–скорост в различни точки:

Вариант	Възли на шанса	Възли на traverser-a	Възли на опонента	Разход на итерация
Външно вземане на проби	Извадка от едно раздаване	Разглеждане на всички действия	Извадка от едно действие	~42 възела (~945× по-бързо от пълното)
Извадка по резултати	Извадка от едно раздаване	Извадка от едно действие (ϵ -on-policy)	Извадка от едно действие	~5.5 възела (~2,228× по-бързо)


Външно вземане на проби разглежда всички възможни действия във възлите на играча, който актуализира стратегията си, но извършва извадка от възлите на шанса и възловите състояния на противника. Съжаленията за traverser-a се актуализират въз основа на извадковото поддърво. Тъй като се посещава само едно раздаване и един път на опонента, всяка итерация обхваща малка част от дървото.

Извадка по резултати избутва извадката още по-напред: тегли се една корен–краен траектория. Тъй като действията във възлите на играча, който актуализира стратегията си, също се изваждат, актуализацията на съжалението трябва да бъде коригирана чрез **извадка по важност** - отношението между истинската вероятност за достигане и вероятността за извадка. Една ϵ -on-policy смес (с вероятност ϵ се избира равномерно; в противен случай се следва текущата стратегия) осигурява разглеждане на всички действия дори когато текущата **политика на работа** им присвоява нулева вероятност.


Критичното теоретично свойство и за двата подхода е, че извадковите контрафактични стойности са **неизместени оценки** на действителните стойности (Lanctot и др., Теорема 1). Това гарантира сходимост към същото равновесие на Наш като при обикновения вариант на CFR, въпреки шума от извадката. Цената, както винаги при метода Монте Карло, е дисперсията. Всяка извадкова актуализация се отклонява от действителната контрафактична стойност, тъй като отразява само едно възможно раздаване, а не очакваната стойност за всички раздавания.

Върху 12-те информационни множества на **Кун покер** и четирите алгоритъма (**обикновен вариант на CFR**, **CFR+**, двата варианта на **MCCFR**) достигат **почти равновесие на Наш** за секунди - **компромисът скорост–вариация** е невидим при този **мащаб** и изборът на алгоритъм е по-скоро теоретичен.

За да се прояви компромисът, дървото на играта трябва да бъде достатъчно голямо, така че разходът на итерация да има значение. Именно затова е необходим **Ледюк**.



Фигура 3: Kuhn Poker - Exploitability vs Iterations



Фигура 4: Kuhn Poker - Exploitability vs Wall-Clock Time

Прочетете повече: Lanctot, M., Waugh, K., Zinkevich, M. & Bowling, M. (2009). “Метод Монте Карло за минимизиране на съжалението в разширени игри.” *neurIPS*.

3.8 Компромисът скорост–вариация

Всички четири алгоритъма демонстрират $O(1/\sqrt{T})$ сходимост, но стойностите на константите им се различават съществено. При изразяване на експлоатируемостта като $\epsilon(T) = C/\sqrt{T}$ и преобразуването ѝ в реално време чрез $C_w = C/\sqrt{\text{speed}}$:

Алгоритъм	C_{iter}	Скорост (итерации/сек)	C_w (реално време)	Относително към обикновен вариант на CFR
Обикновен вариант на CFR	0.34	20.6	0.075	1.0×
CFR+	0.34	20.6	~0.002	~38 пъти по-бърз
MCCFR	107	19,470	0.767	10.2× по-бавен
External MCCFR Outcome	245	45,901	1.143	15.3× по-бавен

Константата в реално време определя представянето в практиката. Въпреки че външното вземане на проби е 945 пъти по-бързо на итерация, неговата константа на дисперсията (107 спрямо 0.34) е 315 пъти по-голяма. Предимството в скоростта **не компенсира наказанието от дисперсията**:


$$\frac{99,000 \times \text{more iterations needed}}{945 \times \text{faster per iteration}} \approx 105 \times \text{more wall-clock time}$$

Защо се наблюдава дисперсия? Обикновеният вариант на CFR изчислява **точни** контрафактични стойности чрез изброяване на всички 120 раздавания. Неговото обновяване на съжалението има нулева дисперсия. MCCFR взема проба от едно раздаване на итерация. Дори ако обходи цялото поддърво за това раздаване, пак ще се наблюдава дисперсия между различните раздавания - следствие от самата скрита информация, а не недостатък на схемата на извадка:

$$\text{Var}[\hat{v}_I] = \mathbb{E}_{\text{deal}} [(\hat{v}_I - v_I)^2] \propto \frac{|N|}{|I|}$$

Формален 180-секунден еталонен тест с ограничение във времето за изпълнение на всичките четири варианта върху Ледюк прави сравнението в реално време конкретно. Гледна точка, базирана


на итерациите (вариантите с извадка завършват милиони обновления, докато вариантите с пълно обхождане - само няколко хиляди):



Фигура 5: Exploitability vs Iterations

Гледна точка в реално време - справедливото сравнение (при еднаква изчислителна мощност кой алгоритъм генерира най-добрата стратегия?):

CFR+ достига експлоатируемост от 2.6×10^{-5} - практически точно наш равновесие - за 3 минути. Обикновеният вариант на CFR следва с 4.4×10^{-3} . И двата варианта на MCCFR изостават с няколко порядъка при този размер на играта.



Фигура 6: Exploitability vs Wall-Clock Time

3.9 Кога MCCFR надделява - точката на пресичане

Горният модел поставя очевиден въпрос: ако MCCFR винаги е по-слаб в Ледюк, защо тогава беше изобретен? Отговорът се крие във факта, че разходът на итерация при обикновения вариант на CFR нараства линейно с размера на дървото $|N|$, докато този на MCCFR е приблизително постоянен. При достатъчно голям мащаб линейната цена надделява. Критичният размер на дървото е:

$$|N|_{\text{crossover}} = |N|_{\text{Leduc}} \cdot \left(\frac{C_{mc}}{C_v} \right)^2 \cdot \frac{\text{speed}_v}{\text{speed}_{mc}}$$

При заместване на измерените стойности:

Вариант	$ N _{\text{crossover}}$
Външно вземане на проби	~2.1 милиона възела
Извадка по резултати	~4.8 милиона възела

Сравнение с реални игри:

Игра	$ N $	Външни победи?	Победи по резултати?
Ледюк	10,200	Не (210 пъти твърде малко)	Не (466 пъти твърде малко)
покер			
Тексас	$\sim 10^{14}$	Да (10^7 пъти над прага)	Да
холдем с			
лимит			
No-Limit	$\sim 10^{17}$	Да (10^{10} пъти над прага)	Да
Texas			
Холдем			

Ледюк е 210 пъти под прага за външно вземане на проби и 466 пъти под прага за извадка по резултати. Пълното обхождане доминира, тъй като цялото дърво на играта се побира в паметта и може да бъде изброено за милисекунди. При реални мащаби на покера заключението се обръща напълно - дори една итерация на пълно обхождане на холдем би отнела повече време от възрастта на Вселената. В такъв мащаб MCCFR (с разширения за намаляване на дисперсията) е **единственият** приложим подход.

3.10 Връзки със стъпка 2 и бъдещи насоки

Същият принцип, различен режим. Стъпка 2 установи Full-Traversal CFR върху Кун и доказа, че минимизирането на съжалението локално във всяко информационно множество води глобалната стратегия към равновесие на Наш. Стъпка 3 запазва този принцип, но въвежда две независими усъвършенствания: CFR+ променя начина на акумулиране на съжаленията (подово ограничаване на съжалението + линейно претегляне), а MCCFR модифицира начина на измерването им (среднопретеглена извадка вместо точна очаквана стойност). И двете все още извеждат **средната** стратегия, а не последната итерация - същият механизъм за осредняване, който стабилизира обикновения вариант на CFR, стабилизира всеки негов вариант.

Скорости на сходимост. Стъпка 2 измери наклон в лог-лог мащаб, близък до -0.5 , за експлоатируемостта на играта Кун, потвърждавайки $O(1/\sqrt{T})$. Стъпка 3 показва, че тази скорост е свойство на цялото семейство алгоритми, а не само на конкретна реализация - единствено емпиричният $O(1/T)$ при CFR+ е по-бърз, но без формално доказателство. MCCFR остава със скорост $O(1/\sqrt{T})$, но с драстично по-голяма константа.

Напред:

- **Стъпка 4 (Абстракция на играта и мащабиране)** - атакува проблема с мащабируемостта от противоположната посока: вместо да се прави извадка от дървото, самото дърво се редуцира чрез абстракция на състоянията и действията. Комбинира се с MCCFR, за да направи реалния покер управляем.

- **Стъпка 5 (Невронно равновесие / Deep CFR)** - заменя табличното съхранение на стратегията с невронни апроксиматори на функции, използвайки рамката за извадка на MCCFR като двигател за генериране на данни. Свойствата на дисперсията, установени тук, обясняват защо Deep CFR изисква специфични техники за намаляване на дисперсията (мрежи за предимство, важни целеви стойности с тегла).
- **Стъпка 6 (Игрови изкуствен интелект от край до край)** - надгражда както върху CFR+, така и върху MCCFR за създаване на пълноценни агенти. Машината Ледюк, разработена за тази стъпка, се превръща в еталонна среда през Стъпка 8.

Отворени въпроси:

- Защо CFR+ емпирично постига $O(1/T)$, когато няма доказателство за такава скорост на сходимост? Най-добрата текуща хипотеза е, че подовото ограничаване на съжалението преоформя траекторията на динамиката на минимизиране на съжалението по начин, който класическите граници на сходимост не улавят.
- При какъв размер на дървото намаляването на дисперсията (среднопретеглена извадка, MCCFR с намаляване на дисперсията) става необходимо, а не просто опция? Формулата за пресичане ни показва къде печели MCCFR - но не и къде спира да бъде конкурентен без допълнителни техники.

Прочетете повече: Brown, N. & Sandholm, T. (2017). “Безопасно и вложено решаване на под-игри за игри с непълна информация.” *neurIPS* - свързва табличния CFR с декомпозицията на под-игра за реалния покер.