

Глава 7 Обобщение – Моделиране на противника в игри с непълна информация

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните
игри

Alexander Andreev

July 2026

Съдържание

7 Глава 7 – Моделиране на противника в игри с непълна информация	1
7.1 Защо е необходимо моделиране на противника	2
7.2 Байесовото ядро – убеждение, наблюдения и реакция	4
7.3 Виждане през ключалка – проблемът с частичната наблюдаемост	7
7.4 Три модела с единен интерфейс	8
7.5 Проблемът на състоятелността и решението в последователна форма	10
7.6 Когато моделът е уверен, но греша	13
7.7 От модела до печалбата – най-добрият отговор, таванът и самонанесената уязвимост	15
7.8 Адаптиране към промяна – нестационарни опоненти	17
7.9 Връзки и бъдещи насоки	19

7 Глава 7 – Моделиране на противника в игри с непълна информация

Това е цялостна глава за моделиране на противника: формулировката на проблема, математическият му апарат, семейството от методи и набор от контролирани експерименти, проведени върху две малки покер игри. Главата е написана така, че да бъде разбираема и без предварително познаване на програмния код на проекта. Всички представени експериментални резултати са получени от възпроизводими изпълнения на двете тестови среди (Кун покер и Ледюк Холдем) и, когато е възможно, са поставени в *точни* аналитични граници, а не в симулирани.

Къде се вписва това в дисертацията. Игровитеоретичният агент от предходните глави изчислява *равновесие на Наш* – стратегия, която не може да бъде победена в дългосрочен план. Настоящата глава изгражда противоположната способност: **сензор**, който наблюдава как *конкретен* противник действително играе и превръща тези наблюдения в оценка на неговата стратегия, така че агентът да може да се отклони от равновесието с цел да накаже грешките на този противник. Този сензор представлява първата половина от рамката за поведенческа адаптация на дисертацията (Принос №1). Втората половина – как да се експлоатира *безопасно*, без да се създаде уязвимост в


собствената игра – е формализирана в Глава 8.

7.1 Защо е необходимо моделиране на противника

Равновесна стратегия на Наш е изградена така, че в дългосрочен план никога да не води до загуба, *независимо срещу кого се играе*. В игра за двама с нулева сума тази гаранция е реална и ценна: една равновесна стратегия има фиксирана *стойност* и нито един противник – колкото и да е умен – не може да я свали под нея. Но същото свойство представлява и ограничение. Една равновесна стратегия играе **идентично** както срещу световен шампион, така и срещу някой, който се отказва всеки път при направен залог. Тя никога не се адаптира, защото е създадена именно така, че да не се нуждае от адаптация.

Този отказ да се адаптира има цена и тази цена е измерима. **Моделирането на противника** е актът на наблюдение на действията на конкретен противник, формиране на убеждение относно неговата стратегия и **отклонение от равновесието на Наш, за да се използва забелязаната закономерност** – повече блъфове срещу някой, който се отказва твърде често, и залози за стойност с по-слаби ръце срещу някой, който плаща твърде често.

Стойността се вижда най-ясно в примера с „камък-ножица-хартия“. Вашият противник тайно хвърля камък 70% от времето. Безопасната стратегия е да избирате трите хода с равни вероятности и така завинаги да излизате на нула. Но ако *забележите* пристрастието, хвърляте повече хартия и започвате да печелите. Този пример съдържа цялата глава в умален вид по две причини: пристрастието трябва да се **изведе** от шумен поток от хвърляния (няколко хвърляния не стигат), а ако **заложите прекалено много** на хартията, ставате предвидими и противникът ви смазва с ножица. Извеждането на пристрастието е моделиране на противника; знанието докъде да се наклоните е компромисът между експлоатация и безопасност, който преминава през всичко по-долу.



Фигура 1: Скалата безопасност–експлоатация: чистата равновесна игра е неексплоатируема, но „сляпа“; чистият най-добър отговор извлича най-голяма стойност, но носи най-голям риск. Моделирането на противника действа между двете крайности. Глава 7 изгражда сензора (модела), а Глава 8 изгражда изпълнителния механизъм (безопасната експлоатация).

7.1.1 Колко е заложено – измерено в Кун покер

Кун покер е най-малката нетривиална покер игра: тесте от три карти (Вале, Дама, Поп), по една карта на всеки, един рунд за залози. Тя е достатъчно малка, за да бъде решена *точно*, което ни позволява да изчислим стойността на моделирането, вместо да я предполагаваме. За всеки от няколко постоянни противникови стила ние изчислихме три точни величини:

- **Очаквана стойност при равновесие на Наш** – това, което равновесната стратегия носи срещу този противник (на раздаване);
- **Стойност на най-добрия отговор** – това, което стратегия, която *познава противника перфектно*, носи: точният таван за експлоатация;
- **разликата** между тях – сумата, която равновесната игра оставя неизползвана.

Таблица 1: Потенциал за експлоатация в Кун: очаквана стойност при равновесие на Наш, при най-добър отговор и разликата между тях, по тип опонент.

Противник (Кун)	Очаквана стойност		Разлика
	при равновесие на Наш	Стойност на най-добрия отговор	
Пасивен играч (никога не се отказва)	+0,119	+0,333	0,215
Rock (ангажира се само с Поп)	-0,060	+0,167	0,227

Противник (Кун)	Очаквана стойност при равновесие на Наш	Стойност на най-добрия отговор	Разлика
Maniac (винаги залага/плаща)	+0,121	+0,333	0,213
„Наш“ (равновесна игра)	-0,055	-0,052	0,004

Срещу трите експлоатируеми стила разликата е огромна – **около 0,21-0,23 на раздаване** (от 0,11 до 0,28, ако се вземат предвид и двете позиции на масата), в игра, чиято цялостна равновесна стойност е около една двадесета от жетон. Срещу противник, който играе равновесие на Наш, разликата е по същество **нула**, точно както изисква теорията: не можете да експлоатирате равновесие, защото най-добрият отговор не може да надмине стойността на играта. (Малките отрицателни стойности при равновесие на Наш са известният недостатък на първия играч в Кун покер от $-1/18 \approx -0,056$ - това е характеристика на самата игра, а не грешка; равновесието тук е приближение, получено с 20 000 итерации на CFR, затова срещу отделен противник стойността може да падне с няколко хилядни под $-1/18$.)

Два урока вече се открояват. Първо, **моделирането си струва**: стойността е значителна и реална. Второ, **експлоатацията зависи от вида на слабостта** – точният най-добър отговор на Rock блъфира повече (той залага най-слабата ръка в отворен пот, защото Rock се отказва от всичко освен Поп). Останалата част от тази глава е посветена на това как да реализираме тази стойност, без да я губим.¹

7.2 Байесовото ядро – убеждение, наблюдения и реакция

Под всеки метод в тази глава стои един цикъл, който е добре да бъде обяснен с прости думи преди въвеждането на каквито и да било означения. Представете си, че сте детектив. Започвате с предположение за начина, по който играе противникът (**априорно разпределение**). Всяко негово действие е следа: то прави някои обяснения по-вероятни, а други – по-малко вероятни. Вие включвате тази следа в подозренията си (**апостериорно разпределение**) и повтаряте процеса. Моделирането на противника *представява* именно този цикъл:


убеждение за стратегията → наблюдавано действие → обновяване на убеждението → най-добър отговор → повторение.

Формално, обновяването се извършва по правилото на Бейс. Ако σ обозначава кандидат-стратегия на противника и a е действието, което току-що беше наблюдавано,

¹Southey, F. et al. (2005). “Bayes’ Bluff: Opponent Modelling in Poker.” *UAI*.

$$P(\sigma | a) \propto P(\sigma) \cdot P(a | \sigma),$$

с думи: **апостериорното разпределение** $\propto$ **априорното разпределение** $\times$ **колко добре дадена стратегия обяснява току-що извършеното действие**. Действие, което кандидатът смята за невъзможно, намалява вероятността му към нула; действие, което предвижда добре, я увеличава. След множество раздавания убеждението се съсредоточава върху най-подходящото обяснение.



Фигура 2: Цикълът на моделиране на противника: априорното убеждение се умножава по правдоподобие на всяко наблюдавано действие и дава апостериорното разпределение, спрямо което се изчислява най-добрият отговор; резултатът от раздаването захранва следващото наблюдение.

7.2.1 „Зоопарк“ от типове

Най-простият начин да направим това конкретно е да разсъждаваме върху малък набор от предварително дефинирани противникови **типове**, вместо върху цялото безкрайно множество стратегии. В рамките на главата използваме повтарящ се набор от типове, всеки от които изпълнява двойна роля – като противник, срещу когото да играем, и като хипотеза, която детекторът обмисля:

Таблица 2: „Зоопаркът“ от типове опоненти: поведението на всеки постоянен стил.

Тип	Поведение
Пасивен играч	Никога не залага и никога не се отказва – пропуска хода без залог (чек), когато може, и плаща всеки залог.

Тип	Поведение
Rock (стегнато-пасивен)	Вкарва жетони само с най-добрата ръка; с всичко останало се отказва. Най-експлоатируемият тип.
Maniac (разпуснато-агресивен)	Винаги залага или плаща, независимо от ръката си.
„Наш“	Балансирана равновесна игра; използва смесени стратегии; неексплоатируем.

7.2.2 Актуализацията, изчислена на ръка

Механиката е най-лесна за разбиране, когато сами завъртите механизма веднъж. Да предположим, че трима кандидати залагат определена ръка с вероятност 0,8, 0,5 и 0,1 съответно, като започват от равномерно априорно разпределение $(\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$. Наблюдават **залог**:

$$\text{апостериорно} \propto \left(\frac{1}{3} \cdot 0,8, \frac{1}{3} \cdot 0,5, \frac{1}{3} \cdot 0,1\right) = (0,267, 0,167, 0,033) \xrightarrow{\text{нормализиране}} (0,571, 0,357, 0,071).$$

Наблюдаваме **втори** залог и отново умножаваме по $(0,8, 0,5, 0,1)$:

$$(0,711, 0,278, 0,011).$$

Убеждението се натрупва върху типа играчи, които правят чести залози, и би го направило *още по-бързо*, колкото повече кандидатите се разминават в мненията си. Тази интуиция „колко много се разминават“ се появява отново в раздел 7.6 като обяснение защо някои опоненти се идентифицират след четири раздавания, а други – след двеста.

7.2.3 Защо Дирихле и защо е нужна само средната стойност

Два факта от литературата оформят всеки практически модел. Първо, когато оценявате разпределение на действия чрез броеве, естественото априорно разпределение е **разпределението на Дирихле**, защото то е *спрегнатото* априорно разпределение за мултиномиалното разпределение: обновяването на разпределение на Дирихле с наблюдаваните броеве дава отново разпределение на Дирихле, в което броевете просто се **добавят** към псевдоброевете на априорното разпределение. Няма нужда от интеграл или симулация – апостериорната средна стойност на действие i е

$$\mathbb{E}[p_i] = \frac{\alpha_i + n_i}{\sum_j (\alpha_j + n_j)},$$

където α_i са априорните псевдоброеве (които едновременно изпълняват ролята на *изглаждане*, като предотвратяват стойността нула за което и да е действие), а n_i са наблюдаваните броеве. Тази затворена форма съответства на „непрекъснатия“ модел, разгледан в раздел 7.4.

Второ – и това е най-често използваният резултат в областта – за да се избере оптималният отговор, не е нужно цялото апостериорно разпределение върху стратегиите; достатъчна е само неговата **средна стойност**. Очакваната печалба срещу *разпределение* от стратегии на опонента е равна на печалбата срещу единствената осреднена стратегия. Това свежда изчислително непосилен интеграл върху пространството на стратегиите до задачата „най-добър отговор на един осреднен опонент“ и именно това прави байесовата експлоатация приложима на практика. (Раздел 7.5 се връща към това: отговорът на средната стойност е оптимален по отношение на печалбата, но, както ще се окаже, оценката може да не *клони* към истинската стратегия на опонента – тънкост, която работата от 2025 г. разрешава.)²


7.3 Виждане през ключалка – проблемът с частичната наблюдаемост

Има причина моделирането на противника в покера да е по-трудно от броенето на честоти в „камък-ножица-хартия“ и това заслужава отделен раздел, тъй като определя характеристиките на всеки следващ модел.

В покера наблюдават **действия** – залог, плащане, отказ – но **не** и частната ръка, която ги е породила. Един и същ „залог“ може да произтича както от силна ръка, така и от блъф. Единственото изключение е **разкриването**, когато картите се показват в края на раздаването, ако то не е приключило с отказ. По този начин всяко раздаване попада в една от двете категории според това какво разкрива:

- **Разкриване – причина и следствие.** Виждате както действията на противника, *така и* частната ръка зад тях. Можете да свържете поведението с точната ситуация, която го е породила. Това представлява златния стандарт за наблюдение.
- **Отказ – само следствие.** Раздаването завършва без разкриване на картите. Видяхте *какво* са направили, но не и *какво са държали*, така че не можете да сте сигурни коя ситуация е причината за това.

²Ganzfried, S. & Sun, Q. (2018). “Bayesian Opponent Exploitation in Imperfect-Information Games.” *IEEE Conference on Computational Intelligence and Games (CIG)*, DOI 10.1109/CIG.2018.8490452; препринт arXiv:1603.03491 (2016). (Теорема 2.1: печалбата срещу средната стойност на апостериорното разпределение е равна на печалбата срещу цялото разпределение.)



Фигура 3: Частична наблюдаемост: при разкриване картата на противника става видима и действието се свързва с една-единствена ситуация; при отказ картата остава скрита и моделът трябва да разпредели наблюдението между всички карти, които противникът би могъл да държи.


Следствието е истинско теоретично ограничение, а не неудобство при имплементацията: **без да наблюдавате частната информация на противника, можете да научите колко често той избира всяко действие, но не и с кои карти го прави.** Много различни стратегии пораждат едни и същи честоти на действията и повече раздавания не могат да ги различат. Разкриването е именно информацията, която премахва тази двусмисленост.

Как се справя моделът с отказ? Като разсъждава върху **всички карти, които противникът би могъл да държи.** Конкретно, той изброява раздаванията, съгласувани с това, което действително е било видяно, преиграва решенията на противника при всяка хипотетична тайна карта и разпределя наблюдението между тях – като претегля всяка хипотеза според нейната правдоподобност. Разкриването свежда този набор до една-единствена възможност; отказът го оставя разпределен. Този ход „маргинализиране върху скритата карта“ е техническото ядро на всеки модел в следващите два раздела и – неслучайно – формалният обект, около който е изградена теорията на състоятелността от раздел 7.5.

7.4 Три модела с единен интерфейс

Няма един-единствен модел на противника. Има семейство, което прави компромис между скорост на сходимост, устойчивост към изненади, интерпретируемост и изчислителни разходи. Този

проект имплементира и сравнява три точки от този спектър, умишлено изградени зад **общ интерфейс** – всеки приема поток от наблюдавани раздавания и генерира прогнозирана стратегия на противника – така че *същият* последващ най-добър отговор може да бъде приложен към всичките три и сравнението да е при равни условия.



Фигура 4: Три модела с общ интерфейс: дискретно убеждение върху типове, свободно преброяване по ситуации и глобално съгласувана оценка в последователна форма; и трите връщат прогноза за стратегията на противника, която постъпва в една и съща стъпка за най-добър отговор.

- **Типово базиран.** Поддържа убеждение (разпределение на вероятностите) върху фиксирано меню от типове противници, актуализира го чрез правилото на Бейс (раздел 7.2) и докладва апостериорно претеглената средна стратегия. Той се сближава *изключително* бързо **когато противникът е в менюто** и изходът му е интерпретируем („80% Rock, 20% Maniac“). Неговата слабост също е ясна: ако реалният противник не прилича на нито един от типовете, моделът няма честен начин да го каже (раздел 7.6).
- **Непрекъснат.** Премахва менюто. Оценява вероятностите за действията на противника *директно във всяка ситуация* чрез броене на това, което те са направили там, изгладено с априорно разпределение на Дирихле (раздел 7.2). Той може да представи **всяка** стратегия, включително смеси и нови стилове, така че е устойчивият избор срещу непознати противници. Цената е данни: той научава всяка ситуация независимо, без споделяне на структура, така че се нуждае от много повече наблюдения – и, както показва раздел 7.7, тази нужда от данни се оказва сериозен проблем в по-голямата игра.
- **Състоятелен.** Оценява една-единствена *глобално съгласувана* стратегия – такава, която със сигурност е валидна стратегия в цялото дърво на играта – вместо всяка ситуация поотделно.

Това е най-строго обоснованият и най-новият модел; той е достатъчно важен и централен за дисертацията, за да получи собствен раздел (раздел 7.5).

Следващата таблица обобщава сравнението и служи за ориентир в останалата част от главата:

Таблица 3: Трите модела на противника, сравнени по представяне, сходимост, устойчивост, интерпретируемост и цена.

Модел	Представява	Сближаване	Устойчив на непознати противници?	Интерпретируемост	Изчислителна цена
Типово базиран	няколко известни типа	най-бързо	не	висока (именувани типове)	евтина
Непрекъснат	всяка стратегия за конкретна ситуация	по-бавно (жаден за данни)	да	средна (за конкретна ситуация)	евтина
Състоятелен	една валидна глобална стратегия	доказуемо към истината	да	средна	скъпа (оптимизация)

Очевидният въпрос – *кой от тях трябва да използва дисертацията?* – няма единствен отговор и това само по себе си е откритие. Естествената цел е хибриден подход: да се разчита на структурни априорни знания (типове), когато данните са оскъдни, и постепенно да се приближава към състоятелната оценка с натрупването на наблюдения. Тази глава изгражда и измерва крайните точки, така че хибридният модел да има стабилна основа, върху която да стъпи.³

7.5 Проблемът на състоятелността и решението в последователна форма

Този раздел е най-напредналата теоретична част на главата и е частта, която дисертацията най-пряко доразвива. Той поставя въпрос, който по-ранните модели подценяват: *ако даден модел добре описва наблюдаваното поведение, означава ли това непременно, че сме възстановили истинската стратегия на опонента?* Изненадващият отговор е **не** – дори при наличие на безкрайни данни – и съществува принципно решение.⁴

³Bard, N., Johanson, M., Burch, N. & Bowling, M. (2013). "Online Implicit Agent Modelling." AAMAS, 255–262 – ос „явни срещу неявни“, която рамкира тази таксономия.

⁴Ganzfried, S. (2025). "Consistent Opponent Modeling in Imperfect-Information Games." *arXiv:2508.17671*.

7.5.1 Недостатъкът: напасването към средната стойност не е равносилно на откриването на истината

Класическата байесова рецепта отговаря на **средната стойност** на апостериорното разпределение на стратегията (раздел 7.2). Един метод за моделиране на противника ще наречем **състоятелен**, ако неговата оценка се сближава със същинската стратегия на опонента σ^* при натрупване на наблюдения срещу постоянен противник. Бихме очаквали класическата рецепта да бъде състоятелна, но тя не е.

Най-ясният контрапример е камък-ножица-хартия. Да предположим, че моделиращият разсъждава върху множество от *извадени* кандидатски стратегии и винаги реагира на някаква тяхна средна стойност. Ако истинската стратегия $\sigma^* = (0,8, 0,1, 0,1)$ лежи **извън** областта, до която тези извадки могат да се комбинират, моделът – тъй като винаги е претеглена средна стойност на извадките – просто **не може да я достигне**, независимо колко много данни постъпват. Това е интуитивно. По-дълбокият резултат е, че методът може да се провали **дори когато истината лежи вътре** в достижимата област: ако истинската стратегия се намира в центъра на три извадки, чиято средна стойност съвпада с нея, апостериорното тегло на единствената най-добре пасваща извадка нараства неограничено спрямо останалите, така че асимптотично убеждението **колабира върху една извадка**, вместо да се установи на истинската смес.⁴ Колкото по-плътно моделът напасва данните, толкова повече се сближава с *грешната* стратегия.



Фигура 5: Защо напасването към средната стойност може да пропусне истината: моделът може да породи само точки в оцветената обвивка на своите извадки. Истинска стратегия извън обвивката е недостижима, а дори такава вътре в нея бива изоставена, защото апостериорното разпределение се свива към един-единствен връх.

Това е важно, защото обезсилва интуитивната представа за „сигурност чрез натрупване на повече данни“. Състоятелността не е автоматична; тя трябва да бъде изградена.

7.5.2 Решението: задача на изпъкналата оптимизация в последователна форма

Подходът преформулира оценката така, че „валидна стратегия“ и „съответства на наблюденията“ да се превърнат в ограничения на една-единствена оптимизационна задача с добри свойства. Ключовата промяна на променливите е **последователната форма**: вместо вероятности за действие във всяка ситуация, стратегията на опонента се представя чрез **реализационни тегла** y_r върху последователности от действия. Допустимите стратегии тогава са точно тези, които удовлетворяват набор от **линейни** ограничения $Fy = f, y \geq 0$ - полиномиални по размер на дървото на играта, вместо експоненциални.

Частичната наблюдаемост (раздел 7.3) се въвежда чрез **функция на наблюдаемост**: за всяко наблюдавано раздаване множеството от траектории, съгласувани с това, което действително е било видяно (отказът скрива картата на опонента и допуска множество траектории; разкриването я показва и допуска само една). Правдоподобие то на едно наблюдение представлява сума от реализационните тегла върху това съгласувано множество. Поставянето на **априорно разпределение на Дирихле** върху теглата и максимизирането на **логаритъма на апостериорната вероятност** води до програмата

$$\max_y \sum_r (\alpha_r - 1) \log y_r + \sum_t \log \left(\sum_{r \in o(\ell_t)} q_r y_r \right) \quad \text{при } Fy = f, y \geq 0,$$

където $o(\ell_t)$ е множеството от съгласувани траектории за наблюдение t и q_r са (нормализирани) вероятности на случайността. Решаващото свойство е, че когато $\alpha_r \geq 1$ тази целева функция е **вдлъбнатата** – първият член е вдлъбнат, вторият е логаритъм на афинна функция, а ограниченията са афинни – така че това е **изпъкнала** задача без **локални оптимуми**. Всеки решаващ, който намери локален оптимум, е намерил глобалния. Достатъчен е стандартен **градиентен метод с проекция**: извършва се стъпка на градиента, след което резултатът се проектира обратно върху множеството от ограничения. В псевдокод цикълът е елементарен, което е и целта -

```
initialize y feasible (F y = f, y >= 0)
repeat until converged:
    g <- gradient of the (negative) log-posterior at y
    z <- y - eta * g                                # gradient step
    y <- project z onto { y : F y = f, y >= 0 }      # convex projection
```

Този метод връща **модата** на апостериорното разпределение (неговата единствена най-вероятна точка), а не средната стойност. Това е ключовият компромис: модата е **състоятелна** – при стандартни условия (истинската стратегия лежи във вътрешността на множеството от допустими стратегии и има положителна априорна плътност, различни стратегии водят до различни наблюдения

и всяка ситуация на противника се посещава безкрайно често) оценката доказано се сближава към σ^{*4} – докато оптималната по отношение на печалбата средна стойност по правило е изчислително непосилна за точно пресмятане. Следователно основната ос на дизайна, върху която стъпва целият процес, е **средна стойност срещу мода**: оптимална по отношение на печалбата, но изчислително непосилна, спрямо ефективно изчислима и състоятелна.

7.5.3 Какво установихме, откровено казано

Ние внедрихме този състоятелен оценител и проверихме неговата работа при възстановяване на стратегия в играта Кун, където той се представя според очакванията: възстановената стратегия е много близка до истинската (разстоянието по обща вариация е приблизително **0,004 до 0,021**), като съвпада или превъзхожда резултатите от възстановяването на непрекъснатия модел в същата игра. Това потвърждава както правилната работа на механизма, така и валидността на теорията върху малката тестова среда.

Ние **не** го стартирахме в рамките на онлайн цикъла на експлоатация, нито върху по-голямата игра. Причината е практическа: оценката представлява решението на оптимизация, която се **пререшава с натрупването на наблюдения**, като цената ѝ нараства с историята – от части от секундата в началото до много секунди за всяко повторно решаване след изиграването на десетки хиляди раздавания. За мач в реално време, раздаване по раздаване, това е непрактично в наивната му форма. Вместо да го разглеждаме като пропуск, ние приемаме това за *емпиричен отговор* на въпрос, който главата поставя изрично – *достатъчно бързо ли е решаването на изпъкналата задача при всяка актуализация за игра в реално време?* – а именно **не, без инкрементални методи** (всяко решаване да започва от предишното решение, а членовете за отделните раздавания да се кешират), което е точно видът приближение, с който се занимава Глава 8. Разбирането и резултатът от възстановяването са това, от което дисертацията се нуждае от този модел сега; онлайн инженерството остава за бъдеща работа.⁴

7.6 Когато моделът е уверен, но греши

Раздел 7.5 беше за фин провал при безкрайни данни. Този раздел разглежда груб провал при крайни данни и именно той най-пряко мотивира *безопасната* експлоатация. Това е различен провал от липсата на състоятелност: тук проблемът е **неправилно зададено меню** – противник, който типово базираният модел просто не може да представи – и как се държи моделът, когато бъде притиснат в ъгъла.

Изградихме скрит противник, който представлява 50/50 смес от действията на Rock и Maniac – съзнателно **нито един** от четирите кандидата. Очаквано е апостериорното разпределение да разреди убеждението си между двата най-близки типа. Това обаче не се случва. Апостериорното разпределение, изчислено като произведение на вероятностите, се концентрира върху *единственото най-добро обяснение*, поради което убеждението прескача от един тип към друг и в крайна

сметка твърдо се ангажира с типа „**Наш**“ – единственият кандидат, който приписва реална вероятност както на залог, така и на чек със средна ръка и по този начин никога не е категорично опроверган. В резултат моделът става **уверен** (апостериорното разпределение е близо до 1,0 върху един тип) и същевременно **грешен** (този тип не отговаря на действителния противник).

Това разкрива един капан, който си струва да бъде изказан ясно: апостериорното разпределение е **относителна** величина. „Деветдесет и пет процента хипотеза на Наш“ означава „най-добро приближение *сред тези четири кандидата*“, а не „добро приближение в абсолютен смисъл“. Измерването на *абсолютното* съответствие на победителя разкрива проблема – същата хипотеза на Наш, която се представя добре срещу противник, който наистина играе равновесие на Наш, се представя значително по-зле срещу тази смес, като същевременно отчита еднаква увереност на хартия. Малкото стереотипно меню няма честен начин да каже „нито едно от горните“.

7.6.1 Колко дълго може да остане грешен? Проверка на устойчивостта

Тъй като уверено-грешните убеждения са опасни, подложихме феномена на стрес-тест върху **300 изпълнения (с различни начални числа) от по 500 раздавания**, като разграничихме две неща, които една наивна метрика обединява: *бавна сходимост* и *отпадане след сходимостта*.

Таблица 4: Надеждност на детектора при 300 начални числа по 500 раздавания.

Измерване (300 начални числа × 500 раздавания)	Резултат
Правилен дългосрочен победител до раздаване 500	300 / 300 (100%)
Някога отстъпва, след като трайно поеме лидерството	0 / 300 (никога)
Грешен тип все още води след раздаване 100	40 / 300 (~13%)
Грешен тип все още води след раздаване 200	14 / 300 (~5%)
Раздаване, на което истината окончателно се установява	медиана 23 – 90-ти персентил 125 – най-лош случай 461

Добрата новина е, че убеждението в крайна сметка винаги се установява върху най-близката представима стратегия и след като се заключи, никога не отстъпва. Тревожната новина са средните редове: в немалка част от случаите моделът поддържаше **уверено грешно убеждение за повече от сто раздавания** – достатъчно дълго, за да може един най-добре реагиращ агент, който експлоатира твърдо това убеждение, да се е настроил да победи илюзия. Това е емпиричното проявление на напрежението между експлоатацията и безопасността: на модела може да се вярва в *крайна сметка*, но „в крайна сметка“ понякога е след 200 раздавания, а действието въз основа на междинното убеждение, сякаш то е сигурно, е начинът, по който самият агент се наранява.

Честната поправка не е по-голямо меню, а да спрем да питаме „кой единствен тип?“ и да се опрема на модели, които могат да представят смеси (непрекъснатите и състоятелните модели от раздели 7.4–7.5), и да **мащабираме степента на експлоатация според това доколко е обоснована преценката за противника**. Този принцип е нишката, която преминава през следващите два раздела и към Глава 8.

7.7 От модела до печалбата – най-добрият отговор, таванът и самонанесената уязвимост

Моделът е полезен единствено ако действията, основани на него, носят печалба. За да измерим това по ясен начин, подаваме оценката на всеки модел в **същия** точен най-добър отговор и играем пълни мачове и в двете игри, като поставяме всеки резултат между два аналитични критерия, изчислени чрез ръчно проверена математика, а не чрез симулация:

- **Очаквана стойност при равновесие на Наш** – това, което безопасната равновесна игра носи срещу този опонент (дори при безполезна преценка за противника резултатът не може да е по-лош от тази стойност);
- **таван** – точната стойност на най-добрия отговор, максималното, което може да бъде извлечено при пълно познаване на опонента.

Добрият експлоататор се намира между двете и се стреми към тавана. Първо, проверка за коректност, че апаратът е надежден: решаващът възпроизвежда точната равновесна стойност на Кун $-1/18$ (остатъчна експлоатируемост $\approx 0,002$, по същество неексплоатируем), а точен най-добър отговор превъзхожда равномерната игра с предвидените разлики (+0,500 при Кун, +2,087 при Ледюк).

Кун – и двата модела достигат тавана.

Таблица 5: Кун: таванът на експлоатация спрямо реално постигнатото от всеки модел.

Опонент	таван	типово базиран	непрекъснат
Rock	0,167	0,168	0,168
Maniac	0,333	0,337	0,330
„Наш“	-0,055	-0,055	-0,053

(Чист опонент, който винаги се отказва при залог, е още по-експлоатируем – таван от 0,975, достигнат до 0,966 – но той не е сред повтарящите се типове, дефинирани по-горе, и поради това е пропуснат тук с цел еднообразие.)


Ледюк – започва да се проявява значението на класа на модела. Ледюк Холдем добавя втори

рунд за залози и една споделена обща карта, което води до приблизително два порядъка повече ситуации в сравнение с Кун – все още точно решима, но вече достатъчно голяма, за да различи моделите.

Таблица 6: Ледюк: таванът на експлоатация спрямо реално постигнатото от всеки модел.

Опонент	таван	типово базиран	непрекъснат
Ниво 1	3,056	3,061	2,672
Maniac	2,177	2,199	2,038
Пасивен играч	1,464	1,451	1,434
Rock	0,937	0,912	0,848
„Наш“	-0,083	-0,085	-0,175

(„Ниво 1“ е противник, който играе най-добър отговор срещу случаен играч, а „Ниво k“ – най-добър отговор срещу „Ниво k-1“; в Ледюк менюто на типово базирания модел съдържа девет типа, показани на следващата фигура.)



Фигура 6: Експлоатация срещу всеки противник в Ледюк: типово базираният модел (който описва точно тези противници) следва плътно точния таван на най-добрия отговор, а непрекъснатият модел остава близо, но под тавана при най-трудните за нападение типове и пада под безопасната базова стойност срещу „Наш“.

Два резултата подчертават извода, като вторият е от съществено значение:

1. **Не можете да експлоатирате равновесие.** Срещу противника „Наш“ всеки модел реализира приблизително (отрицателната) стойност на играта и не повече. Таванът *по същество представлява* стойността на играта. Това потвърждава, че наблюдаваната експлоатация другаде е реална, а не артефакт на средата за тестване.
2. **Уверен, но недообучен модел ви прави уязвими.** В Ледюк непрекъснатият модел губи срещу „Наш“ – $-0,175$ при таван от $-0,083$. С несъвършени данни за множеството ситуации в Ледюк той реагира най-добре на *грешна* оценка на противник, който изобщо не подлежи на експлоатация, и по този начин създава **уязвимост** в собствената си игра. Недостигът на наблюдения, който срещу експлоатируеми опоненти му струва малко, се оказва активно вреден срещу неексплоатируем опонент.

Това е напрежението между експлоатацията и безопасността, изразено в едно число. Когато класът на модела пасва на противника, най-добрият отговор извлича пълната теоретична стойност; когато не съвпада, агентът както оставя пари на масата и – по-опасно – връща част от тях обратно. Тази втора цена е именно това, което предпазният механизъм от Глава 8 (ограничаване на отклонението от равновесието на Наш според увереността на самия модел) съществува, за да предотврати.

Разликите тук не се дължат на начална случайност. При пет различни начални числа стандартната грешка на печалбата на раздаване е незначителна в сравнение с наблюдаваните ефекти: типово базираният модел остава в рамките на 3% от тавана за всеки тип и в двете игри (и в рамките на две стандартни грешки за почти всички типове), а недостигът на непрекъснатия модел в Ледюк и неговата уязвимост срещу „Наш“ са многократно по-големи от стандартната грешка.⁵


7.8 Адаптиране към промяна – нестационарни опоненти

Досега всичко се основаваше на постоянен противник. Реалните опоненти обаче се променят и адаптират, а модел, който е учил търпеливо десет хиляди раздавания, става безполезен в момента, в който неговият обект промени стила си – той вече *уверено* описва играч, който вече не съществува. Това е отворен проблем, към който е насочена дисертацията, и главата включва първи контролиран експеримент по него.

Пълният адаптивен агент изпълнява цикъла от раздел 7.2 от край до край: **наблюдава** раздавания, **актуализира** модела, периодично преизгражда собствената си стратегия като най-добър отговор на текущата оценка (по избор смесена с равновесието на Наш за безопасност) и **действа**. За да се справи с промяната, той добавя детектор: лек статистически монитор върху агресията на опонен-

⁵Ganzfried, S. & Sandholm, T. (2015). “Safe Opponent Exploitation.” *ACM Transactions on Economics and Computation* 3(2), DOI 10.1145/2716322 – статията, която характеризира кога е възможен принципът „експлоатирай, но никога не губи спрямо базовата линия“; безопасната половина от скалата и основата за Глава 8.

та (байесово онлайн откриване на точки на промяна⁶), който следи за промяна в режима и при задействане **нулира** модела и преминава към безопасна игра, докато отново се учи.



Фигура 7: Цикълът на адаптивна експлоатация: наблюдение, обновяване на модела, най-добър отговор (смесен с равновесието на Наш за безопасност) и действие; детекторът на точки на промяна може да нулира модела, когато противникът смени стила си.

Сменихме стила на опонента в средата на мач от 20 000 раздавания и сравнихме **статичен** модел (който никога не забравя) с такъв, който прилага **забравяне на точка на промяна**. Резултатът е **сценарийно-зависим**, и именно това представлява откритието:

Таблица 7: Статичен модел срещу забравяне при точка на промяна, след смяна на стила по средата на мача.

Игра	Смяна на стила (в средата)	статичен (след смяната)	точка на промяна (след смяната)
Кун	TightPassive → LooseAggressive	-0,106 ± 0,007	+0,211 ± 0,008
Ледюк	Rock → Maniac	+1,834 ± 0,054	+0,552 ± 0,017

- **В Кун забравянето печели.** Стратегията, научена срещу Rock, е блъф-ориентирана; пусната срещу Maniac, който плаща всеки залог, тя *активно губи* (печалбата на статичния модел става отрицателна). Откриването на смяната и повторното обучение връщат стабилна печалба.

⁶Adams, R. P. & MacKay, D. J. C. (2007). "Bayesian Online Changepoint Detection." *arXiv:0710.3742*.

- **В Ледюк забравянето губи.** Там Maniac губи над два жетона на раздаване, така че непрекъснато адаптиращ се модел го експлоатира успешно и без нулиране – докато детекторът, твърде нетърпелив, задейства десетки **фалшиви аларми** по време на стабилните периоди (около шестдесет нулирания срещу една истинска промяна), всяко от които изхвърля трудно спечелени данни и преминава към безопасна игра.

Урокът не е „откриването на промени е добро“ или „лошо“ – той е, че **реакцията при открита промяна има толкова голямо значение, колкото и самото откриване.** Детектор, който задейства твърде често, съчетан с пълно връщане в безопасен режим, може да струва повече от остарелия модел, когато новият опонент е толкова експлоатируем, че остарелият модел губи малко. По-евтини и по-меки реакции – частично забравяне вместо твърдо нулиране, по-малко чувствителен детектор – са ясна следваща стъпка и те се свързват пряко с експлоатацията, мащабирана според увереността, от Глава 8. (Стойностите са средни от пет начални числа $\pm$ стандартната грешка; посоката на ефекта е една и съща при всяко от тях.)

7.9 Връзки и бъдещи насоки

Какво установява тази глава. Добрият модел на противника е *необходим, но не и достатъчен* за печеливша и безопасна адаптация. Когато класът на модела съответства на противника, най-добрият отговор достига точния таван на извличимата стойност – реализира се пълната теоретична стойност на моделирането. Но при частична наблюдаемост и ограничени данни, недообученият модел както оставя пари на масата, така и срещу противник, който не може да бъде експлоатиран, реагира най-добре на химера и *губи*. Нестационарността добавя втори аспект: забравянето на остарял модел е полезно само когато остарялостта е активно вредна, а фалшивите аларми на небрежен детектор могат да струват повече, отколкото спестяват. Един принцип се повтаря през всичко това: **степената на експлоатация трябва да съответства на това доколко е обоснована преценката за противника.**

Обратни връзки. Тази глава е огледален образ на работата по равновесие, която я предшества. Докато една равновесна стратегия *игнорира* идентичността на противника по замисъл, моделът на противника е механизмът, който я *използва* – двата са крайните точки на спектъра безопасност–експлоатация. Механизмът за извадка, използван в предишните глави за обхождане на дърво на играта според *текущата* стратегия, се появява отново тук, за да разсъждава върху действията на противника според *изведения* модел. А идеята за групиране на много конкретни ситуации в няколко представителни категории – абстракция – е именно това, което типово базираният модел прави в пространство на стратегиите.

Напред към Глава 8 и дисертацията. Тази глава изгради **сензора**, а Глава 8 изгражда **изпълнителния механизъм** – механизма, който превръща модела в *безопасна* експлоатация, като ограничава отклонението от равновесието според това доколко е обоснована преценката за противника. Самонанесената уязвимост на непрекъснатия модел срещу „Наш“ (раздел 7.7) е емпиричният ар-

гумент за този механизъм; проверката на увереното, но грешно убеждение (раздел 7.6) определя неговия бюджет; теорията на състоятелността (раздел 7.5) е принципният гръбнак, върху който рамката се разширява.⁷

⁷Shoham, Y. & Leyton-Brown, K. (2008). *Multiagent Systems: Algorithmic, Game-Theoretic, and Logical Foundations*. Гл. 3 (игри в нормална форма); гл. 4 (изчисляване на решения на игри в нормална форма, §4.1 – линейно програмиране за игри с нулева сума); гл. 5 (игри в разгърната форма; §5.2 – игри с непълна информация и последователната форма, механизмът под всяка линейна програма в Глава 8); гл. 7 “Learning and Teaching” – рамката за учене в повтарящи се игри, включително напрежението, че действията едновременно *експлоатират* и *обучават* опонента. Свободно достъпна: <http://www.masfoundations.org/download.html>