

Стъпка 8 Обобщение - Безопасна експлоатация в игри с непълна информация

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Съдържание

8	Стъпка 8 - Безопасна експлоатация в игри с непълна информация	1
8.1	1. Защо безопасната експлоатация - другата половина на скалата	2
8.2	2. Експлоатацията като ограничена оптимизация	3
8.3	3. Какво означава „безопасен“ - три определения с нарастваща степен на реализъм	5
8.4	4. Двигателят - линейно програмиране в последователна форма и генериране на ограничения	7
8.5	5. Ограничен отговор по Наш и граница „включено–изключено“	8
8.6	6. Ганцфрид върху Кун - безопасен и печеливш (основният резултат)	11
8.7	7. Безопасност в реално време - под-игра джаджи (SES)	14
8.8	8. В мащаб - Кун работи; Ледюк се разпада глобално, но се задържа локално	15
8.9	9. Връзки и бъдещи насоки	18

8 Стъпка 8 - Безопасна експлоатация в игри с непълна информация

Това е глава, изградена из основи, за *безопасна* експлоатация на противника: формулировката на проблема, математическият апарат, семейството от методи и набор от контролирани експерименти, проведени върху две малки покер игри. Тя изпълнява две функции - служи като самостоятелно въведение и опресняване, докато по-късните стъпки се надграждат върху него, както и като основен източник за синтеза на дисертацията в Част 1. Написана е така, че да може да бъде прочетена самостоятелно; не се предполага предварителна познатост с кода на проекта. Всички експериментални числа, докладвани тук, са **измерени** при възпроизводими изпълнения на двете тестови среди (Кун покер и Ледюк холдем) и са ограничени, където е възможно, от *точни* аналитични препратки, а не симулирани такива. Когато дадено изпълнение противоречи на това, което теорията ме е накарала да очаквам, аз го заявявам и го съгласувам - тези пропуски са най-показателните части от стъпката.

Къде се вписва това в дисертацията. Стъпка 7 изгради **сензор**: модел, който наблюдава как даден противник играе и оценява неговата стратегия. Тя също така разкри опасността от наив-

ното действие въз основа на този сензор - уверен, но недообучен модел, към който се реагира оптимално, може да отвори дупка в собствената ви игра (в Ледюк той всъщност загуби срещу не-експлоатируем Нашов противник). Стъпка 8 изгражда **изпълнителен механизъм**: механизма, който превръща модел в печалба, **без да става експлоатируем**. Този изпълнителен механизъм е втората половина на рамката за поведенческа адаптация на дисертацията (принос №1), а определянето *точно къде неговите гаранции зависят от предположението за игра с нулева сума за двама играчи* е отправната точка за многоагентното разширение (принос №2).


8.1 1. Защо безопасната експлоатация - другата половина на скалата

Стратегия в **равновесие на Наш** е изградена така, че никога да не губи в дългосрочен план. В **двуигрова игра с нулева сума** тази гаранция е точна: стратегията има фиксирана *стойност* v^* , и никой противник, колкото и умен да е, не може да ви свали под нея. **Моделиране на противника** (Стъпка 7) ви дава възможността да се *отклоните* от тази безопасна стратегия, за да накажете грешките на конкретен противник. Очевидният начин да реализирате печалба от модел е да изчислите **най-добър отговор** към него и да играете така. Проблемът е, че най-добрият отговор обикновено сам по себе си е **силно експлоатируем**: за да накаже „винаги пасваш на залог“, той напълно спира да блъфира определени **раздавания**, а по-умен противник - или същият противник, след като спре да се преструва - минава право през отворения пробив.

Представете си **скала**. Ако я завъртите докрай към *безопасност*, ще играете в **равновесие на Наш**: непобедими, но без да наказвате слаб противник. Ако пък я завъртите докрай към *експлоатация*, ще **оптимално отговарям** твърдо на текущото си впечатление: максимална **печалба**, ако впечатлението е вярно и противникът остане на място, но сериозен риск, ако грешите, извадката ви е малка или сте били *сандбегвани* (умишлено подхранвани със слаб стил, за да се предизвика голямо **отклонение**). **Безопасна експлоатация** поставя *регулатор* върху тази скала: можете да се наклоните към експлоатацията колкото желаете, но никога не бива да минавате отвъд точката, в която противник в **най-лошия случай** може да ви свали под вашата **безопасна базова линия**.

Причината това да не е параноя е едно число от Стъпка 7 и отново от тази стъпка: пълният **оптимален отговор** на стегнатия стил „камък“ в Кун носи **+0.167 на раздаване**, но неговият **най-лош стойностен случай е -0.5** - противник, който **оптимално отговаря** обратно, може да вземе половин чип на раздаване от него. **Най-лошият случай при равновесие на Наш**, напротив, е самата **стойност на играта**. **Безопасна експлоатация** е дисциплината да се запази по-голямата част от този +0.167 потенциал за печалба, като същевременно се избягва -0.5 потенциала за загуба.

Какво означава „безопасен“ в неформален план. Вашата *очаквана стойност за целия мач* никога не бива да пада под избран праг, **независимо какво прави противникът**. Това е твърдение за най-лошия случай, а не за конкретно раздаване - все пак ще губите раздавания; гаранцията се отнася до дългосрочната средна стойност при противников подход. Целият въпрос на дизайна в тази стъпка е *какъв праг* да бъде избран и как да се изчисли стратегия, която го спазва, като



Фигура 1: The safety-exploitation dial with a governor. Pure Nash is unexploitable but blind; a full best response extracts the most value but is maximally risky. Safe exploitation operates in between, capped by a floor on the worst-case value. Step 7 built the sensor (the model); Step 8 builds the actuator (safe exploitation). The only thing that differs between methods is where the floor sits.

същевременно извлича възможно най-много над него.

Прочетете повече: Ганцфрид, С. & Сандхолм, Т. (2015). „Безопасна експлоатация на противника“. *ACM Trans. Economics and Computation* - статията, която за първи път формулира като теорема принципа „експлоатирай, но никога не губи спрямо базовата линия“.

8.2 2. Експлоатацията като ограничена оптимизация

Единствената най-полезна идея в тази стъпка е, че **всеки метод за експлоатация представлява един и същ проблем на оптимизация**, при който се заменя само една негова част. С други думи:

максимизиране на очакваната стойност на героя спрямо модела на противника, **при условие** за праг на безопасност за най-лошия стойностен случай на героя.

За да се превърне това в *изчислима* програма, представете стратегията на героя в **последователна форма**: вместо вероятности за действие според ситуацията, използвайте **план за реализация** x , който присвоява тегло на всяка от последователностите от действия на героя (вериги от корен до тук от собствените им избори), подчинени на линейните ограничения на **treeplex** (празната последователност има тегло 1; при всяко информационно множество теглата на децата се сумират до теглото на родителя; всички тегла са неотрицателни). Причината да се плати тази „данък“ за смяна на променливите е решаваща: срещу **фиксирана** стратегия на противника, очакваната стойност на героя е **линейна** в x ,


$$EV(x) = \sum_{\text{terminals } z} [\text{chance}(z) \cdot \text{opp-reach}(z) \cdot u_{\text{hero}}(z)] x_{\text{seq}(z)} = c \cdot x,$$

защото собственото произведение на вероятностите за действие на героя по всяка линия е x при последователността на тази линия. Така „максимизиране на очакваната стойност спрямо модела“ представлява **линейна цел** $c \cdot x$, treeplex е множество от **линейни ограничения**, а целият метод е **линейна програма**. Пълният най-добър отговор е просто $\max_x c \cdot x$ върху treeplex - което ни позволява да проверим линейната програма спрямо кода за точен най-добър отговор от Стъпка 7 (те съвпадат до 10^{-6}).

Прагът на безопасност представлява ограничение върху **най-лошия случай** стойност - „за всеки противник σ' , $EV(x, \sigma') \geq \text{floor}$.“ Това вътрешно „за всеки противник“ само по себе си е най-добър отговор (минимакс), поради което не го записваме като една гигантска билинейна програма; решаваме го чрез **генериране на ограничения** (двоен предсказвач / цикъл с равнини на сечение): решаваме линейната програма, прочитаме стратегията на героя, извикваме **точен най-добър отговор като предсказвач за най-лош случай**, и ако най-лошият случай е под прага, добавяме единственото линейно сечение, което той предполага, и преизчисляваме. Това е крайно (съществува краен брой чисти най-добри отговори), прозрачно и подлежи на отстраняване на грешки.

Концептуалната полза от този подход е икономия: **пет метода, един двигател**. Те се различават единствено по прага, който ще бъде разгледан в следващия раздел. И тъй като както целта (векторът на печалбата), така и предсказвачът за безопасност използват повторно *валидирания* най-добър отговор от Стъпка 7, цялата Стъпка 8 се основава на една вече доверена примитивна операция, а не на нова поредица от математически изчисления.

Прочетете повече: Shoham, Y. & Leyton-Brown, K. (2008). *Многоагентни системи*, §3.4 (изчисляване на равновесия) и §4.6 (изчисляване на най-добри отговори) - последователната форма на механизма под всяка линейна програма в тази глава.



Фигура 2: One LP engine, five safety floors. The sequence-form treeplex gives a linear objective (EV vs the model); a constraint-generation loop calls an exact best response as the worst-case oracle and adds a safety cut until the floor is met. RNR, Ganzfried, prime-safe, SES and adaptation are the SAME solve with a different floor - and one validated primitive (Step 7's best response) powers both the objective and every safety check.

8.3 3. Какво означава „безопасен“ - три определения с нарастваща степен на реализъм

„Безопасността“ звучи като абсолютна характеристика, но всъщност не е еднозначна. От значение са три различни определения, а изследователската линия по същество представлява *отслабване* на изискването, за да стане то приложимо в практиката.

(а) Сигурност при ганцфрид (2015): никога да не се печели по-малко от стойността на играта. При *перфектно* нашево равновесие σ^* като базова линия, изискването е

$$EV(x, \sigma') \geq v^* \quad \text{for all opponents } \sigma'.$$

Това е най-силната и най-чистата концепция. Нейното доказателство се основава на **теоремата за минимакс**: в двуигрови игра с нулева сума нашевата стратегия *гарантира* стойността v^* срещу всеки противник, така че човек може да се отклони към експлоатация на модела в рамките на „хлябината“, създадена от грешките на противника (техните *подаръци*) и никога да не падне под v^* . Уловката е предпоставката: *перфектно* нашево равновесие, което е неизчислимо във всяка голяма

игра.

(б) Безопасен спрямо прайм / ε -safety (Jeary & Turrini 2023): корекция за несъвършена базова линия. Всяка реална базова линия е **ε -равновесие** (поради абстракция и ограничена изчислителна мощност - предмет на Стъпка 4), така че самата тя е експлоатируема в известна степен ε . Поради това закрепването към точната v^* е неоправдано; безопасен спрямо прайм понижава пода с точно експлоатируемостта на самата базова линия,

$$\text{floor} = v^* - \varepsilon, \quad \varepsilon = \text{exploitability}(\text{baseline}) \geq 0,$$

т.е. „никога не печели по-малко от най-лошия случай на стратегията, която така или иначе ще се играе“. ε трябва да бъде **измерена**, а не предполагаема - точка, която експериментите приемат буквално.

(в) Безопасност на адаптацията (Ge и др. 2024): да бъдеш не по-експлоатируем от своя план. Най-практичната концепция. Една експлоатираща стратегия е *безопасна за адаптация*, ако и само ако

$$\text{exploitability}(x) \leq \text{exploitability}(\text{blueprint}) \iff \text{worst-case}(x) \geq \text{worst-case}(\text{blueprint}).$$

Тъй като планът вече е ε -експлоатируем, това е по-слабо от абсолютната долна граница на Ганцфрид (по-слабо точно с ε) и следователно *постижимо* там, където строгата безопасност не е. Опасността му е огледален образ: ако планът е *ужасен*, „не по-лошо от плана“ се удовлетворява тривиално от почти всичко - така че безопасността на адаптацията има смисъл само при разумна базова линия (отворено изискване, което отбелязвам, вместо да реша).

Понятие за безопасност	Неформална долна граница	Нужди	Слабост
Ганцфрид (2015)	$\geq v^*$	едно <i>перфектно</i> нашево референтно ниво	перфектното нашево равновесие е неизчислимо в мащаб
Безопасен спрямо прайм (2023)	$\geq v^* - \varepsilon$	измерената експлоатируемост на базовата линия	трябва честно да измерите ε
Адаптация (2024)	$\leq$ експлоатируемост на плана	всеки план	безсмислено, ако планът е лош

8.3.1 Къде се крие предположението за игра с нулева сума при двама играчи - атакуващата точка на дисертацията

Всеки от горните прагове се основава на един факт: **в игра за двама с нулева сума, една нашева стратегия гарантира стойността v^* срещу всеки противник** ($\min_{\sigma'} \text{EV}(\sigma^*, \sigma') = v^*$). Именно това прави „отклонявай се към модела, но никога под прага“ последователно и приложимо ограничение, което произтича директно от теоремата за минимакс. В $N > 2$ -игрова игра това се срива: нашевата стратегия *не* гарантира фиксирана стойност срещу произволни противници (другите могат да координират действията си и техните печалби вече не се сумират до отрицанието на твоята), така че няма единна v^* , към която да се закотви. **Това е отвореният проблем за Принос №2** - дали съществува аналог на гаранцията за стойност в N -игрова игра или структурно предположение (например коалиционна структура) трябва да възстанови опорната точка. Тази стъпка не го решава; тя прави провала *прецизен*, което е точно това, от което се нуждае една глава на дисертация.

Прочетете повече: Johanson, M., Zinkevich, M. & Bowling, M. (2007). „Изчисляване на устойчиви контрастратегии.“ *NeurIPS* - Ограничен отговор по Наш, настройваемият предшественик на всички изброени по-горе. · Jeary, J. & Turrini, P. (2023). „Безопасна експлоатация на противника за ϵ -равновесие стратегии“, *arXiv:2307.12338*. · Ge, Z. и др. (2024). „Безопасна и устойчива експлоатация на под-игра...“, *ICML*.

8.4 4. Двигателят - линейно програмиране в последователна форма и генериране на ограничения

Този раздел описва „как е изградено“. Единствената примитивна операция, която цялата стъпка добавя, е `HeroTreeplex`, който (i) изброява последователностите на героя и дървовидните ограничения (използвайки повторно кода в последователна форма от Стъпка 7), (ii) изгражда вектора на печалбата c за постоянен противник чрез едно обхождане на дървото, и (iii) решава линейното програмиране с ограничение за безопасност със решавача `HiGHS` на `SciPy`. Всичко останало е цикълът на генериране на ограничения, който е достатъчно кратък, за да бъде представен изцяло:

```
c_model <- payoff vector of EV vs the opponent model      # linear objective
cuts    <- {}                                              # discovered safety cuts
repeat:
  x <- argmax c_model . x s.t. treeplex(x) and all cuts    # one LP solve
  pol <- behavioral strategy read out of x
  wc <- worst_case_value(pol)                               # = -(opponent's exact best response) : the oracle
  if wc >= floor - tol: return pol                          # safe: done
  adv <- opponent's exact best response to pol
  add the cut c(adv) . x >= floor - slack to cuts          # a valid lower bound on the worst
```

Всяко генерирано ограничение представлява вектора на печалбата спрямо *специфичен* най-добър отговор на противника; то е валидна линейна долна граница на истинския най-лош случай, поради което добавянето на ограничения монотонно затяга релаксираното ограничение за безопасност към действителното. Извеждането на поведенческа стратегия от план за реализация x се извършва чрез съотношението $\beta(I, a) = x_{Ia} / x_{\text{seq}(I)}$ (равномерно в случаите, когато теглото на родителя е приблизително 0).

Единственото, което се различава между петте метода, е стойността на `floor` и, за метода на под-игра (§7), набор от *цифтове*, които фиксират играта на героя извън избрана под-игра да бъде равна на плана. Ганцфрид използва `floor = v*`; безопасен спрямо прайм използва `floor = v* - ε`; адаптация използва `floor = worst_case(blueprint)`; RNR преформулира целевата функция като максимин в параметър p (§5).

Една практическа особеност, която си струва да се отбележи (тя доведе до реално отстраняване на грешки при изпълненията): *приблизителната* стойност от самообучението в равновесието на Наш може да бъде съвсем малко **над** истинската постижима максимин стойност на играта, така че изискването за точно `ws ≥ floor` може да направи линейното програмиране в крайна сметка недопустимо и, при неблагоприятен път на ограниченията, да върне *небезопасна* стратегия. Решението е малък резерв за допустимост върху ограниченията (`floor - slack`, като `slack ≈ 5 · 10-4`, поддържан независим от допустимата грешка при сходимост), така че истинската максимин стратегия винаги да остава допустима. Това е видът числов детайл, който никога не се появява в научните статии, но решава дали методът всъщност ще върне безопасна стратегия.

Прочетете повече: идеята за генериране на ограничения / двоен предсказвач води началото си от McMahan, Gordon & Blum (2003), “Планиране в присъствието на функции на разходите, контролирани от противник,” *ICML* - общата рецепта за “оптимизиране срещу най-лош случай, който откривате докато вървите.”


8.5 5. Ограничен отговор по Наш и граница „включено–изключено“.

Най-старият принципен метод, **ограничен отговор по Наш** (Johanson 2007), е концептуалният предшественик на всички останали и въвежда *настройваемия параметър*. Неговата идея: да се изчисли равновесието на героя срещу p -**ограничен** противник - такъв, който е принуден да играе фиксирания модел с вероятност p и е свободен да играе противнически с вероятност $1 - p$. Променяйки p от 0 до 1 се проследява път от равновесието на Наш ($p = 0$) до пълния най-добър отговор ($p = 1$). Тъй като свободният компонент дава най-добър отговор на героя, RNR е **максимин**:

$$\text{RNR}(p) = \arg \max_x \left[p \cdot \text{EV}(x, \text{model}) + (1 - p) \cdot \min_{\sigma'} \text{EV}(x, \sigma') \right],$$

която решаваме със същия механизъм с равнини на отсичане плюс допълнителна променлива за най-лошия случай.

Знаме, което си струва да се запази. В първоначалните бележки на проекта RNR беше описан като *наивна смеска*, $(1 - p) \cdot \text{Nash} + p \cdot \text{BR}$. Това е полезен интуитивен инструмент, но **не представлява** алгоритъма на Johanson; ние имплементирахме *и двата* и ги обозначихме, тъй като в малка игра поведението им е коренно различно. Наивната смеска проследява плавна крива (фигура по-долу, вляво): печалбата и експлоатируемостта се увеличават почти пропорционално заедно - от **наш равновесие** до пълен най-добър отговор.



Фигура 3: The naive Nash/best-response blend on Kuhn: a smooth exploitation-safety frontier where each increment of profit costs a near-proportional increment of your own worst-case loss.


Измерената изненада - Canonical RNR е изненадващ обрат. Предвидих, че каноничното обхождане ще бъде гладка, монотонна граница, която доминира смеската навсякъде. Не е така. В играта Кун срещу камък, Canonical RNR връща **една и съща безопасна стратегия** за всички $p \in [0, 0.6]$ (EV -0.044 , експлоатируемост ≈ 0) и след това **преминава направо към пълен най-добър отговор** при $p = 0.6$ (EV 0.167 , експлоатируемост 0.444). Няма междинни точки.

p	Canonical RNR - EV	Canonical - експлоатируемост	наивна смеска - EV	наивна - експлоатируемост
0.0	-0.044	~ 0.000	-0.047	0.000
0.3	-0.044	~ 0.000	+0.017	0.133

p	Canonical RNR - EV	Canonical - експлоатируемост	наивна смеска - EV	наивна - експлоатируемост
0.6	-0.044	~0.000	+0.081	0.266
0.7	+0.167	0.444	+0.103	0.311
1.0	+0.167	0.444	+0.167	0.444

Защо (проверих, преди да се доверя на историята). Целта на RNR е **линейна** в x върху един **политоп**, така че нейният оптимум е **върх** и сменя върховете само когато p пресече критично съотношение. Политопът на стратегиите в Кун е малък - малко върхове - така че **преходът се изразява в един-единствен скок**. Гладката крива на Йохансон е феномен от *големи игри* (много върхове) или идва от *данни-ориентирания* вариант, който прави p за всеки информационен набор. Наивната смеска изглежда гладка само защото линейно интерполира две фиксирани стратегии - и тя е **доминирана в безопасния връх** (при експлоатируемост ≈ 0 методите на ЛП достигат EV -0.044 спрямо -0.047 на смеската). Основният извод остава - „избери *къде* да се отклониш, а не *колко* равномерно“ - но механизмът („гладък RNR циферблат“) е артефакт от големи игри и в малка игра честната картина е дискретен преход от безопасен връх към BR-върх, чийто праг *се измества според това колко експлоатируем е противникът*. Тази последна точка се повтаря в §6: срещу много експлоатируем противник дори $p = 0.5$ вече е отминал скока.

Прочетете повече: Johanson, M. & Bowling, M. (2009). “Data Biased Robust Counter Strategies.” *AISTATS* - прави лоста p да зависи от това колко данни подкрепят всяка част от стратегията, което е това, което изглажда границата на практика.



Фигура 4: The exploitation-safety frontier on Kuhn with the LP operating points. The canonical RNR “curve” is only an interpolation between two achieved clusters (the safe corner and the full-BR corner); the smooth line is the dominated naive blend; the stars (Ganzfried, prime-safe, adaptation) sit at the efficient safe corner.

8.6 6. Ганцфрид върху Кун - безопасен и печеливш (основният резултат)


Централният експеримент решава всеки метод срещу *перфектен* модел на всеки **тип противник** и го оценява по **печалба** (EV спрямо този **тип противник**) и **безопасност** (**най-лошият случай**), като подът на **наш равновесие** е $v^* = -0.056$ (известната първоначална **стойност** в Кун, $\approx -1/18$). Всички числа са точни (пълно дърво), от мащабния прогон.

Противникметрика		nash	full_br	rn timer_0.5	ganzfried	prime_safe	adaptation
Камък	EV	-0.047	+0.167	-0.044	-0.044	-0.040	-0.040
	(стегнат-пасивен)						
	най-лошият случай	-0.056	-0.500	-0.056	-0.056	-0.063	-0.063

Противник	метрика	nash	full_br	rn timer_0.5	ganzfried	prime_safe	adaptation
Маниак	EV	+0.118	+0.333	+0.278	+0.131	+0.151	+0.151
(LooseAggr.)	най-лошият случай	-0.056	-0.167	-0.111	-0.056	-0.063	-0.063
AlwaysBet	EV	+0.113	+0.333	+0.333	+0.115	+0.131	+0.131
	най-лошият случай	-0.056	-0.167	-0.167	-0.056	-0.063	-0.063
AlwaysPass	EV	+0.146	+0.975	+0.975	+0.222	+0.266	+0.266
(най-експлоатируем)	най-лошият случай	-0.056	-0.500	-0.333	-0.056	-0.063	-0.063
Наш равновесие	EV	-0.056	-0.055	-0.056	-0.056	-0.055	-0.055
(конт-рол)	най-лошият случай	-0.056	-0.333	-0.056	-0.056	-0.063	-0.063

Три основни резултата обобщават тази глава.

1. **Пълният най-добър отговор е поучителната история.** Той винаги печели най-много срещу фиксиран модел - до **+0.975** срещу alwaysPass - но неговият най-лошият случай се срива до **-0.5**. Това е единственият експлоатируем метод в таблицата и той е експлоатируем срещу *всеки* противник, защото противникът винаги може оптимално да отговаря обратно на дупката, която той отваря.
2. **Ганцфрид е безопасната и печелившата златна среда.** Срещу *всеки* противник неговият най-лошият случай остава на долната граница на Наш (безопасен в рамките на 10^{-3}) **и** той превъзхожда равновесната стойност на Наш при всеки експлоатируем тип - най-ярко **+0.222** срещу **+0.146** на Наш срещу alwaysPass и +0.131 срещу +0.118 срещу маниак. Това е резултатът, който стъпката съществува, за да произведе: *можете да експлоатирате смислено, като доказуемо никога не падате под равновесната стойност.*
3. **Един глобален p не е настройка за безопасност.** rn timer_0.5 е безопасен срещу камък, но



Фигура 5: Methods versus the Rock on Kuhn: green is EV against the opponent, red is worst-case value, the dashed line is the Nash floor. Only the full best response's worst-case (red) plunges to -0.5 , far below the floor; every principled method hugs the floor while still exploiting.

вече е скочил до пълния най-добър отговор срещу силно експлоатируемите alwaysPass / AlwaysBet (идентична стойност с full_br, най-лошият случай $-0.33 / -0.17$, експлоатируем). Това е §5 праг „включено–изключено“, който се движи с експлоатируемостта на противника - и конкретната причина Ганцфрид, който ограничава стойността, а не копче, да бъде по-добрият примитив.

Безопасен спрямо прайм и адаптацията изразходват предвидения ϵ -бюджет. Те понижават долната граница от v^* до $v^* - \epsilon$, а изпълнението измерва експлоатируемостта на базовата линия с ранно прекратен CFR при $\epsilon = 0.0074$; техният най-лош случай излиза $-0.063 = v^* - 0.008$ срещу всеки противник, съответствайки на долната граница, коригирана с ϵ . Изразходвайки този бюджет, те печелят малко повече от ганцфрид ($+0.266$ спрямо $+0.222$ на AlwaysPass). Те изглеждат „експлоатируеми“ в таблицата само защото флагът се сравнява с v^* ; спрямо тяхната собствена долна граница те са безопасни по конструкция. (Безопасен спрямо прайм и адаптацията съвпадат тук, защото за тази базова линия [MATH15] - двете долни граници са буквално равни, което изпълнението потвърждава, а не е грешка.)

Бележка за резолюцията на измерването, защото това ме ухапа. В smoke изпълнението (30,000 CFR итерации) дори стратегията на Наш е маркирана като „експлоатируема“ - нейният най-лошият случай е -0.0568 , т.е. 0.0013 под точната стойност

v^* , малко над допустимата стойност 10^{-3} . Това е чиста грешка на приближението, а не провал в безопасността: при по-голям мащаб (200,000 итерации) недостигът спада до 3×10^{-4} и Наш правилно е маркиран като безопасен. Урокът за тестовата среда е, че допустимата стойност на флага за безопасност трябва да надвишава собствената грешка на приближението на базовата линия, в противен случай базовата линия ще „спъне“ собственения си тест.

Прочетете повече: Ganzfried, S. & Sandholm, T. (2015), *op. cit.* - Theorem 1 is exactly the guarantee this table exhibits on Kuhn (най-лошият случай $\geq v^*$), and its minimax step is the 2-player-zero-sum dependency of §3.

8.7 7. Безопасност в реално време - под-игра джаджи (SES)

Гаранцията на ганцфрид е *глобална*: ограничението за безопасност се прилага върху **цялото** дърво на играта. Това е приемливо при Кун, но в реална игра не можете да преизчислявате цялото дърво всеки път, когато моделът се актуализира. Идеята за **търсене на безопасна експлоатация** (Liu и др. 2022) прави безопасността **локално** свойство на една единствена **под-игра**: играйте нашия план навсякъде, но в избрана под-игра оптимизирайте отново играта на героя, за да експлоатира модела - с **приспособление**, което гарантира, че локалното отклонение никога не може да направи героя по-зле *глобално* от плана.


В последователна форма приспособлението се реализира директно върху treeplex: **фиксирайте** всяка последователност от герои *извън* под-играта към теглото на реализацията на плана (така че героят играе плана навсякъде, освен в под-играта) и задайте прага на безопасност на най-лошата стойност на самия план. Тъй като „играйте плана също вътре в под-играта“ винаги е възможно и достига точно този праг, линейното програмиране може само да се справи поне толкова добре - локалната експлоатация е безопасна по конструкция. Единственото изискване е под-играта да бъде **надолу-затворена** (веднъж щом сте в нея, оставате в нея), което важи за естествени избори като „Ледюк кръг 2“ или „след като се падне поп“.

Значението на „локално“ не е само въпрос на естетика; §8 показва, че именно то определя дали решаването ще **успее** или няма да успее.


Прочетете повече: Liu, W. и др. (2022). “Safe Opponent-Exploitation Subgame Refinement.” *NeurIPS* (приспособлението). · Ge, Z. и др. (2024), *op. cit.* - OX-Search ограничава загубата от експлоатация *по информационно множество*, като по този начин укрепва същата идея срещу атаки тип „обучение“. · Miles, D., Kovařík, V. & Lisý, V. (2025). “Adapting Beyond the Depth Limit,” *arXiv:2501.10464* - използване на информация от модел на противника *отвъд* хоризонта на търсене.

GLOBAL safety (Ganzfried / prime-safe / adaptation)

LOCAL safety (SES subgame gadget)



*Leduc: capped at 40 iters, NOT converged
worst-case -0.64 .. -1.33 (grossly unsafe)*



*Leduc: converged in 194-350 iters
worst-case ~ -0.13 (near-safe), +0.25..+0.68 vs weak types*

Фигура 6: Global versus local safety. Global methods re-solve the whole tree; on Ледюк their constraint-generation loop did not converge within the iteration budget and left grossly unsafe strategies. The subgame method pins play outside a chosen subgame to the blueprint and re-solves only that subgame with a gadget - a far smaller problem that did converge and stayed near-safe.

8.8 8. В мащаб - Кун работи; Ледюк се разпада глобално, но се задържа локално

Ледюк Холдем добавя втори рунд за залози и една обща карта - приблизително два порядъка повече ситуации от Кун, все още точно решими, но достатъчно големи, за да натоварят методите. Изпълнението за Ледюк използваше конфигурация с ограничен брой итерации (брой итерации 40 в цикъла на генериране на ограничения, допустима стойност 10^{-2} и под-играта зададена на крал-флоп), като записваше за всяка клетка дали решаването е **сходимо** или е достигнало лимита. Стойност на играта $v^* = -0.086$.

Опонент	метрика	nash	full_br	ses_subgame	ganzfried	prime_safe / adaptation
Камък	EV	+0.201	+0.937	+0.247	+0.624	+0.635
	най-	-0.089	-1.633	-0.130	-0.838	-0.744
	лошият					
	случай					
	сходим?	✓	✓	✓ (194 итерации)	✗ достигнат лимит	✗ достигнат лимит
Маниак	EV	+0.438	+2.177	+0.682	+1.806	+1.842
	най-	-0.089	-1.100	-0.130	-0.638	-0.657
	лошият					
	случай					

Опонент	метрика	nash	full_br	ses_subgame	ganzfried	prime_safe / adaptation
CallingStatBot	сходим?	✓	✓	✓ (211 итерации)	✗ достигнат лимит	✗ достигнат лимит
	най-лошият случай	+0.559	+1.464	+0.663	+1.342	+1.363
	сходим?	✓	✓	✓ (350 итерации)	✗ достигнат лимит	✗ достигнат лимит
	най-лошият случай	-0.089	-1.000	-0.130	-0.915	-0.686
	сходим?	✓	✓	✗ (400 итерации)	✗ достигнат лимит	✗ достигнат лимит
LoosePassiveEV	сходим?	✓	✓	✓ (350 итерации)	✗ достигнат лимит	✗ достигнат лимит
	най-лошият случай	+0.449	+1.405	+0.559	+1.306	+1.309
	сходим?	✓	✓	✗ (400 итерации)	✗ достигнат лимит	✗ достигнат лимит
	най-лошият случай	-0.089	-4.200	-0.133	-1.239	-1.334
	сходим?	✓	✓	✗ (400 итерации)	✗ достигнат лимит	✗ достигнат лимит

Основната констатация е отрицателна и емпирична: глобалната безопасна експлоатация не се мащабира, дори до Ледюк. Предвидих, че ганцфрид ще бъде безопасен на Ледюк, както е на Кун. Вместо това **глобалните** решаващи (ganzfried, prime_safe, adaptation и rnr_0.5) всички **достигнаха лимита от 40 итерации без да сходят**, оставяйки стойности за най-лошия случай от **-0.64 до -1.33** - грубо небезопасни. Причината, която потвърдих, вместо да предполагам: цикълът с равнини на сечение добавя по един съперников срез на итерация и при по-голямото дърво на Ледюк множеството от релевантни чисти най-добри отговори е голямо, така че 40 среза изобщо не фиксират истинския най-лош случай; главната линейна програма продължава да връща оптимистични, но небезопасни стратегии. Това беше маркирано като номер едно „вероятно ще се счупи“ елемент *преди* изпълнението и точно там се счупи.

Положителната половина е методът на под-играта. SES **сходи** при трима от четиримата експлоатируеми опоненти (194–350 итерации), тъй като пререшава само малката под-игра „крал-флоп“, като останалата част от дървото е фиксирана - значително по-малка линейна програма с далеч по-малък съперников набор. Той извлича реална **стойност (+0.25 до +0.68)** спрямо слабите типове, надминавайки **наш равновесие)** при **най-лошия случай** от ≈ -0.13 , което е с порядък по-близо до **безопасност** в сравнение с глобалните методи. Това е разграничението *глобална срещу локална безопасност* от §7, което се проявява като измерима констатация върху игра толкова малка като **Ледюк** - конкретният аргумент за методите за под-игри в реално време и против наивно глобално решаване.

Оставам честен към себе си относно SES: неговата остатъчна експлоатируемост (≈ 0.043) все още надвишава допустимата стойност от 0.01, така че и той е маркиран като небезопасен, а при


LoosePassive изпълни пълните 400 итерации без **сходимост**. Дали този остатък от 0.04 представлява приспособлението, което легитимно се ограничава до вече под- v^* план (най-лошият случай на самото **наш равновесие** е -0.089 , което е с 0.003 под v^*), артефакт от толерантността при **сходимост** или малко изтичане във външното поддеревно фиксиране е основният въпрос за разрешаване, преди SES да бъде обявен за **доказуемо безопасен**.

8.8.1 Обучаващата атака - и защо осъществената печалба е погрешен критерий

Последният експеримент е стрес тест за измама, който цялата система за безопасност трябва да издържи. Измамлив опонент играе слабата примамка „камък“ в продължение на 10,000 раздавания, след което преминава към силно „наш равновесие“ „разкриване“ за още 10,000; моделът от Стъпка 7 подава всеки решаващ на всеки 500 раздавания (5 семена).

метод	средна стойност/ръка (всички)	средна стойност/ръка (след преминаване)	нарушения на безопасността / начално число
full_br	+0.051	-0.061	40, 40, 40, 40, 40
ganzfried	-0.048	-0.055	0, 0, 0, 0, 0
адаптация	-0.046	-0.055	40, 40, 40, 40, 40
наш равновесие	-0.051	-0.061	0, 0, 0, 0, 0

Наивният разказ - „обучаващата атака наказва алчния експлойтър“ - **не се потвърди по отношение на осъществената печалба**, а разбирането защо е поучително. Пълният най-добър отговор завършва *значително положително* ($+0.051$ /ръка общо): той реализира неочаквана печалба по време на фазата с примамката и, тъй като „разкриването“ е само *Нашов* опонент, този опонент успява да си върне едва малко повече от стойността на играта на ръка, така че неочакваната печалба никога не се възстановява в рамките на 10,000 ръце. Сигналът, който *наистина* отличава безопасните от небезопасните методи, е **точният най-лош случай / брой нарушения на безопасността**: пълният най-добър отговор наруши долната граница на Наш в **40 от 40** повторни настройки, а Ганцфрид - в **0 от 40**. Най-лошият случай за една стратегия се реализира от опонент, който *дава най-добър отговор спрямо нея* - и стационарното разкриване на равновесието на Наш просто не е такъв противник. Коригиращият извод, в който сега вярвам, че е правилният урок за проектиране: **измервайте безопасността чрез най-лошия случай, а не чрез осъществената печалба срещу добронамерен опонент**; за да накажете алчния експлойтър *по отношение на печалбата*, разкриването трябва да бъде адаптивен контраексплойтър, а не фиксирано равновесие на Наш. (Това, че adaptation показва 40 нарушения, докато nash показва 0, също не е грешка: адаптацията умишлено се насочва към долна граница *под* v^* , така че по дизайн задейства брояча, посочен в v^* .)



Фигура 7: Teaching attack on Kuhn, cumulative profit. The full best response (blue) climbs on the bait to about +1700, then only drifts down after the switch - it ends far ahead, because a Nash “revealer” claws back only about the game value per hand. The safe methods refuse the bait and pay the first-player tax throughout.

8.9 9. Връзки и бъдещи насоки

Какво установява тази стъпка. Безопасното използване представлява една идея - *максимизиране на стойността спрямо модела при спазване на праг на безопасност* - и в напълно решима игра то функционира точно както предвижда теорията: „Ганцфрид“ е безопасен срещу всеки опонент, като същевременно надминава равновесната стойност при всеки експлоатируем такъв, докато наивният най-добър отговор носи повече печалба, но е катастрофално експлоатируем. „Прайм-безопасен“ и „адаптация“ разширяват гаранцията към неперфектните базови нива, присъщи на всяка реална система, като изразходват *измерен ϵ -бюджет* под стойността на играта. Но най-ценният резултат от тази стъпка е отрицателен и емпиричен: дори в игра с малък размер като „Ледюк“ глобалното решаване на задачата за безопасна експлоатация не сходява в рамките на практически бюджет, докато локалният метод на под-играта успява - разликата между глобалната и локалната безопасност от теория към практика, измерена, а не просто заявена.

Обратни връзки. Тази стъпка представлява точния комплемент на предходната работа върху равновесието и моделирането на противника. Сензорът от Стъпка 7 създава модела на противника, който тук се превръща в *цел*; точният най-добър отговор от Стъпка 7 функционира като *предсказвач за най-лош случай*; а представянето в последователна форма от работата върху CFR и съгласува-

ността е *променливата*, която линейното програмиране оптимизира. Емпиричната мотивация за необходимостта от прага на безопасност в тази стъпка произтича от самопричиненото изтичане на непрекъснатия модел спрямо **наш равновесие** в играта **Ледюк** (Стъпка 7, §7) - и действително **ганцфрид** тук никога не изтича към **наш равновесие**.

Напред към дисертацията. Резултатите на Кун потвърждават коректността на изпълнителния механизъм; несходимостта в Ледюк представлява конкретният аргумент за двата мащабируеми пътя, между които дисертацията трябва да избере - **точно еднократно двойно линейно програмиране** за ограничението при най-лошия случай или ангажимент към **локална / под-игра** безопасност (SES, ОХ-търсене) като механизъм в реално време. И в двата случая прагът на безопасност е това, което превръща крехкия сензор от Стъпка 7 в приложим адаптивен агент.

Отворени въпроси за бъдещи изследвания.

- *Мащабируема безопасност.* Заменете цикъла с равнини на сечение с точно двойно линейно програмиране или възприемете изцяло безопасността на под-играта; установете дали глобалните решаващи за Ледюк са просто *бавни* или *структурно* заседнали чрез повторно изпълнение с голям бюджет.
- *Остатъчна експлоатируемост на SES джаджата.* Определете дали разликата от 0.04 над толерантността е ефект на ограничаване от плана, артефакт на толерантност или изтичане при фиксиране - това решава дали методът на под-играта е доказуемо или само приблизително безопасен.
- *Наказваща обучаваща атака.* Заменете разкриването на равновесието на Наш с адаптивен контраексплойтър, така че осъществената печалба да потвърждава най-лошия случай и може да се покаже, че безопасният метод *надминава* алчния при измама.
- *От двама играчи до N .* Всяка гаранция тук се основава на факта за двуигрови игри с нулева сума, че стратегията на Наш осигурява стойността v^* срещу всеки противник - котва, която изчезва за $N > 2$. Намирането на аналог за N играчи (или структурен заместител) е отвореният проблем, който тази стъпка прави прецизен, и сърцевината на Принос №2.

Прочетете повече: Shoham, Y. & Leyton-Brown, K. (2008). *Multiagent Systems*, гл. 7 „Обучение и преподаване“ - повтарящата се игра, в която вашите действия едновременно *експлоатират* и *преподават* на противника, което е точното напрежение, което обучаващата атака (§8) изследва и многоагентното разширение трябва да посрещне.