

Глава 8 Обобщение – Безопасна експлоатация в игри с непълна информация

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните
игри

Alexander Andreev

July 2026

Съдържание

8 Глава 8 – Безопасна експлоатация в игри с непълна информация	1
8.1 Защо безопасната експлоатация – другата половина на скалата	2
8.2 Експлоатацията като оптимизация с ограничения	4
8.3 Какво означава „безопасен“ – три определения с нарастваща степен на реализъм .	6
8.4 Линеино програмиране в последователна форма и генериране на ограничения . . .	8
8.5 Ограничен отговор по Наш и скокообразното превключване	9
8.6 Най-доброто равновесие в Кун – безопасно, но само малко по-печелившо (основни- ят резултат)	12
8.7 Безопасност в реално време – решаване на под-игри (SES)	15
8.8 В мащаб – Кун работи; Ледюк се разпада глобално, но се задържа локално	16
8.9 Връзки и бъдещи насоки	20

8 Глава 8 – Безопасна експлоатация в игри с непълна информация

Тази глава въвежда от самото начало *безопасната* експлоатация на противника: формулировката на проблема, математическият апарат, семейството от методи и набор от контролирани експерименти, проведени върху две малки покер игри. Всички експериментални числа, докладвани тук, са **измерени** при възпроизводими изпълнения на двете тестови среди (Кун покер и Ледюк Холдем) и където е възможно, са поставени в *точни* аналитични граници, а не в симулирани. Когато резултатът противоречи на онова, което теорията ме е карала да очаквам, казвам го изрично и обяснявам разминаването – тъкмо тези разминавания са най-поучителните части на главата.

Къде се вписва това в дисертацията. Глава 7 изгради **сензор**: модел, който наблюдава как даден противник играе и оценява неговата стратегия. Тя също така разкри опасността от наивното действие въз основа на този сензор – най-добрият отговор на уверен, но недообучен модел може да отвори пробив в собствената ви игра (в Ледюк той всъщност *загуби* срещу неексплоатируемия противник „Наш“). Глава 8 изгражда **изпълнителен механизъм**: механизма, който превръща модел в печалба, **без да става експлоатируем**. Този изпълнителен механизъм е втората половина

на рамката за поведенческа адаптация на дисертацията (принос №1), а определянето *точно къде неговите гаранции зависят от предположението за игра с нулева сума за двама играчи* е отправната точка за многоагентното разширение (принос №2).

8.1 Защо безопасната експлоатация – другата половина на скалата

Стратегия в **равновесие на Наш** е изградена така, че никога да не губи в дългосрочен план. В игра с нулева сума за двама играчи тази гаранция е точна: стратегията има фиксирана *стойност* v^* и никой противник, колкото и умен да е, не може да ви свали под нея. Моделирането на противника (Глава 7) ви дава възможността да се *отклоните* от тази безопасна стратегия, за да накажете грешките на конкретен противник. Очевидният начин да реализирате печалба от модел е да изчислите **най-добър отговор** към него и да играете така. Проблемът е, че най-добрият отговор обикновено сам по себе си е **силно експлоатируем**: за да накаже „винаги се отказваш при залог“, той напълно спира да блъфира с определени карти, а по-умен противник – или същият противник, след като спре да се преструва – минава право през отворения пробив.

Представете си **скала**. Ако я завъртите докрай към *безопасност*, ще играете равновесие на Наш: непобедими, но без да наказвате слаб противник. Ако пък я завъртите докрай към *експлоатация*, ще играете чист най-добър отговор на текущата си преценка за противника: максимална печалба, **ако** преценката е вярна и противникът остане на място, но сериозен риск, ако грешите, извадката ви е малка или противникът нарочно ви е подвел (показвал ви е слаб стил, за да ви примамва към голямо отклонение). **Безопасната експлоатация** поставя *ограничител* върху тази скала: можете да се наклоните към експлоатацията колкото желаете, но никога не бива да минавате отвъд точката, в която най-неблагоприятният противник може да ви свали под вашата безопасна базова линия.



Фигура 1: Скалата безопасност–експлоатация с ограничител. Чистото равновесие на Наш е не-експлоатируемо, но „сляпо“; пълният най-добър отговор извлича най-голяма стойност, но носи най-голям риск. Безопасната експлоатация действа между двете крайности, като стойността в най-лошия случай не може да падне под определен праг. Глава 7 изгради сензора (модела), а Глава 8 изгражда изпълнителния механизъм (безопасната експлоатация). Методите се различават единствено по това къде е поставен прагът.

Нуждата от тази граница е нагледно показана в едно число от Глава 7, получено отново и в тази глава: пълният най-добър отговор на стегнатия стил Rock в Кун носи **+0,167 на раздаване**, но стойността му в най-лошия случай е **-0,5** – противник, който на свой ред играе най-добър отговор срещу него, може да му взема по половин жетон на раздаване. Стойността в най-лошия случай при равновесие на Наш, напротив, е самата стойност на играта. Безопасната експлоатация е дисциплината да се вземе от този потенциал толкова, колкото позволяват грешките на противника, без да се поема рискът от -0,5.

Какво означава „безопасен“ в неформален план. Вашата *очаквана стойност за целия мач* никога не бива да пада под избран праг, **независимо какво прави противникът**. Това е твърдение за най-лошия случай, а не за конкретно раздаване – все пак ще губите раздавания; гаранцията се отнася до дългосрочната средна печалба срещу най-неблагоприятния противник. Целият въпрос на дизайна в тази глава е *какъв праг* да бъде избран и как да се изчисли стратегия, която го спазва, като същевременно извлича възможно най-много над него.¹

¹Ganzfried, S. & Sandholm, T. (2015). “Safe Opponent Exploitation.” *ACM Transactions on Economics and Computation* 3(2), статия 8. DOI 10.1145/2716322 – статията, която показва, че в повтаряща се игра за двама с нулева сума отклонението от равновесието може да е безопасно точно когато противникът прави „подаръци“, и дава алгоритми, които рискуват само вече спечеленото; безопасната половина от скалата и основата за Глава 8.

8.2 Експлоатацията като оптимизация с ограничения

Най-полезната идея в тази глава е, че **всеки метод за безопасна експлоатация е една и съща оптимизационна задача**, в която се сменя само една част. С други думи:


максимизиране на очакваната стойност на собствения агент спрямо модела на противника **при ограничение**: стойността му в най-лошия случай да не пада под прага на безопасност.

За да се превърне това в *изчислима* задача, представете стратегията на агента в **последователна форма**, въведена в раздел 7.5 за стратегията на противника: **планът за реализация** x присвоява тегло на всяка от последователностите от действия на агента (поредици от собствените му избори от корена до текущата точка), подчинени на линейните ограничения на **дървовидния политоп** (treeplex): празната последователност има тегло 1; при всяко информационно множество теглата на децата се сумират до теглото на родителя; всички тегла са неотрицателни. Причината да се плати този „данък“ за смяната на променливите е решаваща: срещу **фиксирана** стратегия на противника очакваната стойност на агента е **линейна** по x ,

$$EV(x) = \sum_{z \in Z} [\pi_c(z) \cdot \pi_{-h}(z) \cdot u_h(z)] x_{\text{seq}(z)} = c \cdot x,$$

където Z са крайните състояния, $\pi_c(z)$ е вероятността на случайните ходове, $\pi_{-h}(z)$ - вероятността на ходовете на противника, а $u_h(z)$ - печалбата на агента. Това е така, защото собственото произведение на вероятностите за действие на агента по всеки път e x при последователността на този път. Така „максимизиране на очакваната стойност спрямо модела“ е **линейна целева функция** $c \cdot x$, дървовидният политоп се задава с **линейни ограничения**, а целият метод е **задача на линейното програмиране (LP)**. Пълният най-добър отговор е просто $\max_x c \cdot x$ върху дървовидния политоп – което ни позволява да проверим LP-задачата спрямо кода за точен най-добър отговор от Глава 7 (те съвпадат до 10^{-6}).

Прагът на безопасност е ограничение върху **стойността в най-лошия случай** – „за *всеки* противник σ' , $EV(x, \sigma') \geq \text{праг}$ “. Това вътрешно „за всеки противник“ само по себе си е задача за най-добър отговор (минимакс), поради което не го записваме като една гигантска билинейна задача; решаваме го чрез **генериране на ограничения** (метод на двойния предсказвач / метод на отсичащите равнини): решаваме LP-задачата, прочитаме стратегията на агента, извикваме **точния най-добър отговор като предсказвач за най-лошия случай** и ако стойността в най-лошия случай е под прага, добавяме единственото линейно отсичащо ограничение, което той поражда, и решаваме отново. Процедурата е крайна (съществува краен брой чисти най-добри отговори), прозрачна и лесна за отстраняване на грешки.



Фигура 2: Една LP-задача, пет прага за безопасност. Дървовидният политоп в последователна форма дава линейна целева функция (оачваната стойност срещу модела); цикълът за генериране на ограничения използва точния най-добър отговор като предсказвач за най-лошия случай и добавя отсичащо ограничение, докато прагът не бъде спазен. RNR, най-доброто равновесие (базовият вариант на Ganzfried и Sandholm), prime-safe, SES и адаптацията са ЕДНА И СЪЩА задача с различен праг, а една вече проверена операция (най-добрият отговор от Глава 7) захранва както целевата функция, така и всяка проверка за безопасност.

Концептуалната полза от този подход е икономия: **пет метода, един двигател**. Те се различават единствено по прага, който е предмет на следващия раздел. И тъй като както целевата функция (векторът на печалбата), така и предсказвачът за безопасност използват повторно *проверения* код за най-добър отговор от Глава 7, цялата Глава 8 се основава на една вече проверена елементарна операция, а не на нова поредица от математически изчисления.²

²Shoham, Y. & Leyton-Brown, K. (2008). *Multiagent Systems: Algorithmic, Game-Theoretic, and Logical Foundations*. Гл. 3 (игри в нормална форма); гл. 4 (изчисляване на решения на игри в нормална форма); §4.1 – линейно програмиране за игри с нулева сума; гл. 5 (игри в разгърната форма); §5.2 – игри с непълна информация и последователната форма, механизмът под всяка LP-задача в Глава 8); гл. 7 “Learning and Teaching” – рамката за учене в повтарящи се игри, включително напрежението, че действията едновременно *експлоатират* и *обучават* противника. Свободно достъпна: <http://www.masfoundations.org/download.html>

8.3 Какво означава „безопасен“ – три определения с нарастваща степен на реализъм

„Безопасността“ звучи като абсолютна характеристика, но всъщност не е еднозначна. От значение са три различни определения, а изследователската линия по същество представлява *отслабване* на изискването, за да стане то приложимо в практиката.

(а) Безопасност по Ganzfried и Sandholm (2015): никога да не се печели по-малко от стойността на играта. Определението им се отнася до повтарящата се игра: средно поне v^* на раздаване, каквото и да прави противникът. Тук то се налага на стратегията за всяко отделно раздаване, с точно равновесие на Наш σ^* като базова линия:

$$EV(x, \sigma') \geq v^* \quad \text{за всеки противник } \sigma'.$$

Това е най-силното и най-чистото понятие. То се опира на **теоремата за минимакса**: в игра с нулева сума за двама играчи равновесната стратегия на Наш *гарантира* стойността v^* срещу всеки противник. На прага за всяко отделно раздаване обаче отговарят само равновесните стратегии, затова методът избира онази равновесна стратегия, която печели най-много срещу модела (вариантът „най-добро равновесие“ при Ganzfried и Sandholm; по-нататък методът се нарича **най-доброто равновесие**, в кода ganzfried). Пълните им алгоритми отиват по-далеч: отклоняват се от равновесието, като рискуват само „подаръците“ (грешките на противника), вече спечелени в предходните раздавания. Уловката е в предпоставката: нужно е точно равновесие на Наш, а то е практически неизчислимо във всяка голяма игра.

Какво биха добавили пълните алгоритми. Техният алгоритъм RWYWE (Risk What You’ve Won in Expectation – „рискувай средно спечеленото дотук“) решава при всяко раздаване същата LP-задача, но с праг, понижен до $v^* - k_t$, където k_t е средната стойност на натрупаните дотук подаръци, така че стратегията излиза извън равновесието точно дотолкова, доколкото грешките на противника вече са го платили; BEFFE играе най-доброто равновесие, докато натрупаните подаръци не покрият пълна експлоатация до края на мача. И двата алгоритъма са доказуемо безопасни в повтарящата се игра и могат да експлоатират повече от най-доброто равновесие; реализацията и изпитването им остават за бъдеща работа (RWYWE е естественият базов метод за двама играчи за Принос №2).

(б) Безопасност prime-safe (Jeary & Turrini 2023): корекция за несъвършена базова линия. Всяка реална базова линия е **ϵ -равновесие** (поради абстракция и ограничени изчислителни ресурси – предмет на Глава 4), така че самата тя е експлоатируема в известна степен ϵ . Поради това закрепването към точната v^* е неоправдано; методът prime-safe понижава прага точно с експлоатируемостта на самата базова линия,

$$\text{праг} = v^* - \epsilon, \quad \epsilon = \text{експлоатируемост(базова линия)} \geq 0,$$

т.е. „никога не печели по-малко от стойността в най-лошия случай на стратегията, която така или иначе щеше да играеш“. ε трябва да бъде **измерена**, а не приета наготово – точка, която експериментите приемат буквално.

(в) Безопасност на адаптацията (Ge и др. 2024): да не бъдеш по-експлоатируем от своя план (blueprint). Най-практичното понятие. Една експлоатираща стратегия е *безопасна за адаптация*, ако и само ако

$$\begin{aligned} \text{експлоатируемост}(x) &\leq \text{експлоатируемост}(\text{план}) \\ \Leftrightarrow \text{най-лош случай}(x) &\geq \text{най-лош случай}(\text{план}). \end{aligned}$$

Тъй като планът вече е ε -експлоатируем, това е по-слабо от абсолютния праг на Ganzfried и Sandholm (по-слабо точно с ε) и следователно *постижимо* там, където строгата безопасност не е. Опасността му е огледален образ: ако планът е *ужасен*, „не по-лошо от плана“ се удовлетворява тривиално от почти всичко – така че безопасността на адаптацията има смисъл само при разумна базова линия (отворено изискване, което отбелязвам, вместо да реша).

Таблица 1: Три понятия за безопасност: прагът, който всяко гарантира, какво изисква и къде е слабо.

Понятие за безопасност	Неформален праг	Изисква	Слабост
Ganzfried и Sandholm (2015)	$\geq v^*$	<i>точно</i> равновесие на Наш като базова линия	точното равновесие на Наш е практически неизчислимо в големи игри
Prime-safe (2023)	$\geq v^* - \varepsilon$	измерената експлоатируемост на базовата линия	трябва честно да измерите ε
Адаптация (2024)	$\leq$ експлоатируемостта на плана	произволен план	безсъдържателно, ако планът е лош

8.3.1 Къде се крие предположението за игра с нулева сума за двама играчи – точката, от която тръгва дисертацията

Всеки от горните прагове се основава на един факт: **в игра с нулева сума за двама играчи равновесната стратегия на Наш гарантира стойността v^* срещу всеки противник** ($\min_{\sigma'} \text{EV}(\sigma^*, \sigma') = v^*$). Именно това прави „отклонявай се към модела, но никога под прага“ последователно и приложимо ограничение, което произтича директно от теоремата за минимакса. В игра с $N > 2$ играчи това се срива: равновесната стратегия на Наш *не* гарантира

фиксирана стойност срещу произволни противници (печалбата на отделния противник вече не е равна на вашата със знак минус – в игра с нулева сума това важи само за сумата от печалбите на всички противници, – затова противниците могат да действат координирано срещу вас, а различните равновесия ви носят различни печалби), така че няма единна v^* , към която да се закотви. Равновесията в игри с повече от двама играчи не са „нито единствени, нито неексплоатируеми“.³ Понятия за безопасност при N играчи съществуват, но са или много консервативни (максиминната стойност срещу координирана коалиция⁴), или цел, която по принцип не може да бъде гарантирана (равният дял – справедливата част C/n - доказано не може да бъде осигурен срещу противници с различни фиксирани стратегии⁵). **Това е отвореният проблем за Принос №2** – експлоатация на слаби противници в малки игри с N играчи при ограничена загуба спрямо базова линия, включително срещу противници, действащи в сговор. Тази глава не го решава; тя прави провала *прецизен*, което е точно това, от което се нуждае една глава на дисертация.⁵⁶⁷

8.4 Линеино програмиране в последователна форма и генериране на ограничения

Този раздел описва „как е изградено“. Единствената нова елементарна операция, която главата добавя, е HeroTreeplex, който (i) изброява последователностите на агента и ограниченията на дървовидния политоп (използвайки повторно кода в последователна форма от Глава 7), (ii) изгражда вектора на печалбата c за фиксиран противник чрез едно обхождане на дървото и (iii) решава LP-задачата с ограничение за безопасност с решавача HiGHS на SciPy. Всичко останало е цикълът на генериране на ограничения, който е достатъчно кратък, за да бъде представен изцяло:

```
c_model <- payoff vector of EV vs the opponent model      # linear objective
cuts    <- {}                                             # discovered safety cuts
repeat:
  x <- argmax c_model . x s.t. treeplex(x) and all cuts    # one LP solve
  pol <- behavioral strategy read out of x
  wc <- worst_case_value(pol) # = -(opp. exact BR value): the oracle
  if wc >= floor - tol: return pol # safe: done
  adv <- opponent's exact best response to pol
  add cut c(adv) . x >= floor - slack # valid lower bound on worst case
```

Всяко генерирано ограничение представлява вектора на печалбата спрямо *конкретен* най-добър

³Ge, J., Wang, Y., Li, W. & Jin, C. (2025). “Securing Equal Share: A Principled Approach for Learning Multiplayer Symmetric Games.” *ICML*; arXiv:2406.04201.

⁴Celli, A. & Gatti, N. (2018). “Computational Results for Extensive-Form Adversarial Team Games.” *AAAI* 32(1). DOI 10.1609/aaai.v32i1.11462.

⁵Johanson, M., Zinkevich, M. & Bowling, M. (2007). “Computing Robust Counter-Strategies.” *NIPS 2007*, 721–728 – органиченият отговор по Наш (RNR), настройваемият предшественик на методите по-rope.

⁶Jeary, L. & Turrini, P. (2023). “Safe Opponent Exploitation For Epsilon Equilibrium Strategies.” *arXiv:2307.12338*.

⁷Ge, Z., Xu, Z., Ding, T., Meng, L., An, B., Li, W. & Gao, Y. (2024). “Safe and Robust Subgame Exploitation in Imperfect Information Games.” *ICML*, PMLR 235, 15255–15270.

отговор на противника; то е валидна линейна долна граница на истинския най-лош случай, поради което добавянето на ограничения монотонно затяга релаксираното ограничение за безопасност към действителното. Извеждането на поведенческа стратегия от план за реализация x се извършва чрез съотношението $\beta(I, a) = x_{Ia} / x_{\text{seq}(I)}$ (равномерно в случаите, когато теглото на родителя е приблизително 0).

Единственото, което се различава между петте метода, е стойността на `floor` и, за метода на под-игра (§ 8.7), набор от *фиксиращи тегла*, които задържат играта на агента извън избраната под-игра такава, каквато е в плана. Най-доброто равновесие използва `floor = v*`; `prime-safe` използва `floor = v* - ε`; адаптацията използва `floor = worst_case(blueprint)`; RNR преформулира целевата функция като максимин по параметъра p (§ 8.5).

Една практическа особеност, която си струва да се отбележи (тя доведе до реално отстраняване на грешки при изпълненията): стойността, която *приблизителното* равновесие на Наш постига срещу самото себе си, може да бъде съвсем малко **над** истинската постижима максиминна стойност на играта, така че изискването за точно `ws ≥ floor` може в даден момент да направи LP-задачата недопустима (без допустимо решение) и, при неблагоприятна поредица от отсичащи ограничения, да върне *небезопасна* стратегия. Решението е малък резерв за допустимост в ограниченията (`floor - slack`, като `slack` $\approx 5 \cdot 10^{-4}$, поддържан независим от допустимата грешка при сходимост), така че истинската максиминна стратегия винаги да остава допустима. Това е видът числов детайл, който никога не се появява в научните статии, но решава дали методът всъщност ще върне безопасна стратегия.⁸

8.5 Ограничен отговор по Наш и скокообразното превключване

Един от най-ранните строго обосновани методи, **ограниченият отговор по Наш** (Johanson 2007; близък до ϵ -безопасните стратегии на McCracken и Bowling от 2004 г.), е концептуалният предшественик на всички останали и въвежда *настройваемия параметър*. Неговата идея: да се изчисли равновесието на агента срещу p -**ограничен** противник – такъв, който е принуден да играе фиксирания модел с вероятност p и е свободен да играе противнически с вероятност $1 - p$. При изменение на p от 0 до 1 се проследява път от равновесието на Наш ($p = 0$) до пълния най-добър отговор ($p = 1$). Тъй като свободният компонент дава най-добър отговор на агента, RNR е **максимин**:

$$\text{RNR}(p) = \arg \max_x \left[p \cdot \text{EV}(x, \text{модел}) + (1 - p) \cdot \min_{\sigma'} \text{EV}(x, \sigma') \right],$$

който решаваме със същия метод на отсичащите равнини плюс допълнителна променлива за най-

⁸Идеята за генериране на ограничения / двоен предсказвач идва от McMahan, H. B., Gordon, G. J. & Blum, A. (2003). “Planning in the Presence of Cost Functions Controlled by an Adversary.” *ICML* – общата рецепта за „оптимизиране срещу най-лош случай, който се открива в хода на решаването“.


лошия случай.

Уговорка, която си струва да се запомни. В първоначалните бележки на проекта RNR беше описан като *наивно смесване*, $(1 - p) \cdot \text{Наш} + p \cdot \text{BR}$. Това е полезен интуитивен инструмент, но **не представлява** алгоритъма на Johanson; ние реализирахме *и двата* и ги обозначихме, тъй като в малка игра поведението им е коренно различно. Наивното смесване проследява плавна крива (сивата линия на следващата фигура): печалбата и експлоатируемостта се увеличават почти пропорционално заедно – от равновесието на Наш до пълния най-добър отговор.

Измерената изненада – каноничният RNR превключва скокообразно. Предвидих, че при изменение на p каноничният RNR ще очертае гладка, монотонна граница, която доминира смесването навсякъде. Не е така. В Кун срещу Rock каноничният RNR връща **една и съща безопасна стратегия** за всички $p \in [0, 0,6]$ (EV $-0,044$, експлоатируемост ≈ 0) и след това **преминава направо към пълния най-добър отговор** при $p \approx 0,7$ (EV $+0,167$, експлоатируемост $0,444$). Между изпробваните стойности на p (през $0,1$) няма междинни точки.

Таблица 2: Ограничен отговор по Наш по стойността на параметъра на смесване: каноничната форма срещу наивно смесване.

	каноничен RNR –			наивно
	каноничен RNR –	експлоатируе-	наивно	смесване – экс-
p	EV	мост	смесване – EV	плоатируемост
0,0	-0,044	~0,000	-0,047	0,000
0,3	-0,044	~0,000	+0,017	0,133
0,6	-0,044	~0,000	+0,081	0,266
0,7	+0,167	0,444	+0,103	0,311
1,0	+0,167	0,444	+0,167	0,444



Фигура 3: Границата между експлоатация и безопасност в Кун с работните точки на LP-методите. Каноничният RNR дава само две групи точки (безопасния ъгъл при $p \leq 0,6$ и ъгъла на пълния най-добър отговор при $p \geq 0,7$); сивата линия е доминираното наивно смесване; звездите (най-доброто равновесие и съвпадащите prime-safe и адаптация) са в ефективния безопасен ъгъл, увеличен във вложената графика.

Защо (проверих, преди да се доверя на обяснението). Целевата функция на RNR е **линейна** по x върху **политоп**, така че нейният оптимум е **върх** и сменя върховете само когато p премине през критично съотношение. Политопът на стратегиите в Кун е малък – малко върхове – така че преходът е единичен скок. Гладката крива на Johanson е явление от *големи игри* (много върхове) или идва от варианта *със смещение към данните* (data-biased), който задава отделно p за всяко информационно множество. Наивното смесване изглежда гладко само защото линейно интерполира две фиксирани стратегии – и то е **доминирано в безопасния ъгъл** (при експлоатируемост ≈ 0 LP-методите достигат EV $-0,044$ спрямо $-0,047$ на смесването). Скокообразно обаче е само съответствието между p и стратегията, а не самата граница: смесването на двете RNR стратегии (Johanson и др. дефинират такова смесване) достига всяка точка от отсечката между двата ъгъла, защото очакваната стойност е линейна по смесването, а стойността в най-лошия случай е вдлъбната. При двата намерени върха превключването става при $p \approx 0,68$, а евентуален междинен връх би бил оптимален само за p между $0,6$ и $0,7$ – стойности, които серията не е включвала. В Кун срещу Rock тази

отсечка подобрява наивното смесване само с около 0,002, така че тук изборът *къде* да се отклониш почти не носи предимство пред равномерното смесване; силно вдлъбнати граници Johanson и др. отчитат в голяма абстрахирана игра на Холдем. Малката игра показва друго: p не е плавна скала – стратегията превключва от безопасния връх към BR-върха при праг, който *се измества според това колко експлоатируем е противникът*. Тази последна точка се повтаря в § 8.6: срещу много експлоатируем противник дори $p = 0,5$ вече е след скока.⁹

8.6 Най-доброто равновесие в Кун – безопасно, но само малко по-печелившо (основният резултат)

Централният експеримент решава всеки метод срещу *точен* модел на всеки тип противник и го оценява по **печалба** (EV срещу този противник) и **безопасност** (стойност в най-лошия случай), като прагът на Наш е $v^* = -0,056$ (известната стойност на Кун за първия играч, $\approx -1/18$). Всички числа са точни (пълно дърво) и са от изпълнението в пълен мащаб (*scale*).


Таблица 3: Кун: очаквана стойност и стойност в най-лошия случай за всеки метод срещу всеки противник („най-добро равн.“ е базовият вариант „най-добро равновесие“ на Ganzfried и Sandholm, в кода ganzfried).

Противник	метрика	nash	full_br	rn timer_0.5	най-добро равн.	prime_safe	adaptation
Rock (стегнато-пасивен)	EV	-0,047	+0,167	-0,044	-0,044	-0,040	-0,040
	най-лош случай	-0,056	-0,500	-0,056	-0,056	-0,063	-0,063
Maniac (разпуснато-агресивен)	EV	+0,118	+0,333	+0,278	+0,131	+0,151	+0,151
	най-лош случай	-0,056	-0,167	-0,111	-0,056	-0,063	-0,063
AlwaysBet	EV	+0,113	+0,333	+0,333	+0,115	+0,131	+0,131
	най-лош случай	-0,056	-0,167	-0,167	-0,056	-0,063	-0,063

⁹Johanson, M. & Bowling, M. (2009). “Data Biased Robust Counter Strategies.” *AISTATS*, PMLR 5, 264–271 – прави параметъра p зависим от това колко данни подкрепят всяка част от стратегията – и именно това изглажда границата на практика.

Противник	метрика	nash	full_br	nrnr_0.5	най-добро равн.	prime_safe	adaptation
AlwaysPass (най-експлоатируем)	EV	+0,146	+0,975	+0,975	+0,222	+0,266	+0,266
	най-лош случай	-0,056	-0,500	-0,333	-0,056	-0,063	-0,063
„Наш“ (контролен)	EV	-0,056	-0,055	-0,056	-0,056	-0,055	-0,055
	най-лош случай	-0,056	-0,333	-0,056	-0,056	-0,063	-0,063

(ses_subgame не е показан: в Кун под-играта е цялата игра и методът съвпада с адаптацията. Шестият тип в данните, Thresholdish, дава същата картина: най-доброто равновесие +0,019 срещу +0,015 за Наш.)



Фигура 4: Методите срещу Rock в Кун: в зелено е очакваната стойност срещу противника, в червено – стойността в най-лошия случай, а пунктирът е прагът на Наш. Само при пълния най-добър отговор стойността в най-лошия случай (червено) пада до -0,5, далеч под прага; всички строго обосновани методи остават близо до прага и печелят колкото равновесието или малко повече.

Три основни резултата обобщават тази глава.

1. **Пълният най-добър отговор е поучителният пример.** Той винаги печели най-много срещу фиксиран модел – до **+0,975** срещу AlwaysPass – но стойността му в най-лошия случай се срина до **-0,5**. Това е единственият метод, който е небезопасен срещу *всеки* противник (rng_0.5 е небезопасен срещу три от петте), защото противникът винаги може да отговори с най-добър отговор на уязвимостта, която той създава.
2. **Най-доброто равновесие е безопасно и все пак печели – но съвсем малко.** Срещу *всеки* противник стойността му в най-лошия случай остава на прага на Наш (безопасно в рамките на 10^{-3}) и печели повече от стратегията на Наш срещу всеки експлоатируем тип – най-ярко **+0,222 срещу +0,146 за Наш** срещу AlwaysPass и **+0,131 срещу +0,118** при Maniac. Именно този резултат е целта на главата: *може да се експлоатира, като доказуемо никога не се пада под равновесната стойност* – но печалбата е малка: срещу четирите експлоатируеми типа най-доброто равновесие печели с 0,002–0,076 на раздаване повече от Наш, т.е. 1–9% от онава, което печели пълният най-добър отговор. Печалбата е малка, защото прагът v^* за всяко отделно раздаване допуска само равновесни стратегии (§ 8.3).
3. **Един глобален p не е настройка за безопасност.** rng_0.5 е безопасен срещу Rock, но *вече е скочил* до пълния най-добър отговор срещу силно експлоатируемите AlwaysPass / AlwaysBet (същата стойност като full_br , стойност в най-лошия случай $-0,33 / -0,17$ – небезопасен). Това е прагът на превключване от § 8.5, който се измества според експлоатируемостта на противника – и конкретната причина най-доброто равновесие, което ограничава *стойността*, а не параметър, да е по-добрата основа.

Prime-safe и адаптацията изразходват измерен ϵ -бюджет. Те понижават прага от v^* до $v^* - \epsilon$, а при изпълнението експлоатируемостта на базовата линия (CFR, спрян преждевременно) е *изменена*: $\epsilon = 0,0074$; стойността им в най-лошия случай излиза $-0,063 = v^* - 0,008$ срещу всеки противник, което съответства на коригирания с ϵ праг. Изразходвайки този бюджет, те печелят малко повече от най-доброто равновесие (+0,266 спрямо +0,222 срещу AlwaysPass). Те изглеждат „небезопасни“ в таблицата само защото флагът ги сравнява с v^* ; спрямо *собствения* си праг те са безопасни по конструкция. (Prime-safe и адаптацията съвпадат по конструкция: ϵ се определя като v^* минус стойността на базовата линия в най-лошия случай, така че $v^* - \epsilon$ е точно тази стойност, а реализацията използва една и съща стратегия (CFR, спрян преждевременно) и като базова линия за prime-safe, и като план за адаптацията. Праговете на Jeary и Turrini и на Ge и др. съвпадат винаги, когато двете са една и съща стратегия; разликата е в приложението – алгоритми за цялата игра срещу повторно решаване на под-игри.)¹

Бележка за точността на измерването (сблъсках се с този проблем на практика).

При бързата проверка (*smoke*, 30 000 итерации на CFR) дори стратегията на Наш е маркирана като „небезопасна“ – стойността ѝ в най-лошия случай е $-0,0568$, т.е. 0,0013 под точната стойност v^* , малко над допустимото отклонение 10^{-3} . Това е чиста грешка на приближението, а не провал в безопасността: в пълен мащаб (200 000 итерации) недостигът спада до 3×10^{-4} и Наш правилно е маркиран като безопасен. Урокът за


тестовата среда е, че допустимото отклонение на флага за безопасност трябва да надвишава собствената грешка на приближението на базовата линия, в противен случай базовата линия няма да издържи собствената си проверка.

8.7 Безопасност в реално време – решаване на под-игри (SES)

Гаранцията на най-доброто равновесие е *глобална*: ограничението за безопасност се прилага върху **цялото** дърво на играта. Това е приемливо при Кун, но в реална игра не можете да решавате наново цялото дърво всеки път, когато моделът се актуализира. Идеята за **търсене на безопасна експлоатация** (Liu и др. 2022) прави безопасността **локално** свойство на една единствена **под-игра**: играйте навсякъде плана (равновесието на Наш), но в избрана под-игра оптимизирайте отново играта на агента, за да експлоатира модела – с **приспособление**, което ограничава отгоре колко локалното отклонение може да увеличи експлоатируемостта (границата расте с нивото на експлоатация и с грешката на модела на противника). По-строгата гаранция, използвана тук – никога да не си по-експлоатируем от плана, – е безопасността на адаптацията на Ge и др., която техният метод OX-Search постига при повторното решаване на под-игри.


Реализацията в тази глава налага тази по-строга гаранция директно върху дървовидния политоп: **фиксирайте** всяка последователност на агента *извън* под-играта на теглото, което тя има в плана (така че агентът играе плана навсякъде освен в под-играта), и задайте прага на безопасност равен на стойността в най-лошия случай на самия план. Тъй като „играйте плана и вътре в под-играта“ винаги е допустимо и достига точно този праг, решението на LP-задачата може да бъде само поне толкова добро – локалната експлоатация е безопасна по конструкция. Единственото изискване е под-играта да бъде **затворена надолу** (веднъж влезли в нея, оставате в нея), което важи за естествени избори като „втори рунд в Ледюк“ или „след като се падне поп“.

ГЛОБАЛНА безопасност
(най-добро равновесие / prime-safe / адаптация)



Ледюк: спрени при лимит 40 итерации,
БЕЗ сходимост; най-лош случай
от $-0,64$ до $-1,33$ (силно небезопасни)

ЛОКАЛНА безопасност
(SES: под-игра + приспособление)



Ледюк: сходимост за 194-350 итерации (лимит 400);
най-лош случай $\approx -0,13$ (почти безопасен);
от $+0,25$ до $+0,68$ срещу слабите типове

Фигура 5: Глобална срещу локална безопасност. Глобалните методи решават наново цялото дърво; в Ледюк техният цикъл за генериране на ограничения не достигна сходимост в рамките на лимита от 40 итерации и остави силно небезопасни стратегии. Методът с под-игра фиксира играта извън избраната под-игра според плана и решава наново само нея с приспособление – много по-малка задача, която при лимит 400 итерации достигна сходимост и остана почти безопасна.

Значението на „локално“ не е само въпрос на естетика: § 8.8 показва, че в Ледюк решаването на под-игра достига сходимост в рамките на своя бюджет, а глобалното – не.¹⁰¹¹¹²

8.8 В мащаб – Кун работи; Ледюк се разпада глобално, но се задържа локално

Ледюк Холдем (раздел 3.4) е все още точно решима игра, но достатъчно голяма, за да натовари методите. Изпълнението за Ледюк използваше конфигурация с ограничен брой итерации (лимит от 40 итерации за цикъла на генериране на ограничения, допустимо отклонение 10^{-2} и под-игра,

¹⁰Liu, M., Wu, C., Liu, Q., Jing, Y., Yang, J., Tang, P. & Zhang, C. (2022). “Safe Opponent-Exploitation Subgame Refinement.” *NeurIPS* – търсене на безопасна експлоатация (SES) с приспособление; добавената експлоатируемост е ограничена отгоре (теорема 4.1).

¹¹Ge, Z. et al. (2024), *op. cit.* – OX-Search: повторно решаване на под-игри с приспособление, което гарантира, че експлоатируемостта не надвишава тази на плана (безопасност на адаптацията, теорема 4.3); може да се прилага вложено при всяко ново информационно множество и е насочено срещу противник, който първо „обучава“ модела, а после го експлоатира; изпитано в Ледюк и Flop Hold'em, за двама играчи.

¹²Milec, D., Kovařík, V. & Lisý, V. (2025). “Adapting Beyond the Depth Limit: Counter Strategies in Large Imperfect Information Games.” *AAMAS 2025* (разширено резюме), 2675–2677; arXiv:2501.10464 – използване на информация от модел на противника *отвъд* хоризонта на търсене.

зададена като „поп на масата“), като за всяка клетка е записано дали решаването е **достигнало сходимост**, или лимита. Стойност на играта $v^* = -0,086$.

Таблица 4: Ледюк: методът с под-игри срещу глобалните решаващи („ит.“ – итерации; „лимит“ – спрян при лимита от 40 итерации).

Противник	метрика	nash	full_br	ses_subgame	най-добро равн.	prime_safe / adaptation
Rock	EV	+0,201	+0,937	+0,247	+0,624	+0,635
	най-лош случай	-0,089	-1,633	-0,130	-0,838	-0,744
	сходим?	✓	✓	✓ (194 ит.)	✗ лимит	✗ лимит
Maniac	EV	+0,438	+2,177	+0,682	+1,806	+1,842
	най-лош случай	-0,089	-1,100	-0,130	-0,638	-0,657
	сходим?	✓	✓	✓ (211 ит.)	✗ лимит	✗ лимит
Пасивен играч (CallingStation)	EV	+0,559	+1,464	+0,663	+1,342	+1,363
	най-лош случай	-0,089	-1,000	-0,130	-0,915	-0,686
	сходим?	✓	✓	✓ (350 ит.)	✗ лимит	✗ лимит
Разпуснато- пасивен (LoosePassive)	EV	+0,449	+1,405	+0,559	+1,306	+1,309
	най-лош случай	-0,089	-4,200	-0,133	-1,239	-1,334
	сходим?	✓	✓	✗ (400 ит.)	✗ лимит	✗ лимит

Основната констатация е отрицателна и емпирична: при лимит от 40 итерации глобалното решаване не достига сходимост дори в Ледюк. Предвидих, че най-доброто равновесие ще бъде безопасно в Ледюк, както в Кун. Вместо това **глобалните** решаващи (най-доброто равновесие ganzfried, prime_safe, adaptation и rnr_0.5) всички **достигнаха лимита от 40 итерации, без да достигнат сходимост**, оставяйки стойности в най-лошия случай от **-0,64 до -1,33** – силно небезопасни. Причината, която потвърдих, вместо да предполагам: методът на отсичащите равнини добавя по едно отсичащо ограничение на итерация и при по-голямото дърво на Ледюк множеството от релевантни чисти най-добри отговори е голямо, така че 40 отсичащи ограничения изобщо не фиксират истинския най-лош случай; главната LP-задача продължава да връща оптимистични, но небезопасни стратегии. Още *преди* изпълнението това беше отбелязано като най-вероятното слабо място – и методът се провали точно там.

Положителната половина е методът на под-играта. SES достига сходимост при трима от четиримата експлоатируеми противници (194–350 итерации), тъй като решава наново само малката под-игра „поп на масата“, като останалата част от дървото е фиксирана – значително по-малка LP-задача с далеч по-малко множество от отговори на противника. Той извлича реална стойност (+0,25 до +0,68 срещу слабите типове – повече от стратегията на Наш) при стойност в най-лошия случай $\approx -0,13$, което е с порядък по-близо до безопасността в сравнение с глобалните методи. Това е разграничението *глобална срещу локална безопасност* от § 8.7, което се проявява като измерим факт в игра толкова малка като Ледюк – конкретният аргумент за методите за под-игри в реално време и против наивно глобално решаване. Сравнението обаче не е при равни условия: глобалните решавачи са спрени след 40 итерации (около 2,5 s на клетка), а SES е имал лимит 400 и е използвал 194–400 итерации (30–79 s на клетка). Резултатът показва, че глобалният цикъл е бавен и небезопасен *в рамките на този бюджет*, а не че не може да достигне безопасност при по-голям. Глава 14 решава въпроса за мащабирането: нейната еднократно решавана двойствена LP-задача, която заменя цикъла, решава задачата за пълния Ледюк за 0,02–0,04 s, така че препятствието е било в цикъла, а не в глобалната задача.

За SES обаче трябва да се отбележи: неговата остатъчна експлоатируемост ($\approx 0,043$) все още надвишава допустимото отклонение от 0,01, така че и той е маркиран като небезопасен, а при LoosePassive изпълни пълните 400 итерации, без да достигне сходимост. Това нарушение обаче се мери спрямо v^* . Собственият праг на SES е стойността в най-лошия случай на плана – тук това е спряното преждевременно CFR ($-0,120$), а не равновесието на Наш ($-0,089$) – и трите клетки със сходимост са с 0,010 под този праг, т.е. точно на границата на допустимото отклонение 0,01. Следователно SES е спазил своя праг в рамките на допустимото отклонение, а остатъкът се дължи главно на експлоатируемостта на самия план; дали методът е *доказуемо* безопасен, ще покаже повторно изпълнение с по-малко допустимо отклонение.


8.8.1 Обучаващата атака – и защо осъществената печалба е погрешен критерий

Последният експеримент е проверка при измама – изпитанието, което цялата система за безопасност трябва да издържи. Измамлив противник играе слабия стил Rock като примамка в продължение на 10 000 раздавания, след което „разкрива“ силната си игра и още 10 000 раздавания играе равновесие на Наш; на всеки 500 раздавания моделът от Глава 7 подава обновената си оценка на всеки решавач (5 начални числа).

Таблица 5: Обучаващата атака: реализирана печалба и нарушения на безопасността по метод.

метод	средно на раздаване (общо)	средно на раздаване (след смяната)	нарушения на безопасността / начално число
full_br	+0,051	-0,061	40, 40, 40, 40, 40

метод	средно на раздаване (общо)	средно на раздаване (след смяната)	нарушения на безопасността / начално число
най-добро равн. (ganzfried)	-0,048	-0,055	0, 0, 0, 0, 0
adaptation	-0,046	-0,055	40, 40, 40, 40, 40
nash	-0,051	-0,061	0, 0, 0, 0, 0



Фигура 6: Обучаваща атака в Кун, натрупана печалба (изпълнение с начално число 0). Пълният най-добър отговор (синьо) се изкачва до около +1700 по време на примамката и след смяната само бавно слиза – завършва далеч напред, защото „разкриващият“ противник, който играе равновесие на Наш, си връща само около стойността на играта на раздаване. Безопасните методи не се хващат на примамката и през цялото време плащат „данъка“ на първия играч.

Наивният разказ – „обучаващата атака наказва алчния експлоататор“ – **не се потвърди по отношение на осъществената печалба**, а разбирането защо е поучително. Пълният най-добър отговор завършва със *значителна печалба* (+0,051 на раздаване общо): той реализира неочаквана печалба по време на фазата с примамката и, тъй като „разкриващият“ противник е само „Наш“, този противник успява да си върне едва малко повече от стойността на играта на раздаване, така че тази неочаквана печалба не бива върната в рамките на 10 000 раздавания. Сигналът, който *наистина* отличава безопасните от небезопасните методи, е **точната стойност в най-лошия случай / бро-**

ят нарушения на безопасността: пълният най-добър отговор наруши прага на Наш в **40 от 40** повторни настройки, а най-доброто равновесие – в **0 от 40**. Най-лошият случай за една стратегия се реализира от противник, който *играе най-добър отговор срещу нея* – а стационарният противник, който след „разкриването“ играе равновесие на Наш, просто не е такъв противник. Коригираният извод, който сега смятам за правилния урок при проектирането, е: **измервайте безопасността чрез най-лошия случай, а не чрез осъществената печалба срещу безобиден противник**; за да накажете алчния експлоататор *по отношение на печалбата*, разкриващият противник трябва да бъде адаптивен контраексплоататор, а не фиксирано равновесие на Наш. (Това, че adaptation показва 40 нарушения, докато nash показва 0, също не е грешка: адаптацията умишлено се насочва към праг *под* v^* , така че по замисъл задейства брояча, който се отчита спрямо v^* .)

8.9 Връзки и бъдещи насоки

Какво установява тази глава. Безопасната експлоатация е една идея – *максимизиране на стойността спрямо модела при спазване на праг на безопасност* – и в напълно решима игра тя работи точно както предвижда теорията: най-доброто равновесие е безопасно срещу всеки противник и срещу всеки експлоатируем противник печели повече от стратегията на Наш, макар и съвсем малко, докато наивният най-добър отговор носи повече печалба, но е катастрофално експлоатируем. Prime-safe и адаптацията разширяват гаранцията към несъвършените базови линии, присъщи на всяка реална система, като изразходват *измерен* ϵ -бюджет под стойността на играта. Но най-ценният резултат от тази глава е отрицателен и емпиричен: дори в игра с малък размер като Ледюк глобалното решаване на задачата за безопасна експлоатация не достигна сходимост при лимит от 40 итерации, докато локалният метод на под-играта (с лимит 400) достигна – разликата между глобалната и локалната безопасност от теория към практика, измерена, а не просто заявена, макар и при неравни бюджети.

Обратни връзки. Тази глава е точното допълнение на предходната работа върху равновесието и моделирането на противника. Сензорът от Глава 7 създава модела на противника, който тук се превръща в *целева функция*; точният най-добър отговор от Глава 7 служи като *предсказвач за най-лошия случай*; а представянето в последователна форма от работата върху CFR и върху състоятелността (Глава 7) е *променливата*, която LP-задачата оптимизира. Емпиричната мотивация за прага на безопасност в тази глава идва от самонанесената уязвимост на непрекъснатия модел срещу „Наш“ в Ледюк (Глава 7, § 7.7) – и наистина тук най-доброто равновесие никога не губи срещу „Наш“ повече от стойността на играта.

Напред към дисертацията. Резултатите в Кун показват, че изпълнителният механизъм работи според теорията (при точен модел на противника и в игра, която може да се реши точно); липсата на сходимост в Ледюк е конкретният аргумент за двата мащабируеми пътя, между които дисертацията трябва да избере – **точна двойствена LP-задача, решавана еднократно**, за ограничението за най-лошия случай, или избор на **локална безопасност на ниво под-игра** (SES, OX-Search)

като механизъм в реално време; Глава 14 избра първия път (пълният Ледюк за 0,02–0,04 s). Първото допълнение е собственият алгоритъм на Ganzfried и Sandholm, който рискува натрупаните подаръци (RWYWE, § 8.3) – по-силният базов метод за двама играчи за Принос №2; той изисква само съществуващата LP-задача с праг, който се мени според натрупаните подаръци, а реализирането му остава за бъдеща работа. И в двата случая прагът на безопасност е това, което превръща крехкия сензор от Глава 7 в приложим адаптивен агент.