

# Стъпка 8 Обобщение — Безопасно експлоатиране в игри с непълна информация

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

## Съдържание

|          |                                                                                                   |          |
|----------|---------------------------------------------------------------------------------------------------|----------|
| <b>8</b> | <b>Стъпка 8 — Безопасна експлоатация в игри с непълна информация</b>                              | <b>1</b> |
| 8.1      | 1. Защо безопасната експлоатация — другата половина на скалата . . . . .                          | 2        |
| 8.2      | 2. Експлоатацията като <b>ограничена оптимизация</b> . . . . .                                    | 3        |
| 8.3      | 3. Какво означава „безопасен“ — три определения с нарастваща степен на реализъм . . . . .         | 5        |
| 8.4      | 4. Двигателят — линейно програмиране в последователна форма и генериране на ограничения . . . . . | 6        |
| 8.5      | 5. Ограничен отговор по Наш и граница тип „вкл.–изкл.“ . . . . .                                  | 7        |
| 8.6      | 6. Ганцфрид върху кун — безопасен <i>и</i> печеливш (основният резултат) . . . . .                | 10       |
| 8.7      | 7. Безопасност в реално време — под-игра джаджи (SES) . . . . .                                   | 12       |
| 8.8      | 8. В мащаб — кун работи; ледюк се разпада глобално, но се задържа локално . . . . .               | 14       |
| 8.9      | 9. Връзки и бъдещи насоки . . . . .                                                               | 17       |

## 8 Стъпка 8 — Безопасна експлоатация в игри с непълна информация

Това е глава, изградена из основи, за *безопасна* експлоатация на противника: формулировката на проблема, математическият апарат, семейството от методи и набор от контролирани експерименти, проведени върху две малки покер игри. Тя изпълнява две функции — служи като самостоятелно въведение и опресняване, докато по-късните стъпки се надграждат върху него, както и като основен източник за синтеза на дисертацията в Част 1. Написана е така, че да може да бъде прочетена самостоятелно; не се предполага предварителна познатост с кода на проекта. Всички експериментални числа, докладвани тук, са **измерени** при възпроизводими изпълнения на двете тестови среди (кун покер и ледюк холдем) и са ограничени, където е възможно, от *точни* аналитични препратки, а не симулирани такива. Когато дадено изпълнение противоречи на това, което теорията ме е накарала да очаквам, аз го заявявам и го съгласувам — тези пропуски са най-показателните части от стъпката.


**Къде се вписва това в дисертацията.** Стъпка 7 изгради **сензор**: модел, който наблюдава как даден противник играе и оценява неговата стратегия. Тя също така разкри опасността от наивното действие въз основа на този сензор — уверен, но недообучен модел, към който се реагира оптимално, може да отвори дупка в собствената ви игра (в Ледик той всъщност *загуби* срещу неексплоатируем Нашов противник). Стъпка 8 изгражда **изпълнителен механизъм**: механизма, който превръща модел в печалба, **без да става експлоатируем**.

Този изпълнителен механизъм е втората половина на рамката за поведенческа адаптация на дисертацията (принос №1), а определянето *точно къде неговите гаранции зависят от предположението за игра с нулева сума за двама играчи* е отправната точка за многоагентното разширение (принос №2).

## 8.1 1. Защо безопасната експлоатация — другата половина на скалата

Стратегия в **равновесие на Наш** е изградена така, че никога да не губи в дългосрочен план. В **двуйгрова игра с нулева сума** тази гаранция е точна: стратегията има фиксирана *стойност*  $v^*$ , и никой противник, колкото и умен да е, не може да ви свали под нея. **Моделиране на противника** (Стъпка 7) ви дава възможността да се *отклоните* от тази безопасна стратегия, за да накажете грешките на конкретен противник. Очевидният начин да реализирате печалба от модел е да изчислите **най-добър отговор** към него и да играете така. Проблемът е, че най-добрият отговор обикновено сам по себе си е **силно експлоатируем**: за да накаже „винаги пасваш на залог“, той напълно спира да блъфира определени **раздавания**, а по-умен противник — или същият противник, след като спре да се преструва — минава право през отворения пробив.

Представете си **скала**. Ако я завъртите докрай към *безопасност*, ще играете в **равновесие на Наш**: непобедими, но без да наказвате слаб противник. Ако пък я завъртите докрай към *експлоатация*, ще **оптимално отговарям** твърдо на текущото си впечатление: максимална **печалба**, ако впечатлението е вярно и противникът остане на място, но сериозен риск, ако грешите, извадката ви е малка или сте били *сандбегвани* (умишлено подхранвани със слаб стил, за да се предизвика голямо **отклонение**). **Безопасна експлоатация** поставя *регулатор* върху тази скала: можете да се наклоните към експлоатацията колкото желаете, но никога не бива да минавате отвъд точката, в която противник в **най-лошия случай** може да ви свали под вашата **безопасна базова линия**.



Фигура 1: The safety-exploitation dial with a governor. Pure Nash is unexploitable but blind; a full best response extracts the most value but is maximally risky. Safe exploitation operates in between, capped by a floor on the worst-case value. Step 7 built the sensor (the model); Step 8 builds the actuator (safe exploitation). The only thing that differs between methods is where the floor sits.

Причината това да не е параноя е едно число от Стъпка 7 и отново от тази стъпка: пълният **оптимален**

отговор на стегнатия стил „камък“ в кун носи +0,167 на раздаване, но неговият най-лош стойностен случай е −0,5 — противник, който оптимално отговаря обратно, може да вземе половин чип на раздаване от него. Най-лошият случай при равновесие на Наш, напротив, е самата стойност на играта. Безопасна експлоатация е дисциплината да се запази по-голямата част от този +0,167 потенциал за печалба, като същевременно се избягва −0,5 потенциала за загуба.

**Какво означава „безопасен“ в неформален план.** Вашата очаквана стойност за целия мач никога не бива да пада под избран праг, **независимо какво прави противникът**. Това е твърдение за най-лошия случай, а не за конкретно раздаване — все пак ще губите раздавания; гаранцията се отнася до дългосрочната средна стойност при противников подход. Целият въпрос на дизайна в тази стъпка е *какъв праг* да бъде избран и как да се изчисли стратегия, която го спазва, като същевременно извлича възможно най-много над него.

**Прочетете повече:** Ганцфрид, С. & Сандхолм, Т. (2015). „Безопасна експлоатация на противника“. *ACM Trans. Economics and Computation* — статията, която за първи път формулира като теорема принципа „експлоатирай, но никога не губи спрямо базовата линия“.

## 8.2 2. Експлоатацията като ограничена оптимизация

Единствената най-полезна идея в тази стъпка е, че **всеки метод за експлоатация представлява един и същ проблем на оптимизация**, при който се заменя само една негова част. С други думи:

максимизиране на очакваната стойност на героя спрямо модела на противника, **при условие** за праг на безопасност за най-лошия стойностен случай на героя.


За да се превърне това в *изчислима* програма, представете стратегията на героя в **последователна форма**: вместо вероятности за действие според ситуацията, използвайте **план за реализация**  $x$ , който присвоява тегло на всяка от последователностите от действия на героя (вериги от корен до тук от собствените им избори), подчинени на линейните ограничения на **treeplex** (празната последователност има тегло 1; при всяко информационно множество теглата на децата се сумират до теглото на родителя; всички тегла са неотрицателни). Причината да се плати тази „данък“ за смяна на променливите е решаваща: срещу **фиксирана** стратегия на противника, очакваната стойност на героя е **линейна** в  $x$ ,

$$EV(x) = \sum_{\text{terminals } z} [\text{chance}(z) \cdot \text{opp-reach}(z) \cdot u_{\text{hero}}(z)] x_{\text{seq}(z)} = c \cdot x,$$

защото собственото произведение на вероятностите за действие на героя по всяка линия е  $x$  при последователността на тази линия. Така „максимизиране на очакваната стойност спрямо модела“ представлява **линейна цел**  $c \cdot x$ , **treeplex** е множество от **линейни ограничения**, а целият метод е **линейна програма**. Пълният най-добър отговор е просто  $\max_x c \cdot x$  върху **treeplex** — което ни позволява да проверим линейната програма спрямо кода за точен най-добър отговор от Стъпка 7 (те съвпадат до  $10^{-6}$ ).

Прагът на безопасност представлява ограничение върху **най-лошия случай** стойност — „за *всеки* противник  $\sigma'$ ,  $EV(x, \sigma') \geq \text{floor}$ .“ Това вътрешно „за всеки противник“ само по себе си е най-добър отговор (ми-

нимакс), поради което не го записваме като една гигантска билинейна програма; решаваме го чрез **генериране на ограничения** (двойно предсказание / цикъл с равнини на сечение): решаваме линейната програма, прочитаме стратегията на героя, извикваме **точен най-добър отговор като най-лошият случай оракул**, и ако най-лошият случай е под прага, добавяме единственото линейно сечение, което той предполага, и преизчисляваме. Това е крайно (съществува краен брой чисти най-добри отговори), прозрачно и подлежи на отстраняване на грешки.



*one validated primitive (Step 7's exact best response) powers BOTH the objective and every safety check*

Фигура 2: One LP engine, five safety floors. The sequence-form treeplex gives a linear objective (EV vs the model); a constraint-generation loop calls an exact best response as the worst-case oracle and adds a safety cut until the floor is met. RNR, Ganzfried, prime-safe, SES and adaptation are the SAME solve with a different floor — and one validated primitive (Step 7's best response) powers both the objective and every safety check.

Концептуалната полза от този подход е икономия: **пет метода, един двигател**. Те се различават единствено по прага, който ще бъде разгледан в следващия раздел. И тъй като както целта (векторът на печалбата), така и оракулът за безопасност използват повторно *валидирания* най-добър отговор от Стъпка 7, цялата Стъпка 8 се основава на една вече доверена примитивна операция, а не на нова поредица от математически изчисления.

**Прочетете повече:** Shoham, Y. & Leyton-Brown, K. (2008). *Многоагентни системи*, §3.4 (изчисляване на равновесия) и §4.6 (изчисляване на най-добри отговори) — последователната форма на механизма под всяка линейна програма в тази глава.

### 8.3 3. Какво означава „безопасен“ — три определения с нарастваща степен на реализъм

„Безопасността“ звучи като абсолютна характеристика, но всъщност не е еднозначна. От значение са три различни определения, а изследователската линия по същество представлява *отслабване* на изискването, за да стане то приложимо в практиката.

**(а) Сигурност при ганцфрид (2015):** никога да не се печели по-малко от стойността на играта. При *перфектно* нашево равновесие  $\sigma^*$  като базова линия, изискването е

$$EV(x, \sigma') \geq v^* \quad \text{for all opponents } \sigma'.$$

Това е най-силната и най-чистата концепция. Нейното доказателство се основава на **теоремата за минимакс**: в двуигрови игра с нулева сума нашевата стратегия *гарантира* стойността  $v^*$  срещу всеки противник, така че човек може да се отклони към експлоатация на модела в рамките на „хлябината“, създадена от грешките на противника (техните *подаръци*) и никога да не падне под  $v^*$ . Уловката е предпоставката: *перфектно* нашево равновесие, което е неизчислимо във всяка голяма игра.

**(б) Безопасен спрямо прайм /  $\epsilon$ -safety (Jeary & Turrini 2023):** корекция за несъвършена базова линия. Всяка реална базова линия е  **$\epsilon$ -равновесие** (поради абстракция и ограничена изчислителна мощност — предмет на Стъпка 4), така че самата тя е експлоатируема в известна степен  $\epsilon$ . Поради това закрепването към точната  $v^*$  е неоправдано; безопасен спрямо прайм понижава пода с точно експлоатируемостта на самата базова линия,

$$\text{floor} = v^* - \epsilon, \quad \epsilon = \text{exploitability}(\text{baseline}) \geq 0,$$

т.е. „никога не печели по-малко от най-лошия случай на стратегията, която така или иначе щеше да се играе“.  $\epsilon$  трябва да бъде **измерена**, а не предполагаема — точка, която експериментите приемат буквално.

**(в) Безопасност на адаптацията (Ge и др. 2024):** да бъдеш не по-експлоатируем от своя план. Най-практичната концепция. Една експлоатираща стратегия е *безопасна за адаптация*, ако и само ако

$$\text{exploitability}(x) \leq \text{exploitability}(\text{blueprint}) \iff \text{worst-case}(x) \geq \text{worst-case}(\text{blueprint}).$$

Тъй като планът вече е  $\epsilon$ -експлоатируем, това е по-слабо от абсолютната долна граница на Ганцфрид (по-слабо точно с  $\epsilon$ ) и следователно *постижимо* там, където строгата безопасност не е. Опасността му е огледан образ: ако планът е *ужасен*, „не по-лошо от плана“ се удовлетворява тривиално от почти всичко — така че безопасността на адаптацията има смисъл само при разумна базова линия (отворено изискване, което отбелязвам, вместо да реша).

|                               | Неформална долна                 |                                               |                                                     |
|-------------------------------|----------------------------------|-----------------------------------------------|-----------------------------------------------------|
| Понятие за безопасност        | граница                          | Нужди                                         | Слабост                                             |
| Ганцфрид (2015)               | $\geq v^*$                       | едно <i>перфектно</i> нашево референтно ниво  | перфектното нашево равновесие е неизчислимо в мащаб |
| Безопасен спрямо прайм (2023) | $\geq v^* - \varepsilon$         | измерената експлоатируемост на базовата линия | трябва честно да измерите $\varepsilon$             |
| Адаптация (2024)              | $\leq$ експлоатируемост на плана | всеки план                                    | безсмислено, ако планът е лош                       |

### 8.3.1 Къде се крие предположението за игра с нулева сума при двама играчи — атакуващата точка на дисертацията

Всеки от горните прагове се основава на един факт: **в игра за двама с нулева сума, една нашева стратегия гарантира стойността  $v^*$  срещу всеки противник** ( $\min_{\sigma'} \text{EV}(\sigma^*, \sigma') = v^*$ ). Именно това прави „отклонявай се към модела, но никога под прага“ последователно и приложимо ограничение, което произтича директно от теоремата за минимакс. В  $N > 2$ -игрова игра това се срива: нашевата стратегия *не* гарантира фиксирана стойност срещу произволни противници (другите могат да координират действията си и техните печалби вече не се сумират до отрицанието на твоята), така че няма единна  $v^*$ , към която да се закотви. **Това е отвореният проблем за Принос №2** — дали съществува аналог на гаранцията за стойност в  $N$ -игрова игра или структурно предположение (например коалиционна структура) трябва да възстанови опорната точка. Тази стъпка не го решава; тя прави провала *прецизен*, което е точно това, от което се нуждае една глава на дисертация.

**Прочетете повече:** Johanson, M., Zinkevich, M. & Bowling, M. (2007). „Изчисляване на устойчиви контрастратегии.“ *NeurIPS* — Ограничен отговор по Наш, настройваемият предшественик на всички изброени по-горе. · Jeary, J. & Turrini, P. (2023). „Безопасна експлоатация на противника за  $\varepsilon$ -равновесие стратегии,“ *arXiv:2307.12338*. · Ge, Z. и др. (2024). „Безопасна и устойчива експлоатация на под-игра...,“ *ICML*.

## 8.4 4. Двигателят — линейно програмиране в последователна форма и генериране на ограничения

Този раздел описва „как е изградено“. Единствената примитивна операция, която цялата стъпка добавя, е HeroTreeplex, който (i) изброява последователностите на героя и дървовидните ограничения (използвайки повторно кода в последователна форма от Стъпка 7), (ii) изгражда вектора на печалбата  $c$  за постоянен противник чрез едно обхождане на дървото, и (iii) решава линейното програмиране с ограничение за безопасност със решавача HiGHS на SciPy. Всичко останало е цикълът на генериране на ограничения, който е достатъчно кратък, за да бъде представен изцяло:

```

c_model <- payoff vector of EV vs the opponent model      # linear objective
cuts    <- {}                                              # discovered safety cuts
repeat:
  x <- argmax c_model . x s.t. treplex(x) and all cuts      # one LP solve
  pol <- behavioral strategy read out of x
  wc <- worst_case_value(pol)                               # = -(opponent's exact best response) : the oracle
  if wc >= floor - tol: return pol                          # safe: done
  adv <- opponent's exact best response to pol
  add the cut c(adv) . x >= floor - slack to cuts          # a valid lower bound on the worst case

```

Всяко генерирано ограничение представлява вектора на печалбата спрямо *специфичен* най-добър отговор на противника; то е валидна линейна долна граница на истинския най-лош случай, поради което добавянето на ограничения монотонно затяга релаксираното ограничение за безопасност към действителното. Извеждането на поведенческа стратегия от план за реализация  $x$  се извършва чрез съотношението  $\beta(I, a) = x_{Ia} / x_{\text{seq}(I)}$  (равномерно в случаите, когато теглото на родителя е приблизително 0).

Единственото, което се различава между петте метода, е стойността на `floor` и, за метода на под-игра (§7), набор от *цифтове*, които фиксират играта на героя извън избрана под-игра да бъде равна на плана. Ганцфрид използва `floor = v*`; безопасен спрямо прайм използва `floor = v* -`; адаптация използва `floor = worst_case(blueprint)`; RNR преформулира целевата функция като максимин в параметър  $p$  (§5).

**Една практическа особеност, която си струва да се отбележи** (тя доведе до реално отстраняване на грешки при изпълненията): *приблизителната* стойност от самообучението в равновесието на Наш може да бъде съвсем малко **над** истинската постижима максимин стойност на играта, така че изискването за точно `wc floor` може да направи линейното програмиране в крайна сметка недопустимо и, при неблагоприятен път на ограниченията, да върне *небезопасна* стратегия. Решението е малък резерв за допустимост върху ограниченията (`floor - slack`, като `slack = 5 · 10-6`, поддържан независим от допустимата грешка при сходимост), така че истинската максимин стратегия винаги да остава допустима. Това е видът числов детайл, който никога не се появява в научните статии, но решава дали методът всъщност ще върне безопасна стратегия.

**Прочетете повече:** идеята за генериране на ограничения / двойно предсказание води началото си от McMahān, Gordon & Blum (2003), “Планиране в присъствието на функции на разходите, контролирани от противник,” *ICML* — общата рецепта за “оптимизиране срещу най-лош случай, който откривате докато вървите.”

## 8.5 5. Ограничен отговор по Наш и граница тип „вкл.–изкл.”


Най-старият принципен метод, **ограничен отговор по Наш** (Johanson 2007), е концептуалният предшественик на всички останали и въвежда *настройваемия параметър*. Неговата идея: да се изчисли равновесието на героя срещу  $p$ -ограничен противник — такъв, който е принуден да играе фиксирания модел с вероятност  $p$  и е свободен да играе противнически с вероятност  $1 - p$ . Променяйки  $p$  от 0 до 1 се проследява път от

равновесието на Наш ( $p = 0$ ) до пълния най-добър отговор ( $p = 1$ ). Тъй като свободният компонент дава най-добър отговор на героя, RNR е **максимин**:

$$\text{RNR}(p) = \arg \max_x \left[ p \cdot \text{EV}(x, \text{model}) + (1 - p) \cdot \min_{\sigma'} \text{EV}(x, \sigma') \right],$$

която решаваме със същия механизъм с равнини на отсичане плюс допълнителна променлива за най-лошия случай.


**Знаме, което си струва да се запази.** В първоначалните бележки на проекта RNR беше описан като *наивна смеска*,  $(1 - p) \cdot \text{Nash} + p \cdot \text{BR}$ . Това е полезен интуитивен инструмент, но **не представлява** алгоритъма на Johanson; ние имплементирахме *и двата* и ги обозначихме, тъй като в малка игра поведението им е коренно различно. Наивната смеска проследява плавна крива (фигура по-долу, вляво): печалбата и експлоатируемостта се увеличават почти пропорционално заедно — от **наш равновесие** до пълен най-добър отговор.



Фигура 3: The naive Nash/best-response blend on Kuhn: a smooth exploitation-safety frontier where each increment of profit costs a near-proportional increment of your own worst-case loss.

**Измерената изненада — Canonical RNR е изненадващ обрат.** Предвидих, че каноничното обхождане ще бъде гладка, монотонна граница, която доминира смеската навсякъде. Не е така. В играта кун срещу камък, Canonical RNR връща **една и съща безопасна стратегия** за всички  $p \in [0, 0.6]$  (EV  $-0.044$ , експлоатируемост  $\approx 0$ ) и след това **преминава направо към пълен най-добър отговор** при  $p \in (0.6, 1]$  (EV  $0.16$ , експлоатируемост  $\approx 0.44$ ). Няма междинни точки.

|            | Canonical RNR — | Canonical —      | наивна смеска — | наивна —         |
|------------|-----------------|------------------|-----------------|------------------|
| $p$        | EV              | експлоатируемост | EV              | експлоатируемост |
| 0.0        | −0.044          | ~0.000           | −0.047          | 0.000            |
| 0.3        | −0.044          | ~0.000           | +0.017          | 0.133            |
| 0.6        | −0.044          | ~0.000           | +0.081          | 0.266            |
| <b>0.7</b> | <b>+0.167</b>   | <b>0.444</b>     | +0.103          | 0.311            |
| 1.0        | +0.167          | 0.444            | +0.167          | 0.444            |



Фигура 4: The exploitation-safety frontier on Kuhn with the LP operating points. The canonical RNR “curve” is only an interpolation between two achieved clusters (the safe corner and the full-BR corner); the smooth line is the dominated naive blend; the stars (Ganzfried, prime-safe, adaptation) sit at the efficient safe corner.

Защо (проверих, преди да се доверя на историята). Целта на RNR е **линейна** в  $x$  върху един **политоп**, така че нейният оптимум е **връх** и сменя върховете само когато  $p$  пресече критично съотношение. Политопът на стратегиите в кун е малък — малко върхове — така че **преходът се изразява в един-единствен скок**. Гладката крива на Йохансон е феномен от *големи игри* (много върхове) или идва от *данни-ориентирания* вариант, който прави  $p$  за всеки информационен набор. Наивната смеска изглежда гладка само защото линейно интерполира две фиксирани стратегии — и тя е **доминирана в безопасния връх** (при експлоатируемост  $\approx 0$

методите на ЛП достигат EV  $-0.044$  спрямо  $-0.047$  на смеската). Основният извод остава — „избери къде да се отклониш, а не *колко* равномерно“ — но механизмът („гладък RNR циферблат“) е артефакт от големи игри и в малка игра честната картина е дискретен преход от безопасен връх към BR-връх, чийто праг *се измества според това колко експлоатируем е противникът*. Тази последна точка се повтаря в §6: срещу много експлоатируем противник дори  $p = 0.5$  вече е отминал скока.


**Прочетете повече:** Johanson, M. & Bowling, M. (2009). “Data Biased Robust Counter Strategies.” *AISTATS* — прави лоста  $p$  да зависи от това колко данни подкрепят всяка част от стратегията, което е това, което изглажда границата на практика.

## 8.6 6. Ганцфрид върху кун — безопасен и печеливш (основният резултат)

Централният експеримент решава всеки метод срещу *перфектен* модел на всеки **тип противник** и го оценява по **печалба** (EV спрямо този **тип противник**) и **безопасност** (**най-лошият случай**), като подът на **наш равновесие** е  $v^* = -0.056$  (известната първоначална **стойност в кун**,  $\approx -1/18$ ). Всички числа са точни (пълно дърво), от мащабния прогон.

|                                          |                   | наш        |                            |          |                            |            |           |
|------------------------------------------|-------------------|------------|----------------------------|----------|----------------------------|------------|-----------|
| Противник                                | метрика           | равновесие | full_br                    | rnr_0.5  | ганцфрид                   | prime_safe | адаптация |
| <b>Камък</b><br>(стегнат-пасивен)        | EV                | $-0.047$   | <b><math>+0.167</math></b> | $-0.044$ | $-0.044$                   | $-0.040$   | $-0.040$  |
|                                          | най-лошият случай | $-0.056$   | <b><math>-0.500</math></b> | $-0.056$ | $-0.056$                   | $-0.063$   | $-0.063$  |
| <b>Маниак</b><br>(LooseAggr.)            | EV                | $+0.118$   | $+0.333$                   | $+0.278$ | <b><math>+0.131</math></b> | $+0.151$   | $+0.151$  |
|                                          | най-лошият случай | $-0.056$   | $-0.167$                   | $-0.111$ | $-0.056$                   | $-0.063$   | $-0.063$  |
| <b>AlwaysBet</b>                         | EV                | $+0.113$   | $+0.333$                   | $+0.333$ | <b><math>+0.115</math></b> | $+0.131$   | $+0.131$  |
|                                          | най-лошият случай | $-0.056$   | $-0.167$                   | $-0.167$ | $-0.056$                   | $-0.063$   | $-0.063$  |
| <b>AlwaysPass</b><br>(най-експлоатируем) | EV                | $+0.146$   | <b><math>+0.975</math></b> | $+0.975$ | <b><math>+0.222</math></b> | $+0.266$   | $+0.266$  |
|                                          | най-лошият случай | $-0.056$   | $-0.500$                   | $-0.333$ | $-0.056$                   | $-0.063$   | $-0.063$  |

|                                          |                          | наш        |         |              |          |            |           |
|------------------------------------------|--------------------------|------------|---------|--------------|----------|------------|-----------|
| Противник метрика                        |                          | равновесие | full_br | rn timer_0.5 | ганцфрид | prime_safe | адаптация |
| Наш<br>равно-<br>весие<br>(конт-<br>рол) | EV                       | -0.056     | -0.055  | -0.056       | -0.056   | -0.055     | -0.055    |
|                                          | най-<br>лошият<br>случай | -0.056     | -0.333  | -0.056       | -0.056   | -0.063     | -0.063    |



Фигура 5: Methods versus the Rock on Kuhn: green is EV against the opponent, red is worst-case value, the dashed line is the Nash floor. Only the full best response's worst-case (red) plunges to  $-0.5$ , far below the floor; every principled method hugs the floor while still exploiting.

Три основни резултата обобщават тази глава.

1. **Пълният най-добър отговор е поучителната история.** Той винаги печели най-много срещу фиксиран модел — до  $+0.975$  срещу `alwaysPass` — но неговият най-лошият случай се срива до  $-0.5$ . Това е единственият експлоатируем метод в таблицата и той е експлоатируем срещу *всеки* противник, защото противникът винаги може оптимално да отговаря обратно на дупката, която той отваря.
2. **Ганцфрид е безопасната и печелившата златна среда.** Срещу *всеки* противник неговият най-лошият

случай остава на долната граница на Наш (безопасен в рамките на  $10^{-3}$ ) и той превъзхожда равновесната стойност на Наш при всеки експлоатируем тип — най-ярко **+0.222 срещу +0.146 на Наш** срещу alwaysPass и +0.131 срещу +0.118 срещу маниак. Това е резултатът, който стъпката съществува, за да произведе: *можете да експлоатирате смислено, като доказуемо никога не падате под равновесната стойност.*

3. **Един глобален  $p$  не е настройка за безопасност.** `rn_r_0.5` е безопасен срещу камък, но вече е скочил до пълния най-добър отговор срещу силно експлоатируемите alwaysPass / AlwaysBet (идентична стойност с `full_br`, най-лошият случай  $-0.33 / -0.17$ , експлоатируем). Това е §5 прагов контрол „включено/изключено“, който се движи с експлоатируемостта на противника — и конкретната причина на Ганцфрид, който ограничава *стойността*, а не *копче*, да бъде по-добрият примитив.

**Безопасен спрямо прайм и адаптацията изразходват предвидения  $\epsilon$ -бюджет.** Те понижават долната граница от  $v^*$  до  $v^* - \epsilon$ , а изпълнението *измерва* експлоатируемостта на базовата линия с ранно прекратен CFR при  $\epsilon = 0.0074$ ; техният най-лош случай излиза  $-0.063 = v^* - 0.008$  срещу всеки противник, съответствайки на долната граница, коригирана с  $\epsilon$ . Изразходвайки този бюджет, те печелят малко повече от ганцфрид (+0.266 спрямо +0.222 на AlwaysPass). Те изглеждат „експлоатируеми“ в таблицата само защото флагът се сравнява с  $v^*$ ; спрямо тяхната *собствена* долна граница те са безопасни по конструкция. (Безопасен спрямо прайм и адаптацията съвпадат тук, защото за тази базова линия `□MATHI5□` — двете долни граници са буквално равни, което изпълнението потвърждава, а не е грешка.)

**Бележка за резолюцията на измерването, защото това ме ухапа.** В *smoke* изпълнението (30 000 CFR итерации) дори стратегията на Наш е маркирана като „експлоатируема“ — нейният най-лошият случай е  $-0.0568$ , т.е.  $0.0013$  под точната стойност  $v^*$ , малко над допустимата стойност  $10^{-3}$ . Това е чиста грешка на приближението, а не провал в безопасността: при по-голям мащаб (200 000 итерации) недостигът спада до  $3 \times 10^{-4}$  и Наш правилно е маркиран като безопасен. Урокът за тестовата среда е, че допустимата стойност на флага за безопасност трябва да надвишава собствената грешка на приближението на базовата линия, в противен случай базовата линия ще „спъне“ собствения си тест.

**Read more:** Ganzfried, S. & Sandholm, T. (2015), *op. cit.* — Theorem 1 is exactly the guarantee this table exhibits on Kuhn (най-лошият случай  $\geq v^*$ ), and its minimax step is the 2-player-zero-sum dependency of §3.


---

## 8.7 7. Безопасност в реално време — под-игра джаджи (SES)

Гаранцията на ганцфрид е *глобална*: ограничението за безопасност се прилага върху **цялото** дърво на играта. Това е приемливо при кун, но в реална игра не можете да преизчислявате цялото дърво всеки път, когато моделът се актуализира. Идеята за **търсене на безопасна експлоатация** (Liu и др. 2022) прави безопасността **локално** свойство на една единствена **под-игра**: играйте нашия план навсякъде, но в избрана под-игра оптимизирайте отново играта на героя, за да експлоатира модела — с **приспособление**, което гарантира, че локалното отклонение никога не може да направи героя по-зле *глобално* от плана.


В последователна форма приспособлението се реализира директно върху treeplex: **фиксирайте** всяка последователност от герои *извън* под-играта към теглото на реализацията на плана (така че героят играе плана навсякъде, освен в под-играта) и задайте прага на безопасност на най-лошата стойност на самия план. Тъй като „играйте плана също вътре в под-играта“ винаги е възможно и достига точно този праг, линейното програмиране може само да се справи поне толкова добре — локалната експлоатация е безопасна по конструкция. Единственото изискване е под-играта да бъде **надолу-затворена** (веднъж щом сте в нея, оставате в нея), което важи за естествени избори като „ледюк кръг 2“ или „след като се падне поп“.

GLOBAL safety (Ganzfried / prime-safe / adaptation)



Leduc: capped at 40 iters, NOT converged  
worst-case -0.64 .. -1.33 (grossly unsafe)

LOCAL safety (SES subgame gadget)



Leduc: converged in 194-350 iters  
worst-case  $\sim -0.13$  (near-safe),  $+0.25..+0.68$  vs weak types

Фигура 6: Global versus local safety. Global methods re-solve the whole tree; on Leduc their constraint-generation loop did not converge within the iteration budget and left grossly unsafe strategies. The subgame method pins play outside a chosen subgame to the blueprint and re-solves only that subgame with a gadget — a far smaller problem that did converge and stayed near-safe.

Значението на „локално“ не е само въпрос на естетика; §8 показва, че именно то определя дали решаването ще **успее** или няма да успее.

**Прочетете повече:** Liu, W. и др. (2022). “Safe Opponent-Exploitation Subgame Refinement.” *NeurIPS* (приспособлението). · Ge, Z. и др. (2024), *op. cit.* — OX-Search ограничава загубата от експлоатация *по информационно множество*, като по този начин укрепва същата идея срещу атаки тип „обучение“. · Milec, D., Kovařík, V. & Lisý, V. (2025). “Adapting Beyond the Depth Limit,” *arXiv:2501.10464* — използване на информация от модел на противника *отвъд* хоризонта на търсене.

## 8.8 8. В мащаб — кун работи; ледюк се разпада глобално, но се задържа локално

Ледюк Холдем добавя втори рунд за залози и една обща карта — приблизително два порядъка повече ситуации от кун, все още точно решими, но достатъчно големи, за да натоварят методите. Изпълнението за ледюк използваше конфигурация с ограничен брой итерации (брой итерации 40 в цикъла на генериране на ограничения, допустима стойност  $10^{-2}$  и под-играта зададена на крал-флоп), като записваше за всяка клетка дали решаването е **сходимо** или е достигнало лимита. Стойност на играта  $v^* = -0.086$ .

| Опонент                 | метрика          | наш<br>равновесие | full_br       | ses_под-игра        | ганцфрид             | prime_safe /<br>адаптация |
|-------------------------|------------------|-------------------|---------------|---------------------|----------------------|---------------------------|
| <b>Камък</b>            | EV               | +0.201            | +0.937        | <b>+0.247</b>       | +0.624               | +0.635                    |
|                         | най-             | -0.089            | -1.633        | <b>-0.130</b>       | -0.838               | -0.744                    |
|                         | лошият<br>случай |                   |               |                     |                      |                           |
|                         | сходим?          | □                 | □             | □ (194<br>итерации) | □ достигнат<br>лимит | □ достигнат<br>лимит      |
| <b>Маниак</b>           | EV               | +0.438            | +2.177        | <b>+0.682</b>       | +1.806               | +1.842                    |
|                         | най-             | -0.089            | -1.100        | <b>-0.130</b>       | -0.638               | -0.657                    |
|                         | лошият<br>случай |                   |               |                     |                      |                           |
|                         | сходим?          | □                 | □             | □ (211<br>итерации) | □ достигнат<br>лимит | □ достигнат<br>лимит      |
| <b>CallingStationEV</b> | EV               | +0.559            | +1.464        | <b>+0.663</b>       | +1.342               | +1.363                    |
|                         | най-             | -0.089            | -1.000        | <b>-0.130</b>       | -0.915               | -0.686                    |
|                         | лошият<br>случай |                   |               |                     |                      |                           |
|                         | сходим?          | □                 | □             | □ (350<br>итерации) | □ достигнат<br>лимит | □ достигнат<br>лимит      |
| <b>LoosePassiveEV</b>   | EV               | +0.449            | +1.405        | <b>+0.559</b>       | +1.306               | +1.309                    |
|                         | най-             | -0.089            | <b>-4.200</b> | -0.133              | -1.239               | -1.334                    |
|                         | лошият<br>случай |                   |               |                     |                      |                           |
|                         | сходим?          | □                 | □             | □ (400<br>итерации) | □ достигнат<br>лимит | □ достигнат<br>лимит      |

**Основната констатация е отрицателна и емпирична: глобалната безопасна експлоатация не се мащабира, дори до ледюк.** Предвидих, че ганцфрид ще бъде безопасен на ледюк, както е на кун. Вместо това **глобалните** решаващи (ganzfried, prime\_safe, adaptation и rnr\_0.5) всички **достигнаха лимита от 40 итерации без да сходят**, оставяйки стойности за най-лошия случай от **-0.64 до -1.33** — грубо небезопасни. Причината, която потвърдих, вместо да предполагам: цикълът с равнини на сечение добавя по

един съперников срез на итерация и при по-голямото дърво на ледюк множеството от релевантни чисти най-добри отговори е голямо, така че 40 среза изобщо не фиксират истинския най-лош случай; главната линейна програма продължава да връща оптимистични, но небезопасни стратегии. Това беше маркирано като номер едно „вероятно ще се счупи“ елемент *преди* изпълнението и точно там се счупи.

**Положителната половина е методът на под-играта.** SES **сходи** при трима от четиримата експлоатируеми опоненти (194–350 итерации), тъй като пререшава само малката под-игра „крал-флоп“, като останалата част от дървото е фиксирана — значително по-малка линейна програма с далеч по-малък съперников набор. Той извлича реална **стойност** (+0,25 до +0,68 спрямо слабите типове, надминавайки **наш равновесие**) при **най-лошия случай** от  $\approx -0,13$ , което е с порядък по-близо до **безопасност** в сравнение с глобалните методи. Това е разграничението *глобална срещу локална безопасност* от §7, което се проявява като измерима констатация върху игра толкова малка като **ледюк** — конкретният аргумент за методите за под-игри в реално време и против наивно глобално решаване.


*Оставам честен към себе си относно SES:* неговата остатъчна експлоатируемост ( $\approx 0,043$ ) все още надвишава допустимата стойност от 0,01, така че и той е маркиран като небезопасен, а при LoosePassive изпълни пълните 400 итерации без **сходимост**. Дали този остатък от 0,04 представлява приспособлението, което легитимно се ограничава до вече под- $v^*$  план (най-лошият случай на самото **наш равновесие** е  $-0,089$ , което е с 0,003 под  $v^*$ ), артефакт от толерантността при **сходимост** или малко изтичане във външното поддеревно фиксиране е основният въпрос за разрешаване, преди SES да бъде обявен за *доказуемо безопасен*.

### 8.8.1 Обучаващата атака — и защо осъществената печалба е погрешен критерий

Последният експеримент е стрес тест за измама, който цялата система за безопасност трябва да издържи. Измамлив опонент играе слабата примамка „камък“ в продължение на 10 000 раздавания, след което преминава към силно „наш равновесие“ „разкриване“ за още 10 000; моделът от Стъпка 7 подава всеки решаващ на всеки 500 раздавания (5 семена).

| метод          | средна стойност/ръка<br>(всички) | средна стойност/ръка (след<br>преминаване) | нарушения на<br>безопасността /<br>начално число |
|----------------|----------------------------------|--------------------------------------------|--------------------------------------------------|
| full_br        | <b>+0.051</b>                    | -0.061                                     | <b>40, 40, 40, 40, 40</b>                        |
| ганцфрид       | -0.048                           | -0.055                                     | <b>0, 0, 0, 0, 0</b>                             |
| адаптация      | -0.046                           | -0.055                                     | 40, 40, 40, 40, 40                               |
| наш равновесие | -0.051                           | -0.061                                     | 0, 0, 0, 0, 0                                    |

Наивният разказ — „обучаващата атака наказва алчния експлойтър“ — **не се потвърди по отношение на осъществената печалба**, а разбирането защо е поучително. Пълният най-добър отговор завършва *значително положително* (+0,051/ръка общо): той реализира неочаквана печалба по време на фазата с примамката и, тъй като „разкриването“ е само *Нашов* опонент, този опонент успява да си върне едва малко повече от стойността на играта на ръка, така че неочакваната печалба никога не се възстановява в рамките на 10 000



Фигура 7: Teaching attack on Kuhn, cumulative profit. The full best response (blue) climbs on the bait to about +1700, then only drifts down after the switch — it ends far ahead, because a Nash “revealer” claws back only about the game value per hand. The safe methods refuse the bait and pay the first-player tax throughout.

ръце. Сигналът, който *наистина* отличава безопасните от небезопасните методи, е **точният най-лош случай / брой нарушения на безопасността**: пълният най-добър отговор наруши долната граница на Наш в **40 от 40** повторни настройки, а Ганцфрид — в **0 от 40**. Най-лошият случай за една стратегия се реализира от опонент, който *дава най-добър отговор спрямо нея* — и стационарното разкриване на равновесието на Наш просто не е такъв противник. Коригираният извод, в който сега вярвам, че е правилният урок за проектиране: **измервайте безопасността чрез най-лошия случай, а не чрез осъществената печалба срещу добронамерен опонент**; за да накажете алчния експлойтър *по отношение на печалбата*, разкриването трябва да бъде адаптивен контраексплойтър, а не фиксирано равновесие на Наш. (Това, че показва 40 нарушения, докато показва 0, също не е грешка: адаптацията умишлено се насочва към долна граница под  $v^*$ , така че по дизайн задейства брояча, посочен в  $v^*$ .)

---

## 8.9 9. Връзки и бъдещи насоки

**Какво установява тази стъпка.** Безопасното използване представлява една идея — *максимизиране на стойността спрямо модела при спазване на праг на безопасност* — и в напълно решима игра то функционира точно както предвижда теорията: „Ганцфрид“ е безопасен срещу всеки опонент, като същевременно надминава равновесната стойност при всеки експлоатируем такъв, докато наивният най-добър отговор носи повече печалба, но е катастрофално експлоатируем. „Прайм-безопасен“ и „адаптация“ разширяват гаранцията към неперфектните базови нива, присъщи на всяка реална система, като изразходват *измерен  $\epsilon$ -бюджет* под стойността на играта. Но най-ценният резултат от тази стъпка е отрицателен и емпиричен: дори в игра с малък размер като „Ледюк“ глобалното решаване на задачата за безопасно използване не сходява в рамките на практически бюджет, докато локалният метод на под-играта успява — разликата между глобалната и локалната безопасност от теория към практика, измерена, а не просто заявена.

**Обратни връзки.** Тази стъпка представлява точния комплемент на предходната работа върху равновесието и моделирането на противника. Сензорът от Стъпка 7 създава модела на противника, който тук се превръща в *цел*; точният най-добър отговор от Стъпка 7 функционира като *най-лошият случай оракул*; а представянето в последователна форма от работата върху CFR и съгласуваността е *променливата*, която линейното програмиране оптимизира. Емпиричната мотивация за необходимостта от прага на безопасност в тази стъпка произтича от самопричиненото изтичане на непрекъснатия модел спрямо **наш равновесие** в играта **ледюк** (Стъпка 7, §7) — и действително **ганцфрид** тук никога не изтича към **наш равновесие**.

**Напред към дисертацията.** Резултатите на Кун потвърждават коректността на изпълнителния механизъм; несходимостта в Ледик представлява конкретният аргумент за двата мащабируеми пътя, между които дисертацията трябва да избере — **точно еднократно двойно линейно програмиране** за ограничението при най-лошия случай или ангажимент към **локална / под-игра безопасност** (SES, OX-търсене) като механизъм в реално време. И в двата случая прагът на безопасност е това, което превръща крехкия сензор от Стъпка 7 в приложим адаптивен агент.

**Отворени въпроси за бъдещи изследвания.**

- *Мащабируема безопасност.* Заменете цикъла с равнини на сечение с точно двойно линейно програ-

миране или възприемете изцяло безопасността на под-играта; установете дали глобалните решаващи за Ледияк са просто *бавни* или *структурно* заседнали чрез повторно изпълнение с голям бюджет.

- *Остатъчна експлоатируемост на SES джаджата.* Определете дали разликата от 0,04 над толерантността е ефект на ограничаване от плана, артефакт на толерантност или изтичане при фиксиране — това решава дали методът на под-играта е доказуемо или само приблизително безопасен.
- *Наказваща обучаваща атака.* Заменете разкриването на равновесието на Наш с адаптивен контраексплойтър, така че осъществената печалба да потвърждава най-лошия случай и може да се покаже, че безопасният метод *надминава* алчния при измама.
- *От двама играчи до  $N$ .* Всяка гаранция тук се основава на факта за двуигрови игри с нулева сума, че стратегията на Наш осигурява стойността  $v^*$  срещу всеки противник — котва, която изчезва за  $N > 2$ . Намирането на аналог за  $N$  играчи (или структурен заместител) е отвореният проблем, който тази стъпка прави прецизен, и сърцевината на Принос №2.

**Прочетете повече:** Shoham, Y. & Leyton-Brown, K. (2008). *Multiagent Systems*, гл. 7 „Обучение и преподаване“ — повтарящата се игра, в която вашите действия едновременно *експлоатират* и *преподават* на противника, което е точното напрежение, което обучаващата атака (§8) изследва и многоагентното разширение трябва да посрещне.