

Стъпка 9 Обобщение — Многоагентно обучение с подсилване

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Съдържание

9	Стъпка 9 — Многоагентно обучение с подкрепление: координация, конкуренция и комуникация	1
9.1	1. Защо многоагентното обучение с подкрепление е различен проблем	2
9.2	2. Марковски игри — мостът между стъпки 2–8 и MARL	3
9.3	3. Семейството от методи	4
9.4	4. Самостоятелно обучение и неговите режими на провал	7
9.5	5. Централизирано обучение, децентрализирано изпълнение (CTDE)	8
9.6	6. PSRO — теория на игрите върху съвкупност от политики	13
9.7	7. Научена комуникация (commNet)	17
9.8	8. LOLA — моделиране на опонента като учащ се	17
9.9	9. Честни бележки, ограничения и къде това раздаване продължава нататък	18
9.10	Основни изводи за синтеза на дисертацията	20

9 Стъпка 9 — Многоагентно обучение с подкрепление: координация, конкуренция и комуникация

Тази глава е изградена от основи върху многоагентното обучение с подкрепление (MARL): проблемът, който го отличава от всичко преди него, математиката, която го рамкира, семейството от методи, които се използват за решаването му, и набор от контролирани експерименти, проведени в малки, точно решими игри. Тя има две цели — да послужи като самостоятелно опресняване за по-късните стъпки, които се надграждат върху него, и като основен източник за синтеза на дисертацията в Част 1. Написана е така, че да може да бъде прочетена независимо; не се предполага предварително запознаване с кода на проекта. **Всички експериментални числа, представени тук, са измерени** при възпроизводими изпълнения на тестовите среди и, където това е възможно, са ограничени от *точни* аналитични препратки (наш равновесия, точни стойности на най-добър отговор), а не от други симулации. Когато дадено изпълнение противоречи на очакванията, произтичащи от теорията, запазвам първоначалното предварително убеждение и го съгласувам с получения резултат — тези разминавания са най-поучителните части от стъпката.

Къде се вписва това в дисертацията. Стъпки 2–8 съществуват изцяло в рамките на **двуигрови игри с нулева сума**: има стойност v^* , нашава стратегия я осигурява срещу *всеки* противник и CFR доказуемо се сближава към нея. Стъпка 9 е повратната точка към **многоагентния** свят, където тези три удобства отслабват

или изчезват. Тя съдържа три теза. **LOLA** — диференциране през *стъпката на обучение* на противника — е *динамично* моделиране на противника, допълнение към статичното четене от Стъпка 7 (Принос №1). **PSRO** — игра, която се играе върху *популация от стратегии* — едновременно представлява рамката за безопасна експлоатация, когато няма теорема за минимакс (Принос №2), и обща многоагентна *методология за оценяване* (Принос №3). Мястото, където всяка двуйгрова гаранция се нарушава — липсващата минимакс котва за $N > 2$ — е названо тук и оставено отворено за атака от дисертацията.

9.1 1. Защо многоагентното обучение с подкрепление е различен проблем


В single-agent RL (Стъпки 1 и 6) един агент се учи чрез проба и грешка в **непроменяща се** среда. Формално той се изправя пред стационарен марковски процес на вземане на решения: законът за преход $P(s' | s, a)$ и наградата $R(s, a)$ не се изменят по време на обучението, което позволява да съществува фиксирана оптимална стойностна функция Q^* , към която агентът сходява. В Стъпки 2–8 ние преминахме към едно по-високо ниво и изчислихме **равновесия** — стратегии, които са оптимални срещу *съвършено рационален* противник, който вече е завършил своите разсъждения.

Многоагентното обучение с подкрепление се намира между тези два подхода и е по-трудно и от двете. Няколко агента **се учат едновременно в споделена среда**, така че от гледната точка на всеки един агент „средата“ — която вече *включва и другите агенти* — **непрекъснато се изменя**, докато всички се обновяват. Това е **нестационарност** и тя нарушава предположението, което стои в основата на single-agent RL. От гледна точка на агент i ефективният преход и награда зависят от политиките π_{-i} на другите агенти, а те се променят при всяко обновяване, така че целта Q^* , която агент i преследва, самата тя е в движение. Това също така поражда два проблема, които просто не съществуват за самостоятелен агент: **координация** (как си сътрудническите агенти се учат да действат заедно, без да им бъде казано как?) и **разпределяне на заслугата** (когато отборът успее, чии действия са имали значение?).

Картина, която да запомните: **учене на танц с партньор, който също се учи да танцува**. Ако стъпките на вашия партньор бяха фиксирани, бихте могли да запаметите рутина, която им подхожда — това е single-agent RL. Ако вашият партньор беше безупречен професионалист, бихте могли да изучите известния му стил и да се подготвите с перфектен отговор — това е изчисляване на равновесие. Но когато *и двамата* се подобряват в реално време, всяка промяна, която правите, променя това, което другият трябва да направи, и обратното; вие си стъпвате един на друг по краката, прекоригирате и осцилирате — докато или не се заключите в споделен ритъм (координирано равновесие), или циклирате завинаги (както в игра „хвърляне на монета“, §4). Цялата област е изкуството да *подредите картите така, че синхронизацията да се случва надеждно*.

Прочетете още: Zhang, K., Yang, Z. & Başar, T. (2021). “Multi-Agent Reinforcement Learning: A Selective Overview of Theories and Algorithms.” *Handbook of RL and Control* — §1–2 за нестационарността и таксономията, използвана тук.

Single-agent RL assumes a fixed world; here the 'world' is a partner who is also learning.



Фигура 1: Non-stationarity as two partners learning to dance at once. Each agent optimizes against the other's current policy (the solid arrows), but that policy is itself moving because the other agent is optimizing back (the dashed arrows). The target each one chases is never still, so naive learners cycle or over-correct rather than converge. Every method in this chapter is a different way to make the moving target hold still long enough to learn against.

9.2 2. Марковски игри — мостът между стъпки 2–8 и MARL

Стъпки 2–8 разсъждаваха върху **игри в екстензивна форма (EFGs)**: дърво на играта, **множества информация**, групиращи истории, които играчът не може да различи, и контрафактични стойности, подавани към решавач за съжаление (CFR). Стъпка 9 разсъждава върху **Марковски (стохастични) игри**, стандартната формализация на MARL. Двете се свързват чисто и изясняването на тази връзка е това, което не позволява преминаването да изглежда като започване отначало.

Една **Марковска игра** е наредената n -торка

$$(\mathcal{S}, \{\mathcal{A}_i\}_{i=1}^N, P, \{R_i\}_{i=1}^N, \{\Omega_i\}, O, \gamma),$$

с множество състояния $s \in \mathcal{S}$, по едно множество действия $\mathcal{A}_i$ за всеки агент, закон за преход $P(s' | s, a_1, \dots, a_N)$, управляван от **съвместното** действие, награди на агент $R_i(s, a_1, \dots, a_N)$ и (при частично наблюдавания случай) наблюдения $o_i = O_i(s)$. Всеки агент има стратегия $\pi_i(a_i | o_i)$; заедно те формират **съвместна стратегия** $\pi = (\pi_1, \dots, \pi_N)$. Специалните случаи са именно предишните стъпки:

- $N = 1$ възстановява обикновено **MDP** (Стъпка 1).
- $N = 2, R_1 = -R_2$, едно състояние води до **матрична игра** (тестовата среда на тази стъпка, §4).
- Последователна игра с **непълна информация** и игра с **нулева сума** дава **EFG** (Стъпки 2–8): Markov игра, при която „състоянието“ е *история*, а **частичната наблюдаемост** се изразява чрез **информа-**

ЦИОННО МНОЖЕСТВО.

Какво преминава през моста е *речникът*. Политиката все още съпоставя това, което знаеш, с разпределение върху действията, така че поведенческата стратегия на EFG в информационно множество е точно политиката на марковска игра $\pi_i(a_i \mid o_i)$; информационното множество се превръща в наблюдението o_i ; а контрафактичната стойност на история става оценка на централизиран оценител в състояние. Това, което **не** преминава през моста, са *гаранциите*. Контрафактичното разлагане на CFR изисква дърво и пълна памет, които общите марковски игри (цикли, едновременни ходове, $N > 2$) не предоставят, така че „средна стратегия $\rightarrow$ Наш“ вече не важи; MARL се връща към обучение чрез градиент/стойност, чиято сходимост не е гарантирана (оттук и цикличността в §4). Най-съществено, **котва на минимакс стойността** изчезва: в двуговни игра с нулева сума нашата стратегия гарантира v^* срещу всеки противник — фактът, който направи безопасната експлоатация в Стъпка 8 последователна — и за $N > 2$ няма такава единична стойност. Тази липсваща котва е точната празнина, която Принос #2 наследява.

Прочетете повече: Littman, M. L. (1994). “Markov Games as a Framework for Multi-Agent Reinforcement Learning.” *ICML* — статията, която въведе тази рамка и алгоритъма minimax-Q.

9.3 3. Семейството от методи

Всеки метод на този етап представлява различно структурно решение на въпроса „другите агенти се учат, докато аз се уча“. Тук са от значение пет основни **семейства**.

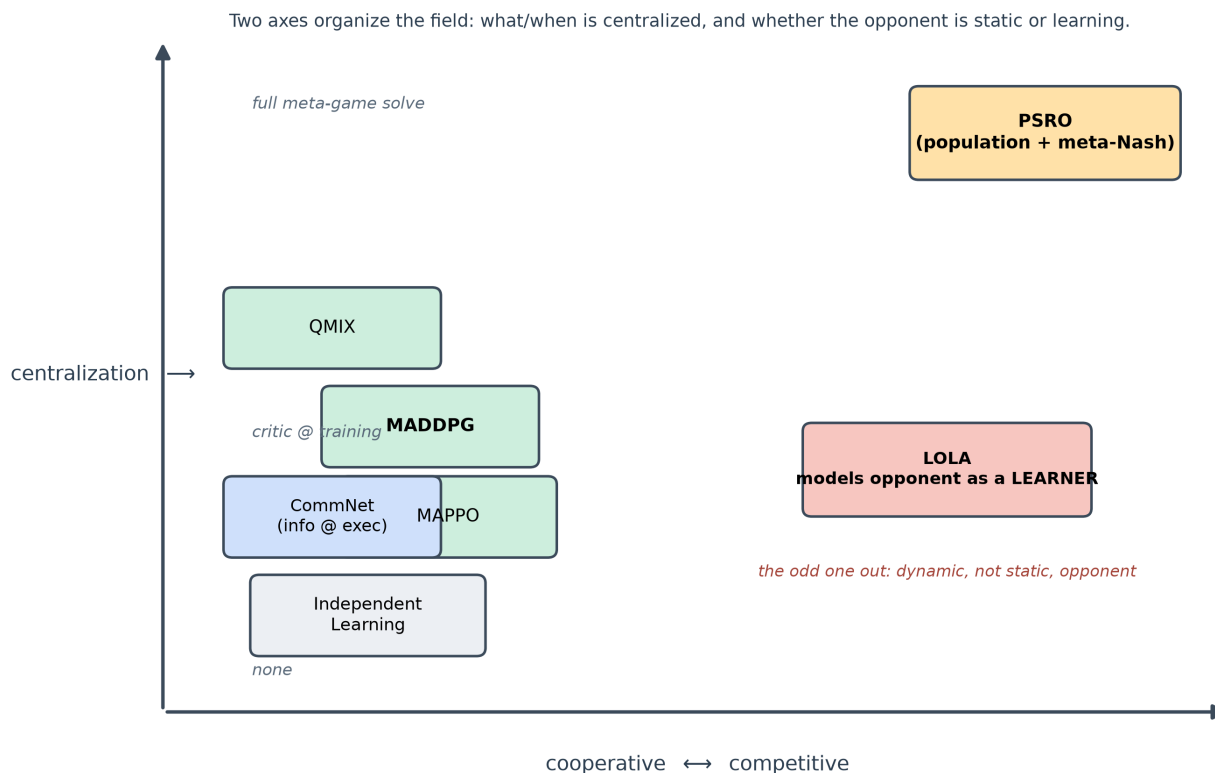
Подход	Какво прави	Кога да го използвате	Основна слабост
Самостоятелно обучение (IL)	всеки агент изпълнява свое собствено single-agent RL, третирайки останалите като среда	бърза базова линия; почти стационарни настройки	нестационарност $\rightarrow$, цикличност, координационен провал
MADDPG (CTDE)	критикът на всеки агент вижда obs+действията на всички агенти по време на обучението; всеки актьор вижда само своите obs при изпълнение	смесени кооперативно-конкурентни задачи; каноничният CTDE шаблон	входът на критика нараства с N ; актьорското обновяване е сложно за настройка
MAPPO (CTDE)	обикновен PPO с централизирана стойност $V(\text{global state})$ и споделени параметри	кооперативен MARL, когато искате проста и надеждна базова линия	цена на on-policy извадката; „прост“, но чувствителен към настройка

Подход	Какво прави	Кога да го използвате	Основна слабост
PSRO	поддържайте съвкупност от политики; решавайте мета-Наш върху нея; обучете най-добър отговор към тази смес; добавете го; повторете	конкурентни/обща игра; когато искате игровитеоретична цел на сходимост	пълнен най-добър отговор на рунд; приблизителен оракул отслабва гаранцията
LOLA	оптимизирайте, приемайки, че противникът прави една стъпка на обучение ; диференцирайте <i>през</i> неговото обновяване	2-играч диференцируеми игри, където наивното обучение се проваля (IPD)	предполага, че знаете и можете да диференцирате обновяването на противника
CommNet	агентите излъчват диференцируемо съобщение ; всеки получава средното от останалите и го подава в своята политика	кооперативни задачи с частична наблюдаемост	средното обединяване изхвърля <i>кой</i> какво е казал

Две оси пресичат таблицата (фигурата по-долу). Първата е **какво е централизирано и кога?** IL не централизира нищо; CTDE централизира *оценителя/стойността само по време на обучението* (изпълнението остава децентрализирано); PSRO централизира цялостно *решаване на мета-играта* между рундовете на обучение; commNet централизира *информация по време на изпълнение* чрез научен канал. Втората е **противникът моделиран ли е като статичен или като учащ се?** Всичко освен LOLA третира стратегията на противника като фиксирана, докато ти отговаряш; **LOLA** предвижда *следващото обновяване* на противника — динамично, а не статично.

Исторически развитието протича така: научи се да говориш (commNet, 2016) → централизирай оценителя (MADDPG, 2017) → внеси теория на игрите в популацията (PSRO, 2017) → факторизирай стойността (QMIX, 2018) → предвиди обучението на противника (LOLA, 2018) → и след това установи, че простият подход често е най-успешен (MAPPO, 2022).

Прочетете повече: Albrecht, S. V., Christianos, F. & Schäfer, L. (2024). *Многоагентно обучение с подкрепление: Основи и съвременни подходи* (MIT Press), гл. 8–9 — актуално учебникарско изложение точно на тази таксономия.



Фигура 2: The method family on two axes. Horizontal: how competitive vs cooperative the target setting is (IL and PSRO span competition; MADDPG/MAPPO/QMIX/CommNet target cooperation; LOLA is the mixed-motive bridge). Vertical: how much is centralized and when (nothing for IL; the critic at training for CTDE; a full meta-game solve for PSRO; information at execution for CommNet). LOLA is the outlier that models the opponent as a learner rather than a fixed strategy.

9.4 4. Самостоятелно обучение и неговите режими на провал

Най-ясният начин да се разбере *защо* останалата част от областта изобщо съществува, е чрез изпълнението на контролен експеримент, който води до провал. При самостоятелното обучение всеки агент се поставя в собствен градиентен цикъл и се приема, че останалите агенти са част от средата. Върху четири канонични 2×2 матрични игри — всяка от които представлява различен качествен случай — това води до четири различни изхода.

Игрите и техните аналитични равновесия на Наш (обективна истина): **дилемата на затворника** (доминираща стратегия: дефектът строго превъзхожда сътрудничеството, така че уникалното равновесие е взаимен дефект); **игра „хвърляне на монета“** (игра с нулева сума; уникалното равновесие е напълно смесената $(\frac{1}{2}, \frac{1}{2})$ със стойност 0); **Stag Hunt** (две чисти равновесия на Наш — доминиращото по печалба (Stag, Stag) и рисково доминиращото (Hare, Hare) — плюс едно смесено); **битка на половете** (две чисти равновесия на Наш, които не са съгласни кое да изберат, плюс едно смесено).

Изпълнението на двама независими градиентни учещи се (с точни градиенти, така че динамиката е чиста и безшумна) дава, измерено:

Игра	Измерено равновесие	NashConv	Съвпада ли с аналитичното равновесие на Наш?
дилемата на затворника	$x \rightarrow [0.001, 0.999]$ (дефект)	0.0013	да — равновесието при доминиращи стратегии
лов на елен	всички семена $\rightarrow$ (Hare, Hare)	0.0013	да — <i>рисково доминиращото</i> чисто равновесие на Наш
битка на половете	всички семена $\rightarrow$ едно чисто равновесие на Наш	0.0013	да — чисто равновесие на Наш
игра „хвърляне на монета“	не сходява (последната итерация се отклонява към границата)	1.4–1.8	не — никога не се установява

Три от четирите игри сходяват към истинско равновесие на Наш, а интересните детайли са в „как“. В **лов на елен** обучаемите надеждно избират **рисково доминиращото** равновесие (Hare), вместо доминиращото по печалба (Stag), въпреки че Stag носи повече печалба — едностранен ход към Stag се наказва, така че градиентната динамика се плъзга към безопасния ъгъл. В **битка на половете** всяко начално число води до *едно и също* чисто равновесие; обучаемите решават проблема на координатията, но не по начин, разнообразен според началните числа. Това са проблемите с избора на равновесие и координатията, представени в конкретен вид.

Играта „хвърляне на монета“ е показателна: тя **никога не сходи към равновесие**, което е именно същината

на проблема.

Съгласуване (запази прогнозата → за това какво всъщност се случи). Прогнозирах, че Matching Pennies ще проследи чиста орбита с приблизително постоянен радиус около $(\frac{1}{2}, \frac{1}{2})$. Двама обучаеми, пуснати по два начина, и двамата не успяха да **сходяват** — но нито един от тях не обиколи чисто. Обучаемият с проектиран градиент (IGA), използван в скриптовите за изследване, *спираловидно се отдалечава*: измереното разстояние до нашово равновесие нарасна през времевите прозорци от 0.30 до 0.48. Обучаемият със softmax-logit, използван в имплементацията, *се отклонява към ъглите* (последни профили като $x = [0.96, 0.04]$, $y = [0.03, 0.97]$, $\text{NashConv} \approx 1.8$). **Изводът остава непроменен и дори е по-ясен:** при наивно едновременно учене *последната итерация* не сходи към равновесие в игра само със смесено равновесие — това, което сходи, е *усредненото време* (§6). Конкретният мисловен модел за „енергозапазваща орбита“ беше грешната част; механизмът е бавно **разминаване** към границата, което, ако нещо, е още по-силен аргумент за среднопретеглящия механизъм, който следва.


Прочетете още: Singh, S., Kearns, M. & Mansour, Y. (2000). “Nash Convergence of Gradient Dynamics in General-Sum Games.” *UAI* — анализът защо изкачването по градиент циклира, вместо да се сходи в игри като игра „хвърляне на монета“.

9.5 5. Централизирано обучение, децентрализирано изпълнение (CTDE)


Първата структурна корекция запазва изпълнението реалистично — всеки агент все още действа въз основа на собственото си наблюдение — като същевременно предоставя на *обучаващия* привилегирован изглед по време на обучение. Архетипът е **MADDPG** (Lowe и др., 2017): актьорът $\pi_i(a_i \mid o_i)$ на всеки агент вижда само собственото си наблюдение, но централизираният оценител $Q_i(s, a_1, \dots, a_N)$ вижда глобалното състояние и действието на *всеки* агент. Асиметрията е същността на подхода. Оценителят за всеки агент, който наблюдава само o_i , се сблъсква с нестационарен, частично наблюдаем свят, така че идентични входи водят до различни възвръщаемости и неговата целева стойност е шумна; централизираният оценител, обусловен върху всичко, вижда целева стойност, която е (почти) детерминистична, така че той е значително по-нисък дисперсионен учител. **MARPO** (Yu и др., 2022) е минималната версия: обикновен PPO с една централизирана функция на стойността $V(\text{global state})$ вместо на агент $V(o_i)$, и често е най-силната базова линия — предупреждение срещу прекалено усложняване.

Има ли централизираният оценител действително по-ниска дисперсия? Измерено върху едностъпкова кооперативна „референтна“ задача (говорителят вижда целта, слушателят не, и двамата трябва да я назоват), обучено до сходимост:

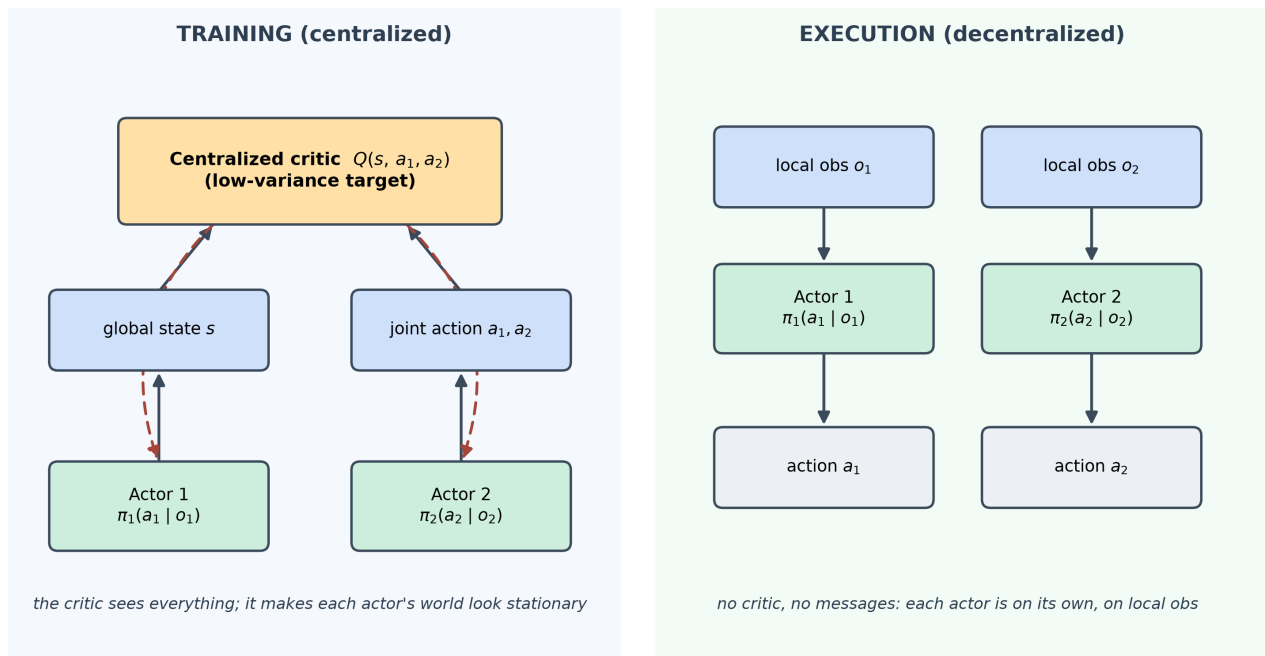
Оценител	Краен остатък (загуба на стойност)
централизиран $Q(s, \text{joint } a)$	3.2×10^{-11}
независим $Q_i(o_i)$	0.077



Фигура 3: Independent learners on the four matrix games: Prisoner's Dilemma collapses to mutual defection, Stag Hunt and Battle of the Sexes settle on a pure equilibrium, and Matching Pennies fails to converge (its trajectory drifts away from the mixed Nash rather than settling on it). The contrast is the visceral case for coordination machinery.



Фигура 4: Zoom on non-stationarity: the distance-to-Nash for Matching Pennies does not shrink (it grows across time-windows, 0.30 to 0.48), while the Prisoner's Dilemma distance-to-(Defect,Defect) collapses to zero. More compute traces a bigger divergence, not convergence — non-stationarity is structural, not a budget problem.




Фигура 5: CTDE architecture. During training a centralized critic (or value function) sees the global state and the joint action and produces low-variance value targets; during execution each actor acts on its own local observation with no access to the critic and no message passing. The training/execution asymmetry is what makes the world look stationary to the learner without cheating at showtime.

Централизираният оценител свежда остатъка си практически до нула — той вижда целта и съвместното действие, така че наградата е детерминистична функция на неговите входове — докато независимият оценител не може да види целта и остава блокиран в прогнозирането на базовата честота. Това потвърждава твърдението за намаляване на дисперсията при CTDE по ясен начин.

Но намаляването на дисперсията не е същото като решаването на координацията и именно тук една прогноза се провали.

Съгласуване (запази прогноза → какво всъщност се случи). Прогнозирах, че в **изкачващата се игра** на Claus–Boutilier — кооперативна матрична игра без състояние, чийто оптимум (11) е фланкиран от -30 санкции за некоординация, с „безопасен“ атрактор при 5 — централизираният оценител ще избяга от капана и ще достигне оптимума, побеждавайки независимите обучаващи агенти. Това не се случи. Измерени алчни награди: **независими обучаващи агенти 7, MADDPG 5, MAPPO 7** (оптимум 11, безопасен 5). Нито един метод не достигна оптимума, а MADDPG всъщност *изостана* както спрямо IL, така и спрямо MAPPO. Честният прочит: централизираният оценител намалява дисперсията на целевата стойност (потвърдено по-горе), но това **не е достатъчно**, за да преодолее относителната свръхобобщеност плюс риска от прекомерно изследване на -30 санкциите — агентите няма да опитат рискованото съвместно действие достатъчно дълго, за да открият 11. Резултатът на MADDPG под нивото на IL конкретно посочва неговото дискретно контрафактично актьорско обновяване с базова линия като частта, която трябва да бъде разгледана следваща. Урокът оцелява в по-сдържан вид: **CTDE купува по-добър оценител, но не и автоматична координация.**

Методологическа бележка, която си струва да се запомни: и двата ефекта на CTDE по-горе бяха **невидими при бързата “smoke config”** — там загубите на оценителя бяха почти еднакви, а ползата от комуникацията (§7) беше нула. Те се проявиха едва след обучение до сходимост при по-голямата “scale” конфигурация. Конфигурацията на дима показва, че кодът функционира; за да се наблюдават явленията, е необходимо обучение до сходимост.




Фигура 6: Cooperative CTDE and communication results (scale config). Left: the centralized critic’s residual is orders of magnitude below the independent critic’s. Middle: on the climbing game, no method reaches the optimum (11); MADDPG (5) trails IL and MAPPO (7) — CTDE reduces critic variance but does not by itself solve hard-exploration coordination. Right: communication lifts the listener far above the $1/K$ guessing ceiling (see §7).

Прочетете повече: Lowe, R. и др. (2017). „Многоагентен актьор-критик за смесени кооперативни и състезателни среди.“ *neurIPS* (MADDPG); и Yu, C. и др. (2022). „Изненадващата ефективност на PPO в кооперативни многоагентни игри.“ *neurIPS* (MAPPO).

9.6 6. PSRO — теория на игрите върху съвкупност от политики

Втората структурна корекция е последователността на стъпката и прекият наследник на **итерирания най-добър отговор** от Стъпка 2. **PSRO** (Policy-Space Response Oracles; Lanctot и др., 2017) разглежда цели стратегии като атомите на една по-висша игра. То поддържа **популация** от стратегии за всеки играч, изгражда емпиричната **мета-игра** матрица на печалбата между популациите, решава **мета-Наш равновесие** върху нея, обучава **най-добър отговор** (оракул) към сместа мета-Наш на опонента и добавя този отговор към популацията — повтори. То обединява самообучението, фиктивната игра и метода на **двойно предсказание** в една рамка и, което е от решаващо значение за този проект, неговата метрика за прогрес е **експлоатируемост** — същата NashConv, използвана в Стъпки 2–8.



Фигура 7: The PSRO double-oracle loop. From the current populations, build the meta-game payoff matrix, solve its meta-Nash mixture, then call a best-response oracle against the opponent’s mixture and add the new policy to the population. Exploitability of the meta-Nash mixture is expected to fall as the population grows. In this project the oracle is Step 07’s exact best response, so PSRO’s convergence is measured with the same exploitability yardstick as the game-theory steps.

Два факта правят имплементацията точна, а не приблизителна. Първо, оракулът използва повторно **точния най-добър отговор** от Стъпка 07 за игрите кун и ледюк. Второ, мета-Наш сместа на опонента върху по-

веденчески стратегии е, съгласно Kuhn's Theorem (тъй като тези игри имат пълна памет), реализационно еквивалентна на **една единствена поведенческа стратегия**; свеждането на сместа по този начин позволява директното прилагане на двигателя за точен най-добър отговор.

Защо популация, а не просто последната стратегия от самообучението? Защото самообучението се сближава в *средното*, а не в последната итерация. Измерено върху **кун** при фиктивна игра със самообучение: експлоатируемостта на **средната** итерация спадна от 0.24 до 0.031 за 200 итерации, докато експлоатируемостта на **последната** итерация продължи да осцилира между 0.33 и 0.83. Доверяването на последната стратегия би означавало да се доверим на стойност, която никога не се установява; мета-сместа на PSRO е популационната версия на осредняването, върху което се основават CFR и фиктивната игра.


Сходимост на PSRO, измерена (експлоатируемост = NashConv на мета-Наш сместа в цялата игра):

Игра	Траектория на експлоатируемостта	Присъда
кун покер	$0.917 \rightarrow \sim 2 \times 10^{-16}$ до кръг 6	сближава се до Machine Zero
матрица (игра „хвърляне на монета”)	$2.0 \rightarrow 0$ до кръг 2	сближава се
камък-ножица-хартия (изследване)	$2.0 \rightarrow 0.017$; популация $\rightarrow \{R,P,S\}$, смес $\rightarrow$ равномерна	сближава се
Ледюк Холдем	$4.75 \rightarrow 2.16$ за 20 кръга	намалява, но е далеч над целта
Goofspiel ($K = 3$)	$1.33 \rightarrow 0$	сближава се
Goofspiel ($K = 4$)	колебае се $1.4 \leftrightarrow 2.0$	не се установява


Резултатите за **кун** / матрица / RPS са учебникови: при малките игри популацията бързо обхваща необходимите стратегии и експлоатируемостта рязко спада. Два резултата не се развива според очакванията.

Съгласуване 1 (ледюк). I predicted PSRO would drive Leduc exploitability below 0.5 within 20 iterations. Measured, it fell from 4.75 to 2.16 — a clear, roughly monotone decline, but nowhere near 0.5. This is **genuine slow convergence**, not a bug: Kuhn hit machine zero in 6 rounds, but Leduc's game tree is far larger, and a population of 20 *pure* best responses is simply too small to closely approximate its mixed Nash. The “< 0.5 in 20” target was optimistic. The lesson — exploitability decreases as the population grows — holds; the *rate* is the scaling wall, and it rhymes with Step 8's global-vs-local scaling finding.

Съгласуване 2 (Goofspiel $K = 4$). I predicted non-increasing exploitability. At $K = 3$ it converged to 0 чисто; at $K = 4$ it oscillates between ~ 1.4 and ~ 2.0 and does not settle. This is the one result I cannot yet fully explain, and per the workflow I am **documenting it, not fixing it**. Two concrete suspects for a follow-up session: the Goofspiel PSRO driver never de-duplicates best-response policies (so the meta-game can stall on repeats), and a pure-strategy population is likely too weak to represent the larger game's mixed meta-Nash. Flagged as an open code item, not a validated result.



Фигура 8: PSRO exploitability vs population size across games (scale config). Kuhn, the matrix game, and Rock-Paper-Scissors collapse to (near) zero within a handful of rounds; Leduc declines steadily but stays well above the 0.5 target after 20 rounds (a scaling wall for a pure-strategy population); Goofspiel K=4 oscillates rather than settling (a flagged anomaly). The exact best-response oracle guarantees convergence in principle; the rate is what size controls.



Фигура 9: Self-play on Kuhn: the average-iterate exploitability (NashConv) falls steadily toward zero while the last-iterate exploitability keeps oscillating. This is why self-play and PSRO rely on averaging over a population rather than trusting the most recent policy.

Прочетете повече: Lanctot, M. и др. (2017). „Унифициран игровотеоретичен подход към обучението с подкрепление на множество агенти.“ *neurIPS* (PSRO); и McMahan, H. B., Gordon, G. & Blum, A. (2003). „Планиране в присъствието на функции на разходите, контролирани от противник.“ *ICML* (методът на двойно предсказание, който PSRO обобщава).

9.7 7. Научена комуникация (commNet)

CTDE централизира информацията по време на *обучение*; комуникацията я централизира по време на *изпълнение* чрез канал, който агентите **научават**, а не такъв, който дизайнерът изгражда. В **commNet** (Sukhbaatar и др., 2016) всеки агент кодира своето наблюдение в скрит вектор, излъчва **съобщение**, и след това получава **средната стойност** на съобщенията на останалите агенти като допълнителен вход за своята стратегия. Цялото се обучава от край до край, така че протоколът възниква: в референтната задача говорещият (който единствен вижда целта) трябва да се научи да я кодира, а слушателят – да я декодира.

Тестът е показателен, тъй като без канал слушателят е ограничен единствено до чисто отгатване, $1/K$. Измерено (конфигурация на мащаба, $K = 5$, при което прагът на отгатваемост е 0.2):

Канал	Награда за отборна алчност
комуникация върху	0.795
изключена комуникация	0.204

С канала слушателят се издига далеч над тавана от $1/K$; без него той остава точно на тавана. Комуникацията върши реална работа — и обърнете внимание, че съгласуването от §5 важи и тук: при конфигурацията с дим и двете числа бяха 0.24 (каналът все още не се беше научил да пренася информация), а ползата се появи едва след обучение в мащаб.

Прочетете повече: Sukhbaatar, S., Szlam, A. & Fergus, R. (2016). “Обучение на многоагентна комуникация с обратно разпространение на грешката.” *neurIPS* (commNet).

9.8 8. LOLA — моделиране на опонента като учащ се

Всеки метод досега разглежда стратегията на противника като фиксирана, докато агентът реагира. **LOLA** (обучение с осъзнаване за ученето на противника; Foerster и др., 2018) е изключението и е този, който е най-пряко свързан с дисертацията. Вместо да се оптимизира спрямо *настоящата* стратегия на противника, всеки агент се оптимизира спрямо стратегията, която противникът ще има *след една стъпка на обучение*, като диференцира *през* тази стъпка. Допълнителният член представлява смесена втора производна — как актуализацията на стратегията на противника зависи от *моите* параметри — и именно той превръща егоистичните агенти в кооперативни.

Класическата демонстрация е **Iterated Prisoner's Dilemma** с памет-1, при която стратегията на всеки агент се състои от пет вероятности за сътрудничество, а очакваната дисконтирана възвръщаемост има затворена форма чрез стационарната марковска верига върху двойките резултати. Наивни градиентни обучаеми, всеки максимизиращ собствената си възвръщаемост спрямо текущата стратегия на другия, сходява към взаимно предателство; **IOLA learners**, всеки отчитащ предстоящата актуализация на другия, достига взаимно сътрудничество.

Измерена (дисконтирана възвръщаемост на стъпка; пълно сътрудничество ≈ 3 , взаимно предателство $\square \text{MATHPI} \square$):

Обучаващи се	Възвръщаемост
наивни срещу наивни	1.04
LOLA срещу LOLA	2.82

Посоката е точно резултатът на LOLA — сътрудничеството възниква там, където наивното обучение води до дефектиране. (Моята прогноза за ≈ 3 беше малко завишена; измерената 2.82 е близка до пълно сътрудничество, а изследователското изпълнение с по-голяма **скорост на обучение при предвиждане** достигна ~ 2.9 .) Вградена **проверка за коректност** потвърждава механизма: задаването на **скоростта на обучение при предвиждане** на нула кара **градиента** на LOLA да се редуцира точно до **наивния градиент**, така че сътрудничеството произтича конкретно от втория ред на члена за **предвиждане**.


Концептуално това представлява **динамично** моделиране на противника: Стъпка 7 извежда *текущата* стратегия на противника; LOLA предвижда тяхната *обучителна траектория*. Комбинирането на двете — статично четене, което задейства динамично предвиждане — е кандидат за Принос №1, а не нещо вече решено.

Прочетете повече: Foerster, J. и др. (2018). “Обучение с осъзнаване на обучението на противника.” *AAMAS* (LOLA).

9.9 9. Честни бележки, ограничения и къде това раздаване продължава нататък

Какво се задържа. Потвърдените резултати са гръбнакът: самостоятелното обучение се сближава при доминиращи/координационни игри и *се проваля* при игра „хвърляне на монета“; PSRO свежда експлоатируемостта до (почти) нула при Кун, матричната игра и RPS с точен оракул; самостоятелното обучение се сближава в средното, но не и в последната итерация; централизиращият оценител има дисперсия на остатъка с порядъци по-ниска; научената комуникация издига слушателя над прага на отгатваемост; и LOLA превръща дефекторите в IPD сътрудници. Взети заедно, те проследяват предвидената дъга — от „защо наивното обучение се разпада“ до „структурните поправки, които го възстановяват“.

Какво не успя и защо това е от значение. Четири честни уговорки се пренасят напред. (1) Игра „хвърляне на монета“ се отклонява към границата, вместо да обикаля — по-остра версия на урока за несходимост. (2) PSRO при Leduc се сближава *бавно* (експлоатируемост ~ 2.16 след 20 рунда, а не < 0.5) — стена на



Фигура 10: LOLA vs naive learners on the Iterated Prisoner's Dilemma: naive learners' per-step return collapses toward mutual defection (~ 1), while LOLA learners' return climbs toward mutual cooperation (~ 2.8). Anticipating the opponent's next learning step is what reshapes the dynamics from defection to cooperation.

мащабиране на популацията с чисти стратегии. (3) Goofspiel $K = 4$ се колебае, вместо да се сближава — маркирана, необяснена аномалия в кода (документирана, но не поправена). (4) При играта „изкачване“ нито един метод не достигна оптимума и MADDPG се представи по-зле от независимите обучаващи агенти — централизираният оценител намалява дисперсията, но сам по себе си не решава координация при риск от прекомерно изследване. Двата елемента на кода (Goofspiel $K = 4$; контрафактична базова линия на MADDPG) трябва да бъдат разгледани, преди тези части да бъдат използвани отново. И един методологичен момент: ефектите на невронните мрежи бяха невидими при бързата конфигурация на дима и се появиха едва в мащаб, така че именно числата за мащаб са тези, върху които почиват твърденията.

Доверие. Всяка цел на равновесие е *точна* (аналитично равновесие на Наш за матричните игри; точен най-добър отговор и NashConv от Стъпка 07 за кун/ледюк/Goofspiel), така че игровитеоретичните резултати се ограничават от обективната истина, а не от други симулации. Невронните резултати представляват качествени неравенства (централен < независим; комуникация ВКЛЮЧЕНА > комуникация ИЗКЛЮЧЕНА), а не точни стойности, и по конструкция са чувствителни към началното число и версията. PNG изображенията на експериментите, цитирани по-горе, са генерирани от ангажираните JSON artifacts (виж `../figures/README.md`); няколко от тях не бяха запазени при изпълнението и са маркирани като „за затваряне“.

Обратни и бъдещи връзки. Обратно: PSRO представлява итерираният най-добър отговор от Стъпка 2, издигнат до ниво популация, и използва изцяло двигателя за точен най-добър отговор от Стъпка 07; стената на мащабиране при ледюк отеква откритието глобално срещу локално от Стъпка 8. Напред: трите тези вече са конкретизирани — LOLA като динамично моделиране на противника (Принос №1), мета-играта на PSRO като методология за оценяване (Принос №3) и, преди всичко, **липсващата $N > 2$ минимакс котва** (Принос №2), единственото място, където всяка двуйгрова гаранция от Стъпки 2–8 престава да бъде валидна.

Отворени въпроси. Може ли приблизителен (RL) оракул да доближи PSRO при ледюк значително повече до наш равновесие и с каква цена за гаранцията за сходимост? Какво премахва колебанието в Goofspiel $K = 4$ — дедупликация, популация от смесени стратегии или различен мета-решател? Защо централизираният оценител *вреди* при изкачващата се игра и дали контрафактична/COMA базова линия го коригира? И основният въпрос на дисертацията, който стои под всички тях: без минимаксна стойност за $N > 2$, какво означава „безопасно“ дори за популация и може ли мета-играта на PSRO да осигури приложима заместителка?

9.10 Основни изводи за синтеза на дисертацията

- **Нестационарността е основният проблем, и тя е структурна, а не въпрос на изчислителна мощност** — играта „хвърляне на монета“ се разминава, независимо колко дълго тренирате.
- **CTDE централизира оценителя по време на обучението и децентрализира актьора при изпълнението**; измерено е, че осигурява оценител с почти нулева дисперсия (3.2×10^{-11} спрямо 0.077) — но само намаляването на дисперсията не реши изкачващата се игра, така че то е необходимо, но не и

достатъчно.

- **PSRO е мостът между теорията на игрите $\leftrightarrow$ MARL:** измерено е, че довежда кун до експлоатируемост, равна на машинната нула, а RPS — до равномерност; ледюк намалява, но достига стена на машабиране — същата стена, която мотивира скалируемите методи в дисертацията.
- **Самообучението/PSRO успяват в средното/популацията, а не в последната итерация** (средната NashConv на кун $0.24 \rightarrow 0.031$, докато последната итерация се колебае) — причината да съществува популация.
- **LOLA преформулира противника като обучаем** и превръща дефекцията в IPD в кооперация ($1.04 \rightarrow 2.82$) — динамичният комплемент към статичния модел на противника от Стъпка 7 (Принос №1).
- **Минимаксната разлика $N > 2$ е отворената врата към дисертацията** (Принос №2): речникът на стъпки 2–8 преминава в MARL, но предпазният ограничител не.