

Глава 9 Обобщение – Многоагентно обучение с подкрепление

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Съдържание

9 Глава 9 – Многоагентно обучение с подкрепление: координация, конкуренция и комуникация	1
9.1 Защо многоагентното обучение с подкрепление е различен проблем	2
9.2 Марковски игри – мостът между глави 2–8 и MARL	3
9.3 Семейството от методи	4
9.4 Независимо обучение и начините, по които то се проваля	8
9.5 Централизирано обучение, децентрализирано изпълнение (CTDE)	11
9.6 PSRO – теория на игрите върху популация от стратегии	15
9.7 Научена комуникация (CommNet)	19
9.8 LOLA – моделиране на противника като учещ се агент	20
9.9 Честни бележки, ограничения и връзка със следващите глави	22
9.10 Основни изводи за синтеза на дисертацията	23

9 Глава 9 – Многоагентно обучение с подкрепление: координация, конкуренция и комуникация

Тази глава въвежда от самото начало многоагентното обучение с подкрепление (MARL): проблемът, който го отличава от всичко преди него, математиката, която го рамкира, семейството от методи, които се използват за решаването му, и набор от контролирани експерименти, проведени в малки, точно решими игри. Написана е така, че да може да бъде прочетена независимо; не се предполага предварително запознаване с кода на проекта. **Всички експериментални числа, представени тук, са измерени** при възпроизводими изпълнения на тестовите среди и, където това е възможно, са поставени в *точни* аналитични граници (равновесия на Наш, точни стойности на най-добрия отговор), а не в граници, получени от други симулации. Когато дадено изпълнение противоречи на очакванията, произтичащи от теорията, запазвам първоначалното очакване и го съпоставям с получения резултат – тези разминавания са най-поучителните части от главата.

Къде се вписва това в дисертацията. Глави 2–8 работят почти изцяло в рамките на **игри за двама с нулева сума** (Pluribus в Глава 6 е изключението, което се отказва от гаранциите): има стойност v^* , равновесната стратегия на Наш я осигурява срещу *всеки* противник и CFR доказуемо

се сближава към нея. Глава 9 е повратната точка към **многоагентния** свят, където тези три удобства отслабват или изчезват. Тя предлага три връзки с дисертацията. **LOLA** (Foerster и др., 2018) – диференциране през *стъпката на обучение* на противника – може да се разглежда като *динамично* моделиране на противника, допълнение към статичната преценка за противника от Глава 7, насочено към противник, който се променя (Принос №1). **PSRO** – игра, която се играе върху *популация от стратегии* – е кандидат-рамка за безопасна експлоатация там, където няма теорема за минимакса (Принос №2), и обща многоагентна *методология за оценяване* (Принос №3). Мястото, където се нарушава всяка гаранция за игри с двама играчи – липсващата минимаксна опора при $N > 2$ – е назовано тук и оставено като отворен проблем, към който е насочена дисертацията.


9.1 Защо многоагентното обучение с подкрепление е различен проблем

В едноагентното обучение с подкрепление (Глава 1) един агент се учи чрез проба и грешка в **непроменяща се** среда. Формално той се изправя пред стационарен марковски процес на вземане на решения: законът за преход $P(s' | s, a)$ и наградата $R(s, a)$ не се изменят по време на обучението, което позволява да съществува фиксирана оптимална стойностна функция Q^* , към която агентът да се сближава. В Глави 2–8 ние преминахме към едно по-високо ниво и изчислихме **равновесия** – стратегии, които са оптимални срещу *съвършено рационален* противник, който вече е завършил своите разсъждения.

Многоагентното обучение с подкрепление се намира между тези два подхода и е по-трудно и от двете. Няколко агента **се учат едновременно в споделена среда**, така че от гледната точка на всеки един агент „средата“ – която вече *включва и другите агенти* – **непрекъснато се изменя**, докато всички се обновяват. Това е **нестационарност** и тя нарушава предположението, на което се крепи едноагентното обучение с подкрепление. От гледна точка на агент i ефективният преход и награда зависят от стратегиите π_{-i} на другите агенти, а те се променят при всяко обновяване, така че целта Q^* , която агент i преследва, самата тя е в движение. Това също така поражда два проблема, които просто не съществуват за агент, който действа сам: **координация** (как агентите, които си сътрудничат, се научават да действат заедно, без някой да им казва как?) и **разпределяне на заслугата** (когато отборът успее, чии действия са имали значение?).

Образ, който си струва да запомните: **учене на танц с партньор, който също се учи да танцува**. Ако стъпките на вашия партньор бяха фиксирани, бихте могли да научите наизуст последователност от стъпки, която им подхожда – това е едноагентното обучение с подкрепление. Ако вашият партньор беше безупречен професионалист, бихте могли да изучите известния му стил и да се подготвите с перфектен отговор – това е изчисляване на равновесие. Но когато *и двамата* се подобряват в реално време, всяка промяна, която правите, променя това, което другият трябва да направи, и обратното; вие си стъпвате един на друг по краката, прекоригирате и осцилирате – докато или не намерите общ ритъм (координирано равновесие), или не започнете да се въртите в кръг безкрайно (както в „съвпадение на монети“, Matching Pennies, раздел 9.4). Цялата област е

изкуството да подредите картите така, че синхронизацията да се случва надеждно.¹



Фигура 1: Нестационарността като двама партньори, които се учат да танцуват едновременно. Всеки агент оптимизира спрямо текущата стратегия на другия (плътните стрелки), но тази стратегия също се променя, защото другият агент на свой ред оптимизира спрямо него (пунктирните стрелки). Целта, която всеки преследва, никога не стои на място, затова наивните обучаващи се агенти циклират или прекалено се коригират, вместо да се сближат с равновесие. Всеки метод в тази глава е различен начин целта да се задържи неподвижна достатъчно дълго, за да може агентът да се научи спрямо нея.

9.2 Марковски игри – мостът между глави 2–8 и MARL

Глави 2–8 разсъждаваха върху **игри в екстензивна форма (EFGs)**: дърво на играта, **информационни множества**, които групират истории, които играчът не може да различи, и контрафактични стойности, подавани към алгоритъм за минимизиране на съжалението (CFR). Глава 9 разсъждава върху **марковски (стохастични) игри**, стандартната формализация на MARL. Двете се свързват естествено и изясняването на тази връзка е това, което не позволява преминаването да изглежда като започване отначало.

Марковската игра е наредената n -торка

¹Zhang, K., Yang, Z. & Başar, T. (2021). “Multi-Agent Reinforcement Learning: A Selective Overview of Theories and Algorithms.” *Handbook of RL and Control* – §1–2 за нестационарността и таксономията, използвана тук.

$$(\mathcal{S}, \{\mathcal{A}_i\}_{i=1}^N, P, \{R_i\}_{i=1}^N, \{\Omega_i\}, O, \gamma),$$

с множество състояния $s \in \mathcal{S}$, по едно множество действия $\mathcal{A}_i$ за всеки агент, закон за преход $P(s' \mid s, a_1, \dots, a_N)$, управляван от **съвместното** действие, наградите на отделните агенти $R_i(s, a_1, \dots, a_N)$ и (при частично наблюдавания случай) наблюдения $o_i = O_i(s)$. Всеки агент има стратегия $\pi_i(a_i \mid o_i)$; заедно те формират **съвместна стратегия** $\pi = (\pi_1, \dots, \pi_N)$. Специалните случаи са именно предишните глави:

- $N = 1$ възстановява обикновено **MDP** (Глава 1).
- $N = 2$ и едно състояние дава **матрична игра** (с нулева сума при $R_1 = -R_2$; тестовата среда на тази глава, раздел 9.4).
- Последователна игра с непълна информация и нулева сума дава **EFG** (глави 2–8): марковска игра, при която „**състоянието**“ е *история*, а **частичната наблюдаемост** се изразява чрез **информационно множество**.

Това, което преминава през моста, е *речникът*. Стратегията все още съпоставя това, което агентът знае, с разпределение върху действията, така че поведенческата стратегия на EFG в информационно множество е точно стратегията в марковската игра $\pi_i(a_i \mid o_i)$; информационното множество се превръща в наблюдението o_i ; а контрафактичната стойност на история става оценка на централизиран оценител в състояние. Това, което **не** преминава през моста, са *гаранциите*. Контрафактичното разлагане на CFR изисква дърво на играта с пълна памет, каквото общите марковски игри (с цикли и едновременни ходове) не предоставят, а при $N > 2$ играчи CFR губи гаранцията за сходимост към равновесие на Наш дори в дърво с пълна памет (Abou Risk и Szafron, 2010),² така че „средна стратегия $\rightarrow$ Наш“ вече не важи; MARL се връща към обучение чрез градиент/стойност, чиято сходимост не е гарантирана (оттук и цикличността в раздел 9.4). Най-съществено, изчезва **опората на минимаксната стойност**: в игра за двама с нулева сума равновесната стратегия на Наш гарантира v^* срещу всеки противник – фактът, на който се крепи безопасната експлоатация в Глава 8 – и за $N > 2$ няма такава единична стойност. Именно тази липсваща опора е празнината, която наследява Принос №2.³

9.3 Семейството от методи

Всеки метод в тази глава представлява различно структурно решение на въпроса „другите агенти се учат, докато аз се уча“. Тук са от значение пет основни **семејства** (MADDPG, MAPPO и QMIX са три варианта на CTDE).

²Abou Risk, N. & Szafron, D. (2010). “Using Counterfactual Regret Minimization to Create Competitive Multiplayer Poker Agents.” AAMAS, 159–166 – гаранцията за сходимост на CFR обхваща игрите за двама с нулева сума и пълна памет; при повече играчи тя се губи.


³Littman, M. L. (1994). “Markov Games as a Framework for Multi-Agent Reinforcement Learning.” ICML – статията, която въведе тази рамка и алгоритъма minimax-Q.

Таблица 1: Семействата методи в MARL: какво прави всеки, кога да се използва и основната му слабост.

Подход	Какво прави	Кога да го използвате	Основна слабост
Независимо обучение (IL)	всеки агент използва собствен алгоритъм за едноагентно обучение и третира останалите като част от средата	бърза базова линия; почти стационарни среди	нестационарност → цикличност, провал на координацията
MADDPG (CTDE)	оценителят на всеки агент вижда наблюденията и действията на всички агенти по време на обучението; всеки актьор вижда само собственото си наблюдение при изпълнение	смесени кооперативно-конкурентни задачи; каноничният CTDE шаблон	входът на оценителя нараства с N ; актьорското обновяване е сложно за настройка
MAPPO (CTDE)	обикновен PPO с централизирана функция на стойността $V(s)$ на глобалното състояние и споделени параметри	кооперативен MARL, когато искате проста и надеждна базова линия	висока цена на данните при обучение по текущата стратегия (on-policy); „прост“, но чувствителен към настройката
QMIX (CTDE)	факторизира съвместната стойност монотонно на стойности по агенти	кооперативни задачи с обща награда	монотонността ограничава класа на представимите функции на стойността
PSRO	поддържа популация от стратегии; намира мета-Наш сместа върху нея; обучава най-добър отговор на тази смес; добавя го; цикълът се повтаря	конкурентни/общии игри; когато искате игровитеоретична цел на сходимост	пълен най-добър отговор във всеки кръг; приблизителният оракул отслабва гаранцията

Подход	Какво прави	Кога да го използвате	Основна слабост
LOLA	оптимизира, като приема, че противникът ще направи една стъпка на обучение ; диференцира през неговото обновяване	диференцируеми игри с двама играчи, в които наивното обучение се проваля (IPD)	предполага, че знаете и можете да диференцирате обновяването на противника
CommNet	агентите излъчват диференцируемо съобщение ; всеки получава средното от останалите и го подава на входа на своята стратегия	кооперативни задачи с частична наблюдаемост	усредняването губи информацията <i>кой</i> какво е казал

Две оси пресичат таблицата (фигурата по-долу). Първата е **какво е централизирано и кога?** IL не централизира нищо; CTDE централизира *оценителя/стойността само по време на обучението* (изпълнението остава децентрализирано); PSRO централизира *цялостно решаване на мета-играта* между кръговете на обучение; CommNet централизира *информацията по време на изпълнение* чрез канал, който агентите сами научават. Втората е **моделира ли се противникът като статичен, или като учещ се агент?** Всичко освен LOLA третира стратегията на противника като фиксирана, докато агентът ѝ отговаря; **LOLA** предвижда *следващото обновяване* на противника – динамично, а не статично.



Фигура 2: Семейството методи по две оси. Хоризонтално: доколко целевата среда е кооперативна или конкурентна (IL и PSRO обхващат и конкурентните среди; MADDPG, MAPPO, QMIX и CommNet са насочени към сътрудничество; LOLA е мостът към смесените мотиви). Вертикално: какво и кога се централизира (нищо при IL; оценителят по време на обучение при CTDE; пълното решаване на мета-играта при PSRO; информацията по време на изпълнение при CommNet). LOLA е изключението, което моделира противника като учещ се агент, а не като фиксирана стратегия.

Исторически развитието протича така: научи се да говориш (CommNet, 2016) → централизирай оценителя (MADDPG, 2017) → внеси теория на игрите в популацията (PSRO, 2017) → факторизирай стойността (QMIX, 2018)⁴ → предвиди обучението на противника (LOLA, 2018) → и след това установи, че простият подход често е най-успешен (MAPPO, 2022).⁵

⁴Rashid, T., Samvelyan, M., Schroeder de Witt, C., Farquhar, G., Foerster, J. & Whiteson, S. (2018). "QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning." *ICML*. arXiv:1803.11485.

⁵Albrecht, S. V., Christianos, F. & Schäfer, L. (2024). *Multi-Agent Reinforcement Learning: Foundations and Modern Approaches* (MIT Press), гл. 5 и 9 – съвременно учебно изложение на тези предизвикателства и методи.

9.4 Независимо обучение и начините, по които то се проваля

Най-ясният начин да се разбере *защо* останалата част от областта изобщо съществува, е чрез изпълнението на контролен експеримент, който води до провал. При независимото обучение всеки агент се поставя в собствен градиентен цикъл и се приема, че останалите агенти са част от средата. Върху четири канонични 2×2 матрични игри – всяка от които представлява различен качествен случай – това води до четири различни изхода.

Игрите и техните аналитични равновесия на Наш (обективна истина): **дилемата на затворника** (доминираща стратегия: предателството строго превъзхожда сътрудничеството, така че единственото равновесие е взаимно предателство); **„съвпадение на монети“** (Matching Pennies; игра с нулева сума; единственото равновесие е напълно смесеното $(\frac{1}{2}, \frac{1}{2})$ със стойност 0); **лов на елен** (две чисти равновесия на Наш – доминиращото по печалба (Елен, Елен) и рисково доминиращото (Заек, Заек) – плюс едно смесено); **битка на половете** (две чисти равновесия на Наш, които не са съгласни кое да изберат, плюс едно смесено).

Два независими градиентни агента (с точни градиенти, така че динамиката е чиста и без шум) дават следните измерени резултати:

Таблица 2: Независими обучаващи се агенти в четири матрични игри, сравнени с аналитичното равновесие на Наш.

Игра	Измерен резултат	NashConv	Съвпада ли с аналитичното равновесие на Наш?
дилемата на затворника	$x \rightarrow [0,001, 0.999]$ (предателство)	0,0013	да – равновесието при доминиращи стратегии
лов на елен	всички начални числа $\rightarrow$ (Заек, Заек)	0,0013	да – <i>рисково доминиращото</i> чисто равновесие на Наш
битка на половете	всички начални числа $\rightarrow$ едно чисто равновесие на Наш	0,0013	да – чисто равновесие на Наш
„съвпадение на монети“	не се сближава (последната итерация се отклонява към границата)	1,4–1,8	не – никога не се установява

В три от четирите игри агентите се сближават с истинско равновесие на Наш, а интересните детайли са в „как“. В **лов на елен** агентите надеждно избират **рисково доминиращото** равновесие


(Заек), вместо доминиращото по печалба (Елен), въпреки че „Елен“ носи по-голяма печалба – едностранният ход към „Елен“ се наказва, така че градиентната динамика се плъзга към безопасния ъгъл. В **битка на половите** всяко начално число води до *едно и също* чисто равновесие; агентите решават проблема на координацията, но не по начин, разнообразен според началните числа. Това са проблемите с избора на равновесие и координацията, представени в конкретен вид.

Играта „съвпадение на монети“ е показателна: тя **никога не се сближава с равновесие**, което е именно същината на проблема.⁶


Съпоставка (запазена прогноза → какво всъщност се случи). Прогнозирах, че в „съвпадение на монети“ траекторията ще опише чиста орбита с приблизително постоянен радиус около $(\frac{1}{2}, \frac{1}{2})$. И двата вида обучаващи се агенти не успяха да **се сближат с равновесие** – но нито един не описа чиста орбита. Агентът с градиентен метод с проекция (IGA), използван в изследователските скриптове, *спираловидно се отдалечава*: измереното разстояние до равновесието на Наш нарасна през времевите прозорци от 0,30 до 0,48. Агентът със softmax параметризация, използван в имплементацията, *се отклонява към ъглите* (последни профили като $x = [0,96, 0.04]$, $y = [0,03, 0.97]$, $\text{NashConv} \approx 1,8$). **Изводът остава непроменен и дори е по-ясен**: при наивно едновременно учене *последната итерация* не се сближава с равновесие в игра само със смесено равновесие – това, което се сближава, е *средното по времето* (раздел 9.6). Моделът на „енергозапазващата орбита“ е верен за непрекъснатата динамика (безкрайно малка стъпка): тогава траекторията обикаля около равновесието по затворена крива (Singh и др., 2000). При фиксирана стъпка 0,1 обаче всяка стъпка излиза леко навън от кривата и траекторията бавно се отдалечава по спирала към границата. И в двата случая последната итерация не се сближава, а това е аргумент в полза на механизмите за осредняване, разгледани по-нататък.

⁶Singh, S., Kearns, M. & Mansour, Y. (2000). “Nash Convergence of Gradient Dynamics in General-Sum Games.” *UAI* – анализ на това защо градиентното изкачване циклира, вместо да се сближи с равновесие, в игри като „съвпадение на монети“.

Независими обучаващи се агенти в игри 2×2
(траектории в пространството на стратегиите)



Фигура 3: Независими обучаващи се агенти в четирите матрични игри: в дилемата на затворника те стигат до взаимно предателство, в „лов на елен“ и „битка на половете“ се установяват в чисто равновесие, а в „съвпадение на монети“ не се сближават (при начало извън центъра траекторията се отдалечава от смесеното равновесие на Неш, вместо да се установи в него). Контрастът показва нагледно защо са нужни механизми за координация.




Фигура 4: Нестационарността отблизо: при „съвпадение на монети“ разстоянието до смесеното равновесие на Нaш не намалява, а расте през последователните времеви прозорци (от 0,30 до 0,48); траекторията се отдалечава по спирала към границата. Последната итерация не се сближава, колкото и дълго да продължи обучението.

9.5 Централизирано обучение, децентрализирано изпълнение (CTDE)

Първата структурна корекция запазва изпълнението реалистично – всеки агент все още действа въз основа на собственото си наблюдение – като същевременно дава на *обучаващия се агент* привилегирован достъп до информация по време на обучение. Архетипът е **MADDPG** (Lowe и др., 2017): актьорът $\pi_i(a_i \mid o_i)$ на всеки агент вижда само собственото си наблюдение, но централизираният оценител $Q_i(s, a_1, \dots, a_N)$ вижда глобалното състояние и действието на *всеки* агент. Асиметрията е същността на подхода. Оценителят за всеки агент, който наблюдава само o_i , се

сблъсква с нестационарен, частично наблюдаван свят, така че идентични входи водят до различни възвръщаемости и неговата целева стойност е шумна; централизиранят оценител, който отчита цялата информация, вижда целева стойност, която е (почти) детерминистична, затова дава обучаващ сигнал със значително по-ниска дисперсия. **MARPO** (Yu и др., 2022) е минималната версия: обикновен PPO с една централизирана функция на стойността $V(s)$ на глобалното състояние вместо отделна $V(o_i)$ за всеки агент, и е силна базова линия, която често не отстъпва на по-сложни методи – предупреждение срещу прекалено усложняване.



Фигура 5: Архитектура CTDE. По време на обучението централизиран оценител (или функция на стойността) вижда глобалното състояние и съвместното действие и дава целеви стойности с ниска дисперсия; по време на изпълнението всеки актьор действа само въз основа на собственото си локално наблюдение, без достъп до оценителя и без обмен на съобщения. Асиметрията между обучение и изпълнение прави света стационарен в очите на обучаващия се агент, без да се „мами“ по време на реалната игра.

Има ли централизиранят оценител действително по-ниска дисперсия? Измерено в едностъпкова кооперативна „референциална“ задача (говорителят вижда целта, слушателят – не, а двамата трябва да я назоват), след обучение до сходимост:

Таблица 3: Централизиран срещу независим оценител:
краен остатък на грешката на функцията на стойността.

Оценител	Краен остатък (грешка на функцията на стойността)
централизиран $Q(s, a_1, \dots, a_N)$	$3,2 \times 10^{-11}$
независим $Q_i(o_i)$	0,077

Централизираният оценител свежда остатъка си практически до нула – той вижда целта и съвместното действие, така че наградата е детерминистична функция на неговите входи – докато независимият оценител не може да види целта и остава блокиран в прогнозирането на базовата честота. Това потвърждава, че централизираният оценител напасва целевата си стойност много по-точно. Това само по себе си не означава по-ниска дисперсия на градиента на стратегията: при сходили оценители централизираният оценител може дори да я увеличи (Lyu и др., 2021).⁷

Но по-точният оценител не е същото като решаването на координацията и именно тук една прогноза се провали.

Съпоставка (запазена прогноза → какво всъщност се случи). Прогнозирах, че в играта „изкачване“ на Claus и Boutilier⁸ – кооперативна матрична игра без състояние, чийто оптимум (11) е фланкиран от –30 санкции за некоординация, с „безопасен“ атрактор при 5 – централизираният оценител ще избяга от капана и ще достигне оптимума, побеждавайки независимите обучаващи се агенти. Това не се случи. Измерени награди при алчна стратегия: **независими обучаващи се агенти 7, MADDPG 5, MAPPO 7** (оптимум 11, безопасна стойност 5). Нито един метод не достигна оптимума, а MADDPG всъщност *изостана* както спрямо IL, така и спрямо MAPPO. (Използваният вариант на MADDPG за дискретни действия заменя детерминистичния градиент на стратегията с контрафактична базова линия в стила на COMA (Foerster и др., 2018),⁹ затова резултатът се отнася до този вариант, а не до MADDPG в оригиналния му вид.) Честното тълкуване: централизираният оценител напасва целевата си стойност много по-точно (потвърдено по-горе), но това **не е достатъчно**, за да преодолее относителното свръхобобщаване¹⁰ и трудното изследване, което санкциите от –30 налагат – агентите няма да опитат рискованото съвместно действие достатъчно дълго, за да открият 11. Това, че MADDPG остава под IL, насочва вниманието към дискретното обновяване на

⁷Lyu, X., Xiao, Y., Daley, B. & Amato, C. (2021). “Contrasting Centralized and Decentralized Critics in Multi-Agent Reinforcement Learning.” AAMAS, 844–852. arXiv:2102.04402 – при сходили оценители по текущата стратегия централизираният оценител дава на децентрализираните актьори обновявания с по-висока дисперсия. Версия в списание: Lyu, X., Baisero, A., Xiao, Y., Daley, B. & Amato, C. (2023). JAIR 77, 295–354. DOI 10.1613/jair.1.14386.

⁸Claus, C. & Boutilier, C. (1998). “The Dynamics of Reinforcement Learning in Cooperative Multiagent Systems.” AAAI, 746–752.


⁹Foerster, J., Farquhar, G., Afouras, T., Nardelli, N. & Whiteson, S. (2018). “Counterfactual Multi-Agent Policy Gradients.” AAAI 32(1). DOI 10.1609/aaai.v32i1.11794 (COMA).

¹⁰Matignon, L., Laurent, G. J. & Le Fort-Piat, N. (2012). “Independent reinforcement learners in cooperative Markov games: a survey regarding coordination problems.” Knowledge Engineering Review 27(1), 1–31. DOI 10.1017/S0269888912000057.

актьора с контрафактична базова линия – то трябва да бъде проверено първо. Урокът оцелява в по-сдържан вид: **CTDE осигурява по-добър оценител, но не и автоматична координация.**

Методологическа бележка, която си струва да се запомни: и двата ефекта на CTDE по-горе бяха **невидими при бързата конфигурация за проверка (smoke)** – там загубите на оценителя бяха почти еднакви, а ползата от комуникацията (раздел 9.7) беше нула. Те се проявиха едва след обучение до сходимост в по-голямата конфигурация в пълен мащаб (scale). Бързата проверка показва, че кодът работи; за да се наблюдават явленията, е необходимо обучение до сходимост.¹¹

¹¹Lowe, R. et al. (2017). “Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments.” *NeurIPS* (MADDPG); и Yu, C., Velu, A., Vinitsky, E., Gao, J., Wang, Y., Bayen, A. & Wu, Y. (2022). “The Surprising Effectiveness of PPO in Cooperative, Multi-Agent Games.” *NeurIPS Datasets and Benchmarks Track*. arXiv:2103.01955 (MAPPO).




Фигура 6: Резултати за кооперативното CTDE и за комуникацията (конфигурация в пълен мащаб). Горе вляво: остатъкът на централизирания оценител е с порядъци по-малък от този на независимия (логаритмична скала). Горе вдясно: комуникацията издига слушателя далеч над тавана при случайно отгатване $1/K$ (вж. раздел 9.7). Долу: в играта „изкачване“ нито един метод не достига оптимума (11); MADDPG (5) изостава от IL и MAPPO (7) – CTDE намалява дисперсията на оценителя, но само по себе си не решава координацията, когато изследването е трудно.

9.6 PSRO – теория на игрите върху популация от стратегии

Втората структурна корекция е водещата нишка на главата и прекият наследник на **итерирания най-добър отговор** от Глава 2. **PSRO** (Policy-Space Response Oracles; Lanctot и др., 2017) разглежда цели стратегии като атомите на една по-висша игра. То поддържа **популация** от стратегии за всеки играч, изгражда емпиричната матрица на печалбите на **мета-играта** между популациите, решава **мета-Наш равновесие** върху нея, обучава **най-добър отговор** (оракул) на мета-Наш сместа на противника и добавя този отговор към популацията; цикълът се повтаря. То обединява

самообучението, фиктивната игра и метода на **двойния оракул** в една рамка и, което е от решаващо значение за този проект, неговата метрика за прогрес е *експлоатируемост* – същата NashConv, използвана в Глави 2–8.

PSRO = итерираният най-добър отговор от Глава 2, пренесен от действия към цели стратегии.



Фигура 7: Цикълът на двойния оракул в PSRO. От текущите популации се построява матрицата на печалбите на мета-играта и се намира нейната мета-Наш смес; оракулът за най-добър отговор изчислява отговор на сместа на противника и новата стратегия се добавя към популацията. Очаква се експлоатируемостта на мета-Наш сместа да намалява с нарастването на популацията. В този проект оракулът е точният най-добър отговор от Глава 7, затова сходимостта на PSRO се измерва със същата мярка за експлоатируемост като в главите по теория на игрите.

Два факта правят имплементацията точна, а не приблизителна. Първо, оракулът използва повторно **точния най-добър отговор** от Глава 7 за игрите Кун и Ледюк. Второ, мета-Наш сместа на противника върху *поведенчески стратегии* е, съгласно теоремата на Кун¹² (тъй като тези игри са с пълна памет), реализационно еквивалентна на **една единствена поведенческа стратегия**; свеждането на сместа по този начин позволява модулът за точен най-добър отговор да се приложи директно.

¹²Kuhn, H. W. (1953). "Extensive Games and the Problem of Information." *Contributions to the Theory of Games II*, 193–216. DOI 10.1515/9781400881970-012.

Защо популация, а не просто последната стратегия от самообучението? Защото самообучението се сближава в *средното*, а не в последната итерация. Измерено върху **Кун** при фиктивна игра със самообучение: експлоатируемостта на **средната** итерация спадна от 0,24 до 0,031 за 200 итерации, докато експлоатируемостта на **последната** итерация продължи да осцилира между 0,33 и 0,83. Доверяването на последната стратегия би означавало да се доверим на стойност, която никога не се установява; мета-сместа на PSRO е популационната версия на осредняването, върху което се основават CFR и фиктивната игра.

Сходимост на PSRO, измерена (експлоатируемост = NashConv на мета-Наш сместа в цялата игра):

Таблица 4: Траектория на експлоатируемостта при PSRO, по семейство игри.

Игра	Траектория на експлоатируемостта	Извод
Кун покер	$0,917 \rightarrow \sim 2 \times 10^{-16}$ до кръг 6	сближава се до машинна нула
матрична игра („съвпадение на монети“)	$2,0 \rightarrow 0$ до кръг 2	сближава се
камък-ножица-хартия (изследване)	$2,0 \rightarrow 0,017$; популация $\rightarrow \{R,P,S\}$, смес $\rightarrow$ равномерна	сближава се
Ледюк Холдем	$4,75 \rightarrow 2,16$ за 20 кръга	намалява, но е далеч над целта
Goofspiel ($K = 3$, бърза проверка)	$1,33 \rightarrow 0$	сближава се
Goofspiel ($K = 4$)	колебае се $1,24 \leftrightarrow 2,0$ (8 кръга)	не се установява


Резултатите за **Кун** / матрица / RPS са учебникови: при малките игри популацията бързо обхваща необходимите стратегии и експлоатируемостта рязко спада. Два резултата не се развиха според очакванията.¹³

Съпоставка 1 (Ледюк). Прогнозирах, че PSRO ще намали експлоатируемостта на Ледюк под 0,5 в рамките на 20 итерации. Измерено, тя спадна от 4,75 до 2,16 - след силни колебания през първите осем кръга (до 6,83) следва ясно намаление, но стойността остава далеч от 0,5. Това е **истинска бавна сходимост**, а не грешка: Кун достигна машинна нула за 6 кръга, но игровото дърво на Ледюк е много по-голямо и популация от 20 *чисти* най-добри отговора просто е твърде малка, за да приближи добре неговото


¹³Lanctot, M. et al. (2017). “A Unified Game-Theoretic Approach to Multiagent Reinforcement Learning.” *NeurIPS* (PSRO). Свързани: McMahan, H. B., Gordon, G. & Blum, A. (2003). “Planning in the Presence of Cost Functions Controlled by an Adversary.” *ICML* (методът на двойния оракул, който PSRO обобщава); Tuyls, K. et al. (2020). “Bounds and dynamics for empirical game theoretic analysis.” *Autonomous Agents and Multi-Agent Systems* 34(1), art. 7. DOI 10.1007/s10458-019-09432-y (EGTA).

смесено равновесие на Наш. Целта „ $< 0,5$ за 20“ беше оптимистична. Изводът – експлоатируемостта намалява с нарастването на популацията – остава валиден; *скоростта* е стената на мащабиране и тя се вписва в откритието от Глава 8 за глобално спрямо локално мащабиране.

Съпоставка 2 (Goofspiel $K = 4$). Прогнозирах ненарастваща експлоатируемост. При $K = 3$ (бърза проверка) тя се сближи до 0 напълно; при $K = 4$ тя осцилира между $\sim 1,2$ и $2,0$ и не се установява. Това е единственият резултат, който все още не мога да обясня напълно и съгласно работния процес аз го **документирам, а не го коригирам**. Две конкретни подозрения за последваща сесия: драйверът на PSRO за Goofspiel никога не премахва дублиращите се стратегии за най-добър отговор (така че мета-играта може да спре поради повторения) и популация от чисти стратегии вероятно е твърде слаба, за да представи смесения мета-Наш на по-голямата игра. Маркирано като отворен елемент в кода, а не като валидиран резултат.



Фигура 8: Експлоатируемост при PSRO спрямо размера на популацията в различни игри (конфигурация в пълен мащаб). При Кун и при матричната игра тя спада до (почти) нула за няколко кръга; при Ледюк силно се колебае през първите осем кръга, след което намалява, но след 20 кръга остава далеч над целта 0,5 (стената на мащабиране за популация от чисти стратегии); при Goofspiel с $K = 4$ се колебае, без да се установи (отбелязана аномалия). Точният оракул за най-добър отговор гарантира сходимост по принцип; размерът на играта определя скоростта.



Фигура 9: Самообучение в Кун: експлоатируемостта (NashConv) на средната стратегия постепенно спада към нула, докато тази на последната итерация продължава да се колебае. Затова самообучението и PSRO разчитат на осредняване по популацията, а не на последната стратегия.

9.7 Научена комуникация (CommNet)

CTDE централизира информацията по време на *обучение*; комуникацията я централизира по време на *изпълнение* чрез канал, който агентите **научават**, а не такъв, който дизайнерът изгражда. В **CommNet** (Sukhbaatar и др., 2016) всеки агент кодира своето наблюдение в скрит вектор, излъчва **съобщение**, и след това получава **средната стойност** на съобщенията на останалите агенти като допълнителен вход за своята стратегия. Цялото се обучава от край до край, така че протоколът възниква: в референциалната задача говорителят (който единствен вижда целта) трябва да се научи да я кодира, а слушателят – да я декодира.

Тестът е показателен, тъй като без канал слушателят е ограничен единствено до чисто отгатване, $1/K$. Измерено (конфигурация в пълен мащаб, $K = 5$, при което таванът при случайно отгатване е 0,2):

Таблица 5: Научена комуникация: отборна награда при включен и изключен канал.

Канал	Отборна награда (алчна стратегия)
с комуникация	0,795
без комуникация	0,204

С канала слушателят се издига далеч над тавана от $1/K$; без него той остава точно на тавана. Комуникацията върши реална работа – и обърнете внимание, че изводът от съпоставката в раздел 9.5 важи и тук: при конфигурацията за бърза проверка и двете числа бяха 0,24 (каналът все още не се беше научил да пренася информация), а ползата се появи едва след обучението в пълен мащаб.¹⁴

9.8 LOLA – моделиране на противника като учещ се агент

Всеки метод досега разглежда стратегията на противника като фиксирана, докато агентът реагира. **LOLA** (обучение с осъзнаване за ученето на противника; Foerster и др., 2018) е изключението и е този, който е най-пряко свързан с дисертацията. Вместо да се оптимизира спрямо *настоящата* стратегия на противника, всеки агент се оптимизира спрямо стратегията, която противникът ще има *след една стъпка на обучение*, като диференцира *през* тази стъпка на обучение. Допълнителният член представлява смесена втора производна – как актуализацията на стратегията на противника зависи от *моите* параметри – и именно той превръща егоистичните агенти в кооперативни.

Класическата демонстрация е **повтарящата се дилема на затворника** с памет 1, при която стратегията на всеки агент се състои от пет вероятности за сътрудничество, а очакваната дисконтирана възвръщаемост има затворена форма чрез стационарната марковска верига върху двойките резултати. Наивните градиентни агенти, всеки от които максимизира собствената си възвръщаемост спрямо текущата стратегия на другия, стигат до взаимно предателство, докато агентите с **LOLA**, всеки от които отчита предстоящото обновяване на другия, достигат взаимно сътрудничество.

Измерено (дисконтирана възвръщаемост на стъпка; пълно сътрудничество ≈ 3 , взаимно предателство ≈ 1):

¹⁴Sukhbaatar, S., Szlam, A. & Fergus, R. (2016). “Learning Multiagent Communication with Backpropagation.” *NeurIPS* (CommNet).


Таблица 6: LOLA срещу наивни обучаващи се агенти в повтарящата се дилема на затворника.

Обучаващи се	Възвръщаемост
наивни срещу наивни	1,04
LOLA срещу LOLA	2,82

Посоката е точно резултатът на LOLA – сътрудничеството възниква там, където наивното обучение води до предателство. (Моята прогноза за ≈ 3 беше малко завишена; измерената 2,82 е близка до пълно сътрудничество, а в изследователското изпълнение с по-голяма **скорост на обучение при предвиждане** двамата агенти достигнаха 2,67 и 2,93 (средно 2,80).) Вградена **проверка за коректност** потвърждава механизма: задаването на **скоростта на обучение при предвиждане** на нула кара **градиента** на LOLA да се редуцира точно до **наивния градиент**, така че сътрудничеството произтича именно от члена за **предвиждане** от втори ред.

Концептуално това представлява **динамично** моделиране на противника: Глава 7 извежда *текущата* стратегия на противника; LOLA предвижда неговата *траектория на обучение*. Съчетаването на двете – статична преценка, която задава началото на динамичното предвиждане – е кандидат за Принос №1, а не нещо вече решено.¹⁵

¹⁵Foerster, J., Chen, R. Y., Al-Shedivat, M., Whiteson, S., Abbeel, P. & Mordatch, I. (2018). “Learning with Opponent-Learning Awareness.” AAMAS, 122–130. arXiv:1709.04326 (LOLA).



Фигура 10: LOLA срещу наивни обучаващи се агенти в повтарящата се дилема на затворника: при наивните агенти възвръщаемостта на стъпка спада към взаимно предателство (~ 1), а при агентите с LOLA нараства към взаимно сътрудничество ($\sim 2,8$, средно за двамата агенти). Именно предвиждането на следващата стъпка на обучение на противника превръща динамиката от предателство в сътрудничество.

9.9 Честни бележки, ограничения и връзка със следващите глави

Какво се задържа. Потвърдените резултати са гръбнакът: независимото обучение се сближава в игрите с доминираща стратегия и в координационните игри и *се проваля* в „съвпадение на монети“; PSRO свежда експлоатируемостта до (почти) нула при Кун, матричната игра и RPS с точен оракул; самообучението се сближава в средното, но не и в последната итерация; остатъкът на централизирания оценител е с порядъци по-малък; научената комуникация издига слушателя над тавана при случайно отгатване; и LOLA превръща предателството в повтарящата се дилема на затворника в сътрудничество. Взети заедно, те проследяват предвидената дъга – от „защо наивното обучение се разпада“ до „структурните поправки, които го възстановяват“.

Какво не успя и защо това е от значение. Четири честни уговори остават в сила и за следващите глави. (1) При фиксирана стъпка траекторията в „съвпадение на монети“ се отклонява към границата, вместо да обикаля – по-остра версия на урока за несходимост. (2) PSRO при Ледюк се сближава *бавно* (експлоатируемост $\sim 2,16$ след 20 кръга, а не $< 0,5$) – стена на мащабиране на по-

пулацията с чисти стратегии. (3) Goofspiel $K = 4$ се колебае, вместо да се сближава – маркирана, необяснена аномалия в кода (документирана, но не поправена). (4) При играта „изкачване“ нито един метод не достигна оптимума и MADDPG се представи по-зле от независимите обучаващи се агенти – централизираният оценител намалява остатъка си, но сам по себе си не решава координатията, когато изследването е трудно. Двата елемента на кода (Goofspiel $K = 4$; контрафактична базова линия на MADDPG) трябва да бъдат разгледани, преди тези части да бъдат използвани отново. И един методологичен момент: ефектите при невронните мрежи бяха невидими при бързата проверка и се появиха едва в пълен мащаб, така че твърденията почиват именно на числата от конфигурацията в пълен мащаб.

Доверие. Всяка цел на равновесие е *точна* (аналитично равновесие на Наш за матричните игри; точен най-добър отговор и NashConv от Глава 7 за Кун/Ледюк/Goofspiel), така че игровитеоретичните резултати се ограничават от обективната истина, а не от други симулации. Невронните резултати представляват качествени неравенства (централизиран $<$ независим; с комуникация $>$ без комуникация), а не точни стойности, и по конструкция са чувствителни към началното число и версията. Графиките на експериментите по-горе са генерирани от JSON файловете с резултати, записани в хранилището (вж. `../figures/README.md`).

Връзки с предходните и следващите глави. Назад: PSRO представлява итерираният най-добър отговор от Глава 2, издигнат до ниво популация, и използва изцяло модула за точен най-добър отговор от Глава 7; стената на мащабиране при Ледюк отеква откритието глобално срещу локално от Глава 8. Напред: трите връзки с дисертацията вече са конкретни – LOLA като динамично моделиране на противника (Принос №1), мета-играта на PSRO като методология за оценяване (Принос №3) и, преди всичко, **липсващата минимаксна опора при $N > 2$** (Принос №2), единственото място, където престава да важи всяка гаранция за игри с двама играчи от глави 2–8.

9.10 Основни изводи за синтеза на дисертацията

- **Нестационарността е основният проблем и тя е структурна, а не въпрос на изчислителен бюджет** – в „съвпадение на монети“ последната итерация не се сближава, колкото и дълго да продължи обучението.
- **CTDE централизира оценителя по време на обучението и децентрализира актьора при изпълнението**; измерено е, че централизираният оценител напасва целевата си стойност почти без остатък ($3,2 \times 10^{-11}$ спрямо 0,077) – но по-точният оценител не реши играта „изкачване“: той не е достатъчен за координатия.
- **PSRO е мостът между теорията на игрите и MARL**: измерено е, че довежда Кун до експлоатируемост, равна на машинната нула, а RPS – до равномерна смес; Ледюк намалява, но достига стена на мащабиране – същата стена, която мотивира мащабируемите методи в дисертацията.
- **Самообучението и PSRO успяват чрез средното и популацията, а не чрез последната**

итерация (средната NashConv на Кун $0,24 \rightarrow 0.031$, докато последната итерация се колебае) – причината да съществува популация.

- **LOLA разглежда противника като учещ се агент** и превръща предателството в IPD в сътрудничество ($1,04 \rightarrow 2.82$) – динамичното допълнение към статичния модел на противника от Глава 7 (Принос №1).
- **Липсата на минимаксна стойност при $N > 2$ е отворената врата към дисертацията** (Принос №2): речникът на глави 2–8 преминава в MARL, но опората на безопасността – не.