

Глава 10 Обобщение - Обучение на базата на популации и еволюционна теория на игрите

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Съдържание

10 Глава 10 - Обучение на базата на популации и еволюционна теория на игрите	1
10.1 Защо популации - и защо структурата определя всичко	2
10.2 Семейството от методи	2
10.3 Репликаторна динамика - къде една популация може да се установи	4
10.4 „Пумпалът“ - транзитивна и циклична структура	7
10.5 PBT лига в стила на AlphaStar	10
10.6 Разнообразие - наистина ли популацията е разнообразна?	13
10.7 EGTA - оценка на популацията и неочаквано откритие	15
10.8 Честни бележки, ограничения и предаване на щафетата	17
10.9 Основни изводи за синтеза на дисертацията	18

10 Глава 10 - Обучение на базата на популации и еволюционна теория на игрите

Тази глава изгражда от основите темата за обучение и оценка на **популации** от агенти: еволюционната математика, която определя дали дадена популация изобщо може да се установи в равновесие, транзитивната/циклична структура, която решава дали процесът на самообучение ще се сближи или ще се завърти, и малка **лига** в стила на AlphaStar, изградена върху решим вариант на покер. Написана е така, че да може да се чете независимо от останалите глави. **Всички експериментални резултати, представени тук, са получени** от възпроизводими изпълнения и, когато е възможно, са съпоставени с *точни* еталонни стойности (аналитичните ESS и равновесия на Наш за матричните игри; точната експлоатируемост спрямо най-добър отговор от Глава 7 за Ледюк). Когато дадено изпълнение противоречи на очакванията, произтичащи от теорията, запазвам първоначалното теоретично предвиждане и го съпоставям с получените резултати - именно тези разминавания са най-показателните части от главата.

Място в дисертацията. Глави 2–8 решават *една* фиксирана игра; Глава 9 добавя *втори* обучаващ се агент. Глава 10 преминава към *цяла популация*, която се обучава срещу себе си. Тя има три

връзки с приносите на дисертацията. **Основните експлоататори** на практика са автоматизирани модели на противника - статичната преценка за противника от Глава 7, пренесена на ниво популация (Принос №1). **Лигата на AlphaStar** използва експлоататори, за да направи основните агенти устойчиви - механизъм, близък до безопасната експлоатация на ниво популация, но без формална гаранция: авторите обосновават подхода с фиктивната игра срещу себе си, чиято смес се сближава към равновесие на Наш при игри за двама с нулева сума, а устойчивостта на лигата показват само емпирично¹. Точно тук се намира Принос №2. А **EGTA / мета-Наш** е методологията за оценяване на популацията (Принос №3).

10.1 Защо популации - и защо структурата определя всичко

Самообучението има известен **режим на отказ**: играч, който тренира единствено срещу самия себе си, може да се върти в кръг. Ако играта е **камък-ножица-хартия**, „да станеш по-добър“ няма смисъл - камък побеждава ножица, губи от хартия и подобряването срещу един противник просто те прави по-лош срещу друг. Най-важната идея в тази глава е, че игрите имат два вида структура, смесени заедно: **транзитивна** част (истинска **стълбица на уменията** - съществува *по-добър играч*) и **циклична** част (**кръг от контрастратегии** - има само *какво побеждава какво*). Дали една **самообучаваща се популация** ще се сближи до нещо добро или ще се върти вечно, зависи от това *коя част е доминираща*, а не от **скоростта на обучение**.

Една представа, която да запомните: **доджо**. **Основните ученици** са това, което се опитвате да създадете. Поддържате зала, пълна със **спаринг партньори**, чиято единствена задача е да откриват и наказват конкретна слабост в настоящите ученици (експлоататори). И поддържате **музей на минали шампиони** - замразени „снимки“ - така че никой да не печели, като забрави как да победи стар стил. Обучението тогава представлява цикъл: учениците тренират помежду си, по-силните се копират и леко се изменят (**обучение на базата на популации**), а периодично копие на всички се замразява в музея. Лигата е това доджо, превърнато в математическа форма.¹

10.2 Семейството от методи

Всеки от разгледаните методи представлява различен начин за превръщане на **популацията** в тренировъчен сигнал или средство за оценка.

¹Vinyals, O. et al. (2019). “Grandmaster level in StarCraft II using multi-agent reinforcement learning.” *Nature* 575(7782), 350–354. DOI 10.1038/s41586-019-1724-z (AlphaStar; лигата и PFSP).

Таблица 1: Семействата методи, базирани на популации:
какво прави всеки, кога да се използва и основната му
слабост.

Подход	Какво прави	Кога да се използва	Основна слабост
Самообучение	обучава последната стратегия срещу (копие на) самата себе си	транзитивни игри; бърза базова линия	зацикля и забравя в цикличните игри; последната итерация не се сближава
PSRO	популация + мета-Наш + оракул за най-добър отговор; добавя най-добрия отговор, повтаря	състезателни игри; търси се игровотеоретична цел	пълен най-добър отговор на всеки кръг; <i>сместа</i> не е решението (вж. §10.7)
PBT	обучава много агенти; копира по-приспособените (експлоатация) + променя хиперпараметри (изследване)	всяка популация; онлайн търсене на хиперпараметри	може да загуби разнообразието си или да регресира (вж. §10.5)
Лига в стила на AlphaStar	PBT с три типа агенти (основни агенти / основни експлоататори / експлоататори на лигата) + замразяване + PFSP	нетранзитивни игри, където наивното самообучение зацикля	много агенти, големи изчислителни разходи; евристичен метод без гаранция за безопасност

Два инструмента за оценка са общи за всички тях. **Репликаторната динамика** (§10.3) е непрекъснатата идеализация на подбора - тя показва накъде се движи една популация и къде може да се установи. **Декомпозицията „пумпал“** (§10.4) измерва доколко една игра (или популация) е транзитивна или циклична. Заедно те представляват диагностика, която предсказва, *преди* да бъдат направени изчислителните разходи, дали лигата от §10.5 ще се установи или ще се завърти.

Исторически линията е следната: обучение на базата на популации като онлайн търсене на хиперпараметри (PBT, 2017)² → теория на игрите върху популация от стратегии (PSRO, 2017)³ → ли-

²Jaderberg, M., Dalibard, V., Osindero, S., Czarnecki, W. M. et al. (2017). “Population Based Training of Neural Networks.” *arXiv:1711.09846*.

³Lanctot, M. et al. (2017). “A Unified Game-Theoretic Approach to Multiagent Reinforcement Learning.” *NeurIPS* (PSRO). Вж.

гата с три типа агенти, достигнала ниво „гросмайстор“ в StarCraft II - над 99.8% от класираните човешки играчи (AlphaStar, 2019)¹ → геометрията, която обяснява *защо* е необходима популация (транзитивно-циклична декомпозиция, 2018-2019; „пумпал“, 2020)⁴. Такива популации се оценяват с емпиричен теоретико-игрови анализ (EGTA)⁵⁶.

10.3 Репликаторна динамика - къде една популация може да се установи

Репликаторното уравнение е най-простият модел на подбора: делът на дадена стратегия нараства пропорционално на това колко тя превъзхожда средната за популацията.

$$\dot{x}_i = x_i [f_i(x) - \bar{f}(x)], \quad \bar{f}(x) = \sum_j x_j f_j(x).$$

Всяко равновесие на Наш е точка на покой, но не и обратното - например всяка чиста стратегия също е точка на покой. Устойчивите точки на покой обаче винаги са равновесия на Наш, а всяка **еволюционно стабилна стратегия (ESS)** - чиста или смесена стратегия, която, възприета от цялата популация, не може да бъде изместена от малък дял мутанти - е асимптотично устойчива точка на покой⁷. Това е непрекъснатата идеализация на онова, което РВТ лигата прави дискретно: копира по-успешните агенти (подбор) и внася малки случайни промени в тях (мутация).

също: McMahan, H. B., Gordon, G. & Blum, A. (2003). "Planning in the Presence of Cost Functions Controlled by an Adversary." *ICML*, 536–543 (методът на двойния оракул, който PSRO обобщава).

⁴Czarnecki, W. M., Gidel, G., Tracey, B., Tuyls, K., Omidshafiei, S., Balduzzi, D. & Jaderberg, M. (2020). "Real World Games Look Like Spinning Tops." *NeurIPS*; arXiv:2004.09468 - геометрията „пумпал“ и защо обучението изисква популации.

⁵Wellman, M. P. (2006). "Methods for Empirical Game-Theoretic Analysis." *AAAI*, 1552–1555.

⁶Tuyls, K., Pérolat, J., Lanctot, M., Hughes, E., Everett, R., Leibo, J. Z., Szepesvári, C. & Graepel, T. (2020). "Bounds and dynamics for empirical game theoretic analysis." *Autonomous Agents and Multi-Agent Systems* 34(1), 7. DOI 10.1007/s10458-019-09432-y.

⁷Hofbauer, J. & Sigmund, K. (2003). "Evolutionary game dynamics." *Bulletin of the American Mathematical Society* 40(4), 479–519 - т.нар. „фолклорна теорема“ за репликаторната динамика (§2.3), асимптотичната устойчивост на ESS (§2.6) и затворените орбити при „камък-ножица-хартия“ (теорема 2).



пунктир = „дискретен аналог на“: лигата е репликаторна динамика с обучаващи се агенти вместо фиксирани дялове на стратегиите

Фигура 1: Еволюционната теория на игрите като непрекъсната идеализация на РВТ лигата: подборът в репликаторната динамика съответства на копирането на по-успешните агенти, мутацията (дрейфът) - на промяната на скоростта на обучение и на ентропията, а устойчивите точки на покой (ESS) - на мета-Наш сместа, към която се стреми лигата. Лигата е репликаторна динамика, в която вместо фиксирани дялове на стратегиите участват обучаващи се агенти.


При четири канонични симетрични игри (динамиката е детерминистична, затова резултатът е еднозначен) измерените резултати съвпадат напълно с теорията:

Таблица 2: Репликаторна динамика върху четири симетрични игри, спрямо аналитичния еталон.

Игра	Аналитичен еталон	Измерено крайно състояние	Сходим?
Дилемата на затворника	предателството доминира; ESS (0, 1)	[0.0, 1.0]	да
Ястреб-гълъб	вътрешна ESS $p(\text{ястреб}) = V/C = 0.5$	[0.5, 0.5] (орбитален радиус 0.0)	да
Камък-ножица-хартия	равновесие на Наш = равномерна стратегия; няма ESS	обикаля около центъра на разстояние 0.095	не
Лов на елен	две чисти ESS (според басейна на привличане)	[0.8, 0.2] $\rightarrow$ [1, 0]; [0.2, 0.8] $\rightarrow$ [0, 1]	да

Дилемата на затворника се свежда до доминиращата стратегия; ястреб-гълъб *достига* вътрешната 0.5 ESS; ловът на елен избира различна чиста ESS в зависимост от басейна на привличане, в който попада началната точка. **Камък-ножица-хартия никога не се сближава** - вътрешната ѝ неподвижна точка е *център*, така че популацията обикаля около нея завинаги (в непрекъснато време орбитите са затворени; явният метод на Ойлер ги превръща в бавно разширяваща се спирала). Този последен ред е цялата мотивация за останалата част от главата: цикличната игра няма стабилна популация.⁸

⁸Hofbauer, J. & Sigmund, K. (1998). *Evolutionary Games and Population Dynamics* (Cambridge) - репликаторна динамика, ESS и центъра при „камък-ножица-хартия“; вж. също обзора на Bloembergen, Tuyls, Hennes & Kaisers (JAIR 53, 659–697, 2015), който свързва репликаторната динамика с многоагентното обучение.




Фигура 2: Траектории на репликаторната динамика (дял на първата стратегия във времето): в дилемата на затворника популацията стига до всеобщо предателство, в „ястреб-гълъб“ - до вътрешната ESS с дял 0.5 на ястребите, в „камък-ножица-хартия“ обикаля около центъра, без да се сближава, а в „лов на елен“ стига до „всички ловуват елен“ или „всички ловуват заек“ в зависимост от началната точка. Тази несходяща орбита показва защо популациите в циклични игри се нуждаят от специални механизми, за да не се въртят в кръг.

10.4 „Пумпалът“ - транзитивна и циклична структура

Ако цикличните игри са проблемът, необходимо е да *измерим* степента им на цикличност. **Декомпозицията „пумпал“** разделя матрицата на печалбите на една игра на **транзитивна** компонента (стълбица на уменията, изразена чрез рейтинг на всяка стратегия) и **циклична** компонента (оста-

тъкът - частта „камък-ножица-хартя“)⁹. Името идва от формата, която Czarnecki и др. откриват при реални игри: те са най-широки (най-циклични) при стратегиите със средна сила и се стесняват към крайностите на уменията⁴.



една и съща игра, различни популации: популацията от най-добри отговори (PSRO) е в широката циклична част, а популацията от моментни снимки (лигата) се изкачва по транзитивната ос.

Фигура 3: „Пумпалът“ (схема): вертикалната ос е транзитивната сила (умението - съществува по-добър играч), а ширината е цикличното измерение (броят на контрастратегии, структурата „камък-ножица-хартя“). „Камък-ножица-хартя“ е в най-широката циклична част (транзитивно съотношение 0.0), чистата стълбица на уменията е върху транзитивната ос (1.0), мета-играта на най-добрите отговори в PSRO за Ледюк е в широката циклична част (транзитивно съотношение ~ 0.45), а мета-играта на моментните снимки на лигата се изкачва по транзитивната ос ($\sim 0.94-0.98$). T - транзитивно, C - циклично съотношение.

Една тънкоост заслужава внимание: първоначалният план предлагаше декомпозиция чрез **SVD** с

⁹Balduzzi, D., Tuyls, K., Pérolat, J. & Graepel, T. (2018). “Re-evaluating Evaluation.” *NeurIPS*; arXiv:1806.02643 - разлагане на Ходж на антисиметричната матрица на печалбите на транзитивна и циклична компонента; усредняване по Наш.

ранг 1, която неправилно дава транзитивно съотношение ≈ 0.707 за „камък-ножица-хартя“ - сингулярните стойности на антисиметрична матрица винаги са по двойки, затова приближението с ранг 1 обхваща най-много половината от квадрата на нормата ѝ при всяка игра. Реализацията използва вместо това комбинаторното разлагане на Ходж (по разлики в рейтингите)⁹, което правилно дава транзитивно съотношение 0.0 за „камък-ножица-хартя“. Измерено:


Таблица 3: Транзитивни и циклични компоненти на четири популации чрез комбинаторна декомпозиция на Ходж.

Популация	Транзитивна компонента (Ходж)	Циклична компонента	Структура
камък-ножица-хартя	0.0	1.0	чисто циклична
стълбица на уменията	1.0	0.0	чисто транзитивна
мета-игра на най-добрите отговори в PSRO (Ледюк)	0.41–0.46	0.89–0.91	предимно циклична (27 цикъла от три стратегии)
мета-игра на моментните снимки на лигата	0.94–0.98	-	предимно транзитивна

Двете *реални* популации са основният извод - и те си противоречат в рамките на една и съща игра.¹⁰

Съпоставка (запазена прогноза → какво всъщност се случи). Бях приел, че покерът е стълбица на уменията, и очаквах мета-играта на Ледюк да бъде предимно транзитивна. Измерванията показват, че тя зависи изцяло от това *коя популация се разлага*. Популация от **най-добри отговори** (PSRO) е предимно **циклична** (транзитивно съотношение ≈ 0.45 , 27 цикъла от три стратегии): най-добрият отговор побеждава текущата смес, по-нов най-добър отговор побеждава *него*, и така нататък - „пумпалът“ на Szarnecki и др. в действие. Популация от **моментни снимки на траекториите на обучение** (лигата) е предимно **транзитивна** (≈ 0.94 - 0.98), защото по-късните моментни снимки обикновено са по-силни от по-ранните, образувайки стълбица. Нито едното не е грешка; съотношението транзитивно/циклично е свойство на *популацията*, а изборът как да изградите популацията е избор дали ще видите кръг или стълбица.

¹⁰Balduzzi, D. et al. (2019). “Open-ended Learning in Symmetric Zero-sum Games.” *ICML* - разлагане на функционалните игри на транзитивна и циклична част; $\text{PSRO}_{\tau N}$.




Фигура 4: Транзитивно съотношение на четири популации: „камък-ножица-хартя“ (0.0, чисто циклична), чиста стълбица на уменията (1.0), мета-играта на най-добрите отговори в PSRO за Ледюк (~0.41-0.46, предимно циклична) и мета-играта на моментните снимки на лигата (~0.94-0.98, предимно транзитивна). Една и съща игра има противоположна структура в зависимост от това как е изградена популацията.

10.5 PBT лига в стила на AlphaStar

С помощта на диагнозата изграждаме доджото. Лигата обучава **невронни** PPO агенти на **Ледюк Холдем** с три типа агенти: **основни** агенти (продуктът; те играят срещу всички чрез PFSP самообучение), **основни експлоататори** (търсят слабости в *текущите* основни агенти) и **експлоататори на лигата** (търсят слабости навсякъде в *замразената история*). Обучението на базата на популации копира най-добрите агенти (експлоатация) и променя тяхната **скорост на обучение / ентропия** (изследване); периодически се добавя **замразена моментна снимка** на всеки агент в музея; вдвояването по **PFSP** (приоритизирана фиктивна игра срещу себе си, Prioritized Fictitious Self-Play) избира всеки противник с вероятност, която нараства според това колко е трудно да бъде победен. От решаващо значение е всяка **невронна мрежа** да бъде извлечена до **таблична** стратегия, така че **точният** най-добър отговор от Глава 7 да измерва нейната експлоатируемост - същият NashConv, използван още от Глава 2 (NashConv е сумата от печалбите на двата най-добри отговора; в конвенцията на OpenSpiel експлоатируемостта е половината от нея).

Сдвояване по PFSP: всеки противник се избира с вероятност, която расте с трудността да бъде победен (обучението се съсредоточава там, където агентът губи).



Фигура 5: Лигата: основни агенти (крайният продукт), основни експлоататори (търсят слабости в текущите основни агенти) и експлоататори на лигата (търсят слабости в цялата замразена история), с периодично замразяване на копия в „музей“ от моментни снимки и сдвояване по PFSP, което насочва обучението към противниците, срещу които агентът губи. PBT копира най-добрите агенти и променя хиперпараметрите им.


Подобрява ли се лигата? Резултатите от двете конфигурации (бърза проверка: 7 агента, 15 епохи; пълен мащаб: 8 агента, 120 епохи, 48 замразени моментни снимки) са следните:

Таблица 4: Показатели от обучението на лигата при двата мащаба.

Показател	Бърза проверка	Пълен мащаб
минимална експлоатируемост сред основните агенти	4.67 → 3.04 (най-ниската стойност е в края)	4.73 → мин ≈ 1.21 → 2.05
експлоатируемост на мета-Наш сместа	4.73 → 3.04	5.01 → мин ≈ 1.32 (плато 1.60) → 2.96

(Стойността 2.96 е за мета-Наш сместа на популацията в началото на епоха 119, преди последната стъпка на обучение; стойността 3.418 в §10.7 е за крайната популация от 56 агента.)

Съпоставка (запазена прогноза → какво всъщност се случи). Очаквах *монотонно* намаляване на експлоатируемостта. При бързата проверка (15 епохи) очакването се потвърждава: спадът е плавен и най-ниската стойност е в края. При пълния мащаб (120 епохи) картината е друга: експлоатируемостта спада рязко през първите около 15 епохи и е най-ниска около епохи 20-40 (мета-Наш сместа достига ≈ 1.32 в епоха 21, а най-добрата моментна снимка е от епоха 29; единичният минимум сред основните агенти, ≈ 1.21 , е в епоха 66). След плато (≈ 1.60 за мета-Наш сместа) тя **нараства отново** до $\approx 2.05 / \approx 2.96$ в епоха 119. Най-добрите агенти са *замразените моментни снимки* от първата половина на обучението; *активните* основни агенти се влошават към края - стратегиите им непрекъснато се сменят и част от наученото се забравя. Самообучението, което няма експлоататори, също се влошава след епоха 100, така че натискът на експлоататорите не е единственото обяснение. Това се вижда само при достатъчно дълго обучение: лигата не се подобрява монотонно. Възможното решение (непроверено тук) е запазване на най-добрата моментна снимка или регуляризация на популацията. Методологично това повтаря извода от Глава 9: **пълният мащаб разкрива това, което бързата проверка скрива.**



Фигура 6: Експлоатируемост (NashConv) на лигата за 120 епохи (пълен мащаб): минималната експлоатируемост сред основните агенти и тази на мета-Наш сместа спадат рязко през първите около 15 епохи, най-ниски са около епохи 20-40 и отново нарастват в края на обучението. Замразените моментни снимки запазват силните агенти от първата половина на обучението, а активните агенти се влошават към края. Пунктирната сива линия е самообучението (базова линия), което също се влошава след епоха 100.


10.6 Разнообразие - наистина ли популацията е разнообразна?

Лигата е толкова добра, колкото и *разнообразието* от стратегии, които съдържа. Измерваме три показателя: **ефективен размер на популацията** (коефициентът на участие на мета-Наш теглата), **поведенческа клъстеризация** (наистина ли стратегиите са различни?) и **покрытие на експлоатация**. Резултатите показват, че популацията е само слабо разнообразна: коефициентът на участие нараства от 1.0 (бърза проверка) до 1.9 (пълен мащаб), но поведенческата клъстеризация свежда всичко до **един клъстер** и при двата мащаба - дори при пълен мащаб, където максималното поведенческо разстояние между двойки (0.48) надвишава прага за клъстеризация (0.30), методът на единичното свързване обединява агентите във верига. Разнообразието тук е *на ниво тегла* (мета-Наш сместа разпределя теглото си между няколко агента), а не *на ниво поведение* (агентите играят почти еднакво).

Механизмът се проявява най-ясно в опростена среда - мини-PVT върху матрични игри:

Таблица 5: Разнообразие при мини-PBT през поколенията - върху транзитивна и върху циклична игра.

Игра	Разнообразие през поколенията
Дилемата на затворника (транзитивна)	спада до 0 (всички → предателство)
Камък-ножица-хартия (циклична)	непрекъснато се променя (0.07–0.29), никога не се установява




Фигура 7: Разнообразие при мини-PBT: в транзитивната дилема на затворника популацията се свежда до една-единствена стратегия (разнообразие $\rightarrow 0$), а в цикличната игра „камък-ножица-хартия“ стратегиите непрекъснато се сменят (0.07-0.29), докато популацията следва кръга от контрастратегии. Дали разнообразието ще се запази, зависи от структурата на играта.

Транзитивните игри *унищожават* разнообразието (има една най-добра стратегия и всички се сближават към нея), а цикличните игри го *налагат* (най-добра стратегия няма, затова популацията непрекъснато се променя). Лигата в Ледюк е близо до транзитивния край - затова разнообразието ѝ е ниско и затова ползите от разнообразието, описани за AlphaStar, където по време на обучението са създадени близо 900 различни агента, не се проявяват в този мащаб.¹

10.7 EGTA - оценка на популацията и неочаквано откритие

Последният инструмент е **емпиричният теоретико-игрови анализ (EGTA)**: цели агенти (стратегии за цялата игра) се разглеждат като „чисти стратегии“ на игра от по-високо ниво, всяка двойка агенти се изиграва, за да се попълни емпиричната матрица на печалбите, намира се **мета-Наш** сместа на тази матрица и тя се оценява. Така експлоатируемостта се пренася на ниво популация: търси се равновесие на Наш на игра, чиито „атоми“ са цели стратегии.

EGTA = равновесие на Наш на игра, чиито „стратегии“ са цели агенти – експлоатируемостта, пренесена на ниво популация.



Фигура 8: Процесът на EGTA: всяка двойка агенти се изиграва, за да се построи емпирична матрица на печалбите, намира се мета-Наш сместа, тя се свежда до една поведенческа стратегия и се измерва ТОЧНАТА ѝ експлоатируемост в пълната игра. Измерената уговорка: мета-Наш минимизира съжалението в мета-играта, а не експлоатируемостта в пълната игра, затова сместа може да е по-експлоатируема от най-добрия член на популацията, който дори може да не участва в нея.

Очакването (от първоначалния план) беше, че **мета-Наш** сместа на **лигата** ще бъде *по-малко* експлоатируема от всеки отделен член. Измерено:

Таблица 6: Експлоатируемост на мета-Наш сместа спрямо най-добрия отделен агент, по конфигурация.

Конфигурация	експлоатируемост на мета-Наш сместа	най-добър отделен агент	мета-Наш $\leq$ най-добрия?
Бърза проверка	2.665	2.665	да (цялото тегло е върху най-добрия агент)
Пълен мащаб	3.418	1.305	не

Съпоставка (запазена прогноза $\rightarrow$ какво всъщност се случи). Очаквах **мета-Наш сместа** да бъде поне толкова **неексплоатируема**, колкото най-добрият член на популацията. Бързата проверка го потвърди тривиално: **мета-Наш** даде *цялото* тегло на единствения най-добър агент, така че сместа = най-добрия = 2.665. При пълния мащаб **мета-Наш** разпределя теглото (0.645 върху един агент и по-малки тегла върху още два), а сместа, сведена до една поведенческа стратегия, има експлоатируемост 3.418 - **по-висока** от тази на най-добрата отделна моментна снимка (1.305). Това не е грешка в смесването: същият код дава смес = най-добрия при бързата проверка, а сместа е по-малко експлоатируема от всеки от трите си компонента (3.558, 3.932 и 4.262). Причината е в целта: **мета-Наш** минимизира **съжалението в мета-играта** - тоест доколко добре се представя *срещу популацията* - а това е *различна цел* от минимизирането на **експлоатируемостта в пълната игра**. Затова най-малко експлоатируемите агенти получиха тегло нула. Изводът е обратен на очакването: като резултат от лигата трябва да се използва избран член, **устойчив срещу най-добър отговор**, а не **мета-Наш сместа**.


Как се представя **лигата** спрямо останалите методи по показателя за **експлоатируемост** в **Ледюк**?

Таблица 7: Експлоатируемост в Ледюк (NashConv) по метод; при самообучението са дадени и крайният агент, и най-добрата итерация.

Метод (пълен мащаб)	Експлоатируемост (NashConv)
CFR, равновесие на Наш (долна граница)	0.0099
Лига - най-добър отделен агент (за цялото обучение)	1.305
Самообучение - най-добра итерация (епоха 100)	1.396
PSRO (точен оракул за най-добър отговор)	2.163

Метод (пълнен мащаб)	Експлоатируемост (NashConv)
Лига - мета-Наш смес	3.418
Самообучение - краен агент	3.683

Най-добрият отделен агент на лигата (1.305, най-добрата моментна снимка за цялото обучение) е най-добрият резултат сред методите, основани на обучение, но предимството му трябва да се чете внимателно: PSRO достига 2.163, а при самообучението най-добрата итерация е 1.396 (епоха 100) и едва накрая се влошава до 3.683. Всички тези методи остават далеч над долната граница, зададена от CFR. Мета-Наш сместа на лигата (3.418) е по-добра от крайния агент на самообучението, но по-лоша от PSRO и от най-добрия отделен агент (вж. съпоставката по-горе). Затова като резултат от лигата трябва да се използва избран отделен агент, а не сместа.³



Фигура 9: Експлоатируемост (NashConv) в Ледюк по методи (пълнен мащаб): долна граница CFR (равновесие на Наш) ~0.01; най-добрият отделен агент на лигата (1.31, най-добрият за цялото обучение) е сравним с най-добрата итерация на самообучението (1.40) и е под PSRO (2.16), под мета-Наш сместа на лигата (3.42) и под крайния агент от самообучението (3.68).

10.8 Честни бележки, ограничения и предаване на щафетата

Какво се потвърди. Основните резултати се потвърдиха: репликаторната динамика възпроизвежда всеки аналитичен резултат за матричните игри (ESS или равновесие на Наш), включително затворената орбита при „камък-ножица-хартия“, която не се сближава⁷; разлагането на Ходж ясно отделя умението от цикличността и правилно определя чистите случаи; лигата постига бързо

ранно подобрене и дава отделен агент с експлоатируемост 1.305 - по-добър от PSRO (2.163) и сравним с най-добрата итерация на самообучението (1.396); а EGTA дава работеща мярка за експлоатируемост на ниво популация. Заедно те проследяват пътя от „в кои игри една популация изобщо може да се установи?“ до „какво се случва, когато една популация сама се обучава?“.

Какво не се получи и защо това има значение. Три уговорки остават валидни и за следващите глави. (1) При пълен мащаб експлоатируемостта на лигата **нараства отново в края на обучението** ($4.73 \rightarrow \approx 1.21 \rightarrow \approx 2.05$) - лигата не се подобрява монотонно, а най-добрите агенти са замразени моментни снимки. (2) При пълен мащаб **мета-Наш сместа е по-експлоатируема от най-добрия член на популацията** (3.42 срещу 1.31), защото не му дава никакво тегло - изборът на мета-Наш не гарантира устойчивост, затова като резултат трябва да се използва избран отделен агент, а не сместа. (3) Мета-играта на Ледюк е **циклична като популация от най-добри отговори**, но **транзитивна като популация от моментни снимки** - структурата е свойство на начина, по който е изградена популацията. И един методологичен извод: късната регресия и слабостта на сместа не се виждат при бързата проверка - пълният мащаб разкрива това, което бързата проверка скрива.

Доверие. Всяка еволюционна цел е *аналитична* (ESS или равновесие на Наш на матричните игри), а всяка стойност на експлоатируемостта в лигата е *точният* NashConv от Глава 7, изчислен върху таблично извлечените стратегии - така игровитеоретичните резултати са проверени спрямо точни стойности. Невронните резултати идват от едно изпълнение на PBT за всяка конфигурация: надеждни са *посоките* (ранно подобрене; най-добрата моментна снимка < PSRO < крайния агент на самообучението; късна регресия; мета-Наш сместа > най-добрия член на популацията), а не точните стойности до третия десетичен знак. Графиките с експериментални резултати са построени от съхранените в проекта JSON файлове с резултати, а концептуалните диаграми - от скриптовете `make_*_figure.py`.

Връзки с предходните и следващите глави. С предходните: лигата е асинхронен вариант на PSRO от Глава 9 с невронни оракули и изцяло използва точния най-добър отговор от Глава 7; „мета-Наш на популация“ е равновесието на Наш от Глава 2, пренесено едно ниво по-горе. Със следващите: основните експлоататори на практика са автоматизирани модели на противника (Принос №1); EGTA/мета-Наш е методологията за оценяване (Принос №3); а липсващата гаранция на лигата - тя може да се влоши и сместа ѝ може да е експлоатируема - е популационната форма на **липсващата опора за безопасност при $N > 2$ играчи** (Принос №2). Транзитивната/цикличната диагностика предсказва, че коалиционните игри всеки срещу всеки от Глава 11 ще бъдат силно циклични, така че наивното PBT там ще зацikli.

10.9 Основни изводи за синтеза на дисертацията

- **Структурата определя сходимостта.** Транзитивното/цикличното съотношение („пумпал“) е *диагностика преди обучението*: транзитивните игри се установяват (и потискат разнообраз-

разието), цикличните игри се въртят (и налагат разнообразие). Измерено транзитивно съотношение: „камък-ножица-хартия“ 0.0, стълбица на уменията 1.0, PSRO в Ледюк ≈ 0.45 (циклична), моментни снимки на лигата $\approx 0.94-0.98$ (транзитивна).

- **Лигата произвежда силни отделни агенти, но не носи гаранция.** Най-добрата моментна снимка (1.305) е по-добра от PSRO (2.163) и сравнима с най-добрата итерация на самообучението (1.396) - и двете при едно изпълнение; въпреки това експлоатируемостта *нараства отново* към края ($\rightarrow 2.05$), а мета-Наш *сместа* (3.42) е по-лоша от най-добрия член на популацията (1.31).
- **Мета-Наш оптимизира съжалението в мета-играта, а не експлоатируемостта в пълната игра** - двете не съвпадат, затова при оценката на популацията експлоатируемостта на сместа трябва да се измерва пряко, а като резултат да се използва избран отделен агент.
- **Точната оценка е опората.** Извличането на невронните стратегии в табличен вид и оценяването им с точния най-добър отговор от Глава 7 прави всяко твърдение за популацията проверимо спрямо точни стойности - със същия NashConv като в Глава 2.
- **Липсата на гаранция за безопасност на ниво популация е отворен проблем (Принос №2):** механизмът с експлоататори в лигата на AlphaStar е аналог на ниво популация на безопасната експлоатация от Глава 8, но е евристичен: устойчивостта му е показана само емпирично¹, а в малката лига от тази глава той не осигури нито монотонно подобрене, нито неексплоатируема смес.