

Стъпка 10 Обобщение — Обучение на базата на популации и Еволюционна теория на игрите

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Съдържание

10 Стъпка 10 — Обучение, базирано на популации и еволюционна теория на игрите	1
10.1 1. Защо популации — и защо структурата определя всичко	2
10.2 2. Семейството от методи	2
10.3 3. Репликаторна динамика — равновесия на популацията	3
10.4 4. Въртящият се пумпал — транзитивна спрямо циклична структура	5
10.5 5. Лигата AlphaStar-style PBT	7
10.6 6. Разнообразие — наистина ли популацията е разнообразна?	9
10.7 7. EGTA — оценка на популацията и неочаквано откритие	12
10.8 8. Честни бележки, ограничения и предаване на щафетата	13
10.9 Основни изводи за синтеза на дисертацията	15

10 Стъпка 10 — Обучение, базирано на популации и еволюционна теория на игрите

Това е цялостна глава за обучение и оценка на **популации** от агенти: еволюционната математика, която определя дали дадена популация изобщо може да се установи в равновесие, транзитивната/циклична структура, която решава дали процесът на самообучение ще се сближи или ще се завърти, и малка **лига** в стил alphaStar, изградена върху решима покер игра. Тя има две цели — да послужи като самостоятелно обобщение за следващите стъпки и като основен източник на приносите на тезата на популационно ниво. Написана е така, че да може да се чете независимо от останалите глави. **Всички експериментални резултати, представени тук, са получени** от възпроизводими изпълнения и, когато е възможно, са ограничени от *точни* референции (аналитично равновесие на Еволюционно стабилни стратегии/Наш за матричните игри; точната експлоатируемост по най-добър отговор от Стъпка 07 за ледюк). Когато дадено изпълнение противоречи на очакванията, произтичащи от теорията, запазвам първоначалното теоретично предвиждане и го съпоставям с получените резултати — именно тези разминавания са най-показателните части от стъпката.

Къде се вписва това в тезата. Стъпки 2–8 решават *една* фиксирана игра; Стъпка 9 добавя *втори* обучаем. Стъпка 10 преминава към *цяла популация*, която се обучава срещу себе си. Тя носи три основни приноса на тезата. **Основни експлоатори** са автоматизирани моделиращи съперника — повдигането на популационно

ниво на статичния прочит от Стъпка 7 (Принос №1). **AlphaStar League** е механизъм за безопасно използване на популационно ниво, но чиято гаранция *липсва* — точното място, където се съдържа Принос №2. А **EGTA / мета-Наш** е методологията за оценяване на популацията (Принос №3).

10.1 1. Защо популации — и защо структурата определя всичко

Самообучението има известен **режим на отказ**: играч, който тренира единствено срещу самия себе си, може да се върти в кръг. Ако играта е **камък-ножица-хартия**, „да станеш по-добър“ няма смисъл — камък побеждава ножица, губи от хартия и подобряването срещу един противник просто те прави по-лош срещу друг. Най-важната идея в тази стъпка е, че игрите имат два вида структура, смесени заедно: **транзитивна** част (истинска **скала на уменията** — съществува *по-добър играч*) и **циклична** част (**колело от броячи** — има само *какво побеждава какво*). Дали една **самообучаваща се популация** ще се сближи до нещо добро или ще се върти вечно, зависи от това *коя част е доминираща*, а не от **скоростта на обучение**.

Една представа, която да запомните: **доджо**. **Основните** ученици са това, което се опитвате да създадете. Поддържате зала, пълна с **спаринг партньори**, чиято единствена задача е да откриват и наказват конкретна слабост в настоящите ученици (експлоататори). И поддържате **музей на минали шампиони** — замразени „снимки“ — така че никой да не печели, като забрави как да победи стар стил. Обучението тогава представлява цикъл: учениците спарингуват, силните се копират и леко мутират (**обучение, базирано на популации**), а периодично копие на всички се замразява в музея. Лигата е това доджо, превърнато в математическа форма.

Прочетете повече: Balduzzi, D. и др. (2019). „Open-ended Learning in Symmetric Zero-sum Games.“ *ICML* — геометрията на пумпала на транзитивната спрямо цикличната структура; и Jaderberg, M. и др. (2017). „Population Based Training of Neural Networks.“ *arXiv:1711.09846*.

10.2 2. Семейството от методи

Всеки от разгледаните методи представлява различен начин за превръщане на **популацията** в тренировъчен сигнал или средство за оценка.

Подход	Какво прави	Кога да се използва	Основна слабост
Самообучение	обучава последната политика срещу (копие на) самата себе си	транзитивни игри; бърза базова линия	цикли / забравя в циклични игри; последната итерация не се сближава

Подход	Какво прави	Кога да се използва	Основна слабост
PSRO	популация + мета-Наш + предсказвач за най-добър отговор; добавя най-добрия отговор, повтаря	състезателни игри; търси се игровитеоретична цел	пълен най-добър отговор на рунд; <i>смесването</i> не е решението (виж §7)
PBT	обучава много агенти; копира по-приспособените (експлоатация) + променя хиперпараметри (изследване)	всяка популация; онлайн търсене на хиперпараметри	може да намали разнообразието или да регресира (виж §5)
AlphaStar League	PBT с три типа агенти (основен / експлоататор на основния / експлоататор на лигата) + замразяване + PFSP	нетранзитивни игри, където наивното самообучение циклира	много агенти, голямо изчислително усилие; евристика, без гаранция за безопасност

Два инструмента за оценка ги пресичат. **Репликаторната динамика** (§3) е непрекъснатата идеализация на подбора — тя показва къде една популация *тече* и къде може да *почине*. **Декомпозицията „пумпал“** (§4) измерва доколко една игра (или популация) е транзитивна или циклична. Заедно те представляват диагностика, която предсказва, *преди* да бъде използвана изчислителната мощност, дали лигата в §5 ще се установи или ще се завърти.

Исторически линията е следната: обучение, базирано на популации като онлайн търсене на хиперпараметри (PBT, 2017) → теория на игрите върху популация от стратегии (PSRO, 2017) → геометрията, която обяснява *защо* е необходима популация („пумпал“, 2019) → и пълната тритипна лига, която победи професионални човешки играчи (AlphaStar, 2019), оценена с емпирична теория на игрите (EGTA, Tuyls и др., 2020).


10.3 3. Репликаторна динамика — равновесия на популацията

Репликаторното уравнение е най-простият модел на подбора: делът на дадена стратегия нараства пропорционално на това колко тя превъзхожда средната за популацията.

$$\dot{x}_i = x_i [f_i(x) - \bar{f}(x)], \quad \bar{f}(x) = \sum_j x_j f_j(x).$$

Точките на покой съвпадат точно с равновесията на Наш; *стабилните* точки на покой са **еволюционно**

стабилни стратегии (ESS) — смесени стратегии, които, след като бъдат възприети от цялата популация, не могат да бъдат изместени от малък дял мутанти. Това представлява непрекъснатото идеализиране на това, което една PBT лига прави дискретно: копиране на по-добрите агенти (подбор) и тяхното смущаване (мутация).



Фигура 1: Evolutionary game theory as the continuous idealization of a PBT league: replicator selection $\leftrightarrow$ copying the fitter agents, mutation/drift $\leftrightarrow$ perturbing learning rate and entropy, and replicator rest points $\leftrightarrow$ the meta-Nash / ESS the league is trying to reach. The league is replicator dynamics with learned agents instead of fixed strategy shares.

Изпълнен върху четири канонични симетрични игри (с детерминистична динамика, поради което резултатът е недвусмислен), измерените резултати съвпадат напълно с теорията:

Игра	Аналитична референция	Измерено крайно състояние	Сходим?
Дилемата на затворника	Дефект доминира; ESS (0, 1)	[0.0, 1.0]	да
Ястреб-гълъб	вътрешно ESS $p(\text{Hawk}) = V/C = 0.5$	[0.5, 0.5] (орбитален радиус 0.0)	да
Камък-ножица-хартия	Наш равновесие = равномерно; няма ESS	орбитира около центъра с радиус 0.095	не

Игра	Аналитична референция	Измерено крайно състояние	Сходим?
Лов на елен	две чисти ESS (басейнозависими)	$[0.8, 0.2] \rightarrow [1, 0]$; $[0.2, 0.8] \rightarrow [0, 1]$	да

Дилемата на затворника се свежда до доминиращата стратегия; ястреб-гълъб *достига* вътрешната 0.5 ESS; ловът на елен избира различно чисто ESS в зависимост от басейна, в който попада началната точка. **Камък-ножица-хартия никога не се сближава** — неговата вътрешна неподвижна точка е *център*, така че популацията обикаля около нея завинаги. Този последен ред е цялата мотивация за останалата част от стъпката: цикличната игра няма стабилна популация.


Прочетете още: Hofbauer, J. & Sigmund, K. (1998). *Evolutionary Games and Population Dynamics* (Cambridge) — репликаторна динамика, ESS и центърът на RPS; както и обзорът на Bloembergen–Tuyls (JAIR, 2015), който свързва репликаторната динамика с многоагентното обучение.

10.4 4. Въртящият се пумпал — транзитивна спрямо циклична структура


Ако цикличните игри са проблемът, необходимо е да *измерим* степента им на цикличност. **Декомпозицията на пумпала** (Balduzzi и др.) разделя матрицата на печалбата на една игра на **транзитивен** компонент (скала на уменията, изразена чрез оценки за всяка стратегия) и **цикличен** компонент (това, което остава — частта камък-ножица-хартия). Името произлиза от формата: реалните игри са най-широки (най-циклични) сред посредствените стратегии и се стесняват до точка (чисто транзитивни) в крайностите на уменията.

Една тънко̀ст, която си струва да се отбележи: първоначалната стъпка предполагаше **sVD rank-1** декомпозиция, която неправилно съобщава за ≈ 0.707 транзитивно съотношение на **камък-ножица-хартия** — едно **антисиметрично приближение** с ранг 1 просто не може да представи чист цикъл. Внедряването използва вместо това **комбинаторния-Ходж** (разлика в оценките) метод, който правилно определя транзитивното съотношение на RPS като 0.0. Измерено:

Популация	Транзитивен (Ходж)	Цикличен	Структура
камък-ножица-хартия	0.0	1.0	чисто цикличен
чиста скала на уменията	1.0	0.0	чисто транзитивен
PSRO-ледюк най-добър отговор мета-игра	0.41–0.46	0.89–0.91	предимно цикличен (27 трицикли)
Лига моментна снимка мета-игра	0.94–0.98	—	предимно транзитивен



Фигура 2: Replicator phase portraits: Prisoner's Dilemma → all-Defect, Hawk-Dove → the 0.5 interior ESS, Rock-Paper-Scissors → a closed orbit that never converges, and Stag Hunt → two basins (all-Stag or all-Hare). The non-converging RPS orbit is why populations in cyclic games need explicit machinery to avoid spinning.




same game, different populations: a best-response population (PSRO) sits in the wide cyclic belly; a training-snapshot population (league) climbs the transitive spine.

Фигура 3: The spinning top: a vertical transitive axis (skill — there is a better player) and a cyclic dimension (width — the number of counters, rock-paper-scissors structure). Rock-Paper-Scissors sits in the widest cyclic belly (transitive ratio 0.0); a pure skill ladder sits on the transitive spine (1.0); the PSRO-Leduc best-response meta-game sits in the wide cyclic belly (~0.45 transitive), while the league's snapshot meta-game climbs the transitive spine (~0.94-0.98).

Двете *реални* популации са основният извод — и те си противоречат в рамките на една и съща игра.

Reconciliation (kept prediction → what actually happened). I framed poker as a skill ladder and expected Leduc’s meta-game to be mostly transitive. Measured, it depends entirely on *which population you decompose*. A population of **best responses** (PSRO) is mostly **cyclic** (≈ 0.45 transitive, 27 three-cycles): the best response beats the current mixture, a newer best response beats *that*, and so on — Balduzzi’s spinning-top in action. A population of **моментни снимки на траекториите на обучение** (the league) is mostly **transitive** (≈ 0.94 - 0.98), because later snapshots are usually stronger than earlier ones, forming a ladder. Neither is a bug; the transitive/cyclic ratio is a property of the *population*, and choosing how you build the population is choosing whether you see a wheel or a ladder.



Фигура 4: Transitive ratio across four populations: RPS (0.0, purely cyclic), a pure skill ladder (1.0), the PSRO-Leduc best-response meta-game (~ 0.41 - 0.46 , mostly cyclic), and the league snapshot meta-game (~ 0.94 - 0.98 , mostly transitive). Same game, opposite structure, depending on how the population is built.


Прочетете повече: Balduzzi, D. и др. (2019). „Open-ended Learning in Symmetric Zero-sum Games“. *ICML*; и Czarnecki, W. M. и др. (2020). „Real World Games Look Like Spinning Tops“. *NeurIPS*.

10.5 5. Лигата AlphaStar-style PBT

С помощта на диагнозата изграждаме доджото. Лигата обучава **невронни** PPO агенти на **Leduc Холдем** с три типа агенти: **основни** агенти (продуктът; те играят срещу всички чрез PFSP самообучение), **основни**

експлоатъори (търсят слабости в *текущите* основни) и **експлоатъори в лигата** (търсят слабости навсякъде в *замразената история*). Обучението, базирано на популации, копира най-добрите агенти (експлоатация) и променя тяхната **скорост на обучение / ентропия** (изследване); периодически се добавя **замразена моментна снимка** на всеки агент в музея; **PFSP** съдвояването избира всеки противник с вероятност, която нараства според това колко е трудно да бъде победен. От решаващо значение е всяка **невронна мрежа** да бъде извлечена до **таблична** стратегия, така че **точният** най-добър отговор на Стъпка 07 да измерва нейната експлоатируемост — същият NashConv, използван още от Стъпка 2.

PFSP matchmaking: sample each opponent with probability rising in how hard it is to beat (focus training where you are losing).



measured: main exploitability falls 4.73 -> ~1.21 then regresses to ~2.05 (scale, 120 epochs); best frozen snapshot 1.31 beats PSRO 2.16 and self-play 3.68.

Фигура 5: The league: main agents (the product), main exploiters (hunt weaknesses in the current mains), and league exploiters (hunt weaknesses in the frozen history), with periodic freezing into a snapshot museum and PFSP matchmaking that focuses training where the agent is losing. PBT copies the top agents and perturbs their hyperparameters.

Измерва ли се подобрение? Оценено върху две конфигурации (smoke: 7 агента, 15 епохи; мащаб: 8 агента, 120 епохи, 48 замразени моментни снимки):

Метрика	Smoke	Машаб
минимална експлоатируемост при основен отговор	4.67 → 3.04 (завършва на мин)	4.73 → мин ≈ 1.21 → 2.05
експлоатируемост на мета-Наш равновесие	4.73 → 3.04	5.01 → мин ≈ 1.32 (плато 1.60) → 2.96
финален ЕЛО (активни агенти)	1176–1211	1198–1210

Метрика	Smoke	Мащаб
---------	-------	-------

Съгласуване (kept prediction → what actually happened). I predicted a *monotone* decrease in експлоатируемост. Smoke’s 15 epochs oblige — a clean drop that ends at its minimum. But scale’s 120 epochs tell the real story: exploitability falls steeply to a minimum near epoch 60 (минимална експлоатируемост при основен отговор ≈ 1.21 , мета-Наш равновесие bottoming ≈ 1.32 then holding a ≈ 1.60 plateau), and then **regresses** back up to ≈ 2.05 / ≈ 2.96 by epoch 119. The best agents are the *frozen snapshots* from mid-run; the *live* основни агенти се влошават късно, преследвайки своите експлоататори (churn / частично забравяне). This is only visible once training is long enough — a непрекъсната лига is not a monotonically improving one. The remedy (untested here) is съхраняване на най-добрия модел / population регуляризация. Methodologically it echoes Step 9: **scale reveals what smoke hides.**

10.6 6. Разнообразие — наистина ли популацията е разнообразна?


Лигата е толкова добра, колкото и *разнообразието* от стратегии, които съдържа. Измерваме три показателя: **ефективен размер на популацията** (коефициентът на участие на мета-Наш теглата), **поведенческо групиране** (политиките наистина ли са различни?) и **покрытие на експлоатация**. Резултатите показват, че популацията е само слабо разнообразна: коефициентът на участие се увеличава от 1.0 (smoke) до 1.9 (scale), но поведенческото групиране свежда всичко до **един клъстер** и при двата мащаба — дори при scale, където максималното поведенческо разстояние между двойки (0.48) надвишава прага за клъстеризация (0.30), методът на единична връзка обединява веригата. Разнообразието тук е *на ниво тегло* (мета-Наш разпределя подкрепата върху няколко агента), а не *на поведенческо ниво* (агентите играят почти идентично).

Механизмът се проявява най-ясно в опростена среда — мини-PBT върху матрични игри:


Игра	Разнообразие през поколенията
Дилемата на затворника (транзитивен)	колабира до 0 (всички → дефект)
Камък-ножица-хартия (цикличен)	върти се безкрайно (0.07–0.29), никога не се установява

Транзитивните игри *убиват* разнообразието (съществува един най-добър отговор и всички стратегии се сближават към него), докато цикличните игри го *поддържат* (няма един най-добър отговор, поради което популацията продължава да се променя). Лигата ледюк е близка до транзитивния край, което е и причината за ниското ѝ разнообразие — както и защо ползите от разнообразието на alphaStar, докладвани при приблизително 600 агента, не се проявяват в този мащаб.

Прочетете повече: Vinyals, O. и др. (2019). “Ниво на гросмайстор в StarCraft II с помощта на многоагентно обучение с подкрепление.” *Nature* (alphaStar; лигата и PFSP).



Фигура 6: League exploitability over 120 epochs (scale): both min-main and meta-Nash exploitability fall to a minimum near epoch 60 and then regress upward. The frozen snapshots capture the strong mid-run agents; the live agents degrade late under exploiter pressure.




Фигура 7: Mini-PBT diversity: on the transitive Prisoner's Dilemma the population collapses to a single strategy (diversity $\rightarrow 0$), while on cyclic Rock-Paper-Scissors it churns indefinitely (0.07-0.29) as it chases the wheel of counters. Game structure, not population size, decides whether diversity survives.

10.7 7. EGTA — оценка на популацията и неочаквано откритие

Последният инструмент е **емпиричен игровотеоретичен анализ (EGTA)**: разглеждат се цялостните политики като „стратегии“ в по-висша игра, изиграва се всяка двойка с цел попълване на емпирична матрица на печалбата, намисля се нейната **мета-Наш** смес и тя се оценява. Това представлява измерване на експлоатируемостта на ниво популация — наш равновесие в игра, чиито атоми са политики.

EGTA = Nash of a game whose 'strategies' are whole policies -- the population lift of exploitability.



Фигура 8: The EGTA pipeline: play every pair of agents to build an empirical payoff matrix, solve its meta-Nash mixture, collapse the mixture to a single behavioral policy, and measure its EXACT full-game exploitability. The measured caveat: the meta-Nash minimizes meta-game regret, not full-game exploitability, so the mixture can be more exploitable than the best single member.

Очакването (от контролния списък на суровата стъпка) беше, че **мета-Наш** равновесието в **лигата** ще бъде *по-малко* експлоатируемо от всеки отделен член. Измерено:

Конфигурация	експлоатируемост на мета-Наш равновесие	най-добър индивид	мета-Наш ≤ най-добър?
Smoke	2.665	2.665	да (цялото тегло е върху най-добрия агент)
Scale	3.418	1.305	не

Съгласуване (запазена прогноза → какво всъщност се случи). Очаквах **мета-Наш** смес да бъде поне толкова **неексплоатируема**, колкото нейният най-добър елемент. Smoke го потвърди тривиално — **мета-Наш** постави *цялото* тегло върху единствения най-добър агент, така че мета

= най-добър = 2.665. При мащаб **мета-Наш** разпределя тегло (0.645 върху един агент плюс опашка), а колапсираната **поведенческа смес** отбелязва 3.418 — **по-лошо** от най-добрата единична моментна снимка (1.305). Това не е грешка в смесването (същият кодов път даде мета = най-добър в smoke). **Мета-Наш** минимизира **мета-игрово съжаление** — справяне добре *срещу популацията* — което е *различна цел* от минимизирането на **пълна експлоатируемост на играта**; и реализационно претеглена смес от поведенчески политики може да бъде *по-експлоатируема* от своите компоненти, защото блендът въвежда „разкриващи“ информационни множества, които най-добрият отговорчик наказва. Изводът се обръща: това, което една **лига** трябва да *изпрати*, е избран, **най-добър устойчив на отговор елемент** — а не **мета-Наш смес**.

Как се представя **лигата** спрямо останалите методи по показателя за **експлоатируемост в ледюк**?

Метод (мащаб)	Крайна експлоатируемост
cFR-Nash (прагът)	0.0099
Лига — най-добър индивид	1.305
PSRO (точен предсказвач за най-добър отговор)	2.163
Самообучение	3.683
Лига — мета-Наш смес	3.418


Най-добрият индивид от **лигата** е най-силният научен резултат — надминавайки точния PSRO и самообучението — въпреки че всички научени методи остават далеч над долната граница на Наш. Сместа от **лигата** е най-слабата, дори по-лоша от самообучението (съгласуване в §7). Изпратете индивида, а не сместа.

Прочетете повече: Lanctot, M. и др. (2017). „Унифициран игровотеоретичен подход към обучението с подкрепление на множество агенти.“ *NeurIPS* (PSRO); и Tuyls, K. и др. (2020). „Граници и динамика за емпиричен игровотеоретичен анализ.“ *AAMAS/JAAMAS* (EGTA).

10.8 8. Честни бележки, ограничения и предаване на щафетата

Какво се потвърди. Потвърденият гръбнак: репликаторната динамика възпроизвежда всяко аналитично равновесие на Еволюционно стабилни стратегии/Наш, включително неконвергиращата орбита на RPS; декомпозицията тип пумпал на Ходж чисто отделя умението от цикли и правилно обозначава чистите случаи; лигата води до силно *ранно* подобрене и създава най-добър индивид (1.305), който превъзхожда PSRO (2.163) и самообучение (3.683); а EGTA дава работеща експлоатируемост на ниво популация. Заедно те проследяват дъгата от „в кои игри една популация дори може да се установи?“ до „какво се случва, когато една популация сама се обучава?“.

Какво не се получи и защо това има значение. Три честни уговорки вървят напред. (1) Експлоатируемостта на лигата **претърпява късна регресия** в мащаб ($4.73 \rightarrow \approx 1.21 \rightarrow \approx 2.05$) — непрекъснатата лига не е монотонно подобряваща се; най-добрите агенти са замразени моментни снимки. (2) **Мета-Наш сместа е**



Фигура 9: Final Leduc exploitability by method (scale): CFR-Nash floor ~ 0.01 ; the league's best individual (1.31) beats PSRO (2.16) and self-play (3.68); the league's meta-Nash mixture (3.42) is the weakest learned result.

по-експлоатируема от своя най-добър член в мащаб (3.42 срещу 1.31) — смесването на поведенчески политики не гарантира устойчивост, затова изпратете член, а не сместа. (3) Мета-играта на ледюк е **циклична като популация на най-добри отговори**, но **транзитивна като моментна популация** — структурата е свойство на популацията, която се изгражда. И един методологичен момент: късната регресия и провалът при смесването са невидими в бързата конфигурация на дима — мащабът разкрива това, което димът скрива.

Доверие. Всяка еволюционна цел е *аналитична* (ESS/Наш равновесие на матричните игри), а всяка експлоатируемост на лигата е *точният* NashConv от стъпка 07 върху таблично извлечена политика — така че игровитеоретичните резултати са ограничени от обективната истина. Невронните резултати са едно PBT изпълнение на конфигурация: *посоките* (ранно подобрение, най-добър индивид $<$ PSRO $<$ самообучение, къс-на регресия, мета-Наш $>$ най-добър член) представляват надеждните твърдения, а не величините с третия десетичен знак. Експерименталните PNG изображения по-горе са генерирани от ангажираните JSON artifacts (виж `../figures/README.md`); концептуалните диаграми са създадени от скриптовете `make_*_figure.py`.

Обратни и бъдещи връзки. Обратно: лигата е асинхронизиран вариант на PSRO от стъпка 9, използващ невронни оракули, и тя изцяло възприема точния най-добър отговор от стъпка 07; „мета-Наш на популация“ представлява Наш от стъпка 2, повдигнат на едно ниво. Бъдеще: основните експлоататори са автоматизирани моделиращи съперника (Принос №1); EGTA/мета-Наш е методологията за оценяване (Принос №3); а липсващата гаранция на лигата — тя може да претърпи регресия и нейната смес може да бъде експлоатируема — е популационната форма на **липсващия $N > 2$ предпазен ограничител** (Принос №2). Транзитивна-

та/циклична диагностика предсказва, че коалиционните игри от стъпка 11 ще бъдат силно циклични, така че naïve PBT там ще се държи циклично.

Отворени въпроси. Отстраняват ли съхраняването на най-добрия модел и регуляризацията на популацията късната регресия (поправка в обучението), или тя е присъща на тритипния дизайн (поправка в дизайна)? Трябва ли оценката на популацията да представя избран член, вместо мета-Наш сместа, или пък **мета-решавател с регуляризация за разнообразие**? И в основата на всичко: без минимаксна стойност за популация, какво всъщност означава „безопасно“ и може ли експлоатационният механизъм на лигата да получи гаранция, вместо да остане евристика?

10.9 Основни изводи за синтеза на дисертацията

- **Структурата определя сходимостта.** Транзитивното/цикличното (пумпал) съотношение е *диагностика при предварително обучение*: транзитивните игри се установяват (и потискат разнообразието), цикличните игри се въртят (и налагат разнообразие). Измерено: RPS 0.0 е транзитивна, скала на уменията 1.0, PSRO-Leduc ≈ 0.45 (циклична), моментни снимки на лигата $\approx 0.94\text{--}0.98$ (транзитивни).
- **Лигата произвежда силни индивиди, но не носи гаранция.** Най-добрият модел 1.305 побеждава PSRO 2.163 и самообучението 3.683 — въпреки това експлоатируемостта *регресира* късно ($\rightarrow 2.05$), а мета-Наш *сместа* (3.42) е по-лоша от най-добрия си член (1.31).
- **Мета-Наш оптимизира мета-игровото съжаление, а не пълната експлоатируемост на играта** — двете не съвпадат, така че оценката на популацията трябва директно да оценява колапсиралата смес и да изпраща избран член.
- **Точната оценка е котва.** Извличането на невронни политики в табличен вид и оценяването им с точния най-добър отговор от Стъпка 07 прави всяко твърдение за популацията проверено на място — същият NashConv от Стъпка 2.
- **Разликата в безопасността за населението е отворената врата (Принос №2):** експлоатационният механизъм на AlphaStar е аналогът на популацията на безопасната експлоатация от Стъпка 8, но той е евристичен — нито гарантира монотонно подобрене, нито неексплоатируема смес.