

Глава 12 Обобщение - Модели на последователности и агенти с голям езиков модел в стратегически среди

Изследване върху възможностите за прилагане на изкуствен интелект в компютърните игри

Alexander Andreev

July 2026

Съдържание

12 Глава 12 - Модели на последователности и агенти с голям езиков модел в стратегически среди	1
12.1 Защо да се разглежда обучението с подкрепление като прогнозиране на последователност	1
12.2 Капанът между късмета и умението	2
12.3 ARDT - обуславяне по гарантираната възвръщаемост	2
12.4 Какво всъщност прави обуславянето по възвръщаемостта в покера	4
12.5 Езикови модели като стратегически агенти	5
12.6 Експлоатация, адаптация и ограниченията на опростената игра	8
12.7 Основни изводи за синтеза на дисертацията	9

12 Глава 12 - Модели на последователности и агенти с голям езиков модел в стратегически среди

12.1 Защо да се разглежда обучението с подкрепление като прогнозиране на последователност

Класическото обучение с подкрепление оптимизира, като оценява функцията на стойността, разпространява наградите назад (белманово обновяване) и подобрява стратегията. Decision Transformer (DT, „трансформър за вземане на решения“; Chen и др., 2021) предлага друг подход: разглежда целия проблем като **моделиране на последователности чрез обучение с учител**. На модел от типа GPT се подава траектория от тройки

$$(\hat{R}_1, s_1, a_1, \hat{R}_2, s_2, a_2, \dots)$$

където $\hat{R}_t = \sum_{t' \geq t} r_{t'}$ е *остатъчната възвръщаемост* (return-to-go), а моделът се обучава да предсказва a_t въз основа на всичко, случващо се до s_t . Не се използва оператор на Белман и не се извършва стъпка за подобряване на стратегията. При използването на модела той просто се **обулавя**:

задава се желана висока остатъчна възвръщаемост и моделът генерира действията, които в данните са предшестваха такива възвръщаемости.

За дисертацията подходът е привлекателен, защото работи изцяло **офлайн** - върху фиксиран набор от записани данни, както е случаят с историите на реални игри, при които самообучението не е възможно.¹

12.2 Капанът между късмета и умението

Преформулирането прикрива едно предположение: че остатъчната възвръщаемост е нещо, което агентът *е заслужил*. В стохастична среда това не е вярно. Paster и др. (2022) показват, че стратегиите, обусловени от възвръщаемостта, систематично преследват късмета, а най-простият пример го прави очевидно.

Разгледайте едностъпкова задача с два възможни избора (двурък бандит). Действие А изплаща 0.5 детерминистично, а действие В изплаща 1.0 с вероятност 0.4 и 0 в останалите случаи, така че очакваната му стойност е $\mathbb{E}[B] = 0.4 < 0.5$. Действие А е оптимално по очаквана стойност. Единственият начин обаче една траектория да постигне възвръщаемост от 1.0 е чрез избор на действие В и получаване на късмет. Ако обусловим по „възвръщаемост = 1.0“, ще получим единствено траектории с действие В:

$$P(a = B \mid \hat{R} = 1.0) = 1.00 \quad (\text{измерено в собствена симулация})$$

Обучаваният модел, обусловен по възвръщаемостта, уверено избира действието с по-ниска очаквана стойност. Това не е грешка в модела, а самата същност на обуславянето по изхода, когато изходът отчасти зависи от случайността.²

12.3 ARDT - обуславяне по гарантираната възвръщаемост

Решението е да се обуславя не по възвръщаемостта, която *се е случила*, а по възвръщаемостта, която агентът може да си гарантира срещу противник в най-лошия случай - минимаксната остатъчна възвръщаемост. ARDT (Tang и др., 2024) я оценява чрез **регресия с експектили**, която минимизира асиметричната квадратична загуба

$$L_{\text{ER}}^{\alpha}(u) = \mathbb{E}_u[|\alpha - \mathbf{1}(u > 0)| \cdot u^2]$$

чиито граници дават необходимите оператори: $\alpha \rightarrow 0$ възстановява **минимума**, а $\alpha \rightarrow 1$ - **максимума**. Траекториите се преетикетират с оценената минимаксна възвръщаемост и върху тях се обучава стандартен DT.


¹Chen et al., *Decision Transformer: Reinforcement Learning via Sequence Modeling*, NeurIPS 2021 (arXiv:2106.01345).

²Paster, McIlraith & Ba, *You Can't Count on Luck: Why Decision Transformers and RvS Fail in Stochastic Environments*, NeurIPS 2022 (arXiv:2205.15967).

Два детайла от публикувания метод са съществени; и двата са проверени в самата статия, а не само в резюмето ѝ. Първо, песимистичната страна съответства на **ниско** α (в първоначалния план на главата $\tau = 0.9$ погрешно е описано като песимистично); самата статия използва $\alpha = 0.01$. Второ - и по-важно - целевата стойност при преетикетирането е

$$\tilde{R}_t = \tilde{Q}_\nu(s_t, a_t)$$

стойност на двойката **състояние-действие**, получена от два *свързани* оценителя, които се напасват редуващо се със загуби α и $1 - \alpha$. Стойност на състояние $V(s)$ не може да различи „това състояние е лошо“ от „това действие в това състояние е лошо“, а точно на това разграничение се основава методът.



Фигура 1: Експлоатируемост на ARDT в зависимост от параметъра τ на експектилната регресия; по втората ос - средната целева стойност при преетикетирането. Средни стойности от три начални числа (за сравнение: стандартен DT - 0.731, равновесие - 0.017 жетона).

Измерена върху **Кун** с умишлено опростен заместител, който отчита само състоянието, целевата стойност при преетикетирането се изменя монотонно с τ , както изисква теорията - но експлоатируемостта е *най-ниска* от оптимистичната страна. Най-вероятната причина е, че действието липсва като аргумент на оценката; вариант с $\tilde{Q}(s, a)$ още не е изпълнен, така че резултатът нито


опровергава, нито потвърждава ARDT.³

12.4 Какво всъщност прави обуславянето по възвръщаемостта в покера

Равновесието и експлоатируемостта на **Кун покер** могат да бъдат изчислени точно (вж. глава 2),⁴ поради което въпросът може да бъде решен, а не само обсъждан. Резултатът е, че обуславянето по възвръщаемостта **променя** стратегията съществено, но не я **насочва**: експлоатируемостта остава почти една и съща в целия диапазон на реално постижимите целеви стойности, с изключение на рязък скок (до ≈ 1.9 жетона) при една конкретна стойност - най-честата печалба, която в Кун е печалбата при пас.

На същите данни обикновеното поведенческо клониране достига експлоатируемост 0.055 жетона - близо до равновесието (0.016) - срещу 0.799 за DT: обуславянето по възвръщаемостта активно унищожава информация (стойността за DT варира между повторни обучения, 0.67–0.80).

Естественото обяснение е, че в игра само с четири възможни стойности на печалбата *големината* на възвръщаемостта кодира коя последователност от залози е изиграна, а *знакът* ѝ - кой е държал по-добрата карта. Следователно обуславянето избира хода на раздаването, а не качеството на играта.



Фигура 2: Резултат на DT в Ледюк Холдем (жетони на раздаване срещу почти равновесен противник) според целевата възвръщаемост, по която е обусловен, със стандартни грешки (Пирсън $r = +0.062$). Прекъснатата линия: най-честата възвръщаемост (-1); точкова: недостижима цел (+15).

³Tang, X., Marques, A., Kamalaruban, P. & Bogunovic, I., *Adversarially Robust Decision Transformer*, NeurIPS 2024 (arXiv:2407.18414) - Section 3 и Algorithm 1.

⁴Kuhn, H. W. (1950). "A Simplified Two-Person Poker." In H. W. Kuhn & A. W. Tucker (Eds.), *Contributions to the Theory of Games*, Vol. I (Annals of Mathematics Studies 24), pp. 97–103. Princeton University Press. DOI 10.1515/9781400881727-010.

Ледюк Холдем тества това обяснение с петнадесет стойности на печалбата вместо четири, два рунда на залагане и обща карта. **Спадът при най-честата възвръщаемост изчезва, както предвижда обяснението, но насочване пак не се наблюдава** (Пирсън $r = +0.062$); остават обаче два необяснени спада - при 0 (втората по честота възвръщаемост) и при -5 . Следователно обяснението чрез малкия брой възможни печалби обяснява срива, но не и провала. Провалът е по-фундаментален: в игра с нулева сума и непълна информация реализираната възвръщаемост се определя основно от тайната карта и действията на опонента, които агентът не контролира. Колкото и да са възможните стойности на печалбата, сигнал, който агентът не контролира, не става управляем.

Това е основният извод на главата: при обучение върху записани партии DT, обусловен по възвръщаемостта, е неподходящ инструмент, а предимството на преетикетирането при ARDT е, че заменя целева стойност, която агентът не контролира, с такава, която зависи главно от собствените му действия.


12.5 Езикови модели като стратегически агенти

Втората парадигма изцяло пропуска обучението: опишете правилата на английски и оставете езиков модел да играе. Тествани са три модела с отворени тегла, изпълнявани локално (LM Studio 0.4.20 на RTX 5090, температура 0.7; квантизацията на теглата не е записана): gpt-oss-20b, Qwen2.5-7B-Instruct и OpenThinker3-7B (Qwen2.5-7B-Instruct, дообучен за разсъждения). Ако не е посочено друго, резултатите по-долу са за Qwen2.5-7B-Instruct; всички числа са от собствени измервания. Сходни експерименти в Кун, Ледюк и лимитен холдем показват, че и по-големи модели не се доближават до равновесна игра, а действията им често се разминават със заявените разсъждения⁵; подкана с изрично разсъждение за противника позволява на GPT-4 да адаптира играта си.⁶ Измерени със същия точен критерий, големите езикови модели се оказват **действително експлоатируеми**, но по-интересно е *къде* грешат.

Те разбират правилно **ранга** на ръцете, но грешат в **честотите** на смесените стратегии. Всеки от тестваните реални модели залага за стойност с поп с вероятност 1.00, докато изчисленото с CFR равновесие смесва с 0.68, и при обикновена подкана нито един не блъфира с вале в извадка от 24 опита на информационно множество. (В Кун равновесието на първия играч образуват еднопараметрично семейство - блъф с вале с вероятност $\alpha \in [0, 1/3]$ и залог с поп с вероятност 3α ,⁴ така че поотделно и двете поведения са равновесни; неравновесна е само комбинацията им.) Модел със 7 млрд. параметъра (Qwen2.5-7B) се представя наравно с gpt-oss-20b - модел със смес от експерти с 21 млрд. параметъра общо, но само 3.6 млрд. активни при всеки токен; при три модела и една опростена игра това не позволява извод за ролята на мащаба.


⁵Lin, M., Dai, E., Liu, H. et al., *How Far Are LLMs from Professional Poker Players? Revisiting Game-Theoretic Reasoning with Agentic Tool Use*, ICLR 2026 (arXiv:2602.00528).

⁶Guo, J., Yang, B., Yoo, P., Lin, B. Y., Iwasawa, Y. & Matsuo, Y., *Suspicion-Agent: Playing Imperfect Information Games with Theory of Mind Aware GPT-4*, 2023 (arXiv:2309.17277).



Фигура 3: Дял на всяко информационно множество в общата експлоатируемост на Qwen2.5-7B-Instruct в Кун покер (0.357 жетона) и отклонението му от равновесието на Наш (1/2/3 - вале/дама/поп; p - пас, b - залог в историята). Двете подредби почти не си съответстват.


Разлагането на загубата по решение обръща очевидното тълкуване. „Провалът“ с поп - най-голямото видимо отклонение от равновесието - носи само **0.1%** от общата загуба, защото прекомерното залагане с ръка, която никога не е по-слаба, почти не струва нищо. Едно-единствено решение с дама струва **41.4%**. Големината на отклонението и цената му почти не са корелирани - конкретен аргумент при оценяването да се отчита диагностика по отделни решения, а не само едно число за експлоатируемост.



Фигура 4: Заявени (при запитване) и реално изиграни честоти на залагане на gpt-oss-20b и Qwen2.5-7B-Instruct по информационни множества, с равновесието за сравнение (горе; средно абсолютно отклонение от равновесието, заявени срещу изиграни: 0.43 срещу 0.33 и 0.35 срещу 0.25), и експлоатируемост на изиграната стратегия и на стратегия, построена от заявените честоти (долу).

Питането на модел какво възнамерява е *по-лошо* от измерването на това, което прави. Оценени като стратегии, заявените от тези модели честоти са 2.6 и 4.0 пъти по-експлоатируеми в сравнение със стратегиите, които те реално играят. Един модел отговаря „50%“ почти навсякъде, а другият - „почти 0%“ почти навсякъде, включително и когато държи най-силната ръка. Поведенческото проучване тук не е просто по-удобно от самоанализа - то е по-точно (собствено измерване).


12.6 Експлоатация, адаптация и ограничения на опростената игра



Фигура 5: Печалба срещу всеки противник от набора: Qwen2.5-7B-Instruct печели средно 0.177 жетона на раздаване (равновесието - 0.110) при експлоатируемост 0.357 жетона (равновесието - 0.006).

Мерките за експлоатируемост показват доколко съвършен противник ви наказва; те не казват нищо за това колко добре вие сами наказвате слабостите. Измерено спрямо набор от умишлено експлоатируеми архетипи, езиковият модел (Qwen2.5-7B-Instruct) **печели средно 0.177 жетона на раздаване срещу 0.110 за равновесната игра (с 61% повече), но експлоатируемостта му е 0.357 жетона срещу 0.006** - и близо 90% от предимството идва от пасивния и случайния противник. Срещу двата най-компетентни архетипа той се представя *по-зле* от равновесието. Това е компромисът между безопасност и експлоатация, с който се занимава вторият принос на дисертацията - тук наблюдаван, а не предположен.

Когато историята на сесията (последните 20 раздавания) е подадена в контекста, моделът (Qwen2.5-7B-Instruct) **не** се адаптира: срещу тривиално пасивен противник той улавя 83% от наличната експлоатация още в първата половина на сесията и не се подобрява във втората (0.824 срещу 0.827); при другите два противника резултатът не е статистически надежден. Това, което изглежда като моделиране на противника, всъщност е фиксирано априорно убеждение, благоприятстващо разпуснатото-агресивна игра. Когато обаче типът на противника е *описан* в подканата, моделите променят честотата на блъфиране с до 0.92 - липсва изводът от историята, а не способността да се реагира на описание.



Фигура 6: Склонност към недопустими действия в Ледюк Холдем (Qwen2.5-7B-Instruct) по категории и по ситуации (средно 0.234 от вероятностната маса в 220 информационни множества): почти цялата маса е отказ от ръката, когато чекът е безплатен, във втория рунд на залагане.

Накрая опростената игра ласкае тези модели. С един рунд на залагане и една обща карта повече големият езиков модел вече е статистически неразличим от DT, губи средно срещу набора от слаби противници (печели само срещу двата пасивни типа) и насочва приблизително една четвърт от вероятностната си маса към недопустими действия. Този провал се дължи на *едно* погрешно схващане, а не на обща обърканост: моделът иска **да се откаже от ръката, когато може безплатно да направи чек**, почти изключително със слаби ръце без чифт при висока обща карта, и нито веднъж не се опитва да повиши над лимита за залагане. Всеки оптимизъм, произтичащ от опростената игра, трябва да се възприема като свойство на самата опростена игра.

12.7 Основни изводи за синтеза на дисертацията

- **Обулавянето по величина, която агентът контролира само отчасти, не насочва поведението му.** Наблюдавано е в две опростени игри и съответства на теорема 2.1 на Paster и др.; затова за записани покер партии по-обещаващо е преетикетирането на ARDT, а не самият DT - при условие че се отчетат и случайните ходове (раздаването на картите), при които минимаксната цел на ARDT вече не е точна.⁷
- **Публикуваният ARDT преетикетира със стойност на двойката състояние-действие.**

⁷Tang, X., Cheng, Z. & Kumar, S., *Robust Adversarial Reinforcement Learning in Stochastic Games via Sequence Modeling*, Reliable ML Workshop @ NeurIPS 2025 (arXiv:2510.11877) - метод CART; отбелязва, че минимаксната цел на ARDT е точна само при детерминирани преходи.

Възпроизвеждането на ползата от метода най-вероятно изисква $\tilde{Q}(s, a)$, а не $V(s)$ - това е следващата стъпка, която още предстои да се провери.

- **Скаларна оценка класира методите, но не ги диагностицира.** Едно решение носи 41.4% от загубата, докато най-забележимото отклонение носи 0.1%.
- **Измервайте поведението, а не самоотчета.** Вербализираната стратегия е съществено по-лоша от изиграната стратегия за всеки тестван модел.
- **Моделът не изведе противника от историята в контекста** (един модел със 7 млрд. параметъра, прозорец от 20 раздавания), но реагира, когато типът на противника му е съобщен; затова моделът на противника трябва да се изгради изрично и резултатът му да се подава на стратегията - пряко свързано с първия принос на дисертацията.
- **Протоколът за измерване е част от резултата.** При алчно декодиране (температура 0) езиковият модел играе чиста стратегия и всяка измерена честота дегенерира до 0 или 1; четири отделни открития в тази глава се оказаха измервателни артефакти, всеки от които беше открит чрез евтина проверка спрямо точно изчисливо количество.